

Fortgeschrittene mathematische Methoden in der Statistik

Skript zur Vorlesung

Fabian Scheipl

Institut für Statistik, LMU München

Version: 3. Oktober 2026

(Druckfassung ohne die interaktiven Elemente der Web-Ausgabe.)

Inhaltsverzeichnis

1	Worum geht's?	1
1.1	Worum geht es in diesem Skript?	1
1.2	Landkarte des Skripts	4
2	Algorithmen & Komplexität	7
2.1	Numerische Probleme und Algorithmen	7
2.2	Algorithmen konkret: Fibonacci und Verwandte	11
2.3	Aufwand und Komplexität	14
2.4	Landau-Symbole und Rechenregeln	18
2.5	Fibonacci: Komplexitätsanalyse	22
2.6	Übungsempfehlungen	27
3	Spur & Matrixnormen	29
3.1	Die Spur einer Matrix	29
3.2	Matrixnormen: Definition und Beispiele	34
3.3	Operatornormen	38
3.4	Schattennormen	44
3.5	Eigenschaften von Matrixnormen	48
3.6	Zusammenfassung	55
3.7	Übungsempfehlungen	58
4	Fehler, Kondition & Stabilität	59
4.1	Fehlermaße und Fehlerzerlegung	59
4.2	Kondition	64
4.3	Stabilität von Algorithmen	69
4.4	Zusammenfassung	75
4.5	Übungsempfehlungen	76
5	Lineare Gleichungssysteme	79

5.1 Numerische lineare Algebra: Grundlagen	79
5.2 Lineare Gleichungssysteme	81
5.3 Die LU-Zerlegung	85
5.4 Die Cholesky-Zerlegung	92
5.5 Zusammenfassung	98
5.6 Übungsempfehlungen	99
6 Die Singulärwertzerlegung	101
6.1 Motivation	101
6.2 Singulärwerte und Singulärvektoren	105
6.3 Reduzierte SVD und Pseudoinverse	115
6.4 Anwendungen	124
6.5 Zusammenfassung	132
6.6 Übungsempfehlungen	135
7 Kleinste Quadrate	137
7.1 Kleinste Quadrate: Problem und Motivation	137
7.2 Kondition des Kleinste-Quadrate-Problems	143
7.3 Normalengleichungen und Cholesky-Zerlegung	147
7.4 QR-Zerlegung und Gram-Schmidt-Verfahren	152
7.5 Konstruktion von Q: Givens-Rotationen und Householder-Spiegelungen	157
7.6 Pseudoinverse, SVD-Lösung und Methodenvergleich	165
7.7 Übungsempfehlungen	169
8 Numerische Lineare Algebra: Iteration & Zufall	171
8.1 Eigenwertprobleme: Potenzmethode und QR-Iteration	171
8.2 Anwendungen: PageRank, PCA und approximative SVD	183
8.3 Iterative Löser für lineare Gleichungssysteme	186
8.4 Probabilistische Methoden: Matrix-Sketching	194
8.5 Zusammenfassung	203
8.6 Übungsempfehlungen	205
9 Tensoren & Tensorprodukte	207
9.1 Multilineare Abbildungen	207
9.2 Tensoren	211

9.3	Produkte von Tensoren	217
9.4	Tensorprodukt von Vektorräumen	227
9.5	Zusammenfassung	234
10	Differentialrechnung	239
10.1	Ableitung als lineare Approximation	239
10.2	Der Gradient: Vektor zu Skalar	245
10.3	Die Jacobimatrix: Vektor zu Vektor	252
10.4	Ableitungen mit Matrizen	261
10.5	Stetigkeit und Linearität	270
10.6	Produkt- und Kettenregel	276
10.7	Ableitungen höheren Grades	286
10.8	Taylorapproximation	297
10.9	Zusammenfassung	307
10.10	Übungsempfehlungen	312
11	Konvexität	315
11.1	Konvexkombinationen und konvexe Hülle	315
11.2	Konvexe Mengen	321
11.3	Projektion und konvexe Funktionen	331
11.4	Eigenschaften konvexer Funktionen	341
11.5	Konvexe Optimierung und Zusammenfassung	352
11.6	Übungsempfehlungen	360
12	Nichtlineare Gleichungen & Optimierung	361
12.1	Nichtlineare Gleichungen	361
12.2	Optimalität und Sattelpunkte	372
12.3	Nelder-Mead und Gradientenabstieg	380
12.4	Newton, Quasi-Newton und SGD	392
12.5	Beschränkte Optimierung	404
12.6	Optimierung in R und Zusammenfassung	410
12.7	Übungsempfehlungen	414
13	Funktionsapproximation	417
13.1	Approximation, Interpolation, Glättung	417

13.2 Interpolation durch Basisdarstellung	422
13.3 Polynominterpolation	428
13.4 Splines und B-Splines	436
13.5 Minimale Krümmung	446
13.6 Approximationsfehler	452
13.7 Glättung und Regression	458
13.8 Bias-Varianz und Modellwahl	466
13.9 Multivariat und Zusammenfassung	474
13.10 Übungsempfehlungen	483

Worum geht's?

1.1 Worum geht es in diesem Skript?

Statistik ist heute, wie das maschinelle Lernen, Rechnerarbeit: Jedes Modell, das wir fitten, und jede Prognose, die wir berechnen, entsteht durch einen Algorithmus auf einem Rechner. In diesem Skript lernen wir die mathematischen Konzepte, mit denen wir solche Algorithmen entwickeln, verstehen und beurteilen können. Die Leitfrage lautet: *Wie berechnen wir das schnell, speichersparend und zuverlässig?*

Warum Numerik?

Ein Beispiel zeigt, warum die Formeln aus den Statistik-Vorlesungen allein nicht reichen. Wir wollen ein lineares Regressionsmodell mit $p = 10\,000$ Merkmalen auf $n = 100\,000$ Beobachtungen trainieren, also das Kleinste-Quadrate-Problem

$$\min_{\beta \in \mathbb{R}^p} \|\mathbf{X}\beta - \mathbf{y}\|_2^2$$

lösen. Hat $\mathbf{X}$ vollen Spaltenrang, liefert die Theorie die Formel $\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$. Wer sie wörtlich in den Rechner tippt, bekommt drei Probleme. Das erste ist die *Kondition*: Die Matrix $\mathbf{X}^\top \mathbf{X}$ kann so empfindlich sein, dass winzige Rundungsfehler das Ergebnis komplett verfälschen. Das zweite ist die *Komplexität*: Das Invertieren kostet $O(p^3)$ Rechenoperationen, für $p = 10\,000$ rund 10^{12} Gleitkommaoperationen. Das dritte ist der *Speicher*: $\mathbf{X}^\top \mathbf{X}$ ist eine $p \times p$ -Matrix und belegt allein schon etwa 800 MB. Wie es besser geht (mit der QR-Zerlegung, der Singulärwertzerlegung oder iterativen Verfahren), ist der Stoff dieses Skripts.

Wie stark das erste Problem ins Gewicht fallen kann, zeigt schon ein Gleichungssystem mit zwei Unbekannten:

Beispiel 1.1.1 (Ein schlecht konditioniertes Problem)

Wir lösen $\mathbf{A}\mathbf{x} = \mathbf{b}$ mit

$$\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1,0001 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ 2,0001 \end{pmatrix}.$$

Subtrahieren wir die erste Zeile von der zweiten, bleibt $0,0001 x_2 = 0,0001$, also $x_2 = 1$ und damit $x_1 = 1$: Die exakte Lösung ist $\mathbf{x} = (1, 1)^\top$. Nun stören wir die rechte Seite minimal im zweiten Eintrag, etwa so, wie es ein Rundungsfehler täte:

$$\tilde{\mathbf{b}} = \begin{pmatrix} 2 \\ 2,0002 \end{pmatrix} \implies 0,0001 x_2 = 0,0002 \implies \tilde{\mathbf{x}} = \begin{pmatrix} 0 \\ 2 \end{pmatrix}.$$

Die Division durch 0,0001 verstärkt die winzige Störung um das Zehntausendfache: Aus $x_2 = 1$ wird $\tilde{x}_2 = 2$, aus $x_1 = 1$ wird $\tilde{x}_1 = 0$. Ein Datenfehler von 0,005 % erzeugt einen Fehler von 100 % in der Lösung. Solche Probleme heißen *schlecht konditioniert*. Die Konditionszahl misst das präzise.

Beim zweiten Problem, dem Rechenaufwand, kommt es auf den Algorithmus an:

Beispiel 1.1.2 (Komplexität der Matrixmultiplikation)

Wir multiplizieren zwei $n \times n$ -Matrizen.

Algorithmus	Rechenoperationen für $n = 1000$	Komplexität
Naive Methode	$\approx 10^9$	$O(n^3)$
Strassen	$\approx 6 \cdot 10^8$	$O(n^{2,807})$
Asymptotisch schnellere Verfahren	$\approx 2 \cdot 10^8$	$O(n^{2,373})$

Die Exponenten liegen nah beieinander, machen bei großen Matrizen aber viel aus. Für $n = 10\,000$ stehen grob 10^{12} Operationen der naiven Methode etwa $2 \cdot 10^{10}$ der schnellsten Verfahren gegenüber, ein Faktor 50. Welches Verfahren in der Praxis gewinnt, hängt allerdings auch von Konstanten und Speicherzugriffen ab. Beim Schätzen großer Modelle fallen solche Produkte ständig an.

Die drei Teile des Skripts

Der erste Teil, *Numerische Lineare Algebra*, klärt zunächst, wie empfindlich ein Problem auf Störungen reagiert (Kondition) und was einen guten Algorithmus ausmacht (Stabilität, Komplexität). Dann entwickelt er Matrixzerlegungen, mit denen wir Gleichungssysteme und KQ-Probleme $\mathbf{Ax} \approx \mathbf{b}$ zuverlässig lösen, statt naiv zu invertieren; zum Schluss kommen Tensoren dazu.

Der zweite Teil, *Analysis und Optimierung*, verallgemeinert die Ableitung auf Funktionen mit Vektor-, Matrix- und Tensor-Argumenten. Wozu? Beim Training neuronaler Netze müssen wir Verlustfunktionen wie $L(\mathbf{W}) = \frac{1}{2} \|\mathbf{XW} - \mathbf{Y}\|_F^2$ nach einer ganzen Matrix $\mathbf{W}$ ableiten. Naiv wären das so viele einzelne partielle Ableitungen, wie $\mathbf{W}$ Einträge hat, bei 1000×10 schon 10 000. Der Matrixkalkül liefert stattdessen eine einzige Zeile, $\partial L / \partial \mathbf{W} = \mathbf{X}^\top (\mathbf{XW} - \mathbf{Y})$, und die lässt sich auch effizient implementieren. Darauf baut die numerische Optimierung auf. Die Verlustfunktionen neuronaler Netze sind meist nicht konvex, hängen von sehr vielen Parametern ab (GPT-3 hat $1,75 \cdot 10^{11}$) und werden pro Schritt nur auf einem kleinen Teil der Daten ausgewertet, einem Minibatch. Minima solcher Funktionen suchen wir mit Gradientenverfahren und ihren Verwandten wie SGD.

Der dritte Teil, *Funktionsapproximation*, fragt: Wie ersetzen wir eine komplizierte Funktion durch eine einfache, mit der sich gut rechnen lässt? Das klassische Werkzeug ist die Taylor-Approximation: Schon die Näherung zweiter Ordnung um $x_0 = 0$, $e^x \approx 1 + x + \frac{x^2}{2}$, liefert bei $x = 0,5$ den Wert 1,625 statt $e^{0,5} = 1,6487 \dots$, ein relativer Fehler von unter 2 %. Später kommen flexiblere Bausteine wie Splines dazu, mit denen die Statistik glatte Funktionen aus Daten schätzt.

Welches Kapitel im Einzelnen worauf aufbaut, zeigt die Landkarte in Abschnitt 1.2.

Wie dieses Skript funktioniert

Der Haupttext deckt den Stoff der Vorlesung vollständig ab. Die gelben Boxen mit der Marke „Vertiefung · optional“ gehen darüber hinaus (weitere Beweise, Exkurse, Übersichten) und lassen sich überspringen; die ersten beiden stehen in Abschnitt 1.2.

Gepunktet unterstrichene Begriffe wie Eigenwerte öffnen Tooltips, die das nötige Vorwissen auffrischen, oft mit weiteren Links bis zu den Grundlagen. Blaue „Interaktiv“-Kästen gehören zum Haupttext; sie enthalten Widgets mit einer Aufgabe und ihrer Auswertung. Beweise lassen sich Schritt für Schritt aufdecken, jeder nichttriviale Schritt trägt seine Begründung. Die kursive Zeile „Vertiefung: ...“ am Ende eines Abschnitts nennt Literatur zum Weiterlesen.

Selbsttest: Reicht das Vorwissen?

Das Skript setzt Lineare Algebra I, Analysis I und etwas R-Programmierung voraus. Die folgenden Fragen sollten wir nach kurzem Nachdenken beantworten können. Wer hängen bleibt, klappt die Lösung auf und frischt das Thema per Tooltip auf. Für die geometrische Intuition empfehlen sich außerdem die Videos von *3blue1brown* („Essence of Linear Algebra“).

Lineare Algebra:

1. Was ist der Rang einer Matrix? Wie berechnen wir ihn?

Der Rang ist die Anzahl linear unabhängiger Spalten (gleichwertig: Zeilen), also die Dimension des Bildes der zugehörigen Abbildung. Von Hand berechnen wir ihn z. B. per Gauß-Elimination: Rang = Anzahl der Nichtnullzeilen in der Stufenform.

2. Was bedeutet es, dass eine Matrix A invertierbar ist?

Es gibt eine Matrix A^{-1} mit $AA^{-1} = A^{-1}A = I$ (Inverse). Das geht nur für quadratisches A , und zwar genau dann, wenn A vollen Rang hat. Gleichwertig: $\det(A) \neq 0$, 0 ist kein Eigenwert, und $Ax = b$ hat für jedes b genau eine Lösung.

3. Was sind Eigenwerte und Eigenvektoren? Wie finden wir sie?

Ein Eigenvektor $v \neq 0$ mit Eigenwert λ erfüllt $Av = \lambda v$: Die Matrix skaliert v nur, statt seine Richtung zu ändern. Von Hand finden wir Eigenwerte als Nullstellen des charakteristischen Polynoms $\det(A - \lambda I) = 0$; am Rechner mit numerischen Verfahren.

4. Was bedeutet das Matrix-Vektor-Produkt Ax geometrisch?

Ax wendet die lineare Abbildung A auf den Vektor x an (Matrix-Vektor-Produkt): Je nach A wird x gestreckt, gedreht, gespiegelt, geschert oder in einen Unterraum projiziert.

5. Wann bilden Vektoren $v_1, \dots, v_n$ eine Basis des $\mathbb{R}^n$? Was ist ihr Span?

Die Vektoren bilden eine Basis des $\mathbb{R}^n$, wenn sie linear unabhängig sind und den gesamten $\mathbb{R}^n$ aufspannen. Bei n Vektoren im $\mathbb{R}^n$ genügt bereits eine dieser beiden Bedingungen. Ihr Span ist die Menge aller Linearkombinationen $\alpha_1 v_1 + \dots + \alpha_n v_n$ mit $\alpha_1, \dots, \alpha_n \in \mathbb{R}$.

Analysis:

1. Was bedeutet es, dass eine Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ stetig ist?

Kleine Änderungen im Argument führen zu kleinen Änderungen im Funktionswert (Stetigkeit). Formal, in jedem Punkt x_0 : Zu jedem $\varepsilon > 0$ gibt es ein $\delta > 0$, sodass $|x - x_0| < \delta$ stets $|f(x) - f(x_0)| < \varepsilon$ erzwingt.

2. Was ist die Ableitung $f'(x_0)$ geometrisch?

Die Steigung der Tangente an den Graphen von f im Punkt x_0 , also die momentane Änderungsrate von f an dieser Stelle (Ableitung).

3. Was unterscheidet ein lokales von einem globalen Minimum?

Ein lokales Minimum x_0 erfüllt $f(x_0) \leq f(x)$ nur für alle x in einer Umgebung von x_0 ; ein globales Minimum für *alle* x im Definitionsbereich. Bei nichtkonvexen Zielfunktionen können Abstiegsverfahren an lokalen Minima oder anderen stationären Punkten enden, bei konvexen ist jedes lokale Minimum global.

Vertiefung: Heath §1 (wissenschaftliches Rechnen: Näherungen, Fehler, Kondition im Überblick); MML, Vorwort und Teil I als Panorama der Mathematik hinter dem maschinellen Lernen.

1.2 Landkarte des Skripts

Die dreizehn Kapitel dieses Skripts sind zum Lesen von vorne nach hinten gebaut, ihre Abhängigkeiten folgen dieser Reihenfolge aber nur zum Teil. Manche Kapitel sind Fundament für fast alles Spätere (die Normen aus Kapitel 3, die Fehleranalyse aus Kapitel 4), andere stützen sich auf weit zurückliegende Kapitel: Die Funktionsapproximation in Teil 3 etwa braucht aus Teil 2 wenig, aus Teil 1 dafür umso mehr.

Interaktiv: Landkarte: worauf ein Kapitel aufbaut und wohin es führt

Interaktives Element — nur in der Web-Fassung

Die Kästen sind die Kapitel in Lesereihenfolge, die Bögen Abhängigkeiten über Nachbarkapitel hinweg. Wählen wir ein Kapitel aus, hebt die Karte hervor, worauf es aufbaut und wohin es führt. Das hilft vor dem Lesen (was sollten wir parat haben?) und bei der Prüfungsvorbereitung (wofür brauchen wir das noch?).

Vertiefung (optional): Die Kapitel im Detail

Teil 1: Numerische lineare Algebra (Kapitel 2 bis 9). Kapitel 2 stellt die Sprache bereit: was ein numerisches Problem, ein Algorithmus und sein Aufwand in Landau-Notation ist. Kapitel 3 liefert die Messwerkzeuge (Spur und Matrixnormen), Kapitel 4 die zentrale Unterscheidung des Skripts: *Kondition* ist eine Eigenschaft des Problems, *Stabilität* eine Eigenschaft des Algorithmus, und nur an letzterer können wir drehen. Darauf bauen die Rechenkerne auf: Kapitel 5 löst Gleichungssysteme über Zerlegungen (LU und Cholesky) und hält sich damit an die goldene Regel, *niemals eine Matrix zu invertieren*. Kapitel 6 entwickelt mit der Singulärwertzerlegung die vielseitigste Matrixzerlegung, und Kapitel 7 vergleicht drei Lösungswege für das Kleinste-Quadrate-Problem (Normalengleichungen, QR, SVD) nach den Kriterien aus Kapitel 4. Kapitel 8 tauscht dann Exaktheit gegen Geschwindigkeit (Iteration und Zufall, von der Potenzmethode bis zum Matrix-Sketching), und Kapitel 9 baut mit Tensoren und Tensorprodukten multivariate Strukturen aus univariaten Bausteinen.

Teil 2: Analysis & Optimierung (Kapitel 10 bis 12). Kapitel 10 verallgemeinert die Ableitung nach dem Prinzip „Ableitung = lineare Approximation“ auf Vektoren und Matrizen (Gradient, Jacobi-Matrix) und baut darauf die Rechenregeln, die Hesse-Matrix und die Taylor-Entwicklung auf; nebenbei ergeben sich die Normalengleichungen aus Kapitel 7 als kurze Rechnung im Matrixkalkül. Kapitel 11 behandelt Konvexität, die Eigenschaft, die aus lokalen Verfahren globale macht: Bei konvexen Zielfunktionen ist jedes lokale Minimum bereits das globale. Kapitel 12 sortiert die Verfahren dann nach der Ordnung der verwendeten Ableitungen: Nelder-Mead (nullte), Gradientenabstieg mit Line Search und SGD (erste), Newton und Quasi-Newton (zweite), dazu Optimierung unter Nebenbedingungen. Eine feinere Karte

dieses Teils, von der Fréchet-Ableitung bis zu den KKT-Bedingungen, steht am Anfang von Kapitel 10.

Teil 3: Funktionsapproximation (Kapitel 13). Kapitel 13 überträgt zuerst die Idee der Basis aus dem $\mathbb{R}^n$ auf Funktionenräume, stellt Funktionen als Linearkombination $\hat{f} = \sum_k a_k \phi_k$ von Basisfunktionen dar (die Koeffizienten liefert wieder ein Gleichungssystem oder ein KQ-Problem) und erklärt, warum Polynominterpolation mit hohem Grad scheitern kann (Runge-Phänomen) und B-Splines funktionieren. Die zweite Hälfte des Kapitels macht daraus Statistik: Glättung verrauschter Daten als Regressionsproblem, die Bias-Varianz-Abwägung bei der Wahl der Basisgröße und der Fluch der Dimension im Multivariaten, den additive Modelle (GAMs) umgehen. Aus Teil 2 braucht dieser Teil wenig; er stützt sich vor allem auf die Kapitel 1, 4, 5, 7 und 9. Die feinere Karte dazu steht am Anfang von Kapitel 13.

Vertiefung (optional): Was sich durch das ganze Skript zieht

Vier Themen kehren im ganzen Skript wieder.

Stabilität. Die Konditionszahl gibt das Problem vor, die Stabilität wählen wir mit dem Algorithmus: Er soll Fehler nicht zusätzlich verstärken. Deshalb lösen wir mit Zerlegungen statt per Inversion, arbeiten wo immer möglich mit orthogonalen Matrizen (perfekt konditioniert, $\kappa = 1$) und führen schlecht konditionierte Teilschritte möglichst früh aus.

Rechenaufwand. Die typischen Größenordnungen: Vektoroperationen $O(n)$, Matrix-Vektor-Produkte $O(n^2)$, Matrixzerlegungen $O(n^3)$, iterative Verfahren $O(n^2 \log(1/\epsilon))$ bis zur Genauigkeit ϵ und, als Warnung, der Fluch der Dimension: $O(K^p)$ bei K Basisfunktionen je Richtung in p Dimensionen.

Matrixzerlegungen. Die Zerlegungen aus Teil 1, auf die alles Spätere zurückgreift:

Zerlegung	Form	Kapitel	typischer Einsatz
LU	$A = LU$	5	allgemeine Gleichungssysteme
Cholesky	$A = LL^T$	5	SPD-Matrizen, Simulation aus $\mathcal{N}(\mathbf{0}, \Sigma)$
QR	$A = QR$	7	Kleinste Quadrate, stabil
SVD	$A = U\Sigma V^T$	6	universell: Rang, Pseudoinverse, Approximation

Von exakt zu approximativ. Je allgemeiner die Problemklasse, desto schwächer die Garantien: Lineare Gleichungssysteme lösen wir mit Zerlegungen in endlich vielen Schritten exakt (bis auf Rundungsfehler), Kleinste-Quadrate-Probleme als Projektion. Nichtlineare Gleichungen lösen wir nur noch iterativ (Newton), allgemeine Optimierungsprobleme mit Gradientenverfahren, die lokal suchen. Erst Konvexität gibt globale Garantien zurück. Die Funktionsapproximation schließlich tauscht Genauigkeit gegen Aufwand.

Selbsttest

1. Wie viele Kapitel bauen laut der Karte direkt auf Kapitel 6 auf?

Lösung: 3

Drei ausgehende Pfeile: 7, 8 und 9.

Vertiefung: Die Referenzen des Skripts, nach Teilen sortiert. Zu Teil 1 Heath, Scientific Computing, §1–4 (und §11 für die iterativen Verfahren) sowie MML §2–4; zu Teil 2 MML §5 und §7 und Heath §5–6, für die Konvexität Boyd & Vandenberghe, Convex Optimization (frei verfügbar); zu Teil 3 Heath §7.

Algorithmen & Komplexität

2.1 Numerische Probleme und Algorithmen

Statistische Methoden sind am Ende Rechenvorschriften, die ein Computer ausführt, und Computer rechnen anders als die Mathematik auf dem Papier. Wir klären zuerst, was ein *numerisches Problem* und was ein *Algorithmus* ist, und sehen an Beispielen, dass dieselbe Formel als Rechenvorschrift gut oder unbrauchbar sein kann. Danach fragen wir, wie *teuer* ein Algorithmus ist, und vergleichen Rechenaufwand mit den Landau-Symbolen.

Verwendete Vorkenntnisse

Aus der Analysis brauchen wir Folgen, ihre Grenzwerte und die Grundidee der Konvergenz, aus der linearen Algebra Matrizen und ihre Grundoperationen, insbesondere Matrix-Vektor- und Matrixmultiplikation, samt einem ersten Gespür dafür, wie viele Einzelrechnungen darin stecken.

Numerische Probleme

Ein numerisches Problem ist eine Rechenaufgabe, deren Lösung aus einer oder mehreren Zahlen besteht. Drei typische Beispiele aus der Statistik: der Wert eines Integrals (etwa eine Wahrscheinlichkeit als Fläche unter einer Dichte), die Lösung eines linearen Gleichungssystems (etwa die Koeffizienten einer Regression) oder die Basis-Koeffizienten einer Funktionsapproximation. Allgemein fassen wir das so:

Definition 2.1.1 (Numerisches Problem)

Ein *numerisches Problem* ist eine Aufgabe der Form: *Gegeben ein Problem f mit Input $\mathbf{x}$, berechne die Lösung $f(\mathbf{x})$.*

Dabei ist f die mathematische Abbildung von den Eingabedaten auf die exakte Lösung, beim Gleichungssystem $\mathbf{A}\mathbf{y} = \mathbf{b}$ etwa $f(\mathbf{A}, \mathbf{b}) = \mathbf{A}^{-1}\mathbf{b}$. Ob und wie wir $f(\mathbf{x})$ tatsächlich ausrechnen können, ist damit noch offen.

Zwei grundsätzliche Schwierigkeiten

Computer rechnen so gut wie nie exakt. Der Grund sind zwei prinzipielle Beschränkungen jeder endlichen Maschine:

Bemerkung 2.1.2 (Grenzen des Rechnens)

- Computer können nur *endlich viele Zahlen mit endlich vielen Stellen* darstellen. Schon

$$\pi = 3,141592653589793238462643383279 \dots$$

passt in keinen endlichen Speicher. Gespeichert wird immer nur eine gerundete Näherung.

- Computer können nur *endlich viele Rechenoperationen* ausführen. Schon die Exponentialfunktion ist über eine unendliche Reihe definiert,

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!},$$

und unendlich viele Summanden kann keine Maschine aufaddieren. Jede Auswertung bricht irgendwo ab.

Deshalb kommt es darauf an, *wie* wir etwas berechnen. Was geben die folgenden vier R-Ausdrücke aus? Erst raten, dann aufdecken:

Interaktives Element — nur in der Web-Fassung

Weil der Computer nur endlich viele Zahlen darstellen kann, entstehen *Rundungsfehler* (ausführlich in Kapitel 4). Der Fehler einer einzelnen Operation ist meist vernachlässigbar klein, aber die Fehler können sich *akkumulieren*. Und weil jede Operation neu rundet, spielt sogar die *Reihenfolge* unserer Rechenschritte eine Rolle. Daraus folgt eine erste praktische Empfehlung: besonders große und besonders kleine Zahlen im selben Ausdruck vermeiden.

Zwei warnende Beispiele

Beispiel 2.1.3 (Katastrophale Auslöschung)

Wir berechnen die Varianz von $\mathbf{x}$ mit der bekannten Verschiebungsformel

$$\text{Var}(x) = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

(der Einfachheit halber mit $1/n$ statt $1/(n-1)$; am Phänomen ändert das nichts). Die Daten sind vier kleine Zahlen, verschoben um eine große Konstante:

$$\mathbf{x} = (4 + 10^9, 7 + 10^9, 13 + 10^9, 16 + 10^9).$$

Rechnen wir zunächst exakt. Der Mittelwert ist $\bar{x} = 10^9 + 10$, die Abweichungen davon sind $-6, -3, 3, 6$, also

$$\text{Var}(x) = \frac{36 + 9 + 9 + 36}{4} = \frac{90}{4} = 22,5.$$

Für die beiden Terme der Verschiebungsformel gilt exakt

$$\frac{1}{n} \sum_{i=1}^n x_i^2 = 10^{18} + 2 \cdot 10^{10} + 122,5, \quad \bar{x}^2 = 10^{18} + 2 \cdot 10^{10} + 100,$$

und die Differenz $122,5 - 100 = 22,5$ stimmt. Beide Terme sind aber riesig ($\approx 10^{18}$), und die ganze Information über die Varianz steckt in ihren letzten drei Ziffern. Bei der Größenordnung 10^{18} liegen benachbarte Gleitkommazahlen schon 128 auseinander; feiner kann die Maschine dort nicht auflösen. In R (Doppelpräzision) werden deshalb *beide* Terme auf dieselbe Maschinenzahl gerundet:

$$1\,000\,000\,020\,000\,000\,128 - 1\,000\,000\,020\,000\,000\,128 = 0.$$

Die berechnete „Varianz“ ist 0 statt 22,5. Die zweistufige Rechnung $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ liefert dagegen exakt 22,5, denn sie subtrahiert die großen Zahlen, *bevor* quadriert wird, und arbeitet danach nur noch mit den kleinen Abweichungen.

Ursache ist die Subtraktion zweier fast gleich großer Zahlen: Die übereinstimmenden führenden Ziffern heben sich weg, übrig bleiben nur die (verrauschten) hinteren Stellen. Dieses Phänomen heißt *katastrophale Auslöschung* (engl. *catastrophic cancellation*) und ist eine der häufigsten numerischen Fehlerquellen.

Beispiel 2.1.4 (Verletzte Assoziativität)

Gleitkomma-Addition ist nicht assoziativ! Seien $x = 10^{30}$, $y = -10^{30}$ und $z = 1$. Mathematisch ist $x + y + z = 1$, egal wie wir klammern. Die Maschine rechnet:

$$(x + y) + z = (10^{30} + (-10^{30})) + 1 = 0 + 1 = 1,$$

$$x + (y + z) = 10^{30} + ((-10^{30}) + 1) \stackrel{!!}{\approx} 10^{30} + (-10^{30}) = 0.$$

Die erste Klammerung ist exakt: $x + y = 0$ hebt die großen Zahlen genau auf, danach überlebt die 1 . In der zweiten Klammerung muss die Maschine $-10^{30} + 1$ als Gleitkommazahl speichern. Bei der Größenordnung 10^{30} liegen benachbarte Maschinenzahlen aber etwa 10^{14} auseinander. Die 1 ist viel kleiner als diese Auflösung, das Zwischenergebnis wird auf -10^{30} zurückgerundet, und am Ende steht 0 statt 1.

⇒ Die Reihenfolge (Klammerung) einer Summe beeinflusst das Ergebnis. Das zeigte oben schon $\text{sum}(x) - \text{sum}(\text{rev}(x))$: Vorwärts und rückwärts summiert ergeben dieselben 10^5 Zahlen verschiedene Summen.

Beide Beispiele scheitern am selben Mechanismus: An der Stelle, an der die Maschine rechnet, liegen benachbarte darstellbare Zahlen weiter auseinander als die Größe, die wir suchen. Wie weit dürfen wir die Verschiebung treiben, bis das passiert?

Interaktiv: Varianz und Klammerung bei wachsender Verschiebung

Schätzfrage. Im Rechenweg »Varianz«: bei welcher Verschiebung c verliert die Verschiebungsformel die Varianz zum ersten Mal?

Lösung: e8

Die Verschiebungsformel verliert schon bei $c = 10^8$ die erste Nachkommastelle (22 statt 22,5) und ab $c = 10^9$ jede Information; die Klammerung der Summe hält bis 10^{15} und bricht bei 10^{16} .

Die Tafel stellt die Auflösung der Maschine an der Rechenstelle (orange) neben die gesuchte Größe (grün): Solange die Auflösung kleiner ist, überlebt das Ergebnis, sonst geht es verloren.

Algorithmen

Für dieselbe Varianz gab es zwei Rechenvorschriften mit sehr verschiedenem Ergebnis. Zum numerischen Problem f gehört also eine zweite Zutat: die konkrete Rechenvorschrift, mit der wir $f(\mathbf{x})$ zu berechnen versuchen.

Definition 2.1.5 (Algorithmus)

Ein *Algorithmus* ist ein Verfahren $\tilde{f} = \tilde{f}_s \circ \dots \circ \tilde{f}_1$, das für Inputs $\mathbf{x}$ eine mögliche Lösung $\tilde{f}(\mathbf{x})$ des Problems $f(\mathbf{x})$ berechnet.

Der Algorithmus ist also eine Verkettung endlich vieler elementarer Rechenschritte $\tilde{f}_1, \dots, \tilde{f}_s$: Erst wird $\tilde{f}_1$ auf den Input angewandt, dann $\tilde{f}_2$ auf dessen Ergebnis und so weiter. Die Tilde markiert, dass $\tilde{f}$ nur ein Versuch ist, f nachzubauen; deshalb verspricht die Definition nur eine „mögliche Lösung“. Wie gut $\tilde{f}(\mathbf{x})$ die wahre Lösung $f(\mathbf{x})$ trifft, untersuchen wir in Kapitel 4. Zu einem Problem gibt es meist viele Algorithmen, und sie unterscheiden sich in Genauigkeit und Rechenaufwand.

Bemerkung 2.1.6 (Arten von Algorithmen)

Die gebräuchlichen Bezeichnungen beschreiben drei *unabhängige Achsen*:

- *exakt* ($\tilde{f}(\mathbf{x}) = f(\mathbf{x})$ bis auf Rundungsfehler) oder *approximativ* ($\tilde{f}(\mathbf{x}) \approx f(\mathbf{x})$): Trifft das Verfahren die mathematische Lösung in exakter Arithmetik, oder entsteht schon durch das Verfahren ein Approximationsfehler, wie bei einer abgebrochenen Reihe für e^x ?
- *direkt oder numerisch iterativ*: Liefert eine vorab feste, endliche Folge von Rechenschritten die Lösung, oder erzeugt das Verfahren eine Folge von Näherungen mit Abbruchkriterium? Eine Programmschleife allein macht ein Verfahren noch nicht *numerisch iterativ*; auch direkte Algorithmen können Schleifen enthalten.
- *deterministisch oder randomisiert* (probabilistisch): Ist das Ergebnis bei gleichem Input vollständig festgelegt, oder verwendet das Verfahren Zufall?

Beispiele für alle drei Achsen und ihre Kombinationen folgen in Abschnitt 2.2.4.

Selbsttest

1. Ab welchem Exponenten k liefern im Widget oben die beiden Klammerungen von $10^k + (-10^k) + 1$ verschiedene Ergebnisse?

Lösung: 16

Bei 10^{15} liegen benachbarte Maschinenzahlen 0,125 auseinander, die 1 überlebt also die Zwischensumme. Bei 10^{16} ist der Abstand bereits 2, und $-10^{16} + 1$ wird auf -10^{16} zurückgerundet (Beispiel 2.1.4).

2. Auch die zweistufige Varianzformel $\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ versagt, wenn wir die Verschiebung im Widget weit genug treiben.

Antwort: Wahr

Sie hält viel länger durch als die Verschiebungsformel und liefert bis $k = 15$ exakt 22,5. Ab $k = 16$ sind aber schon die Abweichungen $-6, -3, 3, 6$ nicht mehr darstellbar: Das Widget zeigt 20, bei $k = 17$ sogar 128 und ab $k = 18$ nur noch 0. Robuster heißt nicht immun.

3. Ein Rundungsfehler pro Operation ist meist vernachlässigbar, gefährlich ist erst das Zusammenspiel vieler Operationen.

Antwort: Wahr

Jede einzelne Rundung ist relativ winzig. Folgt aber eine Subtraktion fast gleich großer Zahlen, wird daraus ein großer relativer Fehler des Ergebnisses, wie in Beispiel 2.1.3.

Vertiefung: Heath §1.1–1.2 (wissenschaftliches Rechnen, Näherungen und Fehlerquellen); die Gleitkomma-Arithmetik hinter den Beispielen behandelt Heath §1.3.

2.2 Algorithmen konkret: Fibonacci und Verwandte

Die abstrakte Definition aus Abschnitt 2.1 spielen wir jetzt an einem Problem vollständig durch, das einfach genug ist, um jeden Schritt hinzuschreiben, und das uns durch das ganze Kapitel begleitet: den Fibonacci-Zahlen.

2.2.1 Beispiel: Fibonacci-Zahlen

Definition 2.2.1 (Fibonacci-Zahlen)

Die *Fibonacci-Zahlen* sind die Folge $(x_n)_{n \in \mathbb{N}}$ mit

$$x_1 = 0, \quad x_2 = 1, \quad x_{n+1} = x_n + x_{n-1} \quad (n \geq 2).$$

Jedes Folgenglied ist also die Summe seiner beiden Vorgänger; die Folge beginnt mit 0, 1, 1, 2, 3, 5, 8, 13, 21, ... (Manche Bücher lassen die Folge bei 1, 1 oder mit dem Index 0 beginnen; wir bleiben bei der obigen Konvention.) Unser numerisches Problem lautet: *Berechne die ersten n Fibonacci-Zahlen*. Es ist also die Abbildung f mit Input n und Lösung $f(n) = (x_1, \dots, x_n)$.

Wie berechnen wir das? Die Definition selbst gibt den Weg vor: Wir bauen den Ergebnisvektor von links nach rechts auf und gewinnen jeden neuen Eintrag durch *eine* Addition aus den beiden zuletzt berechneten:

Algorithmus 2.2.2 (Fibonacci, schleifenbasiert)

$$\tilde{f} : \mathbb{N} \rightarrow \bigcup_{n \geq 1} \mathbb{N}_0^n, \quad \tilde{f}(n) = (x_1, \dots, x_n).$$

Für $n \geq 1$ setzt der Algorithmus $x_1 = 0$, für $n \geq 2$ zusätzlich $x_2 = 1$, und führt dann aus:

```
für i = 2, ..., n-1:
    x[i+1] = x[i] + x[i-1]
gib (x[1], ..., x[n]) zurück
```

Als Komposition $\tilde{f} = \tilde{f}_n \circ \dots \circ \tilde{f}_1$ elementarer Schritte geschrieben:

$$\tilde{f}_1(n) = 0, \quad \tilde{f}_2(x) = (x, 1), \quad \tilde{f}_{i+1}(x_1, \dots, x_i) = (x_1, \dots, x_i, x_i + x_{i-1}) \quad (i \geq 2).$$

Jeder Schritt ab $\tilde{f}_3$ hängt an das bisherige Tupel die Summe aus dem **letzten** und dem **vorletzten** Element als neues Element an. Weil die Länge des Ergebnisses von n abhängt, ist der Zielraum die

Vereinigung aller $\mathbb{N}_0^n$ und kein fester Raum $\mathbb{N}_0^n$.

Beispiel 2.2.3 (Die ersten 6 Fibonacci-Zahlen)

Berechnen wir $\tilde{f}(6)$ Schritt für Schritt. Die Farben verfolgen die Rollen aus Algorithmus 2.2.2: **letztes Element**, **vorletztes Element**, **neu berechnete Summe**.

$$\begin{aligned}\tilde{f}_1(6) &= 0 \\ \tilde{f}_2(0) &= (0, 1) \\ \tilde{f}_3(0, 1) &= (0, 1, 1) \\ \tilde{f}_4(0, 1, 1) &= (0, 1, 1, 2) \\ \tilde{f}_5(0, 1, 1, 2) &= (0, 1, 1, 2, 3) \\ \tilde{f}_6(0, 1, 1, 2, 3) &= (0, 1, 1, 2, 3, 5)\end{aligned}$$

Ergebnis: $\tilde{f}(6) = (0, 1, 1, 2, 3, 5)$, vier Additionen (1, 2, 3, 5) für sechs Zahlen.

2.2.2 Vom Algorithmus zum Programm

Der Algorithmus lässt sich fast wörtlich in R übersetzen. `numeric(n)` legt einen mit Nullen gefüllten Vektor der Länge n an; damit ist $x_1 = 0$ schon erledigt:

```
fibonacci <- function(n) {
  x <- numeric(n) # Vektor (0, ..., 0) der Länge n
  if (n > 1) {
    x[2] <- 1
  }
  if (n > 2) {
    for (i in 2:(n - 1)) {
      x[i + 1] <- x[i] + x[i - 1]
    }
  }
  x
}
```

Eine Schleife, eine Addition pro Durchlauf, und jedes Zwischenergebnis wird genau einmal berechnet und dann wiederverwendet.

Interaktiv: Wie oft rechnet die Rekursion doppelt?

Dass hier *nichts doppelt* gerechnet wird, ist nicht selbstverständlich. Die Definition 2.2.1 legt einen zweiten Weg nahe: Für x_n ruft sich dieselbe Rechenvorschrift rekursiv für x_{n-1} und x_{n-2} auf, ohne Zwischenergebnisse zu speichern. Das liefert dieselben Zahlen, aber beide Teilaufrufe berechnen große Teile der Folge unabhängig voneinander noch einmal, und deren Teilaufrufe wieder. Wie oft ist „noch einmal“?

Schätzfrage. Beim Ziel x_8 : wie oft rechnet die naive Rekursion die Zahl x_3 von vorn aus?

Lösung: 8 mal

Bis x_8 kommt die Iteration mit sechs Additionen aus und hat dabei *alle* acht Zahlen berechnet; die Rekursion braucht für die *eine* Zahl x_8 schon 20 Additionen und 41 Aufrufe, weil sie x_3 achtmal und x_2 dreizehnmal von vorn ausrechnet.

Der Abstand wächst schnell: Für x_{15} allein braucht die Rekursion 609 Additionen, die Iteration für alle fünfzehn Zahlen 13. Wie schnell der Aufwand der Rekursion wächst, bestimmen wir

in Abschnitt 2.5.

2.2.3 Selbsttest

Wo liegt Algorithmus 2.2.2 auf den Achsen aus Bemerkung 2.1.6?

1. Der Algorithmus ist *exakt*.

Antwort: Wahr

Es gilt $f(n) = \tilde{f}(n)$: Der Algorithmus liefert genau die definierten Fibonacci-Zahlen, keine Näherung. Die Einschränkung „bis auf Rundungsfehler“ greift erst, wenn x_n für sehr großes n den exakt darstellbaren Ganzzahlbereich der Gleitkommazahlen verlässt.

2. Der Algorithmus ist *numerisch iterativ*.

Antwort: Falsch

Er enthält zwar eine Schleife, erzeugt aber keine Folge von Näherungen mit Abbruchkriterium: Nach einer durch n festgelegten Zahl von Schritten steht das exakte Ergebnis fest. In der numerischen Terminologie ist er daher *direkt*. Die übliche Bezeichnung „iterative Fibonacci-Variante“ meint nur die Schleife im Gegensatz zur Rekursion.

3. Der Algorithmus ist *probabilistisch*.

Antwort: Falsch

Es kommt kein Zufall vor: Der Algorithmus ist deterministisch und liefert bei jedem Aufruf mit demselben n exakt dasselbe Ergebnis.

4. Wie viele Additionen braucht die naive Rekursion im Stepper oben für die Zahl x_{10} ?

Lösung: 54

Der Zähler steht bei Ziel $n = 10$ und Schritt 10 auf 54; die Iteration kommt für dieselben zehn Zahlen mit 8 Additionen aus.

2.2.4 Algorithmenarten in ML und Statistik

Der Fibonacci-Algorithmus ist also exakt, direkt und deterministisch. Wo liegen die Verfahren, mit denen wir in Statistik und Machine Learning arbeiten?

Beispiel 2.2.4 (Algorithmenarten in ML und Statistik)

- *Exakt und direkt*: Matrixmultiplikation und Gauß-Elimination (Kapitel 5).
- *Approximativ*: Monte-Carlo-Integration, die Integrale durch Stichproben schätzt, und das Training neuronaler Netze, das nur bis zu einem Toleranzniveau optimiert.
- *Numerisch iterativ*: Gradientenabstieg und Newton-Verfahren zur Nullstellensuche.
- *Probabilistisch*: approximative Singulärwertzerlegung durch Matrix Sketching (Abschnitt 8.4) und MCMC-Verfahren der Bayes-Statistik.

Oft sind die Achsen kombiniert: Viele ML-Algorithmen, etwa das stochastische Gradientenverfahren, sind iterativ, approximativ und probabilistisch zugleich.

2.2.5 Was ist ein guter Algorithmus?

Bemerkung 2.2.5 (Eine Analogie)

Problem: *Koche Schweinsbraten wie bei Oma*. Dann entspricht der Algorithmus dem Kochrezept, und der Computer dem Koch, der sich zwar an das Rezept hält, dabei aber Fehler macht.

Für dasselbe Gericht gibt es viele Rezepte, und nicht alle sind gleich gut, so wie unsere beiden Fibonacci-Varianten dasselbe Problem zu sehr verschiedenen Kosten lösen. Ein gutes Rezept verzeiht außerdem kleine Ungenauigkeiten des Kochs, und ein gutes numerisches Verfahren verstärkt die unvermeidlichen Rundungsfehler nicht unnötig. Wir wollen also Algorithmen, die

- möglichst exakte Ergebnisse liefern,
- schnell sind,
- wenig Speicher brauchen.

Die drei Wünsche konkurrieren oft: Mehr Genauigkeit kostet meist Rechenzeit oder Speicher, und der schnellste Weg ist nicht immer der stabilste. „Schnell“ und „wenig Speicher“ machen wir in Abschnitt 2.3 messbar, „möglichst exakt“ ist das Thema von Kapitel 4.

Vertiefung: Heath §1.1 (Näherungen und Fehlerquellen im wissenschaftlichen Rechnen); Cormen, Leiserson, Rivest & Stein, Introduction to Algorithms (Entwurf und Analyse von Algorithmen).

2.3 Aufwand und Komplexität

Die beiden Fibonacci-Varianten aus Abschnitt 2.2 lösen dasselbe Problem sehr verschieden schnell. „Langsam“ ist aber kein mathematischer Begriff. Wir machen daraus eine Größe, die wir zählen können, den Aufwand, und vergleichen Aufwände dann über ihr *Skalierungsverhalten*, die Komplexität.

2.3.1 Zeit- und Speicheraufwand

Definition 2.3.1 (Zeit- und Speicheraufwand)

Ein Algorithmus werde durch elementare Operationen ausgeführt: Rechenoperationen $f_i \in \{+, -, \cdot, /\}$, aber auch Vergleiche, Zuweisungen und Speicherzugriffe, jede mit (etwa) konstantem Aufwand.

- Der *Zeitaufwand* des Algorithmus ist die Anzahl dieser elementaren Operationen. Höherer Zeitaufwand bedeutet (ungefähr) längere Laufzeit.
- Der *Speicheraufwand* ist (in etwa) die Anzahl der gespeicherten und zwischengespeicherten Zahlen. Höherer Speicheraufwand bedeutet mehr benötigten Speicherplatz.

Rechenoperationen mit Gleitkommazahlen heißen in der Numerik-Literatur auch *FLOPs* (engl. *floating point operations*). Reale Laufzeiten hängen zusätzlich von Zwischenspeichern (Caches) und Parallelisierung ab, daher das „ungefähr“ in der Definition; für den Vergleich von Algorithmen genügt das Zählen.

2.3.2 Beispiel: Matrix-Vektor-Multiplikation

Das Matrix-Vektor-Produkt $\mathbf{y} = \mathbf{Ax}$ steckt in jeder Vorhersage eines linearen Modells und in jeder Schicht eines neuronalen Netzes. Wir verfolgen die Matrix $\mathbf{A}$ in Rot, den Vektor $\mathbf{x}$ in Blau und das Ergebnis $\mathbf{y}$ in Grün.

Beispiel 2.3.2 (Matrix-Vektor-Multiplikation)

Gesucht ist $\mathbf{y} = \mathbf{Ax}$ für $\mathbf{A} \in \mathbb{R}^{3 \times 2}$, $\mathbf{x} \in \mathbb{R}^2$, konkret

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 7 \\ 8 \end{pmatrix}.$$

Jede Komponente von $\mathbf{y}$ ist das Skalarprodukt einer Zeile von $\mathbf{A}$ mit $\mathbf{x}$:

$$y_1 = 1 \cdot 7 + 2 \cdot 8 = 7 + 16 = 23 \quad (2 \text{ Mult.}, 1 \text{ Add.})$$

$$y_2 = 3 \cdot 7 + 4 \cdot 8 = 21 + 32 = 53 \quad (2 \text{ Mult.}, 1 \text{ Add.})$$

$$y_3 = 5 \cdot 7 + 6 \cdot 8 = 35 + 48 = 83 \quad (2 \text{ Mult.}, 1 \text{ Add.})$$

- *Zeitaufwand:* $3 \cdot 2 = 6$ Multiplikationen und $3 \cdot 1 = 3$ Additionen, zusammen 9 Operationen.
- *Speicheraufwand:* 6 Zahlen für $\mathbf{A}$, 2 für $\mathbf{x}$, 3 für $\mathbf{y}$, zusammen 11 Zahlen.

Das Muster aus dem Beispiel verallgemeinert sich direkt auf beliebige Dimensionen:

Satz 2.3.3 (Aufwand der Matrix-Vektor-Multiplikation)

Sei $\mathbf{A} \in \mathbb{R}^{n \times d}$ und $\mathbf{x} \in \mathbb{R}^d$. Die Berechnung von $\mathbf{y} = \mathbf{Ax}$ hat

- Zeitaufwand nd Multiplikationen + $n(d-1)$ Additionen = $n(2d-1) \approx 2nd$ Operationen,
- Speicheraufwand $nd + d + n$ Zahlen (für $\mathbf{A}$, $\mathbf{x}$ und $\mathbf{y}$).

Jede der n Komponenten $y_i = \sum_{j=1}^d a_{ij} x_j$ (in Summenschreibweise) kostet d Multiplikationen und $d-1$ Additionen; gespeichert werden die Eingaben und das Ergebnis. Als Faustregel kostet das Matrix-Vektor-Produkt also $\approx 2nd$ Operationen, je eine Multiplikation und eine Addition pro Matrixeintrag. Dieselbe Zählung gilt für die Matrix-Matrix-Multiplikation $\mathbf{C} = \mathbf{AB}$ mit $\mathbf{B} \in \mathbb{R}^{d \times m}$. Sie besteht aus m Matrix-Vektor-Produkten (eines pro Spalte von $\mathbf{B}$) und kostet $\approx 2ndm$ Operationen.

Interaktiv: FLOP-Zähler: Was kosten Matrix-Vektor- und Matrix-Matrix-Produkt?

Verdoppelt sich der Aufwand, wenn wir alle Dimensionen verdoppeln? Um diese Frage nach dem Wachstum geht es im Rest des Kapitels.

Schätzfrage. Verdoppeln wir n , d und m : um welchen Faktor wächst der Matrix-Matrix-Aufwand?

Lösung: acht

Beim Matrix-Vektor-Produkt stecken zwei Dimensionen im Produkt $2nd$, also wird der Aufwand beim Verdoppeln aller Dimensionen viermal so groß; beim Matrix-Matrix-Produkt sind es drei Dimensionen und damit der Faktor acht.

Entscheidend ist nicht die absolute Zahl, sondern die Zahl der Dimensionen im Produkt; der Speicher wächst dabei langsamer als die Rechenzeit.

Selbsttest: Operationen und Speicher zählen

Gegeben sind $A \in \mathbb{R}^{n \times d}$ und $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$, und wir wollen

$$\mathbf{z} = f(A, \mathbf{x}, \mathbf{y}) = A(\mathbf{x} - \mathbf{y}) = \sum_{i=1}^d (x_i - y_i) \mathbf{A}_i$$

berechnen, also eine Linearkombination der Spalten $\mathbf{A}_i$ von A . Der Algorithmus arbeitet die Summe spaltenweise ab:

Algorithmus 2.3.4 (Spaltenweise Auswertung)

1. Initialisiere $\mathbf{z} = \mathbf{0} \in \mathbb{R}^n$.
2. Für $i = 1, \dots, d$: berechne den Skalar $(x_i - y_i)$ und aktualisiere $\mathbf{z} \leftarrow \mathbf{z} + (x_i - y_i) \cdot \mathbf{A}_i$.

2.3.3 Komplexität: Wie skaliert der Aufwand?

Ob oben $2nd + d$, $2nd - n$ oder $2nd$ herauskommt, hängt von Zählkonventionen ab: Zählt man die Initialisierung mit, das Zwischenergebnis? Für den Vergleich von Algorithmen ist die exakte Anzahl unwichtig. Uns interessiert, *wie der Aufwand mit der Größe des Problems wächst*: Was passiert bei 10 000 statt 1000 Datenpunkten, bei 1000 statt 10 Kovariablen?

Definition 2.3.5 (Komplexität)

Wie der Zeit- bzw. Speicheraufwand eines Algorithmus mit der Größe des Problems *skaliert*, nennen wir die *Laufzeitkomplexität* bzw. *Speicherkomplexität* des Algorithmus.

Beispiel 2.3.6

Ein Algorithmus benötige $4n^3 + 16n^2 + 239$ Operationen. Für großes n ist $16n^2 + 239$ gegenüber $4n^3$ vernachlässigbar: Bei $n = 100$ steuert der kubische Term $4 \cdot 10^6$ Operationen bei, die restlichen Terme nur 160 239, rund 4 % des Gesamtaufwands. Bei $n = 1000$ sind es nur noch 0,4 %. Der Algorithmus *skaliert* also wie $4n^3$; seine Komplexität ist von *kubischer Ordnung*, und wir schreiben kurz: „ $O(n^3)$ “.

Die Schreibweise $O(n^3)$ lässt auch den Vorfaktor 4 weg; es zählt allein die *Ordnung* des Wachstums. Präzise definiert wird O in Abschnitt 2.4; bis dahin lesen wir es als „wächst höchstens wie“.

2.3.4 Komplexitätsklassen

Die wichtigsten Wachstumsordnungen haben Namen. Ein Gefühl für sie bekommen wir über die Frage: *Was passiert mit dem Aufwand, wenn sich die Problemgröße verdoppelt?*

Bemerkung 2.3.7 (Interpretation der Komplexitätsklassen)

- *Konstant*, $O(1)$: Die Anzahl der Operationen hängt nicht von n ab.
- *Logarithmisch*, $O(\log n)$: Verdoppelt sich n , kommt im Modell $c \log_2 n$ ein konstanter Aufwand hinzu, denn $\log_2(2n) = \log_2(n) + 1$ (Logarithmus).

- *Linear*, $O(n)$: Verdoppelt sich n , verdoppelt sich der führende Aufwand.
- *Quadratisch*, $O(n^2)$: Verdoppelt sich n , vervierfacht sich der führende Aufwand.
- *Exponentiell*, $O(2^n)$: Verdoppelt sich n , *quadriert* sich die Anzahl der Operationen, denn $2^{2n} = (2^n)^2$. Schon ein einziger Schritt $n \rightarrow n + 1$ *verdoppelt* den Aufwand.

Exponentielle Algorithmen sind damit schon für moderate Problemgrößen meist unbrauchbar; die naive Fibonacci-Rekursion gehört dazu (Abschnitt 2.5). In der numerischen linearen Algebra bewegen wir uns dagegen meist zwischen $O(n)$ (Vektoroperationen), $O(n^2)$ (Matrix-Vektor-Produkte, Satz 2.3.3 mit $d = n$) und $O(n^3)$ (Matrix-Zerlegungen, Matrix-Matrix-Produkte).

Wie weit die Klassen auseinanderliegen, zeigt das Bild. Auf der linearen Skala links verlässt 2^n den Bildausschnitt schon bei $n = 10$, während n und n^2 bis $n = 30$ darin bleiben. Auf der logarithmischen Skala rechts wird 2^n zu einer Geraden, und alle drei Klassen passen in ein Bild:

Interaktives Element – nur in der Web-Fassung

Bemerkung 2.3.8 (Vorsicht: Konstanten!)

Die $O(\cdot)$ -Notation ignoriert konstante Faktoren und Terme niedrigerer Ordnung. Ein Algorithmus mit $1000n + 10\,000$ Operationen ist $O(n)$, aber trotzdem *langsamer* als ein $O(n^2)$ -Algorithmus mit n^2 Operationen, solange $n^2 < 1000n + 10\,000$ gilt. Bei $n = 100$ etwa stehen 110 000 Operationen gegen nur 10 000. Die Komplexitätsklasse sagt, wer für *hinreichend große* Probleme gewinnt, nicht, wer bei *unserem konkreten* Problem gewinnt.

Selbsttest: Aufwand und Ordnung

1. Ab welchem n ist ein Algorithmus mit n^2 Operationen schneller als einer mit $1000n + 10\,000$ Operationen?

Lösung: 1010

Der Schnittpunkt liegt bei $n = 500 + \sqrt{260\,000} \approx 1009,9$. Für $n = 1009$ stehen 1 018 081 gegen 1 019 000 Operationen, für $n = 1010$ dagegen 1 020 100 gegen 1 020 000.

2. Um welchen Faktor wächst der Zeitaufwand des Matrix-Matrix-Produkts, wenn wir im FLOP-Zähler n , d und m gleichzeitig verdoppeln?

Lösung: 8

In $2ndm$ stecken drei Dimensionen, also $2^3 = 8$. Beim Matrix-Vektor-Produkt sind es nur zwei Dimensionen und damit der Faktor 4.

3. Ein $O(n)$ -Algorithmus ist für jedes n schneller als ein $O(n^2)$ -Algorithmus.

Antwort: Falsch

Die Landau-Notation ignoriert Vorfaktoren, und die können bei jeder endlichen Problemgröße den Ausschlag geben (Bemerkung 2.3.8). Die Aussage gilt nur für *hinreichend große* n .

Vertiefung: Heath §1.1 (Kosten und Genauigkeit wissenschaftlichen Rechnens); Heath §2.4.5 (Operationen zählen am Beispiel des Gauß-Verfahrens).

2.4 Landau-Symbole und Rechenregeln

Das Zählen in Abschnitt 2.3 liefert Ausdrücke wie $4n^3 + 16n^2 + 239$: exakt, aber unhandlich, und die Vorfaktoren hängen ohnehin von Maschine, Programmiersprache und Zählweise ab. Wir brauchen eine Notation, die nur das Wachstumsverhalten für große n festhält: die *Landau-Symbole* (engl. *big-O notation*).

2.4.1 Klein-o und Groß-O

Wir vergleichen den Aufwand a_n mit einer einfachen Vergleichsfolge b_n (etwa n^2 oder 2^n) über den Grenzwert des Quotienten a_n/b_n :

Definition 2.4.1 (Landau-Symbole)

Seien a_n, b_n Folgen, wobei b_n ab einem Index ungleich null ist.

- $a_n = o(b_n)$ („ a_n ist klein-o von b_n “), wenn

$$\lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0.$$

- $a_n = O(b_n)$ („ a_n ist groß-O von b_n “), wenn

$$\limsup_{n \rightarrow \infty} \left| \frac{a_n}{b_n} \right| < \infty.$$

Anschaulich heißt das:

- $a_n = o(b_n)$: a_n wächst *langsamer* als b_n ; gegenüber b_n wird a_n vernachlässigbar klein.
- $a_n = O(b_n)$: a_n wächst *höchstens so schnell* wie b_n ; die Vergleichsfolge b_n ist gegenüber a_n nicht vernachlässigbar.
- Zusätzlich schreiben wir $a_n = \Theta(b_n)$, falls $a_n = O(b_n)$ und $b_n = O(a_n)$ gilt: a_n wächst *genauso schnell* wie b_n .

Bei Groß-O steht der Limes superior statt des Grenzwerts, weil der Quotient a_n/b_n nicht konvergieren muss; er darf zum Beispiel oszillieren. Die Bedingung bedeutet: Ab irgendeinem Index gilt $|a_n| \leq C \cdot |b_n|$ für eine Konstante C .

2.4.2 Rechenbeispiele

Eine Landau-Beziehung weisen wir meist nach, indem wir den Grenzwert des Quotienten ausrechnen. In den drei Beispielen verfolgt **Rot** die untersuchte Folge a_n und **Blau** die Vergleichsfolge b_n .

Beispiel 2.4.2

(a) Wir zeigen $3n^2 + 5n = O(n^2)$:

$$\lim_{n \rightarrow \infty} \frac{3n^2 + 5n}{n^2} = \lim_{n \rightarrow \infty} \left(3 + \frac{5}{n} \right) = 3 < \infty \implies 3n^2 + 5n = O(n^2). \quad \square$$

Der Quotient konvergiert gegen 3, also ist auch sein Limes superior $3 < \infty$.

(b) Wir zeigen $5n = o(n^2)$:

$$\lim_{n \rightarrow \infty} \frac{5n}{n^2} = \lim_{n \rightarrow \infty} \frac{5}{n} = 0 \implies 5n = o(n^2). \quad \square$$

(c) Gilt $n^2 = O(n)$? Nein!

$$\lim_{n \rightarrow \infty} \frac{n^2}{n} = \lim_{n \rightarrow \infty} n = \infty \quad (\text{divergiert!}) \implies n^2 \neq O(n).$$

Der Quotient wächst über jede Schranke hinaus; n^2 wächst echt schneller als n .

Vertiefung (optional): Limes superior, Schreibweise und Theta

Bemerkung 2.4.3 (Feinheiten der Definition)

Was ist der Limes superior? Der größte Häufungswert einer Folge, gebildet als Grenzwert der Suprema der Restfolgen. Anders als der Grenzwert existiert er immer, notfalls als ∞ ; deshalb ist die Bedingung $\limsup_{n \rightarrow \infty} |a_n/b_n| < \infty$ auch für oszillierende Quotienten definiert.

Das Gleichheitszeichen ist ein Notationsmissbrauch: $a_n = O(b_n)$ liest man besser als „ a_n gehört zur Klasse $O(b_n)$ “. Insbesondere ist die Beziehung nicht symmetrisch: Aus $5n = O(n^2)$ folgt nicht $n^2 = O(5n)$.

Wozu Theta? Groß-O ist nur eine obere Schranke. „Ein $O(n^2)$ -Algorithmus“ heißt deshalb nicht, dass seine Laufzeit tatsächlich quadratisch wächst: Ein Sortierverfahren mit Laufzeit $O(n \log n)$ ist automatisch auch $O(n^2)$, weil $n \log n$ für große n höchstens so groß wie n^2 ist. Die zweite Aussage ist richtig, unterscheidet das Verfahren aber nicht von einem tatsächlich quadratischen. Θ legt die Ordnung von beiden Seiten fest. Im Skript genügt uns meist die obere Schranke O , weil sie für Laufzeit- und Fehlerabschätzungen die entscheidende Garantie liefert.

Meist suchen wir eine möglichst einfache Folge b_n mit $a_n = O(b_n)$, aber *nicht* $a_n = o(b_n)$, also eine obere Schranke, die nicht unnötig grob ist. Für $3n^2 + 5n$ ist das $b_n = n^2$; auch $b_n = n^3$ wäre eine obere Schranke, aber wegen $3n^2 + 5n = o(n^3)$ eine zu grobe.

2.4.3 Rechenregeln

Aufwandsausdrücke entstehen durch Hintereinanderausführung (Addition der Kosten) und Verschachtelung (Multiplikation der Kosten) von Algorithmus-Bausteinen. Die Landau-Symbole vertragen sich mit beiden Operationen, sodass wir die Grenzwertrechnung nicht jedes Mal neu machen müssen:

Lemma 2.4.4 (Rechenregeln für Landau-Symbole)

Seien $a_n, b_n > 0$ Vergleichsfolgen.

1. Sei $f_n = O(a_n)$ und $g_n = O(b_n)$. Dann gilt

$$f_n + g_n = O(a_n + b_n) \quad \text{und} \quad f_n \cdot g_n = O(a_n \cdot b_n).$$

2. Sei $f_n = O(a_n)$ und $g_n = o(b_n)$. Dann gilt

$$f_n \cdot g_n = o(a_n \cdot b_n).$$

3. Sei $f_n = O(a_n + b_n)$ mit $a_n = O(b_n)$. Dann gilt

$$f_n = O(b_n).$$

Die Positivität der Vergleichsfolgen setzen wir voraus, damit sich in $a_n + b_n$ nichts wegheben kann. Für Aufwandsvergleiche ist das keine Einschränkung, denn Operationenzahlen sind positiv.

Vertiefung (optional): Warum die Rechenregeln gelten

Beweis.

- (1) *Regel 1, Addition.* Wir schätzen den Quotienten ab:

$$\frac{|f_n + g_n|}{a_n + b_n} \leq \frac{|f_n|}{a_n + b_n} + \frac{|g_n|}{a_n + b_n} \leq \frac{|f_n|}{a_n} + \frac{|g_n|}{b_n}.$$

Dreiecksungleichung; danach verkleinern wir die Nenner ($a_n + b_n \geq a_n$ bzw. $\geq b_n$, da beide Folgen positiv sind), was die Brüche höchstens vergrößert

- (2)

$$\limsup_{n \rightarrow \infty} \frac{|f_n + g_n|}{a_n + b_n} < \infty \implies f_n + g_n = O(a_n + b_n).$$

beide Summanden haben nach Voraussetzung endlichen Limes superior, und der Limes superior einer Summe ist höchstens die Summe der Limes superiores

- (3) *Regel 1, Multiplikation, und Regel 2.* Der Quotient zerfällt in ein Produkt:

$$\frac{|f_n \cdot g_n|}{a_n \cdot b_n} = \frac{|f_n|}{a_n} \cdot \frac{|g_n|}{b_n}.$$

Betrag und Bruch faktorisieren, beide Faktoren kennen wir schon

- (4) Der erste Faktor ist beschränkt ($f_n = O(a_n)$). Ist $g_n = O(b_n)$, so ist auch der zweite Faktor beschränkt und das Produkt bleibt beschränkt: $f_n g_n = O(a_n b_n)$. Ist dagegen $g_n = o(b_n)$, so konvergiert der zweite Faktor gegen 0 und damit das ganze Produkt: $f_n g_n = o(a_n b_n)$.

das Produkt zweier beschränkter Folgen ist beschränkt; das Produkt einer beschränkten Folge mit einer Nullfolge ist eine Nullfolge

- (5) *Regel 3.* Zuerst zeigen wir $a_n + b_n = O(b_n)$:

$$\frac{a_n + b_n}{b_n} = \frac{a_n}{b_n} + 1 = O(1).$$

$a_n = O(b_n)$ macht den ersten Summanden beschränkt; die Konstante 1 ist es sowieso

- (6)

$$\frac{|f_n|}{b_n} = \frac{|f_n|}{a_n + b_n} \cdot \frac{a_n + b_n}{b_n} \implies f_n = O(b_n).$$

Produkt zweier beschränkter Folgen; das ist gerade Regel 1 (Multiplikation) mit $b_n \cdot 1$ als Vergleichsfolge

□

2.4.4 Anwendung: auf den dominanten Term reduzieren

Wieder verfolgt **Rot** die Folge f_n und **Grün** die Folge g_n .

Beispiel 2.4.5 (Addition und Multiplikation)

Gegeben seien $f_n = 3n^2 = O(n^2)$ und $g_n = 5n = O(n)$.

Addition (Regel 1, dann Regel 3):

$$f_n + g_n = 3n^2 + 5n = O(n^2 + n) = O(n^2), \quad \text{denn } n = O(n^2).$$

Multiplikation (Regel 1):

$$f_n \cdot g_n = 3n^2 \cdot 5n = 15n^3 = O(n^2 \cdot n) = O(n^3).$$

Beispiel 2.4.6 (Vereinfachung eines Aufwandsausdrucks)

Ein Algorithmus benötige $4n^3 + 16n^2 + 239$ Operationen. Rot verfolgt jetzt den am schnellsten wachsenden Term:

$$4n^3 + 16n^2 + 239 = O(n^3 + n^2 + 1) = O(n^3),$$

denn $n^2 = O(n^3)$ und $1 = O(n^3)$, zweimal Regel 3 angewandt. Dass auch der Vorfaktor 4 verschwindet, liegt an der Definition: Für jede Konstante $c > 0$ ist $\limsup_{n \rightarrow \infty} |c b_n / b_n| = c < \infty$, also $c \cdot b_n = O(b_n)$.

Wir können komplexe Aufwandsausdrücke also auf ihren dominanten Term reduzieren. Deshalb sprechen wir kurz von einem „ $O(n^3)$ -Algorithmus“. Die üblichen Komplexitätsklassen bilden dabei eine strikte Hierarchie, jede ist klein-o der nächsten:

$$\log n, \quad n, \quad n \log n, \quad n^2, \quad n^3, \quad 2^n.$$

Ab welchem n überholt ein schneller wachsender Term einen noch so großen Vorfaktor? Das zeigt der Explorer, wahlweise auf linearer oder logarithmischer Skala.

Interaktiv: Wachstumsraten-Explorer: Klassen und Vorfaktoren

Interaktives Element — nur in der Web-Fassung

Ohne Vorfaktor überholt 2^n die Kurve n^2 endgültig ab $n = 5$, mit dem Vorfaktor $c = 1000$ erst ab $n = 19$: Der Faktor 1000 verschiebt die Schwelle nur um vierzehn Schritte. Bei den polynomialen Klassen gilt $n^3 > c n^2$ ab $n > c$. Das ist die praktische Bedeutung von $c n^2 = O(n^2)$ und $n^2 = o(n^3)$: Vorfaktoren verschieben die Schwelle, die Reihenfolge drehen sie nie um.

2.4.5 Selbsttest

Welche Aussagen sind wahr? Den Quotienten bilden, dann aufklappen.

Wahr. $\lim_{n \rightarrow \infty} \frac{2n}{n^2} = \lim_{n \rightarrow \infty} \frac{2}{n} = 0 < \infty$; es gilt sogar die stärkere Aussage $2n = o(n^2)$. Die informativere obere Schranke ist $2n = O(n)$.

Wahr. Mit $b_n = 1$ ist $\lim_{n \rightarrow \infty} \frac{7/n}{1} = 0$. Landau-Symbole beschreiben also auch, wie schnell Nullfolgen abklingen; so klassifizieren wir später Approximations- und Rundungsfehler.

Falsch. $\lim_{n \rightarrow \infty} \frac{8n^3 + 7n^2 + n}{n} = \lim_{n \rightarrow \infty} (8n^2 + 7n + 1) = \infty$; der Quotient divergiert. Richtig wäre $O(n^3)$: der dominante Term entscheidet (Beispiel 2.4.6).

Wahr. $\lim_{n \rightarrow \infty} \frac{n^{-3} + n^{-2}}{n^{-2}} = \lim_{n \rightarrow \infty} \left(\frac{1}{n} + 1\right) = 1 < \infty$. ☒ Auch $n^{-3} + n^{-2} = o(1)$ wäre richtig (die Folge ist eine Nullfolge), aber $O(n^{-2})$ ist schärfer: Die Aussage sagt auch, *wie schnell* die Folge verschwindet.

1. Setzen wir im Explorer oben den Vorfaktor auf $c = 100$ und schalten $c \cdot n^2$ und 2^n an: Ab welchem n gilt endgültig $2^n > c \cdot n^2$?

Lösung: 15

Von Hand nachgerechnet: $2^{14} = 16\,384$ liegt noch unter $100 \cdot 14^2 = 19\,600$, aber $2^{15} = 32\,768$ liegt über $100 \cdot 15^2 = 22\,500$, und danach bleibt die Exponentialfunktion vorn.

2. Aus $a_n = O(b_n)$ folgt $b_n = O(a_n)$.

Antwort: Falsch

Das Gleichheitszeichen in $a_n = O(b_n)$ bezeichnet keine symmetrische Beziehung: $5n = O(n^2)$ gilt, $n^2 = O(5n)$ nicht.

3. Gilt $a_n = o(b_n)$, so gilt auch $a_n = O(b_n)$.

Antwort: Wahr

Konvergiert der Quotient gegen 0, so ist er insbesondere beschränkt: Klein-o ist die stärkere Aussage.

Vertiefung: Heath §1.1 (Aufwand und Genauigkeit numerischer Verfahren); Cormen, Leiserson, Rivest & Stein, Introduction to Algorithms, Kap. 3 (asymptotische Notation, einschließlich scharfer Schranken).

2.5 Fibonacci: Komplexitätsanalyse

Mit den Werkzeugen aus Abschnitt 2.3 und Abschnitt 2.4 machen wir jetzt präzise, wie verschieden die beiden Fibonacci-Varianten aus Abschnitt 2.2 sind. Es geht nicht um einen konstanten Faktor, sondern um *linear gegen exponentiell*.

2.5.1 Die iterative Variante: linearer Aufwand

Die iterative Variante, die R-Funktion `fibonacci` aus Abschnitt 2.2.2, legt einen Ergebnisvektor der Länge n an, setzt $x_2 = 1$ und füllt in einer Schleife jeden weiteren Eintrag als Summe seiner beiden Vorgänger: $x_{i+1} = x_i + x_{i-1}$ für $i = 2, \dots, n-1$. Wir zählen die Schritte wie beim Matrix-Vektor-Produkt.

Satz 2.5.1 (Komplexität der iterativen Variante)

Der iterative Fibonacci-Algorithmus berechnet die ersten n Fibonacci-Zahlen mit Zeitkomplexität $O(n)$ und Speicherkomplexität $O(n)$.

Beweis.

- (1) *Initialisierung: n Operationen.*

das Anlegen des Vektors schreibt n Nullen, eine Schreiboperation pro Eintrag

(2)

Schleife: $(n - 2) \cdot 3$ Operationen.

die Schleife durchläuft $i = 2, \dots, n - 1$, also $n - 2$ Durchläufe; pro Durchlauf zählen wir 1 Addition, 1 Zuweisung und 1 Indexrechnung; ob man die Indexrechnungen mitzählt, ist Konvention (Bemerkung 2.5.2)

(3)

$$a_n = n + 3(n - 2) + c = 4n + (c - 6) \implies a_n = O(n).$$

Summen- und Dominanzregel aus Abschnitt 2.4: mit $n = O(n)$ und $1 = O(n)$ ist $O(n) + O(n) + O(1) = O(n)$; die Konstante c deckt Funktionsaufruf und die beiden `if`-Abfragen ab

- (4) *Speicher: $n + O(1) = O(n)$ Speicherzellen.*

gespeichert werden der Vektor x mit n Einträgen und konstant viele Hilfsgrößen (n , Laufindex i)

□

Bemerkung 2.5.2 (Zählen ist Konvention, die Ordnung nicht)

Ob wir pro Schleifendurchlauf 3, 5 oder 10 Elementaroperationen ansetzen, ändert am Ergebnis nichts: Jede konstante Zahl von Operationen pro Durchlauf liefert einen Gesamtaufwand der Form $c_1 n + c_2$, und der ist immer $O(n)$. Die Landau-Notation macht die Analyse unabhängig von solchen Zählkonventionen. Schneller als linear geht es für dieses Problem nicht, denn schon das Hinschreiben der n Ergebniszahlen kostet n Schritte: Die iterative Variante ist ordnungsoptimal.

2.5.2 Die naive Rekursion: exponentieller Aufwand

Die zweite Variante übersetzt die Rekursionsformel wörtlich in Code: `fib_rek(n)` gibt für $n \leq 1$ direkt n zurück, ruft sich sonst für $n - 1$ und $n - 2$ selbst auf und addiert die Ergebnisse:

```
fib_rek <- function(n) {
  if (n <= 1) {
    return(n)
  }
  return(fib_rek(n - 1) + fib_rek(n - 2))
}
```

Bemerkung 2.5.3 (Was die Rekursion berechnet)

`fib_rek(n)` berechnet nur eine *einzelne* Fibonacci-Zahl F_n (mit der Zählung $F_0 = 0, F_1 = 1, F_n = F_{n-1} + F_{n-2}$), nicht den ganzen Vektor der ersten n Zahlen; in der Notation aus Abschnitt 2.2 gilt $F_n = x_{n+1}$. Das macht den Vergleich nicht unfair, im Gegenteil: Die Rekursion braucht schon für *eine* Zahl exponentiell viele Schritte, während die Iteration *alle* ersten n Zahlen in $O(n)$ liefert.

Außer den beiden rekursiven Aufrufen passiert in einem Aufruf von `fib_rek(n)` nur konstant viel (ein Vergleich, eine Addition). Als Aufwandsmaß zählen wir deshalb die *Funktionsaufrufe*:

$T(n)$ sei ihre Gesamtzahl, den Startaufruf mitgezählt. Diese Folge erbt die Fibonacci-Struktur des Algorithmus:

Lemma 2.5.4 (Rekurrenz der Aufrufzahl)

Die Aufrufzahl $T(n)$ von `fib_rek(n)` erfüllt

$$T(0) = T(1) = 1, \quad T(n) = 1 + T(n-1) + T(n-2) \quad (n \geq 2).$$

Denn für $n \leq 1$ kehrt die Funktion sofort zurück, und für $n \geq 2$ besteht der Aufrufbaum aus der Wurzel und den vollständigen Teilbäumen von `fib_rek(n-1)` und `fib_rek(n-2)`.

Beispiel 2.5.5 (Der Aufrufbaum für $n = 5$)

Der Aufruf `fib_rek(5)` erzeugt den folgenden Baum (jeder Knoten ist ein Funktionsaufruf):

Interaktives Element – nur in der Web-Fassung

Zählen wir nach: F_5 und F_4 werden je einmal berechnet, F_3 aber 2-mal, F_2 schon 3-mal, F_1 sogar 5-mal und F_0 noch 3-mal, zusammen $1 + 1 + 2 + 3 + 5 + 3 = 15$ Aufrufe. Das passt zum Lemma: Aus $T(2) = 3$ und $T(3) = 1 + 3 + 1 = 5$ folgt $T(4) = 1 + 5 + 3 = 9$ und $T(5) = 1 + 9 + 5 = 15$. $\square$

Rot markiert ist die Ursache: Der komplette Teilbaum unter `fib_rek(3)` wird zweimal durchgerechnet, weil die Rekursion keine Zwischenergebnisse aufbewahrt. Bei größerem n vervielfachen sich solche Wiederholungen. Die iterative Variante berechnet jede Zahl genau einmal.

Allgemein erzeugt jeder Aufruf bis zu 2 weitere Aufrufe, diese wieder je 2, und so fort über bis zu n Ebenen, insgesamt höchstens $1 + 2 + 4 + \dots + 2^n$ Aufrufe, also $O(2^n)$. Der folgende Satz macht das präzise und zeigt auch die Gegenrichtung: Das Wachstum ist tatsächlich exponentiell und nicht nur nach oben durch eine Exponentialfunktion beschränkt.

Satz 2.5.6 (Exponentielle Laufzeit der naiven Rekursion)

Für alle $n \geq 0$ gilt

$$(\sqrt{2})^{n-1} \leq T(n) \leq 2^{n+1} - 1.$$

Insbesondere ist $T(n) = O(2^n)$, und für jedes feste $k \in \mathbb{N}$ gilt $n^k = o(T(n))$: Die Aufrufzahl wächst exponentiell und überholt jedes Polynom. Die Speicherkomplexität ist dagegen nur $O(n)$.

Der Speicherbedarf bleibt klein, weil der Aufrufbaum nie ganz gleichzeitig gespeichert wird: „Offen“ ist immer nur der Pfad von der Wurzel zum aktuellen Aufruf, und der ist höchstens n Aufrufe lang. Der Aufruf-Stapel (call stack) braucht also $O(n)$ Speicherzellen.

Vertiefung (optional): Beweis der Schranken für die Aufrufzahl

Beweis.

- (1) *Obere Schranke*, per vollständiger Induktion: Für $n \leq 1$ gilt $T(n) \leq 2^{n+1} - 1$.

Induktionsanfang: $T(0) = T(1) = 1$ und $2^1 - 1 = 1$, $2^2 - 1 = 3$

(2)

$$T(n) = 1 + T(n-1) + T(n-2) \leq 1 + (2^n - 1) + (2^{n-1} - 1) = 2^n + 2^{n-1} - 1 \leq 2^{n+1} - 1.$$

Rekurrenz aus Lemma 2.5.4, dann Induktionsvoraussetzung für $n-1$ und $n-2$ einsetzen; zuletzt $2^n + 2^{n-1} = 3 \cdot 2^{n-1} \leq 4 \cdot 2^{n-1} = 2^{n+1}$

(3)

$$T(n) = O(2^n).$$

Definition von O aus Abschnitt 2.4: $T(n)/2^n \leq 2$ für alle n , der Limes superior ist also endlich

- (4) *Untere Schranke*: Für $n \geq 2$ ist

$$T(n) \geq T(n-1) + T(n-2) \geq 2T(n-2).$$

T ist monoton wachsend (in der Rekurrenz kommt zu $T(n-1)$ nur Positives hinzu), also $T(n-1) \geq T(n-2)$

(5)

$$T(n) \geq 2T(n-2) \geq 4T(n-4) \geq \dots \geq 2^{\lfloor n/2 \rfloor} \geq 2^{(n-1)/2} = (\sqrt{2})^{n-1}.$$

die Ungleichung $\lfloor n/2 \rfloor$ -mal anwenden; bei jedem Schritt verdoppelt sich der Faktor wie bei einer geometrischen Folge, bis das Argument 0 oder 1 erreicht (dort ist $T = 1$); schließlich $\lfloor n/2 \rfloor \geq (n-1)/2$

(6)

$$\frac{n^k}{T(n)} \leq \frac{n^k}{(\sqrt{2})^{n-1}} \rightarrow 0 \implies n^k = o(T(n)).$$

exponentiell schlägt polynomiell: Der Grenzwert $n^k/q^n \rightarrow 0$ für jedes $q > 1$ ist ein Analysis-Standardresultat, hier mit $q = \sqrt{2}$

□

Die Basis des exponentiellen Wachstums liegt damit zwischen $\sqrt{2}$ und 2. Welche es ist, zeigt eine logarithmische Auftragung der gezählten Aufrufe: Dort wird jedes exponentielle Wachstum zu einer Geraden, und deren Steigung verrät die Basis.

Interaktiv: Gezählte Schritte gegen die Landau-Vorhersage

Interaktives Element — nur in der Web-Fassung

Nur auf der logarithmischen Skala passen beide Varianten in ein gemeinsames Bild; die Iteration bleibt dort fast am Boden. Welche Basis die rote Gerade hat und woher sie kommt, rechnet die folgende Vertiefung nach.

Vertiefung (optional): Exakte Aufrufzahl und goldener Schnitt

Bemerkung 2.5.7 (Die exakte Aufrufzahl)

Zwischen der unteren Schranke (Basis $\sqrt{2} \approx 1,41$) und der oberen (Basis 2) klappt eine Lücke. Die Aufrufzahl lässt sich aber exakt angeben, und sie ist selbst fast eine Fibonacci-Zahl: Aus der Rekurrenz folgt per Induktion $T(n) = 2F_{n+1} - 1$. Der Anfang stimmt wegen $T(0) = 1 = 2F_1 - 1$ und $T(1) = 1 = 2F_2 - 1$, und der Schritt ist

$$T(n) = 1 + (2F_n - 1) + (2F_{n-1} - 1) = 2(F_n + F_{n-1}) - 1 = 2F_{n+1} - 1.$$

Die Fibonacci-Zahlen selbst wachsen wie φ^n : Nach der Binet-Formel ist $F_n = (\varphi^n - \psi^n) / \sqrt{5}$ mit dem goldenen Schnitt $\varphi = (1 + \sqrt{5}) / 2 \approx 1,618$ und $\psi = 1 - \varphi \approx -0,618$. Weil $|\psi| < 1$ ist, verschwindet der zweite Term, und es bleibt $F_{n+1} \approx \varphi^{n+1} / \sqrt{5}$, also $T(n) = O(\varphi^n)$. Der wahre Wachstumsfaktor liegt zwischen unseren Schranken; im Widget liegen die gezählten Aufrufe deshalb auf einer Geraden mit Steigung $\log_{10} \varphi \approx 0,209$, nicht auf der steileren 2^n -Geraden mit Steigung $\log_{10} 2 \approx 0,301$. Am Urteil ändert das nichts: Jede Basis $q > 1$ bedeutet, dass eine um 1 größere Eingabe den Aufwand um den Faktor q vervielfacht.

2.5.3 Der Vergleich: Ordnung schlägt Konstante

Was bedeutet linear gegen exponentiell in echten Zahlen? Wir setzen die gezählten Aufwände ein, iterativ $4n - 6$ Operationen (ohne die Konstante c aus dem Beweis von Satz 2.5.1), naiv rekursiv die exakte Aufrufzahl $T(n)$ aus Lemma 2.5.4, und rechnen als grobes Modell mit 10^9 Elementarschritten pro Sekunde. Ein realer Funktionsaufruf in R kostet deutlich mehr, das Modell ist also optimistisch:

n	iterativ ($4n - 6$)	naiv ($T(n)$)	Zeit naiv (Modell)
20	74	21 891	$\approx 22 \mu\text{s}$
30	114	2 692 537	$\approx 2,7 \text{ ms}$
50	194	$\approx 4,1 \cdot 10^{10}$	$\approx 41 \text{ s}$
100	394	$\approx 1,1 \cdot 10^{21}$	$\approx 36\,000 \text{ Jahre}$

Die iterative Variante bleibt durchgehend unter einer Mikrosekunde. Am Abstand ändert schnellere Hardware wenig: Ein tausendmal schnellerer Rechner verkürzt die 36 000 Jahre der Rekursion auf 36 Jahre. Helfen kann nur ein *besserer Algorithmus*, und die Landau-Notation drückt „besser“ präzise aus: *Die iterative Lösung liegt in einer anderen Komplexitätsklasse.*

Selbsttest

1. Die Laufzeit der iterativen Variante ist $O(n^2)$.

Antwort: Wahr

O ist nur eine *obere* Schranke: $4n - 6$ wächst höchstens so schnell wie n^2 , also gilt $O(n^2)$, wenn auch wenig informativ. Scharf ist $O(n)$; $4n - 6$ ist sogar $o(n^2)$.

2. Die naive Rekursion braucht exponentiell viel *Speicher*, weil ihr Aufrufbaum exponentiell viele Knoten hat.

Antwort: Falsch

Der Baum wird nie ganz gleichzeitig gespeichert: Auf dem Aufruf-Stapel liegt immer nur der aktive Pfad von der Wurzel zum aktuellen Aufruf, und der ist höchstens n Aufrufe lang. Die Speicherkomplexität ist also $O(n)$ (Satz 2.5.6); exponentiell ist nur die *Zeit*.

3. Zählt man pro Schleifendurchlauf 5 statt 3 Operationen, ändert sich die Zeitkomplexität der iterativen Variante nicht.

Antwort: Wahr

Konstante Faktoren und additive Konstanten verschwinden in der Landau-Notation: $n + 5(n - 2) + c = O(n)$ genauso wie $n + 3(n - 2) + c$ (Bemerkung 2.5.2). Diese Robustheit gegen Zählkonventionen ist der Zweck der Notation.

4. Aus $T(n) \geq 2T(n - 2)$ für alle $n \geq 2$ (mit $T(0), T(1) \geq 1$) folgt bereits, dass T mindestens exponentiell wächst.

Antwort: Wahr

Wiederholtes Einsetzen liefert $T(n) \geq 2^{\lfloor n/2 \rfloor} \geq (\sqrt{2})^{n-1}$, geometrisches Wachstum mit Basis $\sqrt{2} > 1$. Das ist das Argument für die untere Schranke in Satz 2.5.6.

5. Wie viele Jahre rechnet die naive Rekursion im Modell des Widgets oben bei $n = 80$?

Lösung: 2

Der Ablesekasten des Widgets nennt bei $n = 80$ rund $7,6 \cdot 10^{16}$ Aufrufe; bei 10^9 Schritten pro Sekunde sind das etwa $7,6 \cdot 10^7$ Sekunden, also gut zwei Jahre. Die Iteration braucht für dieselbe Zahl 314 Operationen.

Zusammenfassung des Kapitels

Ein *numerisches Problem* ist eine Abbildung f , die Eingabedaten x eine gesuchte Lösung $f(x)$ zuordnet; ein *Algorithmus* ist eine endliche Folge elementarer Rechenschritte, die diese Lösung exakt oder näherungsweise berechnet (Abschnitte 2.1–2.2). Gute Algorithmen kommen mit wenig Laufzeit und Speicher aus. Beides messen wir als Funktion der Problemgröße n (Abschnitt 2.3) und beschreiben es durch seine Ordnung, mit Landau-Symbolen und ihren Rechenregeln (Abschnitt 2.4). Die Fibonacci-Fallstudie zeigt, was diese Sprache leistet: Linear gegen exponentiell ist der Unterschied zwischen „sofort fertig“ und „Jahrtausende“. Als Nächstes kommen Normen als Fehlermaße hinzu (Kapitel 3); mit ihnen behandelt Kapitel 4 Rundungsfehler, Kondition und Stabilität.

Vertiefung: Heath §1.1 (*wissenschaftliches Rechnen: Probleme, Algorithmen und die Rolle des Aufwands*).

2.6 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Schaback/Wendland Aufgabe 1.10	Komplexität von Vektor- und Matrixoperationen	leicht, ca. 15 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Schaback/Wendland Aufgabe 1.11	Rechenregeln für Landau-Symbole	mittel, ca. 30 Min.
Heath Review Question 1.45	Optimale Summationsreihenfolge	mittel, ca. 15 Min.
Deuffhard/Hohmann Aufgabe 2.1	Gleitkomma-Addition ist nicht assoziativ	leicht, ca. 15 Min.

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 1.8	Signifikante Stellen und Exponentenbereich bei Auslöschung	leicht, ca. 15 Min.
Heath Exercise 1.16	Drei Definitionen der Maschinengenauigkeit $\varepsilon_{\text{mach}}$	mittel, ca. 30 Min.
Schaback/Wendland Aufgabe 1.6	Dezimal exakt, binär nie exakt	mittel, ca. 30 Min.
Schaback/Wendland Aufgabe 1.7	Basisumrechnung von $(3417)_{10}$	leicht, ca. 15 Min.

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deuffhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.).

Spur & Matrixnormen

3.1 Die Spur einer Matrix

Um Gleichungssysteme zu lösen und Fehler abzuschätzen, müssen wir Matrizen *messen* können: Wie groß ist eine Matrix, wie stark verstärkt sie Fehler, wann konvergiert ein iteratives Verfahren? Jede dieser Fragen verlangt, eine Tabelle von Zahlen zu einer Kennzahl zu verdichten. Dieses Kapitel behandelt die zwei wichtigsten: die *Spur* (dieser Abschnitt) und die *Matrixnormen* (Rest des Kapitels). Beide begegnen uns in der Statistik ständig; die Gesamtvarianz eines Zufallsvektors etwa ist die Spur seiner Kovarianzmatrix.

Bemerkung 3.1.1 (Verwendete Vorkenntnisse)

Dieses Kapitel setzt voraus:

- aus der linearen Algebra: Matrixoperationen (Addition, Multiplikation, Transposition), Eigenwerte und Eigenvektoren, Orthogonalität, Skalarprodukte sowie grundlegende Vektornormen (euklidische Norm $\|\mathbf{x}\|_2$ und p -Normen),
- aus der Analysis: Grenzwerte und Suprema, Maximum und Minimum von Funktionen.

3.1.1 Definition und erste Beispiele

Die einfachste Kennzahl einer quadratischen Matrix ist die Summe ihrer Diagonalelemente.

Definition 3.1.2 (Spur)

Die *Spur* (*trace*) einer quadratischen Matrix $A \in \mathbb{R}^{n \times n}$ ist die Summe ihrer Diagonalelemente:

$$\text{tr}(A) = \sum_{i=1}^n a_{ii}.$$

Die Spur ist *nur für quadratische Matrizen* definiert. Sie ist eine *skalare Invariante* der Matrix: Sie ändert sich nicht, wenn wir dieselbe lineare Abbildung in einer anderen Basis darstellen (Ähnlichkeitsinvarianz, Satz 3.1.4). Berechnen lässt sie sich mit $n - 1$ Additionen, ohne eine einzige Multiplikation.

Beispiel 3.1.3

Für die Einheitsmatrix stehen auf der Diagonale n Einsen, also $\text{tr}(I_n) = n$. Zwei konkrete Rechnungen (die Diagonalelemente sind grün markiert):

$$\operatorname{tr} \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = 1 + 4 = 5, \quad \operatorname{tr} \begin{pmatrix} 2 & -1 & 0 \\ 0 & 3 & 5 \\ 1 & 0 & -2 \end{pmatrix} = 2 + 3 + (-2) = 3.$$

Die Einträge abseits der Diagonale spielen für die Spur keine Rolle.

3.1.2 Rechenregeln und zyklische Vertauschung

Nützlich wird die Spur durch ihre Rechenregeln.

Satz 3.1.4 (Eigenschaften der Spur)

Für Matrizen $A, B \in \mathbb{R}^{n \times n}$, invertierbares $P \in \mathbb{R}^{n \times n}$ und $c \in \mathbb{R}$ gilt:

1. *Additiv*: $\operatorname{tr}(A + B) = \operatorname{tr}(A) + \operatorname{tr}(B)$
2. *Homogen*: $\operatorname{tr}(cA) = c \cdot \operatorname{tr}(A)$
3. *Zyklisch*: $\operatorname{tr}(AB) = \operatorname{tr}(BA)$
4. *Ähnlichkeitsinvariant*: $\operatorname{tr}(PAP^{-1}) = \operatorname{tr}(A)$
5. *Transpositionsinvariant*: $\operatorname{tr}(A^T) = \operatorname{tr}(A)$

Die Eigenschaften 1, 2 und 5 folgen direkt aus der Definition: Addition und Skalierung wirken eintragsweise, also auch auf jedes Diagonalelement, und das Transponieren spiegelt die Matrix an der Diagonale, deren Elemente dabei bleiben, wo sie sind. Die Eigenschaften 3 und 4 brauchen eine kurze Rechnung.

Vertiefung (optional): Beweis der Spur-Rechenregeln

Beweis.

- (1) Zu Eigenschaft 3: Wir schreiben beide Seiten als Doppelsumme aus.

$$\operatorname{tr}(AB) = \sum_{i=1}^n (AB)_{ii} = \sum_{i=1}^n \sum_{k=1}^n a_{ik} b_{ki}$$

Definition der Spur; der Diagonaleintrag $(AB)_{ii}$ ist das Skalarprodukt aus i -ter Zeile von A und i -ter Spalte von B (Matrixprodukt)

- (2)

$$= \sum_{k=1}^n \sum_{i=1}^n b_{ki} a_{ik} = \sum_{k=1}^n (BA)_{kk} = \operatorname{tr}(BA)$$

endliche Summen dürfen wir vertauschen, und die Faktoren a_{ik}, b_{ki} sind Skalare, kommutieren also

- (3) Eigenschaft 4 ist damit ein Einzeiler:

$$\operatorname{tr}(PAP^{-1}) = \operatorname{tr}((PA)P^{-1}) = \operatorname{tr}(P^{-1}(PA)) = \operatorname{tr}(A).$$

Eigenschaft 3, angewendet auf die beiden Faktoren PA und P^{-1} ; dann $P^{-1}P = I$ (Inverse)

□

Eigenschaft 3 ist die *wichtigste* Eigenschaft der Spur. Wenden wir sie auf ein Produkt aus drei Matrizen an (mit den Faktorpaaren $A \cdot (BC)$ bzw. $(AB) \cdot C$), erhalten wir die *zyklische Vertauschung*:

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB}).$$

Wir dürfen die Faktoren unter der Spur also „im Kreis herumschieben“: Die Reihenfolge im Kreis bleibt erhalten, nur der Startpunkt wandert.

Bemerkung 3.1.5 (Was die Spur nicht kann)

- Die Spur ist *nicht* multiplikativ: $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$, aber $\text{tr}(\mathbf{AB}) \neq \text{tr}(\mathbf{A}) \cdot \text{tr}(\mathbf{B})$! Kleinstes Gegenbeispiel: $\mathbf{A} = \mathbf{B} = \mathbf{I}_2$, denn $\text{tr}(\mathbf{I}_2 \mathbf{I}_2) = \text{tr}(\mathbf{I}_2) = 2$, aber $\text{tr}(\mathbf{I}_2) \cdot \text{tr}(\mathbf{I}_2) = 4$.
- Erlaubt sind nur *zyklische* Vertauschungen, keine beliebigen: Im Allgemeinen ist $\text{tr}(\mathbf{ABC}) \neq \text{tr}(\mathbf{ACB})$, weil sich die Umordnung $\mathbf{ACB}$ nicht durch Weiterdrehen aus $\mathbf{ABC}$ erzeugen lässt.

Vertiefung (optional): Anwendung: Freiheitsgrade in der linearen Regression

Beispiel 3.1.6 (Zyklische Vertauschung in der Statistik)

In der linearen Regression mit Designmatrix $\mathbf{X} \in \mathbb{R}^{n \times p}$ (voller Spaltenrang) erzeugt die „Hutmatrix“ $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \in \mathbb{R}^{n \times n}$ die gefitteten Werte $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$. Ihre Spur zählt die effektiven Parameter des Modells. Die zyklische Vertauschung berechnet sie, ohne dass wir einen einzigen Eintrag der $n \times n$ -Matrix $\mathbf{H}$ kennen müssen:

$$\text{tr}(\mathbf{H}) = \text{tr}(\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top) = \text{tr}((\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}) = \text{tr}(\mathbf{I}_p) = p.$$

Im zweiten Schritt haben wir den Faktor $\mathbf{X}$ einmal im Kreis nach hinten geschoben; dann kürzt sich $(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}$ zur $p \times p$ -Einheitsmatrix.

3.1.3 Spur und Eigenwerte

Dass die Diagonalsumme unter Basiswechseln invariant ist, hat einen Grund: Die Spur ist eine Kennzahl der Eigenwerte, und die hängen nur von der Abbildung ab, nicht von der Basis, in der wir sie aufschreiben.

Satz 3.1.7 (Spur als Summe der Eigenwerte)

Für eine Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit Eigenwerten $\lambda_1, \dots, \lambda_n$ gilt

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i.$$

Für diagonalisierbares $\mathbf{A}$ folgt der Satz direkt aus der Ähnlichkeitsinvarianz (Eigenschaft 4 in Satz 3.1.4; ähnliche Matrizen haben dieselbe Spur). Ist $\mathbf{A} = \mathbf{PDP}^{-1}$ mit der Diagonalmatrix $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$ der Eigenwerte, so gilt

$$\text{tr}(\mathbf{A}) = \text{tr}(\mathbf{PDP}^{-1}) = \text{tr}(\mathbf{D}) = \sum_{i=1}^n \lambda_i.$$

Der Satz gilt auch für nicht diagonalisierbare Matrizen; der Beweis läuft dann über einen Koeffizientenvergleich im charakteristischen Polynom $\det(\mathbf{A} - \lambda \mathbf{I})$ (Determinante). Die Eigenwerte zählen

wir dabei mit ihrer algebraischen Vielfachheit, und sie dürfen komplex sein. Komplexe Eigenwerte einer reellen Matrix treten immer als konjugierte Paare $a \pm bi$ auf, deren Imaginärteile sich in der Summe wegheben: Die Spur bleibt reell.

Interaktiv: Was macht ein Eintrag neben der Diagonale mit Eigenwerten und Spur?

Verändern wir einen Eintrag *außerhalb* der Diagonale: Was macht das mit den beiden Eigenwerten, und was mit ihrer Summe?

Interaktives Element — nur in der Web-Fassung

Die Eigenwerte reagieren empfindlich: Ein kleiner Nebendiagonaleintrag schiebt sie auseinander, lässt sie zusammenfallen oder hebt sie aus der reellen Achse heraus. Ihre Summe ändert sich nicht: Sie ist die Spur, und die liest nur die Diagonale ab. Im komplexen Fall ergeben die beiden gleichen Realteile der konjugierten Eigenwerte zusammen wieder die Spur.

3.1.4 Die Frobenius-Norm

Als Maß für die „Größe“ einer Matrix taugt die Spur nicht: Sie ignoriert alle Einträge abseits der Diagonale, kann negativ werden und ist für rechteckige Matrizen nicht definiert. Näher liegt es, die $m \cdot n$ Einträge wie einen langen Vektor zu behandeln und dessen euklidische Norm zu nehmen.

Definition 3.1.8 (Frobenius-Norm)

Die *Frobenius-Norm* einer Matrix $A \in \mathbb{R}^{m \times n}$ ist

$$\|A\|_F := \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}.$$

Bemerkung 3.1.9

- Die Frobenius-Norm ist das Analogon zur euklidischen Vektornorm: quadrieren, aufsummieren, Wurzel ziehen, über alle $m \cdot n$ Einträge. Sie ist auch für rechteckige Matrizen definiert.
- In der Literatur heißt sie auch *Hilbert-Schmidt-Norm*.
- Sie misst so etwas wie die „Größe“ der Matrix. Ob sie misst, was wir in der Fehleranalyse brauchen, nämlich wie stark eine Matrix Vektoren verzerren kann, klären wir in Abschnitt 3.2.

Die Frobenius-Norm lässt sich durch die Spur ausdrücken. Damit stehen ihr alle Rechenregeln aus Satz 3.1.4 zur Verfügung, insbesondere die zyklische Vertauschung.

Satz 3.1.10 (Frobenius-Norm über die Spur)

Für $A \in \mathbb{R}^{m \times n}$ gilt

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2} = \sqrt{\operatorname{tr}(A^T A)}.$$

Beweis.

- (1) Wir berechnen $\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{n \times n}$ eintragsweise:

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} \sum_{i=1}^m a_{i1}^2 & \sum_{i=1}^m a_{i1}a_{i2} & \cdots \\ \sum_{i=1}^m a_{i2}a_{i1} & \sum_{i=1}^m a_{i2}^2 & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

Eintrag (j, k) von $\mathbf{A}^\top \mathbf{A}$ ist das Skalarprodukt aus j -ter Zeile von $\mathbf{A}^\top$ (also j -ter Spalte von $\mathbf{A}$) und k -ter Spalte von $\mathbf{A}$; auf der Diagonale ($j = k$, grün) steht also jede Spalte im Skalarprodukt mit sich selbst

- (2)

$$\Rightarrow \operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{j=1}^n \sum_{i=1}^m a_{ij}^2 = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^2$$

die Spur summiert die grünen Diagonalelemente; zusammen durchlaufen die beiden Summen alle $m \cdot n$ Einträge von $\mathbf{A}$ genau einmal

- (3)

$$\Rightarrow \sqrt{\operatorname{tr}(\mathbf{A}^\top \mathbf{A})} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2} = \|\mathbf{A}\|_F.$$

Wurzel ziehen auf beiden Seiten; Definition 3.1.8

□

Selbsttest

1. Die Spur einer Matrix ändert sich, wenn wir einen Eintrag außerhalb der Diagonale verändern.

Antwort: Falsch

Die Spur summiert ausschließlich die Diagonalelemente (Definition 3.1.2). Die Eigenwerte ändern sich dabei sehr wohl, ihre Summe aber nicht.

2. Eine reelle Matrix mit komplexen Eigenwerten hat trotzdem eine reelle Spur.

Antwort: Wahr

Komplexe Eigenwerte reeller Matrizen treten als konjugierte Paare $a \pm bi$ auf. In der Summe heben sich die Imaginärteile weg, und Satz 3.1.7 liefert eine reelle Zahl, wie es die Diagonalsumme verlangt.

3. Stellen wir im Spur-Widget die Voreinstellung „defekt (Jordan)“ ein. Welchen Wert zeigt die Summe der Eigenwerte?

Lösung: 4

Vier. Die Voreinstellung ist $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 2 \end{pmatrix}$ mit dem doppelten Eigenwert 2. Satz 3.1.7 zählt Eigenwerte mit ihrer algebraischen Vielfachheit, die Summe ist also $2 + 2 = 4 = \operatorname{tr}(\mathbf{A})$ und nicht 2. Die Matrix ist nicht diagonalisierbar; die Rechnung über $\mathbf{PDP}^{-1}$ greift hier nicht, die Aussage gilt trotzdem.

Vertiefung: Heath §2; MML §4.1.

3.2 Matrixnormen: Definition und Beispiele

Die Frobenius-Norm aus Abschnitt 3.1 ist ein erstes Größenmaß für Matrizen. Jetzt fragen wir allgemein, was eine Matrixnorm ist und was sie leisten soll.

3.2.1 Warum Matrixnormen?

Für Vektoren sind Normen unser wichtigstes Messinstrument: Sie machen aus einem Fehlervektor eine Fehlergröße. Für Matrizen brauchen wir dasselbe, und zwar aus vier Anlässen:

- die „Größe“ einer Matrix messen, analog zur Länge eines Vektors;
- *Fehler* quantifizieren: Wie weit liegt eine mit Rundungsfehlern gespeicherte oder näherungsweise berechnete Matrix von der exakten entfernt?
- *Konvergenz* von Algorithmen analysieren: Iterative Verfahren erzeugen Folgen von Matrizen oder Vektoren, und die Aussage „ $A_k \rightarrow A$ “ braucht ein Abstandsmaß (Konvergenz);
- die *Konditionierung* von Problemen verstehen: Die Konditionszahl einer Matrix wird über Matrixnormen definiert.

Zur Auffrischung: Für Vektoren kennen wir neben der euklidischen Norm $\|x\|_2$ die ganze Familie der p -Normen. Vergleichen lassen sie sich am besten über ihre Einheitskugeln $\{x : \|x\|_p = 1\}$: Raute, Kreis, Quadrat.

Interaktiv: Auffrischung: Was misst die Norm an der Einheitskugel?

Was haben diese Formen mit der Zahl $\|x\|_p$ zu tun?

Interaktives Element — nur in der Web-Fassung

Die Norm eines Vektors ist der Faktor, mit dem wir die Einheitskugel aufblasen müssen, damit ihr Rand durch die Spitze von x läuft. Für $p \geq 1$ ist die Kugel konvex; das ist die Dreiecksungleichung in geometrischer Gestalt.

3.2.2 Die Axiome

Was macht eine Funktion auf Matrizen zu einer „Norm“? Dieselben drei Forderungen, die wir schon von Vektornormen kennen:

Definition 3.2.1 (Matrixnorm)

Eine Funktion $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow [0, \infty)$ heißt *Matrixnorm*, wenn für alle $A, B \in \mathbb{R}^{m \times n}$ und $c \in \mathbb{R}$ gilt:

1. *Definitheit*: $\|A\| = 0 \iff A = 0$
2. *absolute Homogenität*: $\|cA\| = |c| \cdot \|A\|$
3. *Dreiecksungleichung*: $\|A + B\| \leq \|A\| + \|B\|$

Bemerkung 3.2.2

Das sind dieselben Axiome wie bei einer Vektornorm: $\mathbb{R}^{m \times n}$ ist ein Vektorraum der Dimension mn , und eine Matrixnorm ist eine Norm auf diesem Raum. Umgekehrt ist jede Vektornorm eine Matrixnorm auf dem Raum $\mathbb{R}^{n \times 1}$ der einspaltigen Matrizen.

3.2.3 Matrixnormen durch Vektorisierung

Der schnellste Weg zu Matrixnormen: Wir rollen die Matrix zu einem langen Vektor aus und wenden darauf eine Vektornorm an, die wir schon kennen.

Definition 3.2.3 (Vektorisierung)

Die *Vektorisierung* einer Matrix $A \in \mathbb{R}^{m \times n}$ stapelt ihre Spalten zu einem Vektor der Länge mn :

$$\text{vec}(A) = (a_{11}, \dots, a_{m1}, a_{12}, \dots, a_{m2}, \dots, a_{1n}, \dots, a_{mn})^T \in \mathbb{R}^{mn}.$$

Weil vec die Einträge nur umsortiert, erbt $A \mapsto \|\text{vec}(A)\|$ alle drei Axiome von der Vektornorm und ist eine Matrixnorm.

Vertiefung (optional): Warum jede Vektornorm auf diesem Weg eine Matrixnorm liefert**Satz 3.2.4**

Ist $\|\cdot\|$ eine Vektornorm auf $\mathbb{R}^{mn}$, so ist

$$A \mapsto \|\text{vec}(A)\|$$

eine Matrixnorm auf $\mathbb{R}^{m \times n}$.

Beweis.

- (1) Die Abbildung $\text{vec} : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{mn}$ ist linear und bijektiv:

$$\begin{aligned} \text{vec}(A + B) &= \text{vec}(A) + \text{vec}(B), & \text{vec}(cA) &= c \text{vec}(A), \\ \text{vec}(A) &= \mathbf{0} & \Leftrightarrow & A = \mathbf{0}. \end{aligned}$$

vec sortiert die Einträge nur um: Jeder Eintrag von A landet an genau einer Position des langen Vektors, Addition und Skalarmultiplikation wirken eintragsweise

- (2)

$$\|\text{vec}(A)\| = 0 \Leftrightarrow \text{vec}(A) = \mathbf{0} \Leftrightarrow A = \mathbf{0}.$$

Definitheit der Vektornorm auf $\mathbb{R}^{mn}$, dann die letzte Äquivalenz aus dem vorigen Schritt

- (3)

$$\|\text{vec}(cA)\| = \|c \text{vec}(A)\| = |c| \cdot \|\text{vec}(A)\|.$$

erst Linearität von vec, dann absolute Homogenität der Vektornorm

- (4)

$$\|\text{vec}(A + B)\| = \|\text{vec}(A) + \text{vec}(B)\| \leq \|\text{vec}(A)\| + \|\text{vec}(B)\|.$$

erst Additivität von vec, dann Dreiecksungleichung der Vektornorm

□

Die drei wichtigsten Vertreter dieser Bauart entstehen aus den drei vertrauten Vektornormen:

Beispiel 3.2.5 (Vektorisierungsnormen)

- *Frobenius-Norm* (aus der 2-Norm):

$$\|A\|_F = \|\text{vec}(A)\|_2 = \sqrt{\sum_{i,j} a_{ij}^2}$$

Das ist Definition 3.1.8, also gilt auch $\|A\|_F = \sqrt{\text{tr}(A^\top A)}$ (Satz 3.1.10).

- *Summennorm* (aus der 1-Norm):

$$\|A\|_S = \|\text{vec}(A)\|_1 = \sum_{i,j} |a_{ij}|$$

- *Maximumsnorm* (aus der ∞ -Norm):

$$\|A\|_M = \|\text{vec}(A)\|_\infty = \max_{i,j} |a_{ij}|$$

Interaktiv: Frobenius-, Summen- und Maximumsnorm: was sehen sie, was nicht?

Können zwei Matrizen, die als Abbildung nichts miteinander zu tun haben, in allen drei Normen denselben Wert haben?

Interaktives Element — nur in der Web-Fassung

Ja. „Einträge durchtauschen“ verteilt dieselben vier Zahlen auf andere Plätze: Alle drei Normen bleiben gleich, obwohl die Abbildung eine andere ist (aus der Identität wird etwa eine singuläre Matrix). Wir brauchen also Normen, die die *Abbildung* messen.

3.2.4 Was elementweise Normen nicht sehen

Die Vektorisierungsnormen sind leicht zu berechnen und erfüllen alle Axiome. Sie behandeln die Matrix aber wie einen langen Vektor, und jede Umordnung der Einträge lässt die Norm unverändert. Eine Matrix repräsentiert jedoch die lineare Abbildung $x \mapsto Ax$, und von dieser Abbildung wissen die elementweisen Normen nichts. Die Frobenius-Norm etwa misst nur die Summe der quadrierten Bildlängen der Einheitsvektoren (Ae_j ist die j -te Spalte von A),

$$\|A\|_F^2 = \sum_{j=1}^n \|Ae_j\|_2^2,$$

nicht, wie stark A einen Vektor höchstens strecken kann.

Beispiel 3.2.6 (Gleiche Frobenius-Norm, völlig verschiedene Abbildungen)

Betrachten wir die drei Matrizen

$$\mathbf{A}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{A}_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \mathbf{A}_3 = \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{pmatrix}.$$

Ihre Frobenius-Normen rechnen wir direkt aus:

$$\|\mathbf{A}_1\|_F = \sqrt{1^2 + 0^2 + 0^2 + 1^2} = \sqrt{2}, \quad \|\mathbf{A}_2\|_F = \sqrt{0^2 + 1^2 + 1^2 + 0^2} = \sqrt{2},$$

$$\|\mathbf{A}_3\|_F = \sqrt{(\sqrt{2})^2 + 0^2 + 0^2 + 0^2} = \sqrt{2}.$$

Alle drei Matrizen haben also *dieselbe* Frobenius-Norm $\sqrt{2}$. Als Abbildungen sind sie sehr verschieden. Verfolgen wir den Vektor $\mathbf{x} = (1, 0)^\top$:

- $\mathbf{A}_1 \mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \mathbf{x}$: Die Identität lässt *jeden* Vektor unverändert.
- $\mathbf{A}_2 \mathbf{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$: Die Permutationsmatrix $\mathbf{A}_2$ vertauscht die beiden Koordinaten. Geometrisch ist das eine Spiegelung an der Winkelhalbierenden $x_2 = x_1$ (keine Drehung: es gilt $\det \mathbf{A}_2 = -1$, siehe Determinante).
- $\mathbf{A}_3 \mathbf{x} = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix}$: $\mathbf{A}_3$ streckt die erste Koordinate um den Faktor $\sqrt{2}$ und löscht die zweite: $\mathbf{A}_3(0, 1)^\top = \mathbf{0}$. Die Matrix ist singulär (nicht invertierbar) und bildet die ganze Ebene auf die x_1 -Achse ab.

Zwei längentreue Abbildungen und eine, die eine ganze Dimension auslöscht: Die Frobenius-Norm kann sie nicht auseinanderhalten.

Dasselbe Problem zeigt sich, wenn wir die Dimension wachsen lassen:

Beispiel 3.2.7 (Identität in wachsender Dimension)

Für die Identitätsmatrix $\mathbf{I}_n \in \mathbb{R}^{n \times n}$ liefern die drei Vektorisierungsnormen

$$\|\mathbf{I}_n\|_F = \sqrt{\underbrace{1 + \dots + 1}_n} = \sqrt{n}, \quad \|\mathbf{I}_n\|_S = n, \quad \|\mathbf{I}_n\|_M = 1.$$

Die Abbildung $\mathbf{x} \mapsto \mathbf{I}_n \mathbf{x} = \mathbf{x}$ ändert überhaupt nichts, trotzdem wachsen Frobenius- und Summennorm mit n über alle Grenzen.

Eine Norm, die die Matrix als *Abbildung* misst, sollte der Identität den Wert 1 geben, unabhängig von der Dimension. Die Maximumsnorm trifft diesen Wert zufällig, bleibt aber ebenso blind für das, was $\mathbf{A}$ im Matrix-Vektor-Produkt $\mathbf{A}\mathbf{x}$ mit Vektoren *tut*. Die Lösung sind *Operatornormen* (Abschnitt 3.3), die direkt messen, wie stark $\mathbf{A}$ einen Vektor höchstens verlängert.

Selbsttest

1. Vertauschen wir zwei Einträge einer Matrix, so ändert sich keine der drei Vektorisierungsnormen.

Antwort: Wahr

Alle drei entstehen als Vektornorm von $\text{vec}(\mathbf{A})$, und die 1-, 2- und ∞ -Norm eines Vektors hängen nicht von der Reihenfolge seiner Einträge ab.

2. Die p -Normen sind für jedes $p > 0$ definiert.

Antwort: Falsch

Für $p < 1$ ist die Dreiecksungleichung verletzt: Im Widget beult sich die Einheitskugel nach innen, und für $p = 0,5$ ist $\|\mathbf{e}_1 + \mathbf{e}_2\|_p = 4 > 2 = \|\mathbf{e}_1\|_p + \|\mathbf{e}_2\|_p$. Das dritte Normaxiom (für Matrizen: Definition 3.2.1) verlangt daher $p \geq 1$.

3. Setzen wir im Einheitskugel-Widget das Kästchen $p = \infty$ und die Regler auf $\mathbf{x} = (-1, 2; 0, 9)$. Welchen Wert zeigt das Widget für $\|\mathbf{x}\|_p$?

Lösung: 1.2

1,2. Die Maximumsnorm nimmt den größten Betrag, hier $|-1,2| = 1,2$; die zweite Koordinate spielt keine Rolle. Zum Vergleich: $\|\mathbf{x}\|_2 = 1,5$ und $\|\mathbf{x}\|_1 = 2,1$. Die skalierte Kugel ist entsprechend ein Quadrat der halben Kantenlänge 1,2, dessen Rand genau durch die Pfeilspitze läuft.

Vertiefung: Heath §2.3.

3.3 Operatornormen

Die elementweisen Normen aus Abschnitt 3.2 sehen nicht, was die Matrix als lineare Abbildung $\mathbf{x} \mapsto \mathbf{Ax}$ tut. Operatornormen messen stattdessen, wie stark $\mathbf{A}$ einen Vektor strecken kann.

3.3.1 Definition und Interpretation

Die Idee: Wir schicken alle Vektoren $\mathbf{x} \neq \mathbf{0}$ durch die Abbildung und vergleichen die Länge des Bildes $\mathbf{Ax}$ mit der Länge des Urbildes $\mathbf{x}$, gemessen mit einer Vektornorm unserer Wahl. Der größte auftretende Streckfaktor ist die Norm der Matrix.

Definition 3.3.1 (Operatornorm)

Sei $\|\cdot\|_V$ eine Vektornorm. Die *Operatornorm* (auch: *induzierte Norm*) von $\mathbf{A} \in \mathbb{R}^{m \times n}$ ist

$$\|\mathbf{A}\|_V := \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_V}{\|\mathbf{x}\|_V} = \max_{\|\mathbf{x}\|_V=1} \|\mathbf{Ax}\|_V.$$

Der *Normquotient* $s_{\mathbf{A}}(\mathbf{x}) = \|\mathbf{Ax}\|_V / \|\mathbf{x}\|_V$ ist der Faktor, um den $\mathbf{A}$ den Vektor $\mathbf{x}$ streckt. Eine große Operatornorm heißt: In mindestens einer Richtung streckt $\mathbf{A}$ stark. Eine kleine heißt: $\mathbf{A}$ staucht jeden Vektor oder lässt ihn höchstens schwach wachsen. Die zweite Gleichheit in der Definition gilt, weil der Normquotient skaleninvariant ist: Ersetzen wir $\mathbf{x}$ durch $c\mathbf{x}$ mit $c \neq 0$, kürzt sich $|c|$ heraus.

Vertiefung (optional): Zwei Normen, und warum wir das Maximum schreiben dürfen

Bemerkung 3.3.2

- Genau genommen brauchen wir zwei Normen: eine auf $\mathbb{R}^n$ für $\mathbf{x}$ und eine auf $\mathbb{R}^m$ für $\mathbf{Ax}$. Wir verwenden stets dieselbe Normfamilie in der jeweils passenden Dimension und schreiben dafür dasselbe Symbol.
- Warum dürfen wir „max“ statt „sup“ schreiben? Die Funktion $\mathbf{x} \mapsto \|\mathbf{Ax}\|_V$ ist stetig, und die Einheitskugel $\{\mathbf{x} : \|\mathbf{x}\|_V = 1\}$ ist eine abgeschlossene und beschränkte Menge; das Maximum wird also tatsächlich angenommen.

Geometrisch: In der euklidischen Norm ($p = 2$) bilden die Einheitsvektoren des $\mathbb{R}^2$ den Einheitskreis. Sein Bild unter einer 2×2 -Matrix ist eine Ellipse, und die Operatornorm ist deren längste Halbachse.

Beispiel 3.3.3 (Visualisierung)

Betrachten wir $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$. Nach Satz 3.3.7 (weiter unten) ist $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$, und

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix}.$$

Die Eigenwerte sind die Nullstellen des charakteristischen Polynoms $\lambda^2 - 6\lambda + 4$, also $\lambda_{1,2} = 3 \pm \sqrt{5}$, und damit

$$\|\mathbf{A}\|_2 = \sqrt{3 + \sqrt{5}} \approx 2,29.$$

In R können wir das direkt nachprüfen (`crossprod(A)` berechnet $\mathbf{A}^\top \mathbf{A}$):

```
A <- matrix(c(2, 1,
              0, 1), nrow = 2, byrow = TRUE)
AtA <- crossprod(A) # t(A) %*% A
sqrt(eigen(AtA)$values)
#> [1] 2.288246 0.874032
```

Der größte Wert ist die Operatornorm: Kein Einheitsvektor wird um mehr als den Faktor 2,29 gestreckt. Der kleinere Wert 0,874 ist die kürzeste Halbachse der Bildellipse, also die stärkste Stauchung. In Beispiel 3.4.6 berechnen wir aus denselben Eigenwerten die Schattenormen dieser Matrix.

Interaktiv: Wie schwankt der Streckfaktor, wenn der Vektor um den Einheitskreis wandert?

Die Definition läuft über *alle* Einheitsvektoren. Wie stark schwankt der Streckfaktor $\|\mathbf{Ax}\|_2$, wenn $\mathbf{x}$ einmal um den Einheitskreis wandert, und in welche Richtung muss $\mathbf{x}$ zeigen, damit er maximal wird?

Interaktives Element — nur in der Web-Fassung

Der Streckfaktor pendelt zweimal pro Umlauf zwischen der kürzesten und der längsten Halbachse der Bildellipse, denn $\mathbf{x}$ und $-\mathbf{x}$ werden gleich stark gestreckt. Die Operatornorm ist der obere Wert; dort berührt die Ellipse den roten Kreis mit Radius $\|\mathbf{A}\|_2$ von innen. In der Voreinstellung „schiefe Streckung“ liegt die Richtung $\mathbf{x}^*$ des Maximums schräg zu den Koor-

diagonalenachsen; welche Richtung es ist, klärt Satz 3.3.7.

3.3.2 Die wichtigsten Operatornormen

Jede p -Norm $\|v\|_p = (\sum_i |v_i|^p)^{1/p}$ induziert ihre eigene Operatornorm. Drei Fälle sind so wichtig, dass sie eigene Namen tragen, und für zwei davon gibt es einfache Formeln:

Satz 3.3.4 (Induzierte p -Normen)

Sei $A \in \mathbb{R}^{m \times n}$ mit Einträgen a_{ij} . Dann gilt:

Spektralnorm ($p = 2$):

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

Spaltensummennorm ($p = 1$):

$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

Zeilensummennorm ($p = \infty$):

$$\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

Die 1-Norm einer Matrix ist also die größte betragsmäßige Spaltensumme, die ∞ -Norm die größte betragsmäßige Zeilensumme; beide lassen sich ohne Eigenwertrechnung ablesen. Als Eselsbrücke: Die 1 steht senkrecht wie eine Spalte, das Symbol ∞ liegt waagrecht wie eine Zeile. Die Spektralnorm ist teurer zu berechnen, passt dafür aber zur euklidischen Geometrie: Sie ist die längste Halbachse der Bildellipse aus Beispiel 3.3.3. Ihre Formel beweisen wir in Satz 3.3.7.

Vertiefung (optional): Beweis der Spaltensummenformel

Wir zeigen $\|A\|_1 = \max_j c_j$ mit den Spaltensummen $c_j := \sum_{i=1}^m |a_{ij}|$ (grün). Der Fall $p = \infty$ verläuft analog und ist eine gute Übung.

Beweis.

(1)

$$\|Ax\|_1 = \sum_{i=1}^m \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \sum_{i=1}^m \sum_{j=1}^n |a_{ij}| |x_j|$$

i -te Komponente von Ax ausschreiben; Dreiecksungleichung $|u+v| \leq |u| + |v|$ im Betrag

(2)

$$\sum_{i=1}^m \sum_{j=1}^n |a_{ij}| |x_j| = \sum_{j=1}^n |x_j| \sum_{i=1}^m |a_{ij}| = \sum_{j=1}^n |x_j| c_j$$

Summationsreihenfolge tauschen (endliche Summen), dann $\sum_i |a_{ij}| = c_j$ einsetzen

(3)

$$\sum_{j=1}^n |x_j| c_j \leq \left(\max_j c_j \right) \sum_{j=1}^n |x_j| = \max_j c_j$$

jede Spaltensumme durch die größte abschätzen; $\sum_j |x_j| = \|\mathbf{x}\|_1 = 1$

(4)

$$\|\mathbf{A}\mathbf{e}_{j^*}\|_1 = \sum_{i=1}^m |a_{ij^*}| = c_{j^*} = \max_j c_j$$

die Schranke wird angenommen: Für den Einheitsvektor $\mathbf{e}_{j^*}$ zur maximalen Spalte j^* ist $\mathbf{A}\mathbf{e}_{j^*}$ genau die j^* -te Spalte von $\mathbf{A}$

□

3.3.3 Einschub: Orthogonalmatrizen

Matrizen, die Längen nicht verändern, begegnen uns im ganzen Skript; auch die Spektralnorm-Formel stützt sich auf sie.

Definition 3.3.5 (Orthogonalmatrix)

Eine Matrix $\mathbf{Q} \in \mathbb{R}^{n \times n}$ heißt *Orthogonalmatrix*, wenn ihre Spalten orthonormale Vektoren sind, also

$$\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

Bemerkung 3.3.6 (Eigenschaften von Orthogonalmatrizen)

- Geometrisch beschreibt $\mathbf{Q}$ eine Rotation und/oder Spiegelung in $\mathbb{R}^n$.
- $\mathbf{Q}$ erhält die euklidische Norm: Für alle $\mathbf{x} \in \mathbb{R}^n$ gilt

$$\|\mathbf{Q}\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{x}} = \sqrt{\mathbf{x}^\top \mathbf{x}} = \|\mathbf{x}\|_2.$$

Insbesondere ist $\|\mathbf{Q}\|_2 = 1$: Jeder Normquotient ist exakt 1.

- Die Inverse ist $\mathbf{Q}^{-1} = \mathbf{Q}^\top$: Statt ein Gleichungssystem zu lösen, genügt Transponieren.
- Alle Eigenwerte haben Betrag 1: Aus $\mathbf{Q}\mathbf{x} = \lambda\mathbf{x}$ mit $\mathbf{x} \neq \mathbf{0}$ folgt $\|\mathbf{x}\|_2 = \|\mathbf{Q}\mathbf{x}\|_2 = |\lambda| \|\mathbf{x}\|_2$, also $|\lambda| = 1$.
- Mit $\mathbf{Q}$ ist auch $\mathbf{Q}^{-1} = \mathbf{Q}^\top$ orthogonal (denn $(\mathbf{Q}^\top)^\top \mathbf{Q}^\top = \mathbf{Q}\mathbf{Q}^\top = \mathbf{I}$), hat also ebenfalls Spektralnorm 1. Für die Konditionszahl folgt $\kappa_2(\mathbf{Q}) = \|\mathbf{Q}\|_2 \|\mathbf{Q}^{-1}\|_2 = 1$: Multiplikation mit $\mathbf{Q}$ oder $\mathbf{Q}^{-1}$ verstärkt relative Störungen in der 2-Norm nicht. Stabil implementierte orthogonale Transformationen gehören deshalb zu den wichtigsten Werkzeugen der numerischen linearen Algebra (mehr dazu bei der QR-Zerlegung in Kapitel 7).
- Produkte bleiben orthogonal: Sind $\mathbf{Q}_1, \dots, \mathbf{Q}_k$ orthogonal, dann auch $\mathbf{Q} = \mathbf{Q}_1 \cdots \mathbf{Q}_k$. Warum? Weil $(\mathbf{Q}_1 \mathbf{Q}_2)^\top \mathbf{Q}_1 \mathbf{Q}_2 = \mathbf{Q}_2^\top \mathbf{Q}_1^\top \mathbf{Q}_1 \mathbf{Q}_2 = \mathbf{Q}_2^\top \mathbf{Q}_2 = \mathbf{I}$ (Transponierregeln), und dann induktiv weiter.

3.3.4 Spektralnorm und Spektralzerlegung

Die Formel $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$ beruht auf der Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$: Als symmetrische Matrix hat $\mathbf{A}^\top \mathbf{A}$ eine *orthogonale* Eigenvektormatrix $\mathbf{P}$. Die Eigenwerte von $\mathbf{A}^\top \mathbf{A}$ sind nicht-negativ, denn $\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \|\mathbf{A}\mathbf{x}\|_2^2 \geq 0$ ($\mathbf{A}^\top \mathbf{A}$ ist positiv semidefinit).

Satz 3.3.7 (Spektralnorm und Spektralzerlegung)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$, wobei $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0)$ mit $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$. Dann gilt

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}.$$

Vertiefung (optional): Beweis der Spektralnormformel

Beweis.

(1)

$$\|\mathbf{Ax}\|_2^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top \mathbf{x}$$

euklidische Norm als Skalarprodukt schreiben, dann die Spektralzerlegung einsetzen

(2)

$$\mathbf{x}^\top \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top \mathbf{x} = (\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x})^\top (\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x}) = \|\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x}\|_2^2$$

$\mathbf{\Lambda} = \mathbf{\Lambda}^{1/2} \mathbf{\Lambda}^{1/2}$ mit $\mathbf{\Lambda}^{1/2} = \text{diag}(\sqrt{\lambda_i})$ aufspalten und die Faktoren den beiden Seiten zuschlagen, wieder eine quadrierte Norm

(3)

$$\max_{\|\mathbf{x}\|_2=1} \|\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x}\|_2^2 = \max_{\|\mathbf{y}\|_2=1} \|\mathbf{\Lambda}^{1/2} \mathbf{y}\|_2^2$$

Substitution $\mathbf{y} = \mathbf{P}^\top \mathbf{x}$: Weil $\mathbf{P}$ orthogonal ist, gilt $\|\mathbf{y}\|_2 = \|\mathbf{x}\|_2$ (Bemerkung 3.3.6), und $\mathbf{x} \mapsto \mathbf{P}^\top \mathbf{x}$ ist bijektiv; $\mathbf{y}$ durchläuft also die Einheitssphäre, wenn $\mathbf{x}$ dies tut

(4)

$$\|\mathbf{\Lambda}^{1/2} \mathbf{y}\|_2^2 = \lambda_1 y_1^2 + \lambda_2 y_2^2 + \dots + \lambda_r y_r^2 \leq \lambda_1 (y_1^2 + \dots + y_r^2) \leq \lambda_1$$

$\mathbf{\Lambda}^{1/2}$ ist diagonal; jeden Koeffizienten durch den größten Eigenwert λ_1 abschätzen und $\sum_i y_i^2 = 1$ benutzen

(5)

$$\|\mathbf{A}\|_2^2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{Ax}\|_2^2 = \lambda_1$$

die Schranke wird angenommen: Für $\mathbf{y} = \mathbf{e}_1$ (also $\mathbf{x}$ = erste Spalte von $\mathbf{P}$, der Eigenvektor zu λ_1) gilt Gleichheit; Wurzel ziehen liefert die Behauptung

□

Der größte Eigenwert von $\mathbf{A}^\top \mathbf{A}$ ist also die quadrierte maximale Streckung, und die Richtung der stärksten Streckung ist der zugehörige Eigenvektor (im Widget oben die rot gestrichelte Richtung $\mathbf{x}^*$). Anschaulicher wird das mit den Singulärwerten von $\mathbf{A}$ (Abschnitt 3.4) und der Singulärwertzerlegung (Kapitel 6).

3.3.5 Beispiele

Beispiel 3.3.8

Berechnen wir alle drei Operatornormen von $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$.

Spaltensummennorm (Grün verfolgt die erste, Blau die zweite Spalte):

$$\|\mathbf{A}\|_1 = \max\{|2| + |0|, |1| + |3|\} = \max\{2, 4\} = 4.$$

Zeilensummennorm (Rot verfolgt die erste, Violett die zweite Zeile):

$$\|\mathbf{A}\|_\infty = \max\{|2| + |1|, |0| + |3|\} = \max\{3, 3\} = 3.$$

Spektralnrm (hier müssen wir rechnen):

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 2 & 0 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 10 \end{pmatrix}.$$

Das charakteristische Polynom ist $\lambda^2 - 14\lambda + 36$ (Spur 14, Determinante $4 \cdot 10 - 2 \cdot 2 = 36$), mit Nullstellen $\lambda_{1,2} = 7 \pm \sqrt{13}$. Also

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})} = \sqrt{7 + \sqrt{13}} \approx \sqrt{10,61} \approx 3,26.$$

Die drei Normen liefern verschiedene Werte (4, 3,26, 3), weil sie die maximale Streckung in verschiedenen Geometrien messen. Beliebige weit auseinander liegen können sie aber nicht (Abschnitt 3.5).

Beispiel 3.3.9 (Identitätsmatrix)

Für die Identitätsmatrix $\mathbf{I}_n$ gilt in jeder Operatornorm $\|\mathbf{I}_n \mathbf{x}\| / \|\mathbf{x}\| = 1$ für alle $\mathbf{x} \neq \mathbf{0}$, also

$$\|\mathbf{I}_n\|_1 = \|\mathbf{I}_n\|_2 = \|\mathbf{I}_n\|_\infty = 1. \quad \boxtimes$$

Eine Abbildung, die nichts verändert, bekommt also Norm 1, unabhängig von der Dimension; die Schwäche der elementweisen Normen ($\|\mathbf{I}_n\|_F = \sqrt{n}$) ist behoben.

Selbsttest

- Berechnen wir $\|\mathbf{A}\|_1$ und $\|\mathbf{A}\|_\infty$ für $\mathbf{A} = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$, ganz ohne Eigenwerte.

Spaltensummen: $|1| + |3| = 4$ und $|-2| + |4| = 6$, also $\|\mathbf{A}\|_1 = 6$. Zeilensummen: $|1| + |-2| = 3$ und $|3| + |4| = 7$, also $\|\mathbf{A}\|_\infty = 7$. Die Beträge nicht vergessen: -2 zählt als 2.

1. Stellen wir im Operatornorm-Widget die Voreinstellung „zehnfach“ ein, also $\mathbf{A} = \begin{pmatrix} 20 & 10 \\ 0 & 10 \end{pmatrix}$. Welchen Wert zeigt es für $\|\mathbf{A}\|_2$?

Lösung: 22,882

22,882, das Zehnfache des Werts aus Beispiel 3.3.3: Jedes Bild wird zehnmal so lang, und die absolute Homogenität aus Definition 3.2.1 liefert $\|10\mathbf{A}\|_2 = 10\|\mathbf{A}\|_2$. Die Ellipse behält ihre Gestalt und die Maximalrichtung $\mathbf{x}^*$, nur der Maßstab wächst.

2. Bei der Voreinstellung „singulär“ zeigt das Widget die Operatornorm 0, weil eine Richtung ganz platt gedrückt wird.

Antwort: Falsch

Die Operatornorm ist ein *Maximum* über Richtungen, kein Minimum. Die Bildellipse entartet zu einer Strecke, ihre kurze Halbachse ist $\sigma_2 = 0$, die lange aber 2,5, und nur die ist $\|\mathbf{A}\|_2$ (Definition 3.3.1).

Vertiefung: Heath §2.3.2.

3.4 Schattennormen

Die Operatornormen aus Abschnitt 3.3 messen die Transformation direkt, aber nur ihre *stärkste* Streckung. Wie stark A die übrigen Richtungen streckt, verraten *alle* Eigenwerte von $A^\top A$. Die dritte Normfamilie dieses Kapitels nutzt sie alle.

3.4.1 Von Eigenwerten zu Singulärwerten

Nach Satz 3.3.7 ist $\|A\|_2 = \sqrt{\lambda_{\max}(A^\top A)}$. Die Eigenwerte der symmetrischen und positiv semidefiniten Matrix $A^\top A$ sind reell und nichtnegativ, wir können also aus allen die Wurzel ziehen:

$$\sigma_i := \sqrt{\lambda_i}, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0 \text{ Eigenwerte von } A^\top A.$$

Diese Zahlen $\sigma_1 \geq \dots \geq \sigma_n \geq 0$ heißen die *Singulärwerte* (singular values) von A . Geometrisch sind sie die Halbachsenlängen der Ellipse, in die A die Einheitssphäre abbildet: σ_1 ist die stärkste Streckung (die Spektralnorm), σ_n die schwächste. Systematisch entwickelt sie Kapitel 6 mit der Singulärwertzerlegung; hier genügt: Der Vektor $(\sigma_1, \dots, \sigma_n)$ beschreibt die Streckung vollständig. Auf ihn wenden wir eine Vektornorm an:

Definition 3.4.1 (Schatten-p-Norm)

Sei $A \in \mathbb{R}^{m \times n}$, und sei $\lambda = (\lambda_1, \dots, \lambda_n)$ der Vektor der Eigenwerte von $A^\top A$. Die *Schatten-p-Norm* von A ist für $1 \leq p < \infty$

$$\|A\|_{S,p} := \|\lambda^{1/2}\|_p = \left(\sum_{i=1}^n \lambda_i^{p/2} \right)^{1/p} = \left(\sum_{i=1}^n \sigma_i^p \right)^{1/p}$$

und für $p = \infty$

$$\|A\|_{S,\infty} := \max_{1 \leq i \leq n} \sigma_i = \sigma_1.$$

Bemerkung 3.4.2

- Das Bauprinzip ist dasselbe wie bei der Vektorisierung in Abschnitt 3.2, nur wenden wir die p -Norm nicht auf die Einträge $\text{vec}(A)$ an, sondern auf den Singulärwertvektor, also auf die geometrische Wirkung der Matrix.
- Der Fall $p = \infty$ fügt sich ein: Wie bei Vektornormen ist die Maximumsnorm der Grenzwert der p -Normen für $p \rightarrow \infty$.
- Schatten- p -Normen erfüllen alle drei Normaxiome aus Definition 3.2.1. Definitheit und absolute Homogenität lassen sich direkt nachrechnen; den aufwendigen Beweis der Dreiecksungleichung lassen wir weg.

3.4.2 Die drei wichtigen Spezialfälle

Drei Werte von p liefern die Normen, die in der Praxis dominieren; zwei davon kennen wir schon. Für den überraschendsten Fall verbinden wir die Frobenius-Norm über die Spur mit den Eigenwerten:

Satz 3.4.3 (Frobenius-Norm und Spur)

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Eigenwerten $\lambda_1 \geq \dots \geq \lambda_r > 0$ von $\mathbf{A}^\top \mathbf{A}$ (alle übrigen sind null) gilt

$$\|\mathbf{A}\|_F^2 = \operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{i=1}^r \lambda_i.$$

Beweis.

(1)

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{j=1}^n (\mathbf{A}^\top \mathbf{A})_{jj} = \sum_{j=1}^n \sum_{i=1}^m a_{ij}^2 = \|\mathbf{A}\|_F^2$$

Satz 3.1.10: Der Diagonaleintrag $(\mathbf{A}^\top \mathbf{A})_{jj}$ ist die quadrierte Länge der j -ten Spalte von $\mathbf{A}$

(2)

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{A}) = \operatorname{tr}(\mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top) = \operatorname{tr}(\mathbf{\Lambda} \mathbf{P}^\top \mathbf{P}) = \operatorname{tr}(\mathbf{\Lambda}) = \sum_{i=1}^r \lambda_i$$

Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$ mit orthogonalem $\mathbf{P}$ und $\mathbf{\Lambda} = \operatorname{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0)$; dann Zyklizität der Spur (Satz 3.1.4) und $\mathbf{P}^\top \mathbf{P} = \mathbf{I}$

□

Damit ergeben sich die Spezialfälle direkt:

Korollar 3.4.4 (Spezialfälle der Schatten-p-Norm)

- $p = \infty$: $\|\mathbf{A}\|_{S,\infty} = \sigma_1 = \sqrt{\lambda_{\max}} = \|\mathbf{A}\|_2$, die **Spektralnorm** aus Abschnitt 3.3.
- $p = 2$: $\|\mathbf{A}\|_{S,2} = (\sum_i \lambda_i)^{1/2} = \sqrt{\operatorname{tr}(\mathbf{A}^\top \mathbf{A})} = \|\mathbf{A}\|_F$, die **Frobenius-Norm** (nach Satz 3.4.3).
- $p = 1$: $\|\mathbf{A}\|_{S,1} = \sum_{i=1}^r \sigma_i =: \|\mathbf{A}\|_*$, die **Nuklearnorm** (nuclear norm).

Der Fall $p = 2$ überrascht: Die Frobenius-Norm hatten wir in Abschnitt 3.2 als elementweise Norm eingeführt, die von der Transformation nichts weiß. Sie ist aber zugleich eine Schatten-Norm, also durch die Singulärwerte bestimmt. Das erklärt auch Beispiel 3.2.6: Bei allen drei Matrizen summieren sich die quadrierten Singulärwerte zu 2.

Vertiefung (optional): Nuklearnorm und Niedrigrang-Probleme

Bemerkung 3.4.5 (Nuklearnorm und Niedrigrang-Probleme)

Warum eine dritte Norm, wenn wir schon zwei haben? Der Rang von A ist die Anzahl der Singulärwerte $\sigma_i > 0$. Rang-Minimierung ist ein kombinatorisch schwieriges Problem; die Nuklearnorm $\sum_i \sigma_i$ ist dagegen konvex und wird klein, wenn viele Singulärwerte (nahezu) verschwinden. Sie dient deshalb in Statistik und maschinellem Lernen als konvexer Ersatz für den Rang, etwa bei der Niedrigrang-Approximation und beim Vervollständigen von Matrizen mit fehlenden Einträgen (Empfehlungssysteme).

Konkret rechnen wir die drei Normen für die Matrix aus Beispiel 3.3.3 aus.

Beispiel 3.4.6

Sei $A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$. Die Eigenwerte von $A^T A = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix}$ kennen wir aus Beispiel 3.3.3:

$$\lambda_1 = 3 + \sqrt{5} \approx 5,236, \quad \lambda_2 = 3 - \sqrt{5} \approx 0,764.$$

Die Singulärwerte sind die Wurzeln daraus:

$$\sigma_1 = \sqrt{3 + \sqrt{5}} \approx 2,288, \quad \sigma_2 = \sqrt{3 - \sqrt{5}} \approx 0,874.$$

Spektralnorm ($p = \infty$): der größte Singulärwert,

$$\|A\|_{S,\infty} = \sigma_1 \approx 2,288.$$

Frobenius-Norm ($p = 2$): über die Singulärwerte und, zur Probe, *elementweise*, beides muss nach Korollar 3.4.4 dasselbe ergeben:

$$\|A\|_{S,2} = \sqrt{\lambda_1 + \lambda_2} = \sqrt{6}, \quad \sqrt{2^2 + 1^2 + 0^2 + 1^2} = \sqrt{6} \approx 2,449. \quad \square$$

Nuklearnorm ($p = 1$): die Summe der Singulärwerte:

$$\|A\|_{S,1} = \sigma_1 + \sigma_2 = \sqrt{10} \approx 3,162.$$

3.4.3 Unitäre Invarianz

Multiplizieren wir eine Matrix mit einer Orthogonalmatrix, etwa einer Drehung, dann ändern sich ihre Einträge und mit ihnen Summen- und Maximumsnorm. Die Streckungsfaktoren bleiben aber dieselben, nur die Richtungen rotieren. Schattenormen hängen allein von den Streckungsfaktoren ab und ändern sich deshalb nicht:

Satz 3.4.7 (Unitäre Invarianz)

Seien $P \in \mathbb{R}^{m \times m}$ und $Q \in \mathbb{R}^{n \times n}$ orthogonal. Dann gilt für alle $A \in \mathbb{R}^{m \times n}$ und alle $p \in [1, \infty]$:

$$\|PAQ\|_{S,p} = \|A\|_{S,p}.$$

Beweis.

(1)

$$(\mathbf{PAQ})^\top (\mathbf{PAQ}) = \mathbf{Q}^\top \mathbf{A}^\top \mathbf{P}^\top \mathbf{PAQ} = \mathbf{Q}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{Q}$$

Transponierregel $(\mathbf{BC})^\top = \mathbf{C}^\top \mathbf{B}^\top$ und Orthogonalität $\mathbf{P}^\top \mathbf{P} = \mathbf{I}$

(2) $(\mathbf{PAQ})^\top (\mathbf{PAQ})$ und $\mathbf{A}^\top \mathbf{A}$ haben dieselben Eigenwerte $\lambda_1, \dots, \lambda_n$.

$\mathbf{Q}^\top = \mathbf{Q}^{-1}$, also ist $\mathbf{Q}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{Q}$ ähnlich zu $\mathbf{A}^\top \mathbf{A}$, und ähnliche Matrizen haben dasselbe charakteristische Polynom:
 $\det(\mathbf{Q}^\top \mathbf{M} \mathbf{Q} - \lambda \mathbf{I}) = \det(\mathbf{Q}^\top (\mathbf{M} - \lambda \mathbf{I}) \mathbf{Q}) = \det(\mathbf{M} - \lambda \mathbf{I})$

(3) Also haben $\mathbf{PAQ}$ und $\mathbf{A}$ dieselben Singulärwerte und damit dieselbe Schatten-p-Norm, für jedes p gleichzeitig.

Schatten-p-Normen hängen nach Definition 3.4.1 nur vom Eigenwertvektor λ ab

□

Insbesondere ist $\|\mathbf{PAQ}\|_F = \|\mathbf{A}\|_F$. Die elementweise Definition verrät das nicht; erst Korollar 3.4.4 macht es offensichtlich. Für Summen- und Maximumsnorm gilt nichts dergleichen.

Bemerkung 3.4.8 (Namensgeber und Anwendung)

- Benannt sind die Normen nach dem Mathematiker *Robert Schatten* (1911–1977), der sie für unendlichdimensionale Operatoren untersuchte.
- Die unitäre Invarianz macht Schattennormen zum Standardwerkzeug für *Approximationsprobleme*: Wie gut eine Matrix eine andere approximiert, sollte nicht vom (orthogonalen) Koordinatensystem abhängen, in dem wir die Daten aufschreiben. In einer Schatten-Norm gemessen, ist das garantiert. Darauf kommen wir bei der Niedrigrang-Approximation zurück.

Interaktiv: Was überlebt eine Drehung? Schattennormen gegen elementweise Normen

Eine Drehung ändert jeden Eintrag der Matrix. Welche Normen bleiben dabei gleich, und welche wandern mit?

Interaktives Element — nur in der Web-Fassung

Ellipse, Halbachsen und alles, was aus ihnen gebaut ist (Spektral-, Frobenius- und Nuklearnorm), bleiben konstant, während sich die Einträge von $\mathbf{Q}_\theta \mathbf{A}$ ändern; die gemeldete Abweichung ist Rundungsrauschen der Größenordnung 10^{-16} . Summen- und Maximumsnorm, beide elementweise definiert, wandern sichtbar mit.

Selbsttest

- Sei $\mathbf{Q} \in \mathbb{R}^{n \times n}$ orthogonal. Was sind die Singulärwerte von $\mathbf{Q}$, und damit ihre Spektral-, Frobenius- und Nuklearnorm?

Wegen $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$ sind alle Eigenwerte von $\mathbf{Q}^\top \mathbf{Q}$ gleich 1, also $\sigma_1 = \dots = \sigma_n = 1$. Damit ist $\|\mathbf{Q}\|_{S,\infty} = 1$, $\|\mathbf{Q}\|_{S,2} = \sqrt{n}$ und $\|\mathbf{Q}\|_{S,1} = n$. Das passt zu Abschnitt 3.2: Auch dort war $\|\mathbf{I}_n\|_F = \sqrt{n}$; nur die Spektralnrm honoriert, dass eine Orthogonalmatrix „nichts streckt“.

1. Drehen wir im Schattennorm-Widget den Regler von 0° auf 90° (die Matrix bleibt die aus Beispiel 3.4.6). Welchen Wert zeigt es dann für die Nuklearnorm $\|Q_\theta A\|_{S,1}$?

Lösung: 3,162

$3,162 = \sqrt{10} = \sigma_1 + \sigma_2$, denselben Wert wie bei 0° . Alle vier Einträge der Matrix sind unterwegs andere geworden, die Singulärwerte nicht: Das ist Satz 3.4.7 an einer konkreten Zahl.

2. Weil die Drehung eine Isometrie ist, bleibt im Widget jede der angezeigten Normen konstant.

Antwort: Falsch

Konstant bleiben nur die Schattennormen, die aus den Singulärwerten gebaut sind. Summen- und Maximumsnorm lesen die Einträge ab und wandern mit; bei $\theta = 45^\circ$ etwa steigt die Summennorm von 4,000 auf 4,243. Satz 3.4.7 gilt für Schattennormen, nicht für alle Matrixnormen.

Vertiefung: MML §4.5 (SVD-Bezug: dort werden die Singulärwerte, auf denen die Schattennormen aufbauen, über die Singulärwertzerlegung systematisch entwickelt).

3.5 Eigenschaften von Matrixnormen

Kann dieselbe Matrix in einer Norm „klein“ und in einer anderen „riesig“ sein? Wie verhalten sich Matrixnormen unter der Multiplikation? Die Antworten heißen *Normenäquivalenz*, *Submultiplikativität* und *Verträglichkeit*; mit ihnen kommen wir zur Konditionszahl und zur Fehleranalyse.

3.5.1 Normenäquivalenz

Auf $\mathbb{R}^n$ sind alle Vektornormen äquivalent: Je zwei schätzen sich gegenseitig bis auf konstante Faktoren ab. Da eine Matrix aus Sicht der Normaxiome nur ein langer Vektor mit mn Einträgen ist, überträgt sich das direkt:

Satz 3.5.1 (Alle Matrixnormen sind äquivalent)

Für je zwei Matrixnormen $\|\cdot\|_a$ und $\|\cdot\|_b$ auf $\mathbb{R}^{m \times n}$ (bei festen m, n) existieren Konstanten $c, C > 0$ mit

$$c \|A\|_a \leq \|A\|_b \leq C \|A\|_a \quad \text{für alle } A \in \mathbb{R}^{m \times n}.$$

Den Beweis (wie im Vektorfall ein Kompaktheitsargument) führen wir nicht aus. Für die Praxis zählt, wie groß die Konstanten für die konkreten Normen dieses Kapitels ausfallen:

Beispiel 3.5.2 (Explizite Äquivalenzkonstanten)

Für $A \in \mathbb{R}^{m \times n}$ gilt unter anderem:

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{\min(m, n)} \|A\|_2,$$

$$\|A\|_F \leq \|A\|_* \leq \sqrt{\min(m, n)} \|A\|_F,$$

$$\frac{1}{\sqrt{n}} \|A\|_\infty \leq \|A\|_2 \leq \sqrt{m} \|A\|_\infty.$$

($\|\cdot\|_\infty$ ist hier die Zeilensummennorm aus Abschnitt 3.3, nicht die elementweise Maximumsnorm $\|\cdot\|_M$.) Die Konstanten hängen nur von den Dimensionen m, n ab und wachsen mit ihnen; für sehr große Matrizen können zwei Normen um Größenordnungen auseinanderliegen.

Vertiefung (optional): Beweis der Kette zwischen Spektral- und Frobenius-Norm

Die erste Kette folgt aus Abschnitt 3.4: Sind $\lambda_1 \geq \dots \geq \lambda_r > 0$ die positiven Eigenwerte von $A^\top A$ (mit $r = \text{rang}(A)$), so ist $\|A\|_2 = \sqrt{\lambda_1}$ und $\|A\|_F = \sqrt{\sum_{i=1}^r \lambda_i}$.

Beweis.

(1)

$$\|A\|_2^2 = \lambda_1 \leq \sum_{i=1}^r \lambda_i = \|A\|_F^2$$

alle λ_i sind positiv, die Summe ist also mindestens so groß wie ihr größter Summand λ_1

(2)

$$\|A\|_F^2 = \sum_{i=1}^r \lambda_i \leq r \cdot \lambda_1 \leq \min(m, n) \cdot \lambda_1 = \min(m, n) \cdot \|A\|_2^2$$

jeder der r Summanden ist höchstens λ_1 ; und der Rang erfüllt $r \leq \min(m, n)$

(3)

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{\min(m, n)} \|A\|_2$$

Wurzelziehen ist monoton, erhält also beide Ungleichungen

□

Bemerkung 3.5.3 (Äquivalenz ist nicht Gleichheit)

Äquivalenz heißt nur, dass keine Norm „unendlich viel größer“ sein kann als eine andere. Verschiedene Normen können Matrizen aber *unterschiedlich ordnen*. Betrachten wir

$$A = I_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 1,2 & 0 \\ 0 & 0 \end{pmatrix}.$$

In der Frobenius-Norm ist A die größere Matrix: $\|A\|_F = \sqrt{2} \approx 1,41 > 1,2 = \|B\|_F$. In der Spektralnrm ist es umgekehrt: $\|A\|_2 = 1 < 1,2 = \|B\|_2$. Beide Antworten sind richtig: Die Frobenius-Norm misst die „Gesamtmasse“ aller Einträge, die Spektralnrm die maximale Streckung. Welche Norm passt, entscheidet die Anwendung.

Interaktiv: Wie scharf sind die Äquivalenzkonstanten?

Lässt sich der Faktor $\sqrt{\min(m, n)}$ in der ersten Kette aus Beispiel 3.5.2 noch verbessern, oder gibt es Matrizen, für die eine der beiden Ungleichungen mit Gleichheit gilt? Spektral- und Frobenius-Norm hängen nur von den Singulärwerten ab, für 2×2 können wir das also vollständig durchprobieren.

Interaktives Element – nur in der Web-Fassung

Beide Enden der Kette werden an den Rändern des zulässigen Bereichs angenommen: unten,

wenn der zweite Singulärwert verschwindet, oben, wenn beide gleich sind. Dazwischen ist der Quotient echt kleiner als $\sqrt{2}$. Verbessern lässt sich die Konstante also nicht. Im $\mathbb{R}^{n \times n}$ steht dort $\sqrt{n}$, und für $\mathbf{A} = \mathbf{I}_n$ wird auch diese Schranke angenommen.

3.5.2 Submultiplikativität

Die Normaxiome regeln per Dreiecksungleichung, wie sich Normen unter *Addition* verhalten; über das *Matrixprodukt* sagen sie nichts. Algorithmen sind aber Ketten von Matrixmultiplikationen, und wir wollen abschätzen, wie stark so eine Kette Fehler aufbläht:

Definition 3.5.4 (Submultiplikative Matrixnorm)

Eine Matrixnorm $\|\cdot\|$ heißt *submultiplikativ*, wenn für alle Matrizen mit passenden Formaten ($\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{B} \in \mathbb{R}^{n \times p}$) gilt:

$$\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|.$$

Die wichtigsten Normen aus diesem Kapitel haben diese Eigenschaft.

Satz 3.5.5 (Operatornormen sind submultiplikativ)

Jede Operatornorm (Abschnitt 3.3) ist submultiplikativ.

Der Beweis ruht auf einer Ungleichung, die wir noch öfter brauchen:

Bemerkung 3.5.6 (Die Operatornorm als Streckungsschranke)

Für jede Matrix $\mathbf{M}$ und jeden Vektor $\mathbf{y}$ gilt

$$\|\mathbf{M}\mathbf{y}\|_V \leq \|\mathbf{M}\|_V \cdot \|\mathbf{y}\|_V.$$

Die Operatornorm ist als Maximum des Quotienten $\|\mathbf{M}\mathbf{y}\|_V / \|\mathbf{y}\|_V$ definiert, also mindestens so groß wie dieser Quotient an jeder einzelnen Stelle $\mathbf{y} \neq \mathbf{0}$; für $\mathbf{y} = \mathbf{0}$ stehen links und rechts null.

Vertiefung (optional): Beweis der Submultiplikativität von Operatornormen

Beweis.

(1) Sei $\mathbf{x}$ ein Vektor mit $\|\mathbf{x}\|_V = 1$. Dann:

$$\|(\mathbf{AB})\mathbf{x}\|_V = \|\mathbf{A}(\mathbf{B}\mathbf{x})\|_V \leq \|\mathbf{A}\|_V \|\mathbf{B}\mathbf{x}\|_V \leq \|\mathbf{A}\|_V \|\mathbf{B}\|_V.$$

Bemerkung 3.5.6 zweimal anwenden: erst auf $\mathbf{A}$ mit dem Vektor $\mathbf{B}\mathbf{x}$, dann auf $\mathbf{B}$ mit $\mathbf{x}$, wobei $\|\mathbf{x}\|_V = 1$

(2)

$$\|\mathbf{AB}\|_V = \max_{\|\mathbf{x}\|_V=1} \|(\mathbf{AB})\mathbf{x}\|_V \leq \|\mathbf{A}\|_V \cdot \|\mathbf{B}\|_V$$

die Operatornorm von $\mathbf{AB}$ ist das Maximum der linken Seite über alle $\mathbf{x}$ mit $\|\mathbf{x}\|_V = 1$; die rechte Seite hängt nicht von $\mathbf{x}$ ab

□

Auch alle Schatten-Normen aus Abschnitt 3.4 (insbesondere Frobenius- und Nukleornorm) sind

submultiplikativ. Den Beweis, der Ungleichungen für Singulärwerte von Produkten braucht, lassen wir weg.

Interaktiv: Gilt $\|AB\| \leq \|A\| \cdot \|B\|$ für jede Matrixnorm?

Gilt die Ungleichung vielleicht für jede Matrixnorm?

Interaktives Element — nur in der Web-Fassung

Nein. In Operator- und Schattennormen bleibt der Quotient $\|AB\| / (\|A\| \cdot \|B\|)$ höchstens 1, in der Maximumsnorm steigt er für die Einsermatrizen über 1. Ein einziges solches Paar widerlegt die Ungleichung für diese Norm.

Beispiel 3.5.7 (Die Maximumsnorm ist nicht submultiplikativ)

Betrachten wir die Einsermatrix $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ und ihr Quadrat. Jeder Eintrag von A^2 ist ein Skalarprodukt aus einer Zeile und einer Spalte voller Einsen:

$$A^2 = \begin{pmatrix} 1 \cdot 1 + 1 \cdot 1 & 1 \cdot 1 + 1 \cdot 1 \\ 1 \cdot 1 + 1 \cdot 1 & 1 \cdot 1 + 1 \cdot 1 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}.$$

Damit ist

$$\|A^2\|_M = 2 > 1 = 1 \cdot 1 = \|A\|_M \cdot \|A\|_M.$$

Die Maximumsnorm „übersieht“, dass bei der Matrixmultiplikation viele Produkte *aufsummiert* werden, denn sie schaut nur auf den größten einzelnen Eintrag.

Vertiefung (optional): Reparatur der Maximumsnorm

Bemerkung 3.5.8 (Reparatur: die Gesamtnorm)

Der Defekt lässt sich durch einen dimensionsabhängigen Faktor beheben: Die *Gesamtnorm* $\|A\|_G := \sqrt{mn} \|A\|_M$ ist submultiplikativ. Der Nachweis ist eine gute Übung; er benutzt die Summenstruktur des Matrixprodukts, die die Maximumsnorm ignoriert. Probe an Beispiel 3.5.7 mit $m = n = 2$, also $\sqrt{mn} = 2$: $\|A\|_G = 2 \cdot 1 = 2$ und $\|A^2\|_G = 2 \cdot 2 = 4 \leq 4 = \|A\|_G^2$.

Wozu Submultiplikativität? Sie kontrolliert die *Fehlerfortpflanzung*: Für eine Kette $A_1 A_2 \cdots A_k$ deckeln die Normen der Faktoren die Norm des Produkts, $\|A_1 \cdots A_k\| \leq \|A_1\| \cdots \|A_k\|$. Sie trägt Konvergenzanalysen iterativer Verfahren: Aus $\|A\| < 1$ folgt $\|A^k\| \leq \|A\|^k \rightarrow 0$, die Potenzen einer solchen Matrix gehen also gegen die Nullmatrix. Und sie verbindet Normen mit dem Spektralradius: Für jede submultiplikative Norm gilt $\rho(A) \leq \|A\|$ (ohne Beweis), jede solche Norm beschränkt also die Beträge aller Eigenwerte.

3.5.3 Verträglichkeit von Normen

Oft wirkt eine Matrix auf einen *Vektor*, und wir wollen $\|Ax\|$ durch die Normen von A und x abschätzen:

Definition 3.5.9 (Verträgliche Norm)

Eine Matrixnorm $\|\cdot\|$ ist *verträglich* (kompatibel) mit einer Vektornorm $\|\cdot\|_V$, wenn für alle $A \in \mathbb{R}^{m \times n}$ und $x \in \mathbb{R}^n$ gilt:

$$\|Ax\|_V \leq \|A\| \cdot \|x\|_V.$$

(Dabei bezeichnet $\|\cdot\|_V$ die Vektornorm gleichen Typs auf $\mathbb{R}^n$ und auf $\mathbb{R}^m$.)

Satz 3.5.10 (Wichtige Verträglichkeiten)

1. Jede submultiplikative Matrixnorm ist mit „sich selbst“ verträglich, d. h. mit der Vektornorm, die entsteht, wenn wir $x \in \mathbb{R}^n$ als $n \times 1$ -Matrix lesen.
2. Jede Operatornorm ist mit der Vektornorm verträglich, die sie induziert.
3. Die Frobenius-Norm ist mit der euklidischen Norm verträglich: $\|Ax\|_2 \leq \|A\|_F \|x\|_2$.

Vertiefung (optional): Beweis der drei Verträglichkeiten

Beweis.

- (1) Zu (1): Lesen wir x als $n \times 1$ -Matrix, so ist Ax ein Matrixprodukt, und die Submultiplikativität liefert direkt

$$\|Ax\| \leq \|A\| \cdot \|x\|.$$

Submultiplikativität (Definition 3.5.4), angewendet auf das Matrixprodukt einer $m \times n$ - mit einer $n \times 1$ -Matrix

- (2) Zu (2): Das ist Bemerkung 3.5.6.
- (3) Zu (3): Schreiben wir A zeilenweise mit Zeilenvektoren $a_1^\top, \dots, a_m^\top$. Die i -te Komponente von Ax ist das Skalarprodukt $a_i^\top x$, also

$$\|Ax\|_2^2 = \sum_{i=1}^m (a_i^\top x)^2 \leq \sum_{i=1}^m \|a_i\|_2^2 \|x\|_2^2.$$

Cauchy-Schwarz-Ungleichung für jedes einzelne Skalarprodukt $a_i^\top x$

$$(4) \quad \|Ax\|_2^2 \leq \left(\sum_{i=1}^m \|a_i\|_2^2 \right) \|x\|_2^2 = \|A\|_F^2 \|x\|_2^2$$

die Summe der quadrierten Zeilennormen ist genau die Summe aller quadrierten Einträge, also $\|A\|_F^2$; dann Wurzel ziehen

□

Verträglichkeit ist das Werkzeug für *Fehlerabschätzungen*. Steckt in einem Vektor ein Fehler e (etwa aus Rundungsfehlern früherer Rechenschritte) und multiplizieren wir mit A , so gilt $\|Ae\|_V \leq \|A\| \cdot \|e\|_V$: Die Matrixnorm ist der Verstärkungsfaktor im schlimmsten Fall, ein kleiner Eingangsfehler bleibt kontrolliert.

3.5.4 Matrixnormen und Konditionierung

Die Konditionszahl misst, wie stark ein Problem relative Eingabefehler verstärkt. Für lineare Gleichungssysteme $\mathbf{Ax} = \mathbf{b}$ lässt sich dieser Faktor aus Matrixnormen gewinnen; das rechnen wir in Abschnitt 4.2 nach. Die Definition halten wir schon hier fest:

Definition 3.5.11 (Konditionszahl einer Matrix)

Für eine invertierbare Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ und eine submultiplikative Matrixnorm $\|\cdot\|$ ist die *Konditionszahl*

$$\kappa(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|;$$

für singuläre Matrizen setzen wir $\kappa(\mathbf{A}) = \infty$. Speziell für die Spektralnorm ergibt sich die *Spektralkondition*

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \cdot \|\mathbf{A}^{-1}\|_2 = \frac{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})^{1/2}}{\lambda_{\min}(\mathbf{A}^\top \mathbf{A})^{1/2}}.$$

Die zweite Gleichheit der Spektralkondition folgt in Kapitel 6 aus der Singulärwertzerlegung. Inhaltlich ist $\kappa_2(\mathbf{A})$ das *Verhältnis der extremen Streckungsfaktoren*: maximale Streckung durch $\mathbf{A}$ geteilt durch minimale Streckung, also der Quotient aus größtem und kleinstem Singulärwert. Für *symmetrische* Matrizen sind die Singulärwerte die Beträge der Eigenwerte; dort ist $\kappa_2(\mathbf{A}) = \max_i |\lambda_i| / \min_i |\lambda_i|$.

Diese Deutung als Verhältnis von Streckungsfaktoren gilt in jeder *Operatornorm*. In anderen submultiplikativen Normen kann schon die Normierung abweichen: $\kappa_F(\mathbf{I}_n) = n$, nicht 1.

Bemerkung 3.5.12 (Interpretation der Konditionszahl)

Für eine induzierte Operatornorm gilt:

- $\kappa(\mathbf{A}) \approx 1$: gut konditioniert; $\mathbf{A}$ streckt alle Richtungen ungefähr gleich stark.
- $\kappa(\mathbf{A}) \gg 1$: schlecht konditioniert; manche Richtungen werden enorm gestreckt, andere fast plattgedrückt.
- $\kappa(\mathbf{A}) = \infty$: singulär.

Kleiner als 1 kann die Konditionszahl (in einer Operatornorm) nie werden: Wegen $\|\mathbf{I}\| = 1$ und der Submultiplikativität gilt

$$1 = \|\mathbf{I}\| = \|\mathbf{A}\mathbf{A}^{-1}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\| = \kappa(\mathbf{A}).$$

Den Idealwert $\kappa_2 = 1$ erreichen zum Beispiel Orthogonalmatrizen: Sie lassen alle euklidischen Längen unverändert, strecken also jede Richtung mit dem Faktor 1 (Bemerkung 3.3.6).

3.5.5 Normen in der Fehleranalyse

Lösen wir $\mathbf{Ax} = \mathbf{b}$ numerisch, erhalten wir wegen Rundungsfehlern nicht die exakte Lösung, sondern eine Näherung $\tilde{\mathbf{x}}$. Die *Rückwärts-Fehleranalyse* (backward error analysis) fragt nicht, wie falsch $\tilde{\mathbf{x}}$ ist (Vorwärtsfehler), sondern: *Für welches gestörte Problem ist $\tilde{\mathbf{x}}$ die exakte Lösung?* Ist die nötige Störung winzig, ist der Algorithmus nicht zu beanstanden; alles Weitere ist Sache der Kondition des Problems.

Satz 3.5.13 (Rückwärtsfehler beim linearen Gleichungssystem)

Sei $\tilde{\mathbf{x}} \neq \mathbf{0}$ eine Näherungslösung von $\mathbf{A}\mathbf{x} = \mathbf{b}$ mit Residuum $\mathbf{r} = \mathbf{A}\tilde{\mathbf{x}} - \mathbf{b}$. Dann löst $\tilde{\mathbf{x}}$ das gestörte System

$$(\mathbf{A} + \Delta\mathbf{A})\tilde{\mathbf{x}} = \mathbf{b} \quad \text{mit} \quad \Delta\mathbf{A} = -\frac{\mathbf{r}\tilde{\mathbf{x}}^\top}{\|\tilde{\mathbf{x}}\|_2^2}$$

exakt, und die relative Größe der Störung ist

$$\frac{\|\Delta\mathbf{A}\|_2}{\|\mathbf{A}\|_2} = \frac{\|\mathbf{r}\|_2}{\|\mathbf{A}\|_2 \cdot \|\tilde{\mathbf{x}}\|_2}.$$

Vertiefung (optional): Beweis der Rückwärtsfehler-Formel

Beweis.

(1)

$$\Delta\mathbf{A}\tilde{\mathbf{x}} = -\frac{\mathbf{r}(\tilde{\mathbf{x}}^\top\tilde{\mathbf{x}})}{\|\tilde{\mathbf{x}}\|_2^2} = -\mathbf{r}$$

$\mathbf{r}\tilde{\mathbf{x}}^\top$ ist ein äußeres Produkt; multiplizieren wir es mit $\tilde{\mathbf{x}}$, entsteht das Skalarprodukt $\tilde{\mathbf{x}}^\top\tilde{\mathbf{x}} = \|\tilde{\mathbf{x}}\|_2^2$, das sich gegen den Nenner kürzt

(2)

$$(\mathbf{A} + \Delta\mathbf{A})\tilde{\mathbf{x}} = \mathbf{A}\tilde{\mathbf{x}} - \mathbf{r} = \mathbf{b} + \mathbf{r} - \mathbf{r} = \mathbf{b}$$

Definition des Residuums: $\mathbf{A}\tilde{\mathbf{x}} = \mathbf{b} + \mathbf{r}$

(3)

$$\|\Delta\mathbf{A}\|_2 = \frac{\|\mathbf{r}\tilde{\mathbf{x}}^\top\|_2}{\|\tilde{\mathbf{x}}\|_2^2} = \frac{\|\mathbf{r}\|_2 \|\tilde{\mathbf{x}}\|_2}{\|\tilde{\mathbf{x}}\|_2^2} = \frac{\|\mathbf{r}\|_2}{\|\tilde{\mathbf{x}}\|_2}$$

für Rang-1-Matrizen gilt $\|\mathbf{u}\mathbf{v}^\top\|_2 = \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$: wegen $(\mathbf{u}\mathbf{v}^\top)\mathbf{x} = (\mathbf{v}^\top\mathbf{x})\mathbf{u}$ wird $\|(\mathbf{u}\mathbf{v}^\top)\mathbf{x}\|_2 = |\mathbf{v}^\top\mathbf{x}| \|\mathbf{u}\|_2$ nach Cauchy-Schwarz maximal für $\mathbf{x} = \mathbf{v}/\|\mathbf{v}\|_2$

(4)

$$\frac{\|\Delta\mathbf{A}\|_2}{\|\mathbf{A}\|_2} = \frac{\|\mathbf{r}\|_2}{\|\mathbf{A}\|_2 \cdot \|\tilde{\mathbf{x}}\|_2}$$

beide Seiten durch $\|\mathbf{A}\|_2$ teilen

□

Matrixnormen machen den Rückwärtsfehler *berechenbar*: Rechts stehen nur Größen, die nach der Rechnung vorliegen, und ein kleines relatives Residuum bedeutet, dass $\tilde{\mathbf{x}}$ ein nur winzig gestörtes System exakt löst. Wie weit $\tilde{\mathbf{x}}$ dann von der wahren Lösung entfernt sein kann, entscheidet die Konditionszahl aus Definition 3.5.11. Als Faustregel gilt: Vorwärtsfehler $\lesssim \kappa(\mathbf{A}) \times$ Rückwärtsfehler.

Selbsttest

- Gilt $\|\mathbf{A}^2\| \leq \|\mathbf{A}\|^2$ für jede Matrixnorm?

Nein, garantiert ist das nur für submultiplikative Normen. Die Maximumsnorm liefert ein Gegenbeispiel: Für die Einsermatrix aus Beispiel 3.5.7 ist $\|\mathbf{A}^2\|_M = 2 > 1 = \|\mathbf{A}\|_M^2$. Operator- und Schatten-Normen (also auch Spektral-, Frobenius- und Nuklearnorm) erfüllen die Ungleichung dagegen immer.

- Sei Q eine Orthogonalmatrix. Was ist $\kappa_2(Q)$?

$\kappa_2(Q) = 1$. Wegen $\|Qx\|_2 = \|x\|_2$ für alle x ist $\|Q\|_2 = 1$; und $Q^{-1} = Q^T$ ist selbst orthogonal, also auch $\|Q^{-1}\|_2 = 1$. Orthogonalmatrizen sind perfekt konditioniert, ein Hauptgrund, warum numerische Verfahren so oft mit ihnen arbeiten.

- Für die Einheitsmatrix gilt $\|I_n\|_2 = 1$, aber $\|I_n\|_F = \sqrt{n}$. Widerspricht das der Normen-äquivalenz (Satz 3.5.1)? Und was sagt uns das Beispiel über die Konstante $\sqrt{\min(m, n)}$ aus Beispiel 3.5.2?

Kein Widerspruch: Satz 3.5.1 gilt bei *festen* Dimensionen, und die Konstanten dürfen von m, n abhängen. Das Beispiel zeigt außerdem, dass die Konstante scharf ist: $\|I_n\|_F = \sqrt{n} = \sqrt{\min(n, n)} \cdot \|I_n\|_2$, die obere Schranke aus Beispiel 3.5.2 wird also angenommen.

1. Ziehen wir im Äquivalenz-Widget den Punkt auf die Winkelhalbierende $\sigma_1 = \sigma_2$. Welchen Quotienten $\|A\|_F / \|A\|_2$ zeigt es dann?

Lösung: 1.414

$\sqrt{2} \approx 1,414$, unabhängig davon, wie weit außen auf der Winkelhalbierenden wir landen. Dort ist A ein Vielfaches der Einheitsmatrix, und die rechte Ungleichung aus Beispiel 3.5.2 steht mit Gleichheit. Auf der waagerechten Achse dagegen ist der Quotient 1.

2. Stellen wir im Submultiplikativitäts-Widget die Einsermatrix für A und B ein und wählen wir die Maximumsnorm. Welchen Quotienten $\|AB\| / (\|A\| \cdot \|B\|)$ zeigt der Balken?

Lösung: 2

2, also doppelt so viel wie erlaubt. Alle Einträge von AB sind 2, alle Einträge von A und B sind 1: $2/(1 \cdot 1) = 2$ (Beispiel 3.5.7). Schalten wir bei denselben Matrizen auf eine Operatornorm um, springt der Balken auf 1: Dort ist die Schranke aus Satz 3.5.5 scharf, aber nicht verletzt.

Vertiefung: Heath §2.3.

3.6 Zusammenfassung

Dieses Kapitel hat zwei Arten von Kennzahlen einer Matrix eingeführt: die Spur als skalare Invariante und drei Familien von Matrixnormen. Operator- und Schattenormen sagen etwas über die lineare Abbildung $x \mapsto Ax$ aus, nicht nur über die Einträge.

Die Konzepte im Überblick

Konzept	Kernaussage	Abschnitt
Spur	$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii}$; linear, zyklisch ($\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$) und damit ähnlichkeitsinvariant; gleich der Summe der Eigenwerte (Koeffizient des charakteristischen Polynoms)	3.1
Matrixnorm	dieselben Axiome wie bei Vektornormen: Definitheit, absolute Homogenität, Dreiecksungleichung	3.2
elementweise Normen	Vektornorm auf $\text{vec}(\mathbf{A})$: $\ \mathbf{A}\ _F$, $\ \mathbf{A}\ _S$, $\ \mathbf{A}\ _M$; schnell berechnet, aber blind für die Transformation	3.2
Operatornormen	maximale Streckung $\max_{\mathbf{x} \neq 0} \ \mathbf{Ax}\ _V / \ \mathbf{x}\ _V$: Spaltensummennorm $\ \mathbf{A}\ _1$, Spektralnorm $\ \mathbf{A}\ _2$, Zeilensummennorm $\ \mathbf{A}\ _\infty$	3.3
Schatten-p-Normen	p -Norm des Vektors der Singulärwerte $\sigma_i = \sqrt{\lambda_i(\mathbf{A}^\top \mathbf{A})}$; invariant unter orthogonalen Transformationen	3.4
Eigenschaften	Normäquivalenz, Submultiplikativität ($\ \mathbf{AB}\ \leq \ \mathbf{A}\ \ \mathbf{B}\ $), Verträglichkeit mit Vektornormen; Konditionszahl $\kappa(\mathbf{A}) = \ \mathbf{A}\ \ \mathbf{A}^{-1}\ $	3.5

Die drei Familien hängen zusammen. Die Frobenius-Norm ist elementweise Norm (die euklidische Norm von $\text{vec}(\mathbf{A})$) und zugleich die Schatten-Norm mit $p = 2$; die Verbindung liefert die Spur, $\|\mathbf{A}\|_F^2 = \text{tr}(\mathbf{A}^\top \mathbf{A})$. Die Spektralnorm ist die von der euklidischen Norm induzierte Operatornorm und die Schatten-Norm mit $p = \infty$, berechenbar als $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$; hier knüpft die Singulärwertzerlegung in Kapitel 6 an.

Vertiefung (optional): Was kostet die Berechnung der einzelnen Normen?

Spalten- und Zeilensummennorm sowie die Frobenius-Norm brauchen nur einen Durchlauf über alle Einträge. Für die exakte Spektral- und Nukleornorm berechnen dichte Standardverfahren dagegen eine Spektralzerlegung bzw. SVD. Genügt eine Näherung des größten Singulärwerts, können iterative oder randomisierte Verfahren deutlich billiger sein.

Norm	Aufwand	Algorithmus
$\ \mathbf{A}\ _1$	$O(mn)$	Spaltensummen berechnen
$\ \mathbf{A}\ _\infty$	$O(mn)$	Zeilensummen berechnen
$\ \mathbf{A}\ _F$	$O(mn)$	Quadratsumme aller Einträge
$\ \mathbf{A}\ _2$	$O(\min(m^2n, mn^2))$	größten Singulärwert berechnen (dicht: SVD; approximativ: Iteration)
$\ \mathbf{A}\ _*$	$O(\min(m^2n, mn^2))$	SVD, dann Singulärwerte summieren

Vertiefung (optional): Ausblick: Normen als Regularisierer im maschinellen Lernen

Bemerkung 3.6.1

Im maschinellen Lernen steuern Normen als Strafterme, *welche* Lösung ein Schätzproblem liefert. Drei Beispiele, alle Varianten des KQ-Problems:

$$\text{Ridge: } \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_2^2, \quad \text{LASSO: } \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1,$$

$$\text{Matrix Completion: } \min_{\mathbf{X}} \|\mathbf{P}_{\Omega}(\mathbf{X}) - \mathbf{P}_{\Omega}(\mathbf{M})\|_F^2 + \lambda \|\mathbf{X}\|_*.$$

Verschiedene Normen erzwingen verschiedene Lösungseigenschaften: Die 2-Norm schrumpft alle Koeffizienten gleichmäßig, die 1-Norm setzt viele exakt auf null, und die Nukleornorm aus Abschnitt 3.4 begünstigt Lösungen mit kleinem Rang (Niedrigrang-Approximation).

Selbsttest

Welche der folgenden Aussagen über die Spur sind wahr ($\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$)?

1. $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{A}) \cdot \text{tr}(\mathbf{B})$

Antwort: Falsch

Die Spur ist nicht multiplikativ. Gegenbeispiel $\mathbf{A} = \mathbf{B} = \mathbf{I}_2$: links steht $\text{tr}(\mathbf{I}_2) = 2$, rechts $2 \cdot 2 = 4$.

2. $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$

Antwort: Wahr

Das ist die zyklische Eigenschaft aus Satz 3.1.4, die wichtigste Rechenregel der Spur.

3. $\text{tr}(\mathbf{A}^\top) = -\text{tr}(\mathbf{A})$

Antwort: Falsch

Transponieren spiegelt an der Diagonale und lässt die Diagonaleinträge unverändert; es gilt $\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$, ohne Vorzeichenwechsel.

4. $\text{tr}(\mathbf{I}_n) = n$

Antwort: Wahr

Auf der Diagonale stehen n Einsen, also ist die Summe n .

5. Ist $\mathbf{A}$ invertierbar, so gilt $\text{tr}(\mathbf{A}^{-1}) = 1/\text{tr}(\mathbf{A})$.

Antwort: Falsch

Gegenbeispiel $\mathbf{A} = 2\mathbf{I}_2$: dann ist $\mathbf{A}^{-1} = \frac{1}{2}\mathbf{I}_2$, also $\text{tr}(\mathbf{A}^{-1}) = 1$, aber $1/\text{tr}(\mathbf{A}) = \frac{1}{4}$.

Berechnen wir für $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 0 \end{pmatrix}$ die Spaltensummennorm $\|\mathbf{A}\|_1$, die Zeilensummennorm $\|\mathbf{A}\|_\infty$ und die Frobenius-Norm $\|\mathbf{A}\|_F$.

Spaltensummennorm: Die Beträge spaltenweise summieren; die **erste Spalte** gewinnt:

$$\|\mathbf{A}\|_1 = \max\{|1| + |3|, |2| + |0|\} = \max\{4, 2\} = 4.$$

Zeilensummennorm: Die Beträge zeilenweise summieren; hier liefern **beide Zeilen** denselben Wert:

$$\|\mathbf{A}\|_{\infty} = \max\{|1| + |2|, |3| + |0|\} = \max\{3, 3\} = 3.$$

Frobenius-Norm: Wurzel aus der Quadratsumme aller Einträge:

$$\|\mathbf{A}\|_F = \sqrt{1^2 + 2^2 + 3^2 + 0^2} = \sqrt{14} \approx 3,74.$$

Probe über die Spur (Satz 3.1.10): $\mathbf{A}^T \mathbf{A} = \begin{pmatrix} 10 & 2 \\ 2 & 4 \end{pmatrix}$, also $\text{tr}(\mathbf{A}^T \mathbf{A}) = 10 + 4 = 14 = \|\mathbf{A}\|_F^2$. ☒ Zum

Vergleich: Die Spektralnorm ist $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})} = \sqrt{7 + \sqrt{13}} \approx 3,26$, kleiner als die Frobenius-Norm, wie es Beispiel 3.5.2 verlangt.

Wie geht es weiter?

Matrixnormen sind das Messwerkzeug der *Fehleranalyse* in Kapitel 4. Mit Konditionszahl, Rückwärtsfehler, Submultiplikativität und Verträglichkeit (Abschnitt 3.5) schätzen wir dort ab, wie viel Vertrauen eine numerisch berechnete Lösung verdient.

Vertiefung: Heath §2.3; MML §4.1/4.5.

3.7 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuffhard/Hohmann Aufgabe 2.9	Spektralnorm und Frobenius-Norm	mittel, 1 Std. und mehr

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuffhard/Hohmann Aufgabe 2.7	Operatornormen sind Matrixnormen	mittel, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.8	Spaltensummen-, Zeilensummen- und Spektralnorm	mittel, 1 Std. und mehr

Bücher: Deuffhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.).

Fehler, Kondition & Stabilität

4.1 Fehlermaße und Fehlerzerlegung

Computer rechnen praktisch nie exakt: Schon das Speichern einer Zahl im Gleitkommaformat erzeugt Rundungsfehler, und jede Rechenoperation kann weitere hinzufügen (Abschnitt 2.1). In der Statistik kommt hinzu: Unsere Inputs sind Daten, und Daten sind gemessen, also fehlerbehaftet, bevor der Computer anfängt zu rechnen. Wir klären zuerst, wie wir Fehler *messen*, und zerlegen dann den Gesamtfehler eines berechneten Ergebnisses in seine zwei Quellen. Diese Zerlegung führt auf die Begriffe *Kondition* (Abschnitt 4.2) und *Stabilität* (Abschnitt 4.3).

Bemerkung 4.1.1 (Verwendete Vorkenntnisse)

Dieses Kapitel setzt voraus:

- aus Kapitel 2: den Algorithmusbegriff und die Komplexitätsanalyse (Abschnitte 2.1–2.3) sowie das Verständnis, dass Algorithmen meist nur *approximative* Lösungen berechnen,
- aus der linearen Algebra: Vektor- und Matrixnormen (Kapitel 3, insbesondere Abschnitt 3.2) mit den Normeigenschaften Definitheit, Homogenität und Dreiecksungleichung, außerdem Matrixoperationen und Matrix-Vektor-Produkte,
- aus der Analysis: Grenzwerte und Konvergenz, Stetigkeit und die Grundlagen der Taylor-Approximation.

4.1.1 Absolute und relative Fehler

Soll eine einzelne Zahl gespeichert oder berechnet werden, erhalten wir statt des **tatsächlichen Werts** einen **fehlerhaften Wert**. Am einfachsten messen wir den Fehler als Differenz der beiden:

$$\text{absoluter Fehler} = \text{fehlerhafter Wert} - \text{tatsächlicher Wert}.$$

Der absolute Fehler hängt aber von der Skala ab. Ein Fehler von einem Meter ist beim Vermessen eines Zimmers viel, beim Abstand zwischen München und Hamburg belanglos. Deshalb ist es üblicher, Fehler *relativ* zum tatsächlichen Wert zu betrachten:

$$\text{relativer Fehler} = \frac{\text{fehlerhafter Wert} - \text{tatsächlicher Wert}}{\text{tatsächlicher Wert}}.$$

Der Vorteil: Der relative Fehler ist einheitenfrei und lässt sich als Prozentzahl lesen. Der Nachteil: Der tatsächliche Wert darf nicht 0 sein. Lösen wir die Definition nach dem fehlerhaften Wert auf, erhalten wir eine Umformung, die uns noch oft begegnen wird:

$$\text{fehlerhafter Wert} = \text{tatsächlicher Wert} \cdot (1 + \text{relativer Fehler}).$$

So lässt sich auch das Runden im Gleitkommaformat aus Kapitel 2 beschreiben: Dort ist der relative Fehler höchstens die Maschinengenauigkeit.

4.1.2 Fehlermaße und Fehlerschranken

In der Statistik sind Ergebnisse selten einzelne Zahlen: Wir rechnen mit Vektoren von Schätzern, mit Kovarianzmatrizen, mit ganzen Funktionen. Dort tritt an die Stelle des Betrags eine Norm (Kapitel 3), und beide Fehlerbegriffe übertragen sich auf beliebige Vektorräume:

Definition 4.1.2 (Fehlermaß)

Sei V ein Vektorraum mit (Semi-)Norm $\|\cdot\|$ und $\tilde{\mathbf{v}} \in V$ eine Approximation zu $\mathbf{v} \in V$. Dann ist

- der *absolute Fehler*

$$\Delta_{\mathbf{v}} = \tilde{\mathbf{v}} - \mathbf{v},$$

- der *relative Fehler*

$$\delta_{\mathbf{v}} = \frac{\|\tilde{\mathbf{v}} - \mathbf{v}\|}{\|\mathbf{v}\|} = \frac{\|\Delta_{\mathbf{v}}\|}{\|\mathbf{v}\|} \quad (\text{sofern } \|\mathbf{v}\| \neq 0).$$

Der absolute Fehler $\Delta_{\mathbf{v}}$ ist selbst ein Element von V und sagt auch, *in welche Richtung* die Approximation danebenliegt; der relative Fehler $\delta_{\mathbf{v}}$ ist eine einzelne nichtnegative Zahl. Für Skalare ($V = \mathbb{R}$ mit dem Betrag als Norm) ist $\delta_{\mathbf{v}}$ der Betrag des relativen Fehlers aus Abschnitt 4.1.1.

Den Fehler selbst kennen wir meist nicht, sonst könnten wir ihn abziehen. Angeben können wir eine Schranke nach oben: Gilt $\|\Delta_{\mathbf{v}}\| \leq \varepsilon$ bzw. $\delta_{\mathbf{v}} \leq \varepsilon$, so nennen wir ε eine *absolute* bzw. *relative Fehlerschranke*. Eine relative Fehlerschranke kontrolliert auch, wie weit die Norm der Approximation von der Norm des wahren Werts abweichen kann:

Lemma 4.1.3 (Fehlerschranken)

Es gilt

$$\|\mathbf{z}\| (1 - \delta_{\mathbf{z}}) \leq \|\tilde{\mathbf{z}}\| \leq \|\mathbf{z}\| (1 + \delta_{\mathbf{z}}).$$

Beweis.

(1)

$$\delta_{\mathbf{z}} = \frac{\|\tilde{\mathbf{z}} - \mathbf{z}\|}{\|\mathbf{z}\|} \implies \|\tilde{\mathbf{z}} - \mathbf{z}\| = \delta_{\mathbf{z}} \|\mathbf{z}\|$$

Definition des relativen Fehlers $\delta_{\mathbf{z}}$, beide Seiten mit $\|\mathbf{z}\| > 0$ multipliziert

(2)

$$\left| \|\tilde{\mathbf{z}}\| - \|\mathbf{z}\| \right| \leq \|\tilde{\mathbf{z}} - \mathbf{z}\| = \delta_{\mathbf{z}} \|\mathbf{z}\|$$

umgekehrte Dreiecksungleichung: $\|a\| - \|b\| \leq \|a - b\|$ für alle $a, b \in V$

(3)

$$-\delta_{\mathbf{z}} \|\mathbf{z}\| \leq \|\tilde{\mathbf{z}}\| - \|\mathbf{z}\| \leq \delta_{\mathbf{z}} \|\mathbf{z}\|$$

Definition des Betrags: $|t| \leq c \Leftrightarrow -c \leq t \leq c$

(4)

$$\|z\| - \delta_z \|z\| \leq \|\tilde{z}\| \leq \|z\| + \delta_z \|z\|$$

überall $\|z\|$ addiert; Ausklammern liefert die Behauptung

□

Ein relativer Fehler von zum Beispiel $\delta_z = 0,01$ garantiert also: Die Norm der Approximation liegt zwischen 99 % und 101 % der wahren Norm.

Beispiel 4.1.4 (Fehlermaße für Vektoren)

Sei $\mathbf{v} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$ und $\tilde{\mathbf{v}} = \begin{pmatrix} 3,2 \\ 4,3 \end{pmatrix}$ mit der euklidischen Norm $\|\cdot\|_2$.

Absoluter Fehler, komponentenweise Differenz:

$$\Delta_{\mathbf{v}} = \tilde{\mathbf{v}} - \mathbf{v} = \begin{pmatrix} 3,2 \\ 4,3 \end{pmatrix} - \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 0,2 \\ 0,3 \end{pmatrix}.$$

Norm des absoluten Fehlers:

$$\|\Delta_{\mathbf{v}}\|_2 = \sqrt{0,2^2 + 0,3^2} = \sqrt{0,04 + 0,09} = \sqrt{0,13} \approx 0,361.$$

Relativer Fehler, wegen $\|\mathbf{v}\|_2 = \sqrt{3^2 + 4^2} = \sqrt{25} = 5$:

$$\delta_{\mathbf{v}} = \frac{\|\Delta_{\mathbf{v}}\|_2}{\|\mathbf{v}\|_2} = \frac{\sqrt{0,13}}{5} \approx \frac{0,361}{5} \approx 0,072 = 7,2\%.$$

Fehlerschranke: Wegen $\delta_{\mathbf{v}} \approx 0,072 \leq 0,1$ ist $\varepsilon = 0,1$ eine relative Fehlerschranke.

Interaktiv: Fehlermaß-Rechner: $\mathbf{v}$ und $\tilde{\mathbf{v}}$ in der Ebene

Für den Vektor aus Beispiel 4.1.4 heißt $\delta_{\mathbf{v}} \leq 0,1$: Die Spitze von $\tilde{\mathbf{v}}$ liegt höchstens $0,1 \cdot \|\mathbf{v}\|_2$ neben der von $\mathbf{v}$. Wie groß ist dieser Spielraum in der Ebene, und was sagt Lemma 4.1.3 dann über $\|\tilde{\mathbf{v}}\|$?

Interaktives Element — nur in der Web-Fassung

Der absolute Fehler $\Delta_{\mathbf{v}}$ ist der rote Pfeil zwischen den beiden Spitzen, der relative Fehler setzt seine Länge ins Verhältnis zu $\|\mathbf{v}\|_2$. Solange die blaue Spitze im gestrichelten Kreis um $\mathbf{v}$ mit Radius $0,1 \cdot 5 = 0,5$ liegt, ist $\varepsilon = 0,1$ eine gültige Fehlerschranke. Der orange Ring um den Ursprung zeigt Lemma 4.1.3: Bei den 7,2 % aus Beispiel 4.1.4 ist er schmal (mit $\|\tilde{\mathbf{v}}\|_2 = \sqrt{28,73}$ gilt $5 \cdot (1 - \delta_{\mathbf{v}}) \approx 4,6394 \leq 5,3600 \leq 5,3606 \approx 5 \cdot (1 + \delta_{\mathbf{v}})$), bei 40 % lässt er für $\|\tilde{\mathbf{v}}\|_2$ fast alles zu.

4.1.3 Fehlerzerlegung

Woher kommt der Fehler in einem berechneten Ergebnis? Sei f ein Problem (eine Funktion, die wir auswerten wollen) mit idealem Input $\mathbf{x}$. Was der Computer stattdessen ausführt, ist ein Algorithmus $\tilde{f}$ (eine Näherung an f), und zwar am tatsächlichen Input $\tilde{\mathbf{x}}$, einer Näherung an $\mathbf{x}$:

$$\text{Input } \tilde{x} \longrightarrow \text{Algorithmus } \tilde{f} \longrightarrow \text{Ergebnis } \tilde{f}(\tilde{x}).$$

Weicht das Ergebnis $\tilde{f}(\tilde{x})$ vom idealen Wert $f(x)$ ab, kann das an zwei Stellen liegen:

- am *Fehler im Input*, also $\tilde{x} \neq x$, etwa durch Messen oder Speichern von x . Diese Fehler sind *unvermeidbar*: Sie entstehen, bevor unser Programm die erste Zeile ausführt.
- am *Fehler im Algorithmus*, also $\tilde{f} \neq f$, etwa durch Rundung in Maschinendarithmetik oder durch bewusste Approximation (abgebrochene Reihen, Diskretisierung, endlich viele Iterationen). Diese Fehler *können wir beeinflussen*: durch die Wahl eines besseren Algorithmus.

Subtrahieren und addieren wir den Zwischenwert $f(\tilde{x})$ (das ideale Problem am tatsächlichen Input), zerfällt der Gesamtfehler exakt in diese zwei Anteile:

$$\underbrace{\tilde{f}(\tilde{x}) - f(x)}_{\text{Gesamtfehler}} = \underbrace{\tilde{f}(\tilde{x}) - f(\tilde{x})}_{\substack{\text{Fehler im Algorithmus} \\ \text{(Maschinendarithmetik)}}} + \underbrace{f(\tilde{x}) - f(x)}_{\substack{\text{Folgefehler aus Input} \\ \text{(exakte Arithmetik)}}} \quad (4.1.1)$$

Bemerkung 4.1.5 (Stabilität und Kondition: Ausblick)

- Der erste Term $\tilde{f}(\tilde{x}) - f(\tilde{x})$ vergleicht Algorithmus und Problem *am selben Input* und hängt damit nicht vom Inputfehler ab. Ist er „klein“, nennen wir den Algorithmus *stabil* (Abschnitt 4.3).
- Der zweite Term $f(\tilde{x}) - f(x)$ vergleicht das ideale Problem f an zwei Inputs, in exakter Arithmetik, und hängt damit nicht vom Algorithmus $\tilde{f}$ ab. Ist er „klein“, nennen wir das Problem f an der Stelle x *gut konditioniert* (Abschnitt 4.2).

Beispiel 4.1.6 (Fehlerzerlegung: Berechnung von e^π)

Die Exponentialfunktion hat die Potenzreihe $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$. Angenommen, wir wollen $f(\pi) = e^\pi$ berechnen und verwenden dazu zwei Näherungen: als Input $\tilde{\pi} = 3$ (auf eine ganze Zahl gerundet) und als Algorithmus die nach dem quadratischen Glied abgebrochene Reihe $\tilde{f}(x) = \sum_{n=0}^2 \frac{x^n}{n!} = 1 + x + \frac{x^2}{2}$. Wie zerfällt der Gesamtfehler nach (4.1.1)? Erst selbst probieren, dann weiterlesen.

Der Algorithmus liefert $\tilde{f}(3) = 1 + 3 + \frac{9}{2} = 8,5$. Einsetzen des Zwischenwerts $f(3) = e^3$ ergibt die Zerlegung

$$\tilde{f}(3) - f(\pi) = [\tilde{f}(3) - f(3)] + [f(3) - f(\pi)].$$

Fehler im Algorithmus, also die abgebrochene Reihe gegen e^3 ; der Fehler ist gerade der weggelassene Reihenrest, mit Minuszeichen:

$$\tilde{f}(3) - f(3) = \left(1 + 3 + \frac{9}{2}\right) - e^3 = - \sum_{n=3}^{\infty} \frac{3^n}{n!} \approx 8,5 - 20,086 = -11,586.$$

Folgefehler aus dem Input, das exakte Problem f an den zwei Inputs 3 und π :

$$f(3) - f(\pi) = e^3 - e^\pi \approx 20,086 - 23,141 = -3,055.$$

Gesamtfehler, zur Probe direkt und über die Zerlegung:

$$\tilde{f}(3) - f(\pi) \approx 8,5 - 23,141 = -14,641 = (-11,586) + (-3,055). \quad \boxtimes$$

Beide Anteile sind hier negativ: Die abgebrochene Reihe lässt nur positive Terme weg und unterschätzt e^3 deshalb systematisch; und wegen $3 < \pi$ und der Monotonie von e^x ist auch $e^3 < e^\pi$. Der Algorithmusfehler dominiert ($-11,6$ gegenüber $-3,1$). Hier würde sich also zuerst ein besserer Algorithmus lohnen (mehr Reihenglieder), nicht ein genauere Input.

Interaktiv: Fehlerzerlegungs-Explorer: Abbruchordnung N und Input-Genauigkeit k

Den Algorithmusfehler drücken wir mit mehr Reihengliedern, den Folgefehler nur mit einem genaueren $\tilde{\pi}$. Ab welcher Abbruchordnung begrenzt nicht mehr der Algorithmus, sondern der Input das Ergebnis?

Interaktives Element — nur in der Web-Fassung

Bei $\tilde{\pi} = 3$ wechselt die Dominanz zwischen $N = 4$ und $N = 6$: Bis $N = 3$ ist der Algorithmusfehler mehr als doppelt so groß wie der Folgefehler, ab $N = 6$ ist es umgekehrt. Danach bringt jedes weitere Reihenglied wenig, denn der zweite Summand in (4.1.1) hängt nicht von N ab. Weiter kommen wir dann nur mit einem genaueren Input.

Selbsttest

1. Ein absoluter Fehler von 0,36 ist ein kleiner Fehler.

Antwort: Falsch

Ohne Bezugsgröße sagt der absolute Fehler nichts. In Beispiel 4.1.4 sind 0,36 gemessen an $\|\mathbf{v}\|_2 = 5$ gerade 7,2 %, bei einem Vektor der Länge 0,5 wären dieselben 0,36 ein relativer Fehler von über 70 %. Deshalb steht neben dem absoluten Fehler immer auch der relative.

2. Der absolute Fehler $\Delta_{\mathbf{v}}$ trägt mehr Information als der relative Fehler $\delta_{\mathbf{v}}$.

Antwort: Wahr

$\Delta_{\mathbf{v}}$ ist ein Element von V und sagt auch, in welche *Richtung* die Näherung danebenliegt; $\delta_{\mathbf{v}}$ ist eine einzelne nichtnegative Zahl (Definition 4.1.2). Aus $\Delta_{\mathbf{v}}$ und $\mathbf{v}$ lässt sich $\delta_{\mathbf{v}}$ berechnen, umgekehrt nicht.

3. Mehr Reihenglieder in $\tilde{f}$ verkleinern beide Anteile der Zerlegung (4.1.1).

Antwort: Falsch

Nur den ersten. Der Folgefehler $f(\tilde{\mathbf{x}}) - f(\mathbf{x})$ vergleicht das *ideale* Problem an zwei Inputs und weiß von $\tilde{f}$ gar nichts (Bemerkung 4.1.5). Deshalb läuft der Gesamtfehler im Explorer gegen den Folgefehler und nicht gegen null.

4. Ziehen wir im Fehlermaß-Rechner die blaue Spitze bei $\mathbf{v} = (3, 4)^T$ genau auf den gestrichelten Kreis. Welchen Wert zeigt der Rechner dann für $\|\Delta_{\mathbf{v}}\|_2$?

Lösung: 0.5

Der gestrichelte Kreis hat den Radius $0,1 \cdot \|\mathbf{v}\|_2$, und $\|\mathbf{v}\|_2 = 5$. Auf dem Kreis ist also $\|\Delta_{\mathbf{v}}\|_2 = 0,5$ und damit $\delta_{\mathbf{v}} = 0,5/5 = 10\%$: der Grenzfall der Fehlerschranke $\varepsilon = 0,1$ aus Beispiel 4.1.4.

Vertiefung: Heath §1.2.

4.2 Kondition

Der zweite Teil der Fehlerzerlegung (4.1.1) ist der Folgefehler aus einem fehlerhaften Input. Inputfehler betrachten wir als *unvermeidbar*: Messwerte sind ungenau, Daten wurden gerundet gespeichert, und schon das Ablegen einer reellen Zahl als Gleitkommazahl erzeugt einen relativen Rundungsfehler von der Größenordnung der Maschinengenauigkeit.

Wie stark sich solche Inputfehler im Ergebnis niederschlagen, ist eine Eigenschaft des Problems f , noch bevor ein Algorithmus ins Spiel kommt. Stellen wir uns die Menge aller Inputs vor, die wir von x nicht unterscheiden können, weil ihr relativer Fehler unter einer Toleranz δ liegt:

$$E = \{\tilde{x} : \|\tilde{x} - x\| / \|x\| \leq \delta\}.$$

Jeder Punkt in E ist ein plausibler Input, also ist jeder Punkt der Bildmenge $R = f(E)$ ein plausibles Ergebnis. Ist R groß im Vergleich zu E , macht f aus kleinen Eingabestörungen große Ergebnisänderungen. Wir nennen das Problem dann *schlecht konditioniert*. Kein Algorithmus kann das reparieren, denn er sieht nur $\tilde{x}$ und kann nicht wissen, welcher Punkt von E der „wahre“ Input war.

4.2.1 Ein Warnbeispiel: der Kehrwert

Beispiel 4.2.1 (Kehrwert nahe null)

Sei $f(x) = x^{-1}$ mit Input $x = 10^{-17}$, und sei der gestörte Input $\tilde{x} = x + \varepsilon$ mit $\varepsilon \in (-10^{-17}, 10^{-17})$. Dann durchläuft $\tilde{x}$ das Intervall $(0, 2 \cdot 10^{-17})$ und damit

$$f(\tilde{x}) = \frac{1}{\tilde{x}} \in \left(\frac{1}{2} \cdot 10^{17}, \infty\right).$$

Der Output kann also um Größenordnungen vom wahren Wert $f(x) = 10^{17}$ abweichen. Den relativen Outputfehler erhalten wir so (die Störung ε in Rot):

$$f(\tilde{x}) - f(x) = \frac{1}{x + \varepsilon} - \frac{1}{x} = \frac{x - (x + \varepsilon)}{(x + \varepsilon)x} = \frac{-\varepsilon}{(x + \varepsilon)x},$$

und nach Division durch $f(x) = 1/x$:

$$\frac{|f(\tilde{x}) - f(x)|}{|f(x)|} = \frac{|\varepsilon|}{|x + \varepsilon|} = \frac{|x|}{|x + \varepsilon|} \cdot \frac{|\varepsilon|}{|x|}.$$

Der *relative Outputfehler* ist also der *relative Inputfehler*, multipliziert mit dem *Verstärkungsfaktor* $|x|/|x + \varepsilon|$. Für $\varepsilon \rightarrow -10^{-17}$ wächst dieser Faktor über alle Grenzen; insgesamt durchläuft der relative Outputfehler das gesamte Intervall $[0, \infty)$, obwohl die Störung absolut winzig ist: $|\varepsilon| < 10^{-17}$. Relativ zu x kann sie allerdings bis zu 100 % betragen.

Interaktiv: Der Kehrwert unter Störungen

Wie schnell wächst dieser Verstärkungsfaktor, wenn $\tilde{x}$ sich der Polstelle nähert?

Interaktives Element — nur in der Web-Fassung

Solange ε klein gegenüber x ist, sind roter und grüner Balken fast gleich lang: Die Verstärkung liegt nahe 1. Schieben wir $\tilde{x}$ an die Polstelle, wächst der grüne Outputbalken über den Bildrand hinaus, während der rote Inputbalken kaum länger wird.

4.2.2 Konditionszahlen

Um „sensitiv gegenüber Inputfehlern“ quantitativ zu fassen, setzen wir Output- und Inputfehler ins Verhältnis, einmal für absolute, einmal für relative Fehler. Im Folgenden betrachten wir Abbildungen $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$; $\|\cdot\|$ bezeichnet eine beliebige Vektornorm bzw. die von ihr induzierte Operatornorm für Matrizen (Abschnitt 3.3).

Definition 4.2.2 (Konditionszahl)

Sei f ein Problem mit Input $\mathbf{x}$. Für die relative Konditionszahl setzen wir $\|\mathbf{x}\| \neq 0$ und $\|f(\mathbf{x})\| \neq 0$ voraus.

- Die *absolute Konditionszahl* ist

$$\kappa_{abs}(f, \mathbf{x}) = \limsup_{\substack{\mathbf{h} \rightarrow 0 \\ \mathbf{h} \neq 0}} \frac{\|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x})\|}{\|\mathbf{h}\|}.$$

- Die *relative Konditionszahl* ist

$$\kappa_{rel}(f, \mathbf{x}) = \limsup_{\substack{\mathbf{h} \rightarrow 0 \\ \mathbf{h} \neq 0}} \frac{\|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x})\| / \|f(\mathbf{x})\|}{\|\mathbf{h}\| / \|\mathbf{x}\|}.$$

Bemerkung 4.2.3 (Wie lesen wir das?)

- Der Limes superior läuft über alle Richtungen, aus denen Störungen gegen null gehen: κ ist der größte Verstärkungsfaktor *im Grenzfall* verschwindender Störungen. Konditionszahlen sind also lokale Größen; sie hängen vom Problem f und von der Stelle $\mathbf{x}$ ab.
- Für differenzierbares $f: \mathbb{R} \rightarrow \mathbb{R}$ können wir die Konditionszahlen direkt ausrechnen: Wegen $f(\tilde{x}) - f(x) \approx f'(x)(\tilde{x} - x)$ (Taylor-Näherung erster Ordnung) gilt

$$\kappa_{abs} = |f'(x)| \quad \text{und} \quad \kappa_{rel} = \frac{|f'(x)| |x|}{|f(x)|}.$$

- Meist ist κ_{rel} die relevantere Größe: Gleitkommarechnung erzeugt *relative* Fehler (Abschnitt 4.1), und relative Fehler sind unabhängig von Maßeinheiten und Skalierung.

Bemerkung 4.2.4 (Interpretation)

- *gut konditioniert* ($\kappa \lesssim 1$): Ein Inputfehler führt zu einem ähnlich großen oder kleineren Outputfehler.
- *schlecht konditioniert* ($\kappa \gg 1$): Ungünstig gerichtete kleine Inputfehler können zu viel größeren Outputfehlern führen. Als Faustregel bei $\kappa_{rel} \approx 10^k$: Wir verlieren bis zu k signifikante Dezimalstellen gegenüber der Genauigkeit des Inputs.

- *schlecht gestellt* (engl. *ill-posed*, $\kappa = \infty$): Der Verstärkungsfaktor ist unbeschränkt: Beliebige kleine Inputfehler können, gemessen an ihrer eigenen Größe, beliebig stark verstärkt werden.

Mit den Formeln aus Bemerkung 4.2.3 können wir das Warnbeispiel auflösen:

Beispiel 4.2.5 (Der Kehrwert, aufgelöst)

Für $f(x) = x^{-1}$ ist $f'(x) = -x^{-2}$, also an der Stelle $x = 10^{-17}$:

$$\kappa_{abs} = |f'(x)| = \frac{1}{x^2} = 10^{34}, \quad \kappa_{rel} = \frac{|f'(x)| |x|}{|f(x)|} = \frac{x^{-2} \cdot x}{x^{-1}} = 1.$$

Absolut gemessen ist das Problem also extrem sensitiv, relativ gemessen gut konditioniert: Asymptotisch wird ein relativer Inputfehler von 0,1 % zu einem relativen Outputfehler von ebenfalls 0,1 %. Der große Fehler in Beispiel 4.2.1 entsteht, weil die Störungen dort *relativ zu x* nicht klein waren (bis zu 100 %): Ein absoluter Fehler fester Größe, etwa ein additiver Messfehler, bedeutet bei winzigem x eine riesige relative Störung. Welche Konditionszahl zählt, hängt also davon ab, welche Fehlerart im Input unvermeidbar ist.

4.2.3 Kondition eines linearen Gleichungssystems

Das wichtigste Beispiel des Kapitels ist ein lineares Gleichungssystem $\mathbf{A}\mathbf{y} = \mathbf{x}$ mit invertierbarem $\mathbf{A} \in \mathbb{R}^{n \times n}$, dessen rechte Seite $\mathbf{x}$ der fehlerbehaftete Input ist. Als Problem geschrieben: $f(\mathbf{x}) = \mathbf{A}^{-1}\mathbf{x} = \mathbf{y}$; die Inverse bezeichnet hier nur die Lösungsabbildung und ist keine Empfehlung, sie auszurechnen. Wie empfindlich reagiert die Lösung $\mathbf{y}$ auf Störungen von $\mathbf{x}$? Die Antwort führt auf die *Konditionszahl der Matrix* $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ aus Abschnitt 3.5.

Satz 4.2.6 (Kondition der Lösung eines LGS)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ invertierbar und $f(\mathbf{x}) = \mathbf{A}^{-1}\mathbf{x}$. Bezüglich einer beliebigen Vektornorm und der von ihr induzierten Operatornorm gilt dann

$$\kappa_{abs} = \|\mathbf{A}^{-1}\|, \quad \kappa_{rel} = \|\mathbf{A}^{-1}\| \frac{\|\mathbf{x}\|}{\|\mathbf{A}^{-1}\mathbf{x}\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| = \kappa(\mathbf{A}).$$

Beweis.

(1)

$$f(\tilde{\mathbf{x}}) - f(\mathbf{x}) = \mathbf{A}^{-1}\tilde{\mathbf{x}} - \mathbf{A}^{-1}\mathbf{x} = \mathbf{A}^{-1}\mathbf{h}$$

f ist linear; wir kürzen die Störung als $\mathbf{h} = \tilde{\mathbf{x}} - \mathbf{x}$ ab

(2)

$$\|f(\tilde{\mathbf{x}}) - f(\mathbf{x})\| = \|\mathbf{A}^{-1}\mathbf{h}\| \leq \|\mathbf{A}^{-1}\| \|\mathbf{h}\| \implies \kappa_{abs} \leq \|\mathbf{A}^{-1}\|$$

die Operatornorm als Streckungsschranke: $\|\mathbf{A}^{-1}\mathbf{v}\| \leq \|\mathbf{A}^{-1}\| \|\mathbf{v}\|$ für alle $\mathbf{v}$ (Bemerkung 3.5.6)

(3) Keine kleinere Konstante genügt: Wählen wir $\mathbf{h}$ (beliebig klein) entlang einer maximierenden Richtung, gilt in der Ungleichung Gleichheit. Also ist $\kappa_{abs} = \|\mathbf{A}^{-1}\|$.

die Operatornorm ist ein Maximum: $\|\mathbf{A}^{-1}\| = \max_{\mathbf{v} \neq 0} \|\mathbf{A}^{-1}\mathbf{v}\| / \|\mathbf{v}\|$, und eine maximierende Richtung dürfen wir beliebig klein skalieren

(4)

$$\frac{\|A^{-1}h\| / \|A^{-1}x\|}{\|h\| / \|x\|} = \underbrace{\frac{\|A^{-1}h\|}{\|h\|}}_{\leq \|A^{-1}\|} \cdot \frac{\|x\|}{\|A^{-1}x\|} \implies \kappa_{rel} = \|A^{-1}\| \frac{\|x\|}{\|A^{-1}x\|}$$

den Quotienten aus relativem Output- und Inputfehler umsortieren; dann liefern Schritt 2 und 3 wieder Schranke und Gleichheitsfall für den ersten Faktor

(5)

$$\kappa_{rel} = \|A^{-1}\| \frac{\|Ay\|}{\|y\|} \leq \|A\| \|A^{-1}\| = \kappa(A)$$

substituiere $y = A^{-1}x$, also $x = Ay$; Operatornorm-Schranke $\|Ay\| \leq \|A\| \|y\|$

□

Bemerkung 4.2.7 (Konditionszahl einer Matrix)

- Die relative Kondition des Gleichungslösens hängt von der rechten Seite x ab; $\kappa(A) = \|A\| \|A^{-1}\|$ ist die von x unabhängige *Worst-Case-Schranke*, und sie wird für ungünstige x auch angenommen. Das erklärt im Nachhinein, warum dieses Produkt in Abschnitt 3.5 den Namen *Konditionszahl von A* bekommen hat.
- Für die von $\|\cdot\|_2$ induzierte Operatornorm (*Spektralnorm*) gilt

$$\kappa_2(A) = \frac{\sqrt{\lambda_{\max}(A^T A)}}{\sqrt{\lambda_{\min}(A^T A)}} = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)},$$

das Verhältnis des größten zum kleinsten Singulärwert (bzw. der Wurzeln der extremen Eigenwerte von $A^T A$).

Interaktiv: Kondition eines Gleichungssystems: aus dem Kreis wird eine Ellipse

Geometrisch: Ein Kreis plausibler rechter Seiten um x wird von A^{-1} zu einer Ellipse verzogen; für welche x ist diese Ellipse groß gemessen an $\|A^{-1}x\|$, und für welche nicht?

Interaktives Element — nur in der Web-Fassung

Beide Tafeln zeigen dieselbe Störung, einmal vor und einmal nach dem Lösen. In der Voreinstellung ($A = \begin{pmatrix} 1 & 1 \\ 1 & 1,05 \end{pmatrix}$, $x = (2; 2,05)^T$, also $y = (1; 1)^T$) schöpft $\kappa_{rel}(f, x) \approx 82,0$ die Schranke $\kappa(A) \approx 82,0$ zu 99,99 % aus: Aus 5 % Inputfehler werden 410 % Outputfehler, aus dem kleinen roten Kreis links wird die lange Nadel rechts. Ziehen wir x dagegen in Richtung $(1; -1)^T$, fällt κ_{rel} auf 1, obwohl die Matrix dieselbe bleibt.

Für eine Diagonalmatrix ist $A^T A = \text{diag}(4, 25, 0,01)$, die Singulärwerte sind also die Beträge der Diagonaleinträge: $\sigma \in \{2, 5, 0,1\}$. Damit

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} = \frac{5}{0,1} = 50.$$

Die Antwort $20 = 2/0,1$ nimmt den ersten Diagonaleintrag statt des größten Singulärwerts 5; die Antworten 2 und 5 sind einzelne Streckungsfaktoren. κ_2 misst das *Verhältnis* von stärkster zu schwächster Streckung.

4.2.4 Aufgabe: die Kondition einer Summe

Beispiel 4.2.8 (Aufgabe: Kondition der Summe)

Sei $f(\mathbf{x}) = x_1 + x_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}^\top \mathbf{x} = \mathbf{1}^\top \mathbf{x}$ mit $\mathbf{x} \in \mathbb{R}^2$ und der euklidischen Norm $\|\cdot\|_2$.

1. Was sind die Konditionszahlen?
2. Für welche $\mathbf{x}$ ist das Problem schlecht konditioniert?

Lösung

1. Für die Störung $\mathbf{h} = \tilde{\mathbf{x}} - \mathbf{x}$ liefert die Cauchy-Schwarz-Ungleichung

$$|f(\tilde{\mathbf{x}}) - f(\mathbf{x})| = |\mathbf{1}^\top \mathbf{h}| \leq \|\mathbf{1}\|_2 \|\mathbf{h}\|_2 = \sqrt{2} \|\mathbf{h}\|_2,$$

mit Gleichheit genau dann, wenn $\mathbf{h}$ parallel zu $\mathbf{1} = (1, 1)^\top$ liegt. Solche Störungen gibt es beliebig klein, die Schranke ist also scharf: $\kappa_{abs} = \sqrt{2}$. Da f linear ist, tritt derselbe Gleichheitsfall beim relativen Fehlerquotienten auf, und wie im Beweis von Satz 4.2.6 folgt

$$\kappa_{rel} = \kappa_{abs} \frac{\|\mathbf{x}\|_2}{|f(\mathbf{x})|} = \frac{\sqrt{2} \|\mathbf{x}\|_2}{|x_1 + x_2|}.$$

2. Schlecht konditioniert ist das Problem, wenn $\kappa_{rel} \gg 1$, also wenn $|x_1 + x_2| \approx 0$, während $\|\mathbf{x}\|_2$ nicht klein ist, sprich für $x_1 \approx -x_2$, nahe der Antidiagonalen. Dort heben sich die beiden Summanden fast auf: Das ist die Auslöschung aus Abschnitt 2.1, jetzt als Konditionsaussage über das Problem „addiere zwei Zahlen“, unabhängig davon, wie wir die Summe ausrechnen. Auf der Diagonalen $x_1 = x_2$ gilt dagegen $\kappa_{rel} = 1$: besser geht es nicht.

Interaktiv: Die Kondition der Summe in der Ebene

Für welche Punkte $\mathbf{x}$ der Ebene ist die Summe gut konditioniert, für welche schlecht, und wie schnell wechselt das eine ins andere?

Interaktives Element — nur in der Web-Fassung

Entlang jedes Strahls durch den Ursprung ist die Farbkarte einfarbig: Zähler und Nenner von κ_{rel} sind homogen vom Grad 1 in $\mathbf{x}$, es zählt also nur die *Richtung*. Schlecht konditioniert sind die Punkte in einem schmalen Keil um die Antidiagonale: Bei $\mathbf{x} = (1, 5; -1, 45)^\top$ ist $\kappa_{rel} \approx 59$, es gehen knapp zwei Dezimalstellen verloren; auf $(1, 5; -1, 5)^\top$ ist das Problem schlecht gestellt.

In Abschnitt 4.3 wird die Kondition der Differenz zweier fast gleicher Zahlen erklären, warum die Verschiebungsformel für die Varianz numerisch scheitert.

Selbsttest

1. Ein schlecht konditioniertes Problem lässt sich durch einen besseren Algorithmus retten.

Antwort: Falsch

Die Kondition ist eine Eigenschaft des Problems f an der Stelle $\mathbf{x}$, nicht der Rechenvorschrift. Ein Algorithmus sieht nur $\tilde{\mathbf{x}}$ und kann nicht wissen, welcher Punkt der ununterscheidbaren Menge E der wahre Input war. Ein *stabiler* Algorithmus sorgt nur dafür, dass der Fehler nicht größer wird, als das Problem erzwingt.

- Die absolute Konditionszahl von $f(x) = 1/x$ ist bei $x = 10^{-17}$ riesig, also ist das Problem dort in jedem Sinn schlecht konditioniert.

Antwort: Falsch

$\kappa_{abs} = 10^{34}$, aber $\kappa_{rel} = 1$ (Beispiel 4.2.5). Welche der beiden zählt, hängt davon ab, welche Fehlerart im Input unvermeidbar ist. Bei Gleitkommarechnung sind das *relative* Fehler, und die gibt der Kehrwert unverändert weiter.

- Für dieselbe Matrix A kann das Lösen von $A\mathbf{y} = \mathbf{x}$ je nach rechter Seite gut oder schlecht konditioniert sein.

Antwort: Wahr

Nach Satz 4.2.6 ist $\kappa_{rel} = \|A^{-1}\| \|\mathbf{x}\| / \|A^{-1}\mathbf{x}\|$, und dieser Quotient hängt von der Richtung von $\mathbf{x}$ ab. Er schöpft die Schranke $\kappa(A)$ nur für ungünstige rechte Seiten aus; im LGS-Widget sind das die Richtungen nahe 45° .

- Stellen wir im Widget zur Kondition der Summe die Voreinstellung „Diagonale“ ein. Welchen Wert zeigt der Readout für κ_{rel} ?

Lösung: 1

Eins. Auf der Diagonalen $x_2 = x_1$ ist $\|\mathbf{x}\|_2 = \sqrt{2}|x_1|$ und $|x_1 + x_2| = 2|x_1|$, also $\kappa_{rel} = \sqrt{2} \cdot \sqrt{2}|x_1| / (2|x_1|) = 1$. Besser als 1 geht nicht: Relative Inputfehler werden dort überhaupt nicht verstärkt.

Vertiefung: Heath §1.2.5–1.2.6 (Fehlerfortpflanzung, Sensitivität und Kondition).

4.3 Stabilität von Algorithmen

Den **zweiten Summanden** der Fehlerzerlegung (4.1.1), den Folgefehler aus dem Input, haben wir in Abschnitt 4.2 untersucht: Er hängt nur vom Problem ab, und die Konditionszahl sagt, wie stark er den unvermeidbaren Inputfehler verstärkt. Jetzt geht es um den ersten Summanden $\tilde{f}(\tilde{\mathbf{x}}) - f(\tilde{\mathbf{x}})$, den Fehler, den der Algorithmus *selbst* hinzufügt: durch Rundungsfehler in jeder Gleitkomma-Operation, durch abgebrochene Reihen oder geschätzte Zwischengrößen. Er entsteht auch bei exaktem Input. Ist er „klein“, nennen wir den Algorithmus $\tilde{f}$ *stabil*.

Vertiefung (optional): Vorwärts- und Rückwärtsstabilität, präzise

Definition 4.3.1 (Vorwärts- und Rückwärtsstabilität)

Sei f ein Problem, $\tilde{f}$ ein Gleitkomma-Algorithmus und $\hat{y} = \tilde{f}(\mathbf{x})$ sein Ergebnis für einen exakt dargestellten Input $\mathbf{x}$. Für $\|\mathbf{x}\| \neq 0$ und $\|f(\mathbf{x})\| \neq 0$ heißen

$$\eta_{\text{vor}} = \frac{\|\hat{y} - f(\mathbf{x})\|}{\|f(\mathbf{x})\|}$$

der *relative Vorwärtsfehler* und

$$\eta_{\text{rck}} = \inf \left\{ \frac{\|\Delta \mathbf{x}\|}{\|\mathbf{x}\|} : \hat{y} = f(\mathbf{x} + \Delta \mathbf{x}) \right\}$$

der *relative Rückwärtsfehler*. Der Algorithmus heißt *rückwärtsstabil*, wenn $\eta_{\text{rck}} = O(u)$ ist, wobei u die Rundungseinheit bezeichnet. Er heißt *vorwärtsstabil*, wenn sein Vorwärtsfehler bis auf moderate Faktoren nicht größer ist als der durch Kondition und Rundung erwartbare Fehler, $\eta_{\text{vor}} = O(\kappa_{\text{rel}}(f, \mathbf{x})u)$.

Die Konstanten in den O -Aussagen dürfen von Dimension und Algorithmus abhängen, sollen aber moderat bleiben. Anschaulich bedeutet Rückwärtsstabilität: Das berechnete Ergebnis ist die exakte Lösung eines nur geringfügig gestörten Problems. Zusammen mit der Kondition liefert das typischerweise eine Vorwärtsfehlerschranke.

Die *Kondition* ist eine Eigenschaft des *Problems*, die wir nicht wählen können. Die *Stabilität* ist eine Eigenschaft des *Algorithmus*, und den wählen wir. Für dasselbe Problem können zwei mathematisch äquivalente Rechenwege sehr unterschiedlich stabil sein.

Eine verwandte Idee aus dem maschinellen Lernen: SGD

Das nächste Beispiel zeigt die *dynamische* Stabilität einer Iteration. Es ist eine Analogie zur Stabilität von Algorithmen: Hier mischen sich numerische Fehler mit der Konvergenzdynamik des Verfahrens.

Beispiel 4.3.2 (Stochastic Gradient Descent)

Beim Training von Machine-Learning-Modellen minimieren wir eine Verlustfunktion $L(\theta)$ mit dem Gradientenabstieg in seiner stochastischen Variante (SGD):

$$\theta_{k+1} = \theta_k - \alpha \hat{\nabla} L(\theta_k),$$

wobei $\hat{\nabla} L(\theta_k)$ nur eine *Schätzung* des Gradienten ist (berechnet auf einem zufälligen Teil der Daten, in endlicher Gleitkomma-Genauigkeit) und $\alpha > 0$ die *Lernrate* (learning rate).

- Eine relativ zur Krümmung von L hinreichend kleine Lernrate kann Fehler in bestimmten Richtungen dämpfen und unter geeigneten Annahmen Konvergenz ermöglichen.
- Eine zu große Lernrate kann Iterierte oszillieren oder divergieren lassen. Zahlenwerte wie 0,001 oder 1 sind ohne Skalierung und Krümmung des konkreten Problems nicht allgemein als „klein“ oder „groß“ einzuordnen.

In unseren Begriffen: Das Problem f ist, das Minimum von L zu finden; der Algorithmus $\tilde{f}$ ist SGD in endlicher Genauigkeit; der algorithmische Fehler sammelt die Rundungs- und Schätzfehler des Gradienten über die Iterationen k an. Ob SGD konvergiert und wogegen, hängt außer von der Lernrate auch von Annahmen an L , an die Gradientenschätzung und an den Lernratenplan ab.

Interaktiv: SGD-Demo: Lernrate und Stabilität

Im einfachsten Modell $L(\theta) = \theta^2$ mit exaktem Gradienten 2θ und Start bei $\theta_0 = 2,5$: Ab welcher Lernrate laufen die Iterierten nicht mehr auf das Minimum zu, sondern davon weg?

Interaktives Element — nur in der Web-Fassung

Ohne Rauschen ist $\theta_{k+1} = \theta_k - \alpha \cdot 2\theta_k = (1 - 2\alpha)\theta_k$, der Abstand zum Minimum wird in jedem Schritt also mit $\rho(\alpha) = |1 - 2\alpha|$ multipliziert. Die nach dem Auflösen eingeblendete ρ -Kurve ordnet die vier Regime ein. Die Schwelle ist keine Eigenschaft von SGD, sondern der Krümmung von L : Für $L(\theta) = \frac{c}{2}\theta^2$ läge sie bei $\alpha = 2/c$.

Zusammengesetzte Algorithmen

Praktisch jeder Algorithmus ist eine Kette von Teilschritten. Was passiert mit den Fehlern der frühen Schritte, wenn spätere darauf aufbauen? Für eine Verkettung zweier Teilprobleme verknüpft das folgende Resultat die Stabilität des zusammengesetzten Algorithmus mit der *Kondition seiner Teilschritte*.

Satz 4.3.3 (Fehlerfortpflanzung in einer Komposition)

Sei $f = h \circ g$, $y = g(x) \neq 0$ und $\tilde{y} = \tilde{g}(x)$. Wir setzen $h(y) \neq 0$ voraus und definieren

$$\eta_g = \frac{\|\tilde{y} - y\|}{\|y\|}, \quad \eta_h = \frac{\|\tilde{h}(\tilde{y}) - h(\tilde{y})\|}{\|h(\tilde{y})\|}.$$

Ist h in y stetig und $\tilde{y} \rightarrow y$, dann gilt in erster Ordnung

$$\frac{\|\tilde{h}(\tilde{y}) - h(y)\|}{\|h(y)\|} \leq (1 + o(1))\eta_h + (\kappa_{rel}(h, y) + o(1))\eta_g.$$

Rechts steht der relative Fehler von $\tilde{h}$ selbst, am tatsächlich übergebenen Input, plus der Fehler von $\tilde{g}$, verstärkt durch die lokale Kondition von h . Die $o(1)$ -Terme machen explizit, dass dies eine asymptotische Aussage für verschwindende Zwischenfehler ist, keine exakte Ungleichung für beliebig große Störungen.

Beweis.

- (1) Durch Addieren und Subtrahieren von $h(\tilde{y})$ sowie die Dreiecksungleichung erhalten wir exakt

$$\frac{\|\tilde{h}(\tilde{y}) - h(y)\|}{\|h(y)\|} \leq \frac{\|\tilde{h}(\tilde{y}) - h(\tilde{y})\|}{\|h(\tilde{y})\|} + \frac{\|h(\tilde{y}) - h(y)\|}{\|h(y)\|}.$$

- (2) Stetigkeit und $h(y) \neq 0$ liefern $\|h(\tilde{y})\|/\|h(y)\| = 1 + o(1)$. Daher ist der erste Summand gleich $(1 + o(1))\eta_h$.
- (3) Nach Definition der relativen Konditionszahl ist der zweite Summand entlang $\tilde{y} \rightarrow y$ höchstens

$$(\kappa_{rel}(h, y) + o(1)) \frac{\|\tilde{y} - y\|}{\|y\|} = (\kappa_{rel}(h, y) + o(1))\eta_g.$$

□

Bemerkung 4.3.4 (Was folgt daraus, und was nicht?)

Ein schlecht konditionierter später Teilschritt kann die Fehler aller früheren Schritte stark verstärken; eine schlecht konditionierte Zwischenstelle ist deshalb ein *Indiz* für Instabilität. Daraus ergibt sich die Faustregel: *Schlecht konditionierte Teilschritte möglichst früh ausführen*. Am Anfang der Kette trifft ein solcher Schritt nur auf den unvermeidbaren Inputfehler, am Ende auf alle angesammelten Fehler.

Die Faustregel ist allerdings kein Satz: Eine Umordnung verändert Zwischengrößen, Rundungsfehler und oft auch die relevanten Konditionen. Verlässlicher ist es, das Teilproblem umzuformulieren, große, beinahe gleiche Zwischengrößen zu vermeiden und eine rückwärts-stabile Implementierung zu verwenden, deren Ergebnis die exakte Lösung eines nur geringfügig gestörten Problems ist.

Anwendung: Stabilität der Varianzberechnung

In Abschnitt 2.1 haben wir *beobachtet*, dass die Verschiebungsformel für die Varianz versagen kann. Mit Satz 4.3.3 können wir quantitativ *erklären*, warum.

Beispiel 4.3.5 (Zwei Algorithmen für die Varianz)

Problem: Berechne die Stichprobenvarianz $f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.

Algorithmen: Wir vergleichen die zweistufige Rechnung (erst zentrieren, dann quadrieren) mit der Verschiebungsformel:

$$\tilde{f}_1(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \quad \tilde{f}_2(\mathbf{x}) = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2.$$

Mathematisch sind beide identisch. Als Rechenvorschriften sind sie es nicht: $\tilde{f}_2$ ist eine Verkettung $\tilde{f}_2 = \tilde{h} \circ \tilde{g}$ im Sinne von Satz 4.3.3. Der erste Schritt $\tilde{g}$ berechnet das Paar

$$g(\mathbf{x}) = (a, b) \quad \text{mit} \quad a = \frac{1}{n} \sum_{i=1}^n x_i^2 \quad \text{und} \quad b = \bar{x}^2,$$

und der *letzte* Schritt bildet die Differenz $h(a, b) = a - b$.

Nach Satz 4.3.3 kommt es auf die Kondition des letzten Schritts an der Übergabestelle an:

Lemma 4.3.6 (Kondition der Differenz)

Für $h(a, b) = a - b$ gilt bezüglich der euklidischen Norm

$$\kappa_{\text{rel}}(h, (a, b)) = \sqrt{2} \frac{\sqrt{a^2 + b^2}}{|a - b|}.$$

Der Beweis verläuft wie die Lösung von Beispiel 4.2.8, nur mit $(1, -1)^\top$ statt $(1, 1)^\top$: Die Cauchy-Schwarz-Ungleichung liefert $\kappa_{\text{abs}} = \sqrt{2}$, und die Division durch $|h(a, b)| = |a - b|$ ergibt die Behauptung.

Vertiefung (optional): Kondition der Differenz: Beweis im Detail

Beweis.

(1)

$$h(\tilde{a}, \tilde{b}) - h(a, b) = (\tilde{a} - a) - (\tilde{b} - b) = \begin{pmatrix} 1 \\ -1 \end{pmatrix}^\top \begin{pmatrix} \tilde{a} - a \\ \tilde{b} - b \end{pmatrix}$$

h ist linear: Die Differenz zweier Funktionswerte ist h , angewandt auf die Differenz der Inputs, geschrieben als Skalarprodukt mit dem Vektor $(1, -1)^\top$

(2)

$$|h(\tilde{a}, \tilde{b}) - h(a, b)| \leq \sqrt{2} \left\| \begin{pmatrix} \tilde{a} - a \\ \tilde{b} - b \end{pmatrix} \right\|_2$$

Cauchy-Schwarz-Ungleichung mit $\|(1, -1)^\top\|_2 = \sqrt{2}$; für Störungen proportional zu $(1, -1)^\top$ gilt Gleichheit, die Schranke wird also angenommen; $\sqrt{2}$ ist die kleinste solche Konstante und damit $\kappa_{abs} = \sqrt{2}$

(3)

$$\frac{|h(\tilde{a}, \tilde{b}) - h(a, b)|}{|a - b|} \leq \underbrace{\sqrt{2} \frac{\sqrt{a^2 + b^2}}{|a - b|}}_{=\kappa_{rel}} \cdot \frac{\|(\tilde{a} - a, \tilde{b} - b)^\top\|_2}{\sqrt{a^2 + b^2}}$$

Definition der relativen Konditionszahl (Abschnitt 4.2): beide Seiten durch $|h(a, b)| = |a - b|$ teilen und mit der Inputnorm $\|(a, b)^\top\|_2 = \sqrt{a^2 + b^2}$ erweitern

□

Sind a und b groß, liegen aber nah beieinander ($a \approx b$), dann ist κ_{rel} groß, und der letzte Schritt verstärkt alle vorangegangenen Fehler mit diesem Faktor. Das passiert bei der Varianz von Daten mit großem Mittelwert: Für $x_i = c + z_i$ mit Verschiebung c und Varianz 1 ist $a \approx c^2 + 1$ und $b \approx c^2$, während die Differenz (die Varianz) bei 1 bleibt. Damit wächst

$$\kappa_{rel} \approx \sqrt{2} \frac{\sqrt{2} c^2}{1} = 2c^2$$

quadratisch in der Verschiebung. Das ist die katastrophale Auslöschung aus Abschnitt 2.1.

Dass $\tilde{f}_1$ so viel besser abschneidet, passt zur Faustregel aus Bemerkung 4.3.4: Auch $\tilde{f}_1$ subtrahiert fast gleich große Zahlen ($x_i - \bar{x}$ mit $x_i \approx \bar{x} \approx c$), aber dieser schlecht konditionierte Schritt kommt zuerst und arbeitet auf Zahlen der Größenordnung c . Bei $\tilde{f}_2$ kommt die Subtraktion ganz am Ende, nach dem Quadrieren, auf Zahlen der Größenordnung c^2 . Der Verstärkungsfaktor ist $\sim c^2$ statt $\sim c$, und er trifft alle vorher akkumulierten Rundungsfehler.

Beispiel 4.3.7 (Die Instabilität in R)

Ein Zahlenexperiment dazu: $n = 1000$ standardnormalverteilte Werte, um $c = 10^{10}$ verschoben. Die wahre Varianz ist 1.

```
set.seed(5)
x <- rnorm(10^3, mean = 0, sd = 1) + 10^10
mean((x - mean(x))^2)
#> [1] 1.023151
mean(x^2) - mean(x)^2
#> [1] 16384
```

Die zweistufige Rechnung $\tilde{f}_1$ liefert 1,023, eine plausible Stichprobenvarianz. Die Verschiebungsformel $\tilde{f}_2$ liefert 16384: um mehr als vier Größenordnungen daneben. Passt das zu un-

serer Analyse? Mit $c = 10^{10}$ ist $\kappa_{rel} \approx 2c^2 = 2 \cdot 10^{20}$; die Zwischenergebnisse $a, b \approx 10^{20}$ tragen relative Rundungsfehler der Größenordnung $\varepsilon \approx 2,2 \cdot 10^{-16}$, also erwarten wir relative Fehler im Ergebnis bis etwa $\kappa_{rel} \cdot \varepsilon \approx 4 \cdot 10^4$. Beobachtet: $16384/1,02 \approx 1,6 \cdot 10^4$. Die Größenordnung stimmt.

Dabei ist $16384 = 2^{14}$ genau der Abstand zweier benachbarter Maschinenzahlen in der Größenordnung 10^{20} . Was die Verschiebungsformel als „Varianz“ ausgibt, ist hier also ein einzelner Rundungsschritt der Zwischenergebnisse; mit den Daten hat diese Zahl nichts mehr zu tun.

Interaktiv: Der κ -Rechner für den letzten Schritt

Bei $c = 10^{10}$ ging alles verloren. Ab welcher Verschiebung c verbraucht die Kondition des letzten Schritts die 16 Dezimalstellen doppelter Genauigkeit?

Interaktives Element — nur in der Web-Fassung

Nach der Faustregel aus Bemerkung 4.2.4 zeigt der Rechner $\log_{10} \kappa_{rel}$ als Zahl der verlorenen Dezimalstellen. Bei $c = 10^5$ sind das schon 10 von 16, bei $c = 10^8$ gut 16, und darüber bleibt nichts mehr übrig, wie in Beispiel 4.3.7.

Selbsttest

1. Sei $f = h \circ g$, und h sei an der Stelle $g(x)$ schlecht konditioniert. Ist der Algorithmus $\tilde{f} = \tilde{h} \circ \tilde{g}$ dann zwangsläufig instabil?

Nein. Satz 4.3.3 liefert eine lokale *obere Schranke*: Die schlechte Kondition von h kann ungünstig gerichtete Fehler von $\tilde{g}$ stark verstärken. Ist $\tilde{g}$ (nahezu) exakt oder liegt sein Fehler in einer wenig empfindlichen Richtung, kann der resultierende Fehler trotzdem klein bleiben. Eine schlecht konditionierte Zwischenstelle ist deshalb ein Indiz, kein Beweis für Instabilität.

2. Auch $\tilde{f}_1$ subtrahiert fast gleich große Zahlen ($x_i - \bar{x}$ mit $x_i \approx \bar{x}$). Warum ist $\tilde{f}_1$ trotzdem viel stabiler als $\tilde{f}_2$?

Entscheidend ist nicht allein die Position der Subtraktion. $\tilde{f}_1$ bildet direkt die Abweichungen und arbeitet danach mit deren Quadraten. $\tilde{f}_2$ bildet dagegen zunächst zwei Aggregate der Größenordnung c^2 und versucht, ihre kleine Differenz als Varianz zurückzugewinnen; deren Information kann schon in den Rundungen der großen Aggregate verschwunden sein. Die Zentrierung vermeidet diese großen, beinahe gleichen Zwischenwerte.

3. Beim Training eines neuronalen Netzes beginnt der Verlust nach wenigen Epochen zu oszillieren und wächst dann über alle Grenzen. Welche Stellschraube prüfen wir zuerst, und warum?

Die Lernrate α . Oszillation mit wachsender Amplitude ist das typische Verhalten eines instabilen Iterationsverfahrens: Der Verstärkungsfaktor pro Schritt liegt über 1, jeder Schritt vergrößert die Fehler des geschätzten Gradienten weiter. Eine kleinere Lernrate drückt den Faktor wieder unter 1. In der SGD-Demo oben lässt sich der Umschlag direkt beobachten.

1. Stellen wir im κ -Rechner den Modus „an Verschiebung c gekoppelt“ und den Exponenten $k = 5$ ein. Wie viele Dezimalstellen gehen laut Rechner verloren?

Lösung: 10.3

Rund 10,3. Mit $a = c^2 + 1$ und $b = c^2$ bei $c = 10^5$ ist $\kappa_{rel} = \sqrt{2} \sqrt{a^2 + b^2} \approx 2c^2 = 2 \cdot 10^{10}$, also $\log_{10} \kappa_{rel} \approx 10,3$. Von den etwa 16 Stellen doppelter Genauigkeit bleiben knapp 6 übrig.

2. In der SGD-Demo: Bei welcher Lernrate $\alpha > 0,5$ springen die Iterierten mit konstanter Amplitude um das Minimum, ohne näher zu kommen oder wegzulaufen?

Lösung: 1

Bei $\alpha = 1$. Dort ist $|1 - 2\alpha| = 1$, also $\theta_{k+1} = -\theta_k$: Die Iterierten pendeln zwischen 2,5 und -2,5. Die zweite Lösung von $|1 - 2\alpha| = 1$ ist $\alpha = 0$, und dort passiert gar nichts.

Vertiefung: Heath §1.2.7 (Stabilität und Genauigkeit).

4.4 Zusammenfassung

Die Konzepte im Überblick

Konzept	Kernaussage	Abschnitt
absoluter / relativer Fehler	$\Delta_v = \tilde{v} - v$ bzw. $\delta_v = \ \tilde{v} - v\ / \ v\ $, gemessen in einer Norm	4.1
Fehlerzerlegung	Gesamtfehler = algorithmischer Fehler $\tilde{f}(\tilde{x}) - f(\tilde{x})$ + Input-Folgefehler $f(\tilde{x}) - f(x)$	4.1
Kondition	Sensitivität eines Problems bezüglich Inputfehlern, unabhängig vom verwendeten Algorithmus	4.2
Konditionszahlen	κ_{abs} und κ_{rel} : kleinste Verstärkungsfaktoren von absolutem bzw. relativem Inputfehler; gut konditioniert ($\kappa \lesssim 1$), schlecht konditioniert ($\kappa \gg 1$), schlecht gestellt ($\kappa = \infty$)	4.2
Konditionszahl einer Matrix	$\kappa(A) = \ A\ \ A^{-1}\ $ in einer Matrixnorm: obere Schranke für die relative Kondition des Problems $x \mapsto A^{-1}x$ (eingeführt in Abschnitt 3.5)	4.2
Stabilität	Eigenschaft eines Algorithmus: $\tilde{f}$ ist stabil, wenn der algorithmische Fehler $\tilde{f}(\tilde{x}) - f(\tilde{x})$ klein ist	4.3
zusammengesetzte Algorithmen	Fehlerfortpflanzung über Teilschritte: Die Kondition eines späteren Teilschritts verstärkt die Fehler aller früheren	4.3

Bemerkung 4.4.1 (Faustregel, mit Einschränkung)

Schlecht konditionierte Teilschritte möglichst früh ausführen!

Bei der Varianz tut das die zweistufige Rechnung $\tilde{f}_1$ (Beispiel 4.3.5). Ein Satz ist die Regel nicht; ihre Einschränkungen stehen in Bemerkung 4.3.4.

Wie geht es weiter?

Kapitel 5 wendet das neue Vokabular auf das wichtigste Rechenproblem der Statistik an, die numerische Lösung linearer Gleichungssysteme $Ax = b$. Die Konditionszahl $\kappa(A)$ sagt dort, wie genau die Lösung überhaupt sein kann, und die Stabilitätsanalyse, welche Lösungsverfahren diese Genauigkeit auch erreichen.

Selbsttest zum Kapitel

1. Ein stabiler Algorithmus für ein schlecht konditioniertes Problem liefert im Allgemeinen ungenaue Ergebnisse.

Antwort: Wahr

Die Stabilität begrenzt nur den roten Term der Zerlegung, den der Algorithmus selbst beisteuert. Den orangen Term erzwingt das Problem: Ist es schlecht konditioniert, verstärkt es den unvermeidbaren Inputfehler, und daran ändert kein Algorithmus etwas. Die richtige Erwartung lautet: nicht ungenauer, als das Problem es erzwingt.

2. Im Widget zur Kondition eines Gleichungssystems (Abschnitt 4.2) ist die Voreinstellung „schlecht konditioniert“ gewählt. Welchen Wert zeigt der Readout für die Schranke $\kappa(\mathbf{A})$?

Lösung: 82

Rund 82. Die Matrix ist $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1,05 \end{pmatrix}$ mit den Singulärwerten $\sigma_{\max} \approx 2,025$ und $\sigma_{\min} \approx 0,0247$,

also $\kappa_2(\mathbf{A}) = \sigma_{\max}/\sigma_{\min} \approx 82,0$ (Bemerkung 4.2.7). Für die Voreinstellung der rechten Seite wird diese Schranke fast exakt angenommen.

Vertiefung: Heath §1.2.

4.5 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuffhard/Hohmann Aufgabe 2.15	Kondition der Summation von n Zahlen	mittel, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.16	Stabilität der Varianzberechnung	mittel, ca. 30 Min.
Heath Exercise 1.5	Konditionszahl der Subtraktion	mittel, ca. 15 Min.
Heath Exercise 1.10	Auslöschung bei $\frac{1}{1-x} - \frac{1}{1+x}$	leicht, ca. 15 Min.
Heath Exercise 1.12	Auslöschung bei $x^2 - y^2$	leicht, ca. 15 Min.
Schaback/Wendland Aufgabe 1.9	Subtraktive Auslöschung algebraisch beseitigen	mittel, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.12	$\kappa(\mathbf{A})$ als Verhältnis von maximaler zu minimaler Streckung	mittel, ca. 30 Min.
Heath Review Question 2.57	Kondition einer Diagonalmatrix in 1- und ∞ -Norm	leicht, ca. 15 Min.
Deuffhard/Hohmann Aufgabe 2.13	Kondition symmetrisch positiv definiter Matrizen	leicht, ca. 15 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 1.1	Relativer Fehler der „normalen“ Körpertemperatur	leicht, ca. 15 Min.
Heath Exercise 1.3	Multiplikative Darstellung des relativen Fehlers	leicht, ca. 15 Min.
Schaback/Wendland Aufgabe 1.8	Relativer Fehler von $1/x - 1/(x+1)$ in dreistelliger Arithmetik	leicht, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.3	Auslöschungsfreie Cardano-Formel	schwer, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.5	Totalauslöschung bei einer e -Approximation	schwer, 1 Std. und mehr
Schaback/Wendland Aufgabe 1.4	Auslöschungsfreie Berechnung von $\tanh x$ für $x \approx 0$	mittel, ca. 30 Min.
Deuffhard/Hohmann Aufgabe 2.18	Fast singuläres 2×2 -System, normweise und komponentenweise Kondition	mittel, 1 Std. und mehr

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deuffhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.).

Lineare Gleichungssysteme

5.1 Numerische lineare Algebra: Grundlagen

Ab hier geht es um *numerische lineare Algebra*: Wie berechnen wir die Objekte und Operationen der linearen Algebra auf dem Rechner schnell und verlässlich? Auf dem Programm stehen numerische Methoden für

- die Matrizenrechnung (Addition, Multiplikation),
- lineare Gleichungssysteme (der Kern dieses Kapitels, ab Abschnitt 5.2),
- Kleinste-Quadrate-Probleme (Kapitel 7),
- Eigenwertprobleme und mehr.

Bei jeder Methode achten wir auf zwei Gütekriterien: auf die Kondition (wie stark verstärken sich kleine Fehler?) und auf die Komplexität (wie wächst der Aufwand mit der Problemgröße?).

Was wir mitbringen

Aus den bisherigen Kapiteln brauchen wir

- den Algorithmus-Begriff (Abschnitt 2.1), insbesondere *direkte Methoden* (endlich viele Schritte, exakte Lösung in exakter Arithmetik), und die Komplexitätsanalyse mit Landau-Symbolen (Abschnitt 2.4),
- die Kondition von Problemen (Abschnitt 4.2) und die Stabilität von Algorithmen (Abschnitt 4.3),
- Matrixnormen (Abschnitt 3.2) und Orthogonalmatrizen mit ihrer perfekten Kondition $\kappa_2(\mathbf{Q}) = 1$ (Abschnitt 3.3).

Dazu kommt Grundwissen aus der Linearen Algebra I: das Lösen linearer Gleichungssysteme mit grundlegenden Methoden, Dreiecksmatrizen, symmetrische und positiv definite Matrizen sowie die Matrixinverse. Über Letztere lernen wir in diesem Kapitel vor allem eines: dass wir sie numerisch *nicht* berechnen.

Matrizenrechnung

Die algorithmische Berechnung der Grundoperationen folgt für gewöhnlich direkt den mathematischen Formeln. Für die Addition von $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times m}$ heißt das

$$\mathbf{A} + \mathbf{B} = \begin{pmatrix} a_{11} + b_{11} & \cdots & a_{1m} + b_{1m} \\ \vdots & & \vdots \\ a_{n1} + b_{n1} & \cdots & a_{nm} + b_{nm} \end{pmatrix},$$

und für die Matrixmultiplikation von $\mathbf{A} \in \mathbb{R}^{n \times m}$ mit $\mathbf{B} \in \mathbb{R}^{m \times k}$

$$\mathbf{AB} = \begin{pmatrix} \sum_{i=1}^m a_{1i}b_{i1} & \cdots & \sum_{i=1}^m a_{1i}b_{ik} \\ \vdots & & \vdots \\ \sum_{i=1}^m a_{ni}b_{i1} & \cdots & \sum_{i=1}^m a_{ni}b_{ik} \end{pmatrix}.$$

Jeder Eintrag des Produkts ist also ein Skalarprodukt einer Zeile von $\mathbf{A}$ mit einer Spalte von $\mathbf{B}$.

Wie gut diese Operationen konditioniert sind, untersuchen wir in der Übung mit dem Handwerkszeug aus Abschnitt 4.2. Ihre Komplexität können wir sofort bestimmen, indem wir Operationen zählen wie in Abschnitt 2.3.

Was ist die algorithmische Komplexität der *Addition* von $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times m}$? Zur Auswahl stehen $O(nm)$, $O(n + m)$ und $O(n^2m^2)$.

1. Die Addition gelingt in $O(nm)$ Operationen, und schneller geht es größenordnungsmäßig auch nicht.

Antwort: Wahr

Das Ergebnis hat nm Einträge, und jeder Eintrag kostet genau eine Addition $a_{ij} + b_{ij}$; zusammen nm Additionen, also $O(nm)$. Weniger geht nicht, denn schon das Hinschreiben der nm Ergebniseinträge braucht nm Schritte.

2. Die Addition gelingt sogar in $O(n + m)$ Operationen.

Antwort: Falsch

$n + m$ ist viel kleiner als nm (für $n = m = 100$ etwa 200 gegen 10 000). Ein Algorithmus mit nur $O(n + m)$ Schritten könnte nicht einmal alle Ergebniseinträge schreiben.

3. Der Aufwand wächst wie n^2m^2 , weil jeder Eintrag von $\mathbf{A}$ mit jedem Eintrag von $\mathbf{B}$ verrechnet werden muss.

Antwort: Falsch

Addiert wird nur *paarweise* an gleicher Position (i, j) ; Einträge an verschiedenen Positionen treffen nie aufeinander. Als obere Schranke wäre $O(n^2m^2)$ formal korrekt (Landau-Symbole erlauben Überschätzung, Abschnitt 2.4), beschreibt das Wachstum aber grob falsch: Die scharfe Ordnung ist nm .

Und die *Multiplikation* von $\mathbf{A} \in \mathbb{R}^{n \times m}$ mit $\mathbf{B} \in \mathbb{R}^{m \times k}$? Zur Auswahl stehen $O(nk)$, $O(nmk)$ und $O(nm + k)$.

1. Die Multiplikation kostet $O(nk)$ Operationen, denn das Produkt hat nk Einträge.

Antwort: Falsch

nk zählt nur die Ergebniseinträge. Jeder einzelne ist aber ein Skalarprodukt der Länge m und kostet selbst m Multiplikationen und $m - 1$ Additionen; der Faktor m fehlt.

2. Die Multiplikation nach der Produktformel kostet $O(nmk)$ Operationen.

Antwort: Wahr

Für jede der $n \cdot k$ Kombinationen aus Zeile und Spalte fallen m Multiplikationen und $m - 1$ Additionen an, insgesamt also $nk(2m - 1) = O(nmk)$ Operationen. Für quadratische Matrizen ($n = m = k$) ist das der bekannte $O(n^3)$ -Aufwand.

3. Es reichen $O(nm + k)$ Operationen.

Antwort: Falsch

Für $n = m = k$ wüchse $nm + k = n^2 + n$ nur quadratisch, die Produktformel braucht aber kubischen Aufwand n^3 .

Geht Matrixmultiplikation schneller?

Für quadratische Matrizen $A, B \in \mathbb{R}^{n \times n}$ gibt es Algorithmen mit besserer Komplexität als $O(n^3)$. Der erste stammt von Strassen (1969): Er zerlegt beide Matrizen in vier Blöcke und kommt mit sieben statt acht Blockmultiplikationen aus. Rekursiv angewandt kostet das $O(n^{\log_2 7})$ Operationen, also etwa $O(n^{2.8})$, denn $\log_2 7 \approx 2.807$. Der aktuelle Rekord liegt bei etwa $O(n^{2.37})$ (Alman et al., 2024). 2022 hat DeepMinds AlphaTensor per Reinforcement Learning bisher unbekannte Multiplikationsschemata für kleine Matrixformate gefunden.

Bemerkung 5.1.1 (Warum wir trotzdem mit $O(nmk)$ rechnen)

Die Landau-Notation versteckt konstante Faktoren, und bei den schnellen Multiplikationsalgorithmen sind diese Konstanten meist so groß, dass sich die bessere Ordnung erst bei riesigen Matrizen auszahlen würde. In der Praxis werden die Verfahren deshalb kaum verwendet. Wir rechnen der Einfachheit halber immer mit $O(nmk)$ für die Multiplikation und $O(nm)$ für die Addition.

Ab Abschnitt 5.2 geht es um das wichtigste Problem der numerischen linearen Algebra: das Lösen von $Ax = b$.

Vertiefung: Heath §2.1 (Einstieg in lineare Gleichungssysteme); zur Komplexitätsanalyse Heath §1.1.

5.2 Lineare Gleichungssysteme

Problemstellung

Gesucht ist die Lösung x eines linearen Gleichungssystems (LGS)

$$Ax = b.$$

Ob Kleinste-Quadrate-Schätzer (Abschnitt 7.1) oder gemischtes Modell: In der Statistik steht am Ende fast immer ein solches System.

Sinnvoll gestellt ist die Aufgabe nur, wenn es genau eine Lösung gibt. Wir nehmen deshalb in diesem Kapitel an, dass $A \in \mathbb{R}^{n \times n}$ quadratisch und invertierbar ist. Die Lösung lässt sich dann als $x = A^{-1}b$ schreiben. Diese Formel ist allerdings eine Schreibweise, kein Rechenweg.

Bemerkung 5.2.1 (Für ein LGS keine explizite Inverse bilden)

Wer nur $Ax = b$ lösen will, bildet die Inverse nicht explizit, sondern löst das System direkt.

Wo immer in einer Formel $A^{-1}\mathbf{b}$ steht, lösen wir in der Implementierung das LGS $A\mathbf{x} = \mathbf{b}$. Zwei Gründe sprechen gegen den Umweg über A^{-1} :

- **Aufwand:** A^{-1} explizit auszurechnen heißt, die n Systeme $A\mathbf{z}_j = \mathbf{e}_j$ für alle Einheitsvektoren $\mathbf{e}_j$ zu lösen und danach noch das Produkt $A^{-1}\mathbf{b}$ zu bilden: n Lösungen statt einer. Die Größenordnung (Abschnitt 2.4) bleibt dabei die einer einzigen Elimination, weil sich deren teure Vorarbeit für alle n rechten Seiten wiederverwenden lässt; in der versteckten Konstanten kostet der Umweg aber ein Mehrfaches.
- **Genauigkeit:** Bei einer schlecht konditionierten Matrix können die zusätzlichen Rundungen der Inversenbildung und des anschließenden Matrix-Vektor-Produkts den Fehler deutlich vergrößern. Einen Genauigkeitsvorteil bringt der Umweg für eine einzelne rechte Seite nicht. Gauß-Elimination *mit partieller Pivotierung* ist in der Praxis meist rückwärtsstabil. Wie genau die Lösung überhaupt sein kann, begrenzt in beiden Fällen die Konditionszahl $\kappa(\mathbf{A})$ (Abschnitt 3.5 und Abschnitt 4.2).

Legitim ist eine explizite Inverse, wenn sie selbst das gesuchte Objekt ist.

Beispiel 5.2.2 (Hilbert-Matrix: Inverse gegen direktes Lösen)

Die Hilbert-Matrix $\mathbf{H}_n$ mit Einträgen $h_{ij} = 1/(i + j - 1)$ ist schon für kleine n sehr schlecht konditioniert; für $n = 11$ ist $\kappa_2(\mathbf{H}_{11}) \approx 5 \cdot 10^{14}$. Wir wählen die exakte Lösung $\mathbf{x} = (1, \dots, 1)^\top$, berechnen $\mathbf{b} = \mathbf{H}_n\mathbf{x}$ und lösen in R direkt mit `solve(A, b)` und über die Inverse mit `solve(A) %*% b`:

```
n <- 11 # Hilbert-Matrix
A <- outer(1:n, 1:n,
           function(i, j) 1 / (i + j - 1))
x <- rep(1, n)
b <- A %*% x

range((solve(A) %*% b) - x) # Fehler über Inverse
range(solve(A, b) - x)      # Fehler direkte Lösung
```

Für $n = 11$ haben wir beide Wege mit derselben einfachen Gauß-Elimination mit partieller Pivotierung in JavaScript nachgerechnet. Beim direkten Lösen ist der relative Fehler $\|\hat{\mathbf{x}} - \mathbf{x}\|_\infty / \|\mathbf{x}\|_\infty \approx 9,66 \cdot 10^{-3}$, über die explizite Inverse etwa $3,73 \cdot 10^{-1}$: rund 38,6-mal ungenauer. Die genauen Werte hängen von Algorithmus, Reihenfolge der Operationen und Gleitkommaarithmetik ab (R rechnet mit LAPACK und kann andere Zahlen liefern); allgemeine Fehlerschranken sind sie nicht.

Interaktiv: Kondition und Rechenweg

Ab welcher Ordnung trennen die Rundungsfehler die beiden Rechenwege sichtbar?

Interaktives Element — nur in der Web-Fassung

Ab $n = 9$ übersteigt $\kappa_\infty(\mathbf{H}_n) \cdot \varepsilon$ den Wert 10^{-4} : Von den rund 16 Dezimalstellen doppelter Genauigkeit bleiben dann höchstens vier. Die Kondition bestimmt, wie empfindlich beide Rechenwege sind; genauer als das direkte Lösen ist der Inversenweg bei keiner Ordnung.

Gauß-Elimination und Rückwärtssubstitution

Direkt lösen wir mit dem Gauß'schen Eliminationsverfahren aus der linearen Algebra. Es besteht aus zwei Phasen:

Algorithmus 5.2.3 (Gauß-Elimination mit partieller Pivotierung)

1. Wähle in Eliminationsschritt k unter den Zeilen $k, \dots, n$ einen Eintrag mit maximalem Betrag in Spalte k und tausche seine Zeile nach oben. Eliminiere anschließend die Einträge darunter. So entsteht aus $(A \mid b)$ eine Zeilenstufenform $(U \mid c)$ mit oberer Dreiecksmatrix U .
2. Löse das gestaffelte System

$$\begin{array}{ccccccc} u_{11}x_1 & + & u_{12}x_2 & + & \dots & + & u_{1n}x_n & = & c_1 \\ & & u_{22}x_2 & + & \dots & + & u_{2n}x_n & = & c_2 \\ & & & & \ddots & & \vdots & & \vdots \\ & & & & & & u_{nn}x_n & = & c_n \end{array}$$

durch *Rückwärtssubstitution* (backward substitution):

$$x_n = c_n / u_{nn}, \quad x_i = \left(c_i - \sum_{j=i+1}^n u_{ij}x_j \right) / u_{ii} \quad (i \leq n-1). \quad (5.2.1)$$

Die letzte Gleichung des gestaffelten Systems enthält nur noch x_n und verrät diesen Wert sofort. Danach arbeiten wir uns Zeile für Zeile nach oben. Im Farbcode dieses Kapitels: Ist Zeile i an der Reihe (blau), sind die Komponenten aus den Zeilen darunter schon bekannt (grün). Die Zeile setzt sie ein und teilt zum Schluss durch ihr Diagonalelement, das Pivot (rot):

$$x_i = \left(c_i - \sum_{j=i+1}^n u_{ij} x_j \right) / u_{ii}.$$

Mit partieller Pivotierung garantiert die Invertierbarkeit in jedem Schritt ein von null verschiedenes Pivot. *Ohne* Zeilentausch reicht sie nicht, ein Nullpivot kann trotzdem auftreten (Beispiel 5.3.5). Auch ein sehr kleines Pivot ist in Gleitkommaarithmetik gefährlich; deshalb wählen wir den betragsgrößten Eintrag (mehr dazu in Abschnitt 5.3).

Interaktiv: Rückwärtseinsetzen Schritt für Schritt

Die Formel (5.2.1) bestimmt die Komponenten von unten nach oben. Zählen wir dabei die Divisionen.

Interaktives Element — nur in der Web-Fassung

Und was kostet die zweite Phase für ein $n \times n$ -System (Landau-Notation: Abschnitt 2.4)?

1. Wie viele Divisionen hat das voreingestellte Rückwärtseinsetzen im Widget?

Lösung: 3

Eine pro Diagonalzeile, also drei.

2. Die Rückwärtssubstitution für ein $n \times n$ -System hat die Komplexität $O(1)$.

Antwort: Falsch

Konstanter Aufwand ist unmöglich: Schon um jeden Eintrag von U einmal anzufassen, braucht es mit n wachsende Arbeit.

3. Die Rückwärtssubstitution für ein $n \times n$ -System hat die Komplexität $O(n)$, denn sie besteht aus n Schritten.

Antwort: Falsch

Die Schrittzahl stimmt, aber die Schritte sind nicht konstant teuer: Schritt i setzt die $n - i$ schon bekannten Komponenten ein, im ungünstigsten Fall also $n - 1$ Stück.

4. Die Rückwärtssubstitution für ein $n \times n$ -System hat die Komplexität $O(n^2)$.

Antwort: Wahr

Es sind n Schritte, und Schritt i kostet nach Formel (5.2.1) je $n - i$ Multiplikationen und ebenso viele Subtraktionen, dazu eine Division. Aufsummiert sind das $n(n - 1)/2 \approx n^2/2$ Multiplikationen und insgesamt genau n^2 Rechenoperationen, also $O(n^2)$.

5. Die Rückwärtssubstitution für ein $n \times n$ -System hat die Komplexität $O(n^3)$.

Antwort: Falsch

Das überschätzt den Aufwand um einen Faktor n . (Formal enthält $O(n^3)$ auch alle $O(n^2)$ -Algorithmen, gemeint ist hier aber die Größenordnung des tatsächlichen Aufwands.) Bei $O(n^3)$ liegt erst die Eliminationsphase, wie wir in Abschnitt 5.3 sehen werden.

Warum Matrixzerlegungen?

Die Gauß-Elimination löst unser LGS. In den nächsten Abschnitten organisieren wir sie als *Matrixzerlegung* (matrix decomposition) neu. Die Grundidee ist „Teile und herrsche“ für Matrizen: Statt direkt mit A zu arbeiten, schreiben wir $A = BC$ mit „einfachen“ Faktoren B und C .

Eine Analogie ist die Primfaktorzerlegung. Es gilt $84 = 2^2 \cdot 3 \cdot 7$, und wer diese Zerlegung kennt, rechnet leichter weiter:

$$84 \cdot 126 = (2^2 \cdot 3 \cdot 7) \cdot (2 \cdot 3^2 \cdot 7) = 2^3 \cdot 3^3 \cdot 7^2.$$

Multiplizieren wird zum Addieren von Exponenten. Für Matrizen suchen wir entsprechend Faktoren, mit denen sich leicht rechnen lässt. Drei Familien haben sich als „einfach“ bewährt:

- Dreiecksmatrizen: Ein Dreieckssystem lösen wir per Vorwärts- bzw. Rückwärtssubstitution in $O(n^2)$ statt $O(n^3)$, wie eben gesehen.
- Orthogonale Matrizen: Sie verstärken Störungen in der 2-Norm nicht und sind wegen $Q^{-1} = Q^T$ trivial zu invertieren.
- Diagonalmatrizen: Invertieren, Multiplizieren und Potenzieren laufen elementweise auf der Diagonalen.

Was bringt uns eine Zerlegung?

1. **Mehrere LGS mit derselben Matrix effizient lösen.** Die Zerlegung rechnen wir einmal; danach braucht jedes weitere System $Ax = b_i$ nur noch die schnellen Dreiecks- oder Dia-

gonallösungen. In der Statistik ist das der Normalfall, etwa wenn dieselbe Modellmatrix auf viele Zielvariablen trifft.

2. **Numerische Stabilität verbessern.** Wer die Arbeit in gut konditionierte Teilschritte zerlegt, etwa über orthogonale Faktoren, vermeidet unnötige Fehlerverstärkung (Abschnitt 4.3).
3. **Struktur und Eigenschaften von A erkennen.** An den Faktoren lässt sich ablesen, ob A (fast) singular oder positiv definit ist; solche Diagnosen fallen bei der Zerlegung nebenbei ab.
4. **Grundlage für weitere Algorithmen.** Auf Zerlegungen bauen viele Verfahren auf, von der QR-Zerlegung für das KQ-Problem (Abschnitt 7.4) bis zur Spektralzerlegung und der Singulärwertzerlegung (SVD, Kapitel 6).

Den Anfang macht in Abschnitt 5.3 die LU-Zerlegung, die Gauß-Elimination in Matrixform.

Vertiefung: Heath §2.1–2.2 (Problemstellung und Lösbarkeit) sowie §2.4.2 (Dreieckssysteme und Rückwärtssubstitution).

5.3 Die LU-Zerlegung

Elimination als Zerlegung

Die Gauß-Elimination aus Abschnitt 5.2 verwandelt $(A \mid \mathbf{b})$ durch Zeilenoperationen in ein gestaffeltes System. Dabei zerlegt sie auch die Matrix selbst. Alles, was wir dabei tun, halten zwei Faktoren fest:

- L (*lower*) speichert sämtliche Eliminationsschritte,
- U (*upper*) ist die entstehende obere Dreiecksmatrix.

Definition 5.3.1 (LU-Zerlegung)

Eine Darstellung

$$A = LU$$

von $A \in \mathbb{R}^{n \times n}$ mit einer unteren Dreiecksmatrix L mit Einsen auf der Diagonalen und einer oberen Dreiecksmatrix U heißt *LU-Zerlegung* (LU decomposition) von A .

Sobald wir $A = LU$ einmal berechnet haben, lösen wir $A\mathbf{x} = \mathbf{b}_i$ für *jedes* $\mathbf{b}_i$ über zwei Dreieckssysteme, jedes für nur $O(n^2)$ Operationen (Algorithmus 5.3.6).

Eliminationsmatrizen

Wie sehen die Faktoren aus? Die Elimination arbeitet sich von links nach rechts durch die Spalten und entfernt alle Einträge unter der Diagonalen. Nennen wir das aktuelle System $(M \mid \mathbf{r})$. Die k -te Spalte räumen wir, indem wir von links mit der *Eliminationsmatrix* L_k multiplizieren:

$$\mathbf{L}_k = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{(k+1)k} & 1 & \\ & & \vdots & & \ddots \\ & & -l_{nk} & & & 1 \end{pmatrix} \quad \text{mit} \quad l_{ik} = \frac{m_{ik}}{m_{kk}}. \quad (5.3.1)$$

$\mathbf{L}_k$ ist eine Einheitsmatrix mit Zusatzeinträgen in Spalte k . Das Produkt $\mathbf{L}_k \mathbf{M}$ zieht für jedes $i > k$ von Zeile i das l_{ik} -fache der Pivotzeile k ab und erzeugt so die Nullen unter dem Pivot m_{kk} . Nach $n - 1$ solchen Schritten sind alle Spalten abgeräumt.

Jeder Schritt lässt sich rückgängig machen: $\mathbf{L}_k^{-1}$ addiert die abgezogenen Vielfachen wieder und ist deshalb dieselbe Matrix mit umgekehrten Vorzeichen unterhalb der Diagonalen. Als Produkt unterer Dreiecksmatrizen ist dann auch $\mathbf{L} = \mathbf{L}_1^{-1} \cdots \mathbf{L}_{n-1}^{-1}$ eine untere Dreiecksmatrix, und zwar eine besonders einfache:

Satz 5.3.2 (Die Gauß-Elimination liefert eine LU-Zerlegung)

Läuft die Gauß-Elimination für $\mathbf{A} \in \mathbb{R}^{n \times n}$ ohne Nullpivot durch, so ist

$$\mathbf{U} = \mathbf{L}_{n-1} \cdots \mathbf{L}_1 \mathbf{A}$$

eine obere Dreiecksmatrix, und es gilt $\mathbf{A} = \mathbf{LU}$ mit

$$\mathbf{L} = \mathbf{L}_1^{-1} \cdots \mathbf{L}_{n-1}^{-1} = \begin{pmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ l_{31} & l_{32} & 1 & & \\ \vdots & & \ddots & \ddots & \\ l_{n1} & \cdots & \cdots & l_{n(n-1)} & 1 \end{pmatrix}. \quad (5.3.2)$$

$\mathbf{L}$ sammelt also unter der Diagonalen unverändert die Multiplikatoren l_{ik} der Elimination.

Vertiefung (optional): Beweis der Produktformel für $\mathbf{L}$

Der Beweis rechnet mit einer kompakten Schreibweise für $\mathbf{L}_k$; entscheidend ist, dass sich das Produkt der Inversen ohne Mischterme ausmultiplizieren lässt.

Beweis.

- (1) Wir schreiben $\mathbf{L}_k$ kompakt als $\mathbf{L}_k = \mathbf{I} - \mathbf{l}_k \mathbf{e}_k^\top$, wobei $\mathbf{e}_k$ der k -te Einheitsvektor ist und $\mathbf{l}_k = (0, \dots, 0, l_{(k+1)k}, \dots, l_{nk})^\top$ die Multiplikatoren der k -ten Spalte sammelt; die ersten k Komponenten von $\mathbf{l}_k$ sind null.

$\mathbf{l}_k \mathbf{e}_k^\top$ ist die Matrix, die in Spalte k unterhalb der Diagonalen die Einträge l_{ik} trägt und sonst nur Nullen; abgezogen von $\mathbf{I}$ ergibt das die Gestalt aus (5.3.1)

- (2) Es gilt $\mathbf{L}_k^{-1} = \mathbf{I} + \mathbf{l}_k \mathbf{e}_k^\top$.

Ausmultiplizieren: $(\mathbf{I} - \mathbf{l}_k \mathbf{e}_k^\top)(\mathbf{I} + \mathbf{l}_k \mathbf{e}_k^\top) = \mathbf{I} - \mathbf{l}_k (\mathbf{e}_k^\top \mathbf{l}_k) \mathbf{e}_k^\top = \mathbf{I}$, denn $\mathbf{e}_k^\top \mathbf{l}_k$ ist die k -te Komponente von $\mathbf{l}_k$, und die ist null

- (3) Für das Produkt der Inversen gilt

$$\mathbf{L} = (\mathbf{I} + \mathbf{l}_1 \mathbf{e}_1^\top) \cdots (\mathbf{I} + \mathbf{l}_{n-1} \mathbf{e}_{n-1}^\top) = \mathbf{I} + \sum_{k=1}^{n-1} \mathbf{l}_k \mathbf{e}_k^\top,$$

und die rechte Seite ist die Matrix aus (5.3.2): Einsen auf der Diagonalen, darunter die Multiplikatoren, jeder an seinem Platz.

Beim Ausmultiplizieren verschwinden alle gemischten Terme: Sie enthalten Faktoren der Form $e_j^T \mathbf{l}_k$ mit $j < k$, und die j -te Komponente von $\mathbf{l}_k$ ist für $j \leq k$ null

- (4) Insbesondere ist $\mathbf{L}$ als Summe der Einheitsmatrix und von Beiträgen unterhalb der Diagonalen eine untere Dreiecksmatrix mit Einsen auf der Diagonalen. Auflösen von $\mathbf{U} = \mathbf{L}_{n-1} \cdots \mathbf{L}_1 \mathbf{A}$ nach $\mathbf{A}$ ergibt schließlich $\mathbf{A} = \mathbf{L}_1^{-1} \cdots \mathbf{L}_{n-1}^{-1} \mathbf{U} = \mathbf{L}\mathbf{U}$.

wir multiplizieren von links nacheinander mit $\mathbf{L}_{n-1}^{-1}, \dots, \mathbf{L}_1^{-1}$; diese Inversen existieren nach Schritt 2

□

Bei der klassischen Elimination treffen die Eliminationsmatrizen auch die rechte Seite: Aus $\mathbf{b}$ wird $\mathbf{c} = \mathbf{L}_{n-1} \cdots \mathbf{L}_1 \mathbf{b}$, das gestaffelte Endsystem ist $(\mathbf{U} \mid \mathbf{c})$. Mit gespeichertem $\mathbf{L}$ können wir uns das sparen, denn die Vorwärtssubstitution $\mathbf{L}\mathbf{y} = \mathbf{b}$ liefert später denselben Vektor, $\mathbf{y} = \mathbf{L}^{-1} \mathbf{b} = \mathbf{c}$.

Ein vollständiges Beispiel

Wir rechnen im Farbcode des Kapitels: Pivots rot, Multiplikatoren blau, fertige L-Einträge grün.

Beispiel 5.3.3 (LU-Zerlegung einer 3×3-Matrix)

Sei

$$\mathbf{A} = \begin{pmatrix} 2 & 1 & -1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix}.$$

Schritt 1: Spalte 1 räumen. Das Pivot ist $m_{11} = 2$, die Multiplikatoren nach Formel (5.3.1) sind

$$l_{21} = \frac{4}{2} = 2, \quad l_{31} = \frac{-2}{2} = -1.$$

Damit ist

$$\mathbf{L}_1 = \begin{pmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}, \quad \mathbf{L}_1 \mathbf{A} = \begin{pmatrix} 2 & 1 & -1 \\ 0 & -8 & 2 \\ 0 & 8 & 1 \end{pmatrix}.$$

Schritt 2: Spalte 2 räumen. Das Pivot ist jetzt -8 , und mit

$$l_{32} = \frac{8}{-8} = -1, \quad \mathbf{L}_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix}$$

erreichen wir die Dreiecksform:

$$\mathbf{L}_2 \mathbf{L}_1 \mathbf{A} = \begin{pmatrix} 2 & 1 & -1 \\ 0 & -8 & 2 \\ 0 & 0 & 3 \end{pmatrix} = \mathbf{U}.$$

Ergebnis: Die Multiplikatoren wandern mit ihrem ursprünglichen Vorzeichen nach $\mathbf{L}$:

$$\mathbf{L} = \mathbf{L}_1^{-1}\mathbf{L}_2^{-1} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix}, \quad \mathbf{U} = \begin{pmatrix} 2 & 1 & -1 \\ 0 & -8 & 2 \\ 0 & 0 & 3 \end{pmatrix}.$$

Die Probe $\mathbf{LU} = \mathbf{A}$ geht auf.

Wann existiert die Zerlegung?

In jedem Schritt teilen wir durch das Pivot m_{kk} . Steht dort eine Null, bricht die Elimination ab, auch wenn $\mathbf{A}$ invertierbar ist.

Satz 5.3.4 (Existenz der LU-Zerlegung)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ invertierbar. Dann gilt:

1. Die LU-Zerlegung $\mathbf{A} = \mathbf{LU}$ aus Definition 5.3.1 existiert genau dann, wenn die Gauß-Elimination an $\mathbf{A}$ ohne Nullpivot durchläuft. In diesem Fall ist sie eindeutig.
2. Es gibt stets eine Permutationsmatrix $\mathbf{P}$ (sie vertauscht Zeilen), sodass die Elimination an $\mathbf{PA}$ ohne Nullpivot durchläuft; es gilt dann $\mathbf{PA} = \mathbf{LU}$.

Die Richtung „kein Nullpivot $\Rightarrow$ Zerlegung existiert“ ist Satz 5.3.2; auf die übrigen Beweisteile verzichten wir. Ein Beispiel zeigt, dass die Bedingung in Teil 1 nötig ist:

Beispiel 5.3.5 (Invertierbar, aber keine LU-Zerlegung)

Die Vertauschungsmatrix

$$\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

ist invertierbar ($\det \mathbf{A} = -1$). Trotzdem scheitert die Elimination sofort, denn das erste Pivot ist $m_{11} = 0$. Auch keine andere Konstruktion hilft: Der Ansatz

$$\mathbf{LU} = \begin{pmatrix} 1 & 0 \\ l & 1 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{pmatrix} = \begin{pmatrix} u_{11} & u_{12} \\ l u_{11} & l u_{12} + u_{22} \end{pmatrix}$$

erzwingt $u_{11} = 0$ aus dem Eintrag links oben und zugleich $l u_{11} = 1$ aus dem Eintrag links unten: ein Widerspruch.

Ein Zeilentausch löst das Problem dagegen sofort auf, denn mit $\mathbf{P} = \mathbf{A}$ ist $\mathbf{PA} = \mathbf{I} = \mathbf{I} \cdot \mathbf{A}$ eine (triviale) LU-Zerlegung.

Lösen mit der LU-Zerlegung

Mit $\mathbf{A} = \mathbf{LU}$ und $\mathbf{y} = \mathbf{U}\mathbf{x}$ zerfällt $\mathbf{Ax} = \mathbf{b}$ in zwei gestaffelte Systeme,

$$\mathbf{L} \underbrace{\mathbf{U}\mathbf{x}}_{=\mathbf{y}} = \mathbf{b},$$

die wir per Vorwärts- und Rückwärtssubstitution (forward/backward substitution) lösen:

Algorithmus 5.3.6 (Lösen von $Ax = b$ mit der LU-Zerlegung)

1. *Vorwärtssubstitution*: Löse $Ly = b$ von oben nach unten,

$$y_i = b_i - \sum_{j=1}^{i-1} l_{ij} y_j \quad (i = 1, \dots, n);$$

eine Division ist nicht nötig, denn auf der Diagonalen von L stehen Einsen.

2. *Rückwärtssubstitution*: Löse $Ux = y$ von unten nach oben wie in Formel (5.2.1),

$$x_i = \left(y_i - \sum_{j=i+1}^n u_{ij} x_j \right) / u_{ii} \quad (i = n, \dots, 1).$$

Beispiel 5.3.7 (Fortsetzung: Lösen mit der Zerlegung)

Wir nehmen L und U aus Beispiel 5.3.3 und lösen $Ax = b$ für $b = (5, -2, 9)^T$.

Schritt 1: Vorwärtssubstitution für $Ly = b$:

$$\begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & -1 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \\ 9 \end{pmatrix} \implies \begin{aligned} y_1 &= 5, \\ y_2 &= -2 - 2 \cdot 5 = -12, \\ y_3 &= 9 - (-1) \cdot 5 - (-1) \cdot (-12) = 9 + 5 - 12 = 2. \end{aligned}$$

Schritt 2: Rückwärtssubstitution für $Ux = y$ mit $y = (5, -12, 2)^T$; die Divisoren sind die Diagonalelemente u_{ii} :

$$\begin{aligned} x_3 &= 2/3 = \frac{2}{3}, \\ x_2 &= (-12 - 2 \cdot \frac{2}{3}) / (-8) = \frac{5}{3}, \\ x_1 &= (5 - 1 \cdot \frac{5}{3} - (-1) \cdot \frac{2}{3}) / 2 = 2. \end{aligned}$$

Die Lösung ist $x = (2, \frac{5}{3}, \frac{2}{3})^T$; die Probe $Ax = b$ geht auf.

Interaktiv: LU-Zerlegung Schritt für Schritt

Welche Einträge speichert die LU-Zerlegung zusätzlich zur Arbeitsmatrix?

Interaktives Element — nur in der Web-Fassung

Zu jeder neuen Null der Arbeitsmatrix erscheint an derselben Position in L der Multiplikator, der sie erzeugt hat. Was von der Arbeitsmatrix übrig bleibt, ist U .

Pivotierung

Tritt ein Pivot $m_{kk} = 0$ auf wie in Beispiel 5.3.5, tauschen wir die Pivotzeile gegen eine Zeile weiter unten, in deren k -ter Spalte keine Null steht; bei invertierbarem A gibt es so eine Zeile immer. Dieses Umsortieren heißt *Pivotierung* (pivoting). Alle Vertauschungen sammeln wir in einer Permutationsmatrix P und erhalten die pivotierte Zerlegung $PA = LU$ aus Satz 5.3.4. Zum Lösen von

$\mathbf{Ax} = \mathbf{b}$ substituieren wir entlang $\mathbf{LUx} = \mathbf{Pb}$: Die rechte Seite wird mitvertauscht, sonst ändert sich nichts.

Auch ein sehr kleines Pivot $m_{kk} \approx 0$ ist gefährlich: Die Multiplikatoren $l_{ik} = m_{ik}/m_{kk}$ werden riesig, beim Abziehen der aufgeblähten Pivotzeile gehen die ursprünglichen Einträge der Matrix in Rundungsfehlern unter, und der Eliminationsschritt wird instabil (Abschnitt 4.3). Der Tausch zum betragsgrößten Pivot der Spalte (*partielle Pivotierung*) hält alle Multiplikatoren im Betrag bei höchstens 1 und macht die Elimination in der Praxis stabil. Numerikbibliotheken pivotieren deshalb grundsätzlich, auch wenn kein Pivot exakt null ist.

Interaktiv: Kleine Pivots, große Fehler

Was verändert der Zeilentauch am Rundungsfehler eines kleinen Pivots?

Interaktives Element — nur in der Web-Fassung

Ohne Zeilentauch wächst der Fehler mit jedem Zehnerschritt von ϵ mit: Bei $\epsilon = 10^{-12}$ stimmen nur noch vier Nachkommastellen, und ab $\epsilon \approx 10^{-16}$ geht der Eintrag a_{22} in der Subtraktion $1 - 1/\epsilon$ vollständig unter; die berechnete Zerlegung gehört dann zu einer anderen Matrix. Die Zeile mit Zeilentauch bleibt über den ganzen Reglerbereich bei Maschinengenauigkeit. Am Problem ändert der Tausch nichts, nur am Rechenweg.

Komplexität

Was kostet die Zerlegung? Zuerst ein einzelner Schritt: Im k -ten Schritt multiplizieren wir das aktuelle System mit $\mathbf{L}_k$, und die ersten $k - 1$ Spalten der Arbeitsmatrix haben ihre Nullen unter der Diagonalen bereits (Landau-Notation: Abschnitt 2.4).

1. Für den k -ten Schritt müssen wir das volle Matrixprodukt $\mathbf{L}_k \mathbf{M}$ ausrechnen; er kostet also $O(n^3)$ Operationen.

Antwort: Falsch

$\mathbf{L}_k$ wird nicht als volle Matrix multipliziert. Es unterscheidet sich von der Einheitsmatrix nur in Spalte k ; das Produkt zieht nur von den Zeilen $k + 1, \dots, n$ je ein Vielfaches der Pivotzeile ab.

2. Im k -ten Schritt ändern sich nur die Einträge im rechten unteren $(n - k) \times (n - k)$ -Block (und die rechte Seite); der Aufwand ist $O((n - k)^2)$.

Antwort: Wahr

Betroffen sind die Zeilen $k + 1, \dots, n$; links von Spalte k stehen dort schon Nullen, und die bleiben null. In Spalte k entsteht die neue Null, neu berechnet werden die Spalten $k + 1, \dots, n$ und der Eintrag der rechten Seite: $n - k$ Zeilen mit je $n - k + 1$ Aktualisierungen, zusammen $(n - k)(n - k + 1)$ Rechenschritte, also $O((n - k)^2)$.

3. $O(n^2)$ ist eine korrekte obere Schranke für den Aufwand des k -ten Schritts.

Antwort: Wahr

Wegen $(n - k)^2 \leq n^2$ stimmt das; die Schranke ist nur nicht scharf, denn späte Schritte sind viel billiger. Für die Gesamtkosten macht das keinen Unterschied: Beide Abschätzungen liefern aufsummiert $O(n^3)$.

4. Die Schritte werden mit wachsendem k teurer; der k -te Schritt kostet $O(k^3)$ Operationen.

Antwort: Falsch

Umgekehrt: Der aktive Block schrumpft von Schritt zu Schritt. Der erste Schritt ist mit etwa n^2 Aktualisierungen der teuerste; der letzte bearbeitet nur noch die unterste Zeile, also eine neue Null, einen aktualisierten Eintrag und die rechte Seite.

Satz 5.3.8 (Komplexität der LU-Zerlegung)

Für invertierbares $A \in \mathbb{R}^{n \times n}$ gilt:

1. Die Berechnung der LU-Zerlegung kostet $O(n^3)$ Operationen.
2. Vorwärts- und Rückwärtssubstitution kosten je $O(n^2)$.
3. Das Lösen von J Systemen $Ax = b_j, j = 1, \dots, J$, mit derselben Matrix kostet insgesamt $O(n^3 + Jn^2)$.

Teil 1 folgt durch Aufsummieren der Schrittkosten aus dem Quiz, mit $j = n - k$:

$$\sum_{k=1}^{n-1} O((n-k)^2) = O\left(\sum_{j=1}^{n-1} j^2\right) = O(n^3).$$

Die Quadratsumme ist $\frac{(n-1)n(2n-1)}{6} \approx \frac{n^3}{3}$; rund so viele Multiplikationen kostet die Zerlegung. Teil 2 haben wir in Abschnitt 5.2 gezählt, ein Substitutionspaar braucht rund n^2 Multiplikationen. Teil 3 beruht darauf, dass L und U nur von A abhängen und nicht von b : Die teure Elimination fällt einmal an, für jede weitere rechte Seite bleiben die beiden Substitutionen. Demselben Muster folgt die QR-Zerlegung für Kleinste-Quadrate-Probleme (Abschnitt 7.4).

Interaktiv: Einmal zerlegen oder jedes Mal neu?

Dieselbe Matrix, J rechte Seiten, Kosten $n^3/3$ je Zerlegung und n^2 je Substitutionspaar: Wie viel spart die gespeicherte Zerlegung gegenüber dem Neuansatz?

Interaktives Element — nur in der Web-Fassung

Bei $n = 100$ und $J = 50$ rechten Seiten kostet der Neuansatz rund das Zwanzigfache: Die Zerlegung wird fünfzigmal statt einmal gerechnet, während die Substitutionen mit ihren n^2 kaum ins Gewicht fallen. Mit wachsendem J läuft der Ersparnisfaktor gegen rund $n/3$.

1. Ab wie vielen rechten Seiten ist die gespeicherte LU-Zerlegung im Kosten-Widget günstiger?

Lösung: 2

Ab der zweiten rechten Seite fällt die Zerlegung nur einmal an.

Bemerkung 5.3.9 (Struktur ausnutzen)

Die Laufzeit lässt sich weiter drücken, wenn A besondere Eigenschaften erfüllt, zum Beispiel:

- symmetrisch: $A = A^T$;
- positiv definit: $x^T Ax > 0$ für alle $x \neq 0$;
- *Bandeigenschaft*: $a_{ij} = 0$ für alle $|i - j| > \beta$, das heißt, außerhalb eines Bandes der Breite β um die Diagonale stehen nur Nullen;

- dünn besetzt (*sparse*): $a_{ij} = 0$ für die allermeisten (i, j) .

Für symmetrische, positiv definite Matrizen halbiert etwa die Cholesky-Zerlegung des nächsten Abschnitts (Abschnitt 5.4) den Aufwand. Für all diese Fälle gibt es ausgereifte Implementierungen, die wir selten selbst schreiben.

Vertiefung: Heath §2.4 (Gauß-Elimination, LU-Zerlegung, Pivotierung) und §2.5 (Spezialstrukturen).

5.4 Die Cholesky-Zerlegung

Die LU-Zerlegung (Abschnitt 5.3) funktioniert, notfalls mit Pivotierung, für jede invertierbare Matrix. Viele Matrizen der Statistik haben aber mehr Struktur: Sie sind symmetrisch, und ihre quadratische Form ist strikt positiv. Für sie gibt es eine maßgeschneiderte Zerlegung, die mit halbem Aufwand auskommt und ohne Pivotierung stabil bleibt: die Cholesky-Zerlegung.

SPD-Matrizen

SPD-Matrizen sind symmetrisch und positiv definit.

Definition 5.4.1 (SPD-Matrix)

Eine Matrix $A \in \mathbb{R}^{n \times n}$ heißt SPD, wenn

- $A = A^T$ gilt (A also symmetrisch ist) und
- $x^T A x > 0$ für alle $x \in \mathbb{R}^n$ mit $x \neq 0$ gilt (A also *positiv definit* ist).

Verlangen wir statt der strikten Ungleichung nur $x^T A x \geq 0$ für alle $x \in \mathbb{R}^n$, heißt ein symmetrisches A *positiv semidefinit* (PSD); den Nullvektor müssen wir dann nicht mehr ausnehmen. Der Unterschied wirkt klein, entscheidet aber später darüber, ob die Cholesky-Zerlegung ohne Zusatztricks durchläuft.

Interaktiv: Welche Richtung widerlegt positive Definitheit?

Eine einzelne Richtung kann positive Definitheit widerlegen, aber nie beweisen. Suchen wir eine Richtung, die den Gegenbeweis liefert.

Interaktives Element — nur in der Web-Fassung

Bei $\text{diag}(1, -1)$ ist $x^T A x$ strikt zwischen 45° und 135° sowie zwischen 225° und 315° negativ und bei 45° , 135° , 225° und 315° genau null; jede dieser Richtungen widerlegt positive Definitheit. Bei $\text{diag}(2, 1)$ bleibt der Wert in jeder Richtung positiv.

SPD- und PSD-Matrizen in Statistik und ML

In Statistik und maschinellem Lernen treten SPD- und PSD-Matrizen vor allem in drei Familien auf:

1. Kovarianzmatrizen $\Sigma = \mathbb{E}[(x - \mu)(x - \mu)^T]$ sind stets positiv semidefinit, denn für jeden

festen Vektor $\mathbf{a}$ ist $\mathbf{a}^\top \Sigma \mathbf{a} = \text{Var}(\mathbf{a}^\top \mathbf{x}) \geq 0$ eine Varianz. SPD ist Σ genau dann, wenn keine Linearkombination $\mathbf{a}^\top \mathbf{x}$ mit $\mathbf{a} \neq \mathbf{0}$ fast sicher konstant ist, die Verteilung also nicht auf einer Hyperebene liegt. Kovarianzmatrizen parametrisieren multivariate Normalverteilungen $\mathcal{N}_p(\boldsymbol{\mu}, \Sigma)$ und stehen im Zentrum der Hauptkomponentenanalyse (PCA).

2. **Gram-Matrizen** $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$, etwa für eine Designmatrix $\mathbf{X}$ in der Regression: Sie bilden die linke Seite der Normalgleichungen $\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$ für *Kleinste-Quadrate*-Probleme (Abschnitt 7.3). SPD ist $\mathbf{K}$ genau dann, wenn $\mathbf{X}$ vollen Spaltenrang hat; sonst bleibt nur positive Semidefinitheit. Auch Kernel-Matrizen in Support Vector Machines, Gauß-Prozessen und der nichtparametrischen Glättung gehören in diese Familie.
3. **Hesse-Matrizen** $\mathbf{H} = \left[\frac{\partial^2}{\partial x_i \partial x_j} f(\mathbf{x}) \right]_{i,j}$: In der Optimierung charakterisieren sie Konvexität und bilden die Grundlage des Newton-Verfahrens und anderer Optimierer zweiter Ordnung. Ihr statistisches Gegenstück ist die Fisher-Information $\mathbb{E} \left[-\frac{\partial^2}{\partial \theta_i \partial \theta_j} \log L(\boldsymbol{\theta}) \right]_{i,j}$ der Log-Likelihood.

Warum lohnt sich diese Klasse für die Numerik? SPD-Matrizen garantieren:

- Existenz und, bei positiver Diagonale von $\mathbf{L}$, Eindeutigkeit der Cholesky-Zerlegung (Satz 5.4.2),
- ihre numerische Stabilität (im Sinne von Abschnitt 4.3) auch ohne Pivotierung,
- lauter positive Eigenwerte, also vollen Rang und Invertierbarkeit.

Der Zerlegungssatz

Bei einer symmetrischen Matrix steckt die gesamte Information schon in einer Dreieckshälfte. Für SPD-Matrizen können wir die Faktoren $\mathbf{L}$ und $\mathbf{U}$ der LU-Zerlegung so wählen, dass $\mathbf{U} = \mathbf{L}^\top$ gilt: Die Symmetrie von $\mathbf{A}$ vererbt sich an die Zerlegung.

Satz 5.4.2 (Cholesky-Zerlegung)

Jede SPD-Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ lässt sich zerlegen als

$$\mathbf{A} = \mathbf{L} \mathbf{L}^\top, \quad (5.4.1)$$

wobei $\mathbf{L}$ eine untere Dreiecksmatrix mit positiven Diagonaleinträgen $l_{ii} > 0$ ist. Diese Zerlegung ist eindeutig.

Statt zweier Faktoren speichern wir nur noch $\mathbf{L}$, und auch die Rechnung halbiert sich: Die Cholesky-Zerlegung kommt mit rund $n^3/6$ Multiplikationen aus, die LU-Zerlegung derselben Matrix braucht rund $n^3/3$ (Abschnitt 5.3). An der Größenordnung $O(n^3)$ ändert das nichts, an der Rechenzeit sehr wohl. Die Normierung $l_{ii} > 0$ braucht es für die Eindeutigkeit: Ohne sie dürften wir in einer beliebigen Spalte von $\mathbf{L}$ alle Vorzeichen umdrehen, ohne $\mathbf{L} \mathbf{L}^\top$ zu verändern.

Vertiefung (optional): Induktionsbeweis der Cholesky-Zerlegung

Der Beweis ist eine Induktion über die Dimension n und liefert nebenbei ein Rezept, wie sich $\mathbf{L}$ Spalte für Spalte berechnen lässt.

Beweis.

- (1) **Induktionsanfang** $n = 1$: Hier ist $\mathbf{A} = (a)$ mit $a \in \mathbb{R}$, und aus der Definitheit folgt $a > 0$. Also leistet $\mathbf{L} = (\sqrt{a})$ das Verlangte, denn $\mathbf{L} \mathbf{L}^\top = (\sqrt{a})^2 = a$.

mit dem Testvektor $x = 1 \neq 0$ liefert die Definitheit $x a x = a > 0$; die Wurzel existiert also

- (2) **Induktionsschritt** $n > 1$: Die Behauptung gelte für $(n-1) \times (n-1)$ -Matrizen. Wir zerlegen A in Blöcke,

$$A = \begin{pmatrix} a & \mathbf{c}^\top \\ \mathbf{c} & \mathbf{B} \end{pmatrix}, \quad a \in \mathbb{R}, \quad \mathbf{c} \in \mathbb{R}^{n-1}, \quad \mathbf{B} \in \mathbb{R}^{(n-1) \times (n-1)},$$

und halten fest, dass $a > 0$ gilt.

$a = \mathbf{e}_1^\top A \mathbf{e}_1 > 0$, weil A positiv definit und $\mathbf{e}_1 \neq \mathbf{0}$ ist

- (3) Wir setzen $\mathbf{l} = \mathbf{c}/\sqrt{a}$ und betrachten die $(n-1) \times (n-1)$ -Matrix $\mathbf{B} - \mathbf{l}\mathbf{l}^\top = \mathbf{B} - \mathbf{c}\mathbf{c}^\top/a$. Sie ist symmetrisch.

$\mathbf{B}$ ist als Diagonalblock der symmetrischen Matrix A selbst symmetrisch, und $(\mathbf{l}\mathbf{l}^\top)^\top = \mathbf{l}\mathbf{l}^\top$

- (4) $\mathbf{B} - \mathbf{l}\mathbf{l}^\top$ ist auch positiv definit. Zu beliebigem $\mathbf{x} \in \mathbb{R}^{n-1}$ mit $\mathbf{x} \neq \mathbf{0}$ wählen wir den Testvektor

$$\mathbf{y} = \begin{pmatrix} -\frac{\mathbf{c}^\top \mathbf{x}}{a} \\ \mathbf{x} \end{pmatrix} \in \mathbb{R}^n$$

und rechnen zuerst

$$A\mathbf{y} = \begin{pmatrix} a \cdot \left(-\frac{\mathbf{c}^\top \mathbf{x}}{a}\right) + \mathbf{c}^\top \mathbf{x} \\ \mathbf{c} \cdot \left(-\frac{\mathbf{c}^\top \mathbf{x}}{a}\right) + \mathbf{B}\mathbf{x} \end{pmatrix} = \begin{pmatrix} 0 \\ (\mathbf{B} - \frac{\mathbf{c}\mathbf{c}^\top}{a})\mathbf{x} \end{pmatrix}.$$

blockweises Ausmultiplizieren; in der ersten Komponente kürzt sich a heraus, es bleibt $-\mathbf{c}^\top \mathbf{x} + \mathbf{c}^\top \mathbf{x} = 0$

- (5) Damit folgt

$$\mathbf{x}^\top \left(\mathbf{B} - \frac{\mathbf{c}\mathbf{c}^\top}{a} \right) \mathbf{x} = \mathbf{y}^\top A \mathbf{y} > 0.$$

im Produkt $\mathbf{y}^\top (A\mathbf{y})$ trifft die erste Komponente von $\mathbf{y}$ auf die 0, übrig bleibt genau $\mathbf{x}^\top (\mathbf{B} - \mathbf{c}\mathbf{c}^\top/a) \mathbf{x}$; und $\mathbf{y}^\top A \mathbf{y} > 0$, weil A SPD ist und $\mathbf{y} \neq \mathbf{0}$ (schon der untere Block $\mathbf{x}$ ist es)

- (6) $\mathbf{B} - \mathbf{l}\mathbf{l}^\top$ ist also eine SPD-Matrix der Dimension $n-1$, und nach Induktionsvoraussetzung existiert eine untere Dreiecksmatrix $\tilde{\mathbf{L}}$ mit $\mathbf{B} - \mathbf{l}\mathbf{l}^\top = \tilde{\mathbf{L}}\tilde{\mathbf{L}}^\top$. Wir setzen

$$\mathbf{L} = \begin{pmatrix} \sqrt{a} & \mathbf{0}^\top \\ \mathbf{l} & \tilde{\mathbf{L}} \end{pmatrix}$$

und prüfen blockweise nach:

$$\mathbf{L}\mathbf{L}^\top = \begin{pmatrix} a & \sqrt{a}\mathbf{l}^\top \\ \sqrt{a}\mathbf{l} & \mathbf{l}\mathbf{l}^\top + \tilde{\mathbf{L}}\tilde{\mathbf{L}}^\top \end{pmatrix} = \begin{pmatrix} a & \mathbf{c}^\top \\ \mathbf{c} & \mathbf{B} \end{pmatrix} = A.$$

$\sqrt{a}\mathbf{l} = \mathbf{c}$ nach Definition von $\mathbf{l}$, und $\mathbf{l}\mathbf{l}^\top + \tilde{\mathbf{L}}\tilde{\mathbf{L}}^\top = \mathbf{l}\mathbf{l}^\top + (\mathbf{B} - \mathbf{l}\mathbf{l}^\top) = \mathbf{B}$

□

Auf der Diagonalen von $\mathbf{L}$ steht in jedem Schritt eine Wurzel, also eine positive Zahl. Eindeutig ist die Zerlegung ebenfalls: Der Vergleich der ersten Spalte von $\mathbf{L}\mathbf{L}^\top = A$ erzwingt $l_{11} = \sqrt{a}$ (wegen $l_{11} > 0$) und $\mathbf{l} = \mathbf{c}/\sqrt{a}$, und $\tilde{\mathbf{L}}$ ist nach Induktionsvoraussetzung eindeutig.

Cholesky von Hand: Koeffizientenvergleich

Wie kommen wir konkret an $\mathbf{L}$? Für kleine Matrizen genügt ein Koeffizientenvergleich.

Beispiel 5.4.3 (Cholesky-Zerlegung einer 2×2-Matrix)

Wir berechnen die Cholesky-Zerlegung von $A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$.

Ansatz: $A = LL^T$ mit $L = \begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix}$.

Ausmultiplizieren:

$$LL^T = \begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix} \begin{pmatrix} l_{11} & l_{21} \\ 0 & l_{22} \end{pmatrix} = \begin{pmatrix} l_{11}^2 & l_{11}l_{21} \\ l_{11}l_{21} & l_{21}^2 + l_{22}^2 \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}.$$

Koeffizientenvergleich, von links oben nach rechts unten (der jeweils verglichene Eintrag von A rot, fertig berechnete Einträge von L grün):

$$\begin{aligned} l_{11}^2 &= 4 &\implies l_{11} &= 2, \\ l_{11}l_{21} &= 2 &\implies l_{21} &= 2/2 = 1, \\ l_{21}^2 + l_{22}^2 &= 3 &\implies l_{22} &= \sqrt{3-1} = \sqrt{2}. \end{aligned}$$

Ergebnis: $L = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix}$, und die Probe bestätigt $LL^T = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix} = A$.

Jede Gleichung enthielt genau eine neue Unbekannte; in dieser Reihenfolge löst sich das System Schritt für Schritt auf. Dass unter der Wurzel mit $3 - 1 = 2 > 0$ etwas Positives stand, garantiert Satz 5.4.2 für jede SPD-Matrix: Die Radikanden sind die Quadrate der positiven Diagonaleinträge von L .

Für allgemeines n funktioniert derselbe Vergleich. Der Eintrag (i, j) von LL^T ist $\sum_{k=1}^n l_{ik}l_{jk}$, und weil L untere Dreiecksmatrix ist, brechen die Summen früh ab. Wir lösen Spalte für Spalte auf, jeweils nach dem einzigen noch unbekannten Eintrag:

$$l_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2}, \quad l_{ij} = \frac{1}{l_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik}l_{jk} \right) \quad (i > j). \quad (5.4.2)$$

Interaktiv: Cholesky-Zerlegung Schritt für Schritt

Ab 3×3 entsteht pro Eintrag ein Rechenschritt. In welcher Reihenfolge füllt sich L ?

Interaktives Element – nur in der Web-Fassung

Auf jeden Diagonaleintrag (Wurzel) folgen die Einträge darunter (Division durch ihn), Spalte für Spalte. Bei einer nicht positiv definiten Matrix steht irgendwann eine Zahl ≤ 0 unter der Wurzel, und die Rechnung bricht ab.

Anwendung: korrelierte Zufallsvektoren simulieren

Zufallszahlengeneratoren liefern unabhängige Standardnormalvariablen, also Vektoren $\mathbf{x}$ mit $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\text{Var}(\mathbf{x}) = \mathbf{I}_d$. Gebraucht werden in der Statistik aber meist *korrelierte* Ziehungen mit

vorgegebener Kovarianzmatrix Σ . Der Cholesky-Faktor liefert sie: Als lineare Abbildung verformt er unkorreliertes Rauschen in die gewünschte Abhängigkeitsstruktur.

Satz 5.4.4 (Kovarianz unter dem Cholesky-Faktor)

Sei $\mathbf{x} \in \mathbb{R}^d$ ein Zufallsvektor mit $\mathbb{E}[\mathbf{x}] = \mathbf{0}$ und $\text{Var}(\mathbf{x}) = \mathbf{I}_d$, und sei $\Sigma \in \mathbb{R}^{d \times d}$ SPD mit Cholesky-Zerlegung $\Sigma = \mathbf{L}\mathbf{L}^\top$. Dann hat $\mathbf{y} = \mathbf{L}\mathbf{x}$ den Erwartungswert $\mathbf{0}$ und die Kovarianzmatrix

$$\text{Var}(\mathbf{y}) = \Sigma.$$

Beweis.

(1) Wegen $\mathbb{E}[\mathbf{y}] = \mathbf{L} \mathbb{E}[\mathbf{x}] = \mathbf{0}$ ist $\text{Var}(\mathbf{y}) = \mathbb{E}[\mathbf{y}\mathbf{y}^\top]$, und damit

$$\text{Var}(\mathbf{y}) = \mathbb{E}[\mathbf{L}\mathbf{x}\mathbf{x}^\top\mathbf{L}^\top] = \mathbf{L} \mathbb{E}[\mathbf{x}\mathbf{x}^\top] \mathbf{L}^\top = \mathbf{L} \mathbf{I}_d \mathbf{L}^\top = \Sigma.$$

der Erwartungswert ist linear und $\mathbf{L}$ eine feste, nicht zufällige Matrix, darf also aus ihm herausgezogen werden; für zentrierte Vektoren ist $\text{Var}(\mathbf{y}) = \mathbb{E}[\mathbf{y}\mathbf{y}^\top]$, insbesondere $\mathbb{E}[\mathbf{x}\mathbf{x}^\top] = \text{Var}(\mathbf{x}) = \mathbf{I}_d$; zuletzt die Zerlegung (5.4.1)

□

Bemerkung 5.4.5 (Ziehen aus der multivariaten Normalverteilung)

So simulieren wir aus $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$: Wir erzeugen $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ aus d unabhängigen Standardnormalvariablen, berechnen den Cholesky-Faktor $\mathbf{L}$ von Σ und geben $\boldsymbol{\mu} + \mathbf{L}\mathbf{z}$ zurück. Als lineare Transformation eines normalverteilten Vektors ist $\boldsymbol{\mu} + \mathbf{L}\mathbf{z}$ wieder normalverteilt, nach Satz 5.4.4 mit Erwartungswert $\boldsymbol{\mu}$ und Kovarianz Σ . Die Zerlegung rechnen wir nur einmal; jede weitere Ziehung kostet ein Matrix-Vektor-Produkt.

In R liefert `chol()` den oberen Faktor $\mathbf{R} = \mathbf{L}^\top$ mit $\Sigma = \mathbf{R}^\top \mathbf{R}$; den unteren erhalten wir mit `t(chol(Sigma))`:

```
set.seed(7)
Sigma <- matrix(c(1, 0.9,
                  0.9, 1), 2, 2)
L <- t(chol(Sigma)) # chol() liefert die obere Dreiecksmatrix
x <- matrix(rnorm(2 * 1000), nrow = 2)
y <- L %*% x
round(cov(t(y)), 2) # empirische Kovarianz, nahe bei Sigma
```

Interaktiv: Wie $\mathbf{L}$ eine runde Punktwolke verformt

Welche Veränderung der Wolke erwarten wir, wenn $|\rho|$ fast eins wird?

Im zweidimensionalen Fall lässt sich Satz 5.4.4 direkt ansehen. Aus σ_1, σ_2 und der Korrelation ρ bauen wir

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{pmatrix},$$

und (5.4.2) liefert den Cholesky-Faktor in geschlossener Form:

$$\mathbf{L} = \begin{pmatrix} \sigma_1 & 0 \\ \rho \sigma_2 & \sigma_2 \sqrt{1 - \rho^2} \end{pmatrix}.$$

Interaktives Element — nur in der Web-Fassung

$\mathbf{L}$ streckt die erste Koordinate mit σ_1 und mischt der zweiten über $\rho \sigma_2$ einen Anteil davon bei: Aus der runden Wolke wird eine gestreckte, für $\rho \neq 0$ geneigte Ellipse. Läuft $|\rho|$ gegen eins, geht der Eintrag $\sigma_2 \sqrt{1 - \rho^2}$ gegen null, die Wolke fällt auf eine Gerade zusammen und Σ wird singulär.

Vertiefung (optional): Cholesky mit Pivotierung: semidefinite und rangdefiziente Matrizen

Was passiert, wenn $\mathbf{A}$ nur positiv *semidefinit* ist (also $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$ statt > 0), etwa weil $\mathbf{A}$ singulär ist? Oder wenn $\mathbf{A}$ zwar SPD, aber so schlecht konditioniert (Abschnitt 4.2) ist, dass Rundungsfehler den Unterschied verwischen? Dann läuft der Koeffizientenvergleich irgendwann auf eine Wurzel aus null oder sogar aus einer negativen Zahl, und die gewohnte Rechnung bricht ab. Abhilfe schafft wie bei der LU-Zerlegung die Pivotierung. Diesmal vertauschen wir Zeilen *und* Spalten symmetrisch (*complete pivoting*), damit die Symmetrie erhalten bleibt:

$$\mathbf{P}^\top \mathbf{A} \mathbf{P} = \mathbf{L} \mathbf{L}^\top$$

mit einer Permutationsmatrix $\mathbf{P}$. Diese Variante hat drei nützliche Eigenschaften:

- **Rang-aufdeckend:** Nullspalten in $\mathbf{L}$ zeigen direkt den Rangabfall von $\mathbf{A}$ an; die Zerlegung bestimmt nebenbei den Rang der Matrix.
- **Stabil:** Auch für semidefinite Matrizen bleibt die pivotierte Cholesky-Zerlegung numerisch stabil (Higham, 1990).
- **Praktisch relevant** in Statistik und ML: für Kernel-Matrizen (Gauß-Prozesse, SVMs), für niedrig-rangige approximative Zerlegungen mit Aufwand $O(k^2 n)$ statt $O(n^3)$ bei Abbruch nach k Spalten, und für Gram-Matrizen $\mathbf{X}^\top \mathbf{X}$ im Fall $p > n$ (mehr Merkmale als Beobachtungen), die zwangsläufig singulär sind.

Selbsttest

1. Welchen Wert zeigt der Sampler für L_{22} , wenn wir $\sigma_1 = \sigma_2 = 1$ und $\rho = 0,9$ einstellen?

Lösung: 0.436

$$L_{22} = \sigma_2 \sqrt{1 - \rho^2} = \sqrt{0,19} \approx 0,436.$$

2. Bricht der Cholesky-Stepper mit einer exakten Null unter der Wurzel ab, kann $\mathbf{A}$ trotzdem positiv semidefinit sein.

Antwort: Wahr

Semidefinit verlangt nur $\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0$; dieser Randfall liefert $l_{jj} = 0$, und erst die nächste Spalte scheitert an der Division.

3. Eine symmetrische Matrix ist positiv definit, sobald alle ihre Einträge positiv sind oder ihre Determinante positiv ist.

Antwort: Falsch

Beides reicht nicht. $\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$ hat nur positive Einträge, aber $\mathbf{x} = (1, -1)^\top$ liefert $\mathbf{x}^\top \mathbf{A} \mathbf{x} = -2$; $-\mathbf{I}_2$ hat Determinante 1 und $\mathbf{x}^\top (-\mathbf{I}_2) \mathbf{x} < 0$ für jedes $\mathbf{x} \neq \mathbf{0}$. Für symmetrisches $\mathbf{A}$ ist positive Defi-

nitheit gleichwertig dazu, dass alle Eigenwerte positiv sind; $\det A > 0$ ist dafür nur notwendig.

Vertiefung: Heath §2.5 (spezielle lineare Systeme, insbesondere symmetrische und positiv definite Matrizen).

5.5 Zusammenfassung

Beide Zerlegungen dieses Kapitels lösen $Ax = b$ nach demselben Plan: einmal zerlegen, dann pro rechter Seite zwei Dreieckssysteme substituieren. Sie unterscheiden sich in Voraussetzungen, Aufwand und Stabilität (Abschnitt 4.3).

LU und Cholesky im Vergleich

	LU-Zerlegung	Cholesky-Zerlegung
Zerlegung	$PA = LU$	$A = LL^T$
geeignet für	jede invertierbare Matrix	SPD-Matrizen
Pivotierung	für die Stabilität nötig	nicht nötig
Aufwand	rund $n^3/3$ Multiplikationen	rund $n^3/6$, also halb so viel
scheitert	ohne Pivotierung an Nullpivots; kleine Pivots machen sie instabil	in exakter Arithmetik bei nicht-SPD-Matrizen; numerisch eventuell nahe der Semidefinitheitsgrenze

Die Stabilität der LU-Zerlegung entscheidet sich am Pivot (Abschnitt 5.3). Partielle Pivotierung hält alle Multiplikatoren im Betrag bei höchstens 1; ein Stabilitätsbeweis ist das nicht, aber in der Praxis gilt die pivotierte LU-Zerlegung als stabil (Higham, 2020). Auch ein stabiler Algorithmus liefert nur eine Näherung, deren relativer Fehler in der Größenordnung $\kappa(A) \cdot \varepsilon$ liegen kann, mit der Konditionszahl $\kappa(A)$ (Abschnitt 3.5, Abschnitt 4.2) und der Maschinengenauigkeit ε . Ist A schlecht konditioniert, liegt das am Problem, nicht am Algorithmus.

Die Cholesky-Zerlegung braucht für eine SPD-Matrix keine Pivotierung und ist rückwärtsstabil. In exakter Arithmetik läuft sie für jede SPD-Matrix durch und bricht für jede symmetrische, nicht positiv definite Matrix ab. In Gleitkommaarithmetik kann eine Matrix nahe der Grenze zur Semidefinitheit wegen Daten- oder Rundungsfehlern als nicht positiv definit erscheinen. Ein Abbruch ist deshalb ein nützlicher Diagnosehinweis: Entweder ist A nicht SPD, oder A liegt numerisch an dieser Grenze. Für nur *semidefinite* Matrizen gibt es die pivotierte Variante $P^T A P = LL^T$ (Abschnitt 5.4).

Was wir mitnehmen

- Für ein LGS keine explizite Inverse bilden. Wo in einer Formel $A^{-1}b$ steht, lösen wir in der Implementierung direkt das LGS $Ax = b$ (Bemerkung 5.2.1).
- Die LU-Zerlegung $PA = LU$ ist die Gauß-Elimination in Matrixform: einmal zerlegen für $O(n^3)$, danach kostet jede weitere rechte Seite nur noch $O(n^2)$.
- Die Cholesky-Zerlegung $A = LL^T$ nutzt Symmetrie und Definitheit aus, halbiert den Aufwand und dient auch zum Simulieren korrelierter Zufallsvektoren (Abschnitt 5.4). Kovarianz- und Gram-Matrizen sind stets positiv semidefinit und bei vollem Rang SPD, Hesse-Matrizen nur unter Krümmungsannahmen.

In Kapitel 6 folgt die Singulärwertzerlegung (SVD), die für beliebige, auch nicht quadratische Matrizen funktioniert.

Selbsttest

1. Um $\mathbf{Ax} = \mathbf{b}$ numerisch zu lösen, berechnen wir am besten zuerst $\mathbf{A}^{-1}$ und bilden dann das Produkt $\mathbf{A}^{-1}\mathbf{b}$.

Antwort: Falsch

Das explizite Invertieren löst versteckt n Gleichungssysteme statt einem. Die Größenordnung $O(n^3)$ bleibt, weil eine Zerlegung für alle n rechten Seiten reicht, aber der Umweg kostet ein Mehrfaches an Rechenzeit und bringt zusätzliche Rundungsfehler (Bemerkung 5.2.1).

2. Liegt $\mathbf{PA} = \mathbf{LU}$ einmal vor, kostet jede weitere rechte Seite $\mathbf{b}$ nur noch $O(n^2)$ Operationen.

Antwort: Wahr

Pro rechter Seite fallen eine Vorwärts- und eine Rückwärtssubstitution an, zusammen rund n^2 Multiplikationen (Satz 5.3.8); die teure Zerlegung hängt nicht von $\mathbf{b}$ ab.

3. Jede invertierbare Matrix $\mathbf{A}$ besitzt eine Zerlegung $\mathbf{A} = \mathbf{LU}$.

Antwort: Falsch

Schon die Vertauschungsmatrix $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ startet mit dem Pivot 0 und hat keine LU-Zerlegung (Beispiel 5.3.5). Mit Zeilenvertauschungen existiert aber immer $\mathbf{PA} = \mathbf{LU}$ (Satz 5.3.4). Pivotierung brauchen wir, sobald ein Pivot null oder nahe null ist, auch bei invertierbarem $\mathbf{A}$.

4. Eine einzige Richtung $\mathbf{x} \neq \mathbf{0}$ mit $\mathbf{x}^\top \mathbf{Ax} \leq 0$ widerlegt, dass $\mathbf{A}$ positiv definit ist.

Antwort: Wahr

Definition 5.4.1 verlangt strikte Positivität für *alle* von null verschiedenen Richtungen; ein Gegenbeispiel genügt daher zum Widerlegen. Umgekehrt beweist keine endliche Liste bestehender Richtungen die Definitheit.

5. Für eine SPD-Matrix ist die Cholesky-Zerlegung etwa doppelt so schnell wie die LU-Zerlegung und kommt ohne Pivotierung aus.

Antwort: Wahr

Wegen $\mathbf{U} = \mathbf{L}^\top$ muss nur ein Faktor berechnet und gespeichert werden, rund $n^3/6$ statt $n^3/3$ Multiplikationen; und die positive Definitheit garantiert positive Pivots, sodass kein Tauschen nötig ist (Abschnitt 5.4).

Vertiefung: Heath §2.4 (LU-Zerlegung, Pivotierung, Stabilität) und §2.5 (SPD-Systeme und Cholesky).

5.6 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den

Kurstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 2.17	LU-Zerlegung einer singulären Tridiagonalmatrix	leicht, ca. 15 Min.
Heath Exercise 2.13	Blockweise Vorwärtssubstitution	mittel, ca. 15 Min.
Schaback/Wendland Aufgabe 2.3	LU-Zerlegung einer um Zeile und Spalte erweiterten Matrix	mittel, ca. 30 Min.
Heath Exercise 2.38	Cholesky-Zerlegung einer wachsenden Matrix	mittel, ca. 30 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 2.5	Inverse einer unteren Dreiecksmatrix	leicht, ca. 15 Min.
Heath Exercise 2.10	Permutationsmatrizen – Transponierte statt Inverser, Zerlegung in Vertauschungen	mittel, ca. 30 Min.
Heath Exercise 2.34	Positiv definite Matrizen – Invertierbarkeit und Inverse	leicht, ca. 15 Min.
Schaback/Wendland Aufgabe 2.6	Cholesky ohne Wurzeln – die LDL^T -Zerlegung	mittel, ca. 30 Min.

Bücher: Heath: *Scientific Computing* (2. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.).

Die Singulärwertzerlegung

6.1 Motivation

In Kapitel 5 haben wir Matrizen zerlegt, um Gleichungssysteme zu lösen. Die LU-Zerlegung braucht dafür eine quadratische Matrix, die Cholesky-Zerlegung sogar eine symmetrische und positiv definite. Die Matrizen, mit denen wir in der Statistik rechnen, sehen selten so aus: Eine Designmatrix hat n Zeilen für die Beobachtungen und p Spalten für die Merkmale, und $n = p$ ist der Ausnahmefall. Dieses Kapitel baut eine Zerlegung, die für jede Matrix funktioniert.

Was wir brauchen

Das Kapitel setzt voraus:

- Die *Spektralnorm* $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$, also der größte Streckfaktor der Abbildung $x \mapsto Ax$ (Abschnitt 3.3).
- Orthogonalmatrizen Q mit $Q^T Q = I$. Sie erhalten Längen und Winkel, ihre Inverse ist die Transponierte (Abschnitt 3.3).
- Matrixzerlegungen als Werkzeug: eine Matrix in leicht handhabbare Faktoren aufspalten und die eigentliche Rechnung dann auf den Faktoren machen (Abschnitt 5.2).
- Aus der linearen Algebra:
 - Eigenwerte und Eigenvektoren, $Av = \lambda v$;
 - der Rang einer Matrix;
 - die fundamentalen Unterräume $\text{col}(A)$, $\text{Kern}(A)$ und $\text{col}(A^T)$ (Spaltenraum und Kern);
 - Projektionen auf Unterräume.

Diagonalisierung ist limitiert

Die Eigenwertzerlegung $A = PDP^{-1}$ ist das Standardwerkzeug, um eine Matrix in ihre Wirkungsrichtungen zu zerlegen. Sie ist aber in zwei Punkten eingeschränkt.

Zum einen verlangt schon die Gleichung $Av = \lambda v$, dass Av und v im selben Raum liegen. Die Matrix muss also quadratisch sein; für $A \in \mathbb{R}^{m \times n}$ mit $m \neq n$ stellt sich die Frage nach Eigenwerten gar nicht erst. Und selbst unter den quadratischen Matrizen hat nicht jede eine Eigenwertzerlegung: $\begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ besitzt nur den Eigenwert 0, dessen Eigenraum eindimensional ist. Eine Basis aus Eigenvektoren kommt so nicht zustande.

Zum anderen nützt uns die Zerlegung vor allem dann etwas, wenn P orthogonal gewählt werden kann, denn nur dann verzerrt der Basiswechsel nichts. Das gelingt genau für symmetrische Matrizen (Spektralsatz, Abschnitt 3.3). Mehr können es nicht sein, denn wegen $(PDP^T)^T = PD^T P^T =$

$\mathbf{PDP}^\top$ ist alles, was sich so zerlegen lässt, automatisch symmetrisch. Die meisten Matrizen, die uns begegnen, sind weder quadratisch noch symmetrisch.

Was wir wollen

Gesucht ist eine Zerlegung, die dieselbe Arbeit leistet, aber ohne diese Bedingungen:

$$\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{Q}^{-1}. \quad (6.1.1)$$

Drei Dinge wünschen wir uns dabei:

1. Sie existiert für *beliebige* Matrizen $\mathbf{A} \in \mathbb{R}^{m \times n}$.
2. $\mathbf{D}$ ist „diagonal“, trägt also außerhalb der Diagonalen nur Nullen. Was Diagonale bei einer rechteckigen Matrix heißt, klären wir in Abschnitt 6.2.
3. $\mathbf{P}$ und $\mathbf{Q}$ sind Orthogonalmatrizen.

Auf Punkt 3 kommt es an. Orthogonalmatrizen drehen und spiegeln, mehr nicht. Steckt die ganze Verzerrung in $\mathbf{D}$, dann lesen wir an den Diagonaleinträgen ab, was die Abbildung mit dem Raum anstellt. Außerdem entfällt die Inverse: Für orthogonales $\mathbf{Q}$ ist $\mathbf{Q}^{-1} = \mathbf{Q}^\top$, aus (6.1.1) wird also $\mathbf{A} = \mathbf{P} \mathbf{D} \mathbf{Q}^\top$.

Später heißen die Faktoren $\mathbf{U}$, $\mathbf{\Sigma}$ und $\mathbf{V}$, und die Zerlegung $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ trägt den Namen Singulärwertzerlegung. Die Farben gelten im ganzen Kapitel: orange die Streckfaktoren, blau die rechte Seite $\mathbf{V}$, grün die linke Seite $\mathbf{U}$.

Geometrische Intuition

Woher kommt so eine Zerlegung? Statt einen einzelnen Vektor durch die Abbildung zu schicken, schicken wir alle Einheitsvektoren auf einmal, also die Einheitssphäre aller $\mathbf{x}$ mit $\|\mathbf{x}\| = 1$. Ihre Bilder $\mathbf{A}\mathbf{x}$ haben verschiedene Längen: Manche Richtungen streckt $\mathbf{A}$, andere staucht sie. Die Leitfrage dieses Kapitels: Welche Richtung wird am stärksten gestreckt, welche am zweitstärksten, und so weiter?

Für eine 2×2 -Matrix wird aus dem Einheitskreis eine Ellipse; ist $\mathbf{A}$ singulär, so entartet sie zu einer Strecke. Der längste Bildvektor liegt auf ihrer Hauptachse, der kürzeste auf der Nebenachse, und diese Halbachsenlängen sind uns als Singulärwerte in Abschnitt 3.4 schon begegnet. Bildet $\mathbf{A}$ dagegen von $\mathbb{R}^3$ in die Ebene ab, so drückt sie die Richtungen in $\text{Kern}(\mathbf{A})$ auf $\mathbf{0}$, und aus der Einheitssphäre wird eine ausgefüllte Ellipse. Haupt- und Nebenachse zeigen weiterhin die stärkste und die zweitstärkste Streckung.

Nehmen wir die Matrix aus Beispiel 3.3.3,

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}.$$

Interaktiv: Welche Richtung streckt die Matrix am stärksten?

Welche Richtung streckt sie am stärksten, und um welchen Faktor? Das Widget schickt den ganzen Einheitskreis durch $\mathbf{A}$ und trägt rechts die Länge des Bildvektors über dem Winkel

auf.

Interaktives Element — nur in der Web-Fassung

Beispiel 6.1.1 (Der Einheitskreis wird zur Ellipse)

Die beiden Streckfaktoren von A kennen wir bereits aus Kapitel 3: $2,288 = \sqrt{3 + \sqrt{5}}$ ist die längste Halbachse der Bildellipse, $0,874$ die kürzeste. Am stärksten gestreckt wird die Richtung

$$\mathbf{x}^* \approx \begin{pmatrix} 0,851 \\ 0,526 \end{pmatrix}, \quad A\mathbf{x}^* \approx \begin{pmatrix} 2,227 \\ 0,526 \end{pmatrix}, \quad \|A\mathbf{x}^*\| \approx 2,288,$$

ein Einheitsvektor, der rund $31,7^\circ$ über der x_1 -Achse liegt. Die dazu senkrechte Richtung $\mathbf{x}^\perp \approx (-0,526, 0,851)^\top$ hat das Bild $A\mathbf{x}^\perp \approx (-0,201, 0,851)^\top$ der Länge $0,874$, wird also am schwächsten gestreckt.

Die beiden Bilder stehen wieder senkrecht aufeinander,

$$A\mathbf{x}^{*\top} A\mathbf{x}^\perp \approx 2,227 \cdot (-0,201) + 0,526 \cdot 0,851 = -0,4476 + 0,4476 = 0$$

(bis auf Rundung). Zwei senkrechte Richtungen im Urbild, zwei senkrechte Richtungen im Bild, dazwischen zwei Streckfaktoren: Dieses Muster schreiben wir in Abschnitt 6.2 als Zerlegung auf. Dort klärt sich auch, woher $\mathbf{x}^*$ kommt und warum die Bilder senkrecht bleiben.

Die Grundidee

Wie finden wir die Richtung der stärksten Streckung? Wir schreiben die Frage als Optimierungsproblem:

$$\max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|. \quad (6.1.2)$$

Ein Maximum existiert, denn die Einheitssphäre ist abgeschlossen und beschränkt und $\mathbf{x} \mapsto \|A\mathbf{x}\|$ ist stetig. Der Maximalwert ist die Spektralnorm $\|A\|_2$ aus der Vorwissensliste. Neu ist die Frage nach der Maximalstelle und danach, was in den übrigen Richtungen passiert.

Unhandlich an (6.1.2) ist die Zielfunktion: In der Norm steckt eine Wurzel über einer Quadratsumme. Wir maximieren deshalb stattdessen das Quadrat.

Satz 6.1.2 (Streckung als quadratische Form)

Für $A \in \mathbb{R}^{m \times n}$ und alle $\mathbf{x} \in \mathbb{R}^n$ gilt

$$\|A\mathbf{x}\|^2 = (A\mathbf{x})^\top (A\mathbf{x}) = \mathbf{x}^\top (A^\top A) \mathbf{x}. \quad (6.1.3)$$

Auf der Einheitssphäre haben $\|A\mathbf{x}\|$ und $\|A\mathbf{x}\|^2$ dieselben Maximalstellen.

Vertiefung (optional): Die Identität im Detail

Beweis.

- (1) Für jeden Vektor $\mathbf{y} \in \mathbb{R}^m$ ist $\|\mathbf{y}\|^2 = \mathbf{y}^\top \mathbf{y}$. Mit $\mathbf{y} = \mathbf{A}\mathbf{x}$ folgt die erste Gleichheit in (6.1.3).

Definition der euklidischen Norm: $\|\mathbf{y}\| = \sqrt{\sum_i y_i^2}$, und das Skalarprodukt $\mathbf{y}^\top \mathbf{y}$ ist genau $\sum_i y_i^2$

- (2) Ausmultiplizieren liefert die zweite Gleichheit:

$$(\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{x}) = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{x}.$$

$(\mathbf{A}\mathbf{x})^\top = \mathbf{x}^\top \mathbf{A}^\top$, die Transposition dreht die Reihenfolge des Produkts um; danach klammern wir nur um

- (3) Die Abbildung $t \mapsto t^2$ wächst auf $[0, \infty)$ streng monoton, und Normen sind nie negativ. Ein $\mathbf{x}$ maximiert daher $\|\mathbf{A}\mathbf{x}\|$ genau dann, wenn es $\|\mathbf{A}\mathbf{x}\|^2$ maximiert.

strenge Monotonie erhält die Ordnung: $\|\mathbf{A}\mathbf{x}_1\| \leq \|\mathbf{A}\mathbf{x}_2\|$ gilt genau dann, wenn $\|\mathbf{A}\mathbf{x}_1\|^2 \leq \|\mathbf{A}\mathbf{x}_2\|^2$ gilt

□

Die rechte Seite von (6.1.3) ist eine quadratische Form, und zwar die zur Matrix $\mathbf{A}^\top \mathbf{A}$. Ist $\mathbf{A}$ vom Format $m \times n$, so ist $\mathbf{A}^\top \mathbf{A}$ quadratisch vom Format $n \times n$, ganz gleich, ob $\mathbf{A}$ mehr Zeilen oder mehr Spalten hat. Symmetrisch ist $\mathbf{A}^\top \mathbf{A}$ außerdem (Abschnitt 6.2). Der Umweg über $\mathbf{A}^\top \mathbf{A}$ führt uns also zu einer Matrix zurück, die sich orthogonal diagonalisieren lässt. Aus ihren Eigenwerten und Eigenvektoren werden in Abschnitt 6.2 die Singulärwerte und die Singulärvektoren.

Bemerkung 6.1.3 (Notation)

Ab hier ist $\|\cdot\|$ ohne Index immer die euklidische Norm $\|\cdot\|_2$, bei Matrizen entsprechend die davon induzierte Operatornorm, also die Spektralnorm (Abschnitt 3.3). Ist eine andere Norm gemeint, schreiben wir den Index dazu.

Selbsttest

1. Stellen wir im Widget oben das Preset „Strecken und Stauchen“ ein, also $\mathbf{A} = \begin{pmatrix} 2 & 0 \\ 0 & 0,5 \end{pmatrix}$, und schieben wir θ auf 45° . Wie lang ist dann der Bildvektor $\|\mathbf{A}\mathbf{x}\|$?

Lösung: 1.458

Rund 1,458. Der Einheitsvektor ist $\mathbf{x} = (0,7071, 0,7071)^\top$, sein Bild $(1,4142, 0,3536)^\top$, und dessen Länge ist $\sqrt{2 + 0,125} = \sqrt{2,125} \approx 1,458$. Der Wert liegt zwischen den beiden Streckfaktoren 0,5 und 2; auf dem Einheitskreis liegt $\|\mathbf{A}\mathbf{x}\|$ immer zwischen kleinstem und größtem Singulärwert.

2. Für $\mathbf{A} \in \mathbb{R}^{3 \times 2}$ ist die Frage nach Eigenwerten sinnlos, die Matrix $\mathbf{A}^\top \mathbf{A}$ dagegen ist ein 2×2 -Objekt.

Antwort: Wahr

$\mathbf{A}$ bildet von $\mathbb{R}^2$ nach $\mathbb{R}^3$ ab; in $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ stünde links ein Vektor aus $\mathbb{R}^3$ und rechts einer aus $\mathbb{R}^2$. Das Produkt $\mathbf{A}^\top \mathbf{A}$ ist dagegen $(2 \times 3) \cdot (3 \times 2)$, also eine quadratische 2×2 -Matrix. Deshalb machen wir den Umweg aus Satz 6.1.2.

3. Jede symmetrische Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ lässt sich als $\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$ mit orthogonalem $\mathbf{Q}$ und reeller Diagonalmatrix $\mathbf{D}$ schreiben.

Antwort: Wahr

Das ist der Spektralsatz. Mehr sichert die Symmetrie nicht: Die Eigenwerte dürfen negativ oder null sein, und verschieden müssen sie auch nicht sein, wie $\mathbf{I}$ mit dem n -fachen Eigenwert 1 zeigt.

4. Jede quadratische Matrix lässt sich orthogonal diagonalisieren, also als $A = PDP^T$ mit orthogonalem P schreiben.

Antwort: Falsch

Aus $A = PDP^T$ folgt $A^T = PD^T P^T = PDP^T = A$. So zerlegbar sind also nur symmetrische Matrizen. Die quadratische Matrix $A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$ aus Beispiel 6.1.1 ist nicht symmetrisch und fällt damit heraus.

5. Wenn $\det A = 1$ gilt, wird jede Richtung des Einheitskreises gleich stark gestreckt.

Antwort: Falsch

Die Determinante misst nur die Flächenänderung insgesamt, nicht ihre Verteilung auf die Richtungen. Für $A = \begin{pmatrix} 2 & 0 \\ 0 & 0,5 \end{pmatrix}$ ist $\det A = 1$, trotzdem wird die x_1 -Richtung um den Faktor 2 gestreckt und die x_2 -Richtung auf die Hälfte gestaucht. Alle Richtungen gleich stark streckt nur ein Vielfaches $A = cQ$ einer Orthogonalmatrix Q ; dann ist $\|Ax\| = |c|$ für jeden Einheitsvektor x .

6. Der Übergang von $\|Ax\|$ zu $\|Ax\|^2$ ändert weder die Maximalstelle noch den Maximalwert.

Antwort: Falsch

Die Maximalstelle bleibt, der Wert nicht: Er wird quadriert. Für die Matrix aus Beispiel 6.1.1 ist $\max_{\|x\|=1} \|Ax\| \approx 2,288$, während $\max_{\|x\|=1} \|Ax\|^2 = 3 + \sqrt{5} \approx 5,236$ herauskommt. Für die Suche nach der Richtung spielt das keine Rolle, deshalb dürfen wir quadrieren.

Vertiefung: vgl. Heath §3.6 (Singulärwertzerlegung) sowie MML §4.5 und §4.6.

6.2 Singulärwerte und Singulärvektoren

In Abschnitt 6.1 haben wir die Richtung stärkster Streckung als Maximalstelle über der Einheits-sphäre gesucht und dabei statt $\|Ax\|$ das Quadrat maximiert:

$$\|Ax\|^2 = (Ax)^T(Ax) = x^T(A^T A)x. \quad (6.2.1)$$

Rechts steht eine quadratische Form in $A^T A$. Diese eine Matrix bestimmt also, wie stark A in welche Richtung streckt.

Die Matrix $A^T A$

Satz 6.2.1 (Eigenschaften von $A^T A$)

Für $A \in \mathbb{R}^{m \times n}$ gilt:

1. $A^T A \in \mathbb{R}^{n \times n}$ ist symmetrisch, das heißt $(A^T A)^T = A^T A$.
2. $A^T A$ ist *positiv semidefinit*, das heißt $x^T(A^T A)x \geq 0$ für alle $x \in \mathbb{R}^n$. Insbesondere sind alle Eigenwerte λ_i von $A^T A$ nichtnegativ.

Beweis.

(1) Zu (1):

$$(A^T A)^T = A^T (A^T)^T = A^T A.$$

$$(XY)^T = Y^T X^T \text{ und } (X^T)^T = X$$

- (2) Zu (2): Die quadratische Form ist ein Längenquadrat:

$$\mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x} = \|\mathbf{A}\mathbf{x}\|^2 \geq 0 \quad \text{für alle } \mathbf{x} \in \mathbb{R}^n.$$

(6.2.1), von rechts nach links gelesen

- (3) Für die Eigenwerte setzen wir einen normierten Eigenvektor $\mathbf{v}_i$ von $\mathbf{A}^T \mathbf{A}$ zum Eigenwert λ_i ein:

$$0 \leq \|\mathbf{A}\mathbf{v}_i\|^2 = \mathbf{v}_i^T (\mathbf{A}^T \mathbf{A}) \mathbf{v}_i = \mathbf{v}_i^T (\lambda_i \mathbf{v}_i) = \lambda_i \|\mathbf{v}_i\|^2 = \lambda_i.$$

Eigenwertgleichung $\mathbf{A}^T \mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$, dann $\|\mathbf{v}_i\| = 1$; reelle Eigenwerte mit reellen Eigenvektoren gibt es dank des Spektralsatzes, siehe direkt im Anschluss

□

Dass die Eigenwerte überhaupt reell sind und dass es eine Orthonormalbasis aus Eigenvektoren gibt, garantiert der Spektralsatz für symmetrische Matrizen. Zusammen mit Satz 6.2.1 ergibt das:

Korollar 6.2.2 ($\mathbf{A}^T \mathbf{A}$ ist orthogonal diagonalisierbar)

Zu $\mathbf{A} \in \mathbb{R}^{m \times n}$ gibt es eine Orthogonalmatrix $\mathbf{V} \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_n)$ mit $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$, sodass

$$\mathbf{A}^T \mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T.$$

Die Spalten von $\mathbf{V}$ sind Eigenvektoren von $\mathbf{A}^T \mathbf{A}$ und bilden eine Orthonormalbasis des $\mathbb{R}^n$.

In der Basis aus den Spalten von $\mathbf{V}$ skaliert $\mathbf{A}^T \mathbf{A}$ also nur entlang der Achsen. Durch den ganzen Abschnitt begleitet uns eine kleine Beispielmatrix.

Beispiel 6.2.3 (Die Matrix $\mathbf{A}^T \mathbf{A}$ einer 3×2 -Matrix)

Sei

$$\mathbf{A} = (\mathbf{a}_1 \quad \mathbf{a}_2) = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 2}.$$

Der Eintrag (i, j) von $\mathbf{A}^T \mathbf{A}$ ist das Skalarprodukt der i -ten mit der j -ten Spalte von $\mathbf{A}$:

$$\mathbf{A}^T \mathbf{A} = \begin{pmatrix} \mathbf{a}_1^T \mathbf{a}_1 & \mathbf{a}_1^T \mathbf{a}_2 \\ \mathbf{a}_2^T \mathbf{a}_1 & \mathbf{a}_2^T \mathbf{a}_2 \end{pmatrix} = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix}.$$

Die Symmetrie sieht man der Matrix an. Die Eigenwerte liefert das charakteristische Polynom:

$$\det(\mathbf{A}^T \mathbf{A} - \lambda \mathbf{I}) = (6 - \lambda)(5 - \lambda) - 16 = \lambda^2 - 11\lambda + 14 \stackrel{!}{=} 0,$$

also

$$\lambda_{1,2} = \frac{11 \pm \sqrt{11^2 - 4 \cdot 14}}{2} = \frac{11 \pm \sqrt{65}}{2}, \quad \lambda_1 \approx 9,531, \quad \lambda_2 \approx 1,469.$$

Satz 6.2.1 verspricht nur $\lambda_i \geq 0$. Hier sind beide Eigenwerte sogar echt positiv, $A^\top A$ ist also positiv definit. Der Grund: Die beiden Spalten von A sind linear unabhängig, $Ax = 0$ gilt somit nur für $x = 0$, und ein Eigenwert 0 hätte nach der Rechnung oben einen Eigenvektor mit $Av = 0$ verlangt. Zwei Proben: Die Summe der Eigenwerte ist 11, die Spur von $A^\top A$; ihr Produkt ist 14, die Determinante $6 \cdot 5 - 4^2$.

Singulärwerte

Die Eigenwerte von $A^\top A$ sind nach (6.2.1) quadrierte Längen. Wer an Streckungsfaktoren interessiert ist, zieht deshalb die Wurzel.

Definition 6.2.4 (Singulärwerte)

Für $A \in \mathbb{R}^{m \times n}$ heißen die $q = \min(m, n)$ Zahlen

$$\sigma_1 \geq \dots \geq \sigma_q \geq 0$$

die *Singulärwerte* (singular values) von A . Die positiven unter ihnen sind die Quadratwurzeln der positiven Eigenwerte von $A^\top A$; bis zur Länge q wird die Liste mit Nullen ergänzt.

Bemerkung 6.2.5 (Singulärwerte sind Streckungsfaktoren)

- $\sigma_1 = \max_{\|x\|=1} \|Ax\|$ ist die maximale Streckung. Das ist das Maximierungsproblem aus Abschnitt 6.1: Über (6.2.1) maximieren wir die quadratische Form von $A^\top A$, und deren größter Wert auf der Einheitssphäre ist λ_1 .
- Falls $m \geq n$, ist $\sigma_n = \min_{\|x\|=1} \|Ax\|$ die minimale Streckung. Für $m < n$ ist dieses Minimum null, weil A dann einen nichttrivialen Kern hat; in der erweiterten Liste (letzter Punkt) ist das $\sigma_n = 0$.
- $\sigma_i = 0$ gilt genau dann, wenn $\lambda_i = 0$ ist.
- *Konvention bei breiten Matrizen.* Für $m < n$ hat $A^\top A$ insgesamt n Eigenwerte, darunter mindestens $n - m$ strukturell erzwungene Nullen. Als Singulärwerte zählen nur die $q = \min(m, n)$ Diagonalplätze von Σ ; wer alle Eigenwerte indizieren will, ergänzt $\sigma_{q+1} = \dots = \sigma_n = 0$ zu dieser *erweiterten Liste*, ohne dass die Nullen weitere Diagonaleinträge wären.

Der größte Singulärwert ist damit die *Spektralnorm* $\|A\|_2$ aus Abschnitt 3.3 (Satz 6.4.1).

Beispiel 6.2.6 (Singulärwerte der Beispielmatrix)

Für A aus Beispiel 6.2.3 mit $\lambda_1 \approx 9,531$ und $\lambda_2 \approx 1,469$ ist

$$\sigma_1 = \sqrt{\lambda_1} \approx \sqrt{9,531} \approx 3,087, \quad \sigma_2 = \sqrt{\lambda_2} \approx \sqrt{1,469} \approx 1,212.$$

In der einen Richtung streckt A also um gut das Dreifache, in der anderen wächst die Länge nur um gut ein Fünftel. Ihr Verhältnis

$$\frac{\sigma_1}{\sigma_2} \approx \frac{3,087}{1,212} \approx 2,55$$

sagt, wie richtungsabhängig (*anisotrop*) diese Matrix wirkt. Für quadratische, invertierbare Matrizen ist σ_1/σ_n die Spektralkondition $\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2$ aus Abschnitt 3.5: $\|\mathbf{A}\|_2 = \sigma_1$ ist die stärkste Streckung durch $\mathbf{A}$, und $\|\mathbf{A}^{-1}\|_2 = 1/\sigma_n$, denn die schwächste Streckung durch $\mathbf{A}$ ist die stärkste durch $\mathbf{A}^{-1}$. Für rechteckige Matrizen mit vollem Spaltenrang wie diese ist σ_1/σ_n die übliche Verallgemeinerung.

Singulärvektoren

Streckungsfaktoren allein nützen wenig, solange wir nicht wissen, *welche* Richtung um σ_i gestreckt wird. Diese Richtungen stecken bereits in Korollar 6.2.2.

Definition 6.2.7 (Rechte und linke Singulärvektoren)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$. Für die rechten Singulärvektoren verwenden wir die in Bemerkung 6.2.5 erklärte erweiterte Liste $\sigma_1 \geq \dots \geq \sigma_n \geq 0$; bei $m < n$ enthält sie die zusätzlichen erzwungenen Nullen.

- Die *rechten Singulärvektoren* $\mathbf{v}_1, \dots, \mathbf{v}_n \in \mathbb{R}^n$ sind normierte, paarweise orthogonale Eigenvektoren von $\mathbf{A}^\top \mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i, \quad \|\mathbf{v}_i\| = 1.$$

- Die *linken Singulärvektoren* $\mathbf{u}_i \in \mathbb{R}^m$ sind für $\sigma_i > 0$ erklärt durch

$$\mathbf{u}_i = \frac{\mathbf{A} \mathbf{v}_i}{\sigma_i}, \quad \text{gleichwertig} \quad \mathbf{A} \mathbf{v}_i = \sigma_i \mathbf{u}_i. \quad (6.2.2)$$

Die zweite Schreibweise in (6.2.2) sagt mehr: $\mathbf{A}$ bildet die Richtung $\mathbf{v}_i$ auf die Richtung $\mathbf{u}_i$ ab und streckt dabei um σ_i . Dass diese Bildrichtungen aufeinander senkrecht stehen, zeigt der nächste Satz; auf ihm beruht die ganze Konstruktion.

Satz 6.2.8 (Orthogonalität der Singulärvektoren)

Seien $\mathbf{v}_1, \dots, \mathbf{v}_n$ orthonormale rechte Singulärvektoren von $\mathbf{A}$. Dann gilt

$$(\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j) = 0 \quad \text{für } i \neq j, \quad \|\mathbf{A} \mathbf{v}_i\| = \sigma_i.$$

Insbesondere sind die linken Singulärvektoren $\mathbf{u}_1, \dots, \mathbf{u}_r$ zu den r von null verschiedenen Singulärwerten orthonormal.

Vertiefung (optional): Beweis der Orthogonalität

Beweis.

- (1) Für $i \neq j$ rechnen wir

$$(\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j) = \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_j = \mathbf{v}_i^\top (\lambda_j \mathbf{v}_j) = \lambda_j (\mathbf{v}_i^\top \mathbf{v}_j) = \lambda_j \cdot 0 = 0.$$

$(\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j) = \mathbf{v}_i^\top \mathbf{A}^\top \mathbf{A} \mathbf{v}_j$; dann die Eigenwertgleichung für $\mathbf{v}_j$ und zuletzt die Orthogonalität $\mathbf{v}_i^\top \mathbf{v}_j = 0$

- (2) Für $i = j$ liefert dieselbe Rechnung die Länge:

$$\|\mathbf{A} \mathbf{v}_i\|^2 = \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_i = \lambda_i \|\mathbf{v}_i\|^2 = \lambda_i = \sigma_i^2.$$

(6.2.1) mit $\mathbf{x} = \mathbf{v}_i$, danach Eigenwertgleichung und $\|\mathbf{v}_i\| = 1$

- (3) Die $\mathbf{v}_i$ sind *orthonormal*, ihre Bilder $\mathbf{A}\mathbf{v}_i$ dagegen nur orthogonal, mit Längen σ_i . Erst die Normierung (6.2.2) macht daraus orthonormale Vektoren,

$$\mathbf{u}_i^\top \mathbf{u}_j = \frac{(\mathbf{A}\mathbf{v}_i)^\top (\mathbf{A}\mathbf{v}_j)}{\sigma_i \sigma_j} = 0 \quad (i \neq j), \quad \|\mathbf{u}_i\| = \frac{\|\mathbf{A}\mathbf{v}_i\|}{\sigma_i} = 1.$$

dividieren dürfen wir nur bei $\sigma_i, \sigma_j > 0$, also für Indizes $i, j \leq r$; die übrigen $\mathbf{u}_i$ liefert Definition 6.2.7 gar nicht erst

□

Beispiel 6.2.9 (Singulärvektoren der Beispielmatrix)

Wir bleiben bei $\mathbf{A}$ aus Beispiel 6.2.3 mit $\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix}$.

Rechte Singulärvektoren. Für $\lambda_1 \approx 9,531$ suchen wir $\mathbf{v}_1$ mit

$$\begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \begin{pmatrix} v_{11} \\ v_{21} \end{pmatrix} = 9,531 \begin{pmatrix} v_{11} \\ v_{21} \end{pmatrix}.$$

Die erste Zeile heißt $(6 - 9,531)v_{11} + 4v_{21} = 0$, also $v_{21} \approx 0,883v_{11}$. Normieren wir (das Vorzeichen dürfen wir dabei frei wählen, siehe Bemerkung 6.2.10), so ergibt sich zusammen mit dem dazu orthogonalen zweiten Eigenvektor

$$\mathbf{v}_1 \approx \begin{pmatrix} -0,750 \\ -0,662 \end{pmatrix}, \quad \mathbf{v}_2 \approx \begin{pmatrix} 0,662 \\ -0,750 \end{pmatrix}.$$

Linke Singulärvektoren. Jetzt liefert (6.2.2) die Bildrichtungen:

$$\mathbf{u}_1 = \frac{\mathbf{A}\mathbf{v}_1}{\sigma_1} \approx \frac{1}{3,087} \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -0,750 \\ -0,662 \end{pmatrix} = \frac{1}{3,087} \begin{pmatrix} -2,074 \\ -2,162 \\ -0,750 \end{pmatrix} \approx \begin{pmatrix} -0,672 \\ -0,700 \\ -0,243 \end{pmatrix},$$

$$\mathbf{u}_2 = \frac{\mathbf{A}\mathbf{v}_2}{\sigma_2} \approx \frac{1}{1,212} \begin{pmatrix} -0,838 \\ 0,574 \\ 0,662 \end{pmatrix} \approx \begin{pmatrix} -0,691 \\ 0,474 \\ 0,546 \end{pmatrix}.$$

Probe auf Orthonormalität. Satz 6.2.8 behauptet, dass diese beiden Vektoren orthonormal sind, und die Zahlen bestätigen es:

$$\begin{aligned} \mathbf{u}_1^\top \mathbf{u}_2 &\approx (-0,672)(-0,691) + (-0,700)(0,474) + (-0,243)(0,546) \\ &= 0,4644 - 0,3318 - 0,1327 \approx 0, \\ \|\mathbf{u}_1\| &\approx \sqrt{0,672^2 + 0,700^2 + 0,243^2} = \sqrt{0,4516 + 0,4900 + 0,0590} \approx 1. \end{aligned}$$

Bemerkung 6.2.10 (Singulärvektoren sind nicht eindeutig)

Mit $\mathbf{v}_i$ ist auch $-\mathbf{v}_i$ ein normierter Eigenvektor zum selben Eigenwert. Die Singulärwerte ändern sich dadurch nicht, die Vektoren schon, und zwar paarweise: Nach (6.2.2) dreht sich mit $\mathbf{v}_i$ zugleich $\mathbf{u}_i$ um, sonst passen die beiden Seiten von $\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i$ nicht mehr zusammen. Bei mehrfachen Singulärwerten ist die Freiheit noch größer: Im zugehörigen Eigenraum lässt sich die Orthonormalbasis beliebig drehen.

Stimmt die Handrechnung? Was liefert `svd(A)` in R?

```
A <- matrix(c(1, 2,
              2, 1,
              1, 0), nrow = 3, byrow = TRUE)
svd(A)
```

Die Komponente `d` enthält die Singulärwerte 3,087 und 1,212 wie von Hand berechnet, die Spalten von `u` und `v` die Singulärvektoren, womöglich mit anderen Vorzeichen als bei uns. Numerische Bibliotheken wählen das Vorzeichen nach eigenen Konventionen; falsch ist deshalb keine der beiden Rechnungen.

Interaktiv: Die Rechnung Schritt für Schritt

Wie läuft dieser Weg an einer anderen Matrix, und was geht schief, wenn die beiden Spalten linear abhängig sind? Das Widget rechnet die Schritte von Beispiel 6.2.3 bis 6.2.9 für jede eingetragene 3×2 -Matrix nach; die beiden Vorzeichen-Knöpfe in Schritt 5 führen Bemerkung 6.2.10 vor. Unter den Schritten steht dieselbe Abbildung geometrisch: links der Einheitskreis des $\mathbb{R}^2$, rechts sein Bild im $\mathbb{R}^3$.

Interaktives Element — nur in der Web-Fassung

Sind die beiden Spalten linear abhängig, so verschwindet σ_2 , und für $\mathbf{u}_2$ liefert (6.2.2) nichts mehr, weil sie durch σ_2 teilt.

Fundamentale Unterräume

Die Singulärvektoren liefern außerdem Basen der fundamentalen Unterräume.

Satz 6.2.11 (Charakterisierung der fundamentalen Unterräume)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit genau r von null verschiedenen Singulärwerten. In der erweiterten Liste aus Bemerkung 6.2.5 gilt also $\sigma_1 \geq \dots \geq \sigma_r > 0$ und $\sigma_{r+1} = \dots = \sigma_n = 0$. Dann gilt:

1. $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ ist eine Orthonormalbasis des Zeilenraums $\text{col}(\mathbf{A}^\top)$.
2. $\{\mathbf{A}\mathbf{v}_1, \dots, \mathbf{A}\mathbf{v}_r\}$ ist eine Orthogonalbasis des Spaltenraums $\text{col}(\mathbf{A})$, also des Bildes von $\mathbf{A}$; normiert man sie, erhält man die Orthonormalbasis $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$.
3. $\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}$ ist eine Orthonormalbasis des Kerns $\text{Kern}(\mathbf{A})$.
4. $\text{rang}(\mathbf{A}) = r$: Der Rang von $\mathbf{A}$ ist die Anzahl der von null verschiedenen Singulärwerte.

Vertiefung (optional): Beweis der Charakterisierung der Unterräume

Der Beweis geht in vier Etappen: Kern, Umkehrung, Spaltenraum, Zeilenraum.

Beweis.

- (1) Für $i > r$ ist $\sigma_i = 0$, nach Satz 6.2.8 also $\|A\mathbf{v}_i\| = 0$ und damit $A\mathbf{v}_i = \mathbf{0}$. Die letzten $n - r$ rechten Singulärvektoren liegen im Kern von A .

nur der Nullvektor hat die Länge null

- (2) Umgekehrt liegt jedes $\mathbf{x}$ mit $A\mathbf{x} = \mathbf{0}$ in deren linearer Hülle. Wir entwickeln $\mathbf{x} = \sum_{i=1}^n c_i \mathbf{v}_i$ und erhalten

$$\mathbf{0} = A\mathbf{x} = \sum_{i=1}^r c_i \sigma_i \mathbf{u}_i,$$

woraus $c_1 = \dots = c_r = 0$ folgt. Zusammen mit dem ersten Schritt ist $\text{Kern}(A) = \text{span}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}$, und diese Vektoren sind als Teil einer Orthonormalbasis orthonormal.

die Summanden mit $i > r$ fallen weg; die $\mathbf{u}_i$ sind orthonormal, also linear unabhängig, und wegen $\sigma_i > 0$ müssen alle Koeffizienten verschwinden

- (3) Die Spalten von A sind Linearkombinationen der $A\mathbf{v}_i$ mit $i \leq r$: Für jeden Einheitsvektor $\mathbf{e}_j$ ist $\mathbf{e}_j = \sum_{i=1}^n (\mathbf{v}_i^\top \mathbf{e}_j) \mathbf{v}_i$, und Anwenden von A liefert $A\mathbf{e}_j = \sum_{i \leq r} (\mathbf{v}_i^\top \mathbf{e}_j) A\mathbf{v}_i$. Die r Vektoren $A\mathbf{v}_i$ sind nach Satz 6.2.8 orthogonal und von null verschieden, also linear unabhängig. Sie bilden damit eine Orthogonalbasis von $\text{col}(A)$, und es folgt $\text{rang}(A) = \dim \text{col}(A) = r$.

$A\mathbf{e}_j$ ist die j -te Spalte von A ; die Summanden mit $i > r$ fallen nach Schritt 1 weg

- (4) Für den Zeilenraum multiplizieren wir (6.2.2) von links mit $A^\top$: Für $i \leq r$ ist

$$A^\top \mathbf{u}_i = \frac{A^\top A \mathbf{v}_i}{\sigma_i} = \frac{\sigma_i^2 \mathbf{v}_i}{\sigma_i} = \sigma_i \mathbf{v}_i.$$

Jedes $\mathbf{v}_i$ mit $i \leq r$ ist also eine Linearkombination von Spalten von $A^\top$, liegt somit in $\text{col}(A^\top)$. Da $\dim \text{col}(A^\top) = \text{rang}(A^\top) = \text{rang}(A) = r$ ist und die $\mathbf{v}_1, \dots, \mathbf{v}_r$ orthonormal sind, spannen sie $\text{col}(A^\top)$ vollständig auf.

r linear unabhängige Vektoren in einem r -dimensionalen Raum bilden bereits eine Basis, und orthonormale Vektoren sind linear unabhängig

□

Den vierten fundamentalen Unterraum, den linken Kern $\text{Kern}(A^\top)$, spannen orthonormale Vektoren $\mathbf{u}_{r+1}, \dots, \mathbf{u}_m$ auf, die $\mathbf{u}_1, \dots, \mathbf{u}_r$ zu einer Orthonormalbasis des $\mathbb{R}^m$ ergänzen; das nächste Beispiel führt das vor. Damit liefert die SVD Orthonormalbasen für alle vier fundamentalen Unterräume.

Beispiel 6.2.12 (Alle Unterräume einer Rang-1-Matrix)

Wir nehmen

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}, \quad A^\top A = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}.$$

Singulärwerte. Das charakteristische Polynom ist $(2 - \lambda)^2 - 4 = \lambda^2 - 4\lambda = \lambda(\lambda - 4)$, also $\lambda_1 = 4$ und $\lambda_2 = 0$ und damit

$$\sigma_1 = 2, \quad \sigma_2 = 0, \quad r = 1.$$

In Richtung $\mathbf{v}_1$ streckt A um den Faktor 2, in Richtung $\mathbf{v}_2$ um den Faktor 0.

Rechte Singulärvektoren und Zeilenraum. Die Eigenvektoren von $A^\top A$ sind

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix},$$

also $\text{col}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1\} = \text{span}\{(1, 1)^\top\}$. Das passt: Die beiden Zeilen von $\mathbf{A}$, die nicht null sind, lauten beide $(1, 1)$.

Linker Singulärvektor und Spaltenraum. Aus (6.2.2) folgt

$$\mathbf{u}_1 = \frac{\mathbf{A}\mathbf{v}_1}{\sigma_1} = \frac{1}{2} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 2 \\ 2 \\ 0 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix},$$

also $\text{col}(\mathbf{A}) = \text{span}\{\mathbf{u}_1\} = \text{span}\{(1, 1, 0)^\top\}$.

Kern. Nach Satz 6.2.11 ist $\text{Kern}(\mathbf{A}) = \text{span}\{\mathbf{v}_2\} = \text{span}\{(1, -1)^\top\}$, und die Probe bestätigt das: $\mathbf{A}(1, -1)^\top = (0, 0, 0)^\top$.

Linker Kern. Für $\mathbf{u}_2$ liefert (6.2.2) nichts, denn $\sigma_2 = 0$; ein $\mathbf{u}_3$ sieht die Formel nicht vor, weil $\mathbf{A}$ nur zwei Spalten und damit nur zwei rechte Singulärvektoren hat. Wir ergänzen $\mathbf{u}_1$ stattdessen zu einer Orthonormalbasis des $\mathbb{R}^3$, etwa durch

$$\mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{u}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}.$$

Diese beiden spannen den linken Kern auf, $\text{Kern}(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_2, \mathbf{u}_3\}$, denn

$$\mathbf{A}^\top \begin{pmatrix} -1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

Der SVD-Hauptsatz

Sammeln wir die rechten Singulärvektoren als Spalten in einer Matrix, ebenso die linken, und schreiben wir die Singulärwerte auf eine Diagonale, dann steht die Zerlegung da.

Satz 6.2.13 (Singulärwertzerlegung)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$. Dann existiert eine Zerlegung

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top \quad (6.2.3)$$

mit

- $\mathbf{V} \in \mathbb{R}^{n \times n}$ orthogonal, in den Spalten die rechten Singulärvektoren $\mathbf{v}_1, \dots, \mathbf{v}_n$;
- $\mathbf{U} \in \mathbb{R}^{m \times m}$ orthogonal, in den ersten r Spalten die linken Singulärvektoren $\mathbf{u}_1, \dots, \mathbf{u}_r$, ergänzt zu einer Orthonormalbasis des $\mathbb{R}^m$;
- $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ „diagonal“ mit den Singulärwerten auf der Hauptdiagonalen,

$$\mathbf{\Sigma} = \begin{pmatrix} \text{diag}(\sigma_1, \dots, \sigma_r) & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{pmatrix}. \quad (6.2.4)$$

Die Anführungszeichen um „diagonal“ sind nötig, weil Σ dasselbe Format wie A hat und für $m \neq n$ nicht quadratisch ist.

Vertiefung (optional): Beweisskizze des SVD-Hauptsatzes

Die Skizze sammelt die Konstruktion dieses Abschnitts und stützt sich auf den Spektralsatz, den wir nicht bewiesen haben.

Beweis.

- (1) **Rechte Singulärvektoren.** Nach Korollar 6.2.2 besitzt $A^T A$ eine Orthonormalbasis aus Eigenvektoren. Wir sortieren sie nach absteigenden Eigenwerten und stellen sie spaltenweise zusammen: $V = (v_1 \mid v_2 \mid \dots \mid v_n)$.

V ist orthogonal, weil seine Spalten orthonormal sind

- (2) **Linke Singulärvektoren.** Für $i \leq r$ setzen wir $u_i = Av_i / \sigma_i$ nach (6.2.2) und sammeln sie in $U_r = (u_1 \mid \dots \mid u_r)$.

nach Satz 6.2.8 sind diese r Vektoren orthonormal

- (3) **Vervollständigung.** Wir ergänzen U_r zu einer Orthonormalbasis des $\mathbb{R}^m$, etwa mit dem Gram-Schmidt-Verfahren. Das ergibt die Orthogonalmatrix $U \in \mathbb{R}^{m \times m}$.

die ergänzten Spalten spannen gerade $\text{Kern}(A^T)$ auf, wie in Beispiel 6.2.12

- (4) **Verifikation.** Für $i \leq r$ ist $U\Sigma V^T v_i = U\Sigma e_i = \sigma_i Ue_i = \sigma_i u_i = Av_i$, und für $i > r$ steht auf beiden Seiten der Nullvektor. Beide Abbildungen stimmen also auf einer Basis des $\mathbb{R}^n$ überein und sind damit gleich.

$V^T v_i = e_i$, weil V orthogonal ist; $\Sigma e_i = \sigma_i e_i$ nach (6.2.4), und für $i > r$ ist $\Sigma e_i = 0$

Beispiel 6.2.14 (Die Gestalt von Σ)

Die Blockform (6.2.4) in drei Fällen:

Für ein quadratisches A mit $m = n = 3$ und $r = 2$ ist

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

Für ein rechteckiges A mit $m = 2$, $n = 3$ und $r = 2$ ist

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix}.$$

Und für unsere Beispielmatrix aus Beispiel 6.2.3 mit $m = 3$, $n = 2$, $r = 2$ ist

$$\Sigma \approx \begin{pmatrix} 3,087 & 0 \\ 0 & 1,212 \\ 0 & 0 \end{pmatrix}.$$

Hier hat U drei Spalten, wir kennen aber erst zwei. Die dritte ergänzt u_1, u_2 wie in Beispiel 6.2.12 zu einer Orthonormalbasis des $\mathbb{R}^3$; sie spannt den linken Kern auf und ist bis aufs Vorzeichen

$$u_3 = \frac{1}{\sqrt{14}} \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix} \approx \begin{pmatrix} 0,267 \\ -0,535 \\ 0,802 \end{pmatrix}, \quad \text{denn} \quad A^T \begin{pmatrix} 1 \\ -2 \\ 3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Geometrische Interpretation

Bemerkung 6.2.15 (Merkregel: Drehen, Strecken, Drehen)

Lesen wir (6.2.3) als Abbildungsvorschrift $\mathbf{x} \mapsto \mathbf{Ax} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{x}$, dann geschieht die Abbildung in drei Etappen:

1. $\mathbf{V}^T$: Koordinatenwechsel im $\mathbb{R}^n$, eine Drehung oder Spiegelung auf die „optimalen“ Richtungen $\mathbf{v}_1, \dots, \mathbf{v}_n$.
2. $\mathbf{\Sigma}$: Strecken entlang dieser Achsen um die Faktoren σ_i , Nullsetzen der Richtungen mit $i > r$ und Übergang von $\mathbb{R}^n$ nach $\mathbb{R}^m$.
3. $\mathbf{U}$: Koordinatenwechsel im $\mathbb{R}^m$, wieder eine Drehung oder Spiegelung, diesmal in die Endlage.

Die SVD zerlegt also *jede* lineare Abbildung von $\mathbb{R}^n$ nach $\mathbb{R}^m$ in Drehen, Strecken, Drehen. Aus der Einheitssphäre des $\mathbb{R}^n$ wird dabei ein Ellipsoid mit den Hauptachsenrichtungen $\mathbf{u}_i$ und den Halbachsenlängen σ_i . Drückt A Richtungen auf null, ist also $r < n$, so wird daraus ein ausgefülltes Ellipsoid im r -dimensionalen Spaltenraum (Abschnitt 6.1).

Interaktiv: Drehen, Strecken, Drehen an einer editierbaren Matrix

Welche der drei Etappen ist für die Form der Bildellipse zuständig, und welche nur für ihre Lage? Vier Tafeln zeigen denselben Kreis vor $\mathbf{V}^T$, danach, nach $\mathbf{\Sigma}$ und nach $\mathbf{U}$. Voreingestellt ist $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$ aus Abschnitt 3.3; drei weitere Knöpfe stellen eine Drehmatrix, eine Scherung und eine Matrix mit zwei gleichen Spalten ein.

Interaktives Element — nur in der Web-Fassung

Nach $\mathbf{V}^T$ ist der Kreis noch ein Kreis, nur gedreht oder gespiegelt. Erst $\mathbf{\Sigma}$ macht ihn zur Ellipse mit den Halbachsen σ_1 und σ_2 , und $\mathbf{U}$ legt diese Ellipse nur noch in ihre Endlage. Bei zwei gleichen Spalten ist $\sigma_2 = 0$, und aus dem Kreis wird eine Strecke.

Selbsttest

1. Der Rechner oben zeigt in Schritt 4 das Verhältnis σ_1/σ_2 der voreingestellten Matrix. Wie groß ist es?

Lösung: 2.547

$3,087/1,212 \approx 2,547$. Ohne Widget geht es auch, denn Wurzelziehen und Teilen vertauschen: $\sqrt{9,531/1,469} = \sqrt{6,488} \approx 2,547$. Diese Zahl ist die Konditionszahl $\kappa_2(\mathbf{A})$ aus Abschnitt 3.5; die Bildellipse ist gut zweieinhalbmals so lang wie breit.

2. Für jede Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ sind alle Eigenwerte von $\mathbf{A}^T \mathbf{A}$ nichtnegativ.

Antwort: Wahr

Das ist Satz 6.2.1(2). Der Grund steckt in (6.2.1): Für einen normierten Eigenvektor $\mathbf{v}_i$ ist $\lambda_i = \|\mathbf{A}\mathbf{v}_i\|^2$, also das Quadrat einer Länge.

3. Wenn ein Singulärwert von A null ist, muss A die Nullmatrix sein.

Antwort: Falsch

Ein verschwindender Singulärwert bedeutet nur, dass A eine Richtung auf null abbildet. Beispiel

6.2.12 zeigt eine Matrix mit $\sigma_1 = 2$ und $\sigma_2 = 0$, die nicht null ist; nach Satz 6.2.11 hat sie den Rang 1 und einen eindimensionalen Kern.

4. Die rechten Singulärvektoren $\mathbf{v}_i$ sind orthonormal, die Bildvektoren $\mathbf{A}\mathbf{v}_i$ dagegen im Allgemeinen nur orthogonal.

Antwort: Wahr

Das sagt Satz 6.2.8: Die Bilder stehen paarweise senkrecht aufeinander, haben aber die Längen σ_i . Erst die Division durch σ_i macht daraus die orthonormalen linken Singulärvektoren.

5. In der Zerlegung $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ ist $\mathbf{\Sigma}$ immer eine quadratische Diagonalmatrix.

Antwort: Falsch

$\mathbf{\Sigma}$ hat dasselbe Format wie $\mathbf{A}$, ist also für $m \neq n$ rechteckig. Quadratisch sind nur die beiden Orthogonalmatrizen: $\mathbf{U}$ ist $m \times m$, $\mathbf{V}$ ist $n \times n$.

6. Die Singulärwerte und die Singulärvektoren einer Matrix sind eindeutig bestimmt.

Antwort: Falsch

Die Singulärwerte schon, die Vektoren nicht: Mit $\mathbf{v}_i$ leistet auch $-\mathbf{v}_i$ dasselbe, und dann dreht sich nach (6.2.2) auch $\mathbf{u}_i$ um (Bemerkung 6.2.10). Bei mehrfachen Singulärwerten kommt sogar noch die freie Wahl einer Orthonormalbasis im zugehörigen Eigenraum hinzu.

Vertiefung: Heath §3.6 (Singulärwertzerlegung); vgl. MML §4.5 für die geometrische Deutung der SVD und §4.6 für die daran anschließende Rang-k-Approximation.

6.3 Reduzierte SVD und Pseudoinverse

Die Zerlegung $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ aus Abschnitt 6.2 ist vollständig, aber verschwenderisch. Sobald der Rang r kleiner als m oder n ist, besteht ein Teil von $\mathbf{\Sigma}$ aus Nullen, und diese Nullen löschen ganze Spalten von $\mathbf{U}$ und $\mathbf{V}$ aus. Lassen wir sie weg, bleibt die reduzierte SVD. Aus ihr lesen wir eine Matrix ab, die auch eine rechteckige oder singuläre Matrix so weit wie möglich umkehrt.

Nullblöcke in Sigma

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$ hat $\mathbf{\Sigma}$ die Blockgestalt

$$\mathbf{\Sigma} = \begin{pmatrix} \mathbf{\Sigma}_r & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{pmatrix} \in \mathbb{R}^{m \times n}, \quad \mathbf{\Sigma}_r = \text{diag}(\sigma_1, \dots, \sigma_r). \quad (6.3.1)$$

Nur der Block links oben ist besetzt: Die letzten $m - r$ Zeilen von $\mathbf{\Sigma}$ sind Nullzeilen, die letzten $n - r$ Spalten Nullspalten. Bei einer Matrix mit $m = 1000$, $n = 50$ und $r = 5$ sind von den 50 000 Einträgen in $\mathbf{\Sigma}$ nur fünf von null verschieden.

Passend dazu trennen wir in beiden Orthogonalmatrizen die ersten r Spalten ab:

$$\mathbf{U} = (\mathbf{U}_r \mid \mathbf{U}_{m-r}), \quad \mathbf{V} = (\mathbf{V}_r \mid \mathbf{V}_{n-r}), \quad (6.3.2)$$

mit $\mathbf{U}_r \in \mathbb{R}^{m \times r}$ und $\mathbf{V}_r \in \mathbb{R}^{n \times r}$. Nach Satz 6.2.11 stehen in $\mathbf{U}_r$ die linken Singulärvektoren $\mathbf{u}_1, \dots, \mathbf{u}_r$, also eine Orthonormalbasis des Spaltenraums $\text{col}(\mathbf{A})$, und in $\mathbf{V}_r$ die rechten Singulärvektoren

$\mathbf{v}_1, \dots, \mathbf{v}_r$, eine Orthonormalbasis des Zeilenraums $\text{col}(\mathbf{A}^\top)$. Die abgetrennten Blöcke gehören zu den beiden Kernen: $\mathbf{V}_{n-r}$ spannt $\text{Kern}(\mathbf{A})$ auf, $\mathbf{U}_{m-r}$ den linken Kern $\text{Kern}(\mathbf{A}^\top)$.

Satz 6.3.1 (Reduzierte Darstellung)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r \geq 1$ und einer Singulärwertzerlegung $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$. Mit den Partitionen aus (6.3.2) gilt

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top. \quad (6.3.3)$$

Die Blöcke $\mathbf{U}_{m-r}$ und $\mathbf{V}_{n-r}$ tragen zu $\mathbf{A}$ nichts bei.

Vertiefung (optional): Beweis der reduzierten Darstellung

Beweis.

- (1) Transponieren wir die Partition von $\mathbf{V}$, so werden aus den Spaltenblöcken übereinanderliegende Zeilenblöcke:

$$\mathbf{V}^\top = \begin{pmatrix} \mathbf{V}_r^\top \\ \mathbf{V}_{n-r}^\top \end{pmatrix}.$$

Transponieren macht aus der j-ten Spalte die j-te Zeile; der obere Block hat r Zeilen, der untere die restlichen n - r

- (2) Multiplizieren wir blockweise mit (6.3.1):

$$\mathbf{\Sigma} \mathbf{V}^\top = \begin{pmatrix} \mathbf{\Sigma}_r & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{pmatrix} \begin{pmatrix} \mathbf{V}_r^\top \\ \mathbf{V}_{n-r}^\top \end{pmatrix} = \begin{pmatrix} \mathbf{\Sigma}_r \mathbf{V}_r^\top \\ \mathbf{0}_{(m-r) \times n} \end{pmatrix}.$$

Blockmultiplikation: oben steht $\mathbf{\Sigma}_r \mathbf{V}_r^\top + \mathbf{0} \mathbf{V}_{n-r}^\top$, unten nur Nullen; $\mathbf{V}_{n-r}$ kommt rechts gar nicht mehr vor

- (3) Multiplizieren wir von links mit $\mathbf{U}$, ebenfalls blockweise:

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top = (\mathbf{U}_r \mid \mathbf{U}_{m-r}) \begin{pmatrix} \mathbf{\Sigma}_r \mathbf{V}_r^\top \\ \mathbf{0} \end{pmatrix} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top + \mathbf{U}_{m-r} \mathbf{0} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top.$$

Spaltenblöcke mal Zeilenblöcke: der zweite Summand ist die Nullmatrix, ganz gleich, was in $\mathbf{U}_{m-r}$ steht

□

Die reduzierte SVD

Definition 6.3.2 (Reduzierte SVD)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r \geq 1$. Die Darstellung (6.3.3),

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top,$$

heißt *reduzierte SVD* (reduced SVD) von $\mathbf{A}$. Dabei ist

- $\mathbf{U}_r \in \mathbb{R}^{m \times r}$ die Matrix der ersten r linken Singulärvektoren,
- $\mathbf{V}_r \in \mathbb{R}^{n \times r}$ die Matrix der ersten r rechten Singulärvektoren,
- $\mathbf{\Sigma}_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ die Diagonalmatrix der von null verschiedenen Singulärwerte.

Bemerkung 6.3.3 (Was die reduzierte Form spart, und was sie kostet)

1. *Kompakter.* Die volle Zerlegung speichert $m^2 + n^2 + \min(m, n)$ Zahlen (beide Orthogonalmatrizen plus die Diagonale von Σ), die reduzierte nur $r(m+n+1)$. Im Beispiel oben mit $m = 1000$, $n = 50$ und $r = 5$ sind das 5255 statt 1 002 550 Zahlen, also nicht einmal ein Prozent. Sogar A selbst braucht mit 50 000 Einträgen noch fast das Zehnfache.
2. *Schneller.* Auch Ax kostet über die drei kleinen Faktoren nur $r(m+n+1)$ statt mn Multiplikationen.
3. Σ_r ist invertierbar. Sie ist quadratisch, und auf ihrer Diagonalen stehen ausschließlich positive Zahlen. Darauf baut der Rest dieses Abschnitts auf.

Eines geht dabei verloren: U_r und V_r sind für $r < m$ bzw. $r < n$ keine Orthogonalmatrizen mehr, denn sie sind nicht quadratisch. Ihre Spalten bleiben orthonormal, es gilt also

$$U_r^T U_r = I_r \quad \text{und} \quad V_r^T V_r = I_r, \quad (6.3.4)$$

aber die Produkte in der anderen Reihenfolge, $U_r U_r^T$ und $V_r V_r^T$, sind im Allgemeinen keine Einheitsmatrizen, sondern Projektionen (Satz 6.3.8). Beim Rechnen mit reduzierten Faktoren ist diese Unterscheidung eine typische Fehlerquelle.

Beispiel 6.3.4 (Reduzierte SVD einer Rang-1-Matrix)

Nehmen wir die Matrix aus Beispiel 6.2.12,

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}, \quad \sigma_1 = 2, \quad \sigma_2 = 0, \quad r = 1.$$

Die volle Zerlegung braucht ein 3×3 -großes U , ein 3×2 -großes Σ und ein 2×2 -großes V . Bei $r = 1$ bleiben davon die erste Spalte von U , die erste Spalte von V und der einzige positive Singulärwert übrig:

$$U_1 = u_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \Sigma_1 = (2), \quad V_1 = v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Die Probe bestätigt (6.3.3):

$$U_1 \Sigma_1 V_1^T = 2 \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix} = A.$$

Aus drei Matrizen mit 9, 6 und 4 Einträgen sind $3 + 1 + 2$ Zahlen geworden. Ganz rechts steht ein äußeres Produkt von zwei Vektoren; dass sich jede Matrix so als Summe von r solchen Produkten schreiben lässt, ist der Ausgangspunkt von Abschnitt 6.4.

Interaktiv: Welche Blöcke fallen weg?

Welche Teile der Zerlegung verschwinden beim Schrumpfen, und wie viel Speicher spart das? Das Widget zeichnet die volle Zerlegung als Blockschema mit einstellbaren Formaten; ein Klick auf einen Block sagt, wozu er da ist. Der Umschalter führt Satz 6.3.1 vor und wirft

alles heraus, was auf einen Nullblock von Σ trifft. Die Zeile ganz unten zählt die gespeicherten Zahlen aus Bemerkung 6.3.3.

Interaktives Element — nur in der Web-Fassung

Im Preset $r = 1$ fällt der Speicherbedarf unter den der Matrix selbst; im Preset $r = m = n$ schrumpft nichts, die reduzierte Zerlegung ist die volle.

Die Moore-Penrose-Pseudoinverse

Ein Gleichungssystem $Ax = b$ lösen wir mit $x = A^{-1}b$, sofern A quadratisch und invertierbar ist. In der Statistik ist das der Ausnahmefall: Designmatrizen sind rechteckig, und auch quadratische Matrizen sind manchmal singulär. Was tritt an die Stelle von A^{-1} , wenn es die Inverse nicht gibt?

Die reduzierte SVD zerlegt die Abbildung $x \mapsto Ax$ in drei Etappen: V_r^T liest die Koordinaten von x bezüglich $v_1, \dots, v_r$ ab, Σ_r streckt jede dieser Koordinaten um ihren Singulärwert, und U_r setzt das Ergebnis in der Basis $u_1, \dots, u_r$ des Spaltenraums zusammen. Jede Etappe lässt sich umkehren: die beiden äußeren durch Transponieren, die mittlere durch Division durch die positiven σ_i . Verloren ist nur, was x außerhalb des Zeilenraums mitbrachte, denn das hat A auf null gedrückt. Die drei Etappen rückwärts ergeben die folgende Matrix.

Definition 6.3.5 (Moore-Penrose-Pseudoinverse)

Sei $A \in \mathbb{R}^{m \times n}$ mit $\text{rang}(A) = r \geq 1$ und reduzierter SVD $A = U_r \Sigma_r V_r^T$. Die *Pseudoinverse* (Moore-Penrose-Inverse) von A ist

$$A^+ := V_r \Sigma_r^{-1} U_r^T \in \mathbb{R}^{n \times m}. \quad (6.3.5)$$

Bemerkung 6.3.6 (Zum Bau der Pseudoinversen)

- Die Inverse in der Mitte existiert immer, denn Σ_r ist eine Diagonalmatrix mit positiven Einträgen:

$$\Sigma_r^{-1} = \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}\right).$$

Dafür brauchen wir die Reduktion: In Σ selbst stehen Nullen auf der Diagonalen, durch die wir nicht teilen könnten.

- Die Reihenfolge der drei Faktoren dreht sich um, wie wir es von $(XY)^{-1} = Y^{-1}X^{-1}$ gewohnt sind: Was zuletzt angewandt wurde, wird zuerst rückgängig gemacht.
- Die Formate passen zusammen. A bildet von $\mathbb{R}^n$ nach $\mathbb{R}^m$ ab, also muss A^+ von $\mathbb{R}^m$ nach $\mathbb{R}^n$ abbilden, und tatsächlich ist A^+ vom Format $(n \times r) \cdot (r \times r) \cdot (r \times m) = n \times m$.
- Für die Nullmatrix, also $r = 0$, setzt man $A^+ = 0 \in \mathbb{R}^{n \times m}$.

Vertiefung (optional): Eindeutigkeit der Pseudoinversen

Die Singulärvektoren liegen nach Bemerkung 6.2.10 nicht eindeutig fest. Auf A^+ schlägt diese Freiheit aber nicht durch: Die Pseudoinverse hängt allein an A , nicht an der gewählten Zerlegung.

Beim Vorzeichen sieht man es sofort: Dreht sich das von $\mathbf{v}_i$, so dreht sich nach (6.2.2) auch das von $\mathbf{u}_i$, und in der Summendarstellung

$$\mathbf{A}^+ = \sum_{i=1}^r \frac{1}{\sigma_i} \mathbf{v}_i \mathbf{u}_i^\top$$

heben die beiden Vorzeichen einander auf. Bei einem mehrfachen Singulärwert ist die Freiheit größer, das Ergebnis aber dasselbe: Dort darf die Orthonormalbasis des Eigenraums gedreht werden, $\mathbf{V}_r \mapsto \mathbf{V}_r \mathbf{Q}$ und mit (6.2.2) zugleich $\mathbf{U}_r \mapsto \mathbf{U}_r \mathbf{Q}$, und weil Σ_r^{-1} in diesem Block ein Vielfaches der Einheitsmatrix ist, kürzt sich $\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}$ ebenso weg.

Beispiel 6.3.7 (Fortsetzung: die Pseudoinverse der Rang-1-Matrix)

Für $\mathbf{A}$ aus Beispiel 6.3.4 setzen wir die drei Faktoren in umgekehrter Reihenfolge zusammen:

$$\mathbf{A}^+ = \mathbf{V}_1 \Sigma_1^{-1} \mathbf{U}_1^\top = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} \cdot \frac{1}{2} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 & 0 \end{pmatrix} = \frac{1}{4} \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \end{pmatrix}.$$

Dazu die beiden Produkte:

$$\mathbf{A}\mathbf{A}^+ = \frac{1}{2} \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \mathbf{u}_1 \mathbf{u}_1^\top, \quad \mathbf{A}^+\mathbf{A} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} = \mathbf{v}_1 \mathbf{v}_1^\top.$$

Keines von beiden ist eine Einheitsmatrix, und zwar aus je eigenem Grund: $\mathbf{A}^+\mathbf{A} \neq \mathbf{I}_2$, weil $\mathbf{A}$ die Richtung $\mathbf{v}_2$ auf null drückt und diese Information verloren ist; $\mathbf{A}\mathbf{A}^+ \neq \mathbf{I}_3$, weil der Spaltenraum nur eine Gerade im $\mathbb{R}^3$ ist und $\mathbf{A}\mathbf{A}^+\mathbf{b}$ immer auf ihr landet. Was $\mathbf{A}\mathbf{A}^+$ stattdessen tut, zeigt ein Testvektor: Für $\mathbf{b} = (1, 3, 5)^\top$ ist

$$\mathbf{A}\mathbf{A}^+\mathbf{b} = \begin{pmatrix} 2 \\ 2 \\ 0 \end{pmatrix},$$

der Punkt von $\text{col}(\mathbf{A}) = \text{span}\{(1, 1, 0)^\top\}$, der $\mathbf{b}$ am nächsten liegt: Die ersten beiden Einträge werden gemittelt, der dritte fällt weg. $\mathbf{A}\mathbf{A}^+$ wirkt also als Projektion.

Eigenschaften der Pseudoinversen

Satz 6.3.8 (Eigenschaften der Pseudoinversen)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r \geq 1$ und Pseudoinverser $\mathbf{A}^+$. Dann gilt:

1. $\mathbf{A}\mathbf{A}^+\mathbf{x} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{x}$ für alle $\mathbf{x} \in \mathbb{R}^m$;
2. $\mathbf{A}^+\mathbf{A}\mathbf{x} = \text{proj}_{\text{col}(\mathbf{A}^\top)}\mathbf{x}$ für alle $\mathbf{x} \in \mathbb{R}^n$;
3. $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$;
4. $\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+$.

Dabei ist proj_U die orthogonale Projektion auf den Untervektorraum U .

Die Punkte 3 und 4 heißen *Konsistenzbedingungen*: In den Dreierprodukten verhält sich $\mathbf{A}^+$ wie eine echte Inverse, obwohl $\mathbf{A}\mathbf{A}^+$ und $\mathbf{A}^+\mathbf{A}$ für sich keine Einheitsmatrizen sind.

Warum Projektionen herauskommen, zeigt das Einsetzen der reduzierten Faktoren:

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top = \mathbf{U}_r \mathbf{U}_r^\top,$$

denn die inneren Faktoren heben sich nach (6.3.4) weg; ebenso wird $\mathbf{A}^+\mathbf{A} = \mathbf{V}_r \mathbf{V}_r^\top$. Die Spalten von $\mathbf{U}_r$ sind eine Orthonormalbasis von $\text{col}(\mathbf{A})$, die von $\mathbf{V}_r$ eine von $\text{col}(\mathbf{A}^\top)$. Daraus folgen die Aussagen 1 und 2, und aus ihnen die Aussagen 3 und 4.

Vertiefung (optional): Beweis der Eigenschaften der Pseudoinversen

Der Beweis zeigt, dass $\mathbf{U}_r \mathbf{U}_r^\top$ auf $\text{col}(\mathbf{A})$ nichts ändert und das orthogonale Komplement auf null abbildet.

Beweis.

- (1) Geben wir dem Produkt einen Namen:

$$\mathbf{P} := \mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top.$$

in $\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top$ ist $\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$ nach (6.3.4), danach $\Sigma_r \Sigma_r^{-1} = \mathbf{I}_r$

- (2) $\mathbf{P}$ ist symmetrisch und idempotent:

$$\mathbf{P}^\top = (\mathbf{U}_r \mathbf{U}_r^\top)^\top = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}, \quad \mathbf{P}^2 = \mathbf{U}_r (\mathbf{U}_r^\top \mathbf{U}_r) \mathbf{U}_r^\top = \mathbf{U}_r \mathbf{U}_r^\top = \mathbf{P}.$$

Transponieren dreht das Produkt um und trifft es dadurch selbst; für $\mathbf{P}^2$ klammern wir die inneren Faktoren zusammen und nutzen wieder (6.3.4)

- (3) Auf $\text{col}(\mathbf{A})$ ändert $\mathbf{P}$ nichts. Jedes $\mathbf{y} \in \text{col}(\mathbf{A})$ lässt sich als $\mathbf{y} = \mathbf{U}_r \mathbf{c}$ mit einem Koeffizientenvektor $\mathbf{c} \in \mathbb{R}^r$ schreiben, und damit ist

$$\mathbf{P}\mathbf{y} = \mathbf{U}_r (\mathbf{U}_r^\top \mathbf{U}_r) \mathbf{c} = \mathbf{U}_r \mathbf{c} = \mathbf{y}.$$

die Spalten von $\mathbf{U}_r$ sind nach Satz 6.2.11 eine Orthonormalbasis von $\text{col}(\mathbf{A})$, jedes $\mathbf{y}$ dort ist also eine Linearkombination von ihnen

- (4) Auf dem orthogonalen Komplement bildet $\mathbf{P}$ alles auf null ab. Steht $\mathbf{z}$ senkrecht auf $\text{col}(\mathbf{A})$, so ist $\mathbf{u}_i^\top \mathbf{z} = 0$ für $i = 1, \dots, r$, also $\mathbf{U}_r^\top \mathbf{z} = \mathbf{0}$ und damit

$$\mathbf{P}\mathbf{z} = \mathbf{U}_r (\mathbf{U}_r^\top \mathbf{z}) = \mathbf{0}.$$

der i -te Eintrag von $\mathbf{U}_r^\top \mathbf{z}$ ist das Skalarprodukt $\mathbf{u}_i^\top \mathbf{z}$, und die $\mathbf{u}_i$ spannen $\text{col}(\mathbf{A})$ auf

- (5) Beides zusammen ergibt Aussage 1. Jedes $\mathbf{x} \in \mathbb{R}^m$ zerlegt sich eindeutig in $\mathbf{x} = \mathbf{y} + \mathbf{z}$ mit $\mathbf{y} \in \text{col}(\mathbf{A})$ und $\mathbf{z} \perp \text{col}(\mathbf{A})$, und nach den beiden Vorschriften ist

$$\mathbf{P}\mathbf{x} = \mathbf{P}\mathbf{y} + \mathbf{P}\mathbf{z} = \mathbf{y} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{x}.$$

$\mathbf{P} = \mathbf{U}_r \mathbf{U}_r^\top$ ist also die orthogonale Projektionsmatrix auf $\text{col}(\mathbf{A})$. Bild und Kern lesen wir gleich mit ab: $\text{col}(\mathbf{P}) = \text{col}(\mathbf{A})$ und $\text{Kern}(\mathbf{P}) = \text{col}(\mathbf{A})^\perp$. Schritt 2 bestätigt das von der anderen Seite, denn $\mathbf{P}^2 = \mathbf{P}$ macht $\mathbf{P}$ zu einer Projektion und $\mathbf{P}^\top = \mathbf{P}$ zu einer orthogonalen.

die Spalten von $\mathbf{U} = (\mathbf{U}_r \mid \mathbf{U}_{m-r})$ sind eine Orthonormalbasis des $\mathbb{R}^m$; die ersten r spannen $\text{col}(\mathbf{A})$ auf, die übrigen den linken Kern $\text{Kern}(\mathbf{A}^\top) = \text{col}(\mathbf{A})^\perp$, und die Entwicklung von $\mathbf{x}$ in dieser Basis liefert die Zerlegung

- (6) Aussage 2 geht wörtlich genauso, nur mit den blauen Faktoren:

$$\mathbf{A}^+\mathbf{A} = \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top = \mathbf{V}_r \mathbf{V}_r^\top.$$

jetzt treffen sich $\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$ in der Mitte; die Spalten von $\mathbf{V}_r$ sind eine Orthonormalbasis von $\text{col}(\mathbf{A}^\top)$, also ist $\mathbf{V}_r \mathbf{V}_r^\top$ nach demselben Argument die Projektion auf den Zeilenraum

(7) Die Konsistenzbedingungen fallen jetzt ab:

$$\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{U}_r\mathbf{U}_r^\top \mathbf{U}_r\boldsymbol{\Sigma}_r\mathbf{V}_r^\top = \mathbf{U}_r\boldsymbol{\Sigma}_r\mathbf{V}_r^\top = \mathbf{A},$$

$$\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{V}_r\mathbf{V}_r^\top \mathbf{V}_r\boldsymbol{\Sigma}_r^{-1}\mathbf{U}_r^\top = \mathbf{V}_r\boldsymbol{\Sigma}_r^{-1}\mathbf{U}_r^\top = \mathbf{A}^+.$$

beide Male steht (6.3.4) in der Mitte; anschaulich: jede Spalte von $\mathbf{A}$ liegt in $\text{col}(\mathbf{A})$, und dort lässt die Projektion nach Schritt 3 alles unverändert

□

Für Matrizen mit vollem Zeilen- oder Spaltenrang wird eine der beiden Projektionen zur Identität, und dann sieht die Pseudoinverse einer echten Inversen sehr ähnlich.

Korollar 6.3.9 (Spezialfälle)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$.

1. Ist $r = m$ (voller Zeilenrang), so gilt $\mathbf{A}\mathbf{A}^+ = \mathbf{I}_m$.
2. Ist $r = n$ (voller Spaltenrang), so gilt $\mathbf{A}^+\mathbf{A} = \mathbf{I}_n$.
3. Ist $\mathbf{A}$ quadratisch und invertierbar, so gilt $\mathbf{A}^+ = \mathbf{A}^{-1}$.

Vertiefung (optional): Beweis der Spezialfälle

Beweis.

- (1) Zu 1 und 2: Für $r = m$ ist $\mathbf{U}_r \in \mathbb{R}^{m \times m}$ quadratisch mit orthonormalen Spalten, also eine Orthogonalmatrix, und aus $\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_m$ folgt dann auch $\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r\mathbf{U}_r^\top = \mathbf{I}_m$. Für $r = n$ liefert dasselbe Argument mit $\mathbf{V}_r$ die Gleichung $\mathbf{A}^+\mathbf{A} = \mathbf{V}_r\mathbf{V}_r^\top = \mathbf{I}_n$.

bei einer quadratischen Matrix ist eine einseitige Inverse automatisch die beidseitige; geometrisch: $\text{col}(\mathbf{A})$ ist ganz $\mathbb{R}^m$ bzw. $\text{col}(\mathbf{A}^\top)$ ganz $\mathbb{R}^n$, und die Projektion auf den ganzen Raum ändert nichts

- (2) Zu 3: Ist $\mathbf{A}$ quadratisch und invertierbar, so ist $r = m = n$, beide Fälle greifen gleichzeitig, und $\mathbf{A}^+$ ist eine beidseitige Inverse von $\mathbf{A}$.

die Inverse einer Matrix ist eindeutig: aus $\mathbf{BA} = \mathbf{I}$ und $\mathbf{AC} = \mathbf{I}$ folgt $\mathbf{B} = \mathbf{BAC} = \mathbf{C}$

□

Der zweite Spezialfall ist der für die Statistik wichtigste, denn eine Designmatrix hat in aller Regel mehr Zeilen als Spalten. Er lässt sich sogar ohne SVD ausrechnen.

Bemerkung 6.3.10 (Voller Spaltenrang: eine geschlossene Formel)

Hat $\mathbf{A} \in \mathbb{R}^{m \times n}$ vollen Spaltenrang $r = n$, so ist $\mathbf{V}_r$ orthogonal, und $\mathbf{A}^\top \mathbf{A}$ lässt sich mit (6.3.3) und (6.3.4) ausrechnen:

$$\mathbf{A}^\top \mathbf{A} = \mathbf{V}_r\boldsymbol{\Sigma}_r\mathbf{U}_r^\top \mathbf{U}_r\boldsymbol{\Sigma}_r\mathbf{V}_r^\top = \mathbf{V}_r\boldsymbol{\Sigma}_r^2\mathbf{V}_r^\top, \quad \text{also} \quad (\mathbf{A}^\top \mathbf{A})^{-1} = \mathbf{V}_r\boldsymbol{\Sigma}_r^{-2}\mathbf{V}_r^\top.$$

Multiplizieren wir das mit $\mathbf{A}^\top = \mathbf{V}_r\boldsymbol{\Sigma}_r\mathbf{U}_r^\top$, so bleibt

$$(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top = \mathbf{V}_r\boldsymbol{\Sigma}_r^{-2} \underbrace{\mathbf{V}_r^\top \mathbf{V}_r}_{=\mathbf{I}_n} \boldsymbol{\Sigma}_r \mathbf{U}_r^\top = \mathbf{V}_r\boldsymbol{\Sigma}_r^{-1}\mathbf{U}_r^\top = \mathbf{A}^+. \quad (6.3.6)$$

Bei vollem Spaltenrang ist die Pseudoinverse also $(\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$, die aufgelöste Form der Normalengleichungen.

Vertiefung (optional): Die geschlossene Formel an der Beispielmatrix

Beispiel 6.3.11 (Pseudoinverse der Beispielmatrix)

Kehren wir zu der Matrix zurück, die uns durch Abschnitt 6.2 begleitet hat:

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}, \quad \mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix}, \quad \sigma_1 \approx 3,087, \quad \sigma_2 \approx 1,212.$$

Beide Singulärwerte sind positiv, also ist $r = 2 = n$: voller Spaltenrang. Die reduzierte SVD wirft hier nur die dritte Spalte von $\mathbf{U}$ weg, jene $\mathbf{u}_3$ aus Beispiel 6.2.14, die den linken Kern aufspannt. Weil $r = n$ ist, dürfen wir (6.3.6) benutzen und die Singulärwerte ganz umgehen. Mit $\det(\mathbf{A}^\top \mathbf{A}) = 30 - 16 = 14$ ist

$$(\mathbf{A}^\top \mathbf{A})^{-1} = \frac{1}{14} \begin{pmatrix} 5 & -4 \\ -4 & 6 \end{pmatrix}, \quad \mathbf{A}^+ = \frac{1}{14} \begin{pmatrix} 5 & -4 \\ -4 & 6 \end{pmatrix} \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 0 \end{pmatrix} = \frac{1}{14} \begin{pmatrix} -3 & 6 & 5 \\ 8 & -2 & -4 \end{pmatrix}.$$

Korollar 6.3.9 verspricht $\mathbf{A}^+ \mathbf{A} = \mathbf{I}_2$, und die Rechnung bestätigt das:

$$\frac{1}{14} \begin{pmatrix} -3 & 6 & 5 \\ 8 & -2 & -4 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} = \frac{1}{14} \begin{pmatrix} -3 + 12 + 5 & -6 + 6 + 0 \\ 8 - 4 - 4 & 16 - 2 + 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

In der anderen Reihenfolge kommt dagegen keine Einheitsmatrix heraus, denn $\text{col}(\mathbf{A})$ ist nur eine Ebene im $\mathbb{R}^3$: Es ist $\mathbf{A}\mathbf{A}^+ = \mathbf{I}_3 - \mathbf{u}_3\mathbf{u}_3^\top$, die orthogonale Projektion auf diese Ebene.

Bemerkung 6.3.12 (Ausblick: Kleinste Quadrate)

Aussage 1 aus Satz 6.3.8 hat eine wichtige Anwendung. Ein überbestimmtes System $\mathbf{A}\mathbf{x} = \mathbf{b}$ hat in aller Regel keine Lösung, weil $\mathbf{b}$ nicht in $\text{col}(\mathbf{A})$ liegt. Am nächsten kommt $\mathbf{b}$ der Punkt $\mathbf{A}\mathbf{A}^+\mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$. Der Vektor

$$\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b}$$

löst deshalb das Kleinste-Quadrate-Problem $\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|$: Kleiner als $\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b} - \mathbf{b}\|$ wird das Residuum nicht. Bei vollem Spaltenrang ist $\hat{\mathbf{x}}$ nach (6.3.6) die vertraute Lösung der Normalengleichungen; bei kleinerem Rang gibt es unendlich viele Lösungen, und $\mathbf{A}^+\mathbf{b}$ wählt unter ihnen die mit der kleinsten Norm. Ausgeführt wird das in Abschnitt 7.6, wo die Pseudoinverse der robusteste von drei Lösungswegen ist.

Interaktiv: Die kürzeste unter unendlich vielen Lösungen

Was heißt „die mit der kleinsten Norm“ geometrisch? Das Widget stellt beide Räume nebeneinander: rechts den Bildraum mit $\mathbf{b}$, dem Spaltenraum $\text{col}(\mathbf{A})$ und dem Residuum, links den Urbildraum mit der Menge aller Kleinste-Quadrate-Lösungen. Ist $\mathbf{A}$ singulär, so ist diese Menge eine Gerade.

Interaktives Element — nur in der Web-Fassung

Das Residuum hängt nur von der Projektion auf $\text{col}(\mathbf{A})$ ab und ist für jede Lösung dasselbe.

Die Norm $\|\mathbf{x}\|$ dagegen unterscheidet die Lösungen, und $\mathbf{A}^+\mathbf{b}$ ist der Punkt der Lösungsgeraden, der dem Ursprung am nächsten liegt.

Selbsttest

1. Stellen wir im Blockschema oben das Preset $r < \min(m, n)$ ein, also $m = 5$, $n = 4$, $r = 2$, und schalten wir auf die reduzierte Zerlegung um. Wie viele Zahlen speichert sie?

Lösung: 20

$r \cdot (m + n + 1) = 2 \cdot 10 = 20$. Die volle Zerlegung braucht $m^2 + n^2 + \min(m, n) = 25 + 16 + 4 = 45$ Zahlen, die Matrix selbst $m \cdot n = 20$. Bei diesen Formaten lohnt die Reduktion gegenüber der vollen Zerlegung deutlich, gegenüber $\mathbf{A}$ selbst aber noch nicht: Erst kleines r bei großem m und n spart wirklich (Bemerkung 6.3.3).

2. Im Pseudoinversen-Widget steht voreingestellt $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ mit $\mathbf{b} = (1, 5)^\top$. Wie groß ist die Norm $\|\mathbf{A}^+\mathbf{b}\|$ der Minimalnorm-Lösung?

Lösung: 2,121

$\|\mathbf{A}^+\mathbf{b}\| = 2,121$. Es ist $\mathbf{A}^+ = \frac{1}{4} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$, also $\mathbf{A}^+\mathbf{b} = (1,5, 1,5)^\top$ mit der Länge $1,5\sqrt{2}$. Jede andere Lösung liegt weiter außen: Bei $t = 1$ auf der Lösungsgeraden sind es schon 2,345, während das Residuum unverändert 2,828 bleibt.

3. In der reduzierten SVD $\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top$ sind $\mathbf{U}_r$ und $\mathbf{V}_r$ Orthogonalmatrizen.

Antwort: Falsch

Ihre Spalten sind orthonormal, es gilt also $\mathbf{U}_r^\top \mathbf{U}_r = \mathbf{I}_r$ und $\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$. Orthogonal heißt eine Matrix aber erst, wenn sie quadratisch ist, und das sind die beiden nur für $r = m$ bzw. $r = n$. In der anderen Reihenfolge sind die Produkte im Allgemeinen keine Einheitsmatrizen, sondern Projektionen (Satz 6.3.8).

4. Die Pseudoinverse erfüllt $\mathbf{A}\mathbf{A}^+ = \mathbf{I}_m$ für jede Matrix $\mathbf{A}$.

Antwort: Falsch

Das gilt nur bei vollem Zeilenrang $r = m$ (Korollar 6.3.9). Im Allgemeinen ist $\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \mathbf{U}_r^\top$ die Projektion auf $\text{col}(\mathbf{A})$, und die ist von der Einheitsmatrix weit entfernt, sobald $\text{col}(\mathbf{A})$ ein echter Untervektorraum des $\mathbb{R}^m$ ist. In Beispiel 6.3.7 etwa hat $\mathbf{A}\mathbf{A}^+$ eine Nullzeile.

5. Ist $\mathbf{A}$ quadratisch und invertierbar, so ist $\mathbf{A}^+ = \mathbf{A}^{-1}$.

Antwort: Wahr

Dann ist $r = m = n$, und beide Spezialfälle aus Korollar 6.3.9 greifen gleichzeitig: $\mathbf{A}^+$ ist eine beidseitige Inverse, und die ist eindeutig. Die Pseudoinverse verallgemeinert die Inverse also wirklich, sie ersetzt sie nicht.

6. Weil $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$ gilt, ist $\mathbf{A}^+\mathbf{A}$ die Einheitsmatrix.

Antwort: Falsch

Das eine folgt nicht aus dem anderen. In Beispiel 6.3.7 ist $\mathbf{A}^+\mathbf{A} = \frac{1}{2} \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$, und trotzdem stimmt $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$. Der Grund: Die Projektion $\mathbf{A}^+\mathbf{A}$ lässt den Zeilenraum $\text{col}(\mathbf{A}^\top)$ punktweise fest, und mehr braucht es nicht, weil $\mathbf{A}$ ohnehin nur auf diesem Teilraum etwas anderes als den Nullvektor produziert.

Vertiefung: Heath §3.6 (SVD und Pseudoinverse); vgl. MML §4.5 für die reduzierten Varianten der Zerlegung und §4.6 für den Anschluss an die Rang-k-Approximation.

6.4 Anwendungen

Bisher war die SVD vor allem eine Aussage über die Geometrie einer Abbildung. Jetzt wird sie zum Werkzeug, bis hin zur Bildkompression und zu Empfehlungssystemen.

Die Spektralnrm ist der größte Singulärwert

Die Matrixnorm $\|A\|_2$ ist in Abschnitt 3.3 als maximale Streckung $\max_{\|x\|=1} \|Ax\|$ definiert, und Satz 3.3.7 hat sie dort zu $\sqrt{\lambda_{\max}(A^T A)}$ ausgerechnet. Nach Definition 6.2.4 ist $\sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_1} = \sigma_1$, denn die Singulärwerte erben die absteigende Sortierung der Eigenwerte. Damit gilt:

Satz 6.4.1 (Spektralnrm und größter Singulärwert)

Sei $A \in \mathbb{R}^{m \times n}$ mit Singulärwerten $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$. Dann gilt

$$\|A\|_2 = \sigma_1 = \sigma_{\max}(A). \quad (6.4.1)$$

Die SVD als Summe von Rang-1-Matrizen

Multiplizieren wir $A = U\Sigma V^T$ aus, so fallen fast alle Summanden weg, weil Σ außerhalb der Diagonalen nur Nullen trägt: Übrig bleibt für jeden von null verschiedenen Singulärwert genau ein Term.

Satz 6.4.2 (Summenform der SVD)

Sei $A \in \mathbb{R}^{m \times n}$ mit $\text{rang}(A) = r$ und der Zerlegung $A = U\Sigma V^T$ aus Satz 6.2.13 (Abschnitt 6.2). Dann gilt

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T. \quad (6.4.2)$$

Jeder Summand $u_i v_i^T \in \mathbb{R}^{m \times n}$ hat Rang 1, und in der Frobeniusnorm aus Abschnitt 3.1 gilt

$$\|u_i v_i^T\|_F = 1.$$

Vertiefung (optional): Herleitung der Rang-1-Summenform

Beweis.

(1) Wir schreiben den Eintrag (a, b) des Produkts aus:

$$(U\Sigma V^T)_{ab} = \sum_{i=1}^m \sum_{j=1}^n U_{ai} \Sigma_{ij} V_{bj} = \sum_{i=1}^r \sigma_i U_{ai} V_{bi}.$$

Σ_{ij} ist null, außer für $i = j \leq r$; dort steht σ_i . Von der Doppelsumme bleibt also nur die Diagonale übrig

(2) Die rechte Seite ist genau der Eintrag (a, b) von $\sum_{i=1}^r \sigma_i u_i v_i^T$, denn $(u_i v_i^T)_{ab} = U_{ai} V_{bi}$. Da die Einträge übereinstimmen, stimmen die Matrizen überein, und (6.4.2) ist gezeigt.

das äußere Produkt xy^T hat an der Stelle (a, b) den Eintrag $x_a y_b$; hier ist u_i die i -te Spalte von U und v_i die i -te Spalte von V

- (3) Zu den beiden Zusatzaussagen: Jede Spalte von $\mathbf{u}_i \mathbf{v}_i^\top$ ist ein Vielfaches von $\mathbf{u}_i$, der Spaltenraum also eindimensional und der Rang damit 1; und für die Frobeniusnorm faktorisiert die Doppelsumme:

$$\|\mathbf{u}_i \mathbf{v}_i^\top\|_F^2 = \left(\sum_{a=1}^m U_{ai}^2 \right) \left(\sum_{b=1}^n V_{bi}^2 \right) = 1 \cdot 1 = 1.$$

$\mathbf{u}_i$ und $\mathbf{v}_i$ sind Spalten von Orthogonalmatrizen, haben also Länge 1 und sind insbesondere nicht der Nullvektor; in der Doppelsumme hängt U_{ai}^2 nicht von b und V_{bi}^2 nicht von a ab, beide Klammern sind quadrierte Längen von Einheitsvektoren

□

Die Summenform ist die reduzierte SVD $\mathbf{A} = \mathbf{U}_r \boldsymbol{\Sigma}_r \mathbf{V}_r^\top$ aus Abschnitt 6.3, als Summe statt als Produkt geschrieben. Sie zeigt aber, was im Produkt versteckt bleibt: $\mathbf{A}$ ist eine gewichtete Summe von r Bausteinen, die in der Frobeniusnorm alle gleich groß sind. Was sie unterscheidet, sind allein die Gewichte σ_i : Ein großes σ_i markiert eine wichtige Richtung, ein kleines eine unwichtige. Weil die Singulärwerte absteigend sortiert sind, stehen die wichtigen Terme vorn. Das legt nahe, nur die ersten Summanden zu behalten.

Die beste Approximation von kleinem Rang

Definition 6.4.3 (Rang-k-Approximation)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$ und der Summenform (6.4.2). Für $k \leq r$ heißt

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top \quad (6.4.3)$$

die *Rang-k-Approximation* (low-rank approximation) von $\mathbf{A}$. Für $k \geq 1$ hat sie tatsächlich Rang k , denn wegen $k \leq r$ sind alle beteiligten σ_i positiv und die $\mathbf{u}_i$ orthonormal.

Wie in Abschnitt 6.3 lässt sich die Summe wieder zu einem Produkt zusammenfassen: Mit den ersten k Spalten $\mathbf{U}_k$ von $\mathbf{U}$, den ersten k Spalten $\mathbf{V}_k$ von $\mathbf{V}$ und $\boldsymbol{\Sigma}_k = \text{diag}(\sigma_1, \dots, \sigma_k)$ ist gleichbedeutend

$$\mathbf{A}_k = \mathbf{U}_k \boldsymbol{\Sigma}_k \mathbf{V}_k^\top.$$

Was verlieren wir beim Abschneiden, und könnte eine andere Matrix vom Rang k es besser? Auf beide Fragen gibt derselbe Satz Antwort.

Satz 6.4.4 (Eckart und Young: beste Approximation von Rang k)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Singulärwerten $\sigma_1 \geq \dots \geq \sigma_r > 0$ und sei $k < r$. Dann löst $\mathbf{A}_k$ aus (6.4.3) beide Approximationsprobleme

$$\min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rang}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_F \quad \text{und} \quad \min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rang}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_2,$$

und die zugehörigen Fehler sind

$$\|\mathbf{A} - \mathbf{A}_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}, \quad \|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1}. \quad (6.4.4)$$

Den Beweis lassen wir aus (vgl. Heath §3.6; MML §4.6). Eckart und Young (1936) haben den Fall der Frobeniusnorm behandelt, die Aussage für die Spektralnorm geht auf Mirsky (1960) zurück.

Bemerkung 6.4.5 (Was der Satz liefert und was nicht)

- **Der Fehler steht in den weggeworfenen Singulärwerten.** In der Spektralnorm ist es der größte weggelassene Wert σ_{k+1} , in der Frobeniusnorm die Wurzel aus der Summe aller weggelassenen Quadrate. Wir kennen den Approximationsfehler also, bevor wir approximieren.
- **Beide Normen führen zum selben Minimierer.** Selbstverständlich ist das nicht, denn zwei verschiedene Gütemaße haben im Allgemeinen verschiedene Optima.
- **Der Satz sagt, dass A_k das Minimum annimmt, nicht dass es der einzige Minimierer ist.** In der Frobeniusnorm ist A_k eindeutig, solange $\sigma_k > \sigma_{k+1}$ gilt; bei Gleichheit gibt es mehrere. In der Spektralnorm ist die Lage anders. Für $A = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}$ und $k = 1$ etwa hat jede Matrix $B = \begin{pmatrix} b & 0 \\ 0 & 0 \end{pmatrix}$ mit $b \in [1, 5]$ den Fehler $\|A - B\|_2 = \max(|3 - b|, 2) = 2 = \sigma_2$. A_1 ist also *eine* beste Approximation, nicht *die*. In der Frobeniusnorm ist dagegen nur $b = 3$ optimal, denn dort beträgt der Fehler $\sqrt{(3 - b)^2 + 2^2}$.

Wie wählen wir k ?

Der Satz von Eckart und Young sagt, wie gut jedes k ist, aber nicht, welches wir nehmen sollen. Die Wahl ist ein Kompromiss zwischen Genauigkeit und Aufwand; drei Kriterien sind gebräuchlich.

Bemerkung 6.4.6 (Drei Kriterien für die Wahl von k)

1. *Relativer Fehler in der Spektralnorm.* Aus (6.4.4) folgt

$$\frac{\|A - A_k\|_2}{\|A\|_2} = \frac{\sigma_{k+1}}{\sigma_1},$$

denn der Nenner ist nach Satz 6.4.1 gerade σ_1 . Wir wählen das kleinste k , für das dieser Quotient unter einer Schranke bleibt.

2. *Relativer Fehler in der Frobeniusnorm.* Mit derselben Rechnung und der Identität $\|A\|_F = \sqrt{\sum_i \sigma_i^2}$ aus Korollar 3.4.4 ist

$$\frac{\|A - A_k\|_F}{\|A\|_F} = \frac{\sqrt{\sum_{i=k+1}^r \sigma_i^2}}{\sqrt{\sum_{i=1}^r \sigma_i^2}}.$$

Dieses Maß nimmt alle Richtungen zusammen, das erste nur die schlechteste.

3. *Energiekriterium.* Statt den Fehler zu beschränken, verlangen wir einen Mindestanteil an erklärter „Energie“:

$$\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} \geq p,$$

üblich sind $p = 0,9$ oder $p = 0,99$. Das ist nur eine Umformulierung von Kriterium 2, denn die linke Seite ist 1 minus dem Quadrat des relativen Frobeniusfehlers.

Kriterium 3 hat eine Schwäche: Wenn σ_1 die übrigen Singulärwerte weit überragt, ist der Ener-

gieanteil schon bei $k = 1$ nahe bei eins, obwohl die Approximation noch grob ist. Als alleiniges Kriterium taugt es deshalb wenig.

In der Praxis wählt man k oft am *Ellenbogen* (elbow): Tragen wir $\log \sigma_i$ gegen i auf, so ist das die Stelle, an der die Singulärwerte abknicken und die Kurve flach wird.

Vertiefung (optional): Typische Singulärwert-Verläufe

Bemerkung 6.4.7 (Typische Singulärwert-Verläufe)

Wie gut sich eine Matrix überhaupt komprimieren lässt, steht im Verlauf ihrer Singulärwerte. Drei Muster begegnen uns immer wieder:

1. *Schneller Abfall*, etwa $\sigma_i \approx c \cdot e^{-\alpha i}$. Wenige Werte dominieren, der Rest ist vernachlässigbar. Solche Matrizen sind der ideale Fall für eine Rang- k -Approximation.
2. *Linearer Abfall*, $\sigma_i \approx c - \alpha i$. Die Approximation gelingt noch ordentlich, der Kompressionsfaktor bleibt aber mittelmäßig.
3. *Langsamer Abfall*, $\sigma_i \approx c \cdot i^{-\alpha}$. Viele Komponenten tragen ähnlich viel bei; ein kleines k verliert dann zwangsläufig viel Information.

In der Auftragung von $\log \sigma_i$ gegen i wird ein exponentieller Abfall zur Geraden. Der Ellenbogen trennt die Richtungen, in denen Struktur steckt, von denen, in denen nur noch Rauschen sitzt, und liefert einen Startwert für k . Eine Garantie ist das nicht; manche Spektren haben keinen Ellenbogen.

1. Ein Spektrum mit langsam abfallenden Singulärwerten, $\sigma_i \approx c \cdot i^{-\alpha}$, eignet sich besonders gut für eine Rang- k -Approximation.

Antwort: Falsch

Es ist der ungünstigste Fall: Viele Komponenten tragen ähnlich viel bei, der Fehler $\sqrt{\sum_{i>k} \sigma_i^2}$ sinkt entsprechend langsam, und ein kleines k verliert echte Struktur. Gut komprimieren lässt sich der exponentielle Abfall.

Anwendung: Datenkompression

Ein Graustufenbild ist eine Matrix: Jeder Pixel ist ein Eintrag, seine Helligkeit der Wert. Farbbilder bestehen aus drei solchen Matrizen, einer pro Kanal.

Beispiel 6.4.8 (Ein Bild mit 659×512 Pixeln)

Das Bild sei $A \in \mathbb{R}^{659 \times 512}$. Vollständig gespeichert sind das

$$659 \cdot 512 = 337\,408 \text{ Zahlen (pro Kanal).}$$

Für die Rang-50-Approximation brauchen wir dagegen nur die ersten 50 Spalten von $\mathbf{U}$, die ersten 50 Singulärwerte und die ersten 50 Spalten von $\mathbf{V}$:

$$\underbrace{659 \cdot 50}_{\mathbf{U}_{50}} + \underbrace{50}_{\Sigma_{50}} + \underbrace{50 \cdot 512}_{\mathbf{V}_{50}} = 32\,950 + 50 + 25\,600 = 58\,600.$$

Das sind $58\,600 / 337\,408 \approx 17,4\%$ des Originals, wir sparen also rund 83% des Speichers. Der Speicherbedarf $k \cdot (659 + 512 + 1)$ wächst linear in k und übersteigt ab $k = 288$ die $337\,408$ Zahlen des Bildes selbst. Kompression gibt es hier nur für $k \leq 287$.

Algorithmus 6.4.9 (Kompression mit der SVD)

1. Berechne die SVD $A = U\Sigma V^T$.
2. Wähle k anhand der Kriterien aus Bemerkung 6.4.6.
3. Bilde die Approximation $A_k = U_k \Sigma_k V_k^T$.
4. Speichere nur U_k , Σ_k und V_k ; das Bild wird bei Bedarf daraus zurückgerechnet.

Interaktiv: Bildkompression mit der Rang-k-Approximation

Wie viele Rang-1-Terme braucht ein Bild? Wir probieren es an einem synthetisch erzeugten Graustufenbild aus. Der Schieber gibt k vor, die dritte Tafel zeigt die Differenz $A - A_k$ als Bild, und die beiden Kurven sind die Fehlerformeln aus (6.4.4), an diesem Bild ausgewertet.

Interaktives Element — nur in der Web-Fassung

Mit wachsendem k sinken beide Fehler. Die ersten Terme geben die großflächigen Helligkeiten wieder, die feinen Kanten stecken in den Termen mit kleinem σ_i .

Für echte Fotos gibt es unter shinyapps.io eine Shiny-App zur abgeschnittenen SVD.

Anwendung: Empfehlungssysteme

Die zweite Anwendung ist das *kollaborative Filtern* (collaborative filtering). Ein Streamingdienst kennt m Nutzer und n Filme und will für jedes Paar vorhersagen, wie gut der Film ankommt. Die Bewertungen bilden eine Matrix, in der die meisten Einträge fehlen: Fast niemand hat fast alles gesehen.

Beispiel 6.4.10 (Eine dünn besetzte Bewertungsmatrix)

Zeilen sind Nutzer, Spalten sind Filme, ein Fragezeichen steht für eine fehlende Bewertung:

$$R = \begin{pmatrix} 5 & ? & 1 & ? & 4 \\ ? & 3 & ? & 4 & ? \\ 2 & 1 & ? & ? & 5 \\ ? & 5 & 4 & 3 & ? \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

Hier sind $m = 4$ und $n = 5$, und von 20 möglichen Einträgen sind 11 bekannt. In der Praxis ist die Matrix noch weit dünner besetzt: Millionen von Nutzern, Hunderttausende von Titeln, und pro Zeile eine Handvoll Bewertungen.

Füllen wir die Lücken mit den Spaltenmitteln der bekannten Einträge, so sind das der Reihe nach 3,5, 3, 2,5, 3,5 und 4,5.

Eine Zerlegung hilft, weil Geschmack Struktur hat: Wer zwei Science-Fiction-Filme mag, mag wahrscheinlich auch den dritten. Die Vorlieben von Millionen Nutzern lassen sich deshalb durch wenige Größen wie Genres und Nutzertypen beschreiben, die Bewertungsmatrix ist also näherungsweise von kleinem Rang.

Algorithmus 6.4.11 (Empfehlungen über eine Rang-k-Approximation)

1. Ergänze die fehlenden Einträge grob, etwa durch die Spaltenmittel der bekannten Bewertungen.
2. Berechne von der aufgefüllten Matrix die Rang-k-Approximation $\mathbf{R}_k = \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^T$.
3. Lies die Vorhersagen an den zuvor fehlenden Stellen von $\mathbf{R}_k$ ab.

Bemerkung 6.4.12 (Was die Faktoren bedeuten)

- Die *rechten* Singulärvektoren $\mathbf{v}_j \in \mathbb{R}^n$ leben im Filmraum. Sie sind gelernte Genres: $\mathbf{v}_1$ könnte eine Achse von Action nach Drama beschreiben, $\mathbf{v}_2$ eine von Komödie nach Thriller. Diese Achsen hat niemand vorgegeben, sie fallen aus den Daten.
- Die *linken* Singulärvektoren $\mathbf{u}_i \in \mathbb{R}^m$ leben im Nutzerraum und geben an, wie stark die einzelnen Nutzer auf diese Genre-Achsen ansprechen.
- Die Singulärwerte σ_i gewichten, wie viel eine Achse überhaupt erklärt.

Eine Vorhersage ist damit ein gewichtetes Skalarprodukt aus Nutzerprofil und Filmprofil, summiert über die ersten k Achsen mit den Gewichten σ_i .

Interaktiv: Rang-k-Glättung einer Bewertungsmatrix

Wie gut trifft dieses Verfahren eine Bewertung, die es nicht kennt? Das Widget rechnet Beispiel 6.4.10 durch und lässt uns eine bekannte Bewertung zurückhalten; sie wird damit zur Testgröße. Der Vergleich der drei Auffüllregeln zeigt zusätzlich, wie stark die Vorhersage an Schritt 1 von Algorithmus 6.4.11 hängt.

Interaktives Element — nur in der Web-Fassung

Die Vorhersage hängt stark an der Auffüllregel, und das hat einen Grund: Schritt 1 erfindet Daten, und Schritt 2 behandelt diese Erfindungen wie Messwerte. Denn $\mathbf{R}_k$ minimiert nach Satz 6.4.4 den Fehler über *alle* Einträge, also auch über die selbst gesetzten Mittelwerte.

Vertiefung (optional): Stärken, Schwächen und neuere Verfahren

Bemerkung 6.4.13 (Stärken, Schwächen, Ausblick)

Für den Ansatz spricht einiges:

- **Speicher.** Statt $m \cdot n$ Zahlen genügen $(m + n) \cdot k + k$, und für $k \ll \min(m, n)$ ist das viel weniger.
- **Glättung.** Das Abschneiden wirkt als *Regularisierung*: Die Rang- k -Approximation kann den Zufall in einzelnen Bewertungen gar nicht nachbilden, weil ihr die Freiheitsgrade fehlen.
- **Robustheit gegen Lücken.** Auch bei sehr spärlichen Daten kann das Verfahren brauchbare Schätzungen liefern, solange die zugrunde liegende Struktur wirklich niedrigdimensional ist.

Gegen ihn spricht der Einwand oben, und neuere Verfahren umgehen ihn: Unter dem Stichwort *Matrix Completion* sucht man direkt eine Faktorisierung von kleinem Rang, die nur an den beobachteten Stellen gut passt; mit der Nebenbedingung, dass alle Faktoren nichtnegativ sind, heißt das nichtnegative Matrixfaktorisierung (NMF).

Wann lohnt sich die SVD?**Bemerkung 6.4.14 (Ideale Situationen für die SVD)**

1. *Niedrig-Rang-Strukturen:* $\text{rang}(\mathbf{A}) \ll \min(m, n)$, oder wenigstens näherungsweise.
2. *Schnell abfallende Singulärwerte:* wenige Richtungen dominieren.
3. *Überbestimmte Systeme:* $m > n$ und womöglich inkonsistent, wie bei Kleinst-Quadrate-Problemen (Kapitel 7).
4. *Datenanalyse:* Die Hauptkomponentenanalyse (PCA) lässt sich direkt aus der SVD der zentrierten Datenmatrix $\mathbf{X}$ ablesen, ohne dass wir das Kreuzprodukt $\mathbf{X}^\top \mathbf{X}$ je aufstellen müssen. Dieses Kreuzprodukt ist bis auf einen Faktor die empirische Kovarianzmatrix; ausgeführt wird die PCA in Abschnitt 8.2.
5. *Numerische Robustheit:* als Alternative zu den Normalgleichungen (Abschnitt 7.3).

Punkt 4 und Punkt 5 haben denselben Kern. Das Produkt $\mathbf{X}^\top \mathbf{X}$ zu bilden kostet Genauigkeit, denn es quadriert die Konditionszahl (Abschnitt 7.3.3). Die SVD arbeitet direkt an $\mathbf{X}$ und vermeidet diesen Schritt.

Bemerkung 6.4.15 (Rechenaufwand)

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ gilt in der Landau-Notation (Abschnitt 2.4):

- *SVD:* $O(\min(m^2 n, mn^2))$; für $m \gg n$ sind das rund $4mn^2$ Operationen.
- *Normalgleichungen:* $O(mn^2 + n^3)$; für $m \gg n$ dominiert der Aufbau von $\mathbf{A}^\top \mathbf{A}$ mit rund mn^2 Operationen.

Für $m \gg n$ ist die SVD also grob viermal so teuer. Das ist der übliche Kompromiss: Geschwindigkeit gegen Stabilität. Bei schlecht konditionierten Daten lohnt sich der Faktor.

SVD und Eigenwertzerlegung im Vergleich

In der Tabelle meint „Eigenwertzerlegung“ die Zerlegung $A = PDP^{-1}$ mit beliebigem invertierbarem P ; erst im symmetrischen Fall wird daraus die Spektralzerlegung mit orthogonalem P aus Abschnitt 3.3.

Eigenschaft	Eigenwertzerlegung	SVD
Matrixtyp	quadratisch	beliebig, $m \times n$
orthogonale Faktoren	nur für symmetrische Matrizen	immer
numerische Stabilität	kann problematisch sein	stabil
Existenz	nur für diagonalisierbare Matrizen	immer, auch für singuläre; $\sigma_i = 0$ zeigt den Rangabfall an
geometrische Deutung	Hauptachsen (im symmetrischen Fall)	optimale Koordinaten in Urbild und Bild

Selbsttest

1. Stellen wir im Rang-k-Explorer oben $k = 2$ ein. Wie viel Prozent der Energie $\sum_i \sigma_i^2$ stecken dann schon in A_2 ?

Lösung: 98.59

98,59 %. Die ersten beiden Singulärwerte des Testbilds sind 26,475 und 6,060, alle übrigen zusammen tragen nur noch den Rest bei. Trotzdem sieht die Rekonstruktion bei $k = 2$ noch sichtbar falsch aus: Der Energie-Anteil misst Quadrate und wird deshalb schon von den großflächigen Helligkeiten fast ausgeschöpft, während die feinen Kanten in den kleinen σ_i stecken. Ein Kriterium allein reicht für die Wahl von k nicht (Bemerkung 6.4.6).

2. Halten wir im Empfehlungs-Widget Adas Bewertung für „Sternenstaub“ zurück, also die 5 links oben, und setzen wir $k = 2$ bei Auffüllung mit dem Filmmittel. Welche Vorhersage steht danach in diesem Feld?

Lösung: 1.8

Rund 1,8, bei einem wahren Wert von 5. Der Grund ist Schritt 1 von Algorithmus 6.4.11: Ohne Adas Bewertung sinkt das Mittel der Spalte „Sternenstaub“ von 3,5 auf 2,0, und dieser selbst gesetzte Wert bestimmt die Vorhersage fast allein. Bei elf bekannten Bewertungen sagt das Ergebnis mehr über die Füllregel als über Ada; das ist der Einwand gegen das Auffüllen in Schritt 1.

3. Die Spektralnorm $\|A\|_2$ ist der betragsgrößte Eigenwert von A .

Antwort: Falsch

Sie ist der größte *Singulärwert* (Satz 6.4.1). Für symmetrische Matrizen fallen beide Größen bis aufs Vorzeichen zusammen, sonst nicht. Gegenbeispiel: $A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ hat den doppelten Eigenwert 0, aber $A^T A = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$ und damit $\|A\|_2 = 1$. Für nicht quadratische Matrizen existieren Eigenwerte ohnehin nicht.

4. Unter allen Matrizen vom Rang höchstens k minimiert A_k den Fehler gleichzeitig in der Frobenius- und in der Spektralnorm.

Antwort: Wahr

So steht es in Satz 6.4.4: Zwei verschiedene Gütemaße führen zur selben Lösung. Der einzige Minimierer ist A_k allerdings nicht (Bemerkung 6.4.5).

5. Für $\mathbf{A} = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}$ ist $\begin{pmatrix} 2,5 & 0 \\ 0 & 2,5 \end{pmatrix}$ die beste Rang-1-Approximation.

Antwort: Falsch

Diese Matrix hat Rang 2, ist also nicht zugelassen. Die Singulärwerte von $\mathbf{A}$ sind $\sigma_1 = 3$ und $\sigma_2 = 2$, die beste Rang-1-Approximation ist $\mathbf{A}_1 = \begin{pmatrix} 3 & 0 \\ 0 & 0 \end{pmatrix}$, und der Fehler beträgt $\|\mathbf{A} - \mathbf{A}_1\|_2 = \sigma_2 = 2$.

6. Solange $k < \min(m, n)$ gilt, spart die Rang-k-Approximation immer Speicher.

Antwort: Falsch

Sie kostet $k(m + n + 1)$ Zahlen gegen mn für die volle Matrix, und das ist für großes k mehr. Bei $m = n = 100$ und $k = 50$ etwa speichern wir $50 \cdot 201 = 10\,050$ statt $10\,000$ Zahlen. Ein Gewinn entsteht erst für $k < mn/(m + n + 1) \approx 49,8$, hier also für $k \leq 49$.

7. Ist $\sigma_{k+1} = 0$, so ist die Rang-k-Approximation exakt.

Antwort: Wahr

Weil die Singulärwerte absteigend sortiert sind, folgt aus $\sigma_{k+1} = 0$ sofort $\text{rang}(\mathbf{A}) \leq k$. Die Summenform (6.4.2) hat dann höchstens k Summanden, also ist $\mathbf{A}_k = \mathbf{A}$. Satz 6.4.4 selbst setzt $k < r$ voraus und greift hier nicht mehr. Setzen wir $\sigma_i = 0$ für $i > r$, sagt (6.4.4) aber dasselbe: Der Fehler ist null.

Vertiefung: vgl. Heath §3.6 (Singulärwertzerlegung und ihre Anwendungen) sowie MML §4.5 und §4.6 (SVD und Matrixapproximation).

6.5 Zusammenfassung

Was wir gelernt haben

Bemerkung 6.5.1 (Die fünf Kernkonzepte)

1. **Die SVD erweitert die Eigenwertzerlegung.** Sie verlangt weder eine quadratische noch eine symmetrische Matrix und existiert für jedes $\mathbf{A} \in \mathbb{R}^{m \times n}$ (Abschnitt 6.1).
2. **Singulärwerte sind Wurzeln von Eigenwerten:** $\sigma_i(\mathbf{A}) = \sqrt{\lambda_i(\mathbf{A}^\top \mathbf{A})}$ (Definition 6.2.4). Der Umweg über $\mathbf{A}^\top \mathbf{A}$ verwandelt eine beliebige Matrix in eine symmetrische, auf die der Spektralsatz passt.
3. **Der Hauptsatz:** $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top$ mit orthogonalem $\mathbf{U} \in \mathbb{R}^{m \times m}$, orthogonalem $\mathbf{V} \in \mathbb{R}^{n \times n}$ und „diagonalem“ $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ (Satz 6.2.13).
4. **Reduzierte SVD:** $\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top$ mit $r = \text{rang}(\mathbf{A})$. Die Nullblöcke von $\mathbf{\Sigma}$ tragen nichts bei und dürfen weg (Definition 6.3.2).
5. **Pseudoinverse:** $\mathbf{A}^+ = \mathbf{V}_r \mathbf{\Sigma}_r^{-1} \mathbf{U}_r^\top$, die Verallgemeinerung der Inversen auf beliebige Matrizen (Definition 6.3.5).

Zwei Anwendungen tragen das Kapitel. Die Pseudoinverse löst Kleinste-Quadrate-Probleme über $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$, auch wenn die Normalgleichungen mangels vollen Spaltenrangs versagen (Bemerkung 6.3.12). Die abgeschnittene Zerlegung liefert die beste Approximation niedrigen Rangs, deren Fehler die weggelassenen Singulärwerte beziffern (Abschnitt 6.4). Sie ist das Standardwerkzeug für Datenkompression und Datenanalyse, von der Hauptkomponentenanalyse (Abschnitt 8.2) bis zum Empfehlungssystem (Beispiel 6.4.10). Wer die SVD einer Matrix kennt, kennt ihren Rang, ihre Norm, ihre Kondition, ihre fundamentalen Unterräume und die beste Näherung jeder Stufe.

Vertiefung (optional): Querverbindungen zu anderen Kapiteln

- *Normen:* Der größte Singulärwert ist die Spektralnorm, $\|\mathbf{A}\|_2 = \sigma_1$ (Abschnitt 3.3); die Frobeniusnorm nimmt alle Singulärwerte zusammen, $\|\mathbf{A}\|_F = \sqrt{\sum_i \sigma_i^2}$ (Abschnitt 3.4). Für quadratische, invertierbare Matrizen ist der Quotient σ_1/σ_n die Spektralkondition $\kappa_2(\mathbf{A})$ (Abschnitt 3.5); sie beschränkt, wie stark ein relativer Datenfehler in der Lösung anwachsen kann (Abschnitt 4.2).
- *Matrixzerlegungen:* LU (Abschnitt 5.3) und Cholesky (Abschnitt 5.4) zerlegen, um Gleichungssysteme schnell zu lösen. Die SVD zerlegt, um die Geometrie einer Abbildung sichtbar zu machen. Sie ist die teuerste der drei und die einzige, die für jede Matrix existiert.

Praktische Hinweise

Drei Zuschnitte der Zerlegung sind gebräuchlich:

Variante	Zerlegung	Formate	Wozu
volle SVD	$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$	$\mathbf{U}$ ist $m \times m$, $\mathbf{V}$ ist $n \times n$	exakt, alle fundamentalen Unterräume auf einmal
reduzierte SVD	$\mathbf{A} = \mathbf{U}_r\mathbf{\Sigma}_r\mathbf{V}_r^\top$	$\mathbf{U}_r$ ist $m \times r$, $\mathbf{V}_r$ ist $n \times r$	exakt, ohne die Nullblöcke
truncated SVD	$\mathbf{A} \approx \mathbf{A}_k = \mathbf{U}_k\mathbf{\Sigma}_k\mathbf{V}_k^\top, k < r$	$\mathbf{U}_k$ ist $m \times k$, $\mathbf{V}_k$ ist $n \times k$	Approximation, Kompression

Nur die dritte Variante verliert Information, und wie viel, sagen die abgeschnittenen Singulärwerte; die Wahl von k ist eine Modellierungsentscheidung (Bemerkung 6.4.6).

Die Definition der Singulärwerte führt über die Eigenwerte von $\mathbf{A}^\top \mathbf{A}$, als *Rechenweg* taugt dieser Umweg aber nicht. Das Produkt quadriert die Kondition, $\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2$, und beim Aufstellen gehen kleine Beiträge neben großen im Rundungsfehler unter. Als Faustregel lassen sich über $\mathbf{A}^\top \mathbf{A}$ Singulärwerte unterhalb von $\sqrt{\varepsilon} \cdot \sigma_1 \approx 1,5 \cdot 10^{-8} \cdot \sigma_1$ nicht mehr bestimmen.

Vertiefung (optional): Der Umweg über $\mathbf{A}^\top \mathbf{A}$ an einem Beispiel

Ist $\mathbf{A}^\top \mathbf{A}$ erst aufgestellt, müsste eine Differenz fast gleicher Zahlen den kleinen Singulärwert liefern, und diese Auslöschung kann den Rundungsverlust nicht rückgängig machen (Abschnitt 4.3).

Beispiel 6.5.2 (Der Umweg über $A^T A$)

Betrachten wir

$$A = \begin{pmatrix} 1 & 1 \\ \delta & 0 \\ 0 & \delta \end{pmatrix}, \quad \delta = 10^{-8}, \quad A^T A = \begin{pmatrix} 1 + \delta^2 & 1 \\ 1 & 1 + \delta^2 \end{pmatrix}.$$

Eine Matrix der Bauart $\begin{pmatrix} a & b \\ b & a \end{pmatrix}$ hat die Eigenwerte $a + b$ und $a - b$, hier also $(1 + \delta^2) + 1 = 2 + \delta^2$

und $(1 + \delta^2) - 1 = \delta^2$. Damit besitzt A die Singulärwerte $\sigma_1 = \sqrt{2 + \delta^2} \approx 1,4142$ und $\sigma_2 = \delta = 10^{-8}$; die Matrix hat Rang 2. Der kleinere Eigenwert ist eine Differenz fast gleicher Zahlen. Er hängt allein an dem Summanden δ^2 im Diagonaleintrag, und der ist gefährdet.

In doppelter Genauigkeit geht das schief. Der Abstand von 1 zur nächstgrößeren darstellbaren Zahl ist die Maschinengenauigkeit $\varepsilon \approx 2,22 \cdot 10^{-16}$, und gerundet wird zur nächstgelegenen. Weil $\delta^2 = 10^{-16}$ kleiner als die halbe Schrittweite $1,11 \cdot 10^{-16}$ ausfällt, ergibt sich $\text{fl}(1 + \delta^2) = 1$. Die berechnete Matrix ist

$$\widehat{A^T A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \quad \text{mit den Eigenwerten 2 und 0.}$$

Die Rechnung meldet $\sigma_2 = 0$ und damit Rang 1. Ein Verfahren, das direkt mit A arbeitet, bestimmt σ_2 dagegen bis auf einen absoluten Fehler der Größenordnung $\varepsilon \cdot \sigma_1$, also auf etwa $3 \cdot 10^{-16}$ genau, und sieht den Rang 2.

Die gebräuchlichen Verfahren arbeiten deshalb direkt mit A und benutzen nur orthogonale Transformationen, die alle Singulärwerte unverändert lassen (Satz 3.4.7); Standard ist der Algorithmus von Golub und Reinsch. Bei sehr großen Matrizen berechnen wir nur die k größten Singulärwerte samt Singulärvektoren (*truncated SVD*), ohne A je vollständig zu zerlegen. In R stehen beide Wege bereit:

```
s <- svd(A)                # s$d: Singulärwerte, s$u und s$v: Singulärvektoren
k <- 5
A_k <- s$u[, 1:k] %*% diag(s$d[1:k], nrow = k) %*% t(s$v[, 1:k])

irlba::irlba(A, nv = k)     # nur die k größten, iterativ (Lanczos)
irlba::svdr(A, k)          # dasselbe, randomisiert
```

Selbsttest

1. Für $A \in \mathbb{R}^{m \times n}$ ist $A^T A \in \mathbb{R}^{m \times m}$.

Antwort: Falsch

Die Formate ergeben $(n \times m) \cdot (m \times n)$, also ist $A^T A$ eine $n \times n$ -Matrix (Satz 6.2.1). Die $m \times m$ -Matrix ist AA^T . In Beispiel 6.2.3 mit $m = 3$ und $n = 2$ war $A^T A$ entsprechend 2×2 groß.

2. Für $A \in \mathbb{R}^{m \times n}$ ist $A^T A$ symmetrisch.

Antwort: Wahr

Transponieren dreht die Reihenfolge um: $(A^T A)^T = A^T (A^T)^T = A^T A$ (Satz 6.2.1). Das gilt für jede Matrix A .

3. Die Eigenwerte von $A^T A$ sind die Singulärwerte von A .

Antwort: Falsch

Sie sind deren *Quadrate*: $\lambda_i = \sigma_i^2$, oder umgekehrt $\sigma_i = \sqrt{\lambda_i}$ (Definition 6.2.4). In Beispiel 6.2.6 gehören zu $\lambda_1 \approx 9,531$ und $\lambda_2 \approx 1,469$ die Singulärwerte $\sigma_1 \approx 3,087$ und $\sigma_2 \approx 1,212$.

4. Jede quadratische Matrix $A \in \mathbb{R}^{n \times n}$ ist diagonalisierbar.

Antwort: Falsch

Der Jordan-Block $A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ hat nur den Eigenwert 0, und dessen Eigenraum ist die Gerade $\text{span}\{e_1\}$. Es gibt also keine Basis des $\mathbb{R}^2$ aus Eigenvektoren. Symmetrie ist dabei *hinreichend* für Diagonalisierbarkeit, aber nicht notwendig: Die unsymmetrische Matrix $\begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$ aus Beispiel 6.1.1 hat die zwei verschiedenen Eigenwerte 2 und 1 und ist damit diagonalisierbar, nur nicht *orthogonal* diagonalisierbar (Abschnitt 6.1).

5. $A^T A$ ist immer orthogonal diagonalisierbar.

Antwort: Wahr

$A^T A$ ist symmetrisch, und der Spektralsatz liefert für symmetrische Matrizen eine Orthonormalbasis aus Eigenvektoren, also $A^T A = V \Lambda V^T$ mit orthogonalem V (Korollar 6.2.2). Darauf beruht die Konstruktion der SVD: Die Spalten von V sind die rechten Singulärvektoren.

Vertiefung: Heath §3.6 (Singulärwertzerlegung, Pseudoinverse und ihre Anwendungen); vgl. MML §4.5 und §4.6 für die Zerlegung selbst und die Approximation niedrigen Rangs.

6.6 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 3.30	Reduzierte SVD eines Spalten- und eines Zeilenvektors	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 4.8	SVD einer 2×3 -Matrix von Hand	mittel, ca. 30 Min.
Heath Exercise 3.33	Pseudoinverse in drei Spezialfällen	mittel, ca. 30 Min.
Heath Exercise 3.34	Pseudoinverse einer fast singulären Matrix	leicht, ca. 15 Min.
Schaback/Wendland Aufgabe 4.4	Tychonoff-Regularisierung und ihre Berechnung via SVD	mittel, ca. 30 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 4.36	Singulärwerte als Eigenwerte der erweiterten Matrix	mittel, ca. 30 Min.

Bücher: Heath: *Scientific Computing* (2. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.); Deisenroth et al. (MML): *Mathematics for Machine Learning*.

Kleinste Quadrate

7.1 Kleinste Quadrate: Problem und Motivation

Die linearen Gleichungssysteme $\mathbf{Ax} = \mathbf{b}$ der bisherigen Kapitel hatten eine quadratische Matrix, also genauso viele Gleichungen wie Unbekannte. In der Statistik haben wir dagegen fast immer *viel mehr* fehlerbehaftete Beobachtungen als Modellparameter. Ein solches *überbestimmtes* System (engl. *overdetermined*) hat in aller Regel keine exakte Lösung. Wir suchen deshalb den Vektor, der alle Gleichungen *möglichst gut* erfüllt, gemessen an der euklidischen Norm des Fehlers. Das ist die *Methode der Kleinsten Quadrate* (engl. *least squares*). Dieses Kapitel behandelt, wie wir solche Probleme *numerisch* stabil und effizient lösen.

Wir bauen auf früheren Kapiteln auf: Kondition und Konditionszahl $\kappa(\mathbf{A})$, Matrixnormen (besonders $\|\cdot\|_2$), Orthogonalmatrizen, die LU- und Cholesky-Zerlegung sowie die Singulärwertzerlegung $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^\top$ (auch in reduzierter Form) mit der Pseudoinversen $\mathbf{A}^+$. Aus der linearen Algebra brauchen wir orthogonale Projektionen auf Unterräume und die Normalengleichungen, aus der Statistik das lineare Regressionsmodell und die Methode der Kleinsten Quadrate (OLS), die wir hier aus numerischer Sicht betrachten.

Vom Gleichungssystem zum Ausgleichsproblem

Definition 7.1.1 (Kleinste-Quadrate-Problem, KQ-Problem)

Gegeben seien eine Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ und ein Vektor $\mathbf{b} \in \mathbb{R}^m$. Gesucht ist ein Vektor $\hat{\mathbf{x}} \in \mathbb{R}^n$, der die Norm des *Residuums* minimiert:

$$\hat{\mathbf{x}} \in \arg \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2 .$$

Da $t \mapsto t^2$ auf $[0, \infty)$ streng monoton wächst, können wir genauso gut $\|\mathbf{Ax} - \mathbf{b}\|_2^2$ minimieren: dieselben Minimalstellen, aber ohne Wurzel. Ausgeschrieben ist das eine Summe von Quadraten,

$$\|\mathbf{Ax} - \mathbf{b}\|_2^2 = \sum_{i=1}^m ((\mathbf{Ax})_i - b_i)^2 ,$$

daher der Name der Methode.

Bemerkung 7.1.2

Hat das Gleichungssystem $\mathbf{Ax} = \mathbf{b}$ eine exakte Lösung $\mathbf{x}^*$, dann gilt $\|\mathbf{Ax}^* - \mathbf{b}\|_2 = 0$, und $\mathbf{x}^*$ löst automatisch auch das KQ-Problem. Das KQ-Problem verallgemeinert also das Lösen von Gleichungssystemen. Interessant ist es vor allem für „Gleichungssysteme“ $\mathbf{Ax} \approx \mathbf{b}$, die

keine exakte Lösung besitzen: typischerweise überbestimmte Systeme mit $m > n$, bei denen $\mathbf{b}$ wegen Messfehlern nicht im Spaltenraum von $\mathbf{A}$ liegt.

Motivation: Regression und Ausgleichsrechnung

Die KQ-Methode gehört zu den Grundlagen von Statistik und Machine Learning: Jedes Mal, wenn wir ein lineares Modell mit OLS an Daten anpassen, lösen wir ein KQ-Problem.

Beispiel 7.1.3 (Lineare Regression)

Wir wollen Immobilienpreise anhand der Wohnfläche vorhersagen. Unsere Daten sind n Beobachtungen (x_i, y_i) mit x_i = Fläche in m^2 und y_i = Preis in €. Als Modell wählen wir eine Gerade mit Fehlerterm ϵ_i :

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, \dots, n.$$

In Matrixform lauten die n Modellgleichungen $\mathbf{b} \approx \mathbf{A}\boldsymbol{\beta}$ mit

$$\mathbf{A} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}.$$

Sobald $n > 2$ Datenpunkte nicht alle exakt auf einer gemeinsamen Geraden liegen (bei verauschten Messungen praktisch immer), liegt $\mathbf{b}$ nicht im Spaltenraum von $\mathbf{A}$: Kein Parameterpaar (β_0, β_1) erfüllt alle n Gleichungen zugleich. Die KQ-Lösung

$$\hat{\boldsymbol{\beta}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$$

minimiert stattdessen die Summe der quadrierten Abweichungen $\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = \|\mathbf{A}\hat{\boldsymbol{\beta}} - \mathbf{b}\|_2^2$ und ist damit der Kleinste-Quadrate-Schätzer (OLS) aus der Einführungsvorlesung. Die Lösungsformel begründen die Sätze 7.1.5 und 7.1.7.

KQ-Probleme stecken auch in *generalisierten linearen Modellen* und *additiven Modellen* (dort löst man iterativ gewichtete KQ-Probleme), im Training neuronaler Netze (der quadratische Verlust ist ein KQ-Kriterium), in der Computer Vision (Kamerakalibrierung, 3D-Rekonstruktion aus 2D-Bildern), im Signal Processing (De-Noising, Signalschätzung) und in der Geodäsie (GPS-Positionsbestimmung gleicht widersprüchliche Distanzmessungen aus).

Interaktiv: Wie gut passt die Gerade?

Jeder Punkt im folgenden Bild ist ein (fiktiver) Wohnungsverkauf, Fläche gegen Preis in Tsd. €; die blaue Gerade gehört zum eingestellten Parameterpaar (β_0, β_1) , jede violette Strecke ist ein Residuum $y_i - \beta_0 - \beta_1 x_i$. Wie nah kommen wir mit Augenmaß an das Minimum heran, das Definition 7.1.1 über *alle* Paare verlangt?

Interaktives Element — nur in der Web-Fassung

Mit Augenmaß kommen wir bis auf wenige Prozent an das Optimum heran, unter die Quadratsumme der KQ-Geraden aber nie.

Die Geometrie: Projektion auf den Spaltenraum

Interaktiv: Die Projektion aus verschiedenen Blickrichtungen

Während $\mathbf{x}$ alle Vektoren in $\mathbb{R}^n$ durchläuft, durchläuft $\mathbf{Ax}$ genau den Spaltenraum $\text{col}(\mathbf{A}) \subseteq \mathbb{R}^m$, also alle Linearkombinationen der Spalten von $\mathbf{A}$. Das KQ-Problem fragt daher: Welcher Punkt des Unterraums $\text{col}(\mathbf{A})$ liegt am nächsten an $\mathbf{b}$? Aus der linearen Algebra wissen wir: der Fußpunkt des Lots, also die orthogonale Projektion von $\mathbf{b}$ auf $\text{col}(\mathbf{A})$. Links steht die übliche Lehrbuchskizze, rechts dieselbe Konfiguration im Raum, drehbar. Die linke Skizze wirkt auch wegen der günstig gewählten Blickrichtung so plausibel.

Interaktives Element — nur in der Web-Fassung

Drehen wir die rechte Tafel, bleibt dieselbe Projektion sichtbar: Der Lotfuß liegt im Spaltenraum, das Residuum steht senkrecht darauf.

Satz 7.1.4 (KQ-Lösung als Projektion)

Die Lösungsmenge des KQ-Problems zu $\mathbf{A}$ und $\mathbf{b}$ gleicht der Lösungsmenge des linearen Gleichungssystems

$$\mathbf{Ax} = \hat{\mathbf{b}} \quad \text{mit } \hat{\mathbf{b}} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}.$$

Vertiefung (optional): Beweis der Projektionseigenschaft

Beweis.

- (1) Wir zerlegen $\mathbf{b}$ orthogonal bezüglich $S := \text{col}(\mathbf{A})$:

$$\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r}, \quad \hat{\mathbf{b}} = \text{proj}_S \mathbf{b} \in S, \quad \mathbf{r} \perp S.$$

$\mathbb{R}^m = \text{col}(\mathbf{A}) \oplus \text{col}(\mathbf{A})^\perp$: Zerlegung in Unterraum und orthogonales Komplement existiert und ist eindeutig

- (2) Für ein beliebiges $\mathbf{x} \in \mathbb{R}^n$ schreiben wir das Residuum als

$$\mathbf{b} - \mathbf{Ax} = \underbrace{(\hat{\mathbf{b}} - \mathbf{Ax})}_{\in S} + \underbrace{\mathbf{r}}_{\perp S}.$$

$\mathbf{Ax} \in S$ und $\hat{\mathbf{b}} \in S$; S ist ein Untervektorraum, also liegt auch die Differenz in S

- (3)

$$\|\mathbf{b} - \mathbf{Ax}\|_2^2 = \|\hat{\mathbf{b}} - \mathbf{Ax}\|_2^2 + \|\mathbf{r}\|_2^2 \geq \|\mathbf{r}\|_2^2.$$

Satz des Pythagoras: für $\mathbf{u} \perp \mathbf{v}$ gilt $\|\mathbf{u} + \mathbf{v}\|_2^2 = \|\mathbf{u}\|_2^2 + \|\mathbf{v}\|_2^2$

- (4) Die untere Schranke $\|\mathbf{r}\|_2^2$ hängt nicht von $\mathbf{x}$ ab, und Gleichheit gilt genau für $\mathbf{Ax} = \hat{\mathbf{b}}$. Also minimiert $\mathbf{x}$ das KQ-Kriterium genau dann, wenn $\mathbf{Ax} = \hat{\mathbf{b}}$ gilt.

$$\|\mathbf{v}\|_2 = 0 \Leftrightarrow \mathbf{v} = \mathbf{0} \text{ (Definitheit der Norm)}$$

□

Zerlegen wir $\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r}$ mit $\mathbf{r} \perp \text{col}(\mathbf{A})$, so ist das optimale Residuum $\mathbf{b} - \mathbf{Ax}$ genau der *senkrechte* Anteil $\mathbf{r}$: der Teil der Daten, den das Modell prinzipiell nicht erklären kann. Das Gleichungssystem

$A\hat{\mathbf{x}} = \hat{\mathbf{b}}$ ist stets lösbar (denn $\hat{\mathbf{b}} \in \text{col}(\mathbf{A})$), eindeutig aber nur, wenn die Spalten von $\mathbf{A}$ linear unabhängig sind.

Interaktiv: Wo genau steht das Residuum senkrecht?

Das kleinste mögliche KQ-Problem: $m = 2, n = 1$, die Matrix hat als einzige Spalte $\mathbf{a} = (3, 1)^\top$, gesucht ist ein einzelner Skalar x , und $\text{col}(\mathbf{A})$ ist die graue Ursprungsgerade. Für welches x wird $\|\mathbf{r}\|_2^2$ am kleinsten, und welchen Winkel bildet das Residuum dort?

Interaktives Element — nur in der Web-Fassung

An genau einer Stelle steht $\mathbf{r}$ senkrecht auf $\text{col}(\mathbf{A})$, und dort ist $\|\mathbf{r}\|_2^2$ am kleinsten; links und rechts davon wird das Residuum wieder länger. Das ist Satz 7.1.4 als Bild.

Normalengleichungen und eindeutige Lösung

Satz 7.1.4 ist geometrisch anschaulich, aber unpraktisch: Um $\hat{\mathbf{b}}$ auszurechnen, müssten wir die Projektion schon kennen. Die Orthogonalitätsbedingung lässt sich aber in ein Gleichungssystem übersetzen, das nur $\mathbf{A}$ und $\mathbf{b}$ enthält: die aus der linearen Algebra bekannten Normalengleichungen.

Satz 7.1.5 (Normalengleichungen)

Die Lösungsmenge des KQ-Problems gleicht der Lösungsmenge der *Normalengleichungen*

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}. \quad (7.1.1)$$

Beweis.

(1)

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} \Leftrightarrow \mathbf{b} - \mathbf{A}\hat{\mathbf{x}} = \mathbf{r} \perp \text{col}(\mathbf{A}).$$

Satz 7.1.4 mit der Zerlegung $\mathbf{b} = \hat{\mathbf{b}} + \mathbf{r}$: Genau dann besteht das Residuum nur aus dem zu $\text{col}(\mathbf{A})$ senkrechten Anteil

(2) Senkrecht auf dem ganzen Spaltenraum zu stehen heißt, senkrecht auf jeder einzelnen Spalte $\mathbf{a}_j$ zu stehen:

$$\mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \perp \text{col}(\mathbf{A}) \Leftrightarrow \mathbf{a}_j^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = 0 \quad \forall j \Leftrightarrow \mathbf{A}^\top (\mathbf{b} - \mathbf{A}\hat{\mathbf{x}}) = \mathbf{0}.$$

$\text{col}(\mathbf{A}) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\}$: senkrecht auf dem Spann heißt senkrecht auf jedem Erzeuger; $\mathbf{A}^\top \mathbf{v}$ stapelt gerade die Skalarprodukte $\mathbf{a}_j^\top \mathbf{v}$

(3)

$$\mathbf{A}^\top \mathbf{b} - \mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{0} \Leftrightarrow \mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Ausmultiplizieren und Umstellen

□

Vertiefung (optional): Die Normalgleichungen aus der Analysis**Bemerkung 7.1.6 (Analysis-Perspektive)**

Dieselben Gleichungen liefert die Analysis ohne Geometrie: Die Zielfunktion $g(\mathbf{x}) = \|\mathbf{Ax} - \mathbf{b}\|_2^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} - 2 \mathbf{b}^\top \mathbf{Ax} + \mathbf{b}^\top \mathbf{b}$ ist eine konvexe quadratische Funktion mit Gradient

$$\nabla g(\mathbf{x}) = 2 \mathbf{A}^\top \mathbf{Ax} - 2 \mathbf{A}^\top \mathbf{b}.$$

Nullsetzen ergibt exakt (7.1.1); wegen der Konvexität ist die notwendige Bedingung auch hinreichend. Diese Sichtweise begegnet uns in Kapitel 12 wieder (vgl. MML §7.1).

Ob die Lösung eindeutig ist, entscheidet der Rang von $\mathbf{A}$.

Satz 7.1.7 (Eindeutige Lösung bei vollem Spaltenrang)

Falls $\text{rang}(\mathbf{A}) = n$, ist $\mathbf{A}^\top \mathbf{A}$ invertierbar und das KQ-Problem hat die eindeutige Lösung

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} =: \mathbf{A}^+ \mathbf{b}.$$

Vertiefung (optional): Beweis der Eindeutigkeit

Beweis.

- (1) Sei $\mathbf{x} \neq \mathbf{0}$ beliebig. Wegen $\text{rang}(\mathbf{A}) = n$ sind die Spalten von $\mathbf{A}$ linear unabhängig, also $\mathbf{Ax} \neq \mathbf{0}$.
volle Spaltenzahl im Rang $\implies$ Spalten linear unabhängig $\implies$ Kern = $\{\mathbf{0}\}$

- (2) Damit ist $\mathbf{A}^\top \mathbf{A}$ symmetrisch und positiv definit:

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} = \|\mathbf{Ax}\|_2^2 > 0 \quad \text{für alle } \mathbf{x} \neq \mathbf{0}.$$

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} = (\mathbf{Ax})^\top (\mathbf{Ax}); \text{Definitheit der Norm}$$

- (3) Eine positiv definite Matrix ist invertierbar. Die Normalgleichungen (7.1.1) haben daher genau eine Lösung, und Auflösen liefert $\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$.

$$\text{positiv definit} \implies \text{alle Eigenwerte} > 0 \implies \det(\mathbf{A}^\top \mathbf{A}) \neq 0$$

□

Die Matrix $\mathbf{A}^+ = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$ ist die Pseudoinverse aus Kapitel 6, hier für den Fall $\text{rang}(\mathbf{A}) = n$; für quadratisches, invertierbares $\mathbf{A}$ ist $\mathbf{A}^+ = \mathbf{A}^{-1}$. Wie wir $\hat{\mathbf{x}}$ *numerisch* am besten berechnen (über die Normalgleichungen jedenfalls *nicht* immer), behandeln die Abschnitte 7.3 bis 7.6; zuvor klärt Abschnitt 7.2, wie gut das Problem *konditioniert* ist.

Vertiefung (optional): Rechenbeispiel mit drei Wohnungen

Beispiel 7.1.8 (Rechenbeispiel: Regressionsgerade durch drei Punkte)

Drei Wohnungen wurden verkauft: 50 m^2 für 250, 75 m^2 für 350 und 100 m^2 für 500 (Preise in Tsd. €). Mit dem Modell aus Beispiel 7.1.3:

$$\mathbf{A} = \begin{pmatrix} 1 & 50 \\ 1 & 75 \\ 1 & 100 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 250 \\ 350 \\ 500 \end{pmatrix}.$$

Wir bilden die Bausteine der Normalgleichungen:

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 3 & 225 \\ 225 & 18\,125 \end{pmatrix}, \quad \mathbf{A}^\top \mathbf{b} = \begin{pmatrix} 1\,100 \\ 88\,750 \end{pmatrix}.$$

Die beiden Spalten von $\mathbf{A}$ sind linear unabhängig, nach Satz 7.1.7 ist die Lösung also eindeutig. Auflösen des 2×2 -Systems $\mathbf{A}^\top \mathbf{A} \hat{\boldsymbol{\beta}} = \mathbf{A}^\top \mathbf{b}$ liefert

$$\hat{\boldsymbol{\beta}} = \begin{pmatrix} -25/3 \\ 5 \end{pmatrix} \approx \begin{pmatrix} -8,33 \\ 5 \end{pmatrix}.$$

Jeder Quadratmeter kostet also geschätzt 5 000 € mehr. Zur Probe berechnen wir die angepassten Werte und das Residuum:

$$\hat{\mathbf{b}} = \mathbf{A} \hat{\boldsymbol{\beta}} = \frac{1}{3} \begin{pmatrix} 725 \\ 1\,100 \\ 1\,475 \end{pmatrix} \approx \begin{pmatrix} 241,7 \\ 366,7 \\ 491,7 \end{pmatrix}, \quad \mathbf{r} = \mathbf{b} - \hat{\mathbf{b}} = \frac{1}{3} \begin{pmatrix} 25 \\ -50 \\ 25 \end{pmatrix}.$$

Tatsächlich gilt $\mathbf{A}^\top \mathbf{r} = \mathbf{0}$: Die Residuen summieren sich zu $(25 - 50 + 25)/3 = 0$, und ebenso ist $\sum_{i=1}^n x_i r_i = (50 \cdot 25 - 75 \cdot 50 + 100 \cdot 25)/3 = 0$. Das Residuum steht also senkrecht auf beiden Spalten, wie Satz 7.1.5 verlangt.

Selbsttest

Im Folgenden sei $\text{rang}(\mathbf{A}) = n$, $m > n$ und $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$.

1. $\mathbf{A} \mathbf{A}^+ = \mathbf{I}_m$

Antwort: Falsch

$\mathbf{A} \mathbf{A}^+ = \mathbf{A} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top$ ist die Projektionsmatrix auf $\text{col}(\mathbf{A})$; die Identität auf $\mathbb{R}^m$ ist das nur, wenn $\text{col}(\mathbf{A}) = \mathbb{R}^m$ gilt, also für invertierbares quadratisches $\mathbf{A}$. (Richtig ist dagegen stets $\mathbf{A}^+ \mathbf{A} = \mathbf{I}_n$ bei vollem Spaltenrang.)

2. $\mathbf{A} \mathbf{A}^+ \mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}$

Antwort: Wahr

$\mathbf{A} \mathbf{A}^+ \mathbf{b} = \mathbf{A} \hat{\mathbf{x}} = \hat{\mathbf{b}}$: die KQ-Lösung bildet $\mathbf{b}$ gerade auf seine Projektion in den Spaltenraum ab (Satz 7.1.4).

3. $\mathbf{r} = \mathbf{b} - \mathbf{A} \hat{\mathbf{x}} \perp \text{col}(\mathbf{A})$

Antwort: Wahr

Das ist die Aussage der Normalgleichungen: $\mathbf{A}^\top (\mathbf{b} - \mathbf{A} \hat{\mathbf{x}}) = \mathbf{0}$ heißt, das Residuum steht senkrecht auf allen Spalten von $\mathbf{A}$.

4. $\mathbf{b} = \text{proj}_V \mathbf{b} + \text{proj}_{V^\perp} \mathbf{b}$ für jeden Untervektorraum $V \subseteq \mathbb{R}^m$

Antwort: Wahr

Wegen $\mathbb{R}^m = V \oplus V^\perp$ zerfällt jeder Vektor eindeutig in seine Anteile in V und im orthogonalen Komplement $V^\perp$.

5. Im Miniaturbeispiel oben ($\mathbf{a} = (3, 1)^\top$, $\mathbf{b} = (1, 2)^\top$) schieben wir den Kandidaten so weit, bis das Residuum senkrecht steht. Welchen Wert hat dort $\|\mathbf{r}\|_2^2$?

Lösung: 2.5

Der senkrechte Stand wird bei $x = 1/2$ erreicht, also $\mathbf{r} = (1, 2)^\top - \frac{1}{2}(3, 1)^\top = (-0,5; 1,5)^\top$ und $\|\mathbf{r}\|_2^2 = 0,25 + 2,25 = 2,5$. Das ist das Minimum aus Satz 7.1.4; jeder andere Kandidat liefert einen größeren Wert.

Vertiefung: Heath §3.1–3.2; MML §7.1 (Gradienten-Perspektive) und §9.2 (lineare Regression aus statistischer Sicht).

7.2 Kondition des Kleinste-Quadrate-Problems

Bevor wir Algorithmen entwickeln, fragen wir wie bei den linearen Gleichungssystemen: Wie empfindlich reagiert die Lösung $\hat{\mathbf{x}}$ auf kleine Störungen der Eingaben? Die Antwort gibt die Kondition des Problems. Sie ist eine Eigenschaft des Problems, nicht des Lösungswegs, und legt fest, welche Genauigkeit wir von *jedem* Algorithmus bestenfalls erwarten dürfen. Gestört sein können zwei Eingaben, der Datenvektor $\mathbf{b}$ und die Matrix $\mathbf{A}$; wir behandeln beide Fälle getrennt.

Vorbemerkungen

Wir betrachten KQ-Probleme $\mathbf{A}\mathbf{x} \approx \mathbf{b}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ und beschränken uns auf den Fall $m \geq n$ und $\text{rang}(\mathbf{A}) = n$. Dann ist die Lösung nach Abschnitt 7.1 eindeutig, $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$ mit der Pseudoinversen $\mathbf{A}^+$. Als Norm verwenden wir stets $\|\cdot\| = \|\cdot\|_2$, denn das KQ-Problem minimiert einen Abstand in der euklidischen Norm. Damit übertragen wir die vertraute Definition der Konditionszahl auf rechteckige Matrizen:

Definition 7.2.1 (Konditionszahl einer nicht quadratischen Matrix)

Für eine nicht notwendigerweise quadratische Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $m \geq n$ definieren wir die *Konditionszahl*

$$\kappa(\mathbf{A}) = \begin{cases} \infty, & \text{rang}(\mathbf{A}) < n, \\ \|\mathbf{A}\| \|\mathbf{A}^+\|, & \text{sonst.} \end{cases}$$

Bemerkung 7.2.2

Für quadratisches, reguläres $\mathbf{A}$ ist $\mathbf{A}^+ = \mathbf{A}^{-1}$, und wir erhalten die bekannte Konditionszahl $\kappa(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ zurück. In der 2-Norm gilt außerdem (mit den Singulärwerten aus der SVD)

$$\kappa_2(\mathbf{A}) = \frac{\sigma_{\max}}{\sigma_{\min}},$$

denn $\|\mathbf{A}\|_2 = \sigma_{\max}$ und $\|\mathbf{A}^+\|_2 = 1/\sigma_{\min}$. Die Fallunterscheidung in Definition 7.2.1 ist konsistent: Nähert sich $\mathbf{A}$ dem Rangdefekt, geht $\sigma_{\min} \rightarrow 0$ und damit $\kappa_2(\mathbf{A}) \rightarrow \infty$.

Interaktiv: Wie schnell wächst $\kappa_2(\mathbf{A})$, wenn die Spalten zusammenrücken?

Nehmen wir zwei Einheitsspalten im Winkel α zueinander. Für $\alpha \rightarrow 0$ werden sie linear abhängig, für $\alpha = 90^\circ$ stehen sie senkrecht. Dazwischen: Wie schnell wächst $\kappa_2(\mathbf{A})$, wenn wir α halbieren?

Interaktives Element — nur in der Web-Fassung

Hier ist $\kappa_2(\mathbf{A}) = \cot(\alpha/2)$: Jede Halbierung von α verdoppelt sie ungefähr, und rangdefekt ist $\mathbf{A}$ erst bei $\alpha = 0$, nicht schon davor.

Kondition bezüglich $\mathbf{b}$

Der statistisch wichtigste Fall: $\mathbf{A}$ ist fix, aber der Datenvektor $\mathbf{b}$ ist gestört, etwa durch Messfehler oder durch Rundungsfehler beim Einlesen. Das Problem ist dann die Abbildung $f(\mathbf{b}) = \mathbf{A}^+\mathbf{b}$, und wir fragen: Wie stark ändert sich $f(\mathbf{b})$ relativ, wenn wir $\mathbf{b}$ durch ein gestörtes $\tilde{\mathbf{b}}$ ersetzen?

Satz 7.2.3

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ fix mit $\text{rang}(\mathbf{A}) = n$, und sei f das Problem mit Lösung $f(\mathbf{b}) = \mathbf{A}^+\mathbf{b}$. Für $f(\mathbf{b}) \neq \mathbf{0}$ ist die exakte relative Konditionszahl bezüglich $\mathbf{b}$

$$\kappa_{\text{rel}}(f, \mathbf{b}) = \|\mathbf{A}^+\|_2 \frac{\|\mathbf{b}\|_2}{\|\mathbf{A}^+\mathbf{b}\|_2}.$$

Sie erfüllt die geometrisch anschauliche obere Schranke

$$\kappa_{\text{rel}}(f, \mathbf{b}) \leq \kappa_2(\mathbf{A}) \frac{\|\mathbf{b}\|_2}{\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|_2}.$$

Die exakte Formel folgt daraus, dass die Ableitung der linearen Abbildung f die Matrix $\mathbf{A}^+$ ist. Die obere Schranke muss für ein festes $\mathbf{b}$ nicht scharf sein, zeigt aber, worauf es ankommt: wie viel von $\mathbf{b}$ im Spaltenraum (Bild) $\text{col}(\mathbf{A})$ liegt.

Vertiefung (optional): Beweis der Konditionsschranke bezüglich $\mathbf{b}$

Wir verfolgen die Störung $\tilde{\mathbf{b}} - \mathbf{b}$ in Blau und die Projektion $\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$ in Grün.

Beweis.

(1)

$$\frac{\|\mathbf{A}^+\tilde{\mathbf{b}} - \mathbf{A}^+\mathbf{b}\|}{\|\mathbf{A}^+\mathbf{b}\|} = \frac{\|\mathbf{A}^+(\tilde{\mathbf{b}} - \mathbf{b})\|}{\|\mathbf{A}^+\mathbf{b}\|}$$

$\mathbf{A}^+$ ist eine Matrix, die Abbildung $\mathbf{b} \mapsto \mathbf{A}^+\mathbf{b}$ also linear

(2)

$$\leq \frac{\|\mathbf{A}^+\| \|\tilde{\mathbf{b}} - \mathbf{b}\|}{\|\mathbf{A}^+\mathbf{b}\|}$$

Submultiplikativität der natürlichen Matrixnorm: $\|\mathbf{A}^+\mathbf{v}\| \leq \|\mathbf{A}^+\| \|\mathbf{v}\|$

(3)

$$= \frac{\kappa_2(\mathbf{A})}{\|\mathbf{A}\| \|\mathbf{A}^+\mathbf{b}\|} \|\tilde{\mathbf{b}} - \mathbf{b}\|$$

Definition 7.2.1: $\kappa_2(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^+\|$, also $\|\mathbf{A}^+\| = \kappa_2(\mathbf{A}) / \|\mathbf{A}\|$

(4)

$$\leq \frac{\kappa_2(\mathbf{A})}{\|\mathbf{A}\mathbf{A}^+\mathbf{b}\|} \|\tilde{\mathbf{b}} - \mathbf{b}\|$$

nochmals Submultiplikativität: $\|\mathbf{A}\mathbf{A}^+\mathbf{b}\| \leq \|\mathbf{A}\| \|\mathbf{A}^+\mathbf{b}\|$; wir verkleinern den Nenner, der Bruch kann nur wachsen

(5)

$$= \kappa_2(\mathbf{A}) \frac{\|\mathbf{b}\|}{\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|} \cdot \frac{\|\tilde{\mathbf{b}} - \mathbf{b}\|}{\|\mathbf{b}\|}$$

$\mathbf{A}\mathbf{A}^+\mathbf{b} = \mathbf{A}\hat{\mathbf{x}} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$: Die KQ-Lösung ist die orthogonale Projektion von $\mathbf{b}$ auf $\text{col}(\mathbf{A})$ (Abschnitt 7.1); anschließend erweitern wir mit $\|\mathbf{b}\|$

□

Geometrische Interpretation

Nach dem Satz des Pythagoras zerlegt sich $\mathbf{b}$ orthogonal in seinen Anteil im Spaltenraum und seinen Anteil im orthogonalen Komplement,

$$\|\mathbf{b}\|^2 = \|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|^2 + \|\text{proj}_{\text{col}(\mathbf{A})^\perp}\mathbf{b}\|^2 \geq \|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|^2,$$

also ist der Faktor $\|\mathbf{b}\| / \|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|$ stets ≥ 1 und die obere Schranke mindestens $\kappa_2(\mathbf{A})$. Bezeichnet θ den Winkel zwischen $\mathbf{b}$ und $\text{col}(\mathbf{A})$ (siehe die Abbildung in Abschnitt 7.1), dann ist $\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\| = \cos(\theta) \|\mathbf{b}\|$ und damit

$$\kappa_{\text{rel}}(f, \mathbf{b}) \leq \frac{\kappa_2(\mathbf{A})}{\cos(\theta)}.$$

- **Best case:** $\mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$, d. h. $\mathbf{b} \in \text{col}(\mathbf{A})$ und $\theta = 0$. Die Schranke reduziert sich auf $\kappa_2(\mathbf{A})$; die exakte Kondition am konkreten $\mathbf{b}$ kann kleiner sein.
- **Worst case:** $\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b} = \mathbf{0}$, d. h. $\mathbf{b} \perp \text{col}(\mathbf{A})$ und $\theta = 90^\circ$. Dann ist $\hat{\mathbf{x}} = \mathbf{A}^+\mathbf{b} = \mathbf{0}$ und der relative Fehler der Lösung nicht definiert. Die Kondition gilt hier als ∞ , passend zum Grenzverhalten: Schon eine winzige Störung mit Anteil in $\text{col}(\mathbf{A})$ erzeugt einen beliebig großen *relativen* Fehler.

Für die Regression heißt das: Ein kleiner Projektionsanteil kann die Koeffizienten relativ empfindlich machen. Wie empfindlich genau, hängt zusätzlich von der Richtung von $\mathbf{b}$ innerhalb des Spaltenraums und von den Singulärrichtungen von $\mathbf{A}$ ab.

Interaktiv: Wann ist die obere Schranke scharf?

Nehmen wir das einfachste nichttriviale KQ-Problem: $m = 2, n = 1, \mathbf{A} = (1, 0)^\top$, also $\kappa_2(\mathbf{A}) = 1$ und $\text{col}(\mathbf{A})$ gleich der horizontalen Achse. Die ganze Empfindlichkeit steckt dann im Winkel θ . Bei welcher Richtung der Störung $\Delta \mathbf{b}$ wird die Schranke angenommen, und bei welcher ändert sich die Lösung gar nicht?

Interaktives Element — nur in der Web-Fassung

Nur der Anteil von $\Delta \mathbf{b}$ längs $\text{col}(\mathbf{A})$ verschiebt $\hat{\mathbf{x}}$, der Rest landet im Residuum. Die Schranke aus Satz 7.2.3 wird deshalb genau längs $\text{col}(\mathbf{A})$ angenommen, sonst nur zum Bruchteil $|\cos(\varphi)|$.

Kondition bezüglich $\mathbf{A}$

Nun ist $\mathbf{b}$ fix und die Matrix $\mathbf{A}$ gestört, etwa durch Messfehler in den Kovariablen oder durch Rundungsfehler beim Speichern von $\mathbf{A}$ und in den Zwischenschritten der Algorithmen. Das Problem ist jetzt die Abbildung $f(\mathbf{A}) = \mathbf{A}^+ \mathbf{b}$:

Satz 7.2.4 (Störung der Designmatrix, erste Ordnung)

Sei $\mathbf{b} \in \mathbb{R}^m$ fix, $\mathbf{A}$ habe vollen Spaltenrang und $f(\mathbf{A}) = \mathbf{A}^+ \mathbf{b} \neq \mathbf{0}$. Für $\Delta \mathbf{A} \rightarrow \mathbf{0}$ und $\mathbf{A} + \Delta \mathbf{A}$ weiterhin von vollem Spaltenrang gilt

$$\frac{\|f(\mathbf{A} + \Delta \mathbf{A}) - f(\mathbf{A})\|}{\|f(\mathbf{A})\|} \leq \left(\kappa_2(\mathbf{A}) + \kappa_2(\mathbf{A})^2 \frac{\|\mathbf{r}\|}{\|\text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}\|} + o(1) \right) \frac{\|\Delta \mathbf{A}\|}{\|\mathbf{A}\|},$$

wobei $\mathbf{r} = \mathbf{b} - \mathbf{A} \hat{\mathbf{x}}$ das Residuum des ungestörten Problems bezeichnet.

Der Beweis ist, anders als der von Satz 7.2.3, eine sehr aufwändige Rechnung; wir verzichten darauf (vgl. Heath §3.3).

Interpretation

Der erste Term der Schranke ist $\kappa_2(\mathbf{A})$, der zweite koppelt das *Quadrat* der Konditionszahl an das Verhältnis von Residuum zu Projektion. Mit dem Winkel θ von oben ist $\|\mathbf{r}\| = \sin(\theta) \|\mathbf{b}\|$ (das Residuum ist gerade die zu $\text{col}(\mathbf{A})$ orthogonale Komponente von $\mathbf{b}$), also

$$\kappa_{\text{lok}}^{\text{oben}} = \kappa_2(\mathbf{A}) + \kappa_2(\mathbf{A})^2 \tan(\theta).$$

- **Best case:** $\mathbf{r} = \mathbf{0}$, d.h. $\mathbf{A} \mathbf{x} = \mathbf{b}$ ist exakt lösbar. Dann ist $\tan(\theta) = 0$, und die lokale obere Schranke reduziert sich auf $\kappa_2(\mathbf{A})$, wie bei einem gewöhnlichen linearen Gleichungssystem.
- **Worst case:** $\text{proj}_{\text{col}(\mathbf{A})} \mathbf{b} = \mathbf{0}$, aber $\mathbf{r} \neq \mathbf{0}$: Dann ist $\mathbf{A} \mathbf{x} = \mathbf{b}$ nicht lösbar, $\mathbf{b} \perp \text{col}(\mathbf{A})$ und $\theta = 90^\circ$. Wie oben ist $\hat{\mathbf{x}} = \mathbf{0}$, und die relative Kondition wird konventionsgemäß als ∞ behandelt.
- **Normalfall:** $\mathbf{r} \neq \mathbf{0}$ und $\text{proj}_{\text{col}(\mathbf{A})} \mathbf{b} \neq \mathbf{0}$, in der Statistik praktisch immer. Dann kann eine Störung von $\mathbf{A}$ mit dem Quadrat $\kappa_2(\mathbf{A})^2$ verstärkt werden.

Dieses Quadrat begegnet uns in Abschnitt 7.3 wieder: Beim Weg über die Normalengleichungen tritt es *immer* auf, auch bei kleinem Residuum, wo das Problem selbst nur mit $\kappa_2(\mathbf{A})$ reagiert.

Interaktiv: Die quadrierte Kondition im Experiment

Wir stören eine konkrete Problemfamilie mit einstellbarem ε :

$$\mathbf{A} = \begin{pmatrix} 1 & 1 \\ \varepsilon & -\varepsilon \\ 0 & 0 \end{pmatrix}, \quad \tilde{\mathbf{A}} = \mathbf{A} + \mathbf{E} \text{ mit } \mathbf{E} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \\ -\varepsilon & \varepsilon \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 0 \\ b_3 \end{pmatrix}.$$

Hier ist $\kappa_2(\mathbf{A}) = 1/\varepsilon$, und die relative Störung ist $\|\mathbf{E}\|_2 / \|\mathbf{A}\|_2 = \varepsilon$. Die ungestörte Lösung ist

stets $\hat{\mathbf{x}} = (1/2, 1/2)^\top$, unabhängig von ε und b_3 . Wie stark muss das Residuum sein, damit der quadrierte Term die Schranke übernimmt?

Interaktives Element – nur in der Web-Fassung

Über $b_3/\varepsilon = 1$ übernimmt der quadrierte Term die Schranke, darunter reagiert das Problem nur mit $\kappa_2(\mathbf{A})$. Entscheidend ist nicht ε , sondern das Verhältnis von Residuum zu Störung.

Selbsttest

1. Stellen wir im Rangdefekt-Widget den Spaltenwinkel auf $\alpha = 12^\circ$. Welchen Wert zeigt es dann für $\kappa_2(\mathbf{A})$?

Lösung: 9,51

Für diese Matrizenfamilie ist $\kappa_2(\mathbf{A}) = \cot(\alpha/2)$, bei $\alpha = 12^\circ$ also $\cot(6^\circ) \approx 9,51$. Das entspricht knapp einer verlorenen Dezimalstelle: $\log_{10}(9,51) \approx 0,98$.

2. Eine Störung von $\mathbf{b}$ senkrecht zu $\text{col}(\mathbf{A})$ verändert $\hat{\mathbf{x}}$ genauso stark wie eine gleich große Störung längs $\text{col}(\mathbf{A})$.

Antwort: Falsch

Sie verändert $\hat{\mathbf{x}}$ gar nicht. Das Winkel-Widget zeigt es: Bei $\varphi = 90^\circ$ bleibt $\Delta\hat{\mathbf{x}} = 0$, die ganze Störung landet im Residuum. Ausgeschöpft wird von der Schranke aus Satz 7.2.3 der Anteil $|\cos(\varphi)|$.

3. Bei exakt lösbarem $\mathbf{Ax} = \mathbf{b}$ reduziert sich die lokale Schranke aus Satz 7.2.4 auf $\kappa_2(\mathbf{A})$.

Antwort: Wahr

Exakt lösbar heißt $\mathbf{r} = \mathbf{0}$, also $\tan(\theta) = 0$; der Term $\kappa_2(\mathbf{A})^2 \tan(\theta)$ verschwindet, und übrig bleibt $\kappa_2(\mathbf{A})$ wie bei einem gewöhnlichen linearen Gleichungssystem.

4. Die Konditionszahl $\kappa_2(\mathbf{A})$ hängt davon ab, mit welchem Verfahren wir das KQ-Problem lösen.

Antwort: Falsch

Die Kondition ist eine Eigenschaft des Problems, nicht des Lösungswegs. Deshalb behandeln wir sie vor den Algorithmen. Der Lösungsweg entscheidet nur, wie nah ein Verfahren an diese unvermeidbare Empfindlichkeit herankommt (Stabilität).

Vertiefung: Heath §3.1–3.3, insbesondere §3.3 („Sensitivity and Conditioning“) mit der vollständigen Störungsanalyse inklusive des Beweises von Satz 7.2.4; zum KQ-Problem als Optimierungsproblem und seiner Rolle in der Regression außerdem MML §7.1 und §9.2.

7.3 Normalengleichungen und Cholesky-Zerlegung

Für $\text{rang}(\mathbf{A}) = n$ hat das Kleinste-Quadrate-Problem die eindeutige Lösung $\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$, charakterisiert durch die Normalengleichungen $\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}$ (Satz 7.1.5). Das ist eine Formel, aber noch kein Rechenverfahren. Das erste und einfachste Verfahren löst die Normalengleichungen mit der Cholesky-Zerlegung. Es ist schnell, aber numerisch problematisch, und das führt uns auf orthogonale Transformationen.

7.3.1 Warum wir niemals invertieren

Die folgende R-Funktion setzt die Lösungsformel wörtlich um: Sie bildet erst die Inverse von $A^T A$ und multipliziert dann.

```
kq_solve <- function(A, b) {
  solve(t(A) %*% A) %*% t(A) %*% b
}
```

Aufgabe: Wo steckt der Fehler in dieser Funktion? Der Fehler ist kein Tippfehler, sondern der Ansatz selbst:

Bemerkung 7.3.1 (Merkregel)

Für ein LGS keine explizite Inverse bilden!

Die Formel $\hat{x} = (A^T A)^{-1} A^T b$ ist ein *mathematisches* Objekt, keine Rechenvorschrift. Numerisch lösen wir stattdessen das lineare Gleichungssystem $(A^T A) \hat{x} = A^T b$ mit einer geeigneten Zerlegung der Matrix. In R heißt das `solve(M, c)` statt `solve(M)`, mit $M = A^T A$ und $c = A^T b$.

Explizites Invertieren ist teurer: Die Inverse zu berechnen heißt, n lineare Gleichungssysteme zu lösen (eines pro Spalte von I), obwohl wir nur die Lösung zu *einer* rechten Seite brauchen. Die anschließende Multiplikation bringt zusätzliche Rundungsfehler ohne Genauigkeitsvorteil; eine stabile Zerlegung mit Substitution löst dasselbe System direkter. Grundsätzlich instabil ist das Invertieren nicht, die Inverse ist hier nur das falsche Zwischenprodukt. Außerdem zerstört sie Struktur: Die Inverse einer dünnbesetzten Matrix ist typischerweise voll besetzt. Wie beim Gauß-Verfahren mit seiner LR-Zerlegung gilt also: zerlegen und substituieren statt invertieren.

7.3.2 Das Cholesky-Verfahren

Welche Zerlegung passt zu $A^T A$? Für $\text{rang}(A) = n$ ist $A^T A$ symmetrisch, denn $(A^T A)^T = A^T A$, und positiv definit, denn $x^T (A^T A) x = \|Ax\|_2^2 > 0$ für jedes $x \neq 0$ (die Spalten von A sind linear unabhängig, also ist $Ax \neq 0$).

Symmetrisch positiv definit, kurz *SPD* (engl. *symmetric positive definite*): das ist die Klasse von Matrizen, für die die Cholesky-Zerlegung $M = LL^T$ mit einer unteren Dreiecksmatrix L existiert. Damit zerfällt das KQ-Problem in einfache Teilschritte:

Algorithmus 7.3.2 (Cholesky-Verfahren für das KQ-Problem)

1. Berechne $M = A^T A$ und $c = A^T b$.
2. Berechne die Cholesky-Zerlegung $M = LL^T$.
3. Löse $Ly = c$ durch Vorwärtssubstitution.
4. Löse $L^T \hat{x} = y$ durch Rückwärtssubstitution.

Schritt 1 ersetzt das $m \times n$ -Ausgangsproblem durch ein quadratisches $n \times n$ -System, die Schritte 2 bis 4 lösen es wie bei der LR-Zerlegung: zerlegen, dann zweimal substituieren.

Beispiel 7.3.3

Wir legen eine Regressionsgerade $y = \beta_0 + \beta_1 x$ wie in Beispiel 7.1.3 durch die drei Punkte $(1, 2)$, $(2, 3)$, $(3, 5)$:

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 2 \\ 3 \\ 5 \end{pmatrix}.$$

Die x -Werte stehen in der zweiten Spalte von A , die Einser-Spalte gehört zum Achsenabschnitt β_0 .

Schritt 1: M und c aufstellen.

$$M = A^T A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}, \quad c = A^T b = \begin{pmatrix} 10 \\ 23 \end{pmatrix}.$$

Schritt 2: Cholesky-Zerlegung $M = LL^T$. Für 2×2 lauten die Formeln $\ell_{11} = \sqrt{m_{11}}$, $\ell_{21} = m_{21}/\ell_{11}$, $\ell_{22} = \sqrt{m_{22} - \ell_{21}^2}$:

$$\ell_{11} = \sqrt{3}, \quad \ell_{21} = \frac{6}{\sqrt{3}} = 2\sqrt{3}, \quad \ell_{22} = \sqrt{14 - (2\sqrt{3})^2} = \sqrt{2},$$

$$\text{also } L = \begin{pmatrix} \sqrt{3} & 0 \\ 2\sqrt{3} & \sqrt{2} \end{pmatrix}.$$

Schritt 3: Vorwärtssubstitution $Ly = c$, Zeile für Zeile von oben.

$$y_1 = \frac{10}{\sqrt{3}} = \frac{10}{\sqrt{3}}, \quad y_2 = \frac{23 - 2\sqrt{3} \cdot \frac{10}{\sqrt{3}}}{\sqrt{2}} = \frac{23 - 20}{\sqrt{2}} = \frac{3}{\sqrt{2}}.$$

Schritt 4: Rückwärtssubstitution $L^T \hat{x} = y$, Zeile für Zeile von unten.

$$x_2 = \frac{3/\sqrt{2}}{\sqrt{2}} = \frac{3}{2}, \quad x_1 = \frac{\frac{10}{\sqrt{3}} - 2\sqrt{3} \cdot \frac{3}{2}}{\sqrt{3}} = \frac{10}{3} - 3 = \frac{1}{3}.$$

Die KQ-Lösung ist also $\hat{x} = \left(\frac{1}{3}, \frac{3}{2}\right)^T$, die Regressionsgerade $\hat{y} = \frac{1}{3} + \frac{3}{2}x$. Probe mit den Normalengleichungen:

$$M \hat{x} = \begin{pmatrix} 3 \cdot \frac{1}{3} + 6 \cdot \frac{3}{2} \\ 6 \cdot \frac{1}{3} + 14 \cdot \frac{3}{2} \end{pmatrix} = \begin{pmatrix} 10 \\ 23 \end{pmatrix} = c. \quad \square$$

Auch die geometrische Deutung aus Abschnitt 7.1 können wir nachprüfen: Das Residuum $\hat{r} = b - A\hat{x} = \left(\frac{1}{6}, -\frac{1}{3}, \frac{1}{6}\right)^T$ erfüllt $A^T \hat{r} = 0$: Es steht senkrecht auf beiden Spalten von A .

7.3.3 Effizient, aber möglicherweise instabil

Das Cholesky-Verfahren ist effizient: Ab Schritt 2 rechnen wir nur noch mit der kleinen $n \times n$ -Matrix $A^T A$ statt mit der $m \times n$ -Matrix A , und die Cholesky-Zerlegung nutzt deren Symmetrie aus und kostet nur etwa halb so viel wie eine LR-Zerlegung. Für gut konditionierte Probleme ist das Verfahren in der Praxis brauchbar. Sein Schwachpunkt liegt im ersten Schritt.

Bemerkung 7.3.4 (Stabilität des Cholesky-Verfahrens)

- Fehler, die beim Aufstellen von $A^T A$ passieren, beeinflussen alle folgenden Schritte; kein späterer Schritt kann sie reparieren.
- Man kann zeigen: Der relative algorithmische Fehler ist typischerweise von der Größenordnung $\kappa_2(A)^2 \varepsilon_{\text{mach}}$ (Maschinengenauigkeit $\varepsilon_{\text{mach}} \approx 2,2 \cdot 10^{-16}$).
- Zum Vergleich: Die Best-Case-Kondition des KQ-Problems selbst ist $O(\kappa_2(A))$ (Abschnitt 7.2).

Woher kommt das Quadrat? Ab Schritt 2 rechnen wir mit $A^T A$, deren Singulärwerte die Quadrate der Singulärwerte von A sind; also ist $\kappa_2(A^T A) = \kappa_2(A)^2$. Diese quadrierte Kondition erben alle weiteren Schritte, gleich wie empfindlich das KQ-Problem selbst ist. Bei kleinem Residuum gilt $\kappa \approx \kappa_2(A)$, der Algorithmus verstärkt Fehler aber trotzdem mit $\kappa_2(A)^2$: Er ist deutlich fehleranfälliger, als die Kondition des Problems erzwingt, also *instabil*. Dazu kommt ein zweiter Effekt, den die Konditionszahl nicht erfasst: Schon beim Ausrechnen von $A^T A$ in Gleitkommaarithmetik kann Information über die Spalten von A verloren gehen. Im Extremfall macht ein einziger Rundungsschritt aus einer Matrix mit vollem Spaltenrang eine numerisch singuläre.

Interaktiv: Wann verliert die Kreuzproduktmatrix ihren Rang?

Bei der folgenden Matrix steckt der ganze Unterschied zwischen den Spalten in einem einzigen kleinen Summanden. Das Widget führt die kritische Addition in der Gleitkommaarithmetik des Browsers aus.

Interaktives Element — nur in der Web-Fassung

Sobald ε^2 höchstens die halbe Maschinengenauigkeit beträgt, hat $\text{fl}(A^T A)$ zwei identische Spalten und damit Rang 1. An A selbst ist bei diesem ε nichts passiert; ein Verfahren, das direkt mit A arbeitet, merkt davon nichts. Die Information geht verloren, bevor der Löser überhaupt rechnet.

7.3.4 Alternative Lösungswege: orthogonale Transformationen

Wir würden $A^T A$ also gerne ganz vermeiden und direkt auf A operieren. Erinnern wir uns an die Ausgangsform des Problems:

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2.$$

Die Idee: Wir transformieren das Problem mit einer Matrix Q zu einem „einfacheren“ Problem $Q\mathbf{Ax} \approx Q\mathbf{b}$, ohne die Lösung zu ändern. Wann ändert sich die Lösung nicht? Wenn die Zielfunktion für *jedes* $\mathbf{x}$ denselben Wert behält, das Transformieren also alle Normen unangetastet lässt. Das leisten Orthogonalmatrizen ($Q^T Q = I$, ausführlich in Abschnitt 7.4), denn für diese gilt

$$\|Q\mathbf{Ax} - Q\mathbf{b}\|_2 = \|Q(\mathbf{Ax} - \mathbf{b})\|_2 = \|\mathbf{Ax} - \mathbf{b}\|_2.$$

Die erste Gleichheit ist Ausklammern, die zweite die Norminvarianz orthogonaler Matrizen: $\|Q\mathbf{z}\|_2 = \sqrt{\mathbf{z}^T Q^T Q \mathbf{z}} = \sqrt{\mathbf{z}^T \mathbf{z}} = \|\mathbf{z}\|_2$. Jedes $\mathbf{x}$ liefert im transformierten Problem also denselben

Zielfunktionswert wie im ursprünglichen; insbesondere stimmen die Minimierer überein.

Nicht jede Transformation, die ein System „einfacher“ macht, ist hier erlaubt. Das Gauß-Verfahren bringt A zwar auf Dreiecksform, seine Eliminationsschritte sind aber Scherungen: Sie verzerren Längen und würden den Minimierer verschieben. Zulässig sind nur normerhaltende Transformationen, also Drehungen und Spiegelungen. Wie wir mit ihnen QA gezielt auf Dreiecksform bringen (die QR-Zerlegung), zeigen Abschnitt 7.4 und Abschnitt 7.5.

Interaktiv: Welche Abbildungen erhalten Längen, und welche nicht?

Drei Kandidaten stehen zur Wahl: eine Drehung, eine Spiegelung und ein Eliminationsschritt des Gauß-Verfahrens. Welche davon dürfen wir auf ein KQ-Problem anwenden?

Interaktives Element — nur in der Web-Fassung

Drehung und Spiegelung bilden den Einheitskreis auf sich selbst ab, die Scherung dagegen auf eine Ellipse; einzelne Vektoren behalten dabei zufällig ihre Länge, alle zusammen aber nicht. Dass $\det M = 1$ bleibt, hilft nichts, denn Flächentreue ist nicht Längentreue.

Selbsttest

1. Im Widget oben lässt sich $\varepsilon = 10^{-k}$ einstellen. Ab welchem k speichert der Rechner $\text{fl}(1 + \varepsilon^2)$ als glatte 1?

Lösung: 8

Sobald ε^2 höchstens 2^{-53} ist, die Hälfte von $\varepsilon_{\text{mach}} = 2^{-52}$, verschwindet es in der Addition. Das passiert ab $\varepsilon \leq 2^{-26,5} \approx 1,05 \cdot 10^{-8}$, also ab $k \approx 8$. Ab dort sind die beiden Spalten der gespeicherten Matrix identisch, ihr Rang ist 1, und die Cholesky-Zerlegung aus Algorithmus 7.3.2 bricht ab.

2. Das Cholesky-Verfahren ist instabil, weil die Cholesky-Zerlegung selbst ein schlecht konditionierter Rechenschritt ist.

Antwort: Falsch

Die Cholesky-Zerlegung ist für SPD-Matrizen stabil. Der Schaden entsteht bereits in Schritt 1: Mit $A^T A$ arbeiten wir ab dann mit einer Matrix der Konditionszahl $\kappa_2(A)^2$, und kein späterer Schritt kann das reparieren (Bemerkung 7.3.4).

3. Der Eliminationsschritt des Gauß-Verfahrens darf auf ein KQ-Problem nicht angewandt werden, weil er die euklidische Norm ändert.

Antwort: Wahr

Er ist eine Scherung; das Widget oben zeigt, wie aus dem Einheitskreis eine Ellipse wird. Damit ändert sich der Wert der Zielfunktion $\|Ax - b\|_2$ und mit ihm der Minimierer. Orthogonalmatrizen lassen beides unangetastet.

4. Weil $A^T A$ nur $n \times n$ groß ist, ist der Weg über die Normalengleichungen bei großem m auch numerisch der beste.

Antwort: Falsch

Das System ist klein und schnell gelöst, aber gerade der Übergang zu $A^T A$ quadriert die Konditionszahl. Effizienz und Stabilität stehen hier gegeneinander; den Vergleich rechnen wir in Abschnitt 7.6 aus.

Vertiefung: Heath §3.4 (Normalengleichungen, Cholesky-Verfahren, orthogonale Transformationen); Heath §3.2 zur Herleitung; MML §7.1 für den Gradientenblick auf Optimierungsprobleme.

7.4 QR-Zerlegung und Gram-Schmidt-Verfahren

Wir führen jetzt den Plan aus Abschnitt 7.3 aus und bringen das Kleinste-Quadrate-Problem mit Matrizen, die die euklidische Norm erhalten, auf Dreiecksgestalt, ohne $A^T A$ und damit ohne die quadrierte Konditionszahl.

Recap: Orthogonalmatrizen

Die normerhaltenden Matrizen kennen wir schon aus der linearen Algebra.

Definition 7.4.1 (Orthogonalmatrix)

Eine Matrix $Q \in \mathbb{R}^{n \times n}$ heißt *Orthogonalmatrix*, wenn ihre Spalten orthonormale Vektoren sind, also

$$Q^T Q = I.$$

Geometrisch beschreibt Q eine Rotation und/oder Spiegelung des $\mathbb{R}^n$, also eine Abbildung, die Längen und Winkel unverändert lässt. Die für uns wichtigen Eigenschaften:

Lemma 7.4.2 (Eigenschaften von Orthogonalmatrizen)

Sei $Q \in \mathbb{R}^{n \times n}$ orthogonal. Dann gilt:

1. $Q^{-1} = Q^T$, die Inverse erfordert also keine Rechnung.
2. $\|Qx\|_2 = \|x\|_2$ für alle $x \in \mathbb{R}^n$.
3. Alle Eigenwerte haben Betrag 1: $|\lambda_1(Q)| = \dots = |\lambda_n(Q)| = 1$, und es gilt $\kappa_2(Q) = 1$.
4. Für Orthogonalmatrizen $Q_1, \dots, Q_n$ ist auch das Produkt $Q = Q_1 \dots Q_n$ orthogonal.

Vertiefung (optional): Beweis der Eigenschaften von Orthogonalmatrizen

Beweis.

(1)

$$(i): Q^T Q = I \implies Q^{-1} = Q^T$$

$Q^T Q = I$ per Definition; eine quadratische Matrix mit Linksinverser ist invertierbar, und die Linksinverse ist dann die Inverse

(2)

$$(ii): \|Qx\|_2 = \sqrt{x^T Q^T Q x} = \sqrt{x^T x} = \|x\|_2$$

Norm als Skalarprodukt schreiben und $Q^T Q = I$ einsetzen

(3)

$$(iii): \|v\|_2 = \|Qv\|_2 = \|\lambda v\|_2 = |\lambda| \|v\|_2 \implies |\lambda| = 1$$

(ii) auf einen Eigenvektor $v \neq 0$ anwenden; κ_2 ist das Produkt $\|Q\|_2 \|Q^{-1}\|_2$, und beide Faktoren sind wegen (i) und (ii) gleich 1

(4)

$$(iv): (Q_1 Q_2)^T (Q_1 Q_2) = Q_2^T \underbrace{Q_1^T Q_1}_{=I} Q_2 = Q_2^T Q_2 = I$$

Definition nachrechnen für zwei Faktoren; der allgemeine Fall folgt induktiv

□

Bemerkung 7.4.3

Eigenschaft (iii) ist für die Numerik entscheidend: Alle Singulärwerte von Q sind 1 (denn $Q^T Q = I$), also ist $\kappa_2(Q) = 1$, und die Multiplikation mit Q oder Q^{-1} ist *immer* gut konditioniert. Anders als der Übergang zu den Normalengleichungen (Abschnitt 7.3) verschlechtern orthogonale Transformationen die Kondition unseres Problems also nicht. Eigenschaft (iv) erlaubt, Q aus vielen einfachen orthogonalen Bausteinen zusammenzusetzen; das nutzen wir in Abschnitt 7.5.

Interaktiv: Woran erkennt man Drehung und Spiegelung?

Jede Orthogonalmatrix in $\mathbb{R}^{2 \times 2}$ ist eine Drehung oder eine Spiegelung. Welche Größe unterscheidet sie, und welche bleibt in beiden Fällen gleich?

Interaktives Element — nur in der Web-Fassung

Die Typen trennt $\det Q = \pm 1$; gleich bleibt $\|Qx\|_2 = \|x\|_2$. Für KQ-Probleme zählt nur das Zweite, also dürfen wir beide mischen.

Die QR-Zerlegung

Welche „einfache Gestalt“ streben wir an? Wie beim Gauß-Verfahren eine obere Dreiecksmatrix, denn Dreieckssysteme lösen wir direkt durch Rückwärtseinsetzen. Das führt auf die zentrale Zerlegung dieses Kapitels:

Definition 7.4.4 (QR-Zerlegung)

Sei $A \in \mathbb{R}^{m \times n}$ mit $m \geq n$ und $Q \in \mathbb{R}^{m \times m}$ eine Orthogonalmatrix, sodass

$$Q^T A = \begin{pmatrix} R \\ 0_{(m-n) \times n} \end{pmatrix},$$

wobei $R \in \mathbb{R}^{n \times n}$ eine obere Dreiecksmatrix ist. Dann nennen wir

$$A = Q \begin{pmatrix} R \\ 0 \end{pmatrix}$$

eine *QR-Zerlegung* von A .

Bemerkung 7.4.5

Eine QR-Zerlegung in der hier dargestellten Blockform existiert für jede Matrix $A \in \mathbb{R}^{m \times n}$ mit $m \geq n$. Eindeutig ist sie aber nicht: schon ein Vorzeichenwechsel in einer Spalte von

Q (mit passendem Vorzeichenwechsel in der zugehörigen Zeile von R) liefert eine andere gültige Zerlegung.

Ein Beispiel: QR-Zerlegung über Gram-Schmidt

Woher bekommen wir Q und R ? Ein Verfahren kennen wir bereits aus der linearen Algebra: die Gram-Schmidt-Orthonormalisierung der Spalten von A . Sie liefert orthonormale Vektoren $q_1, q_2, \dots$, die denselben Raum aufspannen wie die Spalten $a_1, a_2, \dots$, und die Koeffizienten, die dabei anfallen (Normen und Projektions-Koeffizienten), sind die Einträge von R . Die Farben im Beispiel: q_1 , a_2 , der Projektionskoeffizient R_{12} , der noch unnormierte Rest $\tilde{q}_2$ und der fertige Vektor q_2 .

Beispiel 7.4.6 (QR-Zerlegung via Gram-Schmidt)

Gegeben: $A = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix}$. Gesucht: $Q^T A = \begin{pmatrix} R \\ 0_{1 \times 2} \end{pmatrix}$ mit $Q \in \mathbb{R}^{3 \times 3}$ orthogonal und $R \in \mathbb{R}^{2 \times 2}$ obere Dreiecksmatrix.

Schritt 1: erste Spalte $a_1 = (1, 0, 0)^T$ normieren.

$$q_1 = \frac{a_1}{\|a_1\|_2} = \frac{1}{1} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad R_{11} = \|a_1\|_2 = 1.$$

Schritt 2: zweite Spalte $a_2 = (2, 0, 2)^T$ orthogonalisieren. Zuerst die Projektion auf q_1 :

$$R_{12} = q_1^T a_2 = 1 \cdot 2 + 0 \cdot 0 + 0 \cdot 2 = 2.$$

Dann den Projektionsanteil abziehen:

$$\tilde{q}_2 = a_2 - R_{12} q_1 = \begin{pmatrix} 2 \\ 0 \\ 2 \end{pmatrix} - \begin{pmatrix} 2 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix}$$

und normieren:

$$q_2 = \frac{\tilde{q}_2}{\|\tilde{q}_2\|_2} = \frac{1}{2} \begin{pmatrix} 0 \\ 0 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad R_{22} = \|\tilde{q}_2\|_2 = 2.$$

Schritt 3: zu einer Orthonormalbasis des $\mathbb{R}^3$ vervollständigen. Wir brauchen ein q_3 orthogonal zu q_1 und q_2 ; hier geht das durch Hinsehen:

$$q_3 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}.$$

Ergebnis:

$$Q = \begin{pmatrix} \textcolor{red}{1} & \textcolor{blue}{0} & 0 \\ \textcolor{red}{0} & \textcolor{blue}{0} & 1 \\ \textcolor{red}{0} & \textcolor{blue}{1} & 0 \end{pmatrix}, \quad R = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}.$$

Verifikation: Zerlegung ausmultiplizieren.

$$Q \begin{pmatrix} R \\ 0 \end{pmatrix} = \begin{pmatrix} \textcolor{red}{1} & \textcolor{blue}{0} & 0 \\ \textcolor{red}{0} & \textcolor{blue}{0} & 1 \\ \textcolor{red}{0} & \textcolor{blue}{1} & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix} = A \boxtimes$$

Q sammelt die orthonormalen Richtungen, R protokolliert, wie sich die Originalspalten aus diesen Richtungen linear kombinieren: $\mathbf{a}_1 = R_{11} \mathbf{q}_1$, $\mathbf{a}_2 = R_{12} \mathbf{q}_1 + R_{22} \mathbf{q}_2$. Dass R eine obere Dreiecksmatrix ist, liegt an der Struktur des Verfahrens: Die k -te Spalte von A braucht nur die ersten k Orthonormalvektoren.

Interaktiv: Was bleibt von $\mathbf{a}_2$ übrig, wenn es fast auf $\mathbf{a}_1$ liegt?

Nach Abzug der Projektion bleibt von $\mathbf{a}_2$ nur der zu $\mathbf{q}_1$ senkrechte Anteil übrig, und den normieren wir anschließend. Wie viel ist das noch, wenn die beiden Spalten fast dieselbe Richtung haben?

Interaktives Element — nur in der Web-Fassung

Der Rest ist $\|\mathbf{a}_2\|_2 \sin \angle(\mathbf{a}_1, \mathbf{a}_2)$: Je kleiner der Winkel, desto weniger bleibt übrig und desto stärker vergrößert das Normieren die Rundungsfehler darin.

In Gleitkommaarithmetik ist das klassische Gram-Schmidt-Verfahren instabil. Sind zwei Spalten fast linear abhängig, ist der Rest nach der Projektion winzig, und das Normieren verstärkt die Rundungsfehler darin: Die berechneten $\mathbf{q}_k$ verlieren ihre Orthogonalität, und dieser Verlust wächst mit $\kappa_2(A)^2$. Das *modifizierte Gram-Schmidt-Verfahren* (MGS) zieht die Projektionen nacheinander von der jeweils schon aktualisierten Spalte ab statt alle auf einmal von der Originalspalte. In exakter Arithmetik ändert das nichts, in Gleitkommaarithmetik wächst der Verlust dann nur noch mit $\kappa_2(A)$.

Vertiefung (optional): Numerische Stabilität der Gram-Schmidt-Varianten

Interaktiv: Wie schnell verliert Gram-Schmidt die Orthogonalität, und wie repariert man es?

Die Lauchli-Matrix ist der Ernstfall: drei fast parallele Spalten, deren Unterschied allein in $\varepsilon = 10^{-p}$ steckt. Wie weit laufen die Varianten bei wachsendem p auseinander?

Interaktives Element — nur in der Web-Fassung

Die Messung zeigt beide Wachstumsraten, klassisch $\kappa_2(A)^2$ und modifiziert $\kappa_2(A)$; ein zweiter Durchlauf drückt den Verlust auf Maschinengenauigkeit.

Ein Detail kann in die Irre führen: Für $p \gtrsim 8$ *sinkt* der gemessene MGS-Fehler wieder. Das ist kein Fortschritt, sondern derselbe Effekt wie in Abschnitt 7.3: Der Rechner rundet $1 + \varepsilon^2$ bereits zu 1, und das Experiment bildet die Theorie dort nicht mehr ab.

Warum die QR-Zerlegung das KQ-Problem löst

Haben wir eine QR-Zerlegung, zerfällt das Kleinste-Quadrate-Problem in einen Teil, den wir exakt auf null bringen können, und einen Teil, den keine Wahl von $\mathbf{x}$ beeinflusst. Zur Orientierung im Beweis: $\mathbf{R}\mathbf{x} - \mathbf{c}_1$ verfolgt den steuerbaren, $\mathbf{c}_2$ den unvermeidbaren Anteil.

Satz 7.4.7 (KQ-Lösung über die QR-Zerlegung)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$ und $\mathbf{Q} \in \mathbb{R}^{m \times m}$ eine Orthogonalmatrix, sodass

$$\mathbf{Q}^\top \mathbf{A} = \begin{pmatrix} \mathbf{R} \\ \mathbf{0}_{(m-n) \times n} \end{pmatrix} \quad \text{und} \quad \mathbf{Q}^\top \mathbf{b} = \begin{pmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{pmatrix}$$

mit $\mathbf{R} \in \mathbb{R}^{n \times n}$ invertierbar. Dann gilt

$$\hat{\mathbf{x}} = \mathbf{R}^{-1} \mathbf{c}_1 = \arg \min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2.$$

Beweis.

(1)

$$\|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 = \|\mathbf{Q}^\top (\mathbf{A}\mathbf{x} - \mathbf{b})\|_2^2 = \|\mathbf{Q}^\top \mathbf{A}\mathbf{x} - \mathbf{Q}^\top \mathbf{b}\|_2^2$$

Multiplikation mit $\mathbf{Q}^\top$ ändert die Norm nicht (Lemma 7.4.2 (ii), angewandt auf die Orthogonalmatrix $\mathbf{Q}^\top$)

(2)

$$= \left\| \begin{pmatrix} \mathbf{R}\mathbf{x} - \mathbf{c}_1 \\ -\mathbf{c}_2 \end{pmatrix} \right\|_2^2$$

Blockstruktur einsetzen: $\mathbf{Q}^\top \mathbf{A}\mathbf{x} = \begin{pmatrix} \mathbf{R}\mathbf{x} \\ \mathbf{0} \end{pmatrix}$ und $\mathbf{Q}^\top \mathbf{b} = \begin{pmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{pmatrix}$

(3)

$$= \|\mathbf{R}\mathbf{x} - \mathbf{c}_1\|_2^2 + \|\mathbf{c}_2\|_2^2$$

die Quadratsumme eines gestapelten Vektors zerfällt über die Blöcke: $\left\| \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix} \right\|_2^2 = \|\mathbf{u}\|_2^2 + \|\mathbf{v}\|_2^2$

(4)

$$\arg \min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2 = \arg \min_{\mathbf{x}} \|\mathbf{R}\mathbf{x} - \mathbf{c}_1\|_2$$

der zweite Term $\|\mathbf{c}_2\|_2^2$ hängt nicht von $\mathbf{x}$ ab, minimieren müssen wir nur den ersten

(5)

$$\|\mathbf{R}\hat{\mathbf{x}} - \mathbf{c}_1\|_2 = \|\mathbf{R}\mathbf{R}^{-1}\mathbf{c}_1 - \mathbf{c}_1\|_2 = 0 \quad \implies \quad \hat{\mathbf{x}} = \mathbf{R}^{-1}\mathbf{c}_1 \text{ ist Minimierer.}$$

$\mathbf{R}$ ist invertierbar, also bringt $\hat{\mathbf{x}} = \mathbf{R}^{-1}\mathbf{c}_1$ den ersten Term exakt auf null, und kleiner als null kann eine Norm nicht werden

□

In der Praxis invertieren wir $\mathbf{R}$ nicht explizit, sondern lösen das Dreieckssystem $\mathbf{R}\hat{\mathbf{x}} = \mathbf{c}_1$ durch Rückwärtseinsetzen in $\mathcal{O}(n^2)$ Operationen. Die Residuumsnorm bekommen wir dabei ohne Zusatzaufwand: Aus dem Beweis lesen wir $\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2 = \|\mathbf{c}_2\|_2$ ab, ohne $\hat{\mathbf{x}}$ einzusetzen.

Was noch fehlt, ist ein stabiler Weg zu $\mathbf{Q}$, denn das klassische Gram-Schmidt-Verfahren ist numerisch instabil. In Abschnitt 7.5 bauen wir $\mathbf{Q}$ deshalb wie beim Gauß-Verfahren spaltenweise aus einfachen orthogonalen Bausteinen auf: Givens-Rotationen und Householder-Spiegelungen.

Selbsttest

1. Stellen wir im Gram-Schmidt-Widget die beiden Spalten auf einen Winkel von 8° ein (etwa $\varphi_1 = 120^\circ$, $\varphi_2 = 112^\circ$) bei $\|\mathbf{a}_2\|_2 = 2,2$. Wie lang ist der senkrechte Anteil $\|\tilde{\mathbf{q}}_2\|_2$?

Lösung: 0.306

Der senkrechte Anteil ist $\|\mathbf{a}_2\|_2 \sin(8^\circ) = 2,2 \cdot 0,1392 = 0,306$, also knapp 14 % der ursprünglichen Länge. Diesen Rest teilen wir anschließend durch seine eigene Länge, mitsamt aller Rundungsfehler, die in ihm stecken.

2. $\mathbf{R}$ ist deshalb eine obere Dreiecksmatrix, weil die k -te Spalte von $\mathbf{A}$ nur die ersten k Orthonormalvektoren braucht.

Antwort: Wahr

Das ist die Struktur des Verfahrens: $\mathbf{q}_k$ entsteht erst aus $\mathbf{a}_k$, kann also in $\mathbf{a}_1, \dots, \mathbf{a}_{k-1}$ gar nicht vorkommen. Alle Einträge unterhalb der Diagonalen sind deshalb null.

3. Klassisches und modifiziertes Gram-Schmidt rechnen mathematisch Verschiedenes aus.

Antwort: Falsch

In exakter Arithmetik liefern beide dasselbe $\mathbf{Q}$ und dasselbe $\mathbf{R}$; sie unterscheiden sich nur in der Reihenfolge der Operationen. Erst in Gleitkommaarithmetik trennen sich die Wege, und zwar um den Faktor $\kappa_2(\mathbf{A})$ im Fehler.

4. Aus dem Beweis von Satz 7.4.7 lässt sich die minimale Residuumsnorm ablesen, ohne $\hat{\mathbf{x}}$ überhaupt einzusetzen.

Antwort: Wahr

Der Beweis zerlegt die Zielfunktion in $\|\mathbf{R}\mathbf{x} - \mathbf{c}_1\|_2^2 + \|\mathbf{c}_2\|_2^2$; der erste Term wird exakt null, also ist das Minimum gerade $\|\mathbf{c}_2\|_2$. Das liefert die QR-Zerlegung ohne Zusatzaufwand.

Vertiefung: Heath §3.5 (Orthogonalisierungsverfahren, QR-Zerlegung, Gram-Schmidt); MML §3.8 (Orthonormalbasen) und MML §9.2 für die KQ-Perspektive der linearen Regression.

7.5 Konstruktion von Q: Givens-Rotationen und Householder-Spiegelungen

Sobald eine QR-Zerlegung von $\mathbf{A}$ vorliegt, schrumpft das Kleinste-Quadrate-Problem auf das Dreieckssystem $\mathbf{R}\hat{\mathbf{x}} = \mathbf{c}_1$ (Abschnitt 7.4). Offen blieb, wie wir die Orthogonalmatrix $\mathbf{Q}$ finden. Die Strategie kennen wir vom Gauß-Verfahren: Wir gehen von links nach rechts durch die Spalten von $\mathbf{A}$ und erzeugen Nullen unter der Diagonalen, diesmal durch Multiplikation von links mit Orthogonalmatrizen $\mathbf{Q}_k$. Sie erhalten die euklidische Norm und damit das KQ-Kriterium; ihr Produkt ist $\mathbf{Q}^\top$. Die beiden gängigsten Bausteine sind die *Givens-Rotation* und die *Householder-Spiegelung* (engl. *Householder reflection*).

Die Eliminationsaufgabe

Was muss ein einzelner Eliminationsschritt leisten? Sei $\mathbf{a} \in \mathbb{R}^n$ beliebig. Wir suchen eine Orthogonalmatrix $\mathbf{Q}_k$, sodass in $\mathbf{Q}_k \mathbf{a}$

- die ersten $k - 1$ Komponenten unberührt bleiben,
- die letzten $n - k$ Komponenten 0 sind:

$$\mathbf{Q}_k \mathbf{a} = \begin{pmatrix} a_1 \\ \vdots \\ a_{k-1} \\ \alpha \\ 0 \\ \vdots \\ 0 \end{pmatrix}.$$

Der Wert α ist dabei nicht frei wählbar: Orthogonale Abbildungen erhalten Normen, also muss die gesamte „Länge“ des hinteren Teilvektors $(a_k, \dots, a_n)^\top$ in der k -ten Komponente landen. Es genügt deshalb, das Problem für diesen Teilvektor zu lösen: Gesucht ist zu gegebenem $\mathbf{a}$ ein orthogonales $\mathbf{Q}$ mit

$$\mathbf{Q}\mathbf{a} = \alpha \mathbf{e}_1 = \alpha \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \alpha = \pm \|\mathbf{a}\|_2.$$

Für $n = 2$ und $k = 1$ heißt das: Wir müssen $\mathbf{a}$ längentreu auf die erste Koordinatenachse bringen. Dafür gibt es zwei naheliegende Bewegungen:

- **Givens:** wir *drehen* $\mathbf{a}$ auf $\alpha \mathbf{e}_1$ (eine Rotation),
- **Householder:** wir *spiegeln* $\mathbf{a}$ auf $\alpha \mathbf{e}_1$ (eine Spiegelung; mehr dazu in der Übung).

Givens-Rotationen

Aus der linearen Algebra kennen wir die Drehmatrix der Ebene. Drehungen sind orthogonal und damit die Art von Transformation, die wir suchen.

Definition 7.5.1 (Givens-Rotation)

Seien $c, s \in \mathbb{R}$ mit $c^2 + s^2 = 1$. Dann heißt

$$\mathbf{G} = \begin{pmatrix} c & s \\ -s & c \end{pmatrix}$$

Givens-Rotation. Wegen $\mathbf{G}^\top \mathbf{G} = (c^2 + s^2) \mathbf{I} = \mathbf{I}$ ist jede solche Matrix orthogonal; c und s spielen die Rolle von Kosinus und Sinus des Drehwinkels.

Wie müssen wir c und s wählen, damit die Drehung $\mathbf{a}$ auf die erste Koordinatenachse bringt?

Satz 7.5.2 (Wahl von c und s)

Sei $\mathbf{a} = (a_1, a_2)^\top \neq \mathbf{0}$. Mit

$$c = \frac{a_1}{\sqrt{a_1^2 + a_2^2}}, \quad s = \frac{a_2}{\sqrt{a_1^2 + a_2^2}}$$

gilt $\mathbf{G}\mathbf{a} = \begin{pmatrix} \alpha \\ 0 \end{pmatrix}$ mit $\alpha = \|\mathbf{a}\|_2$.

Beweis.

(1)

$$\mathbf{G}\mathbf{a} = \begin{pmatrix} c a_1 + s a_2 \\ -s a_1 + c a_2 \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} \alpha \\ 0 \end{pmatrix}$$

Matrixprodukt ausschreiben; die zweite Komponente soll verschwinden

(2)

$$r := \sqrt{a_1^2 + a_2^2} = \|\mathbf{a}\|_2 > 0, \quad c := \frac{a_1}{r}, \quad s := \frac{a_2}{r}$$

Ansatz aus dem Satz; wegen $c^2 + s^2 = (a_1^2 + a_2^2)/r^2 = 1$ ist $\mathbf{G}$ tatsächlich eine Givens-Rotation

(3)

$$-s a_1 + c a_2 = \frac{-a_2 a_1 + a_1 a_2}{r} = 0$$

einsetzen; die zweite Komponente verschwindet wie gefordert

(4)

$$c a_1 + s a_2 = \frac{a_1^2 + a_2^2}{r} = r = \|\mathbf{a}\|_2 = \alpha$$

einsetzen; Definition von r

□

Dass $\alpha = \|\mathbf{a}\|_2$ herauskommt, muss so sein, denn eine Orthogonalmatrix erhält die Norm. Den Drehwinkel brauchen wir nicht, c und s ergeben sich direkt aus a_1 und a_2 . (Gedreht wird um $-\text{atan2}(a_2, a_1)$, also um den Polarwinkel von $\mathbf{a}$ zurück auf die Achse.)

Beispiel 7.5.3 (Givens-Rotation)

Wir eliminieren die zweite Komponente von $\mathbf{a} = (4, 3)^\top$. Zuerst die Norm:

$$r = \sqrt{4^2 + 3^2} = \sqrt{16 + 9} = \sqrt{25} = 5.$$

Damit sind Kosinus und Sinus festgelegt:

$$c = \frac{4}{5} = 0,8, \quad s = \frac{3}{5} = 0,6.$$

Anwenden und nachrechnen:

$$\mathbf{G}\mathbf{a} = \begin{pmatrix} 0,8 & 0,6 \\ -0,6 & 0,8 \end{pmatrix} \begin{pmatrix} 4 \\ 3 \end{pmatrix} = \begin{pmatrix} 0,8 \cdot 4 + 0,6 \cdot 3 \\ -0,6 \cdot 4 + 0,8 \cdot 3 \end{pmatrix} = \begin{pmatrix} 3,2 + 1,8 \\ -2,4 + 2,4 \end{pmatrix} = \begin{pmatrix} 5 \\ 0 \end{pmatrix}.$$

In der zweiten Komponente steht die gewünschte Null, und die Länge $\|Ga\|_2 = 5 = \|a\|_2$ bleibt erhalten.

Interaktiv: Wo landet Ga , wenn wir a im Bild herumziehen?

Satz 7.5.2 bestimmt c und s allein aus den beiden Komponenten von a . Was bedeutet das geometrisch? Wohin schickt G den Vektor, und wohin das Koordinatengitter?

Interaktives Element — nur in der Web-Fassung

Die Drehung schiebt a längentreu auf die x_1 -Achse: $Ga = (r, 0)^T$ mit $r = \|a\|_2$. Das Koordinatengitter dreht sich als Ganzes mit, und der Einheitskreis geht in sich über.

In $\mathbb{R}^n$ machen wir so jede einzelne Komponente eines Vektors zu Null. Neben der zu eliminierenden Komponente j wählen wir eine Partnerkomponente i , bestimmen c und s nach Satz 7.5.2 aus a_i und a_j und setzen die 2×2 -Rotation in die Zeilen und Spalten i und j einer Einheitsmatrix ein. Für $n = 5$, $i = 3$ und $j = 5$ entsteht so

$$\begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & c & 0 & s \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & -s & 0 & c \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ a_3 \\ a_4 \\ a_5 \end{pmatrix} = \begin{pmatrix} a_1 \\ a_2 \\ \alpha \\ a_4 \\ 0 \end{pmatrix}.$$

Alle übrigen Komponenten bleiben unberührt. Pro Rotation gewinnen wir aber nur eine Null; eine ganze Spalte räumen wir mit einer Folge von Rotationen leer. Dabei ist auf die Reihenfolge zu achten: Schon erzeugte Nullen dürfen die nachfolgenden Rotationen nicht wieder auffüllen.

Bemerkung 7.5.4 (Wann Givens?)

Eine Givens-Rotation ändert nur zwei Zeilen; alle anderen Einträge der Matrix bleiben, wie sie sind. Deshalb greifen wir zu Givens, wenn wir gezielt einzelne Nullen erzeugen wollen: bei dünnbesetzten Matrizen, deren Nullen erhalten bleiben sollen, oder wenn eine bestehende QR-Zerlegung um eine neue Datenzeile ergänzt wird. Eine voll besetzte Matrix vollständig zu eliminieren, kostet mit Givens dagegen etwa das Anderthalbfache der Rechenoperationen des Householder-Zugangs.

Householder-Spiegelungen

Um *alle* Einträge unter der Diagonalen einer Spalte in einem Schritt zu eliminieren, spiegeln wir a an einer geschickt gewählten Hyperebene, statt es auf αe_1 zu drehen.

Definition 7.5.5 (Householder-Spiegelung)

Sei $v \in \mathbb{R}^n$, $v \neq 0$. Die Matrix

$$H = I - 2 \frac{vv^T}{v^T v}$$

heißt *Householder-Spiegelung* (engl. *Householder reflection*, *elementary reflector*) mit Spiegelvektor $\mathbf{v}$.

Warum „Spiegelung“? Der Baustein $\mathbf{P} = \mathbf{v}\mathbf{v}^\top / (\mathbf{v}^\top \mathbf{v})$, ein skaliertes dyadisches Produkt, ist die orthogonale Projektion auf die Gerade $\text{span}(\mathbf{v})$ (lineare Hülle von $\mathbf{v}$). Entsprechend projiziert $\mathbf{I} - \mathbf{P}$ auf die Hyperebene $\text{span}(\mathbf{v})^\perp$, das orthogonale Komplement. $\mathbf{H} = \mathbf{I} - 2\mathbf{P}$ geht doppelt so weit: Es zieht von $\mathbf{a}$ den $\mathbf{v}$ -Anteil *zweimal* ab und landet damit auf der anderen Seite der Hyperebene; $\text{span}(\mathbf{v})^\perp$ ist der Spiegel.

Vertiefung (optional): Warum eine Householder-Spiegelung symmetrisch und orthogonal ist

Satz 7.5.6 (Symmetrie und Orthogonalität)

Jede Householder-Spiegelung $\mathbf{H}$ ist symmetrisch und orthogonal:

$$\mathbf{H}^\top = \mathbf{H}, \quad \mathbf{H}^\top \mathbf{H} = \mathbf{H}^2 = \mathbf{I}.$$

Beweis.

(1)

$$\mathbf{P} := \frac{\mathbf{v}\mathbf{v}^\top}{\mathbf{v}^\top \mathbf{v}} \implies \mathbf{P}^\top = \mathbf{P}$$

$$(\mathbf{v}\mathbf{v}^\top)^\top = (\mathbf{v}^\top)^\top \mathbf{v}^\top = \mathbf{v}\mathbf{v}^\top \text{ (Transponieren eines Produkts)}$$

(2)

$$\mathbf{P}^2 = \frac{\mathbf{v}(\mathbf{v}^\top \mathbf{v})\mathbf{v}^\top}{(\mathbf{v}^\top \mathbf{v})^2} = \frac{\mathbf{v}\mathbf{v}^\top}{\mathbf{v}^\top \mathbf{v}} = \mathbf{P}$$

$\mathbf{v}^\top \mathbf{v}$ ist ein Skalar (Skalarprodukt) und lässt sich kürzen: $\mathbf{P}$ ist eine Projektion

(3)

$$\mathbf{H}^\top = (\mathbf{I} - 2\mathbf{P})^\top = \mathbf{I} - 2\mathbf{P}^\top = \mathbf{I} - 2\mathbf{P} = \mathbf{H}$$

Linearität des Transponierens und Schritt 1

(4)

$$\mathbf{H}^\top \mathbf{H} = \mathbf{H}^2 = (\mathbf{I} - 2\mathbf{P})^2 = \mathbf{I} - 4\mathbf{P} + 4\mathbf{P}^2 = \mathbf{I}$$

ausmultiplizieren; Schritt 2 ($\mathbf{P}^2 = \mathbf{P}$)

□

$\mathbf{H}$ ist damit symmetrisch, orthogonal und selbstinvers: Eine Spiegelung, zweimal ausgeführt, ist die Identität. Welchen Spiegelvektor $\mathbf{v}$ brauchen wir, damit $\mathbf{a}$ auf $\alpha \mathbf{e}_1$ landet? Das geometrische Bild zeigt es: Der Spiegel muss den Winkel zwischen $\mathbf{a}$ und dem Ziel halbieren, also muss $\mathbf{v}$ in Richtung der Differenz $\mathbf{a} - \alpha \mathbf{e}_1$ zeigen.

Satz 7.5.7 (Wahl des Spiegelvektors)

Sei $\mathbf{a} \in \mathbb{R}^n$ und $\alpha = \pm \|\mathbf{a}\|_2$ so, dass $\mathbf{v} = \mathbf{a} - \alpha \mathbf{e}_1 \neq \mathbf{0}$. Dann gilt für die Householder-Spiegelung $\mathbf{H}$ mit Spiegelvektor $\mathbf{v}$:

$$\mathbf{H}\mathbf{a} = \alpha \mathbf{e}_1.$$

Vertiefung (optional): Warum der gewählte Spiegelvektor funktioniert

Beweis.

(1)

$$\mathbf{v}^\top \mathbf{a} = (\mathbf{a} - \alpha \mathbf{e}_1)^\top \mathbf{a} = \mathbf{a}^\top \mathbf{a} - \alpha \mathbf{e}_1^\top \mathbf{a} = \|\mathbf{a}\|_2^2 - \alpha a_1$$

ausmultiplizieren; $\mathbf{e}_1^\top \mathbf{a} = a_1$ und $\mathbf{a}^\top \mathbf{a} = \|\mathbf{a}\|_2^2$

(2)

$$\mathbf{v}^\top \mathbf{v} = \|\mathbf{a}\|_2^2 - 2\alpha a_1 + \alpha^2 = 2(\|\mathbf{a}\|_2^2 - \alpha a_1)$$

binomisch ausmultiplizieren; $\alpha^2 = \|\mathbf{a}\|_2^2$, weil $\alpha = \pm \|\mathbf{a}\|_2$

(3)

$$2 \frac{\mathbf{v}^\top \mathbf{a}}{\mathbf{v}^\top \mathbf{v}} = \frac{2(\|\mathbf{a}\|_2^2 - \alpha a_1)}{2(\|\mathbf{a}\|_2^2 - \alpha a_1)} = 1$$

Schritte 1 und 2 einsetzen; wegen $\mathbf{v} \neq \mathbf{0}$ ist der Nenner nicht 0

(4)

$$\mathbf{H}\mathbf{a} = \mathbf{a} - 2 \mathbf{v} \frac{\mathbf{v}^\top \mathbf{a}}{\mathbf{v}^\top \mathbf{v}} = \mathbf{a} - \mathbf{v} = \mathbf{a} - (\mathbf{a} - \alpha \mathbf{e}_1) = \alpha \mathbf{e}_1$$

Definition 7.5.5 anwenden; Schritt 3; $\mathbf{v}$ einsetzen

□

Beide Vorzeichen von α erfüllen den Satz. Numerisch wählen wir $\alpha = -\text{sign}(a_1) \|\mathbf{a}\|_2$: Dann ist $v_1 = a_1 - \alpha = a_1 + \text{sign}(a_1) \|\mathbf{a}\|_2$ eine Summe zweier Zahlen gleichen Vorzeichens, und es droht keine Auslöschung (Bemerkung 7.5.9).

Beispiel 7.5.8 (Householder-Spiegelung)

Wir suchen die Householder-Spiegelung, die in $\mathbf{a} = (1, 2, 2)^\top$ alle Komponenten außer der ersten eliminiert. Zunächst die Norm:

$$\|\mathbf{a}\|_2 = \sqrt{1^2 + 2^2 + 2^2} = \sqrt{9} = 3.$$

Da $a_1 = 1 > 0$, wählen wir $\alpha = -3$. Der Spiegelvektor ist dann

$$\mathbf{v} = \mathbf{a} - \alpha \mathbf{e}_1 = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix} + 3 \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 2 \end{pmatrix}.$$

Für $\mathbf{H}\mathbf{a} = \mathbf{a} - 2 \frac{\mathbf{v}^\top \mathbf{a}}{\mathbf{v}^\top \mathbf{v}} \mathbf{v}$ brauchen wir zwei Skalarprodukte:

$$\mathbf{v}^\top \mathbf{a} = 4 \cdot 1 + 2 \cdot 2 + 2 \cdot 2 = 12, \quad \mathbf{v}^\top \mathbf{v} = 4^2 + 2^2 + 2^2 = 24.$$

Es ist $2 \cdot \frac{12}{24} = 1$, also

$$\mathbf{H}\mathbf{a} = \mathbf{a} - \mathbf{v} = \begin{pmatrix} 1 - 4 \\ 2 - 2 \\ 2 - 2 \end{pmatrix} = \begin{pmatrix} -3 \\ 0 \\ 0 \end{pmatrix} = \alpha \mathbf{e}_1.$$

Die Länge bleibt erhalten, $\|\mathbf{H}\mathbf{a}\|_2 = 3 = \|\mathbf{a}\|_2$, und beide Komponenten unterhalb der ersten sind mit *einer* Spiegelung verschwunden.

Interaktiv: Warum wird der $\mathbf{v}$ -Anteil zweimal abgezogen?

Der Faktor 2 in $\mathbf{H} = \mathbf{I} - 2\mathbf{P}$ ist wesentlich. Zerlegen wir die Spiegelung in ihre beiden Hälften: Der Wanderpunkt $\mathbf{w}(t) = \mathbf{a} - t \mathbf{v} \frac{\mathbf{v}^\top \mathbf{a}}{\mathbf{v}^\top \mathbf{v}}$ startet bei $t = 0$ in $\mathbf{a}$. Wo liegt er bei $t = 1$, und was ist dort mit seiner Länge?

Interaktives Element — nur in der Web-Fassung

Der halbe Schritt landet auf der Spiegelgeraden und verkürzt; erst der doppelte bringt die Länge zurück. Dafür steht die Zwei in $\mathbf{H} = \mathbf{I} - 2\mathbf{v}\mathbf{v}^\top / (\mathbf{v}^\top \mathbf{v})$.

Vertiefung (optional): Householder in der Praxis: Vorzeichen und Aufwand**Bemerkung 7.5.9 (Vorzeichenwahl)**

In exakter Arithmetik funktionieren beide Vorzeichen von $\alpha = \pm \|\mathbf{a}\|_2$, denn es gibt zwei Spiegelebenen, die $\mathbf{a}$ auf die Achse bringen. Numerisch sind sie *nicht* gleichwertig: Hat α dasselbe Vorzeichen wie a_1 und dominiert a_1 die Norm, subtrahieren wir in $v_1 = a_1 - \alpha$ zwei fast gleiche Zahlen. Die führenden Ziffern löschen sich aus, und der winzige Rest besteht fast nur noch aus Rundungsfehlern. Mit

$$\alpha = -\text{sign}(a_1) \|\mathbf{a}\|_2$$

kann das nicht passieren. Geometrisch spiegeln wir damit stets auf das Ziel, das *weiter* von $\mathbf{a}$ entfernt liegt.

Interaktiv: Zwei Vorzeichen für α im Vergleich

Testen wir die beiden Vorzeichen an $\mathbf{a} = (1, \delta)^\top$ mit kleinem δ , gerechnet in einer nachgestellten Gleitkommaarithmetik, die nach jeder Operation auf t signifikante Stellen rundet. Wie viele Ziffern von $v_1 = a_1 - \alpha$ überleben in den beiden Fällen?

Interaktives Element — nur in der Web-Fassung

Zeigt $\mathbf{a}$ fast in Richtung $\mathbf{e}_1$, löschen sich in $v_1 = a_1 - \alpha$ bei gleichem Vorzeichen die führenden Ziffern aus. Die Wahl $\alpha = -\text{sign}(a_1) \|\mathbf{a}\|_2$ vermeidet das ohne Mehraufwand.

Bemerkung 7.5.10 (Aufwand)

In der Praxis stellt niemand $\mathbf{H}$ als Matrix auf. Für einen beliebigen Vektor $\mathbf{u}$ gilt

$$\mathbf{H}\mathbf{u} = \mathbf{u} - \left(2 \frac{\mathbf{v}^\top \mathbf{u}}{\mathbf{v}^\top \mathbf{v}} \right) \mathbf{v},$$

also genügen zwei Skalarprodukte und eine Vektor-Aktualisierung: $\mathcal{O}(n)$ Operationen statt $\mathcal{O}(n^2)$ für das explizite Matrix-Vektor-Produkt (Landau-Notation). Genauso wird $\mathbf{Q}$ selbst nie explizit gebildet: Man speichert nur die Spiegelvektoren $\mathbf{v}_k$ (bzw. bei Givens die Paare (c, s)) und wendet sie bei Bedarf nacheinander an.

Von den Bausteinen zur QR-Zerlegung

Im k -ten Eliminationsschritt betrachten wir vom aktuellen Zwischenprodukt die k -te Spalte ab der Diagonalen, also den Teilvektor $\mathbf{a} = (a_{kk}, \dots, a_{mk})^\top$. Zu ihm konstruieren wir nach Satz 7.5.7 eine Spiegelung $\tilde{\mathbf{H}}_k$ mit $\tilde{\mathbf{H}}_k \mathbf{a} = \alpha \mathbf{e}_1$ (oder eine Kette von Givens-Rotationen mit derselben Wirkung) und betten sie ein:

$$\mathbf{Q}_k = \begin{pmatrix} \mathbf{I}_{k-1} & \mathbf{0} \\ \mathbf{0} & \tilde{\mathbf{H}}_k \end{pmatrix}.$$

$\mathbf{Q}_k$ ist orthogonal, lässt die ersten $k-1$ Zeilen unberührt und macht in Spalte k alle Einträge unter der Diagonalen zu Null. Die schon fertigen Spalten $1, \dots, k-1$ bleiben dabei fertig: Unterhalb der Diagonalen stehen dort bereits Nullen, und $\mathbf{Q}_k$ verändert nur die Zeilen $k, \dots, m$; auf diesem Nullblock wirkt $\tilde{\mathbf{H}}_k$ als $\tilde{\mathbf{H}}_k \mathbf{0} = \mathbf{0}$. Nach $p = \min(n, m-1)$ Schritten ist obere Dreiecksgestalt erreicht:

$$\mathbf{Q}_p \cdots \mathbf{Q}_1 \mathbf{A} = \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix} \implies \mathbf{Q}^\top = \mathbf{Q}_p \cdots \mathbf{Q}_1, \quad \mathbf{A} = \mathbf{Q} \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix}.$$

Das Produkt von Orthogonalmatrizen ist wieder orthogonal, also ist $\mathbf{Q} = \mathbf{Q}_1^\top \cdots \mathbf{Q}_p^\top$ die gesuchte Orthogonalmatrix, und wir haben eine QR-Zerlegung im Sinne von Abschnitt 7.4 konstruiert. Für das Kleinste-Quadrate-Problem wenden wir dieselben $\mathbf{Q}_k$ parallel auf $\mathbf{b}$ an und lösen anschließend $\mathbf{R} \hat{\mathbf{x}} = \mathbf{c}_1$ per Rücksubstitution.

Für voll besetzte Matrizen ist **Householder** die Standardwahl: weniger Operationen, sehr gute numerische Stabilität; so arbeiten die QR-Löser gängiger Software (etwa hinter `lm()` in R). **Givens** lohnt sich, wenn Dünnbesetztheit (sparsity) erhalten bleiben soll oder nur einzelne Einträge zu eliminieren sind. Beide vermeiden das Quadrieren der Konditionszahl, das den Weg über die Normalengleichungen belastet; den Methodenvergleich zieht Abschnitt 7.6.

Selbsttest

1. Bei $t = 1$ ist im Householder-Widget schon die halbe Arbeit getan, denn $\mathbf{w}(1)$ hat dieselbe Länge wie $\mathbf{a}$.

Antwort: Falsch

$\mathbf{w}(1)$ liegt zwar auf der Spiegelgeraden, ist aber echt kürzer als $\mathbf{a}$; die Ablesezeile $\|\mathbf{w}(t)\|_2$ zeigt es. Die Projektion allein ist keine Orthogonalmatrix; erst der doppelte Schritt bringt die Länge zurück.

2. Eine Givens-Rotation erzeugt pro Anwendung genau eine Null, eine Householder-Spiegelung räumt eine ganze Spalte auf einmal leer.

Antwort: Wahr

Das ist die Arbeitsteilung: Givens fasst nur zwei Zeilen an und erhält deshalb Dünnbesetztheit, Householder ist für voll besetzte Matrizen billiger (Bemerkung 7.5.4).

3. $\alpha = -\text{sign}(a_1) \|\mathbf{a}\|_2$ ist die numerisch sichere Wahl, weil dann v_1 aus einer Addition gleicher Vorzeichen entsteht.

Antwort: Wahr

Dann ist $v_1 = a_1 + \text{sign}(a_1) \|\mathbf{a}\|_2$, und bei einer Addition zweier Zahlen gleichen Vorzeichens kann keine Auslöschung auftreten (Bemerkung 7.5.9).

Vertiefung: Heath §3.5.1 (Householder-Transformationen) und §3.5.2 (Givens-Rotationen); Methodenvergleich in Heath §3.7; zur Rolle orthogonaler Projektionen im Kleinste-Quadrate-Kontext auch MML §3.8.

7.6 Pseudoinverse, SVD-Lösung und Methodenvergleich

Zwei Lösungswege für das Kleinste-Quadrate-Problem kennen wir schon: die Normalengleichungen mit Cholesky-Zerlegung (Abschnitt 7.3) und die QR-Zerlegung (Abschnitt 7.4 und Abschnitt 7.5). Beide setzen stillschweigend $\text{rang}(\mathbf{A}) = n$ voraus. Ist $\mathbf{A}$ rangdefizient, so ist $\mathbf{A}^\top \mathbf{A}$ singulär, die Cholesky-Zerlegung bricht ab, und auch $\mathbf{R}$ in der QR-Zerlegung ist singulär. Hier hilft die Singulärwertzerlegung (SVD) aus Kapitel 6; sie liefert das dritte und robusteste Lösungsverfahren.

Die SVD-Lösung über die Pseudoinverse

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang r und reduzierter SVD $\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top$ ist die Moore-Penrose-Pseudoinverse aus Kapitel 6 definiert als $\mathbf{A}^+ = \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top \in \mathbb{R}^{n \times m}$, wobei $\Sigma_r^{-1} = \text{diag}(1/\sigma_1, \dots, 1/\sigma_r)$ eine Diagonalmatrix ist. Ihre zentrale Eigenschaft: $\mathbf{A}\mathbf{A}^+$ ist die Projektion auf den Spaltenraum $\text{col}(\mathbf{A})$. Das passt zu den Kleinsten Quadraten, denn nach Satz 7.1.4 löst $\hat{\mathbf{x}}$ das KQ-Problem genau dann, wenn $\mathbf{A}\hat{\mathbf{x}} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$.

Satz 7.6.1 (SVD-Lösung des KQ-Problems)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$ und reduzierter SVD $\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top$, und sei $\mathbf{b} \in \mathbb{R}^m$. Dann löst

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} = \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top \mathbf{b} \quad (7.6.1)$$

das Kleinste-Quadrate-Problem $\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2$. Ist $r = n$, so ist $\hat{\mathbf{x}}$ die eindeutige Lösung. Ist $r < n$, so ist $\hat{\mathbf{x}}$ unter allen KQ-Lösungen diejenige mit minimaler Norm:

$$\mathbf{A}^+ \mathbf{b} = \arg \min \{\|\mathbf{x}\|_2 : \mathbf{x} \text{ minimiert } \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2\}.$$

Vertiefung (optional): Beweis der SVD-Lösung

Zuerst zeigen wir, dass $\mathbf{A}\hat{\mathbf{x}}$ die Projektion von $\mathbf{b}$ auf $\text{col}(\mathbf{A})$ ist, dann die Minimalität der Norm. Die Farben verfolgen $\mathbf{U}_r$, Σ_r und $\mathbf{V}_r$ durch die Rechnung, $\mathbf{z}$ den Anteil einer beliebigen KQ-Lösung, der im Kern von $\mathbf{A}$ liegt.

Beweis.

(1)

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top$$

reduzierte SVD und Definition der Pseudoinversen einsetzen; die inneren Faktoren treffen aufeinander

(2)

$$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \Sigma_r \Sigma_r^{-1} \mathbf{U}_r^\top = \mathbf{U}_r \mathbf{U}_r^\top$$

$\mathbf{V}_r^\top \mathbf{V}_r = \mathbf{I}_r$, denn die Spalten von $\mathbf{V}_r$ sind orthonormal; danach $\Sigma_r \Sigma_r^{-1} = \mathbf{I}_r$

(3)

$$\mathbf{A}\hat{\mathbf{x}} = \mathbf{A}\mathbf{A}^+ \mathbf{b} = \mathbf{U}_r \mathbf{U}_r^\top \mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}$$

die Spalten von $\mathbf{U}_r$ bilden eine Orthonormalbasis von $\text{col}(\mathbf{A})$, also ist $\mathbf{U}_r \mathbf{U}_r^\top$ die Projektionsmatrix auf $\text{col}(\mathbf{A})$

- (4) Also minimiert $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$ die Norm $\|\mathbf{Ax} - \mathbf{b}\|_2$.

das ist die geometrische Charakterisierung der KQ-Lösung aus Abschnitt 7.1

- (5) Für $\text{rang}(\mathbf{A}) < n$ hat das KQ-Problem unendlich viele Lösungen. Jede lässt sich schreiben als

$$\mathbf{x} = \hat{\mathbf{x}} + \mathbf{z} \quad \text{mit} \quad \mathbf{Az} = \mathbf{0}$$

jede KQ-Lösung $\mathbf{x}$ erfüllt dieselbe Projektionsgleichung $\mathbf{Ax} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b} = \mathbf{A}\hat{\mathbf{x}}$; die Differenz $\mathbf{z} = \mathbf{x} - \hat{\mathbf{x}}$ liegt also im Kern

- (6)

$$\hat{\mathbf{x}} = \mathbf{V}_r (\boldsymbol{\Sigma}_r^{-1} \mathbf{U}_r^T \mathbf{b}) \in \text{span}(\mathbf{V}_r) = \text{col}(\mathbf{A}^T) \perp \text{Kern}(\mathbf{A}) \ni \mathbf{z}$$

$\hat{\mathbf{x}}$ ist eine Linearkombination der Spalten von $\mathbf{V}_r$; deren Spann ist der Zeilenraum $\text{col}(\mathbf{A}^T)$, und der steht senkrecht auf dem Kern (orthogonales Komplement, Kapitel 6)

- (7)

$$\|\mathbf{x}\|_2^2 = \|\hat{\mathbf{x}}\|_2^2 + \|\mathbf{z}\|_2^2 \geq \|\hat{\mathbf{x}}\|_2^2$$

Satz des Pythagoras für $\hat{\mathbf{x}} \perp \mathbf{z}$; Gleichheit nur für $\mathbf{z} = \mathbf{0}$

- (8) $\hat{\mathbf{x}}$ hat unter allen KQ-Lösungen die kleinste Norm und ist bei vollem Rang die einzige Lösung.

für $\text{rang}(\mathbf{A}) = n$ ist $\text{Kern}(\mathbf{A}) = \{\mathbf{0}\}$, also $\mathbf{z} = \mathbf{0}$ erzwungen

□

Beispiel 7.6.2 (rangdefizientes KQ-Problem)

Betrachten wir

$$\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \text{rang}(\mathbf{A}) = 1 < n = 2.$$

Die Normalengleichungen versagen hier: $\mathbf{A}^T \mathbf{A} = \begin{pmatrix} 3 & 3 \\ 3 & 3 \end{pmatrix}$ ist singulär, die Cholesky-Zerlegung bricht ab. Die reduzierte SVD existiert trotzdem ($r = 1$): $\mathbf{A}^T \mathbf{A}$ hat die Eigenwerte 6 und 0, also ist $\sigma_1 = \sqrt{6}$, und

$$\mathbf{A} = \mathbf{u}_1 \sigma_1 \mathbf{v}_1^T \quad \text{mit} \quad \mathbf{u}_1 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}, \quad \sigma_1 = \sqrt{6}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

(Probe: $\sqrt{6} \cdot \frac{1}{\sqrt{3}} \cdot \frac{1}{\sqrt{2}} = 1$; jeder Eintrag von $\mathbf{u}_1 \sigma_1 \mathbf{v}_1^T$ ist 1.) Die Pseudoinverse wird damit

$$\mathbf{A}^+ = \mathbf{v}_1 \sigma_1^{-1} \mathbf{u}_1^T = \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{6}} \cdot \frac{1}{\sqrt{3}} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix},$$

und die SVD-Lösung nach (7.6.1):

$$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} = \frac{1}{6} \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 6 \\ 6 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Probe: $\mathbf{A}\hat{\mathbf{x}} = (2, 2, 2)^T$ ist die Projektion von $\mathbf{b}$ auf $\text{col}(\mathbf{A}) = \text{span}\{(1, 1, 1)^T\}$ (der Mittelwert von $\mathbf{b}$ ist 2). Alle KQ-Lösungen erfüllen $x_1 + x_2 = 2$, etwa auch $(2, 0)^T$ mit Norm 2. Unsere Lösung $\hat{\mathbf{x}} = (1, 1)^T$ hat Norm $\sqrt{2} \approx 1,41$, die kleinste, wie Satz 7.6.1 sagt.

SVD vs. Normalengleichungen

Der SVD-Zugang $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$ vermeidet die Schwächen der Normalengleichungen (Abschnitt 7.3): Er arbeitet direkt mit $\mathbf{A}$ statt mit $\mathbf{A}^\top \mathbf{A}$, quadriert die Konditionszahl also nicht, und behandelt rangdefiziente Probleme automatisch (Beispiel 7.6.2). Außerdem *konstruiert* (7.6.1) die Lösung explizit: Liegt die SVD vor, bleiben nur Matrix-Vektor-Produkte. Ein Vorbehalt: Die Pseudoinverse regularisiert exakt unidentifizierte Nullraumanteile, aber *keine* kleinen positiven Singulärwerte: Die Anteile längs der zugehörigen Singulärrichtungen verstärkt sie sogar um den Faktor $1/\sigma_i$. Gegen einen Fast-Rangdefekt helfen erst die abgeschnittene SVD oder die Tikhonov-Regularisierung.

Praktischer Methodenvergleich

Warum dann nicht immer die SVD? Weil sie am teuersten ist.

Bemerkung 7.6.3 (Anmerkungen zur Methodenwahl)

- Die QR-Zerlegung ist stabiler, aber langsamer als der Cholesky-Weg über die Normalengleichungen; sie ist die Standardwahl.
- Die SVD ist am langsamsten, aber sinnvoll, wenn $\mathbf{A}$ fast singulär ist, d. h. $\sigma_{\min}(\mathbf{A}) \approx 0 \implies \kappa(\mathbf{A}) \gg 1$.
- Wir können dann Σ_r verkleinern, indem wir die $r - k$ kleinsten Singulärwerte auf 0 setzen; das ist die Rang-k-Approximation aus Kapitel 6, hier als gezielte Glättung eines fast singulären Problems.
- Alle drei Methoden haben für $m \gg n$ eine Komplexität von $O(mn^2 + n^3)$, aber die Konstanten unterscheiden sich deutlich: Cholesky auf $\mathbf{A}^\top \mathbf{A}$ braucht etwa halb so viele Operationen wie Householder-QR, die SVD ein Mehrfaches davon.

Interaktiv: Wie teuer ist Stabilität?

Um welchen Faktor ist QR teurer als die Normalengleichungen, und hängt dieser Faktor von der Problemgröße ab? Die SVD-Konstante hängt vom Algorithmus ab (typisch 4–12, iterative Verfahren, vgl. Kapitel 6).

Interaktives Element — nur in der Web-Fassung

Für $m \gg n$ läuft QR gegen das Doppelte der Normalengleichungen: Stabilität kostet einen konstanten Faktor, keine Größenordnung.

Beispiel Ein KQ-Problem, drei Verfahren

Wir rechnen eine Regression mit *fast kollinearen* Spalten, deren wahre Lösung wir kennen:

```
set.seed(1)
m <- 100
x <- runif(m)
A <- cbind(1, x, x + 1e-6 * runif(m)) # 3. Spalte fast identisch zur 2.!
beta_wahr <- c(1, 2, 3)
b <- A %*% beta_wahr                # exakte Daten: Lösung = beta_wahr
kappa(A, exact = TRUE)
```

Hier ist $\kappa_2(\mathbf{A}) \approx 7 \cdot 10^6$, also $\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2 \approx 4 \cdot 10^{13}$. Doppelt genaue Gleitkommazahlen tragen rund 16 Dezimalstellen. Wie viele *korrekte* Stellen von $\boldsymbol{\beta}$ erwarten wir bei den Normalengleichungen (Fehler $\sim \kappa_2(\mathbf{A})^2 \varepsilon_{\text{mach}}$), wie viele bei QR und SVD (Fehler $\sim \kappa_2(\mathbf{A}) \varepsilon_{\text{mach}}$)?

```
beta_ne <- solve(t(A) %*% A, t(A) %*% b) # Normalengleichungen (ohne Inverse!)
beta_qr <- qr.solve(A, b)                # QR-Zerlegung
s <- svd(A)
beta_svd <- s$v %*% ((t(s$u) %*% b) / s$d) # SVD: A+ b
fehler <- function(beta_hat) max(abs(beta_hat - beta_wahr))
sapply(list("Normalengl." = beta_ne, QR = beta_qr, SVD = beta_svd), fehler)
```

Die Normalengleichungen liefern einen Fehler von etwa 10^{-2} , passend zu $\kappa_2(\mathbf{A})^2 \varepsilon_{\text{mach}} \approx 4 \cdot 10^{13} \cdot 2 \cdot 10^{-16} \approx 10^{-2}$. Es bleiben nur zwei bis drei korrekte Stellen, obwohl wir die Matrixinversion vermieden haben: Das Problem ist die quadrierte Konditionszahl, nicht (nur) $\text{solve}(\mathbf{M})$. QR und SVD liefern Fehler um 10^{-10} , passend zu $\kappa_2(\mathbf{A}) \varepsilon_{\text{mach}} \approx 10^{-9}$, also etwa zehn korrekte Stellen.

Interaktiv: Wie viele der 16 Stellen überleben?

Wie viele Stellen eine berechnete Lösung behält, hängt von der Maschinengenauigkeit ε , von $\kappa_2(\mathbf{A})$ und von der Größe des Residuums ab. Im Beispiel war das Residuum null; was ändert sich, wenn es groß ist? Erst schätzen, dann im Widget nachsehen.

Interaktives Element — nur in der Web-Fassung

Bei den Normalengleichungen wirkt $\kappa_2(\mathbf{A})^2$ auch dort, wo das Problem selbst nur $\kappa_2(\mathbf{A})$ verlangt; das trennt sie bei kleinem Residuum von QR.

Zusammenfassung: das Kapitel im Überblick

Die Bausteine des Kapitels:

- **Kleinste-Quadrate-Problem** (Abschnitt 7.1): minimiere $\|\mathbf{Ax} - \mathbf{b}\|_2$ für ein überbestimmtes LGS. Geometrisch: $\mathbf{A}\hat{\mathbf{x}}$ ist die Projektion von $\mathbf{b}$ auf $\text{col}(\mathbf{A})$.
- **Kondition** (Abschnitt 7.2): bzgl. $\mathbf{b}$ hängt sie vom Winkel zwischen $\mathbf{b}$ und $\text{col}(\mathbf{A})$ ab, bzgl. $\mathbf{A}$ ist sie typischerweise $O(\kappa_2(\mathbf{A})^2)$, also die quadrierte Konditionszahl.
- **Normalengleichungen + Cholesky** (Abschnitt 7.3): löse $\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}$ per Cholesky, möglich, weil $\mathbf{A}^\top \mathbf{A}$ für $\text{rang}(\mathbf{A}) = n$ SPD ist; $O(mn^2 + n^3)$. Schnell, aber wegen $\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2$ potenziell instabil. Und: keine Matrix explizit invertieren.
- **QR-Zerlegung** (Abschnitte 7.4–7.5): $\mathbf{A} = \mathbf{Q} \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix}$, löse $\mathbf{R}\mathbf{x} = \mathbf{c}_1$ mit $\mathbf{Q}^\top \mathbf{b} = \begin{pmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{pmatrix}$; $O(mn^2)$. Stabil, quadriert die Kondition nicht und ist die Standardwahl.
- **SVD und Pseudoinverse** (dieser Abschnitt): $\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b}$; $O(\min(m^2 n, mn^2))$ mit großen Konstanten. Am stabilsten, funktioniert auch für rangdefiziente $\mathbf{A}$ und liefert dann die Minimal-Norm-Lösung.

Interaktiv: Welche Methode wählen wir wann?

Form von $\mathbf{A}$, Kondition und Anspruch lassen sich hier frei kombinieren. Welche der drei Einstellungen ändert die Empfehlung am häufigsten?

Interaktives Element — nur in der Web-Fassung

Die Empfehlung hängt fast nur an zwei Fragen: Ist $\mathbf{A}$ (fast) rangdefekt, und wie groß ist $\kappa_2(\mathbf{A})$? Der Aufwand entscheidet erst, wenn beide Antworten unkritisch ausfallen.

Selbsttest

1. Stellen wir im Aufwands-Widget das Seitenverhältnis auf $m/n = 10$. Welchen Wert zeigt der Marker für $W(\text{QR})/W(\text{NE})$?

Lösung: 1.87

Mit $W_{\text{NE}} = mn^2/2 + n^3/6$ und $W_{\text{QR}} = mn^2 - n^3/3$ ist das Verhältnis $(r - 1/3)/(r/2 + 1/6)$ mit $r = m/n$, für $r = 10$ also $9,667/5,167 = 1,87$. Es hängt nur von r ab, nicht von n ; der n -Regler ändert daran nichts.

2. Weil die SVD am stabilsten ist, sollte man KQ-Probleme grundsätzlich über die Pseudoinverse lösen.

Antwort: Falsch

Die SVD kostet ein Vielfaches von QR (das Aufwands-Widget zeigt Faktoren von etwa 7 bis 18). Für gut konditionierte Probleme ist dieser Aufwand nicht zu rechtfertigen; sinnvoll wird die SVD bei (fast) rangdefizientem $\mathbf{A}$ (Bemerkung 7.6.3).

3. Die Pseudoinverse regularisiert exakt unidentifizierte Nullraumanteile, aber keine kleinen positiven Singulärwerte.

Antwort: Wahr

Für $\sigma_i > 0$ steht in Σ_r^{-1} der Faktor $1/\sigma_i$, und der wird bei kleinem σ_i riesig. Gegen einen Fast-Rangdefekt helfen erst die abgeschnittene SVD oder Tikhonov-Regularisierung.

4. Bei großem Residuum verlieren QR und Normalengleichungen ähnlich viele Stellen.

Antwort: Wahr

Sobald $\|\mathbf{r}\|_2 \kappa_2(\mathbf{A}) > 1$ ist, dominiert der Term $\|\mathbf{r}\|_2 \kappa_2(\mathbf{A})^2 \varepsilon$ auch den QR-Fehler. Das Genauigkeits-Widget zeigt es: Beide Balken schrumpfen dann gleichermaßen. Der Unterschied zwischen den Verfahren zeigt sich bei kleinem Residuum.

Kapitel 8 wechselt die Perspektive zu probabilistischen und iterativen Methoden.

Vertiefung: Heath §3.6 (SVD und Pseudoinverse) und §3.7 (Methodenvergleich); MML §7.1 verbindet Kleinste Quadrate mit dem Gradientenblick auf Optimierung.

7.7 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den

Kurstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 3.2	Ausgleichsgerade über Normalengleichungen und Cholesky	leicht, ca. 30 Min.
Heath Exercise 3.17	Householder-Transformation für $(1, 1, 1, 1)^T$	mittel, ca. 15 Min.
Heath Exercise 3.19	Elimination, Householder-Reflexion und Givens-Rotation im Vergleich	mittel, ca. 30 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 3.3	Nichtlineare Basisfunktionen in einem linearen KQ-Problem	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 3.5	Orthogonalprojektion auf einen Unterraum des $\mathbb{R}^5$	mittel, ca. 30 Min.
Heath Exercise 3.26	Drehung oder Spiegelung? Geometrie der 2×2 -Orthogonalmatrizen	leicht, ca. 15 Min.

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuflhard/Hohmann Aufgabe 3.1	Eine Givens-Rotation in einer einzigen Zahl speichern	schwer, 1 Std. und mehr

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deuflhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.); Deisenroth et al. (MML): *Mathematics for Machine Learning*.

Numerische Lineare Algebra: Iteration & Zufall

8.1 Eigenwertprobleme: Potenzmethode und QR-Iteration

Die numerische lineare Algebra ist ein großes Feld. Bisher haben wir vor allem eine ihrer Kernideen genutzt, die *Matrixzerlegung*: LU, Cholesky, QR und die SVD schreiben die Matrix als Produkt von Faktoren mit handlicher Struktur und rechnen dann mit diesen Faktoren weiter. In diesem Kapitel kommen zwei weitere Kernideen dazu:

- *Iterative Methoden* erzeugen eine Folge von Näherungen und brechen ab, sobald eine davon genau genug ist. Sie tauschen Genauigkeit gegen Laufzeit.
- *Probabilistische Methoden* ersetzen ein großes Problem durch ein kleineres, dessen Lösung der gesuchten mit hoher Wahrscheinlichkeit sehr nahe kommt.

An beiden wird aktiv geforscht. Die iterative Idee behandeln wir am Eigenwertproblem (dieser Abschnitt und Abschnitt 8.2) und an linearen Gleichungssystemen (Abschnitt 8.3), die probabilistische in Abschnitt 8.4.

Was wir mitbringen

Aus den bisherigen Kapiteln brauchen wir:

- die Komplexitätsanalyse mit der O -Notation (Abschnitt 2.4),
- Kondition und Stabilität (Abschnitt 4.2, Abschnitt 4.3),
- Orthogonalmatrizen (Definition 3.3.5) und die Spektralnorm $\|\cdot\|_2$ (Abschnitt 3.3),
- lineare Gleichungssysteme samt ihrer direkten Lösungsverfahren (Kapitel 5) und die QR-Zerlegung (Abschnitt 7.4).

Aus der linearen Algebra kommen Eigenwerte und Eigenvektoren und Ähnlichkeitstransformationen $\mathbf{B} = \mathbf{Q}\mathbf{A}\mathbf{Q}^{-1}$ dazu, aus der Analysis die Konvergenz von Folgen und die geometrische Reihe $\sum_{k \geq 0} p^k = 1/(1-p)$ für $|p| < 1$, in Abschnitt 8.4 außerdem Zufallsvektoren.

Eigenwerte ohne charakteristisches Polynom

Gesucht sind Paare aus Eigenwert und Eigenvektor, also λ und $\mathbf{v} \neq \mathbf{0}$ mit $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$. Ein direktes Verfahren dafür kennen wir aus der linearen Algebra: die Nullstellen des charakteristischen Polynoms $\det(\mathbf{A} - \lambda\mathbf{I}) = 0$. Als Algorithmus taugt dieser Weg allerdings wenig.

Bemerkung 8.1.1 (Warum das charakteristische Polynom kein Algorithmus ist)

Für eine $n \times n$ -Matrix hat das charakteristische Polynom den Grad n . Das bringt drei Probleme mit sich:

1. Ab $n \geq 5$ gibt es keine allgemeine Lösungsformel für Polynomnullstellen mehr. Wir müssten die Nullstellen also ohnehin iterativ suchen und hätten nichts gewonnen.
2. Der Umweg über die Koeffizienten ist numerisch instabil: Winzige Störungen der Koeffizienten können die Nullstellen weit verschieben, das Problem ist also schlecht konditioniert (Abschnitt 4.2).
3. Er ist teuer. Schon das Aufstellen der Koeffizienten kostet $O(n^4)$ oder mehr, während wir für eine ganze Matrixzerlegung mit $O(n^3)$ auskommen.

Auch die numerische lineare Algebra kennt direkte Eigenwertverfahren. In drei Situationen iterieren wir trotzdem lieber:

- bei großen Matrizen ($n > 1000$), wo $O(n^3)$ zu teuer wird,
- bei dünnbesetzten Matrizen, deren Struktur direkte Verfahren zerstören, weil sie die Nullen mit Zwischenergebnissen auffüllen,
- wenn wir gar nicht alle Eigenwerte brauchen, sondern nur wenige, etwa die $k \ll n$ größten.

Iterative Verfahren kommen oft mit Matrix-Vektor-Produkten als einziger Operation an A aus und nutzen so die Dünnbesetztheit. Über die Abbruchbedingung steuern wir außerdem, wie viel Genauigkeit wir gegen Laufzeit tauschen.

Die Potenzmethode

Das einfachste iterative Verfahren ist die *Potenzmethode* (power iteration, nach von Mises). Sie berechnet den betragsgrößten Eigenwert λ_1 und einen zugehörigen Eigenvektor $\mathbf{v}_1$, vorausgesetzt, dieser Eigenwert ist betragsmäßig von den übrigen getrennt. Die Idee: Wir wenden A immer wieder an und normieren nach jedem Schritt.

Algorithmus 8.1.2 (Potenzmethode)

Gegeben seien $A \in \mathbb{R}^{n \times n}$ und ein Startvektor $\mathbf{x}^{(0)} \neq \mathbf{0}$.

1. Normiere den Start: $\mathbf{x}^{(0)} \leftarrow \mathbf{x}^{(0)} / \|\mathbf{x}^{(0)}\|$.
2. Für $k = 1, 2, \dots$:
 - (a) $\mathbf{y} = A \mathbf{x}^{(k-1)}$,
 - (b) $\lambda^{(k)} = \|\mathbf{y}\|$,
 - (c) $\mathbf{x}^{(k)} = \mathbf{y} / \lambda^{(k)}$.
3. Brich ab, sobald das Residuum $\|A \mathbf{x}^{(k)} - \lambda^{(k)} \mathbf{x}^{(k)}\|$ klein genug ist.

Pro Schritt fällt genau ein Matrix-Vektor-Produkt an. Für eine volle Matrix kostet das $O(n^2)$, für eine dünnbesetzte nur so viel, wie sie Einträge ungleich null hat. A selbst wird weder zerlegt noch umgeformt.

Bemerkung 8.1.3 (Zwei Schätzungen für den Eigenwert)

Ohne Normierung, also für die rohe Iteration $\mathbf{z}^{(k)} = \mathbf{A}\mathbf{z}^{(k-1)}$, wächst die Länge in jedem Schritt um ungefähr den Faktor $|\lambda_1|$, und der Quotient $\|\mathbf{z}^{(k)}\| / \|\mathbf{z}^{(k-1)}\|$ strebt gegen $|\lambda_1|$. In Algorithmus 8.1.2 ist der Nenner gleich 1, weil $\mathbf{x}^{(k-1)}$ normiert ist; derselbe Streckfaktor heißt dort $\lambda^{(k)} = \|\mathbf{A}\mathbf{x}^{(k-1)}\|$. Weil eine Länge kein Vorzeichen hat, konvergiert er gegen $|\lambda_1|$. Das Vorzeichen bringt der *Rayleigh-Quotient* mit,

$$\rho^{(k)} = \frac{\mathbf{x}^{(k)\top} \mathbf{A} \mathbf{x}^{(k)}}{\mathbf{x}^{(k)\top} \mathbf{x}^{(k)}} = \mathbf{x}^{(k)\top} \mathbf{A} \mathbf{x}^{(k)},$$

wobei der Nenner wegen der Normierung gleich 1 ist.

Warum funktioniert das? Sei $\mathbf{A}$ diagonalisierbar mit Eigenvektoren $\mathbf{v}_1, \dots, \mathbf{v}_n$, und der Start habe die Darstellung $\mathbf{x}^{(0)} = \sum_{i=1}^n c_i \mathbf{v}_i$. Wegen $\mathbf{A}\mathbf{v}_i = \lambda_i \mathbf{v}_i$ ist $\mathbf{A}^k \mathbf{v}_i = \lambda_i^k \mathbf{v}_i$, also $\mathbf{A}^k \mathbf{x}^{(0)} = \sum_{i=1}^n c_i \lambda_i^k \mathbf{v}_i$. Klammern wir den größten Faktor aus:

$$\mathbf{A}^k \mathbf{x}^{(0)} = \lambda_1^k \left(c_1 \mathbf{v}_1 + \underbrace{\sum_{i=2}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{v}_i}_{=\mathbf{s}_k} \right). \quad (8.1.1)$$

Ist $|\lambda_1|$ echt größer als alle übrigen $|\lambda_i|$, so dämpft jede Anwendung von $\mathbf{A}$ die i -te Komponente gegenüber der ersten um den Faktor $|\lambda_i/\lambda_1| < 1$. Der rote Rest $\mathbf{s}_k$ geht deshalb gegen null, und nach dem Normieren bleibt $\pm \mathbf{v}_1$ übrig, sofern $c_1 \neq 0$ ist.

Satz 8.1.4 (Konvergenz der Potenzmethode)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ diagonalisierbar mit einer Basis aus normierten Eigenvektoren $\mathbf{v}_1, \dots, \mathbf{v}_n$ und Eigenwerten $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$. Der Startvektor habe die Darstellung $\mathbf{x}^{(0)} = \sum_{i=1}^n c_i \mathbf{v}_i$ mit $c_1 \neq 0$. Dann gilt für die Iterierten aus Algorithmus 8.1.2

$$\mathbf{x}^{(k)} = \pm \mathbf{v}_1 + \mathbf{r}_k \quad \text{mit} \quad \|\mathbf{r}_k\| \leq C \left(\left| \frac{\lambda_2}{\lambda_1} \right| \right)^k \quad \text{für alle hinreichend großen } k$$

und einer von k unabhängigen Konstanten C , sowie $\lambda^{(k)} \rightarrow |\lambda_1|$. Für $\lambda_1 > 0$ ist das Vorzeichen dabei für alle k dasselbe, für $\lambda_1 < 0$ wechselt es in jedem Schritt.

Vertiefung (optional): Beweis der Konvergenz der Potenzmethode

Beweis.

- (1) Wir gehen von (8.1.1) aus. Das Ausklammern ist erlaubt, weil $|\lambda_1| > |\lambda_2| \geq 0$ und damit $\lambda_1 \neq 0$ ist. Der rote Restterm verschwindet mit einer geometrischen Rate:

$$\|\mathbf{s}_k\| \leq \sum_{i=2}^n |c_i| \left(\left| \frac{\lambda_i}{\lambda_1} \right| \right)^k \leq \left(\sum_{i=2}^n |c_i| \right) \left(\left| \frac{\lambda_2}{\lambda_1} \right| \right)^k \rightarrow 0.$$

Übrig bleibt in der Klammer von (8.1.1) nur $c_1 \mathbf{v}_1$.

Dreiecksungleichung und $\|\mathbf{v}_i\| = 1$; danach $|\lambda_i| \leq |\lambda_2|$ für alle $i \geq 2$. Die Potenzen einer Zahl mit Betrag kleiner als 1 bilden eine Nullfolge

- (2) Die Normierung in Algorithmus 8.1.2 ändert an der *Richtung* nichts. Per Induktion gilt

$$\mathbf{x}^{(k)} = \frac{\mathbf{A}^k \mathbf{x}^{(0)}}{\|\mathbf{A}^k \mathbf{x}^{(0)}\|}.$$

für $k = 1$ ist das die Vorschrift selbst; und ist $\mathbf{x}^{(k-1)}$ das normierte $\mathbf{A}^{k-1} \mathbf{x}^{(0)}$, so ist $\mathbf{A} \mathbf{x}^{(k-1)}$ ein positives Vielfaches von $\mathbf{A}^k \mathbf{x}^{(0)}$, und Normieren löscht diesen Faktor wieder aus

- (3) Einsetzen von (8.1.1) liefert die Behauptung: Mit $\mathbf{w}_k = c_1 \mathbf{v}_1 + \mathbf{s}_k$ ist

$$\mathbf{x}^{(k)} = \frac{\lambda_1^k \mathbf{w}_k}{|\lambda_1|^k \|\mathbf{w}_k\|} = \text{sign}(\lambda_1)^k \cdot \frac{\mathbf{w}_k}{\|\mathbf{w}_k\|} \rightarrow \pm \mathbf{v}_1,$$

denn $\mathbf{w}_k \rightarrow c_1 \mathbf{v}_1$ und $c_1 \neq 0$. Das verbleibende Vorzeichen ist das von c_1 , multipliziert mit $\text{sign}(\lambda_1)^k$. Weil der Fehler in $\mathbf{w}_k$ nach dem ersten Beweisschritt wie $|\lambda_2/\lambda_1|^k$ fällt, tut es der Fehler des normierten Vektors ebenso. Für die Eigenwertschätzung folgt schließlich

$$\lambda^{(k)} = \|\mathbf{A} \mathbf{x}^{(k-1)}\| \rightarrow \|\mathbf{A}(\pm \mathbf{v}_1)\| = |\lambda_1|.$$

Normieren ist stetig, solange der Nenner nicht gegen null geht, und $\|\mathbf{w}_k\| \rightarrow |c_1| > 0$

□

Beispiel 8.1.5 (Potenzmethode an einer 2×2-Matrix)

Sei

$$\mathbf{A} = \begin{pmatrix} 5 & -2 \\ -2 & 8 \end{pmatrix}.$$

Das charakteristische Polynom ist

$$\det(\mathbf{A} - \lambda \mathbf{I}) = (5 - \lambda)(8 - \lambda) - 4 = \lambda^2 - 13\lambda + 36 = (\lambda - 9)(\lambda - 4),$$

also $\lambda_1 = 9$ und $\lambda_2 = 4$. Die Eigenvektoren lesen wir aus $(\mathbf{A} - \lambda \mathbf{I})\mathbf{v} = \mathbf{0}$ mit $\mathbf{v} = (a, b)^\top$ ab: Für $\lambda = 9$ heißt die erste Zeile $-4a - 2b = 0$, also $b = -2a$; für $\lambda = 4$ heißt sie $a - 2b = 0$, also $a = 2b$. Normiert ergibt das

$$\mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} -1 \\ 2 \end{pmatrix} \approx \begin{pmatrix} -0,447 \\ 0,894 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$$

Die beiden stehen senkrecht aufeinander, wie es der Spektralsatz für symmetrische Matrizen verlangt. Die zu erwartende Konvergenzrate ist $\lambda_2/\lambda_1 = 4/9 \approx 0,444$.

Wir starten mit $\mathbf{x}^{(0)} = (2; 1,3)^\top$. Weil die Eigenvektoren eine Orthonormalbasis bilden, sind die Koeffizienten der Basisdarstellung die Skalarprodukte:

$$c_1 = \mathbf{v}_1^\top \mathbf{x}^{(0)} = \frac{-2 + 2,6}{\sqrt{5}} \approx 0,268, \quad c_2 = \mathbf{v}_2^\top \mathbf{x}^{(0)} = \frac{4 + 1,3}{\sqrt{5}} \approx 2,370.$$

Der Start liegt also fast in Richtung $\mathbf{v}_2$, und c_1 ist knapp neunmal kleiner als c_2 . Nach (8.1.1) muss die Iteration diesen Rückstand erst aufholen; das zeigen die ersten Schritte:

k	$\mathbf{x}^{(k)}$	$\lambda^{(k)}$	$\rho^{(k)}$	$\sin \angle(\mathbf{x}^{(k)}, \mathbf{v}_1)$
0	(0,838; 0,545)	–	4,063	0,994
1	(0,756; 0,654)	4,102	4,305	0,969
2	(0,554; 0,833)	4,468	5,236	0,868
3	(0,195; 0,981)	5,663	7,122	0,613
4	(–0,131; 0,991)	7,523	8,469	0,326
5	(–0,307; 0,952)	8,608	8,885	0,151
6	(–0,385; 0,923)	8,917	8,977	0,068
8	(–0,435; 0,900)	8,997	8,999	0,013
10	(–0,445; 0,896)	9,000	9,000	0,003

Erst nach vier Schritten liegt die Iterierte im richtigen Quadranten; bis dahin dominiert der $\mathbf{v}_2$ -Anteil. Danach schrumpft der Winkelrest in jedem Schritt auf ungefähr das 0,444-Fache, wie Satz 8.1.4 vorhersagt: $0,151/0,326 \approx 0,46$ und $0,068/0,151 \approx 0,45$. Beide Eigenwertschätzungen konvergieren schneller als die Richtung. Ihr Fehler fällt pro Schritt auf ungefähr das $(\lambda_2/\lambda_1)^2 \approx 0,198$ -Fache, also mit dem Quadrat der Rate.

Vertiefung (optional): Genauigkeit der beiden Schätzungen

Für symmetrische A ist der Rayleigh-Quotient die bessere Wahl. Beide Schätzungen sind dort quadratische Ausdrücke im Winkel zwischen $\mathbf{x}^{(k)}$ und $\mathbf{v}_1$, ihr Fehler fällt also mit $(\lambda_2/\lambda_1)^{2k}$ und damit doppelt so schnell wie der Winkel selbst; der Rayleigh-Quotient liegt dabei um einen konstanten Faktor näher dran. In Beispiel 8.1.5 geht sein Fehler von $k = 8$ auf $k = 10$ von $-9,0 \cdot 10^{-4}$ auf $-3,5 \cdot 10^{-5}$ zurück, der Fehler der Normschätzung von $-3,3 \cdot 10^{-3}$ auf $-1,3 \cdot 10^{-4}$: gleich schnell, aber asymptotisch um den Faktor 3,7 genauer. Ist A nicht symmetrisch, stehen die Eigenvektoren nicht mehr senkrecht aufeinander, und beide Schätzungen sind nur noch linear genau.

Auch ins Abbruchkriterium von Algorithmus 8.1.2 gehört $\rho^{(k)}$, sobald λ_1 negativ sein kann. Für $\lambda_1 < 0$ wechselt $\mathbf{x}^{(k)}$ nämlich in jedem Schritt das Vorzeichen, und das Residuum mit $\lambda^{(k)} = |\lambda_1|$ bliebe bei ungefähr $2|\lambda_1|$ hängen, statt gegen null zu gehen.

Bemerkung 8.1.6 (Wann die Potenzmethode versagt)

Zwei Voraussetzungen von Satz 8.1.4 können verletzt sein. Dann liefert das Verfahren nicht λ_1 und $\mathbf{v}_1$.

Kein Anteil in Richtung $\mathbf{v}_1$. Ist $c_1 = 0$, so fehlt in (8.1.1) der grüne Term. Die Iteration läuft dann gegen die Eigenrichtung mit dem betragsgrößten Eigenwert, der im Startvektor überhaupt vertreten ist. Für symmetrisches A sind die Eigenvektoren orthogonal, dort heißt $c_1 = \mathbf{v}_1^\top \mathbf{x}^{(0)} = 0$ also: Der Startvektor steht senkrecht auf dem gesuchten Eigenvektor. In der Praxis ist das selten ein Problem: Ein zufällig gewählter Startvektor erfüllt $c_1 \neq 0$ mit Wahrscheinlichkeit 1, und Rundungsfehler bringen beim Rechnen ohnehin einen kleinen $\mathbf{v}_1$ -Anteil hinein, den die Iteration dann verstärkt.

Kein separierter größter Eigenwert. Gilt $|\lambda_1| = |\lambda_2|$ mit $\lambda_2 \neq \lambda_1$, etwa bei $\lambda_2 = -\lambda_1$ oder bei einem komplexen Eigenwertpaar, so ist die Rate $|\lambda_2/\lambda_1| = 1$, und die Iterierten laufen gegen keine feste Richtung mehr. Und selbst wenn die beiden nur *nahe* beieinanderliegen, wird die Methode sehr langsam. In beiden Fällen brauchen wir andere Verfahren.

Interaktiv: Die Potenzmethode Schritt für Schritt

Was geschieht, wenn der Start genau auf der zweiten Eigenrichtung liegt? Ziehen wir den Startvektor auf dem Einheitskreis dorthin und vergleichen wir mit anderen Starts.

Interaktives Element — nur in der Web-Fassung

Auf $\mathbf{v}_2$ gestartet, bleibt die normierte Iterierte für immer stehen; dieser Ausnahmefall ist eine Nullmenge. Von jedem anderen Start aus schrumpft der Winkelrest auf Dauer in jedem Schritt auf das $|\lambda_2/\lambda_1|$ -Fache. Die Rate hängt an der Matrix, nicht am Start.

1. Welche Rate zeigt der Potenzmethoden-Stepper für die Beispielmatrix langfristig an?

Lösung: 0.4444444444

Der orange Wert nähert sich dem Verhältnis der beiden Eigenwertbeträge.

Ähnliche Matrizen als Werkzeug

Die Potenzmethode liefert einen Eigenwert. Wollen wir alle, brauchen wir eine andere Idee: Wir überführen A in eine Matrix B , der wir die Eigenwerte ansehen können, ohne sie dabei zu verändern. Das leisten Ähnlichkeitstransformationen.

Satz 8.1.7 (Ähnliche Matrizen haben dieselben Eigenwerte)

Sei $B = QAQ^{-1}$ mit invertierbarem $Q \in \mathbb{R}^{n \times n}$, also B ähnlich zu A . Dann gilt:

1. A und B haben dasselbe charakteristische Polynom, insbesondere dieselben Eigenwerte mit denselben Vielfachheiten, dieselbe Determinante und dieselbe Spur.
2. Ist $\mathbf{y}$ Eigenvektor von B zum Eigenwert λ , so ist $\mathbf{x} = Q^{-1}\mathbf{y}$ Eigenvektor von A zum selben Eigenwert.

Teil (2) folgt direkt aus der Definition von B . Aus $B\mathbf{y} = \lambda\mathbf{y}$ wird

$$QAQ^{-1}\mathbf{y} = \lambda\mathbf{y} \implies A Q^{-1}\mathbf{y} = \lambda Q^{-1}\mathbf{y} \implies A\mathbf{x} = \lambda\mathbf{x},$$

wobei wir von links mit Q^{-1} multipliziert haben. Dabei ist $\mathbf{x} = Q^{-1}\mathbf{y} \neq \mathbf{0}$, weil Q^{-1} invertierbar ist und $\mathbf{y} \neq \mathbf{0}$.

Vertiefung (optional): Beweis von Teil 1 über das charakteristische Polynom

Beweis.

- (1) Wir schieben $I = QQ^{-1}$ in den zweiten Summanden und verwenden die Multiplikativität der Determinante:

$$\det(B - \lambda I) = \det(Q(A - \lambda I)Q^{-1}) = \det(Q) \det(A - \lambda I) \det(Q)^{-1} = \det(A - \lambda I).$$

Beide Matrizen haben also dasselbe charakteristische Polynom und damit dieselben Eigenwerte samt Vielfachheiten.

$QAQ^{-1} - \lambda QIQ^{-1} = Q(A - \lambda I)Q^{-1}$, und $\det(Q)^{-1} = \det(Q^{-1})$ ist wegen der Invertierbarkeit definiert

- (2) Für $\lambda = 0$ liefert das $\det(B) = \det(A)$. Die Gleichheit der Spuren steht schon in Abschnitt 3.1: Die Spur ist zyklisch, also $\text{tr}(QAQ^{-1}) = \text{tr}(AQ^{-1}Q) = \text{tr}(A)$.

alternativ über das charakteristische Polynom: Spur und Determinante sind bis aufs Vorzeichen zwei seiner Koeffizienten, und die stimmen nach Schritt 1 überein

□

Ist $\mathbf{B}$ diagonal, stehen die Eigenwerte auf der Diagonalen.

Beispiel 8.1.8 (Diagonalisierung durch eine Orthogonalmatrix)

Wir bleiben bei $\mathbf{A}$ aus Beispiel 8.1.5 und wählen

$$\mathbf{Q} = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix} \quad \text{mit} \quad \mathbf{Q}^\top \mathbf{Q} = \mathbf{I}.$$

$\mathbf{Q}$ ist orthogonal, also ist $\mathbf{Q}^{-1} = \mathbf{Q}^\top$ und die Ähnlichkeitstransformation $\mathbf{B} = \mathbf{Q}\mathbf{A}\mathbf{Q}^\top$ kommt ohne Inversion aus. Wir rechnen in zwei Etappen, zuerst

$$\mathbf{A}\mathbf{Q}^\top = \frac{1}{\sqrt{5}} \begin{pmatrix} 5 & -2 \\ -2 & 8 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix} = \frac{1}{\sqrt{5}} \begin{pmatrix} 8 & 9 \\ 4 & -18 \end{pmatrix},$$

denn etwa der Eintrag links oben ist $5 \cdot 2 + (-2) \cdot 1 = 8$. Dann

$$\mathbf{B} = \mathbf{Q}(\mathbf{A}\mathbf{Q}^\top) = \frac{1}{5} \begin{pmatrix} 2 & 1 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 8 & 9 \\ 4 & -18 \end{pmatrix} = \frac{1}{5} \begin{pmatrix} 20 & 0 \\ 0 & 45 \end{pmatrix} = \begin{pmatrix} 4 & 0 \\ 0 & 9 \end{pmatrix}.$$

Die beiden Nullen entstehen, weil die Zeilen von $\mathbf{Q}$ gerade die Eigenvektoren von $\mathbf{A}$ sind. Auf der Diagonalen stehen deshalb die Eigenwerte, und sie stimmen mit den Nullstellen des charakteristischen Polynoms aus Beispiel 8.1.5 überein.

Vertiefung (optional): Reihenfolge der Eigenwerte und Rücktransformation

Dass (4, 9) und nicht (9, 4) auf der Diagonalen steht, liegt an der Spaltenwahl: Die erste Spalte von $\mathbf{Q}^\top$ ist $\mathbf{v}_2$, die zweite $-\mathbf{v}_1$. Mit vertauschten Spalten stünde dort (9, 4). Im übrigen Kapitel sortieren wir wie bei der Potenzmethode absteigend, $\lambda_1 = 9 \geq \lambda_2 = 4$.

Auch Satz 8.1.7(2) lässt sich hier ablesen: $\mathbf{y} = \mathbf{e}_2$ ist Eigenvektor von $\mathbf{B}$ zum Eigenwert 9, und $\mathbf{x} = \mathbf{Q}^{-1}\mathbf{e}_2 = \mathbf{Q}^\top \mathbf{e}_2 = \frac{1}{\sqrt{5}}(1, -2)^\top = -\mathbf{v}_1$ ist Eigenvektor von $\mathbf{A}$ zu demselben Eigenwert.

Bemerkung 8.1.9 (Welche Zielgestalt, welches Verfahren)

In Beispiel 8.1.8 kannten wir die Eigenvektoren schon und haben $\mathbf{Q}$ daraus gebaut. Ein Algorithmus muss ein passendes $\mathbf{Q}$ erst finden, und zwar iterativ: Er erzeugt eine Folge $\mathbf{B}^{(k)}$ von zu $\mathbf{A}$ ähnlichen Matrizen, die einer Zielgestalt immer näher kommt. Die Verfahren unterscheiden sich in der Zielgestalt:

- Die *QR-Iteration* strebt eine obere Dreiecksmatrix an, die *Schur-Zerlegung*; auf ihrer Diagonalen stehen die Eigenwerte. Analog gibt es LU- und Cholesky-Iterationen.
- Die *Lanczos-Iteration* strebt eine Tridiagonalmatrix an, also $b_{ij} = 0$ für $|i - j| > 1$, und lässt sich auf die wichtigsten Eigenwerte einschränken. Für große dünnbesetzte Matrizen ist sie deutlich effizienter.

In der Praxis kommen zu beiden noch Techniken hinzu, die sie stabil und schnell genug machen: *Shifted QR* und *Implicitly Restarted Lanczos*.

Die QR-Iteration

Die QR-Iteration zerlegt die aktuelle Matrix in QR und multipliziert die beiden Faktoren in umgekehrter Reihenfolge wieder zusammen.

Algorithmus 8.1.10 (QR-Iteration)

Gegeben sei $A \in \mathbb{R}^{n \times n}$.

1. Starte mit $A^{(0)} = A$.
2. Für $k = 1, 2, \dots$:
 - (a) Berechne die QR-Zerlegung $A^{(k-1)} = Q^{(k)} R^{(k)}$ (Abschnitt 7.4).
 - (b) Setze $A^{(k)} = R^{(k)} Q^{(k)}$.

Der zweite Schritt sieht willkürlich aus, ist aber eine Ähnlichkeitstransformation. Wegen $R^{(k)} = (Q^{(k)})^\top A^{(k-1)}$ ist nämlich

$$A^{(k)} = R^{(k)} Q^{(k)} = (Q^{(k)})^\top A^{(k-1)} Q^{(k)}.$$

Satz 8.1.11 (Die Iterierten sind ähnlich zu A)

Mit $Q_k := Q^{(1)} Q^{(2)} \dots Q^{(k)}$ gilt für die Iterierten aus Algorithmus 8.1.10

$$A^{(k)} = Q_k^\top A Q_k. \quad (8.1.2)$$

Insbesondere ist jedes $A^{(k)}$ ähnlich zu A und hat nach Satz 8.1.7 dieselben Eigenwerte.

Die Iteration verändert die Eigenwerte also nicht. Den Schlüssel zu ihrer Konvergenz liefert der folgende Satz.

Satz 8.1.12 (Die QR-Iteration zerlegt die Potenzen von A)

Mit $Q_k := Q^{(1)} Q^{(2)} \dots Q^{(k)}$ und $R_k := R^{(k)} R^{(k-1)} \dots R^{(1)}$ gilt für alle $k \geq 1$

$$A^k = Q_k R_k. \quad (8.1.3)$$

Die Faktoren der QR-Iteration liefern also nebenbei die QR-Zerlegung der k -ten Potenz von A .

Vertiefung (optional): Beweise der Ähnlichkeit und der Potenzzerlegung

Zu Satz 8.1.11:

Beweis.

- (1) Jedes $Q^{(j)}$ ist orthogonal, also ist auch das Produkt Q_k orthogonal und es gilt $Q_k^{-1} = Q_k^\top$.

Produkte von Orthogonalmatrizen sind orthogonal: $(QP)^\top (QP) = P^\top Q^\top QP = P^\top P = I$

- (2) Die Behauptung folgt per Induktion. Für $k = 1$ ist $A^{(1)} = (Q^{(1)})^\top A Q^{(1)} = Q_1^\top A Q_1$. Gilt sie für $k - 1$, so ist

$$A^{(k)} = (Q^{(k)})^\top A^{(k-1)} Q^{(k)} = (Q^{(k)})^\top Q_{k-1}^\top A Q_{k-1} Q^{(k)} = Q_k^\top A Q_k.$$

$Q_{k-1} Q^{(k)} = Q_k$ nach Definition, und $(Q_{k-1} Q^{(k)})^\top = (Q^{(k)})^\top Q_{k-1}^\top$

Zu Satz 8.1.12:

Beweis.

- (1) *Induktionsanfang* $k = 1$: Der erste Schritt zerlegt $A = A^{(0)} = Q^{(1)}R^{(1)} = Q_1R_1$.
für $k = 1$ sind $Q_1 = Q^{(1)}$ und $R_1 = R^{(1)}$ genau die Faktoren des ersten Iterationsschritts
- (2) Die Rechenregel für den Induktionsschritt: Für jedes i ist $A^{(i)} = R^{(i)}Q^{(i)}$ nach Algorithmus 8.1.10 und $A^{(i)} = Q^{(i+1)}R^{(i+1)}$ nach der Zerlegung im nächsten Schritt, also

$$R^{(i)}Q^{(i)} = Q^{(i+1)}R^{(i+1)}. \quad (*)$$

dieselbe Matrix $A^{(i)}$, einmal als Ergebnis von Schritt i und einmal als Eingang von Schritt $i + 1$ gelesen

- (3) *Induktionsschritt* $k \rightarrow k + 1$: Wir setzen die Induktionsvoraussetzung ein und schieben dann k -mal $(*)$ von links nach rechts durch das Produkt.

$$\begin{aligned} A^{k+1} &= A A^k = (Q^{(1)}R^{(1)})(Q_kR_k) \\ &= Q^{(1)} \underbrace{(R^{(1)}Q^{(1)})}_{= Q^{(2)}R^{(2)}} Q^{(2)} \dots Q^{(k)} R^{(k)} \dots R^{(1)} \\ &= Q^{(1)}Q^{(2)} \underbrace{(R^{(2)}Q^{(2)})}_{= Q^{(3)}R^{(3)}} Q^{(3)} \dots Q^{(k)} R^{(k)} \dots R^{(1)} \\ &= \dots = Q^{(1)}Q^{(2)} \dots Q^{(k+1)} R^{(k+1)}R^{(k)} \dots R^{(1)} \\ &= Q_{k+1}R_{k+1}. \end{aligned}$$

in der zweiten Zeile ist Q_kR_k ausgeschrieben; jede Anwendung von $(*)$ tauscht ein $R^{(i)}Q^{(i)}$ gegen $Q^{(i+1)}R^{(i+1)}$ und schiebt so ein weiteres Q nach vorn

Bemerkung 8.1.13 (Die QR-Iteration ist eine simultane Potenzmethode)

Bei der üblichen Normierung mit positiven Diagonaleinträgen in R ist die QR-Zerlegung gerade das Gram-Schmidt-Verfahren auf den Spalten. Nach (8.1.3) sind die Spalten von Q_k deshalb die orthonormalisierten Versionen von

$$A^k e_1, \quad A^k e_2, \quad \dots, \quad A^k e_n.$$

Jede einzelne dieser Spalten ist eine unnormierte Iterierte der Potenzmethode, gestartet in einem Einheitsvektor. Die QR-Iteration ist also eine *simultane* Potenzmethode auf allen n Einheitsvektoren zugleich, mit einer Orthonormalisierung nach jedem Schritt. Ohne diese Orthonormalisierung liefen alle n Spalten gegen dieselbe Richtung v_1 , und die übrigen Eigenrichtungen gingen verloren.

Bemerkung 8.1.14 (Wogegen die QR-Iteration konvergiert)

Die Konvergenz braucht Voraussetzungen. Ein Gegenbeispiel ist die Drehung um 90° , $A = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$: Hier ist $Q^{(1)} = A$ und $R^{(1)} = I$, also $A^{(1)} = A$, und die Iteration steht für immer still. Ihre Eigenwerte $\pm i$ sind komplex und betragsgleich. Sind dagegen alle Eigenwerte reell und betragsmäßig getrennt,

$$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n| > 0,$$

so konvergiert $\mathbf{A}^{(k)}$ gegen eine obere Dreiecksmatrix mit den Eigenwerten auf der Diagonalen. Das ist die *Schur-Zerlegung* von $\mathbf{A}$. Die Einträge unterhalb der Diagonalen fallen dabei linear, der Eintrag an der Stelle (i, j) mit $i > j$ wie $|\lambda_i/\lambda_j|^k$; die langsamste dieser Raten gehört zum engsten Paar benachbarter Eigenwerte.

Ist $\mathbf{A}$ zusätzlich **symmetrisch**, so ist wegen (8.1.2) auch jedes $\mathbf{A}^{(k)} = \mathbf{Q}_k^\top \mathbf{A} \mathbf{Q}_k$ symmetrisch, und eine symmetrische obere Dreiecksmatrix ist diagonal. In diesem Fall gilt außerdem $\mathbf{A} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top$ mit orthogonalem $\mathbf{V}$ aus Eigenvektoren, und mit $\mathbf{Q}_k \rightarrow \mathbf{V}$ folgt

$$\mathbf{Q}_k^\top \mathbf{A} \mathbf{Q}_k \longrightarrow \mathbf{V}^\top \mathbf{A} \mathbf{V} = \mathbf{V}^\top \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top \mathbf{V} = \mathbf{\Lambda}.$$

Dass sich $\mathbf{V}^\top \mathbf{V}$ zweimal zur Einheitsmatrix kürzt, braucht ein *orthogonales* $\mathbf{V}$, und das liefert der Spektralsatz nur für symmetrisches $\mathbf{A}$. Im allgemeinen Fall konvergiert $\mathbf{Q}_k$ gegen den Orthogonalfaktor der Schur-Zerlegung; nur dessen erste Spalte ist ein Eigenvektor, die übrigen rechnen wir aus der Dreiecksmatrix zurück.

Beispiel 8.1.15 (QR-Iteration an der Beispielmatrix)

Wir nehmen wieder $\mathbf{A} = \begin{pmatrix} 5 & -2 \\ -2 & 8 \end{pmatrix}$ und rechnen den ersten Schritt von Hand. Gram-Schmidt auf den Spalten $\mathbf{a}_1 = (5, -2)^\top$ und $\mathbf{a}_2 = (-2, 8)^\top$ liefert

$$r_{11} = \|\mathbf{a}_1\| = \sqrt{29}, \quad \mathbf{q}_1 = \frac{1}{\sqrt{29}} \begin{pmatrix} 5 \\ -2 \end{pmatrix}, \quad r_{12} = \mathbf{q}_1^\top \mathbf{a}_2 = \frac{-10 - 16}{\sqrt{29}} = \frac{-26}{\sqrt{29}},$$

und nach Abzug der Projektion bleibt $\mathbf{w} = \mathbf{a}_2 - r_{12} \mathbf{q}_1 = \frac{36}{29} (2, 5)^\top$ mit $r_{22} = \|\mathbf{w}\| = 36/\sqrt{29}$. Zusammen also

$$\mathbf{Q}^{(1)} = \frac{1}{\sqrt{29}} \begin{pmatrix} 5 & 2 \\ -2 & 5 \end{pmatrix}, \quad \mathbf{R}^{(1)} = \frac{1}{\sqrt{29}} \begin{pmatrix} 29 & -26 \\ 0 & 36 \end{pmatrix}.$$

Probe: $r_{11} r_{22} = \sqrt{29} \cdot 36/\sqrt{29} = 36 = \det(\mathbf{A})$. Nun die Vertauschung:

$$\mathbf{A}^{(1)} = \mathbf{R}^{(1)} \mathbf{Q}^{(1)} = \frac{1}{29} \begin{pmatrix} 29 & -26 \\ 0 & 36 \end{pmatrix} \begin{pmatrix} 5 & 2 \\ -2 & 5 \end{pmatrix} = \frac{1}{29} \begin{pmatrix} 197 & -72 \\ -72 & 180 \end{pmatrix} \approx \begin{pmatrix} 6,793 & -2,483 \\ -2,483 & 6,207 \end{pmatrix}.$$

Spur und Determinante sind unverändert 13 und 36, wie es Satz 8.1.7(1) verlangt. Weiter iteriert ergibt sich (die Matrizen bleiben symmetrisch, also genügen drei Einträge je Zeile):

k	$a_{11}^{(k)}$	$a_{21}^{(k)}$	$a_{22}^{(k)}$	Schrumpffaktor
0	5,000	-2,000	8,000	–
1	6,793	-2,483	6,207	1,241
2	8,325	-1,709	4,675	0,688
3	8,850	-0,852	4,150	0,498
4	8,970	-0,388	4,030	0,455
5	8,994	-0,173	4,006	0,447
6	8,999	-0,077	4,001	0,445
9	9,000	-0,007	4,000	0,444

Die Diagonale läuft auf (9, 4) zu, absteigend nach Betrag, und der rote Eintrag unter der Diagonalen verschwindet. Sein Schrumpffaktor nähert sich $|\lambda_2/\lambda_1| = 0,444$, derselben Rate

wie bei der Potenzmethode; im ersten Schritt wächst der Eintrag sogar noch, denn die Rate beschreibt nur das asymptotische Verhalten. Das aufgesammelte Produkt $\mathbf{Q}_9$ hat die Spalten $(0,448; -0,894)^\top$ und $(0,894; 0,448)^\top$, also bis auf Rundung $-\mathbf{v}_1$ und $\mathbf{v}_2$. In Beispiel 8.1.8 haben wir dieselbe Diagonalisierung, dort mit vertauschter Reihenfolge, aus den bekannten Eigenvektoren gebaut; die QR-Iteration findet sie selbst.

Interaktiv: Die QR-Iteration zum Durchklicken

Links stehen die Einträge von $\mathbf{A}^{(k)}$, dazu die Faktoren des letzten Schritts und das aufgesammelte Produkt $\mathbf{Q}_k$; rechts fällt der Betrag der Nebendiagonalen auf logarithmischer Skala, wo lineare Konvergenz als Gerade erscheint. Neben der Beispielmatrix lohnen sich zwei weitere Eingaben: die unsymmetrische Matrix $\begin{pmatrix} 2 & 3 \\ 1 & 4 \end{pmatrix}$ und die Drehung aus Bemerkung 8.1.14.

Interaktives Element — nur in der Web-Fassung

Die drei Eingaben zeigen die drei Fälle aus Bemerkung 8.1.14: Getrennte Beträge und Symmetrie führen auf eine Diagonalmatrix mit Eigenvektoren in $\mathbf{Q}_k$, getrennte Beträge ohne Symmetrie nur auf eine Dreiecksmatrix, gleiche Beträge auf Stillstand. Was die Iteration liefert, hängt an den Eigenschaften von $\mathbf{A}$, nicht an der Zahl der Schritte.

Kondition und Aufwand

Bemerkung 8.1.16 (Kondition von Eigenwertproblemen)

Wie gut ein Eigenwertproblem konditioniert ist (Abschnitt 4.2), hängt stark von der Matrix ab.

- *Eigenwerte* sind gut konditioniert, wenn $\mathbf{A}$ nahezu symmetrisch ist. Für exakt symmetrische Matrizen verschiebt eine ebenfalls symmetrische Störung Δ jeden Eigenwert um höchstens $\|\Delta\|_2$. Bei stark unsymmetrischen Matrizen gibt es keine solche Schranke.
- *Eigenvektoren* sind schlecht konditioniert, wenn Eigenwerte nahe beieinanderliegen. Der Grenzfall macht klar, warum: Bei $\lambda_i = \lambda_j$ spannen die zugehörigen Eigenvektoren eine ganze Ebene auf, in der jede Richtung gleich gut ist. Liegen die Eigenwerte nur nahe beieinander, ist die Richtung fast beliebig, und eine kleine Störung dreht sie weit.

Dieselbe Nähe bremst auch beide Verfahren, denn die Rate $|\lambda_2/\lambda_1|$ geht dann gegen 1. Schlechte Kondition und langsame Konvergenz haben hier dieselbe Ursache.

Bemerkung 8.1.17 (Aufwand)

Ein Schritt von Algorithmus 8.1.10 zerlegt eine volle Matrix und kostet $O(n^3)$. Der praktische QR-Eigenwertalgorithmus reduziert $\mathbf{A}$ deshalb einmalig in $O(n^3)$ auf Hessenbergform; danach kostet ein QR-Sweep $O(n^2)$, bei symmetrischen Matrizen (Tridiagonalform) sogar nur $O(n)$. Wie viele Sweeps nötig sind, hängt von Shifts, Deflation und Eigenwertverteilung ab; oft sind es wenige. Ein Schritt der Potenzmethode kostet dagegen nur ein Matrix-Vektor-Produkt, liefert aber auch nur einen Eigenwert.

Für große dünnbesetzte Matrizen sind iterative Verfahren wie die Lanczos-Iteration (Bemer-

kung 8.1.9) und ihre Varianten für die SVD noch schneller; sie kommen in Abschnitt 8.2 wieder vor.

Selbsttest

1. Für $\mathbf{x}^{(0)} = c \mathbf{v}_1$ mit $c \neq 0$ versagt die Potenzmethode.

Antwort: Falsch

Im Gegenteil, das ist der günstigste Startvektor: Er hat $c_1 = c \neq 0$, und die Iteration ist bereits im ersten Schritt am Ziel, denn $A\mathbf{v}_1 = \lambda_1\mathbf{v}_1$ ändert die Richtung nicht.

2. Für $\mathbf{x}^{(0)} = c \mathbf{v}_2$ mit $c \neq 0$ versagt die Potenzmethode.

Antwort: Wahr

Hier ist $c_1 = 0$, in (8.1.1) fehlt also der Term mit $\mathbf{v}_1$. Bei symmetrischem A heißt das anschaulich: Der Startvektor steht senkrecht auf dem gesuchten Eigenvektor. Die Iterierte bleibt in Richtung $\mathbf{v}_2$ stehen und die Schätzung liefert λ_2 statt λ_1 (Bemerkung 8.1.6).

3. Für $\mathbf{x}^{(0)} = c(\mathbf{v}_1 + \mathbf{v}_2)$ mit $c \neq 0$ versagt die Potenzmethode.

Antwort: Falsch

Dieser Start hat $c_1 = c \neq 0$, damit ist die Voraussetzung von Satz 8.1.4 erfüllt. Die Methode konvergiert mit der üblichen Rate $|\lambda_2/\lambda_1|$.

4. Ähnliche Matrizen haben dasselbe charakteristische Polynom.

Antwort: Wahr

Das ist Satz 8.1.7(1), denn $\det(Q(A - \lambda I)Q^{-1}) = \det(A - \lambda I)$. Daraus folgen gleiche Eigenwerte samt Vielfachheiten, Spur und Determinante. Die Eigenvektoren stimmen dagegen im Allgemeinen nicht überein; sie gehen über $\mathbf{x} = Q^{-1}\mathbf{y}$ auseinander hervor.

5. Die QR-Iteration konvergiert für jede reelle Matrix gegen eine obere Dreiecksmatrix.

Antwort: Falsch

Die Drehung um 90° mit den komplexen, betragsgleichen Eigenwerten $\pm i$ ist ein Gegenbeispiel: Dort ist $Q^{(1)} = A$ und $R^{(1)} = I$, die Iteration bleibt also für immer bei A stehen (Bemerkung 8.1.14). Für die Konvergenz gegen die Schur-Form brauchen wir reelle, betragsmäßig getrennte Eigenwerte.

6. Ein Schritt der Potenzmethode kostet $O(n^3)$ Operationen.

Antwort: Falsch

Ein Schritt besteht aus einem Matrix-Vektor-Produkt und einer Normierung, das sind $O(n^2)$ Operationen für eine volle Matrix und noch weniger für eine dünnbesetzte. $O(n^3)$ kostet dagegen jede einzelne QR-Iteration, weil dort in jedem Schritt eine ganze Matrix zerlegt wird (Bemerkung 8.1.17).

Vertiefung: Heath §4.5 zu Potenzmethode, Ähnlichkeitstransformationen und QR-Iteration.

8.2 Anwendungen: PageRank, PCA und approximative SVD

Einige der größten Rechenprobleme der Praxis sind Eigenwertprobleme, für die direkte Verfahren zu teuer sind. Drei Beispiele aus Suche, Statistik und Bildverarbeitung.

Google PageRank

Das Problem: eine Rangordnung für $n \approx 10^{10}$ Webseiten. Das Modell: Jede Seite i bekommt einen Wichtigkeits-Score x_i , und wichtig ist, wer von wichtigen Seiten verlinkt wird:

$$x_i = \sum_{j: j \rightarrow i} \frac{x_j}{d_j},$$

wobei $j \rightarrow i$ bedeutet, dass Seite j auf Seite i verlinkt, und d_j die Anzahl der ausgehenden Links von j ist: Jede Seite vererbt ihren Score gleichmäßig an alle Seiten, auf die sie zeigt. In Matrixform, mit $A = \left[\frac{I(j \rightarrow i)}{d_j} \right]_{i,j}$, heißt das

$$\mathbf{x} = A\mathbf{x},$$

ein Eigenwertproblem zum Eigenwert 1.

Bemerkung 8.2.1 (Warum ausgerechnet der Eigenwert 1?)

Hat jede Seite mindestens einen ausgehenden Link, so summiert sich jede Spalte von A zu 1: Eine Seite verteilt ihren ganzen Score und behält nichts zurück. Solche Matrizen heißen *spaltenstochastisch*, und für sie ist 1 der betragsgrößte Eigenwert; der zugehörige Eigenvektor lässt sich nichtnegativ wählen und taugt damit erst als Score-Verteilung.

Für die Potenzmethode reicht das noch nicht: Satz 8.1.4 verlangt einen *einfachen* betragsgrößten Eigenwert, und das ist beim rohen Web-Graphen aus zwei Gründen nicht gegeben. Seiten ohne ausgehende Links liefern gar keine Spaltensumme 1, und zerfällt das Netz in mehrere Teile, so gehören zu jedem Teil eigene Eigenvektoren zum Eigenwert 1. Leere Spalten füllen wir deshalb gleichverteilt auf: Wer nirgendwohin verlinkt, gibt seinen Score an alle weiter. Gegen die restlichen Eigenwerte vom Betrag 1 hilft ein *Dämpfungsfaktor* α mit $0 < \alpha < 1$, mit dem wir zu $\alpha A + \frac{1-\alpha}{n} E$ übergehen, wobei E nur Einsen enthält. Anschaulich springt ein zufälliger Surfer mit Wahrscheinlichkeit $1-\alpha$ auf eine beliebige Seite, statt einem Link zu folgen. Die neue Matrix ist strikt positiv, ihr Eigenwert 1 ist einfach, und alle übrigen Eigenwerte liegen betragsmäßig bei höchstens α . Erst damit ist der PageRank-Vektor der dominante Eigenvektor, und die Rate aus Satz 8.1.4 ist durch α beschränkt.

Vertiefung (optional): Woher der Eigenwert 1 kommt

Dass 1 der betragsgrößte Eigenwert einer spaltenstochastischen Matrix ist, folgt aus zwei bekannten Tatsachen. A^T hat lauter Zeilensummen 1 und hält damit den Vektor aus lauter Einsen fest; Transponieren ändert das charakteristische Polynom nicht, also ist 1 auch Eigenwert von A . Kein Eigenwert liegt betragsmäßig darüber, denn die Spaltensummennorm (Abschnitt 3.3) ist $\|A\|_1 = 1$, und der Spektralradius bleibt unter jeder submultiplikativen Norm (Abschnitt 3.5). Dass sich der zugehörige Eigenvektor nichtnegativ wählen lässt, liefert die Perron-Frobenius-Theorie für nichtnegative Matrizen.

Warum iterativ? Dicht gespeichert hätte die Matrix 10^{20} Einträge, und eine Zerlegung würde $O(n^3) = 10^{30}$ Operationen kosten. Aber A ist extrem dünn besetzt: Eine typische Seite hat nur et-

wa 10 ausgehende Links, der Speicherbedarf ist also $O(n)$ statt $O(n^2)$. Die Potenziteration $\mathbf{x}^{(k+1)} = \mathbf{A}\mathbf{x}^{(k)} / \|\mathbf{A}\mathbf{x}^{(k)}\|$ braucht pro Schritt nur ein Matrix-Vektor-Produkt mit dieser dünnen Matrix, also $O(n)$ Operationen, und rund 50 Iterationen reichen. Das passt zum klassischen Dämpfungsfaktor $\alpha = 0,85$ aus Bemerkung 8.2.1, denn $0,85^{50} \approx 3 \cdot 10^{-4}$. Insgesamt $O(n)$ statt $O(n^3)$: Erst das macht die Websuche in dieser Größe möglich.

Interaktiv: PageRank auf einem Vier-Seiten-Netz

Welche Seite erhält langfristig den größten Score? Verfolgen wir die Potenziteration auf dem kleinen Netz.

Interaktives Element — nur in der Web-Fassung

Auf a und c zeigen je zwei Links, auf b und d nur einer, und dieses Verhältnis findet die Iteration wieder. Der Score ist trotzdem keine Zählung von Links, sondern ein Fixpunkt: Er hängt davon ab, wie viel die verweisenden Seiten selbst wert sind.

1. Im PageRank-Widget bleibt die Summe der vier Scores bei jedem Schritt gleich.

Antwort: Wahr

Die Linkmatrix ist spaltenstochastisch, daher erhält die Iteration die Summe.

Hauptkomponentenanalyse (PCA)

Auch die Datenanalyse rechnet ständig Eigenwerte. Gegeben ist eine mittelwert-zentrierte Datenmatrix $\mathbf{X} \in \mathbb{R}^{n \times p}$ (n Beobachtungen, p Variablen); gesucht sind die Richtungen maximaler Varianz, um die Daten auf wenige Dimensionen zu verdichten. Die Antwort steckt in der Kovarianzmatrix:

$$\Sigma = \frac{1}{n-1} \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{p \times p}.$$

Ihre Eigenvektoren sind die *Hauptrichtungen* oder *Loading-Vektoren* in $\mathbb{R}^p$; die zugehörigen Eigenwerte geben an, wie viel Varianz jede Richtung erklärt. Die eigentlichen Hauptkomponenten-Scores der Beobachtungen sind $\mathbf{X}\mathbf{v}_j$. In der Praxis rechnen wir schneller direkt mit der Singulärwertzerlegung von $\mathbf{X}$ (Abschnitt 6.2), ohne $\mathbf{X}^\top \mathbf{X}$ je zu bilden; warum das auch numerisch klüger ist, steht in Abschnitt 6.4.

Interaktiv: PCA: Welche Richtung erklärt am meisten?

Wie sieht die Richtung maximaler Varianz in einer Punktwolke aus? Drehen wir eine Projektionsrichtung durch die Daten.

Interaktives Element — nur in der Web-Fassung

Die gesuchte Richtung ist keine Koordinatenachse, sondern die Lösung eines Maximierungsproblems, und die liefert der erste Eigenvektor von Σ . Sein Eigenwert λ_1 ist die dort erreichte Varianz, λ_2 die Varianz senkrecht dazu.

1. Stellen wir im PCA-Widget die blaue Richtung auf die grün gestrichelte Achse: Wie groß ist die dort angezeigte maximale Projektionsvarianz ungefähr?

Lösung: 4.43

Die Anzeige erreicht dort den ersten Eigenwert von Σ , also ungefähr 4,43. In jeder anderen Richtung ist $\mathbf{v}^\top \Sigma \mathbf{v}$ kleiner.

Bemerkung 8.2.2 (Warum iterativ? Lanczos für große p)

Moderne Anwendungen haben $p = 10^4$ bis 10^6 Variablen (Gen-Expression, Bildanalyse), gebraucht werden aber meist nur die $k \ll p$ größten Eigenwerte. Gezielt diese approximiert die Lanczos-Iteration (Bemerkung 8.1.9). Arbeitet sie direkt mit X , kostet ein Matrix-Vektor-Paar $O(\text{nnz}(X))$; hinzu kommen Orthogonalisierung und eine Iterationszahl, die von Spektrallücken und Toleranz abhängt, sodass sich kein pauschaler Beschleunigungsfaktor wie p/k angeben lässt. Σ selbst stellen wir dabei gar nicht erst auf: Bei $p = 100\,000$ hätte sie 10^{10} Einträge, in doppelter Genauigkeit rund 80 Gigabyte. In R übernehmen das zum Beispiel `irlba::irlba()` (iterativ) oder `irlba::svdr()` (iterativ und probabilistisch, siehe Abschnitt 8.4).

Approximative SVD in der Praxis

Wie groß der Unterschied ist, zeigt ein Experiment: eine Rang- k -Approximation an einem Graustufen-Foto (2500×3300 Pixel), einmal mit der vollen SVD und zweimal iterativ mit `irlba`:

```
library(irlba); suppressMessages(library(magick))
# "img" ist 2500 x 3300 px (grayscale)
img <- paste0(
  "https://upload.wikimedia.org/wikipedia/commons/7/7e/",
  "Bolzano_City_Image_-_Photo_by_Giovanni_Ussi_-_In_Black_and_White_19.jpg")
X <- (image_read(img) |>
  image_data(channels = "gray") |>
  as.numeric())[,,1]
r <- 50
microbenchmark::microbenchmark(
  svd_full = svd(X),
  svd_irlba = irlba::irlba(X, nv = r, nu = r),
  svd_random = irlba::svdr(X, k = r),
  times = 5)
```

Die vollständige SVD berechnet alle 2500 Singulärwerte, obwohl nur 50 gebraucht werden. `irlba` und `svdr` tasten die Matrix nur über Matrix-Vektor-Produkte ab und arbeiten in einem Unterraum der Dimension 50; wie viel Rechenzeit das spart, misst der Vergleich oben. An Qualität kostet das kaum etwas: `irlba` rechnet dieselbe Rang-50-Zerlegung bis auf eine einstellbare Toleranz aus, während `svdr` bewusst etwas Genauigkeit gegen Tempo tauscht. Zum Selbst-Ausprobieren: das Rang- k -Widget in Abschnitt 6.4 und die Shiny-App zur Bildkompression.

Vertiefung (optional): Die Qualität der Rekonstruktionen messen

Die drei Rang-50-Rekonstruktionen lassen sich direkt gegenüberstellen:

```
r <- 50
X_r <- with(svd(X, nu = r, nv = r), u %*% diag(d[1:r]) %*% t(v))
X_irlba <- with(irlba::irlba(X, nu = r, nv = r), u %*% diag(d) %*% t(v))
X_svdr <- with(irlba::svdr(X, k = r), u %*% diag(d) %*% t(v))
norm(X - X_r, "F") / norm(X, "F")
c(norm(X_r - X_irlba, "F"), norm(X_r - X_svdr, "F")) / norm(X_r, "F")
```

Die beiden letzten Zeilen messen Verschiedenes. Die erste ist der relative Frobenius-Fehler der exakten

Rang-50-Approximation, also das Minimum aus Satz 6.4.4. Die zweite misst den Abstand der beiden iterativen Rekonstruktionen zu dieser exakten Lösung. Ist sie deutlich kleiner als die erste, spielt der Zusatzfehler der Abkürzung neben dem Approximationsfehler keine Rolle.

Die Verfahren im Vergleich

Methode	Komplexität / Iteration	Anwendung	Output
Potenzmethode	$O(\text{nnz}(\mathbf{A}))$	größter Eigenwert/-vektor	1 Eigenpaar
(shifted) QR	einmalig $O(n^3)$; danach $O(n^2)$ je Hessenberg-Sweep	alle Eigenwerte	n Eigenwerte
Lanczos	$O(m \text{nnz}(\mathbf{A}) + nm^2)$ für m Schritte mit voller Reorthogonalisierung	wenige Extremal-Eigenwerte, <i>sparse</i> $\mathbf{A}$	bis zu $m \ll n$ Eigenpaare

Dabei zählt $\text{nnz}(\cdot)$ die Nicht-Null-Einträge. Die Potenzmethode konvergiert mit der Rate $|\lambda_2/\lambda_1|$, die QR-Iteration mit Shifts oft quadratisch und am stabilsten, ohne Shifts nur linear (Bemerkung 8.1.14). Als Faustregeln: Für *sparse* Matrizen ist Lanczos deutlich überlegen; wer alle Eigenwerte braucht und Speicher übrig hat, nimmt die (shifted) QR-Iteration; für wenige Eigenpaare reichen Potenzmethode (eines) oder Lanczos ($m \ll n$).

Vertiefung: Heath §4.5 (iterative Eigenwertverfahren: Potenzmethode, QR-Iteration, Lanczos); zur PCA-über-SVD-Verbindung noch einmal Abschnitt 6.4.

8.3 Iterative Löser für lineare Gleichungssysteme

Für lineare Gleichungssysteme $\mathbf{Ax} = \mathbf{b}$ und für Kleinste-Quadrate-Probleme kennen wir bisher nur *direkte* Verfahren. Die LU-Zerlegung aus Abschnitt 5.3 und die QR-Zerlegung aus Abschnitt 7.4 zerlegen die Matrix einmal vollständig und liefern danach die Lösung bis auf Rundungsfehler exakt. Das kostet eine feste Operationszahl der Größenordnung n^3 , unabhängig davon, wie genau wir die Lösung brauchen.

Iterative Verfahren erzeugen dagegen eine Folge von Näherungen $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots$, die gegen die Lösung $\mathbf{x}$ strebt, und hören auf, sobald die erreichte Genauigkeit genügt. Meist sind es *Fixpunkt-iterationen* (fixed point iterations): Eine Vorschrift wird immer wieder auf ihr eigenes Ergebnis angewendet, und die gesuchte Lösung ist der Punkt, den sie nicht mehr bewegt.

Residuum und Korrekturschritt

Um uns der Lösung schrittweise zu nähern, brauchen wir ein Maß dafür, wie gut eine Näherung ist. Die Lösung $\mathbf{x}$ kennen wir nicht, einsetzen können wir die Näherung aber immer.

Definition 8.3.1 (Residuum)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{b} \in \mathbb{R}^n$ und $\mathbf{x}^{(k)} \in \mathbb{R}^n$ eine Näherung der Lösung von $\mathbf{Ax} = \mathbf{b}$. Der Vektor

$$\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k)}$$

heißt *Residuum* (residual) von $\mathbf{x}^{(k)}$.

Das Residuum misst, wie weit die Näherung davon entfernt ist, die Gleichung zu erfüllen. Ist $\mathbf{r}^{(k)} = \mathbf{0}$, so gilt $\mathbf{A}\mathbf{x}^{(k)} = \mathbf{b}$, und wir haben die Lösung gefunden. Solange das Residuum nicht verschwindet, korrigieren wir unsere Schätzung:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \underbrace{\mathbf{C}\mathbf{r}^{(k)}}_{\text{Korrekturschritt}}.$$

Die Matrix $\mathbf{C} \in \mathbb{R}^{n \times n}$ legt fest, wie stark und in welche Richtung wir korrigieren; sie ist der einzige Entwurfsspielraum des Verfahrens.

Im einfachsten Fall $\mathbf{C} = \gamma \mathbf{I}_n$ lautet der Schritt $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \gamma \mathbf{r}^{(k)}$: Wir gehen ein Stück in Richtung des Residuums, wie bei einem Gradientenabstieg mit Schrittweite γ . Mit zu kleinen Schritten kommen wir kaum voran, zu große schießen über das Ziel hinaus.

Vertiefung (optional): Das Residuum als negativer Gradient

Bemerkung 8.3.2 (Verwandtschaft mit dem Gradientenabstieg)

Die Analogie ist exakt, wenn $\mathbf{A}$ symmetrisch und positiv definit ist. Dann hat die quadratische Form

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$$

den Gradienten $\nabla f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b} = -\mathbf{r}$, und ihr Minimum liegt bei $\mathbf{A}\mathbf{x} = \mathbf{b}$. Das Residuum zeigt also in Richtung des steilsten Abstiegs, und γ ist die Schrittweite.

Warum geben wir uns mit Näherungen zufrieden, wo doch Kapitel 5 exakte Verfahren bereithält? Weil ein Iterationsschritt viel billiger ist als eine ganze Zerlegung. Für sehr große und für dünnbesetzte Systeme, wie sie in der Statistik etwa bei Netzwerkdaten oder Glättungsproblemen auftreten, sind iterative Verfahren deshalb oft um Größenordnungen schneller.

Die Iteration und ihr Konvergenzsatz

Definition 8.3.3 (Korrekturiteration)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$, $\mathbf{b} \in \mathbb{R}^n$ und $\mathbf{x}$ die Lösung von $\mathbf{A}\mathbf{x} = \mathbf{b}$. Für einen beliebigen Startwert $\mathbf{x}^{(0)} \in \mathbb{R}^n$ und eine Matrix $\mathbf{C} \in \mathbb{R}^{n \times n}$ heißt

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} + \mathbf{C}(\mathbf{b} - \mathbf{A}\mathbf{x}^{(k-1)}), \quad k = 1, 2, \dots \quad (8.3.1)$$

die von $\mathbf{C}$ erzeugte *Korrekturiteration*.

Multiplizieren wir die Klammer aus, so zeigt sich die Fixpunktstruktur.

Bemerkung 8.3.4 (Fixpunktform)

Mit $\mathbf{B} = \mathbf{I}_n - \mathbf{C}\mathbf{A}$ ist (8.3.1) gleichwertig zu

$$\mathbf{x}^{(k)} = \mathbf{B}\mathbf{x}^{(k-1)} + \mathbf{C}\mathbf{b}, \quad k = 1, 2, \dots \quad (8.3.2)$$

Jeder Schritt besteht also aus einer festen affinen Abbildung, angewandt auf das Ergebnis des vorigen Schritts. Die Matrix $\mathbf{B}$ heißt *Iterationsmatrix*; sie allein entscheidet, ob die Folge

zusammenläuft.

Es braucht nur eine Bedingung an B .

Satz 8.3.5 (Konvergenz der Korrekturiteration)

Sei $\mathbf{x}$ die eindeutige Lösung von $A\mathbf{x} = \mathbf{b}$. Gilt für die Spektralnorm

$$\rho := \|I_n - CA\|_2 < 1,$$

so folgt für alle $k \geq 1$

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_2 \leq \rho^k \|\mathbf{x}^{(0)} - \mathbf{x}\|_2. \quad (8.3.3)$$

Insbesondere ist $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}$, und zwar für jeden Startwert.

Zur Notation: Das ρ hier ist die *Konvergenzrate* der Iteration; mit dem Rayleigh-Quotienten $\rho^{(k)}$ aus Abschnitt 8.1 hat es nur den Buchstaben gemeinsam.

Vertiefung (optional): Beweis des Konvergenzsatzes und eine Folgerung

Beweis.

- (1) Mit $B = I_n - CA$ ist $\|B\|_2 = \rho$, und nach (8.3.2) lautet die Iteration $\mathbf{x}^{(k)} = B\mathbf{x}^{(k-1)} + C\mathbf{b}$.

Ausmultiplizieren von (8.3.1): $\mathbf{x} + C(\mathbf{b} - A\mathbf{x}) = (I_n - CA)\mathbf{x} + C\mathbf{b}$

- (2) Die Lösung $\mathbf{x}$ ist ein *Fixpunkt* dieser Abbildung:

$$B\mathbf{x} + C\mathbf{b} = (I_n - CA)\mathbf{x} + C\mathbf{b} = \mathbf{x} - \underbrace{C(A\mathbf{x} - \mathbf{b})}_{=0} = \mathbf{x}.$$

$\mathbf{x}$ löst $A\mathbf{x} = \mathbf{b}$, die Klammer ist also der Nullvektor

- (3) Damit lässt sich der Fehler nach einem Schritt abschätzen. Wir ziehen die Fixpunktgleichung von der Iterationsvorschrift ab:

$$\begin{aligned} \|\mathbf{x}^{(k)} - \mathbf{x}\|_2 &= \|B\mathbf{x}^{(k-1)} + C\mathbf{b} - \mathbf{x}\|_2 \\ &= \|B\mathbf{x}^{(k-1)} + C\mathbf{b} - (B\mathbf{x} + C\mathbf{b})\|_2 \\ &= \|B(\mathbf{x}^{(k-1)} - \mathbf{x})\|_2 \\ &\leq \rho \|\mathbf{x}^{(k-1)} - \mathbf{x}\|_2. \end{aligned}$$

in Zeile 2 ersetzen wir $\mathbf{x}$ durch $B\mathbf{x} + C\mathbf{b}$ (Schritt 2), die Terme $C\mathbf{b}$ heben sich weg; in der letzten Zeile nutzen wir die definierende Eigenschaft der Operatornorm, $\|B\mathbf{v}\|_2 \leq \|B\|_2 \|\mathbf{v}\|_2$

- (4) Jeder Schritt drückt den Fehler also auf höchstens das ρ -fache. Iterieren wir die Ungleichung, so erhalten wir

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_2 \leq \rho \|\mathbf{x}^{(k-1)} - \mathbf{x}\|_2 \leq \rho^2 \|\mathbf{x}^{(k-2)} - \mathbf{x}\|_2 \leq \dots \leq \rho^k \|\mathbf{x}^{(0)} - \mathbf{x}\|_2,$$

und wegen $\rho < 1$ geht die rechte Seite gegen null.

formal eine Induktion über k : Schritt 3 liefert den Induktionsschritt, der Fall $k = 1$ ist genau Schritt 3 selbst; $\rho^k \rightarrow 0$ gilt für jedes $\rho \in [0, 1)$

□

Die Voraussetzung des Satzes ist stärker, als sie aussieht. Wäre A singulär, so gäbe es ein $v \neq 0$ mit $Av = 0$, also $(I_n - CA)v = v$ und damit $\rho \geq 1$. Aus $\rho < 1$ folgt somit von selbst, dass A invertierbar ist und die Lösung eindeutig.

Die Schranke (8.3.3) beschreibt lineare Konvergenz: Der Fehler schrumpft pro Schritt auf einen festen Bruchteil, nicht um eine feste Differenz. Auf logarithmischer Skala aufgetragen bleibt er damit unterhalb einer Geraden mit Steigung $\log \rho$.

Selbsttest: Was kostet ein Schritt?

Wie teuer ist ein Schritt mit $C = \gamma I_n$? Zur Landau-Notation siehe Abschnitt 2.4.

1. Mit $C = \gamma I_n$ kostet ein Iterationsschritt $O(1)$ Operationen.

Antwort: Falsch

Schon das Ergebnis hat n Komponenten, und jede muss geschrieben werden. Unter $O(n)$ geht es also gar nicht.

2. Mit $C = \gamma I_n$ kostet ein Iterationsschritt $O(n)$ Operationen.

Antwort: Falsch

Das gilt nur für die billigen Teile. Der Schritt lautet ausgeschrieben $x^{(k)} = x^{(k-1)} - \gamma(Ax^{(k-1)} + \gamma b)$: Das Skalieren mit γ und die beiden Vektoradditionen kosten $O(n)$, das Matrix-Vektor-Produkt $Ax^{(k-1)}$ aber mehr.

3. Mit $C = \gamma I_n$ kostet ein Iterationsschritt $O(n^2)$ Operationen.

Antwort: Wahr

Der teuerste Posten ist das Matrix-Vektor-Produkt $Ax^{(k-1)}$: n Komponenten mit je n Multiplikationen und $n - 1$ Additionen, zusammen $O(n^2)$; alles Übrige ist $O(n)$. Ist A dünnbesetzt, sinkt der Aufwand auf $O(\text{nnz}(A))$, die Zahl der Einträge ungleich null.

4. Mit $C = \gamma I_n$ kostet ein Iterationsschritt $O(n^3)$ Operationen.

Antwort: Falsch

So teuer wäre es nur, wenn wir in jedem Schritt ein Produkt zweier voller $n \times n$ -Matrizen bilden würden, etwa CA für ein allgemeines C . Das ist nicht nötig: Wir wenden A direkt auf den aktuellen Vektor an. Wäre ein Schritt so teuer wie eine LU-Zerlegung, hätte das Verfahren keinen Zweck.

Wie viele Schritte bis zur Genauigkeit ε ?

Satz 8.3.5 verspricht einen geometrisch fallenden Fehler. Wie oft müssen wir iterieren, bis eine vorgegebene Toleranz ε unterschritten ist?

1. Für $\|x^{(k)} - x\| \leq \varepsilon$ genügen $k = O(1)$ Schritte.

Antwort: Falsch

Eine feste Schrittzahl liefert eine feste Genauigkeit, mehr nicht. Wer ε verkleinert, muss weiter iterieren.

2. Für $\|x^{(k)} - x\| \leq \varepsilon$ genügen $k = O(\log(1/\varepsilon))$ Schritte.

Antwort: Wahr

Der Fehler fällt geometrisch, also braucht jede weitere Dezimalstelle Genauigkeit gleich viele zusätzliche Schritte. Die Herleitung steht direkt im Anschluss als Korollar 8.3.6.

3. Für $\|\mathbf{x}^{(k)} - \mathbf{x}\| \leq \varepsilon$ brauchen wir $k = O(1/\varepsilon)$ Schritte.

Antwort: Falsch

Das wäre die Schrittzahl bei einem Fehler, der nur wie $1/k$ fällt. Hier fällt er wie ρ^k , und das ist ungleich schneller: Für $\varepsilon = 10^{-6}$ stünden hier eine Million Schritte statt der 15, die für das System aus Beispiel 8.3.11 genügen.

4. Für $\|\mathbf{x}^{(k)} - \mathbf{x}\| \leq \varepsilon$ brauchen wir $k = O(1/\varepsilon^k)$ Schritte.

Antwort: Falsch

Das kann schon formal nicht stimmen, denn k steht auf beiden Seiten. Eine Schranke für k darf nur von ε , ρ und dem Startfehler abhängen.

Die Antwort folgt allein aus der Schranke (8.3.3).

Korollar 8.3.6 (Zahl der Iterationen)

Es gelte (8.3.3) mit $\rho \in (0, 1)$, und sei $e_0 = \|\mathbf{x}^{(0)} - \mathbf{x}\|_2 > 0$ der Startfehler. Für $\varepsilon > 0$ ist $\|\mathbf{x}^{(k)} - \mathbf{x}\|_2 \leq \varepsilon$ garantiert, sobald

$$k \geq \max \left\{ 0, \left\lceil \frac{\log(e_0/\varepsilon)}{-\log \rho} \right\rceil \right\}. \quad (8.3.4)$$

Insbesondere ist $k = O(\log(1/\varepsilon))$.

Beweis.

- (1) Nach (8.3.3) genügt es, $\rho^k e_0 \leq \varepsilon$ zu erzwingen, also $\rho^k \leq \varepsilon/e_0$. Beide Seiten sind positiv, wir dürfen also logarithmieren. Wegen $0 < \rho < 1$ ist $\log \rho < 0$, und beim Teilen durch diese negative Zahl dreht sich das Ungleichheitszeichen um:

$$k \log \rho \leq \log \frac{\varepsilon}{e_0} \quad \Longleftrightarrow \quad k \geq \frac{\log(\varepsilon/e_0)}{\log \rho} = \frac{\log(e_0/\varepsilon)}{-\log \rho}.$$

(8.3.3) schätzt den Fehler nach oben ab: Wer die Schranke unter ε drückt, drückt den Fehler mit; $\log$ ist streng monoton wachsend, und $\log(\varepsilon/e_0) = -\log(e_0/\varepsilon)$

- (2) Falls $\varepsilon \geq e_0$, genügt bereits $k = 0$; andernfalls ist das kleinste ganzzahlige k die Aufrundung. Beides zusammen ergibt (8.3.4). Wegen $\log(e_0/\varepsilon) = \log e_0 + \log(1/\varepsilon)$ hängt die Schrittzahl von der geforderten Genauigkeit nur über $\log(1/\varepsilon)$ ab; der Startfehler und der Faktor $1/(-\log \rho)$ sind Konstanten. Damit ist $k = O(\log(1/\varepsilon))$.

in der Landau-Notation zählt allein das Wachstum in ε ; e_0 und ρ hängen nicht von ε ab

□

Für Beispiel 8.3.11 weiter unten ist $\rho \approx 0,405$ und $e_0 \approx 0,643$; (8.3.4) verlangt dann 8 Schritte für $\varepsilon = 10^{-3}$, 15 für $\varepsilon = 10^{-6}$ und 23 für $\varepsilon = 10^{-9}$. Drei zusätzliche Dezimalstellen kosten also jedes Mal rund sieben bis acht weitere Schritte zu je $O(n^2)$.

Die Wahl von C

Bemerkung 8.3.7 (Zwei Anforderungen an C)

Die Matrix C soll gleichzeitig zwei Dinge leisten:

1. $\rho = \|\mathbf{I}_n - \mathbf{C}\mathbf{A}\|_2 < 1$ soll möglichst klein sein, damit wenige Schritte reichen. Optimal wäre $\mathbf{C} \approx \mathbf{A}^{-1}$.
2. Der Schritt (8.3.2) soll billig auszuwerten sein, also möglichst in $O(n^2)$.

Die beiden Wünsche stehen gegeneinander. Mit $\mathbf{C} = \mathbf{A}^{-1}$ wäre $\rho = 0$, und ein einziger Schritt träge die Lösung exakt. Nur müssten wir dafür $\mathbf{A}^{-1}$ kennen, und das ist teurer als das Gleichungssystem selbst. Brauchbare Wahlen sind deshalb grobe, billige Näherungen der Inversen.

Algorithmus 8.3.8 (Drei klassische Wahlen von C)

Für eine dichte Matrix kosten alle drei pro Schritt $O(n^2)$; Konvergenz braucht jeweils zusätzliche Voraussetzungen.

1. *Richardson-Iteration*: $\mathbf{C} = \gamma \mathbf{I}_n$. Ist $\mathbf{A}$ SPD, so garantiert $0 < \gamma < 2/\lambda_{\max}(\mathbf{A})$ Konvergenz. Für eine beliebige Matrix existiert nicht notwendig ein geeignetes positives γ .
2. *Jacobi-Iteration*: $\mathbf{C} = \text{diag}(\mathbf{A}_{11}, \dots, \mathbf{A}_{nn})^{-1}$, die Inverse der Diagonalen von $\mathbf{A}$. Dafür müssen alle Diagonaleinträge von null verschieden sein. Die Korrektur teilt jede Residuumskomponente durch das zugehörige Diagonalelement, zusätzlicher Aufwand n Divisionen. Konvergenz gilt, wenn der Spektralradius der Iterationsmatrix kleiner als 1 ist; strikte Diagonaldominanz ist eine verbreitete hinreichende Bedingung.
3. *Gauss-Seidel-Iteration*: $\mathbf{C}^{-1}$ ist das untere Dreieck von $\mathbf{A}$, also die Diagonale samt allem darunter. Invertiert wird nichts: Die Korrektur $\mathbf{d} = \mathbf{C} \mathbf{r}^{(k)}$ ist die Lösung des Dreieckssystems $\mathbf{C}^{-1} \mathbf{d} = \mathbf{r}^{(k)}$, und die liefert die Vorwärtssubstitution in $O(n^2)$ Operationen. Auch hier müssen die Diagonaleinträge ungleich null sein. Konvergenz ist eine zusätzliche Eigenschaft; für SPD-Matrizen ist sie garantiert.

Alle drei ersetzen $\mathbf{A}$ durch eine Matrix, mit der sich Gleichungssysteme leicht lösen lassen (ein Vielfaches der Einheitsmatrix, die Diagonale, das untere Dreieck), und nehmen deren Inverse als C. Wie gut das gelingt, hängt von $\mathbf{A}$ ab.

Vertiefung (optional): Richardson, Jacobi und Gauss-Seidel im Vergleich

Beispiel 8.3.9 (Die drei Wahlen an einem 2×2-System)

Für

$$A = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}$$

liefern die drei Rezepte die Iterationsmatrizen

$$\text{Richardson } (\gamma = 0,25) : \quad I - \gamma A = \begin{pmatrix} 0 & -0,25 \\ -0,25 & 0,25 \end{pmatrix}, \quad \rho \approx 0,405,$$

$$\text{Jacobi: } \quad I - CA = \begin{pmatrix} 0 & -\frac{1}{4} \\ -\frac{1}{3} & 0 \end{pmatrix}, \quad \rho = \frac{1}{3} \approx 0,333,$$

$$\text{Gauss-Seidel: } \quad I - CA = \begin{pmatrix} 0 & -\frac{1}{4} \\ 0 & \frac{1}{12} \end{pmatrix}, \quad \rho \approx 0,264.$$

Alle drei konvergieren, und in dieser Reihenfolge immer schneller. Hier zählt sich aus, dass Jacobi mehr über A weiß als Richardson und Gauss-Seidel mehr als Jacobi. Als Regel taugt die Reihenfolge trotzdem nicht: Es gibt Matrizen, für die Jacobi konvergiert und Gauss-Seidel nicht, und ebenso umgekehrt.

Dabei ist ρ die Norm der Iterationsmatrix, und die ist nur ein hinreichendes Kriterium. Die Gauss-Seidel-Matrix hier hat die Eigenwerte 0 und $\frac{1}{12}$, ihr Spektralradius ist also 0,083, und mit diesem Faktor schrumpft der Fehler auf lange Sicht. Die Norm 0,264 ist die Garantie, die schon ab dem ersten Schritt gilt.

Bemerkung 8.3.10 (Gesamtaufwand)

Bei dichter Matrix kostet ein Schritt $O(n^2)$, und nach Korollar 8.3.6 reichen $O(\log(e_0/\varepsilon))$ Schritte. Zusammen sind das $O(n^2 \log(e_0/\varepsilon))$ Operationen für einen Fehler unter ε , gegenüber $O(n^3)$ für eine LU- oder QR-Zerlegung. Das gilt allerdings nur, solange $\rho \leq \rho_0 < 1$ unabhängig von der Problemgröße bleibt. Nähert sich ρ mit wachsendem n der 1, so wächst auch die Iterationszahl; Präkonditionierung soll das verhindern. Bei dünnbesetztem A kostet ein Schritt nur $O(\text{nnz}(A))$; umgekehrt können auch direkte Löser bei Band- oder anderer Struktur deutlich billiger als $O(n^3)$ sein.

Ein Beispiel Schritt für Schritt

Beispiel 8.3.11 (Richardson-Iteration)

Gegeben seien

$$A = \begin{pmatrix} 4 & 1 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \text{also} \quad x = A^{-1}b = \frac{1}{11} \begin{pmatrix} 1 \\ 7 \end{pmatrix} \approx \begin{pmatrix} 0,091 \\ 0,636 \end{pmatrix}.$$

Wir iterieren mit $\gamma = 0,25$ und starten in $x^{(0)} = (0, 0)^T$.

Schritt 1: $r^{(0)} = b - Ax^{(0)} = (1, 2)^T$, also

$$x^{(1)} = x^{(0)} + 0,25 r^{(0)} = \begin{pmatrix} 0,25 \\ 0,5 \end{pmatrix}.$$

Schritt 2: $Ax^{(1)} = (1,5, 1,75)^T$, $r^{(1)} = (-0,5, 0,25)^T$, also

$$\mathbf{x}^{(2)} = \begin{pmatrix} 0,125 \\ 0,563 \end{pmatrix}.$$

Schritt 3: $\mathbf{Ax}^{(2)} = (1,063, 1,813)^\top$, $\mathbf{r}^{(2)} = (-0,063, 0,188)^\top$, also

$$\mathbf{x}^{(3)} = \begin{pmatrix} 0,109 \\ 0,609 \end{pmatrix} \quad \left(\text{exakt } \frac{1}{64}(7, 39)^\top \right).$$

Schritt 4: $\mathbf{Ax}^{(3)} = (1,047, 1,938)^\top$, $\mathbf{r}^{(3)} = (-0,047, 0,063)^\top$, also

$$\mathbf{x}^{(4)} = \begin{pmatrix} 0,098 \\ 0,625 \end{pmatrix} \quad \left(\text{exakt } \frac{1}{256}(25, 160)^\top \right).$$

Die Fehler $\|\mathbf{x}^{(k)} - \mathbf{x}\|_2$ lauten

$$0,643 \rightarrow 0,210 \rightarrow 0,081 \rightarrow 0,033 \rightarrow 0,013 \rightarrow \dots$$

Vergleich mit der Theorie: Die Iterationsmatrix $\mathbf{I} - \gamma\mathbf{A}$ ist symmetrisch, ihre Norm also der größte Eigenwertbetrag. Aus den Eigenwerten $\frac{1}{2}(7 \pm \sqrt{5}) \approx 4,618$ und $2,382$ von $\mathbf{A}$ werden die Eigenwerte $1 - 0,25 \cdot 4,618 = -0,155$ und $1 - 0,25 \cdot 2,382 = 0,405$, also

$$\rho = \|\mathbf{I} - \gamma\mathbf{A}\|_2 \approx 0,405.$$

Der Fehler sollte demnach je Schritt etwa auf das 0,405-fache fallen, das heißt um den Faktor $1/0,405 \approx 2,5$ sinken. Die beobachteten Quotienten 0,33, 0,39, 0,40, 0,40 bestätigen das und nähern sich von unten der Vorhersage an.

Interaktiv: Richardson Schritt für Schritt, mit einstellbarem γ

Ab welcher Schrittweite divergiert diese Iteration? Schätzen wir die Grenze, bevor wir den Verlauf ansehen.

Interaktives Element — nur in der Web-Fassung

Die Auflösung markiert die Grenze der Konvergenz: Darunter fällt der Fehler nach Satz 8.3.5 geometrisch, darüber verfehlt die Iterationsmatrix die Kontraktionsbedingung $\rho < 1$.

1. Zeigt das Richardson-Widget für eine Schrittweite eine Rate $\rho > 1$, dann erfüllt diese Wahl die Konvergenzvoraussetzung von Satz 8.3.5 nicht.

Antwort: Wahr

Die Kontraktionsschranke verlangt $\rho < 1$.

Einordnung

Bemerkung 8.3.12 (Was iterative Verfahren leisten)

- Iterative Verfahren gibt es für lineare Gleichungssysteme, für Eigenwertprobleme (Abschnitt 8.1) und ebenso für Kleinste-Quadrate-Probleme (Kapitel 7).

- In Sonderfällen sind sie *exakt*. Mit $C = A^{-1}$ etwa ist $\rho = 0$, und ein Schritt genügt; auch Verfahren vom Krylov-Typ wie das der konjugierten Gradienten erreichen die Lösung in exakter Arithmetik nach höchstens n Schritten.
- Meistens ergibt sich ein Kompromiss zwischen Laufzeit und Genauigkeit, und die Iterationszahl ist der Regler dafür. Wo die Laufzeit wichtiger ist als die letzte Stelle, sind Iterationen die Methode der Wahl.

Vertiefung (optional): Abbruch nach dem Residuum

Den Fehler $\|\mathbf{x}^{(k)} - \mathbf{x}\|$ können wir nicht messen, denn dazu müssten wir $\mathbf{x}$ kennen. Abgebrochen wird deshalb nach dem Residuum, das jederzeit verfügbar ist. Wegen $\mathbf{x}^{(k)} - \mathbf{x} = -A^{-1}\mathbf{r}^{(k)}$ gilt

$$\|\mathbf{x}^{(k)} - \mathbf{x}\|_2 \leq \|A^{-1}\|_2 \|\mathbf{r}^{(k)}\|_2,$$

ein kleines Residuum garantiert also nur bei gut konditionierter Matrix einen kleinen Fehler. Das ist dieselbe Warnung wie bei der Konditionszahl in Abschnitt 4.2, diesmal als Abbruchkriterium.

Vertiefung: Heath §10.9 (iterative Verfahren für lineare Gleichungssysteme, inklusive Jacobi, Gauss-Seidel und konjugierten Gradienten); für die Eigenwert-Iterationen aus Abschnitt 8.1 siehe Heath §4.5.

8.4 Probabilistische Methoden: Matrix-Sketching

Die iterativen Verfahren der Abschnitte 8.1 und 8.3 sparen Laufzeit, indem sie früh abbrechen. Dieser Abschnitt verkleinert stattdessen das Problem selbst.

Zufall mit Absicht

Oft sind Probleme so groß, dass wir Genauigkeit gern gegen bessere Komplexität tauschen. Zunehmend geschieht das durch *Randomisierung* (randomization): Statt sorgfältig auszuwählen, welchen Teil der Daten wir wegwerfen, würfeln wir ihn aus.

Bemerkung 8.4.1 (Hauptidee der Randomisierung)

Wir ersetzen ein großes Problem durch ein zufällig erzeugtes, kleines Problem, das höchstwahrscheinlich eine ähnliche Lösung hat.

„Höchstwahrscheinlich“ heißt: Ein randomisiertes Verfahren darf danebenliegen, und die Fehlerwahrscheinlichkeit δ ist ein Parameter, den wir einstellen. Wir gewinnen Rechenzeit und gehen dafür ein kontrolliertes Risiko ein.

Warum sollte das gutgehen? Wer eine Punktwolke im $\mathbb{R}^{10\,000}$ auf ein paar hundert Koordinaten reduziert, wirft weit über 90 % der Koordinaten weg. Dass die Wolke danach noch dieselbe Form hat, liegt an einer Eigenart hochdimensionaler Räume.

Fast orthogonale Zufallsvektoren

In der Ebene sind zwei zufällige Richtungen selten senkrecht: Der Winkel zwischen ihnen ist gleichverteilt. Im $\mathbb{R}^n$ mit großem n stehen zwei zufällige Vektoren dagegen mit hoher Wahrscheinlichkeit fast senkrecht aufeinander. Für unabhängige, standardnormalverteilte $\mathbf{s}_1, \mathbf{s}_2 \in \mathbb{R}^n$ hat der Kosinus des Winkels zwischen ihnen den Erwartungswert 0 und die Varianz $1/n$. Seine Streuung

schrumpft also wie $1/\sqrt{n}$: In hohen Dimensionen drängt sich der Winkel um 90° zusammen, zufällige Richtungen sind praktisch orthogonal.

Vertiefung (optional): Fast-Orthogonalität zufälliger Vektoren

Satz 8.4.2 (Zufallsrichtungen stehen fast senkrecht aufeinander)

Seien $\mathbf{s}_1, \mathbf{s}_2 \in \mathbb{R}^n$ unabhängig und je $\mathcal{N}(\mathbf{0}, \mathbf{I}_n)$ -verteilt, und sei θ der Winkel zwischen ihnen. Dann gilt

$$\mathbb{E}[\cos \theta] = 0, \quad \text{Var}[\cos \theta] = \frac{1}{n},$$

und für jedes $t > 0$ folgt

$$\mathbb{P}\left(|\cos \theta| \geq \frac{t}{\sqrt{n}}\right) \leq \frac{1}{t^2}.$$

Beweis.

- (1) Wir normieren beide Vektoren, $\mathbf{u} = \mathbf{s}_1 / \|\mathbf{s}_1\|$ und $\mathbf{v} = \mathbf{s}_2 / \|\mathbf{s}_2\|$, und schreiben den Kosinus als Skalarprodukt

$$\cos \theta = \mathbf{u}^\top \mathbf{v}.$$

der Winkel zwischen zwei Vektoren hängt nur von ihren Richtungen ab; $\mathbf{s}_i = \mathbf{0}$ tritt mit Wahrscheinlichkeit 0 ein und stört deshalb nicht

- (2) Die Standardnormalverteilung ist drehinvariant, also ist $\mathbf{u}$ gleichverteilt auf der Einheitssphäre. Daraus folgt

$$\mathbb{E}[\mathbf{u}] = \mathbf{0}, \quad \mathbb{E}[\mathbf{u}\mathbf{u}^\top] = \frac{1}{n} \mathbf{I}_n. \quad (8.4.1)$$

$\mathbf{u}$ und $-\mathbf{u}$ sind gleich verteilt, also ist der Erwartungswert null; die Matrix $\mathbb{E}[\mathbf{u}\mathbf{u}^\top]$ ändert sich unter Drehungen nicht und ist deshalb ein Vielfaches der Einheitsmatrix, und der Faktor folgt aus $\text{tr} \mathbb{E}[\mathbf{u}\mathbf{u}^\top] = \mathbb{E}[\|\mathbf{u}\|^2] = 1$

- (3) Jetzt bedingen wir auf $\mathbf{v}$ und nutzen die Unabhängigkeit:

$$\mathbb{E}[\mathbf{u}^\top \mathbf{v} \mid \mathbf{v}] = \mathbb{E}[\mathbf{u}]^\top \mathbf{v} = 0, \quad \mathbb{E}[(\mathbf{u}^\top \mathbf{v})^2 \mid \mathbf{v}] = \mathbf{v}^\top \mathbb{E}[\mathbf{u}\mathbf{u}^\top] \mathbf{v} = \frac{\|\mathbf{v}\|^2}{n} = \frac{1}{n}.$$

Beide Werte hängen nicht mehr von $\mathbf{v}$ ab, gelten also auch unbedingt.

(8.4.1) mit $(\mathbf{u}^\top \mathbf{v})^2 = \mathbf{v}^\top \mathbf{u}\mathbf{u}^\top \mathbf{v}$; $\|\mathbf{v}\| = 1$ nach Konstruktion

- (4) Wegen $\mathbb{E}[\cos \theta] = 0$ ist $\text{Var}[\cos \theta] = \mathbb{E}[\cos^2 \theta] = 1/n$, und die Tschebyscheff-Ungleichung liefert

$$\mathbb{P}\left(|\cos \theta| \geq \frac{t}{\sqrt{n}}\right) \leq \frac{\text{Var}[\cos \theta]}{t^2/n} = \frac{1}{t^2}.$$

Tschebyscheff ist die Markov-Ungleichung, angewandt auf die quadrierte Abweichung vom Erwartungswert

□

Beispiel 8.4.3 (Wie senkrecht ist fast senkrecht?)

Für $n = 10\,000$ ist $\text{Var}[\cos \theta] = 10^{-4}$, die Standardabweichung also 0,01. Mit $t = 5$ liefert Satz 8.4.2

$$\mathbb{P}(|\cos \theta| \geq 0,05) \leq \frac{1}{25} = 0,04,$$

mit Wahrscheinlichkeit mindestens 96 % liegt der Winkel also zwischen $87,1^\circ$ und $92,9^\circ$. Zum Vergleich: Für $n = 100$ erlaubt dieselbe Schranke noch $|\cos \theta| \leq 0,5$, also jeden Winkel zwischen 60° und 120° . Die Aussage lebt von großem n .

Ziehen wir m solcher Richtungen und schreiben sie als Zeilen in eine Matrix S , so stehen je zwei Zeilen fast senkrecht aufeinander. Ein Orthonormalsystem sind sie deshalb nicht: Für eine Gauss-Zeile $s_i \sim \mathcal{N}(0, I_n/m)$ ist $\mathbb{E}[\|s_i\|^2] = n/m$, bei $n = 10\,000$ und $m = 50$ also 200. Die fast senkrechten Richtungen verdankt S der hohen Dimension, die passende Skalierung dem Faktor $1/m$ in der Verteilung. Die Abbildung $x \mapsto Sx$ misst die Länge von x dann entlang m zufälliger, fast senkrechter Achsen.

Definition 8.4.4 (Sketching-Matrix und Skizze)

Sei $m < n$. Eine Zufallsmatrix $S \in \mathbb{R}^{m \times n}$ heißt *Sketching-Matrix* (sketching matrix), und für $x \in \mathbb{R}^n$ heißt $Sx \in \mathbb{R}^m$ die *Skizze* (sketch) von x . Gesucht sind Verteilungen für S , unter denen mit hoher Wahrscheinlichkeit

$$\|Sx - Sy\| \approx \|x - y\| \quad \text{und} \quad \angle(Sx, Sy) \approx \angle(x, y)$$

gilt, die Skizze also Abstände und Winkel der Originaldaten erbt. Wie im ganzen Kapitel ist $\|\cdot\|$ die euklidische Norm.

Häufig heißt S eine zufällige „Projektion“. Im strengen Sinn ist sie keine: Eine Projektion bildet einen Raum in sich ab und ist idempotent, S dagegen führt vom $\mathbb{R}^n$ in den kleineren $\mathbb{R}^m$.

Ein Zahlenbeispiel**Beispiel 8.4.5 (Sketching zweier Vektoren mit 10 000 Komponenten)**

Ziehen wir zwei beliebige Vektoren $x, y \in \mathbb{R}^{10\,000}$ und eine Gauss-Sketchmatrix mit $m = 50$, also einen Faktor 200 kleiner. Ändern sich Abstand und Winkel dabei eher um 50 %, um 3 % oder um weniger als 0,1 %?

```
set.seed(1312)
## Zwei beliebige n-dimensionale Vektoren
n <- 10000
x <- runif(n)
y <- runif(n)
# (m x n)-Matrix mit m << n und zufälligen Einträgen
m <- 50 # m << n !!
S <- rnorm(m * n, sd = sqrt(1 / m)) |> matrix(nrow = m, ncol = n)
Sx <- S %*% x
Sy <- S %*% y
## Distanzen ||x - y|| und ||Sx - Sy||
c(norm(x - y, "2"), norm(Sx - Sy, "2"))
## Winkel: cos(angle) = (x'y) / (||x|| ||y||)
angle <- function(x, y) (sum(x * y) / (norm(x, "2") * norm(y, "2"))) |> acos()
```

```
c(angle(x, y), angle(Sx, Sy))
```

Die Einträge sind unabhängig $\mathcal{N}(0, 1/m)$ -verteilt, eine Zeile $\mathbf{s}_i$ hat also die Kovarianzstruktur $\mathbb{E}[\mathbf{s}_i \mathbf{s}_i^\top] = \mathbf{I}_n/m$; diese Bedingung brauchen wir gleich. Für diesen Seed weicht der Abstand um rund 3 % ab, der Winkel um rund 1 %, obwohl 99,5 % der Dimensionen wegfallen.

Das war eine gute Ziehung: Bei Gauss-Skizzen liegt die typische relative Abweichung des Abstands bei $1/\sqrt{2m} = 10\%$. Das Verfahren funktioniert, aber einzelne Skizzen streuen erheblich.

Interaktiv: Sketching mit verstellbarem m

Wie weit kann eine einzelne Ziehung danebenliegen? Das Widget rechnet im kleineren Format $n = 200$ statt 10 000, damit sich die Skizzendimension m über den ganzen interessanten Bereich schieben lässt. Verändern wir m und vergleichen wir mehrere Ziehungen.

Interaktives Element — nur in der Web-Fassung

Die Streuung schrumpft wie $1/\sqrt{m}$, nicht wie $1/m$: Für die halbe Abweichung brauchen wir die vierfache Zeilenzahl. Und weil einzelne Ziehungen weit danebenliegen können, ist die Faustregel eine Aussage über die Verteilung, keine Garantie für die eine Skizze, mit der wir gerade rechnen.

1. Wie groß ist im Sketching-Widget die eingeblendete Faustregel in Prozent bei $m = 50$?

Lösung: 10

Nach dem Einblenden zeigt das orange Band $1/\sqrt{2m} = 10\%$.

Der Einbettungssatz

Der folgende Satz macht das präzise. Sein Beweis braucht nur Erwartungswert, Varianz und die Tschebyscheff-Ungleichung.

Satz 8.4.6 (Zufällige Einbettung eines festen Vektors)

Sei $\mathbf{S} \in \mathbb{R}^{m \times n}$ eine Zufallsmatrix, deren Zeilen $\mathbf{s}_1^\top, \dots, \mathbf{s}_m^\top$ unabhängig und identisch verteilt sind und

$$\mathbb{E}[\mathbf{s}_i \mathbf{s}_i^\top] = \frac{1}{m} \mathbf{I}_n \quad (8.4.2)$$

erfüllen, sowie für ein $K > 0$

$$\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4] \leq \frac{K}{m^2} \quad \text{für alle } \mathbf{v} \in \mathbb{R}^n \text{ mit } \|\mathbf{v}\| = 1. \quad (8.4.3)$$

Seien weiter $\mathbf{x} \in \mathbb{R}^n$ fest und $\delta > 0$. Dann gilt mit Wahrscheinlichkeit mindestens $1 - \delta$

$$(1 - \varepsilon) \|\mathbf{x}\|^2 \leq \|\mathbf{S}\mathbf{x}\|^2 \leq (1 + \varepsilon) \|\mathbf{x}\|^2, \quad \varepsilon = \sqrt{\frac{K}{\delta m}}. \quad (8.4.4)$$

Vertiefung (optional): Beweis des Einbettungssatzes

Beweis.

- (1) Wir dürfen $\|\mathbf{x}\| = 1$ annehmen. Beide Seiten von (8.4.4) sind homogen vom Grad 2 in $\mathbf{x}$; für $\mathbf{x} \neq \mathbf{0}$ teilen wir die Ungleichung durch $\|\mathbf{x}\|^2$, und für $\mathbf{x} = \mathbf{0}$ ist nichts zu zeigen. Zu beweisen bleibt

$$P\left(\left|\|\mathbf{S}\mathbf{x}\|^2 - 1\right| \leq \varepsilon\right) \geq 1 - \delta.$$

mit $\mathbf{x}$ erfüllt auch $\mathbf{x}/\|\mathbf{x}\|$ die Voraussetzungen, und $\|\mathbf{S}(\mathbf{x}/\|\mathbf{x}\|)\|^2 = \|\mathbf{S}\mathbf{x}\|^2 / \|\mathbf{x}\|^2$

- (2) Die i -te Komponente von $\mathbf{S}\mathbf{x}$ ist $\mathbf{s}_i^\top \mathbf{x}$, also

$$\|\mathbf{S}\mathbf{x}\|^2 = \sum_{i=1}^m (\mathbf{s}_i^\top \mathbf{x})^2 \quad \text{und} \quad \mathbb{E}[\|\mathbf{S}\mathbf{x}\|^2] = \sum_{i=1}^m \mathbf{x}^\top \mathbb{E}[\mathbf{s}_i \mathbf{s}_i^\top] \mathbf{x} = m \mathbf{x}^\top \frac{\mathbf{I}_n}{m} \mathbf{x} = \|\mathbf{x}\|^2 = 1.$$

Im Erwartungswert trifft die Skizze die Länge also exakt.

$(\mathbf{s}_i^\top \mathbf{x})^2 = \mathbf{x}^\top \mathbf{s}_i \mathbf{s}_i^\top \mathbf{x}$, dann die Linearität des Erwartungswerts und Bedingung (8.4.2)

- (3) Die Summanden sind unabhängig, also addieren sich die Varianzen:

$$\text{Var}[\|\mathbf{S}\mathbf{x}\|^2] = \sum_{i=1}^m \text{Var}[(\mathbf{s}_i^\top \mathbf{x})^2] \leq \sum_{i=1}^m \mathbb{E}[(\mathbf{s}_i^\top \mathbf{x})^4] \leq m \cdot \frac{K}{m^2} = \frac{K}{m}.$$

Hier werden die vierten Momente gebraucht: Sie beschränken die Streuung der Skizze.

$\text{Var}[Z] = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2 \leq \mathbb{E}[Z^2]$ mit $Z = (\mathbf{s}_i^\top \mathbf{x})^2$, danach Bedingung (8.4.3) mit $\mathbf{v} = \mathbf{x}$

- (4) Die Tschebyscheff-Ungleichung führt von der Varianz zur Wahrscheinlichkeit:

$$P\left(\left|\|\mathbf{S}\mathbf{x}\|^2 - 1\right| > \varepsilon\right) \leq \frac{\text{Var}[\|\mathbf{S}\mathbf{x}\|^2]}{\varepsilon^2} \leq \frac{K}{\varepsilon^2 m}.$$

Die Wahl $\varepsilon = \sqrt{K/(\delta m)}$ macht die rechte Seite zu δ , und das Gegenereignis hat damit Wahrscheinlichkeit mindestens $1 - \delta$.

Tschebyscheff mit dem in Schritt 2 berechneten Erwartungswert 1; einsetzen: $K/(\varepsilon^2 m) = K\delta m/(Km) = \delta$

□

Bemerkung 8.4.7 (Warum die Momentenbedingung an der Projektion ansetzt)

Die Varianz in Schritt 3 ließe sich auch einfacher abschätzen, nämlich über die Cauchy-Schwarz-Ungleichung $|\mathbf{s}_i^\top \mathbf{v}| \leq \|\mathbf{s}_i\| \|\mathbf{v}\|$. Dann stünde in (8.4.3) die Länge der ganzen Zeile, $\mathbb{E}[\|\mathbf{s}_i\|^4] \leq K/m^2$. Das wäre richtig, aber unbrauchbar grob: Für $\mathbf{s}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n/m)$ ist

$$\mathbb{E}[\|\mathbf{s}_i\|^4] = \frac{n^2 + 2n}{m^2},$$

das zugehörige K wüchse also wie n^2 ; bei $n = 10\,000$ wäre $K \approx 10^8$ statt 3, und die Schranke aus Satz 8.4.6 wäre wertlos. Der Unterschied ist gerade der verschenkte Faktor $(n^2 + 2n)/3$: Die Zeile $\mathbf{s}_i$ ist lang, ihre Projektion auf eine feste Richtung $\mathbf{v}$ aber kurz, und nur diese Projektion geht in $\|\mathbf{S}\mathbf{x}\|^2$ ein. Bedingung (8.4.3) misst deshalb direkt $\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4]$ und ist für Gauss-Zeilen mit $K = 3$ sogar mit Gleichheit erfüllt (Beispiel 8.4.10).

Weil $\mathbf{S}$ linear ist, gilt $\mathbf{S}\mathbf{x} - \mathbf{S}\mathbf{y} = \mathbf{S}(\mathbf{x} - \mathbf{y})$, und der Satz, angewandt auf den festen Vektor $\mathbf{x} - \mathbf{y}$, liefert die Abstandsangabe aus Definition 8.4.4. Wurzelziehen macht aus der Aussage über $\|\mathbf{S}\mathbf{x}\|^2$ eine über die Länge selbst: Für $\varepsilon \leq 1$ ist $\sqrt{1 - \varepsilon} \leq \|\mathbf{S}\mathbf{x}\| / \|\mathbf{x}\| \leq \sqrt{1 + \varepsilon}$, für $\varepsilon = 0,1$ also $0,949 \leq \|\mathbf{S}\mathbf{x}\| / \|\mathbf{x}\| \leq 1,049$: Eine Verzerrung von 10 % im Quadrat sind rund 5 % in der Länge.

Winkel behandelt der Satz zunächst gar nicht. Sie folgen aber, denn Skalarprodukte lassen sich über die Polarisationsformel aus Längen zurückgewinnen; damit ist auch die Winkelaussage aus Definition 8.4.4 gerechtfertigt.

Vertiefung (optional): Winkeltreue und viele Paare

Korollar 8.4.8 (Skalarprodukte bleiben erhalten)

Seien $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ fest und S wie in Satz 8.4.6. Dann gilt mit Wahrscheinlichkeit mindestens $1 - 2\delta$

$$|(\mathbf{Sx})^\top(\mathbf{Sy}) - \mathbf{x}^\top \mathbf{y}| \leq \frac{\varepsilon}{2} (\|\mathbf{x}\|^2 + \|\mathbf{y}\|^2).$$

Beweis.

- (1) Für beliebige Vektoren $\mathbf{a}, \mathbf{c}$ gilt die Polarisationsformel

$$\mathbf{a}^\top \mathbf{c} = \frac{\|\mathbf{a} + \mathbf{c}\|^2 - \|\mathbf{a} - \mathbf{c}\|^2}{4}.$$

Wir wenden sie einmal auf $\mathbf{Sx}, \mathbf{Sy}$ und einmal auf $\mathbf{x}, \mathbf{y}$ an und nutzen $\mathbf{Sx} \pm \mathbf{Sy} = \mathbf{S}(\mathbf{x} \pm \mathbf{y})$.

ausmultiplizieren: $\|\mathbf{a} + \mathbf{c}\|^2 - \|\mathbf{a} - \mathbf{c}\|^2 = 4 \mathbf{a}^\top \mathbf{c}$

- (2) Satz 8.4.6 gilt für jeden festen Vektor, insbesondere für $\mathbf{x} + \mathbf{y}$ und für $\mathbf{x} - \mathbf{y}$. Jedes der beiden Ereignisse verfehlt die Schranke mit Wahrscheinlichkeit höchstens δ , zusammen also höchstens 2δ . Treten beide ein, so ist

$$|(\mathbf{Sx})^\top(\mathbf{Sy}) - \mathbf{x}^\top \mathbf{y}| \leq \frac{\varepsilon \|\mathbf{x} + \mathbf{y}\|^2 + \varepsilon \|\mathbf{x} - \mathbf{y}\|^2}{4} = \frac{\varepsilon}{2} (\|\mathbf{x}\|^2 + \|\mathbf{y}\|^2).$$

Vereinigungsschranke für die beiden Ausnahmeeignisse; zuletzt die Parallelogrammgleichung $\|\mathbf{x} + \mathbf{y}\|^2 + \|\mathbf{x} - \mathbf{y}\|^2 = 2\|\mathbf{x}\|^2 + 2\|\mathbf{y}\|^2$

□

Für Einheitsvektoren steht rechts ε . Der Kosinus des Winkels ist das Skalarprodukt der normierten Vektoren, und Zähler wie Nenner werden bis auf Terme der Ordnung ε getroffen.

Dieselbe Vereinigungsschranke trägt weiter: Für N Punkte und *alle* Paare brauchen wir die Aussage für $N(N-1)/2$ Differenzvektoren gleichzeitig. Das geht, kostet aber $\delta \rightarrow 2\delta/(N(N-1))$ und damit ein deutlich größeres m .

Bemerkung 8.4.9 (Ein fester Vektor ist nicht jeder Vektor)

Das Wort „fest“ in Satz 8.4.6 ist wesentlich: $\mathbf{x}$ wird festgelegt, bevor S gezogen wird, und die Ausnahmemenge darf für jedes $\mathbf{x}$ eine andere sein. Für alle $\mathbf{x} \in \mathbb{R}^n$ zugleich kann die Aussage nicht gelten. S hat höchstens Rang $m < n$, besitzt also einen nichttrivialen Kern, und für ein $\mathbf{x} \neq \mathbf{0}$ mit $\mathbf{Sx} = \mathbf{0}$ ist (8.4.4) verletzt, wie auch immer S ausgefallen ist.

Gleichmäßige Aussagen sind trotzdem möglich, aber nur auf einem Unterraum kleiner Dimension und mit etwas größerem m (*Subspace Embeddings*): Wir kontrollieren endlich viele Richtungen eines feinen Netzes und übertragen das Ergebnis per Vereinigungsschranke auf den ganzen Unterraum. Solche simultanen Garantien braucht etwa das gesketchte Kleinst-Quadrat-Problem (Algorithmus 8.4.12). Dort hängt der Minimierer selbst von S ab, und die Skizze muss alle Vektoren des von den Spalten von A und $\mathbf{b}$ aufgespannten Unterraums gleichzeitig gut treffen.

Drei Bauarten von Sketching-Matrizen

Welche Verteilungen erfüllen (8.4.2) und (8.4.3)? In der Praxis sind drei Bauarten üblich.

Beispiel 8.4.10 (Gauss, Rademacher, Subsampling)

Gauss. $s_i \text{ iid } \mathcal{N}(0, \mathbf{I}_n/m)$. Bedingung (8.4.2) ist die Definition der Kovarianzmatrix. Für einen Einheitsvektor $\mathbf{v}$ ist $\mathbf{s}_i^\top \mathbf{v} \sim \mathcal{N}(0, 1/m)$, und das vierte Moment einer zentrierten Normalverteilung ist das Dreifache des quadrierten zweiten:

$$\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4] = 3 \left(\frac{1}{m}\right)^2 = \frac{3}{m^2}, \quad \text{also} \quad K = 3.$$

Rademacher. s_{ij} unabhängig mit $\mathbb{P}(s_{ij} = 1/\sqrt{m}) = \mathbb{P}(s_{ij} = -1/\sqrt{m}) = 1/2$. Wegen $\mathbb{E}[s_{ij}^2] = 1/m$ und $\mathbb{E}[s_{ij}s_{ik}] = 0$ für $j \neq k$ gilt wieder (8.4.2). Ausmultiplizieren der vierten Potenz liefert für $\|\mathbf{v}\| = 1$

$$\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4] = \frac{3 - 2 \sum_{j=1}^n v_j^4}{m^2} \leq \frac{3}{m^2},$$

also ebenfalls $K = 3$. Der praktische Vorteil gegenüber Gauss liegt im Erzeugen und Speichern: ein Bit pro Eintrag.

Subsampling. $\mathbf{s}_i = \sqrt{n/m} \mathbf{e}_{K_i}$ mit $K_i \sim \text{Unif}\{1, \dots, n\}$, die Skizze greift also m zufällige Koordinaten heraus und skaliert sie. Auch hier ist $\mathbb{E}[\mathbf{s}_i \mathbf{s}_i^\top] = \frac{n}{m} \cdot \frac{1}{n} \mathbf{I}_n = \mathbf{I}_n/m$. Das vierte Moment sieht aber anders aus:

$$\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4] = \left(\frac{n}{m}\right)^2 \frac{1}{n} \sum_{j=1}^n v_j^4 = \frac{n \sum_{j=1}^n v_j^4}{m^2}, \quad \text{also} \quad K = n \sum_{j=1}^n v_j^4.$$

Dieses K hängt von den Daten ab. Für einen gestreuten Vektor mit $v_j = \pm 1/\sqrt{n}$ ist $\sum_j v_j^4 = 1/n$ und damit $K = 1$, besser als Gauss. Für $\mathbf{v} = \mathbf{e}_1$ dagegen ist $K = n$: Die gesamte Information steckt in einer Koordinate, und die Stichprobe mit Zurücklegen erwischt sie nur mit Wahrscheinlichkeit $1 - (1 - 1/n)^m$ überhaupt. Subsampling taugt also, wenn die Information über viele Koordinaten verteilt ist, und versagt, wenn sie in wenigen sitzt.

Vertiefung (optional): Vergleich der Sketching-Matrizen

Typ	Speicher	Zeit für $\mathbf{Sx}$	Qualität
Gauss	$O(mn)$	$O(mn)$	optimal
Rademacher ($\pm 1/\sqrt{m}$)	$O(mn)$	$O(mn)$	optimal
Subsampling	$O(m)$	$O(m)$	gut bei gestreuten Daten
SRHT (Hadamard)	$O(n+m)$ oder reproduzierbar erzeugte Vorzeichen	$O(n \log n)$	sehr gut

Speicher und Rechenzeit stehen in Landau-Notation: einmal für das Vorhalten von $\mathbf{S}$, einmal für ein einzelnes Produkt $\mathbf{Sx}$.

- **Gauss** ist theoretisch optimal, aber teuer: mn Zahlen speichern und mn Multiplikationen je Vektor.
- **Rademacher** ist genauso gut, wie Beispiel 8.4.10 mit $K = 3$ zeigt, und einfacher zu erzeugen, weil nur Vorzeichen gewürfelt werden. Die Schranke wird sogar besser, je stärker $\mathbf{v}$ auf we-

nige Koordinaten konzentriert ist (für $\mathbf{v} = \mathbf{e}_1$ ist $K = 1$), also gerade umgekehrt wie beim Subsampling.

- **Subsampling** wählt m zufällige Koordinaten und ist damit extrem schnell; die Qualität hängt aber an den Daten (Beispiel 8.4.10).
- **SRHT** verbindet beides. Die Matrix wird nicht explizit gespeichert, sondern durch eine schnelle Transformation angewendet, daher die $O(n \log n)$ in der Tabelle. Neben den m gezogenen Indizes gehören n Vorzeichen zur Transformation; sie werden gespeichert oder reproduzierbar aus einem Seed erzeugt. Die Arbeitskopie des transformierten Vektors benötigt unabhängig davon $O(n)$ Speicher.

Anwendungen

Bemerkung 8.4.11 (Wo Skizzen helfen)

- **Matrixprodukt.** Für $\mathbf{A} \in \mathbb{R}^{p \times n}$ und $\mathbf{B} \in \mathbb{R}^{n \times q}$ ist $\mathbf{AB} \approx (\mathbf{AS}^\top)(\mathbf{SB})$. Der Grund ist (8.4.2): Wegen $\mathbb{E}[\mathbf{S}^\top \mathbf{S}] = \sum_{i=1}^m \mathbb{E}[\mathbf{s}_i \mathbf{s}_i^\top] = \mathbf{I}_n$ ist die rechte Seite erwartungstreu für $\mathbf{AB}$. Statt pnq kostet das Matrixprodukt dann $pnm + mnq + pmq$ Multiplikationen, für $p = q = n$ also rund $3n^2m$ statt n^3 .
- **Kleinste Quadrate.** $\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2 \approx \min_{\mathbf{x}} \|\mathbf{SAx} - \mathbf{Sb}\|_2$, siehe Algorithmus 8.4.12.
- **Approximative Zerlegungen.** Auch die randomisierte Näherung einer Singulärwertzerlegung aus Abschnitt 8.2 arbeitet mit einer Skizze des Spaltenraums.

Schneller wird ein Algorithmus allerdings nur, wenn sich $\mathbf{Sx}$ schnell berechnen lässt. Bei einer dichten Gauss-Matrix kostet $\mathbf{Sx}$ schon $O(mn)$ Operationen, und dann kann die Skizze teurer sein als das Problem, das sie vereinfachen soll. Subsampling zieht nur m Komponenten von $\mathbf{x}$ heraus und kostet $O(m)$, taugt nach Beispiel 8.4.10 aber nur für gestreute Information. Schnelle Anwendung und sehr gute Qualität verbindet die *Subsampled Randomized Hadamard Transform* (SRHT): $\mathbf{S}$ wird nicht gespeichert, sondern über eine schnelle Transformation angewendet. Die vollständige Hadamard-Transformation kostet $O(n \log n)$ Rechenschritte; beschnittene (pruned) Varianten kommen unter zusätzlichen Implementationsannahmen mit weniger aus.

Vertiefung (optional): Sketching für ein Kleinste-Quadrate-Problem

Algorithmus 8.4.12 (Sketching für ein KQ-Problem)

Gegeben $\mathbf{A} \in \mathbb{R}^{n \times p}$ mit $n \gg p$, $\mathbf{b} \in \mathbb{R}^n$ und eine Skizzengröße m mit $p < m \ll n$.

1. Ziehe eine Sketching-Matrix $\mathbf{S} \in \mathbb{R}^{m \times n}$.
2. Berechne $\mathbf{SA} \in \mathbb{R}^{m \times p}$ und $\mathbf{Sb} \in \mathbb{R}^m$.
3. Löse das kleine Problem $\min_{\mathbf{x}} \|(\mathbf{SA})\mathbf{x} - \mathbf{Sb}\|_2$, etwa per QR-Zerlegung (Abschnitt 7.4).

Schritt 3 kostet $O(mp^2)$ statt $O(np^2)$ für das Ausgangsproblem. Ob sich das lohnt, entscheidet Schritt 2: Eine dichte Gauss-Matrix braucht dort $O(mnp)$ Operationen, und wegen $m > p$ ist das mehr als die $O(np^2)$, die wir sparen wollten. Erst mit schnell anwendbaren Skizzen wie der SRHT geht die Rechnung auf.

Wie klein darf m sein?**Beispiel 8.4.13 (Dimensionsreduktion mit Matrix-Sketching)**

Gegeben seien $n = 10\,000$ Dimensionen, eine Fehlerwahrscheinlichkeit $\delta = 0,05$ und eine zulässige Verzerrung $\varepsilon = 0,1$. Wie klein darf m sein? Wir lösen (8.4.4) nach m auf und setzen für Gauss-Zeilen $K = 3$ ein:

$$\varepsilon = \sqrt{\frac{K}{\delta m}} \iff m = \frac{K}{\delta \varepsilon^2} = \frac{3}{0,05 \cdot 0,01} = 6000. \quad (8.4.5)$$

Mit $m = 6000$ Dimensionen bleibt der Abstand eines vorher festgelegten Punktpaares mit Wahrscheinlichkeit 95 % auf 10 % genau erhalten, gemessen im Quadrat der Länge, in der Länge selbst auf rund 5 %. Der Speicher sinkt von 10 000 auf 6000 Zahlen je Punkt, und eine einzelne Distanzberechnung kostet statt $O(n)$ nur noch $O(m)$ Operationen, beide Male ein Gewinn um den Faktor $n/m \approx 1,7$. Typische Anwendungen sind die Suche nach nächsten Nachbarn und die Clusteranalyse in hohen Dimensionen: Beide berühren die Daten fast nur über Abstände, und die bleiben unter der Skizze erhalten.

Die Schranke ist allerdings sehr konservativ, weil die Tschebyscheff-Ungleichung nur zwei Momente benutzt. In der Praxis reichen oft viel kleinere m : Beispiel 8.4.5 kam mit $m = 50$ auf rund 3 % Abweichung, wenn auch mit einer guten Ziehung.

Vertiefung (optional): Wie scharf die Schranke ist

Umgekehrt gelesen sagt (8.4.5), was ein zehnmal kleineres $m = 600$ hergibt: bei $\delta = 0,05$ nur $\varepsilon = \sqrt{3/(0,05 \cdot 600)} = \sqrt{0,1} \approx 0,32$, und bei $\varepsilon = 0,1$ nur $\delta = 3/(600 \cdot 0,01) = 0,5$, also die Verlässlichkeit eines Münzwurfs. Für Gauss-Skizzen ist das viel zu pessimistisch, denn dort lässt sich exakt rechnen. Ist $\mathbf{z} \in \mathbb{R}^n$ fest, so sind die m Komponenten $\mathbf{s}_i^\top \mathbf{z}$ von $\mathbf{S}\mathbf{z}$ unabhängig $\mathcal{N}(0, \|\mathbf{z}\|^2/m)$ -verteilt; damit ist $\|\mathbf{S}\mathbf{z}\|^2 / \|\mathbf{z}\|^2$ genau χ_m^2/m -verteilt. Die Verteilungsfunktion verlangt für $\varepsilon = 0,1$ und $\delta = 0,05$ nur $m = 768$ Zeilen; Tschebyscheff fordert das Achtfache. Auch die Ziehung aus Beispiel 8.4.5 lässt sich so einordnen: Bei $m = 50$ hat die relative Abweichung des Abstands die Standardabweichung 9,97 %, praktisch die Faustregel $1/\sqrt{2m} = 10\%$; nur knapp ein Viertel aller Ziehungen bleibt unter der 3 %-Marke, und nur knapp 8 % landen unter 1 %. Für andere Verteilungen steht diese exakte Rechnung nicht zur Verfügung, schärfere Konzentrationsungleichungen dagegen schon: Sie liefern ein m der Größenordnung $\varepsilon^{-2} \log(1/\delta)$, also eine logarithmische statt einer linearen Abhängigkeit von $1/\delta$. Dafür brauchen sie deutlich mehr Voraussetzungen und einen längeren Beweis (Literatur am Ende des Abschnitts).

Selbsttest

1. Es gibt eine Matrix $\mathbf{S} \in \mathbb{R}^{m \times n}$ mit $m < n$, die alle Abstände exakt erhält.

Antwort: Falsch

Eine solche Matrix hat höchstens Rang $m < n$, also einen nichttrivialen Kern. Für ein $\mathbf{x} \neq \mathbf{0}$ mit $\mathbf{S}\mathbf{x} = \mathbf{0}$ schrumpft der Abstand zum Nullpunkt auf 0. Sketching kann Abstände nur näherungsweise und nur mit hoher Wahrscheinlichkeit erhalten (Bemerkung 8.4.9).

2. Satz 8.4.6 macht eine Aussage über einen vorher festgelegten Vektor $\mathbf{x}$, nicht gleichzeitig über alle $\mathbf{x} \in \mathbb{R}^n$.

Antwort: Wahr

Im Beweis wird $\mathbf{x}$ fixiert, bevor $\mathbf{S}$ gezogen wird; die Ausnahmemenge darf für jedes $\mathbf{x}$ eine andere sein. Gleichmäßige Aussagen über einen Unterraum brauchen ein Netzargument, eine

Vereinigungsschranke und ein etwas größeres m (Bemerkung 8.4.9).

3. Verdoppeln wir m , so halbiert sich die garantierte Verzerrung ε .

Antwort: Falsch

Nach (8.4.4) ist $\varepsilon = \sqrt{K/(\delta m)}$, also proportional zu $1/\sqrt{m}$. Verdoppeltes m drückt ε nur um den Faktor $1/\sqrt{2} \approx 0,71$; für die Halbierung brauchen wir viermal so viele Zeilen.

4. Für Gauss-Zeilen $\mathbf{s}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n/m)$ gilt $\mathbb{E}[(\mathbf{s}_i^\top \mathbf{v})^4] = 3/m^2$ für jeden Vektor $\mathbf{v}$ mit $\|\mathbf{v}\| = 1$.

Antwort: Wahr

Es ist $\mathbf{s}_i^\top \mathbf{v} \sim \mathcal{N}(0, 1/m)$, und das vierte Moment einer zentrierten Normalverteilung ist $3\sigma^4$ (Beispiel 8.4.10). Damit ist (8.4.3) mit $K = 3$ erfüllt, und zwar mit Gleichheit.

5. Subsampling ist für beliebige Daten genauso gut wie eine Gauss-Skizze.

Antwort: Falsch

Für Subsampling ist $K = n \sum_j v_j^4$ und hängt damit von den Daten ab. Bei gestreuten Vektoren ist $K = 1$ und damit besser als die 3 der Gauss-Skizze, beim Standard-Basisvektor $\mathbf{e}_1$ dagegen $K = n$. Subsampling taugt deshalb nur, wenn die Information über viele Koordinaten gestreut ist.

Vertiefung: Die wahrscheinlichkeitstheoretischen Werkzeuge, also Zufallsmatrizen und Konzentrationsungleichungen, behandelt R. Vershynin, High-Dimensional Probability (Cambridge University Press, 2018); die Sketching-Algorithmen selbst, samt SRHT und gesketchten KQ-Problemen, P.-G. Martinsson und J. A. Tropp, Randomized numerical linear algebra: Foundations and algorithms, Acta Numerica 29 (2020).

8.5 Zusammenfassung

Bis Kapitel 7 lief fast alles über *Zerlegungen*. Sie liefern die Lösung bis auf Rundungsfehler und kosten rund n^3 Operationen, gleich ob wir drei Stellen brauchen oder fünfzehn. Dieses Kapitel hat zwei Bauprinzipien hinzugefügt, die diese Kosten senken und dafür Genauigkeit hergeben.

Die drei Kernideen

Bemerkung 8.5.1 (Die drei Kernideen)

1. **Eigenwerte berechnen wir iterativ.** Das charakteristische Polynom taugt nicht als Algorithmus (Bemerkung 8.1.1). Die Potenzmethode (Algorithmus 8.1.2) holt mit einem Matrix-Vektor-Produkt pro Schritt das betragsgrößte Eigenpaar, sofern der größte Eigenwert betragsmäßig getrennt ist (Satz 8.1.4). Die QR-Iteration (Algorithmus 8.1.10) liefert unter den Voraussetzungen von Bemerkung 8.1.14 alle Eigenwerte auf einmal, als simultane Potenzmethode (Bemerkung 8.1.13); jeder ihrer Schritte ist eine Ähnlichkeitstransformation und erhält deshalb das Spektrum (Satz 8.1.11, Satz 8.1.7). Anwendungen (Abschnitt 8.2) sind PageRank, eine Potenzmethode auf einer dünnbesetzten Matrix mit rund 10^{10} Zeilen, die Hauptkomponentenanalyse als Eigenwertaufgabe für die Kovarianzmatrix und die approximative SVD, die nur die k größten Singulärwerte berechnet.

2. **Iterative Löser sind Fixpunktiterationen.** Aus dem Residuum $\mathbf{r}^{(k-1)} = \mathbf{b} - \mathbf{A} \mathbf{x}^{(k-1)}$

wird eine Korrektur; ausmultipliziert ergibt das die affine Vorschrift $\mathbf{x}^{(k)} = \mathbf{B} \mathbf{x}^{(k-1)} + \mathbf{C} \mathbf{b}$ mit $\mathbf{B} = \mathbf{I}_n - \mathbf{C} \mathbf{A}$ (Bemerkung 8.3.4). Hinreichend für Konvergenz ist $\rho = \|\mathbf{B}\|_2 < 1$: Dann schrumpft der Fehler in jedem Schritt auf höchstens das ρ -Fache (Satz 8.3.5). Auch die Potenzmethode ist eine Fixpunktiteration: Die Abbildung $\mathbf{x} \mapsto \mathbf{A} \mathbf{x} / \|\mathbf{A} \mathbf{x}\|$ lässt die normierten Eigenvektoren zu Eigenwerten $\lambda \neq 0$ bis aufs Vorzeichen fest, und ihre Rate ist $|\lambda_2 / \lambda_1|$.

3. **Probabilistische Verfahren ersetzen ein schweres Problem durch ein zufälliges, kleineres.** Eine geeignet gezogene Matrix $\mathbf{S} \in \mathbb{R}^{m \times n}$ mit $m \ll n$ erhält die Abstände und Winkel *vorher festgelegter* Punkte mit hoher Wahrscheinlichkeit näherungsweise (Satz 8.4.6), für alle Vektoren zugleich aber nicht (Bemerkung 8.4.9). Aus einem n -dimensionalen Problem wird ein m -dimensionales, und die Garantie gilt nur mit Wahrscheinlichkeit $1 - \delta$.

Die zweite und die dritte Idee laufen auf denselben Tausch hinaus: Wir geben Genauigkeit her und bekommen Laufzeit zurück. Der Regler sitzt aber an verschiedenen Stellen.

Laufzeit gegen Genauigkeit

Bemerkung 8.5.2 (Zwei Regler und ihre Kosten)

Zugang	Regler	Kosten	Was wir bekommen
Zerlegung (Abschnitt 5.3, Abschnitt 7.4)	keiner	fest, Größenordnung n^3	Lösung bis auf Rundungsfehler
Iteration (8.1, 8.3)	Iterationszahl k	k mal die Kosten eines Schritts	Fehler höchstens ρ^k mal Startfehler
Sketching (8.4)	Skizzengröße m	Rechnen in $\mathbb{R}^m$ statt in $\mathbb{R}^n$	Verzerrung ε je festem Paar, mit Wahrscheinlichkeit $1 - \delta$

Die beiden Regler kosten sehr Verschiedenes. Bei der Iteration fällt der Fehler geometrisch, die Schrittzahl wächst deshalb nur wie $\log(1/\varepsilon)$ (Korollar 8.3.6). Beim Sketching fällt die Verzerrung nur wie $1/\sqrt{m}$: Eine zusätzliche Dezimalstelle verlangt die hundertfache Skizzengröße.

Ein fairer Vergleich ist das trotzdem nicht, denn die beiden ε messen Verschiedenes: einmal den Abstand zur Lösung, einmal die Verzerrung der Geometrie. Als Faustregel: Wo hohe Genauigkeit gefragt ist, iterieren wir; wo eine grobe Antwort genügt und n riesig ist, rechnen wir mit einer Skizze.

Ausblick

Das nächste Kapitel schließt den ersten Teil des Skripts, die numerische lineare Algebra (Abschnitt 1.1), mit Tensoren und Tensorprodukten ab. Ein Tensor ist ein mehrdimensionales Zahlenfeld, die Matrix also der zweidimensionale Sonderfall. Wir brauchen Tensoren, sobald wir nach Matrizen ableiten, denn jedes Differenzieren fügt einen weiteren Index hinzu.

Selbsttest

1. Die Eigenwerte einer großen Matrix bestimmen wir besser nicht über die Nullstellen des charakteristischen Polynoms.

Antwort: Wahr

Drei Gründe stehen in Bemerkung 8.1.1. Ab Grad 5 gibt es keine allgemeine Lösungsformel mehr, wir müssten die Nullstellen also ohnehin iterativ suchen. Der Umweg über die Koeffizienten ist schlecht konditioniert. Und schon das Aufstellen kostet mehr als eine ganze Matrixzerlegung.

2. Iterative Verfahren liefern grundsätzlich nur Näherungen; die exakte Lösung erreichen sie nie.

Antwort: Falsch

In Sonderfällen erreichen sie sie sehr wohl (Bemerkung 8.3.12). Mit $C = A^{-1}$ ist $\rho = 0$, und ein einziger Schritt trifft die Lösung; Verfahren vom Krylov-Typ wie das der konjugierten Gradienten kommen in exakter Arithmetik nach höchstens n Schritten an. Der erste Fall ist nur theoretisch interessant, denn A^{-1} zu kennen wäre teurer als das Gleichungssystem selbst.

3. Die Potenzmethode konvergiert umso schneller, je näher $|\lambda_2|$ bei $|\lambda_1|$ liegt.

Antwort: Falsch

Es ist umgekehrt. Die Rate ist $|\lambda_2/\lambda_1|$ (Satz 8.1.4), und die geht gegen 1, sobald sich die beiden Eigenwerte nähern; im Grenzfall $|\lambda_2| = |\lambda_1|$ trägt Satz 8.1.4 gar nicht mehr (Bemerkung 8.1.6). Dieselbe Nähe macht auch die Eigenvektoren schlecht konditioniert (Bemerkung 8.1.16).

Vertiefung: Heath §4.5 zu den Eigenwertverfahren, Heath §10.9 zu den iterativen Lösern für lineare Gleichungssysteme. Die wahrscheinlichkeitstheoretischen Werkzeuge hinter den Sketching-Schranken behandelt R. Vershynin, High-Dimensional Probability, Cambridge University Press 2018.

8.6 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 4.3	Spektralzerlegung einer 2×2 -Matrix – direkt und iterativ	mittel, ca. 30 Min.
Heath Exercise 4.4	Wann die Potenzmethode versagt	leicht, ca. 15 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 4.17	Eigenwerte von A und A^2	leicht, ca. 15 Min.
Deuffhard/Hohmann Aufgabe 5.1	Eigenwerte, Eigenvektoren und Determinante einer Householder-Matrix	leicht, ca. 15 Min.
Heath Exercise 4.5	Konstante Zeilensummen – Eigenwerte stochastischer Matrizen	leicht, ca. 15 Min.
Schaback/Wendland Aufgabe 6.2	Fixpunktiteration für den Kehrwert $1/a$	mittel, ca. 30 Min.
Schaback/Wendland Aufgabe 6.9	Gesamtschrittverfahren für A und A^T	schwer, ca. 30 Min.

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuffhard/Hohmann Aufgabe 5.4	Pfeilmatrizen – Besetzungsstruktur ausnutzen	schwer, 1 Std. und mehr

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deuffhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.).

Tensoren & Tensorprodukte

9.1 Multilineare Abbildungen

Eine lineare Abbildung nimmt einen Vektor und liefert einen Vektor. Für viele Rechenvorschriften ist das zu eng. Ein Skalarprodukt braucht zwei Vektoren, die Matrizenmultiplikation verarbeitet zwei Matrizen zu einer dritten, und hinter einer quadratischen Form $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ steckt die Abbildung $(\mathbf{x}, \mathbf{y}) \mapsto \mathbf{x}^\top \mathbf{A} \mathbf{y}$ mit zwei Argumenten. Als Abbildung des ganzen Tupels ist keine davon linear, wohl aber in jedem einzelnen Argument. Auf dieser Beobachtung baut das Kapitel auf.

Was wir brauchen

- Vektorräume und ihre Unterräume, dazu Basis und Dimension. In einem Raum der Dimension n ist jeder Vektor durch seine n Koordinaten bezüglich einer festen Basis bestimmt.
- Lineare Abbildungen, also $f(c\mathbf{v} + c'\mathbf{v}') = cf(\mathbf{v}) + c'f(\mathbf{v}')$. Diese Eigenschaft verallgemeinern wir gleich.
- Die lineare Hülle $\text{span}(\{\mathbf{v}_1, \dots, \mathbf{v}_n\}) = \{\mathbf{w} : \mathbf{w} = \sum_i c_i \mathbf{v}_i, c_i \in \mathbb{R}\}$.
- Als Vorschau das *äußere Produkt* $\mathbf{v} \otimes \mathbf{w} = \mathbf{v}\mathbf{w}^\top$ aus Abschnitt 9.3.
- Aus der Analysis: Funktionen mehrerer Veränderlicher, $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$.
- Aus Kapitel 5: lineare Gleichungssysteme $\mathbf{M}\mathbf{z} = \mathbf{c}$ lösen (LU, Cholesky).

Von einem Vektor zu einem Tupel

Bisher haben wir einen Vektor $\mathbf{v} \in V$ linear auf einen Vektor $\mathbf{w} \in W$ abgebildet. Jetzt bilden wir Paare oder allgemeiner Tupel $(\mathbf{v}_1, \dots, \mathbf{v}_n) \in V_1 \times \dots \times V_n$ ab, und zwar wieder „linear“. Die Anführungszeichen sind nötig, denn Linearität bezieht sich hier auf die *einzelnen* Argumente: Halten wir alle Argumente bis auf eines fest, so soll die verbleibende Abbildung linear sein. Solche Abbildungen heißen *multilinear*.

Definition 9.1.1 (Multilineare Abbildung)

Seien $V_1, \dots, V_n, W$ Vektorräume. Eine Abbildung $f : V_1 \times \dots \times V_n \rightarrow W$ heißt *multilinear*, wenn

$$\begin{aligned} f(\mathbf{v}_1, \dots, c\mathbf{v}_i + c'\mathbf{v}'_i, \dots, \mathbf{v}_n) \\ = c f(\mathbf{v}_1, \dots, \mathbf{v}_i, \dots, \mathbf{v}_n) + c' f(\mathbf{v}_1, \dots, \mathbf{v}'_i, \dots, \mathbf{v}_n) \end{aligned}$$

für alle $i = 1, \dots, n$, alle $c, c' \in \mathbb{R}$, alle $\mathbf{v}_i, \mathbf{v}'_i \in V_i$ und alle $\mathbf{v}_\ell \in V_\ell$ ($\ell \neq i$) gilt.

Bemerkung 9.1.2 (Bilinearität und Linearität)

Im Spezialfall $n = 2$ nennen wir f *bilinear*.

Multilineare Abbildungen sind in der Regel *nicht* linear. Skalieren wir alle n Argumente gleichzeitig mit demselben c , so zieht die Homogenität den Faktor n -mal heraus, einmal je Argument:

$$f(c\mathbf{v}_1, c\mathbf{v}_2, \dots, c\mathbf{v}_n) = c^n f(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n).$$

Für eine lineare Abbildung müsste dort c stehen. Ab $n \geq 2$ ist das ein Unterschied, sobald f überhaupt einen Wert ungleich 0 annimmt. Verschiedene Faktoren in verschiedenen Argumenten multiplizieren sich ebenso, für bilineares f etwa $f(2\mathbf{v}, 3\mathbf{w}) = 6 f(\mathbf{v}, \mathbf{w})$.

Die Fläche eines Rechtecks**Beispiel 9.1.3 (Fläche eines Rechtecks)**

Wir betrachten die Fläche eines Rechtecks als Funktion seiner beiden Seitenlängen:

$$f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}, \quad (x, y) \mapsto xy.$$

Warum ist f nicht linear? Verdoppeln wir beide Seiten, setzen also $c = 2$, so wächst die Fläche auf das Vierfache:

$$f(2x, 2y) = 2x \cdot 2y = 4xy = 4f(x, y).$$

Linear wäre $f(cx, cy) = c f(x, y)$, hier also das Doppelte. Solange $xy \neq 0$ ist, sind die beiden Werte verschieden.

Aber f ist bilinear. Halten wir y fest, so gelten Additivität und Homogenität im ersten Argument:

$$\begin{aligned} f(x_1 + x_2, y) &= (x_1 + x_2)y = x_1y + x_2y = f(x_1, y) + f(x_2, y), \\ f(cx, y) &= (cx)y = c(xy) = cf(x, y). \end{aligned}$$

Halten wir umgekehrt x fest, läuft dieselbe Rechnung im zweiten Argument:

$$\begin{aligned} f(x, y_1 + y_2) &= x(y_1 + y_2) = xy_1 + xy_2 = f(x, y_1) + f(x, y_2), \\ f(x, cy) &= x(cy) = c(xy) = cf(x, y). \end{aligned}$$

Die Funktion ist also **in jedem Argument einzeln** linear. Dieselbe Rechnung ohne die geometrische Deutung zeigt zugleich, dass die Multiplikation reeller Zahlen $(x_1, x_2) \mapsto x_1x_2$ bilinear ist; gebraucht haben wir nur Distributiv-, Assoziativ- und Kommutativgesetz in $\mathbb{R}$.

Interaktiv: Verdoppeln, einmal beide Seiten und einmal nur eine

Welche der beiden Skalierungen verhält sich wie bei einer linearen Abbildung?

Interaktives Element — nur in der Web-Fassung

Verdoppeln wir beide Seiten, passt das alte Rechteck viermal in das neue; verdoppeln wir nur eine, passt es zweimal hinein. Das Zweifache ist die Linearität im einzelnen Argument, das

Vierfache $4 = 2^2$ der Fall $n = 2$ der Regel c^n aus Bemerkung 9.1.2.

Weitere Beispiele

Beispiel 9.1.4 (Skalarprodukte sind bilinear)

Jedes Skalarprodukt $f : V \times V \rightarrow \mathbb{R}, (v_1, v_2) \mapsto \langle v_1, v_2 \rangle$, ist bilinear. Im ersten Argument rechnen wir

$$\langle cv + c'v', w \rangle = \langle cv, w \rangle + \langle c'v', w \rangle = c \langle v, w \rangle + c' \langle v', w \rangle.$$

Der erste Schritt ist die Additivität, der zweite die Homogenität. Beide stehen in der Definition des Skalarprodukts; für $x^T y = \sum_i x_i y_i$ folgen sie aus dem Distributivgesetz in $\mathbb{R}$. Das zweite Argument braucht keine neue Rechnung, denn die Symmetrie $\langle v, w \rangle = \langle w, v \rangle$ vertauscht die Rollen.

Beispiel 9.1.5 (Matrizenmultiplikation als bilineare Abbildung)

Die Matrizenmultiplikation

$$\mathbb{R}^{m \times k} \times \mathbb{R}^{k \times n} \rightarrow \mathbb{R}^{m \times n}, \quad (A, B) \mapsto AB,$$

ist bilinear. In beiden Argumenten folgt das aus dem Distributivgesetz für Matrizen und der Verträglichkeit mit Skalaren:

$$(cA + c'A')B = cAB + c'A'B, \quad A(cB + c'B') = cAB + c'AB'.$$

Linear ist auch sie nicht. Skalieren wir beide Faktoren mit c , so erhalten wir $(cA)(cB) = c^2 AB$, wie es Bemerkung 9.1.2 für $n = 2$ vorhersagt.

Darstellung durch Koeffizienten

Sind die beteiligten Räume Koordinatenräume, lässt sich jede multilineare Abbildung durch eine endliche Liste von Zahlen vollständig beschreiben.

Satz 9.1.6 (Darstellung multilinearer Abbildungen)

Eine Abbildung $T : \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_k} \rightarrow \mathbb{R}^m$ ist genau dann multilinear, wenn es reelle Koeffizienten

$$A = (a_{i_1, \dots, i_k, j} : 1 \leq i_1 \leq n_1, \dots, 1 \leq i_k \leq n_k, 1 \leq j \leq m)$$

gibt, sodass

$$T(x^{(1)}, \dots, x^{(k)}) = \sum_{i_1=1}^{n_1} \dots \sum_{i_k=1}^{n_k} \sum_{j=1}^m a_{i_1, \dots, i_k, j} x_{i_1}^{(1)} \dots x_{i_k}^{(k)} e_j \quad (9.1.1)$$

gilt, wobei e_j der j -te Einheitsvektor des $\mathbb{R}^m$ ist. Die Koeffizienten $a_{i_1, \dots, i_k, j}$ sind eindeutig bestimmt.

Die Koeffizienten lassen sich ablesen: $a_{i_1, \dots, i_k, j}$ ist die j -te Komponente von $T(e_{i_1}, \dots, e_{i_k}) \in \mathbb{R}^m$.

Diese Werte legt T selbst fest, daher die Eindeutigkeit. Eine multilineare Abbildung ist also dadurch bestimmt, was sie mit Tupeln von Einheitsvektoren macht.

Vertiefung (optional): Beweisskizze zum Darstellungssatz

Dass eine Abbildung der Gestalt (9.1.1) multilinear ist, ist Nachrechnen. In jedem Summanden steht aus jedem Argument genau eine Koordinate als Faktor. Ersetzen wir $\mathbf{x}^{(l)}$ durch $c\mathbf{x}^{(l)} + c'\mathbf{y}^{(l)}$, so spaltet sich jeder Summand entsprechend auf, und die rechte Seite ist in jedem Argument linear.

Für die andere Richtung entwickeln wir jedes Argument in der Standardbasis seines eigenen Raums, $\mathbf{x}^{(l)} = \sum_{i_l} x_{i_l}^{(l)} \mathbf{e}_{i_l}$ mit $\mathbf{e}_{i_l} \in \mathbb{R}^{n_l}$, und ziehen die Summen nacheinander aus T heraus. Das erlaubt die Multilinearität, und übrig bleibt

$$T(\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(k)}) = \sum_{i_1=1}^{n_1} \dots \sum_{i_k=1}^{n_k} x_{i_1}^{(1)} \dots x_{i_k}^{(k)} T(\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_k}).$$

Der Vergleich mit (9.1.1) liefert die Koeffizienten: Dort steht $a_{i_1, \dots, i_k, j}$ genau an der Stelle, an der hier die j -te Komponente von $T(\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_k})$ auftaucht.

Es sind $n_1 n_2 \dots n_k \cdot m$ Koeffizienten. Die Flächenfunktion aus Beispiel 9.1.3 ($k = 2, n_1 = n_2 = m = 1$) kommt mit der einzigen Zahl $a_{1,1,1} = 1$ aus, ein bilineares $T : \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}$ braucht schon $2 \cdot 2 \cdot 1 = 4$. Wie wir diese Zahlen anordnen, ist das Thema von Abschnitt 9.2.

Selbsttest

1. Wenn im Rechteck-Widget eine Seite null ist, ist das Verhältnis der Flächen vor und nach dem Verdoppeln nicht definiert.

Antwort: Wahr

Das Widget zeigt dann zwei Flächen mit Wert null. Der Quotient wäre $0/0$; darum entscheidet dieser Randfall nicht zwischen Linearität und Bilinearität.

2. Für jede multilineare Abbildung f gilt $f(\mathbf{v}_1, \dots, \mathbf{v}_n) = \mathbf{0}$, sobald $\mathbf{v}_i = \mathbf{0}$ für ein i ist.

Antwort: Wahr

Die Homogenität im i -ten Argument (Definition 9.1.1 mit $c' = 0$) liefert für $c = 0$:

$$f(\mathbf{v}_1, \dots, \mathbf{0}, \dots, \mathbf{v}_n) = f(\mathbf{v}_1, \dots, 0 \cdot \mathbf{v}_i, \dots, \mathbf{v}_n) = 0 \cdot f(\mathbf{v}_1, \dots, \mathbf{v}_i, \dots, \mathbf{v}_n) = \mathbf{0}.$$

Die Werte der übrigen Argumente spielen dabei keine Rolle.

3. Jede bilineare Abbildung ist insbesondere linear.

Antwort: Falsch

Skalieren wir beide Argumente mit c , so wird der Wert mit c^2 multipliziert, nicht mit c (Bemerkung 9.1.2). In Beispiel 9.1.3 ist etwa $f(2, 2) = 4$, eine lineare Abbildung müsste $2 f(1, 1) = 2$ liefern. Bilinear und linear zugleich ist nur die Nullabbildung, denn aus $c^2 f(\mathbf{v}, \mathbf{w}) = c f(\mathbf{v}, \mathbf{w})$ für alle c folgt $f(\mathbf{v}, \mathbf{w}) = \mathbf{0}$.

4. Halten wir in einer multilinearen Abbildung alle Argumente bis auf das i -te fest, so ist die verbleibende Abbildung $V_i \rightarrow W$ linear.

Antwort: Wahr

Das ist Definition 9.1.1 in Worten, und zwar für jedes i .

5. Zwei verschiedene Koeffizienten-Arrays können dieselbe multilineare Abbildung $T : \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_k} \rightarrow \mathbb{R}^m$ darstellen.

Antwort: Falsch

Satz 9.1.6 sichert die Eindeutigkeit zu: $a_{i_1, \dots, i_k, j}$ ist die j -te Komponente von $T(\mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_k})$, also durch T festgelegt. Andere Koeffizienten ergeben eine andere Abbildung.

Vertiefung: vgl. MML §2.7 zu linearen Abbildungen und MML §3.2, wo bilineare Abbildungen als Vorstufe des Skalarprodukts eingeführt werden.

9.2 Tensoren

Der Darstellungssatz (Satz 9.1.6) führt jede multilineare Abbildung auf eine Liste von Zahlen zurück. Um diese Liste geht es im Rest des Kapitels. Wir beginnen mit dem einfachsten Fall.

Der Fall $k = 1$ liefert die Matrix

Setzen wir im Darstellungssatz $k = 1$. Dann hat T nur ein Argument, ist also eine gewöhnliche lineare Abbildung $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$, und von der langen Indexliste bleiben zwei Indizes übrig, $1 \leq i \leq n$ und $1 \leq j \leq m$:

$$T(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^m a_{i,j} x_i \mathbf{e}_j. \quad (9.2.1)$$

Der Faktor x_i hängt nicht von j ab und darf vor die innere Summe. Übrig bleibt ein fester Vektor des $\mathbb{R}^m$, der nur noch von i abhängt:

$$\mathbf{a}_i := \sum_{j=1}^m a_{i,j} \mathbf{e}_j = \begin{pmatrix} a_{i,1} \\ \vdots \\ a_{i,m} \end{pmatrix} \in \mathbb{R}^m, \quad \text{also} \quad T(\mathbf{x}) = \sum_{i=1}^n x_i \mathbf{a}_i.$$

Stellen wir die $\mathbf{a}_i$ als Spalten nebeneinander, so ist diese gewichtete Summe das Matrix-Vektor-Produkt: Mit $\mathbf{A} = (\mathbf{a}_1 \mid \dots \mid \mathbf{a}_n) \in \mathbb{R}^{m \times n}$ gilt

$$T(\mathbf{x}) = \mathbf{A} \mathbf{x}.$$

Für $k = 1$ liefert der Darstellungssatz also die vertraute Tatsache, dass sich jede lineare Abbildung $\mathbb{R}^n \rightarrow \mathbb{R}^m$ als Matrix schreiben lässt.

Bemerkung 9.2.1 (Von der Koeffizientenfamilie zur Matrix)

Im Darstellungssatz steht der Eingangsindex vorn und der Ausgangsindex hinten: In $a_{i,j}$ gehört i zur Komponente von $\mathbf{x}$ und j zur Komponente des Bildvektors. In der Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ ist es umgekehrt, der Ausgangsindex ist der Zeilenindex:

$$(\mathbf{A})_{j,i} = a_{i,j}.$$

Nur so passt das Produkt $\mathbf{A} \mathbf{x}$ zusammen, denn $\mathbf{x}$ hat n Komponenten und $\mathbf{A}$ braucht dafür n Spalten. Wer die Familie unbesehen als Matrix liest, erhält $\mathbf{A}^\top$.

Die Ansammlung der nm Koeffizienten nennen wir eine Matrix. Sie hat zwei Indexpositionen, deshalb sprechen wir von zwei „Dimensionen“ (zu den Anführungszeichen siehe Bemerkung 9.2.6). Allgemein gehört zu jedem k eine Ansammlung von Koeffizienten mit $k + 1$ Indizes, bei $m = 1$ also mit k , und jede solche Ansammlung beschreibt umgekehrt eine multilineare Abbildung.

Ein bilineares Beispiel

Beispiel 9.2.2 (Eine bilineare Abbildung auf $\mathbb{R}^2$ mal $\mathbb{R}^2$)

Wir betrachten $T : \mathbb{R}^2 \times \mathbb{R}^2 \rightarrow \mathbb{R}$ mit

$$T(\mathbf{x}, \mathbf{y}) = 2x_1y_1 + 3x_1y_2 - x_2y_1 + 4x_2y_2.$$

Hier ist $k = 2$, $n_1 = n_2 = 2$ und $m = 1$. Wegen $m = 1$ ist $\mathbf{e}_1 = 1$ die Zahl Eins, und wir lassen den Ausgangsindex weg. Die vier Koeffizienten a_{i_1, i_2} lesen wir direkt ab:

$$a_{1,1} = 2, \quad a_{1,2} = 3, \quad a_{2,1} = -1, \quad a_{2,2} = 4 \quad \implies \quad \mathbf{A} = \begin{pmatrix} 2 & 3 \\ -1 & 4 \end{pmatrix}.$$

Probe. Die Darstellungsformel für $k = 2$ und $m = 1$ lautet

$$\begin{aligned} T(\mathbf{x}, \mathbf{y}) &= \sum_{i_1=1}^2 \sum_{i_2=1}^2 a_{i_1, i_2} x_{i_1} y_{i_2} \\ &= a_{1,1}x_1y_1 + a_{1,2}x_1y_2 + a_{2,1}x_2y_1 + a_{2,2}x_2y_2 \\ &= 2x_1y_1 + 3x_1y_2 - x_2y_1 + 4x_2y_2, \end{aligned}$$

also wieder die Abbildung, von der wir ausgegangen sind. Eine Frage nach der Indexreihenfolge wie in Bemerkung 9.2.1 stellt sich hier nicht: i_1 und i_2 sind beide Eingangsindizes.

Numerisch. Für $\mathbf{x} = (1, 2)^\top$ und $\mathbf{y} = (3, 4)^\top$ ist

$$T(\mathbf{x}, \mathbf{y}) = 2 \cdot 1 \cdot 3 + 3 \cdot 1 \cdot 4 - 1 \cdot 2 \cdot 3 + 4 \cdot 2 \cdot 4 = 6 + 12 - 6 + 32 = 44.$$

In Matrixschreibweise. Die Doppelsumme ist ausgeschrieben der Ausdruck $\mathbf{x}^\top \mathbf{A} \mathbf{y}$:

$$T(\mathbf{x}, \mathbf{y}) = \begin{pmatrix} 1 & 2 \end{pmatrix} \begin{pmatrix} 2 & 3 \\ -1 & 4 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 0 & 11 \end{pmatrix} \begin{pmatrix} 3 \\ 4 \end{pmatrix} = 0 \cdot 3 + 11 \cdot 4 = 44.$$

Eine bilineare Abbildung mit Werten in $\mathbb{R}$ heißt *Bilinearform*. Setzen wir beide Argumente gleich, entsteht aus ihr die quadratische Form $\mathbf{x} \mapsto \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit nur noch einem Argument.

Tensoren

Definition 9.2.3 (Tensor)

Seien $n_1, \dots, n_k \in \mathbb{N}$. Ein *Tensor* (tensor) der *Stufe* k und des Formats $n_1 \times \dots \times n_k$ ist eine durch k Indizes indizierte Familie reeller Zahlen

$$A = (a_{i_1, \dots, i_k})_{1 \leq i_1 \leq n_1, \dots, 1 \leq i_k \leq n_k} \in \mathbb{R}^{n_1 \times \dots \times n_k},$$

also eine Abbildung, die jedem Indextupel $(i_1, \dots, i_k)$ aus $\{1, \dots, n_1\} \times \dots \times \{1, \dots, n_k\}$ genau eine reelle Zahl $a_{i_1, \dots, i_k}$ zuordnet.

Bemerkung 9.2.4 (Stufe und Anordnung der Einträge)

Die Stufe zählt Indexpositionen, nicht Einträge. Die ersten Fälle kennen wir:

Stufe k	Objekt	Format	Einträge
0	Skalar		1
1	Vektor	n	n
2	Matrix	$n_1 \times n_2$	$n_1 n_2$
3	Stapel von Matrizen	$n_1 \times n_2 \times n_3$	$n_1 n_2 n_3$

Die gelegentlich zu lesende Umschreibung „geordnete Menge“ reeller Zahlen ist ungenau, denn eine Menge kennt weder Reihenfolge noch Vielfachheit: $\{1, 1, 2\} = \{2, 1\}$. Es kommt auf die Zuordnung an: Zu jedem Indextupel gehört genau eine Zahl. Derselbe Zahlenvorrat, anders angeordnet, ergibt einen anderen Tensor.

Tensoren desselben Formats addieren wir und strecken sie mit Zahlen, Eintrag für Eintrag wie bei Vektoren und Matrizen.

Satz 9.2.5 (Der Raum aller Tensoren eines Formats)

Seien $n_1, \dots, n_k \in \mathbb{N}$ fest. Mit der eintragsweisen Addition

$$(A + B)_{i_1, \dots, i_k} = a_{i_1, \dots, i_k} + b_{i_1, \dots, i_k}$$

und der eintragsweisen Multiplikation mit Skalaren $(cA)_{i_1, \dots, i_k} = c a_{i_1, \dots, i_k}$ ist $\mathbb{R}^{n_1 \times \dots \times n_k}$ ein Vektorraum über $\mathbb{R}$. Eine Basis bilden die *Einheitstensoren* $\mathbf{E}^{(i_1, \dots, i_k)}$, die an der Stelle $(i_1, \dots, i_k)$ eine 1 und sonst überall 0 haben. Die Dimension ist deshalb $n_1 n_2 \dots n_k$.

Vertiefung (optional): Warum Tensoren eines festen Formats einen Vektorraum bilden

Beweis.

- (1) Jedes Vektorraumaxiom ist eine Gleichung zwischen Tensoren, und zwei Tensoren sind genau dann gleich, wenn sie an jeder Indexstelle übereinstimmen. Beide Verknüpfungen wirken eintragsweise, also bleibt an jeder Indexstelle eine Gleichung zwischen reellen Zahlen stehen. Neutrales Element ist der Nulltensor, das Negative von A der Tensor mit den Einträgen $-a_{i_1, \dots, i_k}$.

Assoziativität, Kommutativität und die Distributivgesetze gelten in $\mathbb{R}$; sie übertragen sich Stelle für Stelle, etwa

$$(c(A + B))_{i_1, \dots, i_k} = c a_{i_1, \dots, i_k} + c b_{i_1, \dots, i_k} = (cA + cB)_{i_1, \dots, i_k}$$

- (2) Zur Basis: Jeder Tensor schreibt sich als

$$A = \sum_{i_1=1}^{n_1} \dots \sum_{i_k=1}^{n_k} a_{i_1, \dots, i_k} \mathbf{E}^{(i_1, \dots, i_k)},$$

und die Koeffizienten dieser Darstellung sind die Einträge von A , also eindeutig. Die $\mathbf{E}^{(i_1, \dots, i_k)}$ erzeugen den Raum somit und sind linear unabhängig. Ihre Anzahl ist die Zahl der Indextupel, und die ist $n_1 n_2 \dots n_k$.

eindeutige Darstellbarkeit ist genau die Basiseigenschaft: Existenz gibt das Erzeugendensystem, Eindeutigkeit die lineare Unabhängigkeit

Bemerkung 9.2.6 (Stufe und Dimension sind zwei verschiedene Zahlen)

Eine 4×4 -Matrix hat die Stufe 2, aber $\mathbb{R}^{4 \times 4}$ hat nach Satz 9.2.5 die Dimension $4^2 = 16$. Ein Tensor des Formats $4 \times 4 \times 4$ hat die Stufe 3, und der zugehörige Raum die Dimension $4^3 = 64$. Wer die Indexpositionen „Dimensionen“ nennt, meint also etwas anderes als die Dimension des Vektorraums. Im maschinellen Lernen heißen die Indexpositionen meist *Achsen* (axes), was die Verwechslung vermeidet.

Zählen wir die Indextupel in einer festen Reihenfolge durch, wird aus jedem Tensor ein Vektor im $\mathbb{R}^{n_1 n_2 \dots n_k}$; Programmbibliotheken nennen das *reshape* oder *flatten*. Zählen wir bei einer Matrix Spalte für Spalte, ist das die Vektorisierung aus Abschnitt 9.5.

Interaktiv: Ein Stufe-3-Tensor, Scheibe für Scheibe

Was bleibt von einem Stufe-3-Tensor übrig, wenn wir die dritte Indexposition k festhalten?

Interaktives Element — nur in der Web-Fassung

Jede Wahl von k liefert eine vollständige Matrix, eine *Scheibe* (slice) des Tensors. Der Tensor ist der Stapel dieser Scheiben.

Anwendungen: Bilder, Stapel, Feature-Maps

Ein Graustufenbild hält je Bildpunkt eine Zahl fest und ist damit eine Matrix: Eine Indexposition läuft über die Höhe, die andere über die Breite. Ein Farbbild braucht drei Zahlen je Pixel, eine je Farbkanal, und wird bei 224×224 Pixeln zu einem Tensor der Stufe 3, $\mathbf{I} \in \mathbb{R}^{224 \times 224 \times 3}$, mit $224 \cdot 224 \cdot 3 = 150\,528$ Zahlen. Neuronale Netze verarbeiten Bilder stapelweise, etwa 32 auf einmal. Der Stapel $\mathbf{B} \in \mathbb{R}^{32 \times 224 \times 224 \times 3}$ ist ein Tensor der Stufe 4 mit rund $4,8 \cdot 10^6$ Zahlen; bei einem Video zählt dieselbe vierte Indexposition die Einzelbilder. Eine Faltungsschicht (convolutional layer) bildet Tensoren auf Tensoren ab, etwa $c : \mathbb{R}^{32 \times 224 \times 224 \times 3} \rightarrow \mathbb{R}^{32 \times 56 \times 56 \times 64}$, mit 64 Merkmalskanälen (*Feature-Maps*) statt der drei Farbkanäle.

Solche Rechnungen bestehen aus sehr vielen gleichartigen Multiplikationen und Additionen auf regelmäßig angeordneten Zahlen. Spezialisierte Rechenwerke wie Googles TPUs und NVIDIAs Tensor Cores führen sie blockweise aus; für das maschinelle Lernen ist diese Hardware eine Voraussetzung.

Interaktiv: Farbbild als Kanäle

Wie setzen sich die drei Zahlen eines Pixels zu seiner sichtbaren Farbe zusammen?

Interaktives Element — nur in der Web-Fassung

Die drei Kanalscheiben sind keine drei Bilder, sondern die drei Komponenten jedes Pixels ein und desselben Bildes.

Vertiefung (optional): Bilder, Stapel und Feature-Maps im Detail

Beispiel 9.2.7 (Ein Farbbild als Tensor der Stufe 3)

Beim Farbbild $I \in \mathbb{R}^{224 \times 224 \times 3}$ nummeriert der dritte Index die Kanäle:

- $I_{i,j,1}$: Rot-Intensität an der Position (i, j) , ein Wert zwischen 0 und 255,
- $I_{i,j,2}$: Grün-Intensität an derselben Position,
- $I_{i,j,3}$: Blau-Intensität an derselben Position.

Das sind

$$224 \cdot 224 \cdot 3 = 150\,528 \approx 150 \cdot 10^3$$

Zahlen für ein einziges Bild. Welche Indexposition wofür steht, ist Verabredung, und die Verabredungen gehen auseinander: Manche Bibliothek stellt den Kanalindex nach vorn, manche lässt ihn hinten, und auch die Reihenfolge von Zeile und Spalte ist nicht überall gleich. Für die Mathematik ist das gleichgültig, für den Code nicht.

Beispiel 9.2.8 (Ein Stapel Bilder als Tensor der Stufe 4)

Ein faltendes Netz (convolutional neural network, CNN) bekommt typischerweise 32 Bilder auf einmal vorgesetzt, also

$$\mathbf{B} \in \mathbb{R}^{32 \times 224 \times 224 \times 3},$$

wobei die vier Indexpositionen der Reihe nach die Nummer des Bildes im Stapel (*Batch-Größe*), die Höhe, die Breite und den Farbkanal angeben. Nachgezählt sind das

$$32 \cdot 224 \cdot 224 \cdot 3 = 4\,816\,896 \approx 4,8 \cdot 10^6$$

Zahlen. Bei einfacher Genauigkeit mit 4 Byte je Zahl belegt allein die Eingabe eines einzigen Rechenschritts damit rund 19 Millionen Byte. Ob die vierte Indexposition die Bilder eines Stapels oder die eines Videos in der Zeit zählt, sieht man ihr nicht an; wir müssen es dazusagen.

Beispiel 9.2.9 (Feature-Maps: eine Abbildung von Tensoren auf Tensoren)

Eine Faltungsschicht (convolutional layer) eines CNN bildet Tensoren auf Tensoren ab, etwa

$$c : \mathbb{R}^{32 \times 224 \times 224 \times 3} \rightarrow \mathbb{R}^{32 \times 56 \times 56 \times 64}.$$

Sie senkt die räumliche Auflösung von 224×224 auf 56×56 und erhöht dabei die Zahl der Kanäle von 3 auf 64. Diese Kanäle stehen jetzt nicht mehr für Farben, sondern für Merkmale (features): Jede der 64 Ebenen hält für jede Position fest, wie stark ein bestimmtes lokales Muster dort anspricht, und heißt deshalb *Feature-Map*.

Kleiner wird der Tensor dabei nicht:

$$32 \cdot 56 \cdot 56 \cdot 64 = 6\,422\,528 \approx 6,4 \cdot 10^6,$$

also mehr als die 4 816 896 Einträge des Eingangs. Die Auflösung fällt zwar um den Faktor 16, die Kanalzahl wächst aber um den Faktor $\frac{64}{3} = \frac{4}{3}$. Das Bild unten zeigt Feature-Maps aus Block 3 des VGG16-Modells: Jede einzelne sieht aus wie ein grobes Graustufenbild, hell an den Stellen, an denen das jeweilige Muster kräftig anspricht.

64 ausgewählte Feature-Maps aus Block 3 von VGG16 für dasselbe Eingabebild. Der Block erzeugt insgesamt 256 Kanäle. Quelle: Machine Learning Mastery.

Was an einer Faltungsschicht linear ist. Die Abbildung c hat nur ein Argument, ist also keine multilineare Abbildung im Sinn von Abschnitt 9.1. Bei fest gewählten Gewichten ist sie linear im Ein-

gangstensor. Nehmen wir die Gewichte als zweites Argument hinzu, so ist jeder Ausgangseintrag eine Summe von Produkten aus je einem Gewicht und je einem Eingangseintrag, die Zuordnung (Gewichte, Eingang) $\mapsto$ Ausgang ist damit bilinear, also der Fall $k = 2$ des Darstellungssatzes. Zu einer vollständigen Schicht gehören meist noch ein additiver Term und eine nichtlineare Funktion, die auf jeden Eintrag einzeln wirkt. Erst diese Funktion macht aus einem neuronalen Netz mehr als eine lange Kette linearer Abbildungen.

1. Ein Farbbild mit 224×224 Pixeln und drei Farbkanälen ist ein Tensor der Stufe 3 mit 150 528 Einträgen.

Antwort: Wahr

Es ist $224 \cdot 224 \cdot 3 = 150\,528$, also rund $150 \cdot 10^3$ Zahlen (Beispiel 9.2.7). Die drei Indexpositionen sind die beiden Pixelrichtungen und der Farbkanal; in welcher Reihenfolge sie stehen, ist Verabredung und von Bibliothek zu Bibliothek verschieden.

2. Weil die Faltungsschicht $c : \mathbb{R}^{32 \times 224 \times 224 \times 3} \rightarrow \mathbb{R}^{32 \times 56 \times 56 \times 64}$ die Auflösung von 224×224 auf 56×56 senkt, hat ihr Ausgang weniger Einträge als ihr Eingang.

Antwort: Falsch

Nachgezählt: $32 \cdot 224 \cdot 224 \cdot 3 = 4\,816\,896$ gegen $32 \cdot 56 \cdot 56 \cdot 64 = 6\,422\,528$. Die Auflösung fällt um den Faktor 16, die Kanalzahl wächst um den Faktor $64/3$, zusammen wächst die Zahl der Einträge um den Faktor $4/3$ (Beispiel 9.2.9).

Selbsttest

1. Wie viele Einträge zeigt der Zahlen-Stapel des Widgets bei vier Scheiben einer 4×4 -Matrix?

Lösung: 64

Die zusätzliche Indexposition multipliziert die Zahl der Einträge mit der Zahl der Scheiben.

2. Setzen wir im Darstellungssatz $k = 1$, so ist die Koeffizientenansammlung eine Matrix $\mathbf{A}$, und es gilt $T(\mathbf{x}) = \mathbf{A}\mathbf{x}$.

Antwort: Wahr

Das ist die Rechnung zu (9.2.1): Die innere Summe $\sum_j a_{ij} \mathbf{e}_j$ ist ein fester Vektor $\mathbf{a}_i \in \mathbb{R}^m$, und $\sum_i x_i \mathbf{a}_i$ ist das Matrix-Vektor-Produkt mit $\mathbf{A} = (\mathbf{a}_1 \mid \cdots \mid \mathbf{a}_n)$. Auf die Reihenfolge der Indizes müssen wir dabei achten (Bemerkung 9.2.1).

3. Die Stufe eines Tensors ist die Anzahl seiner Einträge.

Antwort: Falsch

Die Stufe zählt die Indexpositionen. Ein Tensor des Formats $4 \times 4 \times 4$ hat die Stufe 3, aber $4^3 = 64$ Einträge (Definition 9.2.3).

4. Der Vektorraum $\mathbb{R}^{4 \times 4 \times 4}$ hat die Dimension 3.

Antwort: Falsch

Seine Dimension ist $4 \cdot 4 \cdot 4 = 64$, denn so viele Einheitstensoren bilden nach Satz 9.2.5 eine Basis. Die 3 ist die Stufe, also die Zahl der Indexpositionen (Bemerkung 9.2.6).

5. Ein Tensor ist durch die Menge seiner Einträge festgelegt.

Antwort: Falsch

Eine Menge kennt weder Reihenfolge noch Vielfachheit. Vertauschen wir zwei verschiedene Einträge einer Matrix, so bleibt die Menge der vorkommenden Zahlen dieselbe, die Matrix ist aber eine andere. Festgelegt ist ein Tensor durch die Zuordnung von Indexupeln zu Zahlen (Definition 9.2.3 und Bemerkung 9.2.4).

Vertiefung: vgl. MML §5.4, wo mehrdimensionale Zahlenfelder beim Ableiten matrixwertiger Ausdrücke auftreten.

9.3 Produkte von Tensoren

Das Skalarprodukt macht aus zwei Vektoren eine Zahl. Hier gehen wir in die Gegenrichtung und bauen aus zwei Objekten ein größeres: aus zwei Vektoren eine Matrix, aus zwei Matrizen einen Tensor der Stufe 4 oder, anders angeordnet, eine große Matrix. Die ersten beiden Konstruktionen schreiben wir mit $\otimes$, die dritte, das Kroneckerprodukt, mit $\otimes_K$.

Das äußere Produkt

Definition 9.3.1 (Äußeres Produkt)

Das *äußere Produkt* (outer product) zweier Vektoren $\mathbf{v} \in \mathbb{R}^m$ und $\mathbf{w} \in \mathbb{R}^n$ ist die Matrix

$$\mathbf{v} \otimes \mathbf{w} := \mathbf{v} \mathbf{w}^\top = \begin{pmatrix} v_1 w_1 & \cdots & v_1 w_n \\ \vdots & & \vdots \\ v_m w_1 & \cdots & v_m w_n \end{pmatrix} \in \mathbb{R}^{m \times n}, \quad (9.3.1)$$

also die Matrix mit den Einträgen $(\mathbf{v} \otimes \mathbf{w})_{ij} = v_i w_j$.

Bemerkung 9.3.2 (Inneres und äußeres Produkt)

Das Skalarprodukt heißt auch *inneres Produkt* (inner product). Nebeneinandergestellt:

$$\langle \cdot, \cdot \rangle : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, \quad \langle \mathbf{v}, \mathbf{w} \rangle = \mathbf{v}^\top \mathbf{w},$$

$$\otimes : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}^{m \times n}, \quad \mathbf{v} \otimes \mathbf{w} = \mathbf{v} \mathbf{w}^\top.$$

Das innere Produkt verlangt zwei Vektoren gleicher Länge und liefert eine Zahl, das äußere verträgt beliebige Längen und liefert eine $m \times n$ -Matrix. In $\mathbf{v}^\top \mathbf{w}$, also $(1 \times n)$ mal $(n \times 1)$, treffen sich die beiden Längen innen und verschwinden; in $\mathbf{v} \mathbf{w}^\top$, also $(m \times 1)$ mal $(1 \times n)$, stehen sie außen und ergeben das Format $m \times n$.

Beispiel 9.3.3 (Äußeres Produkt zweier Vektoren)

Für

$$\mathbf{v} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \in \mathbb{R}^2 \quad \text{und} \quad \mathbf{w} = \begin{pmatrix} -2 \\ 3 \\ -11 \end{pmatrix} \in \mathbb{R}^3$$

ist

$$\mathbf{v} \otimes \mathbf{w} = \mathbf{v} \mathbf{w}^\top = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \begin{pmatrix} -2 & 3 & -11 \end{pmatrix} = \begin{pmatrix} -2 & 3 & -11 \\ -4 & 6 & -22 \end{pmatrix} \in \mathbb{R}^{2 \times 3}.$$

Die zweite Zeile ist das Doppelte der ersten, denn $v_2 = 2v_1$, und jede Spalte ist ein Vielfaches von $v = (1, 2)^T$. Das gilt allgemein.

Eine Rang-1-Matrix und was sie tut

Interaktiv: Ein Bildraum als Gerade

Wie hängen die beiden Faktoren einer Rang-1-Matrix mit ihrem Bild und ihrem Kern zusammen?

Interaktives Element — nur in der Web-Fassung

Jedes Bild $(v \otimes w)x$ liegt auf der Geraden durch v , und auf 0 abgebildet werden genau die Vektoren x , die senkrecht auf w stehen.

Satz 9.3.4 (Eigenschaften des äußeren Produkts)

Seien $v \in \mathbb{R}^m$ und $w \in \mathbb{R}^n$ beide vom Nullvektor verschieden, und sei $M = v \otimes w$. Dann gilt:

1. Die j -te Spalte von M ist $w_j v$, die i -te Zeile ist $v_i w^T$.
2. Für alle $x \in \mathbb{R}^n$ ist $Mx = v \langle w, x \rangle$.
3. $\text{col}(M) = \text{span}\{v\}$, das Bild ist also eindimensional, und $\text{rang}(M) = 1$.
4. Der Kern ist $\text{Kern}(M) = \{x \in \mathbb{R}^n : w^T x = 0\}$, also die Hyperebene durch den Ursprung senkrecht zu w ; sie hat die Dimension $n - 1$.

Vertiefung (optional): Beweis der Eigenschaften des äußeren Produkts

Beweis.

- (1) Zu (1): Nach (9.3.1) steht an der Stelle (i, j) der Eintrag $v_i w_j$. In der j -ten Spalte steckt damit in jedem Eintrag derselbe Faktor w_j , sie ist also $w_j v$; für die Zeilen läuft es genauso mit v_i .

Ausklammern eines gemeinsamen Faktors, Eintrag für Eintrag

- (2) Zu (2): Wir setzen die Definition ein und klammern anders:

$$Mx = (v w^T)x = v(w^T x) = v \langle w, x \rangle.$$

Das Matrixprodukt sagt uns damit, was diese lineare Abbildung tut: Sie misst x gegen w und trägt das Ergebnis als Vielfaches von v ab.

Assoziativität des Matrixprodukts; $w^T x$ ist eine 1×1 -Matrix, also eine Zahl, und Zahlen dürfen wir vor den Vektor ziehen

- (3) Zu (3): Nach Schritt 2 ist jedes Bild ein Vielfaches von v , also $\text{col}(M) \subseteq \text{span}\{v\}$. Umgekehrt erreichen wir jedes Vielfache: Für $x = t w / \|w\|^2$ ist $\langle w, x \rangle = t$ und damit $Mx = t v$. Wegen $v \neq 0$ hat dieser Bildraum die Dimension 1.

hier brauchen wir $w \neq 0$, sonst ist die Division nicht erlaubt und M die Nullmatrix; der Rang ist die Dimension des Bildes

- (4) Zu (4): Nach Schritt 2 gilt $Mx = 0$ genau dann, wenn $\langle w, x \rangle v = 0$ ist, und wegen $v \neq 0$ genau dann, wenn $w^T x = 0$ ist. Das ist die Menge aller zu w orthogonalen Vektoren. Die Probe liefert der Rangsatz: $1 + (n - 1) = n$.

ein Vielfaches $c \mathbf{v}$ ist genau dann der Nullvektor, wenn $c = 0$ ist; der Rangsatz verlangt $\text{rang}(\mathbf{M}) + \dim \text{Kern}(\mathbf{M}) = n$

□

Umgekehrt ist jede Matrix vom Rang 1 ein äußeres Produkt: Ihr Spaltenraum hat die Dimension 1, jede Spalte ist also ein Vielfaches eines festen $\mathbf{v}$, und die Vielfachen sammeln wir in $\mathbf{w}$.

Wo äußere Produkte auftauchen

Bemerkung 9.3.5 (Die SVD als Summe äußerer Produkte)

Die Summenform der Singulärwertzerlegung aus Abschnitt 6.4 (Satz 6.4.2, dort als $\mathbf{u}_i \mathbf{v}_i^\top$ geschrieben) lautet für $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$

$$\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top = \sum_{i=1}^r \sigma_i \mathbf{u}_i \otimes \mathbf{v}_i.$$

Nach Satz 9.3.4 ist jeder Summand eine Rang-1-Matrix mit der Bildgeraden $\text{span}\{\mathbf{u}_i\}$, und σ_i gibt ihr Gewicht an. Die SVD zerlegt eine Matrix also in r Rang-1-Bausteine; nach k Termen abgebrochen, liefert die Summe die beste Rang- k -Approximation (Satz von Eckart, Young und Mirsky).

Bemerkung 9.3.6 (Kovarianzmatrizen sind Mittel äußerer Produkte)

Sei $\mathbf{x}$ ein Zufallsvektor im $\mathbb{R}^n$ mit Erwartungswert $\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}]$. Die Kovarianzmatrix ist definiert als

$$\text{Cov}(\mathbf{x}) = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu}) \otimes (\mathbf{x} - \boldsymbol{\mu})],$$

also als Erwartungswert eines äußeren Produkts, gebildet Eintrag für Eintrag. Ausmultiplizieren und die Linearität des Erwartungswerts liefern die Verschiebungsformel

$$\text{Cov}(\mathbf{x}) = \mathbb{E}[\mathbf{x} \otimes \mathbf{x}] - \boldsymbol{\mu} \otimes \boldsymbol{\mu} = \mathbb{E}[\mathbf{x} \otimes \mathbf{x}] - \mathbb{E}[\mathbf{x}] \otimes \mathbb{E}[\mathbf{x}],$$

denn $\mathbb{E}[\mathbf{x} \otimes \boldsymbol{\mu}] = \boldsymbol{\mu} \otimes \boldsymbol{\mu} = \mathbb{E}[\boldsymbol{\mu} \otimes \mathbf{x}]$, und von den drei gleichen Termen bleibt einer mit negativem Vorzeichen übrig. Die Formel ist die mehrdimensionale Fassung von $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$; numerisch ist sie aus demselben Grund heikel wie dort, siehe die Auslöschung in Abschnitt 2.1.

Auch der Aufmerksamkeitsmechanismus (attention) moderner Sprachmodelle rechnet mit äußeren Produkten. Seine übliche Form ist

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{SoftMax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V},$$

wobei die Zeilen von $\mathbf{Q}$, $\mathbf{K}$ und $\mathbf{V}$ Anfragen (queries), Schlüssel (keys) und Werte (values) sind und d_k die Spaltenzahl von $\mathbf{Q}$ und $\mathbf{K}$ ist. Wie $\mathbf{U}_r \Sigma_r \mathbf{V}_r^\top$ in Bemerkung 9.3.5 ist der Faktor $\mathbf{Q}\mathbf{K}^\top$ eine Summe äußerer Produkte, eines je Spalte von $\mathbf{Q}$ und $\mathbf{K}$.

Vertiefung (optional): Empirische Kovarianz und Attention

Für jede einzelne Realisierung mit $\mathbf{x} \neq \boldsymbol{\mu}$ ist $(\mathbf{x} - \boldsymbol{\mu}) \otimes (\mathbf{x} - \boldsymbol{\mu})$ nach Satz 9.3.4 eine Rang-1-Matrix; erst das Mitteln über viele Richtungen macht die Kovarianzmatrix im Regelfall zu einer Matrix von vollem Rang. Genauso gebaut ist die empirische Kovarianzmatrix aus N Beobachtungen, $\hat{\Sigma} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}}) \otimes (\mathbf{x}_i - \bar{\mathbf{x}})$, und weil die zentrierten Vektoren sich zu null summieren, ist $\text{rang}(\hat{\Sigma}) \leq N - 1$: Bei weniger Beobachtungen als Dimensionen ist die Schätzung stets singulär.

In der Attention-Formel ist $\mathbf{Q} \in \mathbb{R}^{n_q \times d_k}$ mit den Zeilen $\mathbf{q}_i^\top$, $\mathbf{K} \in \mathbb{R}^{n_k \times d_k}$ mit den Zeilen $\mathbf{k}_j^\top$ und $\mathbf{V} \in \mathbb{R}^{n_k \times d_v}$; SoftMax wirkt zeilenweise, und das Ergebnis liegt in $\mathbb{R}^{n_q \times d_v}$. Der Eintrag (i, j) von $\mathbf{Q}\mathbf{K}^\top$ ist das innere Produkt $\langle \mathbf{q}_i, \mathbf{k}_j \rangle$, das Modell vergleicht also jede Anfrage mit jedem Schlüssel. Als ganze Matrix ist derselbe Ausdruck eine Summe äußerer Produkte über die d_k Spalten,

$$\mathbf{Q}\mathbf{K}^\top = \sum_{l=1}^{d_k} \mathbf{q}^{(l)} \otimes \mathbf{k}^{(l)},$$

mit $\mathbf{q}^{(l)}$ und $\mathbf{k}^{(l)}$ als l -ten Spalten von $\mathbf{Q}$ und $\mathbf{K}$. Der Rang der Scorematrix $\mathbf{Q}\mathbf{K}^\top$ ist damit höchstens d_k , und weil d_k in der Praxis viel kleiner ist als die Zahl der Zeilen, steckt in den Scores eine Zerlegung von niedrigem Rang, wie bei der SVD. Das gilt vor der Softmax-Transformation: Softmax ist nicht linear und erhält die Rangschranke im Allgemeinen nicht, die Matrix der Attention-Gewichte kann also vollen Rang haben.

Das Tensorprodukt

Das äußere Produkt macht aus zwei Objekten der Stufe 1 eines der Stufe 2. Dieselbe Vorschrift funktioniert für beliebige Stufen: Jeder Eintrag des einen Tensors wird mit jedem Eintrag des anderen multipliziert.

Definition 9.3.7 (Tensorprodukt)

Seien $\mathbf{A} \in \mathbb{R}^{m_1 \times \dots \times m_p}$ ein Tensor der Stufe p und $\mathbf{B} \in \mathbb{R}^{n_1 \times \dots \times n_q}$ einer der Stufe q . Ihr *Tensorprodukt* ist der Tensor $\mathbf{A} \otimes \mathbf{B} = \mathbf{C} \in \mathbb{R}^{m_1 \times \dots \times m_p \times n_1 \times \dots \times n_q}$ der Stufe $p + q$ mit den Einträgen

$$c_{i_1, \dots, i_p, j_1, \dots, j_q} = a_{i_1, \dots, i_p} \cdot b_{j_1, \dots, j_q}, \quad (9.3.2)$$

für alle $1 \leq i_r \leq m_r$ und $1 \leq j_s \leq n_s$. Das Tensorprodukt ist also eine Abbildung

$$\otimes : \mathbb{R}^{m_1 \times \dots \times m_p} \times \mathbb{R}^{n_1 \times \dots \times n_q} \rightarrow \mathbb{R}^{m_1 \times \dots \times m_p \times n_1 \times \dots \times n_q}.$$

Bemerkung 9.3.8 (Stufen addieren sich, Einträge multiplizieren sich)

Der Ergebnistensor hat $p + q$ Indexpositionen, die ersten p von $\mathbf{A}$, die letzten q von $\mathbf{B}$, und $(m_1 \dots m_p) \cdot (n_1 \dots n_q)$ Einträge, denn jeder Eintrag von $\mathbf{A}$ trifft genau einmal auf jeden Eintrag von $\mathbf{B}$.

Für $p = q = 1$ wird (9.3.2) zu $c_{i,j} = a_i b_j$, und das ist Definition 9.3.1: Das äußere Produkt ist das Tensorprodukt zweier Tensoren der Stufe 1. Zwei Vektoren spannen so ein Gitter von Produkten auf, drei Vektoren einen Quader, und jede weitere Stufe legt eine Achse dazu.

Satz 9.3.9 (Das Tensorprodukt ist bilinear)

Für Tensoren $\mathbf{A}, \mathbf{A}'$ desselben Formats, $\mathbf{B}, \mathbf{B}'$ desselben Formats und $c \in \mathbb{R}$ gilt

$$(\mathbf{A} + \mathbf{A}') \otimes \mathbf{B} = \mathbf{A} \otimes \mathbf{B} + \mathbf{A}' \otimes \mathbf{B}, \quad (c\mathbf{A}) \otimes \mathbf{B} = c(\mathbf{A} \otimes \mathbf{B}),$$

und ebenso im zweiten Argument. Außerdem ist das Tensorprodukt assoziativ: Für einen dritten Tensor D beliebigen Formats gilt $(A \otimes B) \otimes D = A \otimes (B \otimes D)$.

Vertiefung (optional): Beweis der Bilinearität des Tensorprodukts

Beweis.

- (1) Alle Aussagen sind Gleichungen zwischen Tensoren, und zwei Tensoren sind genau dann gleich, wenn sie an jeder Indexstelle übereinstimmen. Dort steht jeweils eine Gleichung zwischen reellen Zahlen, die aus den Rechengesetzen in $\mathbb{R}$ folgt. Insbesondere ist $\otimes$ in jedem seiner beiden Argumente linear, also bilinear im Sinn von Definition 9.1.1.

an der Stelle $(i_1, \dots, i_p, j_1, \dots, j_q)$ etwa $(a_{i_1, \dots, i_p} + a'_{i_1, \dots, i_p}) b_{j_1, \dots, j_q} = a_{i_1, \dots, i_p} b_{j_1, \dots, j_q} + a'_{i_1, \dots, i_p} b_{j_1, \dots, j_q}$; Homogenität, zweites Argument und Assoziativität gehen genauso

□

Beispiel 9.3.10 (Tensorprodukt dreier Vektoren)

Wir nehmen

$$\mathbf{u} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{v} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} 7 \\ 11 \end{pmatrix},$$

alle drei im $\mathbb{R}^2$. Das Tensorprodukt $T = \mathbf{u} \otimes \mathbf{v} \otimes \mathbf{w} \in \mathbb{R}^{2 \times 2 \times 2}$ hat nach (9.3.2) die Einträge $T_{i,j,k} = u_i v_j w_k$; auf die Klammerung kommt es nach Satz 9.3.9 nicht an. Alle acht Einträge, geordnet nach der dritten Indexposition:

$$\text{Scheibe } k = 1 \ (\mathbf{w}_1 = 7): \quad T_{1,1,1} = 1 \cdot 3 \cdot 7 = 21, \quad T_{1,2,1} = 1 \cdot 5 \cdot 7 = 35,$$

$$T_{2,1,1} = 2 \cdot 3 \cdot 7 = 42, \quad T_{2,2,1} = 2 \cdot 5 \cdot 7 = 70,$$

$$\text{Scheibe } k = 2 \ (\mathbf{w}_2 = 11): \quad T_{1,1,2} = 1 \cdot 3 \cdot 11 = 33, \quad T_{1,2,2} = 1 \cdot 5 \cdot 11 = 55,$$

$$T_{2,1,2} = 2 \cdot 3 \cdot 11 = 66, \quad T_{2,2,2} = 2 \cdot 5 \cdot 11 = 110.$$

Als Scheiben geschrieben:

$$T_{\cdot, \cdot, 1} = \begin{pmatrix} 21 & 35 \\ 42 & 70 \end{pmatrix}, \quad T_{\cdot, \cdot, 2} = \begin{pmatrix} 33 & 55 \\ 66 & 110 \end{pmatrix}.$$

Beide Scheiben sind Vielfache derselben Matrix, nämlich

$$T_{\cdot, \cdot, k} = w_k \cdot (\mathbf{u} \otimes \mathbf{v}), \quad \mathbf{u} \otimes \mathbf{v} = \begin{pmatrix} 3 & 5 \\ 6 & 10 \end{pmatrix}.$$

Nach Satz 9.3.4 hat $\mathbf{u} \otimes \mathbf{v}$ den Rang 1, und das Vielfache mit $w_k \neq 0$ ändert daran nichts: Jede Scheibe ist eine Rang-1-Matrix. Tensoren der Form $\mathbf{u} \otimes \mathbf{v} \otimes \mathbf{w}$ mit Faktoren $\neq \mathbf{0}$ heißen deshalb *Rang-1-Tensoren*. Jeder Stufe-3-Tensor ist eine Summe solcher Bausteine, denn die Einheitstensoren aus Satz 9.2.5 sind welche: $\mathbf{E}^{(i,j,k)} = \mathbf{e}_i \otimes \mathbf{e}_j \otimes \mathbf{e}_k$. Anders als bei der SVD (Bemerkung 9.3.5) ist ab Stufe 3 aber schon die kleinste Anzahl nötiger Summanden im Allgemeinen schwer zu bestimmen.

Das Kroneckerprodukt

Für zwei Matrizen gibt es eine zweite Lesart des Produkts, die statt eines Tensors der Stufe 4 wieder eine Matrix liefert, mit der wir weiterrechnen können.

Definition 9.3.11 (Kroneckerprodukt)

Das *Kroneckerprodukt* zweier Matrizen $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{B} \in \mathbb{R}^{p \times q}$ ist die Blockmatrix

$$\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B} = \begin{pmatrix} a_{11}\mathbf{B} & \cdots & a_{1n}\mathbf{B} \\ \vdots & & \vdots \\ a_{m1}\mathbf{B} & \cdots & a_{mn}\mathbf{B} \end{pmatrix} \in \mathbb{R}^{mp \times nq}.$$

Sie besteht aus $m \cdot n$ Blöcken der Größe $p \times q$; der Block an der Stelle (i_1, i_2) ist die mit $a_{i_1 i_2}$ skalierte Kopie von $\mathbf{B}$.

Bemerkung 9.3.12 (Zwei Bedeutungen, zwei Zeichen)

Für zwei Matrizen $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{B} \in \mathbb{R}^{p \times q}$ sind jetzt zwei Produkte erklärt:

- Das *Tensorprodukt* nach Definition 9.3.7 liefert einen Tensor der Stufe 4, $C \in \mathbb{R}^{m \times n \times p \times q}$ mit $c_{i_1, i_2, j_1, j_2} = a_{i_1, i_2} b_{j_1, j_2}$.
- Das *Kroneckerprodukt* nach Definition 9.3.11 liefert eine Matrix $\mathbf{D} \in \mathbb{R}^{mp \times nq}$ mit

$$d_{(i_1-1)p+j_1, (i_2-1)q+j_2} = a_{i_1, i_2} b_{j_1, j_2}. \quad (9.3.3)$$

Beide enthalten dieselben mpq Zahlen, nur verschieden angeordnet: $\mathbf{D}$ ist die *abgeflachte* Fassung von C . Die Indexformel (9.3.3) sagt, wie abgeflacht wird. Die mp Zeilen zerfallen in m Gruppen zu je p ; die Gruppe wählt i_1 , die Position in der Gruppe j_1 . Für die Spalten gilt dasselbe mit i_2 und j_2 . Der Index des ersten Faktors läuft also langsam, der des zweiten schnell.

In der Literatur steht meist für beide Produkte $\otimes$; welches gemeint ist, verrät das Format des Ergebnisses. Wir schreiben $\otimes_{\mathbb{K}}$ für das Kroneckerprodukt und behalten $\otimes$ dem äußeren Produkt und dem Tensorprodukt vor. Beim Lesen anderer Texte müssen wir die Unterscheidung selbst treffen.

Vertiefung (optional): Das Kroneckerprodukt zweier Vektoren

Fassen wir $\mathbf{v} \in \mathbb{R}^m$ und $\mathbf{w} \in \mathbb{R}^n$ als $(m \times 1)$ - und $(n \times 1)$ -Matrizen auf, so ist ihr Kroneckerprodukt der Vektor der Länge mn , der die Zeilen des äußeren Produkts hintereinanderhängt. Steht der zweite Faktor dagegen als Zeilenvektor da, kommt das äußere Produkt selbst heraus:

$$\begin{pmatrix} 1 \\ 2 \end{pmatrix} \otimes_{\mathbb{K}} \begin{pmatrix} 3 \\ 5 \\ 7 \end{pmatrix} = \begin{pmatrix} 3 & 5 & 7 & 6 & 10 & 14 \end{pmatrix}^{\top}, \quad \begin{pmatrix} 1 \\ 2 \end{pmatrix} \otimes_{\mathbb{K}} (3 \quad 5 \quad 7) = \begin{pmatrix} 3 & 5 & 7 \\ 6 & 10 & 14 \end{pmatrix}.$$

Beispiel 9.3.13 (Kroneckerprodukt zweier kleiner Matrizen)

Für

$$\mathbf{A} = \begin{pmatrix} 1 & 0 \\ 2 & 5 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ -1 & 0 & -1 \end{pmatrix}$$

ist $\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B} \in \mathbb{R}^{6 \times 6}$, denn $2 \cdot 3 = 6$ Zeilen und ebenso viele Spalten. Blockweise notiert und dann ausgeschrieben:

$$\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B} = \begin{pmatrix} 1 \cdot \mathbf{B} & 0 \cdot \mathbf{B} \\ 2 \cdot \mathbf{B} & 5 \cdot \mathbf{B} \end{pmatrix} = \begin{pmatrix} 3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 \\ -1 & 0 & -1 & 0 & 0 & 0 \\ 6 & 0 & 0 & 15 & 0 & 0 \\ 0 & 4 & 0 & 0 & 10 & 0 \\ -2 & 0 & -2 & -5 & 0 & -5 \end{pmatrix}.$$

Der Block oben rechts ist die Nullmatrix, weil $a_{12} = 0$ ist.

Bemerkung 9.3.14 (Transponieren und Reihenfolge)

Transponieren zieht in beide Faktoren hinein, ohne ihre Reihenfolge zu vertauschen:

$$(\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B})^{\top} = \mathbf{A}^{\top} \otimes_{\mathbb{K}} \mathbf{B}^{\top}.$$

Nach (9.3.3) steht nämlich auf beiden Seiten an der Stelle mit Zeilenindex $(i_2 - 1)q + j_2$ und Spaltenindex $(i_1 - 1)p + j_1$ der Eintrag $a_{i_1, j_1} b_{j_2, i_2}$.

Kommutativ ist das Kroneckerprodukt dagegen **nicht**; im Allgemeinen ist

$$\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B} \neq \mathbf{B} \otimes_{\mathbb{K}} \mathbf{A}.$$

Beide Produkte haben dasselbe Format $mp \times nq$ und enthalten dieselben $mnpq$ Zahlen, aber an anderen Stellen. Für die Matrizen aus Beispiel 9.3.13 steht an der Stelle $(2, 1)$ in $\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B}$ eine 0, in $\mathbf{B} \otimes_{\mathbb{K}} \mathbf{A}$ dagegen eine 6: Dort ist der erste Block $3\mathbf{A}$, und dessen zweite Zeile beginnt mit $3 \cdot 2$.

Interaktiv: Kroneckerprodukte selbst ausrechnen

Der Rechner zeigt $\mathbf{B}^{\top} \otimes_{\mathbb{K}} \mathbf{A}$ in Blockdarstellung, den Operator des vec-Tricks aus Satz 9.5.3. Was ändert sich, wenn wir die Faktoren vertauschen?

Interaktives Element — nur in der Web-Fassung

Jeder Eintrag von $\mathbf{B}^{\top}$ skaliert einen ganzen Block $\mathbf{A}$. Nach dem Vertauschen bleibt das Format gleich, die Einträge stehen aber an anderen Stellen; die Reihenfolge der Faktoren gehört deshalb zur Rechenvorschrift.

Blockstrukturen aus Kroneckerprodukten

Setzen wir eine Einheitsmatrix als einen der beiden Faktoren ein, entstehen Muster, die in der Statistik häufig vorkommen. Auf welcher Seite sie steht, entscheidet über die Struktur.

Beispiel 9.3.15 ($\mathbf{S} \otimes_{\mathbf{K}} \mathbf{I}_n$ verteilt die Einträge)

Sei $\mathbf{S} \in \mathbb{R}^{p \times p}$ mit den Einträgen s_{ij} . Dann ist jeder Block von $\mathbf{S} \otimes_{\mathbf{K}} \mathbf{I}_n$ eine Diagonalmatrix:

$$\mathbf{S} \otimes_{\mathbf{K}} \mathbf{I}_n = \begin{pmatrix} s_{11}\mathbf{I}_n & \cdots & s_{1p}\mathbf{I}_n \\ \vdots & & \vdots \\ s_{p1}\mathbf{I}_n & \cdots & s_{pp}\mathbf{I}_n \end{pmatrix} \in \mathbb{R}^{np \times np}.$$

Jeder Eintrag s_{ij} taucht also n -mal auf. Für $p = n = 2$ und $\mathbf{S} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ sieht das so aus:

$$\mathbf{S} \otimes_{\mathbf{K}} \mathbf{I}_2 = \begin{pmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & 0 & 2 \\ 3 & 0 & 4 & 0 \\ 0 & 3 & 0 & 4 \end{pmatrix}.$$

Als Kovarianzmatrix gelesen: Die np Koordinaten zerfallen in p Gruppen zu je n , und gekoppelt sind nur gleiche Positionen verschiedener Gruppen, mit der Stärke s_{ij} . Das sind n unabhängige Kopien der $\mathbf{S}$ -Struktur, ineinandergeschoben.

Beispiel 9.3.16 ($\mathbf{I}_n \otimes_{\mathbf{K}} \mathbf{S}$ ist blockdiagonal)

Vertauschen wir die Reihenfolge, wird aus demselben Paar eine Blockdiagonalmatrix:

$$\mathbf{I}_n \otimes_{\mathbf{K}} \mathbf{S} = \begin{pmatrix} \mathbf{S} & & \\ & \mathbf{S} & \\ & & \ddots \\ & & & \mathbf{S} \end{pmatrix} \in \mathbb{R}^{np \times np},$$

mit n Kopien von $\mathbf{S} \in \mathbb{R}^{p \times p}$ auf der Diagonalen und Nullen sonst. In der Statistik ist das die Kovarianzmatrix eines Vektors, der aus n voneinander unabhängigen Blöcken besteht, die alle dieselbe Kovarianzmatrix $\mathbf{S}$ haben; ein typischer Fall sind n Personen mit je p Messungen. Dieselben zwei Faktoren ergeben je nach Reihenfolge eine blockdiagonale oder eine über die ganze Matrix verteilte Struktur (Beispiel 9.3.15).

Anwendung: separierbare Kovarianz

Beobachten wir dieselbe Größe an m Orten zu n Zeitpunkten, so haben wir mn Messwerte, und ihre Kovarianzmatrix hat das Format $mn \times mn$. Schon bei $m = 10$ Orten und $n = 50$ Zeitpunkten sind das 500×500 Einträge, weit mehr, als sich aus überschaubaren Datenmengen schätzen lässt. Das Kroneckerprodukt liefert eine sparsame Modellannahme.

Definition 9.3.17 (Separierbare Kovarianz)

Die Kovarianzmatrix $\Sigma \in \mathbb{R}^{mn \times mn}$ der Beobachtungen heißt *separierbar*, wenn sie sich als

$$\Sigma = \Sigma_T \otimes_{\mathbf{K}} \Sigma_S \quad (9.3.4)$$

schreiben lässt, mit der Kovarianzmatrix $\Sigma_T \in \mathbb{R}^{n \times n}$ zwischen den Zeitpunkten und der Kovarianzmatrix $\Sigma_S \in \mathbb{R}^{m \times m}$ zwischen den Orten.

Dazu gehört eine Anordnung der mn Beobachtungen. Da der Index des ersten Faktors langsam läuft und der des zweiten schnell (Bemerkung 9.3.12), läuft in (9.3.4) die Zeit langsam und der Ort schnell: erst alle Orte zum ersten Zeitpunkt, dann alle zum zweiten und so weiter.

Beispiel 9.3.18 (Zwei Orte, zwei Zeitpunkte)

Für $m = 2$ Orte und $n = 2$ Zeitpunkte seien

$$\Sigma_T = \begin{pmatrix} 1,0 & 0,8 \\ 0,8 & 1,0 \end{pmatrix}, \quad \Sigma_S = \begin{pmatrix} 2,0 & 0,5 \\ 0,5 & 2,0 \end{pmatrix}.$$

Dann ist

$$\Sigma = \Sigma_T \otimes_K \Sigma_S = \begin{pmatrix} 1,0 \cdot \Sigma_S & 0,8 \cdot \Sigma_S \\ 0,8 \cdot \Sigma_S & 1,0 \cdot \Sigma_S \end{pmatrix} = \begin{pmatrix} 2,0 & 0,5 & 1,6 & 0,4 \\ 0,5 & 2,0 & 0,4 & 1,6 \\ 1,6 & 0,4 & 2,0 & 0,5 \\ 0,4 & 1,6 & 0,5 & 2,0 \end{pmatrix} \in \mathbb{R}^{4 \times 4}.$$

Die vier Beobachtungen stehen in der Reihenfolge (Ort 1, Zeit 1), (Ort 2, Zeit 1), (Ort 1, Zeit 2), (Ort 2, Zeit 2). Damit lesen wir die erste Zeile ab:

Eintrag	verbindet	Wert	Herkunft
(1, 1)	Ort 1, Zeit 1 mit sich selbst	2,0	$1,0 \cdot 2,0$, eine Varianz
(1, 2)	zwei Orte, gleiche Zeit	0,5	$1,0 \cdot 0,5$
(1, 3)	gleicher Ort, zwei Zeiten	1,6	$0,8 \cdot 2,0$
(1, 4)	anderer Ort, andere Zeit	0,4	$0,8 \cdot 0,5$

In Korrelationen: Beobachtungen am selben Ort zu verschiedenen Zeiten sind mit $1,6/2,0 = 0,8$ korreliert, zur selben Zeit an verschiedenen Orten mit $0,5/2,0 = 0,25$, bei verschiedenem Ort und verschiedener Zeit mit dem Produkt $0,8 \cdot 0,25 = 0,2$. Die Korrelation zerfällt also in einen zeitlichen und einen räumlichen Faktor; daher der Name *separierbar*.

Bemerkung 9.3.19 (Was die Annahme spart und was sie kostet)

Eine beliebige Kovarianzmatrix ist symmetrisch, hat also $\frac{mn(mn+1)}{2}$ freie Einträge. Die separierbare Form braucht nur die Einträge der beiden Faktoren,

$$\frac{m(m+1)}{2} + \frac{n(n+1)}{2}.$$

Für $m = n = 2$ stehen 10 Parametern 6 gegenüber, für $m = 10$ Orte und $n = 50$ Zeitpunkte sind es 125 250 gegen 1 330. Die Zerlegung (9.3.4) ist allerdings nicht eindeutig: Wegen $\Sigma_T \otimes_K \Sigma_S = (c \Sigma_T) \otimes_K (c^{-1} \Sigma_S)$ für jedes $c > 0$ lässt sich ein Skalenfaktor zwischen den Kovarianzfaktoren verschieben. Identifizierbar ist deshalb ein Parameter weniger, im Beispiel also 5 statt 6.

Dafür verbietet Separierbarkeit, dass sich das räumliche Muster über die Zeit ändert. Ein Wetterfeld, dessen Zusammenhänge morgens anders aussehen als abends, lässt sich so nicht beschreiben.

Interaktiv: Parameterzahl der separierbaren Kovarianz

Wie viele Parameter spart die separierbare Form gegenüber einer allgemeinen Kovarianzmatrix, wenn das Messgitter wächst?

Interaktives Element — nur in der Web-Fassung

Die allgemeine Parameterzahl wächst wie $(mn)^2/2$, die separierbare nur wie $(m^2 + n^2)/2$. Auf kleinen Gittern ist der Unterschied gering, auf großen beträgt er Größenordnungen.

Vertiefung (optional): Eigenwerte eines Kroneckerprodukts

Dass Σ überhaupt eine Kovarianzmatrix sein kann, sichert eine weitere Rechenregel: Die Eigenwerte von $\Sigma_T \otimes_K \Sigma_S$ sind die Produkte $\lambda_i \mu_j$ der Eigenwerte beider Faktoren, denn mit Eigenvektoren $\mathbf{a}$ und $\mathbf{b}$ ist

$$(\Sigma_T \otimes_K \Sigma_S)(\mathbf{a} \otimes_K \mathbf{b}) = (\Sigma_T \mathbf{a}) \otimes_K (\Sigma_S \mathbf{b}) = \lambda_i \mu_j (\mathbf{a} \otimes_K \mathbf{b}),$$

wobei $\mathbf{a} \otimes_K \mathbf{b}$ das Kroneckerprodukt der beiden Spaltenvektoren ist. Die mittlere Gleichung ist die Regel $(\mathbf{A} \otimes_K \mathbf{B})(\mathbf{C} \otimes_K \mathbf{D}) = (\mathbf{A}\mathbf{C}) \otimes_K (\mathbf{B}\mathbf{D})$, die sich ebenfalls an (9.3.3) ablesen lässt. Beide Faktoren sind als Kovarianzmatrizen symmetrisch, haben nach dem Spektralsatz also je eine Orthonormalbasis aus Eigenvektoren. Laufen $\mathbf{a}$ und $\mathbf{b}$ durch diese beiden Basen, so bilden die mn Vektoren $\mathbf{a} \otimes_K \mathbf{b}$ eine Basis des $\mathbb{R}^{mn}$; damit sind das bereits alle Eigenwerte. Ist also jeder Faktor positiv definit, so ist es auch Σ . In Beispiel 9.3.18 hat Σ_T die Eigenwerte 1,8 und 0,2, Σ_S die Eigenwerte 2,5 und 1,5; die vier Produkte 4,5, 2,7, 0,5 und 0,3 sind die Eigenwerte von Σ . Ihre Summe ist 8, die Spur von Σ , und ihr Produkt ist 1,8225, die Determinante von Σ .

Selbsttest

1. Das äußere Produkt $\mathbf{v} \otimes \mathbf{w}$ ist nur für Vektoren gleicher Länge definiert.

Antwort: Falsch

Das gilt für das innere Produkt. Das äußere Produkt $\mathbf{v} \otimes \mathbf{w} = \mathbf{v}\mathbf{w}^\top$ verlangt keine Übereinstimmung: Für $\mathbf{v} \in \mathbb{R}^m$ und $\mathbf{w} \in \mathbb{R}^n$ entsteht eine $m \times n$ -Matrix (Definition 9.3.1, Bemerkung 9.3.2). In Beispiel 9.3.3 sind die Längen 2 und 3.

2. Für $\mathbf{v}, \mathbf{w} \neq \mathbf{0}$ bildet $\mathbf{x} \mapsto (\mathbf{v} \otimes \mathbf{w})\mathbf{x}$ den ganzen $\mathbb{R}^n$ auf die Gerade $\text{span}\{\mathbf{v}\}$ ab, und der Kern ist die Hyperebene senkrecht zu $\mathbf{w}$.

Antwort: Wahr

Das ist Satz 9.3.4: Wegen $(\mathbf{v} \otimes \mathbf{w})\mathbf{x} = \mathbf{v}\langle \mathbf{w}, \mathbf{x} \rangle$ besteht das Bild aus Vielfachen von $\mathbf{v}$ und der Kern aus allen $\mathbf{x}$ mit $\mathbf{w}^\top \mathbf{x} = 0$.

3. Die beiden Scheiben $T_{:,1}$ und $T_{:,2}$ des Tensors $T = \mathbf{u} \otimes \mathbf{v} \otimes \mathbf{w} \in \mathbb{R}^{2 \times 2 \times 2}$ sind linear unabhängig voneinander.

Antwort: Falsch

Beide sind Vielfache derselben Rang-1-Matrix, $T_{:,k} = w_k (\mathbf{u} \otimes \mathbf{v})$, also linear abhängig. In Beispiel 9.3.10 ist die zweite Scheibe das 11/7-fache der ersten.

4. Das Kroneckerprodukt zweier Matrizen $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{B} \in \mathbb{R}^{p \times q}$ ist ein Tensor der Stufe 4.

Antwort: Falsch

Der Stufe-4-Tensor ist das *Tensorprodukt* nach Definition 9.3.7. Das Kroneckerprodukt ordnet dieselben $mnpq$ Zahlen nach der Indexformel (9.3.3) in einer Matrix aus $\mathbb{R}^{m \times p \times n \times q}$ an, ist also die abgeflachte Fassung davon (Bemerkung 9.3.12). Für $\mathbf{A} \in \mathbb{R}^{3 \times 2}$ und $\mathbf{B} \in \mathbb{R}^{2 \times 4}$ etwa liegt $\mathbf{A} \otimes_K \mathbf{B}$

in $\mathbb{R}^{6 \times 8}$, das Tensorprodukt dagegen in $\mathbb{R}^{3 \times 2 \times 2 \times 4}$.

5. Es gilt $\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B} = \mathbf{B} \otimes_{\mathbb{K}} \mathbf{A}$, denn beide Produkte enthalten dieselben Zahlen.

Antwort: Falsch

Dieselben Zahlen stehen an verschiedenen Stellen. In Beispiel 9.3.13 ist der Eintrag $(2, 1)$ von $\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B}$ gleich 0, der von $\mathbf{B} \otimes_{\mathbb{K}} \mathbf{A}$ dagegen 6 (Bemerkung 9.3.14). Die Formate stimmen überein, die Matrizen nicht.

6. Es gilt $(\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B})^{\top} = \mathbf{A}^{\top} \otimes_{\mathbb{K}} \mathbf{B}^{\top}$.

Antwort: Wahr

Transponieren zieht in beide Faktoren hinein, ohne ihre Reihenfolge zu vertauschen; die Indexformel (9.3.3) zeigt es unmittelbar (Bemerkung 9.3.14). Anders als beim Matrixprodukt mit $(\mathbf{AB})^{\top} = \mathbf{B}^{\top} \mathbf{A}^{\top}$ dreht sich die Reihenfolge nicht um.

7. Die Matrix $\mathbf{I}_n \otimes_{\mathbb{K}} \mathbf{S}$ mit $\mathbf{S} \in \mathbb{R}^{p \times p}$ ist blockdiagonal mit n Kopien von $\mathbf{S}$.

Antwort: Wahr

Der Block an der Stelle (i, j) ist $\delta_{ij} \mathbf{S}$, außerhalb der Diagonalen steht also die Nullmatrix (Beispiel 9.3.16). In der umgekehrten Reihenfolge entsteht dagegen $\mathbf{S} \otimes_{\mathbb{K}} \mathbf{I}_n$, dessen Einträge über die ganze Matrix verteilt sind (Beispiel 9.3.15).

8. Daten liegen an $m = 10$ Orten zu $n = 20$ Zeitpunkten vor. Eine unstrukturierte Kovarianzmatrix des 200-dimensionalen Datenvektors hat $\frac{200 \cdot 201}{2} = 20\,100$ freie Parameter. Wie viele Parameter haben die beiden Faktoren Σ_T und Σ_S des separierbaren Modells zusammen?

Lösung: 265

265, denn $\frac{m(m+1)}{2} + \frac{n(n+1)}{2} = 55 + 210$ (Bemerkung 9.3.19). Identifizierbar sind davon 264, weil sich ein Skalenfaktor zwischen den beiden Faktoren verschieben lässt.

Vertiefung: vgl. MML §4.5 für die Summendarstellung einer Matrix aus Rang-1-Bausteinen, auf der Bemerkung 9.3.5 aufsetzt; die Rechenregeln des Kroneckerprodukts sammelt Kapitel 2 von Magnus und Neudecker, Matrix Differential Calculus with Applications in Statistics and Econometrics.

9.4 Tensorprodukt von Vektorräumen

In Abschnitt 9.3 war $\otimes$ eine Rechenvorschrift für Vektoren und Tensoren. Jetzt fragen wir nach dem Raum, in dem diese Produkte leben, und machen so aus zwei Vektorräumen einen dritten.

Der Raum $V \otimes W$

Sei zunächst $V = \mathbb{R}^m$ und $W = \mathbb{R}^n$ mit dem äußeren Produkt $\mathbf{v} \otimes \mathbf{w} = \mathbf{vw}^{\top}$. Die Menge aller dieser Produkte ist als Vektorraum unbrauchbar, denn sie ist nicht unter Addition abgeschlossen: Die Summe zweier Matrizen vom Rang 1 hat im Allgemeinen den Rang 2. Der kleinste Vektorraum, der alle Produkte enthält, ist ihre lineare Hülle.

Definition 9.4.1 (Tensorprodukt von Vektorräumen)

Seien V und W Vektorräume und

$$\otimes : V \times W \rightarrow V \otimes W, \quad (\mathbf{v}, \mathbf{w}) \mapsto \mathbf{v} \otimes \mathbf{w},$$

eine bilineare Abbildung. Das *Tensorprodukt* (tensor product) von V und W ist der von ihren Bildern erzeugte Vektorraum

$$V \otimes W = \text{span}\{\mathbf{v} \otimes \mathbf{w} : \mathbf{v} \in V, \mathbf{w} \in W\}. \quad (9.4.1)$$

Die Produkte $\mathbf{v} \otimes \mathbf{w}$ selbst nennen wir *elementare Tensoren*.

Nicht jede bilineare Abbildung eignet sich als $\otimes$: Auch die Nullabbildung ist bilinear, ihre Bilder spannen aber nur den Nullraum auf. Gemeint ist ein $\otimes$ mit der *universellen Eigenschaft* aus der folgenden Vertiefung; das äußere Produkt und das Produkt von Funktionen in den Beispielen unten haben sie.

Vertiefung (optional): Die universelle Eigenschaft

Die universelle Eigenschaft verlangt: Jede bilineare Abbildung $f : V \times W \rightarrow Z$ in einen Vektorraum Z faktorisiert eindeutig über $\otimes$, es gibt also genau eine lineare Abbildung $\tilde{f} : V \otimes W \rightarrow Z$ mit $\tilde{f}(\mathbf{v} \otimes \mathbf{w}) = f(\mathbf{v}, \mathbf{w})$ für alle $\mathbf{v} \in V$ und $\mathbf{w} \in W$. Der Nullraum der Nullabbildung leistet das nicht, denn über ihn lässt sich keine bilineare Abbildung $f \neq 0$ faktorisieren. Das Tensorprodukt *linearisiert* also bilineare Abbildungen: Statt f auf Paaren auszuwerten, wenden wir die lineare Abbildung $\tilde{f}$ auf elementare Tensoren an.

Für $V = \mathbb{R}^m$ und $W = \mathbb{R}^n$ mit dem äußeren Produkt, also $\mathbb{R}^m \otimes \mathbb{R}^n = \mathbb{R}^{m \times n}$ nach Beispiel 9.4.3, lässt sich die Eigenschaft direkt nachrechnen. Zu bilinearem $f : \mathbb{R}^m \times \mathbb{R}^n \rightarrow Z$ setzen wir $\tilde{f}(\mathbf{A}) := \sum_{i=1}^m \sum_{j=1}^n a_{ij} f(\mathbf{e}_i, \mathbf{e}_j)$. Diese Abbildung ist linear, und wegen $\mathbf{v}\mathbf{w}^\top = \sum_{ij} v_i w_j \mathbf{E}_{ij}$ mit der Matrix $\mathbf{E}_{ij}$, die an der Stelle (i, j) eine Eins und sonst lauter Nullen trägt, liefert die Bilinearität $\tilde{f}(\mathbf{v}\mathbf{w}^\top) = f(\mathbf{v}, \mathbf{w})$; eindeutig ist sie, weil die $\mathbf{E}_{ij}$ den Raum aufspannen.

Tensorprodukte existieren und sind durch die universelle Eigenschaft bis auf einen eindeutigen Isomorphismus festgelegt, der die elementaren Tensoren respektiert. Deshalb dürfen wir mit einer konkreten Realisierung arbeiten, in den folgenden Beispielen mit Matrizen beziehungsweise Funktionen. Gebraucht wird die Eigenschaft im Skript nur noch für die lineare Unabhängigkeit der Tensorproduktbasis in Satz 9.4.7.

Für $V = \mathbb{R}^m$ und $W = \mathbb{R}^n$ sind die elementaren Tensoren genau die Matrizen vom Rang höchstens 1 (Abschnitt 9.3): Rang 1 für $\mathbf{v}, \mathbf{w} \neq \mathbf{0}$, Rang 0, wenn ein Faktor der Nullvektor ist.

Bemerkung 9.4.2 (Rechenregeln aus der Bilinearität)

Ausgeschrieben heißt Bilinearität (Definition 9.1.1): Skalare Faktoren dürfen zwischen den Argumenten wandern, und in jedem Argument dürfen wir Summen auseinanderziehen,

$$(c \mathbf{v}) \otimes \mathbf{w} = c(\mathbf{v} \otimes \mathbf{w}) = \mathbf{v} \otimes (c \mathbf{w}),$$

$$(\mathbf{v}_1 + \mathbf{v}_2) \otimes \mathbf{w} = \mathbf{v}_1 \otimes \mathbf{w} + \mathbf{v}_2 \otimes \mathbf{w}, \quad \mathbf{v} \otimes (\mathbf{w}_1 + \mathbf{w}_2) = \mathbf{v} \otimes \mathbf{w}_1 + \mathbf{v} \otimes \mathbf{w}_2.$$

Mit $c = 0$ folgt daraus $\mathbf{0} \otimes \mathbf{w} = \mathbf{v} \otimes \mathbf{0} = \mathbf{0}$. Eine Summe $\mathbf{v}_1 \otimes \mathbf{w}_1 + \mathbf{v}_2 \otimes \mathbf{w}_2$ formen die Regeln dagegen nicht in ein einzelnes Produkt um.

Zwei Beispiele mit Zahlentupeln

Beispiel 9.4.3 (Das Tensorprodukt von $\mathbb{R}^m$ und $\mathbb{R}^n$)

Sei $\otimes$ das äußere Produkt aus Abschnitt 9.3, also $\mathbf{v} \otimes \mathbf{w} = \mathbf{vw}^\top \in \mathbb{R}^{m \times n}$. Wir zeigen beide Inklusionen.

„ $\subseteq$ “: Jedes $\mathbf{v} \otimes \mathbf{w}$ ist eine $m \times n$ -Matrix, und $\mathbb{R}^{m \times n}$ ist ein Vektorraum (Satz 9.2.5). Mit den Produkten liegen deshalb auch alle ihre Linearkombinationen in $\mathbb{R}^{m \times n}$.

„ $\supseteq$ “: Für die Standardbasisvektoren $\mathbf{e}_i \in \mathbb{R}^m$ und $\mathbf{e}_j \in \mathbb{R}^n$ ist

$$\mathbf{e}_i \otimes \mathbf{e}_j = \mathbf{e}_i \mathbf{e}_j^\top = \mathbf{E}_{ij},$$

die Matrix mit einer 1 an der Stelle (i, j) und sonst lauter Nullen. Jede Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ schreibt sich als $\mathbf{A} = \sum_{i=1}^m \sum_{j=1}^n a_{ij} \mathbf{E}_{ij}$, liegt also im Spann der Produkte.

Damit ist $\mathbb{R}^m \otimes \mathbb{R}^n = \mathbb{R}^{m \times n}$ eine konkrete Realisierung des Tensorprodukts, und nach Satz 9.2.5 hat dieser Raum die Dimension mn .

Beispiel 9.4.4 (Drei Faktoren)

Seien $V_1 = \mathbb{R}^m$, $V_2 = \mathbb{R}^n$, $V_3 = \mathbb{R}^q$ und $\otimes$ das Tensorprodukt von Tensoren aus Abschnitt 9.3. Nach Beispiel 9.4.3 ist $V_1 \otimes V_2 = \mathbb{R}^{m \times n}$, und ein elementarer Tensor $\mathbf{A} \otimes \mathbf{w}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{w} \in \mathbb{R}^q$ hat die Einträge $a_{ij} w_k$. Das ist ein Tensor der Stufe 3, und dasselbe Argument wie oben zeigt

$$V_1 \otimes V_2 \otimes V_3 = (\mathbb{R}^m \otimes \mathbb{R}^n) \otimes \mathbb{R}^q = \mathbb{R}^{m \times n} \otimes \mathbb{R}^q = \mathbb{R}^{m \times n \times q}.$$

Auf die Klammerung kommt es dabei nicht an (Satz 9.3.9). Die Dimension ist mnq , wieder nach Satz 9.2.5.

Ein einzelnes Produkt und der ganze Raum

Die Ausdrücke $\mathbf{v} \otimes \mathbf{w}$ und $V \otimes W$ sehen ähnlich aus und meinen Verschiedenes: ein einzelnes Element und den ganzen Raum, den alle diese Elemente aufspannen.

Beispiel 9.4.5 (Die Einheitsmatrix ist kein elementarer Tensor)

Sei $V = W = \mathbb{R}^2$ und

$$\mathbf{A} = \mathbf{I}_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Kein einzelnes Produkt. Gäbe es $\mathbf{v}, \mathbf{w} \in \mathbb{R}^2$ mit $\mathbf{A} = \mathbf{v} \otimes \mathbf{w}$, so wären alle Spalten von $\mathbf{vw}^\top$ Vielfache von $\mathbf{v}$, also $\text{rang}(\mathbf{v} \otimes \mathbf{w}) \leq 1$ (Abschnitt 9.3). Die Einheitsmatrix hat aber den Rang 2.

Aber ein Element des Raums. In $V \otimes W = \mathbb{R}^{2 \times 2}$ liegt $\mathbf{I}_2$ als Summe von zwei elementaren Tensoren:

$$\begin{aligned} \mathbf{e}_1 \otimes \mathbf{e}_1 + \mathbf{e}_2 \otimes \mathbf{e}_2 &= \begin{pmatrix} 1 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}. \end{aligned}$$

Zwei Summanden genügen also.

Satz 9.4.6 (Jede Matrix ist eine kurze Summe elementarer Tensoren)

Sei $A \in \mathbb{R}^{m \times n}$ mit $\text{rang}(A) = r$. Dann gibt es $\mathbf{u}_i \in \mathbb{R}^m$, $\mathbf{v}_i \in \mathbb{R}^n$ und Zahlen $\sigma_i > 0$ mit

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \otimes \mathbf{v}_i.$$

Insbesondere kommt jede Matrix mit höchstens $\min(m, n)$ elementaren Tensoren aus.

Vertiefung (optional): Beweis über die Singulärwertzerlegung

Beweis.

- (1) Die Singulärwertzerlegung liefert $A = U \Sigma V^T$ (Satz 6.2.13 in Abschnitt 6.2), und ausmultipliziert wird daraus die Summenform

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

mit $r = \text{rang}(A)$ und $\sigma_1 \geq \dots \geq \sigma_r > 0$ (Satz 6.4.2 in Abschnitt 6.4, im Kapitel schon in Bemerkung 9.3.5 aufgegriffen).

jeder Summand ist ein äußeres Produkt $\mathbf{u}_i \mathbf{v}_i^T = \mathbf{u}_i \otimes \mathbf{v}_i$, also ein elementarer Tensor

- (2) Für die Schranke bleibt $r \leq \min(m, n)$ zu begründen. Der Rang ist die Dimension des Spaltenraums $\text{col}(A) \subseteq \mathbb{R}^m$, also ist $r \leq m$. Zugleich wird $\text{col}(A)$ von den n Spalten aufgespannt, also ist $r \leq n$.

ein Unterraum des $\mathbb{R}^m$ hat höchstens die Dimension m ; ein Erzeugendensystem aus n Vektoren spannt höchstens einen n -dimensionalen Raum auf

□

Weniger als r Summanden reichen nicht. Wäre $A = \sum_{i=1}^k \mathbf{u}_i \otimes \mathbf{v}_i$ mit $k < r$, so lägen alle Spalten von A im Spann von $\mathbf{u}_1, \dots, \mathbf{u}_k$, und der Rang wäre höchstens k . Die kleinste Anzahl elementarer Tensoren, die eine Matrix darstellen, ist also genau ihr Rang, und die SVD rechnet sie aus.

Die Tensorproduktbasis

Eine Basis von $V \otimes W$ entsteht aus Basen der beiden Faktoren, indem wir alle Paare miteinander multiplizieren.

Satz 9.4.7 (Tensorproduktbasis)

Seien $\mathcal{B}_V = \{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ eine Basis von V und $\mathcal{B}_W = \{\mathbf{w}_1, \dots, \mathbf{w}_n\}$ eine Basis von W . Dann ist

$$\mathcal{B}_{V \otimes W} = \{\mathbf{v}_i \otimes \mathbf{w}_j : i = 1, \dots, m, j = 1, \dots, n\}$$

eine Basis von $V \otimes W$ und heißt *Tensorproduktbasis* (tensor product basis). Insbesondere gilt

$$V \otimes W = \text{span}(\mathcal{B}_{V \otimes W}) = \left\{ \sum_{i=1}^m \sum_{j=1}^n c_{ij} \mathbf{v}_i \otimes \mathbf{w}_j : c_{11}, \dots, c_{mn} \in \mathbb{R} \right\} \quad (9.4.2)$$

und

$$\dim(V \otimes W) = \dim(V) \dim(W) = mn.$$

Vertiefung (optional): Beweis der Tensorproduktbasis

Beweis.

- (1) Die Produkte erzeugen den Raum. Wir entwickeln $\mathbf{v} \in V$ und $\mathbf{w} \in W$ in den beiden Basen, $\mathbf{v} = \sum_i a_i \mathbf{v}_i$ und $\mathbf{w} = \sum_j b_j \mathbf{w}_j$, und ziehen die Summen mit Bemerkung 9.4.2 nach außen, zuerst im ersten, dann im zweiten Argument:

$$\mathbf{v} \otimes \mathbf{w} = \left(\sum_{i=1}^m a_i \mathbf{v}_i \right) \otimes \mathbf{w} = \sum_{i=1}^m \sum_{j=1}^n a_i b_j (\mathbf{v}_i \otimes \mathbf{w}_j). \quad (9.4.3)$$

Jeder elementare Tensor liegt damit im Spann von $\mathcal{B}_{V \otimes W}$, und da die elementaren Tensoren nach Definition 9.4.1 den ganzen Raum erzeugen, gilt die Darstellung (9.4.2).

Bilinearität: Summen und skalare Faktoren dürfen aus jedem Argument einzeln heraus

- (2) Die Produkte sind linear unabhängig. Sei $\sum_i \sum_j c_{ij} \mathbf{v}_i \otimes \mathbf{w}_j = \mathbf{0}$. Zu festen Indizes (k, l) ist

$$(\mathbf{v}, \mathbf{w}) \mapsto a_k(\mathbf{v}) b_l(\mathbf{w})$$

bilinear, wobei a_k und b_l die k -te beziehungsweise l -te Koordinatenfunktion in den beiden Basen sind. Die universelle Eigenschaft liefert dazu eine lineare Abbildung auf $V \otimes W$. Sie schickt $\mathbf{v}_i \otimes \mathbf{w}_j$ auf 1, falls $(i, j) = (k, l)$, und sonst auf 0. Wenden wir sie auf die verschwindende Summe an, erhalten wir $c_{kl} = 0$. Da (k, l) beliebig war, verschwinden alle Koeffizienten.

die universelle Eigenschaft macht aus jeder bilinearen Koordinatenabbildung genau eine lineare Abbildung auf dem Tensorproduktraum

- (3) Die Basis $\mathcal{B}_{V \otimes W}$ enthält damit für jedes Paar (i, j) genau ein Element, also mn Stück.

die mn Produkte sind paarweise verschieden, denn sie sind nach dem zweiten Schritt linear unabhängig

□

Bemerkung 9.4.8 (Koeffizienten elementarer Tensoren)

Die Koeffizienten in (9.4.2) sind beliebig. Bei einem elementaren Tensor $\mathbf{v} \otimes \mathbf{w}$ mit $\mathbf{v} = \sum_i a_i \mathbf{v}_i$ und $\mathbf{w} = \sum_j b_j \mathbf{w}_j$ haben sie die Produktform $c_{ij} = a_i b_j$, wie Ausmultiplizieren mit Bemerkung 9.4.2 zeigt ((9.4.3)); bei einem allgemeinen Element von $V \otimes W$ nicht. In Beispiel 9.4.5 ist die Koeffizientenmatrix bezüglich der Standardbasen $\mathbf{C} = \mathbf{I}_2$, und $\mathbf{I}_2$ lässt sich nicht als $\mathbf{ab}^T$ schreiben.

Tensorproduktbasen für Funktionen

Der Basissatz gilt auch für Funktionenräume und wird dort zum Werkzeug für die Approximation multivariater Funktionen. Der Raum der Polynome vom Grad höchstens 1 auf $[0, 1]$ ist

$$\mathcal{P}_1 = \{p(x) = a_0 + a_1 x : a_0, a_1 \in \mathbb{R}\}$$

mit der Basis $\mathcal{B} = \{1, x\}$, also $\dim(\mathcal{P}_1) = 2$. Für zwei Funktionen $f, g : [0, 1] \rightarrow \mathbb{R}$ setzen wir

$$(f \otimes g)(x, y) := f(x) g(y). \quad (9.4.4)$$

Das Produkt zweier univariater Funktionen ist eine Funktion auf dem Quadrat $[0, 1]^2$, und die Zuordnung $(f, g) \mapsto f \otimes g$ ist bilinear, denn Skalare und Summen in einem Argument ziehen sich punktweise heraus. Im zweiten Faktor schreiben wir die Basis als $\{1, y\}$: dieselben Funktionen, nur mit y als Variable.

Beispiel 9.4.9 (Die Tensorproduktbasis von $\mathcal{P}_1 \otimes \mathcal{P}_1$)

Satz 9.4.7 liefert aus $\mathcal{B}_V = \{1, x\}$ und $\mathcal{B}_W = \{1, y\}$ die vier Produkte, ausgewertet nach (9.4.4):

$$\begin{aligned}\phi_1(x, y) &= (1 \otimes 1)(x, y) = 1 \cdot 1 = 1, & \phi_2(x, y) &= (x \otimes 1)(x, y) = x \cdot 1 = x, \\ \phi_3(x, y) &= (1 \otimes y)(x, y) = 1 \cdot y = y, & \phi_4(x, y) &= (x \otimes y)(x, y) = x \cdot y = xy.\end{aligned}$$

Sie bilden eine Basis von $\mathcal{P}_1 \otimes \mathcal{P}_1$, dem Raum aller bivariaten Polynome, die in jeder der beiden Variablen höchstens den Grad 1 haben. Die Dimension ist

$$\dim(\mathcal{P}_1 \otimes \mathcal{P}_1) = \dim(\mathcal{P}_1) \dim(\mathcal{P}_1) = 2 \cdot 2 = 4.$$

Die Koeffizienten c_{ij} nummerieren wir wie in (9.4.2), i für den ersten und j für den zweiten Faktor: c_{11} gehört zu $1 \otimes 1$, c_{21} zu $x \otimes 1$, c_{12} zu $1 \otimes y$ und c_{22} zu $x \otimes y$.

Beispiel 9.4.10 (Eine bivariate Funktion in dieser Basis)

Nehmen wir

$$f(x, y) = 2 + 3x - y + 5xy.$$

Die Entwicklung ist abzulesen:

$$f = 2\phi_1 + 3\phi_2 + (-1)\phi_3 + 5\phi_4, \quad c_{11} = 2, \quad c_{21} = 3, \quad c_{12} = -1, \quad c_{22} = 5.$$

Bemerkung 9.4.11 (Was der Produktbau bedeutet)

1. Halten wir y fest, so ist $x \mapsto f(x, y)$ ein Polynom aus $\mathcal{P}_1$, und umgekehrt: Jeder achsenparallele Schnitt durch die Fläche ist eine Gerade.
2. Ohne den Basisvektor $x \otimes y$ ist f eine Ebene, die beiden Variablen wirken rein additiv. Erst c_{22} koppelt sie: Die Steigung in x -Richtung ist $c_{21} + c_{22}y$ und hängt vom festgehaltenen y ab.
3. Tensorprodukträume begrenzen den Grad in jeder Variablen einzeln, nicht den Gesamtgrad: xy hat in x und in y den Grad 1, insgesamt aber den Grad 2.

Interaktiv: Vier Koeffizienten, eine Fläche

Wie verändern die vier Koeffizienten die Fläche, und woran erkennen wir, ob c_{22} die beiden Variablen koppelt?

Interaktives Element — nur in der Web-Fassung

Mit $c_{22} = 0$ ist die Fläche eine Ebene, und die Höhenlinien sind parallele Geraden. Ein $c_{22} \neq 0$ biegt die Ebene: Die Höhenlinien krümmen sich, und die Steigung in x -Richtung hängt vom gewählten y ab.

Bemerkung 9.4.12 (Allgemeine Dimension und Fluch der Dimensionalität)

Für k -variate Polynome mit Grad höchstens d in jeder Variablen ist der zugehörige Raum das k -fache Tensorprodukt $\mathcal{P}_d^{\otimes k} = \mathcal{P}_d \otimes \cdots \otimes \mathcal{P}_d$, und Satz 9.4.7 liefert seine Dimension als k -faches Produkt:

$$\dim(\mathcal{P}_d^{\otimes k}) = (d+1)^k.$$

Das wächst exponentiell in der Zahl der Variablen. Für $d = 3$ und $k = 10$ sind das $4^{10} = 1\,048\,576$ Basisfunktionen. Zum Vergleich: Der Raum der Polynome mit *Gesamtgrad* höchstens d in k Variablen hat nur $\binom{d+k}{k}$ Dimensionen, für $d = 3$ und $k = 10$ also $\binom{13}{10} = 286$. Dieses exponentielle Wachstum heißt *Fluch der Dimensionalität* (curse of dimensionality).

Verwendet wird die Konstruktion trotzdem vielfach:

- **Finite-Elemente-Methoden:** Auf Rechteckgittern werden Lösungen partieller Differentialgleichungen durch tensorbasierte Polynome approximiert.
- **Statistik:** Tensorprodukt-Splines dienen der multivariaten Regression, etwa in generalisierten additiven Modellen (generalized additive models, GAM).
- **Numerik:** Dünne Gitter (sparse grids) wählen aus den $(d+1)^k$ Basisfunktionen gezielt aus und drücken den Aufwand damit weit unter den des vollen Produktgitters.

Bemerkung 9.4.13 (Kronecker-Designmatrix für Tensorprodukt-Splines)

Seien $\mathbf{B}_x \in \mathbb{R}^{n_x \times K_x}$ und $\mathbf{B}_y \in \mathbb{R}^{n_y \times K_y}$ die Auswertungsmatrizen zweier univariater B-Spline-Basen auf Gitterpunkten $x_1, \dots, x_{n_x}$ bzw. $y_1, \dots, y_{n_y}$, also $(\mathbf{B}_x)_{ij} = B_j(x_i)$ mit der j -ten Basisfunktion B_j , analog $(\mathbf{B}_y)_{lk} = \tilde{B}_k(y_l)$. Die Tensorprodukt-Spline-Fläche $f(x, y) = \sum_{j,k} c_{jk} B_j(x) \tilde{B}_k(y)$ mit der Koeffizientenmatrix $\mathbf{C} = (c_{jk}) \in \mathbb{R}^{K_x \times K_y}$ hat auf dem $n_x \times n_y$ -Gitter die Werte $\mathbf{F} = \mathbf{B}_x \mathbf{C} \mathbf{B}_y^\top$. Der vec-Trick aus Satz 9.5.3 liefert

$$\text{vec}(\mathbf{F}) = (\mathbf{B}_y \otimes_K \mathbf{B}_x) \text{vec}(\mathbf{C}).$$

Die Designmatrix des Gitters ist also das Kroneckerprodukt $\mathbf{B}_y \otimes_K \mathbf{B}_x$. In R, mit je sechs B-Splines auf 50 Punkten je Achse:

```
library(splines)
x <- seq(0, 1, length.out = 50)
Bx <- bs(x, df = 6) # B-Spline-Basis
By <- bs(x, df = 6)
B <- kronecker(By, Bx)
dim(B) # 2500 Gitterpunkte, 6*6 Koeffizienten
```

Dicht ausgeschrieben hat die Designmatrix das Format $(n_x n_y) \times (K_x K_y)$ und damit $n_x n_y K_x K_y$ Einträge, die beiden Faktoren zusammen nur $n_x K_x + n_y K_y$. Deshalb werten wir $\mathbf{B}_x \mathbf{C} \mathbf{B}_y^\top$ mit zwei kleinen Matrixprodukten aus, statt die große Designmatrix aufzubauen; das spart Speicher und meist auch Rechenzeit.

Selbsttest

1. Wenn wir im Widget c_{22} auf null setzen, wird die dargestellte Fläche eine Ebene.

Antwort: Wahr

Dann hängt die Steigung in x-Richtung nicht mehr vom gewählten y-Wert ab.

2. Mit dem äußeren Produkt als $\otimes$ ist $\mathbb{R}^2 \otimes \mathbb{R}^3 = \mathbb{R}^{2 \times 3}$, und dieser Raum hat die Dimension 6.

Antwort: Wahr

Das ist Beispiel 9.4.3 mit $m = 2$ und $n = 3$; nach Satz 9.4.7 ist die Dimension $2 \cdot 3 = 6$.

3. Jedes Element von $V \otimes W$ lässt sich als ein einzelnes Produkt $v \otimes w$ schreiben.

Antwort: Falsch

$V \otimes W$ ist der Spann der elementaren Tensoren, und Summen von Produkten sind im Allgemeinen selbst keine Produkte. Beispiel 9.4.5 zeigt das an $I_2 \in \mathbb{R}^2 \otimes \mathbb{R}^2$: Als Produkt hätte die Matrix höchstens den Rang 1, sie hat aber den Rang 2. Als Summe von zwei elementaren Tensoren geht es.

4. Für Vektorräume V und W gilt $\dim(V \otimes W) = \dim(V) + \dim(W)$.

Antwort: Falsch

Die Dimensionen multiplizieren sich, sie addieren sich nicht (Satz 9.4.7). Für $\dim(V) = 2$ und $\dim(W) = 3$ ist $\dim(V \otimes W) = 6$ und nicht 5.

5. Jede Matrix $A \in \mathbb{R}^{m \times n}$ ist eine Summe von höchstens $\min(m, n)$ elementaren Tensoren.

Antwort: Wahr

Das ist Satz 9.4.6. Die Summenform der Singulärwertzerlegung liefert $A = \sum_{i=1}^r \sigma_i u_i \otimes v_i$ mit $r = \text{rang}(A)$, und der Rang übersteigt weder die Zeilen- noch die Spaltenzahl.

6. In der Darstellung $\sum_i \sum_j c_{ij} v_i \otimes w_j$ haben die Koeffizienten stets die Form $c_{ij} = a_i b_j$.

Antwort: Falsch

Diese Produktform haben genau die elementaren Tensoren (Bemerkung 9.4.8). Allgemeine Elemente von $V \otimes W$ haben beliebige Koeffizienten; bezüglich der Standardbasen ist die Koeffizientenmatrix zu I_2 die Einheitsmatrix selbst, und die hat nicht die Form ab^T .

7. Die Basis $\{1 \otimes 1, x \otimes 1, 1 \otimes y, x \otimes y\}$ spannt alle Polynome in zwei Variablen vom Gesamtgrad höchstens 2 auf.

Antwort: Falsch

Sie spannt die Polynome auf, die in jeder Variablen einzeln höchstens den Grad 1 haben, und das sind vier Basisfunktionen. Der Raum aller Polynome vom Gesamtgrad höchstens 2 hat dagegen die Dimension $\binom{4}{2} = 6$: Es fehlen x^2 und y^2 . Tensorprodukträume begrenzen den Grad in jeder Variablen einzeln, nicht den Gesamtgrad (Bemerkungen 9.4.11 und 9.4.12).

Vertiefung: vgl. MML §2.6 zu Basis und Dimension eines Vektorraums und MML §4.5 bis §4.6, wo die Zerlegung einer Matrix in Rang-1-Anteile ausgeführt wird.

9.5 Zusammenfassung

Die Kernkonzepte

Bemerkung 9.5.1 (Sechs Begriffe)

1. **Tensoren** verallgemeinern Vektoren und Matrizen auf beliebig viele Indexpositionen: Ein Tensor der Stufe k ist eine durch k Indizes indizierte Familie reeller Zahlen, ein Element von $\mathbb{R}^{n_1 \times \dots \times n_k}$ (Definition 9.2.3). Höhere Stufen braucht das Deep Learning,

die Bild- und Videobearbeitung und die moderne Statistik.

2. **Multilinearität** heißt Linearität in jedem einzelnen Argument bei festgehaltenen übrigen (Definition 9.1.1). Linear im Ganzen ist eine multilineare Abbildung in der Regel nicht: Skalieren wir alle n Argumente mit demselben c , tritt c^n heraus statt c (Bemerkung 9.1.2). So ist die Matrizenmultiplikation bilinear, aber nicht linear.
3. Das **äußere Produkt** $\mathbf{v} \otimes \mathbf{w} = \mathbf{v} \mathbf{w}^\top$ macht aus zwei Vektoren $\neq \mathbf{0}$ eine Matrix vom Rang 1 (Satz 9.3.4). Die Singulärwertzerlegung zerlegt umgekehrt jede Matrix in solche Bausteine, $\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \otimes \mathbf{v}_i$ (Bemerkung 9.3.5).
4. Das **Tensorprodukt** überträgt diese Vorschrift auf beliebige Stufen: Die Stufen addieren sich, die Einträge multiplizieren sich (Definition 9.3.7, Bemerkung 9.3.8).
5. Das **Kroneckerprodukt** ist die flach angeordnete Fassung für zwei Matrizen, dieselben Zahlen als Blockmatrix statt als Tensor der Stufe 4 (Bemerkung 9.3.12). Es liefert den vec-Trick $\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X})$ (Satz 9.5.3), der Matrixgleichungen in lineare Gleichungssysteme übersetzt, und in der Statistik separierbare und blockdiagonale Kovarianzmatrizen (Definition 9.3.17, Beispiel 9.3.16).
6. **Tensorprodukte bauen größere Räume aus kleineren.** Der Raum $V \otimes W$ ist die lineare Hülle aller Produkte $\mathbf{v} \otimes \mathbf{w}$ (Definition 9.4.1), und aus Basen der Faktoren entsteht durch Ausmultiplizieren eine Basis des Produktraums mit $\dim(V \otimes W) = \dim(V) \dim(W)$ (Satz 9.4.7). Mit Funktionenräumen als Faktoren liefert das multivariate Basen aus univariaten, etwa für höherdimensionale Splines; auf Gittern ist ihre Designmatrix ein Kroneckerprodukt (Bemerkung 9.4.13).

Vektorisierung von Matrixgleichungen

Punkt 5 verbindet dieses Kapitel mit Kapitel 5, deshalb führen wir ihn aus. Eine Gleichung der Bauart $\mathbf{AXB} = \mathbf{C}$ ist linear in der Unbekannten $\mathbf{X}$, aber diese Unbekannte ist eine Matrix. Die Verfahren aus Abschnitt 5.2 erwarten ein System $\mathbf{Ax} = \mathbf{b}$ mit einem Vektor als Unbekannter. Also stapeln wir die Matrix zu einem Vektor um.

Definition 9.5.2 (Vektorisierung)

Für $\mathbf{X} \in \mathbb{R}^{p \times q}$ mit den Spalten $\mathbf{x}_1, \dots, \mathbf{x}_q \in \mathbb{R}^p$ ist die *Vektorisierung* (vectorization)

$$\text{vec}(\mathbf{X}) = \begin{pmatrix} \mathbf{x}_1 \\ \vdots \\ \mathbf{x}_q \end{pmatrix} \in \mathbb{R}^{pq},$$

also der Vektor, der die Spalten von $\mathbf{X}$ untereinanderhängt. Gestapelt wird spaltenweise, so wie R eine Matrix ohnehin abspeichert.

Satz 9.5.3 (Vektorisierung eines Matrixprodukts, vec-Trick)

Seien $\mathbf{A} \in \mathbb{R}^{m \times p}$, $\mathbf{X} \in \mathbb{R}^{p \times q}$ und $\mathbf{B} \in \mathbb{R}^{q \times n}$. Dann gilt

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^\top \otimes \mathbf{A}) \text{vec}(\mathbf{X}). \quad (9.5.1)$$

Insbesondere ist $\text{vec}(\mathbf{AX}) = (\mathbf{I}_q \otimes \mathbf{A}) \text{vec}(\mathbf{X})$ und $\text{vec}(\mathbf{XB}) = (\mathbf{B}^\top \otimes \mathbf{I}_p) \text{vec}(\mathbf{X})$. Die Matrix $\mathbf{B}^\top \otimes \mathbf{A}$ hat das Format $nm \times qp$, passend zu $\text{vec}(\mathbf{X}) \in \mathbb{R}^{pq}$ und $\text{vec}(\mathbf{AXB}) \in \mathbb{R}^{mn}$.

Vertiefung (optional): Der vec-Trick, blockweise nachgerechnet

Beweis.

- (1) Wir lesen beide Seiten blockweise, mit Blöcken der Länge m . Sind $\mathbf{x}_1, \dots, \mathbf{x}_q$ die Spalten von $\mathbf{X}$ und b_{kj} die Einträge von $\mathbf{B}$, so ist die j -te Spalte von $\mathbf{AXB}$

$$\mathbf{A} \mathbf{X} \mathbf{B} \mathbf{e}_j = \mathbf{A} \mathbf{X} \begin{pmatrix} b_{1j} \\ \vdots \\ b_{qj} \end{pmatrix} = \sum_{k=1}^q b_{kj} \mathbf{A} \mathbf{x}_k.$$

$\mathbf{B} \mathbf{e}_j$ ist die j -te Spalte von $\mathbf{B}$; ein Matrix-Vektor-Produkt ist die Linearkombination der Spalten mit den Einträgen des Vektors

- (2) Auf der rechten Seite von (9.5.1) zerlegen wir $\mathbf{B}^\top \otimes_{\mathbb{K}} \mathbf{A}$ nach Definition 9.3.11 in Blöcke der Größe $m \times p$. Der Block an der Stelle (j, k) ist $(\mathbf{B}^\top)_{jk} \mathbf{A} = b_{kj} \mathbf{A}$, und der k -te Block von $\text{vec}(\mathbf{X})$ ist $\mathbf{x}_k$. Der j -te Block des Produkts lautet damit $\sum_{k=1}^q b_{kj} \mathbf{A} \mathbf{x}_k$. Das ist die Spalte aus Schritt 1, und da j beliebig war, stimmen beide Seiten überein.

Blockmultiplikation: der j -te Block eines Produkts ist die Summe der Blockprodukte über k ; das Transponieren vertauscht die Indizes, deshalb steht dort b_{kj} und nicht b_{jk}

□

Interaktiv: Die Matrixgleichung als lineares System

Welche Anordnung der Kroneckerfaktoren liefert denselben Vektor wie $\text{vec}(\mathbf{AXB})$, auch wenn wir die Einträge verändern?

Interaktives Element — nur in der Web-Fassung

Nur $\mathbf{B}^\top \otimes_{\mathbb{K}} \mathbf{A}$ stimmt für jede Wahl von $\mathbf{A}$, $\mathbf{X}$ und $\mathbf{B}$; $\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B}^\top$ trifft höchstens bei speziellen Faktoren zufällig. Aus $\mathbf{AXB} = \mathbf{C}$ wird so ein gewöhnliches lineares Gleichungssystem in $\text{vec}(\mathbf{X})$.

Beispiel 9.5.4 (Die Identität an 2×2 -Matrizen)

Für

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 1 & 1 \\ 0 & 2 \end{pmatrix}$$

rechnen wir zuerst direkt:

$$\mathbf{A} \mathbf{X} = \begin{pmatrix} 5 & 6 \\ 2 & 3 \end{pmatrix}, \quad \mathbf{A} \mathbf{X} \mathbf{B} = \begin{pmatrix} 5 & 17 \\ 2 & 8 \end{pmatrix}, \quad \text{vec}(\mathbf{AXB}) = \begin{pmatrix} 5 \\ 2 \\ 17 \\ 8 \end{pmatrix}.$$

Und nun über (9.5.1). Mit $\mathbf{B}^\top = \begin{pmatrix} 1 & 0 \\ 1 & 2 \end{pmatrix}$ ist

$$\mathbf{B}^\top \otimes_K \mathbf{A} = \begin{pmatrix} 1 \cdot \mathbf{A} & 0 \cdot \mathbf{A} \\ 1 \cdot \mathbf{A} & 2 \cdot \mathbf{A} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 2 & 2 & 4 \\ 0 & 1 & 0 & 2 \end{pmatrix}, \quad \text{vec}(\mathbf{X}) = \begin{pmatrix} 1 \\ 2 \\ 0 \\ 3 \end{pmatrix},$$

und das Produkt der beiden ist $(5, 2, 17, 8)^\top$, wie es sein muss. Auf die Reihenfolge kommt es an: $\mathbf{A} \otimes_K \mathbf{B}^\top$ liefert $(1, 17, 0, 6)^\top$. Die Formatprobe bemerkt den Tausch nicht, denn Zeilen- und Spaltenzahl eines Kroneckerprodukts sind Produkte der Zeilen- bzw. Spaltenzahlen beider Faktoren. $\mathbf{B}^\top \otimes_K \mathbf{A}$ und $\mathbf{A} \otimes_K \mathbf{B}^\top$ haben deshalb stets dasselbe Format, hier 4×4 .

Vertiefung (optional): Große Systeme: Struktur statt Ausmultiplizieren

Das zu $\mathbf{AXB} = \mathbf{C}$ gehörende lineare Gleichungssystem $(\mathbf{B}^\top \otimes_K \mathbf{A}) \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{C})$ hat mn Gleichungen und pq Unbekannte, seine Systemmatrix ausgesprochen $mnpq$ Einträge. Bei großen Faktoren nutzen wir deshalb die Struktur, statt sie auszumultiplizieren. Sind $\mathbf{A}$ und $\mathbf{B}$ quadratisch und invertierbar, so liefert $\mathbf{X} = \mathbf{A}^{-1} \mathbf{C} \mathbf{B}^{-1}$ die Lösung allein aus den beiden kleinen Faktoren. Das ist eine symbolische Identität; numerisch bilden wir die Inversen nicht explizit, sondern lösen nacheinander lineare Systeme mit $\mathbf{A}$ und $\mathbf{B}^\top$. Nach demselben Muster arbeiten die separierbaren Kovarianzmatrizen aus Abschnitt 9.3: Ihre Eigenwerte ergeben sich als Produkte der Eigenwerte beider Faktoren, ohne dass wir Σ je aufstellen müssen.

Beispiel 9.5.5 (Sylvester-Gleichung mit dem vec-Trick)

Die *Sylvester-Gleichung* lautet

$$\mathbf{AX} + \mathbf{XB} = \mathbf{C}.$$

Mit den beiden Spezialfällen aus Satz 9.5.3 wird daraus für 2×2 -Matrizen

$$(\mathbf{I}_2 \otimes_K \mathbf{A} + \mathbf{B}^\top \otimes_K \mathbf{I}_2) \text{vec}(\mathbf{X}) = \text{vec}(\mathbf{C}).$$

Für

$$\mathbf{A} = \begin{pmatrix} 3 & 0 \\ 1 & 2 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{C} = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$$

hat das lineare Gleichungssystem die Systemmatrix $\begin{pmatrix} 3 & 0 & 1 & 0 \\ 1 & 2 & 0 & 1 \\ 1 & 0 & 4 & 0 \\ 0 & 1 & 1 & 3 \end{pmatrix}$ und die Lösung

$$\text{vec}(\mathbf{X}) = \begin{pmatrix} 1/11 \\ 27/55 \\ 8/11 \\ 51/55 \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1/11 & 8/11 \\ 27/55 & 51/55 \end{pmatrix}.$$

In R folgt die Rechnung der Formel:

```
A <- matrix(c(3, 1, 0, 2), 2, 2)
B <- matrix(c(0, 1, 1, 1), 2, 2)
C <- matrix(c(1, 2, 3, 4), 2, 2)
M <- kronecker(diag(2), A) + kronecker(t(B), diag(2))
X <- matrix(solve(M, as.vector(C)), 2, 2)
A %**% X + X %**% B
all.equal(A %**% X + X %**% B, C)
```

Die letzte Zeile ergibt TRUE. Wichtige Spezialfälle sind Lyapunov-Gleichungen, etwa für stationäre Kovarianzmatrizen von Zeitreihenmodellen; für große Matrizen gibt es spezialisierte Löser, die die Struktur ausnutzen.

Wie es weitergeht

Wie wir mit Tensorproduktbasen aus guten univariaten Basen (Legendre-Polynome, Fourierbasis, Wavelets) approximieren und dem exponentiellen Wachstum $(d+1)^k$ aus Bemerkung 9.4.12 entkommen, behandelt Kapitel 13.

Zunächst folgt in Kapitel 10 die fortgeschrittene Differentialrechnung. Dort begegnen uns Tensoren wieder: Die Ableitung eines matrixwertigen Ausdrucks nach einer Matrix (Abschnitt 10.9) ist ein mehrdimensionales Zahlenfeld, und die Vektorisierung aus Satz 9.5.3 hilft, es zu ordnen.

Selbsttest

1. Für eine bilineare Abbildung f gilt $f(2\mathbf{v}, 3\mathbf{w}) = 5 f(\mathbf{v}, \mathbf{w})$.

Antwort: Falsch

Die Homogenität gilt in jedem Argument einzeln, die Faktoren multiplizieren sich: $f(2\mathbf{v}, 3\mathbf{w}) = 2 \cdot 3 f(\mathbf{v}, \mathbf{w}) = 6 f(\mathbf{v}, \mathbf{w})$ (Bemerkung 9.1.2).

2. Mit spaltenweiser Vektorisierung gilt $\text{vec}(\mathbf{AXB}) = (\mathbf{A} \otimes_{\mathbb{K}} \mathbf{B}^T) \text{vec}(\mathbf{X})$.

Antwort: Falsch

Die Faktoren stehen vertauscht. Richtig ist $\text{vec}(\mathbf{AXB}) = (\mathbf{B}^T \otimes_{\mathbb{K}} \mathbf{A}) \text{vec}(\mathbf{X})$ nach (9.5.1): Der transponierte *rechte* Faktor steht im Kroneckerprodukt *links*. Am Format ist der Tausch nicht zu erkennen; in Beispiel 9.5.4 liefert die vertauschte Fassung $(1, 17, 0, 6)^T$ statt $(5, 2, 17, 8)^T$.

3. Für $\mathbf{v} \in \mathbb{R}^m$ und $\mathbf{w} \in \mathbb{R}^n$ hat das äußere Produkt $\mathbf{v} \otimes \mathbf{w}$ stets den Rang 1.

Antwort: Falsch

Satz 9.3.4 setzt $\mathbf{v} \neq \mathbf{0}$ und $\mathbf{w} \neq \mathbf{0}$ voraus, und diese Voraussetzung ist nötig: Ist einer der beiden Vektoren der Nullvektor, so sind nach (9.3.1) alle Einträge $v_i w_j$ gleich null, das Produkt ist die Nullmatrix und hat den Rang 0. Andernfalls stimmt die Aussage, denn dann spannt $\mathbf{v}$ allein den Spaltenraum auf.

4. Kombinieren wir k univariate Basen mit je $d+1$ Funktionen zu einer Tensorproduktbasis, so hat diese $(d+1)^k$ Elemente.

Antwort: Wahr

Satz 9.4.7 multipliziert die Dimensionen, bei k Faktoren also k -mal. Für $d = 3$ und $k = 10$ sind das schon $4^{10} = 1\,048\,576$ Basisfunktionen (Bemerkung 9.4.12).

Vertiefung: Den vec -Operator und die Rechenregeln rund um $\text{vec}(\mathbf{AXB})$ entwickelt Kapitel 2 von Magnus und Neudecker, Matrix Differential Calculus with Applications in Statistics and Econometrics; von dort führt dasselbe Buch weiter in die Matrixdifferentialrechnung, die als Nächstes ansteht.

Differentialrechnung

10.1 Ableitung als lineare Approximation

Interaktiv: Konzeptkarte zu Analysis und Optimierung

Mit diesem Kapitel beginnt der zweite Teil des Skripts, *Analysis & Optimierung*. Die Karte zeigt, wie seine Konzepte zusammenhängen, von der Fréchet-Ableitung bis zu den Optimierungsverfahren in Kapitel 12; beim ersten Lesen genügt der Gesamteindruck.

Interaktives Element — nur in der Web-Fassung

Wählen wir einen Begriff aus, hebt die Karte seine Voraussetzungen und Folgerungen hervor; verlinkte Kästen führen direkt zum zugehörigen Kapitel.

Was wir mitbringen

Aus der linearen Algebra brauchen wir die Spur einer Matrix aus Abschnitt 3.1 und die Matrixnormen aus Abschnitt 3.2, dazu Determinante und Matrixinversion. Außerdem hantieren wir mit normierten Vektorräumen, also Vektorräumen mit einer Norm, und mit beschränkten linearen Abbildungen darauf. Aus der Analysis setzen wir die Ableitung $f'(x)$ voraus, die partiellen Ableitungen $\partial f(\mathbf{x})/\partial x_i$, die lineare Approximation $f(x+h) \approx f(x) + f'(x)h$ und die Grundzüge der Taylorreihen.

Ein Werkzeug brauchen wir im ganzen Kapitel: die Landau-Notation für kleine Argumente. Für eine Funktion g schreiben wir

$$g(h) = o(h) \quad : \Longleftrightarrow \quad \lim_{h \rightarrow 0} \frac{g(h)}{h} = 0.$$

Ein $o(h)$ -Term verschwindet also *schneller als h selbst*: Sein Verhältnis zu h geht gegen null. Für $g(h) = h^2$ etwa viertelt sich der Term, wenn wir h halbieren. Genauso schreiben wir $g(h) = o(|h|)$ und später $o(\|h\|)$, wenn der Quotient mit $|h|$ beziehungsweise $\|h\|$ gegen null geht; für reelles h ist $o(|h|)$ dasselbe wie $o(h)$, denn $g(h)/h$ und $g(h)/|h|$ unterscheiden sich höchstens im Vorzeichen. Die Landau-Symbole haben wir in Abschnitt 2.4 für große Argumente kennengelernt, wo sie Rechenaufwand messen; hier läuft das Argument gegen null statt gegen unendlich, die Rechenregeln bleiben dieselben (O-Notation).

Ableitungen und Differenzierbarkeit kennen wir aus der Analysis für Funktionen einer reellen Variablen. Neu ist die *Fréchet-Ableitung*: Mit ihr leiten wir Funktionen ab, die Vektoren oder Matrizen als Ein- oder Ausgabe haben, und zwar in beliebigen normierten Räumen. Die Abschnitte

10.2 bis 10.4 behandeln diese Spezialfälle, ab Abschnitt 10.5 rechnen wir mit dem neuen Begriff. Der Leitgedanke steht in der Überschrift dieses Abschnitts: *Ableitung = lineare Approximation*.

Die Ableitung im Eindimensionalen

Für eine Funktion einer reellen Variablen misst der Differenzenquotient, wie stark sich der Funktionswert ändert, wenn wir das Argument um h verrücken.

Definition 10.1.1 (Differenzierbarkeit)

Seien $S \subseteq \mathbb{R}$ offen und $f : S \rightarrow \mathbb{R}$ eine Funktion. Wir nennen f an der Stelle $x \in S$ *differenzierbar* mit *Ableitung* $f'(x)$, falls der Grenzwert

$$\lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} = f'(x) \quad (10.1.1)$$

existiert.

Geometrisch ist der Quotient in (10.1.1) die Steigung der Sekante durch die beiden Punkte $(x, f(x))$ und $(x+h, f(x+h))$. Lassen wir h gegen null laufen, so wandert der zweite Punkt zum ersten, und die Sekante dreht sich in die Tangente. Die Ableitung $f'(x)$ ist deren Steigung.

Das Wort „der Grenzwert“ in Definition 10.1.1 ist wesentlich. Verlangt ist ein einziger Wert, gegen den der Differenzenquotient strebt, egal von welcher Seite und in welchem Tempo wir uns nähern. Das kann scheitern.

Bemerkung 10.1.2 (Wenn es keine eindeutige Tangente gibt)

Betrachten wir $f(x) = |x|$ an der Stelle $x = 0$. Für $h > 0$ ist der Differenzenquotient

$$\frac{|0+h| - |0|}{h} = \frac{h}{h} = 1,$$

für $h < 0$ dagegen $-h/h = -1$. Von rechts kommend messen wir also die Steigung 1, von links die Steigung -1 , und zwar für *jedes* h , nicht erst im Grenzwert. Der Grenzwert in (10.1.1) existiert damit nicht, f ist in $x = 0$ nicht differenzierbar: An einen Knick lässt sich keine eindeutige Tangente anlegen. Stetig ist die Betragsfunktion trotzdem, Knicke sind also kein Widerspruch zur Stetigkeit.

Ableitung als lineare Approximation

Definition 10.1.1 beschreibt die Ableitung als Grenzwert. Für alles Weitere ist eine zweite Lesart nützlicher. Stellen wir (10.1.1) um und lösen nach $f(x+h)$ auf, so steht dort: In der Nähe von x verhält sich f wie eine Gerade, und $f'(x)$ ist deren Steigung.

Satz 10.1.3 (Ableitung als lineare Approximation)

Seien $S \subseteq \mathbb{R}$ offen, $f : S \rightarrow \mathbb{R}$, $x \in S$ und $a \in \mathbb{R}$. Dann sind die folgenden drei Aussagen gleichwertig:

$$1. \quad \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} = a,$$

2. $\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - ah|}{|h|} = 0,$
 3. $f(x+h) = f(x) + ah + o(|h|)$ für $h \rightarrow 0$.

Trifft eine davon zu, so ist f in x differenzierbar mit $f'(x) = a$.

Vertiefung (optional): Warum die drei Ableitungsfassungen gleichwertig sind

Beweis.

- (1) Zu (1) $\iff$ (2): Für $h \neq 0$ ziehen wir a in den Bruch hinein,

$$\frac{f(x+h) - f(x)}{h} - a = \frac{f(x+h) - f(x) - ah}{h}.$$

Der Differenzenquotient strebt also genau dann gegen a , wenn die rechte Seite gegen 0 strebt.

$a = ah/h$ für $h \neq 0$, dann beide Brüche zusammenfassen

- (2) Eine Größe strebt genau dann gegen null, wenn ihr Betrag es tut, und Beträge vertragen sich mit dem Bruch:

$$\left| \frac{f(x+h) - f(x) - ah}{h} \right| = \frac{|f(x+h) - f(x) - ah|}{|h|}.$$

Damit ist (1) gleichwertig zu (2).

$|z/h| = |z|/|h|$; und $\lim_{h \rightarrow 0} g(h) = 0$ gilt genau dann, wenn $\lim_{h \rightarrow 0} |g(h)| = 0$

- (3) Zu (2) $\implies$ (3): Wir geben dem Fehler einen Namen und setzen

$$r(h) := f(x+h) - f(x) - ah.$$

Aussage (2) besagt $|r(h)|/|h| \rightarrow 0$, also $r(h) = o(|h|)$. Einsetzen in die Definition von $r(h)$ liefert

$$f(x+h) = f(x) + ah + r(h) = f(x) + ah + o(|h|),$$

und das ist (3).

Definition des Landau-Symbols: $g(h) = o(|h|)$ heißt genau, dass $g(h)/|h|$ gegen null strebt

- (4) Zu (3) $\implies$ (2): Gilt (3), so ist die Differenz $f(x+h) - f(x) - ah$ ein Term der Ordnung $o(|h|)$. Nach Definition strebt sein Quotient mit $|h|$ gegen null, und dann tut es auch der Betrag dieses Quotienten. Damit sind alle drei Aussagen gleichwertig, und Aussage (1) ist Definition 10.1.1 mit $f'(x) = a$.

wieder $\lim g = 0 \iff \lim |g| = 0$, diesmal in der Gegenrichtung

□

Aussage (3) ist die Fassung, die wir im ganzen Kapitel benutzen: *die Funktion, ihre lineare Näherung, und ein Rest, der schneller verschwindet als h* . Farblich halten wir das durch: blau die Funktion und ihre Werte, grün die lineare Approximation, rot der Restterm.

Bemerkung 10.1.4 (Was hier linear ist)

Bevor wir verallgemeinern, eine mögliche Verwechslung: Die Ableitung f' selbst ist im Allgemeinen keine lineare Funktion: für $f(x) = \sin(x)$ etwa ist $f'(x) = \cos(x)$, und der Kosinus ist nicht linear.

Linear ist eine andere Abbildung, nämlich

$$D_x f : \mathbb{R} \rightarrow \mathbb{R}, \quad h \mapsto f'(x)h$$

bei festem x . Sie erfüllt $f'(x)(h_1 + h_2) = f'(x)h_1 + f'(x)h_2$ und $f'(x)(ch) = c f'(x)h$, ist also linear in h . Wie $f'(x)$ von x abhängt, bleibt davon unberührt. Diese Trennung ist der Ansatzpunkt für den Rest des Kapitels: Was wir verallgemeinern wollen, ist nicht die Zahl $f'(x)$, sondern die lineare Abbildung $D_x f$.

Zwei Fragen bleiben: Wie schnell verschwindet der Restterm, wenn wir h verkleinern, und was geht schief, wenn die Funktion an der betrachteten Stelle einen Knick hat?

Interaktiv: Sekante, Tangente und der Restterm

Zur Wahl stehen zwei glatte Funktionen und die Betragsfunktion aus Bemerkung 10.1.2. Der rote Balken über $x + h$ ist der Restterm $r(h)$, der letzte Readout darunter der relative Fehler $|r(h)| / |h|$.

Interaktives Element — nur in der Web-Fassung

Dieser relative Fehler ist der Abstand zwischen Sekanten- und Tangentensteigung, und nach Satz 10.1.3(2) geht er gegen null. Bei $f(x) = x^2$ ist er exakt $|h|$, denn der Restterm ist h^2 (Beispiel 10.1.7). Bei der Betragsfunktion mit $x = 0$ dagegen trennen sich die beiden Sekanten und bleiben getrennt, wie klein h auch wird. Knapp neben dem Knick, solange $|x| < h$ ist, läuft eine der Sekanten noch über ihn hinweg: Lineare Approximation ist eine lokale Aussage.

Der allgemeine Ableitungsbegriff

Lesen wir die Ableitung als lineare Approximation, so brauchen wir vom Definitionsbereich nur drei Dinge: Punkte verschieben ($x + h$), Längen messen (um „der Fehler wird klein“ zu präzisieren) und lineare Abbildungen. Ein normierter Vektorraum liefert alle drei Zutaten; einem metrischen Raum ohne Vektorraumstruktur fehlt der lineare Teil.

Die folgende Definition geht auf Maurice Fréchet zurück. Sie reicht für alle endlich-dimensionalen Räume und für einige unendlich-dimensionale; schwächere Varianten (Gateaux- und Hadamard-Ableitung) brauchen wir in diesem Kapitel nicht.

Definition 10.1.5 (Fréchet-Ableitung)

Seien $\mathbb{D}$ und $\mathbb{E}$ zwei normierte Vektorräume und $f : \mathbb{D} \rightarrow \mathbb{E}$. Wir nennen f an der Stelle $x \in \mathbb{D}$ (Fréchet-)differenzierbar, falls eine beschränkte lineare Abbildung $D_x f : \mathbb{D} \rightarrow \mathbb{E}$ und ein Restterm $r(h) \in \mathbb{E}$ existieren, sodass

$$f(x + h) = f(x) + D_x f(h) + r(h) \quad \text{und} \quad \lim_{h \rightarrow 0, h \neq 0} \frac{\|r(h)\|_{\mathbb{E}}}{\|h\|_{\mathbb{D}}} = 0. \quad (10.1.2)$$

Die Abbildung $D_x f$ heißt dann Fréchet-Ableitung von f an der Stelle x .

Das $\mathbb{E}$ hat hier nichts mit dem Erwartungswert zu tun. Die beiden Normstriche in (10.1.2) meinen verschiedene Normen: $\|h\|$ ist die Norm auf $\mathbb{D}$, der Restterm wird in der Norm auf $\mathbb{E}$ gemessen.

Bemerkung 10.1.6 (Wie die Definition zu lesen ist)

Der Restterm. Setzen wir wie im Beweis von Satz 10.1.3

$$r(h) := f(x+h) - f(x) - D_x f(h),$$

so gilt die Gleichung in (10.1.2) für jedes h , sie definiert ja nur $r(h)$. Die Aussage steckt in der Grenzwertbedingung, kurz $r(h) = o(\|h\|)$ für $h \rightarrow 0$.

Beschränktheit. Dass $D_x f$ beschränkt ist, heißt: es gibt ein $M < \infty$ mit

$$\|D_x f(h)\| \leq M \|h\| \quad \text{für alle } h.$$

Das M darf von x abhängen, aber nicht von h . In endlich-dimensionalen Räumen ist jede lineare Abbildung beschränkt, die Forderung ist dort also automatisch erfüllt; im Unendlich-dimensionalen ist sie eine echte Zusatzbedingung und gleichbedeutend mit Stetigkeit.

Linear in h , beliebig in x . Die Abbildung $h \mapsto D_x f(h)$ ist linear, so wie in Bemerkung 10.1.4. Wie $D_x f$ von x abhängt, schreibt die Definition in keiner Weise vor.

Der eindimensionale Fall. Für $f: \mathbb{R} \rightarrow \mathbb{R}$ ist $D_x f(h) = f'(x)h$, und (10.1.2) wird zu Aussage (3) aus Satz 10.1.3. Beschränkt ist diese Abbildung, sobald $|f'(x)| < \infty$ ist, mit $M = |f'(x)|$. Die alte Ableitung ist also ein Spezialfall der neuen.

Wir prüfen die Definition am einfachsten nichttrivialen Beispiel.

Beispiel 10.1.7 (Fréchet-Ableitung von $f(x) = x^2$)

Sei $f: \mathbb{R} \rightarrow \mathbb{R}$ mit $f(x) = x^2$. Behauptung: f ist Fréchet-differenzierbar mit $D_x f(h) = 2xh$. Zuerst multiplizieren wir aus:

$$\begin{aligned} f(x+h) &= (x+h)^2 = x^2 + 2xh + h^2 \\ &= f(x) + 2xh + h^2 \\ &= f(x) + D_x f(h) + h^2. \end{aligned}$$

Der Kandidat für die Ableitung ist $D_x f(h) = 2xh$, linear in h ; übrig bleibt der Restterm h^2 . Ist der Rest klein genug? Wir rechnen den Quotienten aus (10.1.2) nach:

$$\lim_{h \rightarrow 0} \frac{|h^2|}{|h|} = \lim_{h \rightarrow 0} |h| = 0 \quad \implies \quad h^2 = o(|h|). \quad \square$$

Der relative Fehler ist hier exakt $|h|$: bei $h = 0,1$ also 0,1, bei $h = 0,01$ nur noch 0,01. Das Widget oben zeigt diese Zahlen an.

Ist $D_x f$ beschränkt? Bei festem x ist

$$|D_x f(h)| = |2xh| = 2|x| \cdot |h| \leq M|h| \quad \text{für alle } h, \quad M = 2|x| < \infty. \quad \square$$

Beide Bedingungen sind erfüllt, f ist also Fréchet-differenzierbar mit $D_x f(h) = 2xh$. Das passt zur Schulauswertung: Nach Bemerkung 10.1.6 ist $D_x f(h) = f'(x)h$, und aus $f'(x)h = 2x \cdot h$ lesen wir $f'(x) = 2x$ ab.

Das $\forall$ in der Schranke gehört zum h , nicht zum x : $M = 2|x|$ hängt von x ab und wächst über jede Grenze, ein gemeinsames M für alle x gibt es nicht. Beschränktheit gilt also bei festem x für alle h .

Selbsttest

In den ersten vier Aussagen sei $f : S \rightarrow \mathbb{R}$ an der Stelle x differenzierbar mit Ableitung $f'(x)$.

1. Ist f in x differenzierbar, so ist f' eine lineare Funktion.

Antwort: Falsch

Die Ableitung ist zunächst irgendeine Funktion von x , und die muss nichts mit Linearität zu tun haben: Für $f(x) = \sin(x)$ ist $f'(x) = \cos(x)$. Linear ist etwas anderes, nämlich die Abbildung $h \mapsto f'(x)h$ bei festem x (Bemerkung 10.1.4).

2. Für festes x ist $h \mapsto f'(x)h$ eine lineare Funktion.

Antwort: Wahr

Hier ist $f'(x)$ eine feste Zahl, und $h \mapsto f'(x)h$ ist die Multiplikation damit. Additivität und Homogenität sind in einer Zeile nachgerechnet. Diese Abbildung heißt in Definition 10.1.5 $D_x f$.

3. Es gilt $\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - f'(x)h|}{|h|} = 0$.

Antwort: Wahr

Das ist Aussage (2) aus Satz 10.1.3. Der Zähler ist der Restterm $r(h)$, und nach dem Satz ist die Grenzwertdefinition der Ableitung gleichwertig dazu, dass dieser relative Fehler verschwindet.

4. Es gilt $f(x+h) = f(x) + f'(x)h + o(|h|)$ für $h \rightarrow 0$.

Antwort: Wahr

Das ist Aussage (3) aus Satz 10.1.3, gleichwertig zur vorigen: Setzen wir $r(h) := f(x+h) - f(x) - f'(x)h$, so heißt $|r(h)|/|h| \rightarrow 0$ gerade $r(h) = o(|h|)$. Diese Zeile ist die Vorlage für Definition 10.1.5.

5. Für $f(x) = x^2$ gilt bei festem x die Schranke $|D_x f(h)| \leq M|h|$ für alle h , mit $M = 2|x|$.

Antwort: Wahr

So herum stimmt es: $|2xh| = 2|x||h|$, und $M = 2|x|$ ist bei festem x endlich. Der Quantor gehört zum h : Ein einziges M für alle x gäbe es nicht, denn $2|x|$ wächst unbeschränkt (Beispiel 10.1.7).

6. Die Fréchet-Ableitung $D_x f$ ist sowohl in h als auch in x linear.

Antwort: Falsch

Linear ist nur die Abhängigkeit von h . Wie $D_x f$ von der Stelle x abhängt, lässt Definition 10.1.5 offen, und schon $f(x) = x^2$ zeigt den Unterschied: $D_x f(h) = 2xh$ ist linear in h , die Zuordnung $x \mapsto D_x f$ ist es zufällig ebenfalls, bei $f(x) = x^3$ mit $D_x f(h) = 3x^2h$ dagegen nicht mehr.

7. Im Widget: Wir wählen $f(x) = x^2$ und stellen $x = 0,60$ und $h = 0,60$ ein. Welchen Wert zeigt der Readout für den relativen Fehler $|r(h)|/|h|$?

Lösung: 0,6

Der Restterm ist $r(h) = h^2 = 0,36$, also $|r(h)|/|h| = |h| = 0,6$. Dasselbe steht als Abstand zwischen der Sekantensteigung 1,8 und der Tangentensteigung 1,2 in der Readout-Liste.

Vertiefung: MML §5.1 behandelt den eindimensionalen Ableitungsbegriff, §5.1.1 die Taylorreihen, die wir hier nur als Vorkenntnis gestreift haben, und §5.1.2 die Differentiationsregeln.

10.2 Der Gradient: Vektor zu Skalar

Die Fréchet-Ableitung aus Abschnitt 10.1 funktioniert in jedem normierten Raum, ist dafür aber abstrakt: eine lineare Abbildung, kein Objekt, mit dem wir rechnen könnten. Für jede Kombination von Ein- und Ausgabeformat suchen wir deshalb eine konkrete Gestalt dieser Abbildung, also eine Zahl, einen Vektor oder eine Matrix.

Fahrplan durch die Spezialfälle

Alle Ableitungen, die wir aus der Analysis kennen, sind Spezialfälle der Fréchet-Ableitung. Neu und für die Statistik wichtig sind die Fälle, in denen Skalare, Vektoren oder Matrizen als Eingabe oder als Ausgabe auftreten. Wir ordnen sie in einer Tabelle an, die zugleich die nächsten drei Abschnitte gliedert.

Eingabe ↓ / Ausgabe →	Skalar y	Vektor y	Matrix Y
Skalar x	$\frac{dy}{dx}$	$\frac{dy}{dx}$	$\frac{dY}{dx}$
Vektor $\mathbf{x}$	$\frac{d\mathbf{x}}{dy}$	$\frac{d\mathbf{x}}{dy}$	
Matrix $\mathbf{X}$	$\frac{\partial \mathbf{x}}{\partial y}$	$\frac{\partial \mathbf{x}}{\partial \mathbf{x}}$	
	$\frac{\partial \mathbf{X}}{\partial \mathbf{X}}$		

Die Einträge lesen sich so:

- Skalar zu Skalar ist die gewöhnliche Ableitung aus Abschnitt 10.1.
- Vektor zu Skalar ist der Fall dieses Abschnitts. Das zugehörige Objekt heißt *Gradient*.
- Vektor zu Vektor führt auf die Jacobimatrix in Abschnitt 10.3; der Fall Skalar zu Vektor steckt dort als Sonderfall mit einer einzigen Eingabevariablen drin.
- Skalar zu Matrix und Matrix zu Skalar behandelt Abschnitt 10.4.
- Die drei leeren Zellen lassen wir aus: Matrix nach Vektor, Vektor nach Matrix und Matrix nach Matrix bräuchten ein Objekt mit mindestens drei Indexpositionen, also einen Tensor (Abschnitt 9.2). Abschnitt 10.9 kommt kurz darauf zurück.

Der Gradient

Der wichtigste Fall in der Statistik ist der zweite: Eine Verlust- oder Zielfunktion bewertet ein ganzes Bündel von Parametern und gibt dafür eine einzige Zahl zurück. Wie leiten wir nach einem ganzen Bündel ab? Die Analysis geht Koordinate für Koordinate vor: Sie friert alle bis auf eine ein und leitet die übrig bleibende Funktion einer Variablen gewöhnlich ab. Jede solche partielle Ableitung misst die Steigung von f entlang einer Koordinatenachse, und der Gradient ist die Liste dieser n Steigungen.

Definition 10.2.1 (Gradient)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine in $\mathbf{x} \in \mathbb{R}^n$ differenzierbare Funktion. Der *Gradient* (gradient) von f in $\mathbf{x}$ ist der Zeilenvektor der partiellen Ableitungen,

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \nabla f(\mathbf{x}) = \left(\frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right) \in \mathbb{R}^{1 \times n}.$$

Dieser Zeilenvektor ist die Ableitung im Sinne von Abschnitt 10.1. Die Formate passen, denn eine $1 \times n$ -Zeile mal eine $n \times 1$ -Spalte ergibt eine Zahl, und $\mathbf{h} \mapsto \nabla f(\mathbf{x})\mathbf{h}$ ist linear in $\mathbf{h}$. Dass keine andere lineare Abbildung in Frage kommt, zeigt Lemma 10.3.3 in Abschnitt 10.3 für beliebige Ausgabeformate: Mit $\mathbf{h} = t\mathbf{e}_j$ und $t \rightarrow 0$ liefert die Definition gerade die j -te partielle Ableitung. Die lineare Approximation lautet damit

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|) \quad \text{mit} \quad D_{\mathbf{x}}f(\mathbf{h}) = \nabla f(\mathbf{x})\mathbf{h}. \quad (10.2.1)$$

Der Restterm schrumpft wie in Abschnitt 10.1 schneller als $\|\mathbf{h}\|$ (Landau-Notation). Anschaulich ist $\mathbf{h} \mapsto f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h}$ für $n = 2$ eine Ebene, die den Graphen von f im Punkt $(\mathbf{x}, f(\mathbf{x}))$ berührt, die Tangentialebene. Sie übernimmt die Rolle der Tangente aus dem Fall $n = 1$.

Bemerkung 10.2.2 (Zeilenvektor, nicht Spaltenvektor)

Vielerorts wird ∇f als *Spaltenvektor* definiert. Für uns ist die Zeilenform praktischer, und zwar an zwei Stellen der nächsten Abschnitte.

Die Jacobimatrix aus Abschnitt 10.3 hat für $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ das Format $m \times n$, im Fall $m = 1$ also $\mathbb{R}^{1 \times n}$. In der Zeilenkonvention sind Gradient und Jacobimatrix damit dasselbe Objekt, und wir müssen die beiden Fälle weder unterscheiden noch ineinander umrechnen. In der Kettenregel dürfen wir die Faktoren außerdem in der Reihenfolge hinschreiben, in der die Funktionen hintereinander ausgeführt werden; in der Spaltenkonvention kehrt sich diese Reihenfolge um und die Faktoren tragen Transponierte.

Im Gegenzug steht dort, wo der Gradient als Schritt im $\mathbb{R}^n$ auftritt, der transponierte Gradient, etwa im Gradientenabstieg weiter unten.

Was der Gradient über f verrät

Die Definition zählt nur die Steigungen entlang der n Koordinatenachsen auf. Die Steigung in jede schräge Richtung steckt trotzdem schon darin, (10.2.1) liefert sie.

Definition 10.2.3 (Richtungsableitung)

Sei $\mathbf{d} \in \mathbb{R}^n$ mit $\|\mathbf{d}\|_2 = 1$. Die *Richtungsableitung* von f in $\mathbf{x}$ in Richtung $\mathbf{d}$ ist die Ableitung der eindimensionalen Funktion $t \mapsto f(\mathbf{x} + t\mathbf{d})$ an der Stelle $t = 0$. Setzen wir $\mathbf{h} = t\mathbf{d}$ in (10.2.1) ein, so ist sie gerade $\nabla f(\mathbf{x})\mathbf{d}$, denn

$$f(\mathbf{x} + t\mathbf{d}) = f(\mathbf{x}) + t\nabla f(\mathbf{x})\mathbf{d} + o(|t|). \quad (10.2.2)$$

Aus $\|\mathbf{d}\|_2 = 1$ folgt $\|t\mathbf{d}\|_2 = |t|$, deshalb steht rechts $o(|t|)$. Wir kennen die Steigung von f also in *jeder* Richtung, sobald wir den Gradienten kennen. Die Norm legt dabei fest, was ein gleich großer Schritt ist; im Folgenden verwenden wir die euklidische Norm. Unter allen so normierten Richtungen gibt es eine beste.

Satz 10.2.4 (Richtung des stärksten Anstiegs)

Sei f in $\mathbf{x}$ differenzierbar mit $\nabla f(\mathbf{x}) \neq \mathbf{0}$. Dann gilt für alle $\mathbf{d} \in \mathbb{R}^n$ mit $\|\mathbf{d}\|_2 = 1$

$$-\|\nabla f(\mathbf{x})\|_2 \leq \nabla f(\mathbf{x})\mathbf{d} \leq \|\nabla f(\mathbf{x})\|_2,$$

und die obere Schranke wird genau für

$$\mathbf{d}^* = \frac{\nabla f(\mathbf{x})^\top}{\|\nabla f(\mathbf{x})\|_2}$$

angenommen, die untere für $-\mathbf{d}^*$. Der transponierte Gradient zeigt also in die Richtung des stärksten Anstiegs, der negative in die des stärksten Abstiegs, und $\|\nabla f(\mathbf{x})\|_2$ ist die Steigung in dieser Richtung.

Vertiefung (optional): Warum der Gradient die Richtung des stärksten Anstiegs angibt

Beweis.

- (1) Das Produkt aus Zeile und Spalte ist ein Skalarprodukt: Mit $\mathbf{g} = \nabla f(\mathbf{x})^\top \in \mathbb{R}^n$ ist $\nabla f(\mathbf{x})\mathbf{d} = \mathbf{g}^\top \mathbf{d}$. Die Cauchy-Schwarz-Ungleichung liefert

$$|\mathbf{g}^\top \mathbf{d}| \leq \|\mathbf{g}\|_2 \|\mathbf{d}\|_2 = \|\mathbf{g}\|_2,$$

also beide Schranken auf einmal.

$\|\mathbf{d}\|_2 = 1$; die euklidische Norm von $\mathbf{g}$ ist dieselbe wie die des Zeilenvektors $\nabla f(\mathbf{x})$

- (2) Gleichheit gilt in Cauchy-Schwarz genau dann, wenn $\mathbf{d}$ ein Vielfaches von $\mathbf{g}$ ist, also $\mathbf{d} = c \mathbf{g}$ mit $c \in \mathbb{R}$. Aus $\|\mathbf{d}\|_2 = 1$ folgt $|c| = 1/\|\mathbf{g}\|_2$. Das positive Vorzeichen gibt

$$\mathbf{g}^\top \mathbf{d}^* = \frac{\mathbf{g}^\top \mathbf{g}}{\|\mathbf{g}\|_2} = \frac{\|\mathbf{g}\|_2^2}{\|\mathbf{g}\|_2} = \|\mathbf{g}\|_2,$$

das negative den Wert $-\|\mathbf{g}\|_2$.

hier wird $\nabla f(\mathbf{x}) \neq \mathbf{0}$ gebraucht: sonst dürften wir nicht durch $\|\mathbf{g}\|_2$ teilen, und alle Richtungsableitungen wären null

□

Bemerkung 10.2.5 (Der Gradient steht senkrecht auf der Höhenlinie)

Das andere Extrem: Für Richtungen $\mathbf{d}$ mit $\nabla f(\mathbf{x})\mathbf{d} = 0$ verschwindet in (10.2.2) der lineare Term, und f ändert sich in erster Ordnung überhaupt nicht. Solche Richtungen stehen senkrecht auf $\nabla f(\mathbf{x})^\top$. Ist f in einer Umgebung von $\mathbf{x}$ stetig differenzierbar und $\nabla f(\mathbf{x}) \neq \mathbf{0}$, so sind sie genau die Tangentialrichtungen der Niveaumenge $\{\mathbf{y} \in \mathbb{R}^n : f(\mathbf{y}) = f(\mathbf{x})\}$ durch $\mathbf{x}$, für $n = 2$ also der Höhenlinie durch $\mathbf{x}$. Verschwindet der Gradient dagegen, kann die Niveaumenge eine Ecke haben; ein Beispiel folgt gleich.

Beide Beobachtungen zusammen: Der Gradient steht senkrecht auf der Höhenlinie und zeigt bergauf, und je enger die Höhenlinien beieinander liegen, desto größer ist $\|\nabla f(\mathbf{x})\|_2$.

Eine quadratische Funktion als Beispiel

Beispiel 10.2.6 (Gradient einer quadratischen Funktion)

Wir betrachten $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ mit

$$f(\mathbf{x}) = x_1^2 + 3x_1x_2 + 2x_2^2.$$

Schritt 1: partielle Ableitungen. Beim Ableiten nach x_1 ist x_2 eine Konstante und umgekehrt:

$$\frac{\partial f(\mathbf{x})}{\partial x_1} = 2x_1 + 3x_2, \quad \frac{\partial f(\mathbf{x})}{\partial x_2} = 3x_1 + 4x_2.$$

Schritt 2: als Zeile zusammensetzen.

$$\nabla f(\mathbf{x}) = (2x_1 + 3x_2 \quad 3x_1 + 4x_2) \in \mathbb{R}^{1 \times 2}.$$

Beachten wir das Format: ∇f bildet $\mathbb{R}^2$ nicht nach $\mathbb{R}^2$ ab, sondern nach $\mathbb{R}^{1 \times 2}$.

Probe an einer Stelle. In $\mathbf{x} = (1, 1)^\top$ ist $f(\mathbf{x}) = 6$ und $\nabla f(\mathbf{x}) = (5, 7)$. Für $\mathbf{h} = (0, 1; 0, 1)^\top$ sagt (10.2.1)

$$f(\mathbf{x} + \mathbf{h}) \approx 6 + 5 \cdot 0,1 + 7 \cdot 0,1 = 7,2, \quad \text{tatsächlich} \quad f(1,1; 1,1) = 7,26.$$

Der Restterm ist 0,06. Ausmultiplizieren von $f(\mathbf{x} + \mathbf{h})$ gibt ihn exakt als $h_1^2 + 3h_1h_2 + 2h_2^2$; er ist quadratisch in $\mathbf{h}$ und damit $o(\|\mathbf{h}\|)$.

Interaktiv: Gradient und Höhenlinie

Das Widget prüft Bemerkung 10.2.5 nach: Links stehen die Höhenlinien mit dem orangenen Gradientenpfeil am gewählten Punkt, rechts dieselbe Funktion als Fläche mit der grünen Tangentialebene aus (10.2.2).

Interaktives Element — nur in der Web-Fassung

Der orange Pfeil steht an jeder Stelle senkrecht auf der blau gestrichelten Tangente an die Höhenlinie und wird lang, wo die Höhenlinien dicht liegen. Das gilt auch für die nicht quadratische Funktion hinter dem zweiten Knopf, deren Höhenlinien sich krümmen, denn die Aussage ist punktweise. Im Nullpunkt der quadratischen Funktion verschwindet der Gradient, und die Höhenlinie zum Niveau 0 besteht dort aus zwei sich kreuzenden Geraden.

Nach Satz 10.2.4 steigt keine Richtung steiler an als der Gradient. Wie viel vom maximalen Anstieg bleibt, wenn wir schräg dazu laufen?

Interaktiv: Richtungsableitung im Kompass

Der Kompass zeigt für jede Richtung $\mathbf{d}$, wie stark f in diese Richtung ansteigt: Der Abstand der blauen Kurve vom Mittelpunkt ist $\nabla f(\mathbf{x})\mathbf{d}$, gemessen am Maximum. Rechts steht der Schnitt von f entlang des Strahls $\mathbf{x} + t\mathbf{d}$ samt der linearen Näherung aus (10.2.2).

Interaktives Element — nur in der Web-Fassung

Die blaue Kurve ist ein Kreis, der den Mittelpunkt berührt, also der Graph von $\theta \mapsto \|\nabla f(\mathbf{x})\|_2 \cos \theta$ in Polarkoordinaten. Ihr weitester Punkt liegt in Gradientenrichtung, wo die Richtungsableitung ihr Maximum $\|\nabla f(\mathbf{x})\|_2$ erreicht (Satz 10.2.4); senkrecht dazu, längs der Höhenlinie, ist sie null. Dazwischen zählt allein der Kosinus des eingeschlossenen Winkels.

Zwei Gradienten zum Auswendiglernen

Zwei Funktionen tauchen in der Statistik so oft auf, dass sich ihre Gradienten einzuprägen lohnt: die lineare Funktion und die quadratische Form.

Beispiel 10.2.7 (Gradient einer linearen Funktion)

Seien $\mathbf{a}, \mathbf{x} \in \mathbb{R}^n$ und $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$. Was ist $\nabla f(\mathbf{x})$? Erst selbst versuchen, dann die Lösung aufklappen.

Lösung

Ausgeschrieben ist $f(\mathbf{x}) = \sum_{i=1}^n a_i x_i$. In dieser Summe kommt x_k in genau einem Summanden vor, nämlich in $a_k x_k$, und dort linear. Also

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = a_k \quad \text{und damit} \quad \nabla f(\mathbf{x}) = (a_1, \dots, a_n) = \mathbf{a}^\top.$$

Der Gradient hängt hier nicht von $\mathbf{x}$ ab. Das muss so sein: f ist selbst schon linear, die lineare Approximation ist also f selbst, und der Restterm in (10.2.1) ist exakt null.

Satz 10.2.8 (Gradient der quadratischen Form)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ symmetrisch und $f: \mathbb{R}^n \rightarrow \mathbb{R}$ mit $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$. Dann gilt

$$\nabla f(\mathbf{x}) = 2\mathbf{x}^\top \mathbf{A}. \quad (10.2.3)$$

Beweis.

- (1) Wir schreiben die quadratische Form als Doppelsumme aus:

$$f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n x_i a_{ij} x_j.$$

der i -te Eintrag von $\mathbf{A} \mathbf{x}$ ist $\sum_j a_{ij} x_j$, und $\mathbf{x}^\top (\mathbf{A} \mathbf{x})$ summiert diese Einträge mit den Gewichten x_i

- (2) Jetzt leiten wir nach x_k ab. Die Variable x_k kommt in zwei Sorten von Summanden vor: einmal als linker Faktor ($i = k$), einmal als rechter ($j = k$). Die Produktregel liefert

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \sum_{i=1}^n x_i a_{ik} + \sum_{j=1}^n a_{kj} x_j.$$

der Summand mit $i = j = k$ enthält x_k zweimal; die Produktregel gibt dort $2a_{kk}x_k$, also je einen Beitrag $a_{kk}x_k$ an beide Summen

- (3) Hier geht die Symmetrie ein. Aus $a_{ik} = a_{ki}$ folgt, dass beide Summen dasselbe sind:

$$\frac{\partial f(\mathbf{x})}{\partial x_k} = \sum_{i=1}^n a_{ki} x_i + \sum_{j=1}^n a_{kj} x_j = 2 \sum_{i=1}^n a_{ki} x_i = 2(\mathbf{A} \mathbf{x})_k.$$

die zweite Summe ist bis auf den Namen des Laufindex die erste

- (4) Der Gradient sammelt diese n Zahlen als Zeile ein, also

$$\nabla f(\mathbf{x}) = 2(\mathbf{A} \mathbf{x})^\top = 2\mathbf{x}^\top \mathbf{A}^\top = 2\mathbf{x}^\top \mathbf{A}.$$

$(\mathbf{A} \mathbf{x})^\top = \mathbf{x}^\top \mathbf{A}^\top$, und noch einmal $\mathbf{A}^\top = \mathbf{A}$

□

Bemerkung 10.2.9 (Drei Nachträge zur quadratischen Form)

Der Spezialfall $A = I$. Dann ist $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|_2^2$ und (10.2.3) wird zu $\nabla f(\mathbf{x}) = 2\mathbf{x}^\top$. Das ist die mehrdimensionale Fassung von $(x^2)' = 2x$.

Ohne Symmetrie stimmt die Formel nicht. Schritt 3 des Beweises braucht $a_{ik} = a_{ki}$. Allgemein liefern die ersten beiden Schritte

$$\nabla(\mathbf{x}^\top \mathbf{A} \mathbf{x}) = \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top),$$

was für symmetrisches A wieder (10.2.3) ergibt. Ein Gegenbeispiel ist $A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ mit $f(\mathbf{x}) = x_1 x_2$: Hier ist $\nabla f(\mathbf{x}) = (x_2, x_1)$, während $2\mathbf{x}^\top A = (0, 2x_1)$ etwas ganz anderes ist. In $\mathbf{x} = (1, 1)^\top$ steht $(1, 1)$ gegen $(0, 2)$.

Beispiel 10.2.6 ist ein Sonderfall. Mit $A = \begin{pmatrix} 1 & 3/2 \\ 3/2 & 2 \end{pmatrix}$ ist $\mathbf{x}^\top A \mathbf{x} = x_1^2 + 3x_1 x_2 + 2x_2^2$, und (10.2.3) gibt

$$2\mathbf{x}^\top A = \begin{pmatrix} 2x_1 + 3x_2 & 3x_1 + 4x_2 \end{pmatrix},$$

also den Gradienten, den wir dort partiell ausgerechnet haben. Diese Matrix ist allerdings *nicht* positiv definit: Ihre Determinante ist $-1/4 < 0$, ihre beiden Eigenwerte haben also verschiedene Vorzeichen. Im Nullpunkt hat f deshalb kein Minimum, sondern einen Sattel; im Widget oben kreuzen sich dort die beiden Geraden zum Niveau 0. Wie die Hesse-Matrix solche Punkte unterscheidet, klärt Abschnitt 10.7.

Anwendung: Gradientenabstieg

Auf der Richtung des stärksten Anstiegs beruht das Standardwerkzeug der Optimierung in hohen Dimensionen. Gesucht sind Parameter $\theta \in \mathbb{R}^p$, die eine Verlustfunktion $L(\theta)$ klein machen, etwa den mittleren quadratischen Fehler eines Modells; für p in der Größenordnung von Millionen gibt es dafür meist keine geschlossene Lösung, wohl aber kleine Schritte bergab.

Algorithmus 10.2.10 (Gradientenabstieg)

Gegeben eine differenzierbare Verlustfunktion $L : \mathbb{R}^p \rightarrow \mathbb{R}$, ein Startwert $\theta^{(0)}$ und eine Lernrate $\alpha > 0$. Für $t = 0, 1, 2, \dots$ iteriere

$$\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla L(\theta^{(t)})^\top. \quad (10.2.4)$$

Abgebrochen wird, wenn sich θ kaum noch ändert oder der Gradient klein genug ist.

Nach Satz 10.2.4 läuft der Algorithmus in jedem Schritt in die aktuell steilste Richtung bergab, um die Länge $\alpha \|\nabla L(\theta^{(t)})\|$. Ob er damit am Ziel ankommt, hängt an α und an der Gestalt von L . Das Gradientenverfahren und seine Varianten sind die Grundlage für das Training neuronaler Netze und für komplexe Regressionsmodelle.

Bemerkung 10.2.11 (Warum im Update ein Transponiertes steht)

Das $^\top$ in (10.2.4) ist eine Formatfrage. Die Parameter $\theta^{(t)}$ bilden einen Spaltenvektor in $\mathbb{R}^p$, der Gradient $\nabla L(\theta^{(t)})$ nach Definition 10.2.1 dagegen eine Zeile in $\mathbb{R}^{1 \times p}$. Eine Zeile von einer Spalte abzuziehen ist nicht definiert. Erst $\nabla L(\theta^{(t)})^\top \in \mathbb{R}^p$ passt zum Rest der Gleichung. Wer den Gradienten von vornherein als Spalte definiert, spart hier das $^\top$ und braucht es dafür in der Kettenregel (Bemerkung 10.2.2).

Die Lernrate α ist der einzige freie Parameter des Verfahrens. Gibt es eine beste Wahl, und woran erkennen wir sie?

Interaktiv: Gradientenabstieg auf einer konvexen quadratischen Funktion

Zum Ausprobieren nehmen wir nicht die Funktion aus Beispiel 10.2.6, denn an deren Sattelscheitert ein Abstiegsverfahren. Stattdessen minimieren wir $L(\theta) = \frac{1}{2}\theta^\top \mathbf{A}\theta$ mit der symmetrischen und positiv definiten Matrix $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$, deren Eigenwerte $(5 \pm \sqrt{5})/2$ beide positiv sind. Nach Satz 10.2.8 und der Linearität des Ableitens ist $\nabla L(\theta) = \theta^\top \mathbf{A}$, der Schritt also $-\alpha \mathbf{A}\theta$.

Interaktives Element — nur in der Web-Fassung

Über den Erfolg entscheidet allein die Rate $\rho(\alpha) = \max_i |1 - \alpha\lambda_i|$; am besten ist die Lernrate, bei der beide Eigenrichtungen gleich schnell schrumpfen. Bei zu kleinem α kommen die Iterierten kaum voran, oberhalb des Grenzfalles $\alpha = 2/\lambda_{\max}$ (eigener Knopf) divergieren sie. Wie eng dieser Spielraum ist, hängt an der Hesse-Matrix (Abschnitt 10.7); Kapitel 12 nimmt die Konvergenzanalyse als eigenes Thema auf.

Selbsttest

1. Ist $f: \mathbb{R}^n \rightarrow \mathbb{R}$ in $\mathbf{x}$ differenzierbar, so ist $\nabla f(\mathbf{x})$ ein Zeilenvektor in $\mathbb{R}^{1 \times n}$, und $\mathbf{h} \mapsto \nabla f(\mathbf{x})\mathbf{h}$ ist die Fréchet-Ableitung von f in $\mathbf{x}$.

Antwort: Wahr

Das ist Definition 10.2.1 zusammen mit (10.2.1). Das Produkt aus einer $1 \times n$ -Zeile und einer $n \times 1$ -Spalte ist eine Zahl, und die Abbildung ist linear in $\mathbf{h}$.

2. Für $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$ hängt der Gradient von der Stelle $\mathbf{x}$ ab.

Antwort: Falsch

Er ist konstant gleich $\mathbf{a}^\top$ (Beispiel 10.2.7), denn f ist selbst linear, also ist die beste lineare Näherung f selbst, und der Restterm in (10.2.1) verschwindet exakt.

3. Für jede Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ gilt $\nabla(\mathbf{x}^\top \mathbf{A}\mathbf{x}) = 2\mathbf{x}^\top \mathbf{A}$.

Antwort: Falsch

Satz 10.2.8 verlangt Symmetrie, und die wird im dritten Beweisschritt gebraucht. Allgemein gilt $\nabla(\mathbf{x}^\top \mathbf{A}\mathbf{x}) = \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top)$. Für $\mathbf{A} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ ist $f(\mathbf{x}) = x_1 x_2$ mit $\nabla f(\mathbf{x}) = (x_2, x_1)$, während $2\mathbf{x}^\top \mathbf{A} = (0, 2x_1)$ ist. In $\mathbf{x} = (1, 1)^\top$ steht $(1, 1)$ gegen $(0, 2)$.

4. Sei $\nabla f(\mathbf{x}) \neq \mathbf{0}$. Unter allen Richtungen $\mathbf{d}$ mit $\|\mathbf{d}\|_2 = 1$ ist die Richtungsableitung $\nabla f(\mathbf{x})\mathbf{d}$ genau dann maximal, wenn $\mathbf{d}$ in Richtung $\nabla f(\mathbf{x})^\top$ zeigt, und ihr Maximalwert ist $\|\nabla f(\mathbf{x})\|_2$.

Antwort: Wahr

Das ist Satz 10.2.4, bewiesen mit dem Gleichheitsfall der Cauchy-Schwarz-Ungleichung. Ohne die Voraussetzung $\nabla f(\mathbf{x}) \neq \mathbf{0}$ gilt die Aussage nicht: Dann sind alle Richtungsableitungen null, und keine Richtung zeichnet sich aus.

5. Das $^\top$ im Update $\theta - \alpha \nabla L(\theta)^\top$ ist reine Schreibweise und darf weggelassen werden.

Antwort: Falsch

Ohne das $^\top$ passen die Formate nicht: θ ist eine Spalte in $\mathbb{R}^p$, der Gradient eine Zeile in $\mathbb{R}^{1 \times p}$, und die Differenz wäre nicht definiert (Bemerkung 10.2.11).

6. Verschwindet der Gradient in einem Punkt, so liegt dort ein Minimum von f .

Antwort: Falsch

Ein verschwindender Gradient sagt nur, dass die lineare Näherung flach ist. Für $f(\mathbf{x}) = x_1^2 + 3x_1x_2 + 2x_2^2$ aus Beispiel 10.2.6 ist $\nabla f(\mathbf{0}) = (0, 0)$, und der Nullpunkt ist ein Sattel (Bemerkung 10.2.9): Die Hesse-Matrix $\begin{pmatrix} 2 & 3 \\ 3 & 4 \end{pmatrix}$ hat die Eigenwerte 6,162 und $-0,162$, also einen positiven und einen negativen. Entlang der einen Eigenrichtung steigt f , entlang der anderen fällt es.

7. Im Kompass-Widget: Wir setzen $\mathbf{d}$ mit dem Knopf „d 60° daneben“ und lesen im Verdikt den Anteil am maximalen Anstieg ab. Wie viel Prozent sind es?

Lösung: 50 Prozent

Nach Satz 10.2.4 ist $\nabla f(\mathbf{x})\mathbf{d} = \|\nabla f(\mathbf{x})\|_2 \cos \theta$, hier also $\cos 60^\circ = 0,5$, und zwar an jeder Stelle, an der der Gradient nicht verschwindet.

8. Bei welcher Lernrate α ist die Rate $\rho(\alpha) = \max_i |1 - \alpha\lambda_i|$ des Abstiegs-Widgets am kleinsten?

Lösung: 0,4

Bei $\alpha = 2/(\lambda_{\min} + \lambda_{\max}) = 2/5 = 0,4$. Dort schneiden sich die beiden Kurven $|1 - \alpha\lambda_{\min}|$ und $|1 - \alpha\lambda_{\max}|$, beide Eigenrichtungen schrumpfen mit demselben Faktor $\sqrt{5}/5 \approx 0,447$.

Vertiefung: MML §5.2 (partielle Ableitungen und Gradient); für den Gradientenabstieg MML §7.1.

10.3 Die Jacobimatrix: Vektor zu Vektor

Der Gradient aus Abschnitt 10.2 setzt voraus, dass am Ende eine Zahl herauskommt. Viele Abbildungen liefern aber wieder ein ganzes Bündel: das Residuum $\mathbf{x} \mapsto \mathbf{Ax} - \mathbf{b}$ der kleinsten Quadrate (Abschnitt 7.1) mit einer Komponente je Beobachtung, eine Schicht eines neuronalen Netzes, die aus Eingaben Aktivierungen macht, oder eine Koordinatentransformation der Ebene. Solche Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ sind m gestapelte skalarwertige Funktionen,

$$\mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))^\top, \quad f_i: \mathbb{R}^n \rightarrow \mathbb{R}.$$

Jede Komponente f_i hat nach Abschnitt 10.2 einen Gradienten, eine Zeile mit n Einträgen. Stapeln wir diese m Zeilen übereinander, steht eine Matrix da.

Die Jacobimatrix

Definition 10.3.1 (Jacobimatrix)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ in $\mathbf{x} \in \mathbb{R}^n$ differenzierbar mit Komponenten $f(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))^\top$. Die *Jacobimatrix* (Jacobian) von f in $\mathbf{x}$ ist die Matrix der partiellen Ableitungen

$$\mathbf{J}_f(\mathbf{x}) := \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{pmatrix} \partial f_1(\mathbf{x})/\partial x_1 & \cdots & \partial f_1(\mathbf{x})/\partial x_n \\ \vdots & \ddots & \vdots \\ \partial f_m(\mathbf{x})/\partial x_1 & \cdots & \partial f_m(\mathbf{x})/\partial x_n \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

Der Eintrag an der Stelle (i, j) ist $\partial f_i(\mathbf{x})/\partial x_j$.

Damit hat die Fréchet-Ableitung aus Abschnitt 10.1 auch in diesem Fall eine Gestalt, mit der sich rechnen lässt: Sie ist die Multiplikation mit der Jacobimatrix,

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|) \quad \text{mit} \quad D_{\mathbf{x}}f(\mathbf{h}) = \mathbf{J}_f(\mathbf{x})\mathbf{h}. \quad (10.3.1)$$

Die Formate passen: Eine $m \times n$ -Matrix mal eine $n \times 1$ -Spalte ergibt eine $m \times 1$ -Spalte, und dort lebt der Zuwachs von f . Der Restterm wird in der euklidischen Norm des $\mathbb{R}^m$ gemessen, das $\mathbf{h}$ im Nenner der Landau-Bedingung dagegen in der des $\mathbb{R}^n$.

Bemerkung 10.3.2 (Die Zeilen sind Gradienten)

Lesen wir Definition 10.3.1 zeilenweise, so steht in Zeile i der Gradient der i -ten Komponentenfunktion:

$$\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} \nabla f_1(\mathbf{x}) \\ \vdots \\ \nabla f_m(\mathbf{x}) \end{pmatrix}.$$

Die Jacobimatrix ordnet also nur an, was wir schon haben. Zwei Sonderfälle stecken bereits darin.

- Für $m = 1$ bleibt eine einzige Zeile übrig, und das ist der Gradient aus Definition 10.2.1. Weil wir ihn dort als Zeilenvektor definiert haben, sind Gradient und Jacobimatrix dasselbe Objekt, nur mit unterschiedlich vielen Zeilen.
- Für $n = 1$ bleibt eine einzige Spalte übrig. Das ist der Fall Skalar zu Vektor aus der Übersicht in Abschnitt 10.2, etwa die Ableitung einer Kurve $t \mapsto \mathbf{z}(t)$ nach ihrem Parameter.

Gleichung (10.3.1) lässt sich auch rückwärts lesen. Finden wir auf irgendeinem Weg eine Matrix, die f bis auf einen $o(\|\mathbf{h}\|)$ -Rest beschreibt, so ist das bereits die Jacobimatrix.

Lemma 10.3.3 (Die Matrix der linearen Näherung)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, sei $\mathbf{x} \in \mathbb{R}^n$, und sei $\mathbf{M} \in \mathbb{R}^{m \times n}$ eine Matrix mit

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{M}\mathbf{h} + o(\|\mathbf{h}\|) \quad \text{für } \mathbf{h} \rightarrow \mathbf{0}.$$

Dann ist f in $\mathbf{x}$ differenzierbar und $\mathbf{M} = \mathbf{J}_f(\mathbf{x})$.

Vertiefung (optional): Warum die Matrix der linearen Näherung die Jacobimatrix ist

Beweis.

- (1) Differenzierbar ist f schon nach Definition 10.1.5, denn $\mathbf{h} \mapsto \mathbf{M}\mathbf{h}$ ist linear und beschränkt. Zu zeigen bleibt, dass $\mathbf{M}$ die Matrix der partiellen Ableitungen ist. Dazu setzen wir $\mathbf{h} = t\mathbf{e}_j$ mit $t \in \mathbb{R}$ und dem j -ten Einheitsvektor $\mathbf{e}_j$. Dann ist $\|\mathbf{h}\| = |t|$ und $\mathbf{M}\mathbf{h} = t\mathbf{M}\mathbf{e}_j$, also

$$\frac{f(\mathbf{x} + t\mathbf{e}_j) - f(\mathbf{x})}{t} = \mathbf{M}\mathbf{e}_j + \frac{o(|t|)}{t}.$$

$\mathbf{M}\mathbf{e}_j$ ist die j -te Spalte von $\mathbf{M}$; der Restterm hängt von t ab, nicht aber der erste Summand

- (2) Für $t \rightarrow 0$ verschwindet der zweite Summand rechts, denn das besagt $o(|t|)$. Links steht der Differenzenquotient in Richtung der j -ten Koordinate, sein Grenzwert ist die Spalte der partiellen Ableitungen $(\partial f_1/\partial x_j, \dots, \partial f_m/\partial x_j)^\top$. Beide Seiten stimmen also spaltenweise überein, und das für jedes $j = 1, \dots, n$.

der Grenzwert existiert, weil die rechte Seite konvergiert; damit existieren nebenbei alle partiellen Ableitungen

□

Die Übersichtstabelle aus Abschnitt 10.2 listet vier Fälle mit Skalaren und Vektoren auf; nach Definition 10.3.1 folgen alle demselben Bauplan.

Interaktiv: Welche Gestalt hat die Ableitung?

Für jede Ausgabekomponente entsteht eine Zeile, für jede Eingabevariable eine Spalte.

Interaktives Element — nur in der Web-Fassung

Damit ist die Tabelle der Formate vollständig: Die einzelne Zahl, der Gradient als Zeile, die Spalte der Ableitungen einer Kurve und die volle Matrix sind vier Ansichten desselben Objekts, und welche wir sehen, entscheiden nur n und m .

Die Bausteine und ihre Jacobimatrizen

Vier Bausteine tauchen so oft auf, dass wir ihre Jacobimatrizen kennen sollten. Alle vier sind konstant oder linear.

Satz 10.3.4 (Jacobimatrizen der Grundbausteine)

Für $\mathbf{x} \in \mathbb{R}^n$ gilt:

1. $f(\mathbf{x}) = \mathbf{c} \in \mathbb{R}^m$ konstant $\implies \mathbf{J}_f(\mathbf{x}) = \mathbf{0}_{m \times n}$.
2. $f(\mathbf{x}) = \mathbf{x} \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{I}_n$.
3. $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n} \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{A}$.
4. $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}$ mit $\mathbf{A} \in \mathbb{R}^{n \times m} \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{A}^\top$.

Keine dieser vier Jacobimatrizen hängt von $\mathbf{x}$ ab.

Beweis.

- (1) Zu (1): Jede Komponente $f_i(\mathbf{x}) = c_i$ ist konstant, alle partiellen Ableitungen verschwinden, und die Jacobimatrix ist die $m \times n$ -Nullmatrix.

eine konstante Funktion ändert sich nicht, wenn wir eine Koordinate verändern

- (2) Zu (3): Schreiben wir f komponentenweise auf. Die i -te Komponente von $\mathbf{A}\mathbf{x}$ ist

$$f_i(\mathbf{x}) = \sum_{j=1}^n a_{ij} x_j, \quad \text{also} \quad \frac{\partial f_i(\mathbf{x})}{\partial x_k} = \frac{\partial}{\partial x_k} \left(\sum_{j=1}^n a_{ij} x_j \right) = a_{ik}.$$

in der Summe hängt nur der Summand mit $j = k$ von x_k ab, und zwar linear mit Faktor a_{ik} ; alle anderen sind bezüglich x_k konstant

- (3) Die partielle Ableitung an der Stelle (i, k) ist damit der Matrixeintrag a_{ik} selbst, und das Sammeln aller Einträge liefert

$$\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} = \mathbf{A}.$$

Definition 10.3.1: Zeilenindex i = Ausgabe, Spaltenindex k = Eingabe, exakt die Indizierung von $\mathbf{A}$

- (4) Zu (2): Das ist der Sonderfall $\mathbf{A} = \mathbf{I}_n$ von (3), denn $\mathbf{x} = \mathbf{I}_n \mathbf{x}$.

direkt: $\partial x_i / \partial x_j$ ist 1 für $i = j$ und 0 sonst, also die Einheitsmatrix

- (5) Zu (4): Lesen wir die Zeile $\mathbf{x}^\top \mathbf{A}$ als Spalte $(\mathbf{x}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{x}$, so liefert Teil (3) mit $\mathbf{A}^\top \in \mathbb{R}^{m \times n}$ die Jacobimatrix $\mathbf{J}_f(\mathbf{x}) = \mathbf{A}^\top$.

Transponieren dreht ein Produkt um: $(\mathbf{x}^\top \mathbf{A})^\top = \mathbf{A}^\top (\mathbf{x}^\top)^\top = \mathbf{A}^\top \mathbf{x}$

□

Bemerkung 10.3.5 (Zur Identität für $\mathbf{x}^\top \mathbf{A}$)

Streng genommen bildet $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}$ in die Zeilenvektoren $\mathbb{R}^{1 \times m}$ ab, Definition 10.3.1 verlangt aber eine Spalte; wir lesen die Zeile deshalb als Spalte, rechnen also mit $\mathbf{A}^\top \mathbf{x}$. Wer im Zeilenformat bleibt, bekommt dieselben Zahlen in transponierter Anordnung.

Korollar 10.3.6 (Lineare Abbildungen sind ihre eigene Näherung)

Für $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ gilt

$$f(\mathbf{x} + \mathbf{h}) = \mathbf{A}\mathbf{x} + \mathbf{A}\mathbf{h} = f(\mathbf{x}) + \mathbf{J}_f(\mathbf{x})\mathbf{h},$$

und zwar exakt für jedes $\mathbf{h}$, ohne Restterm. Die lineare Näherung (10.3.1) ist hier keine Näherung, sondern eine Identität.

Zusammen mit der Kettenregel lassen sich aus den vier Bausteinen fast alle Ableitungen dieses Kapitels zusammensetzen.

Was die Jacobimatrix geometrisch anstellt

Eine nichtlineare Abbildung $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ verbiegt die Ebene: Ein feines Gitter um einen Punkt $\mathbf{x}_0$ wird zu einem krummen Netz um $f(\mathbf{x}_0)$. Die Jacobimatrix beschreibt dieses Netz näherungsweise durch ein Parallelogrammgitter, dessen Maschen die Spalten $\mathbf{J}_f(\mathbf{x}_0)\mathbf{e}_1$ und $\mathbf{J}_f(\mathbf{x}_0)\mathbf{e}_2$ aufspannen, die Bilder der Koordinatenrichtungen unter der Linearisierung. Je kleiner das Gitter, desto besser passt es. Unter der Linearisierung geht ein Quadrat der Fläche a^2 in ein Parallelogramm der Fläche $|\det \mathbf{J}_f(\mathbf{x}_0)| a^2$ über; dieser *Flächenfaktor* gilt im Grenzwert kleiner Quadrate auch für f selbst.

Beispiel 10.3.7 (Quadrieren in der Ebene)

Wir nehmen

$$f(\mathbf{x}) = \begin{pmatrix} x_1^2 - x_2^2 \\ 2x_1 x_2 \end{pmatrix}, \quad \mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} 2x_1 & -2x_2 \\ 2x_2 & 2x_1 \end{pmatrix}.$$

Wer die Ebene als komplexe Zahlenebene liest, erkennt darin die Abbildung $z \mapsto z^2$. An der Stelle $\mathbf{x}_0 = (1; 0,5)^\top$ ist

$$f(\mathbf{x}_0) = \begin{pmatrix} 0,75 \\ 1 \end{pmatrix}, \quad \mathbf{J}_f(\mathbf{x}_0) = \begin{pmatrix} 2 & -1 \\ 1 & 2 \end{pmatrix}.$$

Der Restterm ist hier $\mathbf{r}(\mathbf{h}) = f(\mathbf{h})$, seine Länge also exakt $\|\mathbf{h}\|^2$: Ein Zehntel Schrittweite kostet ein Hundertstel Fehler.

Vertiefung (optional): Der exakte Restterm und die Jacobi-Determinante als Flächenfaktor

Den Restterm aus Beispiel 10.3.7 können wir vollständig ausrechnen. Setzen wir $\mathbf{x}_0 + \mathbf{h}$ ein und sortieren nach Potenzen von $\mathbf{h}$, so bleibt

$$\mathbf{r}(\mathbf{h}) = f(\mathbf{x}_0 + \mathbf{h}) - f(\mathbf{x}_0) - \mathbf{J}_f(\mathbf{x}_0)\mathbf{h} = \begin{pmatrix} h_1^2 - h_2^2 \\ 2h_1h_2 \end{pmatrix} = f(\mathbf{h}).$$

Der Fehler der linearen Näherung ist also die Funktion selbst, ausgewertet am Zuwachs. Seine Länge kennen wir damit exakt:

$$\|\mathbf{r}(\mathbf{h})\|^2 = (h_1^2 - h_2^2)^2 + 4h_1^2h_2^2 = (h_1^2 + h_2^2)^2, \quad \text{also} \quad \|\mathbf{r}(\mathbf{h})\| = \|\mathbf{h}\|^2.$$

Der relative Fehler ist demnach $\|\mathbf{r}(\mathbf{h})\| / \|\mathbf{h}\| = \|\mathbf{h}\|$ und geht für $\mathbf{h} \rightarrow \mathbf{0}$ gegen null: Bei $\mathbf{h} = (0,1; 0,1)^\top$ mit $\|\mathbf{h}\| \approx 0,1414$ ist der Fehler 0,02 lang, bei $\mathbf{h} = (0,01; 0,01)^\top$ nur noch 0,0002.

Bemerkung 10.3.8 (Wie stark die Fläche verzerrt wird)

Wie stark f die Fläche dehnt oder staucht, steht in der Determinante der Jacobimatrix. Ein achsenparalleles Quadrat mit Kantenlänge a um $\mathbf{x}_0$ geht unter der Linearisierung in das Parallelogramm über, das von $a\mathbf{J}_f(\mathbf{x}_0)\mathbf{e}_1$ und $a\mathbf{J}_f(\mathbf{x}_0)\mathbf{e}_2$ aufgespannt wird; dessen Flächeninhalt ist das $|\det \mathbf{J}_f(\mathbf{x}_0)|$ -fache von a^2 . Weil das krumme Bild für kleine Quadrate immer besser mit diesem Parallelogramm übereinstimmt, gilt derselbe Faktor im Grenzwert auch für f selbst. In Beispiel 10.3.7 ist $\det \mathbf{J}_f(\mathbf{x}) = 4x_1^2 + 4x_2^2$, an der Stelle $\mathbf{x}_0$ also 5: Ein kleines Quadrat um $\mathbf{x}_0$ bekommt annähernd die fünffache Fläche, und je kleiner es ist, desto genauer stimmt der Faktor. In der Wahrscheinlichkeitsrechnung ist dieser Faktor der Korrekturterm im Transformationssatz für Dichten.

Interaktiv: Linearisierung bei schrumpfendem Fenster

Wie schnell verschwindet der Unterschied zwischen krummem Bild und Parallelogramm, wenn das Fenster schrumpft, und stimmt der Flächenfaktor $|\det \mathbf{J}_f(\mathbf{x}_0)|$ schon vorher oder erst im Grenzwert?

Interaktives Element — nur in der Web-Fassung

Links liegt ein Gitter mit dem violetten Fenster der halben Kantenlänge h um $\mathbf{x}_0$, in der Mitte sein Bild unter f , rechts in der Lupe das krumme Bild des Fensters (blau) gegen das Parallelogramm $f(\mathbf{x}_0) + \mathbf{J}_f(\mathbf{x}_0)\mathbf{h}$ (grün). Die roten Strecken in den Ecken sind der Restterm, die orangenen Pfeile h mal die Spalten von $\mathbf{J}_f(\mathbf{x}_0)$.

Beim Halbieren von h schrumpft der rote Abstand schneller als das Fenster, der Quotient $\|\mathbf{r}(\mathbf{h})\| / \|\mathbf{h}\|$ fällt also mit, wie (10.3.1) es verlangt. Bei der Voreinstellung „linear“ ist der Restterm exakt null (Korollar 10.3.6), und das Flächenverhältnis stimmt für jedes h mit $|\det \mathbf{J}_f(\mathbf{x}_0)|$ überein. Beim „Quadrieren“ an der Stelle $\mathbf{x}_0 = (1; 0,5)^\top$ nähert es sich dem Flächenfaktor erst

für kleines h und ist bei $h = 0,075$ auf drei Stellen richtig. Beim „Wirbel“ ist $\det \mathbf{J}_f(\mathbf{x}) = 1$ an jeder Stelle: Die Fläche bleibt erhalten, und trotzdem verbiegt sich das Gitter kräftig.

Verkettung

Bisher haben wir einzelne Abbildungen abgeleitet. Jetzt schalten wir mehrere hintereinander: Die Ausgabe der einen ist die Eingabe der nächsten. Für die Verkettung gilt dieselbe Regel wie in der Analysis, nur dass jetzt Matrizen multipliziert werden.

Satz 10.3.9 (Kettenregel für Jacobimatrizen)

Seien $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ in $\mathbf{x}$ differenzierbar und $f : \mathbb{R}^m \rightarrow \mathbb{R}^p$ in $g(\mathbf{x})$ differenzierbar. Dann ist $f \circ g$ in $\mathbf{x}$ differenzierbar mit

$$\mathbf{J}_{f \circ g}(\mathbf{x}) = \mathbf{J}_f(g(\mathbf{x})) \mathbf{J}_g(\mathbf{x}). \quad (10.3.2)$$

Die Formate passen: Rechts steht eine $p \times m$ -Matrix mal eine $m \times n$ -Matrix, das Produkt ist $p \times n$, und das verlangt Definition 10.3.1 für eine Abbildung von $\mathbb{R}^n$ nach $\mathbb{R}^p$. Der Satz ist die Koordinatenfassung der allgemeinen Kettenregel, Satz 10.6.7 in Abschnitt 10.6; dort steht auch der Beweis.

Anwendung: Backpropagation

Ein neuronales Netz ist eine Verkettung. Aus einer Eingabe $\mathbf{x}$ wird über K Schichten eine Vorhersage $\hat{\mathbf{y}}$,

$$\mathbf{x} \xrightarrow{f_1} \mathbf{z}_1 \xrightarrow{f_2} \mathbf{z}_2 \xrightarrow{\dots} \mathbf{z}_{K-1} \xrightarrow{f_K} \hat{\mathbf{y}} = (f_K \circ \dots \circ f_2 \circ f_1)(\mathbf{x}).$$

Jede Schicht f_k hat eigene Parameter θ_k , also Gewichte und Biases, und rechnet typischerweise $f_k(\mathbf{z}_{k-1}) = \sigma_k(\mathbf{W}_k(\theta_k) \mathbf{z}_{k-1})$ mit einer Gewichtsmatrix $\mathbf{W}_k$ und einer komponentenweise wirkenden Aktivierungsfunktion σ_k . Eine Verlustfunktion $L(\hat{\mathbf{y}}, \mathbf{y})$ misst anhand des Zielwerts $\mathbf{y}$, wie gut die Vorhersagen sind; in der folgenden Formel hängt sie bei festem $\hat{\mathbf{y}}$ nicht noch einmal direkt von den Parametern ab. Zum Trainieren brauchen wir für jede Schicht die Ableitung $\partial L / \partial \theta_k$, denn die verlangt der Gradientenabstieg aus Algorithmus 10.2.10.

Bemerkung 10.3.10 (Die Gradientenkette eines Netzes)

Zwischen θ_k und L liegen die Schichten $k+1$ bis K und danach die Verlustfunktion. Von θ_k hängt dabei allein die Schicht k ab: Ihre Eingabe $\mathbf{z}_{k-1}$ entsteht aus den Schichten davor und bleibt fest, wenn wir θ_k verändern. Satz 10.3.9, mehrfach angewandt, ergibt

$$\frac{\partial L}{\partial \theta_k} = \frac{\partial L}{\partial \hat{\mathbf{y}}} \cdot \mathbf{J}_{f_K}(\mathbf{z}_{K-1}) \cdot \mathbf{J}_{f_{K-1}}(\mathbf{z}_{K-2}) \cdots \mathbf{J}_{f_{k+1}}(\mathbf{z}_k) \cdot \frac{\partial f_k(\mathbf{z}_{k-1}; \theta_k)}{\partial \theta_k}. \quad (10.3.3)$$

Die Formate passen von links nach rechts zusammen. Ganz links steht mit $\partial L / \partial \hat{\mathbf{y}}$ ein Zeilenvektor, weil L skalar ist. Jede Jacobimatrix $\mathbf{J}_{f_j}(\mathbf{z}_{j-1})$ hat so viele Zeilen wie $\mathbf{z}_j$ Komponenten und so viele Spalten wie $\mathbf{z}_{j-1}$. Der letzte Faktor leitet die Schicht k nach ihren *eigenen* Parametern ab, nicht nach ihrer Eingabe. Am Ende steht eine Zeile mit so vielen Einträgen, wie θ_k Parameter hat.

Backpropagation ist die effiziente Auswertung dieser Kette: von links, also von der Ausgabe rückwärts Schicht für Schicht; was das spart, rechnet die Vertiefung unten vor.

Bemerkung 10.3.11 (Wo die Kette aufhört)

In (10.3.3) läuft das Produkt der Jacobimatrizen nur bis $\mathbf{J}_{f_{k+1}}(\mathbf{z}_k)$, bis zur Schicht *über* der gesuchten. Ziehen wir die Kette bis $\mathbf{J}_{f_k}(\mathbf{z}_{k-1})$ weiter und leiten erst dann nach θ_k ab, so zählt $\mathbf{W}_k$ doppelt: $\mathbf{J}_{f_k}(\mathbf{z}_{k-1})$ ist die Ableitung der Schicht k nach ihrer Eingabe und enthält $\mathbf{W}_k$ schon als Faktor. Merkregel: Jede Schicht liefert genau einen Faktor, und für die Schicht k ist das der nach θ_k abgeleitete.

Beispiel 10.3.12 (Jacobimatrix eines ReLU-Layers)

Nehmen wir als Aktivierung die *ReLU-Funktion* (rectified linear unit) $\sigma(u) = \max(0, u)$, komponentenweise angewandt. Die Schicht rechnet also $f_k(\mathbf{z}_{k-1}) = \max(\mathbf{0}, \mathbf{W}_k \mathbf{z}_{k-1})$. Für die Ableitung nach der Eingabe verketteten wir zwei Bausteine: erst die lineare Abbildung $\mathbf{z} \mapsto \mathbf{W}_k \mathbf{z}$ mit Jacobimatrix $\mathbf{W}_k$ nach Satz 10.3.4(3), dann die komponentenweise Schwelle. Die zweite Abbildung reicht eine positive Komponente unverändert durch und setzt eine negative auf null; sie mischt die Komponenten nicht, also ist ihre Jacobimatrix diagonal, und auf der Diagonale steht die Ableitung von $\max(0, \cdot)$, je nach Vorzeichen eine 1 oder eine 0. Nach Satz 10.3.9 ist

$$\mathbf{J}_{f_k}(\mathbf{z}_{k-1}) = \text{diag}(\mathbb{1}_{\{\mathbf{W}_k \mathbf{z}_{k-1} > \mathbf{0}\}}) \cdot \mathbf{W}_k. \quad (10.3.4)$$

Die Diagonalmatrix trägt an der Stelle i eine 1, falls $(\mathbf{W}_k \mathbf{z}_{k-1})_i > 0$ ist, und sonst eine 0. Sie streicht also gerade die Zeilen von $\mathbf{W}_k$, die zu inaktiven Einheiten gehören. Ein Zahlenbeispiel mit

$$\mathbf{W} = \begin{pmatrix} 1 & -1 \\ 2 & 1 \end{pmatrix}, \quad \mathbf{z} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{W}\mathbf{z} = \begin{pmatrix} -1 \\ 4 \end{pmatrix} :$$

Die erste Einheit ist inaktiv, die zweite aktiv, also

$$\mathbf{J}_f(\mathbf{z}) = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 2 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 2 & 1 \end{pmatrix}.$$

An einer Schaltstelle mit $(\mathbf{W}_k \mathbf{z}_{k-1})_i = 0$ hat die i -te Ausgabekomponente einen Knick, sofern die i -te Zeile von $\mathbf{W}_k$ nicht der Nullvektor ist (etwa für $\mathbf{z} = (1; 1)^\top$ mit $\mathbf{W}\mathbf{z} = (0; 3)^\top$); dort ist der Layer nicht differenzierbar (Bemerkung 10.1.2). Bei einer Nullzeile ist die Komponente dagegen konstant null und damit differenzierbar. In der Praxis wird an einem echten Knick meist per Verabredung die Ableitung null verwendet.

Vertiefung (optional): Aufwand der Jacobi-Kette und Backpropagation

Bemerkung 10.3.13 (Wie die Kette ausgewertet wird)

Gleichung (10.3.3) ist ein Produkt aus vielen Matrizen, und Matrixmultiplikation ist assoziativ: Wir dürfen die Klammern setzen, wie wir wollen. Für den Rechenaufwand macht das einen großen Unterschied, denn eine $m \times n$ -Matrix mal eine $n \times p$ -Matrix kostet mnp Multiplikationen (Abschnitt 2.3).

Rechnen wir ein kleines Netz mit drei Schichten durch, mit $\mathbf{z}_1 \in \mathbb{R}^{50}$, $\mathbf{z}_2 \in \mathbb{R}^{20}$ und $\hat{\mathbf{y}} \in \mathbb{R}^{10}$, und zwar die Kette bis hinunter zur ersten Schicht. Beginnen wir in (10.3.3) ganz links, so bleiben wir immer bei einer Zeile: erst $(1 \times 10) \cdot (10 \times 20)$ mit 200 Multiplikationen, dann $(1 \times 20) \cdot (20 \times 50)$ mit 1000, zusammen 1200. Klammern wir dagegen zuerst die beiden Jacobimatrizen zusammen, so entsteht das volle Matrixprodukt $(10 \times 20) \cdot (20 \times 50)$ mit 10 000 Multiplikationen und danach noch einmal 500, zusammen 10 500, also fast das Neunfache.

Der Grund: Weil L skalar ist, ist der äußerste linke Faktor eine Zeile, und eine Zeile mal eine Matrix bleibt eine Zeile. Wer bei $\partial L / \partial \hat{\mathbf{y}}$ anfängt, hält also stets nur einen Vektor im Speicher; wer am anderen Ende beginnt, baut große Zwischenmatrizen auf. In der Sprache des Netzes heißt „links anfangen“ gerade: von der Ausgabe rückwärts Schicht für Schicht zur Schicht k laufen. Das ist Backpropagation, und dazu kommt eine zweite Ersparnis: Das Teilprodukt für die Schicht k entsteht aus dem für die Schicht $k + 1$ durch einen einzigen weiteren Faktor, nämlich $\mathbf{J}_{f_{k+1}}(\mathbf{z}_k)$. Ein Rückwärtslauf liefert deshalb die Gradienten *aller* Schichten, nicht nur den einer einzelnen. Neuronale Netze lassen sich überhaupt nur deshalb mit Millionen von Parametern trainieren.

Wo die Kette für $\mathbf{W}_1$ endet und was unterwegs in den Zwischengrößen steht, Matrizen oder Zeilen, zählen wir am kleinsten möglichen Netz nach.

Interaktiv: Vorwärts und rückwärts durch ein winziges Netz

Das Netz hat zwei Schichten: $\mathbf{a}_1 = \mathbf{W}_1 \mathbf{x}$, dann $\mathbf{z}_1 = \max(\mathbf{0}, \mathbf{a}_1)$, dann $\hat{\mathbf{y}} = \mathbf{W}_2 \mathbf{z}_1$ und schließlich $L = \frac{1}{2}(\hat{\mathbf{y}} - y)^2$ mit dem Zielwert $y = 1$. Unter den Knoten stehen blau die Zahlen des Vorwärtslaufs, über den Knoten orange die Ableitung von L nach dem jeweiligen Knoten.

Interaktives Element — nur in der Web-Fassung

Jede Zwischengröße des Rückwärtslaufs bleibt eine Zeile, weil links immer die Zeile des vorigen Schritts steht und rechts eine Jacobimatrix; erst der letzte Schritt ordnet das Ergebnis als Gewichtsmatrix an, denn $\mathbf{W}_1$ ist keine Liste, sondern ein Rechteck. Und die Kette für $\mathbf{W}_1$ endet bei $\mathbf{J}_{f_2}(\mathbf{z}_1) = \mathbf{W}_2$: Der letzte Faktor ist die Ableitung der ersten Schicht nach ihren eigenen Gewichten, nicht noch einmal $\mathbf{W}_1$ (Bemerkung 10.3.11). Stellen wir den Regler auf $x_1 = 2$, so landen wir auf einer Knickstelle der Art aus Beispiel 10.3.12.

- Ob wir das Produkt in (10.3.3) von links oder von rechts auswerten, ändert nur die Reihenfolge der Rechenschritte, nicht den Aufwand.

Antwort: Falsch

Das Ergebnis ist dasselbe, der Aufwand nicht. Im Beispiel aus Bemerkung 10.3.13 kostet die Auswertung von links 1200 und die von rechts 10 500 Multiplikationen. Weil L skalar ist, bleibt von links jedes Zwischenergebnis eine Zeile; von rechts entstehen volle Matrizen. Diese Auswertungsreihenfolge ist die Backpropagation.

Selbsttest

- Für $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ist $\mathbf{J}_f(\mathbf{x}) \in \mathbb{R}^{m \times n}$, und die i -te Zeile ist der Gradient der i -ten Komponentenfunktion f_i .

Antwort: Wahr

Das ist Definition 10.3.1 zusammen mit Bemerkung 10.3.2: Pro Ausgabekomponente gibt es eine Zeile, pro Eingabevariable eine Spalte. Für $m = 1$ bleibt genau eine Zeile übrig, nämlich der Gradient aus Definition 10.2.1.

2. Für $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$ hängt die Jacobimatrix von der Stelle $\mathbf{x}$ ab.

Antwort: Falsch

Sie ist konstant gleich $\mathbf{A}$ (Satz 10.3.4). Der Grund steht in Korollar 10.3.6: f ist selbst linear, also ist die beste lineare Näherung f selbst, und der Restterm verschwindet für jedes $\mathbf{h}$ exakt.

3. Die Kettenregel lautet $\mathbf{J}_{f \circ g}(\mathbf{x}) = \mathbf{J}_g(\mathbf{x}) \mathbf{J}_f(g(\mathbf{x}))$.

Antwort: Falsch

Die Reihenfolge ist vertauscht; richtig ist (10.3.2), $\mathbf{J}_{f \circ g}(\mathbf{x}) = \mathbf{J}_f(g(\mathbf{x})) \mathbf{J}_g(\mathbf{x})$. Schon die Formate zeigen den Fehler: Für $g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ und $f: \mathbb{R}^m \rightarrow \mathbb{R}^p$ wäre das falsch geordnete Produkt $(m \times n) \cdot (p \times m)$ gar nicht definiert, außer wenn zufällig $n = p$ gilt.

4. Für die Ableitung nach θ_k multiplizieren wir die Jacobimatrizen bis einschließlich $\mathbf{J}_{f_k}(\mathbf{z}_{k-1})$ und hängen danach noch $\partial \mathbf{W}_k(\theta_k) / \partial \theta_k$ an.

Antwort: Falsch

Damit ginge $\mathbf{W}_k$ zweimal in das Produkt ein. Die Matrix $\mathbf{J}_{f_k}(\mathbf{z}_{k-1})$ ist die Ableitung der Schicht k nach ihrer *Eingabe* und enthält $\mathbf{W}_k$ bereits, siehe (10.3.4) für den ReLU-Fall. Die Kette endet nach (10.3.3) bei $\mathbf{J}_{f_{k+1}}(\mathbf{z}_k)$, und der letzte Faktor ist $\partial f_k(\mathbf{z}_{k-1}; \theta_k) / \partial \theta_k$ (Bemerkung 10.3.11).

5. Ein ReLU-Layer $f(\mathbf{z}) = \max(0, \mathbf{W}\mathbf{z})$ ist an einer Stelle mit $(\mathbf{W}\mathbf{z})_i = 0$ nicht differenzierbar, sofern die i -te Zeile von $\mathbf{W}$ nicht der Nullvektor ist.

Antwort: Wahr

Dort hat $\max(0, \cdot)$ einen Knick, links und rechts ergeben sich verschiedene Steigungen (Bemerkung 10.1.2). Formel (10.3.4) gilt deshalb nur abseits echter Schalthyperebenen; in der Praxis wird dort meist die Ableitung null verwendet. Bei einer Nullzeile wäre die Komponente dagegen konstant null und differenzierbar (Beispiel 10.3.12).

6. Im Linearisierungs-Widget: Wir wählen die Voreinstellung „Quadrieren“ und lassen $\mathbf{x}_0$ auf $(1; 0,5)^\top$ stehen. Welchen Wert zeigt $\det \mathbf{J}_f(\mathbf{x}_0)$?

Lösung: 5

$\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} 2x_1 & -2x_2 \\ 2x_2 & 2x_1 \end{pmatrix}$ hat die Determinante $4(x_1^2 + x_2^2)$, an der Stelle $(1; 0,5)^\top$ also 5 (Beispiel 10.3.7). Dasselbe steht als Grenzwert des Flächenverhältnisses im Verdikt.

7. Um welchen Faktor fällt der Restterm $\|r(\mathbf{h})\|$ im Linearisierungs-Widget, wenn wir mit dem Knopf „h halbieren“ die Kantenlänge des Fensters halbieren?

Lösung: 4

Der Restterm fällt wie $\|\mathbf{h}\|^2$, also auf ein Viertel. Bei der Voreinstellung „Quadrieren“ ist das exakt so, bei den anderen krummen Abbildungen bis auf Terme höherer Ordnung.

Vertiefung: MML §5.3 (Jacobimatrix, Jacobi-Determinante als Flächenfaktor); MML §5.6 für Backpropagation und automatisches Differenzieren.

10.4 Ableitungen mit Matrizen

Zwei Felder der Tabelle aus Abschnitt 10.2 fehlen noch: Skalar zu Matrix und Matrix zu Skalar. Beide kommen in der Statistik ständig vor und brauchen kein neues Werkzeug: Wir leiten Eintrag für Eintrag ab und sortieren die Ergebnisse so, dass Definition 10.1.5 wieder in der gewohnten Gestalt dasteht. Der Aufwand liegt im Sortieren der Indizes, nicht in der Analysis.

Skalar zu Matrix

Hier hängt eine ganze Matrix an einer einzigen Zahl, etwa eine Kovarianzmatrix an einem Korrelationsparameter oder eine Modellmatrix an einer Bandbreite. Formal betrachten wir

$$F: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}, \quad F(x) = \begin{pmatrix} f_{11}(x) & \cdots & f_{1n}(x) \\ \vdots & \ddots & \vdots \\ f_{m1}(x) & \cdots & f_{mn}(x) \end{pmatrix}.$$

Jeder der $m \cdot n$ Einträge ist eine gewöhnliche Funktion einer reellen Variablen, also leiten wir jeden einzeln ab und lassen das Ergebnis an seinem Platz.

Definition 10.4.1 (Ableitung einer matrixwertigen Funktion nach einem Skalar)

Sei $F: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$ so, dass alle Einträge f_{ij} an der Stelle $x \in \mathbb{R}$ differenzierbar sind. Dann heißt

$$\frac{\partial F(x)}{\partial x} = \begin{pmatrix} \frac{\partial f_{11}(x)}{\partial x} & \cdots & \frac{\partial f_{1n}(x)}{\partial x} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_{m1}(x)}{\partial x} & \cdots & \frac{\partial f_{mn}(x)}{\partial x} \end{pmatrix} \in \mathbb{R}^{m \times n} \quad (10.4.1)$$

die Ableitung von F nach x . Es gilt dann

$$F(x+h) = F(x) + D_x F(h) + o(|h|) \quad \text{mit} \quad D_x F(h) = \frac{\partial F(x)}{\partial x} h. \quad (10.4.2)$$

Bemerkung 10.4.2 (Das Format bleibt erhalten)

Die Ableitung hat dieselbe Gestalt wie die Funktion. $F(x)$ und $\partial F(x)/\partial x$ liegen beide in $\mathbb{R}^{m \times n}$, die orange Matrix enthält aber Steigungen, die blaue Funktionswerte. Für $n = 1$ ist das der Fall Skalar zu Vektor, die Jacobimatrix mit einer einzigen Spalte aus Abschnitt 10.3.

Warum die Ableitung eine Matrix sein darf. Die Fréchet-Ableitung $D_x F: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$ ist linear mit eindimensionalem Definitionsbereich, also durch ihren Wert an der Stelle 1 festgelegt: $D_x F(h) = h \cdot D_x F(1)$. Dieser eine Wert ist die Matrix (10.4.1), so wie in Abschnitt 10.1 die Zahl $f'(x)$. Den matrixwertigen Restterm messen wir in einer beliebigen Matrixnorm; im Endlichdimensionalen sind alle Normen äquivalent.

Beispiel 10.4.3 (Übung: eine 2×3 -Matrixfunktion)

Sei

$$\mathbf{F}(x) = \begin{pmatrix} x^2 & 2e^x & 0 \\ 0 & x & \ln(x) \end{pmatrix}, \quad x > 0.$$

Die Einschränkung auf $x > 0$ kommt vom Logarithmus im letzten Eintrag. Was ist $\partial \mathbf{F}(x)/\partial x$? Erst selbst versuchen, dann die Lösung aufklappen.

Lösung

Sechsmal die Schulregeln anwenden und das Ergebnis an derselben Stelle notieren:

$$\frac{\partial \mathbf{F}(x)}{\partial x} = \begin{pmatrix} 2x & 2e^x & 0 \\ 0 & 1 & 1/x \end{pmatrix}.$$

Der konstante Eintrag 0 bleibt 0, und $2e^x$ steht unverändert da, weil die Exponentialfunktion ihre eigene Ableitung ist.

Kennzahlen von $\mathbf{F}$ ableiten

Oft wollen wir nicht $\mathbf{F}$ selbst ableiten, sondern eine Größe, die aus $\mathbf{F}$ gewonnen wird: die Spur, die Determinante oder die Inverse. Für alle drei gibt es geschlossene Formeln mit $\partial \mathbf{F}(x)/\partial x$. Alle drei Größen sind nur für quadratische Matrizen erklärt; ab hier setzen wir deshalb $\mathbf{F} : \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ voraus, nur Definition 10.4.1 selbst kommt mit beliebigen Formaten aus.

Satz 10.4.4 (Identitäten für Skalar zu Matrix)

Sei $\mathbf{F} : \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ an der Stelle x differenzierbar. Dann gilt

$$\frac{\partial \operatorname{tr}(\mathbf{F}(x))}{\partial x} = \operatorname{tr}\left(\frac{\partial \mathbf{F}(x)}{\partial x}\right), \quad (10.4.3)$$

und falls $\mathbf{F}(x)$ zusätzlich invertierbar ist, auch

$$\frac{\partial \det(\mathbf{F}(x))}{\partial x} = \det(\mathbf{F}(x)) \operatorname{tr}\left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x}\right] \quad (10.4.4)$$

sowie

$$\frac{\partial \mathbf{F}(x)^{-1}}{\partial x} = -\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \mathbf{F}(x)^{-1}. \quad (10.4.5)$$

Gleichung (10.4.4) heißt *Jacobi-Formel* (Jacobi's formula).

Beweis.

- (1) Wir beweisen die Spur-Identität (10.4.3); die beiden anderen Formeln übernehmen wir aus der Literatur (MML §5.5) und prüfen sie unten numerisch nach. Die Spur liest nur die Diagonale:

$$\operatorname{tr}(\mathbf{F}(x)) = \sum_{i=1}^n f_{ii}(x).$$

Definition 3.1.2 der Spur (Abschnitt 3.1): Summe der Diagonaleinträge

- (2) Die rechte Seite ist eine endliche Summe von Funktionen einer Variablen. Wir dürfen also gliedweise ableiten:

$$\frac{\partial}{\partial x} \operatorname{tr}(\mathbf{F}(x)) = \frac{\partial}{\partial x} \sum_{i=1}^n f_{ii}(x) = \sum_{i=1}^n \frac{\partial f_{ii}(x)}{\partial x}.$$

die Ableitung einer endlichen Summe ist die Summe der Ableitungen; jedes f_{ii} ist nach Voraussetzung differenzierbar

- (3) Rechts steht nun die Summe der Diagonaleinträge derjenigen Matrix, die in (10.4.1) definiert wurde, also

$$\sum_{i=1}^n \frac{\partial f_{ii}(x)}{\partial x} = \operatorname{tr} \left(\frac{\partial \mathbf{F}(x)}{\partial x} \right).$$

der Eintrag (i, i) von $\partial \mathbf{F}(x) / \partial x$ ist gerade $\partial f_{ii}(x) / \partial x$

□

Hinter dem Beweis steckt ein Prinzip: Die Spur ist linear, und lineare Abbildungen vertauschen mit dem Ableiten. Determinante und Inverse sind nicht linear, und ihren Formeln (10.4.4) und (10.4.5) sehen wir an, dass dort mehr passiert.

Vertiefung (optional): Die Jacobi-Formel an einem Diagonalbeispiel nachgerechnet

Beispiel 10.4.5 (Die Jacobi-Formel an einem Diagonalbeispiel)

Sei

$$\mathbf{F}(x) = \begin{pmatrix} x & 0 \\ 0 & 2x \end{pmatrix}.$$

Direkt. Die Determinante einer Diagonalmatrix ist das Produkt der Diagonaleinträge, also

$$\det(\mathbf{F}(x)) = x \cdot 2x = 2x^2 \implies \frac{\partial}{\partial x} \det(\mathbf{F}(x)) = 4x.$$

Über die Jacobi-Formel. Wir brauchen die beiden Zutaten

$$\frac{\partial \mathbf{F}(x)}{\partial x} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad \mathbf{F}(x)^{-1} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix} \quad (x \neq 0),$$

und multiplizieren sie:

$$\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/x \end{pmatrix}.$$

Die Spur dieses Produkts ist $1/x + 1/x = 2/x$, und (10.4.4) liefert

$$\det(\mathbf{F}(x)) \cdot \operatorname{tr} \left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \right] = 2x^2 \cdot \frac{2}{x} = 4x.$$

Beide Wege stimmen überein. Die Spur auf der rechten Seite ist notwendig: Ohne sie stünde dort ein Produkt aus einer Zahl und einer Matrix, also gar keine Zahl, während links die Ableitung einer skalaren Größe steht. Außerdem verlangt die Jacobi-Formel $x \neq 0$, während die direkte Rechnung auch bei $x = 0$ durchläuft und dort 0 liefert. Die Invertierbarkeit in Satz 10.4.4 ist also eine Voraussetzung der Formel, keine Bedingung dafür, dass die Ableitung existiert.

Bemerkung 10.4.6 (Warum das in der Statistik gebraucht wird)

Die Log-Dichte eines multivariaten Normalmodells enthält die Kovarianzmatrix $\Sigma(\theta)$ gleich zweimal: einmal als $\log \det(\Sigma(\theta))$ und einmal als $\Sigma(\theta)^{-1}$ in der quadratischen Form. Wer die Score-Funktion aufstellen will, also die Ableitung der Log-Likelihood nach θ , braucht deshalb (10.4.4) und (10.4.5). Aus der Jacobi-Formel wird mit der Kettenregel

$$\frac{\partial \log \det(\Sigma(\theta))}{\partial \theta} = \text{tr} \left[\Sigma(\theta)^{-1} \frac{\partial \Sigma(\theta)}{\partial \theta} \right],$$

denn die äußere Ableitung des Logarithmus liefert den Faktor $1/\det(\Sigma)$, und der kürzt sich gegen das $\det(\Sigma)$ aus (10.4.4).

Zur Probe werten wir F numerisch an $x \pm 10^{-5}$ aus und stellen den Differenzenquotienten neben den Formelwert.

Interaktiv: Die drei Identitäten im numerischen Vergleich

Die numerische Spalte kennt keine der Formeln, die Formelspalte rechnet mit Satz 10.4.4. Drei Beispiele stehen zur Wahl: die Diagonalmatrix $F(x) = \text{diag}(x, 2x)$, eine Matrix, in der jeder Eintrag anders von x abhängt (einer gar nicht), und eine Drehmatrix.

Interaktives Element — nur in der Web-Fassung

Alle drei Identitäten halten über den ganzen Reglerbereich; die größte Abweichung liegt unter 10^{-9} und ist der Abbruchfehler des Differenzenquotienten. Die Drehmatrix hat die konstante Determinante 1, also muss $\text{tr}[F^{-1} \partial F / \partial x]$ verschwinden. Bei der Diagonalmatrix zeigt der Schieber die Lücke bei $x = 0$: Dort ist F singulär, Determinanten- und Inversenformel setzen F^{-1} voraus, die Spur-Identität gilt auch dort.

Matrix zu Skalar

Jetzt drehen wir die Richtung um: Eine Verlustfunktion bewertet eine ganze Matrix, etwa die Gewichtsmatrix einer Netzschicht oder die Kovarianzmatrix eines Modells, mit einer einzigen Zahl. Wir wollen wissen, wie sich der Wert ändert, wenn wir an einem einzelnen Eintrag drehen, und so lautet auch die Definition.

Definition 10.4.7 (Ableitung nach einer Matrix)

Sei $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ an der Stelle $X = (x_{ij}) \in \mathbb{R}^{m \times n}$ Fréchet-differenzierbar. Dann existieren alle partiellen Ableitungen nach den Einträgen von X , und die Matrix

$$\frac{\partial f(X)}{\partial X} = \begin{pmatrix} \partial f(X)/\partial x_{11} & \cdots & \partial f(X)/\partial x_{1n} \\ \vdots & \ddots & \vdots \\ \partial f(X)/\partial x_{m1} & \cdots & \partial f(X)/\partial x_{mn} \end{pmatrix} \in \mathbb{R}^{m \times n} \quad (10.4.6)$$

heißt die *Ableitung von f nach X* oder *Gradientenmatrix*. Sie stellt die Fréchet-Ableitung dar:

$$f(X + H) = f(X) + D_X f(H) + o(\|H\|) \quad \text{mit} \quad D_X f(H) = \text{tr} \left(\left(\frac{\partial f(X)}{\partial X} \right)^\top H \right). \quad (10.4.7)$$

Bemerkung 10.4.8 (Der Ableitungsterm ist ein Skalarprodukt)

Die Spur in (10.4.7) ist ein Skalarprodukt in anderer Schreibweise. Für zwei Matrizen $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$ gilt

$$\operatorname{tr}(\mathbf{A}^\top \mathbf{B}) = \sum_{i=1}^m \sum_{j=1}^n a_{ij} b_{ij}, \quad (10.4.8)$$

und rechts steht das Skalarprodukt der beiden Matrizen, wenn wir sie als lange Vektoren der Länge $m \cdot n$ lesen. Es heißt *Frobenius-Skalarprodukt*. Damit lesen wir (10.4.7) so:

$$D_{\mathbf{X}} f(\mathbf{H}) = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial f(\mathbf{X})}{\partial x_{ij}} h_{ij}.$$

Der Ableitungsterm summiert also über alle Einträge das Produkt aus Steigung und Auslenkung, wie das Skalarprodukt $\nabla f(\mathbf{x}) \mathbf{h}$ beim Gradienten in Abschnitt 10.2, nur mit zwei Indexrichtungen. Setzen wir speziell $\mathbf{H} = h \cdot \mathbf{E}_{ij}$, wobei $\mathbf{E}_{ij}$ die Matrix mit einer 1 an der Stelle (i, j) und sonst lauter Nullen ist, so bleibt von der Summe nur $h \cdot \partial f(\mathbf{X}) / \partial x_{ij}$ übrig. Das rechtfertigt, die Ableitung eintragsweise zu definieren.

Beispiel 10.4.9 (Ableitung von $f(\mathbf{X}) = \mathbf{a}^\top \mathbf{X} \mathbf{b}$)

Seien $\mathbf{a} \in \mathbb{R}^m$ und $\mathbf{b} \in \mathbb{R}^n$ fest und $f(\mathbf{X}) = \mathbf{a}^\top \mathbf{X} \mathbf{b}$. Schreiben wir das Produkt aus, so steht dort eine Doppelsumme:

$$f(\mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_i x_{ij} b_j \implies \frac{\partial f(\mathbf{X})}{\partial x_{ij}} = a_i b_j.$$

In der Doppelsumme kommt x_{ij} genau einmal vor, und zwar mit dem Vorfaktor $a_i b_j$; alle anderen Summanden sind bezüglich x_{ij} konstant. Sortieren wir die Ergebnisse zurück in eine Matrix, erkennen wir ein äußeres Produkt:

$$\frac{\partial \mathbf{a}^\top \mathbf{X} \mathbf{b}}{\partial \mathbf{X}} = \begin{pmatrix} a_1 b_1 & \cdots & a_1 b_n \\ \vdots & \ddots & \vdots \\ a_m b_1 & \cdots & a_m b_n \end{pmatrix} = \mathbf{a} \mathbf{b}^\top. \quad (10.4.9)$$

Setzen wir das in (10.4.7) ein, so lässt sich die Spur wieder auflösen:

$$D_{\mathbf{X}} f(\mathbf{H}) = \operatorname{tr}((\mathbf{a} \mathbf{b}^\top)^\top \mathbf{H}) = \operatorname{tr}(\mathbf{b} \mathbf{a}^\top \mathbf{H}) = \mathbf{a}^\top \mathbf{H} \mathbf{b}.$$

Im letzten Schritt steckt die zyklische Vertauschung aus Satz 3.1.4: $\mathbf{a}^\top \mathbf{H} \mathbf{b}$ ist eine 1×1 -Matrix und damit gleich ihrer eigenen Spur. Die Probe ist nun leicht, denn f ist linear in $\mathbf{X}$:

$$f(\mathbf{X} + \mathbf{H}) = \mathbf{a}^\top \mathbf{X} \mathbf{b} + \mathbf{a}^\top \mathbf{H} \mathbf{b} = f(\mathbf{X}) + D_{\mathbf{X}} f(\mathbf{H}).$$

Der Restterm ist hier exakt null, wie bei jeder linearen Funktion: Ihre beste lineare Näherung ist sie selbst.

Identitäten zum Nachschlagen

Satz 10.4.10 (Identitäten für Matrix zu Skalar)

Sei $\mathbf{X} \in \mathbb{R}^{m \times n}$.

1. *Quadratische Form.* Für $\mathbf{A} \in \mathbb{R}^{n \times n}$ und $f(\mathbf{X}) = \text{tr}(\mathbf{XAX}^\top)$ gilt

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{X}(\mathbf{A} + \mathbf{A}^\top), \quad (10.4.10)$$

für symmetrisches $\mathbf{A}$ also $2\mathbf{XA}$.

2. *Spur-Produkt.* Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $f(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$ gilt

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{A}. \quad (10.4.11)$$

3. *Frobenius-Norm.* Für $f(\mathbf{X}) = \|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X})$ gilt

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = 2\mathbf{X}. \quad (10.4.12)$$

Vertiefung (optional): Woher die drei Identitäten kommen

Alle drei Formeln lassen sich als Muster lesen. Hinter (10.4.11) steckt nichts weiter als (10.4.8): Dort ist f das Frobenius-Skalarprodukt von $\mathbf{A}$ mit $\mathbf{X}$, und die Ableitung ist der Partner $\mathbf{A}$ selbst. Das ist die Matrixfassung von $\partial(\mathbf{a}^\top \mathbf{x})/\partial \mathbf{x} = \mathbf{a}^\top$ aus Beispiel 10.2.7. In (10.4.10) steht $\mathbf{X}$ einmal links und einmal rechts von $\mathbf{A}$. Ausgeschrieben ist $\text{tr}(\mathbf{XAX}^\top) = \sum_{i,j,k} x_{ij} a_{jk} x_{ik}$, und beim Ableiten nach x_{pq} liefert die Produktregel zwei Beiträge: aus dem linken Vorkommen wird $[\mathbf{XA}^\top]_{pq}$, aus dem rechten $[\mathbf{XA}]_{pq}$. Zusammen ist das $\mathbf{X}(\mathbf{A} + \mathbf{A}^\top)$. Und (10.4.12) ist der Spezialfall $\mathbf{A} = \mathbf{I}$ von (10.4.10), denn $\text{tr}(\mathbf{XIX}^\top) = \text{tr}(\mathbf{XX}^\top) = \|\mathbf{X}\|_F^2$ und $\mathbf{X}(\mathbf{I} + \mathbf{I}) = 2\mathbf{X}$. Das ist die Matrixfassung von $\partial x^2 / \partial x = 2x$.

Beispiel 10.4.11 (Probe der Frobenius-Identität)

Für (10.4.12) brauchen wir keine Matrixrechnung. Nach Definition der Frobenius-Norm ist

$$f(\mathbf{X}) = \|\mathbf{X}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n x_{ij}^2,$$

und in dieser Summe kommt x_{ij} genau einmal vor, nämlich quadriert. Also

$$\frac{\partial f(\mathbf{X})}{\partial x_{ij}} = 2x_{ij} \implies \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = 2\mathbf{X}.$$

Anders als in Beispiel 10.4.9 ist der Restterm hier nicht null. Ausmultiplizieren liefert

$$f(\mathbf{X} + \mathbf{H}) = \sum_{i,j} (x_{ij} + h_{ij})^2 = f(\mathbf{X}) + 2\text{tr}(\mathbf{X}^\top \mathbf{H}) + \|\mathbf{H}\|_F^2,$$

und der mittlere Term ist wegen $\text{tr}((2\mathbf{X})^\top \mathbf{H}) = 2\text{tr}(\mathbf{X}^\top \mathbf{H})$ gerade $D_{\mathbf{X}} f(\mathbf{H})$. Übrig bleibt $r(\mathbf{H}) = \|\mathbf{H}\|_F^2$, und dieser Ausdruck verschwindet im Verhältnis zu $\|\mathbf{H}\|_F$ wie verlangt.

Was sagt ein einzelner Eintrag der Gradientenmatrix aus? Lenken wir nur in Richtung $\mathbf{E}_{ij}$ aus, so schrumpft nach Bemerkung 10.4.8 die Summe über alle Einträge auf einen einzigen Summanden.

Interaktiv: Auslenkung in Richtung einer einzelnen Koordinate

Wir fassen eine Zeile von $\mathbf{X}$ an und ziehen sie um h nach oben oder unten. Das Widget wertet f an der so veränderten Matrix aus und stellt die tatsächliche Änderung neben $h \cdot \partial f(\mathbf{X}) / \partial x_{ij}$; die Zeile darunter trennt sie in den grünen Ableitungsterm und den roten Rest.

Interaktives Element — nur in der Web-Fassung

Der Eintrag (i, j) der Gradientenmatrix ist die Rate, mit der f auf einen Stups an dieser Stelle reagiert. Für die beiden in $\mathbf{X}$ linearen Funktionen bleibt der Rest exakt null. Bei $\|\mathbf{X}\|_F^2$ ist der Rest exakt h^2 : von null verschieden, aber schneller fallend als h , also $\mathcal{O}(h^2)$.

Vertiefung (optional): Anwendung: Matrixzerlegung und Matrix Completion

Zum Schluss ein Problem, das der Fall Matrix zu Skalar vollständig abdeckt. Gegeben sei eine Matrix $\mathbf{Y} \in \mathbb{R}^{m \times n}$, von der wir nur die Einträge an den Positionen einer Indexmenge Ω kennen. Das klassische Beispiel sind Bewertungen von Filmen: Die Zeilen sind Nutzer, die Spalten Filme, und die allermeisten Felder der Tabelle sind leer, weil niemand alle Filme sieht.

Die Hoffnung ist, dass die Tabelle in Wahrheit einfach gebaut ist. Wenige Geschmacksrichtungen erklären die meisten Bewertungen, die Matrix ist also näherungsweise von kleinem Rang. Wir suchen deshalb eine Rang- k -Approximation

$$\mathbf{Y} \approx \mathbf{U}\mathbf{V}^T, \quad \mathbf{U} \in \mathbb{R}^{m \times k}, \quad \mathbf{V} \in \mathbb{R}^{n \times k},$$

mit $k \ll \min(m, n)$. Statt $m \cdot n$ Zahlen sind dann nur noch $k(m + n)$ zu bestimmen, und die Lücken lesen wir am Produkt $\mathbf{U}\mathbf{V}^T$ einfach ab.

Niedriger Rang allein garantiert allerdings noch keine eindeutige Ergänzung. Auch Zahl und Lage der beobachteten Einträge müssen genügend Information über Zeilen- und Spaltenstruktur liefern; in Anwendungen kommen deshalb Annahmen an das Beobachtungsmuster und häufig Regularisierung hinzu. Das folgende Verfahren liefert Vorhersagen unter dem gewählten Rangmodell, nicht automatisch die einzig möglichen fehlenden Werte.

Bei vollständig beobachtetem $\mathbf{Y}$ wäre das Problem gelöst: Nach dem Satz von Eckart und Young (Abschnitt 6.4) liefert die abgeschnittene Singulärwertzerlegung die beste Rang- k -Approximation. Bei fehlenden Einträgen geht das nicht, denn die Zerlegung braucht die ganze Matrix. Also formulieren wir eine Verlustfunktion, die nur die beobachteten Felder bewertet, und minimieren sie numerisch:

$$L(\mathbf{U}, \mathbf{V}) = \frac{1}{2} \sum_{(i,j) \in \Omega} \left(y_{ij} - [\mathbf{U}\mathbf{V}^T]_{ij} \right)^2 = \frac{1}{2} \|\mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{U}\mathbf{V}^T)\|_F^2, \quad \mathbf{P}_\Omega = [\mathbb{1}_{(i,j) \in \Omega}]. \quad (10.4.13)$$

Dabei ist $\mathbf{P}_\Omega \in \mathbb{R}^{m \times n}$ die Maskenmatrix mit einer 1 an jeder beobachteten und einer 0 an jeder fehlenden Position, und $\odot$ bezeichnet das *elementweise Produkt* (Hadamard-Produkt), also $(\mathbf{A} \odot \mathbf{B})_{ij} = a_{ij} b_{ij}$. Die Maske blendet damit alle unbeobachteten Abweichungen aus, bevor die Frobenius-Norm sie aufsummieren kann. Ein gewöhnliches Matrixprodukt kann hier nicht gemeint sein, denn $\mathbf{P}_\Omega$ und $\mathbf{Y} - \mathbf{U}\mathbf{V}^T$ sind beide $m \times n$.

Für die Optimierung brauchen wir die Ableitungen von L nach den beiden Faktormatrizen, und das ist der Fall Matrix zu Skalar.

Satz 10.4.12 (Gradienten der Completion-Verlustfunktion)

Mit $\mathbf{R} := \mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{U}\mathbf{V}^T)$ gilt für L aus (10.4.13)

$$\frac{\partial L}{\partial \mathbf{U}} = -\mathbf{R}\mathbf{V} \in \mathbb{R}^{m \times k}, \quad \frac{\partial L}{\partial \mathbf{V}} = -\mathbf{R}^T \mathbf{U} \in \mathbb{R}^{n \times k}. \quad (10.4.14)$$

Beweis.

- (1) Nach (10.4.6) ist die Ableitung eintragsweise erklärt, also rechnen wir eintragsweise. Mit $r_{ij} = p_{ij}(y_{ij} - \sum_{s=1}^k u_{is}v_{js})$ und $p_{ij} \in \{0, 1\}$ ist

$$L(\mathbf{U}, \mathbf{V}) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n r_{ij}^2.$$

die Maske p_{ij} setzt alle unbeobachteten Summanden auf null, die Summe über Ω wird dadurch zur Summe über alle Positionen

- (2) Nun leiten wir nach einem einzelnen Eintrag u_{ab} ab. Der Eintrag u_{ab} taucht nur in den Residuen der Zeile a auf, und dort mit $\partial r_{aj} / \partial u_{ab} = -p_{aj}v_{jb}$. Die Kettenregel liefert

$$\frac{\partial L}{\partial u_{ab}} = \sum_{j=1}^n r_{aj} \frac{\partial r_{aj}}{\partial u_{ab}} = - \sum_{j=1}^n p_{aj} r_{aj} v_{jb} = - \sum_{j=1}^n r_{aj} v_{jb} = -[\mathbf{R}\mathbf{V}]_{ab}.$$

im vorletzten Schritt fällt die Maske weg, weil r_{aj} den Faktor p_{aj} bereits enthält und $p_{aj}^2 = p_{aj}$ für $p_{aj} \in \{0, 1\}$ gilt

- (3) Für $\mathbf{V}$ läuft die Rechnung genauso, nur über die Spalten. Der Eintrag v_{ab} steckt in den Residuen der Spalte a , mit $\partial r_{ia} / \partial v_{ab} = -p_{ia}u_{ib}$, also

$$\frac{\partial L}{\partial v_{ab}} = \sum_{i=1}^m r_{ia} (-p_{ia}u_{ib}) = - \sum_{i=1}^m r_{ia} u_{ib} = -[\mathbf{R}^\top \mathbf{U}]_{ab}.$$

$\sum_i r_{ia} u_{ib}$ ist das Skalarprodukt der a -ten Spalte von $\mathbf{R}$ mit der b -ten Spalte von $\mathbf{U}$, also der Eintrag (a, b) von $\mathbf{R}^\top \mathbf{U}$

□

Damit steht dem Gradientenabstieg aus Abschnitt 10.2 nichts mehr im Weg. Wir behandeln $\mathbf{U}$ und $\mathbf{V}$ als ein gemeinsames Parameterpaket und gehen in beiden zugleich einen Schritt gegen den Gradienten.

Algorithmus 10.4.13 (Gradientenabstieg für Matrix Completion)

Eingabe: beobachtete Werte $\mathbf{Y}$ auf Ω , Maske $\mathbf{P}_\Omega$, Rang k , Lernrate $\alpha > 0$, Startwerte $\mathbf{U}^{(0)}, \mathbf{V}^{(0)}$.

Für $t = 0, 1, 2, \dots$:

1. Residuum auf den beobachteten Feldern: $\mathbf{R}^{(t)} = \mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{U}^{(t)}\mathbf{V}^{(t)\top})$.
2. Faktoren aktualisieren:

$$\mathbf{U}^{(t+1)} = \mathbf{U}^{(t)} + \alpha \mathbf{R}^{(t)} \mathbf{V}^{(t)}, \quad \mathbf{V}^{(t+1)} = \mathbf{V}^{(t)} + \alpha \mathbf{R}^{(t)\top} \mathbf{U}^{(t)}.$$

3. Abbruch, sobald sich L kaum noch ändert oder eine Schrittzahl erreicht ist.

Ausgabe: $\hat{\mathbf{Y}} = \mathbf{U}\mathbf{V}^\top$; an den Positionen außerhalb von Ω stehen die vom Rangmodell und vom Optimierungslauf gelieferten Vorhersagen.

Das Pluszeichen in Schritt 2 ist kein Tippfehler: Wir gehen gegen den Gradienten, und der trägt nach (10.4.14) bereits ein Minus. Dazu zwei Vorbehalte. L ist in $(\mathbf{U}, \mathbf{V})$ nicht konvex, das Produkt $\mathbf{U}\mathbf{V}^\top$ ist ja quadratisch in den Unbekannten. Gradientenabstieg hat deshalb keine allgemeine Garantie für ein globales Minimum: Je nach Startpunkt und Lernrate kann er zu einem lokalen oder globalen Minimum beziehungsweise einem anderen stationären Punkt konvergieren, oszillieren oder divergieren. Außerdem ist die Zerlegung nie eindeutig, denn für jede invertierbare $\mathbf{T} \in \mathbb{R}^{k \times k}$ ist $(\mathbf{U}\mathbf{T})(\mathbf{V}\mathbf{T}^{-\top})^\top = \mathbf{U}\mathbf{V}^\top$. Für die Vorhersage stört das nicht, wohl aber für jede Interpretation der Spalten von $\mathbf{U}$ und $\mathbf{V}$.

Anwendungen dieses Musters gibt es reichlich: Imputation fehlender Werte, Empfehlungssysteme und kollaboratives Filtern arbeiten alle nach demselben Rezept.

Damit stellt sich die Frage, die über den praktischen Wert des Verfahrens entscheidet: Wenn zwei Modelle den Verlust auf den beobachteten Einträgen beide auf null drücken, sagen sie dann auch dasselbe für die Lücken voraus?

Interaktiv: Matrix Completion an einer 2×3-Matrix

Vier von sechs Einträgen sind beobachtet, zwei sind Lücken. Das Widget führt Algorithmus 10.4.13 für $k = 1$ und $k = 2$ nebeneinander aus, mit derselben Lernrate, und zeigt alle Zwischengrößen: das Residuum $P_Q \odot (Y - UV^T)$ in Rot, die beiden Gradienten in Orange und die Vorhersagen für die Lücken in Grün.

Interaktives Element — nur in der Web-Fassung

Der Verlust fällt bei beiden Rängen auf null, die grünen Vorhersagen für die beiden Lücken laufen aber auseinander. Bei $k = 2$ treffen zehn Parameter auf vier Beobachtungen; wohin die Vorhersage läuft, entscheidet dann der Startpunkt. Größerer Rang heißt also nicht bessere Rekonstruktion. Und wer die Lernrate hochschiebt, sieht ab etwa $\alpha = 0,14$ ein Pendeln des Verlusts und jenseits von etwa $\alpha = 0,25$ divergierende Einträge.

1. Bei der Matrix Completion liefert ein größeres k stets eine bessere Rekonstruktion der unbeobachteten Einträge.

Antwort: Falsch

Ein größeres k senkt den Verlust auf den beobachteten Feldern, über die Lücken sagt es dagegen nichts. Im Widget passt $k = 2$ die vier Beobachtungen mit zehn Parametern exakt an, und die beiden Vorhersagen hängen dann nur noch am Startpunkt. Deshalb steht am Anfang die Annahme, dass die gesuchte Matrix kleinen Rang hat.

2. Im Completion-Widget: Wir lassen beide Modelle mit $\alpha = 0,05$ so lange laufen, bis der Verlust bei beiden praktisch null ist. Welchen Wert sagt das Rang-2-Modell für die Lücke y_{13} voraus?

Lösung: 1,583

1,583, während das Rang-1-Modell 2,5 vorhersagt. Beide erreichen denselben Verlust null auf den vier beobachteten Einträgen; über die Lücken sagt der Verlust nichts.

Selbsttest

1. Für $F: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$ hat die Ableitung $\partial F(x)/\partial x$ dasselbe Format $m \times n$ wie $F(x)$ selbst.

Antwort: Wahr

Das ist Definition 10.4.1: Jeder Eintrag wird für sich abgeleitet und bleibt an seinem Platz. Verwechseln dürfen wir die beiden Matrizen trotzdem nicht, die eine enthält Werte, die andere Steigungen (Bemerkung 10.4.2).

2. Die Identität $\partial \text{tr}(F(x))/\partial x = \text{tr}(\partial F(x)/\partial x)$ gilt für jede Matrixfunktion $F: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$.

Antwort: Falsch

Die Spur ist nur für quadratische Matrizen erklärt, die Aussage braucht also $m = n$. Deshalb setzt Satz 10.4.4 $F: \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ voraus, während Definition 10.4.1 noch mit beliebigen Formaten auskommt.

3. Ist $\det(F(x)) = 1$ für alle x , so gilt $\text{tr}[F(x)^{-1} \partial F(x)/\partial x] = 0$.

Antwort: Wahr

Die linke Seite der Jacobi-Formel (10.4.4) ist die Ableitung einer konstanten Funktion, also null. Rechts steht das Produkt aus $\det(F(x)) = 1$ und der Spur, und ein Produkt mit Faktor 1 verschwindet nur, wenn der andere Faktor verschwindet. Die Drehmatrix im ersten Widget führt das vor.

4. Für $f : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ ist der Ableitungsterm das Matrixprodukt $D_{\mathbf{X}}f(\mathbf{H}) = (\partial f(\mathbf{X})/\partial \mathbf{X})\mathbf{H}$.

Antwort: Falsch

Richtig ist $D_{\mathbf{X}}f(\mathbf{H}) = \text{tr}((\partial f(\mathbf{X})/\partial \mathbf{X})^T \mathbf{H})$ nach (10.4.7). Das angegebene Produkt wäre für $m \neq n$ nicht einmal definiert, denn beide Faktoren haben das Format $m \times n$; und das Ergebnis müsste eine Zahl sein, keine Matrix.

5. Für $f(\mathbf{X}) = \text{tr}(\mathbf{A}^T \mathbf{X})$ ist $\partial f(\mathbf{X})/\partial \mathbf{X} = \mathbf{A}$, und der Restterm in (10.4.7) ist exakt null.

Antwort: Wahr

Die Formel steht als (10.4.11) in Satz 10.4.10. Nach (10.4.8) ist f die Summe $\sum_{ij} a_{ij}x_{ij}$ und damit linear in $\mathbf{X}$, also ist die lineare Näherung exakt. Das zweite Widget zeigt denselben Effekt für die Funktion $\mathbf{a}^T \mathbf{X} \mathbf{b}$ aus (10.4.9).

6. Im Anstups-Widget: Wir wählen $f(\mathbf{X}) = \|\mathbf{X}\|_F^2$ und stupsen einen Eintrag um $h = 0,4$ an. Wie groß ist der rote Restterm?

Lösung: 0,16

Exakt $h^2 = 0,16$, unabhängig davon, welchen Eintrag wir anfassen: Der quadratische Term in $(x_{ij} + h)^2 = x_{ij}^2 + 2x_{ij}h + h^2$ ist der ganze Rest.

Vertiefung: MML §5.4 (Ableitungen von Matrizen) und §5.5 (nützliche Identitäten für Gradienten).

10.5 Stetigkeit und Linearität

Woran wir anknüpfen

Ab hier geht es um das Rechnen mit der Ableitung: Welche Eigenschaften erbt eine differenzierbare Funktion, und wie leiten wir zusammengesetzte Ausdrücke ab, ohne jedes Mal zur Definition zurückzukehren? Ausgangspunkt für jeden Beweis ist die Fréchet-Ableitung (Definition 10.1.5): Für normierte Vektorräume $\mathbb{D}$ und $\mathbb{E}$ heißt $f : \mathbb{D} \rightarrow \mathbb{E}$ in $\mathbf{x} \in \mathbb{D}$ differenzierbar, wenn es eine beschränkte lineare Abbildung $D_{\mathbf{x}}f : \mathbb{D} \rightarrow \mathbb{E}$ und einen Rest $\mathbf{r}(\mathbf{h}) \in \mathbb{E}$ gibt mit

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + \mathbf{r}(\mathbf{h}), \quad \frac{\|\mathbf{r}(\mathbf{h})\|_{\mathbb{E}}}{\|\mathbf{h}\|_{\mathbb{D}}} \rightarrow 0 \quad \text{für } \mathbf{h} \rightarrow \mathbf{0}. \quad (10.5.1)$$

Aus der Analysis brauchen wir Produkt- und Kettenregel für Funktionen einer Variablen, höhere Ableitungen und die Taylorreihe, aus der linearen Algebra bilineare und multilineare Abbildungen samt Skalarprodukt $\langle \cdot, \cdot \rangle$ (Abschnitt 9.1), quadratische Formen $\mathbf{x}^T \mathbf{A} \mathbf{x}$ und die Komposition von Funktionen.

Dieser Abschnitt klärt zwei allgemeine Eigenschaften: Jede differenzierbare Funktion ist stetig, und die Ableitungsoperation selbst ist linear. Abschnitt 10.6 bringt Produkt- und Kettenregel in der allgemeinen Fassung, Abschnitt 10.7 die Ableitungen höheren Grades und Abschnitt 10.8 die Taylorapproximation.

Bemerkung 10.5.1 (Groß-O und klein-o für kleine Argumente)

In Abschnitt 10.1 haben wir $g(\mathbf{h}) = o(\|\mathbf{h}\|)$ so gelesen: Der Quotient $\|g(\mathbf{h})\| / \|\mathbf{h}\|$ geht gegen null, der Term verschwindet also schneller als $\|\mathbf{h}\|$ selbst. Der nächste Beweis braucht zusätzlich das große O, ebenfalls für kleine statt für große Argumente. Wir schreiben $g(\mathbf{h}) = O(\|\mathbf{h}\|)$, wenn es Konstanten $C < \infty$ und $\delta > 0$ gibt mit

$$\|g(\mathbf{h})\| \leq C \|\mathbf{h}\| \quad \text{für alle } \mathbf{h} \text{ mit } \|\mathbf{h}\| < \delta.$$

Ein O -Term darf also von derselben Größenordnung sein wie $\|\mathbf{h}\|$, er muss nur mitschrumpfen. Jeder o -Term ist damit automatisch ein O -Term: Strebt der Quotient gegen null, so liegt er für hinreichend kleine $\mathbf{h}$ unter 1, und das ist die Schranke mit $C = 1$. Umgekehrt geht es nicht, denn $g(h) = h$ ist $O(|h|)$, aber nicht $o(|h|)$.

Differenzierbarkeit erzwingt Stetigkeit

Die lineare Approximation (10.5.1) schließt Sprünge aus: Eine Funktion, die sich in erster Ordnung linear approximieren lässt, kann an dieser Stelle nicht springen.

Satz 10.5.2 (Stetigkeit aus Differenzierbarkeit)

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Vektorräume und $f : \mathbb{D} \rightarrow \mathbb{E}$ in $\mathbf{x} \in \mathbb{D}$ differenzierbar. Dann ist f in $\mathbf{x}$ stetig.

Beweis.

- (1) Die Ableitung $D_{\mathbf{x}}f$ ist nach Definition beschränkt und linear. Es gibt also ein $M < \infty$ mit

$$\|D_{\mathbf{x}}f(\mathbf{h})\| \leq M \|\mathbf{h}\| \quad \text{für alle } \mathbf{h},$$

das heißt $D_{\mathbf{x}}f(\mathbf{h}) = O(\|\mathbf{h}\|)$.

Definition 10.1.5; nur hier geht die Beschränktheit ein, und in endlich-dimensionalen Räumen ist sie automatisch erfüllt (Bemerkung 10.1.6)

- (2) Der Restterm $r(\mathbf{h}) := f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) - D_{\mathbf{x}}f(\mathbf{h})$ ist $o(\|\mathbf{h}\|)$. Es gibt also ein $\delta > 0$, sodass er für $\|\mathbf{h}\| < \delta$ höchstens $\|\mathbf{h}\|$ lang ist. Für diese $\mathbf{h}$ gilt

$$\|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x})\| = \|D_{\mathbf{x}}f(\mathbf{h}) + r(\mathbf{h})\| \leq M \|\mathbf{h}\| + \|\mathbf{h}\| = (M + 1) \|\mathbf{h}\|,$$

kurz $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + O(\|\mathbf{h}\|)$.

der Quotient $\|r(\mathbf{h})\| / \|\mathbf{h}\|$ strebt gegen null, liegt also ab einem δ unter 1 (Bemerkung 10.5.1); dann die Dreiecksungleichung und Schritt 1

- (3) Die rechte Seite geht für $\|\mathbf{h}\| \rightarrow 0$ gegen null, also auch die linke. Das heißt $f(\mathbf{x} + \mathbf{h}) \rightarrow f(\mathbf{x})$, und das ist die Stetigkeit von f in $\mathbf{x}$.

Stetigkeit in $\mathbf{x}$ bedeutet gerade, dass die Funktionswerte in der Nähe von $\mathbf{x}$ gegen $f(\mathbf{x})$ streben

□

Stetig, aber nicht differenzierbar

Satz 10.5.2 hat eine Richtung. Die andere ist falsch, und das Gegenbeispiel ist der Betrag.

Beispiel 10.5.3 (Die Betragsfunktion am Nullpunkt)

Sei $f : \mathbb{R} \rightarrow \mathbb{R}$ mit $f(x) = |x|$, betrachte an der Stelle $x = 0$.

Stetig ist f dort. Für $h \rightarrow 0$ gilt $f(0 + h) = |h| \rightarrow 0 = f(0)$. ▢

Differenzierbar ist f dort nicht. Diesen Knick haben wir in Abschnitt 10.1 schon untersucht: Der Differenzenquotient ist für jedes $h > 0$ exakt $+1$ und für jedes $h < 0$ exakt -1 (Bemerkung 10.1.2). Beide einseitigen Grenzwerte existieren also, sie sind nur verschieden, während Definition 10.1.1 einen einzigen Wert für beide Seiten verlangt. Damit existiert $f'(0)$ nicht, und an den Knick lässt sich keine eindeutige Tangente anlegen.

Bemerkung 10.5.4 (Die Merkregel und ihre Kontraposition)

Satz 10.5.2 und Beispiel 10.5.3 zusammen ergeben

$$\text{differenzierbar in } x \implies \text{stetig in } x, \quad \text{stetig in } x \not\implies \text{differenzierbar in } x.$$

Stetigkeit ist für Differenzierbarkeit also notwendig, aber nicht hinreichend. In der Praxis benutzen wir meist die Kontraposition der ersten Zeile: Wo eine Funktion springt, brauchen wir gar nicht erst nach einer Ableitung zu suchen. Umgekehrt beweist ein Graph ohne Sprünge noch keine Differenzierbarkeit, denn Knicke sind mit Stetigkeit verträglich.

Interaktives Element — nur in der Web-Fassung

Die beiden Aussagen als Bild, an der Stelle $x_0 = 0$: Der grüne Bereich (differenzierbar) liegt vollständig im blauen (stetig), das ist Satz 10.5.2. Im Ring dazwischen liegt die Betragsfunktion aus Beispiel 10.5.3, und weil er nicht leer ist, gilt die Umkehrung nicht; ganz außen steht die Sprungfunktion H , die in 0 nicht einmal stetig ist.

Lässt sich f in x bis auf einen Rest $o(\|h\|)$ durch eine lineare Abbildung ersetzen, so muss der Graph unter einer starken Lupe aussehen wie eine Gerade. Bei welcher der drei Funktionen im Widget passiert das?

Interaktiv: Lokale Linearität unter der Lupe

Wir ziehen ein quadratisches Fenster um x_0 zusammen, beide Achsen gleich stark, also ein echter Zoom. Gemessen wird, wie weit die Kurve im Fenster von der Geraden durch die beiden Fensterränder abweicht.

Interaktives Element — nur in der Web-Fassung

Nur bei einer der drei Funktionen fällt die Abweichung an der Stelle 0 mit jeder Halbierung des Fensters, wie es der Rest $o(\|h\|)$ verlangt. Die anderen beiden zeigen zwei Bauformen von Nichtdifferenzierbarkeit, und keine verträgt sich mit einer Geraden. Verschieben wir x_0 von der 0 weg, so wird auch der Betrag lokal linear: Die Ausnahme liegt an der Stelle, nicht an der Funktion.

Die Ableitung ist linear

Die zweite allgemeine Eigenschaft betrifft nicht eine einzelne Funktion, sondern die Zuordnung $f \mapsto D_x f$ selbst. Sie ist verträglich mit Summen und mit Vielfachen; deshalb dürfen wir Summen

von Bausteinen Summand für Summand ableiten.

Satz 10.5.5 (Linearität der Ableitungsoperation)

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Vektorräume und $f, g : \mathbb{D} \rightarrow \mathbb{E}$ in $\mathbf{x} \in \mathbb{D}$ differenzierbar. Dann ist für alle $c_1, c_2 \in \mathbb{R}$ auch $c_1 f + c_2 g$ in $\mathbf{x}$ differenzierbar, und es gilt

$$D_{\mathbf{x}}(c_1 f + c_2 g) = c_1 D_{\mathbf{x}} f + c_2 D_{\mathbf{x}} g. \quad (10.5.2)$$

Vertiefung (optional): Warum die Ableitungsoperation linear ist

Beweis.

- (1) Wir entwickeln beide Funktionen einzeln nach (10.5.1),

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) &= f(\mathbf{x}) + D_{\mathbf{x}} f(\mathbf{h}) + r_f(\mathbf{h}), \\ g(\mathbf{x} + \mathbf{h}) &= g(\mathbf{x}) + D_{\mathbf{x}} g(\mathbf{h}) + r_g(\mathbf{h}), \end{aligned}$$

mit $r_f(\mathbf{h}) = o(\|\mathbf{h}\|)$ und $r_g(\mathbf{h}) = o(\|\mathbf{h}\|)$.

Definition 10.1.5, einmal für f und einmal für g ; die beiden Restterme bekommen Namen, damit wir sie in Schritt 3 einzeln abschätzen können

- (2) Jetzt bilden wir die Linearkombination und sortieren die Terme nach Bauart:

$$\begin{aligned} (c_1 f + c_2 g)(\mathbf{x} + \mathbf{h}) &= c_1 [f(\mathbf{x}) + D_{\mathbf{x}} f(\mathbf{h}) + r_f(\mathbf{h})] + c_2 [g(\mathbf{x}) + D_{\mathbf{x}} g(\mathbf{h}) + r_g(\mathbf{h})] \\ &= (c_1 f + c_2 g)(\mathbf{x}) + (c_1 D_{\mathbf{x}} f + c_2 D_{\mathbf{x}} g)(\mathbf{h}) + (c_1 r_f(\mathbf{h}) + c_2 r_g(\mathbf{h})). \end{aligned}$$

nichts als Umsortieren: die Funktionswerte nach vorn, die in $\mathbf{h}$ linearen Terme in die Mitte, die Restterme nach hinten

- (3) Die Zerlegung hat die Gestalt von (10.5.1), sobald zwei Dinge stimmen. Der mittlere Term ist eine beschränkte lineare Abbildung in $\mathbf{h}$: Linearkombinationen linearer Abbildungen sind linear, und mit den Schranken M_f und M_g von $D_{\mathbf{x}} f$ und $D_{\mathbf{x}} g$ gilt

$$\|(c_1 D_{\mathbf{x}} f + c_2 D_{\mathbf{x}} g)(\mathbf{h})\| \leq (|c_1| M_f + |c_2| M_g) \|\mathbf{h}\|.$$

Und der hintere Term ist wieder $o(\|\mathbf{h}\|)$, denn

$$\frac{\|c_1 r_f(\mathbf{h}) + c_2 r_g(\mathbf{h})\|}{\|\mathbf{h}\|} \leq |c_1| \frac{\|r_f(\mathbf{h})\|}{\|\mathbf{h}\|} + |c_2| \frac{\|r_g(\mathbf{h})\|}{\|\mathbf{h}\|} \xrightarrow{\|\mathbf{h}\| \rightarrow 0} 0.$$

Dreiecksungleichung und Homogenität der Norm; eine endliche Linearkombination von $o(\|\mathbf{h}\|)$ -Termen ist wieder $o(\|\mathbf{h}\|)$

- (4) Damit erfüllt $c_1 D_{\mathbf{x}} f + c_2 D_{\mathbf{x}} g$ die Definition der Fréchet-Ableitung für $c_1 f + c_2 g$: Die Funktion ist in $\mathbf{x}$ differenzierbar, und die angegebene Abbildung leistet das Verlangte. Eine zweite kann es nicht geben. Erfüllen nämlich A und B beide (10.5.1), so ist $(A - B)(\mathbf{h}) = o(\|\mathbf{h}\|)$; setzen wir für festes $\mathbf{u} \neq \mathbf{0}$ nun $\mathbf{h} = t\mathbf{u}$ mit $t \rightarrow 0$ ein, so kürzt sich der Faktor $|t|$ heraus,

$$\frac{\|(A - B)(t\mathbf{u})\|}{\|t\mathbf{u}\|} = \frac{|t| \|(A - B)(\mathbf{u})\|}{|t| \|\mathbf{u}\|} = \frac{\|(A - B)(\mathbf{u})\|}{\|\mathbf{u}\|}.$$

Der Quotient hängt also gar nicht von t ab, muss aber gegen null streben und ist damit selbst null. Also stimmen A und B überein, und (10.5.2) gilt mit Gleichheitszeichen.

Eindeutigkeit der Fréchet-Ableitung; für Jacobimatrizen steht dasselbe Argument als Lemma 10.3.3 in Abschnitt 10.3

□

Der Kern dieses Beweises steckt in Schritt 3: Beide Zutaten der Definition, Linearität mit Beschränktheit und die Kleinheit des Restes, überstehen das Bilden von Linearkombinationen unbeschadet.

Was die Linearität in den einzelnen Formaten bedeutet

Bemerkung 10.5.6 (Fünf Spezialfälle derselben Aussage)

In den Spezialfällen der Abschnitte 10.2 bis 10.4 steckt die lineare Abbildung aus (10.5.2) jeweils in einem konkreten Objekt, und die Linearität überträgt sich auf dieses Objekt (überall $c_1, c_2 \in \mathbb{R}$ beliebig, alle Funktionen an der jeweiligen Stelle differenzierbar).

1. $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}$: die gewöhnliche Ableitung (Abschnitt 10.1).

$$(c_1 f + c_2 g)' = c_1 f' + c_2 g'$$

2. $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}$: der Gradient (Abschnitt 10.2).

$$\nabla [c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})] = c_1 \nabla f(\mathbf{x}) + c_2 \nabla g(\mathbf{x})$$

3. $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}^m$: die Jacobimatrix (Abschnitt 10.3).

$$\mathbf{J}_{c_1 f + c_2 g}(\mathbf{x}) = c_1 \mathbf{J}_f(\mathbf{x}) + c_2 \mathbf{J}_g(\mathbf{x})$$

4. $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}^{m \times n}$: eine matrixwertige Funktion eines Skalars (Definition 10.4.1 in Abschnitt 10.4).

$$\frac{\partial [c_1 F(x) + c_2 G(x)]}{\partial x} = c_1 \frac{\partial F(x)}{\partial x} + c_2 \frac{\partial G(x)}{\partial x}$$

5. $\mathbb{D} = \mathbb{R}^{m \times n}, \mathbb{E} = \mathbb{R}$: die Ableitung nach einer Matrix (Definition 10.4.7 in Abschnitt 10.4).

$$\frac{\partial [c_1 f(\mathbf{X}) + c_2 g(\mathbf{X})]}{\partial \mathbf{X}} = c_1 \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} + c_2 \frac{\partial g(\mathbf{X})}{\partial \mathbf{X}}$$

Die Ableitungsobjekte werden also eintragsweise addiert und mit Skalaren multipliziert; das wussten wir schon aus der Analysis, denn jeder Eintrag ist eine gewöhnliche oder eine partielle Ableitung. Der Gewinn von Satz 10.5.5: Er gilt in jedem normierten Raum, auch dort, wo es keine Einträge zum Nachrechnen gibt.

Beispiel 10.5.7 (Linearität an einem Zahlenbeispiel)

Gegeben sind $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$ und $g(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$ mit $\mathbf{a} = (1, 2)^\top$. Gesucht ist $\nabla h(\mathbf{x})$ für $h(\mathbf{x}) = 3f(\mathbf{x}) - 2g(\mathbf{x})$ an der Stelle $\mathbf{x} = (1, -1)^\top$. Der Buchstabe h ist hier ausnahmsweise ein Funktionsname, nicht der Zuwachs aus (10.5.1).

Schritt 1: die Gradienten der Bausteine. Ausgeschrieben ist $f(\mathbf{x}) = x_1^2 + x_2^2$, also

$$\nabla f(\mathbf{x}) = (2x_1, 2x_2) = 2\mathbf{x}^\top.$$

Das ist Satz 10.2.8 mit $\mathbf{A} = \mathbf{I}$. Für $g(\mathbf{x}) = x_1 + 2x_2$ liefert Beispiel 10.2.7

$$\nabla g(\mathbf{x}) = \mathbf{a}^\top = (1, 2).$$

Schritt 2: Linearität anwenden. Zeile 2 aus Bemerkung 10.5.6 mit $c_1 = 3$ und $c_2 = -2$ ergibt

$$\nabla h(\mathbf{x}) = 3\nabla f(\mathbf{x}) - 2\nabla g(\mathbf{x}) = 3(2x_1, 2x_2) - 2(1, 2) = (6x_1 - 2, 6x_2 - 4).$$

Schritt 3: die Stelle einsetzen.

$$\nabla h\left(\begin{pmatrix} 1 \\ -1 \end{pmatrix}\right) = (6 \cdot 1 - 2, 6 \cdot (-1) - 4) = (4, -10).$$

Probe. Multiplizieren wir h zuerst aus, so steht dort $h(\mathbf{x}) = 3x_1^2 + 3x_2^2 - 2x_1 - 4x_2$, und die beiden partiellen Ableitungen sind $6x_1 - 2$ und $6x_2 - 4$. ☒ Bei komplizierteren f und g spart der Weg über die Bausteine Arbeit, weil wir auf fertige Identitäten aus Abschnitt 10.2 zurückgreifen.

Selbsttest

1. Ist f in $\mathbf{x}$ differenzierbar, so ist f in $\mathbf{x}$ stetig.

Antwort: Wahr

Das ist Satz 10.5.2. Der Beweis schätzt beide Zusatzterme der linearen Approximation nach oben ab: den Ableitungsterm durch $M \|\mathbf{h}\|$ und den Restterm für kleine $\mathbf{h}$ durch $\|\mathbf{h}\|$. Zusammen bleibt $\|f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x})\| \leq (M + 1) \|\mathbf{h}\|$, und diese Schranke geht gegen null.

2. Ist f in $\mathbf{x}$ stetig, so ist f in $\mathbf{x}$ differenzierbar.

Antwort: Falsch

Die Umkehrung von Satz 10.5.2 gilt nicht. Die Betragsfunktion ist in 0 stetig, ihr Differenzenquotient strebt dort aber von rechts gegen +1 und von links gegen -1 (Beispiel 10.5.3). Stetigkeit ist notwendig, nicht hinreichend.

3. Am Knick von $f(x) = |x|$ existieren die einseitigen Grenzwerte des Differenzenquotienten nicht.

Antwort: Falsch

Sie existieren beide, sie stimmen nur nicht überein: +1 von rechts, -1 von links, und zwar schon für jedes einzelne $h \neq 0$. Daran scheitert Definition 10.1.1, die einen einzigen Grenzwert für beide Seiten verlangt.

4. Weil die Ableitungsoperation nach Satz 10.5.5 linear ist, hängt $D_{\mathbf{x}}f$ linear von der Stelle $\mathbf{x}$ ab.

Antwort: Falsch

Hier werden zwei Linearitäten verwechselt. Satz 10.5.5 sagt etwas über die Zuordnung $f \mapsto D_{\mathbf{x}}f$ bei fester Stelle. Wie $D_{\mathbf{x}}f$ von $\mathbf{x}$ abhängt, bleibt völlig offen: Für $f(x) = x^3$ ist $D_{\mathbf{x}}f(h) = 3x^2h$, und $x \mapsto 3x^2$ ist nicht linear (Bemerkung 10.1.4).

5. Jeder Term der Ordnung $O(\|\mathbf{h}\|)$ ist auch $o(\|\mathbf{h}\|)$.

Antwort: Falsch

Es gilt nur die eine Richtung. Jeder o -Term ist ein O -Term (Bemerkung 10.5.1), aber $g(h) = h$ erfüllt $|g(h)| \leq |h|$ und ist damit $O(|h|)$, während $g(h)/|h|$ betragsmäßig konstant 1 bleibt und nicht gegen null geht. Deshalb steht in (10.5.1) das kleine o und nicht das große O : Mit O wäre die Forderung fast leer, denn sobald überhaupt eine beschränkte lineare Abbildung passte, passte jede andere genauso; die Differenz zweier solcher Abbildungen ist selbst $O(\|\mathbf{h}\|)$.

6. Für in $\mathbf{x}$ differenzierbare $f, g : \mathbb{R}^n \rightarrow \mathbb{R}$ gilt $\nabla [3f(\mathbf{x}) - 2g(\mathbf{x})] = 3\nabla f(\mathbf{x}) - 2\nabla g(\mathbf{x})$.

Antwort: Wahr

Das ist Zeile 2 aus Bemerkung 10.5.6, also Satz 10.5.5 im Fall $\mathbb{D} = \mathbb{R}^n$, $\mathbb{E} = \mathbb{R}$ mit $c_1 = 3$ und $c_2 = -2$. Beispiel 10.5.7 rechnet diesen Fall durch und erhält an der Stelle $(1, -1)^\top$ den Gradienten $(4, -10)$.

7. Stellen wir im Lupen-Widget $f(x) = |x|$ und $x_0 = 0$ ein und zoomen so weit hinein, wie der Regler reicht. Welchen Wert hat die angezeigte Abweichung von der Geraden dann, gemessen in Vielfachen der halben Fensterbreite w ?

Lösung: 1

Genau 1, und zwar auf jeder einzelnen Zoomstufe. Die Sehne durch die beiden Fensterränder ist bei $x_0 = 0$ waagrecht und liegt auf der Höhe w , während die Kurve in der Mitte den Wert 0 hat; die Abweichung ist also w selbst, in Vielfachen von w gerechnet 1. Der Knick verschwindet unter keiner Lupe. Zum Vergleich: Bei $f(x) = x^2$ steht dort w selbst, also eine Zahl, die mit jedem Zoomschritt kleiner wird.

Vertiefung: Die Summenregel in MML §5.1.2 ist der Spezialfall $\mathbb{D} = \mathbb{E} = \mathbb{R}$ von Satz 10.5.5; die übrigen Regeln von dort nimmt Abschnitt 10.6 auf.

10.6 Produkt- und Kettenregel

Warum zwei Regeln fehlen

Die Linearität aus Abschnitt 10.5 erledigt Summen und Vielfache. Die Zielfunktionen der Statistik sind aber meist Produkte und Verkettungen: Die Quadratsumme $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$ ist ein Skalarprodukt einer Funktion mit sich selbst, eine Log-Likelihood schiebt einen linearen Score durch eine nicht-lineare Antwortfunktion, ein neuronales Netz verkettet viele solcher Schichten. Produkt- und Kettenregel aus der Analysis gelten weiter, wenn wir die Ableitung als lineare Approximation lesen. Bei der Produktregel ist nur zuerst zu klären, was „Produkt“ heißen soll.

Produkte sind bilineare Abbildungen

Für $f, g : \mathbb{D} \rightarrow \mathbb{R}^m$ gibt es kein kanonisches Produkt $f(\mathbf{x})g(\mathbf{x})$, wohl aber mehrere nützliche Multiplikationen: das Skalarprodukt zweier Vektoren, das Matrixprodukt, das Produkt aus Zahl und Vektor. Halten wir bei einer von ihnen ein Argument fest, so ist sie im anderen linear. Solche Abbildungen sind uns in Abschnitt 9.1 als multilineare Abbildungen begegnet; hier brauchen wir den Fall zweier Argumente und zusätzlich eine Größenschränke.

Definition 10.6.1 (Beschränkte bilineare Abbildung)

Seien $\mathbb{E}_1, \mathbb{E}_2$ und $\mathbb{B}$ normierte Vektorräume. Eine Abbildung $\langle \cdot, \cdot \rangle : \mathbb{E}_1 \times \mathbb{E}_2 \rightarrow \mathbb{B}$ heißt *bilinear*, wenn sie in jedem Argument linear ist, wenn also für alle $u, u_1, u_2 \in \mathbb{E}_1$, $v, v_1, v_2 \in \mathbb{E}_2$ und $c_1, c_2 \in \mathbb{R}$

$$\langle c_1 u_1 + c_2 u_2, v \rangle = c_1 \langle u_1, v \rangle + c_2 \langle u_2, v \rangle, \quad \langle u, c_1 v_1 + c_2 v_2 \rangle = c_1 \langle u, v_1 \rangle + c_2 \langle u, v_2 \rangle$$

gilt. Sie heißt *beschränkt*, wenn es ein $K < \infty$ gibt mit

$$\|\langle u, v \rangle\| \leq K \|u\| \|v\| \quad \text{für alle } u \in \mathbb{E}_1, v \in \mathbb{E}_2. \quad (10.6.1)$$

Bemerkung 10.6.2 (Vier Multiplikationen und ihre Schranke)

1. Das Skalarprodukt $\langle u, v \rangle = u^\top v$ auf $\mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$; die Cauchy-Schwarz-Ungleichung liefert $K = 1$.
2. Zahl mal Vektor, $\mathbb{R} \times \mathbb{R}^m \rightarrow \mathbb{R}^m$, mit $\|c v\| = |c| \|v\|$, also ebenfalls $K = 1$.
3. Das Matrixprodukt $\mathbb{R}^{m \times n} \times \mathbb{R}^{n \times p} \rightarrow \mathbb{R}^{m \times p}$; für eine submultiplikative Matrixnorm (Abschnitt 3.5) ist $K = 1$.
4. Die Spur eines Matrixprodukts, $(F, G) \mapsto \text{tr}(FG)$ mit $F \in \mathbb{R}^{m \times n}$ und $G \in \mathbb{R}^{n \times m}$. Wegen $\text{tr}(FG) = \sum_{i,j} f_{ij} g_{ji}$ ist diese Spur das Frobenius-Skalarprodukt von F und $G^\top$, also bilinear. Die Frobenius-Norm ist die euklidische Norm der Einträge als langer Vektor (Definition 3.1.8), also gibt Cauchy-Schwarz für diese Vektoren wieder $K = 1$.

In endlicher Dimension ist jede bilineare Abbildung automatisch beschränkt (Entwicklung in Basen, K aus den endlich vielen Werten $\langle e_i, e_j \rangle$); erst im Unendlichdimensionalen ist die Schranke eine echte Zusatzbedingung. Der Beweis des folgenden Satzes braucht (10.6.1) für den Kreuzterm.

Die Regel selbst sieht aus wie die aus der Schule.

Satz 10.6.3 (Produktregel)

Seien $\mathbb{D}$, $\mathbb{E}_1$, $\mathbb{E}_2$ und $\mathbb{B}$ normierte Vektorräume, $\langle \cdot, \cdot \rangle : \mathbb{E}_1 \times \mathbb{E}_2 \rightarrow \mathbb{B}$ beschränkt bilinear und $f : \mathbb{D} \rightarrow \mathbb{E}_1$, $g : \mathbb{D} \rightarrow \mathbb{E}_2$ in $x \in \mathbb{D}$ differenzierbar. Dann ist auch $b(x) = \langle f(x), g(x) \rangle$ in x differenzierbar mit

$$D_x b(h) = \langle D_x f(h), g(x) \rangle + \langle f(x), D_x g(h) \rangle. \quad (10.6.2)$$

Beweis.

- (1) Die Differenzierbarkeit von f und g an der Stelle x heißt

$$f(x+h) = f(x) + D_x f(h) + r_f(h), \quad g(x+h) = g(x) + D_x g(h) + r_g(h)$$

mit $\|r_f(h)\| / \|h\| \rightarrow 0$ und ebenso für r_g . Beide Ableitungen sind beschränkt, es gibt also $M_f, M_g < \infty$ mit $\|D_x f(h)\| \leq M_f \|h\|$ und $\|D_x g(h)\| \leq M_g \|h\|$.

Definition 10.1.5; die Beschränktheit der linearen Abbildung gehört dort zur Definition

- (2) Wir setzen beides ein und multiplizieren mit der Bilinearität gliedweise aus:

$$\begin{aligned} b(x+h) &= \langle f(x) + D_x f(h) + r_f(h), g(x) + D_x g(h) + r_g(h) \rangle \\ &= b(x) + \underbrace{\langle D_x f(h), g(x) \rangle + \langle f(x), D_x g(h) \rangle}_{=: L(h)} + R(h) \end{aligned}$$

mit dem Sammelrest

$$R(h) = \underbrace{\langle D_x f(h), D_x g(h) \rangle}_{\text{Kreuzterm}} + \langle f(x) + D_x f(h) + r_f(h), r_g(h) \rangle + \langle r_f(h), g(x) + D_x g(h) \rangle.$$

neun Terme wie beim Ausmultiplizieren zweier Summen; sortiert nach dem Term ohne $\mathbf{h}$, den beiden in $\mathbf{h}$ linearen Termen und dem Rest

- (3) Der Kreuzterm ist von der Ordnung $\|\mathbf{h}\|^2$:

$$\|\langle D_{\mathbf{x}}f(\mathbf{h}), D_{\mathbf{x}}g(\mathbf{h}) \rangle\| \leq K \|D_{\mathbf{x}}f(\mathbf{h})\| \|D_{\mathbf{x}}g(\mathbf{h})\| \leq KM_f M_g \|\mathbf{h}\|^2.$$

Geteilt durch $\|\mathbf{h}\|$ bleibt $KM_f M_g \|\mathbf{h}\| \rightarrow 0$, also ist er $o(\|\mathbf{h}\|)$.

(10.6.1) mit $u = D_{\mathbf{x}}f(\mathbf{h})$ und $v = D_{\mathbf{x}}g(\mathbf{h})$, danach die beiden Schranken aus Schritt 1; zu O und o siehe Bemerkung 10.5.1

- (4) Die beiden übrigen Summanden von $R(\mathbf{h})$ sind ebenfalls $o(\|\mathbf{h}\|)$. Für den mittleren gilt

$$\|\langle f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + r_f(\mathbf{h}), r_g(\mathbf{h}) \rangle\| \leq K(\|f(\mathbf{x})\| + M_f \|\mathbf{h}\| + \|r_f(\mathbf{h})\|) \|r_g(\mathbf{h})\|.$$

Die Klammer bleibt für kleine $\mathbf{h}$ beschränkt, während $\|r_g(\mathbf{h})\| / \|\mathbf{h}\| \rightarrow 0$; der letzte Summand geht genauso. Mit Schritt 3 ist also $R(\mathbf{h}) = o(\|\mathbf{h}\|)$.

wieder (10.6.1); der erste Faktor hängt nur beschränkt von $\mathbf{h}$ ab, der zweite ist nach Schritt 1 von kleinerer Ordnung als $\|\mathbf{h}\|$; eine Summe endlich vieler $o(\|\mathbf{h}\|)$ -Terme ist wieder $o(\|\mathbf{h}\|)$

- (5) L ist linear in $\mathbf{h}$, weil $D_{\mathbf{x}}f$, $D_{\mathbf{x}}g$ und die Multiplikation im jeweils festgehaltenen Argument es sind, und beschränkt wegen

$$\|L(\mathbf{h})\| \leq K(M_f \|g(\mathbf{x})\| + M_g \|f(\mathbf{x})\|) \|\mathbf{h}\|.$$

Also gilt $b(\mathbf{x} + \mathbf{h}) = b(\mathbf{x}) + L(\mathbf{h}) + o(\|\mathbf{h}\|)$, und das ist Definition 10.1.5 mit $D_{\mathbf{x}}b = L$.

Bilinearität gibt die Additivität und Homogenität in jedem Argument einzeln; für die Schranke wieder (10.6.1), diesmal mit den festen Vektoren $f(\mathbf{x})$ und $g(\mathbf{x})$

□

Die Reihenfolge in (10.6.2) ist verbindlich. Sobald das Produkt nicht kommutativ ist, etwa beim Matrixprodukt, steht der abgeleitete Faktor dort, wo vorher der ursprüngliche stand.

Beispiel 10.6.4 (Die Produktregel in vier Bauformen)

Je nach Wahl der Räume und der Multiplikation liest sich (10.6.2) anders.

Reelle Funktionen, $\mathbb{D} = \mathbb{E}_1 = \mathbb{E}_2 = \mathbb{R}$, gewöhnliche Multiplikation:

$$b(x) = f(x)g(x) \implies b'(x) = f'(x)g(x) + f(x)g'(x).$$

Zwei skalare Felder, $\mathbb{D} = \mathbb{R}^n$, $\mathbb{E}_1 = \mathbb{E}_2 = \mathbb{R}$:

$$b(\mathbf{x}) = f(\mathbf{x})g(\mathbf{x}) \implies \nabla b(\mathbf{x}) = g(\mathbf{x})\nabla f(\mathbf{x}) + f(\mathbf{x})\nabla g(\mathbf{x}) \in \mathbb{R}^{1 \times n}.$$

Skalarprodukt zweier vektorwertiger Funktionen, $\mathbb{D} = \mathbb{R}^n$, $\mathbb{E}_1 = \mathbb{E}_2 = \mathbb{R}^m$:

$$b(\mathbf{x}) = f(\mathbf{x})^\top g(\mathbf{x}) \implies \nabla b(\mathbf{x}) = g(\mathbf{x})^\top J_f(\mathbf{x}) + f(\mathbf{x})^\top J_g(\mathbf{x}).$$

Die Formate passen: $1 \times m$ mal $m \times n$ ergibt $1 \times n$, das Format eines Gradienten auf dem $\mathbb{R}^n$.

Spur eines Matrixprodukts, $\mathbb{D} = \mathbb{R}$:

$$b(x) = \text{tr}[F(x)G(x)] \implies b'(x) = \text{tr}\left[\frac{\partial F(x)}{\partial x}G(x)\right] + \text{tr}\left[F(x)\frac{\partial G(x)}{\partial x}\right].$$

Damit FG quadratisch ist und die Spur existiert, muss $F(x) \in \mathbb{R}^{m \times n}$ und $G(x) \in \mathbb{R}^{n \times m}$ sein; für quadratische Faktoren ($m = n$) ist das von selbst erfüllt.

Mit der dritten Bauform lassen sich quadratische Formen in drei Zeilen ableiten.

Beispiel 10.6.5 (Gradient einer quadratischen Form)

Gesucht ist $\nabla b(\mathbf{x})$ für $b(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{n \times n}$. Wir lesen die quadratische Form als Skalarprodukt,

$$b(\mathbf{x}) = \langle f(\mathbf{x}), g(\mathbf{x}) \rangle \quad \text{mit} \quad f(\mathbf{x}) = \mathbf{x}, \quad g(\mathbf{x}) = \mathbf{A} \mathbf{x}.$$

Die beiden Jacobimatrizen kennen wir aus Abschnitt 10.3: $\mathbf{J}_f(\mathbf{x}) = \mathbf{I}_n$ und $\mathbf{J}_g(\mathbf{x}) = \mathbf{A}$. Die Produktregel gibt

$$\begin{aligned} \nabla b(\mathbf{x}) &= g(\mathbf{x})^\top \mathbf{J}_f(\mathbf{x}) + f(\mathbf{x})^\top \mathbf{J}_g(\mathbf{x}) \\ &= (\mathbf{A} \mathbf{x})^\top \mathbf{I}_n + \mathbf{x}^\top \mathbf{A} = \mathbf{x}^\top \mathbf{A}^\top + \mathbf{x}^\top \mathbf{A} = \mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top), \end{aligned}$$

und für symmetrisches $\mathbf{A}$ vereinfacht sich das zu $\nabla b(\mathbf{x}) = 2\mathbf{x}^\top \mathbf{A}$. In Abschnitt 10.2 haben wir denselben Gradienten über die ausgeschriebene Doppelsumme bestimmt; die Produktregel erspart diese Indexrechnung.

Beispiel 10.6.6 (Ridge-Regression)

Die Ridge-Regression ergänzt die lineare Regression um einen Strafterm. Mit Response $\mathbf{y} \in \mathbb{R}^n$, Designmatrix $\mathbf{X} \in \mathbb{R}^{n \times p}$ und Regularisierungsparameter $\lambda > 0$ minimieren wir

$$\ell(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2.$$

Beide Summanden sind Skalarprodukte einer Funktion mit sich selbst. Für den ersten setzen wir $f(\boldsymbol{\beta}) = \mathbf{y} - \mathbf{X}\boldsymbol{\beta}$ mit $\mathbf{J}_f(\boldsymbol{\beta}) = -\mathbf{X}$ und erhalten aus der Produktregel

$$\begin{aligned} \nabla \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 &= f(\boldsymbol{\beta})^\top \mathbf{J}_f(\boldsymbol{\beta}) + f(\boldsymbol{\beta})^\top \mathbf{J}_f(\boldsymbol{\beta}) = -2(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{X} \\ &= 2(\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} - \mathbf{X}^\top \mathbf{y})^\top. \end{aligned}$$

Der Strafterm ist derselbe Fall mit $f(\boldsymbol{\beta}) = \boldsymbol{\beta}$ und $\mathbf{J}_f(\boldsymbol{\beta}) = \mathbf{I}_p$, sein Gradient also $2\lambda \boldsymbol{\beta}^\top$. Zusammen ergibt die Linearität aus Abschnitt 10.5

$$\nabla \ell(\boldsymbol{\beta}) = 2(\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} - \mathbf{X}^\top \mathbf{y} + \lambda \boldsymbol{\beta})^\top. \quad (10.6.3)$$

Nullsetzen führt auf $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p) \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{y}$, also auf die Normalgleichungen aus Abschnitt 7.3 mit einem Zuschlag auf der Diagonalen. Für $\lambda > 0$ ist $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p$ stets positiv definit und invertierbar, das gestrafte System also *eindeutig* lösbar. Ohne Strafterm haben die Normalgleichungen auch bei Rangdefizit von $\mathbf{X}$ Lösungen, aber keine eindeutige.

Ein Zahlenbeispiel zur Kontrolle: Mit

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \quad \mathbf{y} = (1, 2, 2)^\top, \quad \lambda = 1,5$$

ist $\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}$ und $\mathbf{X}^\top \mathbf{y} = (5, 11)^\top$. An der Stelle $\boldsymbol{\beta} = (0,5, 0,4)^\top$ liefert (10.6.3) den Gradienten $(-0,7, -3,6)$, was ein numerischer Differenzenquotient bestätigt. Die Lösung des

gestraften Systems ist $\beta = (0,341, 0,578)^\top$ gegenüber $(0,667, 0,500)^\top$ ohne Strafterm. Die Länge des Koeffizientenvektors sinkt dabei von 0,833 auf 0,671, die zweite Komponente wächst dagegen leicht: Der Strafterm verkürzt den Vektor, nicht jede einzelne Komponente.

Die Kettenregel

Verkettungen sind die zweite Art, aus einfachen Funktionen komplizierte zu bauen. Für Jacobimatrizen kennen wir die Regel aus Abschnitt 10.3; ohne Koordinaten steht an der Stelle des Matrixprodukts eine Hintereinanderausführung.

Satz 10.6.7 (Kettenregel)

Seien $\mathbb{D}_1, \mathbb{D}_2, \mathbb{D}_3$ normierte Vektorräume, $f : \mathbb{D}_1 \rightarrow \mathbb{D}_2$ in $\mathbf{x} \in \mathbb{D}_1$ differenzierbar und $g : \mathbb{D}_2 \rightarrow \mathbb{D}_3$ in $\mathbf{y} = f(\mathbf{x}) \in \mathbb{D}_2$ differenzierbar. Dann ist die Verkettung $g \circ f$ in $\mathbf{x}$ differenzierbar mit

$$D_{\mathbf{x}}(g \circ f) = D_{\mathbf{y}}g \circ D_{\mathbf{x}}f. \quad (10.6.4)$$

Rechts steht die Verkettung zweier linearer Abbildungen. In Koordinaten wird daraus ein Matrixprodukt, dessen Reihenfolge die Verkettung spiegelt: Zuerst wirkt $D_{\mathbf{x}}f$, also steht es rechts.

Beweis.

- (1) Wir kürzen den Zuwachs ab, den f weiterreicht:

$$\mathbf{k} := f(\mathbf{x} + \mathbf{h}) - f(\mathbf{x}) = D_{\mathbf{x}}f(\mathbf{h}) + r_f(\mathbf{h}).$$

Für hinreichend kleine $\mathbf{h}$ ist $\|\mathbf{k}\| \leq (M_f + 1)\|\mathbf{h}\|$: Der erste Summand ist durch $M_f\|\mathbf{h}\|$ beschränkt (M_f ist die Schranke von $D_{\mathbf{x}}f$), der zweite für kleine $\mathbf{h}$ durch $\|\mathbf{h}\|$.

Differenzierbarkeit von f in $\mathbf{x}$; $\|r_f(\mathbf{h})\|/\|\mathbf{h}\| \rightarrow 0$ heißt insbesondere, dass der Quotient irgendwann unter 1 liegt

- (2) Die Differenzierbarkeit von g an der Stelle $\mathbf{y}$ liefert

$$(g \circ f)(\mathbf{x} + \mathbf{h}) = g(\mathbf{y} + \mathbf{k}) = g(\mathbf{y}) + D_{\mathbf{y}}g(\mathbf{k}) + r_g(\mathbf{k}).$$

$f(\mathbf{x} + \mathbf{h}) = \mathbf{y} + \mathbf{k}$ nach Schritt 1, und für g gilt Definition 10.1.5 an der Stelle $\mathbf{y}$

- (3) Weil $D_{\mathbf{y}}g$ linear ist, dürfen wir den Zuwachs aufspalten:

$$D_{\mathbf{y}}g(\mathbf{k}) = D_{\mathbf{y}}g(D_{\mathbf{x}}f(\mathbf{h})) + D_{\mathbf{y}}g(r_f(\mathbf{h})).$$

Weil sie zusätzlich beschränkt ist, ist der zweite Summand klein: $\|D_{\mathbf{y}}g(r_f(\mathbf{h}))\| \leq M_g\|r_f(\mathbf{h})\| = o(\|\mathbf{h}\|)$.

Linearität erlaubt $D(u + v) = D(u) + D(v)$; Beschränktheit heißt $\|D_{\mathbf{y}}g(u)\| \leq M_g\|u\|$, und ein festes Vielfaches eines $o(\|\mathbf{h}\|)$ -Terms bleibt $o(\|\mathbf{h}\|)$

- (4) Auch $r_g(\mathbf{k})$ ist $o(\|\mathbf{h}\|)$. Nach Schritt 1 ist nämlich

$$\frac{\|r_g(\mathbf{k})\|}{\|\mathbf{h}\|} \leq (M_g + 1) \frac{\|r_g(\mathbf{k})\|}{\|\mathbf{k}\|},$$

und mit $\mathbf{h} \rightarrow \mathbf{0}$ geht auch $\mathbf{k} \rightarrow \mathbf{0}$, der rechte Quotient also gegen null. Der Restterm von g ist zunächst nur gemessen an $\mathbf{k}$ klein; erst die Schranke aus Schritt 1 überträgt das auf $\mathbf{h}$.

für $\mathbf{k} = \mathbf{0}$ ist $r_g(\mathbf{k}) = 0$, der Quotient wird dann gar nicht gebildet; sonst gilt die Abschätzung aus Schritt 1

(5) Zusammengesetzt:

$$(g \circ f)(\mathbf{x} + \mathbf{h}) = (g \circ f)(\mathbf{x}) + (D_{\mathbf{y}}g \circ D_{\mathbf{x}}f)(\mathbf{h}) + o(\|\mathbf{h}\|).$$

Die Verkettung $D_{\mathbf{y}}g \circ D_{\mathbf{x}}f$ ist linear und beschränkt mit Schranke $M_g M_f$, also ist Definition 10.1.5 erfüllt.

$$\|D_{\mathbf{y}}g(D_{\mathbf{x}}f(\mathbf{h}))\| \leq M_g \|D_{\mathbf{x}}f(\mathbf{h})\| \leq M_g M_f \|\mathbf{h}\|$$

□

Beispiel 10.6.8 (Die Kettenregel in fünf Bauformen)

Wie bei der Produktregel hängt das Aussehen an den beteiligten Räumen.

Reelle Funktionen, $f, g : \mathbb{R} \rightarrow \mathbb{R}$:

$$[g(f(x))]' = g'(f(x)) f'(x).$$

Skalares Feld, dann reelle Funktion, $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $g : \mathbb{R} \rightarrow \mathbb{R}$:

$$\nabla [g(f(\mathbf{x}))] = g'(f(\mathbf{x})) \nabla f(\mathbf{x}) \in \mathbb{R}^{1 \times n}.$$

Zwei vektorwertige Abbildungen, $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, $g : \mathbb{R}^m \rightarrow \mathbb{R}^p$:

$$\mathbf{J}_{g \circ f}(\mathbf{x}) = \mathbf{J}_g(f(\mathbf{x})) \mathbf{J}_f(\mathbf{x}) \in \mathbb{R}^{p \times n}.$$

Das ist Satz 10.3.9, der Spezialfall, auf dem Backpropagation beruht.

Matrixargument, dann reelle Funktion, $f : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$, $g : \mathbb{R} \rightarrow \mathbb{R}$:

$$\frac{\partial (g \circ f)(\mathbf{X})}{\partial \mathbf{X}} = g'(f(\mathbf{X})) \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} \in \mathbb{R}^{m \times n}.$$

Matrixwertige Kurve, dann reelle Funktion, $\mathbf{F} : \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$, $g : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$, mit $\mathbf{Y} = \mathbf{F}(x)$:

$$\frac{\partial (g \circ \mathbf{F})}{\partial x} = D_{\mathbf{Y}}g \left(\frac{\partial \mathbf{F}(x)}{\partial x} \right) = \text{tr} \left(\left(\frac{\partial g(\mathbf{Y})}{\partial \mathbf{Y}} \right)^{\top} \frac{\partial \mathbf{F}(x)}{\partial x} \right) \in \mathbb{R}.$$

Die Fréchet-Ableitung einer skalaren Funktion mit Matrixargument wirkt nach Abschnitt 10.4 über das Frobenius-Skalarprodukt, $D_{\mathbf{Y}}g(\mathbf{H}) = \text{tr}((\partial g / \partial \mathbf{Y})^{\top} \mathbf{H})$, hier mit der Richtung $\mathbf{H} = \partial \mathbf{F}(x) / \partial x$.

Die dritte Voreinstellung des folgenden Widgets, $h(x) = \sqrt{x^2}$, ist ein Grenzfall: Zum Nullpunkt hin wächst die äußere Rate über jede Grenze, während die innere gegen null geht. Was kommt dann heraus, und was passiert bei $x = 0$ selbst?

Interaktiv: Die Kettenregel im Eindimensionalen

Für $\mathbb{D}_1 = \mathbb{D}_2 = \mathbb{D}_3 = \mathbb{R}$ ist jede lineare Abbildung die Multiplikation mit einer Zahl, und zwei solche Multiplikationen hintereinander ergeben die Multiplikation mit dem Produkt; deshalb steht in (10.6.4) hier ein Produkt zweier Steigungen. Die Tafel zeigt beide Faktoren einzeln und prüft die Ableitung mit einem zentralen Differenzenquotienten (Schrittweite 10^{-6}).

Interaktives Element — nur in der Web-Fassung

Bei $h(x) = \sqrt{x^2}$ ist das Produkt $g'(f(x))f'(x) = \frac{1}{2|x|} \cdot 2x$ für jedes $x \neq 0$ das Vorzeichen von x , also die Ableitung von $|x|$, obwohl der erste Faktor unbeschränkt ist. Bei $x = 0$ ist die Voraussetzung des Satzes verletzt, weil die Wurzel in $u = f(0) = 0$ nicht differenzierbar ist; der zentrale Differenzenquotient mittelt über den Knick aus Abschnitt 10.1 und meldet 0. Denselben Vorbehalt braucht Beispiel 10.6.11.

Vertiefung (optional): Alternatives Beispiel zur Kettenregel: logistische Regression

Bei der logistischen Regression wollen wir eine binäre Zielgröße $Y \in \{0, 1\}$ aus Merkmalen $\mathbf{x} \in \mathbb{R}^p$ vorhersagen und modellieren dafür

$$P(Y = 1 \mid \mathbf{x}) = \sigma(\boldsymbol{\beta}^\top \mathbf{x}), \quad \sigma(t) = \frac{1}{1 + e^{-t}}.$$

Die Sigmoidfunktion σ presst den linearen Score $\boldsymbol{\beta}^\top \mathbf{x}$ in das Intervall $(0, 1)$, sodass die Vorhersage als Wahrscheinlichkeit lesbar ist. Der Verlust einer einzelnen Beobachtung $(\mathbf{x}, y)$ ist die negative Log-Likelihood

$$\ell(\boldsymbol{\beta}) = -[y \log(\sigma(\boldsymbol{\beta}^\top \mathbf{x})) + (1 - y) \log(1 - \sigma(\boldsymbol{\beta}^\top \mathbf{x}))] = \begin{cases} -\log P(Y = 1 \mid \mathbf{x}) & \text{für } y = 1, \\ -\log P(Y = 0 \mid \mathbf{x}) & \text{für } y = 0. \end{cases}$$

Für $y = 1$ bleibt vom Verlust also der erste Summand, für $y = 0$ der zweite.

Beispiel 10.6.9 (Gradient des logistischen Verlusts)

Zuerst brauchen wir die Ableitung von σ , und schon dafür arbeitet die Kettenregel. Mit $u(t) = 1 + e^{-t}$ und der äußeren Funktion $w \mapsto w^{-1}$ ist

$$\sigma'(t) = -\frac{1}{(1 + e^{-t})^2} \cdot (-e^{-t}) = \frac{e^{-t}}{(1 + e^{-t})^2} = \sigma(t)(1 - \sigma(t)), \quad (10.6.5)$$

wobei wir im letzten Schritt $1 - \sigma(t) = e^{-t}/(1 + e^{-t})$ benutzt haben. Die Ableitung der Sigmoidfunktion lässt sich also aus ihrem eigenen Funktionswert ablesen, was Implementierungen ausnutzen.

Fall $y = 1$. Hier ist $\ell = g \circ f$ mit

$$f(\beta) = \beta^\top \mathbf{x}, \quad \nabla f(\beta) = \mathbf{x}^\top, \quad g(t) = -\log \sigma(t).$$

Für die äußere Funktion liefert (10.6.5)

$$g'(t) = -\frac{\sigma'(t)}{\sigma(t)} = -(1 - \sigma(t)) = \sigma(t) - 1,$$

und die zweite Bauform aus Beispiel 10.6.8 setzt beides zusammen. Mit der Abkürzung $\hat{y} = \sigma(\beta^\top \mathbf{x})$ ist

$$\nabla \ell(\beta) = g'(f(\beta)) \nabla f(\beta) = (\hat{y} - 1) \mathbf{x}^\top.$$

Fall $y = 0$. Jetzt ist $g(t) = -\log(1 - \sigma(t))$, also

$$g'(t) = \frac{\sigma'(t)}{1 - \sigma(t)} = \sigma(t),$$

und damit $\nabla \ell(\beta) = \hat{y} \mathbf{x}^\top$. Das Vorzeichen ist hier positiv, und erst so fügen sich beide Fälle zusammen zu

$$\nabla \ell(\beta) = (\hat{y} - y) \mathbf{x}^\top. \quad (10.6.6)$$

Ein Zahlenbeispiel, beide Fälle numerisch geprüft: Für $\mathbf{x} = (1, -2, 0.5)^\top$ und $\beta = (0.3, -0.7, 1.1)^\top$ ist $\beta^\top \mathbf{x} = 2.25$ und $\hat{y} = 0.9047$. Bei $y = 1$ ergibt (10.6.6) den Gradienten $(-0.0953, 0.1907, -0.0477)$, bei $y = 0$ dagegen $(0.9047, -1.8093, 0.4523)$.

Bemerkung 10.6.10 (Fehler mal Merkmal)

Gleichung (10.6.6) ist eine der meistbenutzten Formeln des maschinellen Lernens, und sie liest sich wie ein Satz: *Der Gradient ist der Vorhersagefehler, gewichtet mit dem Merkmalsvektor*. Daraus folgen Richtung und Länge des Gradienten.

Zur Richtung: Ist $\hat{y} > y$, sagt das Modell also zu viel voraus, so zeigt der Gradient in Richtung $\mathbf{x}^\top$. Der Gradientenabstieg aus Abschnitt 10.2 verschiebt β entgegen dieser Richtung, senkt damit den Score $\beta^\top \mathbf{x}$ und mit ihm die Vorhersage.

Zur Länge: Es gilt stets $|\hat{y} - y| < 1$, weil σ die Werte 0 und 1 nie annimmt, also ist $\|\nabla \ell(\beta)\| = |\hat{y} - y| \|\mathbf{x}\| < \|\mathbf{x}\|$ für jedes $\mathbf{x} \neq \mathbf{0}$. Eine einzelne Beobachtung kann das Modell also nie beliebig weit verschieben, egal wie falsch die Vorhersage liegt.

Wie weit kann eine einzelne Beobachtung den Parameter verschieben, wenn das Modell maximal danebenliegt? Und was bleibt vom Gradienten übrig, wenn das Merkmal selbst null ist?

Interaktiv: Der logistische Gradient an einer Beobachtung

Die Tafel zeigt den einfachsten denkbaren Fall, ein Merkmal und einen Parameter. Links wandert der Punkt auf der Sigmoidkurve, wenn wir β verschieben; der orange Balken ist der Fehler $\hat{y} - y$. Rechts steht der Verlust als Funktion von β , die grüne Tangente hat die Steigung aus (10.6.6), und der orange Pfeil zeigt, wohin ein Abstiegschritt mit Schrittweite 0,5 führt.

Interaktives Element — nur in der Web-Fassung

In beiden Klassen steht derselbe Ausdruck. Schalten wir auf $y = 0$ und schieben β nach oben, so wird das Modell mit wachsender Sicherheit falsch. Der Gradient nähert sich seiner Obergrenze $|x|$, erreicht sie aber nie. Das ist die Aussage zur Länge aus Bemerkung 10.6.10, ablesbar am Fehlerbalken, der nie über die Höhe 1 hinauskommt. Stellen wir umgekehrt $x = 0$ ein, so ist die Verlustkurve eine waagerechte Gerade, und der Gradient verschwindet für jedes β . Die numerische Gegenprobe bestätigt (10.6.6) in beiden Klassen, Vorzeichen eingeschlossen.

1. Für den logistischen Verlust einer Beobachtung gilt $\nabla \ell(\beta) = (\hat{y} - y)\mathbf{x}^\top$ für $y = 0$ und für $y = 1$.

Antwort: Wahr

Beide Fälle führen über die Kettenregel auf dieselbe Form, siehe (10.6.6). Für $y = 1$ ist die äußere Ableitung $\sigma(t) - 1$, für $y = 0$ ist sie $\sigma(t)$, und beides ist $\hat{y} - y$.

2. Stellen wir im Logistik-Widget das Merkmal auf $x = 0$. Auf welcher Höhe liegt die Verlustkurve dann?

Lösung: 0.693147

Bei $\log 2 = 0,693147$, und zwar für jedes β . Mit $x = 0$ ist der Score $t = \beta x$ konstant null, also $\hat{y} = \sigma(0) = 0,5$ und $\ell = -\log 0,5 = \log 2$. Der Gradient $(\hat{y} - y)x$ verschwindet entsprechend, unabhängig von der Klasse: Ein Merkmal ohne Variation trägt keine Information über β .

Übung: Gradient der euklidischen Norm

Zum Schluss eine Rechnung mit beiden Regeln dieses Abschnitts. Gesucht ist $\nabla h(\mathbf{x})$ für

$$h(\mathbf{x}) = \|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{x}}.$$

Bevor wir weiterlesen, lohnt der eigene Versuch: Welche innere und welche äußere Funktion bieten sich an?

Beispiel 10.6.11 (Gradient der euklidischen Norm)

Wir zerlegen $h = g \circ f$ mit

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}, \quad g(u) = \sqrt{u} = u^{1/2}.$$

Die innere Ableitung kennen wir aus Beispiel 10.6.5 mit $\mathbf{A} = \mathbf{I}_n$, denn $\mathbf{x}^\top \mathbf{x}$ ist die quadratische Form zur Einheitsmatrix: $\nabla f(\mathbf{x}) = 2\mathbf{x}^\top$. Die äußere ist $g'(u) = \frac{1}{2}u^{-1/2} = 1/(2\sqrt{u})$. Die Kettenregel gibt

$$\nabla h(\mathbf{x}) = g'(f(\mathbf{x}))\nabla f(\mathbf{x}) = \frac{2\mathbf{x}^\top}{2\sqrt{\mathbf{x}^\top \mathbf{x}}} = \frac{\mathbf{x}^\top}{\|\mathbf{x}\|_2}.$$

Der Gradient der Norm ist also der auf Länge 1 normierte Vektor selbst, als Zeile geschrieben. Er zeigt radial vom Ursprung weg: Am schnellsten wächst der Abstand zum Ursprung,

wenn wir uns direkt von ihm entfernen. Für $\mathbf{x} = (3, 4)^\top$ etwa ist $\nabla h(\mathbf{x}) = (0, 6, 0, 8)$, für $\mathbf{x} = (1, -2, 2)^\top$ entsprechend $(1/3, -2/3, 2/3)$.

Der Vorbehalt. Die Rechnung gilt nur für $\mathbf{x} \neq \mathbf{0}$: Die Kettenregel verlangt Differenzierbarkeit von g in $u = \|\mathbf{x}\|_2^2$, und bei $u = 0$ wächst g' über jede Grenze. Im Nullpunkt gibt es auch keine Fréchet-Ableitung: Aus $\|\mathbf{h}\|_2 = L(\mathbf{h}) + o(\|\mathbf{h}\|)$ folgte mit $\mathbf{h} = t\mathbf{d}$ und $t \rightarrow 0^\pm$ sowohl $L(\mathbf{d}) = \|\mathbf{d}\|_2$ als auch $L(\mathbf{d}) = -\|\mathbf{d}\|_2$, ein Widerspruch für $\mathbf{d} \neq \mathbf{0}$. Für $n = 1$ ist das der Knick der Betragsfunktion aus Abschnitt 10.1.

Selbsttest

1. Für zwei differenzierbare Abbildungen $f, g: \mathbb{R}^n \rightarrow \mathbb{R}^m$ mit $m > 1$ liefert die Produktregel den Gradienten von $f(\mathbf{x})g(\mathbf{x})$.

Antwort: Falsch

Für $m > 1$ ist $f(\mathbf{x})g(\mathbf{x})$ gar nicht erklärt: Zwei Vektoren lassen sich nicht ohne Weiteres multiplizieren. Satz 10.6.3 braucht eine bilineare Abbildung, die aus den beiden Werten ein neues Objekt macht, etwa das Skalarprodukt $f(\mathbf{x})^\top g(\mathbf{x})$. Erst dann steht die Regel bereit.

2. Für jede Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ gilt $\nabla(\mathbf{x}^\top \mathbf{A} \mathbf{x}) = 2\mathbf{x}^\top \mathbf{A}$.

Antwort: Falsch

Allgemein gilt $\mathbf{x}^\top (\mathbf{A} + \mathbf{A}^\top)$; die Kurzform mit dem Faktor 2 setzt $\mathbf{A} = \mathbf{A}^\top$ voraus (Beispiel 10.6.5). Für $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$ und $\mathbf{x} = (1, 2)^\top$ ist der Gradient $(6, 13)$, die Symmetrieformel gäbe $(4, 14)$.

3. Der Kreuzterm $\langle D_{\mathbf{x}} f(\mathbf{h}), D_{\mathbf{x}} g(\mathbf{h}) \rangle$ im Beweis der Produktregel verschwindet für kleine $\mathbf{h}$, deshalb taucht er in der Formel nicht auf.

Antwort: Falsch

Er verschwindet nicht, er ist nur von zu kleiner Ordnung. Nach Schritt 3 des Beweises ist er $O(\|\mathbf{h}\|^2)$, und ein solcher Term geht nach Teilen durch $\|\mathbf{h}\|$ gegen null. Für $b(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$ und $\mathbf{h} = (0, 1, -0, 05)^\top$ etwa hat er den Wert 0,0225, also durchaus nicht null.

4. Im Unendlichdimensionalen genügt Bilinearität für Satz 10.6.3 nicht, dort brauchen wir zusätzlich die Schranke (10.6.1).

Antwort: Wahr

Ohne die Schranke lässt sich der Kreuzterm nicht kontrollieren, und der ganze Beweis bricht an Schritt 3. In endlicher Dimension ist jede bilineare Abbildung automatisch beschränkt (Bemerkung 10.6.2), weshalb die Voraussetzung dort nichts kostet.

5. Für $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ und $g: \mathbb{R}^m \rightarrow \mathbb{R}^p$ gilt $\mathbf{J}_{g \circ f}(\mathbf{x}) = \mathbf{J}_f(\mathbf{x}) \mathbf{J}_g(f(\mathbf{x}))$.

Antwort: Falsch

Die Reihenfolge ist vertauscht. Richtig ist $\mathbf{J}_{g \circ f}(\mathbf{x}) = \mathbf{J}_g(f(\mathbf{x})) \mathbf{J}_f(\mathbf{x})$, also die äußere Ableitung links. Schon die Formate zeigen es: $\mathbf{J}_g$ ist $p \times m$, $\mathbf{J}_f$ ist $m \times n$, und $p \times m$ mal $m \times n$ ergibt $p \times n$. Die falsche Reihenfolge stellt dagegen $m \times n$ neben $p \times m$ und ist für $n \neq p$ nicht einmal definiert.

6. Der Gradient $\nabla \|\mathbf{x}\|_2 = \mathbf{x}^\top / \|\mathbf{x}\|_2$ hat für jedes $\mathbf{x} \neq \mathbf{0}$ die Länge 1.

Antwort: Wahr

Wir teilen einen Vektor durch seine eigene Länge, das Ergebnis hat Länge 1. Anschaulich heißt das: Der Abstand zum Ursprung wächst in radialer Richtung mit Rate 1, und keine Richtung ist besser. In $\mathbf{x} = \mathbf{0}$ existiert der Gradient nicht (Beispiel 10.6.11).

7. Im Kettenregel-Widget steht die erste Voreinstellung $h(x) = (2x + 1)^4$ mit $x = 0,3$. Welchen Wert hat dort $h'(x)$?

Lösung: 32.768

32,768. Die innere Rate ist $f'(x) = 2$, die äußere $g'(f(x)) = 4 \cdot 1,6^3 = 16,384$, und Satz 10.6.7 multipliziert beide. Die numerische Gegenprobe im Widget landet auf demselben Wert; sie weicht erst in der zehnten Stelle ab.

Vertiefung: MML §5.1.2 stellt die Differentiationsregeln im eindimensionalen Fall zusammen, §5.2.1 die Produkt- und Summenregel für partielle Ableitungen und §5.2.2 die Kettenregel für verkettete Abbildungen.

10.7 Ableitungen höheren Grades

Wo die erste Ableitung aufhört

Die Fréchet-Ableitung ersetzt f in der Nähe von $\mathbf{x}$ durch eine lineare Abbildung. Für vieles reicht das, in kritischen Punkten aber nicht. Sei $f : S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ und $\mathbf{x}^*$ ein *kritischer Punkt*, also eine Stelle mit $\nabla f(\mathbf{x}^*) = \mathbf{0}$. Die lineare Näherung lautet dort

$$f(\mathbf{x}^* + \mathbf{h}) \approx f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*) \mathbf{h} = f(\mathbf{x}^*),$$

sie ist konstant. Ob $\mathbf{x}^*$ ein Minimum, ein Maximum oder keines von beidem ist, steht darin nicht. Davon hängt aber ab, ob ein Optimierungsverfahren angekommen ist, und in der Statistik, wie genau ein Schätzer den Parameter trifft.

Der Ausweg ist derselbe wie in der Schule: Wir leiten noch einmal ab und erhalten die Hesse-Matrix, deren Eigenwerte über die Art des kritischen Punktes entscheiden.

Ableitungen höheren Grades

Die folgende Definition ist technisch; die Bemerkung danach erklärt, wie sie zu lesen ist.

Definition 10.7.1 (k -mal (Fréchet-)differenzierbar)

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Vektorräume, $U \subseteq \mathbb{D}$ offen und $f : U \rightarrow \mathbb{E}$. Mit $\mathcal{L}^j(\mathbb{D}, \mathbb{E})$ bezeichnen wir den normierten Vektorraum der beschränkten j -linearen Abbildungen $\mathbb{D}^j \rightarrow \mathbb{E}$; für $j = 0$ setzen wir $\mathcal{L}^0(\mathbb{D}, \mathbb{E}) := \mathbb{E}$. Für $j \geq 1$ ist seine Operatornorm

$$\|A\|_{\text{op}} := \sup_{\|\mathbf{h}_1\|, \dots, \|\mathbf{h}_j\| \leq 1} \|A(\mathbf{h}_1, \dots, \mathbf{h}_j)\|.$$

Wir setzen $D^0 f := f$. Rekursiv heißt f auf U k -mal (Fréchet-)differenzierbar, wenn für jedes $j = 1, \dots, k$ die Abbildung

$$U \longrightarrow \mathcal{L}^{j-1}(\mathbb{D}, \mathbb{E}), \quad \mathbf{y} \longmapsto D_{\mathbf{y}}^{j-1} f$$

Fréchet-differenzierbar ist. Ihre Ableitung an $\mathbf{x}$, eine beschränkte lineare Abbildung $\mathbb{D} \rightarrow \mathcal{L}^{j-1}(\mathbb{D}, \mathbb{E})$, identifizieren wir mit der beschränkten j -linearen Abbildung $D_{\mathbf{x}}^j f \in \mathcal{L}^j(\mathbb{D}, \mathbb{E})$. Äquivalent gilt

$$\lim_{\substack{\mathbf{h} \rightarrow \mathbf{0} \\ \mathbf{x} + \mathbf{h} \in U}} \frac{\|D_{\mathbf{x}+\mathbf{h}}^{j-1}f - D_{\mathbf{x}}^{j-1}f - D_{\mathbf{x}}^j f(\cdot, \dots, \cdot, \mathbf{h})\|_{\text{op}}}{\|\mathbf{h}\|} = 0. \quad (10.7.1)$$

Von k -maliger Differenzierbarkeit an $\mathbf{x}$ sprechen wir, wenn diese Voraussetzungen in einer offenen Umgebung von $\mathbf{x}$ erfüllt sind.

Bemerkung 10.7.2 (Wie die Definition zu lesen ist)

Für $j = 1$ steht dort die alte Definition. Dann ist $\mathcal{L}^0(\mathbb{D}, \mathbb{E}) = \mathbb{E}$ und $D^0 f = f$, also lautet die Restbedingung

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}} f(\mathbf{h}) + r(\mathbf{h}), \quad \frac{\|r(\mathbf{h})\|}{\|\mathbf{h}\|} \rightarrow 0,$$

und das ist die Fréchet-Ableitung aus Definition 10.1.5. Die höheren Stufen sind dieselbe Idee, mehrfach angewandt.

Was hier wonach abgeleitet wird. Halten wir $\mathbf{h}_1, \dots, \mathbf{h}_{j-1}$ fest. Dann ist

$$\mathbf{x} \mapsto D_{\mathbf{x}}^{j-1} f(\mathbf{h}_1, \dots, \mathbf{h}_{j-1})$$

eine Abbildung von $\mathbb{D}$ nach $\mathbb{E}$. Nach (10.7.1) ist ihre Fréchet-Ableitung an der Stelle $\mathbf{x}$, angewandt auf $\mathbf{h}$, gleich $D_{\mathbf{x}}^j f(\mathbf{h}_1, \dots, \mathbf{h}_{j-1}, \mathbf{h})$. Die j -te Ableitung ist also die lineare Näherung an die Änderung der $(j-1)$ -ten. Deshalb rechnen wir höhere Ableitungen wie gewohnt iterativ aus, Stufe für Stufe.

Die Objekte werden größer. $D_{\mathbf{x}}^j f$ ist multilinear, also linear in jedem Argument, wenn die übrigen festgehalten werden (Abschnitt 9.1). Für $f: \mathbb{R}^n \rightarrow \mathbb{R}$ braucht $D_{\mathbf{x}}^1 f$ einen Zeilenvektor mit n Zahlen, $D_{\mathbf{x}}^2 f$ eine Matrix mit n^2 Zahlen, $D_{\mathbf{x}}^3 f$ einen Tensor dritter Stufe mit n^3 Zahlen. Die Stufe wächst mit j , und ab $j = 3$ verlassen wir die Matrixsprache (Abschnitt 9.2).

Vertiefung (optional): Feinheiten der Definition: Umgebung, Operatornorm und Beschränktheit

Warum eine Umgebung vorkommt. Um $D_{\mathbf{x}}^j f$ zu bilden, müssen die Werte $D_{\mathbf{x}+\mathbf{h}}^{j-1} f$ für kleine $\mathbf{h}$ bereits existieren. Ableitungen nur an der einzelnen Stelle $\mathbf{x}$ reichen dafür nicht.

Warum die Operatornorm. Sie verlangt mehr als eine Restabschätzung für feste Richtungen: Der Rest muss gleichmäßig für alle Richtungen mit Norm höchstens eins klein werden. Diese Gleichmäßigkeit braucht der allgemeine Taylor-Satz.

Was beschränkt heißt. Für die multilinearen Abbildungen $D_{\mathbf{x}}^j f$, wie wir sie auch aus der Produktregel in Abschnitt 10.6 kennen, verlangen wir

$$\|D_{\mathbf{x}}^j f(\mathbf{h}_1, \dots, \mathbf{h}_j)\| \leq M \prod_{i=1}^j \|\mathbf{h}_i\|$$

für ein $M < \infty$, das von $\mathbf{x}$ abhängen darf. In endlicher Dimension ist das automatisch erfüllt.

Vektor zu Skalar: die Hesse-Matrix

Für skalarwertige Funktionen sammelt die zweite Ableitung alle partiellen Ableitungen zweiter Ordnung in einer Matrix.

Definition 10.7.3 (Hesse-Matrix)

Die Hesse-Matrix $\mathbf{H}_f(\mathbf{x})$ einer zweimal partiell differenzierbaren Funktion $f : S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ ist die Matrix der zweiten partiellen Ableitungen,

$$\mathbf{H}_f(\mathbf{x})_{i,j} := \frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \in \mathbb{R}^{n \times n}.$$

Für alles Weitere verlangen wir mehr als die Existenz dieser Einträge, nämlich $f \in \mathcal{C}^2$: Alle zweiten partiellen Ableitungen existieren und sind stetig. Dann ist die Hesse-Matrix symmetrisch, und die Formeln für $D_{\mathbf{x}}^2 f$ weiter unten brauchen das bereits.

Satz 10.7.4 (Satz von Schwarz)

Seien $S \subseteq \mathbb{R}^n$ offen und $f : S \rightarrow \mathbb{R}$ zweimal stetig differenzierbar ($f \in \mathcal{C}^2$). Dann gilt für alle $\mathbf{x} \in S$ und alle i, j

$$\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} = \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i}.$$

Vertiefung (optional): Beweis des Satzes von Schwarz

Beweis.

- (1) Wir schreiben kurz $\partial_i f := \partial f / \partial x_i$ und $\partial_j \partial_i f := \partial(\partial_i f) / \partial x_j$; das ist der Eintrag $\mathbf{H}_f(\mathbf{x})_{j,i}$. Für $i = j$ ist nichts zu zeigen, sei also $i \neq j$. Zu kleinen $s, t \neq 0$ betrachten wir die *doppelte Differenz*

$$\Delta(s, t) := f(\mathbf{x} + s\mathbf{e}_i + t\mathbf{e}_j) - f(\mathbf{x} + s\mathbf{e}_i) - f(\mathbf{x} + t\mathbf{e}_j) + f(\mathbf{x}).$$

Diese Größe ändert sich nicht, wenn wir die Rollen von (i, s) und (j, t) vertauschen: Es werden nur die vier Summanden umsortiert.

der erste und der letzte Summand sind schon symmetrisch, die beiden mittleren tauschen die Plätze

- (2) Wir setzen $\varphi(u) := f(\mathbf{x} + u\mathbf{e}_i + t\mathbf{e}_j) - f(\mathbf{x} + u\mathbf{e}_i)$, also $\Delta(s, t) = \varphi(s) - \varphi(0)$. Die Funktion φ hängt nur von einer Variablen ab und ist differenzierbar mit

$$\varphi'(u) = \partial_i f(\mathbf{x} + u\mathbf{e}_i + t\mathbf{e}_j) - \partial_i f(\mathbf{x} + u\mathbf{e}_i).$$

Nach dem Mittelwertsatz gibt es ein σ zwischen 0 und s mit $\Delta(s, t) = s\varphi'(\sigma)$.

Mittelwertsatz für φ auf dem Intervall zwischen 0 und s ; φ ist differenzierbar, weil f nach x_i stetig partiell differenzierbar ist

- (3) Jetzt dasselbe noch einmal in der anderen Richtung. Mit $\psi(v) := \partial_i f(\mathbf{x} + \sigma\mathbf{e}_i + v\mathbf{e}_j)$ ist $\varphi'(\sigma) = \psi(t) - \psi(0)$, und ψ ist differenzierbar mit $\psi'(v) = \partial_j \partial_i f(\mathbf{x} + \sigma\mathbf{e}_i + v\mathbf{e}_j)$. Der Mittelwertsatz liefert ein τ zwischen 0 und t mit

$$\Delta(s, t) = st \partial_j \partial_i f(\mathbf{x} + \sigma\mathbf{e}_i + \tau\mathbf{e}_j).$$

zweite Anwendung des Mittelwertsatzes; ψ ist differenzierbar, weil die zweite partielle Ableitung $\partial_j \partial_i f$ nach Voraussetzung existiert

- (4) Nun wiederholen wir die Schritte 2 und 3 mit vertauschten Rollen von i und j . Weil $\Delta(s, t)$ dabei nach Schritt 1 dasselbe bleibt, gibt es $\tilde{\sigma}$ zwischen 0 und t sowie $\tilde{\tau}$ zwischen 0 und s mit

$$st \partial_j \partial_i f(\mathbf{x} + \sigma\mathbf{e}_i + \tau\mathbf{e}_j) = st \partial_i \partial_j f(\mathbf{x} + \tilde{\tau}\mathbf{e}_i + \tilde{\sigma}\mathbf{e}_j).$$

Wir teilen durch $st \neq 0$ und lassen $s, t \rightarrow 0$ laufen. Beide Argumente streben gegen $\mathbf{x}$, und weil die zweiten partiellen Ableitungen stetig sind, streben beide Seiten gegen $\partial_j \partial_i f(\mathbf{x})$ beziehungsweise $\partial_i \partial_j f(\mathbf{x})$.

hier geht die Voraussetzung $f \in \mathcal{C}^2$ ein; ohne Stetigkeit der zweiten Ableitungen könnten die beiden Grenzwerte auseinanderfallen, und es gibt Gegenbeispiele dieser Art

□

Bemerkung 10.7.5 (Was die Symmetrie spart)

Aus Satz 10.7.4 folgt sofort $\mathbf{H}_f(\mathbf{x}) = \mathbf{H}_f(\mathbf{x})^\top$: Die Hesse-Matrix einer $\mathcal{C}^2$ -Funktion ist symmetrisch. Die Reihenfolge, in der wir partiell ableiten, spielt also keine Rolle.

Statt aller n^2 Einträge müssen wir nur die $n(n+1)/2$ Einträge auf und über der Diagonalen berechnen und speichern. Für $n = 100$ sind das 5050 statt 10 000 Zahlen, für $n = 1000$ schon 500 500 statt einer Million. Das ist etwas *mehr* als die Hälfte, nicht weniger, denn $n(n+1)/2 = n^2/2 + n/2$. Der Quotient fällt mit wachsendem n von 0,75 bei $n = 2$ auf 0,5005 bei $n = 1000$. Die Symmetrie zahlt sich auch beim Lösen von Systemen mit $\mathbf{H}_f$ aus: Ist $\mathbf{H}_f$ zusätzlich positiv definit, wie oft in der Nähe eines Minimums, so bietet sich das Cholesky-Verfahren aus Abschnitt 5.4 an. Für symmetrische Matrizen gilt außerdem der Spektralsatz (Orthonormalbasis aus Eigenvektoren, reelle Eigenwerte); darauf beruht alles Weitere in diesem Abschnitt.

Satz 10.7.6 (Erste und zweite Ableitung in Koordinaten)

Seien $S \subseteq \mathbb{R}^n$ offen, $f \in \mathcal{C}^2(S)$ und $\mathbf{x} \in S$. Dann gilt für alle $\mathbf{h}, \mathbf{h}_1, \mathbf{h}_2 \in \mathbb{R}^n$

$$D_{\mathbf{x}} f(\mathbf{h}) = \nabla f(\mathbf{x}) \mathbf{h} \quad \text{und} \quad D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) = \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2.$$

Die erste Formel kennen wir aus Abschnitt 10.2. Für die zweite fragt die Definition, wie sich $D_{\mathbf{x}} f(\mathbf{h}_1) = \nabla f(\mathbf{x}) \mathbf{h}_1$ ändert, wenn wir $\mathbf{x}$ um $\mathbf{h}$ verschieben. Weil jede Komponente des Gradienten differenzierbar ist, gilt $\nabla f(\mathbf{x} + \mathbf{h}) - \nabla f(\mathbf{x}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) + o(\|\mathbf{h}\|)$, und eingesetzt in (10.7.1) mit $j = 2$ ergibt das $D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1$, nach Satz 10.7.4 gleich $\mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}$.

Vertiefung (optional): Beweis der Koordinatenformeln für die ersten beiden Ableitungen

Beweis.

- (1) Die erste Formel ist Gleichung (10.2.1) aus Abschnitt 10.2: Der Gradient ist der Zeilenvektor der partiellen Ableitungen, und $\mathbf{h} \mapsto \nabla f(\mathbf{x}) \mathbf{h}$ ist die zugehörige lineare Abbildung.

dort mit $\mathbf{h} = \mathbf{e}_j$ hergeleitet: eine lineare Abbildung ist durch ihre Werte auf den Koordinatenrichtungen festgelegt

- (2) Für die zweite Formel setzen wir $j = 2$ in (10.7.1). Das Produkt über $i = 1, \dots, 1$ ist $\|\mathbf{h}_1\|$, und beide D^1 -Terme schreiben wir nach Schritt 1 in Gradientenform:

$$D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}) = (\nabla f(\mathbf{x} + \mathbf{h}) - \nabla f(\mathbf{x})) \mathbf{h}_1 + o(\|\mathbf{h}\|) \|\mathbf{h}_1\|.$$

(10.7.1) mit $j = 2$; $D_{\mathbf{x}+\mathbf{h}}^1 f(\mathbf{h}_1) = \nabla f(\mathbf{x} + \mathbf{h}) \mathbf{h}_1$ und ebenso an der Stelle $\mathbf{x}$

- (3) Der Gradient ist selbst eine Abbildung, nämlich $\mathbf{g} : S \rightarrow \mathbb{R}^n$, $\mathbf{g}(\mathbf{x}) := \nabla f(\mathbf{x})^\top$. Ihre Jacobimatrix hat die Einträge

$$J_{\mathbf{g}}(\mathbf{x})_{ij} = \frac{\partial}{\partial x_j} \frac{\partial f(\mathbf{x})}{\partial x_i} = \mathbf{H}_f(\mathbf{x})_{ji} = \mathbf{H}_f(\mathbf{x})_{ij},$$

also $J_{\mathbf{g}}(\mathbf{x}) = \mathbf{H}_f(\mathbf{x})$. Weil $f \in \mathcal{C}^2$ ist, sind alle diese Einträge stetig, und damit ist $\mathbf{g}$ differenzierbar:

$$\nabla f(\mathbf{x} + \mathbf{h})^\top = \nabla f(\mathbf{x})^\top + \mathbf{H}_f(\mathbf{x}) \mathbf{h} + \mathbf{r}(\mathbf{h}), \quad \|\mathbf{r}(\mathbf{h})\| = o(\|\mathbf{h}\|).$$

Satz 10.7.4 macht $\mathbf{H}_f$ symmetrisch, deshalb dürfen wir die Indizes tauschen; dass stetige partielle Ableitungen schon die volle Differenzierbarkeit von g nach sich ziehen, ist ein Standardsatz der Analysis, den wir hier als bekannt voraussetzen

- (4) Transponieren wir die letzte Zeile und setzen sie in Schritt 2 ein, so wird aus der Differenz der Gradienten $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) + \mathbf{r}(\mathbf{h})^\top$, und

$$D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1 + \mathbf{r}(\mathbf{h})^\top \mathbf{h}_1 + o(\|\mathbf{h}\|) \|\mathbf{h}_1\|.$$

Der ganze rote Rest ist $o(\|\mathbf{h}\|) \|\mathbf{h}_1\|$, denn $|\mathbf{r}(\mathbf{h})^\top \mathbf{h}_1| \leq \|\mathbf{r}(\mathbf{h})\| \|\mathbf{h}_1\|$ nach Cauchy-Schwarz. Halten wir nun $\mathbf{h}_1$ fest, so sind $\mathbf{h} \mapsto D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h})$ und $\mathbf{h} \mapsto \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1$ zwei lineare Abbildungen, die sich nur um $o(\|\mathbf{h}\|)$ unterscheiden, und solche Abbildungen sind gleich. Also ist $D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1$, und wegen der Symmetrie von $\mathbf{H}_f(\mathbf{x})$ ist das gleich $\mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}$. Mit $\mathbf{h}_2 := \mathbf{h}$ steht die Behauptung da.

das Eindeutigkeitsargument aus dem letzten Schritt des Beweises zu Satz 10.5.5: $\mathbf{h} = t\mathbf{u}$ einsetzen, der Quotient hängt nicht von t ab und muss null sein

□

Die Formel $D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) = \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2$ ist in beiden Argumenten linear, also eine bilineare Abbildung im Sinne von Definition 10.6.1. Für $\mathbf{h}_1 = \mathbf{h}_2 = \mathbf{h}$ wird daraus die quadratische Form $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}$, und die misst die Krümmung von f in Richtung $\mathbf{h}$.

Beispiel 10.7.7 (Gradient und Hesse-Matrix einer kubischen Funktion)

Sei $f(\mathbf{x}) = \frac{1}{3}x_1^3 - x_1 + x_2^2$. Die ersten partiellen Ableitungen sind $\partial f / \partial x_1 = x_1^2 - 1$ und $\partial f / \partial x_2 = 2x_2$, also

$$\nabla f(\mathbf{x}) = (x_1^2 - 1 \quad 2x_2) \in \mathbb{R}^{1 \times 2}, \quad \mathbf{H}_f(\mathbf{x}) = \begin{pmatrix} 2x_1 & 0 \\ 0 & 2 \end{pmatrix}.$$

Die Hesse-Matrix hängt hier von $\mathbf{x}$ ab. Kritische Punkte gibt es zwei, $(1, 0)$ und $(-1, 0)$. In $(1, 0)$ ist $\mathbf{H}_f = \text{diag}(2, 2)$ mit zwei positiven Eigenwerten, in $(-1, 0)$ ist $\mathbf{H}_f = \text{diag}(-2, 2)$ mit einem negativen und einem positiven. Von $(-1, 0)$ aus gilt etwa

$$\begin{aligned} f(-0,8; 0) - f(-1; 0) &= -0,0373 < 0, \\ f(-1; 0,2) - f(-1; 0) &= +0,0400 > 0. \end{aligned}$$

f fällt dort also entlang der ersten Koordinate und steigt entlang der zweiten; $(-1, 0)$ ist weder Minimum noch Maximum. In $(1, 0)$ steigt f in jede Richtung, dort liegt ein lokales Minimum mit Wert $f(1, 0) = -2/3$.

Bemerkung 10.7.8 (Die dritte Ableitung ist ein Tensor)

Für $j = 3$ passt kein Matrixformat mehr. Wir schreiben $D_{\mathbf{x}}^3 f \in \mathbb{R}^{n \times n \times n}$ mit den Einträgen

$$(D_{\mathbf{x}}^3 f)_{i,j,k} = \frac{\partial^3 f(\mathbf{x})}{\partial x_k \partial x_j \partial x_i}, \quad D_{\mathbf{x}}^3 f(\mathbf{h}_1, \mathbf{h}_2, \mathbf{h}_3) = \sum_{i,j,k} (D_{\mathbf{x}}^3 f)_{i,j,k} h_{1i} h_{2j} h_{3k}.$$

Das ist ein Tensor dritter Stufe (Abschnitt 9.2) mit n^3 Einträgen. Für $f \in \mathcal{C}^3$ ist er in allen drei Indizes symmetrisch.

Krümmung, Definitheit und kritische Punkte

Die Hesse-Matrix beschreibt die lokale Krümmung von f . Das Vorzeichenmuster ihrer reellen Eigenwerte entscheidet über die Art des kritischen Punktes.

Satz 10.7.9 (Hesse-Kriterium für kritische Punkte)

Seien $S \subseteq \mathbb{R}^n$ offen, $f \in \mathcal{C}^2(S)$ und $\mathbf{x}^* \in S$ ein kritischer Punkt, also $\nabla f(\mathbf{x}^*) = \mathbf{0}$. Dann gilt:

1. Ist $\mathbf{H}_f(\mathbf{x}^*)$ positiv definit, gilt also $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} > 0$ für alle $\mathbf{h} \neq \mathbf{0}$, so ist $\mathbf{x}^*$ ein striktes lokales Minimum.
2. Ist $\mathbf{H}_f(\mathbf{x}^*)$ negativ definit, gilt also $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} < 0$ für alle $\mathbf{h} \neq \mathbf{0}$, so ist $\mathbf{x}^*$ ein striktes lokales Maximum.
3. Ist $\mathbf{H}_f(\mathbf{x}^*)$ indefinit, hat also positive und negative Eigenwerte, so ist $\mathbf{x}^*$ ein *Sattelpunkt*: In jeder noch so kleinen Umgebung von $\mathbf{x}^*$ liegen Punkte mit größerem und Punkte mit kleinerem Funktionswert.

Den Beweis liefert die Taylorentwicklung zweiter Ordnung aus Abschnitt 10.8: In einem kritischen Punkt fällt der lineare Term weg, und es bleibt

$$f(\mathbf{x}^* + \mathbf{h}) = f(\mathbf{x}^*) + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} + o(\|\mathbf{h}\|^2).$$

Ist $\mathbf{H}_f(\mathbf{x}^*)$ positiv definit mit kleinstem Eigenwert $\lambda_{\min} > 0$, so ist der Krümmungsterm mindestens $\frac{1}{2} \lambda_{\min} \|\mathbf{h}\|^2$, während der rote Rest schneller als $\|\mathbf{h}\|^2$ verschwindet. Für hinreichend kleine $\mathbf{h} \neq \mathbf{0}$ gewinnt also die Krümmung, und $f(\mathbf{x}^* + \mathbf{h}) > f(\mathbf{x}^*)$. Bei einem indefiniten $\mathbf{H}_f(\mathbf{x}^*)$ führen wir dasselbe Argument entlang der beiden Eigenrichtungen zu einem positiven und einem negativen Eigenwert getrennt durch.

Bemerkung 10.7.10 (Wenn die Hesse-Matrix nichts entscheidet)

Die drei Fälle in Satz 10.7.9 decken nicht alles ab. Offen bleibt der Grenzfall, in dem $\mathbf{H}_f(\mathbf{x}^*)$ semidefinit, aber nicht definit ist: Mindestens ein Eigenwert ist null, und die übrigen haben dasselbe Vorzeichen. Dann entscheidet die zweite Ableitung nichts. Schon in einer Variablen sehen wir das an drei Funktionen mit $f'(0) = f''(0) = 0$:

$$f(x) = x^4 \text{ (Minimum),} \quad f(x) = -x^4 \text{ (Maximum),} \quad f(x) = x^3 \text{ (weder noch).}$$

In allen drei Fällen ist $\mathbf{H}_f(0) = (0)$, also zugleich positiv und negativ semidefinit. Erst die dritte beziehungsweise vierte Ableitung trennt die Fälle.

Umgekehrt folgt aus einem lokalen Minimum in $\mathbf{x}^*$ nur, dass $\mathbf{H}_f(\mathbf{x}^*)$ positiv *semidefinit* ist; die strikte Ungleichung darf verloren gehen, wie $f(x) = x^4$ zeigt.

Das folgende Widget zeichnet die Höhenlinien von $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{H} \mathbf{x}$. Diese Funktion hat an jeder Stelle dieselbe Hesse-Matrix $\mathbf{H}$, und $\mathbf{0}$ ist ein kritischer Punkt, für invertierbares $\mathbf{H}$ der einzige. Eingestellt werden nicht die Einträge von $\mathbf{H}$, sondern nach dem Spektralsatz die Eigenwerte und die Lage der Eigenbasis: $\mathbf{H} = \mathbf{R}(\varphi) \text{diag}(\lambda_1, \lambda_2) \mathbf{R}(\varphi)^\top$ mit einer Drehung $\mathbf{R}(\varphi)$.

Interaktiv: Hesse-Kriterium und Höhenlinien

Was passiert mit den Höhenlinien, wenn ein Eigenwert das Vorzeichen wechselt oder genau auf null steht?

Interaktives Element — nur in der Web-Fassung

Der erste Knopf setzt $\lambda = (2, 8)$ und $\varphi = 0$, also $\mathbf{H} = \text{diag}(2, 8)$ und $f(\mathbf{x}) = x_1^2 + 4x_2^2$; die Höhenlinien sind Ellipsen um das Minimum in $\mathbf{0}$, und das bleiben sie, solange $\mathbf{H}$ definit ist. Ihre Hauptachsen liegen in Richtung der Eigenvektoren, und die Krümmung längs einer Hauptachse ist der zugehörige Eigenwert, denn $f(t\mathbf{v}_i) = \frac{1}{2}\lambda_i t^2$. Die lange Halbachse gehört deshalb zum *kleinen* Eigenwert (Niveau 4: Halbachsen 2 und 1). Der Regler φ dreht Höhenlinien und Hauptachsen gemeinsam und lässt die Eigenwerte unverändert. Schieben wir einen Eigenwert unter null, so werden aus den Ellipsen Hyperbeln und aus dem Niveau 0 ein Geradenkreuz: der Sattel aus Satz 10.7.9(3), wie im Gradientenfeld-Widget von Abschnitt 10.2 mit den Eigenwerten 6,162 und $-0,162$.

Konvexität

Die Definitheit im kritischen Punkt ist eine lokale Aussage. Verlangen wir sie überall, so bekommen wir eine globale Eigenschaft.

Satz 10.7.11 (Konvexität und positive Semidefinitheit)

Seien $S \subseteq \mathbb{R}^n$ offen und *konvex* und $f \in \mathcal{C}^2(S)$. Dann gilt

$$f \text{ ist konvex auf } S \iff \mathbf{H}_f(\mathbf{x}) \succeq 0 \text{ (positiv semidefinit) für alle } \mathbf{x} \in S.$$

Für eine konvexe Funktion liegt die Verbindungsstrecke zwischen zwei Punkten des Graphen nie unter dem Graphen. Satz 10.7.11 übersetzt das in eine punktweise Bedingung an die zweite Ableitung. Konvexe Optimierungsprobleme sind handhabbar, weil dort jeder kritische Punkt schon ein globales Minimum ist; Sattelpunkte, an denen ein Verfahren hängenbleiben könnte, gibt es nicht.

Vertiefung (optional): Zwei Gegenbeispiele zu den Voraussetzungen offen und konvex

Bemerkung 10.7.12 (Warum die Menge offen und konvex sein muss)

Beide Zusätze in Satz 10.7.11 sind nötig.

S muss konvex sein. Sonst ist die linke Seite gar nicht definiert: Die Konvexitätsbedingung spricht über Punkte $t\mathbf{x} + (1-t)\mathbf{y}$ auf der Verbindungsstrecke, und die kann S verlassen. Nehmen wir $S = (-2, -1) \cup (1, 2) \subset \mathbb{R}$, offen, aber nicht konvex, und darauf $f \equiv -5$ auf dem linken und $f \equiv 0$ auf dem rechten Stück. Dann ist $f'' \equiv 0 \geq 0$ auf ganz S . Trotzdem gibt es keine konvexe Funktion auf $\mathbb{R}$, die f fortsetzt: Eine konvexe Funktion hat nichtfallende Steigung, und wer links die Steigung 0 hat und danach um 5 steigt, kann rechts nicht wieder bei Steigung 0 ankommen. *S muss offen sein.* Sonst scheitert die Richtung von links nach rechts. Sei S die x_1 -Achse im $\mathbb{R}^2$, also konvex, aber ohne innere Punkte, und $f(\mathbf{x}) = x_1^2 - x_2^2$. Auf S ist $f(x_1, 0) = x_1^2$, also konvex. Die Hesse-Matrix ist überall $\text{diag}(2, -2)$ und damit indefinit. Die Äquivalenz bricht, weil die Bedingung an $\mathbf{H}_f$ Information aus Richtungen zieht, die in S gar nicht vorkommen. Sobald S offen und konvex ist, stimmt die Äquivalenz.

1. Gilt $\mathbf{H}_f(\mathbf{x}) \succeq 0$ für alle $\mathbf{x}$ einer beliebigen Menge $S \subseteq \mathbb{R}^n$, so ist f auf S konvex.

Antwort: Falsch

Ohne Zusatzbedingungen an S ist die Behauptung nicht einmal sinnvoll. Auf $S = (-2, -1) \cup (1, 2)$ mit $f \equiv -5$ links und $f \equiv 0$ rechts ist $f'' \equiv 0$, aber die Verbindungsstrecke zwischen zwei Punkten verlässt S , und eine konvexe Fortsetzung auf $\mathbb{R}$ gibt es nicht. Satz 10.7.11 verlangt S offen und konvex (Bemerkung 10.7.12).

Konvexität und ihre Folgen für Optimierungsverfahren behandelt Kapitel 11.

Warum das in der Praxis zählt

Bemerkung 10.7.13 (Praxisrelevanz der Hesse-Matrix)

Sattelpunkte in hoher Dimension. Ein kritischer Punkt mit invertierbarer Hesse-Matrix ist nur dann ein Extremum, wenn *alle* n Eigenwerte dasselbe Vorzeichen haben. Wären die n Vorzeichen unabhängige Münzwürfe, so hätte ein Minimum die Wahrscheinlichkeit 2^{-n} und irgendein Extremum die Wahrscheinlichkeit 2^{1-n} , für $n = 100$ also $7,9 \cdot 10^{-31}$ beziehungsweise $1,6 \cdot 10^{-30}$. Die Eigenwerte sind nicht unabhängig, die Zählung ist nur eine Faustregel. Sie macht aber plausibel, warum in hochdimensionalen Verlustlandschaften Sattelpunkte häufig sind; das Rauschen des stochastischen Gradientenabstiegs kann helfen, sie zu verlassen.

Statistik. Der wichtigste Spezialfall einer Funktion $\mathbb{R}^p \rightarrow \mathbb{R}$ ist die Log-Likelihood $\ell(\theta)$. Die Hesse-Matrix der negativen Log-Likelihood heißt *beobachtete Fisher-Information* und bestimmt, wie genau ein Schätzer den Parameter trifft (nächster Unterabschnitt).

Maschinelles Lernen. Die Hesse-Matrix der Verlustfunktion bestimmt die Kondition des Optimierungsproblems. Im streng konvexen quadratischen Fall hängt die Konvergenzrate des Gradientenabstiegs aus Abschnitt 10.2 am Verhältnis $\kappa = \lambda_{\max}/\lambda_{\min}$ der extremen Eigenwerte: Bei optimal gewählter Lernrate schrumpft der Abstand zum Minimum je Schritt auf das $(\kappa - 1)/(\kappa + 1)$ -fache, bei $\kappa = 1000$ also auf das 0,998-fache, und das Verfahren kommt kaum voran.

Optimierung. Verfahren, die $\mathbf{H}_f$ in der Iteration benutzen, konvergieren lokal deutlich schneller. Das Newton-Verfahren in Abschnitt 10.8 ist der Prototyp.

Anwendung: Fisher-Information

Definition 10.7.14 (Fisher-Informationsmatrix)

Für ein statistisches Modell mit Log-Likelihood $\ell(\theta)$ und Parameter $\theta \in \mathbb{R}^p$ ist unter den üblichen Regularitätsbedingungen, die insbesondere das Differenzieren unter dem Erwartungswert erlauben, die *Fisher-Informationsmatrix* definiert als

$$\mathbf{I}(\theta) := \mathbb{E} [-\mathbf{H}_\ell(\theta)] = -\mathbb{E} \left[\frac{\partial^2 \ell(\theta)}{\partial \theta_i \partial \theta_j} \right]_{i,j} \in \mathbb{R}^{p \times p}.$$

Das $\mathbb{E}$ ist hier der Erwartungswert über die Daten bei festem wahren θ , nicht der Zielraum aus Definition 10.7.1. Lassen wir den Erwartungswert weg, so erhalten wir die *beobachtete* Fisher-Information $-\mathbf{H}_\ell(\theta)$ am jeweiligen Parameterwert; häufig wird sie am ML-Schätzer $\hat{\theta}$ ausgewertet.

Die Interpretation folgt aus der Krümmung. Eine stark gekrümmte Log-Likelihood fällt neben ihrem Maximum steil ab: Benachbarte Parameterwerte erklären die Daten deutlich schlechter, die Daten sind also *informativ* über θ . Eine flache Log-Likelihood lässt einen weiten Bereich von Parametern fast gleich gut aussehen, und der Parameter ist schwer zu schätzen. Für den

ML-Schätzer gilt unter Regularitätsbedingungen bei großem Stichprobenumfang näherungsweise $\text{Var}(\hat{\theta}) \approx \mathbf{I}(\theta)^{-1}$, wobei ℓ die Log-Likelihood der ganzen Stichprobe ist. Er erreicht damit asymptotisch die *Cramér-Rao-Schranke*, die untere Schranke für die Varianz erwartungstreuer Schätzer: mehr Information, kleinere Varianz, präzisere Schätzung.

Vertiefung (optional): Fisher-Information im Bernoulli-Modell und Cramér-Rao-Schranke

Unter den Regularitätsbedingungen aus Definition 10.7.14 ist die erwartete Score-Funktion null, und es gilt außerdem $\mathbf{I}(\theta) = \mathbb{E}[\nabla \ell(\theta) \nabla \ell(\theta)^{\top}]$.

Beispiel 10.7.15 (Fisher-Information im Bernoulli-Modell)

Seien $y_1, \dots, y_n$ unabhängige, identisch verteilte Bernoulli-Variablen mit Erfolgswahrscheinlichkeit $0 < p < 1$. Die Log-Likelihood ist

$$\ell(p) = \sum_{i=1}^n [y_i \log p + (1 - y_i) \log(1 - p)].$$

Zweimal ableiten ergibt

$$\ell''(p) = - \sum_{i=1}^n \left[\frac{y_i}{p^2} + \frac{1 - y_i}{(1 - p)^2} \right],$$

und mit $\mathbb{E}[y_i] = p$ folgt

$$\mathbf{I}_n(p) = \mathbb{E}[-\ell''(p)] = n \left[\frac{p}{p^2} + \frac{1 - p}{(1 - p)^2} \right] = n \left[\frac{1}{p} + \frac{1}{1 - p} \right] = \frac{n}{p(1 - p)}.$$

Der ML-Schätzer ist hier der Mittelwert $\hat{p} = \bar{y}$, und seine Varianz ist bekannt: $\text{Var}(\hat{p}) = p(1 - p)/n$. Das ist exakt $\mathbf{I}_n(p)^{-1}$, in diesem Modell also keine Näherung. Mit $p = 0,2$ und $n = 100$ steht dort $\mathbf{I}_n = 625$, damit $\text{Var}(\hat{p}) = 0,0016$ und eine Standardabweichung von 0,04.

Die Krümmungsinterpretation lässt sich am selben Beispiel ablesen, weiterhin mit $n = 100$. Am flachsten ist die Log-Likelihood bei $p = 0,5$: Dort steuert eine einzelne Beobachtung nur $\mathbf{I}_1 = 4$ bei, und $\text{Var}(\hat{p}) = 0,0025$ ist am größten. Bei $p = 0,05$ ist $\mathbf{I}_1 = 21,05$, also gut das Fünffache, und $\text{Var}(\hat{p}) = 0,000475$: Nahe am Rand des Parameterbereichs sind die Daten deutlich informativer.

Bemerkung 10.7.16 (Cramér-Rao-Schranke und Asymptotik)

Als Merksatz kursiert $\text{Var}(\hat{\theta}) \rightarrow \mathbf{I}(\theta)^{-1}$ für $n \rightarrow \infty$. Gemeint ist das Richtige, aber so verkürzt vermischt sie drei Dinge.

Die Abhängigkeit von n . Ein konsistenter Schätzer hat $\text{Var}(\hat{\theta}) \rightarrow \mathbf{0}$; gegen eine feste Matrix kann die Varianz also nicht streben. Die Aussage trägt nur, wenn $\mathbf{I}$ die Information der *ganzen* Stichprobe meint. Für unabhängige, identisch verteilte Beobachtungen ist $\mathbf{I}_n(\theta) = n \mathbf{I}_1(\theta)$, und die Faustformel lautet

$$\text{Var}(\hat{\theta}) \approx \mathbf{I}_n(\theta)^{-1} = \frac{1}{n} \mathbf{I}_1(\theta)^{-1}.$$

Die asymptotische Fassung. Unter Regularitätsbedingungen gilt für den ML-Schätzer

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(\mathbf{0}, \mathbf{I}_1(\theta)^{-1}),$$

und daraus lesen wir die Faustformel als Näherung für endliches n ab.

Der Name. Die Cramér-Rao-Schranke selbst ist keine asymptotische Aussage, sondern gilt bei festem n und für erwartungstreue Schätzer: Deren Kovarianzmatrix erfüllt $\text{Var}(\hat{\theta}) \succeq \mathbf{I}_n(\theta)^{-1}$ im Sinne der Definitheit. Der ML-Schätzer ist im Allgemeinen nicht erwartungstreu und erreicht die Schranke erst asymptotisch. Im Bernoulli-Beispiel 10.7.15 fällt beides zusammen, weil $\hat{p}$ erwartungstreu ist und die Schranke exakt annimmt.

In allen drei Fassungen bleibt die Merksatz dieselbe: mehr Information, kleinere Varianz, präzisere Schätzung.

1. Für den ML-Schätzer gilt bei jedem Stichprobenumfang $\text{Var}(\hat{\theta}) = \mathbf{I}(\theta)^{-1}$.

Antwort: Falsch

Gemeint ist eine asymptotische Aussage. Bei festem n gilt die Cramér-Rao-Schranke $\text{Var}(\hat{\theta}) \succeq \mathbf{I}_n(\theta)^{-1}$, und zwar für erwartungstreue Schätzer; der ML-Schätzer ist im Allgemeinen verzerrt und erreicht die Schranke erst für $n \rightarrow \infty$, in der Form $\sqrt{n}(\hat{\theta}_n - \theta) \rightarrow N(\mathbf{0}, \mathbf{I}_1(\theta)^{-1})$ (Bemerkung 10.7.16). Das Bernoulli-Modell ist ein Sonderfall, in dem Gleichheit schon für endliches n gilt.

Vektor zu Vektor

Zum Schluss der allgemeine Fall $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$. Die *Score-Funktion* $\nabla \ell(\theta)^\top: \mathbb{R}^p \rightarrow \mathbb{R}^p$ ist von dieser Bauart; transponiert wird, weil $\nabla \ell(\theta)$ in der Zeilenkonvention aus Abschnitt 10.2 eine Zeile ist. Ihre Jacobimatrix ist die Hesse-Matrix $\mathbf{H}_\ell(\theta)$, aus der die Fisher-Information entsteht. Momentengleichungen sind ein zweites Beispiel.

Nach Definition 10.7.1 ist die j -te Ableitung eine multilineare Abbildung $D_{\mathbf{x}}^j f: (\mathbb{R}^n)^j \rightarrow \mathbb{R}^m$. Als Zahlenschema ist das ein Tensor der Stufe $j+1$ mit den Dimensionen

$$m \times \underbrace{n \times n \times \cdots \times n}_{j\text{-mal}},$$

also $m n^j$ Einträgen. In Koordinaten lautet die Auswertung

$$D_{\mathbf{x}}^j f(\mathbf{h}_1, \dots, \mathbf{h}_j) = \sum_{i_1, \dots, i_j=1}^n \underbrace{\frac{\partial^j f(\mathbf{x})}{\partial x_{i_j} \cdots \partial x_{i_1}}}_{\in \mathbb{R}^m} h_{1,i_1} \cdots h_{j,i_j}.$$

Die Ausgabe ist also eine Summe von Vektoren aus $\mathbb{R}^m$, gewichtet mit Produkten von Komponenten der $\mathbf{h}_i$. Für die ersten drei Stufen ausgeschrieben, rechts jeweils über die Jacobimatrix ausgedrückt:

Satz 10.7.17 (Die ersten drei Stufen für Vektor-zu-Vektor)

Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ hinreichend oft stetig differenzierbar. Dann gilt

$$\begin{aligned} D_{\mathbf{x}}f(\mathbf{h}) &= \sum_{i=1}^n \frac{\partial f(\mathbf{x})}{\partial x_i} h_i = \mathbf{J}_f(\mathbf{x}) \mathbf{h}, \\ D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) &= \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i} h_{1,i} h_{2,j} = \sum_{i=1}^n \frac{\partial \mathbf{J}_f(\mathbf{x})}{\partial x_i} \mathbf{h}_1 \cdot h_{2,i}, \\ D_{\mathbf{x}}^3 f(\mathbf{h}_1, \mathbf{h}_2, \mathbf{h}_3) &= \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n \frac{\partial^3 f(\mathbf{x})}{\partial x_k \partial x_j \partial x_i} h_{1,i} h_{2,j} h_{3,k} = \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 \mathbf{J}_f(\mathbf{x})}{\partial x_j \partial x_i} \mathbf{h}_1 \cdot h_{2,i} \cdot h_{3,j}. \end{aligned} \quad (10.7.2)$$

Vertiefung (optional): Herleitung der drei Stufen

Beweis.

- (1) Die erste Zeile ist die Jacobimatrix aus Abschnitt 10.3: Die i -te Spalte von $\mathbf{J}_f(\mathbf{x})$ ist $\partial f(\mathbf{x})/\partial x_i \in \mathbb{R}^m$, und das Produkt $\mathbf{J}_f(\mathbf{x})\mathbf{h}$ summiert die Spalten mit den Gewichten h_i .

Definition 10.3.1: $\mathbf{J}_f(\mathbf{x})_{a,i} = \partial f_a(\mathbf{x})/\partial x_i$; Matrix mal Vektor ist die gewichtete Spaltensumme

- (2) Die zweite und die dritte Zeile sind Umbenennungen von Indizes: Schreiben wir beide Seiten komponentenweise aus, so stehen nach Umbenennung der Summationsindizes zweimal dieselben Summanden.

Umbenennen gebundener Summationsindizes ändert nichts; der Satz von Schwarz wird hier nirgends gebraucht, die Identität ist rein kombinatorisch

- (3) Zur Kontrolle der Spezialfall $m = 1$. Dann ist $\mathbf{J}_f(\mathbf{x}) = \nabla f(\mathbf{x})$ ein Zeilenvektor, und $\partial \nabla f(\mathbf{x})/\partial x_i$ ist die i -te Zeile von $\mathbf{H}_f(\mathbf{x})$. Die zweite Zeile von (10.7.2) wird damit zu

$$\sum_{i=1}^n (\mathbf{H}_f(\mathbf{x}) \mathbf{h}_1)_i h_{2,i} = \mathbf{h}_2^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1 = \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2,$$

also Satz 10.7.6.

der letzte Schritt nutzt die Symmetrie aus Satz 10.7.4; ohne sie stünde dort die Transponierte

□

Weil die j -te Stufe schon $m n^j$ Einträge hat, werden zweite Ableitungen in der Praxis fast nur für skalarwertige Funktionen aufgestellt, und auch dort oft nur näherungsweise.

Selbsttest

1. Ist $f : S \rightarrow \mathbb{R}$ auf der offenen Menge S zweimal stetig differenzierbar, so ist die Hesse-Matrix in jedem Punkt symmetrisch.

Antwort: Wahr

Das ist der Satz von Schwarz (Satz 10.7.4); die Stetigkeit der zweiten Ableitungen ist dabei wesentlich.

2. Der Satz von Schwarz senkt die Zahl der zu berechnenden zweiten Ableitungen von n^2 auf $n(n+1)/2$, also auf weniger als die Hälfte.

Antwort: Falsch

Die Zahlen stimmen, der Zusatz nicht: $n(n+1)/2 = n^2/2 + n/2$ ist etwas *mehr* als die Hälfte von n^2 . Für $n = 100$ sind es 5050 statt 5000. Erst für große n nähert sich der Quotient der Hälfte an, bei $n = 1000$ liegt er bei 0,5005 (Bemerkung 10.7.5).

3. Verschwindet der Gradient in $\mathbf{x}^*$ und ist $\mathbf{H}_f(\mathbf{x}^*)$ positiv semidefinit, so liegt in $\mathbf{x}^*$ ein lokales Minimum.

Antwort: Falsch

Semidefinit reicht nicht. Für $f(x) = x^3$ ist $f'(0) = f''(0) = 0$, die Hesse-Matrix (0) ist positiv semidefinit, und trotzdem liegt in 0 weder ein Minimum noch ein Maximum. Satz 10.7.9 verlangt positive *Definitheit*; im semidefiniten Grenzfall entscheidet die zweite Ableitung nichts (Bemerkung 10.7.10).

4. Die Abbildung $(\mathbf{h}_1, \mathbf{h}_2) \mapsto \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2$ ist in jedem der beiden Argumente linear.

Antwort: Wahr

Halten wir $\mathbf{h}_2$ fest, so ist die Zuordnung $\mathbf{h}_1 \mapsto \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2$ das Skalarprodukt mit einem festen Vektor, also linear; für $\mathbf{h}_1$ fest genauso. Damit ist $D_{\mathbf{x}}^2 f$ eine bilineare Abbildung im Sinne von Definition 10.6.1, so wie es Definition 10.7.1 für alle Stufen verlangt.

5. Nach der Münzwurf-Heuristik aus Bemerkung 10.7.13 sind in sehr hohen Dimensionen die meisten kritischen Punkte lokale Minima oder Maxima.

Antwort: Falsch

Umgekehrt. Ein Extremum verlangt bei invertierbarer Hesse-Matrix, dass alle n Eigenwerte dasselbe Vorzeichen haben; bei gemischten Vorzeichen liegt ein Sattelpunkt vor. Mit unabhängigen Vorzeichen hat ein Extremum irgendeiner Sorte die Wahrscheinlichkeit 2^{1-n} , für $n = 100$ also $1,6 \cdot 10^{-30}$. Das ist eine qualitative Motivation, keine Verteilungsaussage über reale Verlustlandschaften.

6. Stellen wir im Definitheits-Widget die Voreinstellung „Rinne (halbdefinit)“ ein. Welchen Wert hat dort $\det \mathbf{H}$?

Lösung: 0

Null. Die Voreinstellung setzt $\lambda = (3, 0)$, und wegen $\det \mathbf{H} = \lambda_1 \lambda_2$ ist die Determinante damit null, die Matrix also singulär. Im Bild wird das zu Parallelen statt Ellipsen: Entlang der Hauptachse zum Eigenwert 0 bleibt f konstant, statt eines isolierten kritischen Punktes liegt dort eine ganze Gerade davon. Satz 10.7.9 greift in diesem Fall nicht mehr (Bemerkung 10.7.10).

Vertiefung: MML §5.7 behandelt die höheren Ableitungen und die Hesse-Matrix; die Fisher-Information und die Cramér-Rao-Schranke stehen in jedem Lehrbuch zur mathematischen Statistik, etwa bei Casella und Berger, *Statistical Inference*, Kapitel 7.

10.8 Taylorapproximation

Vom linearen Blick zum Polynom

Abschnitt 10.1 hat die Ableitung als lineare Näherung mit Fehler $o(\|\mathbf{h}\|)$ eingeführt. Das ist die erste Stufe; mit den höheren Ableitungen aus Abschnitt 10.7 folgen quadratische, kubische und

weitere Näherungen, die Taylorapproximation. Wir brauchen sie auf zwei Arten. Wir rechnen mit dem Polynom statt mit f , weil sich seine Ableitungen und kritischen Punkte leichter bestimmen lassen; so bestimmt der Newton-Schritt am Ende dieses Abschnitts den stationären Punkt der quadratischen Näherung. Außerdem sind Taylorentwicklungen das Standardwerkzeug der Konvergenz- und Asymptotikanalyse, etwa für die asymptotische Normalität des Maximum-Likelihood-Schätzers. Die Farben bleiben: die Näherung T_k grün, der Restterm rot, Gradient und Hesse-Matrix orange.

Der eindimensionale Fall

Wir beginnen mit $f : \mathbb{R} \rightarrow \mathbb{R}$ und suchen ein Polynom, das sich an der Stelle x möglichst eng an f anschmiegt: Es soll dort denselben Wert, dieselbe Steigung, dieselbe Krümmung und so weiter haben wie f .

Definition 10.8.1 (Taylorpolynom)

Seien $S \subseteq \mathbb{R}$ offen und $f : S \rightarrow \mathbb{R}$ an der Stelle $x \in S$ k -mal differenzierbar. Das Polynom

$$T_k(h) := \sum_{j=0}^k \frac{1}{j!} f^{(j)}(x) h^j = f(x) + f'(x)h + \frac{1}{2} f''(x)h^2 + \dots + \frac{1}{k!} f^{(k)}(x)h^k \quad (10.8.1)$$

heißt *Taylorpolynom der Ordnung k* von f im *Entwicklungspunkt x* . Sein Grad ist höchstens k und kann kleiner sein, wenn die höchsten Koeffizienten verschwinden.

Wir lesen T_k als Funktion des Zuwachses h bei festem Entwicklungspunkt, wie die lineare Abbildung $D_x f$ aus Definition 10.1.5; die gebräuchliche zweite Schreibweise steht in Bemerkung 10.8.4. Leiten wir T_k j -mal nach h ab und setzen $h = 0$, so bleibt nur $f^{(j)}(x)$ stehen: Das ist die Anschmiegebedingung. Für $k = 1$ ist T_1 die Tangente aus Abschnitt 10.1, für $k = 0$ die Konstante $f(x)$.

Satz 10.8.2 (Taylorentwicklung I)

Seien $S \subseteq \mathbb{R}$ offen und $f : S \rightarrow \mathbb{R}$ $(k + 1)$ -mal stetig differenzierbar. Dann gilt für $x \in S$ und $h \rightarrow 0$

$$f(x + h) = f(x) + \sum_{j=1}^k \frac{1}{j!} f^{(j)}(x) h^j + o(|h|^k). \quad (10.8.2)$$

Genauer gibt es zu jedem hinreichend kleinen $h \neq 0$ eine Zwischenstelle ξ strikt zwischen x und $x + h$ mit

$$f(x + h) - T_k(h) = \frac{f^{(k+1)}(\xi)}{(k + 1)!} h^{k+1}. \quad (10.8.3)$$

Vertiefung (optional): Beweis der eindimensionalen Taylorentwicklung

Beweis.

- (1) Sei $h \neq 0$ so klein, dass das abgeschlossene Intervall zwischen x und $x + h$ ganz in S liegt. Wir bauen zwei Hilfsfunktionen auf diesem Intervall, beide in der Variablen t :

$$F(t) := \sum_{j=0}^k \frac{f^{(j)}(t)}{j!} (x + h - t)^j, \quad G(t) := (x + h - t)^{k+1}.$$

An den beiden Endpunkten stehen die Größen, um die es geht: $F(x + h) = f(x + h)$, denn alle Summanden mit $j \geq 1$ verschwinden, und $F(x) = T_k(h)$ nach (10.8.1). Ebenso ist $G(x + h) = 0$ und $G(x) = h^{k+1}$.

In F ist der Entwicklungspunkt die Variable und $x+h$ fest; genau umgekehrt zu (10.8.1). Stünde hier durchgehend $f^{(j)}(x)$ statt $f^{(j)}(t)$, so wäre F ein Polynom in t mit konstanten Koeffizienten und der nächste Schritt scheiterte

- (2) Jetzt leiten wir F nach t ab. Jeder Summand ist ein Produkt, die Produktregel liefert

$$\frac{d}{dt} \left[\frac{f^{(j)}(t)}{j!} (x + h - t)^j \right] = \frac{f^{(j+1)}(t)}{j!} (x + h - t)^j - \frac{f^{(j)}(t)}{(j-1)!} (x + h - t)^{j-1}.$$

Der erste Term für den Index j ist bis aufs Vorzeichen der zweite Term für den Index $j + 1$. Beim Aufsummieren heben sich deshalb alle Terme bis auf einen weg, und es bleibt der erste Term des letzten Summanden übrig:

$$F'(t) = \frac{f^{(k+1)}(t)}{k!} (x + h - t)^k. \quad (10.8.4)$$

Teleskopsumme: der Abzugsterm zu $j + 1$ löscht den Zuwachsterm zu j ; für $j = 0$ ist der Abzugsterm leer, weil dort kein $(j-1)$ -Summand existiert

- (3) Auch G leiten wir ab, $G'(t) = -(k+1)(x + h - t)^k$. Für t strikt zwischen x und $x + h$ ist $x + h - t \neq 0$, also $G'(t) \neq 0$. Damit sind die Voraussetzungen des Mittelwertsatzes in der Cauchyschen Fassung erfüllt: Es gibt ein ξ strikt zwischen x und $x + h$ mit

$$\frac{F(x + h) - F(x)}{G(x + h) - G(x)} = \frac{F'(\xi)}{G'(\xi)}.$$

F und G sind stetig auf dem abgeschlossenen und differenzierbar auf dem offenen Intervall, weil f nach Voraussetzung $(k+1)$ -mal stetig differenzierbar ist

- (4) Beide Seiten sind jetzt bekannt. Links steht

$$\frac{f(x + h) - T_k(h)}{0 - h^{k+1}},$$

rechts kürzt sich der Faktor $(x + h - \xi)^k$ aus (10.8.4) gegen denselben Faktor in $G'(\xi)$ weg:

$$\frac{F'(\xi)}{G'(\xi)} = \frac{f^{(k+1)}(\xi) / k!}{-(k+1)} = -\frac{f^{(k+1)}(\xi)}{(k+1)!}.$$

Multiplizieren wir mit $-h^{k+1}$, so steht (10.8.3) da.

Der Faktor $(x + h - \xi)^k$ ist nach Schritt 3 von null verschieden, das Kürzen ist also erlaubt. In der Zwischenstelle steht $f^{(k+1)}(\xi)$ und nicht $f^{(k+1)}(x)$; sonst wäre der Mittelwertsatz nicht gebraucht worden

- (5) Bleibt die Kleinheitsaussage (10.8.2). Wir wählen ein $\delta > 0$ so, dass das abgeschlossene Intervall $[x - \delta, x + \delta]$ noch in S liegt. Dort ist $f^{(k+1)}$ stetig auf einer abgeschlossenen und beschränkten Menge, also beschränkt, sagen wir durch M . Für $0 < |h| \leq \delta$ folgt

$$\frac{|f(x + h) - T_k(h)|}{|h|^k} = \frac{|f^{(k+1)}(\xi)|}{(k+1)!} |h| \leq \frac{M}{(k+1)!} |h| \xrightarrow{h \rightarrow 0} 0,$$

und das heißt gerade $f(x+h) - T_k(h) = o(|h|^k)$.

Stetigkeit in dem einen Punkt x liefert keine Schranke für die Werte an den Zwischenstellen ξ . Gebraucht wird Beschränktheit auf einer ganzen kompakten Umgebung, und die gibt es, weil $f^{(k+1)}$ dort stetig ist

□

Bemerkung 10.8.3 (Was der Satz sagt und was nicht)

Zwei Restglieder. Die Fassung (10.8.3) mit der Zwischenstelle heißt *Lagrange-Restglied*; sie ist eine Gleichung und liefert konkrete Schranken, sobald wir $f^{(k+1)}$ abschätzen können. Die *o*-Fassung (10.8.2) sagt nur etwas über $h \rightarrow 0$. Sie ist unsere Arbeitsform, weil sie sich auf normierte Vektorräume mit vollständigem Zielraum überträgt.

Warum $|h|^k$ und nicht $|h|^{k+1}$. Nach (10.8.3) ist der Rest sogar von der Ordnung $|h|^{k+1}$. Die schwächere Aussage gilt schon ohne die Voraussetzung „ $(k+1)$ -mal stetig differenzierbar“ und hat die Bauform von Definition 10.1.5: Näherung plus Rest, der schneller verschwindet als die letzte mitgenommene Potenz.

Der Grenzfall $k = 1$. Dann lautet (10.8.2) $f(x+h) = f(x) + f'(x)h + o(|h|)$, also Aussage (3) aus Satz 10.1.3. Die Taylorentwicklung verallgemeinert die Ableitungsdefinition.

Bemerkung 10.8.4 (Die zweite Schreibweise)

Oft wird das Taylorpolynom als Funktion der Auswertungsstelle geschrieben. Mit x_0 als Entwicklungspunkt und $h = x - x_0$ wird aus (10.8.1)

$$T_k(x) = \sum_{j=0}^k \frac{1}{j!} f^{(j)}(x_0) (x - x_0)^j, \quad f(x) = T_k(x) + o(|x - x_0|^k) \quad \text{für } x \rightarrow x_0.$$

Die *h*-Fassung zeigt die Struktur „Näherung plus Rest“, die x_0 -Fassung eignet sich zum Zeichnen.

Bemerkung 10.8.5 (Höher ist nicht automatisch besser)

Oft heißt es: je höher der Grad k , desto besser und globaler die Approximation. Nahe am Entwicklungspunkt stimmt das meist, und (10.8.3) erklärt, warum: Der Faktor $|h|^{k+1}/(k+1)!$ wird mit wachsendem k rasch klein. Eine Garantie ist es nicht, denn der andere Faktor $f^{(k+1)}(\xi)$ kann mindestens ebenso rasch wachsen.

Das Standardbeispiel ist $f(x) = 1/(1+x^2)$ mit Entwicklungspunkt 0. Bei $x = 0,5$ fallen die Fehler der Ordnungen $k = 2, 4, 8, 16$ von $5,0 \cdot 10^{-2}$ über $1,3 \cdot 10^{-2}$ und $7,8 \cdot 10^{-4}$ auf $3,1 \cdot 10^{-6}$. Bei $x = 1,5$ dagegen wachsen sie: 1,6, 3,5, 17,7 und 455. Die Taylorreihe dieser Funktion konvergiert nur für $|x| < 1$, obwohl f auf ganz $\mathbb{R}$ beliebig oft differenzierbar ist. Höhere Ordnung hilft also lokal, nicht global.

Beispiel 10.8.6 (Taylorapproximation der Exponentialfunktion)

Wir entwickeln $f(x) = e^x$ um $x_0 = 0$ bis zur Ordnung $k = 3$ und messen den Fehler bei $x = 0,5$.

Ableitungen. Für die Exponentialfunktion ist $f^{(j)}(x) = e^x$ für jedes $j \geq 0$, im Entwicklungspunkt also $f^{(j)}(0) = e^0 = 1$. Alle Koeffizienten sind damit $1/j!$.

Die *Polynome* in der Schreibweise von Bemerkung 10.8.4 mit $x_0 = 0$:

$$T_1(x) = 1 + x,$$

$$T_2(x) = 1 + x + \frac{1}{2!}x^2 = 1 + x + \frac{x^2}{2},$$

$$T_3(x) = 1 + x + \frac{x^2}{2} + \frac{1}{3!}x^3 = 1 + x + \frac{x^2}{2} + \frac{x^3}{6}.$$

Auswertung bei $x = 0,5$. Der wahre Wert ist $e^{0,5} \approx 1,6487$, und die drei Polynome liefern

$$T_1(0,5) = 1 + 0,5 = 1,5, \quad |f(0,5) - T_1(0,5)| \approx 0,1487,$$

$$T_2(0,5) = 1 + 0,5 + \frac{0,25}{2} = 1,625, \quad |f(0,5) - T_2(0,5)| \approx 0,0237,$$

$$T_3(0,5) = 1 + 0,5 + 0,125 + \frac{0,125}{6} \approx 1,6458, \quad |f(0,5) - T_3(0,5)| \approx 0,0029.$$

Das Lagrange-Restglied erklärt, wie schnell der Fehler fällt: Der Rest ist $e^\xi 0,5^{k+1}/(k+1)!$ mit einem $\xi \in (0; 0,5)$, beim Übergang von k auf $k+1$ kommt also im Wesentlichen der Faktor $0,5/(k+2)$ hinzu.

Gilt der Gewinn je Ordnung auch weit weg vom Entwicklungspunkt?

Interaktiv: Taylorpolynome der Exponentialfunktion

Ein Regler wählt die Ordnung k , ein zweiter die Stelle, an der wir den Fehler ablesen; voreingestellt ist $x = 0,5$ aus Beispiel 10.8.6.

Interaktives Element — nur in der Web-Fassung

Nahe am Entwicklungspunkt gewinnt jede weitere Ordnung viel. Links kehrt sich das um: Für $x \rightarrow -\infty$ geht e^x gegen null, jedes Taylorpolynom positiven Grades gegen $\pm\infty$, und bei $x = -3$ wächst der Fehler beim Schritt von T_0 auf T_1 von 0,950 auf 2,050. Der Faustwert $|x|/(k+1)$, mit dem sich der Fehler beim Schritt auf die Ordnung k multipliziert, gilt nur für kleine $|x|$; solange $|x|$ groß gegen $k+1$ ist, gewinnt zunächst die Potenz. Das ist Bemerkung 10.8.5 in Zahlen.

Der allgemeine Fall

Satz 10.8.2 rechnet mit Potenzen h^j , die es im $\mathbb{R}^n$ oder in einem Funktionenraum nicht gibt. Ersatz liefern die höheren Ableitungen aus Abschnitt 10.7: Setzen wir in die multilineare Abbildung $D_{\mathbf{x}}^j f$ überall denselben Zuwachs $\mathbf{h}$ ein, so entsteht das Gegenstück zu $f^{(j)}(x)h^j$.

Satz 10.8.7 (Taylorentwicklung II)

Seien V ein normierter Vektorraum, W ein Banachraum, $U \subseteq V$ offen, $k \geq 1$ und $f : U \rightarrow W$ in einer Umgebung von $\mathbf{x} \in U$ k -mal stetig Fréchet-differenzierbar; kurz $f \in \mathcal{C}^k$. Dann gibt es einen Rest $r_k(\mathbf{h}) \in W$ mit

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \sum_{j=1}^k \frac{1}{j!} D_{\mathbf{x}}^j f(\underbrace{\mathbf{h}, \dots, \mathbf{h}}_{j\text{-mal}}) + r_k(\mathbf{h}), \quad \frac{\|r_k(\mathbf{h})\|}{\|\mathbf{h}\|^k} \rightarrow 0 \quad \text{für } \mathbf{h} \rightarrow 0. \quad (10.8.5)$$

Vertiefung (optional): Beweis der allgemeinen Taylorentwicklung

Beweis.

- (1) Für hinreichend kleines $\mathbf{h}$ liegt die Strecke von $\mathbf{x}$ nach $\mathbf{x} + \mathbf{h}$ in U . Wir laufen sie mit einer Funktion einer reellen Variablen ab:

$$\psi : [0, 1] \rightarrow W, \quad \psi(t) := f(\mathbf{x} + t\mathbf{h}).$$

Damit ist $\psi(0) = f(\mathbf{x})$ und $\psi(1) = f(\mathbf{x} + \mathbf{h})$: die Frage ist damit auf die Verbindungsstrecke zurückgeführt

- (2) Die Kettenregel aus Satz 10.6.7 liefert die Ableitungen von ψ . Die innere Abbildung $t \mapsto \mathbf{x} + t\mathbf{h}$ ist affin mit Ableitung $\mathbf{h}$, also setzt jedes weitere Ableiten ein $\mathbf{h}$ mehr ein:

$$\psi^{(j)}(t) = D_{\mathbf{x}+t\mathbf{h}}^j f(\underbrace{\mathbf{h}, \dots, \mathbf{h}}_{j\text{-mal}}).$$

Induktiv: $t \mapsto D_{\mathbf{x}+t\mathbf{h}}^j f(\mathbf{h}, \dots, \mathbf{h})$ ist wieder eine Verkettung, deren Ableitung D^{j+1} an einem zusätzlichen $\mathbf{h}$ ausgewertet

- (3) Für eine W -wertige $\mathcal{C}^k$ -Kurve gilt die Taylorformel mit Integralrest:

$$\psi(1) = \sum_{j=0}^{k-1} \frac{1}{j!} \psi^{(j)}(0) + \frac{1}{(k-1)!} \int_0^1 (1-t)^{k-1} \psi^{(k)}(t) dt.$$

Wir addieren und subtrahieren $\psi^{(k)}(0)$ im Integral. Weil $\int_0^1 (1-t)^{k-1} dt = 1/k$, entsteht daraus der fehlende Summand $\psi^{(k)}(0)/k!$ und der Rest

$$r_k(\mathbf{h}) = \frac{1}{(k-1)!} \int_0^1 (1-t)^{k-1} (D_{\mathbf{x}+t\mathbf{h}}^k f - D_{\mathbf{x}}^k f)(\mathbf{h}, \dots, \mathbf{h}) dt.$$

Das Integral ist für stetige Kurven in einem Banachraum definiert; in endlichdimensionalen Zielräumen wird einfach komponentenweise integriert

- (4) Für kleines $s > 0$ mit $\{\mathbf{z} : \|\mathbf{z} - \mathbf{x}\| \leq s\} \subseteq U$ setzen wir

$$\omega(s) := \sup_{\|\mathbf{z}-\mathbf{x}\| \leq s} \|D_{\mathbf{z}}^k f - D_{\mathbf{x}}^k f\|_{\text{op}}.$$

Die Stetigkeit von $D^k f$ in $\mathbf{x}$ liefert $\omega(s) \rightarrow 0$. Mit der Operatornorm und der Dreiecksungleichung für Integrale folgt

$$\|r_k(\mathbf{h})\| \leq \frac{\omega(\|\mathbf{h}\|)}{k!} \|\mathbf{h}\|^k.$$

Nach Division durch $\|\mathbf{h}\|^k$ geht die rechte Seite gegen null. Das beweist (10.8.5).

Die Operatornorm schätzt den Integranden gleichzeitig für jede Richtung ab; das Integral der Gewichtsfunktion liefert den Faktor $1/k$

□

Bemerkung 10.8.8 (Warum hier die Integralform steht)

Das Lagrange-Restglied aus Satz 10.8.2 besitzt eine Zwischenstelle ξ und ist ein skalarer Resultat. Für eine vektorwertige Funktion können verschiedene Komponenten verschiedene Zwischenstellen benötigen; in einem allgemeinen Banachraum gibt es gar keine komponentenweise Formulierung. Die Integralform umgeht dieses Problem und liefert zusammen mit der Operatornorm unmittelbar eine Schranke, die für alle Richtungen zugleich gilt. Deshalb reicht $f \in \mathcal{C}^k$, während das Restglied trotzdem $o(\|\mathbf{h}\|^k)$ ist.

1. Der Beweis von Satz 10.8.7 überträgt die eindimensionale Aussage einfach auf jede Gerade durch $\mathbf{x}$, mehr ist nicht zu zeigen.

Antwort: Falsch

Der Kern ist das, aber die Aussage $o(\|\mathbf{h}\|^k)$ verlangt Kleinheit gleichmäßig über alle Richtungen, während die Entwicklung von ψ zunächst nur längs einer festen Geraden gilt. Die Stetigkeit der k -ten Ableitung liefert eine gemeinsame Normschränke für alle Richtungen und damit die benötigte gleichmäßige Kleinheit (Bemerkung 10.8.8).

Gradient, Hesse-Matrix und die ersten drei Ordnungen

Für den wichtigsten Spezialfall $f: \mathbb{R}^n \rightarrow \mathbb{R}$ haben die ersten Ableitungen aus Abschnitt 10.7 eigene Namen, und (10.8.5) wird zu einer kurzen Formel.

Korollar 10.8.9 (Taylorapproximation für Vektor zu Skalar)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ in einer Umgebung von $\mathbf{x}$ dreimal stetig differenzierbar, sei $\nabla f(\mathbf{x}) \in \mathbb{R}^{1 \times n}$ der Gradient und $\mathbf{H}_f(\mathbf{x}) \in \mathbb{R}^{n \times n}$ die Hesse-Matrix aus Definition 10.7.3. Dann gilt für $\mathbf{h} \rightarrow \mathbf{0}$

$$\begin{aligned} f(\mathbf{x} + \mathbf{h}) &= f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|) \\ &= f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|^2) \\ &= f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} + \frac{1}{6} \sum_{i,j,l=1}^n \frac{\partial^3 f(\mathbf{x})}{\partial x_i \partial x_j \partial x_l} h_i h_j h_l + o(\|\mathbf{h}\|^3). \end{aligned} \quad (10.8.6)$$

Mit dem Entwicklungspunkt $\mathbf{x}_0$ und $\mathbf{h} = \mathbf{x} - \mathbf{x}_0$ lautet dieselbe Aussage

$$\begin{aligned} f(\mathbf{x}) &= f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|) \\ &= f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{H}_f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|^2). \end{aligned}$$

Die ersten beiden Zeilen kommen mit $f \in \mathcal{C}^1$ bzw. $f \in \mathcal{C}^2$ aus.

Gradient und Hesse-Matrix tauchen auf, weil Satz 10.7.6 $D_{\mathbf{x}}f(\mathbf{h})$ in $\nabla f(\mathbf{x})\mathbf{h}$ und $D_{\mathbf{x}}^2f(\mathbf{h}, \mathbf{h})$ in die quadratische Form $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h}$ übersetzt; beides sind Zahlen. Die dritte Ordnung ist ein Tensor (Abschnitt 9.2), deshalb steht dort die ausgeschriebene Summe. Praktisch verwendet werden fast nur die ersten beiden Zeilen.

Bemerkung 10.8.10 (Ebene und Quadrik)

Der Graph von T_1 ist die *Tangentialebene* an den Graphen von f im Punkt $(\mathbf{x}, f(\mathbf{x}))$; für $\nabla f(\mathbf{x}) \neq \mathbf{0}^\top$ sind ihre Höhenlinien parallele Geraden senkrecht zum Gradienten (Abschnitt 10.2). Der Graph von T_2 ist eine *Quadrik*, und ihre Höhenlinien zeigen die Definitheit der Hesse-Matrix: Ellipsen bei definit, Hyperbeln bei indefinit. Das ist der Anschluss an Satz 10.7.9.

Ein Sonderfall: Ist f selbst ein Polynom zweiten Grades, so verschwinden alle Ableitungen ab der dritten, das Restglied ist null und $T_2 = f$ gilt exakt, an jeder Stelle und für jedes $\mathbf{h}$. Auf dieser Beobachtung beruht das Verfahren im nächsten Unterabschnitt.

Nach Korollar 10.8.9 wächst der Restterm von T_1 wie $\|\mathbf{h}\|^2$, der von T_2 wie $\|\mathbf{h}\|^3$. Um welchen Faktor fällt der Fehler, wenn wir den Abstand zum Entwicklungspunkt halbieren?

Interaktiv: Tangentialebene und Quadrik im Höhenlinienbild

Die Tafel zeigt die Höhenlinien von f und des Taylorpolynoms im selben Fenster und auf denselben Niveaus, daneben dieselbe Lage im Raum. Gemessen wird der größte Fehler auf einem Kreis mit Radius r um den Entwicklungspunkt, verglichen mit dem auf dem halb so großen Kreis; eine Shiny-App zeigt dieselbe Idee mit Flächen im Raum.

Interaktives Element — nur in der Web-Fassung

Die Tangentialebene hat gerade Höhenlinien, die Quadrik gekrümmte. Die Faustzahlen 4 und 8 setzen voraus, dass der jeweils führende Restterm nicht selbst verschwindet; wo die Hesse-Matrix nahezu null ist, springt der gemessene Quotient deutlich über den Vorhersagewert. Auf der Quadrik im dritten Menüpunkt fällt der T_2 -Fehler auf Rundungsniveau, weil die Näherung dort exakt ist. Darauf beruht der eine exakte Newton-Schritt im nächsten Unterabschnitt.

Anwendung: das Newton-Raphson-Verfahren

Gesucht ist ein lokales Minimum einer zweimal stetig differenzierbaren Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$, sofern eines existiert. Direkt lösen können wir das im Allgemeinen nicht, für eine quadratische Funktion mit positiv definiter Hesse-Matrix aber schon: Dort ist „Gradient gleich null“ ein lineares Gleichungssystem (Kapitel 5). Die Idee des Newton-Raphson-Verfahrens ist deshalb, an der aktuellen Stelle $\mathbf{x}^{(k)}$ die quadratische Näherung aus Korollar 10.8.9 hinzulegen und ihren stationären Punkt zu bestimmen:

$$f(\mathbf{x}) \approx T_2(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^\top \mathbf{H}_f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}).$$

Der lineare Term hat den Gradienten $\nabla f(\mathbf{x}^{(k)})$, der quadratische nach Beispiel 10.6.5 den Gradienten $(\mathbf{x} - \mathbf{x}^{(k)})^\top (\mathbf{H}_f + \mathbf{H}_f^\top)/2$, nach Satz 10.7.4 also $(\mathbf{x} - \mathbf{x}^{(k)})^\top \mathbf{H}_f(\mathbf{x}^{(k)})$. Nullsetzen liefert

$$\begin{aligned} \nabla T_2(\mathbf{x}) &= \nabla f(\mathbf{x}^{(k)}) + (\mathbf{x} - \mathbf{x}^{(k)})^\top \mathbf{H}_f(\mathbf{x}^{(k)}) \stackrel{!}{=} \mathbf{0}^\top \\ \implies (\mathbf{x} - \mathbf{x}^{(k)})^\top &= -\nabla f(\mathbf{x}^{(k)}) \mathbf{H}_f(\mathbf{x}^{(k)})^{-1}. \end{aligned}$$

Der letzte Schritt setzt voraus, dass $\mathbf{H}_f(\mathbf{x}^{(k)})$ invertierbar ist; sonst hat T_2 keinen oder unendlich viele kritische Punkte. Beide Seiten sind Zeilenvektoren (Konvention aus Abschnitt 10.2); Transponieren führt zurück zu Spalten.

Algorithmus 10.8.11 (Newton-Raphson-Verfahren)

Gegeben seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$ zweimal stetig differenzierbar und ein Startpunkt $\mathbf{x}^{(0)}$. Für $k = 0, 1, 2, \dots$ wiederhole, solange $\mathbf{H}_f(\mathbf{x}^{(k)})$ invertierbar ist:

1. Berechne $\nabla f(\mathbf{x}^{(k)})$ und $\mathbf{H}_f(\mathbf{x}^{(k)})$.
2. Setze

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \left(\nabla f(\mathbf{x}^{(k)}) \mathbf{H}_f(\mathbf{x}^{(k)})^{-1} \right)^\top. \quad (10.8.7)$$

3. Brich ab, wenn $\|\nabla f(\mathbf{x}^{(k)})\|$ oder die Schrittlänge $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|$ unter eine vorgegebene Schranke fällt.

Bemerkung 10.8.12 (Drei Vorbehalte)

Der Schritt sucht kritische Punkte, keine Minima. (10.8.7) ist eine Nullstelle von ∇T_2 , also ein Minimum der Näherung nur bei positiv definiter Hesse-Matrix; sonst ist es ein Sattel oder ein Maximum, und der Schritt muss keine Abstiegsrichtung sein. Je nach Startpunkt kann das Verfahren deshalb gegen Minima, Maxima oder Sattelpunkte konvergieren. Praktische Varianten erzwingen Definitheit, etwa indem sie ein Vielfaches der Einheitsmatrix addieren. *Die Inverse ist eine Schreibweise, keine Rechenanweisung.* Gerechnet wird das Gleichungssystem $\mathbf{H}_f(\mathbf{x}^{(k)}) \mathbf{d} = -\nabla f(\mathbf{x}^{(k)})^\top$ mit anschließendem $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}$; das kostet weniger und ist stabiler (Bemerkung 5.2.1). Bei positiv definiter Hesse-Matrix nehmen wir die Cholesky-Zerlegung aus Abschnitt 5.4, deren Gelingen zugleich die Definitheit prüft. *Nur lokal.* Weit weg vom Ziel kann die quadratische Näherung so schlecht sein, dass der Schritt in die falsche Richtung zeigt. Die Gegenmittel, Schrittweitensteuerung und Trust-Region, gehören zur Optimierung in Kapitel 12.

Bemerkung 10.8.13 (Newton in Statistik und ML)

Die Maximum-Likelihood-Schätzung maximiert die Log-Likelihood $\ell(\boldsymbol{\theta})$, sucht also eine Nullstelle der Score-Funktion $\nabla \ell(\boldsymbol{\theta})$. Dafür ist (10.8.7) gebaut, und die dabei gebrauchte Hesse-Matrix ist bis aufs Vorzeichen die beobachtete Fisher-Information aus Definition 10.7.14. Ersetzen wir sie durch ihren Erwartungswert, so heißt das Verfahren *Fisher-Scoring*; für verallgemeinerte lineare Modelle fällt es mit den *iterativ gewichteten kleinsten Quadraten* (IRLS) zusammen, in denen jeder Schritt ein gewichtetes Kleinste-Quadrate-Problem im Sinne von Kapitel 7 ist.

Vertiefung (optional): Die Asymptotik des ML-Schätzers als Taylorentwicklung

Auch die Asymptotik selbst ist eine Taylorentwicklung. Entwickeln wir die Score um den wahren Parameter $\boldsymbol{\theta}$ und werten sie am Schätzer $\hat{\boldsymbol{\theta}}$ aus, wo sie verschwindet, so bleibt in erster Ordnung $\mathbf{0}^\top \approx \nabla \ell(\boldsymbol{\theta}) + (\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})^\top \mathbf{H}_\ell(\boldsymbol{\theta})$ stehen. Umstellen und Normieren macht daraus unter den üblichen Regularitätsbedingungen die bekannte Aussage $\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \rightarrow N(\mathbf{0}, \mathbf{I}_1(\boldsymbol{\theta})^{-1})$: Der Faktor $n^{-1/2} \nabla \ell(\boldsymbol{\theta})^\top$ ist eine normierte Summe unabhängiger Beiträge und wird nach dem zentralen Grenzwertsatz normal, und $-\mathbf{H}_\ell(\boldsymbol{\theta})/n$ konvergiert gegen die Fisher-Information $\mathbf{I}_1(\boldsymbol{\theta})$ einer einzelnen Beobachtung. Der Restterm aus (10.8.6) ist dabei der Grund, warum die Aussage nur asymptotisch gilt.

Wie schnell ist „quadratisch konvergent“ in Zahlen?

Interaktiv: Newton Schritt für Schritt

Die Tafel zeigt die Höhenlinien, den Weg der Iterierten und eine Tabelle mit Gradientennorm, Fehler und dem Quotienten e_k/e_{k-1}^2 ; bleibt dieser beschränkt, so wird der Fehler je Schritt im Wesentlichen quadriert, das ist die *quadratische Konvergenz* (Konvergenzordnung). Voreingestellt ist $f(\mathbf{x}) = x_1^3/3 - x_1 + x_2^2/2$ mit Start (2; 1,5); der Schrittreger fährt die Iteration vor und zurück. Drei Versuche: ein Start mit $x_1 < 0$, ein Start mit $x_1 = 0$ und der zweite Menüpunkt, die Quadrik aus Bemerkung 10.8.10.

Interaktives Element — nur in der Web-Fassung

In der x_2 -Richtung sitzt der erste Schritt sofort exakt, denn dort ist f quadratisch. In der x_1 -Richtung läuft die Iteration gegen $x_1^* = 1$; der Fehler wird je Schritt im Wesentlichen quadriert, und der Quotient e_k/e_{k-1}^2 läuft gegen $1/(2x_1^*) = 0,5$. Ein Start mit $x_1 < 0$ führt in den Sattelpunkt $(-1; 0)$ statt ins Minimum (Bemerkung 10.8.12), bei $x_1 = 0$ ist die Hesse-Matrix $\text{diag}(0, 1)$ singulär und der Schritt nicht definiert. Auf der Quadrik ist nach einem Schritt Schluss, weil T_2 dort mit f übereinstimmt.

Selbsttest

1. Ist f $(k + 1)$ -mal stetig differenzierbar, so gilt $f(x + h) - T_k(h) = o(|h|^k)$ für $h \rightarrow 0$.

Antwort: Wahr

Das ist Satz 10.8.2. Nach dem Lagrange-Restglied (10.8.3) ist der Fehler sogar von der Ordnung $|h|^{k+1}$.

2. Im Restglied von Satz 10.8.2 steht die $(k + 1)$ -te Ableitung an der Entwicklungsstelle, also $f^{(k+1)}(x)$.

Antwort: Falsch

Sie steht an einer Zwischenstelle ξ zwischen x und $x + h$, über die wir sonst nichts wissen. Bekannt ist nur eine Schranke für $f^{(k+1)}$ in einer Umgebung, und daraus folgt die o -Aussage.

3. Je größer der Grad k , desto kleiner der Fehler, gleichgültig an welcher Stelle wir auswerten.

Antwort: Falsch

Lokal stimmt die Faustregel, global nicht. Für $f(x) = 1/(1+x^2)$ mit Entwicklungspunkt 0 fallen die Fehler bei $x = 0,5$ von $5,0 \cdot 10^{-2}$ auf $3,1 \cdot 10^{-6}$, wenn wir von $k = 2$ auf $k = 16$ gehen, bei $x = 1,5$ wachsen sie im selben Schritt von 1,6 auf 455 (Bemerkung 10.8.5). Im Lagrange-Restglied kann der Faktor $f^{(k+1)}(\xi)$ schneller wachsen, als $(k + 1)!$ ihn drückt.

4. Ist f ein Polynom zweiten Grades, so gilt $T_2 = f$ überall, nicht nur näherungsweise.

Antwort: Wahr

Alle Ableitungen ab der dritten sind null, also verschwindet das Restglied (10.8.3) für $k = 2$ identisch. Bei invertierbarer Hesse-Matrix trifft der Newton-Schritt deshalb den eindeutigen kritischen Punkt in einem Zug. Ein Minimum ist dieser nur bei positiver Definitheit, wie im zweiten Menüpunkt des Widgets.

5. Der Newton-Schritt (10.8.7) liefert stets ein lokales Minimum von f .

Antwort: Falsch

Er liefert einen kritischen Punkt der quadratischen Näherung, mehr nicht. Ist die Hesse-Matrix indefinit, so ist dieser Punkt ein Sattel; im Widget läuft jeder Start mit $x_1 < 0$ nach $(-1; 0)$, wo der Gradient verschwindet und die Hesse-Matrix $\text{diag}(-2, 1)$ indefinit ist. Erst positive Definitheit macht aus dem kritischen Punkt ein Minimum (Bemerkung 10.8.12).

6. Halbieren wir $\|\mathbf{h}\|$, so fällt der Fehler der Tangentialebene auf etwa ein Viertel, der Fehler der quadratischen Näherung auf etwa ein Achtel.

Antwort: Wahr

Nach Korollar 10.8.9 ist der erste Rest von der Größenordnung $\|\mathbf{h}\|^2$ und der zweite von der Größenordnung $\|\mathbf{h}\|^3$. Das Widget misst diesen Quotienten auf einem Kreis: In der Voreinstellung stehen dort 4,34 und 8,07 für $\sin(x_1) + \cos(x_2)$, für die Glockenfunktion an derselben Stelle 3,99

und 8,78.

7. Fahren wir den Schrittreger im Newton-Widget von der Voreinstellung aus hoch. In welchem Schritt unterschreitet der Abstand zum Minimum zum ersten Mal 10^{-10} ?

Lösung: 5

In Schritt 5. Die Fehlerspalte fällt von $4,65 \cdot 10^{-8}$ auf $1,1 \cdot 10^{-15}$, überspringt also sieben Größenordnungen auf einmal. Das ist quadratische Konvergenz in Zahlen: Sobald der Fehler klein genug ist, verdoppelt sich die Zahl der gültigen Stellen mit jedem Schritt.

Vertiefung: MML §5.1.1 behandelt die Taylorreihe im eindimensionalen Fall, §5.8 die Linearisierung und die mehrdimensionale Taylorentwicklung samt der Tensorschreibweise für die höheren Terme.

10.9 Zusammenfassung

Der Grundgedanke dieses Kapitels: Ableiten heißt linear approximieren. Alles Weitere betraf das Format der linearen Näherung und die Regeln, nach denen sich mit ihr rechnen lässt; die Tabelle unten fasst die Abschnitte zusammen.

Vertiefung (optional): Das gemeinsame Muster der Beweise

Die meisten Beweise der Abschnitte 10.5 bis 10.8 folgen demselben Muster. Wir setzen die Definition für jeden Baustein einzeln ein, sortieren die entstehenden Terme nach Bauart und zeigen, dass alles außerhalb des Kandidaten $\mathcal{O}(\|\mathbf{h}\|)$ ist. So entstehen Satz 10.5.5, die Produktregel, die Kettenregel und die Hesse-Formel in Satz 10.7.6. Satz 10.5.2 kommt mit weniger aus, denn dort gibt es gar keinen Kandidaten: Wir schätzen beide Zusatzterme nach oben ab und lassen $\mathbf{h}$ gegen null gehen. Das Rechnen mit Landau-Symbolen ist deshalb das zentrale Handwerkszeug (Bemerkung 10.5.1). Weisen wir den Kandidaten zusätzlich als linear und beschränkt nach, so ist Definition 10.1.5 erfüllt, und mehr braucht es für Produkt- und Kettenregel nicht. Zweimal kommt ein Zusatzargument dazu, im letzten Schritt zu Satz 10.5.5 und in Schritt 4 zu Satz 10.7.6: Zwei lineare Abbildungen, die sich nur um $\mathcal{O}(\|\mathbf{h}\|)$ unterscheiden, sind gleich. Aus dem Muster fallen der Satz von Schwarz und die eindimensionale Taylorentwicklung heraus, denn beide brauchen einen Mittelwertsatz; der allgemeine Satz 10.8.7 verwendet statt einer skalaren Zwischenstelle die Integralform des Restglieds.

Was wir ausgelassen haben

Drei Zellen der Übersicht aus Abschnitt 10.2 sind leer geblieben: Matrix zu Vektor, Vektor zu Matrix und Matrix zu Matrix. Ihre Ableitungen sind Tensoren der Stufe 3 oder 4 (Abschnitt 9.2); alternativ stapeln wir die Matrizen per Vektorisierung zu Vektoren. Für eine Störungsanalyse genügt oft eine einzige Richtung: Bei fester Störungsrichtung $\mathbf{E}$ ist $\varphi(h) = f(\mathbf{X} + h\mathbf{E})$ eine Funktion einer reellen Variablen, und $\varphi'(0) = D_{\mathbf{X}}f(\mathbf{E})$. Ableitungen von Abbildungen zwischen Funktionsräumen bleiben eine Übungsaufgabe. Weitere Formeln sammelt das *Matrix Cookbook* von Petersen und Pedersen (2012).

Vertiefung (optional): Leere Felder, Störungsanalyse und Nachschlagewerke im Detail

Bemerkung 10.9.1 (Die drei leeren Felder)

In der Übersicht aus Abschnitt 10.2 sind drei Zellen leer geblieben: Matrix zu Vektor, Vektor zu Matrix und Matrix zu Matrix. Sie fehlen, weil ihre Ableitungen aus dem Matrixschema herausfallen. Eine Funktion $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$ hat $mnpq$ partielle Ableitungen, jede davon adressiert durch zwei Indizes für die Eingabe und zwei für die Ausgabe. Sortiert ergibt das ein Zahlenfeld mit vier Indexpositionen, also einen Tensor der Stufe 4 (Abschnitt 9.2). Für 2×2 -Matrizen auf beiden Seiten sind das 16 Zahlen in $\mathbb{R}^{2 \times 2 \times 2 \times 2}$. Bei den gemischten Fällen Vektor zu Matrix und Matrix zu Vektor bleiben drei Indexpositionen übrig.

Gebraucht werden diese Fälle seltener als die sechs ausgefüllten Zellen, und wo sie doch auftreten, gibt es zwei Wege. Entweder wir rechnen mit Tensoren weiter, oder wir stapeln jede Matrix zu einem Vektor: Dafür stehen die Vektorisierung und das Kroneckerprodukt aus Abschnitt 9.5 bereit, die eine Matrixgleichung in ein gewöhnliches lineares Gleichungssystem verwandeln.

Eine zweite Lücke ist keine Formatfrage. Definition 10.1.5 lässt für $\mathbb{D}$ und $\mathbb{E}$ beliebige normierte Vektorräume zu, also auch Räume von Funktionen. Der Begriff gilt auch dort, doch die Beschränktheit von $D_X f$ ist dann eine echte Zusatzbedingung (Bemerkung 10.1.6).

Ableiten in eine Richtung

Bemerkung 10.9.2 (Störungsanalyse als Richtungsableitung)

Ein Werkzeug führt die Matrixfälle auf den eindimensionalen zurück. Wollen wir wissen, wie empfindlich eine Matrixrechnung auf eine Störung reagiert, so halten wir eine Störungsrichtung E fest und betrachten die Funktion einer einzigen reellen Variablen

$$\varphi(h) := f(\mathbf{X} + h\mathbf{E}).$$

Ableiten nach dem Skalar h an der Stelle $h = 0$ liefert den Ableitungsterm in Richtung E , für skalarwertiges f also

$$\varphi'(0) = D_X f(\mathbf{E}) = \text{tr} \left(\left(\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} \right)^\top \mathbf{E} \right).$$

Zum Nachweis setzen wir $\mathbf{H} = h\mathbf{E}$ in (10.4.7) ein, so zieht die Linearität den Faktor heraus, $D_X f(h\mathbf{E}) = h D_X f(\mathbf{E})$, und der Restterm ist $o(|h|)$, weil $\|h\mathbf{E}\| = |h| \|\mathbf{E}\|$ gilt. Das ist dieselbe Konstruktion wie die Richtungsableitung aus Definition 10.2.3, nur mit einer Matrix als Richtung. Anders als dort verlangen wir von E keine Länge 1; deshalb steht „Richtung“ hier in Anführungszeichen. Ein Beispiel: Für $f(\mathbf{X}) = \|\mathbf{X}\|_F^2$ mit $\mathbf{X} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ und $\mathbf{E} = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ ist $\varphi(h) = 30 + 4h + h^2$, also $\varphi'(0) = 4$, und das ist der Eintrag $(1, 2)$ von $2\mathbf{X}$ nach (10.4.12). Diese Wahl von E ist gerade das E_{ij} aus Bemerkung 10.4.8, die Störung eines einzelnen Eintrags; beliebige E stören alle Einträge zugleich.

Für die Praxis lesen wir das als Störungsanalyse: E gibt an, wohin gestört wird, und $\varphi'(0)$ misst in erster Ordnung, wie stark diese Störung im Ergebnis ankommt. Über alle Störungsrichtungen zugleich beschränken die Konditionszahlen aus Abschnitt 4.2, wie stark ein relativer Datenfehler anwachsen kann.

Zum Nachschlagen

Die Identitäten dieses Kapitels sind eine kleine Auswahl. Brauchen wir eine Ableitung, die hier nicht steht, so schlagen wir sie besser nach, statt sie neu herzuleiten. Das *Matrix Cookbook* von Petersen und Pedersen (2012) sammelt die Formeln, die in Anwendungen tatsächlich vorkommen, von Determinanten und Inversen bis zu Spur- und Normausdrücken. Dabei ist zu beachten: Die Konventionen unterscheiden sich zwischen den Quellen, und dieselbe Formel steht je nach Zeilen- oder Spaltenkonvention transponiert (Bemerkung 10.2.2). Bei rechteckigen Formaten fällt das schon beim Nachzählen von Zeilen und Spalten auf. Bei quadratischen passt die transponierte Fassung genauso gut, und dann

hilft nur eine numerische Probe an einem kleinen Beispiel.

1. Die Ableitung einer matrixwertigen Funktion nach einer Matrix passt im Allgemeinen in kein rechteckiges Zahlenschema mehr.

Antwort: Wahr

Für $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$ entstehen $mnpq$ partielle Ableitungen mit vier Indexpositionen, also ein Tensor der Stufe 4 (Bemerkung 10.9.1). Deshalb bleiben die drei Zellen der Übersicht aus Abschnitt 10.2 leer. Wer den Fall braucht, rechnet mit Tensoren oder stapelt die Matrizen per Vektorisierung zu Vektoren um (Abschnitt 9.5).

Das Wichtigste in Kürze

Abschnitt	Thema	Was bleibt
10.1	Ableitung als lineare Approximation	Fréchet-Ableitung auf normierten Räumen: $f(x+h) = f(x) + D_x f(h) + r(h)$ mit linearem, beschränktem $D_x f$ und einem Restterm $r(h)$, der schneller verschwindet als h
10.2	Der Gradient	$\nabla f(\mathbf{x}) \in \mathbb{R}^{1 \times n}$ als Zeile der partiellen Ableitungen; Richtung des stärksten Anstiegs; Gradientenabstieg
10.3	Die Jacobimatrix	$J_f(\mathbf{x}) \in \mathbb{R}^{m \times n}$ mit Gradienten als Zeilen; jede Matrix $\mathbf{M}$ mit $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{M}\mathbf{h} + o(\ \mathbf{h}\)$ ist schon die Jacobimatrix; Kettenregel als Matrixprodukt; Backpropagation als Auswertung von links
10.4	Ableitungen mit Matrizen	eintragsweise Ableitungen für Skalar zu Matrix und Matrix zu Skalar; Spur, Jacobi-Formel, Inverse; Frobenius-Skalarprodukt als Ableitungsterm
10.5	Stetigkeit und Linearität	Differenzierbar zieht stetig nach sich, nicht umgekehrt; die Ableitungsoperation $f \mapsto D_x f$ ist linear, in jedem der fünf Formate aus den Abschnitten 10.1 bis 10.4
10.6	Produkt- und Kettenregel	Produktregel für jede beschränkte bilineare Multiplikation $\langle \cdot, \cdot \rangle$; Kettenregel als Verkettung $D_y g \circ D_x f$, in Koordinaten ein Matrixprodukt
10.7	Ableitungen höheren Grades	$D_x^2 f$ als multilineare Abbildung; Hesse-Matrix $\mathbf{H}_f(\mathbf{x})$, Satz von Schwarz, Definitheit im kritischen Punkt trennt lokales Minimum, Maximum und Sattel, entscheidet aber nichts, wenn sie semidefinit und nicht definit ist
10.8	Taylorapproximation	$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h} + \frac{1}{2}\mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h} + r(\mathbf{h})$ mit einem Rest, der schneller verschwindet als die letzte mitgenommene Potenz; Newton bestimmt den stationären Punkt der Quadrik

Nächstes Kapitel

Offen geblieben ist, wann ein lokaler Befund auch ein globaler ist: Satz 10.7.11 verknüpft Konvexität mit der Hesse-Matrix, zieht aber keinen Schluss über globale Minima, und nach Bemerkung 10.8.12 ist ein kritischer Punkt noch kein Minimum. Für konvexe Funktionen ist jeder kritische Punkt ein globales Minimum, Sattelpunkte gibt es keine, und Optimierungsverfahren bekommen Garantien statt Faustregeln. Deshalb behandelt Kapitel 11 die Konvexität als eigenes Thema.

Selbsttest

Erste Runde: Ableitungsbegriff und Formate.

1. Für $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ und $f : \mathbb{R}^m \rightarrow \mathbb{R}$ gilt $\nabla(f \circ g)(\mathbf{x}) = \nabla f(g(\mathbf{x})) \mathbf{J}_g(\mathbf{x})$, ganz ohne Transponierte.

Antwort: Wahr

Dafür ist der Gradient eine Zeile (Bemerkung 10.2.2): Das Produkt einer $1 \times m$ -Zeile mit einer $m \times n$ -Matrix ist wieder eine Zeile, und für $m = 1$ ist der Gradient der Sonderfall der Jacobimatrix (Bemerkung 10.3.2). Zahlenprobe mit $g(\mathbf{x}) = \mathbf{A}\mathbf{x}$, $\mathbf{A} = \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \end{pmatrix}$, $f(\mathbf{y}) = \|\mathbf{y}\|^2$ und $\mathbf{x} = (1, 2, 3)^\top$: $\nabla f(\mathbf{A}\mathbf{x}) \mathbf{A} = 2(5, 11)\mathbf{A} = (10, 42, 66)$. Dieselbe Zeile liefert der direkte Weg über $f(g(\mathbf{x})) = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}$ mit Gradient $2\mathbf{x}^\top \mathbf{A}^\top \mathbf{A}$ (Satz 10.2.8).

2. Die Forderung in Definition 10.1.5, dass $D_{\mathbf{x}}f$ beschränkt sein soll, ist überflüssig, denn lineare Abbildungen sind ohnehin beschränkt.

Antwort: Falsch

In endlich-dimensionalen Räumen stimmt das, dort kostet die Forderung nichts (Bemerkung 10.1.6). Im Unendlichdimensionalen ist sie eine echte Zusatzbedingung. Auf dem Raum der Polynome auf $[0, 1]$ mit der Supremumsnorm etwa ist das Ableiten $p \mapsto p'$ linear, aber unbeschränkt: Für $p_n(x) = x^n$ ist $\|p_n\|_\infty = 1$, während $p'_n(x) = nx^{n-1}$ die Norm n hat. Deshalb bleiben Abbildungen zwischen Funktionenräumen in diesem Kapitel außen vor.

3. Für $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}$ mit $\mathbf{A} \in \mathbb{R}^{n \times m}$ ist $\mathbf{J}_f(\mathbf{x}) = \mathbf{A}$.

Antwort: Falsch

Richtig ist $\mathbf{J}_f(\mathbf{x}) = \mathbf{A}^\top$ nach Satz 10.3.4(4), gelesen über $(\mathbf{x}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{x}$ (Bemerkung 10.3.5). Für $n \neq m$ verraten schon die Formate den Fehler: f bildet von $\mathbb{R}^n$ nach $\mathbb{R}^m$ ab, die Jacobimatrix ist also $m \times n$, während $\mathbf{A}$ das Format $n \times m$ hat. Bei $n = m$ passt die falsche Antwort formal, dort fällt sie erst beim Nachrechnen auf. Für $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 3 & -1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$ ist $\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} 1 & 0 & 3 \\ 2 & 1 & -1 \end{pmatrix}$.

4. Für differenzierbares $F : \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ gilt $\partial \det(F(x)) / \partial x = \det(\partial F(x) / \partial x)$.

Antwort: Falsch

Die Determinante ist nicht linear, Ableiten und Auswerten lassen sich hier also nicht vertauschen. Für $F(x) = \text{diag}(x, 2x)$ ist $\det(F(x)) = 2x^2$ mit Ableitung $4x$, während $\det(\partial F(x) / \partial x) = \det(\text{diag}(1, 2)) = 2$ konstant ist. Beide stimmen nur zufällig bei $x = 0,5$ überein. Richtig ist die Jacobi-Formel (10.4.4), die den Faktor $\det(F(x))$ und die Spur mitführt; für die Spur dagegen dürfen wir vertauschen (10.4.3), denn sie ist linear.

5. Für feste $\mathbf{a} \in \mathbb{R}^m$ und $\mathbf{b} \in \mathbb{R}^n$ mit $\mathbf{a}, \mathbf{b} \neq \mathbf{0}$ ist $\partial(\mathbf{a}^\top \mathbf{X} \mathbf{b}) / \partial \mathbf{X} = \mathbf{a} \mathbf{b}^\top$, und diese Matrix hat den Rang 1.

Antwort: Wahr

Die Formel ist (10.4.9), und rechts steht ein äußeres Produkt, das nach Satz 9.3.4 (Abschnitt 9.3) für Vektoren $\neq \mathbf{0}$ genau den Rang 1 hat. Für $\mathbf{a} = (1, 2)^\top$ und $\mathbf{b} = (3, -1)^\top$ ist $\mathbf{a} \mathbf{b}^\top = \begin{pmatrix} 3 & -1 \\ 6 & -2 \end{pmatrix}$ mit Determinante 0; die zweite Zeile ist das Doppelte der ersten.

6. Im Kompass-Widget aus Abschnitt 10.2: Wir drehen $\mathbf{d}$ so, dass die Richtung längs der Höhenlinie zeigt. Welchen Wert nimmt die Richtungsableitung $\nabla f(\mathbf{x}) \mathbf{d}$ dann an?

Lösung: 0

Null. Entlang der Höhenlinie ändert sich f in erster Ordnung nicht, und deshalb steht der Gradient senkrecht auf ihr (Bemerkung 10.2.5). Im Schnitt rechts liegt die grüne Gerade dann waagerecht.

Zweite Runde: Rechenregeln, Hesse-Matrix, Taylor.

1. Existieren in $\mathbf{x}$ alle partiellen Ableitungen von $f: \mathbb{R}^n \rightarrow \mathbb{R}$, so ist f dort differenzierbar.

Antwort: Falsch

Die Existenz der partiellen Ableitungen sagt nur etwas über die Koordinatenrichtungen aus. Für

$$f(\mathbf{x}) = \frac{x_1 x_2}{x_1^2 + x_2^2} \quad \text{für } \mathbf{x} \neq \mathbf{0}, \quad f(\mathbf{0}) = 0$$

verschwindet f auf beiden Achsen, also existieren im Nullpunkt beide partiellen Ableitungen und sind 0. Auf der Diagonalen $x_1 = x_2 = t$ ist f dagegen konstant 0,5 und auf $x_2 = -x_1$ konstant $-0,5$, für jedes noch so kleine $t \neq 0$. Damit ist f in $\mathbf{0}$ nicht einmal stetig und nach der Kontraposition von Satz 10.5.2 erst recht nicht differenzierbar (Bemerkung 10.5.4). Sind die partiellen Ableitungen dagegen *stetig*, so ist f differenzierbar; davon lebt Schritt 3 im Beweis zu Satz 10.7.6.

2. Für in $\mathbf{x}$ differenzierbare $f, g: \mathbb{R}^n \rightarrow \mathbb{R}$ gilt $\nabla(fg)(\mathbf{x}) = g(\mathbf{x})\nabla f(\mathbf{x}) + f(\mathbf{x})\nabla g(\mathbf{x})$.

Antwort: Wahr

Das ist Satz 10.6.3 mit der Multiplikation zweier Zahlen als bilinearer Abbildung, die wegen $|uv| = |u||v|$ die Schranke $K = 1$ hat (Bemerkung 10.6.2, Punkt 2 mit $m = 1$). Beide Summanden sind Zeilenvektoren, skaliert mit einer Zahl.

3. Für $\mathbf{F}: \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$ und $g: \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$ ist $\partial(g \circ \mathbf{F})(x)/\partial x$ das Matrixprodukt $(\partial g(\mathbf{Y})/\partial \mathbf{Y})^\top \partial \mathbf{F}(x)/\partial x$ an der Stelle $\mathbf{Y} = \mathbf{F}(x)$.

Antwort: Falsch

Links steht eine Zahl, rechts eine Matrix. Es fehlt die Spur: Nach der fünften Bauform in Beispiel 10.6.8 ist die Ableitung $\text{tr}((\partial g/\partial \mathbf{Y})^\top \partial \mathbf{F}(x)/\partial x)$, denn die Fréchet-Ableitung einer skalaren Funktion mit Matrixargument wirkt über das Frobenius-Skalarprodukt (Bemerkung 10.4.8). Nachgerechnet mit $g(\mathbf{Y}) = \|\mathbf{Y}\|_F^2$ und $\mathbf{F}(x) = \begin{pmatrix} x & 1 \\ 0 & e^x \end{pmatrix}$: Direkt ist $g(\mathbf{F}(x)) = x^2 + 1 + e^{2x}$ mit Ableitung $2x + 2e^{2x}$, bei $x = 0,3$ also 4,2442. Das Matrixprodukt ist dort $\begin{pmatrix} 0,6 & 0 \\ 2 & 3,6442 \end{pmatrix}$, und erst seine Spur ergibt 4,2442.

4. Der Satz von Schwarz gilt für jede Funktion, deren zweite partielle Ableitungen existieren.

Antwort: Falsch

Er verlangt zusätzlich deren Stetigkeit, also $f \in \mathcal{C}^2$ (Satz 10.7.4). Das Standardgegenbeispiel ist

$$f(\mathbf{x}) = \frac{x_1 x_2 (x_1^2 - x_2^2)}{x_1^2 + x_2^2} \quad \text{für } \mathbf{x} \neq \mathbf{0}, \quad f(\mathbf{0}) = 0.$$

Auf den Achsen: $\partial f(0, x_2)/\partial x_1 = -x_2$ und $\partial f(x_1, 0)/\partial x_2 = x_1$. Einmal mehr abgeleitet ergibt das im Nullpunkt die beiden Werte -1 und $+1$, je nach Reihenfolge. Die Hesse-Matrix ist dort also nicht symmetrisch, und alles, was auf ihrer Symmetrie aufbaut, von Satz 10.7.6 bis zum Spektralsatz-Argument in Satz 10.7.9, gilt ohne Stetigkeit nicht.

5. Ist $\mathbf{x}^*$ ein kritischer Punkt von $f \in \mathcal{C}^2(S)$ mit $S \subseteq \mathbb{R}^2$ offen und gilt $\det \mathbf{H}_f(\mathbf{x}^*) < 0$, so ist $\mathbf{x}^*$ ein Sattelpunkt.

Antwort: Wahr

Die Determinante ist das Produkt der beiden Eigenwerte, und die sind reell, weil $\mathbf{H}_f(\mathbf{x}^*)$ nach Satz 10.7.4 symmetrisch ist. Ein negatives Produkt lässt nur eine Möglichkeit: ein positiver und ein negativer Eigenwert, also eine indefinite Hesse-Matrix und damit Satz 10.7.9(3). Beispiel ist

die Funktion $f(\mathbf{x}) = x_1^2 + 3x_1x_2 + 2x_2^2$ aus dem Gradientenfeld-Widget in Abschnitt 10.2 mit $\mathbf{H}_f = \begin{pmatrix} 2 & 3 \\ 3 & 4 \end{pmatrix}$, Determinante -1 und Eigenwerten $3 \pm \sqrt{10}$, also $6,162$ und $-0,162$. Ab $n = 3$ trägt das Vorzeichen der Determinante nicht mehr: $\text{diag}(-1, -1, -1)$ hat ebenfalls Determinante -1 , ist aber negativ definit und zeigt ein Maximum an.

6. Weil der Restterm der quadratischen Näherung $\mathcal{O}(\|\mathbf{h}\|^2)$ ist, fällt er beim Halbieren von $\mathbf{h}$ höchstens auf ein Viertel.

Antwort: Falsch

Eine $\mathcal{O}$ -Aussage beschreibt einen Grenzwert und sagt über einzelne Schritte nichts. Schon im Eindimensionalen: Die Funktion $r(h) = h^3(2 + \sin(1/h))$ erfüllt $|r(h)|/h^2 \leq 3|h| \rightarrow 0$, ist also $\mathcal{O}(|h|^2)$. Bei $h = 0,095$ steht trotzdem $|r(h/2)|/|r(h)| = 0,317$. Die Faustregel „ein Achtel“, die das Widget in Abschnitt 10.8 misst, stützt sich nicht auf die $\mathcal{O}$ -Aussage, sondern auf das Lagrange-Restglied (10.8.3) mit beschränkter dritter Ableitung.

7. Für $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x}$ mit symmetrischem, positiv definitem $\mathbf{A}$ landet der Newton-Schritt (10.8.7) aus jedem Startpunkt in der Lösung des Gleichungssystems $\mathbf{A} \mathbf{x} = \mathbf{b}$.

Antwort: Wahr

Nach Beispiel 10.6.5 mit $\mathbf{A} = \mathbf{A}^\top$, Satz 10.3.4(3) für den linearen Term und der Linearität aus Satz 10.5.5 ist $\nabla f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} - \mathbf{b}^\top$, und $\mathbf{H}_f(\mathbf{x}) = \mathbf{A}$ ist konstant. Eingesetzt in (10.8.7) gibt das $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - \mathbf{A}^{-1}(\mathbf{A}\mathbf{x}^{(0)} - \mathbf{b}) = \mathbf{A}^{-1}\mathbf{b}$, unabhängig vom Start. Für $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ und $\mathbf{b} = (1, 2)^\top$ steht von $(5, -4)^\top$, von $\mathbf{0}$ und von $(-13, 7; 8, 2)^\top$ aus nach einem Schritt jeweils exakt $(0, 2; 0, 6)^\top$ da. Der Grund ist Bemerkung 10.8.10: Bei einer quadratischen Funktion ist $T_2 = f$.

8. Ist $f \in \mathcal{C}^2(S)$ auf einer offenen, konvexen Menge S konvex, so ist jeder kritische Punkt von f ein globales Minimum auf S .

Antwort: Wahr

Nach Satz 10.7.11 ist $\mathbf{H}_f(\mathbf{x}) \succeq 0$ für alle $\mathbf{x} \in S$. Sei $\mathbf{x}^*$ kritisch und $\mathbf{y} \in S$ beliebig. Weil S konvex ist, liegt die Strecke dazwischen ganz in S , und wir betrachten $\varphi(t) := f(\mathbf{x}^* + t(\mathbf{y} - \mathbf{x}^*))$ für $t \in [0, 1]$. Die Kettenregel gibt $\varphi'(0) = \nabla f(\mathbf{x}^*)(\mathbf{y} - \mathbf{x}^*) = 0$ und $\varphi''(t) = (\mathbf{y} - \mathbf{x}^*)^\top \mathbf{H}_f(\mathbf{x}^* + t(\mathbf{y} - \mathbf{x}^*))(\mathbf{y} - \mathbf{x}^*) \geq 0$. Also ist φ' nichtfallend und ab $t = 0$ nichtnegativ, damit $\varphi(1) \geq \varphi(0)$, und das heißt $f(\mathbf{y}) \geq f(\mathbf{x}^*)$.

Vertiefung: MML §5.7 behandelt die höheren Ableitungen, §5.8 die Linearisierung und die multivariaten Taylorreihen, und §5.9 sammelt weiterführende Literatur zur Matrixdifferentialrechnung. Die Konvexität und die Verfahren, die auf ihr aufbauen, stehen in MML §7.3; der Gradientenabstieg aus Abschnitt 10.2 steht dort in §7.1 daneben.

10.10 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deisenroth et al. (MML) Exercise 5.5	Dimensionen und Berechnung von Jacobimatrizen	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 5.6	Kettenregel und Ableitung eines Spurausdrucks	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 5.7	Kettenregel mit expliziter Dimensionskontrolle	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 5.8	Mehrstufige Kettenregel und Dimensionen der Zwischenableitungen	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 5.9	Kettenregel bei doppelter Abhängigkeit	mittel, ca. 30 Min.
Eigene Aufgabe zur Vorlesung	Verifikation der Ableitungsidentitäten	mittel, 1 Std. und mehr

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deisenroth et al. (MML) Exercise 5.4	Taylorpolynome von $\sin(x) + \cos(x)$	leicht, ca. 15 Min.
Petersen/Pedersen (Matrix Cookbook), Abschnitt 2	Fünf Ableitungsidentitäten selbst herleiten	schwer, 1 Std. und mehr

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deisenroth et al. (MML) Exercise 5.1	Ableitung von $\log(x^4) \sin(x^3)$	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 5.2	Ableitung der logistischen Sigmoidfunktion	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 5.3	Ableitung des Gauß-Kerns	leicht, ca. 15 Min.

Bücher: Deisenroth et al. (MML): *Mathematics for Machine Learning*; Petersen/Pedersen: *The Matrix Cookbook*.

Konvexität

11.1 Konvexkombinationen und konvexe Hülle

Wozu Konvexität

Gradient, Jacobi- und Hesse-Matrix aus Kapitel 10 beschreiben, wie sich eine Funktion in der Nähe eines Punktes verhält; über ihr Verhalten im Großen sagen sie wenig. Diese Lücke füllt die Konvexität.

Der Begriff hat zwei eng verwandte Ausprägungen: *konvexe Mengen* (Abschnitt 11.2) und *konvexe Funktionen* (Abschnitt 11.3). Beide verallgemeinern Linearität, und zwar durch eine Einschränkung auf der einen und eine Lockerung auf der anderen Seite. Bei einer Linearkombination $\sum_i w_i \mathbf{x}_i$ dürfen die Koeffizienten beliebig sein; lassen wir nur nichtnegative mit Summe 1 zu, entsteht der Begriff dieses Abschnitts. Und wo eine lineare Funktion die Gleichung $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) = \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y})$ exakt erfüllt, verlangt Konvexität davon nur noch die Ungleichung $\leq$.

Warum sich das lohnt, zeigt sich an zwei Stellen. In der Optimierung und damit im maschinellen Lernen und in der Statistik ist ein konvexes Problem eines, bei dem kein Verfahren in einem lokalen Minimum hängenbleiben kann: Jedes lokale Minimum ist dort ein globales. Darauf bauen viele Standardverfahren auf, etwa die Maximum-Likelihood-Schätzung in verallgemeinerten linearen Modellen, Support Vector Machines und die Ridge-Regression, deren Zielfunktion wir in Abschnitt 10.6 abgeleitet haben. Bei der Likelihood ist auf das Vorzeichen zu achten: Meist ist die Log-Likelihood konkav (in verallgemeinerten linearen Modellen etwa bei kanonischem Link), konvex ist dann die *negative* Log-Likelihood, die wir minimieren. Eindeutig ist das Minimum eines konvexen Problems damit noch nicht, und ob es überhaupt angenommen wird, ist eine eigene Frage; Abschnitt 11.5 hält die drei Aussagen auseinander.

In der Wahrscheinlichkeitstheorie liefert Konvexität Ungleichungen für Erwartungswerte. Die Jensen-Ungleichung ist der Prototyp (Abschnitt 11.4); die Kullback-Leibler-Divergenz ist konvex, was in der Variationsinferenz gebraucht wird; und die Nichtnegativität der Varianz ist die Jensen-Ungleichung für $x \mapsto x^2$:

$$\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2.$$

An Vorwissen brauchen wir Vektorräume und Linearkombinationen, den Umgang mit Normen und Skalarprodukten, aus der Analysis Grenzwerte, Supremum und Infimum sowie abgeschlossene Mengen, und aus der Stochastik den Erwartungswert als gewichteten Durchschnitt. Später im Kapitel kommen der Gradient und positiv definite Matrizen dazu.

Konvexkombinationen

Definition 11.1.1 (Konvexkombination)

Sei V ein Vektorraum und $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_k\} \subset V$. Wir nennen $\mathbf{x}$ eine *Konvexkombination* (convex combination) von Vektoren in $\mathcal{X}$, falls es Koeffizienten $w_1, \dots, w_k \geq 0$ gibt mit

$$\mathbf{x} = \sum_{i=1}^k w_i \mathbf{x}_i \quad \text{und} \quad \sum_{i=1}^k w_i = 1.$$

Bemerkung 11.1.2 (Ein gewichteter Durchschnitt)

Konvexkombinationen sind spezielle Linearkombinationen: Die Gewichte sind nichtnegativ, kehren also keine Richtung um, und sie summieren sich zu 1, lassen sich also nicht gemeinsam hochskalieren. Damit bilden $w_1, \dots, w_k$ eine Wahrscheinlichkeitsverteilung auf den k Punkten, und $\mathbf{x}$ ist deren *gewichteter Durchschnitt*. Bei gleichen Gewichten $w_i = \frac{1}{k}$ ist $\mathbf{x}$ das arithmetische Mittel der Punkte.

Nützlich ist auch die Lesart als Verschiebung. Setzen wir $w_1 = 1 - \sum_{i \geq 2} w_i$ in die Definition ein, so wird daraus

$$\mathbf{x} = \mathbf{x}_1 + \sum_{i=2}^k w_i (\mathbf{x}_i - \mathbf{x}_1).$$

Wir starten also in $\mathbf{x}_1$ und gehen ein Stück in Richtung der übrigen Punkte. Wegen der Summenbedingung stehen hier nur *Differenzen*, und das Ergebnis hängt nicht davon ab, wo der Ursprung des Koordinatensystems liegt.

Beispiel 11.1.3 (Der Erwartungswert ist eine Konvexkombination)

Sei X eine diskrete Zufallsvariable mit endlichem Träger $\mathcal{X} = T_X = \{x_1, \dots, x_k\} \subset \mathbb{R}$, in Definition 11.1.1 also $V = \mathbb{R}$. Ihr Erwartungswert

$$\mathbb{E}(X) = \sum_{x_j \in T_X} \mathbb{P}(X = x_j) x_j$$

ist eine Konvexkombination der Werte des Trägers mit den Wahrscheinlichkeiten als Gewichten, denn diese sind nichtnegativ und summieren sich zu 1. Bei abzählbar unendlichem Träger wird daraus eine Reihe, und wir bräuchten einen Grenzübergang.

Beim fairen Würfel etwa tragen alle sechs Augenzahlen das Gewicht $\frac{1}{6}$, und wir erhalten das arithmetische Mittel $\mathbb{E}(X) = 3,5$. Daran hängt eine Aussage, die im ganzen Kapitel wiederkehrt: Ein gewichteter Durchschnitt verlässt den Bereich seiner Zutaten nicht. $\mathbb{E}(X)$ liegt zwischen 1 und 6, obwohl kein einzelner Wurf jemals 3,5 zeigt.

Transformieren wir erst und mitteln dann, kommt etwas anderes heraus als umgekehrt: $\mathbb{E}(X^2) = \frac{91}{6} \approx 15,17$, aber $(\mathbb{E}(X))^2 = 12,25$, und die Differenz $\frac{35}{12} \approx 2,92$ ist die Varianz. Dass sie nie negativ ist, gilt für jede Zufallsvariable; das ist die Jensen-Ungleichung aus Abschnitt 11.4.

Zwei Punkte: das Liniensegment

Der einfachste nichttriviale Fall hat $k = 2$, und er ist die geometrische Grundlage des ganzen Kapitels.

Satz 11.1.4 (Konvexkombinationen zweier Vektoren)

Seien $\mathbf{x}_1, \mathbf{x}_2 \in V$. Die Menge aller Konvexkombinationen von $\mathbf{x}_1$ und $\mathbf{x}_2$ ist das *Liniensegment*

$$[\mathbf{x}_1, \mathbf{x}_2] := \{\mathbf{x}_1 + \lambda(\mathbf{x}_2 - \mathbf{x}_1) : \lambda \in [0, 1]\},$$

also die Verbindungsstrecke der beiden Punkte.

Vertiefung (optional): Beweis für Konvexkombinationen zweier Vektoren

Beweis.

- (1) Sei $\mathbf{x}$ eine Konvexkombination, also $\mathbf{x} = w_1 \mathbf{x}_1 + w_2 \mathbf{x}_2$ mit $w_1, w_2 \geq 0$ und $w_1 + w_2 = 1$. Setzen wir $\lambda := w_2$, so ist $\lambda \in [0, 1]$ und $w_1 = 1 - \lambda$, also

$$\mathbf{x} = (1 - \lambda) \mathbf{x}_1 + \lambda \mathbf{x}_2 = \mathbf{x}_1 + \lambda(\mathbf{x}_2 - \mathbf{x}_1).$$

die Summenbedingung erlaubt es, w_1 zu eliminieren; danach sortieren wir nach $\mathbf{x}_1$

- (2) Sei umgekehrt $\lambda \in [0, 1]$ gegeben. Mit $w_1 := 1 - \lambda$ und $w_2 := \lambda$ sind beide Gewichte nichtnegativ, ihre Summe ist 1, und die zugehörige Konvexkombination ist gerade $\mathbf{x}_1 + \lambda(\mathbf{x}_2 - \mathbf{x}_1)$. Beide Mengen enthalten einander, sind also gleich.

$\lambda \in [0, 1]$ garantiert $1 - \lambda \geq 0$; ohne diese Schranke bekämen wir die ganze Gerade durch $\mathbf{x}_1$ und $\mathbf{x}_2$ statt nur die Strecke

□

Der Parameter λ misst den Fortschritt entlang der Strecke: $\lambda = 0$ gibt $\mathbf{x}_1$, $\lambda = \frac{1}{2}$ den Mittelpunkt, $\lambda = 1$ gibt $\mathbf{x}_2$. Ohne die Schranken $0 \leq \lambda \leq 1$ erhalten wir die ganze Gerade durch die beiden Punkte; die Nichtnegativität der Gewichte unterscheidet also Strecke von Gerade.

Interaktiv: Konvexkombinationen im Dreieck

Welche Punkte der Ebene sind Konvexkombinationen der drei Ecken $(0, 0)$, $(2, 0)$ und $(1, 2)$, und woran sehen wir den Gewichten an, ob ein Punkt im Inneren, auf einer Kante oder in einer Ecke liegt?

Interaktives Element – nur in der Web-Fassung

Der grüne Punkt verlässt das Dreieck nie, weil die Gewichte nichtnegativ sind. Wird ein Gewicht null, bleibt die Konvexkombination zweier Ecken, nach Satz 11.1.4 also ihr Liniensegment; sind zwei Gewichte null, sitzt der Punkt in einer Ecke. Die Regler geben unnormierte Werte, geteilt wird durch ihre Summe; nur wenn alle drei auf 0 stehen, ist die Normierung nicht definiert.

Die konvexe Hülle

Die konvexe Hülle sammelt alles, was sich aus den Punkten einer beliebigen Menge $\mathcal{X}$ kombinieren lässt.

Definition 11.1.5 (Konvexe Hülle)

Sei $\mathcal{X} \subset V$ eine beliebige Menge von Vektoren. Die Menge

$$\text{conv}(\mathcal{X}) = \left\{ \mathbf{x} = \sum_{i=1}^N w_i \mathbf{x}_i : N \in \mathbb{N}, \mathbf{x}_i \in \mathcal{X}, w_i \geq 0, \sum_{i=1}^N w_i = 1 \right\}$$

aller Konvexkombinationen von endlich vielen Vektoren aus $\mathcal{X}$ heißt *konvexe Hülle* (convex hull) von $\mathcal{X}$.

Bemerkung 11.1.6 (Warum endlich viele)

$\mathcal{X}$ selbst darf unendlich sein, eine Kugel etwa oder eine Kurve. Jede *einzelne* Kombination benutzt aber nur endlich viele Punkte daraus, und N darf von Punkt zu Punkt anders ausfallen; deshalb steht $N \in \mathbb{N}$ mit in der Mengenklammer.

Für endliches $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_k\}$ reicht immer $N = k$: Kommt ein Punkt doppelt vor, addieren wir seine Gewichte, und fehlende Punkte bekommen das Gewicht 0.

Schließlich gilt $\mathcal{X} \subseteq \text{conv}(\mathcal{X})$: Für $N = 1$ ist $w_1 = 1$ erzwungen, und wir bekommen die Punkte von $\mathcal{X}$ selbst zurück.

Unter den Punkten von $\mathcal{X}$ gibt es solche, die sich aus den anderen nicht kombinieren lassen.

Definition 11.1.7 (Extrempunkt)

Ein Punkt $\mathbf{x} \in \mathcal{X}$ heißt *Extrempunkt* (extreme point) von $\text{conv}(\mathcal{X})$, wenn er sich nur auf die triviale Weise als Konvexkombination von Punkten aus $\mathcal{X}$ schreiben lässt, nämlich mit dem Gewicht 1 auf $\mathbf{x}$ selbst und 0 auf allen anderen Punkten von $\mathcal{X}$.

Bemerkung 11.1.8 (Extrempunkt zu sein ist keine Eigenschaft des Punktes allein)

Die Definition prüft eine Aussage über *alle* Darstellungen. Ob ein Punkt Extrempunkt ist, hängt deshalb an der ganzen Menge $\mathcal{X}$, nicht am Punkt für sich. Nehmen wir zu $\mathcal{X}$ weitere Vektoren hinzu, so kann ein bisheriger Extrempunkt seinen Status verlieren, sobald er zwischen den neuen liegt. Das Widget im nächsten Kasten führt das vor.

Für beliebige konvexe Mengen führt Abschnitt 11.2 mit Definition 11.2.5 eine allgemeinere Fassung ein; für endliches $\mathcal{X}$ wählt sie dieselben Punkte aus.

Bemerkung 11.1.9 (Die kleinste konvexe Obermenge)

$\text{conv}(\mathcal{X})$ ist die kleinste konvexe Menge, die $\mathcal{X}$ enthält. Dass sie $\mathcal{X}$ enthält, steht in Bemerkung 11.1.6; den Rest beweist Satz 11.2.12.

Interaktiv: Wie eine Punktwolke ihre Hülle aufspannt

Wir lassen eine Punktwolke wachsen und beobachten ihre konvexe Hülle. Die Hülle kann dabei nur größer werden; gilt das auch für die Liste ihrer Extrempunkte?

Interaktives Element — nur in der Web-Fassung

Die Fläche wächst monoton, die Liste der Extrempunkte nicht: Immer wieder fällt eine alte Ecke heraus, während der neue Punkt nachrückt, und schließt ein neuer Punkt zwei alte Ecken ein, sinkt ihre Anzahl sogar (Bemerkung 11.1.8).

Der grüne Punkt ist der Mittelwert der freigeschalteten Punkte, also die Konvexkombination mit lauter Gewichten $\frac{1}{k}$. Er bleibt immer in der blauen Fläche, so wie der Erwartungswert in Beispiel 11.1.3 zwischen 1 und 6 bleibt.

Vertiefung (optional): Die konvexe Hülle dreier Punkte ausführlich berechnet

Beispiel 11.1.10 (Konvexe Hülle dreier Punkte)

Sei $\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\} \subset \mathbb{R}^2$ mit

$$\mathbf{x}_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \mathbf{x}_2 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad \mathbf{x}_3 = \begin{pmatrix} 1 \\ 2 \end{pmatrix},$$

also den Ecken eines Dreiecks.

Extrempunkte. Alle drei Punkte sind Extrempunkte im Sinne von Definition 11.1.7. Keiner von ihnen liegt auf der Verbindungsstrecke der beiden anderen, also erreichen wir ihn nur mit $w_i = 1$ und $w_j = 0$ für $j \neq i$.

Konvexe Hülle. Nach Definition 11.1.5 ist $\text{conv}(\mathcal{X})$ die Menge aller Punkte

$$\mathbf{x} = w_1 \begin{pmatrix} 0 \\ 0 \end{pmatrix} + w_2 \begin{pmatrix} 2 \\ 0 \end{pmatrix} + w_3 \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2w_2 + w_3 \\ 2w_3 \end{pmatrix}$$

mit $w_1, w_2, w_3 \geq 0$ und $w_1 + w_2 + w_3 = 1$, und das ist die Dreiecksfläche samt Rand.

Ein konkreter Punkt. Für $w_1 = w_2 = w_3 = \frac{1}{3}$ ergibt sich

$$\mathbf{x} = \frac{1}{3} \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \frac{1}{3} \begin{pmatrix} 2 \\ 0 \end{pmatrix} + \frac{1}{3} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ \frac{2}{3} \end{pmatrix},$$

der Schwerpunkt des Dreiecks. Er liegt im Inneren, denn alle drei Gewichte sind positiv.

Bemerkung 11.1.11 (Rand und Inneres an den Gewichten ablesen)

Im Dreiecksbeispiel sind die Gewichte durch den Punkt eindeutig bestimmt, weil $\mathbf{x}_2 - \mathbf{x}_1$ und $\mathbf{x}_3 - \mathbf{x}_1$ linear unabhängig sind. Deshalb dürfen wir die Lage eines Punktes direkt an seinen Gewichten ablesen. Sind alle drei positiv, liegt er im Inneren. Ist genau eines gleich 0, liegt er auf der gegenüberliegenden Kante, die nach Satz 11.1.4 gerade das Liniensegment der beiden anderen Ecken ist. Sind zwei gleich 0, sind wir in einer Ecke.

Die Gewichte haben hier eine geometrische Bedeutung: w_i ist der Flächenanteil des Teildreiecks, das aus $\mathbf{x}$ und den beiden anderen Ecken gebildet wird. Beim Schwerpunkt sind alle drei Teilflächen gleich groß, jede also ein Drittel der Gesamtfläche 2. Das Widget „Konvexkombinationen im Dreieck“ oben zeigt diese Flächenanteile mit an.

Die gestrichelte Hilfsstrecke in diesem Widget zeigt, warum die drei Ecken die gesamte Fläche erzeugen. Wir mischen zuerst $\mathbf{x}_2$ und $\mathbf{x}_3$ zum Punkt $\mathbf{y}$ auf ihrer Kante und dann $\mathbf{x}_1$ mit $\mathbf{y}$. Läuft $\mathbf{y}$ über die ganze Kante, so überstreichen die Strecken von $\mathbf{x}_1$ aus das ganze Dreieck. Formal fassen wir Gewichte zusammen:

$$\mathbf{x} = w_1 \mathbf{x}_1 + (w_2 + w_3) \underbrace{\left(\frac{w_2}{w_2 + w_3} \mathbf{x}_2 + \frac{w_3}{w_2 + w_3} \mathbf{x}_3 \right)}_{= \mathbf{y}},$$

und die beiden inneren Gewichte summieren sich wieder zu 1. Vorausgesetzt ist dabei $w_2 + w_3 > 0$; sonst ist $\mathbf{x} = \mathbf{x}_1$, und es gibt nichts zu mischen. Dieselbe Rechnung mit mehr Punkten ist der Induktionsschritt im Beweis von Satz 11.2.3. Umgekehrt braucht keine Kombination beliebig viele Punkte: Im $\mathbb{R}^n$ lässt sich jeder Punkt von $\text{conv}(\mathcal{X})$ als Konvexkombination von höchstens $n+1$ Punkten aus $\mathcal{X}$ schreiben, in der Ebene also von dreien (Satz von Carathéodory).

Selbsttest

1. Jede Konvexkombination ist eine Linearkombination, aber nicht jede Linearkombination ist eine Konvexkombination.

Antwort: Wahr

Konvexkombinationen sind Linearkombinationen mit zwei Zusatzbedingungen (Definition 11.1.1), also ist die erste Hälfte klar. Für die zweite genügt ein Gegenbeispiel. Mit $\mathbf{x}_1 = (1, 0)^\top$ und $\mathbf{x}_2 = (0, 1)^\top$ ist $2\mathbf{x}_1 = (2, 0)^\top$ eine Linearkombination, aber keine Konvexkombination: Nach Satz 11.1.4 sind das genau die Punkte der Strecke zwischen $\mathbf{x}_1$ und $\mathbf{x}_2$, und $(2, 0)^\top$ liegt nicht darauf. Auf die konkreten Vektoren kommt es dabei an: Wäre $\mathbf{x}_1 = \mathbf{0}$, so wäre $2\mathbf{x}_1 = \mathbf{x}_1$ sehr wohl eine Konvexkombination.

2. Für die Dreiecksecken $\mathbf{x}_1 = (0, 0)^\top$, $\mathbf{x}_2 = (2, 0)^\top$ und $\mathbf{x}_3 = (1, 2)^\top$ liegt der Punkt $(1, 1)^\top$ nicht in $\text{conv}(\mathcal{X})$.

Antwort: Falsch

Er liegt darin, und wir können die Gewichte angeben: $\frac{1}{4}\mathbf{x}_1 + \frac{1}{4}\mathbf{x}_2 + \frac{1}{2}\mathbf{x}_3 = (\frac{1}{2} + \frac{1}{2}, 1)^\top = (1, 1)^\top$. Alle drei Gewichte sind positiv und summieren sich zu 1, der Punkt liegt also sogar im Inneren des Dreiecks.

3. Ist $\mathbf{x}$ ein Extrempunkt von $\text{conv}(\mathcal{X})$, so bleibt $\mathbf{x}$ auch dann Extrempunkt, wenn wir $\mathcal{X}$ um weitere Punkte vergrößern.

Antwort: Falsch

Extrempunkt zu sein ist eine Aussage über alle Darstellungen und hängt damit an der ganzen Menge (Bemerkung 11.1.8). Im Hüllen-Widget oben ist $(1,5; 1,4)$ bei $k = 4$ noch Extrempunkt und verliert diesen Status bei $k = 5$, weil der neu hinzukommende Punkt ihn einschließt. Umgekehrt kann ein Punkt seinen Status nie gewinnen, wenn wir Punkte hinzunehmen.

4. Der Erwartungswert einer diskreten Zufallsvariablen mit endlichem Träger ist eine Konvexkombination der Trägerwerte.

Antwort: Wahr

Die Gewichte sind die Wahrscheinlichkeiten $\mathbb{P}(X = x_j)$, nichtnegativ und mit Summe 1 (Beispiel 11.1.3). Deshalb liegt $\mathbb{E}(X)$ zwischen dem kleinsten und dem größten Trägerwert.

5. In der Definition der konvexen Hülle muss die Zahl N der beteiligten Punkte für alle Elemente dieselbe sein, und $\mathcal{X}$ muss endlich sein.

Antwort: Falsch

Beides gilt nicht. N steht mit in der Mengenklammer und darf von Punkt zu Punkt verschieden ausfallen, und $\mathcal{X}$ darf unendlich sein; nur jede einzelne Kombination benutzt endlich viele Punkte (Bemerkung 11.1.6).

6. Schieben wir im Hüllen-Widget den Regler ganz nach rechts, also auf $k = 14$. Wie viele der vierzehn Punkte sind dann noch Extrempunkte?

Lösung: 7

Sieben. Die anderen sieben liegen im Inneren der Hülle und sind Konvexkombinationen der Ecken; zur Fläche 7,46 tragen sie nichts bei. Die Extrempunkte allein beschreiben die Hülle also vollständig.

Vertiefung: Boyd und Vandenberghe, Convex Optimization, §2.1 behandelt Liniensegmente, konvexe Mengen, Konvexkombinationen und die konvexe Hülle mit weiteren Beispielen.

11.2 Konvexe Mengen

Mengen, die ihre Verbindungsstrecken enthalten

In Abschnitt 11.1 haben wir aus gegebenen Punkten neue gemischt; jetzt fragen wir umgekehrt, welche Mengen unter Konvexkombinationen abgeschlossen sind.

In der Optimierung hängt daran viel. Die zulässige Menge eines Problems sammelt alle Punkte, die die Nebenbedingungen erfüllen. Ist sie konvex, so darf ein Verfahren, das zwei zulässige Punkte kennt, jeden Punkt dazwischen ausprobieren; sonst kann schon der Weg zwischen zwei guten Lösungen durch verbotenes Gebiet führen.

Definition 11.2.1 (Konvexe Menge)

Sei V ein Vektorraum. Eine Menge $\mathcal{X} \subseteq V$ heißt *konvex* (convex), falls für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt:

$$\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in \mathcal{X}.$$

Bemerkung 11.2.2 (Was die Bedingung verlangt)

Der grüne Ausdruck ist die Konvexkombination zweier Punkte aus Abschnitt 11.1. Lläuft λ von 0 nach 1, so wandert er von $\mathbf{y}$ nach $\mathbf{x}$ und durchläuft dabei die ganze Verbindungsstrecke. Konvex heißt also: Mit je zwei Punkten liegt auch die Strecke zwischen ihnen in der Menge. Anschaulich hat eine konvexe Menge weder Einbuchtungen noch Löcher.

Nachweis und Widerlegung sind ungleich schwer. Ein einziges Paar, dessen Strecke heraushängt, widerlegt die Konvexität. Für den Nachweis dagegen müssen wir über *alle* Paare und alle λ argumentieren, und dazu brauchen wir eine Rechnung, keine Beispiele.

Interaktiv: Welche Mengen sind konvex?

Zur Wahl stehen die Kreisscheibe $\|\mathbf{z}\| \leq 1,2$, der Kreisring $0,8 \leq \|\mathbf{z}\| \leq 1,2$, ein Dreieck und die Menge unter der Parabel, und zwei Punkte lassen sich frei hineinziehen. Bei welchen der vier finden wir ein Paar, dessen Verbindungsstrecke herausläuft, und wie schwer ist die Suche?

Interaktives Element — nur in der Web-Fassung

Bei Kreisscheibe und Dreieck findet sich kein solches Paar, beim Kreisring und bei der Pa-

rabelunterseite schnell. Der vorbereitete Knopf setzt beim Ring die Punkte $(1,1; 0)^\top$ und $(0; 1,1)^\top$; ihr Mittelpunkt hat die Norm $1,1/\sqrt{2} \approx 0,778$ und unterschreitet den Innenradius 0,8. Bei der Parabel verlässt die Strecke die Menge sogar auf ganzer Länge. Der Ring vertritt im Selbsttest die Einheitssphäre, die als Kurve ohne Dicke nicht anklickbar wäre.

Die Definition spricht nur über zwei Punkte; für die konvexe Hülle brauchen wir beliebig viele.

Satz 11.2.3 (Konvexe Mengen enthalten alle Konvexkombinationen)

Sei $\mathcal{X} \subseteq V$ konvex, seien $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ und $w_1, \dots, w_N \geq 0$ mit $\sum_{i=1}^N w_i = 1$. Dann gilt

$$\sum_{i=1}^N w_i \mathbf{x}_i \in \mathcal{X}.$$

Vertiefung (optional): Beweis per Induktion über die Zahl der Punkte

Beweis.

- (1) Induktion über N . Für $N = 1$ ist $w_1 = 1$ und die Summe gleich $\mathbf{x}_1 \in \mathcal{X}$. Für $N = 2$ ist $w_2 = 1 - w_1$, und die Behauptung ist Definition 11.2.1.

die Nebenbedingung $\sum_i w_i = 1$ macht aus zwei Gewichten gerade das Paar λ und $1 - \lambda$

- (2) Sei die Aussage für N Punkte bewiesen, und seien $\mathbf{x}_1, \dots, \mathbf{x}_{N+1}$ und Gewichte $w_1, \dots, w_{N+1}$ wie im Satz gegeben. Ist $w_{N+1} = 1$, so sind alle übrigen Gewichte null und die Summe ist $\mathbf{x}_{N+1} \in \mathcal{X}$. Sei also $w_{N+1} < 1$ und

$$s := \sum_{i=1}^N w_i = 1 - w_{N+1} > 0.$$

die Gewichte sind nichtnegativ und addieren sich zu eins, also ist $s = 1 - w_{N+1}$ und $s > 0$ genau dann, wenn $w_{N+1} < 1$

- (3) Wir teilen die ersten N Gewichte durch s . Die Zahlen w_i/s sind nichtnegativ und addieren sich zu 1, also ist

$$\mathbf{u} := \sum_{i=1}^N \frac{w_i}{s} \mathbf{x}_i \in \mathcal{X}$$

nach Induktionsvoraussetzung. Damit lässt sich die volle Summe als Konvexkombination zweier Punkte schreiben:

$$\sum_{i=1}^{N+1} w_i \mathbf{x}_i = s \mathbf{u} + (1 - s) \mathbf{x}_{N+1} \in \mathcal{X},$$

denn $s \in (0, 1)$ und $\mathbf{u}, \mathbf{x}_{N+1} \in \mathcal{X}$.

Definition 11.2.1 mit $\lambda = s$; das Normieren der ersten N Gewichte macht aus einer $(N + 1)$ -Kombination eine Zweierkombination aus etwas schon Bekanntem

- (4) Zusammen mit $\mathcal{X} \subseteq \text{conv}(\mathcal{X})$, was wir an der Einerkombination $w_1 = 1$ ablesen, folgt für konvexe Mengen

$$\text{conv}(\mathcal{X}) = \mathcal{X}.$$

Eine Menge ist also genau dann konvex, wenn sie mit ihrer konvexen Hülle übereinstimmt.

der Satz liefert $\text{conv}(\mathcal{X}) \subseteq \mathcal{X}$, die Einerkombination die umgekehrte Inklusion; die Definition der konvexen Hülle steht in Abschnitt 11.1

□

Fünf Mengen im Selbsttest

1. Die leere Menge $\emptyset$ ist konvex.

Antwort: Wahr

Definition 11.2.1 fordert etwas über alle Paare $\mathbf{x}, \mathbf{y} \in \mathcal{X}$. In der leeren Menge gibt es kein solches Paar, also ist nichts zu prüfen und die Bedingung leer erfüllt. Mit demselben Argument ist jede einelementige Menge konvex, denn dort ist $\mathbf{x} = \mathbf{y}$ und $\lambda\mathbf{x} + (1 - \lambda)\mathbf{x} = \mathbf{x}$.

2. Ein Vektorraum V ist, als Teilmenge seiner selbst gelesen, konvex.

Antwort: Wahr

Ein Vektorraum ist gegen Linearkombinationen abgeschlossen, und $\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}$ ist eine solche. Dasselbe gilt für jeden Untervektorraum und für affine Teilräume. Konvexität verlangt diese Abgeschlossenheit nur für nichtnegative Gewichte mit Summe eins.

3. Die Einheitssphäre $\{\mathbf{x} \in V : \|\mathbf{x}\| = 1\}$ ist konvex.

Antwort: Falsch

Sie ist es nicht. Ein Gegenbeispiel im $\mathbb{R}^2$: Für $\mathbf{x} = (1, 0)^\top$ und $\mathbf{y} = (0, 1)^\top$ ist $\|\mathbf{x}\| = \|\mathbf{y}\| = 1$, aber der Mittelpunkt $\lambda = \frac{1}{2}$ liefert

$$\frac{1}{2}\mathbf{x} + \frac{1}{2}\mathbf{y} = (0,5; 0,5)^\top, \quad \|(0,5; 0,5)^\top\| = \sqrt{0,25 + 0,25} = \frac{1}{\sqrt{2}} \approx 0,7071 \neq 1.$$

Ohne Koordinaten: Für $V \neq \{\mathbf{0}\}$ liegt mit $\mathbf{x}$ auch $-\mathbf{x}$ auf der Sphäre, und der Mittelpunkt der beiden ist $\mathbf{0}$ mit Norm 0.

4. Der geschlossene Ball $\{\mathbf{x} \in V : \|\mathbf{x}\| \leq r\}$ ist konvex.

Antwort: Wahr

Das ist die Dreiecksungleichung plus absolute Homogenität der Norm. Für $\lambda \in [0, 1]$ sind λ und $1 - \lambda$ nichtnegativ, also

$$\|\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}\| \leq \lambda\|\mathbf{x}\| + (1 - \lambda)\|\mathbf{y}\| \leq \lambda r + (1 - \lambda)r = r.$$

Das gilt für jede Norm, also auch für die Würfel und Rauten der ∞ - und 1-Norm aus Abschnitt 3.2.

5. Die Menge $\{(x, y) \in \mathbb{R}^2 : y \leq x^2\}$ ist konvex.

Antwort: Falsch

Sie ist es nicht; sie liegt *unter* einer nach oben geöffneten Parabel. Die Punkte $(-1, 1)$ und $(1, 1)$ gehören dazu, denn $1 \leq (\pm 1)^2 = 1$. Ihr Mittelpunkt ist $(0, 1)$, und dort scheitert die Bedingung: $1 \leq 0^2 = 0$ ist falsch. Die Strecke verlässt die Menge sogar für jedes λ zwischen 0 und 1, wie das Widget vorführt.

Konvex ist dagegen die Menge oberhalb der Parabel, $\{(x, y) : y \geq x^2\}$, weil $x \mapsto x^2$ eine konvexe Funktion ist (Abschnitt 11.3).

6. Setzen wir im Widget oben den Kreisring und drücken auf „Gegenbeispiel setzen“. Ab welchem λ verlässt die Strecke die Menge?

Lösung: 0.38

Ab $\lambda \approx 0,380$, und sie kehrt bei 0,620 zurück; dazwischen liegt sie im Loch. Für die Widerlegung genügt ein einziges λ .

Weitere Beispiele

Beispiel 11.2.4 (Offener Ball)

Für $r > 0$ ist der offene Ball $\mathcal{X} = \{\mathbf{x} \in V : \|\mathbf{x}\| < r\}$ ebenfalls konvex. Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$. Mindestens eines der beiden Gewichte λ und $1 - \lambda$ ist echt positiv, und deshalb wird die Abschätzung aus dem Selbsttest strikt:

$$\|\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}\| \leq \lambda \|\mathbf{x}\| + (1 - \lambda) \|\mathbf{y}\| < \lambda r + (1 - \lambda) r = r.$$

Extrempunkte haben wir in Abschnitt 11.1 über die Gewichte eingeführt. Für konvexe Mengen, die nicht als Hülle einer Punktwolke gegeben sind, brauchen wir eine allgemeinere Fassung.

Definition 11.2.5 (Extrempunkt)

Sei $\mathcal{K} \subseteq V$ konvex. Ein Punkt $\mathbf{z} \in \mathcal{K}$ heißt *Extrempunkt* (extreme point) von $\mathcal{K}$, falls aus

$$\mathbf{z} = \lambda \mathbf{u} + (1 - \lambda) \mathbf{w} \quad \text{mit} \quad \mathbf{u}, \mathbf{w} \in \mathcal{K}, \lambda \in (0, 1)$$

stets $\mathbf{u} = \mathbf{w} = \mathbf{z}$ folgt.

Ein Extrempunkt liegt also auf keiner Strecke, die ganz in der Menge verläuft und ihn im Inneren trifft.

Vertiefung (optional): Extrempunkte: beide Fassungen und Beispiele

Für endliches $\mathcal{X}$ und $\mathcal{K} = \text{conv}(\mathcal{X})$ stimmt Definition 11.2.5 mit Definition 11.1.7 überein. Sei zunächst $\mathbf{z} \in \mathcal{X}$ nur trivial darstellbar, und sei $\mathbf{z} = \lambda \mathbf{u} + (1 - \lambda) \mathbf{w}$ mit $\mathbf{u}, \mathbf{w} \in \mathcal{K}$ und $\lambda \in (0, 1)$. Setzen wir für $\mathbf{u}$ und $\mathbf{w}$ ihre Darstellungen als Konvexkombinationen von Punkten aus $\mathcal{X}$ ein und sortieren um, so steht rechts wieder eine Konvexkombination von Punkten aus $\mathcal{X}$. Sie muss also die triviale sein, und daraus folgt $\mathbf{u} = \mathbf{w} = \mathbf{z}$.

Umgekehrt lösen wir eine nichttriviale Darstellung nach $\mathbf{z}$ auf und erhalten $\mathbf{z}$ als Konvexkombination der übrigen Punkte. Mindestens zwei von ihnen tragen positives Gewicht, denn ein einzelner Punkt mit Gewicht 1 wäre $\mathbf{z}$ selbst, und der kommt unter den übrigen nicht vor. Spalten wir einen davon ab, so liegt $\mathbf{z}$ im Inneren einer Strecke innerhalb von $\mathcal{K}$. Dasselbe Argument zeigt auch, dass Punkte aus $\mathcal{K} \setminus \mathcal{X}$ von vornherein ausscheiden.

Der offene Ball aus Beispiel 11.2.4 hat gar keinen Extrempunkt: Jeder seiner Punkte ist Mittelpunkt zweier anderer Punkte des Balls. Beim geschlossenen *euklidischen* Ball dagegen ist jeder Randpunkt extrem. Das hängt von der Norm ab: Der Einheitsball der ∞ -Norm im $\mathbb{R}^2$ ist das Quadrat $[-1, 1]^2$, und dessen Randpunkt $(1, 0)^\top$ ist der Mittelpunkt von $(1, -\frac{1}{2})^\top$ und $(1, \frac{1}{2})^\top$, die beide dazugehören. Extrem sind dort nur die vier Ecken.

Beispiel 11.2.6 (Der Simplex)

Der *Simplex*

$$\Delta^N = \left\{ \mathbf{x} \in \mathbb{R}^N : x_i \geq 0 \text{ für alle } i, \sum_{i=1}^N x_i = 1 \right\}$$

ist konvex. Seien $\mathbf{x}, \mathbf{y} \in \Delta^N$ und $\lambda \in [0, 1]$. Die Komponenten von $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ sind als Summe nichtnegativer Zahlen wieder nichtnegativ, und für die Gesamtsumme gilt

$$\sum_{i=1}^N (\lambda x_i + (1 - \lambda) y_i) = \lambda \sum_{i=1}^N x_i + (1 - \lambda) \sum_{i=1}^N y_i = \lambda \cdot 1 + (1 - \lambda) \cdot 1 = 1.$$

Extrempunkte. Die Extrempunkte von Δ^N sind genau die Standard-Basisvektoren $\mathbf{e}_1, \dots, \mathbf{e}_N$. Dass die Ecken den Simplex auch aufspannen, folgt direkt: Jedes $\mathbf{x} \in \Delta^N$ ist $\mathbf{x} = \sum_{i=1}^N x_i \mathbf{e}_i$, und die x_i sind gerade nichtnegative Gewichte mit Summe eins. Also ist $\Delta^N = \text{conv}\{\mathbf{e}_1, \dots, \mathbf{e}_N\}$.

Geometrie. Δ^2 ist die Strecke von $(1, 0)^\top$ nach $(0, 1)^\top$, Δ^3 das Dreieck mit den Ecken $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$ im $\mathbb{R}^3$, Δ^4 ein Tetraeder. Der Simplex ist außerdem abgeschlossen und beschränkt, denn er ist durch Gleichungen und nichtstrikte Ungleichungen beschrieben und erfüllt $\|\mathbf{x}\|_1 = 1$.

Bedeutung in der Statistik. Ein Punkt von Δ^N ist eine Wahrscheinlichkeitsverteilung über N Ereignisse. Der Vektor $\mathbf{p} = (0,2; 0,5; 0,3)^\top$ beschreibt eine kategoriale Verteilung mit drei Kategorien, und die Extrempunkte $\mathbf{e}_i$ sind die entarteten Verteilungen, die ihre ganze Masse auf eine Kategorie legen. Modelle, die Verteilungen vorhersagen, müssen deshalb in den Simplex hinein abbilden. Die übliche Wahl ist die Softmax-Abbildung

$$\text{SoftMax}(\mathbf{z})_i = \frac{\exp(z_i)}{\sum_{j=1}^N \exp(z_j)},$$

deren Werte nichtnegativ sind und sich nach Konstruktion zu eins addieren. Für $\mathbf{z} = (1; 2; 0,5)^\top$ etwa liefert sie $(0,231; 0,629; 0,140)^\top$. Dieselbe Menge trägt die multinomiale Regression und die Dirichlet-Verteilung, die Verteilungen über Δ^N beschreibt.

Vertiefung (optional): Warum die Ecken des Simplex seine Extrempunkte sind

Gilt $\mathbf{e}_1 = \lambda \mathbf{u} + (1 - \lambda) \mathbf{w}$ mit $\mathbf{u}, \mathbf{w} \in \Delta^N$ und $\lambda \in (0, 1)$, so ist für jedes $i \geq 2$ die Zahl $\lambda u_i + (1 - \lambda) w_i = 0$ eine Summe zweier nichtnegativer Terme mit positiven Vorfaktoren, also $u_i = w_i = 0$; weil sich die Komponenten zu eins addieren, bleibt $u_1 = w_1 = 1$. Also ist $\mathbf{e}_1$ extrem, und für die übrigen $\mathbf{e}_i$ läuft das Argument genauso. Umgekehrt ist jeder Punkt mit zwei positiven Komponenten $x_j, x_k > 0, j \neq k$, der Mittelpunkt von $\mathbf{x} \pm \varepsilon(\mathbf{e}_j - \mathbf{e}_k)$ mit $0 < \varepsilon \leq \min\{x_j, x_k\}$, zweier Punkte von Δ^N , und deshalb nicht extrem.

Der Kegel der positiv semidefiniten Matrizen

Das dritte Beispiel liegt in einem Raum von Matrizen: Die $n \times n$ -Matrizen bilden selbst einen Vektorraum, und mehr verlangt Definition 11.2.1 nicht.

Definition 11.2.7 (Positiv semidefinit)

Eine symmetrische Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ heißt *positiv semidefinit* (PSD), falls

$$\mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0 \quad \text{für alle } \mathbf{x} \in \mathbb{R}^n.$$

Wir schreiben dafür $\mathbf{A} \succeq 0$ und sammeln alle diese Matrizen in

$$\mathcal{P}_n := \{\mathbf{A} \in \mathbb{R}^{n \times n} : \mathbf{A} = \mathbf{A}^\top, \mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0 \quad \forall \mathbf{x} \in \mathbb{R}^n\}.$$

Die Symmetrie ist dabei wesentlich: Die quadratische Form $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ sieht von $\mathbf{A}$ nur den symmetrischen Anteil $(\mathbf{A} + \mathbf{A}^\top)/2$, und nur für symmetrische Matrizen gibt der Spektralsatz die Äquivalenz

zu „alle Eigenwerte sind nichtnegativ“ her.

Satz 11.2.8 (Die positiv semidefiniten Matrizen bilden eine konvexe Menge)

$\mathcal{P}_n$ ist konvex.

Beweis.

- (1) Seien $A_1, A_2 \in \mathcal{P}_n$ und $\lambda \in [0, 1]$. Wir setzen $A_\lambda := \lambda A_1 + (1 - \lambda)A_2$ und prüfen zuerst die Symmetrie:

$$A_\lambda^\top = \lambda A_1^\top + (1 - \lambda)A_2^\top = \lambda A_1 + (1 - \lambda)A_2 = A_\lambda.$$

Transponieren ist linear, und beide Summanden sind nach Voraussetzung symmetrisch

- (2) Sei nun $x \in \mathbb{R}^n$ beliebig. Dann ist

$$\begin{aligned} x^\top A_\lambda x &= x^\top [\lambda A_1 + (1 - \lambda)A_2] x \\ &= \lambda x^\top A_1 x + (1 - \lambda) x^\top A_2 x \\ &\geq \lambda \cdot 0 + (1 - \lambda) \cdot 0 = 0. \end{aligned}$$

Damit ist $A_\lambda \in \mathcal{P}_n$.

die mittlere Zeile nutzt nur, dass das Matrix-Vektor-Produkt in der Matrix linear ist; die Abschätzung nutzt $A_1, A_2 \succeq 0$ und $\lambda, 1 - \lambda \geq 0$

□

Bemerkung 11.2.9 (Kovarianzmatrizen sind semidefinit, nicht immer definit)

Kovarianzmatrizen sind stets symmetrisch und positiv *semidefinit* und bilden die konvexe Menge $\mathcal{P}_n$. Für einen Zufallsvektor X mit Kovarianzmatrix Σ und beliebiges $a \in \mathbb{R}^n$ gilt nämlich

$$a^\top \Sigma a = \text{Var}(a^\top X) \geq 0,$$

und eine Varianz ist nie negativ. Positiv *definit* ist Σ dagegen nur, wenn es keine lineare Degeneration gibt, wenn also kein $a \neq 0$ existiert, für das $a^\top X$ fast sicher konstant ist. Ein Gegenbeispiel: Für $X = (Z, Z)^\top$ mit $\text{Var}(Z) = 1$ ist

$$\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \quad a = (1, -1)^\top, \quad a^\top \Sigma a = 0,$$

und die Eigenwerte sind 2 und 0. In der Praxis passiert das, sobald zwei Merkmale exakt linear zusammenhängen oder eine empirische Kovarianzmatrix aus zu wenigen Beobachtungen geschätzt wird. Der Unterschied hat Folgen: Das Cholesky-Verfahren aus Abschnitt 5.4 verlangt positive Definitheit und scheitert im degenerierten Fall.

Die positiv definiten Matrizen bilden ebenfalls eine konvexe Menge, mit demselben Beweis und strikten Ungleichungen; sie ist das Innere von $\mathcal{P}_n$ *innerhalb des Raums der symmetrischen Matrizen*. Im vollen $\mathbb{R}^{n \times n}$ hat $\mathcal{P}_n$ für $n \geq 2$ gar kein Inneres, denn die Forderung $A = A^\top$ sperrt die Menge in einen echten Untervektorraum.

Für $n = 2$ besteht eine symmetrische Matrix $A = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$ aus nur drei Zahlen, und $\mathcal{P}_2$ lässt sich vollständig zeichnen. Wie sieht diese Menge aus, und woran erkennen wir ihren Rand?

Interaktiv: Der Kegel im Fall zweier Dimensionen

Die Bedingung aus Definition 11.2.7 lässt sich für $n = 2$ in drei Ungleichungen übersetzen: $a \geq 0$, $c \geq 0$ und $ac \geq b^2$. Die linke Tafel zeigt davon den Schnitt bei festem b . Die rechte zeigt dieselbe Menge im Raum der drei Zahlen, aber in gedrehten Koordinaten: waagrecht $\frac{a-c}{2}$ und b , senkrecht die halbe Spur $\frac{a+c}{2}$. Darin ist $\mathcal{P}_2$ ein Kreiskegel, denn $ac \geq b^2$ heißt dort $\frac{a+c}{2} \geq \sqrt{\left(\frac{a-c}{2}\right)^2 + b^2}$.

Interaktives Element — nur in der Web-Fassung

$\mathcal{P}_2$ ist ein Kegel mit gekrümmtem Rand: Mit A gehört der ganze Halbstrahl tA , $t \geq 0$, dazu, denn alle drei Bedingungen sind homogen. Der Rand $ac = b^2$ besteht aus den semidefiniten Matrizen mit Determinante 0, also vom Rang 1 oder 0; innen liegen die positiv definiten, außen die indefiniten und die negativ semidefiniten Matrizen. In den drei Voreinstellungen mit Spur 2 wandert der kleinere Eigenwert von $b = 0$ über $b = 1$ zu $b = 2$ von positiv über null ins Negative. Satz 11.2.8 sagt im Bild: Die Strecke zwischen zwei Punkten des Kegels taucht nie unter die gekrümmte Randfläche.

1. Stellen wir im Kegel-Widget $a = c = 1$ und $b = 1$ ein. Wie groß ist der kleinere Eigenwert von A ?

Lösung: 0

Null. Für $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ ist $\det A = 1 \cdot 1 - 1^2 = 0$, die Eigenwerte sind 0 und 2. Die Matrix ist semidefinit, aber nicht definit, liegt also auf dem Rand des Kegels; es ist die Kovarianzmatrix von $(Z, Z)^\top$ aus Bemerkung 11.2.9.

2. Weil $\mathcal{P}_2$ ein Kegel ist, gehört mit A auch $-A$ dazu.

Antwort: Falsch

Ein Kegel im hier gemeinten Sinn ist unter Multiplikation mit *nichtnegativen* Skalaren abgeschlossen, nicht unter Vorzeichenwechsel. Wäre $\mathcal{P}_2$ unter $t < 0$ abgeschlossen, so wäre die Menge ein Untervektorraum, und $\mathbf{x}^\top A \mathbf{x} \geq 0$ könnte nur für $A = \mathbf{0}$ gelten.

Operationen, die Konvexität erhalten

Statt jede Menge einzeln zu prüfen, bauen wir neue konvexe Mengen nach Regeln aus bekannten zusammen.

Satz 11.2.10 (Konvexitäts-erhaltung)

Sei $\mathcal{X}$ konvex und sei $(\mathcal{X}_i)_{i \in I}$ eine Familie konvexer Mengen über einer beliebigen Indexmenge I . Dann sind auch die folgenden Mengen konvex:

1. *Schnitt:* $\mathcal{S} = \bigcap_{i \in I} \mathcal{X}_i$, sofern alle $\mathcal{X}_i$ im selben Vektorraum liegen;
2. *Kartesisches Produkt:* $\mathcal{X}_1 \times \dots \times \mathcal{X}_k$, hier dürfen die Faktoren in verschiedenen Vektorräumen leben, und das Produkt trägt die komponentenweisen Verknüpfungen;
3. *Bild unter einer affinen Abbildung:* Für $\mathcal{X} \subseteq \mathbb{R}^n$ und $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$, $f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$, ist $f(\mathcal{X}) = \{\mathbf{y} = f(\mathbf{x}) : \mathbf{x} \in \mathcal{X}\}$ konvex;
4. *Summe:* $\mathcal{X}_1 \oplus \mathcal{X}_2 := \{\mathbf{x}_1 + \mathbf{x}_2 : \mathbf{x}_1 \in \mathcal{X}_1, \mathbf{x}_2 \in \mathcal{X}_2\}$ für $\mathcal{X}_1, \mathcal{X}_2 \subseteq \mathbb{R}^n$.

Vertiefung (optional): Beweis der Konvexitätserhaltung*Beweis.*

- (1) *Schnitt.* Seien $\mathbf{x}, \mathbf{y} \in \mathcal{S}$, $\lambda \in [0, 1]$ und $\mathbf{z} = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$. Aus $\mathbf{x}, \mathbf{y} \in \mathcal{S}$ folgt $\mathbf{x}, \mathbf{y} \in \mathcal{X}_i$ für jedes $i \in I$. Weil jedes $\mathcal{X}_i$ konvex ist, liegt $\mathbf{z}$ in jedem $\mathcal{X}_i$, also in ihrem Schnitt.

hier wird über die Indexmenge nichts vorausgesetzt; das Argument läuft für endlich, abzählbar oder überabzählbar viele Mengen gleich

- (2) *Kartesisches Produkt.* Seien $(\mathbf{x}_1, \dots, \mathbf{x}_k)$ und $(\mathbf{y}_1, \dots, \mathbf{y}_k)$ zwei Elemente des Produkts und $\lambda \in [0, 1]$. Addition und Skalarmultiplikation laufen im Produktraum komponentenweise, also ist

$$\begin{aligned} & \lambda(\mathbf{x}_1, \dots, \mathbf{x}_k) + (1 - \lambda)(\mathbf{y}_1, \dots, \mathbf{y}_k) \\ &= (\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{y}_1, \dots, \lambda \mathbf{x}_k + (1 - \lambda) \mathbf{y}_k) \in \mathcal{X}_1 \times \dots \times \mathcal{X}_k, \end{aligned}$$

denn die j -te Komponente liegt nach Voraussetzung in $\mathcal{X}_j$.

jede Komponente wird für sich gemischt, also greift die Konvexität von $\mathcal{X}_j$ genau auf der j -ten Stelle

- (3) *Affines Bild.* Seien $\mathbf{y}_1 = f(\mathbf{x}_1)$ und $\mathbf{y}_2 = f(\mathbf{x}_2)$ zwei Punkte von $f(\mathcal{X})$ mit $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{X}$, und sei $\lambda \in [0, 1]$. Dann ist

$$\begin{aligned} \lambda \mathbf{y}_1 + (1 - \lambda) \mathbf{y}_2 &= \lambda(\mathbf{A} \mathbf{x}_1 + \mathbf{b}) + (1 - \lambda)(\mathbf{A} \mathbf{x}_2 + \mathbf{b}) \\ &= \mathbf{A}(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) + \mathbf{b} \\ &= f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) \in f(\mathcal{X}). \end{aligned}$$

in der mittleren Zeile heben sich die beiden $\mathbf{b}$ -Anteile zu einem einzigen $\mathbf{b}$ auf, weil $\lambda + (1 - \lambda) = 1$ ist; dafür braucht es Konvex- statt Linearkombinationen

- (4) *Summe.* Das folgt aus den beiden vorigen Punkten. Nach Schritt 2 ist $\mathcal{X}_1 \times \mathcal{X}_2 \subseteq \mathbb{R}^{2n}$ konvex, und $f(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1 + \mathbf{x}_2$ ist linear, in Matrixform $f(\mathbf{z}) = (\mathbf{I}_n \ \mathbf{I}_n) \mathbf{z}$. Nach Schritt 3 ist das Bild konvex, und dieses Bild ist gerade $\mathcal{X}_1 \oplus \mathcal{X}_2$.

Schritt 3 mit $\mathbf{A} = (\mathbf{I}_n \ \mathbf{I}_n) \in \mathbb{R}^{n \times 2n}$ und $\mathbf{b} = \mathbf{0}$

□

Die beliebige Indexmenge beim Schnitt brauchen wir für Satz 11.2.12, der über *alle* konvexen Obermengen einer Menge schneidet.

Beispiel 11.2.11 (Ein Dreieck als Schnitt dreier Halbräume)

Im $\mathbb{R}^2$ betrachten wir die drei Mengen

$$\mathcal{X}_1 = \{(x, y) : x + y \leq 1\}, \quad \mathcal{X}_2 = \{(x, y) : x \geq 0\}, \quad \mathcal{X}_3 = \{(x, y) : y \geq 0\}.$$

Jede von ihnen ist ein *Halbraum*, also eine der beiden Seiten einer Hyperebene und damit von der Form $\{\mathbf{z} : \mathbf{a}^\top \mathbf{z} \leq \beta\}$; für $\mathcal{X}_2$ etwa mit $\mathbf{a} = (-1, 0)^\top$ und $\beta = 0$. Jeder Halbraum ist konvex:

$$\mathbf{a}^\top (\lambda \mathbf{z}_1 + (1 - \lambda) \mathbf{z}_2) = \lambda \mathbf{a}^\top \mathbf{z}_1 + (1 - \lambda) \mathbf{a}^\top \mathbf{z}_2 \leq \lambda \beta + (1 - \lambda) \beta = \beta.$$

Nach Satz 11.2.10(1) ist damit auch der Schnitt konvex, und der ist

$$\mathcal{S} = \mathcal{X}_1 \cap \mathcal{X}_2 \cap \mathcal{X}_3 = \{(x, y) : x \geq 0, y \geq 0, x + y \leq 1\},$$

also das Dreieck mit den Ecken $(0, 0)$, $(1, 0)$ und $(0, 1)$.

Endliche Schnitte von Halbräumen heißen *Polyeder*, und die zulässigen Mengen linearer Optimierungsprobleme sind von dieser Bauart: endlich viele lineare Ungleichungen, jede ein

Halbraum, zusammen ein konvexes Polyeder. Die Optimierung unter solchen Nebenbedingungen ist Thema von Abschnitt 12.5.

Die konvexe Hülle als kleinste konvexe Obermenge

Dass $\text{conv}(\mathcal{X})$ die kleinste konvexe Menge ist, die $\mathcal{X}$ enthält (Bemerkung 11.1.9), präzisiert und beweist der folgende Satz.

Satz 11.2.12 (Konvexe Hülle als Durchschnitt)

Für jede Menge $\mathcal{X} \subseteq V$ gilt

$$\text{conv}(\mathcal{X}) = \bigcap_{\mathcal{X} \subseteq \mathcal{Y}, \mathcal{Y} \text{ konvex}} \mathcal{Y}. \quad (11.2.1)$$

Beweis.

- (1) Zuerst zeigen wir, dass $\text{conv}(\mathcal{X})$ konvex ist. Seien $\mathbf{z} = \sum_{i=1}^N w_i \mathbf{x}_i$ und $\mathbf{z}' = \sum_{j=1}^M w'_j \mathbf{x}'_j$ zwei Konvexkombinationen von Punkten aus $\mathcal{X}$ und $\lambda \in [0, 1]$. Dann ist

$$\lambda \mathbf{z} + (1 - \lambda) \mathbf{z}' = \sum_{i=1}^N \lambda w_i \mathbf{x}_i + \sum_{j=1}^M (1 - \lambda) w'_j \mathbf{x}'_j$$

wieder eine Konvexkombination von endlich vielen Punkten aus $\mathcal{X}$: Alle Gewichte sind nicht-negativ, und ihre Summe ist $\lambda \cdot 1 + (1 - \lambda) \cdot 1 = 1$.

Konvexkombinationen von Konvexkombinationen sind wieder Konvexkombinationen

- (2) Sei $\mathcal{S}$ die rechte Seite von (11.2.1). Über wie viele Mengen dieser Schnitt läuft, brauchen wir nicht zu wissen; leer ist die Familie jedenfalls nicht, denn V selbst ist konvex und enthält $\mathcal{X}$. Wir zeigen $\text{conv}(\mathcal{X}) \subseteq \mathcal{S}$. Sei dazu $\mathcal{Y}$ irgendeine konvexe Menge mit $\mathcal{X} \subseteq \mathcal{Y}$, und sei $\mathbf{z} \in \text{conv}(\mathcal{X})$, also $\mathbf{z} = \sum_i w_i \mathbf{x}_i$ mit $\mathbf{x}_i \in \mathcal{X}$. Dann sind alle $\mathbf{x}_i$ auch Punkte von $\mathcal{Y}$, und weil $\mathcal{Y}$ konvex ist, liegt nach Satz 11.2.3 die ganze Konvexkombination in $\mathcal{Y}$. Das gilt für jedes solche $\mathcal{Y}$, also auch für den Schnitt.

hier wird Satz 11.2.3 gebraucht: Die Definition der Konvexität spricht nur über zwei Punkte, die Konvexkombination hat aber N Summanden

- (3) Umgekehrt gilt $\mathcal{S} \subseteq \text{conv}(\mathcal{X})$. Nach Schritt 1 ist $\mathcal{Y} = \text{conv}(\mathcal{X})$ selbst eine konvexe Menge, die $\mathcal{X}$ enthält, denn jedes $\mathbf{x} \in \mathcal{X}$ ist die Einkombination seiner selbst. Der Schnitt läuft also unter anderem über diese Menge und ist damit in ihr enthalten.

ein Durchschnitt ist in jeder beteiligten Menge enthalten, und $\text{conv}(\mathcal{X})$ ist eine davon

- (4) Beide Inklusionen zusammen geben (11.2.1): $\text{conv}(\mathcal{X})$ ist konvex, enthält $\mathcal{X}$ und steckt in jeder anderen konvexen Obermenge, ist also die kleinste.

Schritt 1 und die Einkombination liefern „konvex und enthält $\mathcal{X}$ “, Schritt 2 liefert „steckt in jeder anderen“

□

Anwendung: lineare Ziele werden in Ecken angenommen

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine Menge von Zusammenstellungen: Ein Vektor $\mathbf{x} \in \mathcal{X}$ sagt mit $x_i = k$, dass k Einheiten des i -ten Gegenstands vorhanden sind. Jeder Gegenstand hat einen Wert v_i , und gesucht ist die wertvollste zulässige Zusammenstellung,

$$\mathbf{x}^* \in \arg \max_{\mathbf{x} \in \mathcal{X}} \sum_{i=1}^n v_i x_i = \arg \max_{\mathbf{x} \in \mathcal{X}} \mathbf{v}^\top \mathbf{x}.$$

Das Elementzeichen steht, weil das Argmax nicht eindeutig sein muss. Ist $\mathcal{X}$ groß, so ist das Ab-suchen aller Vektoren aussichtslos; der folgende Satz verkleinert die Suche.

Satz 11.2.13 (Lineare Ziele und Extrempunkte)

Sei $\mathcal{X} \subset \mathbb{R}^n$ endlich und nichtleer, sei $\mathbf{v} \in \mathbb{R}^n$ und $M := \max_{\mathbf{x} \in \mathcal{X}} \mathbf{v}^\top \mathbf{x}$. Dann gilt:

1. $\max_{\mathbf{z} \in \text{conv}(\mathcal{X})} \mathbf{v}^\top \mathbf{z} = M$, das Maximum wächst durch den Übergang zur konvexen Hülle also nicht;
2. unter den Maximierern in $\mathcal{X}$ gibt es einen Extrempunkt $\mathbf{x}^*$ von $\text{conv}(\mathcal{X})$;
3. jeder Extrempunkt von $\text{conv}(\mathcal{X})$ liegt in $\mathcal{X}$.

Vertiefung (optional): Der Beweis des Extrempunkt-Satzes

Der technische Kern des Beweises ist ein Existenzbeweis für Extrempunkte.

Beweis.

- (1) Zu 1. Wegen $\mathcal{X} \subseteq \text{conv}(\mathcal{X})$ ist das Maximum über die Hülle mindestens M . Umgekehrt sei $\mathbf{z} = \sum_i w_i \mathbf{x}_i \in \text{conv}(\mathcal{X})$. Dann ist

$$\mathbf{v}^\top \mathbf{z} = \sum_i w_i \mathbf{v}^\top \mathbf{x}_i \leq \sum_i w_i M = M,$$

also ist das Maximum über die Hülle höchstens M .

ein gewichteter Durchschnitt von Zahlen, die alle höchstens M sind, ist höchstens M ; die Gewichte addieren sich zu eins

- (2) Sei $\mathcal{X}_M := \{\mathbf{x} \in \mathcal{X} : \mathbf{v}^\top \mathbf{x} = M\}$ die Menge der Maximierer und $\mathcal{F} := \{\mathbf{z} \in \text{conv}(\mathcal{X}) : \mathbf{v}^\top \mathbf{z} = M\}$. Wir zeigen $\mathcal{F} = \text{conv}(\mathcal{X}_M)$. Von rechts nach links rechnen wir direkt nach: Für $\mathbf{z} = \sum_i w_i \mathbf{x}_i$ mit $\mathbf{x}_i \in \mathcal{X}_M$ ist $\mathbf{v}^\top \mathbf{z} = \sum_i w_i M = M$. Für die andere Richtung sei $\mathbf{z} = \sum_i w_i \mathbf{x}_i \in \mathcal{F}$ mit $\mathbf{x}_i \in \mathcal{X}$ und $w_i > 0$. Aus $\sum_i w_i (M - \mathbf{v}^\top \mathbf{x}_i) = M - \mathbf{v}^\top \mathbf{z} = 0$ und $M - \mathbf{v}^\top \mathbf{x}_i \geq 0$ folgt $\mathbf{v}^\top \mathbf{x}_i = M$ für jedes dieser i .

eine Summe nichtnegativer Terme mit positiven Gewichten ist nur dann null, wenn jeder Term null ist

- (3) Zu 2, in der Skizze. Unter den endlich vielen Punkten von $\mathcal{X}_M$ wählen wir einen mit größter euklidischer Norm und nennen ihn $\mathbf{x}^*$. Zerlegen wir ihn als $\mathbf{x}^* = \lambda \mathbf{u} + (1 - \lambda) \mathbf{w}$ mit $\mathbf{u}, \mathbf{w} \in \text{conv}(\mathcal{X}_M)$ und $\lambda \in (0, 1)$, so liefert Ausmultiplizieren

$$\lambda \|\mathbf{u}\|^2 + (1 - \lambda) \|\mathbf{w}\|^2 - \|\lambda \mathbf{u} + (1 - \lambda) \mathbf{w}\|^2 = \lambda(1 - \lambda) \|\mathbf{u} - \mathbf{w}\|^2,$$

und links steht höchstens null, rechts mindestens null. Also sind beide Seiten null und $\mathbf{u} = \mathbf{w} = \mathbf{x}^*$, das heißt $\mathbf{x}^*$ ist Extrempunkt von $\text{conv}(\mathcal{X}_M)$. Für eine Zerlegung innerhalb von $\text{conv}(\mathcal{X})$ zwingt Schritt 1 die beiden Teilpunkte ohnehin nach $\mathcal{F} = \text{conv}(\mathcal{X}_M)$, und damit ist $\mathbf{x}^*$ auch dort extrem.

die Identität entsteht aus $\|\lambda \mathbf{u} + (1 - \lambda) \mathbf{w}\|^2 = \lambda^2 \|\mathbf{u}\|^2 + 2\lambda(1 - \lambda) \mathbf{u}^\top \mathbf{w} + (1 - \lambda)^2 \|\mathbf{w}\|^2$ und $\lambda - \lambda^2 = \lambda(1 - \lambda)$; links ist höchstens null, weil $\|\mathbf{u}\|$ und $\|\mathbf{w}\|$ die maximale Norm $\|\mathbf{x}^\|$ nicht überschreiten*

- (4) Zu 3. Sei $\mathbf{z}$ ein Extrempunkt von $\text{conv}(\mathcal{X})$, geschrieben als $\mathbf{z} = \sum_{i=1}^N w_i \mathbf{x}_i$ mit $\mathbf{x}_i \in \mathcal{X}$ und $w_i > 0$. Für $N = 1$ ist $\mathbf{z} = \mathbf{x}_1 \in \mathcal{X}$, und für $N \geq 2$ lesen wir $\mathbf{z} = w_1 \mathbf{x}_1 + (1 - w_1) \mathbf{u}$ mit $\mathbf{u} = \sum_{i=2}^N \frac{w_i}{1 - w_1} \mathbf{x}_i \in \text{conv}(\mathcal{X})$ als Zweierkombination; weil $\mathbf{z}$ extrem ist, folgt wieder $\mathbf{z} = \mathbf{x}_1 \in \mathcal{X}$.

dieselbe Normierung wie im Beweis zu Satz 11.2.3, hier benutzt, um eine N -Kombination als Zweierkombination zu lesen

□

Beispiel 11.2.14 (Auswahl unter einer Budgetschränke)

Zwei Gegenstände, der erste kostet 2 und ist 5 wert, der zweite kostet 3 und ist 8 wert. Das Budget beträgt 12, ganze Einheiten sind zu wählen:

$$\mathcal{X} = \{\mathbf{x} \in \mathbb{N}^2 : 2x_1 + 3x_2 \leq 12\}, \quad \mathbf{v} = (5, 8)^\top.$$

Diese Menge hat 19 Elemente. Ihre konvexe Hülle ist das Dreieck $\{\mathbf{x} \in \mathbb{R}^2 : x_1 \geq 0, x_2 \geq 0, 2x_1 + 3x_2 \leq 12\}$ mit den drei Extrempunkten

$$(0, 0), \quad (6, 0), \quad (0, 4),$$

denn alle Punkte von $\mathcal{X}$ erfüllen die drei Ungleichungen, und die drei Ecken liegen selbst in $\mathcal{X}$. Die Zielwerte dort sind 0, 30 und 32. Nach Satz 11.2.13 ist $\mathbf{x}^* = (0, 4)$ mit dem Wert 32 eine Lösung, und wir haben dafür drei Punkte geprüft statt neunzehn.

Der zweitbeste Punkt $(3, 2)$ schöpft das Budget voll aus ($2 \cdot 3 + 3 \cdot 2 = 12$) und erreicht den Wert 31, ist als Mittelpunkt von $(6, 0)$ und $(0, 4)$ aber kein Extrempunkt. Wer nur die Ecken absucht, übersieht ihn und verliert dadurch nichts.

Bemerkung 11.2.15 (Was der Satz leistet und was nicht)

Nicht jeder Maximierer ist ein Extrempunkt. Satz 11.2.13(2) sichert nur, dass es einen solchen gibt: Bei $\mathcal{X} = \{(0, 0), (1, 0), (2, 0)\}$ und $\mathbf{v} = (0, 1)^\top$ sind alle drei Punkte Maximierer, der mittlere ist aber der Mittelpunkt der beiden äußeren. Die Endlichkeit ist nötig: Der offene Ball aus Beispiel 11.2.4 hat gar keine Extrempunkte, und für $\mathbf{v} \neq \mathbf{0}$ erreicht $\mathbf{v}^\top \mathbf{x}$ dort sein Supremum nie.

Die Hülle muss bekannt sein. Der Satz nützt nur, wenn wir $\text{conv}(\mathcal{X})$ beschreiben können; für allgemeine Teilmengen von $\mathbb{N}^n$ ist das selbst schwer, und darin liegt die Schwierigkeit der ganzzahligen Optimierung. Ist die zulässige Menge ein Polyeder wie in Beispiel 11.2.11, so ist die Suche über die Ecken die Grundidee der linearen Programmierung, die wir nicht behandeln; Abschnitt 12.5 geht Nebenbedingungen über Lagrange-Multiplikatoren und die Karush-Kuhn-Tucker-Bedingungen an.

Vertiefung: Boyd und Vandenberghe, *Convex Optimization*, §2.1 bis §2.3: affine und konvexe Mengen, wichtige Beispiele einschließlich Simplex und semidefinitem Kegel, Operationen, die Konvexität erhalten.

11.3 Projektion und konvexe Funktionen

Der nächste Punkt einer konvexen Menge

Jetzt betrachten wir konvexe Mengen von außen: Welcher Punkt der Menge kommt einem Punkt $\mathbf{x}$ am nächsten, der nicht in ihr liegt?

Verfahren für Optimierungsprobleme mit Nebenbedingungen rechnen einen Schritt oft erst frei aus und holen das Ergebnis danach an die nächstgelegene Stelle der zulässigen Menge zurück. Auch die Kleinste-Quadrate-Rechnung aus Abschnitt 7.1 sucht im Spaltenraum von A den Punkt mit dem kleinsten Abstand zu $\mathbf{y}$. Dafür muss es einen nächstgelegenen Punkt geben, und nur einen; für abgeschlossene konvexe Mengen ist beides gesichert.

Satz 11.3.1 (Projektionstheorem)

Sei V ein endlichdimensionaler Skalarproduktraum und $\mathcal{X} \subseteq V$ eine nichtleere, abgeschlossene und konvexe Teilmenge. Dann gibt es zu jedem $\mathbf{x} \in V$ genau einen Punkt $\hat{\mathbf{x}} \in \mathcal{X}$ mit

$$\|\mathbf{x} - \hat{\mathbf{x}}\| = \min_{\mathbf{y} \in \mathcal{X}} \|\mathbf{x} - \mathbf{y}\|. \quad (11.3.1)$$

Wir nennen $\hat{\mathbf{x}}$ die *Projektion* von $\mathbf{x}$ auf $\mathcal{X}$.

Der Satz gilt ebenso in jedem *vollständigen* Skalarproduktraum; wir brauchen nur den endlichdimensionalen Fall.

Vertiefung (optional): Beweisskizze und Voraussetzungen des Projektionstheorems

Beweis.

- (1) *Existenz.* Wir setzen $d := \inf_{\mathbf{y} \in \mathcal{X}} \|\mathbf{x} - \mathbf{y}\|$. Das Infimum existiert, weil die Menge der Abstände nichtleer und nach unten durch 0 beschränkt ist. Nun wählen wir ein $\mathbf{y}_0 \in \mathcal{X}$ und schneiden die Menge mit einer Kugel:

$$\mathcal{K} := \mathcal{X} \cap \{\mathbf{y} \in V : \|\mathbf{x} - \mathbf{y}\| \leq \|\mathbf{x} - \mathbf{y}_0\|\}.$$

$\mathcal{K}$ ist nichtleer, abgeschlossen und beschränkt, und außerhalb von $\mathcal{K}$ sind alle Abstände größer als in $\mathbf{y}_0$. Es genügt also, über $\mathcal{K}$ zu minimieren.

$\mathcal{K}$ ist als Schnitt zweier abgeschlossener Mengen abgeschlossen und liegt in einer Kugel um $\mathbf{x}$, ist also beschränkt

- (2) Die Abbildung $\mathbf{y} \mapsto \|\mathbf{x} - \mathbf{y}\|$ ist stetig, und in endlicher Dimension ist $\mathcal{K}$ als abgeschlossene und beschränkte Menge kompakt. Nach dem Satz von Weierstraß nimmt eine stetige Funktion auf einer kompakten Menge ihr Minimum an. Es gibt also ein $\hat{\mathbf{x}} \in \mathcal{K} \subseteq \mathcal{X}$ mit $\|\mathbf{x} - \hat{\mathbf{x}}\| = d$.

hier steckt die Vollständigkeit des Raums: In endlicher Dimension liefert der Satz von Bolzano-Weierstraß zu jeder beschränkten Folge eine konvergente Teilfolge, und die Abgeschlossenheit hält den Grenzwert in der Menge

- (3) *Eindeutigkeit.* Angenommen, es gäbe zwei Punkte $\hat{\mathbf{x}}_1 \neq \hat{\mathbf{x}}_2$ in $\mathcal{X}$, beide mit Abstand d zu $\mathbf{x}$. Wir setzen $\mathbf{v} := \hat{\mathbf{x}}_2 - \hat{\mathbf{x}}_1 \neq \mathbf{0}$ und betrachten den Abstand entlang der Verbindungsstrecke, quadriert:

$$g(\lambda) := \|\mathbf{x} - (\hat{\mathbf{x}}_1 + \lambda \mathbf{v})\|^2, \quad \lambda \in [0, 1]. \quad (11.3.2)$$

Wegen der Konvexität von $\mathcal{X}$ liegt $\hat{\mathbf{x}}_1 + \lambda \mathbf{v} = (1 - \lambda)\hat{\mathbf{x}}_1 + \lambda\hat{\mathbf{x}}_2$ für jedes solche λ in $\mathcal{X}$. Nach Schritt 2 ist d der kleinstmögliche Abstand, also gilt $g(\lambda) \geq d^2$ auf dem ganzen Intervall.

hier geht die Konvexität ein: ohne sie wüssten wir über die Punkte der Strecke nichts

- (4) Jetzt multiplizieren wir (11.3.2) aus. Mit der Bilinearität des Skalarprodukts ist

$$g(\lambda) = \|\mathbf{x} - \hat{\mathbf{x}}_1\|^2 - 2\lambda \langle \mathbf{x} - \hat{\mathbf{x}}_1, \mathbf{v} \rangle + \lambda^2 \|\mathbf{v}\|^2,$$

eine quadratische Funktion in λ mit positivem Leitkoeffizienten. Aus $g(0) = d^2$ und $g(1) = \|\mathbf{x} - \hat{\mathbf{x}}_2\|^2 = d^2$ folgt $\langle \mathbf{x} - \hat{\mathbf{x}}_1, \mathbf{v} \rangle = \frac{1}{2} \|\mathbf{v}\|^2$.

$$g(1) - g(0) = -2\langle \mathbf{x} - \hat{\mathbf{x}}_1, \mathbf{v} \rangle + \|\mathbf{v}\|^2 = 0$$

- (5) Eine Parabel mit gleichen Werten an den Rändern hat ihren Scheitel in der Mitte. Setzen wir $\lambda = \frac{1}{2}$ ein:

$$g\left(\frac{1}{2}\right) = d^2 - \langle \mathbf{x} - \hat{\mathbf{x}}_1, \mathbf{v} \rangle + \frac{1}{4} \|\mathbf{v}\|^2 = d^2 - \frac{1}{4} \|\mathbf{v}\|^2 < d^2,$$

denn $\mathbf{v} \neq \mathbf{0}$. Der Mittelpunkt der beiden Kandidaten liegt also echt näher an $\mathbf{x}$ als d , und das widerspricht Schritt 3. Folglich war die Annahme falsch, und es gilt $\hat{\mathbf{x}}_1 = \hat{\mathbf{x}}_2$.

der rote Term misst, wie weit die beiden Kandidaten auseinanderliegen, und um ihn unterbietet der Mittelpunkt den angeblich kleinsten Abstand

□

Bemerkung 11.3.2 (Jede Voraussetzung wird gebraucht)

Der Satz stellt drei Bedingungen, und keine davon ist entbehrlich.

Abgeschlossen. Für den offenen Einheitsball $\{\mathbf{z} : \|\mathbf{z}\| < 1\}$ und $\mathbf{x} = (2, 0)^T$ ist das Infimum der Abstände 1, angenommen wird es nie: Zu jedem $\mathbf{y}$ des Balls gibt es einen näheren. Ein Minimum wie in (11.3.1) gibt es also nicht.

Konvex. Für die Einheitssphäre $\{\mathbf{z} : \|\mathbf{z}\| = 1\}$, die abgeschlossen, aber nicht konvex ist, und $\mathbf{x} = \mathbf{0}$ hat jeder Punkt der Menge den Abstand 1. Statt eines nächsten Punktes gibt es unendlich viele. Noch einfacher ist die zweielementige Menge $\{-1, +1\} \subseteq \mathbb{R}$ mit $\mathbf{x} = 0$: zwei nächste Punkte.

Endliche Dimension. Die Abgeschlossenheit allein trägt die Existenz nicht. Sie sorgt dafür, dass der Grenzwert einer Minimierungsfolge wieder in der Menge liegt; dass die Folge überhaupt konvergiert, ist der schwierigere Teil, und in endlicher Dimension liefert ihn Bolzano-Weierstraß. In unendlichdimensionalen Räumen gilt der Satz ebenfalls, dort allerdings nur für *vollständige* Räume, und die Rechnung aus Schritt 5 wird dann zur Parallelogrammgleichung, mit der sich jede Minimierungsfolge als Cauchy-Folge erweist.

Den nächstgelegenen Punkt erkennen wir auch ohne Minimierung, nämlich an einem Winkel; für Untervektorräume wird daraus die bekannte Orthogonalität.

Satz 11.3.3 (Kriterium des stumpfen Winkels)

Seien $\mathcal{X} \subseteq V$ nichtleer und konvex, $\mathbf{x} \in V$ und $\hat{\mathbf{x}} \in \mathcal{X}$. Dann hat $\hat{\mathbf{x}}$ genau dann unter allen Punkten von $\mathcal{X}$ den kleinsten Abstand zu $\mathbf{x}$, wenn

$$\langle \mathbf{x} - \hat{\mathbf{x}}, \mathbf{y} - \hat{\mathbf{x}} \rangle \leq 0 \quad \text{für alle } \mathbf{y} \in \mathcal{X}. \quad (11.3.3)$$

Geometrisch heißt (11.3.3) für $\mathbf{x} \notin \mathcal{X}$: Die Vektoren $\mathbf{x} - \hat{\mathbf{x}}$ und $\mathbf{y} - \hat{\mathbf{x}}$ schließen für jeden weiteren Punkt $\mathbf{y}$ der Menge einen Winkel von mindestens 90° ein. Die ganze Menge liegt also auf einer Seite der Hyperebene durch $\hat{\mathbf{x}}$, die senkrecht auf $\mathbf{x} - \hat{\mathbf{x}}$ steht (für $\mathbf{x} \in \mathcal{X}$ ist $\hat{\mathbf{x}} = \mathbf{x}$).

Vertiefung (optional): Winkelkriterium: Beweis, Normalgleichungen und Projektionsformeln

Abgeschlossenheit und endliche Dimension braucht das Kriterium nicht. Es sagt allerdings auch nichts darüber, ob ein nächstgelegener Punkt existiert; es erkennt ihn nur, wenn es ihn gibt.

Ist $\mathcal{X} = \mathcal{U}$ sogar ein Untervektorraum, so wird aus (11.3.3) eine Gleichung. Mit $\mathbf{y} = \hat{\mathbf{x}} \pm \mathbf{u}$ für beliebiges $\mathbf{u} \in \mathcal{U}$ liefert (11.3.3) nämlich $\pm \langle \mathbf{x} - \hat{\mathbf{x}}, \mathbf{u} \rangle \leq 0$, also $\langle \mathbf{x} - \hat{\mathbf{x}}, \mathbf{u} \rangle = 0$. Das Residuum steht dann senkrecht auf dem ganzen Unterraum, und aus dieser Bedingung entstehen die Normalgleichungen der Kleinsten Quadrate aus Abschnitt 7.1. Für eine konvexe Menge bleibt davon die Ungleichung übrig, und die

reicht aus.

Der Beweis ist eine Rechnung mit demselben quadratischen Ausdruck wie im Eindeutigkeitsbeweis des Projektionstheorems; die beiden Formeln danach zeigen zwei Fälle, in denen sich die Projektion geschlossen angeben lässt.

Beweis.

- (1) *Aus der Ungleichung folgt die Minimalität.* Sei (11.3.3) erfüllt und $y \in \mathcal{X}$ beliebig. Wir zerlegen $x - y = (x - \hat{x}) + (\hat{x} - y)$ und quadrieren:

$$\|x - y\|^2 = \|x - \hat{x}\|^2 - 2\langle x - \hat{x}, y - \hat{x} \rangle + \|y - \hat{x}\|^2 \geq \|x - \hat{x}\|^2.$$

Beide weggelassenen Terme sind nichtnegativ, der mittlere nach Voraussetzung.

$$\|a + b\|^2 = \|a\|^2 + 2\langle a, b \rangle + \|b\|^2 \text{ mit } a = x - \hat{x} \text{ und } b = \hat{x} - y, \text{ also } \langle a, b \rangle = -\langle x - \hat{x}, y - \hat{x} \rangle$$

- (2) *Aus der Minimalität folgt die Ungleichung.* Sei nun $\hat{x}$ die Projektion und $y \in \mathcal{X}$. Für $t \in (0, 1]$ liegt $z_t := \hat{x} + t(y - \hat{x})$ wegen der Konvexität in $\mathcal{X}$, also ist $\|x - z_t\|^2 \geq \|x - \hat{x}\|^2$. Ausmultipliziert heißt das

$$-2t\langle x - \hat{x}, y - \hat{x} \rangle + t^2\|y - \hat{x}\|^2 \geq 0.$$

Wir teilen durch $2t > 0$ und erhalten $\langle x - \hat{x}, y - \hat{x} \rangle \leq \frac{t}{2}\|y - \hat{x}\|^2$. Weil das für jedes $t \in (0, 1]$ gilt, dürfen wir $t \rightarrow 0$ laufen lassen, und die rechte Seite verschwindet.

dieselbe quadratische Rechnung wie im Eindeutigkeitsbeweis, nur mit dem Laufparameter t statt λ

□

Die Eindeutigkeit folgt daraus ebenfalls: Erfüllen $\hat{x}_1$ und $\hat{x}_2$ beide (11.3.3), so setzen wir einmal $y = \hat{x}_2$ und einmal $y = \hat{x}_1$ ein und addieren die beiden Ungleichungen. Übrig bleibt $\|\hat{x}_2 - \hat{x}_1\|^2 \leq 0$.

Beispiel 11.3.4 (Zwei Projektionen, die wir hinschreiben können)

Selten lässt sich die Projektion in einer Formel angeben; in diesen beiden Fällen geht es. Kugel. Für $\mathcal{X} = \{z : \|z\| \leq r\}$ ist

$$\hat{x} = \begin{cases} x, & \|x\| \leq r, \\ r \frac{x}{\|x\|}, & \|x\| > r. \end{cases}$$

Für $r = 1$ und $x = (1, 6; 1, 2)^\top$ ist $\|x\| = 2$, also $\hat{x} = (0, 8; 0, 6)^\top$ und $d = 1$. Die Probe mit (11.3.3): Es ist $x - \hat{x} = (0, 8; 0, 6)^\top = \hat{x}$, und für jedes y mit $\|y\| \leq 1$ gilt $\langle \hat{x}, y - \hat{x} \rangle = \langle \hat{x}, y \rangle - 1 \leq \|y\| - 1 \leq 0$ nach Cauchy-Schwarz.

Halbraum. Für $\mathcal{X} = \{z : a^\top z \leq \beta\}$ mit $a \neq 0$ ist

$$\hat{x} = x - \frac{\max\{0, a^\top x - \beta\}}{\|a\|^2} a,$$

wir laufen also entlang der Normalenrichtung gerade so weit, bis die Nebenbedingung mit Gleichheit erfüllt ist. Liegt x schon im Halbraum, passiert nichts.

Für ein Dreieck oder ein Polyeder gibt es keine solche Formel mehr. Dort rechnen wir die Projektion auf jede Seite einzeln aus, jeweils auf diese Seite beschränkt, und nehmen die beste; Ecken sind damit abgedeckt. So rechnet das Widget unten.

Interaktiv: Die Projektion mit beweglichem Punkt

Wandert $\hat{x}$ immer mit, wenn wir x bewegen, und wo liegt der nächste Punkt, wenn x hinter einer Ecke steht?

Interaktives Element — nur in der Web-Fassung

Der gestrichelte Kreis um $\mathbf{x}$ mit Radius $d = \|\mathbf{x} - \hat{\mathbf{x}}\|$ berührt die Menge nur in $\hat{\mathbf{x}}$. Ein weiterer Punkt der Menge im Inneren des Kreises wäre näher an $\mathbf{x}$; läge er auf dem Kreis, wäre der Mittelpunkt der beiden noch näher. Die gestrichelte Gerade durch $\hat{\mathbf{x}}$ ist die Trennlinie aus Satz 11.3.3; ziehen wir $\mathbf{x}$ um die Menge herum, dreht sie sich mit, und die Menge bleibt immer auf derselben Seite. Beim Dreieck bleibt $\hat{\mathbf{x}}$ in einer Ecke eine Weile stehen, während $\mathbf{x}$ weiterläuft.

Der Epigraph

Für die Optimierung brauchen wir konvexe *Funktionen*. Wir führen sie auf konvexe Mengen zurück, nämlich auf die Menge über dem Graphen.

Definition 11.3.5 (Epigraph)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ und $f : \mathcal{X} \rightarrow \mathbb{R}$. Der *Epigraph* (epigraph) von f ist die Menge

$$\text{epi}(f) := \{(\mathbf{x}, t) \in \mathcal{X} \times \mathbb{R} : t \geq f(\mathbf{x})\}.$$

Für $f : \mathbb{R} \rightarrow \mathbb{R}$ ist $\text{epi}(f) \subseteq \mathbb{R}^2$ die Fläche über der Kurve, den Graphen eingeschlossen.

Interaktives Element — nur in der Web-Fassung

Definition 11.3.6 (Konvexe Funktion)

Eine Funktion $f : \mathcal{X} \rightarrow \mathbb{R}$ heißt *konvex* (convex), falls ihr Epigraph $\text{epi}(f)$ eine konvexe Teilmenge des Umgebungsraums $\mathbb{R}^n \times \mathbb{R}$ ist.

Bemerkung 11.3.7 (Der Definitionsbereich muss mitspielen)

Dass $\mathcal{X}$ dabei konvex ist, müssen wir nicht eigens fordern: Mit $(\mathbf{x}, f(\mathbf{x}))$ und $(\mathbf{y}, f(\mathbf{y}))$ liegt im konvexen Epigraphen auch $\lambda(\mathbf{x}, f(\mathbf{x})) + (1 - \lambda)(\mathbf{y}, f(\mathbf{y}))$. Dessen erste Komponente $\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}$ liegt deshalb in $\mathcal{X}$, denn alle Punkte des Epigraphen haben ihre erste Komponente in $\mathcal{X}$.

Umgekehrt brauchen wir die Konvexität von $\mathcal{X}$ als Voraussetzung, sobald wir gleich mit Ungleichungen arbeiten: Dort steht $f(\lambda\mathbf{x} + (1 - \lambda)\mathbf{y})$, und dieser Ausdruck muss überhaupt erst definiert sein. Wir setzen deshalb ab jetzt durchgehend voraus, dass $\mathcal{X}$ konvex ist.

Zum Rechnen ist die Epigraph-Fassung unhandlich; gängiger ist die gleichwertige Formulierung über eine Ungleichung.

Satz 11.3.8 (Konvexität als Ungleichung)

Sei $\mathcal{X}$ konvex und $f : \mathcal{X} \rightarrow \mathbb{R}$. Dann ist f genau dann konvex im Sinne von Definition 11.3.6, wenn für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt

$$f(\lambda\mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}). \quad (11.3.4)$$

Vertiefung (optional): Beweis der Ungleichungscharakterisierung*Beweis.*

- (1) *Vom Epigraphen zur Ungleichung.* Sei $\text{epi}(f)$ konvex und seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$, $\lambda \in [0, 1]$. Die Punkte $(\mathbf{x}, f(\mathbf{x}))$ und $(\mathbf{y}, f(\mathbf{y}))$ liegen in $\text{epi}(f)$, also auch ihre Konvexkombination

$$(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}, \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y})) \in \text{epi}(f).$$

Nach Definition des Epigraphen heißt das genau (11.3.4).

ein Paar (z, t) liegt im Epigraphen, wenn $t \geq f(z)$ ist; hier ist $z = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ und $t = \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y})$

- (2) *Von der Ungleichung zum Epigraphen.* Gelte (11.3.4), und seien $(\mathbf{x}, s), (\mathbf{y}, t)$ zwei Punkte aus $\text{epi}(f)$, also $s \geq f(\mathbf{x})$ und $t \geq f(\mathbf{y})$. Für $\lambda \in [0, 1]$ rechnen wir

$$\lambda s + (1 - \lambda) t \geq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}) \geq f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}).$$

Die erste Ungleichung gilt, weil λ und $1 - \lambda$ nichtnegativ sind, die zweite ist die Voraussetzung. Zusammen mit $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in \mathcal{X}$ liegt die Konvexkombination der beiden Punkte damit wieder in $\text{epi}(f)$.

hier wird gebraucht, dass $\mathcal{X}$ konvex ist; sonst wäre die rechte Seite gar nicht definiert

□

Bemerkung 11.3.9 (Wie wir die Ungleichung lesen)

Für $f : \mathbb{R}^n \rightarrow \mathbb{R}$ hat (11.3.4) eine anschauliche Bedeutung. Die rechte Seite ist der Wert, den die Verbindungsstrecke zwischen den Graphenpunkten $(\mathbf{x}, f(\mathbf{x}))$ und $(\mathbf{y}, f(\mathbf{y}))$ an der Stelle $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ hat, die linke der Funktionswert dort. Die *Sehne* liegt also nie unter dem Graphen; konvexe Funktionen sind in diesem Sinn nach oben geöffnet.

Wir nennen f *konkav* (concave), wenn $-f$ konvex ist; für konkave Funktionen dreht sich in (11.3.4) das Ungleichheitszeichen um, die Sehne liegt nie über dem Graphen. Und wir nennen f *strikt konvex* (strictly convex), wenn in (11.3.4) für $\mathbf{x} \neq \mathbf{y}$ und $\lambda \in (0, 1)$ sogar die strikte Ungleichung gilt. Gebräuchlich sind dafür beide Namen, „strikt konvex“ und „streng konvex“; wir bleiben einheitlich bei strikt. Strikt konvexe Funktionen dürfen also keine geraden Stücke haben. Wozu wir das brauchen, zeigt Abschnitt 11.5.

Die folgenden Tafeln stellen konvex und konkav gegenüber, jeweils mit einer Sehne.

Interaktives Element — nur in der Web-Fassung

In der Tafel „konkav“ ist das ganze Zwischenstück rot, in der Tafel „weder noch“ (der Doppelmulde) nur ein Teil davon. Beides widerlegt Konvexität, konkav ist aber nur die erste der beiden.

Interaktiv: Konvexität mit einer beweglichen Sehne

Die Endpunkte der Sehne lassen sich frei wählen. Wie viele Paare müssen wir prüfen, um Konvexität zu widerlegen, und wie viele, um sie zu beweisen?

Interaktives Element — nur in der Web-Fassung

Wie bei den Mengen (Bemerkung 11.2.2) widerlegt ein einziges Paar die Konvexität, während beliebig viele bestandene Proben sie nicht beweisen. Bei der Doppelmulde in der Voreinstellung $x = -1,55$, $y = 1,25$ ragt der Graph über die Sehne (wie weit, zeigt der rote Streifen), und damit ist die Frage entschieden. Rücken wir beide Endpunkte in denselben Talgrund, etwa auf $x = -1,8$ und $y = -0,9$, so besteht das Paar die Probe, und bewiesen ist damit nichts.

Nachweis von Hand: der Betrag

Wie ein Nachweis über alle Paare aussieht, zeigt der Betrag.

Beispiel 11.3.10 (Der Betrag ist konvex)

Die Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = |x|$, ist konvex.

Beweis.

- (1) Seien $x, y \in \mathbb{R}$ und $\lambda \in [0, 1]$ beliebig. Zu zeigen ist $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$. Wir setzen die Definition von f ein und schätzen mit der Dreiecksungleichung ab:

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= |\lambda x + (1 - \lambda)y| \\ &\leq |\lambda x| + |(1 - \lambda)y| \\ &= \lambda |x| + (1 - \lambda) |y| \\ &= \lambda f(x) + (1 - \lambda)f(y). \end{aligned}$$

in der zweiten Zeile die Dreiecksungleichung $|a + b| \leq |a| + |b|$, in der dritten $|\lambda x| = |\lambda| |x| = \lambda |x|$, weil $\lambda \geq 0$ und $1 - \lambda \geq 0$ sind

- (2) Die Rechnung benutzt vom Betrag nur die absolute Homogenität und die Dreiecksungleichung und gilt deshalb für jede Norm (Satz 11.3.15).

$|\cdot|$ ist die Norm $\|\cdot\|_1$ auf $\mathbb{R}^1$

□

Der Betrag ist konvex, aber nicht strikt konvex: Für $x, y > 0$ steht in der Rechnung durchgehend Gleichheit. Außerdem zeigt er: Konvexe Funktionen dürfen Knicke haben, sie müssen nicht differenzierbar sein. Die Ableitungskriterien, die Abschnitt 11.4 bringt, sind deshalb praktisch, aber nicht die Definition.

Selbsttest

1. Die affine Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = ax + b$ mit $a, b \in \mathbb{R}$, ist konvex.

Antwort: Wahr

In (11.3.4) steht hier sogar Gleichheit: $a(\lambda x + (1 - \lambda)y) + b = \lambda(ax + b) + (1 - \lambda)(ay + b)$, weil sich die beiden b -Anteile wegen $\lambda + (1 - \lambda) = 1$ zu einem einzigen b zusammensetzen. Damit ist f konvex und zugleich konkav, aber für kein a strikt konvex.

2. Die Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^4$, ist konvex.

Antwort: Wahr

Sie ist es, und zwar strikt. Konvex ist sie nach Abschnitt 11.4 wegen $f''(x) = 12x^2 \geq 0$, strikt konvex auch über den Nullpunkt hinweg, obwohl dort $f''(0) = 0$ ist.

3. Die Wurzelfunktion $f: \mathbb{R}_+ \rightarrow \mathbb{R}$, $f(x) = \sqrt{x}$, ist konvex.

Antwort: Falsch

Sie ist konkav. Die Sehne zwischen $(0, 0)$ und $(4, 2)$ hat in der Mitte den Wert 1, die Funktion dort aber $\sqrt{2} \approx 1,414$ und liegt damit über der Sehne. Für $-f$ ist die Ungleichung erfüllt, also ist $\sqrt{\cdot}$ konkav im Sinne von Bemerkung 11.3.9.

4. Die Exponentialfunktion $f: \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = e^x$, ist konvex.

Antwort: Wahr

Sogar strikt konvex, denn $f''(x) = e^x > 0$ (Abschnitt 11.4).

5. Der Logarithmus $f: \mathbb{R}_+ \rightarrow \mathbb{R}$, $f(x) = \ln x$, ist konvex.

Antwort: Falsch

Er ist konkav, wie die Wurzel. Zwischen $x = 1$ und $x = 4$ etwa hat die Sehne in der Mitte den Wert $\frac{1}{2} \ln 4 \approx 0,693$, der Logarithmus dort aber $\ln 2,5 \approx 0,916$. Beide steigen mit wachsendem Argument immer langsamer, und das ist die Anschauung hinter konkav.

6. Ist f konkav, so ist ihr Epigraph konvex.

Antwort: Falsch

Umgekehrt. Konkav heißt, dass $-f$ konvex ist, und das ist gleichbedeutend damit, dass die Menge *unter* dem Graphen konvex ist. Für $f(x) = -x^2$ etwa ist der Epigraph das Gebiet über einer nach unten geöffneten Parabel, und die Verbindungsstrecke zwischen $(-1, -1)$ und $(1, -1)$ läuft durch $(0, -1)$, was wegen $-1 < f(0) = 0$ nicht im Epigraphen liegt.

7. Wählen wir im Sehnentest die Doppelmulde in ihrer Voreinstellung $x = -1,55$, $y = 1,25$. Wie dick ist der rote Streifen an seiner stärksten Stelle, also wie weit ragt der Graph über die Sehne?

Lösung: 1.891

Um 1,891. Das ist die größte Verletzung von (11.3.4) auf diesem Paar, und mehr braucht es nicht: Satz 11.3.8 fordert die Ungleichung für alle Paare, ein einziges Gegenbeispiel entscheidet die Frage.

Beispiele konvexer Funktionen

Drei Klassen konvexer Funktionen kommen in der Statistik häufig vor.

Beispiel 11.3.11 (Affine Funktionen)

Für $\mathbf{b} \in \mathbb{R}^n$ und $a \in \mathbb{R}$ ist $f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} + a$ konvex und konkav zugleich, denn in (11.3.4) steht Gleichheit:

$$\mathbf{b}^\top (\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) + a = \lambda (\mathbf{b}^\top \mathbf{x} + a) + (1 - \lambda) (\mathbf{b}^\top \mathbf{y} + a).$$

Satz 11.3.12 (Quadratische Funktionen)

Seien $\mathbf{Q} \in \mathbb{R}^{n \times n}$, $\mathbf{b} \in \mathbb{R}^n$ und $a \in \mathbb{R}$, und sei

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + a.$$

Ist der symmetrische Anteil $\mathbf{Q}_{\text{sym}} := \frac{1}{2}(\mathbf{Q} + \mathbf{Q}^\top)$ positiv semidefinit, so ist f konvex. Ist $\mathbf{Q}_{\text{sym}}$ sogar positiv definit, so ist f strikt konvex.

Vertiefung (optional): Quadratische Funktionen: Beweis und Zahlenbeispiel

Beweis.

- (1) Wir rechnen die Differenz zwischen rechter und linker Seite von (11.3.4) aus. Mit $\mathbf{z} := \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$ und $\mathbf{d} := \mathbf{x} - \mathbf{y}$ gilt

$$\lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) - f(\mathbf{z}) = \lambda(1 - \lambda) \mathbf{d}^\top \mathbf{Q} \mathbf{d}.$$

Die affinen Anteile $\mathbf{b}^\top \mathbf{x} + a$ fallen dabei heraus, weil sie nach Beispiel 11.3.11 die Gleichung mit Gleichheit erfüllen; zu rechnen bleibt der quadratische Teil.

ausmultiplizieren: $\mathbf{z}^\top \mathbf{Q} \mathbf{z} = \lambda^2 \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \lambda(1 - \lambda)(\mathbf{x}^\top \mathbf{Q} \mathbf{y} + \mathbf{y}^\top \mathbf{Q} \mathbf{x}) + (1 - \lambda)^2 \mathbf{y}^\top \mathbf{Q} \mathbf{y}$, und mit $\lambda - \lambda^2 = \lambda(1 - \lambda)$ bleibt der angegebene Term

- (2) Nun ist $\mathbf{d}^\top \mathbf{Q} \mathbf{d} = \mathbf{d}^\top \mathbf{Q}_{\text{sym}} \mathbf{d}$, denn der schiefsymmetrische Anteil $\frac{1}{2}(\mathbf{Q} - \mathbf{Q}^\top)$ liefert in einer quadratischen Form stets null. Ist $\mathbf{Q}_{\text{sym}}$ positiv semidefinit, so ist dieser Ausdruck nichtnegativ, und wegen $\lambda(1 - \lambda) \geq 0$ ist die ganze Differenz nichtnegativ. Das ist (11.3.4). Ist $\mathbf{Q}_{\text{sym}}$ positiv definit, so ist der Ausdruck für $\mathbf{d} \neq \mathbf{0}$ und $\lambda \in (0, 1)$ echt positiv, und wir bekommen die strikte Ungleichung.

$\mathbf{d}^\top \mathbf{A} \mathbf{d} = (\mathbf{d}^\top \mathbf{A} \mathbf{d})^\top = \mathbf{d}^\top \mathbf{A}^\top \mathbf{d}$, also verschwindet $\mathbf{d}^\top (\mathbf{A} - \mathbf{A}^\top) \mathbf{d}$

□

Beispiel 11.3.13 (Eine Quadrik ausgerechnet)

Sei $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + a$ mit

$$\mathbf{Q} = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}, \quad a = 3.$$

$\mathbf{Q}$ ist symmetrisch mit den Eigenwerten 2 und 1, also positiv definit. Nach Satz 11.3.12 ist f strikt konvex. Auswerten an der Stelle $\mathbf{x} = (1, 2)^\top$:

$$\begin{aligned} f(\mathbf{x}) &= \begin{pmatrix} 1 & 2 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 1 & -2 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} + 3 \\ &= \begin{pmatrix} 1 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} + (1 - 4) + 3 = 6 - 3 + 3 = 6. \end{aligned}$$

Weil $\mathbf{Q}$ hier diagonal ist, lässt sich f auch als $2x_1^2 + x_2^2 + x_1 - 2x_2 + 3$ schreiben, und daran ist die strikte Konvexität ohne Matrixrechnung zu sehen: eine Summe zweier nach oben geöffneten Parabeln plus einer affinen Funktion.

Bemerkung 11.3.14 (Warum der symmetrische Anteil entscheidet)

Die Voraussetzung des Satzes betrifft $\mathbf{Q}_{\text{sym}}$ und nicht $\mathbf{Q}$ selbst. Verlangten wir „ $\mathbf{Q}$ positiv semidefinit“, so wäre die Aussage unnötig eng, denn der schiefsymmetrische Anteil $\frac{1}{2}(\mathbf{Q} - \mathbf{Q}^\top)$ liefert in der quadratischen Form null. Für

$$\mathbf{Q} = \begin{pmatrix} 1 & 5 \\ -5 & 1 \end{pmatrix}$$

Ist $\mathbf{Q}_{\text{sym}} = \mathbf{I}$, die Funktion $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x} = x_1^2 + x_2^2$ also strikt konvex, obwohl $\mathbf{Q}$ selbst nicht symmetrisch und damit nach Definition 11.2.7 nicht einmal ein Kandidat für „positiv semidefinit“ ist.

Satz 11.3.15 (Jede Norm ist konvex)

Sei $\|\cdot\|$ eine beliebige Norm auf $\mathbb{R}^n$. Dann ist $f(\mathbf{x}) = \|\mathbf{x}\|$ konvex.

Beweis.

- (1) Seien $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ und $\lambda \in [0, 1]$. Dann ist

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) = \|\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}\| \leq \lambda \|\mathbf{x}\| + (1 - \lambda) \|\mathbf{y}\| = \lambda \|\mathbf{x}\| + (1 - \lambda) \|\mathbf{y}\|.$$

Dreiecksungleichung, dann absolute Homogenität $\|c\mathbf{x}\| = |c| \|\mathbf{x}\|$ mit $c = \lambda \geq 0$ beziehungsweise $c = 1 - \lambda \geq 0$

- (2) Die Definitheit ($f(\mathbf{x}) = 0 \implies \mathbf{x} = \mathbf{0}$) geht nirgends ein; der Beweis gilt also auch für Halbnormen, und für $n = 1$ ist er der aus Beispiel 11.3.10.

die drei Normeigenschaften stehen als Definition 3.2.1 in Kapitel 3, dort für Matrizen formuliert; Bemerkung 3.2.2 hält fest, dass es dieselben Axiome sind

□

Strikt konvex ist keine Norm: Liegen $\mathbf{x}$ und $\mathbf{y}$ auf demselben Strahl durch den Ursprung, so steht in Schritt 1 überall Gleichheit. Das *Quadrat* der euklidischen Norm, $\|\mathbf{x}\|_2^2 = \mathbf{x}^\top \mathbf{I} \mathbf{x}$, ist dagegen nach Satz 11.3.12 strikt konvex, weil $\mathbf{I}$ positiv definit ist.

Beispiel 11.3.16 (Kleinste Quadrate und Ridge)

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ die Designmatrix und $\mathbf{y} \in \mathbb{R}^m$ der Beobachtungsvektor. Der Kleinste-Quadrate-Verlust lässt sich ausmultiplizieren zu

$$f(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|^2 = \mathbf{w}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{w} - 2\mathbf{y}^\top \mathbf{A} \mathbf{w} + \|\mathbf{y}\|^2,$$

also zu einer quadratischen Funktion mit $\mathbf{Q} = \mathbf{A}^\top \mathbf{A}$. Diese Matrix ist symmetrisch und stets positiv semidefinit, denn

$$\mathbf{w}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{w} = (\mathbf{A} \mathbf{w})^\top (\mathbf{A} \mathbf{w}) = \|\mathbf{A} \mathbf{w}\|^2 \geq 0.$$

Nach Satz 11.3.12 ist der Kleinste-Quadrate-Verlust deshalb immer konvex, unabhängig von den Daten. Deshalb spielten lokale Minima in Kapitel 7 keine Rolle.

Strikt konvex ist er dagegen nur bei vollem Spaltenrang. Hat $\mathbf{A}$ zwei gleiche Spalten, etwa

$$\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 2 & 2 \\ 3 & 3 \end{pmatrix}, \quad \mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 14 & 14 \\ 14 & 14 \end{pmatrix},$$

so ist $\mathbf{d}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{d} = 0$ für $\mathbf{d} = (1, -1)^\top$, und entlang dieser Richtung ist f konstant. Die Lösung ist dann nicht eindeutig.

Hier setzt die *Ridge-Regression* an. Sie addiert einen Strafterm,

$$f_\lambda(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|^2 + \lambda \|\mathbf{w}\|^2 = \mathbf{w}^\top (\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I}) \mathbf{w} - 2\mathbf{y}^\top \mathbf{A} \mathbf{w} + \|\mathbf{y}\|^2,$$

und für $\lambda > 0$ ist $\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I}$ positiv definit: $\mathbf{w}^\top (\mathbf{A}^\top \mathbf{A} + \lambda \mathbf{I}) \mathbf{w} = \|\mathbf{A}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|^2 > 0$ für $\mathbf{w} \neq \mathbf{0}$. Nach Satz 11.3.12 ist f_λ also strikt konvex, und die Lösung ist eindeutig, auch bei rangdefizientem $\mathbf{A}$. Die Rechnung dazu, samt Gradient, steht in Beispiel 10.6.6.

Der Strafterm hebt dabei alle Eigenwerte um λ an und drückt so die Konditionszahl: Das rangdefiziente $\mathbf{A}^\top \mathbf{A}$ von oben hat die Eigenwerte 28 und 0, κ_2 ist also unendlich; mit $\lambda = 1$ stehen dort 29 und 1, und κ_2 fällt auf 29.

Vertiefung: Boyd und Vandenberghe, Convex Optimization, Kapitel 3 führt konvexe Funktionen über dieselbe Ungleichung ein, sammelt die Beispiele (Normen, quadratische Funktionen) und behandelt die Epigraph-Charakterisierung ausführlich. Das Projektionstheorem ist der endlichdimensionale Fall des Projektionssatzes für Hilberträume, den jedes Lehrbuch zur Funktionalanalysis bringt.

11.4 Eigenschaften konvexer Funktionen

Regeln statt Nachrechnen

Konvexität für jede neue Funktion aus der Definition nachzuweisen, wie in Abschnitt 11.3 für den Betrag, wäre mühsam. Die Zielfunktionen der Statistik entstehen ohnehin aus Bausteinen: Ein Verlust wird über die Beobachtungen summiert, ein Strafterm kommt dazu, über Klassen wird maximiert, und am Ende steht vielleicht ein Grenzübergang.

Vier Operationen, die Konvexität erhalten

Satz 11.4.1 (Operationen, die Konvexität erhalten)

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und seien $f_1, f_2, \dots : \mathcal{X} \rightarrow \mathbb{R}$ konvexe Funktionen. Dann sind auch die folgenden Funktionen auf $\mathcal{X}$ konvex:

1. die Summe $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$;
2. das nichtnegative Vielfache $f(\mathbf{x}) = c f_1(\mathbf{x})$ mit $c \geq 0$;
3. das punktweise Supremum $f(\mathbf{x}) = \sup_i f_i(\mathbf{x})$, sofern dieser Wert an jeder Stelle endlich ist; bei endlich vielen Funktionen ist das das Maximum $\max_i f_i(\mathbf{x})$;
4. der punktweise Grenzwert $f(\mathbf{x}) = \lim_{k \rightarrow \infty} f_k(\mathbf{x})$, sofern dieser Grenzwert für jedes $\mathbf{x} \in \mathcal{X}$ existiert.

Die Teile (1) und (3) lösen wir unten als Übungen.

Vertiefung (optional): Beweise zu Skalarmultiplikation und Grenzwerten

Beweis.

(1) Zu (2). Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$. Dann gilt

$$\begin{aligned} f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) &= c f_1(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \\ &\leq c(\lambda f_1(\mathbf{x}) + (1 - \lambda) f_1(\mathbf{y})) \\ &= \lambda c f_1(\mathbf{x}) + (1 - \lambda) c f_1(\mathbf{y}) = \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \end{aligned}$$

im zweiten Schritt geht beides ein: die Konvexität von f_1 liefert die Ungleichung, und $c \geq 0$ erlaubt es, mit c zu multiplizieren, ohne das Ungleichheitszeichen zu drehen. Für $c < 0$ dreht es sich um, und $c f_1$ ist dann konkav

- (2) Zu (4). Wieder seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$. Wir setzen $\mathbf{z} := \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$, das nach Voraussetzung wieder in $\mathcal{X}$ liegt, und rechnen nach:

$$\begin{aligned} f(\mathbf{z}) &= \lim_{k \rightarrow \infty} f_k(\mathbf{z}) = \limsup_{k \rightarrow \infty} f_k(\mathbf{z}) \\ &\leq \limsup_{k \rightarrow \infty} [\lambda f_k(\mathbf{x}) + (1 - \lambda) f_k(\mathbf{y})] \\ &\leq \lambda \limsup_{k \rightarrow \infty} f_k(\mathbf{x}) + (1 - \lambda) \limsup_{k \rightarrow \infty} f_k(\mathbf{y}) \\ &= \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \end{aligned}$$

Zeile 1: f ist als Grenzwert definiert, und eine konvergente Folge hat Limes und Limes superior gemeinsam. Zeile 2: jedes einzelne f_k ist konvex, und der Limes superior ist monoton, aus $a_k \leq b_k$ folgt also $\limsup a_k \leq \limsup b_k$. Zeile 3: Subadditivität des Limes superior, zusammen mit $\lambda, 1 - \lambda \geq 0$. Zeile 4: beide Folgen konvergieren nach Voraussetzung, ihr Limes superior ist also ihr Grenzwert

- (3) Weil hier alle drei Folgen konvergieren, kämen wir auch mit den gewöhnlichen Grenzwertregeln aus. Der Limes superior braucht die Konvergenz aber erst in der letzten Zeile.

dieselbe Kette zeigt deshalb: Ist $\limsup_k f_k$ überall endlich, so ist auch diese Funktion konvex, ganz ohne Konvergenzannahme

□

Beispiel 11.4.2 (Übung: die Summe zweier konvexer Funktionen)

Zu zeigen ist Teil (1) von Satz 11.4.1: Sind f_1 und f_2 konvex, so ist $f = f_1 + f_2$ konvex. Aus zwei Ungleichungen wird eine.

Lösung

Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$. Die Konvexität von f_1 und von f_2 liefert je eine Ungleichung, und beide zeigen in dieselbe Richtung:

$$\begin{aligned} f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) &= f_1(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) + f_2(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \\ &\leq [\lambda f_1(\mathbf{x}) + (1 - \lambda) f_1(\mathbf{y})] + [\lambda f_2(\mathbf{x}) + (1 - \lambda) f_2(\mathbf{y})] \\ &= \lambda [f_1(\mathbf{x}) + f_2(\mathbf{x})] + (1 - \lambda) [f_1(\mathbf{y}) + f_2(\mathbf{y})] \\ &= \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \end{aligned}$$

Der einzige Schritt, der etwas verlangt, ist der zweite: Zwei Ungleichungen mit demselben Zeichen dürfen addiert werden. Sortiert wird danach nur noch nach $\mathbf{x}$ und $\mathbf{y}$.

Beispiel 11.4.3 (Übung: das punktweise Maximum)

Zu zeigen ist Teil (3) von Satz 11.4.1 für endlich viele Funktionen: Sind $f_1, \dots, f_m$ konvex, so ist $f(\mathbf{x}) = \max_{i \leq m} f_i(\mathbf{x})$ konvex. Entscheidend ist die Frage, welches i das Maximum liefert.

Lösung

Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$, und sei wieder $\mathbf{z} = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$. Weil es nur endlich viele Funktionen sind, wird das Maximum an der Stelle $\mathbf{z}$ angenommen: Wir wählen ein

$$j \in \arg \max_{i \leq m} f_i(\mathbf{z}), \quad \text{also} \quad f(\mathbf{z}) = f_j(\mathbf{z}).$$

Für dieses eine j rechnen wir:

$$f(\mathbf{z}) = f_j(\mathbf{z}) \leq \lambda f_j(\mathbf{x}) + (1 - \lambda) f_j(\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Die erste Ungleichung ist die Konvexität von f_j . Die zweite benutzt $f_j \leq f$ punktweise, denn f ist das Maximum über alle i , und dass die Gewichte λ und $1 - \lambda$ nichtnegativ sind.

Dass an den Stellen $\mathbf{x}$ und $\mathbf{y}$ womöglich ein anderer Index maximiert, stört nicht: j wird nur links gebraucht, und rechts schätzen wir sofort wieder gegen das Maximum ab.

Für unendlich viele Funktionen gibt es kein Argmax mehr. Dann argumentieren wir ohne Fallunterscheidung: Für jedes einzelne i ist

$$f_i(\mathbf{z}) \leq \lambda f_i(\mathbf{x}) + (1 - \lambda) f_i(\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}),$$

und die rechte Seite hängt nicht mehr von i ab. Sie ist damit eine obere Schranke für alle $f_i(\mathbf{z})$, also auch für deren Supremum $f(\mathbf{z})$.

Vertiefung (optional): Was die vier Regeln zusammen hergeben

Bemerkung 11.4.4 (Was die vier Regeln zusammen hergeben)

Aus (1) und (2) folgt per Induktion: Jede *nichtnegative Linearkombination* $\sum_{i=1}^m c_i f_i$ mit $c_i \geq 0$ konvexer Funktionen ist konvex. Die konvexen Funktionen auf $\mathcal{X}$ bilden also einen konvexen Kegel, analog zum Kegel der positiv semidefiniten Matrizen aus Satz 11.2.8.

Die Vorzeichenbedingung ist unverzichtbar. Für $c < 0$ dreht sich die Ungleichung, $c f_1$ ist dann konkav. Deshalb ist auch die Differenz zweier konvexer Funktionen im Allgemeinen weder konvex noch konkav: Mit $f_1(x) = x^2$ und $f_2(x) = 2x^2$ ist $f_1 - f_2 = -x^2$ konkav, mit $f_2(x) = \frac{1}{2}x^2$ dagegen bliebe die Differenz konvex.

Zu (3) trägt nur die Supremum-Fassung, denn ein Maximum über unendlich viele Werte muss weder angenommen werden noch endlich sein: Für $f_i(x) = i x^2$ ist das Supremum in jedem $x \neq 0$ gleich $+\infty$, und über solche Funktionen redet Definition 11.3.6 nicht.

Regel (4) erhält die Konvexität, nicht aber die Glattheit: Die Funktionen $f_k(x) = |x|^{1+1/k}$ sind konvex und überall differenzierbar, auch in $x = 0$ mit $f'_k(0) = 0$, streben punktweise aber gegen $|x|$ und damit gegen eine Funktion mit Knick. Das ist einer der Gründe, warum wir am Ende dieses Abschnitts einen Ersatz für die Tangente brauchen.

Beispiel 11.4.5 (Zielfunktionen aus Bausteinen)

Die Bausteine kennen wir aus Abschnitt 11.3: Normen, affine Funktionen und quadratische Funktionen mit positiv semidefinitem symmetrischen Anteil sind konvex.

Ridge-Regression. Die Zielfunktion $f(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|^2 + \lambda \|\mathbf{w}\|^2$ ist eine Summe zweier konvexer Funktionen, die zweite mit dem Faktor $\lambda \geq 0$; nach den Regeln (1) und (2) ist sie konvex, ohne dass wir eine Ungleichung nachrechnen. Die strikte Konvexität für $\lambda > 0$ liefern die Regeln nicht, sie kam in Beispiel 11.3.16 aus der quadratischen Form.

LASSO. Mit dem Strafterm $\lambda \|\mathbf{w}\|_1$ bleibt das Argument gleich, denn auch die ℓ_1 -Norm ist eine Norm. Die Zielfunktion ist also konvex, an den Stellen mit $w_j = 0$ aber nicht differenzierbar, und Satz 11.3.12 greift nicht mehr.

Hinge-Verlust und Support Vector Machines. Der Verlust $\ell(u) = \max\{0, 1 - u\}$ mit $u = \mathbf{y}_i \mathbf{x}_i^\top \boldsymbol{\beta}$ ist ein Maximum zweier affiner Funktionen von $\boldsymbol{\beta}$, nach Regel (3) also konvex. Die Summe über die Beobachtungen ist es nach Regel (1) ebenfalls.

Vom empirischen zum theoretischen Risiko. Ist $\theta \mapsto \ell(\theta; \mathbf{z})$ für jede Beobachtung konvex, so ist das empirische Risiko $R_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(\theta; \mathbf{z}_i)$ nach den Regeln (1) und (2) konvex. Es strebt nach dem Gesetz der großen Zahlen punktweise gegen das theoretische Risiko $R(\theta) = \mathbb{E}[\ell(\theta; \mathbf{Z})]$, und Regel (4) überträgt die Konvexität auf diesen Grenzwert.

Die Jensen-Ungleichung

Die Jensen-Ungleichung überträgt die Definition der Konvexität von zwei Punkten auf Konvexkombinationen (Abschnitt 11.1) beliebig vieler Punkte.

Satz 11.4.6 (Jensen-Ungleichung)

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f: \mathcal{X} \rightarrow \mathbb{R}$ konvex. Dann gilt für alle $N \in \mathbb{N}$, alle $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ und alle Gewichte $w_1, \dots, w_N \geq 0$ mit $\sum_{i=1}^N w_i = 1$

$$f\left(\sum_{i=1}^N w_i \mathbf{x}_i\right) \leq \sum_{i=1}^N w_i f(\mathbf{x}_i). \quad (11.4.1)$$

Vertiefung (optional): Induktionsbeweis der Jensen-Ungleichung

Beweis.

- (1) Induktion über N . Für $N = 1$ ist $w_1 = 1$, und auf beiden Seiten steht $f(\mathbf{x}_1)$. Für $N = 2$ ist (11.4.1) mit $\lambda := w_1$ und $w_2 = 1 - \lambda$ die Definition einer konvexen Funktion.

die Jensen-Ungleichung ist also keine neue Eigenschaft, sondern die Definition, mehrfach angewandt

- (2) Sei nun $N \geq 3$ und die Behauptung für $N - 1$ Punkte bereits bewiesen. Ist $w_N = 1$, so sind alle übrigen Gewichte null, und beide Seiten sind $f(\mathbf{x}_N)$. Sei also $w_N < 1$ und

$$s := \sum_{i=1}^{N-1} w_i = 1 - w_N > 0, \quad \mathbf{z} := \sum_{i=1}^{N-1} \frac{w_i}{s} \mathbf{x}_i.$$

Die Koeffizienten w_i/s sind nichtnegativ und summieren sich zu 1, also ist $\mathbf{z}$ eine Konvexkombination von $\mathbf{x}_1, \dots, \mathbf{x}_{N-1}$ und liegt in $\mathcal{X}$.

hier wird Satz 11.2.3 gebraucht: Eine konvexe Menge enthält alle endlichen Konvexkombinationen, nicht nur die Verbindungsstrecken je zweier Punkte. Ohne diese Aussage wüssten wir nicht, dass $f(\mathbf{z})$ überhaupt definiert ist

- (3) Nach Konstruktion ist $\sum_{i=1}^N w_i \mathbf{x}_i = s \mathbf{z} + w_N \mathbf{x}_N$ eine Konvexkombination der beiden Punkte $\mathbf{z}$ und $\mathbf{x}_N$, denn $s + w_N = 1$ und beide Gewichte sind nichtnegativ. Damit rechnen wir

$$\begin{aligned} f\left(\sum_{i=1}^N w_i \mathbf{x}_i\right) &= f(s \mathbf{z} + w_N \mathbf{x}_N) \\ &\leq s f(\mathbf{z}) + w_N f(\mathbf{x}_N) \\ &\leq s \sum_{i=1}^{N-1} \frac{w_i}{s} f(\mathbf{x}_i) + w_N f(\mathbf{x}_N) = \sum_{i=1}^N w_i f(\mathbf{x}_i). \end{aligned}$$

die erste Ungleichung ist die Definition der Konvexität für die zwei Punkte $\mathbf{z}$ und $\mathbf{x}_N$, die zweite ist die Induktionsvoraussetzung, multipliziert mit $s \geq 0$. Im letzten Schritt kürzt sich s heraus

□

Bemerkung 11.4.7 (Gewichte als Wahrscheinlichkeiten)

Beispiel 11.1.3 hat den Erwartungswert einer Zufallsvariablen mit endlichem Träger als Konvexkombination gelesen: Die Gewichte sind die Wahrscheinlichkeiten, der Erwartungswert ist also selbst eine Mischung. In dieser Sprache lautet (11.4.1)

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)],$$

und das ist die Form, in der die Jensen-Ungleichung meist zitiert wird. Erst mischen und dann auswerten gibt höchstens so viel wie erst auswerten und dann mischen.

Satz 11.4.6 deckt nur Zufallsvariablen mit endlichem Träger ab. Für allgemeine integrierbare X gilt die Ungleichung ebenfalls; der Beweis läuft dann über Stützgeraden (Bemerkung 11.4.17). Für konkave f dreht sie sich um, dort gilt $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$, was etwa beim Logarithmus in Likelihood-Rechnungen oft gebraucht wird.

Beispiel 11.4.8 (Die Varianz ist nicht negativ)

Aus der Jensen-Ungleichung folgt eine Aussage, die wir bisher ohne Beweis benutzt haben. Die Funktion $f(x) = x^2$ ist konvex auf $\mathbb{R}$. Für eine Zufallsvariable X mit endlichem Träger liefert Bemerkung 11.4.7 damit

$$(\mathbb{E}[X])^2 = f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)] = \mathbb{E}[X^2],$$

und Umstellen ergibt

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \geq 0.$$

Beim fairen Würfel aus Beispiel 11.1.3 steht $\mathbb{E}[X^2] = \frac{91}{6}$ gegen $(\mathbb{E}[X])^2 = 12,25$, und die Lücke $\frac{35}{12} \approx 2,92$ ist die Varianz. Gleichheit tritt genau dann ein, wenn die Varianz verschwindet, wenn also X mit Wahrscheinlichkeit 1 konstant ist.

Interaktiv: Die Jensen-Ungleichung an drei Stützstellen

Drei feste Stützstellen bekommen einstellbare Gewichte, und das Widget zeichnet beide Seiten von (11.4.1) über derselben Stelle $\sum_i w_i x_i$: orange den Funktionswert der Mischung, grün die Mischung der Funktionswerte. Wie groß ist der Abstand zwischen beiden, und bei welcher Reglerstellung verschwindet er?

Interaktives Element — nur in der Web-Fassung

Das grüne Dreieck ist die konvexe Hülle der drei Graphenpunkte und liegt bei konvexem f nie unter der Kurve, also unterbietet der grüne Punkt den orangen nie. Für $f(x) = x^2$ ist der Abstand die gewichtete Varianz der Stützstellen (Beispiel 11.4.8), bei e^x ist er deutlich größer, weil die Krümmung nach rechts stark zunimmt. Die konkave Wurzel ist die Gegenprobe: Dort liegt der orange Wert über dem grünen. Liegt alles Gewicht auf einer Stützstelle, steht auf beiden Seiten derselbe Wert, wie bei einer Zufallsvariablen mit Varianz 0.

Konvexität an der Ableitung ablesen

Die Bausteine selbst mussten wir bisher aus der Definition prüfen. Für zweimal stetig differenzierbare Funktionen entscheidet die zweite Ableitung.

Satz 11.4.9 (Konvexe Funktionen von Vektoren zu Skalaren)

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine offene, konvexe Menge und $f : \mathcal{X} \rightarrow \mathbb{R}$ zweimal stetig differenzierbar, also $f \in \mathcal{C}^2$. Dann sind die folgenden Aussagen äquivalent:

1. f ist konvex.

2. Mit dem Gradienten gilt für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x}). \quad (11.4.2)$$

3. Die Hesse-Matrix $\mathbf{H}_f(\mathbf{x})$ ist positiv semidefinit für alle $\mathbf{x} \in \mathcal{X}$.

Aussage (1) ist die Sehnbedingung: Die Verbindungsstrecke zwischen zwei Punkten des Graphen verläuft nie unter dem Graphen. Aussage (2) ist die Tangentenbedingung: Die Tangentialebene im Punkt $\mathbf{x}$ verläuft nie über dem Graphen, die lineare Näherung unterschätzt f also überall. Aussage (3) ist die punktweise Krümmungsbedingung: In keiner Richtung und an keiner Stelle krümmt sich f nach unten, denn die quadratische Form $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}$ ist überall nichtnegativ. In einer Variablen wird (3) zur Bedingung $f'' \geq 0$.

Die Äquivalenz von (1) und (3) kennen wir als Satz 10.7.11 aus Abschnitt 10.7, dort ohne Beweis. Der Beweis führt über (2) als Zwischenschritt.

Vertiefung (optional): Beweis der drei Charakterisierungen

Beweis.

- (1) $(1) \Rightarrow (2)$. Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in (0, 1)$. Wir setzen $t := 1 - \lambda \in (0, 1)$ und beobachten $\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} = \mathbf{x} + t(\mathbf{y} - \mathbf{x})$. Die Konvexität liefert

$$\begin{aligned} f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) &\leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \\ \Leftrightarrow f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) - f(\mathbf{x}) &\leq t[f(\mathbf{y}) - f(\mathbf{x})] \\ \Leftrightarrow \frac{f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{t} &\leq f(\mathbf{y}) - f(\mathbf{x}). \end{aligned}$$

in der zweiten Zeile ist $\lambda = 1 - t$ eingesetzt und $f(\mathbf{x})$ auf beiden Seiten abgezogen; in der dritten wird durch $t > 0$ geteilt, das Ungleichheitszeichen bleibt also stehen. Dass der Punkt $\mathbf{x} + t(\mathbf{y} - \mathbf{x})$ überhaupt in $\mathcal{X}$ liegt, ist die Konvexität der Menge

- (2) Auf der linken Seite steht ein Differenzenquotient in Richtung $\mathbf{h} := \mathbf{y} - \mathbf{x}$. Weil f differenzierbar ist, strebt er für $t \rightarrow 0^+$ gegen die Richtungsableitung $\nabla f(\mathbf{x}) \mathbf{h}$. Die rechte Seite hängt nicht von t ab, die Ungleichung überlebt den Grenzübergang, und wir erhalten

$$\nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x}) \leq f(\mathbf{y}) - f(\mathbf{x}),$$

also (11.4.2). Der Fall $\mathbf{y} = \mathbf{x}$ war nicht mitgerechnet, dort steht in (11.4.2) aber ohnehin nur $f(\mathbf{x}) \geq f(\mathbf{x})$.

der Grenzwert eines Differenzenquotienten ist die Ableitung in Richtung $\mathbf{h}$, siehe Abschnitt 10.2; schwache Ungleichungen bleiben beim Grenzübergang erhalten, strikte nicht

- (3) $(2) \Rightarrow (1)$. Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und $\lambda \in [0, 1]$. Wir setzen $\mathbf{z} := \lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in \mathcal{X}$ und wenden (11.4.2) zweimal an, einmal mit $\mathbf{z}$ als Entwicklungspunkt und $\mathbf{x}$ als Argument, einmal mit $\mathbf{y}$:

$$\begin{aligned} \lambda f(\mathbf{x}) &\geq \lambda f(\mathbf{z}) + \lambda \nabla f(\mathbf{z})(\mathbf{x} - \mathbf{z}), \\ (1 - \lambda)f(\mathbf{y}) &\geq (1 - \lambda)f(\mathbf{z}) + (1 - \lambda)\nabla f(\mathbf{z})(\mathbf{y} - \mathbf{z}). \end{aligned}$$

Addieren wir beide Zeilen, so fällt der Gradiententerm weg:

$$\lambda(\mathbf{x} - \mathbf{z}) + (1 - \lambda)(\mathbf{y} - \mathbf{z}) = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y} - \mathbf{z} = \mathbf{0},$$

und es bleibt $\lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \geq f(\mathbf{z})$, also die Definition der Konvexität.

beide Ungleichungen werden mit den nichtnegativen Zahlen λ und $1 - \lambda$ multipliziert, das Zeichen bleibt. Der Gradient $\nabla f(\mathbf{z})$ ist in beiden Zeilen derselbe Zeilenvektor und lässt sich ausklammern, deshalb verschwindet er mit der Klammer

- (4) $(2) \Rightarrow (3)$. Sei $\mathbf{x} \in \mathcal{X}$ und $\mathbf{h} \in \mathbb{R}^n$ beliebig. Weil $\mathcal{X}$ offen ist, liegt $\mathbf{x} + t\mathbf{h}$ für alle hinreichend kleinen $t > 0$ noch in $\mathcal{X}$. Die Taylorentwicklung zweiter Ordnung aus Korollar 10.8.9 lautet

$$f(\mathbf{x} + t\mathbf{h}) = f(\mathbf{x}) + t \nabla f(\mathbf{x}) \mathbf{h} + \frac{t^2}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} + o(t^2).$$

Nach (11.4.2) mit $\mathbf{y} = \mathbf{x} + t\mathbf{h}$ ist die linke Seite mindestens $f(\mathbf{x}) + t \nabla f(\mathbf{x}) \mathbf{h}$. Umgestellt heißt das

$$\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} = \frac{2[f(\mathbf{x} + t\mathbf{h}) - f(\mathbf{x}) - t \nabla f(\mathbf{x}) \mathbf{h}]}{t^2} + o(1) \geq 0 + o(1) \rightarrow 0 \quad (t \rightarrow 0^+).$$

Die linke Seite hängt nicht von t ab, also ist sie nichtnegativ. Da $\mathbf{h}$ beliebig war, ist $\mathbf{H}_f(\mathbf{x})$ positiv semidefinit.

der Faktor 2 vor der eckigen Klammer kommt aus dem $\frac{1}{2}$ der Taylorformel; am Vorzeichen und damit an der Schlussfolgerung ändert er nichts

- (5) $(3) \Rightarrow (2)$. Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$. Weil $\mathcal{X}$ konvex ist, liegt die ganze Verbindungsstrecke in $\mathcal{X}$, und wir dürfen f darauf einschränken:

$$g(s) := f(\mathbf{x} + s(\mathbf{y} - \mathbf{x})), \quad s \in [0, 1].$$

Nach der Kettenregel aus Abschnitt 10.6 ist g zweimal stetig differenzierbar mit

$$g'(s) = \nabla f(\mathbf{x} + s(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x}), \quad g''(s) = (\mathbf{y} - \mathbf{x})^\top \mathbf{H}_f(\mathbf{x} + s(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x}).$$

g ist die Verkettung von f mit der affinen Kurve $s \mapsto \mathbf{x} + s(\mathbf{y} - \mathbf{x})$, deren Ableitung konstant $\mathbf{y} - \mathbf{x}$ ist; die zweite Ableitung ist dann die quadratische Form der Hesse-Matrix an der laufenden Stelle, vgl. Satz 10.7.6

- (6) Auf g wenden wir die eindimensionale Taylorentwicklung mit Lagrange-Restglied an (Satz 10.8.2 mit $k = 1$): Es gibt ein $t \in (0, 1)$ mit $g(1) = g(0) + g'(0) + \frac{1}{2}g''(t)$, ausgeschrieben

$$f(\mathbf{y}) = f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x}) + \frac{1}{2}(\mathbf{y} - \mathbf{x})^\top \mathbf{H}_f(\mathbf{x} + t(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x}).$$

Der letzte Summand ist nach (3) nichtnegativ, denn die Zwischenstelle $\mathbf{x} + t(\mathbf{y} - \mathbf{x})$ liegt in $\mathcal{X}$. Weglassen macht die rechte Seite also nur kleiner, und es folgt (11.4.2).

Damit sind alle Äquivalenzen gezeigt: Die Schritte 1 bis 3 zeigen $(1) \Leftrightarrow (2)$, die Schritte 4 bis 6 zeigen $(2) \Leftrightarrow (3)$.

hier geht die Konvexität von $\mathcal{X}$ ein zweites Mal ein: Ohne sie wüssten wir nicht, dass die Hesse-Matrix an der Zwischenstelle überhaupt zur Verfügung steht

□

Beide Voraussetzungen an $\mathcal{X}$ gehen in den Beweis ein. *Konvex* muss $\mathcal{X}$ sein, damit in den Schritten 1 und 5 überhaupt Punkte auf der Verbindungsstrecke zur Verfügung stehen. *Offen* muss $\mathcal{X}$ sein, damit in Schritt 4 zu jeder Richtung $\mathbf{h}$ ein Stück Weg in $\mathcal{X}$ bleibt; an einem Randpunkt gäbe es Richtungen, in denen wir sofort hinauslaufen, und die Aussage über $\mathbf{H}_f$ zöge Information aus Richtungen, die gar nicht vorkommen. Bemerkung 10.7.12 führt beide Fälle mit Gegenbeispielen vor.

Bemerkung 11.4.10 (Differenzierbarkeit und strikte Konvexität)

Zweimal stetig differenzierbar muss f sein, damit die Hesse-Matrix existiert und die Taylorformeln gelten. Für $(1) \Leftrightarrow (2)$ allein genügt einfache Differenzierbarkeit.

Die naheliegende Verschärfung gilt nur in einer Richtung. Ist $\mathbf{H}_f(\mathbf{x})$ an jeder Stelle positiv definit, so ist f strikt konvex. Die Umkehrung ist falsch: $f(x) = x^4$ ist strikt konvex, hat aber $f''(0) = 0$. Dieselbe Funktion zeigt in Bemerkung 10.7.10, dass die zweite Ableitung im semidefiniten Fall nichts entscheidet.

Beispiel 11.4.11 (Quadratische Funktionen, mit dem Kriterium nachgerechnet)

Satz 11.3.12 hat für die quadratische Funktion $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + a$ schon gezeigt: Ist der symmetrische Anteil $\mathbf{Q}_{\text{sym}} = \frac{1}{2}(\mathbf{Q} + \mathbf{Q}^\top)$ positiv semidefinit, so ist f konvex. Satz 11.4.9 liefert denselben Schluss kürzer und zusätzlich die Umkehrung, macht die Bedingung also zu einem *genau dann, wenn*. Den Gradienten der quadratischen Form kennen wir aus Abschnitt 10.2, und noch einmal ableiten gibt die Hesse-Matrix:

$$\nabla f(\mathbf{x}) = \mathbf{x}^\top (\mathbf{Q} + \mathbf{Q}^\top) + \mathbf{b}^\top, \quad \mathbf{H}_f(\mathbf{x}) = \mathbf{Q} + \mathbf{Q}^\top.$$

Die Hesse-Matrix ist konstant, und nach (3) ist f genau dann konvex, wenn $\mathbf{Q} + \mathbf{Q}^\top \succeq 0$ gilt. Für symmetrisches $\mathbf{Q}$ steht dort $2\mathbf{Q}$, und die Bedingung lautet $\mathbf{Q} \succeq 0$.

Vertiefung (optional): Zwei weitere Beispiele zum Hesse-Kriterium

Zu Beispiel 11.4.11 gehört eine Warnung. Bemerkung 11.3.14 hat eine Matrix gezeigt, die trotz fehlender Symmetrie eine strikt konvexe Funktion erzeugt. Umgekehrt kann $\mathbf{Q}$ lauter positive Eigenwerte haben, ohne dass die Funktion konvex ist. Für $\mathbf{Q} = \begin{pmatrix} 2 & 3 \\ 0 & 1 \end{pmatrix}$ stehen auf der Diagonalen der Dreiecksmatrix die Eigenwerte 2 und 1, beide positiv. Es ist aber $\mathbf{Q} + \mathbf{Q}^\top = \begin{pmatrix} 4 & 3 \\ 3 & 2 \end{pmatrix}$ mit den Eigenwerten 6,162 und **-0,162**, und die zugehörige Funktion ist nicht konvex. Zum negativen Eigenwert gehört ungefähr die Richtung $\mathbf{d} = (2; -3)^\top$, denn $\mathbf{d}^\top (\mathbf{Q} + \mathbf{Q}^\top) \mathbf{d} = 16 - 36 + 18 = \mathbf{-2}$. Mit $\mathbf{x} = (1; -1,5)^\top$, $\mathbf{y} = -\mathbf{x}$, $\mathbf{b} = \mathbf{0}$ und $a = 0$ steht im Mittelpunkt $\mathbf{0}$ der Wert $f(\mathbf{0}) = 0$ gegen den Mittelwert $\frac{1}{2}f(\mathbf{x}) + \frac{1}{2}f(\mathbf{y}) = \mathbf{-0,25}$: Die Sehne verläuft unter dem Graphen. Die Richtung muss dabei passend gewählt sein. Die ähnliche Richtung $\mathbf{d} = (1; -1)^\top$ liefert $4 - 6 + 2 = 0$ und damit Gleichheit, zeigt also nichts.

Beispiel 11.4.12 (Logistische Regression ist ein konvexes Problem)

Die negative Log-Likelihood der logistischen Regression aus Abschnitt 10.6 lautet mit $\pi_i(\boldsymbol{\beta}) = 1/(1 + e^{-\mathbf{x}_i^\top \boldsymbol{\beta}})$

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \left[\log(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}) - y_i \mathbf{x}_i^\top \boldsymbol{\beta} \right], \quad \nabla \ell(\boldsymbol{\beta}) = \sum_{i=1}^n (\pi_i(\boldsymbol{\beta}) - y_i) \mathbf{x}_i^\top.$$

Noch einmal ableiten gibt

$$\mathbf{H}_\ell(\boldsymbol{\beta}) = \sum_{i=1}^n \pi_i(\boldsymbol{\beta}) (1 - \pi_i(\boldsymbol{\beta})) \mathbf{x}_i \mathbf{x}_i^\top.$$

Jeder Summand ist positiv semidefinit, denn $\mathbf{h}^\top \mathbf{x}_i \mathbf{x}_i^\top \mathbf{h} = (\mathbf{x}_i^\top \mathbf{h})^2 \geq 0$, und der Vorfaktor $\pi_i(1 - \pi_i)$ ist wegen $\pi_i \in (0, 1)$ positiv; sein größter Wert $\frac{1}{4}$ wird bei $\pi_i = \frac{1}{2}$ angenommen, also genau dann, wenn $\mathbf{x}_i^\top \boldsymbol{\beta} = 0$ ist. Eine Summe positiv semidefiniter Matrizen ist wieder positiv semidefinit, also ist $\mathbf{H}_\ell(\boldsymbol{\beta}) \succeq 0$ an jeder Stelle, und nach Satz 11.4.9 ist ℓ konvex. Die Log-Likelihood selbst ist damit konkav, und ihre Maximierung ist ein konvexes Problem.

Ein Zahlenbeispiel mit vier Beobachtungen, $\mathbf{x}_i^\top = (1, x_i)$ und $\mathbf{x} = (0,5; -1,2; 2,0; 0,1)$: An der Stelle $\boldsymbol{\beta} = (0,3; -0,7)^\top$ ist

$$\mathbf{H}_\ell(\boldsymbol{\beta}) = \begin{pmatrix} 0,8675 & 0,3040 \\ 0,3040 & 1,0788 \end{pmatrix},$$

mit den Eigenwerten 1,2950 und 0,6513, also sogar positiv definit. Definitheit statt Semidefinitheit bekommen wir hier, weil die Regressormatrix vollen Spaltenrang hat. Bei linear abhängigen Regressoren bliebe nur Semidefinitheit, und mit ihr die Mehrdeutigkeit des Maximums.

Für die Statistik zählt diese Matrix auch jenseits der Konvexität: An der Schätzung $\hat{\boldsymbol{\beta}}$ ausgewertet ist $\mathbf{H}_\ell$ die beobachtete Fisher-Information, aus der die Standardfehler kommen, und Eigenwerte nahe null bedeuten flache Richtungen, in denen die Schätzung schlecht bestimmt ist.

Das Spektrum der Hesse-Matrix

Bemerkung 11.4.13 (Eigenwerte als Krümmungen)

Für $f \in \mathcal{C}^2$ ist $\mathbf{H}_f(\mathbf{x})$ nach dem Satz von Schwarz symmetrisch (Satz 10.7.4). Der Spektralsatz liefert deshalb reelle Eigenwerte $\lambda_1, \dots, \lambda_n$ und eine Orthonormalbasis aus Eigenvektoren $\mathbf{v}_1, \dots, \mathbf{v}_n$. Zerlegen wir einen Zuwachs $\mathbf{h}$ in dieser Basis, so wird aus der Taylorentwicklung zweiter Ordnung

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} = f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \sum_{i=1}^n \lambda_i (\mathbf{v}_i^\top \mathbf{h})^2.$$

Die letzte Gleichung ist die Spektralzerlegung $\mathbf{H}_f = \sum_i \lambda_i \mathbf{v}_i \mathbf{v}_i^\top$, eingesetzt in die quadratische Form. Sie zerlegt die Krümmung nach Richtungen:

- $\lambda_i > 0$: In Richtung $\mathbf{v}_i$ krümmt sich f nach oben, wir stehen in einem Tal.
- $\lambda_i < 0$: In Richtung $\mathbf{v}_i$ krümmt sich f nach unten, wir stehen auf einer Kuppe.
- $|\lambda_i|$ misst, wie stark die Krümmung in Richtung $\mathbf{v}_i$ ausfällt.

Nach Satz 11.4.9(3) ist f also genau dann konvex, wenn an jeder Stelle *alle* Eigenwerte nicht-negativ sind. Es gibt dann nirgends eine Richtung, in der sich die Funktion nach unten krümmt, und damit auch keine Sattelpunkte, in denen ein Verfahren steckenbleiben könnte. Den Gradiententerm dürfen wir in dieser Näherung nur an kritischen Punkten weglassen.

Stützgeraden und Subgradienten

Aussage (2) von Satz 11.4.9 besagt: Eine konvexe Funktion liegt nirgends unter ihrer Tangentialebene. Was aber, wenn es keine Tangente gibt? Der Betrag hat im Nullpunkt keine, der LASSO-Strafterm ebenfalls nicht. Die Existenz einer Stützgeraden bleibt aber erhalten, auch wenn die Ableitung fehlt.

Definition 11.4.14 (Subgradient und Subdifferential)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ konvex, $f: \mathcal{X} \rightarrow \mathbb{R}$ und $\mathbf{x} \in \mathcal{X}$. Ein Vektor $\mathbf{v} \in \mathbb{R}^n$ heißt *Subgradient* (subgradient) von f in $\mathbf{x}$, falls

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \mathbf{v}^\top (\mathbf{y} - \mathbf{x}) \quad \text{für alle } \mathbf{y} \in \mathcal{X}. \quad (11.4.3)$$

Die Menge aller Subgradienten in $\mathbf{x}$ heißt *Subdifferential* und wird $\partial f(\mathbf{x})$ geschrieben.

Ungleichung (11.4.3) ist (11.4.2) mit $\mathbf{v}^\top$ anstelle des Gradienten. Sie sagt, dass die affine Funktion $\mathbf{y} \mapsto f(\mathbf{x}) + \mathbf{v}^\top (\mathbf{y} - \mathbf{x})$ nirgends über dem Graphen von f verläuft und ihn in $\mathbf{x}$ berührt. Ist f konvex und in einem inneren Punkt $\mathbf{x}$ differenzierbar, so ist $\nabla f(\mathbf{x})^\top$ ein solcher Vektor, und dann ist er auch der einzige. Am Knick können dagegen viele auftreten: Für $f(x) = |x|$ ist $\partial f(0) = [-1, 1]$ (Beispiel 11.4.16). Weil sie keine Ableitung brauchen, sind Subgradienten das Werkzeug für konvexe, aber nicht differenzierbare Zielfunktionen wie das LASSO oder die Quantilregression.

Satz 11.4.15 (Existenz von Subgradienten im Inneren)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f: \mathcal{X} \rightarrow \mathbb{R}$ konvex. Dann gibt es zu jedem $\mathbf{x} \in \text{int}(\mathcal{X})$ einen Subgradienten, es ist also $\partial f(\mathbf{x}) \neq \emptyset$.

Vertiefung (optional): Beweis, Subdifferential des Betrags und wozu Subgradienten dienen*Beweis.*

- (1) *Der eindimensionale Fall, in der Skizze.* Schreiben wir für eine Richtung $\mathbf{h}$ und $0 < s \leq t$ mit $\mathbf{x} + t\mathbf{h} \in \mathcal{X}$ den Punkt

$$\mathbf{x} + s\mathbf{h} = \left(1 - \frac{s}{t}\right)\mathbf{x} + \frac{s}{t}(\mathbf{x} + t\mathbf{h})$$

als Konvexkombination, so liefert die Konvexität von f nach Umstellen

$$\frac{f(\mathbf{x} + s\mathbf{h}) - f(\mathbf{x})}{s} \leq \frac{f(\mathbf{x} + t\mathbf{h}) - f(\mathbf{x})}{t},$$

der Differenzenquotient wächst also monoton in der Schrittweite. In einem inneren Punkt $\mathbf{x}$ existieren deshalb beide einseitigen Ableitungen als monotone, beschränkte Grenzwerte, und es gilt $f'_-(\mathbf{x}) \leq f'_+(\mathbf{x})$. Jedes $v \in [f'_-(\mathbf{x}), f'_+(\mathbf{x})]$ erfüllt dann (11.4.3): Für $y > \mathbf{x}$ ist der Differenzenquotient mindestens $f'_+(\mathbf{x})$ und damit mindestens v , für $y < \mathbf{x}$ höchstens $f'_-(\mathbf{x})$ und damit höchstens v , und die Multiplikation mit $y - \mathbf{x}$ dreht im zweiten Fall das Ungleichheitszeichen um.

die Monotonie ist Schritt 1 im Beweis von Satz 11.4.9 ohne den Grenzübergang; eine monotone, beschränkte Folge konvergiert, und die Schranke liefert jeweils der andere einseitige Quotient. Ist f differenzierbar, fallen f'_- und f'_+ zusammen

- (2) Für $n > 1$ liefert dasselbe Argument in jeder einzelnen Richtung eine Steigung, aber noch keinen Vektor $\mathbf{v}$, der alle Richtungen gleichzeitig bedient. Den Rest liefert eine Trennungsaussage: Der Epigraph $\text{epi}(f) = \{(\mathbf{y}, r) : \mathbf{y} \in \mathcal{X}, r \geq f(\mathbf{y})\} \subseteq \mathbb{R}^{n+1}$ aus Definition 11.3.5 ist konvex, und $(\mathbf{x}, f(\mathbf{x}))$ ist ein Randpunkt. Eine stützende Hyperebene in diesem Randpunkt, also eine, die $\text{epi}(f)$ ganz auf einer Seite lässt, hat wegen $\mathbf{x} \in \text{int}(\mathcal{X})$ eine nichtverschwindende letzte Koordinate; nach Division durch diese Koordinate steht (11.4.3) da. Die Trennungsaussage selbst beweisen wir hier nicht, sie lässt sich aus dem Projektionssatz in Abschnitt 11.3 gewinnen.

dass der Epigraph konvex ist, ist Definition 11.3.6, die konvexe Funktionen genau darüber erklärt; läge $\mathbf{x}$ auf dem Rand von $\mathcal{X}$, könnte die stützende Hyperebene senkrecht stehen, und die Division wäre nicht möglich. Daran scheitert das Beispiel in Bemerkung 11.4.17

□

Beispiel 11.4.16 (Das Subdifferential des Betrags)

Sei $f(x) = |x|$ auf $\mathcal{X} = \mathbb{R}$. Für $x > 0$ ist f differenzierbar mit Ableitung 1, und $\partial f(x) = \{1\}$; für $x < 0$ entsprechend $\{-1\}$. Bleibt der Knick in $x = 0$. Dort verlangt (11.4.3)

$$|y| \geq v y \quad \text{für alle } y \in \mathbb{R},$$

und das ist für $v \in [-1, 1]$ erfüllt, sonst nicht: Für $v > 1$ scheitert $y = 1$, denn $1 < v$; für $v < -1$ scheitert $y = -1$. Also ist $\partial f(0) = [-1, 1]$, ein ganzes Intervall von Stützgeraden. Der Satz sagt nur, dass es mindestens eine gibt; eindeutig ist sie an einem Knick nicht.

Diese Mehrdeutigkeit erklärt eine Eigenschaft des LASSO. Für die eindimensionale Zielfunktion $g(\mathbf{w}) = \frac{1}{2}(\mathbf{w} - z)^2 + \lambda |\mathbf{w}|$ mit $\lambda > 0$ ist $0 \in \partial g(\mathbf{w}^*)$ die Optimalitätsbedingung, und sie führt auf die Schwellenwertregel

$$\mathbf{w}^* = \text{sign}(z) \max\{|z| - \lambda, 0\}.$$

Für $z = 2$ und $\lambda = 0,5$ steht dort 1,5, für $z = 0,3$ dagegen exakt 0. Weil das Subdifferential im Nullpunkt ein ganzes Intervall ist, kann die Bedingung dort für einen ganzen Bereich von z erfüllt sein, und das LASSO setzt Koeffizienten exakt auf null statt nur nahe an null.

Bemerkung 11.4.17 (Randpunkte, und wozu Subgradienten gut sind)

Die Voraussetzung eines inneren Punktes in Satz 11.4.15 ist nötig: Am Rand kann die Aussage scheitern. Auf $\mathcal{X} = [0, \infty)$ ist $f(x) = -\sqrt{x}$ konvex, aber im Randpunkt 0 gibt es keinen Subgradienten. Für $v \geq 0$ scheitert schon $y = 1$, denn dort verlangt (11.4.3) die falsche Aussage $-1 \geq v$. Und für $v = -c$ mit $c > 0$ nimmt $f(y) - v y = -\sqrt{y} + c y$ bei $y = 1/(4c^2)$ den Wert $-1/(4c) < 0$ an, während (11.4.3) dort ≥ 0 verlangt. Für $c = 10$ etwa ist das $-0,025$ an der Stelle $y = 0,0025$. Anschaulich wird die Funktion am Rand unendlich steil, und keine Gerade bleibt darunter. Im Inneren von $[0, \infty)$ existiert der Subgradient dagegen.

Die Existenz von Stützgeraden hat weitere Folgen. Sie liefert etwa die Jensen-Ungleichung für beliebige integrierbare Zufallsvariablen, die Satz 11.4.6 mit seinen endlich vielen Gewichten nicht erreicht: Ist $\mu = \mathbb{E}[X]$ ein innerer Punkt von $\mathcal{X}$ und $v \in \partial f(\mu)$, so gilt punktweise $f(X) \geq f(\mu) + v^\top(X - \mu)$, und Erwartungswertbildung auf beiden Seiten lässt den zweiten Summanden verschwinden. Übrig bleibt $\mathbb{E}[f(X)] \geq f(\mathbb{E}[X])$.

Algorithmisch sind Subgradienten die Grundlage der nichtdifferenzierbaren Optimierung. Wo der Gradient fehlt, tritt ein beliebiger Subgradient an seine Stelle, und Verfahren wie der Gradientenabstieg bleiben in ihrer Subgradienten-Fassung anwendbar. Die Verlustfunktion der Quantilregression, $\rho_\tau(u) = u(\tau - \mathbb{1}\{u < 0\})$, hat wie der Betrag einen Knick in $u = 0$ und stimmt für $\tau = \frac{1}{2}$ bis auf den Faktor $\frac{1}{2}$ mit ihm überein. Kapitel 12 entwickelt die Verfahren für den differenzierbaren Fall; die Subgradienten-Varianten gehören nicht mehr zum Stoff dieses Skripts.

Selbsttest

1. Sind f_1 und f_2 konvex, so ist auch die Differenz $f_1 - f_2$ konvex.

Antwort: Falsch

Satz 11.4.1(2) verlangt einen Faktor $c \geq 0$, und $-f_2$ verletzt das. Mit $f_1(x) = x^2$ und $f_2(x) = 2x^2$ ist die Differenz $-x^2$, also konkav. Je nach f_2 kann die Differenz konvex, konkav oder keines von beidem sein.

2. Das punktweise Maximum endlich vieler konvexer Funktionen ist konvex, auch wenn keine der beteiligten Funktionen differenzierbar ist.

Antwort: Wahr

Das ist Satz 11.4.1(3), und der Beweis in Beispiel 11.4.3 kommt ohne Ableitungen aus. Der Hinge-Verlust $\max\{0, 1 - u\}$ zeigt, dass dabei ein Knick entstehen darf: In $u = 1$ wechselt das Maximum von einem Stück zum anderen, und die Funktion bleibt konvex.

3. Das punktweise Minimum zweier konvexer Funktionen ist konvex.

Antwort: Falsch

Zu $f_1(x) = x^2$ und $f_2(x) = (x - 3)^2$ ist $f = \min\{f_1, f_2\}$ in $x = 0$ und $x = 3$ jeweils null, in der Mitte aber $f(1,5) = 2,25$: Der Graph liegt dort über der Sehne. Der Beweis aus Beispiel 11.4.3 scheitert an der Abschätzung nach oben, die beim Minimum in die falsche Richtung zeigt.

4. Für $N = 2$ ist die Jensen-Ungleichung die Definition einer konvexen Funktion.

Antwort: Wahr

Mit $\lambda = w_1$ und $1 - \lambda = w_2$ steht in (11.4.1) $f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$. Die Jensen-Ungleichung verallgemeinert die Definition also von zwei auf beliebig viele Punkte.

5. Eine Funktion $f \in \mathcal{C}^2$ auf einer offenen, konvexen Menge ist genau dann konvex, wenn ihre Hesse-Matrix überall positiv definit ist.

Antwort: Falsch

Satz 11.4.9(3) verlangt positive *Semidefinitheit*. Jede affine Funktion hat $\mathbf{H}_f \equiv \mathbf{0}$ und ist konvex, und $f(x) = x^4$ ist sogar strikt konvex, obwohl $f''(0) = 0$ ist. Definitheit ist hinreichend für strikte Konvexität, aber nicht notwendig (Bemerkung 11.4.10).

6. Jede konvexe Funktion besitzt in jedem Punkt ihres Definitionsbereichs einen Subgradienten.

Antwort: Falsch

Im Inneren ja (Satz 11.4.15), am Rand nicht unbedingt. Auf $[0, \infty)$ ist $-\sqrt{x}$ konvex und hat in $x = 0$ keinen Subgradienten: $v \geq 0$ scheitert schon an $y = 1$, $v = -c < 0$ an $y = 1/(4c^2)$ (Bemerkung 11.4.17).

7. Stellen wir im Jensen-Widget $f(x) = x^2$ und gleiche Gewichte ein. Wie groß ist die Differenz zwischen der grünen und der orangen Markierung?

Lösung: 1.5556

1,5556, nämlich $4,9167 - 3,3611$. Diese Lücke ist die gewichtete Varianz der drei Stützstellen 0,5, 1,5 und 3,5 um ihren Mittelwert $\frac{11}{6} = 1,8333$ (Beispiel 11.4.8). Sie verschwindet genau dann, wenn alles Gewicht auf einer Stützstelle liegt; für die konkave Wurzel wechselt sie das Vorzeichen.

Vertiefung: Boyd und Vandenberghe, *Convex Optimization*, §3.1 behandelt die Bedingungen erster und zweiter Ordnung sowie die Jensen-Ungleichung, §3.2 die Operationen, die Konvexität erhalten.

11.5 Konvexe Optimierung und Zusammenfassung

Warum konvexe Probleme leichter sind

Was bringt Konvexität für die Optimierung? Bleibt ein Verfahren stehen, weil es keine Abstiegsrichtung mehr findet, so fragt sich, ob wir das Beste gefunden haben oder nur ein Zwischenergebnis. Für allgemeine Funktionen ist die Antwort unbefriedigend: Ein verschwindender Gradient kann zu einem Minimum, einem Maximum oder einem Sattelpunkt gehören (Satz 10.7.9 in Abschnitt 10.7), und selbst ein echtes lokales Minimum kann weit über dem globalen liegen. Für konvexe Funktionen entfällt diese Unterscheidung.

Satz 11.5.1 (Kritischer Punkt und globales Minimum)

Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}$ differenzierbar und konvex, und sei $\mathbf{x}^* \in \mathbb{R}^n$. Dann sind die folgenden beiden Aussagen äquivalent:

1. $\mathbf{x}^*$ ist ein globales Minimum von f .
2. $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$.

Vertiefung (optional): Beweis: Kritische Punkte konvexer Funktionen sind global

Beweis.

- (1) $(1) \Rightarrow (2)$. Sei $\mathbf{h} \in \mathbb{R}^n$ beliebig und $\varphi(t) := f(\mathbf{x}^* + t\mathbf{h})$ für $t \in \mathbb{R}$. Nach der Kettenregel ist φ differenzierbar mit $\varphi'(0) = \nabla f(\mathbf{x}^*)\mathbf{h}$. Weil $\mathbf{x}^*$ global minimiert, gilt $\varphi(t) \geq \varphi(0)$ für alle t , und damit

$$\frac{\varphi(t) - \varphi(0)}{t} \geq 0 \quad \text{für } t > 0, \quad \frac{\varphi(t) - \varphi(0)}{t} \leq 0 \quad \text{für } t < 0.$$

Beide Differenzenquotienten streben für $t \rightarrow 0$ gegen $\varphi'(0)$. Also ist $\varphi'(0)$ zugleich nicht negativ und nicht positiv, folglich $\nabla f(\mathbf{x}^*) \mathbf{h} = 0$. Mit $\mathbf{h} = \mathbf{e}_j$ verschwindet so jeder einzelne Eintrag des Gradienten.

in diesem Schritt geht die Konvexität nirgends ein; er gilt für jede differenzierbare Funktion an einer Minimalstelle im Inneren des Definitionsbereichs und heißt notwendige Bedingung erster Ordnung

- (2) $(2) \Rightarrow (1)$. Hier trägt die Konvexität. Nach Satz 11.4.9(2), der Tangentenbedingung aus Abschnitt 11.4, gilt für jedes $\mathbf{y} \in \mathbb{R}^n$

$$f(\mathbf{y}) \geq f(\mathbf{x}^*) + \underbrace{\nabla f(\mathbf{x}^*)}_{= \mathbf{0}^T} (\mathbf{y} - \mathbf{x}^*) = f(\mathbf{x}^*).$$

Damit ist $f(\mathbf{x}^*)$ der kleinste Funktionswert überhaupt.

Satz 11.4.9 ist für $f \in \mathcal{C}^2$ formuliert; für die Äquivalenz seiner Aussagen (1) und (2) genügt nach Bemerkung 11.4.10 einfache Differenzierbarkeit, denn der zugehörige Beweisschritt rechnet nur mit Differenzenquotienten

□

Bemerkung 11.5.2 (Was daraus folgt, und was nicht)

Jeder kritische Punkt ist ein globales Minimum. Das ist die Richtung $(2) \Rightarrow (1)$ des Satzes. Die vorsichtiger Fassung „jeder kritische Punkt ist ein lokales Minimum“ bleibt unter dem, was der Satz hergibt.

Jedes lokale Minimum ist ein globales Minimum. Für differenzierbares f folgt das aus dem Satz, weil auch in einem lokalen Minimum der Gradient verschwindet. Es gilt aber für jedes konvexe f auf einer konvexen Menge, ganz ohne Ableitung, also auch für den Betrag oder den LASSO-Strafterm.

Es gibt keine Sattelpunkte, in denen ein Verfahren hängenbleiben könnte. An einem Sattelpunkt verschwindet der Gradient, und in jeder Umgebung lägen Punkte mit kleinerem Funktionswert. Nach Satz 11.5.1 ist ein solcher Punkt aber ein globales Minimum, und kleinere Werte gibt es dort nicht.

Nicht folgt: Eindeutigkeit und Existenz (Bemerkung 11.5.6). Der Merksatz „wenn wir ein konvexes Optimierungsproblem lösen, finden wir garantiert ein globales Optimum“ heißt also: Falls wir eine Lösung finden, ist sie global.

Und ohne Ableitung? Ist f konvex, so tritt an die Stelle des Gradienten das Subdifferential aus Definition 11.4.14:

$$\mathbf{x}^* \text{ ist globales Minimum} \iff \mathbf{0} \in \partial f(\mathbf{x}^*).$$

Mit $\mathbf{v} = \mathbf{0}$ lautet (11.4.3) gerade $f(\mathbf{y}) \geq f(\mathbf{x}^*)$ für alle $\mathbf{y}$; beide Richtungen stehen also schon in der Definition, auch an Randpunkten. Dass $\partial f(\mathbf{x}^*)$ in inneren Punkten nicht leer ist, sichert Satz 11.4.15. Beim Betrag liegt $\mathbf{0}$ in $\partial f(\mathbf{0}) = [-1, 1]$, und beim LASSO führt das Kriterium auf eine Schwellenwertregel, die Koeffizienten exakt auf null setzt (Beispiel 11.4.16).

Vertiefung (optional): Lokal ist global, auch ohne Ableitung

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ konvex, $f: \mathcal{X} \rightarrow \mathbb{R}$ konvex und $\mathbf{x}^*$ ein lokales Minimum. Gäbe es ein $\mathbf{y} \in \mathcal{X}$ mit $f(\mathbf{y}) < f(\mathbf{x}^*)$, so läge für jedes $\lambda \in (0, 1]$ der Punkt $\mathbf{z}_\lambda = (1 - \lambda)\mathbf{x}^* + \lambda\mathbf{y}$ in $\mathcal{X}$, und die Konvexitätsungleichung (11.3.4) gäbe

$$f(\mathbf{z}_\lambda) \leq (1 - \lambda)f(\mathbf{x}^*) + \lambda f(\mathbf{y}) < f(\mathbf{x}^*).$$

Für hinreichend kleines λ liegt $\mathbf{z}_\lambda$ aber in jeder vorgegebenen Umgebung von $\mathbf{x}^*$, im Widerspruch zur lokalen Minimalität.

Ist die Minimalstelle nicht eindeutig, so bilden die Minimalstellen eine konvexe Menge; deshalb ist in der Statistik von der *Lösungsmenge* eines konvexen Problems die Rede.

Satz 11.5.3 (Die Minimalstellen bilden eine konvexe Menge)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f : \mathcal{X} \rightarrow \mathbb{R}$ konvex. Dann ist

$$\arg \min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) := \{\mathbf{x} \in \mathcal{X} : f(\mathbf{x}) \leq f(\mathbf{y}) \text{ für alle } \mathbf{y} \in \mathcal{X}\}$$

eine konvexe Teilmenge von $\mathcal{X}$.

Vertiefung (optional): Beweis: Die Minimalstellen bilden eine konvexe Menge

Beweis.

- (1) Ist die Menge leer oder einelementig, so ist sie konvex und wir sind fertig. Seien also $\mathbf{u}$ und $\mathbf{w}$ zwei Minimalstellen. Beide tragen denselben Wert: Aus der Minimalität von $\mathbf{u}$ folgt $f(\mathbf{u}) \leq f(\mathbf{w})$, aus der von $\mathbf{w}$ folgt $f(\mathbf{w}) \leq f(\mathbf{u})$. Wir setzen $m := f(\mathbf{u}) = f(\mathbf{w})$.

die leere Menge und einelementige Mengen sind konvex, weil die Bedingung aus Definition 11.2.1 dort nichts fordert oder trivial erfüllt ist

- (2) Sei $\lambda \in [0, 1]$ und $\mathbf{z} = \lambda \mathbf{u} + (1 - \lambda) \mathbf{w}$. Weil $\mathcal{X}$ konvex ist, liegt $\mathbf{z}$ in $\mathcal{X}$, und die Konvexität von f gibt

$$f(\mathbf{z}) \leq \lambda f(\mathbf{u}) + (1 - \lambda) f(\mathbf{w}) = m.$$

Andererseits ist m der kleinste Wert von f auf $\mathcal{X}$, also $f(\mathbf{z}) \geq m$. Damit ist $f(\mathbf{z}) = m$, und $\mathbf{z}$ ist selbst eine Minimalstelle.

hier werden beide Konvexitäten gebraucht: die der Menge, damit $\mathbf{z}$ überhaupt zulässig ist, und die der Funktion für die Abschätzung nach oben

□

Dieselbe Rechnung zeigt mehr, als der Satz behauptet. Für jedes $c \in \mathbb{R}$ ist die *Subniveaumenge* $\{\mathbf{x} \in \mathcal{X} : f(\mathbf{x}) \leq c\}$ konvex, denn aus $f(\mathbf{u}) \leq c$ und $f(\mathbf{w}) \leq c$ folgt $f(\mathbf{z}) \leq \lambda c + (1 - \lambda)c = c$. Die Minimalstellen sind davon der Sonderfall $c = \min f$, sofern dieses Minimum angenommen wird. Konvexe Funktionen haben also konvexe *Subniveaumengen*, und daran hängt in Abschnitt 12.5 die Beschreibung zulässiger Bereiche. Für exakte Niveaumengen $\{\mathbf{x} : f(\mathbf{x}) = c\}$ gilt das nicht: Das Niveau 1 von $f(x) = x^2$ besteht aus $\{-1, 1\}$ und ist nicht konvex.

Strikte Konvexität und Eindeutigkeit

Eindeutigkeit liefert Satz 11.5.1 nicht, weil die Konvexitätsungleichung Gleichheit erlaubt; geometrisch heißt das, dass der Graph auf einem Stück gerade verläuft. Schließen wir das aus, so folgt die Eindeutigkeit.

Definition 11.5.4 (Strikte Konvexität)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f : \mathcal{X} \rightarrow \mathbb{R}$. Wir nennen f *strikt konvex* (strictly convex), falls für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ mit $\mathbf{x} \neq \mathbf{y}$ und alle $\lambda \in (0, 1)$ gilt

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) < \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \quad (11.5.1)$$

Gegenüber der Sehnenungleichung (11.3.4) wird aus $\leq$ ein $<$; dafür müssen $\mathbf{x} \neq \mathbf{y}$ und $\lambda \in (0, 1)$

sein, sonst stünde links und rechts derselbe Wert. Informell kam der Begriff schon in Bemerkung 11.3.9 vor.

Satz 11.5.5 (Höchstens eine Minimalstelle)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f : \mathcal{X} \rightarrow \mathbb{R}$ strikt konvex. Dann besitzt f höchstens eine Minimalstelle.

Vertiefung (optional): Beweis der Eindeutigkeit bei strikter Konvexität

Beweis.

- (1) Angenommen, es gäbe zwei verschiedene Minimalstellen $\mathbf{x}_1 \neq \mathbf{x}_2$. Wie in Schritt 1 des Beweises zu Satz 11.5.3 tragen beide denselben Wert $m := f(\mathbf{x}_1) = f(\mathbf{x}_2)$.

jede der beiden Stellen ist minimal, also höchstens so groß wie die andere

- (2) Wir betrachten den Mittelpunkt $\mathbf{z} = \frac{1}{2}\mathbf{x}_1 + \frac{1}{2}\mathbf{x}_2$. Er liegt in $\mathcal{X}$, weil $\mathcal{X}$ konvex ist, und Definition 11.5.4 mit $\lambda = \frac{1}{2}$ liefert

$$f(\mathbf{z}) < \frac{1}{2}f(\mathbf{x}_1) + \frac{1}{2}f(\mathbf{x}_2) = m.$$

Damit gäbe es einen zulässigen Punkt mit einem kleineren Wert als dem Minimum, ein Widerspruch. Also kann es keine zwei verschiedenen Minimalstellen geben.

hier wird jede Zutat von Definition 11.5.4 gebraucht: $\mathbf{x}_1 \neq \mathbf{x}_2$ und $\frac{1}{2} \in (0, 1)$ machen die strikte Ungleichung anwendbar, und die Konvexität von $\mathcal{X}$ sichert die Zulässigkeit des Mittelpunkts

□

Der Beweis benutzt nur ein einziges λ , nämlich $\frac{1}{2}$. Dasselbe Argument lässt sich auch aus Satz 11.5.3 ablesen: Die Minimalstellen bilden eine konvexe Menge; enthielte sie zwei verschiedene Punkte, so enthielte sie die ganze Strecke dazwischen, und auf deren Innerem ist f nach (11.5.1) echt kleiner als an den Endpunkten. Eine konvexe Funktion, die auf einer Strecke konstant ist, kann also nicht strikt konvex sein.

Bemerkung 11.5.6 (Drei Aussagen, die auseinanderzuhalten sind)

Drei Aussagen werden leicht verwechselt:

1. *Lokal ist global.* Das leistet schon gewöhnliche Konvexität, ohne jede Differenzierbarkeit (Satz 11.5.1, Bemerkung 11.5.2).
2. *Höchstens eine Lösung.* Dafür braucht es strikte Konvexität (Satz 11.5.5).
3. *Mindestens eine Lösung.* Das folgt aus keinem von beiden.

Zu Punkt 3: $f(x) = e^x$ ist auf $\mathbb{R}$ strikt konvex, denn $f''(x) = e^x > 0$, hat aber kein Minimum. Die Existenz sichern andere Argumente, etwa eine kompakte zulässige Menge und Stetigkeit (Satz von Weierstraß, so auch im Beweis von Satz 11.3.1) oder Koerzivität, also $f(\mathbf{x}) \rightarrow \infty$ für $\|\mathbf{x}\| \rightarrow \infty$; dann genügt es, auf einer hinreichend großen abgeschlossenen Kugel zu minimieren.

Strikte Konvexität und Existenz zusammen geben *genau eine* Lösung, etwa beim Kleinste-Quadrat-Verlust mit vollem Spaltenrang der Designmatrix oder bei der Ridge-Regression mit $\lambda > 0$ (Beispiel 11.3.16).

Vertiefung (optional): Perfekt trennbare Daten in der logistischen Regression

Punkt 3 von Bemerkung 11.5.6 hat ein statistisches Beispiel. Bei perfekt trennbaren Daten bleibt die

negative Log-Likelihood der logistischen Regression strikt konvex, angenommen wird ihr Infimum aber nicht: Die Koeffizienten laufen ins Unendliche, während der Wert gegen 0 fällt. Schon mit den beiden Beobachtungen $(x, y) = (1, 1)$ und $(x, y) = (-1, 0)$ und dem Modell $\pi(\beta) = 1/(1 + e^{-\beta x})$ ist $\ell(\beta) = \log(1 + e^\beta) - \beta + \log(1 + e^{-\beta})$, und dieser Wert fällt von 1,386 bei $\beta = 0$ auf $9,1 \cdot 10^{-5}$ bei $\beta = 10$, bleibt aber für jedes endliche β positiv. Ein Ridge-Strafterm repariert hier nicht die Eindeutigkeit, die schon da ist, sondern die Existenz: Der Zusatz $\lambda\beta^2$ ist koerziv, und für $\lambda = 0,2$ liegt das Minimum bei $\beta = 1,18$.

Optimierungslandschaften

Die drei Fälle konvex, strikt konvex und nicht konvex lassen sich in einer Variablen nebeneinander zeichnen.

Interaktiv: Drei Landschaften nebeneinander

Welcher der drei Fälle vorliegt, zeigt die Menge der Minimalstellen.

Interaktives Element — nur in der Web-Fassung

Die Tafel „strikt konvex“ ist der Fall von Satz 11.5.5: eine einzige Minimalstelle, die angenommen wird, weil die Parabel koerziv ist. Die Tafel „konvex, aber nicht strikt“ hat ein flaches Stück, auf dem in (11.5.1) Gleichheit steht; ihre Minimalstellen bilden das Intervall von $-0,8$ bis $0,8$, eine konvexe Menge wie in Satz 11.5.3. In der Tafel „nicht konvex“ gilt die Theorie dieses Abschnitts nicht mehr: Zwei kritische Punkte tragen positive Krümmung, nur einer von beiden ist global.

Vertiefung (optional): Ein Abstiegsverfahren auf der Doppelmulde

Als Vorgriff auf Kapitel 12 lassen wir den Gradientenabstieg aus Abschnitt 10.2 auf der Doppelmulde der Tafel „nicht konvex“ laufen. Er geht wiederholt ein Stück in Richtung des stärksten Abstiegs.

Interaktiv: Ein Abstieg auf der Doppelmulde

Der Startwert lässt sich Schritt für Schritt verschieben; die Tafel zeigt jedes Mal die ausgewählten Zwischenstationen und den Punkt, an dem die Folge zur Ruhe kommt. Wo verläuft die Grenze zwischen den beiden Einzugsgebieten?

Interaktives Element — nur in der Web-Fassung

Der Höcker zwischen den beiden Tälern trennt die Einzugsbereiche. Am Endpunkt ist der Unterschied nicht abzulesen: In beiden Tälern verschwindet die Ableitung bei positiver Krümmung, und jedes Abbruchkriterium meldet Erfolg. Wer ein nicht-konvexes Problem rechnet, muss deshalb mehrere Startwerte durchprobieren; bei einer konvexen Zielfunktion erübrigt sich das, denn nach Satz 11.5.1 ist jeder Punkt mit verschwindendem Gradienten schon das Ziel.

1. Im Abstiegs-Widget oben landet ein Lauf, der bei $x_0 = -0,16$ startet, im tiefen Tal rechts.

Antwort: Wahr

Er landet dort, obwohl er weit links vom tiefen Tal beginnt. Die Grenze ist der Höcker bei $-0,1699$, und $-0,16$ liegt knapp rechts davon; der negative Gradient zeigt dort nach rechts, und die Folge läuft den Hang hinab bis $1,30084$. Ein Start bei $-0,17$ endet dagegen bei $-1,13090$. Ein Reglerschritt von $0,01$ entscheidet also zwischen zwei Endpunkten, deren Funktionswerte um $2,44$ auseinander-

liegen.

Konvexe und nicht-konvexe Probleme in Statistik und maschinellem Lernen

Die folgende Übersicht sortiert gängige Verfahren in dieselben drei Fälle wie die Landschaften und sagt damit voraus, ob ein Startwert das Ergebnis beeinflussen kann.

Bemerkung 11.5.7 (Eine Übersicht der Optimierungsprobleme)

Strikt konvexe Probleme haben höchstens eine Lösung (Satz 11.5.5), und wo sie existiert, ist sie global. Jeder korrekt konvergierte Lauf liefert dieselbe Lösung, auch wenn Rechenweg, Laufzeit und Abbruchstatus vom Startwert abhängen.

- Kleinste Quadrate, $\min_{\beta} \|y - X\beta\|_2^2$, sofern X vollen *Spaltenrang* hat; nur dann ist $X^T X$ positiv definit (Beispiel 11.3.16).
- Allgemeiner die Maximum-Likelihood-Schätzung in verallgemeinerten linearen Modellen mit kanonischem Link: Die negative Log-Likelihood hat die Hesse-Matrix $X^T W X$ mit einer nichtnegativen Diagonalmatrix W , ist also stets konvex und bei vollem Spaltenrang und positiven Gewichten strikt konvex (Beispiel 11.4.12). Bei nicht-kanonischem Link ist Konvexität nicht mehr automatisch; im Probit-Modell besteht sie trotzdem, weil die Verteilungsfunktion der Normalverteilung log-konkav ist.
- Support Vector Machines: Die Zielfunktion $\frac{1}{2} \|w\|_2^2 + C \sum_i \max\{0, 1 - y_i(w^T x_i + b)\}$ ist konvex (Satz 11.4.1) und in w strikt konvex, der Trennvektor w ist also mit dem Argument von Satz 11.5.5 eindeutig. Der Achsenabschnitt b geht nur über den stückweise linearen Hinge-Verlust ein und kann mehrdeutig bleiben.
- Ridge-Regression, $\min_{\beta} \|y - X\beta\|_2^2 + \lambda \|\beta\|_2^2$, für jedes $\lambda > 0$ und jedes X (Beispiel 11.3.16), ebenso das *Elastic Net* mit positivem Ridge-Anteil.
- Graphisches LASSO, die regularisierte Schätzung einer Präzisionsmatrix: Optimiert wird über die positiv definiten Matrizen, eine konvexe Menge (Bemerkung 11.2.9), und der Term $-\log \det$ ist darauf strikt konvex.

Konvexe, aber nicht strikt konvexe Probleme haben nach Satz 11.5.3 eine konvexe Lösungsmenge, die mehr als einen Punkt enthalten darf. Jede gefundene Lösung ist global, aber verschiedene Implementierungen dürfen verschiedene Koeffizienten melden.

- Kleinste Quadrate ohne vollen Spaltenrang: Die Zielfunktion ist entlang eines Kernvektors von X konstant (Beispiel 11.3.16).
- Das LASSO, $\min_{\beta} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$: Der Strafterm ist stückweise linear und damit nicht strikt konvex; bei rangdefizienter Designmatrix, dem Regelfall für $p > n$, überträgt sich das auf die Zielfunktion.
- Quantilregression: Die Verlustfunktion $\rho_{\tau}(u) = u(\tau - \mathbb{1}\{u < 0\})$ besteht aus zwei Geradenstücken und ist auf keinem Intervall strikt konvex; optimiert wird mit Subgradienten oder als lineares Programm.

Nicht-konvexe Probleme können mehrere lokale Minima und Sattelpunkte haben. Verschiedene Startwerte können dann in verschiedene Einzugsgebiete führen, und ein stationäres Ergebnis ist nicht notwendig global optimal.

- Neuronale Netze: Schon das Vertauschen zweier Neuronen einer Schicht liefert andere Parameter mit demselben Verlust; das Problem ist nicht einmal identifizierbar.

- Clusteranalyse mit k -means oder Mischverteilungsmodellen, die in der Praxis mehrfach neu gestartet werden.
- Bäume und darauf aufbauende Verfahren (CART, Random Forests, XGBoost): Der Suchraum ist nicht kontinuierlich, optimiert wird gierig Schnitt für Schnitt.
- Modelle mit latenten Variablen: gemischte Modelle, Strukturgleichungsmodelle, Faktorenanalyse.
- Variablenselektion mit L_0 -Strafe, *Best Subset*, *Spike and Slab*: Das Zählen der Nicht-Null-Koeffizienten ist nicht konvex, das Problem ist kombinatorisch.
- Dimensionsreduktion und Einbettungen: tSNE, UMAP, word2vec.
- Matrixvervollständigung und Tensorzerlegungen, etwa nichtnegative Matrixfaktorisierung oder dünn besetzte Hauptkomponenten: Die Zielfunktion aus Abschnitt 10.4 ist in U und in V jeweils konvex, in beiden zusammen aber nicht.

Die Wahl von Hyperparametern gehört nur mit Vorbehalt in diese Liste: Die Zielfunktion, meist ein Kreuzvalidierungsfehler, ist oft nicht einmal stetig. Deshalb kommen dort Gittersuche, Zufallssuche und Bayessche Optimierung statt Abstiegsverfahren zum Einsatz.

Das Wichtigste in Kürze

Abschnitt	Thema	Was bleibt
11.1	Konvexkombinationen	Gewichte $w_i \geq 0$ mit $\sum_i w_i = 1$; zwei Punkte spannen eine Strecke auf, endlich viele die konvexe Hülle $\text{conv}(\mathcal{X})$
11.2	Konvexe Mengen	Mit je zwei Punkten die ganze Strecke; stabil unter Durchschnitt, kartesischem Produkt, affinen Abbildungen und Summe; der Kegel $\{\mathbf{A} = \mathbf{A}^\top : \mathbf{A} \succeq 0\}$ als Beispiel
11.3	Konvexe Funktionen	Konvexer Epigraph, gleichbedeutend mit $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y})$; die Projektion auf eine nichtleere abgeschlossene konvexe Menge existiert und ist eindeutig
11.4	Eigenschaften	Regeln für Summe, nichtnegatives Vielfaches, Supremum und Grenzwert; Jensen; für $f \in \mathcal{C}^2$ auf offenem, konvexem Bereich ist Konvexität gleichbedeutend mit $\mathbf{H}_f(\mathbf{x}) \succeq 0$ überall; Subgradienten im Knick
11.5	Konvexe Optimierung	Für differenzierbares konvexes f bedeutet $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ globales Minimum; lokal ist global, keine Sattelpunkte; konvexe Lösungsmenge; strikt konvex bedeutet höchstens eine Lösung, Existenz ist eine eigene Frage

Nächstes Kapitel

Wir wissen jetzt, wann ein lokaler Befund ein globaler ist. Wie wir überhaupt zu einem Minimum kommen, mit Abstiegs- und Newton-Verfahren und unter Nebenbedingungen, zeigt Kapitel 12.

Selbsttest

1. Die konvexe Hülle der Einheitssphäre $\{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_2 = 1\}$ ist wieder die Einheitssphäre.

Antwort: Falsch

Sie ist die abgeschlossene Einheitskugel. Der Mittelpunkt von $\mathbf{e}_1$ und $\mathbf{e}_2$ liegt in der Hülle, hat aber die Norm $1/\sqrt{2} = 0,7071$. Umgekehrt liegt jeder Kugelpunkt auf einer Sehne zwischen zwei Sphärenpunkten, etwa $\mathbf{x} = (0,3; -0,2)^\top$ zwischen $(\pm 0,9798; -0,2)^\top$ mit den Gewichten 0,6531 und 0,3469. Die Hülle ist nach Satz 11.2.12 konvex, die Sphäre selbst nicht.

2. Ist $f : \mathbb{R}^n \rightarrow \mathbb{R}$ differenzierbar und konvex und hat f mehrere kritische Punkte, so haben sie alle denselben Funktionswert.

Antwort: Wahr

Nach Satz 11.5.1 ist jeder kritische Punkt ein globales Minimum, und globale Minima tragen alle den kleinsten Wert. Die Tafel „konvex, aber nicht strikt“ zeigt das: Auf dem Plateau von $-0,8$ bis $0,8$ verschwindet die Ableitung überall, und überall steht der Wert 0. Nach Satz 11.5.3 bilden diese Stellen sogar eine konvexe Menge, hier ein Intervall.

3. Jede strikt konvexe Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}$ besitzt genau ein globales Minimum.

Antwort: Falsch

Sie besitzt *höchstens* eines (Satz 11.5.5). Die Existenz ist eine unabhängige Frage: $f(x) = e^x$ ist wegen $f''(x) = e^x > 0$ strikt konvex, nähert sich ihrem Infimum 0 aber nur an. Gesichert wird die Existenz erst durch Kompaktheit oder Koerzivität (Bemerkung 11.5.6).

4. Ist f_1 konvex und f_2 strikt konvex, so ist $f_1 + f_2$ strikt konvex.

Antwort: Wahr

Wir addieren die beiden Ungleichungen (11.3.4) und (11.5.1) für $\mathbf{x} \neq \mathbf{y}$ und $\lambda \in (0, 1)$: Links steht $\leq$, rechts $<$, in der Summe also $<$. Darauf beruht die Ridge-Regression: Der Kleinste-Quadrate-Term ist stets konvex, der Strafterm $\lambda \|\boldsymbol{\beta}\|_2^2$ für $\lambda > 0$ strikt konvex, die Summe also strikt konvex (Beispiel 11.3.16). Ohne den strikten Summanden gilt das nicht: $|x|$ und $\max\{0, x\}$ sind beide konvex, ihre Summe stimmt auf $(-\infty, 0]$ aber mit $|x| = -x$ überein und verläuft dort geradlinig.

5. Aus der Jensen-Ungleichung folgt für eine Zufallsvariable X mit endlichem Träger sowohl $\mathbb{E}[X]^2 \leq \mathbb{E}[X^2]$ als auch $\mathbb{E}[\sqrt{X}] \leq \sqrt{\mathbb{E}[X]}$, sofern $X \geq 0$ ist.

Antwort: Wahr

Beides ist derselbe Satz 11.4.6, einmal mit der konvexen Funktion $x \mapsto x^2$ und einmal mit der konkaven Wurzel, bei der sich das Ungleichheitszeichen umdreht (Bemerkung 11.4.7). Die erste Ungleichung ist die Rechnung aus Beispiel 11.4.8; beim fairen Würfel liegt $\mathbb{E}[\sqrt{X}] = 1,8053$ unter $\sqrt{3,5} = 1,8708$.

6. Die quadratische Funktion $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x}$ ist genau dann konvex, wenn $\mathbf{Q}$ positiv semidefinit ist.

Antwort: Falsch

Die quadratische Form sieht von $\mathbf{Q}$ nur den symmetrischen Anteil $(\mathbf{Q} + \mathbf{Q}^\top)/2$, und nach Satz 11.3.12 entscheidet allein dieser. Für $\mathbf{Q} = \begin{pmatrix} 1 & 5 \\ -5 & 1 \end{pmatrix}$ ist $\mathbf{x}^\top \mathbf{Q} \mathbf{x} = x_1^2 + x_2^2$ sogar strikt konvex, obwohl $\mathbf{Q}$ nicht symmetrisch ist und damit gar nicht positiv semidefinit heißen kann (Bemerkung 11.3.14).

7. Erfüllen zwei verschiedene Koeffizientenvektoren eines LASSO-Problems beide die Subgradienten-Optimalitätsbedingung, so sind beide global optimal.

Antwort: Wahr

Die LASSO-Zielfunktion ist als Summe zweier konvexer Funktionen konvex (Satz 11.4.1), also ist jeder Punkt mit $\mathbf{0}$ im Subdifferential global optimal (Bemerkung 11.5.2). Bei rangdefizienter

Designmatrix ist sie nicht strikt konvex, und die Lösungsmenge kann mehrere Punkte enthalten; nach Satz 11.5.3 liegt dann die ganze Verbindungsstrecke der beiden Lösungen darin, mit demselben Zielwert.

Vertiefung: Boyd und Vandenberghe, Convex Optimization, behandeln in Kapitel 4 die konvexen Optimierungsprobleme selbst, darunter die Aussage, dass jedes lokale Minimum global ist, und das Optimalitätskriterium für differenzierbare Zielfunktionen. Das Buch ist frei verfügbar.

11.6 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 6.2	Konvex, strikt konvex oder nicht konvex?	leicht, ca. 15 Min.
Heath Exercise 6.12	Lokale Minima konvexer Funktionen sind global	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 7.3	Schnitt, Vereinigung und Differenz konvexer Mengen	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 7.4	Welche Operationen erhalten Konvexität?	leicht, ca. 30 Min.

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deisenroth et al. (MML): *Mathematics for Machine Learning*.

Nichtlineare Gleichungen & Optimierung

12.1 Nichtlineare Gleichungen

Was wir mitbringen

Aus Abschnitt 10.2 kommt der Gradient $\nabla f(\mathbf{x})$ einer Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}$. Wo er nicht verschwindet, zeigt sein Transponiertes in die Richtung des steilsten Anstiegs (Satz 10.2.4); der Gradient ist in diesem Skript ein Zeilenvektor, eine Richtung im $\mathbb{R}^n$ eine Spalte. Aus Abschnitt 10.7 kommt die Hesse-Matrix $\mathbf{H}_f(\mathbf{x})$ der zweiten Ableitungen, die die Krümmung misst. Aus Kapitel 11 kommt die Konvexität von Mengen und Funktionen; sie entscheidet später, ob ein gefundenes Minimum auch das globale ist.

Dazu zwei Bausteine aus der Grundvorlesung. *Notwendig* für ein Extremum einer differenzierbaren Funktion in einem inneren Punkt des Definitionsbereichs ist $f'(\mathbf{x}^*) = 0$ beziehungsweise $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$. *Hinreichend* für ein Minimum ist das zusammen mit $f''(\mathbf{x}^*) > 0$, im Mehrdimensionalen mit einer positiv definiten Hesse-Matrix.

Der Farbcode dieses Kapitels: blau die Iterierten $\mathbf{x}^{(k)}$ und die Wege, die sie zurücklegen, grün das Ziel $\mathbf{x}^*$, orange die Ableitungsobjekte und die aus ihnen gebauten Schritte, rot die Nebenbedingungen und die Warnzeichen für Divergenz.

Drei Sorten von Problemen

Das Kapitel behandelt drei eng verwandte Aufgaben.

Definition 12.1.1 (Nichtlineares Gleichungssystem)

Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$. Ein *nichtlineares Gleichungssystem* ist die Aufgabe, ein $\mathbf{x}^* \in \mathbb{R}^n$ zu finden mit

$$f(\mathbf{x}^*) = \mathbf{0}.$$

Für $n = m = 1$ sprechen wir von einer *Nullstelle* (root) von f .

Der Zusatz „nichtlinear“ grenzt gegen Kapitel 5 ab: Ist f affin, also $f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$, so ist das ein lineares Gleichungssystem, und dafür haben wir fertige Zerlegungen. Für nichtlineares f gibt es im Allgemeinen kein Verfahren, das die Lösung in endlich vielen Schritten liefert.

Definition 12.1.2 (Unbeschränktes und beschränktes Optimierungsproblem)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Ein *unbeschränktes Optimierungsproblem* (unconstrained optimization) ist die Aufgabe

$$\mathbf{x}^* \in \arg \min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{beziehungsweise} \quad \mathbf{x}^* \in \arg \max_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}).$$

Ein *beschränktes Optimierungsproblem* (constrained optimization) schränkt die Suche auf eine Menge $S \subseteq \mathbb{R}^n$ ein,

$$\mathbf{x}^* \in \arg \min_{\mathbf{x} \in S} f(\mathbf{x}),$$

wobei die *Nebenbedingungen* typischerweise selbst durch Funktionen beschrieben werden:

$$S = \{\mathbf{x} \in \mathbb{R}^n : g_i(\mathbf{x}) = 0, i = 1, \dots, m\} \quad \text{oder} \quad S = \{\mathbf{x} \in \mathbb{R}^n : h_j(\mathbf{x}) \leq 0, j = 1, \dots, p\}$$

oder eine Kombination aus beidem. Die Funktion f heißt Zielfunktion.

„Beschränkt“ bedeutet hier *mit Nebenbedingungen* und nicht, dass S eine beschränkte Menge sein muss. Eindeutiger ist deshalb auch die Bezeichnung *Optimierung mit Nebenbedingungen*.

Bemerkung 12.1.3 (Zwei Probleme, dieselben Verfahren)

Maximieren und Minimieren sind dieselbe Aufgabe, denn $\arg \max_{\mathbf{x}} f(\mathbf{x}) = \arg \min_{\mathbf{x}} (-f(\mathbf{x}))$. Wir reden deshalb ab jetzt nur noch über Minima.

Ist f differenzierbar, so muss im Minimum eines *unbeschränkten* Problems $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ gelten. Das ist ein nichtlineares Gleichungssystem für die Funktion $\mathbf{x} \mapsto \nabla f(\mathbf{x})^\top$ von $\mathbb{R}^n$ nach $\mathbb{R}^n$; mit Nebenbedingungen tritt eine andere Bedingung an seine Stelle (Abschnitt 12.5). Jedes Verfahren zur Nullstellensuche taugt damit auch zur Suche kritischer Punkte, und deshalb steht die Nullstellensuche am Anfang.

Alle drei Probleme lösen wir *iterativ*: Wir starten irgendwo und bauen eine Folge $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots$, die hoffentlich gegen $\mathbf{x}^*$ läuft. Dieselbe Bauform kennen wir schon von der Potenzmethode (Abschnitt 8.1) und den Korrekturiterationen für lineare Gleichungssysteme (Abschnitt 8.3).

Warum Optimierung?**Beispiel 12.1.4 (Optimierungsprobleme in Statistik und maschinellem Lernen)**

Ein großer Teil beider Fächer besteht daraus, ein Minimum zu suchen.

Maximum-Likelihood-Schätzung. Für unabhängige, identisch verteilte Beobachtungen $y_1, \dots, y_n$ mit Dichte $f_Y(y | \theta)$ ist der ML-Schätzer

$$\hat{\theta}_{\text{ML}} = \arg \max_{\theta} \sum_{i=1}^n \log f_Y(y_i | \theta).$$

Nur in Lehrbuchfällen wie der Normalverteilung lässt sich das nach θ auflösen; sonst bleibt die Iteration.

Überwachtes Lernen. Mit einer Verlustfunktion $L(y, \hat{y})$ und Vorhersagen $\hat{y}_i := p_{\theta}(\mathbf{x}_i)$ aus Merkmalen $\mathbf{x}_i$ lautet die Aufgabe

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n L(y_i, p_{\theta}(\mathbf{x}_i)).$$

Für die lineare Regression mit quadratischem Verlust ist das $\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$, und dieses Problem konnten wir in Kapitel 7 noch geschlossen lösen. Steht bei p_{θ} dagegen ein neuronales Netz, so ist θ hochdimensional, die Zielfunktion nicht konvex, und es bleibt nur die Iteration.

Regularisierte Regression. Ridge und Lasso hängen einen Strafterm an:

$$\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_p^p, \quad p = 2 \text{ (Ridge)}, \quad p = 1 \text{ (Lasso)}.$$

Dieselbe Aufgabe lässt sich als beschränktes Problem schreiben,

$$\arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{so dass} \quad \|\beta\|_p \leq c,$$

und daran lässt sich die Geometrie ablesen: Liegt der KQ-Schätzer außerhalb der p -Norm-Kugel vom Radius c , so ist die Lösung der Punkt, an dem eine um ihn wachsende Niveaumenge des Kleinsten-Quadrat-Verlusts die Kugel zuerst berührt. Bei $p = 1$ ist das oft eine Ecke auf einer Achse; deshalb setzt Lasso Koeffizienten exakt auf null (Abschnitt 12.5). Zu jeder penalisierten Lösung gehört ein Budget c , das dieselbe Lösung liefert, umgekehrt aber nur, solange die Nebenbedingung bindet (Beispiel 12.5.10). Im Strafterm steht die p -te Potenz der Norm; für $p = 2$ ist das $\lambda \|\beta\|_2^2$, die Form mit der geschlossenen Lösung $\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}_p)^{-1} \mathbf{X}^T \mathbf{y}$ aus Beispiel 10.6.6. In der Nebenbedingung spielt die Potenz keine Rolle, weil $\|\beta\|_2 \leq c$ und $\|\beta\|_2^2 \leq c^2$ dieselbe Menge beschreiben.

Wann hat $f(x) = 0$ überhaupt eine Lösung?

Sei $f : [a, b] \rightarrow \mathbb{R}$. Welche Aussagen über die Lösungen von $f(x) = 0$ stimmen?

1. Ist f stetig, so hat $f(x) = 0$ genau eine Lösung.

Antwort: Falsch

Stetigkeit allein liefert weder Existenz noch Eindeutigkeit. Die konstante Funktion $f \equiv 1$ ist stetig und hat gar keine Nullstelle, die konstante Funktion $f \equiv 0$ ist stetig und hat lauter Nullstellen. Stetigkeit hilft erst in Verbindung mit einem Vorzeichenwechsel.

2. Gilt $f(a) < 0$ und $f(b) > 0$, so hat $f(x) = 0$ mindestens eine Lösung.

Antwort: Falsch

Das wäre der Zwischenwertsatz, aber der verlangt Stetigkeit, und die steht in der Voraussetzung nicht. Ein Gegenbeispiel ist die Sprungfunktion auf $[-1, 1]$ mit $f(x) = -1$ für $x < 0$ und $f(x) = 1$ für $x \geq 0$: Die Vorzeichen an den Rändern wechseln, eine Nullstelle gibt es nicht.

3. Ist f streng monoton, so hat $f(x) = 0$ höchstens eine Lösung.

Antwort: Wahr

Streng monotone Funktionen sind injektiv: Aus $x_1 < x_2$ folgt $f(x_1) \neq f(x_2)$. Der Wert 0 wird also höchstens einmal angenommen. Für die Existenz sagt das nichts, dafür brauchen wir Stetigkeit und einen Vorzeichenwechsel.

Satz 12.1.5 (Existenz und Eindeutigkeit einer Nullstelle)

Sei $f : [a, b] \rightarrow \mathbb{R}$ streng monoton und stetig mit $f(a) \cdot f(b) \leq 0$. Dann hat die Gleichung $f(x) = 0$ genau eine Lösung $x^* \in [a, b]$.

Beweis.

- (1) *Höchstens eine Lösung.* Sind $x_1 < x_2$ zwei Punkte aus $[a, b]$, so ist $f(x_1) \neq f(x_2)$, weil f streng monoton ist. Der Wert 0 kann also höchstens an einer Stelle angenommen werden.

strenge Monotonie heißt: $x_1 < x_2$ erzwingt $f(x_1) < f(x_2)$ (steigend) oder $f(x_1) > f(x_2)$ (fallend), in beiden Fällen ungleiche Werte

- (2) *Der Randfall.* Ist $f(a) \cdot f(b) = 0$, so ist $f(a) = 0$ oder $f(b) = 0$, und wir sind bereits fertig: Die Nullstelle liegt am Rand.

ein Produkt reeller Zahlen ist genau dann null, wenn einer der Faktoren null ist

- (3) *Der Hauptfall.* Sei nun $f(a) \cdot f(b) < 0$, die beiden Randwerte haben also verschiedene Vorzeichen. Ohne Beschränkung der Allgemeinheit nehmen wir $f(a) < 0 < f(b)$ an.

im anderen Fall betrachten wir $-f$; diese Funktion ist ebenfalls stetig und streng monoton und hat dieselben Nullstellen

- (4) *Existenz.* Weil f stetig ist, liefert der Zwischenwertsatz zu jedem Wert zwischen $f(a)$ und $f(b)$ eine Urbildstelle, insbesondere zum Wert 0. Es gibt also ein $x^* \in (a, b)$ mit $f(x^*) = 0$. Zusammen mit Schritt 1 ist diese Lösung eindeutig.

der Zwischenwertsatz gilt für stetige Funktionen auf einem Intervall; ohne Stetigkeit ist er falsch, wie die Sprungfunktion aus dem Quiz zeigt

□

Bemerkung 12.1.6 (Hinreichend, aber nicht notwendig)

Der Satz gibt eine Garantie, keine Charakterisierung. Die Funktion $f(x) = x^2 - 1$ auf $[-2, 2]$ ist weder monoton noch wechselt sie das Vorzeichen zwischen den Rändern, und trotzdem hat sie dort zwei Nullstellen. Die Bedingungen des Satzes sind also *hinreichend*, aber nicht *notwendig*.

Für die Verfahren zählt vor allem die Existenzhälfte: Stetigkeit und ein Vorzeichenwechsel garantieren eine Nullstelle; Monotonie braucht nur, wer Eindeutigkeit will.

Das Bisektionsverfahren

Die Idee des Bisektionsverfahrens: Wir kennen ein Intervall, in dem eine Nullstelle stecken muss, weil f an den Rändern das Vorzeichen wechselt. Wir halbieren es, prüfen, in welcher Hälfte der Vorzeichenwechsel liegt, und verwerfen die andere.

Algorithmus 12.1.7 (Bisektionsverfahren)

Gegeben seien eine stetige Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$, zwei Punkte $a < b$ mit $f(a) \cdot f(b) < 0$ und eine Zielgenauigkeit $\epsilon > 0$. Solange $b - a > \epsilon$:

1. Setze $m = a + (b - a)/2$.
2. Haben $f(a)$ und $f(m)$ dasselbe Vorzeichen, so setze $a \leftarrow m$, andernfalls $b \leftarrow m$.

Als Näherung geben wir die Mitte $a + (b - a)/2$ des Endintervalls zurück.

Das ϵ ist hier die gewünschte Genauigkeit, nicht die Maschinengenauigkeit aus Kapitel 4. Wie viele Schritte kostet das?

Satz 12.1.8 (Schrittzahl der Bisektion)

Es gelten die Voraussetzungen von Algorithmus 12.1.7, und das Startintervall sei noch zu grob, $b - a > \epsilon$. Dann hat das Intervall nach k Durchläufen die Länge $(b - a)/2^k$, und es enthält weiterhin eine Nullstelle von f . Die Schleife bricht nach genau

$$k = \left\lceil \log_2 \left(\frac{b - a}{\epsilon} \right) \right\rceil$$

Durchläufen ab, und die zurückgegebene Intervallmitte $\hat{x}$ erfüllt $|x^* - \hat{x}| \leq \epsilon/2$.

Vertiefung (optional): Beweis der Schrittzahlformel

Beweis.

- (1) *Der Vorzeichenwechsel überlebt.* Schreiben wir $[a_k, b_k]$ für das Intervall nach k Durchläufen. Haben $f(a_{k-1})$ und $f(m)$ dasselbe Vorzeichen, so hat $f(m)$ das andere Vorzeichen als $f(b_{k-1})$, und der Wechsel sitzt in $[m, b_{k-1}]$; diese Hälfte behalten wir. Andernfalls sitzt er in $[a_{k-1}, m]$, und wir behalten diese. In beiden Fällen gilt weiter $f(a_k) \cdot f(b_k) \leq 0$.

das leistet die Fallunterscheidung des Algorithmus. Gleichheit tritt nur bei $f(m) = 0$ ein; dann wird $b \leftarrow m$ gesetzt, und die Nullstelle sitzt auf dem rechten Rand

- (2) *Es gibt immer noch eine Nullstelle.* Auf $[a_k, b_k]$ ist f stetig, und die Randwerte haben verschiedene Vorzeichen oder einer von ihnen ist null. Im ersten Fall liefert der Zwischenwertsatz eine Nullstelle x^* im Inneren, im zweiten liegt sie auf dem Rand. Monotonie brauchen wir dafür nicht; nur für die Eindeutigkeit wäre sie nötig.

das sind die Schritte 2 und 4 des Beweises von Satz 12.1.5, angewandt auf das kleinere Intervall

- (3) *Die Länge halbiert sich.* Der Mittelpunkt teilt das Intervall in zwei gleich lange Hälften, also ist $b_k - a_k = (b_{k-1} - a_{k-1})/2$ und per Induktion $b_k - a_k = (b - a)/2^k$.

Induktionsanfang $k = 0$ ist das Startintervall selbst

- (4) *Die Abbruchbedingung.* Die Schleife läuft, solange $b_k - a_k > \epsilon$ ist. Sie endet also beim kleinsten k mit

$$\frac{b - a}{2^k} \leq \epsilon \iff 2^k \geq \frac{b - a}{\epsilon} \iff k \geq \log_2 \left(\frac{b - a}{\epsilon} \right),$$

und die kleinste solche ganze Zahl ist die aufgerundete rechte Seite.

$\log_2$ ist streng monoton wachsend

- (5) *Die Fehlerschranke.* Die Nullstelle x^* liegt nach Schritt 2 im Endintervall, und von dessen Mitte $\hat{x}$ ist jeder Punkt des Intervalls höchstens eine halbe Intervalllänge entfernt. Also ist

$$|x^* - \hat{x}| \leq \frac{b_k - a_k}{2} \leq \frac{\epsilon}{2}.$$

ein Randpunkt des Endintervalls hätte nur die Schranke ϵ

□

Ein Beispiel, das im Rest des Abschnitts wiederkehrt: $f(x) = x^2 - 2$ auf $[1, 2]$, also die Suche nach $\sqrt{2}$. Für $\epsilon = 10^{-6}$ ist $\log_2(10^6) = 19,93$, aufgerundet ergibt das die Schrittzahl. Pro Schritt gewinnt

die Bisektion genau ein Bit, also $\log_{10} 2 \approx 0,301$ Dezimalstellen; eine weitere gültige Stelle kostet rund 3,3 Schritte. Das Verfahren ist zuverlässig und langsam.

Bemerkung 12.1.9 (Die Bisektion in sieben Zeilen)

Kompakt geschrieben ist das Verfahren sieben Zeilen lang:

```
bisect <- function(f, a, b, eps) {
  while (b - a > eps) {
    mid <- (a + b) / 2
    if (f(a) * f(mid) <= 0) b <- mid else a <- mid
  }
  return((a + b) / 2)
}
```

Die letzte Zeile ist wesentlich. Gäbe sie den *letzten Mittelpunkt* zurück, so wäre das nach der Zuweisung stets ein Randpunkt des Endintervalls: Statt der garantierten Genauigkeit $\epsilon/2$ aus Satz 12.1.8 bliebe nur ϵ , ein voller Halbierungsschritt wäre verschenkt.

Vertiefung (optional): Fließkomma-Fallen der Bisektion

Zwei Details dieser Fassung betreffen die Fließkommaarithmetik aus Kapitel 4. Das erste betrifft den Mittelpunkt. Haben a und b dasselbe Vorzeichen, so ist $a + (b - a)/2$ die verlässlichere Formel: Die Differenz $b - a$ ist dann betragsmäßig höchstens so groß wie der größere der beiden Endpunkte, ihre Hälfte erst recht, und der Ausdruck bleibt auch gerundet zwischen a und b . Die Summe $a + b$ dagegen ist ein Zwischenergebnis, das größer sein kann als beide Endpunkte, und sie kann überlaufen, obwohl die Mitte selbst darstellbar wäre. Das zweite betrifft den Vorzeichentest. Nahe der Nullstelle sind $f(a)$ und $f(m)$ beide winzig; ihr Produkt unterläuft dann auf null, und der Produkttest kann einen echten Vorzeichenwechsel nicht mehr von einem Unterlauf unterscheiden. Vergleichen wir stattdessen die Vorzeichen, so stehen im Produkt nur noch ± 1 , und dort kann nichts mehr unterlaufen. So sieht die robuste Fassung aus:

```
bisect <- function(f, a, b, eps) {
  fa <- f(a); fb <- f(b)
  stopifnot(is.finite(fa), is.finite(fb), sign(fa) * sign(fb) < 0)
  while (b - a > eps) {
    mid <- a + (b - a) / 2          # bleibt auch gerundet in [a, b]
    fmid <- f(mid)
    if (fmid == 0) return(mid)      # exakt getroffen
    if (sign(fa) * sign(fmid) < 0) {
      b <- mid
    } else {
      a <- mid; fa <- fmid          # f(a) nur neu auswerten, wenn a sich bewegt
    }
  }
  a + (b - a) / 2                  # Mitte des Endintervalls
}
```

Der Aufruf `stopifnot` macht aus einer stillschweigenden Voraussetzung eine geprüfte, und das Zwischenspeichern von `fa` halbiert die Zahl der Funktionsauswertungen. Bei einer Zielfunktion, deren Auswertung eine Minute dauert, ist das relevant.

Bemerkung 12.1.10 (Umkehrfunktionen, Binärsuche und die Grenze des Verfahrens)

Umkehrfunktionen auswerten. Suchen wir $f^{-1}(y)$, so lösen wir $f(x) - y = 0$. So berechnen viele Programmbibliotheken Quantile ohne geschlossene Formel: Für eine stetige, streng wachsende Verteilungsfunktion F ist das p -Quantil die Lösung von $F(x) - p = 0$, und Satz 12.1.5

ist direkt anwendbar.

Verwandtschaft zur Binärsuche. Wie die binäre Suche in einer sortierten Liste halbiert die Bisektion in jedem Schritt den Suchbereich, mit demselben logarithmischen Aufwand (Abschnitt 2.3); der Vorzeichenwechsel ersetzt den Größenvergleich.

Die Grenze. Beide Verfahren brauchen die Anordnung von $\mathbb{R}$. Im $\mathbb{R}^n$ ist ein „Vorzeichenwechsel“ eines vektorwertigen f nicht definiert; die Bisektion eignet sich deshalb nur für univariate Funktionen.

Die Schrittzahl lässt sich im folgenden Kasten nachzählen.

Interaktiv: Halbieren, Schritt für Schritt

Voreingestellt ist $f(x) = x^2 - 2$ auf $[1, 2]$, also die Suche nach $\sqrt{2}$; die Tabelle daneben protokolliert den Intervall-Verlauf. Der zweite Menüpunkt wechselt zu $f(x) = x^3 - 3x + 1$ auf $[-2, 2]$, wo die Voraussetzung von Satz 12.1.5 verletzt ist.

Schätzfrage. Wie viele Halbierungen braucht die Bisektion auf $[1, 2]$, bis das Intervall kürzer ist als $\epsilon = 10^{-6}$?

Lösung: 20 Schritte

Satz 12.1.8 sagt $\lceil \log_2((b-a)/\epsilon) \rceil = 20$ voraus, und zwar exakt. Dieselbe Formel liefert 10 Schritte für $\epsilon = 10^{-3}$ und 34 für 10^{-10} , also $1/\log_{10} 2 = 3,32$ Schritte je gültiger Dezimalstelle. Die Schranke aus Satz 12.1.8 ist für jedes ϵ exakt; der Stepper stellt am Ende die vorhergesagte Schrittzahl neben die gebrauchte. Beim zweiten Menüpunkt mit drei Nullstellen in $[-2, 2]$ entscheidet schon der erste Mittelpunkt, welche wir finden: Weil $f(0) = 1$ dasselbe Vorzeichen trägt wie $f(2) = 3$, fällt die rechte Hälfte samt zwei Nullstellen sofort weg. Eindeutig ist die Lösung hier nicht, weil die strenge Monotonie aus Satz 12.1.5 fehlt.

Das Newton-Raphson-Verfahren

Die Bisektion benutzt von f nur das Vorzeichen. Ist f differenzierbar, bleibt damit Information ungenutzt: Die Ableitung sagt uns nicht nur, auf welcher Seite die Nullstelle liegt, sondern auch ungefähr wie weit.

Der Ansatz ist die Taylorentwicklung erster Ordnung aus Abschnitt 10.8. Um die aktuelle Stelle $x^{(k)}$ herum ersetzen wir f durch seine Tangente und verlangen von dieser, dass sie null wird:

$$f(x) \approx f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) \stackrel{!}{=} 0.$$

Das ist eine lineare Gleichung in x . Solange $f'(x^{(k)}) \neq 0$ ist, liefert Auflösen die nächste Iterierte.

Algorithmus 12.1.11 (Newton-Raphson-Verfahren für Nullstellen)

Gegeben seien eine differenzierbare Funktion $f: \mathbb{R} \rightarrow \mathbb{R}$ und ein Startwert $x^{(0)}$. Für $k = 0, 1, 2, \dots$ setze

$$x^{(k+1)} = x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}, \quad (12.1.1)$$

solange $f'(x^{(k)}) \neq 0$ ist, und brich ab, sobald $|f(x^{(k)})|$ oder die Schrittlänge $|x^{(k+1)} - x^{(k)}|$ unter eine vorgegebene Schranke fällt.

Geometrisch ist $x^{(k+1)}$ der Schnittpunkt der Tangente an f im Punkt $(x^{(k)}, f(x^{(k)}))$ mit der x -Achse. Der Bruch in (12.1.1) sagt dasselbe in Zahlen: Wir teilen die Höhe, die abzubauen ist, durch die Rate, mit der die Tangente sie abbaut.

Vertiefung (optional): Newton-Raphson einmal vollständig durchgerechnet

Beispiel 12.1.12 (Die Wurzel aus zwei)

Wir bleiben bei $f(x) = x^2 - 2$ mit $f'(x) = 2x$ und $x^* = \sqrt{2} = 1,41421356$. Die Vorschrift (12.1.1) wird zu

$$x^{(k+1)} = x^{(k)} - \frac{(x^{(k)})^2 - 2}{2x^{(k)}} = \frac{1}{2} \left(x^{(k)} + \frac{2}{x^{(k)}} \right),$$

also dem Heron-Verfahren. Vom Startwert $x^{(0)} = 2$ aus laufen die Iterierten so:

k	$x^{(k)}$	$e_k := x^{(k)} - x^* $	e_k/e_{k-1}^2
0	2,000000000000	$5,86 \cdot 10^{-1}$	-
1	1,500000000000	$8,58 \cdot 10^{-2}$	0,250
2	1,416666666667	$2,45 \cdot 10^{-3}$	0,333
3	1,414215686275	$2,12 \cdot 10^{-6}$	0,353
4	1,414213562375	$1,59 \cdot 10^{-12}$	0,354

Die letzte Spalte pendelt sich bei $1/(2x^*) = 0,3536$ ein. Die Zahl der gültigen Dezimalstellen läuft dabei über 0,2, 1,1, 2,6, 5,7 und 11,8: Sie verdoppelt sich in jedem Schritt grob. Zum Vergleich brauchte die Bisektion auf demselben Intervall 20 Schritte für sechs Stellen.

Bemerkung 12.1.13 (Quadratische Konvergenz)

Nahe einer einfachen Nullstelle konvergiert Newton-Raphson *quadratisch* (Konvergenzordnung): Mit $e_k := |x^{(k)} - x^*|$ verhält sich der Fehler des nächsten Schrittes wie das Quadrat des aktuellen,

$$e_{k+1} \approx C \cdot e_k^2,$$

mit einer Konstanten C , die von f abhängt. Ist f in einer Umgebung einer einfachen Nullstelle zweimal stetig differenzierbar, so ist asymptotisch $C = |f''(x^*)|/(2|f'(x^*)|)$, für $f(x) = x^2 - 2$ also $2/(2 \cdot 2\sqrt{2}) = 0,354$. Praktisch heißt das: Sobald wir nah genug dran sind, verdoppelt jeder Schritt grob die Zahl der richtigen Stellen, und wenige Schritte genügen bis zur Maschinengenauigkeit.

Das Verfahren braucht allerdings die Ableitung, und es konvergiert nur *lokal*: Weit weg vom Ziel kann die Tangente irgendwohin zeigen, und die Iteration kann divergieren. Außerdem muss die Nullstelle einfach sein. Ist $f'(x^*) = 0$, so fällt die Konvergenz auf lineare Geschwindigkeit, und ein $f'(x^{(k)}) = 0$ unterwegs macht den Schritt undefiniert. Die Bisektion hat keinen dieser Vorbehalte, braucht aber ein Vielfaches an Schritten; in der Praxis kombinieren wir beides: erst klammern, dann Newton.

Wie stark wirken sich diese Vorbehalte aus, wenn die Tangente flach liegt?

Interaktiv: Die Tangente als Wegweiser

Die Tafel zeigt Algorithmus 12.1.11 Schritt für Schritt: violett der Graph von f , orange die Tangente im aktuellen Punkt, und wo sie die x -Achse trifft, sitzt die nächste blaue Iterierte.

Der Startpunkt lässt sich auf der Achse ziehen oder mit dem Regler setzen; die gestrichelten roten Senkrechten im zweiten Beispiel markieren die Stellen mit $f' = 0$.

Schätzfrage. Die dritte Funktion, $f(x) = \arctan x$, hat genau EINE Nullstelle. Findet Newton sie von jedem Startpunkt aus?

Lösung: *nein*

Die Schwelle liegt bei $|x^{(0)}| = 1,3917$: Ab dort überholt jeder Schritt den vorigen, und die Iterierten laufen über $1,5 \rightarrow -1,694 \rightarrow 2,321 \rightarrow -5,114 \rightarrow 32,30 \rightarrow -1575,3$ auseinander.

Auf $f(x) = x^2 - 2$ pendelt sich der Quotient e_{k+1}/e_k^2 aus der Voreinstellung $x^{(0)} = 3$ bei 0,3536 ein. Auf $f(x) = x^3 - 3x + 1$ entscheidet der Startpunkt, welche der drei Nullstellen wir finden; bei $x^{(0)} = 1,05$ ist $f' = 0,31$, der erste Schritt springt nach 4,28, und der Lauf braucht doppelt so viele Schritte wie aus einem günstigen Startpunkt. Der Arkustangens hat genau eine Nullstelle, doch jenseits einer Schwelle für $|x^{(0)}|$ überholt jeder Schritt den vorigen, und die Iterierten laufen auseinander. Die Bisektion wäre hier langsam, aber sie divergiert nicht.

Bemerkung 12.1.14 (Von der Nullstelle zum Minimum)

Suchen wir das Minimum einer differenzierbaren Funktion f , so suchen wir eine Nullstelle von ∇f (Bemerkung 12.1.3). Wenden wir (12.1.1) auf diese Funktion an, so steht im Nenner die Ableitung des Gradienten, die Hesse-Matrix:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \left(\nabla f(\mathbf{x}^{(k)}) \mathbf{H}_f(\mathbf{x}^{(k)})^{-1} \right)^\top.$$

Das ist Algorithmus 10.8.11 aus Abschnitt 10.8: Newton für $\min_{\mathbf{x}} f(\mathbf{x})$ ist Newton-Raphson für $\nabla f(\mathbf{x}) = \mathbf{0}^\top$. Das Transponierte steht da, weil der Gradient in unserer Konvention eine Zeile ist.

Für $f: \mathbb{R}^n \rightarrow \mathbb{R}$ tritt in (12.1.1) an die Stelle der Division die Lösung des linearen Systems $\mathbf{J}_f(\mathbf{x}^{(k)}) \mathbf{d} = -f(\mathbf{x}^{(k)})$ mit der Jacobimatrix aus Abschnitt 10.3; die nächste Iterierte ist dann $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}$. Das ist teuer: pro Schritt eine ganze Matrix von Ableitungen und eine Zerlegung.

Vertiefung (optional): Fixpunktiteration erster Ordnung

Die einfachste Alternative ersetzt die Ableitung durch eine feste Zahl. Das Ergebnis nimmt den Gradientenabstieg aus Abschnitt 12.3 in seiner einfachsten Form vorweg.

Algorithmus 12.1.15 (Fixpunktiteration erster Ordnung)

Gegeben seien $f: \mathbb{R}^n \rightarrow \mathbb{R}$, ein Startpunkt $\mathbf{x}^{(0)}$ und eine Schrittweite $\gamma > 0$. Für $k = 1, 2, \dots$ setze

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} - \gamma f(\mathbf{x}^{(k-1)}). \quad (12.1.2)$$

Der Name kommt daher, dass (12.1.2) eine Fixpunktiteration $\mathbf{x} \mapsto g(\mathbf{x})$ für $g(\mathbf{x}) := \mathbf{x} - \gamma f(\mathbf{x})$ ist: Wegen $\gamma \neq 0$ gilt $g(\mathbf{x}^*) = \mathbf{x}^*$ genau dann, wenn $f(\mathbf{x}^*) = \mathbf{0}$ ist. Fixpunkte von g und Nullstellen von f sind dasselbe.

Für affines $f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ ist (12.1.2) das Richardson-Verfahren aus Abschnitt 8.3, und die dortige Konvergenzbedingung ist der Spezialfall des folgenden Satzes.

Satz 12.1.16 (Konvergenzrate der Fixpunktiteration)

Sei $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ in einer Umgebung von $\mathbf{x}^*$ differenzierbar mit $f(\mathbf{x}^*) = \mathbf{0}$, und sei

$$\rho := \|\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)\| < 1 \quad (12.1.3)$$

für eine induzierte Matrixnorm. Dann gibt es zu jedem $\rho' \in (\rho, 1)$ ein $\delta > 0$, sodass für jeden Startpunkt mit $\|\mathbf{x}^{(0)} - \mathbf{x}^*\| \leq \delta$ die Iteration (12.1.2) gegen $\mathbf{x}^*$ konvergiert, und zwar mit

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| \leq (\rho')^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\| = O((\rho')^k).$$

Ist f affin, so gilt die Schranke mit ρ selbst und für jeden Startpunkt.

Beweis.

- (1) *Fehlerrekursion und Kontraktion.* Schreiben wir $\mathbf{e}_k := \mathbf{x}^{(k)} - \mathbf{x}^*$. Weil f in $\mathbf{x}^*$ differenzierbar ist und dort verschwindet, ist $f(\mathbf{x}^{(k-1)}) = \mathbf{J}_f(\mathbf{x}^*) \mathbf{e}_{k-1} + r(\mathbf{e}_{k-1})$ mit $\|r(\mathbf{h})\| = o(\|\mathbf{h}\|)$. Einsetzen in (12.1.2) und Abziehen von $\mathbf{x}^*$ auf beiden Seiten liefert

$$\mathbf{e}_k = (\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)) \mathbf{e}_{k-1} - \gamma r(\mathbf{e}_{k-1}), \quad \text{also} \quad \|\mathbf{e}_k\| \leq \rho \|\mathbf{e}_{k-1}\| + \gamma \|r(\mathbf{e}_{k-1})\|.$$

Sei nun $\rho' \in (\rho, 1)$ beliebig. Weil $\|r(\mathbf{h})\| / \|\mathbf{h}\| \rightarrow 0$ für $\mathbf{h} \rightarrow \mathbf{0}$ gilt, gibt es ein $\delta > 0$ mit $\gamma \|r(\mathbf{h})\| \leq (\rho' - \rho) \|\mathbf{h}\|$ für alle $\|\mathbf{h}\| \leq \delta$, und für $\|\mathbf{e}_{k-1}\| \leq \delta$ folgt daraus $\|\mathbf{e}_k\| \leq \rho' \|\mathbf{e}_{k-1}\|$.

die Zerlegung von f ist Definition 10.1.5, die Fréchet-Differenzierbarkeit: Funktionswert gleich lineare Näherung plus Restterm, der schneller als linear verschwindet. Die Abschätzung benutzt danach die Dreiecksungleichung und die Verträglichkeit der induzierten Norm, $\|\mathbf{M}\mathbf{v}\| \leq \|\mathbf{M}\| \|\mathbf{v}\|$ (Satz 3.5.10). Hier wird die Aussage lokal: Sie gilt nur in einer Kugel um $\mathbf{x}^*$, deren Radius von ρ' abhängt

- (2) *Induktion.* Ist $\|\mathbf{e}_0\| \leq \delta$, so ist $\|\mathbf{e}_1\| \leq \rho' \|\mathbf{e}_0\| \leq \delta$, und dasselbe Argument greift erneut. Per Induktion bleibt die ganze Folge in der Kugel und es gilt $\|\mathbf{e}_k\| \leq (\rho')^k \|\mathbf{e}_0\|$. Wegen $\rho' < 1$ konvergiert die rechte Seite gegen null.

$\rho' < 1$ sorgt dafür, dass die Kugel nie verlassen wird; ohne diese Beobachtung wäre die Induktion nicht abgeschlossen

- (3) *Der affine Fall.* Ist $f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$, so ist $\mathbf{J}_f = \mathbf{A}$ konstant und $r \equiv \mathbf{0}$. Die Abschätzung aus Schritt 1 gibt dann direkt $\|\mathbf{e}_k\| \leq \rho \|\mathbf{e}_{k-1}\|$, ohne Einschränkung an den Startpunkt.

eine affine Abbildung ist ihre eigene lineare Näherung, der Restterm entfällt

□

Kurzgefasst lautet das Ergebnis $\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = O(\rho^k)$. Die Kurzform unterschlägt zwei Vorbehalte: Die Aussage gilt nur in der Nähe von $\mathbf{x}^*$, und der Restterm verschlechtert die Rate im nichtaffinen Fall um ein beliebig kleines Stück.

Damit überhaupt ein $\gamma > 0$ mit $\rho < 1$ existiert, muss die Ableitung im Zielpunkt positiv sein: Im Eindimensionalen ist $\rho = |1 - \gamma f'(x^*)| < 1$ genau für $0 < \gamma < 2/f'(x^*)$, und das setzt $f'(x^*) > 0$ voraus. Ist f dort fallend, arbeiten wir mit $-f$, das dieselben Nullstellen hat. Deshalb wird f für die Fixpunktiteration oft gleich als monoton steigend vorausgesetzt.

Bemerkung 12.1.17 (Das Dilemma der Schrittweite)

Die Vor- und Nachteile des Verfahrens hängen an einer einzigen Zahl. Positiv: Es ist einfach, funktioniert für multivariates f und braucht keine Jacobimatrix, sondern nur Funktionsauswertungen; bei gutartigem f , also kleinem ρ , ist es zudem schnell. Negativ: Die Schrittweite γ muss passen.

Zu klein heißt langsam. Mit ρ nahe bei 1 schrumpft der Fehler pro Schritt kaum, und wir brauchen $\log(10)/(-\log \rho)$ Schritte je Dezimalstelle. Zu groß heißt, dass der Schritt über die Nullstelle hinausschießt und dabei größer wird als der Fehler, den er beheben sollte. Dann ist $\rho \geq 1$, und Satz 12.1.16 sagt nichts mehr zu.

Wie eng das Fenster ist, lässt sich im symmetrisch positiv definiten Fall exakt angeben. Hat $J_f(\mathbf{x}^*)$ die Eigenwerte $0 < \lambda_{\min} \leq \dots \leq \lambda_{\max}$, so ist

$$\gamma^* = \frac{2}{\lambda_{\min} + \lambda_{\max}} \quad \text{mit} \quad \rho = \frac{\lambda_{\max} - \lambda_{\min}}{\lambda_{\max} + \lambda_{\min}} = \frac{\kappa - 1}{\kappa + 1}$$

die beste Wahl, mit der Konditionszahl $\kappa = \lambda_{\max}/\lambda_{\min}$. Für $\gamma > 2/\lambda_{\max}$ läuft die Iteration von jedem Startpunkt aus auseinander, dessen Fehler einen Anteil in der steilsten Eigenrichtung hat. Die Herleitung ist dieselbe wie für den Gradientenabstieg in Satz 12.3.15, mit der Jacobi- an Stelle der Hesse-Matrix.

In der Praxis wählen wir γ_k adaptiv, etwa durch eine Liniensuche (Abschnitt 12.3); die akzeptierten Schrittweiten müssen dabei nicht gegen null gehen. Folgen mit $\gamma_k \rightarrow 0$ spielen erst beim stochastischen Gradientenabstieg eine Rolle (Abschnitt 12.4).

Ab welcher Schrittweite divergiert die Iteration? Drei kleine Systeme zeigen es.

Interaktiv: Die Schrittweite als Regler

Alle drei Beispiele sind affin, $f(\mathbf{x}) = \mathbf{A}(\mathbf{x} - \mathbf{x}^*)$ mit $\mathbf{x}^* = \mathbf{0}$. Damit ist die Jacobimatrix überall $\mathbf{A}$, und $\rho = \|\mathbf{I} - \gamma \mathbf{A}\|_2$ ist nach dem affinen Fall im Beweis eine echte Schranke ohne Restterm.

Schätzfrage. Das dritte System hat $\mathbf{A} = \text{diag}(1, 10)$, also Kondition 10. Ab welchem γ divergiert es?

Lösung: 0,2 γ

Die Grenze liegt bei $2/\lambda_{\max} = 0,2$, das beste erreichbare ρ bei $9/11 = 0,818$.

Beim ersten, symmetrischen System liegt das Optimum bei $\gamma^* = 2/7$ mit $\rho = 0,319$. Beim zweiten sind die Eigenwerte komplex, der Weg wird zur Spirale, und den Drehanteil regelt keine Schrittweite weg: Selbst im Optimum bleibt $\rho = 2/\sqrt{5} = 0,894$. Beim dritten ist bei $\gamma = 0,25$ schon $\rho = 1,5$, die Iteration divergiert (Bemerkung 12.1.17). Unterhalb der Schwelle, die die Ablesetafel nach dem Auflösen nennt, läuft sie im Zickzack zusammen: Die steile Richtung überschießt, die flache kommt kaum voran, dasselbe Bild wie beim Gradientenabstieg in Abschnitt 12.3.

1. Für $f(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ ist die Fixpunktiteration (12.1.2) das Richardson-Verfahren aus Abschnitt 8.3.

Antwort: Wahr

Einsetzen gibt $\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} - \gamma(\mathbf{A}\mathbf{x}^{(k-1)} - \mathbf{b})$. Die dortige Konvergenzbedingung $\|\mathbf{I} - \gamma \mathbf{A}\| < 1$ ist (12.1.3), und weil f affin ist, gilt die Schranke nach Satz 12.1.16 für jeden Startpunkt.

2. Ist $\rho = \|\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)\| < 1$, so konvergiert die Fixpunktiteration von jedem Startpunkt aus gegen $\mathbf{x}^*$.

Antwort: Falsch

Satz 12.1.16 ist eine *lokale* Aussage: Die Schranke gilt nur in einer Kugel um $\mathbf{x}^*$, deren Radius wir nicht kennen. Weiter draußen kann die Iteration zu einer anderen Nullstelle laufen oder divergieren.

3. Verdoppeln wir im symmetrisch positiv definiten Fall die optimale Schrittweite, so ist die Konvergenzgarantie verloren.

Antwort: Wahr

Die optimale Wahl ist $\gamma^* = 2/(\lambda_{\min} + \lambda_{\max})$, divergiert wird ab $2/\lambda_{\max}$. Wegen $4/(\lambda_{\min} + \lambda_{\max}) \geq 2/\lambda_{\max}$ liegt das Doppelte immer auf oder jenseits der Grenze, mit Gleichheit nur für $\lambda_{\min} = \lambda_{\max}$.

Für die Optimierung fragt Abschnitt 12.2 zuerst, was ein Minimum überhaupt auszeichnet.

Selbsttest

1. Das Bisektionsverfahren braucht die Ableitung von f .

Antwort: Falsch

Es braucht nur Funktionswerte, genauer sogar nur deren Vorzeichen, und einen Startbereich mit Vorzeichenwechsel. Das ist seine Stärke: Es funktioniert für nicht differenzierbare oder nur numerisch auswertbare Funktionen, und es kann nach Satz 12.1.8 nicht divergieren.

2. Eine zusätzliche gültige Dezimalstelle kostet die Bisektion rund 3,3 Schritte.

Antwort: Wahr

Jeder Schritt halbiert die Intervalllänge, gewinnt also genau ein Bit oder $\log_{10} 2 \approx 0,301$ Dezimalstellen. Für eine ganze Stelle brauchen wir $1/\log_{10} 2 = 3,32$ Schritte. Nach Satz 12.1.8 sind das für $[1, 2]$ und $\epsilon = 10^{-6}$ zusammen 20 Durchläufe.

3. Ab welchem $|x^{(0)}|$ läuft Newton auf $f(x) = \arctan x$ auseinander?

Lösung: 1.39

Die Schwelle liegt bei 1,3917; sie löst $\arctan(\xi)(1 + \xi^2) = 2\xi$. Darunter zieht sich das Pendeln zusammen, darüber wächst es. Dass es eine solche Schwelle gibt, obwohl die Funktion nur eine einzige Nullstelle hat, zeigt den Vorbehalt aus Bemerkung 12.1.13: Quadratische Konvergenz ist eine *lokale* Aussage, und wie groß die Umgebung ist, sagt sie nicht.

4. Das Newton-Raphson-Verfahren konvergiert quadratisch, gleichgültig, wo wir starten und welche Nullstelle wir suchen.

Antwort: Falsch

Beides gilt nicht. Quadratisch wird es erst in der Nähe der Nullstelle, und nur wenn diese einfach ist, also $f'(x^*) \neq 0$ gilt. Bei einer mehrfachen Nullstelle sinkt die Ordnung auf 1, und weit weg vom Ziel kann die Tangente die Iteration beliebig weit wegführen (Bemerkung 12.1.13).

Vertiefung: Heath §5.1 ordnet Existenz, Eindeutigkeit und Konvergenzraten von Nullstellenproblemen ein, §5.5 behandelt Bisektion, Fixpunktiteration und Newton im Eindimensionalen, §5.6 die Systeme. Heath Kapitel 6 ist der Optimierung gewidmet und trägt die folgenden Abschnitte dieses Kapitels.

12.2 Optimalität und Sattelpunkte

Vom Nullstellen- zum Optimierungsproblem

Abschnitt 12.1 hat Gleichungen $f(x) = 0$ gelöst. Ab hier suchen wir die Stelle, an der eine Funktion ihren kleinsten Wert annimmt, wie bei kleinsten Quadraten, Maximum-Likelihood oder dem Training eines neuronalen Netzes. Dieser Abschnitt klärt, was ein Optimum ist, welche Bedingungen dort gelten und warum Konvexität den Unterschied zwischen „irgendein Minimum“ und „das Minimum“ ausmacht.

Definition 12.2.1 (Lokales und globales Minimum)

Seien $\mathcal{X} \subseteq \mathbb{R}^n$ die *zulässige Menge* (feasible set) und $f : \mathcal{X} \rightarrow \mathbb{R}$ die Zielfunktion (objective function), das Problem also

$$\mathbf{x}^* \in \arg \min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}). \quad (12.2.1)$$

Ein Punkt $\mathbf{x}^* \in \mathcal{X}$ heißt

- *globales Minimum*, wenn $f(\mathbf{x}^*) \leq f(\mathbf{x})$ für alle $\mathbf{x} \in \mathcal{X}$ gilt;
- *lokales Minimum*, wenn es eine Umgebung U von $\mathbf{x}^*$ gibt, sodass $f(\mathbf{x}^*) \leq f(\mathbf{x})$ für alle $\mathbf{x} \in U \cap \mathcal{X}$ gilt.

Gilt jeweils die strikte Ungleichung für $\mathbf{x} \neq \mathbf{x}^*$, so heißt das Minimum *strikt*.

In Abschnitt 12.1 hieß die zulässige Menge S ; hier schreiben wir $\mathcal{X}$, weil S in den Sätzen unten den offenen Definitionsbereich bezeichnet. $\arg \min$ ist streng genommen die Menge aller Minimierer, und $\mathbf{x}^*$ steht für ein Element daraus, sofern eines existiert. Die Konvexitätssätze unten gelten für eine allgemeine zulässige Menge; die Verfahren der Abschnitte 12.3 und 12.4 arbeiten mit $\mathcal{X} = \mathbb{R}^n$.

Bemerkung 12.2.2 (Maximieren ist Minimieren)

Ein Maximierungsproblem müssen wir nicht getrennt behandeln:

$$\max_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) = - \min_{\mathbf{x} \in \mathcal{X}} (-f(\mathbf{x})), \quad \arg \max_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) = \arg \min_{\mathbf{x} \in \mathcal{X}} (-f(\mathbf{x})).$$

Die Werte wechseln das Vorzeichen, die Argumente bleiben dieselben. Deshalb sind die gängigen Bibliotheken Minimierer, und deshalb heißt die Zielfunktion der Maximum-Likelihood-Schätzung dort in aller Regel die *negative* Log-Likelihood. Wir formulieren im Folgenden alles für Minima.

Die Bedingung erster Ordnung

Die folgende Bedingung haben wir in Abschnitt 12.1 schon benutzt; sie ist der Ausgangspunkt jedes Optimierungsverfahrens.

Satz 12.2.3 (Notwendige Bedingung erster Ordnung)

Seien $S \subseteq \mathbb{R}^n$ offen, $f : S \rightarrow \mathbb{R}$ und $\mathbf{x}^* \in S$ ein lokales Minimum von f . Ist f in $\mathbf{x}^*$ differenzierbar, so gilt

$$\nabla f(\mathbf{x}^*) = \mathbf{0}^\top. \quad (12.2.2)$$

Dieselbe Aussage gilt für lokale Maxima.

Vertiefung (optional): Beweis der notwendigen Bedingung erster Ordnung

Beweis.

- (1) Sei $\mathbf{h} \in \mathbb{R}^n$ beliebig. Weil S offen ist, gibt es ein $\delta > 0$, sodass $\mathbf{x}^* + t\mathbf{h} \in S$ für alle $|t| < \delta$ gilt. Wir betrachten die Funktion einer einzigen Variablen

$$g : (-\delta, \delta) \rightarrow \mathbb{R}, \quad g(t) := f(\mathbf{x}^* + t\mathbf{h}).$$

Weil $\mathbf{x}^*$ ein lokales Minimum von f ist, hat g in $t = 0$ ein lokales Minimum.

Für kleine $|t|$ liegt $\mathbf{x}^* + t\mathbf{h}$ in der Umgebung U aus Definition 12.2.1, dort ist $f(\mathbf{x}^*) \leq f(\mathbf{x}^* + t\mathbf{h})$, also $g(0) \leq g(t)$

- (2) g ist in $t = 0$ differenzierbar mit $g'(0) = \nabla f(\mathbf{x}^*) \mathbf{h}$. Wir betrachten den Differenzenquotienten von zwei Seiten. Für hinreichend kleine $t > 0$ ist $(g(t) - g(0))/t \geq 0$, weil der Zähler nicht negativ ist; im Grenzwert folgt $g'(0) \geq 0$. Für hinreichend kleine $t < 0$ dreht der Nenner das Vorzeichen um, wir erhalten $(g(t) - g(0))/t \leq 0$ und im Grenzwert $g'(0) \leq 0$. Beides zusammen ergibt $g'(0) = 0$.

Der Wert der Ableitung ist die Richtungsableitung aus Abschnitt 10.2; die Kettenregel auf die affine Abbildung $t \mapsto \mathbf{x}^* + t\mathbf{h}$ angewandt gibt $\nabla f(\mathbf{x}^*)\mathbf{h}$

- (3) Der zweite Schritt gilt für jedes $\mathbf{h}$. Setzen wir nacheinander die Einheitsvektoren $\mathbf{h} = \mathbf{e}_j$ ein, so steht dort $\nabla f(\mathbf{x}^*) \mathbf{e}_j = \partial f(\mathbf{x}^*)/\partial x_j = 0$ für $j = 1, \dots, n$, und das ist (12.2.2). Für ein lokales Maximum wenden wir das Gezeigte auf $-f$ an und benutzen Bemerkung 12.2.2.

Ein Zeilenvektor, der auf jedem Einheitsvektor verschwindet, ist der Nullvektor

□

Definition 12.2.4 (Stationärer Punkt)

Ein Punkt $\mathbf{x}$ mit $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ heißt *stationärer Punkt* von f . In Abschnitt 10.7 heißt derselbe Punkt *kritischer Punkt*; beide Wörter sind gebräuchlich und meinen dasselbe.

Die Bedingung erster Ordnung ist *notwendig*, nicht *hinreichend*: Ein stationärer Punkt kann ebenso ein Maximum oder ein Sattelpunkt sein. Außerdem gilt sie nur im *Inneren*. Am Rand der zulässigen Menge darf der Gradient im Minimum von null verschieden sein, so bei $f(x) = x$ auf $\mathcal{X} = [0, 1]$ mit Minimum in 0 und $f'(0) = 1$; davon handelt Abschnitt 12.5.

Bemerkung 12.2.5 (Optimieren heißt Gleichungen lösen)

Gleichung (12.2.2) ist ein System aus n Gleichungen in n Unbekannten, meist nichtlinear. Damit sind wir wieder bei Abschnitt 12.1, und die dortigen Verfahren stehen bereit. Insbesondere ist

$$\Phi(\mathbf{x}) := \mathbf{x} - \gamma \nabla f(\mathbf{x})^\top \quad (12.2.3)$$

eine Fixpunktabbildung, deren Fixpunkte genau die stationären Punkte von f sind, denn $\Phi(\mathbf{x}) = \mathbf{x}$ gilt für $\gamma \neq 0$ genau dann, wenn $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ ist. Die zu (12.2.3) gehörige Fixpunktiteration $\mathbf{x}^{(k+1)} = \Phi(\mathbf{x}^{(k)})$ ist der Gradientenabstieg aus Abschnitt 12.3.

Analytisch lösen lässt sich (12.2.2) nur in Sonderfällen, etwa bei den kleinsten Quadraten: Dort ist der Gradient linear in β , und aus der Bedingung werden die Normalgleichungen aus Kapitel 7. Sobald das Modell nichtlinear wird, iterieren wir.

Lokal oder global

Ein Verfahren, das nur die Umgebung des aktuellen Punktes ansieht, kann grundsätzlich nur lokale Minima finden. Ob das genügt, entscheidet die Zielfunktion; die beiden Antworten hat Abschnitt 11.5 bewiesen.

Lokal ist global. Sind $\mathcal{X} \subseteq \mathbb{R}^n$ konvex und $f: \mathcal{X} \rightarrow \mathbb{R}$ konvex, so ist jedes lokale Minimum von f auf $\mathcal{X}$ auch ein globales, und zwar ohne jede Differenzierbarkeit (Bemerkung 11.5.2). Ist f differenzierbar, so steht in Satz 11.5.1 sogar die schärfere Fassung: Dann ist schon jeder stationäre Punkt ein globales Minimum. Ein lokal suchendes Verfahren kann bei konvexem f also nichts verpassen; deshalb ist Konvexität für die Optimierung so wichtig.

Höchstens eine Lösung. Ist f darüber hinaus strikt konvex, gilt also $f(\lambda \mathbf{x} + (1-\lambda)\mathbf{y}) < \lambda f(\mathbf{x}) + (1-\lambda)f(\mathbf{y})$ für alle $\mathbf{x} \neq \mathbf{y}$ in $\mathcal{X}$ und alle $\lambda \in (0, 1)$, so hat f auf $\mathcal{X}$ nach Satz 11.5.5 höchstens einen Minimierer. Über die Existenz eines Minimierers sagt keine der beiden Aussagen etwas: $f(x) = e^x$ ist auf $\mathbb{R}$ strikt konvex und hat kein Minimum.

Bemerkung 12.2.6 (Beide Sätze brauchen zwei Konvexitätsbedingungen)

In beiden Sätzen ist die Konvexität der zulässigen Menge so wesentlich wie die der Zielfunktion. Die Beweise in Abschnitt 11.5 zeigen, warum: Der Vergleichspunkt muss *zulässig* sein, dafür sorgt die Menge, und er muss *besser* sein, dafür sorgt die Funktion.

Ohne konvexe Menge keine Eindeutigkeit. Wir nehmen $\mathcal{X} = \{-1, +1\}$ und $f(y) = y^2$. Die Zielfunktion ist strikt konvex, und trotzdem sind $y = -1$ und $y = +1$ beide optimal mit dem Wert 1. Der Mittelpunkt $z = 0$ hätte den kleineren Wert 0, er ist aber nicht zulässig, und der Widerspruch aus dem Beweis von Satz 11.5.5 entsteht gar nicht erst.

Das Projektionstheorem (Satz 11.3.1) minimiert $\|\mathbf{x} - \mathbf{y}\|^2$ über alle $\mathbf{y}$ einer abgeschlossenen konvexen Menge. Dort steht nur eine Bedingung an die Menge, weil die quadrierte Distanz in $\mathbf{y}$ ohnehin strikt konvex ist.

Vertiefung (optional): Warum die quadrierte Norm strikt konvex ist

Die Dreiecksungleichung liefert $\|\lambda \mathbf{a} + (1-\lambda)\mathbf{b}\| \leq \lambda \|\mathbf{a}\| + (1-\lambda)\|\mathbf{b}\|$ und damit nur die Konvexität der Norm, nicht die strikte. Gleichheit tritt nämlich ein, sobald $\mathbf{a}$ und $\mathbf{b}$ in dieselbe Richtung zeigen: Für $\mathbf{a} = (1; 0)$, $\mathbf{b} = (2; 0)$ und $\lambda = \frac{1}{2}$ stehen auf beiden Seiten 1,5. Die *quadrierte* Norm ist dagegen strikt konvex, und zwar wegen der Identität

$$\|\lambda \mathbf{a} + (1-\lambda)\mathbf{b}\|^2 = \lambda \|\mathbf{a}\|^2 + (1-\lambda)\|\mathbf{b}\|^2 - \lambda(1-\lambda)\|\mathbf{a} - \mathbf{b}\|^2, \quad (12.2.4)$$

die durch Ausmultiplizieren mit der Bilinearität des Skalarprodukts entsteht und der Parallelogrammgleichung entspricht. Für $\mathbf{a} \neq \mathbf{b}$ und $\lambda \in (0, 1)$ ist der rote Term strikt negativ, und das ist die strikte Konvexität. Weil $t \mapsto t^2$ auf $[0, \infty)$ streng wächst, haben Distanz und quadrierte Distanz dieselben Minimierer; das Quadrieren ändert die Lösung also nicht und liefert die strikte Konvexität. Gebraucht wird dafür das Skalarprodukt, nicht nur eine Norm.

Konvexe Verlustfunktionen in Statistik und ML

Beispiel 12.2.7 (Vier konvexe Verlustfunktionen)

Welche Probleme aus Statistik und maschinellem Lernen konvex sind und welche nicht, ordnet Bemerkung 11.5.7 ein; hier rechnen wir vier Standardfälle nach.

Kleinste Quadrate. Für $L(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$ ist der Gradient $\nabla L(\boldsymbol{\beta}) = 2(\mathbf{X}\boldsymbol{\beta} - \mathbf{y})^\top \mathbf{X}$ und die Hesse-Matrix

$$\mathbf{H}_L = 2\mathbf{X}^\top \mathbf{X}.$$

Sie ist stets positiv semidefinit, denn $\mathbf{h}^\top \mathbf{X}^\top \mathbf{X} \mathbf{h} = \|\mathbf{X}\mathbf{h}\|_2^2 \geq 0$, und positiv definit genau dann, wenn $\mathbf{X}$ vollen Spaltenrang hat: Nur dann folgt aus $\mathbf{h} \neq \mathbf{0}$ auch $\mathbf{X}\mathbf{h} \neq \mathbf{0}$. Mit vollem Spalten-

rang ist L also strikt konvex und der Kleinste-Quadrate-Schätzer nach Satz 11.5.5 eindeutig. *Ridge-Regression*. Der Strafterm addiert eine Krümmung dazu,

$$f(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2, \quad \mathbf{H}_f = 2(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_p).$$

Die Eigenwerte von $\mathbf{H}_f$ sind $2(\mu_i + \lambda)$, wenn $\mu_i \geq 0$ die Eigenwerte von $\mathbf{X}^\top \mathbf{X}$ sind. Für $\lambda > 0$ sind sie alle positiv, und zwar unabhängig vom Rang von $\mathbf{X}$. Ridge macht so aus einem rangdefekten Problem mit unendlich vielen Lösungen eines mit genau einer; den Gradienten dazu haben wir in Abschnitt 10.6 gerechnet.

Negative Log-Likelihood. Ist die Log-Likelihood konkav, so ist ihr Negatives konvex, und die Maximum-Likelihood-Schätzung wird zu einem konvexen Minimierungsproblem. Das ist bei vielen Standardmodellen so, etwa bei der Normalverteilung mit bekannter Varianz, wo wieder das Kleinste-Quadrate-Problem herauskommt, und bei der logistischen Regression (Beispiel 11.4.12). Die Log-Likelihood einer Mischverteilung dagegen ist nicht konkav und hat typischerweise mehrere lokale Optima.

Hinge-Loss. Die Support-Vector-Machine summiert über die Daten den *Hinge-Verlust* $L(y, \hat{y}) = \max(0, 1 - y\hat{y})$ und addiert einen Strafterm. Als punktweises Maximum zweier affiner Funktionen ist der Hinge-Loss konvex (Satz 11.4.1), aber weder strikt konvex noch überall differenzierbar: Für $y\hat{y} \geq 1$ ist er konstant null, und bei $y\hat{y} = 1$ hat er einen Knick. Verfahren, die nur Gradienten kennen, brauchen dort Subgradienten (Definition 11.4.14).

Sattelpunkte

Bei nicht-konvexen Funktionen sagt $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ wenig. Der Punkt kann ein Minimum sein, ein Maximum, oder keines von beidem.

Definition 12.2.8 (Sattelpunkt)

Ein stationärer Punkt $\mathbf{x}^*$ von f heißt *Sattelpunkt*, wenn jede Umgebung von $\mathbf{x}^*$ Punkte $\mathbf{x}_-$ und $\mathbf{x}_+$ enthält mit

$$f(\mathbf{x}_-) < f(\mathbf{x}^*) < f(\mathbf{x}_+).$$

Ist die Hesse-Matrix $\mathbf{H}_f(\mathbf{x}^*)$ indefinit, hat sie also sowohl positive als auch negative Eigenwerte, so sprechen wir genauer von einem *Sattelpunkt mit indefiniter Hesse-Matrix*.

Für zweimal stetig differenzierbares f ist eine indefinite Hesse-Matrix hinreichend für einen Sattelpunkt (Satz 10.7.9), aber nicht notwendig: Bei $f(x) = x^3$ ist $x = 0$ ein Sattelpunkt, obwohl $f''(0) = 0$ ist. Praktisch wichtig ist vor allem der indefinite Fall.

Beispiel 12.2.9 (Der Standardsattel)

Wir rechnen den einfachsten Fall vollständig durch. Sei

$$f(x, y) = x^2 - y^2.$$

Stationäre Punkte. Der Gradient ist $\nabla f(x, y) = (2x, -2y)$, und er verschwindet genau im Ursprung. Der einzige stationäre Punkt ist also $\mathbf{x}^* = (0; 0)$ (violett: weder Iterierte noch Ziel). *Hesse-Matrix*. Zweimaliges Ableiten gibt

$$\mathbf{H}_f(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix},$$

und zwar an jeder Stelle dieselbe Matrix, weil f quadratisch ist. Sie ist diagonal, ihre Eigenwerte stehen also ablesbar auf der Diagonalen: $\lambda_1 = 2 > 0$ zum Eigenvektor $\mathbf{e}_1$ und $\lambda_2 = -2 < 0$ zum Eigenvektor $\mathbf{e}_2$. Die Vorzeichen sind verschieden, die Matrix ist indefinit, und $\mathbf{x}^*$ ist ein Sattelpunkt.

Was das geometrisch heißt. Schneiden wir f entlang der beiden Achsen, so sehen wir zwei Parabeln mit entgegengesetzter Öffnung:

$$f(t, 0) = t^2 \quad (\text{Minimum in } t = 0), \quad f(0, t) = -t^2 \quad (\text{Maximum in } t = 0).$$

Derselbe Punkt ist in der einen Richtung der tiefste und in der anderen der höchste seiner Umgebung. Die Höhenlinien machen das sichtbar: Das Niveau $f = 0$ besteht aus den beiden Geraden $y = \pm x$, die positiven Niveaus sind Hyperbeln, die in x -Richtung öffnen, die negativen Hyperbeln öffnen in y -Richtung.

Kann ein Verfahren an einem solchen Punkt hängenbleiben?

Interaktiv: Zwei Verfahren am Sattelpunkt

Die Tafel zeichnet die Höhenlinien von Beispiel 12.2.9 und hängt zwei Verfahren daran.

Schätzfrage. Von welchen Startpunkten aus läuft der *Gradientenabstieg* in den Sattelpunkt?

Lösung: achse

Der zweite Start trifft diesen Fall: Auf dem Strahl $y = 0$ bleibt die zweite Komponente in jedem Schritt exakt null, und der Abstieg läuft in den Sattelpunkt. Dieser eine Strahl hat in der Ebene Maß null.

Die beiden Verfahren gehen gegensätzlich mit dem Sattel um. Der Newton-Knopf landet von jedem Startpunkt aus in einem einzigen Schritt exakt in $\mathbf{x}^*$, denn f ist quadratisch und seine Näherung zweiter Ordnung damit exakt. Der Gradientenabstieg dagegen entkommt: Mit $\gamma = 0,25$ steht er aus $(1,5; 0,4)$ nach acht Schritten bei $(0,0059; 10,25)$; die erste Komponente fällt gegen null, die zweite wächst.

Bemerkung 12.2.10 (Was Sattelpunkte für die Verfahren bedeuten)

Newton läuft hinein. Der Newton-Schritt aus Abschnitt 10.8 sucht eine Nullstelle des Gradienten, und ein Sattelpunkt ist eine. Für unser f ist $\mathbf{H}_f^{-1} = \text{diag}(\frac{1}{2}, -\frac{1}{2})$, und der Schritt $\mathbf{x}^{(1)} = \mathbf{x} - \mathbf{H}_f^{-1} \nabla f(\mathbf{x})^\top$ ergibt

$$\mathbf{x}^{(1)} = \begin{pmatrix} x \\ y \end{pmatrix} - \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & -\frac{1}{2} \end{pmatrix} \begin{pmatrix} 2x \\ -2y \end{pmatrix} = \begin{pmatrix} x - x \\ y - y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix},$$

und zwar von jedem Startpunkt aus. Ein Verfahren, das die Krümmung benutzt, ohne auf ihr Vorzeichen zu achten, konvergiert gegen Sattelpunkte wie gegen Minima (Gegenmittel in Abschnitt 12.4).

Der Gradientenabstieg entkommt. Mit Schrittweite γ lautet die Iteration komponentenweise

$$x^{(k+1)} = (1 - 2\gamma) x^{(k)}, \quad y^{(k+1)} = (1 + 2\gamma) y^{(k)}. \quad (12.2.5)$$

Für $0 < \gamma < \frac{1}{2}$ schrumpft nach (12.2.5) die erste Komponente, die zweite wächst in jedem Schritt um den Faktor $1 + 2\gamma > 1$. Nur wer exakt auf der x -Achse startet, also mit $y^{(0)} = 0$,

landet im Sattel. Diese Startmenge ist eine Gerade im $\mathbb{R}^2$ und hat Maß null. In der Praxis genügt schon Rundungsrauschen, um sie zu verfehlen; das Rauschen des stochastischen Gradientenabstiegs (Abschnitt 12.4) hilft zusätzlich.

Hohe Dimension. Ist kein Eigenwert von $\mathbf{H}_f$ null, so verlangt ein Minimum, dass *alle* n Eigenwerte positiv sind; für einen Sattelpunkt genügen gemischte Vorzeichen. In hochdimensionalen, nicht-konvexen Problemen sind Sattelpunkte deshalb meist häufiger als lokale Minima; eine Münzwurf-Faustregel dazu steht in Bemerkung 10.7.13.

Optimalitätsbedingungen im Überblick

Für zweimal stetig differenzierbares f fasst der folgende Satz die Bedingungen zusammen.

Satz 12.2.11 (Bedingungen erster und zweiter Ordnung)

Seien $S \subseteq \mathbb{R}^n$ offen, $f \in \mathcal{C}^2(S)$ und $\mathbf{x}^* \in S$.

1. *Notwendig, erste Ordnung.* Ist $\mathbf{x}^*$ ein lokales Minimum, so gilt $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$.
2. *Notwendig, zweite Ordnung.* Ist $\mathbf{x}^*$ ein lokales Minimum, so ist $\mathbf{H}_f(\mathbf{x}^*) \geq 0$, also positiv semidefinit.
3. *Hinreichend, zweite Ordnung.* Gilt $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ und ist $\mathbf{H}_f(\mathbf{x}^*) \succ 0$, also positiv definit, so ist $\mathbf{x}^*$ ein striktes lokales Minimum.

Vertiefung (optional): Beweis der notwendigen Bedingung zweiter Ordnung

Beweis.

- (1) Teil 1 ist Satz 12.2.3, und Teil 3 ist Satz 10.7.9(1) aus Abschnitt 10.7. Zu zeigen bleibt Teil 2. Sei $\mathbf{h} \in \mathbb{R}^n$ beliebig und wieder $g(t) = f(\mathbf{x}^* + t\mathbf{h})$ wie im Beweis von Satz 12.2.3. Die Taylorentwicklung zweiter Ordnung aus Abschnitt 10.8 gibt mit $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ aus Teil 1

$$g(t) = g(0) + \frac{1}{2} t^2 \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} + o(t^2) \quad (t \rightarrow 0).$$

Der lineare Term fällt weg, weil $\mathbf{x}^$ nach Teil 1 stationär ist*

- (2) Weil $\mathbf{x}^*$ ein lokales Minimum ist, gilt $g(t) \geq g(0)$ für alle hinreichend kleinen $|t|$. Wir ziehen $g(0)$ ab und teilen durch $t^2 > 0$:

$$0 \leq \frac{g(t) - g(0)}{t^2} = \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} + \frac{o(t^2)}{t^2}.$$

Der rote Quotient verschwindet für $t \rightarrow 0$, also bleibt $\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} \geq 0$ stehen. Weil $\mathbf{h}$ beliebig war, ist $\mathbf{H}_f(\mathbf{x}^*)$ positiv semidefinit.

Hier bleibt nur die schwache Ungleichung übrig: Der Grenzwert einer Folge nichtnegativer Zahlen ist nichtnegativ, aber nicht notwendig positiv

□

Bemerkung 12.2.12 (Warum die Rückrichtung nicht gilt)

Teil 3 lässt sich nicht umkehren: $f(x) = x^4$ hat in $x = 0$ ein striktes globales Minimum, aber $f''(0) = 0$, die Hesse-Matrix $\mathbf{H}_f(0) = (0)$ ist also nicht positiv definit. Aus einem lokalen Minimum folgt nur die Semidefinitheit aus Teil 2. Bemerkung 10.7.10 stellt x^4 , $-x^4$ und x^3 nebeneinander: dieselbe Hesse-Matrix im Nullpunkt, drei verschiedene Antworten.

Für stationäre Punkte, $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$, fasst eine Tabelle die Fälle zusammen:

$\mathbf{H}_f(\mathbf{x}^*)$	$\mathbf{x}^*$ ist
> 0 (positiv definit)	striktes lokales Minimum
< 0 (negativ definit)	striktes lokales Maximum
indefinit	Sattelpunkt
semidefinit, aber nicht definit	unklar, weitere Analyse nötig

In der letzten Zeile entscheidet die zweite Ableitung nichts, und wir müssen höhere Ableitungen ansehen oder anders argumentieren. Ein einzelner Eigenwert null führt nicht automatisch dorthin: $\mathbf{H}_f = \text{diag}(1, -1, 0)$ ist indefinit, und die dritte Zeile greift.

Bemerkung 12.2.13 (Was Konvexität aus der Tabelle macht)

Ist f auf einer offenen konvexen Menge S konvex und zweimal stetig differenzierbar, so ist $\mathbf{H}_f(\mathbf{x}) \succeq 0$ an *jeder* Stelle (Satz 10.7.11); die indefinite Zeile der Tabelle bleibt leer. Außerdem wird die Bedingung erster Ordnung hinreichend: Jeder stationäre Punkt ist ein globales Minimum (Satz 11.5.1). Eine konvexe Funktion hat also keine Sattelpunkte, und jedes lokale Minimum ist global.

Bei einem konvexen Problem genügt deshalb ein *verschwindender* Gradient. Ein *kleiner* Gradient garantiert noch nicht, dass wir nahe am Minimum sind; darauf kommen die Abbruchkriterien in Abschnitt 12.3 zurück.

Selbsttest

1. Ein Punkt mit $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ ist ein lokales Minimum von f .

Antwort: Falsch

Die Bedingung ist notwendig, nicht hinreichend (Satz 12.2.3). Der Ursprung ist ein stationärer Punkt von $f(x, y) = x^2 - y^2$, aber weder Minimum noch Maximum, sondern ein Sattelpunkt: entlang der x -Achse geht es nach oben, entlang der y -Achse nach unten.

2. Ein Maximierungsproblem lässt sich ohne Verlust in ein Minimierungsproblem umschreiben.

Antwort: Wahr

Es ist $\max f = -\min(-f)$, und die Maximierer von f sind genau die Minimierer von $-f$ (Bemerkung 12.2.2). Deshalb minimieren Softwarebibliotheken die *negative* Log-Likelihood.

3. Ist die Zielfunktion strikt konvex, so hat das Optimierungsproblem höchstens eine Lösung, gleichgültig, wie die zulässige Menge aussieht.

Antwort: Falsch

Satz 11.5.5 braucht beide Konvexitätsbedingungen. Auf $\mathcal{X} = \{-1, +1\}$ ist $f(y) = y^2$ strikt konvex, und trotzdem sind beide Punkte optimal mit dem Wert 1 (Bemerkung 12.2.6).

4. Die Hesse-Matrix $2\mathbf{X}^\top\mathbf{X}$ des Kleinst-Quadrate-Problems ist immer positiv semidefinit, aber nur bei vollem Spaltenrang von $\mathbf{X}$ positiv definit.

Antwort: Wahr

Es ist $\mathbf{h}^\top \mathbf{X}^\top \mathbf{X} \mathbf{h} = \|\mathbf{X}\mathbf{h}\|_2^2 \geq 0$, also stets semidefinit. Gleichheit tritt für ein $\mathbf{h} \neq \mathbf{0}$ genau dann ein, wenn $\mathbf{X}\mathbf{h} = \mathbf{0}$ gilt, wenn also die Spalten linear abhängig sind. Ohne vollen Spaltenrang ist die Zielfunktion nur konvex, nicht strikt konvex, und das Minimum ist nicht mehr eindeutig. Ridge repariert das, indem es 2λ auf jeden Eigenwert addiert (Beispiel 12.2.7).

5. Aus $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ und positiv semidefiniter Hesse-Matrix folgt, dass $\mathbf{x}^*$ ein lokales Minimum ist.

Antwort: Falsch

Semidefinit reicht nicht, das ist die letzte Zeile der Klassifikationstabelle. Für $f(x) = x^3$ ist $f'(0) = 0$ und $f''(0) = 0$, die Hesse-Matrix also positiv semidefinit, und trotzdem liegt in 0 kein Minimum: links davon ist f negativ. Positive *Definitheit* dagegen genügt (Satz 12.2.11).

6. Das Newton-Verfahren umgeht Sattelpunkte, weil es die Krümmung mitbenutzt.

Antwort: Falsch

Es läuft eher hinein. Auf $f(x, y) = x^2 - y^2$ landet ein einziger Newton-Schritt von jedem Startpunkt aus exakt im Sattel $(0, 0)$, wie die Rechnung in Bemerkung 12.2.10 zeigt. Der Gradientenabstieg entkommt dagegen, weil er die Komponente in der Richtung mit negativem Eigenwert in jedem Schritt um den Faktor $1 + 2\gamma$ vergrößert.

7. Mit welchem Faktor wächst im Widget die y -Komponente des Gradientenabstiegs pro Schritt, wenn $\gamma = 0,25$ eingestellt ist?

Lösung: 1,5

Die Iteration lautet $y^{(k+1)} = y^{(k)} - \gamma \cdot (-2y^{(k)}) = (1 + 2\gamma) y^{(k)}$, mit $\gamma = 0,25$ also der Faktor 1,5. Die Ablesetafel des Widgets nennt ihn direkt; in der x -Richtung steht daneben $|1 - 2\gamma| = 0,5$. Wegen dieser Gegenläufigkeit entkommt der Abstieg dem Sattel.

Vertiefung: Heath §6.1 stellt Optimierungsprobleme und ihre Sprechweisen zusammen, §6.2.1 sammelt die Folgen der Konvexität und §6.2.2 die Optimalitätsbedingungen ohne Nebenbedingungen; die Bedingungen mit Nebenbedingungen (Heath §6.2.3) folgen in Abschnitt 12.5.

12.3 Nelder-Mead und Gradientenabstieg

Wie viel Ableitung darf es sein?

In einem inneren Minimum verschwindet der Gradient (Abschnitt 12.2), und $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ ist ein nichtlineares Gleichungssystem, das wir iterativ lösen. Die Verfahren dafür unterscheiden sich vor allem darin, wie viel Ableitungsinformation sie benutzen.

Bemerkung 12.3.1 (Taxonomie nach Ableitungsordnung)

Ordnung	benutzt	Beispiele
nullte	nur Funktionswerte $f(\mathbf{x})$	Nelder-Mead, Gittersuche
erste	f und ∇f	Gradientenabstieg, Momentum-Verfahren, SGD
zweite	f , ∇f und $\mathbf{H}_f$	Newton-Verfahren

Jede Ableitung, die ein Verfahren verlangt, muss jemand bereitstellen (von Hand, per automatischem Differenzieren oder durch Differenzenquotienten), und sie kostet in jedem Schritt Rechenzeit. Verfahren nullter Ordnung sind robust und laufen auf allem, was sich auswerten lässt; dafür brauchen sie viele Iterationen. Höhere Ordnung bringt schnellere Konvergenz, macht aber jeden Schritt teurer, und die Hesse-Matrix hat n^2 Einträge. In der Praxis greifen wir oft zu einem Kompromiss, den superlinearen Quasi-Newton-Verfahren wie BFGS, die eine Näherung der inversen Hesse-Matrix aus den bereits berechneten Gradienten aufbauen (Abschnitt 12.4).

Nelder-Mead: Optimieren ohne Ableitungen

Manchmal gibt es keine Ableitung: Die Zielfunktion ist das Ergebnis einer Simulation oder eines Programms, dessen Innenleben wir nicht kennen, oder sie hat Knicke. Dann bleibt nur, Funktionswerte zu vergleichen. Das bekannteste Verfahren dieser Art arbeitet mit einem *Simplex* aus $n + 1$ Punkten im $\mathbb{R}^n$, einem Dreieck in der Ebene, einem Tetraeder im Raum, und ersetzt in jedem Schritt seine schlechteste Ecke durch eine bessere.

Algorithmus 12.3.2 (Nelder-Mead-Simplexverfahren)

Gegeben seien $f : \mathbb{R}^n \rightarrow \mathbb{R}$ und ein Startsimplex aus $n + 1$ Punkten. Wiederhole, bis der Simplex klein genug ist:

1. *Sortieren*. Ordne die Ecken nach Funktionswert, $\mathbf{x}_{(1)}$ sei die beste und $\mathbf{x}_{(n+1)}$ die schlechteste. Bilde den Schwerpunkt $\mathbf{c}$ der n besten Ecken.
2. *Reflexion*. Spiegle die schlechteste Ecke am Schwerpunkt, $\mathbf{x}_r = \mathbf{c} + (\mathbf{c} - \mathbf{x}_{(n+1)})$. Ist $f(\mathbf{x}_r)$ besser als die zweitschlechteste Ecke, aber nicht besser als die beste, so übernehme $\mathbf{x}_r$ und beginne von vorn.
3. *Expansion*. Ist $f(\mathbf{x}_r)$ besser als alles Bisherige, so gehe in derselben Richtung noch weiter, $\mathbf{x}_e = \mathbf{c} + 2(\mathbf{c} - \mathbf{x}_{(n+1)})$, und übernehme den besseren der beiden Punkte.
4. *Kontraktion*. Ist $\mathbf{x}_r$ nicht besser als die zweitschlechteste Ecke, so probiere einen Punkt auf halbem Weg zwischen Schwerpunkt und dem besseren der beiden Punkte $\mathbf{x}_r$ und $\mathbf{x}_{(n+1)}$; übernehme ihn, falls er besser ist als beide.
5. *Schrumpfen*. Hilft auch das nicht, so ziehe alle Ecken zur besten Ecke $\mathbf{x}_{(1)}$ hin.

Solange es bergab geht, bewegt sich der Simplex über Reflexionen und Expansionen voran und wird dabei lang; umschließt er ein Tal, ziehen ihn Kontraktionen und Schrumpfschritte zusammen. Die Schrittweite steuert er so selbst, ohne einen Parameter, und das ist der Hauptvorteil des Verfahrens.

Bemerkung 12.3.3 (Wann sich Nelder-Mead lohnt)

Situation	geeignet?
Ableitungen nicht verfügbar	ja, das ist der Hauptgrund
niedrige Dimension, $n \leq 10$	ja
nicht glatte Zielfunktion	ja, es werden nur Werte verglichen
hohe Dimension, $n > 50$	nein, zu langsam
präzise Konvergenz nötig	nein, im Allgemeinen ohne Garantie

Kosten. Ein gewöhnlicher Schritt kostet ein bis zwei neue Funktionsauswertungen, ein Schrumpfschritt n neue Ecken; pro Iteration fallen also $O(n)$ Auswertungen an (Landau-Notation), und meist sind sehr viele Iterationen nötig. In hoher Dimension wird beides zum Problem.

Garantien. Einen allgemeinen Konvergenzsatz gibt es nicht; auf manchen strikt konvexen Funktionen läuft das Verfahren sogar gegen einen Punkt, der kein stationärer Punkt ist (McKinnon 1998). In der Praxis dient Nelder-Mead deshalb oft als robuste Startpunktsuche vor einem gradientenbasierten Verfahren.

In R. Nelder-Mead ist die Voreinstellung von `optim()` (Abschnitt 12.6).

Wie oft welcher der vier Züge fällt, entscheidet über die Kosten, denn die Züge sind verschieden teuer.

Interaktiv: Der Simplex bei der Arbeit

Das Verfahren läuft Schritt für Schritt auf der Testfunktion $f(\mathbf{x}) = (1 - x_1)^2 + 5(x_2 - x_1^2)^2$ mit Minimum in $(1; 1)$. Der orange Strahl markiert jeweils den nächsten Versuchspunkt; der Schrittreger lässt sich vorwärts und rückwärts schieben, der Abspielknopf lässt den ganzen Lauf durchlaufen.

Schätzfrage. Welcher der vier Züge fällt auf dieser Testfunktion am häufigsten?

Lösung: *kontraktion*

Der Zugzähler im Widget führt mit: Aus dem voreingestellten Simplex braucht das Verfahren vierzig Schritte, bis der beste Eckpunkt unter 10^{-6} liegt, und der Zähler steht dann auf 23 Kontraktionen, 13 Reflexionen und 4 Expansionen.

Die Züge verteilen sich sehr ungleich. Der Schrumpfschritt, der teuerste Zug, kommt auf dem voreingestellten Weg gar nicht vor; erst der zweite Startsimplex erzwingt ihn im vierten Schritt. Auf den geraden Stücken des Tals wird der Simplex lang und dünn und legt sich in Laufrichtung, in der Biegung um $x_1 \approx 0$ schrumpft er und dreht sich in die neue Richtung: Die Anpassung an die lokale Geometrie ersetzt die fehlende Ableitung.

Eine Animation derselben Züge, mit einstellbaren Parametern und mehreren Testfunktionen, liegt unter alexdowad.github.io/visualizing-nelder-mead.

Der Gradientenabstieg

Der Gradient zeigt bergauf (Abschnitt 10.2). Zum Minimieren laufen wir also in die Gegenrichtung.

Algorithmus 12.3.4 (Gradientenabstieg)

Gegeben seien eine differenzierbare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$, ein Startpunkt $\mathbf{x}^{(0)}$ und eine Schrittweite $\gamma > 0$. Für $k = 0, 1, 2, \dots$ setze

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)})^\top \quad (12.3.1)$$

und brich ab, sobald eines der Kriterien aus Bemerkung 12.3.17 greift.

Das Transponierte steht da, weil der Gradient in diesem Skript ein Zeilenvektor ist, eine Richtung im $\mathbb{R}^n$ dagegen eine Spalte. Im maschinellen Lernen heißt γ *Lernrate* (learning rate) und der Gradientenabstieg *gradient descent*.

Bemerkung 12.3.5 (Drei Lesarten desselben Schritts)

Steilster Abstieg. Für $\nabla f(\mathbf{x}) \neq \mathbf{0}^\top$ macht unter allen Richtungen $\mathbf{d}$ mit $\|\mathbf{d}\| = 1$ die Richtung $\mathbf{d} = -\nabla f(\mathbf{x})^\top / \|\nabla f(\mathbf{x})\|$ die Richtungsableitung $\nabla f(\mathbf{x})\mathbf{d}$ am kleinsten (Satz 10.2.4, Gleichheitsfall der Cauchy-Schwarz-Ungleichung). Lokal gibt es also keine bessere Richtung als die des negativen Gradienten.

Abstiegsrichtung. Für $\nabla f(\mathbf{x}) \neq \mathbf{0}^\top$ ist $\nabla f(\mathbf{x})(-\nabla f(\mathbf{x})^\top) = -\|\nabla f(\mathbf{x})\|^2 < 0$, und nach der Taylorentwicklung erster Ordnung (Abschnitt 10.8) sinkt f deshalb für alle hinreichend kleinen γ tatsächlich. Zwei Missverständnisse sind dabei zu vermeiden. Abstiegsrichtung ist $-\nabla f(\mathbf{x})^\top$ auch ohne Konvexität, solange der Gradient nicht verschwindet. Und *hin zum Minimum* zeigt sie im Allgemeinen nicht, wie das Zickzack weiter unten zeigt. Die Konvexität sorgt für etwas anderes: Jeder stationäre Punkt ist dann schon ein globales Minimum (Abschnitt 12.2), das Verfahren kann also nirgends sonst hängen bleiben.

Fixpunktiteration. (12.3.1) ist die Fixpunktiteration zu (12.2.3), deren Fixpunkte die stationä-

ren Punkte von f sind. Wie bei jeder Fixpunktiteration entscheidet die Schrittweite über die Konvergenz (Satz 12.1.16).

Beispiel 12.3.6 (Gradientenabstieg von Hand)

Minimieren wir $f(x) = (x - 2)^2 + 1$ mit Startwert $x^{(0)} = 4,5$ und Schrittweite $\gamma = 0,6$. Die Ableitung ist $f'(x) = 2x - 4$, das Minimum liegt bei $x^* = 2$, denn dort und nur dort verschwindet sie.

$$x^{(0)} = 4,5,$$

$$x^{(1)} = x^{(0)} - 0,6 f'(x^{(0)}) = 4,5 - 0,6 \cdot (2 \cdot 4,5 - 4) = 4,5 - 3 = 1,5,$$

$$x^{(2)} = x^{(1)} - 0,6 f'(x^{(1)}) = 1,5 - 0,6 \cdot (2 \cdot 1,5 - 4) = 1,5 + 0,6 = 2,1,$$

$$x^{(3)} = x^{(2)} - 0,6 f'(x^{(2)}) = 2,1 - 0,6 \cdot (2 \cdot 2,1 - 4) = 2,1 - 0,12 = 1,98.$$

Der erste Schritt schießt von 4,5 auf 1,5 weit über das Ziel hinaus, danach konvergiert die Iteration schnell. Die Fehler $x^{(k)} - x^*$ sind 2,5, -0,5, 0,1 und -0,02; sie wechseln in jedem Schritt das Vorzeichen und schrumpfen exakt auf ein Fünftel, der Faktor ist also -0,2.

Welche Schrittweiten führen ans Ziel, welche nicht?

Interaktiv: Die Schrittweite am eindimensionalen Beispiel

Die Tafel zeigt Beispiel 12.3.6 mit frei einstellbarem γ . Weil $f'' \equiv 2$ ist, liegen die beiden Schwellen direkt auf dem Reglerraster und lassen sich einzeln ansteuern; der Schrittregler läuft vorwärts wie rückwärts.

Schätzfrage. Ab welchem γ läuft die Iteration davon, statt sich dem Minimum zu nähern?

Lösung: 1 γ

Die Grenze ist $2/L$, hier also $\gamma = 1$. Dort pendelt die Folge; darüber wächst der Fehler.

Alles hängt am Fehlerfaktor $1 - \gamma L$ mit der Krümmung $L = f'' = 2$, den die Ablesetafel mitführt. Solange sein Betrag unter 1 bleibt, schrumpft der Fehler, bei negativem Faktor mit Sprüngen über das Minimum hinweg; bei Betrag 1 pendelt die Folge, darüber wächst der Fehler.

Bemerkung 12.3.7 (Zu klein, zu groß, gerade richtig)

Für eine Parabel $f(x) = \frac{L}{2}(x - x^*)^2$ mit Krümmung $L > 0$ ist $f'(x) = L(x - x^*)$, und (12.3.1) wird zu einer Rekursion für den Fehler $e^{(k)} := x^{(k)} - x^*$:

$$e^{(k+1)} = e^{(k)} - \gamma L e^{(k)} = (1 - \gamma L) e^{(k)}, \quad \text{also} \quad e^{(k)} = (1 - \gamma L)^k e^{(0)}. \quad (12.3.2)$$

Den Buchstaben L für die Krümmung wählen wir, weil dieselbe Größe im allgemeinen Fall als Lipschitz-Konstante (Definition 12.3.8) die Schrittweite begrenzt. Das Verhalten hängt allein vom Betrag von $1 - \gamma L$ ab:

- $0 < \gamma < 1/L$: Der Faktor liegt in $(0, 1)$, der Fehler behält sein Vorzeichen und schrumpft. Für sehr kleines γ liegt er dicht an 1, und das Verfahren kommt kaum voran.
- $\gamma = 1/L$: Der Faktor ist null, ein einziger Schritt trifft x^* exakt; das ist der Newton-Schritt aus Abschnitt 10.8.
- $1/L < \gamma < 2/L$: Der Faktor ist negativ mit Betrag unter 1; die Iterierten springen über das Minimum hinweg und nähern sich trotzdem.

- $\gamma = 2/L$: Der Betrag ist genau 1. Die Folge pendelt für immer zwischen zwei Punkten.
- $\gamma > 2/L$: Der Betrag übersteigt 1, jeder Schritt vergrößert den Fehler, das Verfahren divergiert. Und das, obwohl jeder einzelne Schritt in die richtige Richtung startet.

Im Beispiel 12.3.6 ist $L = 2$, also $1/L = 0,5$ und $2/L = 1$; mit $\gamma = 0,6$ landen wir im dritten Fall und lesen $1 - 0,6 \cdot 2 = -0,2$ ab. Das ist das Dilemma der Schrittweite: klein genug für Konvergenz, groß genug für Tempo. Im $\mathbb{R}^n$ wird es schwieriger, denn dort gibt es einen solchen Faktor je Krümmungsrichtung, und ein einziges γ muss sie alle zugleich bedienen.

Zwischenfrage: ein Schritt im $\mathbb{R}^2$

Sei $f(\mathbf{x}) = x_1^2 + x_2^2$ und $\mathbf{x}^{(0)} = (4, 3)^\top$ mit Schrittweite $\gamma = 0,25$. Wo liegt $\mathbf{x}^{(1)}$ nach einem Schritt des Gradientenabstiegs?

1. $\mathbf{x}^{(1)} = (2; 1,5)^\top$.

Antwort: Wahr

Der Gradient ist $\nabla f(\mathbf{x}) = (2x_1, 2x_2)$, an der Stelle $(4, 3)^\top$ also $\nabla f(\mathbf{x}^{(0)}) = (8, 6)$. Eingesetzt in (12.3.1): $\mathbf{x}^{(1)} = (4, 3)^\top - 0,25 \cdot (8, 6)^\top = (4, 3)^\top - (2; 1,5)^\top = (2; 1,5)^\top$.

2. $\mathbf{x}^{(1)} = (0, 0)^\top$, das Verfahren ist sofort fertig.

Antwort: Falsch

Das wäre der Treffer in einem Schritt, und den gibt es hier bei $\gamma = 1/L = 0,5$, nicht bei 0,25. Die Hesse-Matrix ist $\mathbf{H}_f = \text{diag}(2, 2)$, also $L = 2$; mit $\gamma = 0,25$ ist der Fehlerfaktor $1 - \gamma L = 0,5$, und die Iterierten halbieren nur ihren Abstand zum Ursprung: $(2; 1,5)$, $(1; 0,75)$, $(0,5; 0,375)$.

3. $\mathbf{x}^{(1)} = (3, 2)^\top$.

Antwort: Falsch

Hier ist von jeder Komponente 1 abgezogen worden, der Schritt hätte also in beiden Richtungen dieselbe Länge. Der Gradientenabstieg skaliert die Richtung aber nicht auf Einheitslänge; er nimmt den Gradienten so, wie er ist, und die Komponente mit dem größeren Betrag bekommt den längeren Schritt.

4. $\mathbf{x}^{(1)} = (8, 6)^\top$.

Antwort: Falsch

Das ist der Gradient selbst. Er ist ein Bestandteil des Schritts, nicht das Ergebnis; abgesehen davon zeigt $+\nabla f$ bergauf, und $(8, 6)^\top$ liegt weiter vom Minimum entfernt als der Startpunkt.

Wie schnell ist der Gradientenabstieg?

Bemerkung 12.3.7 hat die Schrittweite an die Krümmung gekoppelt. Für eine allgemeine Funktion brauchen wir dafür einen Begriff, der die Krümmung nach oben begrenzt, ohne zweite Ableitungen zu verlangen.

Definition 12.3.8 (Lipschitz-Stetigkeit)

Eine Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ heißt *Lipschitz-stetig* (Lipschitz continuous) mit *Lipschitz-Konstante* $L > 0$, falls

$$\|f(\mathbf{x}) - f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\| \quad \text{für alle } \mathbf{x}, \mathbf{y} \in \mathbb{R}^n.$$

Anschaulich: Die Funktionswerte ändern sich höchstens L -mal so schnell wie die Argumente. Je größer L , desto stärker darf f schwanken.

Für den Gradientenabstieg brauchen wir die Bedingung nicht für f , sondern für den Gradienten.

Bemerkung 12.3.9 (Lipschitz-stetiger Gradient und die Spektralnorm)

Wir nennen ∇f *Lipschitz-stetig mit Konstante L* , wenn Definition 12.3.8 auf die Abbildung $\mathbf{x} \mapsto \nabla f(\mathbf{x})^\top \in \mathbb{R}^n$ zutrifft:

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|.$$

Die Steigung von f ändert sich also nicht zu abrupt, die Krümmung ist beschränkt. Ist f auf einer konvexen offenen Menge zweimal stetig differenzierbar, so ist das gleichwertig zu

$$\|\mathbf{H}_f(\mathbf{x})\|_2 \leq L \quad \text{für alle } \mathbf{x}, \quad \text{also} \quad L_{\min} = \sup_{\mathbf{x}} \|\mathbf{H}_f(\mathbf{x})\|_2 = \sup_{\mathbf{x}} \max_i |\lambda_i(\mathbf{H}_f(\mathbf{x}))|, \quad (12.3.3)$$

wobei $L_{\min}$ die kleinste mögliche Lipschitz-Konstante bezeichnet; jede größere Zahl ist ebenfalls eine gültige Konstante.

Der Betrag ist wesentlich. Die kürzere Schreibweise $L = \sup_{\mathbf{x}} \lambda_{\max}(\mathbf{H}_f(\mathbf{x}))$ geht nur gut, solange f konvex ist, denn dann ist $\mathbf{H}_f$ positiv semidefinit und der größte Eigenwert zugleich der betragsgrößte. Für nicht konvexes f ist sie falsch: Für $f(x) = -x^2$ ist $f'(x) = -2x$ mit der exakten Lipschitz-Konstanten 2, während $\lambda_{\max}(\mathbf{H}_f) = -2$ nicht einmal positiv ist.

Vertiefung (optional): Lipschitz-Stetigkeit, Differenzierbarkeit und die Spektralnorm

Lipschitz-stetig und differenzierbar. Lipschitz-Stetigkeit ist deutlich stärker als Stetigkeit, mit Differenzierbarkeit aber ohne Zusatzannahmen nicht vergleichbar: $f(x) = |x|$ ist mit $L = 1$ Lipschitz-stetig und im Nullpunkt trotzdem nicht differenzierbar; $f(x) = x^2$ ist auf $\mathbb{R}$ differenzierbar, aber nicht global Lipschitz-stetig. Auf einem kompakten Intervall ist eine stetig differenzierbare Funktion wegen ihrer dort beschränkten Ableitung Lipschitz-stetig.

Spektralnorm und Eigenwerte. Für symmetrische Matrizen ist die Spektralnorm der betragsgrößte Eigenwert. Satz 3.3.7 berechnet $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$; für symmetrisches $\mathbf{A}$ ist $\mathbf{A}^\top \mathbf{A} = \mathbf{A}^2$, und der Spektralsatz gibt dieser Matrix die Eigenwerte λ_i^2 , also $\|\mathbf{A}\|_2 = \max_i |\lambda_i(\mathbf{A})|$. Dieselbe Umrechnung steckt hinter der Formel für κ_2 symmetrischer Matrizen in Abschnitt 3.5.

Eine Sattelrichtung genügt. Bei $\mathbf{H}_f = \text{diag}(0,5; -8)$ ist $L = 8$, das Supremum der größten Eigenwerte aber 0,5. In der nicht konvexen Optimierung, wo die Schrittweite an L hängt, wäre L mit der kürzeren Schreibweise um den Faktor 16 zu klein.

Satz 12.3.10 (Konvergenzrate bei konvexem f)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ konvex und differenzierbar mit Lipschitz-stetigem Gradienten und Lipschitz-Konstante L , und f nehme sein Minimum in $\mathbf{x}^*$ an. Dann gilt für den Gradientenabstieg (12.3.1) mit fester Schrittweite $\gamma \leq 1/L$

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq \frac{\|\mathbf{x}^{(0)} - \mathbf{x}^*\|^2}{2\gamma k}. \quad (12.3.4)$$

Bemerkung 12.3.11 (Was eine Rate der Ordnung $1/k$ praktisch heißt)

Die Schranke fällt wie $1/k$. Um den Fehler unter ε zu drücken, brauchen wir also $k \sim 1/\varepsilon$ Schritte, und das ist langsam: Eine Dezimalstelle mehr Genauigkeit kostet die zehnfache Iterationszahl. Newton-Raphson verdoppelt dagegen in seinem Einzugsbereich die Zahl der korrekten Stellen in jedem Schritt (Bemerkung 12.1.13).

(12.3.4) misst den Fehler im *Funktionswert*; über den Abstand zu $\mathbf{x}^*$ sagt die Schranke nichts, und die beiden können weit auseinanderliegen (Bemerkung 12.3.17). Außerdem setzt der Satz voraus, dass ein Minimierer existiert.

Schneller wird es, wenn die Krümmung nicht nur nach oben, sondern auch nach unten beschränkt ist. Die Funktion darf dann nirgends flach werden.

Definition 12.3.12 (Starke Konvexität)

Eine zweimal stetig differenzierbare Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}$ heißt *stark konvex* (μ -strongly convex) mit Parameter $\mu > 0$, falls

$$\mathbf{H}_f(\mathbf{x}) - \mu \mathbf{I} \succeq 0 \quad \text{für alle } \mathbf{x},$$

also $\lambda_{\min}(\mathbf{H}_f(\mathbf{x})) \geq \mu$ für alle $\mathbf{x}$. Der größte solche Wert ist $\mu = \inf_{\mathbf{x}} \lambda_{\min}(\mathbf{H}_f(\mathbf{x}))$, die kleinste vorkommende Krümmung.

Ohne Ableitungen formuliert heißt dasselbe: $\mathbf{x} \mapsto f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}\|^2$ ist konvex. Anschaulich steckt unter f an jeder Stelle eine Parabel mit Krümmung mindestens μ .

Satz 12.3.13 (Konvergenzrate bei starker Konvexität)

Sei f stark konvex mit Parameter $\mu > 0$ und habe einen Lipschitz-stetigen Gradienten mit Konstante L . Dann gilt für den Gradientenabstieg (12.3.1) mit Schrittweite $\gamma \leq 1/L$

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq \rho^k \cdot (f(\mathbf{x}^{(0)}) - f(\mathbf{x}^*)), \quad \rho = 1 - \gamma\mu < 1, \quad (12.3.5)$$

insbesondere $\rho = 1 - \mu/L$ für $\gamma = 1/L$.

Der Gewinn gegenüber Satz 12.3.10 ist groß. Dort brauchten wir $k \sim 1/\varepsilon$ Schritte, hier genügen wegen $\rho^k < \varepsilon$ schon $k \sim \log(1/\varepsilon)$: Jede weitere Dezimalstelle kostet nicht mehr das Zehnfache, sondern denselben festen Zuschlag. Diese Konvergenz heißt *linear*, weil der Fehler je Schritt um einen festen Faktor schrumpft. Die beste Rate, die der Satz hergibt, ist $\rho = 1 - \mu/L$ bei $\gamma = 1/L$; ein kleineres γ konvergiert nur mit $1 - \gamma\mu$.

Bemerkung 12.3.14 (Die Konditionszahl einer Funktion)

Die beiden Konstanten spannen die Krümmung von beiden Seiten ein,

$$\mu \mathbf{I} \preceq \mathbf{H}_f(\mathbf{x}) \preceq L \mathbf{I} \quad \text{für alle } \mathbf{x},$$

wobei die obere Hälfte für konvexes f gerade (12.3.3) ist. Das Verhältnis der beiden Konstanten heißt *Konditionszahl* der Funktion,

$$\kappa_f = \frac{L}{\mu} = \frac{\sup_{\mathbf{x}} \lambda_{\max}(\mathbf{H}_f(\mathbf{x}))}{\inf_{\mathbf{x}} \lambda_{\min}(\mathbf{H}_f(\mathbf{x}))}, \quad \text{damit} \quad \rho = 1 - \frac{\mu}{L} = \frac{\kappa_f - 1}{\kappa_f}.$$

Der Name passt zur Matrixkondition. Für eine Quadrik $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit positiv definitem $\mathbf{A}$ ist $\mathbf{H}_f = \mathbf{A}$ überall, also $L = \lambda_{\max}(\mathbf{A})$, $\mu = \lambda_{\min}(\mathbf{A})$ und

$$\kappa_f = \frac{\lambda_{\max}(\mathbf{A})}{\lambda_{\min}(\mathbf{A})} = \kappa_2(\mathbf{A}),$$

die Konditionszahl der Matrix aus Abschnitt 3.5. Für allgemeines f wandert die Hesse-Matrix mit $\mathbf{x}$, und κ_f misst das Verhältnis der extremen Krümmungen über den ganzen Definitionsbereich hinweg.

Wie teuer ein großes κ_f ist, lässt sich beziffern. Aus $\rho^k \leq 10^{-1}$ folgt $k \geq \ln 10 / (-\ln \rho)$, und weil $-\ln(1 - 1/\kappa_f) \approx 1/\kappa_f$ ist, wächst diese Zahl ungefähr proportional zu κ_f : Nach dieser Schranke kostet eine Dezimalstelle bei $\kappa_f = 10$ rund 21,9 Schritte, bei $\kappa_f = 20$ schon 44,9 und bei $\kappa_f = 100$ 229,1. Geometrisch heißt großes κ_f , dass die Höhenlinien lange, schmale Ellipsen sind; bei einer Quadrik gilt das überall, sonst in der Nähe eines Minimums, wo die Hesse-Matrix positiv definit ist. In solchen Tälern läuft der Gradientenabstieg im Zickzack: Er bewegt sich quer zum Tal, statt es entlangzulaufen.

Auf einer Quadrik lässt sich das ausrechnen: Der Fehler zerfällt nach den Eigenrichtungen von $\mathbf{H}_f$, und jede Richtung hat ihren eigenen Faktor $1 - \gamma \lambda_i$ (Satz 12.3.15). Die Schrittweite muss sich mit $\gamma < 2/L$ nach der steilsten Richtung richten, vorankommen müssen wir aber in der flachsten, wo der Faktor $1 - \gamma \mu$ nahe eins liegt.

Vertiefung (optional): Gradientenabstieg auf einer Quadrik: Fehlerzerlegung und Zahlenbeispiel

Auf einer Quadrik ist der folgende Satz schärfer als Satz 12.3.13: Er sagt, was tatsächlich passiert, statt nur eine Schranke zu geben, und deckt jede Schrittweite unterhalb der Divergenzgrenze ab.

Satz 12.3.15 (Gradientenabstieg auf einer Quadrik)

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ symmetrisch und positiv definit mit Eigenwerten $0 < \mu = \lambda_1 \leq \dots \leq \lambda_n = L$, und sei $f(\mathbf{x}) = \frac{1}{2}(\mathbf{x} - \mathbf{x}^*)^\top \mathbf{A}(\mathbf{x} - \mathbf{x}^*)$. Dann gilt für den Gradientenabstieg mit fester Schrittweite γ und den Fehler $\mathbf{e}^{(k)} := \mathbf{x}^{(k)} - \mathbf{x}^*$

$$\mathbf{e}^{(k)} = (\mathbf{I} - \gamma \mathbf{A})^k \mathbf{e}^{(0)} \quad \text{und} \quad f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq q^{2k} (f(\mathbf{x}^{(0)}) - f(\mathbf{x}^*)) \quad (12.3.6)$$

mit $q := \max_i |1 - \gamma \lambda_i|$. Die Iteration konvergiert genau dann für jeden Startpunkt, wenn $q < 1$ ist, und das trifft für $0 < \gamma < 2/L$ zu.

Beweis.

- (1) *Fehlerrekursion und Spektralzerlegung.* Der Gradient der quadratischen Form ist $\nabla f(\mathbf{x}) = (\mathbf{x} - \mathbf{x}^*)^\top \mathbf{A}$. Einsetzen in (12.3.1) und Abziehen von $\mathbf{x}^*$ auf beiden Seiten gibt $\mathbf{e}^{(k+1)} = (\mathbf{I} - \gamma \mathbf{A}) \mathbf{e}^{(k)}$, also nach k Schritten die erste Aussage von (12.3.6). Weil $\mathbf{A}$ symmetrisch ist, liefert der Spektralsatz eine Orthonormalbasis $\mathbf{v}_1, \dots, \mathbf{v}_n$ aus Eigenvektoren, und in ihr zerfällt der Fehler in n unabhängige Anteile: Mit $\mathbf{e}^{(0)} = \sum_i c_i \mathbf{v}_i$ ist

$$(\mathbf{I} - \gamma \mathbf{A}) \mathbf{v}_i = (1 - \gamma \lambda_i) \mathbf{v}_i \quad \implies \quad \mathbf{e}^{(k)} = \sum_{i=1}^n (1 - \gamma \lambda_i)^k c_i \mathbf{v}_i.$$

Jede Eigenrichtung hat also ihren eigenen Fehlerfaktor $1 - \gamma \lambda_i$; (12.3.2) ist der Fall $n = 1$.

der Gradient der quadratischen Form $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ ist für symmetrisches $\mathbf{A}$ gerade $2\mathbf{x}^\top \mathbf{A}$ (Abschnitt 10.6), und der Faktor $\frac{1}{2}$ kürzt die 2 weg; der Fehler erfüllt dieselbe Rekursion wie die Iterierten, weil $\mathbf{x}^$ konstant ist. $\mathbf{I} - \gamma \mathbf{A}$ hat dieselben Eigenvektoren wie $\mathbf{A}$, mit den Eigenwerten $1 - \gamma \lambda_i$*

- (2) *Der Funktionswert.* In derselben Basis ist wegen $\mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i$ und $\mathbf{v}_i^\top \mathbf{v}_j = \delta_{ij}$

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) = \frac{1}{2} \mathbf{e}^{(k)\top} \mathbf{A} \mathbf{e}^{(k)} = \frac{1}{2} \sum_{i=1}^n \lambda_i (1 - \gamma \lambda_i)^{2k} c_i^2 \leq q^{2k} \cdot \frac{1}{2} \sum_{i=1}^n \lambda_i c_i^2,$$

und $\frac{1}{2} \sum_i \lambda_i c_i^2$ ist gerade $f(\mathbf{x}^{(0)}) - f(\mathbf{x}^*)$. Das ist die zweite Aussage von (12.3.6).

Jeder einzelne Faktor $(1 - \gamma \lambda_i)^{2k}$ ist höchstens q^{2k} , und alle Summanden $\lambda_i c_i^2$ sind wegen $\lambda_i > 0$ nichtnegativ, dürfen also mit demselben Faktor abgeschätzt werden

- (3) Die Bedingung an γ . Es ist $q < 1$ genau dann, wenn $0 < \gamma \lambda_i < 2$ für alle i gilt, und weil alle λ_i positiv sind und L der größte ist, ist das gleichwertig zu $0 < \gamma < 2/L$. Ist umgekehrt $q \geq 1$, so fällt die Komponente in der zugehörigen Eigenrichtung nicht mehr gegen null.

Die kritische Bedingung stammt immer vom größten Eigenwert: $\gamma \lambda_i < 2$ für alle i ist dasselbe wie $\gamma L < 2$

□

Beispiel 12.3.16 (Warum der Satz eine Schranke ist und keine Formel)

Nehmen wir $\mathbf{A} = \text{diag}(1, 10)$, also $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 10 x_2^2)$, mit $\mathbf{x}^* = \mathbf{0}$. Dann ist $\mu = 1$, $L = 10$ und $\kappa_f = 10$.

Mit $\gamma = 1/L = 0,1$ sind die beiden Fehlerfaktoren $1 - \gamma \mu = 0,9$ und $1 - \gamma L = 0$. Die steile Richtung wird also in einem einzigen Schritt exakt getroffen, danach lebt der Fehler nur noch in der flachen Richtung und wird je Schritt mit 0,9 multipliziert. Nach Satz 12.3.15 fällt der Funktionswert deshalb ab dem zweiten Schritt auf exakt das $0,9^2 = 0,81$ -fache. Satz 12.3.13 verspricht an derselben Stelle nur $\rho = 1 - \mu/L = 0,9$. Beides ist richtig, denn (12.3.5) ist eine obere Schranke: Der beobachtete Verlauf darf schneller sein, und hier ist er es um genau den Faktor ρ je Schritt. Die Lesart „der Fehler fällt genau wie ρ^k “ ist falsch.

Mit $\gamma = 0,18$ dagegen sind die Faktoren 0,82 und $-0,8$: Die steile Richtung wechselt in jedem Schritt das Vorzeichen, die flache kommt kaum voran. Das ist das Zickzack aus Bemerkung 12.3.14.

Mit $\gamma = 0,2 = 2/L$ pendelt die zweite Komponente zwischen zwei Werten, ohne kleiner zu werden, und darüber divergiert sie.

Wie teuer schlechte Kondition wird, lässt sich zählen.

Interaktiv: Zickzack im schmalen Tal

Die obere Tafel zeigt die Höhenlinien von $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + \kappa x_2^2)$ und den Weg der Iterierten, die mittlere den Verlauf von $f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*)$ auf logarithmischer Skala, daneben steht dieselbe Quadrik als Fläche. Der Regler für γ ist in Vielfachen von $2/L$ geeicht, damit die Schwellen unabhängig von κ an derselben Stelle liegen.

Schätzfrage. Bei $\kappa = 10$ braucht der Abstieg in der Voreinstellung 35 Schritte, bis f auf ein Millionstel gefallen ist. Wie viele bei $\kappa = 100$?

Lösung: 336 Schritte

Der Aufwand wächst ungefähr proportional zu κ : 35 Schritte bei $\kappa = 10$, 88 bei $\kappa = 25$ und 336 bei $\kappa = 100$. Die Ablesetafel des Widgets nennt die Zahl zu jedem eingestellten κ .

Der Aufwand wächst ungefähr proportional zur Kondition. Bei $\kappa = 1$ sind die Höhenlinien Kreise, der negative Gradient zeigt direkt auf das Minimum, und mit einem halben Anteil ist das Verfahren nach einem Schritt fertig. Bei $\kappa = 10$ und $\gamma = 1/L$ zeigt die Tafel den gemessenen Quotienten 0,81 gegen die gestrichelte Schranke $\rho = 0,9$ aus Satz 12.3.13: Der Satz gibt eine obere Schranke, das Verfahren darf schneller sein. Bei einem Anteil um 0,9 entsteht das Zickzack; die Schranke fehlt dann, weil der Satz $\gamma \leq 1/L$ voraussetzt.

Wann hören wir auf?

Die Iteration (12.3.1) läuft von sich aus ewig. Brauchbare Abbruchregeln messen etwas, das wir ausrechnen können; der Abstand $\|\mathbf{x}^{(k)} - \mathbf{x}^*\|$ gehört nicht dazu, denn $\mathbf{x}^*$ ist gerade das Gesuchte.

Bemerkung 12.3.17 (Drei Abbruchkriterien und ihre Grenzen)

1. Der Gradient ist klein: $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon_{\text{grad}}$.
2. Der Funktionswert stagniert: $|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|/|f(\mathbf{x}^{(k)})| < \varepsilon_f$.
3. Das Budget ist aufgebraucht: $k > k_{\text{max}}$.

Üblich sind $\varepsilon_{\text{grad}} \approx 10^{-6}$ bis 10^{-8} und $k_{\text{max}} \approx 1000$ bis $10\,000$, und üblich ist es auch, mehrere Kriterien zu kombinieren: Die ersten beiden sagen etwas über die Lösung, das dritte verhindert eine Endlosschleife, wenn keines der anderen greift.

Bei schlecht konditionierten oder nicht stark konvexen Problemen können die Kriterien versagen. Für stark konvexes f gilt zwar $\|\nabla f(\mathbf{x})\| \geq \mu \|\mathbf{x} - \mathbf{x}^*\|$ und damit $\|\mathbf{x} - \mathbf{x}^*\| \leq \|\nabla f(\mathbf{x})\|/\mu$, doch diese Schranke ist nur so gut wie μ . Ein Beispiel: $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 10^{-8}x_2^2)$ hat an der Stelle $\mathbf{x} = (0; 10)^\top$ den Gradienten $\nabla f = (0; 10^{-7})$, unterschreitet also jede Gradientenschranke ab 10^{-6} , und liegt trotzdem 10 Einheiten vom Minimum entfernt. Der Funktionswert ist dort allerdings schon fast optimal, nämlich $f - f^* = 5 \cdot 10^{-7}$. Das ist die korrekte Auskunft: In einer flachen Richtung ist die Stelle des Minimums schlecht bestimmt, sein Wert dagegen gut. Das zweite Kriterium ist noch schwächer: Kleiner Fortschritt kann auch an einem zu kleinen γ liegen, und für $f(\mathbf{x}^{(k)})$ nahe null ist der relative Quotient nicht aussagekräftig. Am Ende lohnt deshalb die Prüfung, ob der Gradient *relativ zur Skala des Problems* klein ist.

Schrittweitsuche: die Armijo-Bedingung

Eine feste Schrittweite ist immer ein Kompromiss, und L kennen wir in der Regel nicht. Naheliegender ist deshalb, γ in jedem Schritt neu zu bestimmen, klein genug für sicheren Abstieg und groß genug für Fortschritt. Diese Suche auf der Geraden $\gamma \mapsto \mathbf{x}^{(k)} + \gamma \mathbf{d}$ heißt *Liniensuche* (line search). Den exakten Minimierer dort zu bestimmen, wäre wieder ein Optimierungsproblem; billiger ist eine Bedingung, die nur „genügend Abstieg“ verlangt. Der Buchstabe ρ steht im folgenden Algorithmus für den Faktor, um den die Schrittweite verkleinert wird, nicht für die Konvergenzrate aus Satz 12.3.13.

Algorithmus 12.3.18 (Backtracking-Liniensuche nach Armijo)

Gegeben seien die aktuelle Stelle $\mathbf{x}^{(k)}$, die Suchrichtung $\mathbf{d} = -\nabla f(\mathbf{x}^{(k)})^\top$ und Parameter $c \in (0, 1)$ sowie $\rho \in (0, 1)$.

1. Starte mit $\gamma = 1$.
2. Solange

$$f(\mathbf{x}^{(k)} + \gamma \mathbf{d}) > f(\mathbf{x}^{(k)}) + c \gamma \nabla f(\mathbf{x}^{(k)}) \mathbf{d}, \quad (12.3.7)$$

setze $\gamma \leftarrow \rho \gamma$.

3. Gib γ zurück und setze $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \gamma \mathbf{d}$.

Bemerkung 12.3.19 (Was die Armijo-Bedingung fordert)

Das Vorzeichen. Mit $\mathbf{d} = -\nabla f(\mathbf{x}^{(k)})^\top$ ist

$$\nabla f(\mathbf{x}^{(k)}) \mathbf{d} = -\|\nabla f(\mathbf{x}^{(k)})\|^2 < 0 \quad \text{für } \nabla f(\mathbf{x}^{(k)}) \neq \mathbf{0}^\top,$$

der Zusatzterm $c\gamma \nabla f(\mathbf{x}^{(k)}) \mathbf{d}$ auf der rechten Seite von (12.3.7) ist also *negativ*, und die rechte Seite liegt unter dem alten Funktionswert. Der Funktionswert muss um einen Betrag sinken, der proportional zu γ und zum Quadrat der Gradientennorm ist: Wo es steil bergab geht, wird viel verlangt, wo es flach ist, wenig.

Die geometrische Lesart. Die Gerade $\gamma \mapsto f(\mathbf{x}^{(k)}) + \gamma \nabla f(\mathbf{x}^{(k)}) \mathbf{d}$ ist die Tangente an den Schnitt $\varphi(\gamma) = f(\mathbf{x}^{(k)} + \gamma \mathbf{d})$ im Nullpunkt. Die Armijo-Gerade ist dieselbe Gerade, um den Faktor c flacher gelegt. Gefordert wird, unter ihr zu bleiben; je kleiner c , desto bescheidener die Forderung.

Warum die Schleife endet. Nach Taylor ist $\varphi(\gamma) = \varphi(0) + \gamma \varphi'(0) + o(\gamma)$ mit $\varphi'(0) = \nabla f(\mathbf{x}^{(k)}) \mathbf{d} < 0$; für kleine γ liegt die linke Seite von (12.3.7) also nahe bei $\varphi(0) + \gamma \varphi'(0)$ und damit unter der rechten, weil $\gamma \varphi'(0) < c \gamma \varphi'(0)$ für $c < 1$ gilt. Solange der Gradient nicht verschwindet, endet die Schleife deshalb nach endlich vielen Verkleinerungen.

Typische Parameter. $c = 10^{-4}$ und $\rho = 0,5$, die Schrittweite wird also halbiert. Mit so kleinem c ist die Armijo-Gerade praktisch waagrecht, und die Bedingung heißt kaum mehr als „der Funktionswert muss wirklich sinken“; das macht sie robust, denn verworfen wird nur ein Schritt, der über das Ziel hinausschießt.

Ausblick. Quasi-Newton-Verfahren wie BFGS benutzen dieselbe Backtracking-Schleife mit einer anderen Suchrichtung (Abschnitt 12.4).

Wie oft muss die Schleife halbieren, bis sie eine Schrittweite akzeptiert?

Interaktiv: Die Armijo-Bedingung am Schnitt

Die drei Kurven: der Schnitt $\varphi(\gamma)$ in Violett, die Tangente in Orange und die Armijo-Gerade gestrichelt in Grau. Die roten Punkte sind verworfene Probeschritte, der blaue ist der akzeptierte. Als Zielfunktion dient die Quadrik $f(\mathbf{x}) = \frac{1}{2}x_1^2 + \frac{5}{2}x_2^2$ mit $\kappa_f = 5$, als Suchrichtung wie immer $\mathbf{d} = -\nabla f(\mathbf{x})^\top$.

Interaktives Element — nur in der Web-Fassung

In der Voreinstellung wird $\gamma = 1$ verworfen und $\gamma = 0,5$ angenommen, obwohl der exakte Minimierer bei $\gamma^* = 1/3$ läge; der billige Kompromiss genügt, weil ohnehin ein nächster Schritt folgt. Mit $c = 0,3$ wird die Forderung steiler, und erst nach einer zweiten Halbierung wird $\gamma = 0,25$ angenommen. Über alle Reglerstellungen hinweg sind höchstens 16 Halbierungen nötig.

Selbsttest

1. Für $f(\mathbf{x}) = x_1^2 + 4x_2^2$ mit $\mathbf{x}^{(0)} = (2, 1)^\top$ und $\gamma = 0,25$ ist $\mathbf{x}^{(1)} = (1, -1)^\top$.

Antwort: Wahr

Der Gradient ist $\nabla f(\mathbf{x}) = (2x_1, 8x_2)$, an der Stelle $(2, 1)^\top$ also $(4, 8)$. Damit ist $\mathbf{x}^{(1)} = (2, 1)^\top - 0,25 \cdot (4, 8)^\top = (1, -1)^\top$.

2. Auf der Quadrik mit $\mathbf{H}_f = \text{diag}(1, 10)$ fällt der Funktionswert mit $\gamma = 1/L$ in jedem Schritt genau auf das $\rho = 0,9$ -fache.

Antwort: Falsch

(12.3.5) ist eine obere Schranke, keine Gleichung. Tatsächlich fällt der Wert ab dem zweiten Schritt auf das 0,81-fache, also auf das ρ^2 -fache: Die steile Richtung ist wegen $1 - \gamma L = 0$ schon nach dem ersten Schritt erledigt, und in der flachen schrumpft der Fehler mit 0,9, der Funktionswert also mit $0,9^2$.

3. Auch für nicht konvexes f ist $-\nabla f(\mathbf{x})^\top$ eine Abstiegsrichtung, solange $\nabla f(\mathbf{x}) \neq \mathbf{0}^\top$ ist.

Antwort: Wahr

Es ist $\nabla f(\mathbf{x})(-\nabla f(\mathbf{x})^\top) = -\|\nabla f(\mathbf{x})\|^2 < 0$, und daraus folgt mit der Taylorentwicklung erster Ordnung, dass f für hinreichend kleine Schritte sinkt. Konvexität wird dafür nicht gebraucht (Bemerkung 12.3.5).

4. Ist $\|\nabla f(\mathbf{x}^{(k)})\| < 10^{-6}$, so liegt $\mathbf{x}^{(k)}$ nahe am Minimum.

Antwort: Falsch

Die Schranke $\|\mathbf{x} - \mathbf{x}^*\| \leq \|\nabla f(\mathbf{x})\| / \mu$ hängt an der kleinsten Krümmung μ und ist bei kleinem μ unbrauchbar. Für $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + 10^{-8}x_2^2)$ ist der Gradient in $(0; 10)^\top$ nur 10^{-7} lang, der Abstand zum Minimum aber 10 (Bemerkung 12.3.17).

5. Für einen Lipschitz-stetigen Gradienten genügt $L = \sup_{\mathbf{x}} \lambda_{\max}(\mathbf{H}_f(\mathbf{x}))$ als Konstante.

Antwort: Falsch

Gebraucht wird die Spektralnorm, also der betragsgrößte Eigenwert $\sup_{\mathbf{x}} \max_i |\lambda_i|$. Bei konvexem f fällt beides zusammen, weil die Hesse-Matrix dann positiv semidefinit ist; sonst nicht. Für $f(x) = -x^2$ ist die exakte Konstante 2, während der größte Eigenwert -2 beträgt (Bemerkung 12.3.9).

6. Aus dem voreingestellten Simplex fällt im Nelder-Mead-Widget in vierzig Schritten kein einziger Schrumpfschritt.

Antwort: Wahr

Der Zugsähler steht nach vierzig Schritten auf 13 Reflexionen, 4 Expansionen, 23 Kontraktionen und null Schrumpfschritten. Der Schrumpfschritt ist der teuerste der vier Züge aus Algorithmus 12.3.2, und dass er hier gar nicht gebraucht wird, ist der Grund für die verhältnismäßig guten Kosten.

7. Nelder-Mead braucht pro Iteration $O(n^2)$ Funktionsauswertungen.

Antwort: Falsch

Es sind $O(n)$: In einem gewöhnlichen Schritt werden nur ein oder zwei neue Punkte ausgewertet, erst der Schrumpfschritt kostet n neue Ecken. Langsam wird das Verfahren in hoher Dimension nicht wegen der Kosten pro Iteration, sondern wegen der Zahl der Iterationen (Bemerkung 12.3.3).

8. Verdoppeln wir κ_f , so verdoppelt sich ungefähr die Schrittzahl, die Satz 12.3.13 für dieselbe Genauigkeit garantiert.

Antwort: Wahr

Die garantierte Zahl der Schritte je Dezimalstelle ist $\ln 10 / (-\ln \rho)$ mit $\rho = 1 - 1/\kappa_f$, und wegen $-\ln(1 - 1/\kappa_f) \approx 1/\kappa_f$ wächst sie näherungsweise linear in κ_f : 21,9 bei $\kappa_f = 10$, 44,9 bei 20, 229,1 bei 100 und 459,4 bei 200 (Bemerkung 12.3.14). Der tatsächliche Verlauf darf schneller sein, wie das Widget „Zickzack im schmalen Tal“ zeigt, langsamer aber nicht.

Vertiefung: Heath §6.5.1 behandelt die direkten Suchverfahren einschließlich Nelder-Mead, §6.5.2 den steilsten Abstieg samt Zickzack-Bild, und die eindimensionalen Verfahren hinter der Liniensuche stehen in §6.4.

12.4 Newton, Quasi-Newton und SGD

Krümmung statt nur Steigung

Der Gradientenabstieg aus Abschnitt 12.3 benutzt von f nur die Steigung: Er ersetzt die Funktion an der aktuellen Stelle durch ihre Tangentialebene und geht bergab. Wie weit er gehen darf, lässt sich daraus nicht ablesen; daher die Schrittweite γ und der Zickzack in engen Tälern.

Die nächstbessere Näherung liefert die Taylorentwicklung zweiter Ordnung. Für zweimal stetig differenzierbares f gilt sie mit einem Restterm $o(\|\mathbf{h}\|^2)$ (Satz 10.8.7), in Gradient und Hesse-Matrix ausgeschrieben:

$$f(\mathbf{x} + \mathbf{h}) \approx T_2(\mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}. \quad (12.4.1)$$

Statt einer Geraden legen wir also eine Parabel an, im $\mathbb{R}^n$ eine quadratische Form über dem aktuellen Punkt. Anders als eine Gerade hat eine nach oben geöffnete Parabel einen tiefsten Punkt, und den können wir ausrechnen.

Dazu leiten wir (12.4.1) nach dem Zuwachs $\mathbf{h}$ ab. Der Gradient ist in unserer Konvention eine Zeile (Abschnitt 10.2); der lineare Term steuert $\nabla f(\mathbf{x})$ bei, und die quadratische Form hat nach Beispiel 10.6.5 den Gradienten $\mathbf{h}^\top (\mathbf{H}_f + \mathbf{H}_f^\top)/2 = \mathbf{h}^\top \mathbf{H}_f$, denn die Hesse-Matrix ist nach dem Satz von Schwarz (Satz 10.7.4) symmetrisch:

$$\nabla_{\mathbf{h}} T_2(\mathbf{h}) = \nabla f(\mathbf{x}) + \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \stackrel{!}{=} \mathbf{0}^\top.$$

Beide Seiten sind Zeilenvektoren; Auflösen nach $\mathbf{h}^\top$ und Transponieren liefert den gesuchten Schritt. In Spalten gerechnet, als $\nabla f(\mathbf{x})^\top + \mathbf{H}_f(\mathbf{x}) \mathbf{h} = \mathbf{0}$, kommt derselbe Schritt heraus, nur mischen dürfen wir die beiden Konventionen nicht.

Algorithmus 12.4.1 (Newton-Verfahren für die Optimierung)

Gegeben seien $f : \mathbb{R}^n \rightarrow \mathbb{R}$ zweimal stetig differenzierbar und ein Startpunkt $\mathbf{x}^{(0)}$. Für $k = 0, 1, 2, \dots$ wiederhole:

1. Berechne $\nabla f(\mathbf{x}^{(k)})$ und $\mathbf{H}_f(\mathbf{x}^{(k)})$.
2. Setze

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \mathbf{H}_f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})^\top, \quad (12.4.2)$$

sofern $\mathbf{H}_f(\mathbf{x}^{(k)})$ invertierbar ist.

3. Brich ab, sobald $\|\nabla f(\mathbf{x}^{(k)})\|$ oder die Schrittlänge $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|$ unter eine vorgegebene Schranke fällt, wie beim Gradientenabstieg in Abschnitt 12.3.

Bemerkung 12.4.2 (Was der Schritt voraussetzt und wie wir ihn rechnen)

Die Hesse-Matrix muss invertierbar sein. Sonst hat die quadratische Näherung keinen kritischen Punkt oder einen ganzen affinen Unterraum davon, und (12.4.2) ist nicht definiert. Konvexität sichert das nicht: Sie liefert nur positive Semidefinitheit (Abschnitt 11.4), und selbst strikte Konvexität reicht nicht, wie $f(x) = x^4$ im Nullpunkt zeigt. Invertierbarkeit, bei konvexem f also eine positiv definite Hesse-Matrix, ist eine eigene Annahme.

Die Inverse ist eine Schreibweise, keine Rechenanweisung. Gerechnet wird nicht $\mathbf{H}_f^{-1}$, sondern das lineare Gleichungssystem

$$\mathbf{H}_f(\mathbf{x}^{(k)}) \mathbf{d}^{(k)} = -\nabla f(\mathbf{x}^{(k)})^\top, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}.$$

Das ist billiger und stabiler (Bemerkung 5.2.1). Ist $\mathbf{H}_f$ positiv definit, so ist die Cholesky-Zerlegung aus Abschnitt 5.4 das Standardverfahren, und ob sie gelingt, ist zugleich die Probe auf Definitheit. Kurz: *Invertiere niemals eine Matrix.*

Newton-Raphson und Newton-Optimierung sind dasselbe Verfahren**Bemerkung 12.4.3 (Eine Vorschrift, zwei Spalten)**

Newton-Raphson für Nullstellen und das Newton-Verfahren für Minima, nebeneinander:

	Nullstellensuche	Optimierung
Aufgabe	löse $f(x) = 0$	löse $\nabla f(\mathbf{x}) = \mathbf{0}^\top$
Schritt	$x^{(k+1)} = x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$	$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \mathbf{H}_f^{-1} \nabla f(\mathbf{x}^{(k)})^\top$

Setzen wir $\mathbf{g}(\mathbf{x}) := \nabla f(\mathbf{x})^\top$, so ist die Optimierung die Nullstellensuche für $\mathbf{g}: \mathbb{R}^n \rightarrow \mathbb{R}^n$. Deren Jacobimatrix ist nach Definition 10.7.3 die Hesse-Matrix, $\mathbf{J}_g = \mathbf{H}_f$, und der mehrdimensionale Newton-Raphson-Schritt $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \mathbf{J}_g^{-1} \mathbf{g}$ aus Abschnitt 12.1 ist wörtlich (12.4.2). Alles, was wir über Newton-Raphson wissen, gilt deshalb weiter: Unter ausreichender Glattheit, etwa einer lokal Lipschitz-stetigen Hesse-Matrix, konvergiert das Verfahren nahe einer Lösung mit invertierbarer Hesse-Matrix quadratisch. Es bleiben die Empfindlichkeit gegen schlechte Startpunkte und das Problem einer (fast) singulären Hesse-Matrix, das Gegenstück zur verschwindenden Ableitung im Nenner.

Newton Schritt für Schritt

Vertiefung (optional): Newton an einer nicht-quadratischen Funktion: Zahlenbeispiel

Beispiel 12.4.4 (Newton auf einer nicht-quadratischen Funktion)

Wir minimieren

$$f(x) = x - 2 \ln x, \quad x > 0,$$

mit $f'(x) = 1 - 2/x$ und $f''(x) = 2/x^2 > 0$. Die Funktion ist also strikt konvex, und $f'(x) = 0$ hat die einzige Lösung $x^* = 2$ (Abschnitt 12.2). Bis auf eine additive Konstante ist f die negative Log-Dichte einer Gammaverteilung mit Formparameter 3 und Rate 1, und 2 ist deren Modus. Der Newton-Schritt (12.4.2) wird in einer Dimension zu

$$x^{(k+1)} = x^{(k)} - \frac{f'(x^{(k)})}{f''(x^{(k)})} = x^{(k)} - \frac{1 - 2/x^{(k)}}{2/(x^{(k)})^2} = \frac{x^{(k)}(4 - x^{(k)})}{2}.$$

Von $x^{(0)} = 1$ aus laufen die Iterierten so:

k	$x^{(k)}$	$e_k := x^{(k)} - x^* $	e_k/e_{k-1}^2
0	1,0000000000	$1,00 \cdot 10^0$	-
1	1,5000000000	$5,00 \cdot 10^{-1}$	0,500
2	1,8750000000	$1,25 \cdot 10^{-1}$	0,500
3	1,9921875000	$7,81 \cdot 10^{-3}$	0,500
4	1,9999694824	$3,05 \cdot 10^{-5}$	0,500
5	1,9999999995	$4,66 \cdot 10^{-10}$	0,500

Die letzte Spalte ist exakt $1/2$, denn aus der Schrittformel folgt

$$x^{(k+1)} - 2 = \frac{4x^{(k)} - (x^{(k)})^2 - 4}{2} = -\frac{(x^{(k)} - 2)^2}{2},$$

also $e_{k+1} = e_k^2/2$ in jedem einzelnen Schritt. Der Faktor $1/2$ ist das Gegenstück zu der Konstanten aus Bemerkung 12.1.13: Weil wir Newton-Raphson auf f' anwenden, steigt jede Ableitung um eine Ordnung, und aus $|f''|/(2|f'|)$ wird $|f'''(x^*)|/(2f''(x^*)) = 0,5/(2 \cdot 0,5) = 0,5$.

Die Aussage gilt nur lokal. Für $x^{(0)} = 4$ liefert die Schrittformel 0, für $x^{(0)} = 4,5$ sogar $-1,125$. Beide Male landet der erste Schritt außerhalb von $(0, \infty)$, wo f nicht erklärt ist.

Interaktiv: Die Parabel am Startpunkt

Orange liegt das quadratische Modell (12.4.1) am aktuellen Punkt, sein Scheitel ist die nächste Iterierte, und die blauen Punkte zeigen den Verlauf der Iteration. Voreingestellt ist die strikt konvexe Funktion $f(x) = x - 2 \ln x$ auf $x > 0$ mit Minimum bei 2, gestartet bei $x^{(0)} = 1$ (Zahlentabelle in Beispiel 12.4.4); der zweite Menüpunkt ist die nicht-konvexe Funktion aus Bemerkung 12.4.5.

Schätzfrage. Wo landet Newton auf der nicht-konvexen Funktion, wenn wir bei $x^{(0)} = 0,5$ starten?

Lösung: *max*

Der zweite Menüpunkt und der Startpunktregler zeigen es in einem einzigen Schritt: 0,5 landet exakt auf dem lokalen Maximum bei 0, denn dort ist $f'' = -2,25$, die Modellparabel öffnet nach unten, und ihr Scheitel ist ein Hochpunkt.

Auf der konvexen Funktion verlässt der erste Schritt ab $x^{(0)} = 4$ den Definitionsbereich. Auf der nicht-konvexen führt -2 in das lokale Minimum bei -1 und 2,5 in das globale bei 2. Bei $x^{(0)} = 1,2$ ist $f'' = -0,08$ fast null: Der erste Schritt springt nach $-25,2$, und 14 Schritte später steht die Iteration im lokalen Minimum bei -1 , obwohl der Startpunkt näher am globalen lag.

Bemerkung 12.4.5 (Newton bei nicht-konvexen Funktionen)

(12.4.2) sucht Nullstellen des Gradienten, nicht Minima. Bei konvexem f fällt beides zusammen (Abschnitt 12.2), sonst nicht.

Ein lokales statt des globalen Minimums. Die nicht-konvexe Funktion im Widget, $f(x) = x^4/4 - x^3/3 - x^2 + 2$, hat die kritischen Punkte $-1, 0$ und 2 : bei -1 ein lokales Minimum mit $f(-1) \approx 1,583$, bei 2 das globale mit $f(2) \approx -0,667$. Welches der beiden Täler die Iteration findet, entscheidet allein der Startpunkt. Das gilt für alle Verfahren dieses Kapitels, denn sie benutzen nur lokale Information.

Ein Sattelpunkt oder ein Maximum. Ist $\mathbf{H}_f(\mathbf{x}^{(k)})$ indefinit, so ist der Scheitel der Näherung ein Sattel, ist sie negativ definit, ein Maximum, und der Schritt läuft genauso dorthin wie sonst ins Minimum (Abschnitt 12.2). Im Widget zeigt das der Startpunkt **0,5**.

Praktische Fassungen erzwingen deshalb einen Abstiegsschritt: Sie addieren $\mu\mathbf{I}$, bis $\mathbf{H}_f + \mu\mathbf{I}$ positiv definit ist, begrenzen die Schrittlänge (Trust-Region) oder dämpfen mit einer Linien-suche (Abschnitt 12.3). Das hilft gegen Schritte zu Sattelpunkten oder Maxima, ein globales Minimum garantiert es bei nicht-konvexem f aber nicht.

Newton gegen Gradientenabstieg**Beispiel 12.4.6 (Newton und Gradientenabstieg an einer Parabel)**

Wir minimieren $f(x) = x^2$ mit $f'(x) = 2x$, $f''(x) = 2$ und Startwert $x^{(0)} = 4$.

Gradientenabstieg mit $\gamma = 0,4$:

$$x^{(1)} = 4 - 0,4 \cdot 8 = 0,8,$$

$$x^{(2)} = 0,8 - 0,4 \cdot 1,6 = 0,16,$$

$$x^{(3)} = 0,16 - 0,4 \cdot 0,32 = 0,032.$$

Jeder Schritt multipliziert die Iterierte mit $1 - 2\gamma = 0,2$. Das ist lineare Konvergenz: Die Zahl der richtigen Stellen wächst um einen festen Betrag pro Schritt, erreicht wird die Null nie.

Newton:

$$x^{(1)} = 4 - \frac{8}{2} = 0.$$

Ein Schritt, und wir stehen exakt im Minimum. Für eine quadratische Funktion ist die Näherung (12.4.1) exakt (Bemerkung 10.8.10), ihr Scheitel ist der kritische Punkt der Funktion selbst. Bei positiv definiter Hesse-Matrix ist das das Minimum, und Newton trifft es von jedem Startpunkt aus in einem Schritt; sonst trifft derselbe Schritt den Sattel oder das Maximum (Bemerkung 12.4.5).

Bemerkung 12.4.7 (Kondition und Kosten des Newton-Schritts)

Die Schrittzahl des Gradientenabstiegs hängt an der Konditionszahl $\kappa(\mathbf{H}_f)$ (Abschnitt 12.3), die des Newton-Verfahrens nicht. Newton benutzt die Krümmung, statt sie zu schätzen: Sein Schritt ist gegen lineare Koordinatenwechsel unempfindlich, und schlechte Kondition ist ein ungünstig gewähltes Koordinatensystem.

Die Kosten liegen an anderer Stelle. Ein Newton-Schritt braucht die $n(n+1)/2$ zweiten Ableitungen, ihren Speicher der Größenordnung n^2 und eine Zerlegung der Größenordnung n^3 (Abschnitt 5.3). Für $n = 10\,000$ Parameter, in der Statistik keine ungewöhnliche Zahl, sind

das 10^8 Einträge allein für die Matrix.

Vertiefung (optional): Warum Newton die Kondition nicht spürt: affine Invarianz

Unabhängig von der Kondition ist die Zahl der Newton-Schritte, nicht die Rechnung darin: Numerisch bleibt die Kondition spürbar, denn das lineare System aus Bemerkung 12.4.2 wird mit $\kappa(\mathbf{H}_f)$ schlechter konditioniert, und der gelöste Schritt trägt diesen Fehler weiter (Abschnitt 4.2).

Dass die Schrittzahl nicht an κ hängt, liegt an der affinen Invarianz. Rechnen wir in neuen Koordinaten $\mathbf{x} = \mathbf{A}\mathbf{y}$ mit invertierbarem $\mathbf{A}$, so wird aus dem Gradienten $\nabla f\mathbf{A}$ und aus der Hesse-Matrix $\mathbf{A}^\top \mathbf{H}_f \mathbf{A}$. Im Newton-Schritt heben sich die Faktoren weg,

$$-(\mathbf{A}^\top \mathbf{H}_f \mathbf{A})^{-1} (\nabla f \mathbf{A})^\top = -\mathbf{A}^{-1} \mathbf{H}_f^{-1} \nabla f^\top,$$

und übrig bleibt das Bild des alten Schrittes. Beim Gradientenschritt $-\gamma (\nabla f \mathbf{A})^\top = -\gamma \mathbf{A}^\top \nabla f^\top$ bleibt der Faktor $\mathbf{A}^\top$ dagegen stehen, und er trägt die Kondition.

Quasi-Newton: die Krümmung schätzen statt rechnen

Newton ist schnell und teuer, der Gradientenabstieg billig und langsam; die Quasi-Newton-Verfahren liegen dazwischen. Sie gewinnen die Krümmungsinformation aus den Gradienten, die ohnehin anfallen.

Algorithmus 12.4.8 (Quasi-Newton-Schritt)

Gegeben seien $f : \mathbb{R}^n \rightarrow \mathbb{R}$ stetig differenzierbar, ein Startpunkt $\mathbf{x}^{(0)}$ und eine Startmatrix $\mathbf{B}_0$, meist $\mathbf{B}_0 = \mathbf{I}$. Für $k = 0, 1, 2, \dots$ setze

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \gamma_k \mathbf{B}_k \nabla f(\mathbf{x}^{(k)})^\top, \quad (12.4.3)$$

wobei $\mathbf{B}_k \approx \mathbf{H}_f(\mathbf{x}^{(k)})^{-1}$ aus den bisherigen Schritten geschätzt wird und die Schrittweite γ_k aus einer Liniensuche stammt (Abschnitt 12.3).

Die Schrittweite γ_k ist nötig: Ohne sie ist der erste Schritt aus $\mathbf{B}_0 = \mathbf{I}$ ein ungebremster Gradientenschritt, der den Funktionswert erhöhen kann; das Widget unten zeigt es.

(12.4.3) ersetzt die exakte inverse Hesse-Matrix aus (12.4.2) durch eine Näherung, die schon da ist; statt $O(n^3)$ kostet die Richtung dann nur eine Matrix-Vektor-Multiplikation. Die Verfahren der Familie unterscheiden sich darin, wie sie $\mathbf{B}_k$ bauen, häufig als Diagonalmatrix oder als Einheitsmatrix plus eine Korrektur kleinen Ranges, weil sich beides billig speichern und anwenden lässt.

Woher kommt $\mathbf{B}_k$? In einer Dimension ist die zweite Ableitung die Ableitung der ersten, und die schätzen wir durch einen Differenzenquotienten aus zwei benachbarten Werten:

$$f''(x) \approx \frac{f'(x^{(k+1)}) - f'(x^{(k)})}{x^{(k+1)} - x^{(k)}}.$$

Im $\mathbb{R}^n$ verlangen wir mit den Abkürzungen

$$\mathbf{s}_k := \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}, \quad \mathbf{y}_k := (\nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)}))^\top$$

von der Näherung der *inversen* Hesse-Matrix die

$$\text{Sekantenbedingung: } \mathbf{B}_{k+1} \mathbf{y}_k = \mathbf{s}_k. \quad (12.4.4)$$

In einer Dimension ist das der Kehrwert des Differenzenquotienten von eben, $b = s/y$ statt $f'' \approx y/s$ (beide heißen „Sekantenbedingung“), denn $\mathbf{B}_k$ nähert die Inverse der Hesse-Matrix, nicht die Hesse-Matrix selbst. Im $\mathbb{R}^n$ legen die n Gleichungen von (12.4.4) die $n(n+1)/2$ Einträge einer symmetrischen Matrix bei Weitem nicht fest; die verbleibende Freiheit nutzen wir, um $\mathbf{B}_{k+1}$ möglichst wenig von $\mathbf{B}_k$ abweichen zu lassen. Die bekannteste Wahl ist diese:

Definition 12.4.9 (BFGS-Update)

Sei $\mathbf{B}_k \in \mathbb{R}^{n \times n}$ symmetrisch und gelte $\mathbf{y}_k^\top \mathbf{s}_k \neq 0$. Mit $\rho_k := 1/(\mathbf{y}_k^\top \mathbf{s}_k)$ heißt

$$\mathbf{B}_{k+1} = (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{y}_k^\top) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{y}_k \mathbf{s}_k^\top) + \rho_k \mathbf{s}_k \mathbf{s}_k^\top \quad (12.4.5)$$

das *BFGS-Update*, benannt nach Broyden, Fletcher, Goldfarb und Shanno.

Den Nenner von ρ_k können wir deuten. Auf einer Quadrik mit Hesse-Matrix $\mathbf{H}$ ist $\mathbf{y}_k = \mathbf{H} \mathbf{s}_k$, also

$$\frac{\mathbf{y}_k^\top \mathbf{s}_k}{\mathbf{s}_k^\top \mathbf{s}_k} = \frac{\mathbf{s}_k^\top \mathbf{H} \mathbf{s}_k}{\mathbf{s}_k^\top \mathbf{s}_k},$$

und das ist die Krümmung in Richtung $\mathbf{s}_k$. Die Krümmungsbedingung $\mathbf{y}_k^\top \mathbf{s}_k > 0$ aus Bemerkung 12.4.11 sagt damit: Entlang des gerade gegangenen Schrittes ist f nach oben gekrümmt.

In (12.4.5) sind beide Klammern Einheitsmatrizen plus eine Rang-1-Störung, der letzte Summand hat ebenfalls Rang 1. Ausmultipliziert steht dort $\mathbf{B}_k$ plus eine Korrektur, die von $\mathbf{s}_k$ und $\mathbf{B}_k \mathbf{y}_k$ aufgespannt wird und deshalb höchstens Rang 2 hat.

Satz 12.4.10 (Das BFGS-Update erfüllt die Sekantenbedingung)

Unter den Voraussetzungen von Definition 12.4.9 gilt $\mathbf{B}_{k+1} \mathbf{y}_k = \mathbf{s}_k$.

Vertiefung (optional): Beweis: Die BFGS-Aktualisierung erfüllt die Sekantenbedingung

Beweis.

- (1) Wir lassen die Indizes weg und multiplizieren (12.4.5) von rechts mit $\mathbf{y}$. Die rechte Klammer trifft dabei zuerst auf $\mathbf{y}$:

$$(\mathbf{I} - \rho \mathbf{y} \mathbf{s}^\top) \mathbf{y} = \mathbf{y} - \rho \mathbf{y} (\mathbf{s}^\top \mathbf{y}) = \mathbf{y} - \mathbf{y} = \mathbf{0}.$$

$\mathbf{s}^\top \mathbf{y}$ ist eine Zahl und darf vor den Vektor gezogen werden; nach Definition von ρ ist $\rho(\mathbf{s}^\top \mathbf{y}) = 1$

- (2) Damit verschwindet der ganze erste Summand von (12.4.5), denn er hat diese Klammer als rechten Faktor:

$$(\mathbf{I} - \rho \mathbf{s} \mathbf{y}^\top) \mathbf{B} \underbrace{(\mathbf{I} - \rho \mathbf{y} \mathbf{s}^\top) \mathbf{y}}_{=\mathbf{0}} = \mathbf{0}.$$

Matrixmultiplikation ist assoziativ, wir dürfen also von rechts nach links auswerten

- (3) Übrig bleibt der zweite Summand, und der liefert genau den gesuchten Vektor:

$$\rho \mathbf{s} \mathbf{s}^\top \mathbf{y} = \mathbf{s} (\rho \mathbf{s}^\top \mathbf{y}) = \mathbf{s}.$$

wieder dieselbe Zahl $\rho(\mathbf{s}^\top \mathbf{y}) = 1$; die Sekantenbedingung (12.4.4) ist also nicht näherungsweise, sondern exakt erfüllt

□

Bemerkung 12.4.11 (Eigenschaften, Kosten und L-BFGS)

Symmetrie und Definitheit bleiben erhalten. Mit $\mathbf{B}_k$ ist auch $\mathbf{B}_{k+1}$ symmetrisch, und unter der Krümmungsbedingung $\mathbf{y}_k^\top \mathbf{s}_k > 0$ bleibt auch positive Definitheit erhalten. Dann ist $\nabla f \mathbf{B}_k \nabla f^\top > 0$, und $-\mathbf{B}_k \nabla f(\mathbf{x}^{(k)})^\top$ zeigt bergab, solange der Gradient nicht verschwindet. Erzwingen lässt sich die Krümmungsbedingung durch eine Liniensuche, die neben dem Abstiegs Kriterium aus Abschnitt 12.3 auch die Steigung im neuen Punkt prüft.

Kosten. Ein Schritt besteht aus einer Matrix-Vektor-Multiplikation und zwei Rang-1-Korrekturen, zusammen $O(n^2)$ statt $O(n^3)$ bei Newton. Eine Zerlegung fällt nie an, und zweite Ableitungen braucht das Verfahren nicht.

Konvergenz. Zwischen linear und quadratisch liegt *superlinear*: Der Quotient e_{k+1}/e_k geht gegen null, ohne dass e_{k+1}/e_k^2 beschränkt bleiben müsste (Konvergenzordnung). In der Praxis ist BFGS deutlich schneller als der Gradientenabstieg und kaum langsamer als Newton.

L-BFGS. Für großes n ist schon das Speichern von $\mathbf{B}_k$ zu teuer. Die Variante mit beschränktem Speicher (*limited memory*) speichert keine Matrix, sondern nur die letzten m Paare $(\mathbf{s}_j, \mathbf{y}_j)$, meist m zwischen 5 und 20, und setzt daraus bei Bedarf das Produkt $\mathbf{B}_k \nabla f^\top$ zusammen. Der Speicher fällt damit von $O(n^2)$ auf $O(mn)$, bei $n = 10\,000$ und $m = 10$ von 10^8 Zahlen auf einige Hunderttausend.

Interaktiv: BFGS Schritt für Schritt

Minimiert wird die Quadrik $f(\mathbf{x}) = 0,5 x_1^2 + 2,5 x_2^2$ mit der Hesse-Matrix $\text{diag}(1; 5)$, gestartet wird bei $(5; 1)$ mit $\mathbf{B}_0 = \mathbf{I}$; der erste Schritt ist also ein reiner Gradientenschritt. Die letzte Zeile des Ablesefelds prüft in jedem Schritt die Sekantenbedingung nach.

Interaktives Element — nur in der Web-Fassung

Das Residuum $\|\mathbf{B}_k \mathbf{y} - \mathbf{s}\|$ bleibt in jedem Schritt auf Rundungsfehlerniveau, wie Satz 12.4.10 es verspricht. Mit $\gamma_k = 1$ ist der erste Schritt zu lang: f steigt von 15 auf 40, und $\mathbf{B}_k$ ist nach sechs Schritten noch 0,011 (in der Frobeniusnorm) von $\text{diag}(1; 0,2)$ entfernt. Mit exakter Schrittweite liefert jeder Schritt eine Sekantenbedingung für eine neue Richtung; im $\mathbb{R}^2$ sitzt die Iterierte nach zwei Schritten im Minimum, und $\mathbf{B}_2$ stimmt mit $\text{diag}(1; 0,2)$ überein. Auf einer Quadrik im $\mathbb{R}^n$ ist BFGS mit exakter Liniensuche deshalb nach höchstens n Schritten fertig.

Vier Verfahren nebeneinander

Eigenschaft	Nelder-Mead	Gradientenabstieg	Quasi-Newton	Newton
Ordnung	nullte	erste	dazwischen	zweite
braucht	nur f	∇f	∇f	$\nabla f, \mathbf{H}_f$
lineare Algebra je Schritt	$O(n)$	$O(n)$	$O(n^2)$	$O(n^3)$
Konvergenz	keine Garantie	linear	superlinear	lokal quadratisch
Schrittweite	automatisch	kritisch (γ)	Linienuche	automatisch
Skalierbarkeit	schlecht ($n \lesssim 10$)	sehr gut	gut	schlecht

Bemerkung 12.4.12 (Wie die Tabelle zu lesen ist)

Die Aufwandsspalte zählt die lineare Algebra je Schritt, nicht die Funktions- und Gradientenauswertungen. Die können ihrerseits teuer sein: Bei einem empirischen Risiko über N Beobachtungen kostet schon ein einziger Gradient $O(N)$; davon handelt der letzte Unterabschnitt.

Die Konvergenzspalte ist asymptotisch und lokal. Die quadratische Rate von Newton gilt in der Nähe eines Minimums mit invertierbarer und lokal hinreichend glatter Hesse-Matrix, die lineare Rate des Gradientenabstiegs unter den Voraussetzungen aus Abschnitt 12.3. Über das Verhalten weit vom Ziel sagt die Zeile nichts.

Drei der vier sind Fixpunktiterationen. Gradientenabstieg, Quasi-Newton und Newton haben dieselbe Bauform

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \mathbf{M}_k \nabla f(\mathbf{x}^{(k)})^\top, \quad \mathbf{M}_k \in \{\gamma \mathbf{I}, \gamma_k \mathbf{B}_k, \mathbf{H}_f(\mathbf{x}^{(k)})^{-1}\},$$

sind also allesamt Fixpunktiterationen für $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ im Sinne von Abschnitt 12.1. Die Wahl von $\mathbf{M}_k$ ist die Wahl zwischen Rechenzeit und Schrittqualität.

Wo sie eingesetzt werden. Nelder-Mead ist die Rückfalloption ohne Ableitungen (Abschnitt 12.3), der Gradientenabstieg die Grundlage der Optimierer für neuronale Netze, BFGS der Standardkompromiss für mittelgroße glatte Probleme, und Newton steckt in der Likelihood-Inferenz, etwa als Fisher-Scoring (IWLS) für verallgemeinerte lineare Modelle (Bemerkung 10.8.13), und im Boosting-Verfahren XGBoost. In R bekommen wir BFGS mit `method = "BFGS"`; die Voreinstellung von `optim()` ist es nicht (Abschnitt 12.6).

Momentum: Schwung gegen den Zickzack

Zurück zum Gradientenabstieg und seiner Schwäche bei schlechter Kondition: In einem langen, schmalen Tal zeigt der negative Gradient fast quer zur Talrichtung, die Iterierten pendeln zwischen den Hängen und kommen der Länge nach kaum voran (Abschnitt 12.3). Große Schritte verstärken das Pendeln, kleine bremsen den Fortschritt entlang des Tals.

Eine Kugel, die den Hang hinunterrollt, folgt nicht in jedem Augenblick der lokalen Falllinie, sondern sammelt Schwung (*momentum*). Quer zum Tal wird sie von den Hängen abwechselnd nach links und rechts gelenkt, das mittelt sich weg; entlang des Tals wirken alle Kräfte in dieselbe Richtung und addieren sich.

Algorithmus 12.4.13 (Gradientenabstieg mit Heavy-Ball-Momentum)

Gegeben seien $f : \mathbb{R}^n \rightarrow \mathbb{R}$ stetig differenzierbar, ein Startpunkt $\mathbf{x}^{(0)}$, eine Schrittweite $\gamma > 0$ und ein Momentumparameter $\alpha \in [0, 1)$. Setze die *Geschwindigkeit* $\mathbf{v}^{(0)} = \mathbf{0}$, die im Folgenden die bisherigen Schritte aufsummiert, und für $k = 0, 1, 2, \dots$

$$\begin{aligned}\mathbf{v}^{(k+1)} &= \alpha \mathbf{v}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)})^\top, \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} + \mathbf{v}^{(k+1)}.\end{aligned}\tag{12.4.6}$$

Für $\alpha = 0$ ist das der gewöhnliche Gradientenabstieg.

Bemerkung 12.4.14 (Was der Schwung bewirkt)

Gleichgerichtete Gradienten summieren sich auf. Bleibt der Gradient über mehrere Schritte ungefähr gleich, so wird aus (12.4.6) eine geometrische Reihe, und die Geschwindigkeit läuft gegen $\mathbf{v} \rightarrow -\gamma \nabla f^\top / (1 - \alpha)$. Der effektive Schritt in einer flachen, aber konsistenten Richtung ist also um den Faktor $1/(1 - \alpha)$ größer als beim reinen Gradientenabstieg; für den üblichen Wert $\alpha = 0,9$ ist das ein Faktor 10.

Wechselnde Gradienten mitteln sich weg. Wechselt die Gradientenrichtung dagegen in jedem Schritt, so heben sich die Beiträge in (12.4.6) weitgehend auf; das dämpft den Zickzack. In der mechanischen Analogie ist $1 - \alpha$ die Reibung: Je größer α , desto weniger Reibung und desto mehr Gedächtnis.

Größere Schritte sind erlaubt. Auf einer Quadrik mit Krümmungen zwischen μ und L konvergiert der Gradientenabstieg genau für $\gamma L < 2$, mit Momentum für $\gamma L < 2(1 + \alpha)$. Bei $\alpha = 0,9$ dürfen die Schritte also fast doppelt so lang sein.

Nicht jedes α hilft. Bei gut konditionierten Problemen ist der Standardwert $\alpha = 0,9$ zu groß und macht das Verfahren *langsamer* als den reinen Gradientenabstieg; das Widget zeigt es. Die Variante von Nesterov wertet den Gradienten am voraussichtlichen nächsten Punkt aus statt am aktuellen und ist oft die bessere Wahl.

Vertiefung (optional): Optimale Momentum-Parameter und ihre Grenzen

Optimale Parameter. Für eine Quadrik lässt sich die beste Wahl ausrechnen: Mit $\alpha^* = ((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1))^2$ und $\gamma^* = 4/(\sqrt{L} + \sqrt{\mu})^2$ fällt der Fehler pro Schritt auf das $(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ -fache statt auf das $(\kappa - 1)/(\kappa + 1)$ -fache. Statt κ steht dort also $\sqrt{\kappa}$, und das ist bei $\kappa = 100$ der Unterschied zwischen 0,98 und 0,82 pro Schritt. Der Standardwert 0,9 passt zu κ in der Größenordnung 10^3 .

Die Garantie gilt nur für Quadriken. Für allgemeine glatte, stark konvexe Funktionen ist die Beschleunigung kein Satz: Es gibt Beispiele, auf denen Heavy-Ball mit den für Quadriken optimalen Parametern in einen Zyklus läuft und nicht konvergiert. Die Variante von Nesterov trägt dort eine bewiesene Schranke. Der Merksatz „bei strikt konvexen Funktionen beschleunigt Momentum die Konvergenz deutlich“ ist also eine Faustregel, kein Theorem.

Adaptive Verfahren. Adagrad, RMSprop und ADAM nutzen dieselbe Beobachtung, dass in den bisherigen Gradienten Information steckt. Sie merken sich zusätzlich, wie groß die Gradienten typischerweise waren, und geben daraus jeder Koordinate eine eigene Schrittweite; ADAM verbindet das mit dem Schwung aus (12.4.6). Der Kurs *Optimization for ML* im Master geht ihnen nach.

Interaktiv: Mit und ohne Schwung

Beide Verfahren laufen auf derselben Quadrik $f(\mathbf{x}) = \frac{1}{2}(x_1^2 + c x_2^2)$ mit Konditionszahl $\kappa = c$, blau ohne und violett mit Momentum. Die Schrittweite steht als Vielfaches von $1/L$ am Regler, sodass die Stabilitätsgrenzen 2 und $2(1 + \alpha)$ direkt ablesbar sind. Die drei Voreinstellungen sind gut, mittel und schlecht konditioniert, jeweils mit $\alpha = 0,9$.

Schätzfrage. Hilft der Standardwert $\alpha = 0,9$ bei einer *gut* konditionierten Quadrik, etwa $\kappa = 5$?

Lösung: *nein*

Die Ablesezeile zählt beide Verfahren mit: Bei $\kappa = 5$ dreht sich das Ergebnis sogar um, 106 Schritte mit gegen 31 ohne Momentum.

Bei $\kappa = 25$ steht es 103 Schritte mit gegen 161 ohne Momentum, bei $\kappa = 100$ schon 121 zu 608: Je schlechter die Kondition, desto größer der Gewinn. Bei $\gamma L = 2,5$ divergiert der blaue Weg, der violette bleibt stabil, denn seine Grenze liegt bei $2 \cdot 1,9 = 3,8$. Der Standardwert 0,9 stammt aus dem Deep Learning, wo die Konditionszahlen um Größenordnungen höher liegen als hier.

Eine Shiny-App zeigt Gradientenabstieg und Momentum auf weiteren Landschaften.

Stochastischer Gradientenabstieg

Bisher ging es darum, wie viele Schritte ein Verfahren braucht, jetzt darum, was ein einzelner Schritt kostet. In Statistik und maschinellem Lernen ist die Zielfunktion meist ein Mittelwert über Daten, das *empirische Risiko*

$$R(\theta) = \frac{1}{N} \sum_{i=1}^N L(y_i, p_{\theta}(\mathbf{x}_i)), \quad (12.4.7)$$

wobei L den Fehler einer einzelnen Vorhersage misst und N die Zahl der Beobachtungen ist (Beispiel 12.1.4). Typische Verluste sind der Kleinste-Quadrate-Verlust und die negative Log-Likelihood (Beispiel 12.2.7), für die logistische Regression also der Kreuzentropie-Verlust.

Der Gradient erbt die Summe:

$$\nabla R(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla L(y_i, p_{\theta}(\mathbf{x}_i)).$$

Ein einziger Gradientenschritt läuft also einmal durch den gesamten Datensatz; bei N in Millionenhöhe begrenzt das die Rechenzeit, wie gut die Richtung auch ist. Der *stochastische Gradientenabstieg* ersetzt diesen Mittelwert durch einen unverzerrten Schätzer, statt ihn auszurechnen.

Satz 12.4.15 (Der Gradient einer zufällig gezogenen Beobachtung ist unverzerrt)

Seien θ fest, der Datensatz fest, und sei i gleichverteilt auf $\{1, \dots, N\}$ gezogen. Dann gilt

$$\mathbb{E}[\nabla L(y_i, p_{\theta}(\mathbf{x}_i))] = \nabla R(\theta).$$

Vertiefung (optional): Beweis der Unverzerrtheit

Beweis.

- (1) Der Erwartungswert läuft allein über den Index i , und der nimmt jeden der N Werte mit Wahrscheinlichkeit $1/N$ an:

$$\mathbb{E}[\nabla L(y_i, p_{\theta}(\mathbf{x}_i))] = \sum_{j=1}^N \mathbb{P}(i=j) \nabla L(y_j, p_{\theta}(\mathbf{x}_j)) = \frac{1}{N} \sum_{j=1}^N \nabla L(y_j, p_{\theta}(\mathbf{x}_j)),$$

und das ist $\nabla R(\theta)$.

Erwartungswert einer Funktion einer diskreten Zufallsvariablen; die y_j und $\mathbf{x}_j$ sind hier Konstanten, zufällig ist nur, welche von ihnen gezogen wird

□

Gemittelt wird allein über die Ziehung des Index, nicht über die Verteilung der Daten. Die Unverzerrtheit ist deshalb keine Annahme über das Modell, sondern folgt daraus, wie wir ziehen: Den unverzerrten Schätzer bauen wir selbst.

Algorithmus 12.4.16 (Stochastischer Gradientenabstieg, SGD)

Gegeben seien das empirische Risiko (12.4.7), ein Startwert $\theta^{(0)}$ und Schrittweiten $\gamma^{(k)} > 0$. Für $k = 0, 1, 2, \dots$

1. ziehe einen Index i_k gleichverteilt aus $\{1, \dots, N\}$,
2. setze

$$\theta^{(k+1)} = \theta^{(k)} - \gamma^{(k)} \nabla L(y_{i_k}, p_{\theta^{(k)}}(\mathbf{x}_{i_k}))^\top. \quad (12.4.8)$$

Bemerkung 12.4.17 (Rauschen und Mini-Batches)

Kosten und Gewinn. Ein Schritt kostet jetzt $O(1)$ statt $O(N)$, unabhängig von der Datenmenge. Dafür ist die Richtung nur im Mittel richtig: Die Iterierten laufen nicht mehr glatt bergab, sondern schwanken, und in der Nähe des Minimums bleibt bei fester Schrittweite ein Rauschband, das nicht kleiner wird.

Mini-Batches. In der Praxis ziehen wir einen Stapel von b Beobachtungen und mitteln deren Gradienten; dieses Mittel ersetzt den einzelnen Summanden in (12.4.8). (Wir schreiben b , weil n hier schon die Zahl der Parameter ist.) Der Schätzer bleibt unverzerrt, und bei unabhängigen Ziehungen fällt seine Varianz auf den b -ten Teil, die Standardabweichung also nur auf den $\sqrt{b}$ -ten. Ein Stapel von 32 kostet das 32-fache einer einzelnen Beobachtung und drückt das Rauschen nur um den Faktor 5,7. Übliche Größen liegen zwischen 32 und 256; die Wahl folgt eher der Hardware, die viele gleichartige Rechnungen gleichzeitig erledigt, als der Statistik.

Warum das wichtig ist. Mini-Batch-SGD, meist mit Momentum oder als AdamW, ist die Grundlage fast des gesamten Trainings neuronaler Netze. Oft ebenso wichtig wie das Verfahren ist der Lernratenplan (*learning rate schedule*), der die Schrittweite nach einer Aufwärmphase absenkt. Häufig begrenzen wir außerdem die Norm zu großer Gradienten auf einen Höchstwert (*gradient clipping*), was das Training stabilisiert, und das Rauschen der Mini-Batches hilft, Sattelpunkte und Plateaus zu verlassen (Bemerkung 12.2.10). Der MSC-Kurs Optimization for ML behandelt ADAM, Muon und die Lernratenpläne im Detail.

Vertiefung (optional): Lernraten und Ziehen ohne Zurücklegen

Lernraten. Damit die Iterierten nicht im Rauschband hängen bleiben, lassen wir $\gamma^{(k)}$ langsam fallen. Klassisch verlangen wir $\sum_k \gamma^{(k)} = \infty$, damit die Iteration beliebig weit kommt, und $\sum_k (\gamma^{(k)})^2 < \infty$, damit sich das Rauschen herausmittelt; $\gamma^{(k)} \sim 1/k$ erfüllt beides.

Ziehen ohne Zurücklegen. Die gängigen Implementierungen mischen den Datensatz einmal pro Durchlauf und gehen ihn der Reihe nach durch, statt unabhängig zu ziehen. Satz 12.4.15 gilt dann nur noch gemittelt über alle Mischungen, praktisch funktioniert es aber besser.

Selbsttest

1. Ein Newton-Schritt liefert stets ein lokales Minimum der Funktion.

Antwort: Falsch

Er liefert einen kritischen Punkt der quadratischen Näherung, mehr nicht. Ist die Hesse-Matrix indefinit, so ist das ein Sattel, ist sie negativ definit, ein Maximum. Im Widget genügt der Startpunkt 0,5 auf der nicht-konvexen Funktion: Ein einziger Schritt landet exakt auf dem lokalen Maximum bei 0, weil dort ebenfalls $f' = 0$ gilt (Bemerkung 12.4.5).

2. Auf einer strikt konvexen quadratischen Funktion trifft Newton das Minimum in einem Schritt, ganz gleich, wie schlecht konditioniert sie ist und wo wir starten.

Antwort: Wahr

Für ein Polynom zweiten Grades ist die Näherung (12.4.1) exakt. Ist seine Hesse-Matrix positiv definit, ist der Scheitel das eindeutige Minimum selbst (Bemerkung 10.8.10). Beispiel 12.4.6 rechnet das vor: $4 - 8/2 = 0$. Der Gradientenabstieg schafft den Treffer im Allgemeinen nicht, seine Schrittzahl hängt an der Kondition. In einer Dimension gibt es allerdings eine Ausnahme: Mit $\gamma = 1/f''$ trifft auch er sofort, und diese Schrittweite ist der Newton-Schritt.

3. Damit BFGS funktioniert, muss $\mathbf{B}_k$ gegen die inverse Hesse-Matrix konvergieren.

Antwort: Falsch

Das ist nicht nötig. Im Widget steht nach sechs Schritten mit $\gamma_k = 1$ eine Matrix, die $\text{diag}(1; 0,2)$ nur nahek kommt, und das Verfahren konvergiert trotzdem. Gebraucht wird eine gute Richtung, nicht die richtige Matrix. Nur im Sonderfall der Quadrik mit exakter Liniensuche wird die Näherung nach n Schritten exakt.

4. Das BFGS-Update erfüllt die Sekantenbedingung nicht näherungsweise, sondern exakt.

Antwort: Wahr

Das ist Satz 12.4.10; der Beweis braucht nur die Definition $\rho_k = 1/(\mathbf{y}_k^\top \mathbf{s}_k)$. Näherungsweise ist die *Sekantenbedingung selbst*, denn ein Differenzenquotient ist nicht die Ableitung.

5. Momentum mit $\alpha = 0,9$ ist immer mindestens so schnell wie der reine Gradientenabstieg.

Antwort: Falsch

Bei gut konditionierten Problemen schadet es. Im Widget braucht der Abstieg bei $\kappa = 5$ ohne Momentum 31 Schritte, mit $\alpha = 0,9$ dagegen 106. Rechnerisch optimal wäre dort ein Momentumparameter von etwa 0,15. Der Wert 0,9 stammt aus dem Deep Learning, wo die Konditionszahl um Größenordnungen höher liegt (Bemerkung 12.4.14).

6. Ein Mini-Batch aus 32 Beobachtungen macht die Schätzung des Gradienten 32-mal genauer als eine einzelne Beobachtung.

Antwort: Falsch

Die Varianz fällt auf ein Zweiunddreißigstel, die Standardabweichung also nur um den Faktor $\sqrt{32} \approx 5,7$. Deshalb sind Mini-Batches ein Kompromiss und keine Lösung: Der Aufwand wächst linear, die Genauigkeit mit der Wurzel.

7. Wie viele Schritte braucht der reine Gradientenabstieg im Momentum-Widget bei $\kappa = 5$ und $\gamma L = 1$ für einen Faktor 10^{-6} im Funktionswert?

Lösung: 31 Schritte

Es sind 31. Der Abstieg *mit* Momentum ($\alpha = 0,9$) braucht dafür 106, also mehr als dreimal so viele. Bei guter Kondition schadet der Schwung, weil die Iterierten über das Tal hinausschießen; bei schlechterer Kondition dreht sich das Verhältnis um, bei $\kappa = 100$ auf 121 gegen 608 (Bemerkung 12.4.14).

8. Die Unverzerrtheit des SGD-Gradienten folgt aus der Art, wie wir den Index ziehen, und nicht aus einer Annahme über die Daten.

Antwort: Wahr

In Satz 12.4.15 sind Datensatz und Parameter fest; zufällig ist nur, welcher Summand von (12.4.7) gezogen wird. Weil jeder Index Wahrscheinlichkeit $1/N$ hat, ist der Erwartungswert der Mittelwert aller Summanden, also der volle Gradient.

Vertiefung: Heath §6.5.3 behandelt das Newton-Verfahren für die unbeschränkte Optimierung, §6.5.4 die Quasi-Newton-Verfahren im Überblick und §6.5.5 die Sekanten-Updates samt BFGS; §5.6 zeigt die Newton-Verfahren für nichtlineare Gleichungssysteme, aus denen sie hervorgehen. Zum stochastischen Gradientenabstieg und seinen Varianten führt der MSc-Kurs Optimization for ML weiter.

12.5 Beschränkte Optimierung

Die Verfahren der Abschnitte 12.3 und 12.4 haben f auf ganz $\mathbb{R}^n$ minimiert. Oft ist aber nicht jeder Punkt erlaubt: Wahrscheinlichkeiten müssen nichtnegativ sein und sich zu 1 summieren, ein Budget hat eine Obergrenze, Erhaltungsgrößen der Physik sind festgelegt. Solche Einschränkungen formulieren wir als Gleichungen und Ungleichungen an $\mathbf{x}$.

Definition 12.5.1 (Beschränktes Optimierungsproblem)

Das *beschränkte Optimierungsproblem* (constrained optimization) aus Definition 12.1.2 schreiben wir als

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) && \text{(Zielfunktion)} \\ \text{unter} \quad & g_i(\mathbf{x}) = 0, \quad i = 1, \dots, m && \text{(Gleichungen)} \\ & h_j(\mathbf{x}) \leq 0, \quad j = 1, \dots, p && \text{(Ungleichungen).} \end{aligned}$$

Die Menge S aller Punkte, die sämtliche Nebenbedingungen erfüllen, heißt *zulässiger Bereich* (feasible set).

Bemerkung 12.5.2 (Das Optimum liegt oft auf der Nebenbedingung)

Minimieren wir etwa $f(x, y) = x^2 + y^2$ unter der Gleichungsnebenbedingung $g(x, y) = x + y - 1 = 0$, so ist das unbeschränkte Minimum $(0, 0)$ nicht zulässig. Das beschränkte Optimum muss auf der Geraden $x + y = 1$ liegen, und zwar dort, wo die Gerade die niedrigste Höhenlinie von f berührt. Auf dieser Berührbedingung beruht das folgende Verfahren.

Die Idee der Lagrange-Multiplikatoren

Dürfen wir uns nur entlang der Kurve $g(\mathbf{x}) = 0$ bewegen, dann zählt am Optimum nur noch die Richtung entlang der Kurve: Gäbe es dort eine Richtung mit Steigung nach unten, könnten wir den Zielwert weiter senken. Am Optimum $\mathbf{x}^*$ hat f also entlang der Nebenbedingung keine Steigung mehr. Das heißt geometrisch:

- $\nabla f(\mathbf{x}^*)$ steht senkrecht auf der Tangente der Nebenbedingungskurve,
- und weil auch $\nabla g(\mathbf{x}^*)$ senkrecht auf dieser Tangente steht (Abschnitt 10.2: der Gradient steht senkrecht auf den Höhenlinien), sind die beiden Gradienten *parallel*:

$$\exists \lambda \in \mathbb{R} : \quad \nabla f(\mathbf{x}^*) + \lambda \nabla g(\mathbf{x}^*) = \mathbf{0}^\top.$$

Bemerkung 12.5.3 (Auch null ist ein zulässiger Multiplikator)

$\lambda = 0$ ist erlaubt: Liegt das unbeschränkte Minimum auf der Nebenbedingung, dann ist dort schon $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$, und die Bedingung gilt mit $\lambda = 0$. Auch das Vorzeichen ist bei Gleichungsnebenbedingungen frei, wie Beispiel 12.5.6 zeigt. Gebraucht wird dagegen $\nabla g(\mathbf{x}^*) \neq \mathbf{0}^\top$, sonst legt die Nebenbedingung ihre Tangente nicht fest.

Definition 12.5.4 (Lagrange-Funktion)

Für das Problem $\min f(\mathbf{x})$ unter $g(\mathbf{x}) = \mathbf{0}$ mit $g(\mathbf{x}) = (g_1(\mathbf{x}), \dots, g_m(\mathbf{x}))^\top$ heißt

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\lambda}^\top g(\mathbf{x}), \quad \boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_m)^\top \in \mathbb{R}^m,$$

Lagrange-Funktion; die λ_i heißen Lagrange-Multiplikatoren.

Satz 12.5.5 (Notwendige Bedingung von Lagrange)

Seien f und g stetig differenzierbar und sei $\mathbf{x}^*$ ein lokales Minimum von f unter $g(\mathbf{x}) = \mathbf{0}$. Sind die Gradienten $\nabla g_1(\mathbf{x}^*), \dots, \nabla g_m(\mathbf{x}^*)$ linear unabhängig, so existiert ein $\boldsymbol{\lambda}^* \in \mathbb{R}^m$ mit

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*) = \mathbf{0}^\top \quad \text{und} \quad g(\mathbf{x}^*) = \mathbf{0}.$$

Die erste Gleichung ist die Parallelitätsbedingung von oben, für alle m Nebenbedingungen gleichzeitig; die zweite ist die Zulässigkeit. Statt eines Minimierungsproblems mit Nebenbedingung lösen wir also ein Gleichungssystem in den $n + m$ Unbekannten $(\mathbf{x}, \boldsymbol{\lambda})$, und dafür haben wir die Verfahren aus Abschnitt 12.1.

Ohne die Unabhängigkeitsbedingung gilt der Satz nicht. Minimieren wir $f(x, y) = x$ unter $g(x, y) = y^2 - x^3 = 0$, so erzwingt die Nebenbedingung $x \geq 0$, und das Minimum liegt im Ursprung. Dort ist wegen $\nabla g(x, y) = (-3x^2, 2y)$ aber $\nabla g(0, 0) = \mathbf{0}^\top$, während $\nabla f = (1, 0)$ nirgends verschwindet: Kein λ erfüllt die Stationaritätsgleichung.

Hinreichende Bedingungen sind feiner (zweite Ableitungen der Lagrange-Funktion auf dem Tangentialraum); dazu Heath, Ch. 6.2.3.

Beispiel 12.5.6 (Minimieren auf einer Geraden)

Wir minimieren $f(x, y) = x^2 + y^2$ unter $x + y - 1 = 0$.

Die Lagrange-Funktion ist $\mathcal{L}(x, y, \lambda) = x^2 + y^2 + \lambda(x + y - 1)$, und ihre partiellen Ableitungen liefern drei Gleichungen:

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial x} &= 2x + \lambda = 0 &\implies x &= -\lambda/2, \\ \frac{\partial \mathcal{L}}{\partial y} &= 2y + \lambda = 0 &\implies y &= -\lambda/2, \\ \frac{\partial \mathcal{L}}{\partial \lambda} &= x + y - 1 = 0 &\implies -\lambda &= 1.\end{aligned}$$

Also $\lambda^* = -1$ und $x^* = y^* = \frac{1}{2}$ mit $f(x^*, y^*) = \frac{1}{2}$. Das passt zur Geometrie: Im Punkt $(\frac{1}{2}, \frac{1}{2})$ ist $\nabla f = (1, 1)$ parallel zu $\nabla g = (1, 1)$, und das Vorzeichen von λ^* ist negativ. Bei Gleichungsnebenbedingungen ist das erlaubt.

Interaktiv: Höhenlinien, Gerade und zwei Pfeile

Das Widget zeigt das Beispiel: grau die Höhenlinien von f , violett die gerade erreichte, rot die Nebenbedingung und orange die beiden Gradienten an einem verschiebbaren Punkt der Geraden. Daneben steht dieselbe Funktion als Fläche, auf die die Nebenbedingung als rote Kurve gehoben ist. Die drei Knöpfe wechseln zwischen der Gleichung und den beiden Ungleichungen.

Interaktives Element — nur in der Web-Fassung

Nur an einer Stelle der Geraden sind die beiden Pfeile *parallel*, und nur dort liefern beide Stationaritätsgleichungen denselben Multiplikator, $\lambda^* = -1$ im Punkt $(0,5; 0,5)$ mit $f^* = 0,5$. Überall sonst schneidet die Höhenlinie die Gerade, statt sie zu berühren. Die Ungleichungs-Modi nehmen die KKT-Bedingungen vorweg: Bei $x + y \geq 1$ zeigen die Pfeile im Optimum gegeneinander, $\mu = 1 > 0$, und die Nebenbedingung bindet. Bei $x + y \leq 1$ verlangte jeder Randpunkt $\mu < 0$; stattdessen gewinnt das unbeschränkte Minimum $(0; 0)$ mit $\mu = 0$.

Ungleichungen: die KKT-Bedingungen

Bei Ungleichungs-Nebenbedingungen $h_j(\mathbf{x}) \leq 0$ kommt eine neue Unterscheidung dazu: Eine Ungleichung kann im Optimum *aktiv* sein (es gilt Gleichheit, sie blockiert die Bewegung) oder *inaktiv* (es gilt strikte Ungleichheit, lokal schränkt sie nichts ein).

Satz 12.5.7 (Karush-Kuhn-Tucker-Bedingungen)

Sei $\mathbf{x}^*$ ein lokales Minimum von f unter $g_i(\mathbf{x}) = 0$ und $h_j(\mathbf{x}) \leq 0$, und seien die Gradienten aller Gleichungen zusammen mit denen der in $\mathbf{x}^*$ aktiven Ungleichungen linear unabhängig. Dann existieren Multiplikatoren λ_i, μ_j mit:

1. *Stationarität*: $\nabla f(\mathbf{x}^*) + \sum_i \lambda_i \nabla g_i(\mathbf{x}^*) + \sum_j \mu_j \nabla h_j(\mathbf{x}^*) = \mathbf{0}^\top$
2. *Primale Zulässigkeit*: $g_i(\mathbf{x}^*) = 0$ und $h_j(\mathbf{x}^*) \leq 0$
3. *Duale Zulässigkeit*: $\mu_j \geq 0$
4. *Komplementarität*: $\mu_j h_j(\mathbf{x}^*) = 0$ für alle j

Bemerkung 12.5.8 (Komplementarität: bindet oder abgeschaltet)

Bedingung 4 ist ein Entweder-oder je Ungleichung:

- $h_j(\mathbf{x}^*) < 0$ (inaktiv) $\implies \mu_j = 0$: Die Nebenbedingung trägt nichts zur Stationarität bei.
- $\mu_j > 0 \implies h_j(\mathbf{x}^*) = 0$ (aktiv): Die Nebenbedingung bindet, und ihr Gradient gleicht in der Stationaritätsgleichung ∇f aus.

Anders als bei Gleichungen ist das Vorzeichen hier festgelegt: $\mu_j \geq 0$, denn eine Ungleichung kann nur in eine Richtung drücken. Die λ_i der Gleichungen bleiben vorzeichenfrei.

Beispiel 12.5.9 (Eine Box-Beschränkung)

Wir minimieren $f(x) = (x - 3)^2$ unter $0 \leq x \leq 2$, also mit $h_1(x) = -x \leq 0$ und $h_2(x) = x - 2 \leq 0$.

Die KKT-Bedingungen lauten

$$2(x^* - 3) - \mu_1 + \mu_2 = 0, \quad \mu_1, \mu_2 \geq 0, \quad \mu_1 x^* = 0, \quad \mu_2(x^* - 2) = 0. \quad (12.5.1)$$

Das unbeschränkte Minimum $x = 3$ ist unzulässig, der Kandidat ist der rechte Rand: $x^* = 2$. Komplementarität erzwingt dann $\mu_1 = 0$ (denn $x^* = 2 \neq 0$), und (12.5.1) liefert $2(2 - 3) + \mu_2 = 0$, also $\mu_2 = 2 > 0$. Alle vier Bedingungen sind erfüllt: Die obere Schranke ist *aktiv*, die untere *inaktiv*.

Die beiden anderen Kandidaten scheitern an den KKT-Bedingungen. Am linken Rand $x = 0$ ist $\mu_2 = 0$, und (12.5.1) verlangte dann $\mu_1 = 2(0 - 3) = -6 < 0$, was die duale Zulässigkeit verletzt. Im Inneren wären beide Multiplikatoren null und (12.5.1) verlangte $x^* = 3$, was die Box verlässt.

Anschaulich zeigt die negative Ableitung $-f'(2) = 2$ nach rechts, Richtung des unbeschränkten Minimums, aber die aktive Schranke h_2 blockiert jede weitere Bewegung. Diese blockierte Abstiegsrichtung entspricht $\mu_2 > 0$.

Anwendung: Ridge und Lasso als beschränkte Optimierung

Die regularisierte Regression aus Abschnitt 12.1 lässt sich in einer penalisierten und einer beschränkten Form schreiben; die zweite ist ein beschränktes Problem im Sinn von Definition 12.5.1:

$$\text{penalisiert: } \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_p^p$$

$$\text{beschränkt: } \min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 \quad \text{unter} \quad \|\boldsymbol{\beta}\|_p^p \leq c,$$

mit $p = 2$ (Ridge) beziehungsweise $p = 1$ (Lasso).

Beispiel 12.5.10 (KKT-Stationarität für Ridge)

Für Ridge ($p = 2$) ist die Lagrange-Funktion der beschränkten Form

$$\mathcal{L}(\boldsymbol{\beta}, \mu) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \mu (\|\boldsymbol{\beta}\|_2^2 - c),$$

und die Stationarität liefert mit den Gradienten aus Abschnitt 10.6

$$\nabla_{\boldsymbol{\beta}} \mathcal{L}^T = -2\mathbf{X}^T(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + 2\mu\boldsymbol{\beta} = \mathbf{0} \quad \implies \quad \hat{\boldsymbol{\beta}}_{\text{Ridge}} = (\mathbf{X}^T\mathbf{X} + \mu\mathbf{I})^{-1}\mathbf{X}^T\mathbf{y}.$$

Das ist die Ridge-Lösung, der Multiplikator μ spielt die Rolle des Strafparameters. Zu jedem $\lambda > 0$ mit $\hat{\boldsymbol{\beta}}(\lambda) \neq \mathbf{0}$ gehört das bindende Budget $c = \|\hat{\boldsymbol{\beta}}(\lambda)\|_2^2$ mit derselben Lösung (im Sonderfall $\hat{\boldsymbol{\beta}}(\lambda) = \mathbf{0}$ ist $c = 0$). Umgekehrt gilt das nur, solange die Nebenbedingung bindet: Ist c so groß, dass der Kleinste-Quadrate-Schätzer selbst zulässig ist, erzwingt die Komplementarität $\mu = 0$, und das entspricht $\lambda = 0$. Welches c zu welchem λ gehört, hängt von den Daten ab; eine Umrechnungsformel gibt es nicht. Für $\mu > 0$ ist $\mathbf{X}^T\mathbf{X} + \mu\mathbf{I}$ symmetrisch positiv definit, das System also eindeutig lösbar (Abschnitt 5.4), auch wenn $\mathbf{X}$ keinen vollen Rang hat.

Bemerkung 12.5.11 (Kreis gegen Raute: warum Lasso Nullen erzeugt)

Geometrisch minimieren beide Verfahren dieselben elliptischen Höhenlinien des Kleinste-Quadrate-Verlusts, nur über verschiedenen zulässigen Bereichen: Ridge über der Kreisscheibe $\|\boldsymbol{\beta}\|_2^2 \leq c$, Lasso über der Raute $|\beta_1| + |\beta_2| \leq c$. Verletzt der Kleinste-Quadrate-Schätzer die Nebenbedingung, so liegt die Lösung dort, wo die um ihn herum wachsende Ellipse den Bereich zuerst berührt. Einen Kreis trifft sie fast immer in einem glatten Randpunkt, an dem beide Koordinaten von null verschieden sind. Die Raute hat ihre Ecken auf den Achsen, und dort trifft die Ellipse häufig zuerst auf; dann ist eine Koordinate exakt null. Dieser Ecken-Fall ist der geometrische Grund für die Sparsity des Lasso. Formal steckt dahinter das Subdifferential der Betragsfunktion (Definition 11.4.14): An den Ecken ist $\|\boldsymbol{\beta}\|_1$ nicht differenzierbar, die KKT-Stationarität gilt dort nur mit Subgradienten, und gerechnet wird mit Subgradienten- oder Proximal-Verfahren.

Interaktiv: Kreis gegen Raute

Das Widget parametrisiert beide Mengen über ihren sichtbaren Radius r , zeigt also $\|\boldsymbol{\beta}\|_2 \leq r$ und $\|\boldsymbol{\beta}\|_1 \leq r$; für Ridge ist das Budget in der Formel oben $c = r^2$, für Lasso $c = r$.

Schätzfrage. Bis zu welchem Radius r bleibt die Lasso-Lösung in der Ecke, setzt also β_2 exakt auf null?

Lösung: 1,342857 r

Der Ecken-Vermerk in der rechten Tafel verschwindet an dieser Schwelle, nämlich bei $r = 1,3429$.

Unterhalb der Eckenschwelle steht die Lasso-Lösung exakt auf $(r; 0)$, darüber auf einer Kante der Raute mit beiden Koordinaten besetzt; die Ridge-Lösung wandert am Kreisrand entlang und wird nie exakt null. Für große r wird die Nebenbedingung inaktiv, bei Ridge ab $\|\hat{\boldsymbol{\beta}}\|_2 = 1,8358$, beim Lasso ab $\|\hat{\boldsymbol{\beta}}\|_1 = 2,5$. Beide Male erzwingt die Komplementarität aus Satz 12.5.7 dann $\mu = 0$.

Satz 12.5.12 (KKT und Konvexität)

Sind f und alle h_j konvex und alle g_i affin, so ist jeder zulässige Punkt $\mathbf{x}^*$, der die KKT-Bedingungen erfüllt, ein globales Minimum.

Diese Richtung braucht keine Regularitätsbedingung; die umgekehrte aus Satz 12.5.7 braucht sie auch bei konvexen Problemen.

Vertiefung (optional): Beweis und Grenzen von KKT bei konvexen Problemen

Beweis. Mit festen λ_i^* und $\mu_j^* \geq 0$ ist $\mathcal{L}(\cdot, \lambda^*, \mu^*)$ konvex, die Stationarität macht $\mathbf{x}^*$ zu ihrem Minimierer, und für jedes zulässige $\mathbf{x}$ gilt

$$f(\mathbf{x}) \geq \mathcal{L}(\mathbf{x}, \lambda^*, \mu^*) \geq \mathcal{L}(\mathbf{x}^*, \lambda^*, \mu^*) = f(\mathbf{x}^*).$$

Die erste Ungleichung nutzt $g_i(\mathbf{x}) = 0$, $h_j(\mathbf{x}) \leq 0$ und $\mu_j^* \geq 0$, die letzte Gleichheit die Komplementarität.

Die Umkehrung. Die beiden Richtungen sind nicht symmetrisch, und die verbreitete Kurzformel „im konvexen Fall sind die KKT-Bedingungen notwendig und hinreichend“ unterschlägt das. Bei $\min x$ unter $h(x) = x^2 \leq 0$ sind Ziel und Nebenbedingung konvex, der einzige zulässige Punkt $x^* = 0$ ist das Optimum, und trotzdem erfüllt kein $\mu \geq 0$ die Stationarität $1 + \mu \cdot 2x^* = 0$: Wegen $x^* = 0$ steht links immer 1.

Viele statistische Probleme sind konvex: Kleinste Quadrate, Ridge, Lasso, die negative Log-Likelihood einer Exponentialfamilie in ihrer kanonischen Parametrisierung (Abschnitt 11.5). Bei nicht-konvexen Problemen wie neuronalen Netzen liefern die KKT-Bedingungen dagegen nur Kandidaten, darunter auch lokale Optima und Sattelpunkte (Abschnitt 12.2).

Selbsttest

1. Ist $\mathbf{x}^*$ ein lokales Minimum von f unter $g(\mathbf{x}) = 0$, so gibt es immer ein λ^* mit $\nabla f(\mathbf{x}^*) + \lambda^* \nabla g(\mathbf{x}^*) = \mathbf{0}^\top$.

Antwort: Falsch

Nur unter der Bedingung aus Satz 12.5.5. Bei $f(x, y) = x$ unter $g(x, y) = y^2 - x^3 = 0$ liegt das Minimum im Ursprung, dort ist $\nabla g(0, 0) = \mathbf{0}^\top$, und $\nabla f = (1, 0)$ lässt sich durch kein Vielfaches des Nullvektors ausgleichen.

2. Bei einer Gleichungsnebenbedingung darf der Multiplikator den Wert null annehmen.

Antwort: Wahr

Das ist Bemerkung 12.5.3. Minimieren wir etwa $f(x, y) = x^2 + y^2$ unter $x + y = 0$, so liegt das unbeschränkte Minimum $(0, 0)$ selbst auf der Nebenbedingung; dort ist $\nabla f = \mathbf{0}^\top$, und die Stationarität gilt mit $\lambda^* = 0$.

3. Ist eine Ungleichung im Optimum aktiv, so ist ihr Multiplikator positiv.

Antwort: Falsch

Die Komplementarität $\mu_j h_j(\mathbf{x}^*) = 0$ ist auch dann erfüllt, wenn beide Faktoren null sind. Bei $\min x^2$ unter $h(x) = x \leq 0$ ist $x^* = 0$, die Ungleichung also aktiv, und die Stationarität $2x^* + \mu = 0$ liefert trotzdem $\mu = 0$. Nur die andere Richtung trägt: inaktiv erzwingt $\mu_j = 0$.

4. Ist die Lösung der penalisierten Ridge-Regression zu $\lambda > 0$ von null verschieden, so liefert $c = \|\hat{\beta}(\lambda)\|_2^2$ eine bindende beschränkte Form mit derselben Lösung.

Antwort: Wahr

Wir lösen die penalisierte Form und setzen $c := \|\hat{\beta}(\lambda)\|_2^2$. Dann ist $\hat{\beta}(\lambda)$ zulässig, die Nebenbedingung aktiv, und mit $\mu = \lambda$ sind alle KKT-Bedingungen erfüllt; Satz 12.5.12 macht daraus das globale Optimum. Für $\mathbf{X}$ und $\mathbf{y}$ aus Beispiel 10.6.6 (Abschnitt 10.6) und $\lambda = 1,5$ ist das $\hat{\beta} = (0,341; 0,578)$ mit $c = 0,450$. Die Umkehrung gilt dagegen nur, solange die Nebenbedingung bindet.

5. Bei einem konvexen Problem erfüllt das globale Minimum stets die KKT-Bedingungen.

Antwort: Falsch

Satz 12.5.12 trägt nur die andere Richtung; für die notwendige braucht es auch bei konvexen Problemen eine Regularitätsbedingung. Bei $\min x$ unter $h(x) = x^2 \leq 0$ ist $x^* = 0$ das Optimum, aber die Stationarität $1 + \mu \cdot 2x^* = 0$ scheitert an jedem $\mu \geq 0$.

6. Die Lasso-Lösung muss nicht in einer Ecke der Raute liegen.

Antwort: Wahr

In der Ecke liegt sie nur, solange das Budget klein genug ist. Im Widget sitzt die Lösung für $c \leq 1,30$ exakt in $(c; 0)$, bei $c = 1,40$ dagegen liest das Readout $(1,36; 0,04)$: beide Koordinaten sind besetzt. Die Sparsity des Lasso ist eine Tendenz, keine Garantie.

Vertiefung: Heath behandelt die beschränkte Optimierung in §6.2.3 (Lagrange-Multiplikatoren, hinreichende Bedingungen) sowie §6.7 (Verfahren für Probleme mit Nebenbedingungen); die konvexe Theorie samt KKT-Dualität entwickeln Boyd und Vandenberghe, Convex Optimization, Kapitel 5.

12.6 Optimierung in R und Zusammenfassung

Zum Abschluss übersetzen wir die Verfahren dieses Kapitels in R-Aufrufe: `optimize()` für univariate und `optim()` für multivariate Zielfunktionen. Die Ausgaben drucken wir nicht ab; die Beispielfunktion rechnet das Widget selbst nach.

Univariat: optimize

```
f <- function(x) (x - 3)^2
optimize(f, interval = c(0, 10))
```

Der Aufruf sucht das Minimum von f auf dem Intervall $[0, 10]$. Das analytische Minimum ist $x^* = 3$ mit $f(x^*) = 0$; genauer als das voreingestellte `tol` trifft es der Aufruf nicht, und das steht auf `.Machine$double.eps^0.25`, also auf rund $1,2 \cdot 10^{-4}$.

Bemerkung 12.6.1 (Golden Section Search)

`optimize()` verwendet die *Golden Section Search*, eine Verwandte der Bisektion aus Abschnitt 12.1, die statt eines Vorzeichenwechsels ein Minimum einschachtelt. Zwei innere Testpunkte teilen das Intervall im Verhältnis des goldenen Schnitts; in jedem Schritt fällt das Teilintervall weg, das das Minimum nicht enthalten kann, und weil ein Testpunkt wiederverwendet wird, genügt ein neuer Funktionswert. So schrumpft das Intervall ohne Ableitungen pro Schritt auf das 0,618-fache. Verlässlich ist das für *unimodale* Funktionen, die bis zu einer Minimalstelle nicht ansteigen und danach nicht mehr fallen; ein eindeutiges globales Minimum allein genügt nicht.

Dazu kommt eine parabolische Interpolation (zusammen heißt das *Brent-Verfahren*): Solange es die drei zuletzt berechneten Punkte erlauben, springt der nächste Testpunkt in den Scheitel der Parabel durch sie. Führt der Sprung aus dem eingeschachtelten Intervall oder bringt er zu wenig, greift wieder der goldene Schnitt, sodass die Einschachtelung erhalten bleibt.

Multivariat: optim

Als Testfall dient uns die Funktion

$$f(\mathbf{x}) = \log(1 + (x_1^2 + \sin 3x_2)^2) + 0,1 x_1^2 + 0,1 x_2^2, \quad (12.6.1)$$

deren erster Term entlang der Kurven $x_1^2 + \sin 3x_2 = 0$ verschwindet, während die quadratischen Terme zum Ursprung ziehen. Das globale Minimum ist $\mathbf{x}^* = (0; 0)$ mit $f(\mathbf{x}^*) = 0$; im Fenster des Widgets liegen daneben genau zwei lokale Mulden.

```
f <- function(x) log1p((x[1]^2 + sin(3*x[2]))^2) +
  .1 * x[1]^2 + .1 * x[2]^2
optim(c(-1, -0.5), f)           # Default: Nelder-Mead
optim(c(-1, -0.5), f, method = "BFGS")
```

Ohne `method`-Argument verwendet `optim()` das ableitungsfreie Nelder-Mead-Verfahren aus Abschnitt 12.3, mit `method = "BFGS"` das Quasi-Newton-Verfahren aus Abschnitt 12.4; den Gradienten schätzt es dann mangels `gr`-Argument durch finite Differenzen. Ein über `gr` übergebener Gradient wechselt die Methode nicht, das tut nur `method`. Von diesem Startpunkt aus landen beide Verfahren im globalen Minimum.

Bemerkung 12.6.2 (Falsche Konvergenz ohne Warnung)

Drei Aufrufe zeigen zwei Probleme:

```
optim(c(-1, 1), f)           # Nelder-Mead
optim(c(-0.5, -1), f, method = "BFGS") # BFGS
optim(c(-1, -0.5), f, control = list(maxit = 50)) # abgeschnitten
```

Lokale Minima. Die beiden spiegelbildlichen Mulden liegen bei $(0; \pm 1,04)$ mit $f \approx 0,11$. Vom Startpunkt $(-1; 1)$ aus endet der Lauf in der oberen, von $(-0,5; -1)$ aus in der unteren, und `optim()` meldet trotzdem Konvergenz: `convergence = 0` heißt nur, dass ein Abbruchkriterium erfüllt ist, nicht, dass das Ergebnis global optimal ist (Abschnitt 12.2).

Abgebrochene Läufe. Begrenzen wir die Iterationen, etwa mit `control = list(maxit = 50)`, kann `optim()` mitten am Hang stehen bleiben. Das Ergebnis sieht aus wie immer, nur der `convergence`-Code (dann $\neq 0$) verrät den Abbruch; eine Warnung gibt es nicht. Abbruchkriterien prüfen heißt hier: den Rückgabewert lesen, statt sich auf `warnings()` zu verlassen (Abschnitt 12.3, Abbruchkriterien).

Interaktiv: Die Landkarte zur Beispielfunktion

Das Widget zeichnet die Funktion aus (12.6.1) als Karte und lässt uns den Startpunkt setzen, per Klick, per Zug oder über die beiden Regler. Weil das Widget mit Gradientenabstieg rechnet, sind das die Einzugsgebiete *dieses* Verfahrens; Nelder-Mead und BFGS nehmen andere Wege und können von manchen Startpunkten aus in einer anderen Mulde enden als die blaue Spur.

Schätzfrage. Wie viele verschiedene Grenzwerte findet der Gradientenabstieg auf diesem Ausschnitt?

Lösung: drei

Es sind genau drei: das globale Minimum $(0; 0)$ mit $f = 0$ und zwei lokale Mulden bei $(0; \pm 1,0357)$ mit $f = 0,1085$.

Von den drei voreingestellten Startpunkten führt $(-1; -0,5)$ ins globale Minimum, $(-1; 1)$ in die obere und $(-0,5; -1)$ in die untere Mulde. Alle drei Läufe enden regulär, mit Gradient null, positiv definiter Hesse-Matrix und ohne Warnung, und doch landen zwei im falschen Minimum. Dagegen hilft keine bessere Schrittweite, nur weitere Startpunkte.

Der analytische Gradient

Wer den Gradienten kennt, sollte ihn `optim()` übergeben: Finite Differenzen kosten pro Gradient n (einseitig) oder $2n$ (zentral) zusätzliche Funktionsauswertungen und bringen Rundungsfehler mit (Kapitel 4). Der analytische Gradient ist schneller und genauer.

Beispiel 12.6.3 (Kettenregel für die Beispielfunktion)

Mit $u(\mathbf{x}) = x_1^2 + \sin 3x_2$ ist $f = \log(1 + u^2) + 0,1x_1^2 + 0,1x_2^2$, und die Kettenregel (Abschnitt 10.6) liefert wegen $\frac{d}{du} \log(1 + u^2) = \frac{2u}{1+u^2}$:

$$\nabla f(\mathbf{x}) = \left(\frac{4x_1 u}{1 + u^2} + 0,2 x_1, \quad \frac{6 \cos(3x_2) u}{1 + u^2} + 0,2 x_2 \right).$$

```
grad_f <- function(x) {
  u <- x[1]^2 + sin(3*x[2])
  d <- 2 * u / (1 + u^2)
  c(d * 2 * x[1] + .2 * x[1],
    d * 3 * cos(3*x[2]) + .2 * x[2])
}
optim(c(-1, -0.5), f, gr = grad_f, method = "BFGS")
optim(c(-1, 0.5), f, gr = grad_f, method = "L-BFGS-B",
      lower = c(-1, -1), upper = c(1, 1))
```

L-BFGS-B ist die speicherschonende BFGS-Variante aus Abschnitt 12.4, erweitert um Box-Nebenbedingungen `lower/upper`; damit sind wir zurück bei der beschränkten Optimierung aus Abschnitt 12.5.

Wann welches Verfahren

Methode	Wann verwenden?
Bisektion, Newton-Raphson	Nullstellen $f(x) = 0$; Bisektion nur univariat
Nelder-Mead	Keine Ableitungen, niedrige Dimension ($n \leq 10$)
Gradientenabstieg	Große Probleme, einfache Implementierung
Quasi-Newton (BFGS)	Mittlere Probleme, guter Kompromiss
Newton	Kleine Probleme, schnelle Konvergenz nötig
Momentum	Gradientenabstieg bei schlecht konditionierten Problemen
SGD	Sehr große Datensätze und hohe Dimension
Lagrange/KKT	Nebenbedingungen

Was bleibt

Bemerkung 12.6.4 (Kernkonzepte des Kapitels)

1. **Nichtlineare Gleichungen:** Die Bisektion halbiert verlässlich, aber langsam; Newton-Raphson konvergiert lokal quadratisch, $e_{k+1} \approx C e_k^2$ (Abschnitt 12.1).
2. **Optimalität** heißt stationär plus Krümmungsbedingung; ohne Konvexität drohen lokale Minima und Sattelpunkte (Abschnitt 12.2).
3. **Gradientenabstieg** hängt an der Schrittweite; für $\gamma = 1/L$ konvergiert er bei starker

Konvexität linear mit $\rho = 1 - \mu/L$, und die Kondition $\kappa_f = L/\mu$ bestimmt den Zickzack (Abschnitt 12.3).

4. **Newton und Quasi-Newton** konvergieren mit Krümmungsinformation schneller, bei teureren Schritten; SGD ersetzt den Gradienten durch einen unverzerrten Schätzer aus zufällig gezogenen Beobachtungen (Abschnitt 12.4).
5. **Nebenbedingungen:** Lagrange-Multiplikatoren und KKT-Bedingungen bringen die Gradienten von Ziel und Nebenbedingungen ins Gleichgewicht; Ridge und Lasso sind die statistischen Musterbeispiele (Abschnitt 12.5).

Selbsttest

1. Die Bisektion auf $[0, 8]$ braucht für die Zielgenauigkeit $\epsilon = 10^{-3}$ genau 13 Halbierungen.

Antwort: Wahr

Nach Satz 12.1.8 sind es $\lceil \log_2((b-a)/\epsilon) \rceil = \lceil \log_2 8000 \rceil$ Schritte, und wegen $2^{12} = 4096 < 8000 \leq 8192 = 2^{13}$ sind das 13.

2. Der Gradientenabstieg auf $f(x) = x^2$ konvergiert für jede feste Schrittweite $\gamma > 0$.

Antwort: Falsch

Der Schritt lautet $x^{(k+1)} = (1 - 2\gamma) x^{(k)}$. Für $\gamma \geq 1$ ist $|1 - 2\gamma| \geq 1$: Bei $\gamma = 1$ springt die Iteration zwischen $x^{(0)}$ und $-x^{(0)}$ hin und her, für $\gamma > 1$ wächst der Betrag sogar. Konvergenz braucht hier $\gamma < 1 = 2/L$ mit $L = 2$ (Abschnitt 12.3).

3. Meldet `optim()` `convergence = 0`, so hat es das globale Minimum gefunden.

Antwort: Falsch

`convergence = 0` heißt nur, dass ein Abbruchkriterium erfüllt ist. Ein lokales Minimum wie die beiden Mulden der Beispielfunktion erfüllt es genauso (Bemerkung 12.6.2).

4. In den KKT-Bedingungen müssen auch die Multiplikatoren λ_i der Gleichungsnebenbedingungen nichtnegativ sein.

Antwort: Falsch

Nur die μ_j der Ungleichungen tragen die Vorzeichenbedingung $\mu_j \geq 0$; die λ_i sind frei. Beispiel 12.5.6 hat $\lambda^* = -1$.

5. Ist eine Ungleichungs-Nebenbedingung im Optimum inaktiv, so ist ihr KKT-Multiplikator null.

Antwort: Wahr

Das ist die Komplementarität $\mu_j h_j(\mathbf{x}^*) = 0$ aus Satz 12.5.7: Aus $h_j(\mathbf{x}^*) < 0$ folgt $\mu_j = 0$. In Beispiel 12.5.9 gilt das für die untere Schranke.

6. Welchen Funktionswert erreicht der Gradientenabstieg im Landkarten-Widget, wenn wir bei $(-1; 1)$ starten?

Lösung: 0.1085

Er landet in der oberen Mulde bei $(0; 1,0357)$ mit $f = 0,1085$. Das globale Minimum liegt bei $(0; 0)$ mit $f = 0$, also gut ein Zehntel tiefer. Der Lauf endet trotzdem mit verschwindendem Gradienten und ohne Warnung, also mit „falscher Konvergenz“ im Sinn von Bemerkung 12.6.2.

7. Weil $-\nabla f$ die Richtung des steilsten Abstiegs ist, verkleinert jeder Gradientenabstiegs-Schritt den Funktionswert.

Antwort: Falsch

Die Richtung stimmt, solange $\nabla f \neq \mathbf{0}^\top$ ist, aber die Schrittweite kann den Abstieg überschießen: Auf $f(x) = x^2$ mit $\gamma = 1$ gilt $x^{(k+1)} = -x^{(k)}$ und der Funktionswert bleibt exakt gleich, mit $\gamma > 1$ wächst er. Dagegen sichert die Armijo-Bedingung aus Abschnitt 12.3 ab.

Vertiefung: Heath, Scientific Computing, behandelt in Kapitel 5 die nichtlinearen Gleichungen und in Kapitel 6 die Optimierung, jeweils mit den hier gezeigten Verfahren; die R-Seite dokumentieren die Hilfeseiten zu `optimize()` und `optim()`. Zum stochastischen Gradientenabstieg führt der MSc-Kurs Optimization for ML weiter.

12.7 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Review Question 6.14	Ein Newton-Schritt – exakt beim Minimieren, nicht beim Nullstellensuchen	leicht, ca. 15 Min.
Heath Exercise 6.3	Optimalitätsbedingungen für x^2 , x^3 , x^4 und $-x^4$	leicht, ca. 15 Min.
Heath Exercise 6.5	Kritische Punkte im $\mathbb{R}^2$ klassifizieren	mittel, 1 Std. und mehr
Heath Review Question 6.23	Gradientenabstieg – wann versagt er, wann konvergiert er schnell?	mittel, ca. 15 Min.
Heath Review Question 6.27	Schrittweitensteuerung bei Gradientenabstieg und Newton	mittel, ca. 15 Min.
Heath Exercise 6.9	Newton und Gradientenabstieg bei quadratischer Zielfunktion	mittel, ca. 30 Min.
Heath Exercise 6.8	Ein Newton-Schritt für die Rosenbrock-Funktion – gut und schlecht zugleich	mittel, ca. 30 Min.
Heath Exercise 6.6	Kritische Punkte der Lagrange-Funktion klassifizieren	mittel, 1 Std. und mehr
Heath Review Question 6.38	Was sind Lagrange-Multiplikatoren – und wozu?	leicht, ca. 15 Min.
Heath Review Question 6.39	Lagrange-Funktion und notwendige Optimalitätsbedingung	leicht, ca. 15 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Schaback/Wendland Aufgabe 7.1	k -te Wurzel mit dem Newton-Verfahren	mittel, ca. 30 Min.
Schaback/Wendland Aufgabe 7.6	Newton-Verfahren für konvexe Funktionen	schwer, 1 Std. und mehr
Heath Exercise 6.4	Kritische Punkte kubischer Polynome und von $x^2 e^x$	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 7.1	Stationäre Punkte von $x^3 + 6x^2 - 3x - 5$	leicht, ca. 15 Min.
Heath Review Question 6.15	Konvergenzraten univariater Minimierungsverfahren	leicht, ca. 15 Min.
Heath Review Question 6.16	Konvergenzraten multivariater Minimierungsverfahren	leicht, ca. 15 Min.
Deisenroth et al. (MML) Exercise 7.2	SGD-Update bei Mini-Batch-Größe 1	leicht, ca. 15 Min.
Heath Review Question 6.24	Wann nützt eine Liniensuche beim Newton-Verfahren – und wann nicht?	mittel, ca. 15 Min.
Heath Review Question 6.25	Welche Faktorisierung für welches lineare Teilproblem?	mittel, ca. 15 Min.
Heath Review Question 6.30	Worauf reduziert sich die erste BFGS-Iteration?	leicht, ca. 15 Min.
Heath Review Question 6.19 b), c)	Maximale Iterationszahl bei quadratischer Zielfunktion	mittel, ca. 15 Min.
Heath Exercise 6.7	Optimalitätsbedingungen unter einer linearen Nebenbedingung	mittel, ca. 30 Min.
Heath Computer Problem 6.9	Steepest Descent, Newton und gedämpftes Newton für die Rosenbrock-Funktion	schwer, 1 Std. und mehr

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deisenroth et al. (MML) Exercise 7.5	Lineares Programm in Standardform	mittel, ca. 15 Min.
Deisenroth et al. (MML) Exercise 7.6	Duales lineares Programm via Lagrange-Dualität	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 7.7	Duales quadratisches Programm via Lagrange-Dualität	mittel, ca. 30 Min.
Deisenroth et al. (MML) Exercise 7.8	Lagrange-duales Problem für $\min \frac{1}{2} \mathbf{w}^T \mathbf{w}$ unter $\mathbf{w}^T \mathbf{x} \geq 1$	mittel, ca. 30 Min.

Bücher: Heath: *Scientific Computing* (2. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.); Deisenroth et al. (MML): *Mathematics for Machine Learning*.

Funktionsapproximation

13.1 Approximation, Interpolation, Glättung

Mit diesem Kapitel beginnt der dritte Block des Skripts (Abschnitt 1.1). Die Aufgabe: Gegeben sind n Datenpunkte $(x_1, y_1), \dots, (x_n, y_n)$ mit paarweise verschiedenen x_i , gesucht ist eine Funktion $\hat{f}$, die zu ihnen passt. Manchmal stammen die Punkte nicht aus einer Messung, sondern sind Auswertungen einer bekannten Funktion f , die zu teuer ist, um sie an beliebig vielen Stellen auszurechnen.

Interaktiv: Konzeptkarte des Kapitels

Die Karte zeigt, wie die Begriffe dieses Kapitels zusammenhängen und auf welche Bausteine aus dem ersten Teil des Skripts sie zurückgreifen; beim ersten Lesen genügt der Gesamteindruck.

Interaktives Element — nur in der Web-Fassung

Ein ausgewählter Begriff hebt seine Voraussetzungen und Folgerungen hervor; verlinkte Kästen führen zum zugehörigen Kapitel.

Vorkenntnisse

- Lineare Gleichungssysteme $\mathbf{B}\mathbf{a} = \mathbf{y}$ und ihre Lösbarkeit (Abschnitt 5.2); jede Interpolationsaufgabe dieses Kapitels endet in einem solchen System.
- Die Konditionszahl einer Matrix (Abschnitt 4.2, Abschnitt 3.5); sie entscheidet ab Abschnitt 13.3, welches Basissystem brauchbar ist.
- Basen und lineare Unabhängigkeit, diesmal in einem Vektorraum aus Funktionen.
- Polynome samt Grad und Monombasis, Stetigkeit, Differenzierbarkeit und stückweise definierte Funktionen.
- Normen (Abschnitt 3.2), vor allem die *Supremumsnorm* $\|g\|_\infty = \sup_{x \in [a,b]} |g(x)|$ einer Funktion g auf $[a, b]$; für stetiges g ist das der größte Betrag, den g dort annimmt.

Drei Varianten desselben Wunsches

„Passt“ lässt sich auf drei Weisen verlangen. Alle drei Aufgaben liefern am Ende ein $\hat{f}$, verlangen aber sehr Verschiedenes von ihm.

Definition 13.1.1 (Approximationsproblem)

Gegeben seien eine Funktion f auf $[a, b]$, eine Norm $\|\cdot\|$ auf einem Funktionenraum, der f enthält, und eine vorgegebene, einfacher handhabbare Klasse $\mathcal{A}$ von Funktionen. Gesucht ist ein $\hat{f} \in \mathcal{A}$, das den Abstand zu f minimiert oder dem bestmöglichen Abstand wenigstens nahekommmt:

$$\|f - \hat{f}\| \approx \inf_{g \in \mathcal{A}} \|f - g\|.$$

Die Bedingung ist global: $\hat{f}$ soll f überall auf $[a, b]$ nahekommen, muss es aber an keiner einzigen Stelle exakt treffen. Ist $\hat{f}$ ein Minimierer, gilt Gleichheit.

Definition 13.1.2 (Interpolationsproblem)

Gegeben seien Datenpunkte (x_i, y_i) , $i = 1, \dots, n$, mit paarweise verschiedenen x_i . Gesucht ist ein $\hat{f}$ mit

$$\hat{f}(x_i) = y_i, \quad i = 1, \dots, n. \quad (13.1.1)$$

Jede Funktion mit dieser Eigenschaft heißt *Interpolant* (interpolant) der Daten, die x_i heißen *Stützstellen* (nodes). Die Bedingung ist punktweise und exakt: An den n Stützstellen muss $\hat{f}$ die Werte treffen, zwischen ihnen ist alles erlaubt.

Definition 13.1.3 (Glättungsproblem)

Gegeben seien Datenpunkte (x_i, y_i) , $i = 1, \dots, n$, die aus einer unbekannten Funktion f und Fehlern entstanden sind:

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, n.$$

Gesucht ist eine Schätzung $\hat{f}$ von f , die das Signal trifft, statt jeden beobachteten Fehler mitzuzeichnen. Die ε_i sind in aller Regel Zufallsvariablen; die Residuen $y_i - \hat{f}(x_i)$ sind dagegen aus den Daten berechenbare Abweichungen und nicht mit den unbeobachteten Fehlern gleichzusetzen.

Bemerkung 13.1.4 (Daten oder Funktion?)

Die Interpolationsbedingung wird mal als $f(x_i) = \hat{f}(x_i)$ geschrieben, mal als $y_i = \hat{f}(x_i)$; bei rauschfreien Daten, also $y_i = f(x_i)$, ist das dasselbe. Bei der Glättung ist f unbekannt, nur die verrauschten y_i liegen vor. Wir schreiben deshalb durchgehend y_i und sagen dazu, ob $y_i = f(x_i)$ gelten soll.

Interaktiv: Die drei Aufgaben nebeneinander

Wann wird aus Glättung wieder Interpolation? Wir variieren dafür nur das Rauschen.

Interaktives Element — nur in der Web-Fassung

Bei der Approximation darf $\hat{f}$ überall ein wenig danebenliegen, bei der Interpolation nirgends an den Knoten und dazwischen beliebig. Nur bei $\sigma = 0$ fallen Glättung und Interpolation

zusammen.

Wie die drei Aufgaben zusammenhängen

Bemerkung 13.1.5 (Approximation über Interpolation)

Ein wichtiger Weg zu einer Approximation führt über Interpolation: Wir werten f an endlich vielen Stellen x_i aus und interpolieren die Paare $(x_i, f(x_i))$; aus der Bedingung (13.1.1) wird in Abschnitt 13.2 ein lineares Gleichungssystem. Andere Verfahren minimieren die Norm $\|f - \hat{f}\|$ tatsächlich direkt, etwa Kleinste Quadrate oder eine Minimax-Approximation. Sind die Auswertungen fehlerbehaftet, tritt an die Stelle der Interpolation ein Glättungsproblem. Die Glättung ist die schwierigste der drei Varianten, weil sie entscheiden muss, welcher Teil der Daten Signal und welcher Rauschen ist, und dafür ein stochastisches Modell für die ε_i braucht. Dieses Kapitel behandelt deshalb zuerst die Interpolation; die Glättung folgt in Abschnitt 13.7.

Wozu wir das brauchen

Klassisch sind drei Anlässe. Für eine Grafik brauchen wir eine glatte Kurve durch eine Punktwolke. Erfordert jede Auswertung von f ein numerisches Verfahren, etwa bei $f(x) = \int_0^x g(y) dy$ oder $f(x) = g^{-1}(x)$, ist es billiger, f an wenigen Stellen zu bestimmen und dazwischen zu interpolieren. Und ein Polynom oder ein Spline lässt sich exakt differenzieren und integrieren; das Ergebnis dient als Näherung für f' beziehungsweise $\int f$.

Auch im maschinellen Lernen ist oft von Interpolation die Rede, aber nicht immer im Sinn von Definition 13.1.2. Computergrafik (Pixelwerte beim Drehen oder Skalieren eines Bildes) und Zeitreihen (Auffüllen fehlender Werte) sind Interpolation in diesem Sinn. Latent-Space-Interpolation in generativen Modellen und Positional Encodings in Transformern sind nur Analogien.

Vertiefung (optional): Interpolation im maschinellen Lernen

Bemerkung 13.1.6 (Interpolation im maschinellen Lernen, und was nur so aussieht)

Zwei der vier Anwendungen sind Interpolation im Sinn von Definition 13.1.2:

- *Computergrafik.* Wird ein Bild gedreht oder skaliert, liegen die neuen Pixelmittelpunkte zwischen den alten. Bilineare und bikubische Verfahren legen eine Funktion durch die umliegenden Pixelwerte und werten sie an der neuen Stelle aus.
- *Zeitreihen.* Fehlende Werte in Sensor- oder Finanzdaten werden aufgefüllt, indem eine Kurve durch die vorhandenen Messzeitpunkte gelegt wird.

Die beiden anderen sind nur Analogien:

- *Latent-Space-Interpolation* in VAEs und GANs interpoliert linear zwischen zwei Codes, $\mathbf{z}(t) = (1-t)\mathbf{z}_0 + t\mathbf{z}_1$. Das ist Interpolation im Argumentraum mit $n = 2$ Stützstellen. Über das erzeugte Bild sagt sie nichts: Ob der Übergang glatt aussieht, hängt am Decoder, nicht an einer Interpolationsbedingung.
- *Positional Encodings* wie RoPE werten feste Sinus- und Kosinusfunktionen an den Token-Positionen aus. Eine Bedingung der Form $\hat{f}(x_i) = y_i$ kommt darin nicht vor; gemeinsam sind mit unserem Thema nur dieselben Sinus- und Kosinusfunktionen. Interpolation im engen Sinn taucht dort erst auf, wenn ein trainiertes Modell auf längere Kontexte umskaliert wird.

Ein Grenzfall ist die Idee, die feste Aktivierungsfunktion eines neuronalen Netzes durch eine lernbare, spline-basierte zu ersetzen (*Kolmogorow-Arnold-Netze*). Die Splines aus Abschnitt 13.4 sind dort das Modell selbst; ihre Koeffizienten werden allerdings trainiert und nicht aus Interpolationsbedingungen bestimmt.

Warum die Interpolationsbedingung zu wenig ist

Interpolation stellt n Gleichungen an eine Funktion. Eine Funktion hat unendlich viele Freiheitsgrade, und deshalb bleibt nach diesen n Gleichungen sehr viel offen.

Beispiel 13.1.7 (Vier Interpolanten durch drei Punkte)

Betrachten wir die $n = 3$ Punkte $(0, 1)$, $(1, 2)$, $(2, 5)$. Die folgenden vier Funktionen interpolieren sie alle:

$$\begin{aligned}\hat{f}_1(x) &= 1 + x^2, \\ \hat{f}_2(x) &= \begin{cases} x + 1 & x \in [0, 1] \\ 3x - 1 & x \in [1, 2] \end{cases}, \\ \hat{f}_3(x) &= x^3 - 2x^2 + 2x + 1, \\ \hat{f}_4(x) &= 1 + x^2 + 0,5 \sin(2\pi x).\end{aligned}$$

Die Probe ist jeweils eine Zeile, für $\hat{f}_1$ etwa $1 + 0 = 1$, $1 + 1 = 2$ und $1 + 4 = 5$, für $\hat{f}_3$ ebenso. Bei $\hat{f}_4$ verschwindet $\sin(2\pi x)$ an jeder ganzen Zahl, und $\hat{f}_2$ ist auf beiden Teilintervallen die Gerade durch die Endpunkte.

Zwischen den Stützstellen sehen die vier Funktionen dagegen völlig verschieden aus; wie weit sie dort auseinandergehen, legen die drei Bedingungen nicht fest.

Interaktiv: Vier Interpolanten, ein Datensatz

Wie weit können vier Interpolanten, die dieselben drei Punkte treffen, zwischen zwei Stützstellen auseinanderliegen?

Schätzfrage. Schätzen wir die größte Spanne auf $[0, 2]$.

Lösung: 0,75

Bei $x = 1,3$ liefern die vier Kurven 2,69, 2,90, 2,42 und 3,17, die höchste und die niedrigste trennt dort 0,75. Weiter gehen sie nirgends auseinander: Die größte Spanne ist 0,7499 bei $x \approx 1,288$.

Satz 13.1.8 erklärt, warum die Interpolationsbedingungen diese Zwischenwerte nicht festlegen.

Satz 13.1.8 (Gestalt aller Interpolanten)

Seien Daten (x_i, y_i) , $i = 1, \dots, n$, gegeben und sei p irgendein Interpolant dieser Daten. Dann ist eine Funktion $\hat{f}$ genau dann ebenfalls ein Interpolant, wenn sie sich schreiben lässt als

$$\hat{f} = p + g \quad \text{mit} \quad g(x_i) = 0 \quad \text{für } i = 1, \dots, n. \quad (13.1.2)$$

Vertiefung (optional): Beweis der allgemeinen Gestalt aller Interpolanten

Beweis.

- (1) Sei zunächst g eine Funktion mit $g(x_i) = 0$ für alle i . Dann gilt für jedes i

$$(p + g)(x_i) = p(x_i) + g(x_i) = y_i + 0 = y_i,$$

also interpoliert $p + g$ die Daten.

Funktionen werden punktweise addiert, und p ist nach Voraussetzung ein Interpolant

- (2) Sei umgekehrt $\hat{f}$ ein Interpolant. Wir setzen $g := \hat{f} - p$ und erhalten für jedes i

$$g(x_i) = \hat{f}(x_i) - p(x_i) = y_i - y_i = 0.$$

Mit diesem g ist $\hat{f} = p + g$ von der Form (13.1.2).

beide Funktionen erfüllen die Interpolationsbedingung (13.1.1) an derselben Stelle x_i

□

Bemerkung 13.1.9 (Unendlich viele Lösungen)

Die Menge der Funktionen g mit $g(x_i) = 0$ für alle i ist ein Untervektorraum des Funktionenraums, und er ist unendlichdimensional: Für jedes Polynom q liegt $q(x) \prod_{i=1}^n (x - x_i)$ darin, und diese Produkte sind für verschiedene Grade von q linear unabhängig. Schon der Spezialfall $g_c(x) = c \prod_{i=1}^n (x - x_i)$ liefert für jedes $c \in \mathbb{R}$ einen weiteren Interpolanten. Damit hat das Interpolationsproblem aus Definition 13.1.2 stets unendlich viele Lösungen, sobald wir $\hat{f}$ nicht weiter einschränken.

Die Differenzen aus Beispiel 13.1.7 sind von dieser Bauart: Mit $p = \hat{f}_1$ ist $\hat{f}_3 - p = x(x-1)(x-2)$ und $\hat{f}_4 - p = 0,5 \sin(2\pi x)$, und auch $\hat{f}_2 - p$ verschwindet an 0, 1 und 2.

Interpolation allein legt also nichts fest. Erst ein *Basissystem* schränkt die Auswahl so ein, dass so viele Freiheitsgrade übrig bleiben, wie wir Datenpunkte haben: Wir lassen nur Linearkombinationen von K Basisfunktionen zu, und aus der Interpolationsbedingung wird ein lineares Gleichungssystem

chungssystem in den K Koeffizienten (Abschnitt 13.2). Die Wahl der Basis entscheidet dann über die Kondition dieses Systems und darüber, ob eine lokale Datenänderung die Kurve global verbiegt (Abschnitt 13.4).

Selbsttest

1. Zu Daten (x_i, y_i) , $i = 1, \dots, n$, mit paarweise verschiedenen x_i gibt es unendlich viele Funktionen $\hat{f}$ mit $\hat{f}(x_i) = y_i$ für alle i .

Antwort: Wahr

Das ist Bemerkung 13.1.9. Ist p ein Interpolant, so ist nach Satz 13.1.8 auch $p + c \prod_i (x - x_i)$ für jedes $c \in \mathbb{R}$ einer, und verschiedene c liefern verschiedene Funktionen.

2. Aus $\hat{f}(x_i) = y_i$ für $i = 1, \dots, n$ folgt $\|f - \hat{f}\| \approx 0$.

Antwort: Falsch

Die Interpolationsbedingung sagt über die Stellen zwischen den Stützstellen nichts. In Beispiel 13.1.7 erfüllen alle vier Funktionen dieselben drei Bedingungen und liegen bei $x = 1,3$ trotzdem 0,75 auseinander; höchstens eine von ihnen kann einem gegebenen f nahekommen.

3. Beschränken wir $\hat{f}$ auf Polynome vom Grad höchstens $n - 1$, so hat das Interpolationsproblem bei paarweise verschiedenen x_i genau eine Lösung.

Antwort: Wahr

Das ist der Eindeigkeitsatz der Polynominterpolation aus Abschnitt 13.3. Ohne den Zusatz „vom Grad höchstens $n - 1$ “ wäre die Aussage falsch; so gelesen widerspräche sie der ersten Aussage dieses Selbsttests.

4. Beim Glättungsproblem verlangen wir wie bei der Interpolation, dass $\hat{f}$ durch alle Datenpunkte läuft.

Antwort: Falsch

Definition 13.1.3 lässt Residuen $y_i - \hat{f}(x_i) \neq 0$ ausdrücklich zu. Bei verrauschten Daten wäre eine Kurve durch alle Punkte die falsche Antwort, weil sie das Rauschen mit abbildet.

5. Ein Interpolant muss ein Polynom sein.

Antwort: Falsch

Definition 13.1.2 verlangt nur die n Gleichungen an den Stützstellen. $\hat{f}_2$ aus Beispiel 13.1.7 ist stückweise linear und an $x = 1$ nicht differenzierbar, $\hat{f}_4$ enthält einen Sinusterm; beide interpolieren. Polynome sind eine praktische Wahl, keine Vorschrift.

Vertiefung: Heath, *Scientific Computing*, Kapitel 7 (Interpolation), führt in §7.1 dieselbe Aufgabenstellung ein und diskutiert, nach welchen Kriterien eine Funktionenklasse für die Interpolation ausgewählt wird.

13.2 Interpolation durch Basisdarstellung

Abschnitt 13.1 hat ein Problem offengelassen: Durch dieselben drei Punkte laufen eine Parabel, ein Polygonzug, ein kubisches Polynom und eine wellige Sinuskurve, und alle vier erfüllen die Interpolationsbedingungen exakt. Wir suchen den Interpolanten deshalb nur noch in einem kleinen, endlichdimensionalen Ansatzraum. Aus der Suche nach einer Funktion wird damit die Suche

nach endlich vielen Zahlen, und dafür haben wir seit Kapitel 5 die Werkzeuge.

Funktionen als Vektoren

Definition 13.2.1 (Der Vektorraum der Funktionen)

Sei $\mathcal{F} = \{f : [a, b] \rightarrow \mathbb{R}\}$ die Menge aller reellwertigen Funktionen auf einem Intervall $[a, b]$. Mit den punktweise erklärten Verknüpfungen

$$(f + g)(x) = f(x) + g(x), \quad (\alpha \cdot f)(x) = \alpha \cdot f(x), \quad \alpha \in \mathbb{R},$$

ist $\mathcal{F}$ ein Vektorraum über $\mathbb{R}$.

Nachzurechnen ist daran wenig: Assoziativität, Kommutativität und die Distributivgesetze erbt $\mathcal{F}$ punktweise von $\mathbb{R}$, die Nullfunktion $x \mapsto 0$ ist das neutrale Element, und $-f$ ist das Inverse zu f . Anders als der $\mathbb{R}^n$ ist $\mathcal{F}$ aber unendlichdimensional, und deshalb legen n Interpolationsbedingungen nichts fest (Abschnitt 13.1).

Vertiefung (optional): Die Auswertungsabbildung und der Rangsatz

Was heißt der Befund aus Abschnitt 13.1 in dieser Sprache? Dort war jeder Interpolant von der Gestalt $p + g$ mit einer Funktion g , die an allen Stellen x_i verschwindet. So sieht auch die Lösungsmenge eines linearen Gleichungssystems aus, und das hat einen Grund.

Bemerkung 13.2.2 (Unendlich viele Freiheitsgrade, endlich viele Bedingungen)

Die Auswertungsabbildung

$$E : \mathcal{F} \rightarrow \mathbb{R}^n, \quad E(f) = (f(x_1), \dots, f(x_n))^T,$$

ist linear, und die Interpolanten der Daten $\mathbf{y}$ sind genau die Urbilder von $\mathbf{y}$ unter E : eine spezielle Lösung plus der Kern, also genau die Gestalt aus Abschnitt 13.1. Der Kern ist unendlichdimensional, denn E misst nur n Zahlen aus einem unendlichdimensionalen Raum (Rangsatz).

Ansatzräume und Basisdarstellung

Statt in ganz $\mathcal{F}$ suchen wir nur noch in einem endlichdimensionalen Unterraum.

Definition 13.2.3 (Ansatzraum, Basisdarstellung, Basiskoeffizienten)

Seien $\phi_1, \dots, \phi_K : [a, b] \rightarrow \mathbb{R}$ fest gewählte Funktionen, genannt *Basisfunktionen* (basis functions). Der von ihnen aufgespannte Unterraum

$$\mathcal{F}_K = \text{span}\{\phi_1, \dots, \phi_K\} = \left\{ \sum_{k=1}^K a_k \phi_k \mid a_1, \dots, a_K \in \mathbb{R} \right\} \subset \mathcal{F}$$

heißt *Ansatzraum*. Eine Darstellung $f = \sum_{k=1}^K a_k \phi_k$ heißt *Basisdarstellung* von f , und $a_1, \dots, a_K$ heißen *Basiskoeffizienten*.

Ein Element von $\mathcal{F}_K$ ist damit durch seinen Koeffizientenvektor $\mathbf{a} = (a_1, \dots, a_K)^T \in \mathbb{R}^K$ beschrieben. Ob umgekehrt auch jede Funktion in $\mathcal{F}_K$ nur *einen* solchen Vektor besitzt, ist eine echte Zusatzforderung an die ϕ_k .

Satz 13.2.4 (Wann K Zahlen eine Funktion festlegen)

Die Koordinatenabbildung

$$\Phi: \mathbb{R}^K \rightarrow \mathcal{F}_K, \quad \Phi(\mathbf{a}) = \sum_{k=1}^K a_k \phi_k,$$

ist linear und surjektiv. Sie ist genau dann bijektiv, wenn $\phi_1, \dots, \phi_K$ linear unabhängig sind. In diesem Fall bilden sie eine Basis von $\mathcal{F}_K$, es gilt $\dim \mathcal{F}_K = K$, und jedes $f \in \mathcal{F}_K$ hat genau einen Koeffizientenvektor.

Vertiefung (optional): Beweis: Wann Koeffizienten eine Funktion eindeutig festlegen*Beweis.*

- (1) Linearität und Surjektivität stehen schon in Definition 13.2.3.

$\mathcal{F}_K$ ist als Menge aller Linearkombinationen definiert, also ist jedes Element ein Bild unter Φ ; die Linearität folgt aus den punktweisen Rechenregeln

- (2) Φ ist genau dann bijektiv, wenn $\text{Kern}(\Phi) = \{\mathbf{0}\}$ ist, und das ist genau die lineare Unabhängigkeit der ϕ_k .

eine surjektive lineare Abbildung ist genau dann bijektiv, wenn sie injektiv ist, und injektiv ist sie genau bei trivialem Kern; $\Phi(\mathbf{a}) = \mathbf{0}$ heißt ausgeschrieben $\sum_k a_k \phi_k(x) = 0$ für alle x , und dass daraus $\mathbf{a} = \mathbf{0}$ folgt, ist die Definition der linearen Unabhängigkeit

- (3) Ist Φ bijektiv, so ist es ein Isomorphismus zwischen $\mathbb{R}^K$ und $\mathcal{F}_K$; damit ist $\dim \mathcal{F}_K = K$, und die Basisdarstellung jedes $f \in \mathcal{F}_K$ ist eindeutig.

ein Isomorphismus bildet eine Basis auf eine Basis ab; das Bild der Standardbasis von $\mathbb{R}^K$ ist gerade $\phi_1, \dots, \phi_K$

□

Bemerkung 13.2.5 (Das Wort Basisfunktion trägt eine Voraussetzung mit)

Von den Koeffizienten zur Funktion ist der Weg immer eindeutig, denn Φ ist eine Abbildung; die Gegenrichtung braucht Satz 13.2.4. Wählen wir etwa $\phi_1(x) = 1$, $\phi_2(x) = x$ und $\phi_3(x) = 1 + x$, so ist $K = 3$, aber $\mathcal{F}_3$ besteht nur aus den Polynomen vom Grad höchstens 1 und hat die Dimension 2. Die Funktion $f(x) = 1 + x$ hat dort die Koeffizientenvektoren $(1, 1, 0)^\top$, $(0, 0, 1)^\top$ und unendlich viele weitere. Das Wort *Basisfunktion* setzt die lineare Unabhängigkeit stillschweigend voraus; wir prüfen sie im Zweifelsfall nach.

Beispiel 13.2.6 (Zwei Ansatzräume)

1. *Polynome vom Grad höchstens $n - 1$* : Mit der Monombasis $\phi_k(x) = x^{k-1}$ und $K = n$ ist $\mathcal{F}_K$ der Raum aller Polynome vom Grad höchstens $n - 1$. Die Monome sind linear unabhängig, also ist $\dim \mathcal{F}_K = n$. Diesen Ansatzraum behandelt Abschnitt 13.3.
2. *Splines vom Grad q über $m + 1$ Knoten*: Stückweise Polynome vom Grad höchstens q , die an den $m - 1$ inneren Knoten C^{q-1} -glatt aneinanderstoßen, bilden ebenfalls einen Ansatzraum. Bei einfachen inneren Knoten und dieser größtmöglichen Glattheit hat er $K = m + q$ Freiheitsgrade (Abschnitt 13.4).

Der Ansatz und sein Gleichungssystem

Gesucht ist jetzt nicht mehr eine Funktion, sondern ein Vektor aus K Zahlen.

Algorithmus 13.2.7 (Interpolation durch Basisdarstellung)

Gegeben seien Daten (x_i, y_i) , $i = 1, \dots, n$, mit paarweise verschiedenen x_i .

1. *Basissystem wählen:* Lege $\phi_1, \dots, \phi_K$ fest. Diese Funktionen sind bekannt.
2. *Ansatz machen:* $\hat{f}(x) = \sum_{k=1}^K a_k \phi_k(x)$ mit den unbekannten Koeffizienten $a_1, \dots, a_K$.
3. *Bedingungen hinschreiben:* $y_i = \hat{f}(x_i)$ für alle i ergibt das lineare Gleichungssystem $\mathbf{B}\mathbf{a} = \mathbf{y}$ aus Satz 13.2.8.
4. *System lösen* (Abschnitt 5.2) und die Koeffizienten in den Ansatz einsetzen.

Satz 13.2.8 (Das Interpolationsproblem ist ein lineares Gleichungssystem)

Sei $\mathbf{B} \in \mathbb{R}^{n \times K}$ die Matrix mit den Einträgen $B_{ik} = \phi_k(x_i)$, also

$$\mathbf{B} = \begin{pmatrix} \phi_1(x_1) & \cdots & \phi_K(x_1) \\ \vdots & \ddots & \vdots \\ \phi_1(x_n) & \cdots & \phi_K(x_n) \end{pmatrix} \in \mathbb{R}^{n \times K}, \quad \mathbf{a} = \begin{pmatrix} a_1 \\ \vdots \\ a_K \end{pmatrix} \in \mathbb{R}^K, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n.$$

Dann interpoliert $\hat{f} = \sum_{k=1}^K a_k \phi_k$ die Daten genau dann, wenn $\mathbf{B}\mathbf{a} = \mathbf{y}$ gilt.

Der Beweis ist kurz: Die i -te Komponente von $\mathbf{B}\mathbf{a}$ ist $\sum_{k=1}^K \phi_k(x_i) a_k = \hat{f}(x_i)$, die i -te Zeile der Gleichung ist also die i -te Interpolationsbedingung.

Bemerkung 13.2.9 (Was in $\mathbf{B}$ steckt und was nicht)

Die Matrix $\mathbf{B}$ liest sich zeilenweise wie eine Datentabelle: *eine Zeile je Datenpunkt, eine Spalte je Basisfunktion*.

- $\mathbf{B}$ hängt nur von den Stellen x_i und vom Basissystem ab, nicht von den gemessenen Werten y_i . Kommen neue Messwerte an denselben Stellen herein, bleibt die Matrix stehen, und eine einmal berechnete Zerlegung lässt sich wiederverwenden (Abschnitt 5.3).
- Für $n = K$ ist $\mathbf{B}$ quadratisch, und das System ist genau dann für jede rechte Seite eindeutig lösbar, wenn $\mathbf{B}$ invertierbar ist (Abschnitt 5.2). Das ist der Normalfall der Interpolation; die folgenden Abschnitte fragen, wie gut $\mathbf{B}$ dann konditioniert ist.
- Für $n > K$ gibt es in der Regel keinen exakten Interpolanten, und wir minimieren stattdessen die Residuen, also Kleinste Quadrate (Kapitel 7); das ist der Übergang zur Glättung. Für $n < K$ ist das Problem unterbestimmt.

Ein Beispiel von Hand

Beispiel 13.2.10 (Basisdarstellung konkret)

Gegeben seien die $n = 3$ Punkte $(0, 1)$, $(1, 2)$, $(2, 5)$ aus Abschnitt 13.1, dazu die Monobasis $\phi_k(x) = x^{k-1}$ mit $K = 3$. Der Ansatzraum ist der Raum der Polynome vom Grad höchstens 2,

der Ansatz lautet $\hat{f}(x) = a_1 + a_2x + a_3x^2$.

Die Matrix entsteht durch Auswerten der drei Basisfunktionen an den drei Stellen:

$$\mathbf{B} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} 1 \\ 2 \\ 5 \end{pmatrix}.$$

Wir lösen $\mathbf{B}\mathbf{a} = \mathbf{y}$ durch Einsetzen. Die erste Zeile liefert a_1 sofort, danach eliminieren wir:

$$\text{Zeile 1: } a_1 = 1,$$

$$\text{Zeile 2: } a_1 + a_2 + a_3 = 2 \implies a_2 + a_3 = 1 \implies a_2 = 1 - a_3,$$

$$\text{Zeile 3: } a_1 + 2a_2 + 4a_3 = 5 \implies 2a_2 + 4a_3 = 4 \implies 2 + 2a_3 = 4.$$

In Zeile 3 steckt bereits $a_2 = 1 - a_3$ aus Zeile 2. Aus der letzten Gleichung folgt $a_3 = 1$ und damit $a_2 = 0$. Der Koeffizientenvektor ist $\mathbf{a} = (1, 0, 1)^\top$, der Interpolant also

$$\hat{f}(x) = 1 + x^2.$$

Die Probe an allen drei Stellen geht auf: $\hat{f}(0) = 1$, $\hat{f}(1) = 2$, $\hat{f}(2) = 5$.

Bemerkung 13.2.11 (Einsetzen ist hier nicht Vorwärtssubstitution)

Der Rechenweg sieht aus wie Vorwärtssubstitution, ist aber Gauß-Elimination (Abschnitt 5.2): In Zeile 2 von $\mathbf{B}$ steht rechts der Diagonalen $\phi_3(x_2) = 1 \neq 0$, $\mathbf{B}$ ist also keine untere Dreiecksmatrix. Nur $x_1 = 0$ macht die erste Zeile so einfach.

Beispiel 13.2.12 (Dieselbe Funktion, andere Koeffizienten)

Wir behalten die Daten und wechseln nur das Basissystem, und zwar zur *Newton-Basis* zu den Knoten 0 und 1:

$$\phi_1(x) = 1, \quad \phi_2(x) = x, \quad \phi_3(x) = x(x-1).$$

Auch diese drei Funktionen spannen die Polynome vom Grad höchstens 2 auf, der Ansatzraum ist also unverändert. Die Matrix dagegen ändert ihre Gestalt:

$$\mathbf{B} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 2 & 2 \end{pmatrix}.$$

Sie ist eine untere Dreiecksmatrix, denn ϕ_2 verschwindet in 0 und ϕ_3 verschwindet in 0 und in 1. Jetzt greift die Vorwärtssubstitution, Zeile für Zeile von oben nach unten:

$$a_1 = 1 \implies a_1 = 1,$$

$$a_1 + a_2 = 2 \implies a_2 = 1,$$

$$a_1 + 2a_2 + 2a_3 = 5 \implies 2a_3 = 2 \implies a_3 = 1.$$

Der Koeffizientenvektor ist diesmal $\mathbf{a} = (1, 1, 1)^\top$, und ausmultipliziert steht dort

$$\hat{f}(x) = 1 + x + x(x-1) = 1 + x^2,$$

dieselbe Funktion wie in Beispiel 13.2.10. Anders kann es nicht sein, denn in den Polynomen vom Grad höchstens 2 ist der Interpolant durch drei Punkte eindeutig (Satz 13.3.5).

Der Ansatzraum bestimmt also den Interpolanten, das Basissystem nur seine Koeffizienten und den Rechenweg dorthin. Für die Numerik ist der Rechenweg allerdings wesentlich: Ein Dreieckssystem kostet $O(K^2)$ Operationen, die volle Elimination $O(K^3)$ (Abschnitt 5.3).

Interaktiv: Zwei Basen, ein Interpolant

Ändert ein Basiswechsel die Kurve oder nur die Koeffizienten? Und was am Gleichungssystem bleibt stehen, wenn wir einen Messwert verschieben?

Interaktives Element — nur in der Web-Fassung

Die Knoten $x_1 = 0$, $x_2 = 1$, $x_3 = 2$ bleiben fest, wir verschieben nur die Messwerte; deshalb bleibt $\mathbf{B}$ stehen, und nur die rechte Seite $\mathbf{y}$ wandert mit. Der Schalter wechselt das Basissystem, ohne den Ansatzraum zu ändern: Die Koeffizienten $\mathbf{a}$ springen, die grüne Kurve nicht. Die orangen Bausteine $a_k \phi_k$ summieren sich punktweise zu dieser Kurve.

Woran sich Basissysteme unterscheiden

Interpolationsverfahren unterscheiden sich im Wesentlichen durch die Wahl des Basissystems; vier Kriterien bestimmen den Rest des Kapitels.

- *Kondition.* Wie empfindlich reagieren die berechneten Koeffizienten auf Störungen der Daten? Das misst die Konditionszahl $\kappa(\mathbf{B})$ (Abschnitt 4.2); bei der Monombasis wächst sie mit K sehr schnell (Abschnitt 13.3).
- *Stabilität.* Ändert sich ein Messwert ein wenig, soll sich der Interpolant nur wenig ändern, am besten nur in der Nähe dieses Punktes. Ein globales Polynom ändert sich dagegen im ganzen Intervall, oft am stärksten weit weg von der Störung (Abschnitt 13.3).
- *Lokalität.* Ist jede Basisfunktion nur auf einem kleinen Teilintervall von null verschieden, wird $\mathbf{B}$ zur Bandmatrix; das leisten die B-Splines aus Abschnitt 13.4.
- *Effiziente Lösbarkeit.* Ein Bandsystem lässt sich mit linearem Aufwand in der Zahl der Unbekannten lösen, ein Dreieckssystem mit quadratischem, eine volle Matrix nur mit kubischem (Abschnitt 5.3, Abschnitt 2.4; zum Bandsystem Bemerkung 13.4.14).

Selbsttest

1. Im System $\mathbf{B}\mathbf{a} = \mathbf{y}$ hat $\mathbf{B}$ genau n Zeilen und K Spalten, und in Zeile i , Spalte k steht $\phi_k(x_i)$.

Antwort: Wahr

So steht es in Satz 13.2.8: Jede Zeile gehört zu einem Datenpunkt, jede Spalte zu einer Basisfunktion. Die Unbekannte ist der Koeffizientenvektor $\mathbf{a} \in \mathbb{R}^K$, die rechte Seite der Datenvektor $\mathbf{y} \in \mathbb{R}^n$.

2. Die Matrix $\mathbf{B}$ hängt von den gemessenen Werten y_i ab.

Antwort: Falsch

In $\mathbf{B}$ stehen ausschließlich Werte der Basisfunktionen an den Stellen x_i . Die Messwerte stehen komplett auf der rechten Seite. Deshalb dürfen wir für neue Daten an denselben Stellen dieselbe Matrix und dieselbe Zerlegung weiterverwenden (Bemerkung 13.2.9).

3. Sobald wir uns auf einen endlichdimensionalen Ansatzraum $\mathcal{F}_K$ beschränken, ist der Interpolant eindeutig.

Antwort: Falsch

Die Einschränkung allein genügt nicht. Suchen wir zu unseren drei Punkten in den Polynomen vom Grad höchstens 3, also mit $K = 4 > 3 = n$, so hat das System mehr Unbekannte als Gleichungen und weiterhin unendlich viele Lösungen; der kubische Interpolant aus Abschnitt 13.1 ist eine davon. Genau eine Lösung für jede rechte Seite gibt es erst, wenn B quadratisch und invertierbar ist.

4. Wechseln wir von der Monobasis zur Newton-Basis, so ändert sich der Interpolant.

Antwort: Falsch

Es ändern sich nur die Koeffizienten, von $(1, 0, 1)^\top$ auf $(1, 1, 1)^\top$. Beide Basen spannen denselben Ansatzraum auf, und in ihm gibt es zu drei verschiedenen Stellen nur einen Interpolanten, hier $1 + x^2$ (Beispiel 13.2.12). Im Widget springt die grüne Kurve beim Umschalten nicht.

5. Wählen wir K Basisfunktionen, so hat der Ansatzraum $\mathcal{F}_K$ die Dimension K .

Antwort: Falsch

Nur wenn die ϕ_k linear unabhängig sind (Satz 13.2.4). Mit $\phi_1(x) = 1$, $\phi_2(x) = x$ und $\phi_3(x) = 1+x$ ist $K = 3$, aber $\mathcal{F}_3$ enthält nur die Polynome vom Grad höchstens 1 und hat die Dimension 2; jede Funktion darin hat dann unendlich viele Koeffizientenvektoren (Bemerkung 13.2.5).

Vertiefung: Heath §7.1 (Interpolation, Wahl des Basissystems) und §7.2 (Existenz, Eindeutigkeit, Kondition).

13.3 Polynominterpolation

Abschnitt 13.2 hat das Interpolationsproblem auf das lineare Gleichungssystem $Ba = y$ zurückgeführt. Damit ist die Wahl des Ansatzraums die eigentliche Entscheidung, und die naheliegendste ist zugleich die älteste: Polynome, aufgeschrieben in der Monobasis. Theoretisch ist der Fall einfach: Durch n Punkte läuft genau ein Polynom vom Grad höchstens $n - 1$. Numerisch hat der Ansatz drei Probleme: Kondition, Stabilität und Konvergenz.

Wie viele Nullstellen ein Polynom haben kann

Die Eindeutigkeit hängt an einer Aussage über Nullstellen aus der Algebra.

Satz 13.3.1 (Fundamentalsatz der Algebra)

Jedes Polynom $p(x) = a_n x^n + \dots + a_1 x + a_0$ mit $a_n \neq 0$ und $n \geq 1$ hat mindestens eine Nullstelle in $\mathbb{C}$.

Gleichwertig dazu: Jedes Polynom vom Grad n hat in $\mathbb{C}$ genau n Nullstellen, wenn wir sie mit Vielfachheit zählen.

Korollar 13.3.2 (Zu viele Nullstellen erzwingen das Nullpolynom)

Sei p ein Polynom vom Grad höchstens $n - 1$ mit n paarweise verschiedenen Nullstellen. Dann ist p das Nullpolynom, es gilt also $p(x) = 0$ für alle x .

Vertiefung (optional): Gleichwertigkeit der Fassungen und Beweis der Folgerung

Die beiden Fassungen von Satz 13.3.1 gehen durch Polynomdivision auseinander hervor: Ist x_0 eine Nullstelle von p , so lässt sich der Linearfaktor abspalten, $p(x) = (x - x_0)q(x)$ mit $\deg q = n - 1$, und auf q wenden wir dieselbe Überlegung an. Nach n Schritten ist p vollständig in Linearfaktoren zerlegt.

Beweis.

- (1) Nehmen wir an, p sei nicht das Nullpolynom. Dann besitzt p einen Grad d mit $0 \leq d \leq n - 1$ und einen führenden Koeffizienten $a_d \neq 0$.

der Grad eines Polynoms ist der größte Index mit $a_d \neq 0$; nur das Nullpolynom hat gar keinen solchen Index

- (2) Im Fall $d = 0$ ist p die konstante Funktion $a_0 \neq 0$ und hat überhaupt keine Nullstelle. Das widerspricht der Voraussetzung, denn $n \geq 1$.

- (3) Im Fall $d \geq 1$ hat p nach Satz 13.3.1 mit Vielfachheit gezählt genau d Nullstellen in $\mathbb{C}$, also höchstens $d \leq n - 1$ verschiedene. Auch das widerspricht der Voraussetzung von n verschiedenen Nullstellen.

verschiedene Nullstellen zählen mindestens einfach, ihre Anzahl ist also höchstens die Zahl der mit Vielfachheit gezählten

- (4) Beide Fälle sind unmöglich, die Annahme fällt. Also ist p das Nullpolynom. □

Beispiel 13.3.3 (Drei Nullstellen bei Grad höchstens zwei)

Ein Polynom vom Grad höchstens 2 hat höchstens zwei verschiedene Nullstellen; das kennen wir von der Parabel. Finden wir also ein solches Polynom mit drei Nullstellen, etwa $p(-1) = p(0) = p(1) = 0$, so bleibt nur ein Schluss: p ist das Nullpolynom, und dann ist auch $p(7) = 0$ und $p(10^6) = 0$.

Genau ein Polynom durch n Punkte

Ansatzraum und Basismatrix kennen wir schon aus Beispiel 13.2.6; hier bekommen sie ihre Namen.

Definition 13.3.4 (Monobasis und Vandermonde-Matrix)

Die n Funktionen

$$\phi_1(x) = 1, \quad \phi_2(x) = x, \quad \dots, \quad \phi_n(x) = x^{n-1}$$

heißen *Monobasis* (monomial basis). Sie sind linear unabhängig und spannen den Ansatzraum $\mathcal{F}_n$ aller Polynome vom Grad höchstens $n - 1$ auf, der damit die Dimension n hat.

Die zugehörige Basismatrix aus Satz 13.2.8 zu Stellen $x_1, \dots, x_n$ heißt *Vandermonde-Matrix*:

$$\mathbf{B} = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

Dass die Monome linear unabhängig sind, folgt aus Korollar 13.3.2: Verschwindet $\sum_{k=1}^n a_k x^{k-1}$ für alle x , so hat dieses Polynom vom Grad höchstens $n - 1$ unendlich viele Nullstellen, ist also das Nullpolynom, und damit sind alle a_k null.

Satz 13.3.5 (Existenz und Eindeutigkeit der Polynominterpolation)

Zu n Paaren (x_i, y_i) , $i = 1, \dots, n$, mit paarweise verschiedenen x_i gibt es *genau ein* Polynom p vom Grad *höchstens* $n - 1$ mit

$$p(x_i) = y_i \quad \text{für } i = 1, \dots, n.$$

Gleichbedeutend damit ist: Die Vandermonde-Matrix zu paarweise verschiedenen Stellen ist invertierbar.

Beweis.

- (1) *Eindeutigkeit.* Seien p und q zwei Polynome vom Grad höchstens $n - 1$, die beide interpolieren. Für ihre Differenz gilt an jeder Stelle

$$(p - q)(x_i) = p(x_i) - q(x_i) = y_i - y_i = 0.$$

beide erfüllen dieselbe Interpolationsbedingung an derselben Stelle

- (2) Damit hat $p - q$ mindestens n verschiedene Nullstellen, obwohl der Grad höchstens $n - 1$ ist. Nach Korollar 13.3.2 ist die Differenz das Nullpolynom, also $p = q$.

die Differenz zweier Polynome vom Grad höchstens $n - 1$ hat wieder Grad höchstens $n - 1$

- (3) *Invertierbarkeit von B.* Sei $\mathbf{a} \in \mathbb{R}^n$ mit $\mathbf{B}\mathbf{a} = \mathbf{0}$. Nach Satz 13.2.8 heißt das: Das Polynom $\sum_{k=1}^n a_k x^{k-1}$ verschwindet an allen n Stellen. Korollar 13.3.2 macht daraus das Nullpolynom, und weil die Monome linear unabhängig sind, folgt $\mathbf{a} = \mathbf{0}$.

$\mathbf{B}$ ist der Vektor der Werte dieses Polynoms an den Stellen $x_1, \dots, x_n$

- (4) $\mathbf{B}$ ist quadratisch und hat nur den trivialen Kern, ist also invertierbar. Damit besitzt $\mathbf{B}\mathbf{a} = \mathbf{y}$ für jede rechte Seite genau eine Lösung, und das ist die *Existenz*: Zu jedem Datenvektor gehört ein interpolierendes Polynom, nämlich $p = \sum_{k=1}^n a_k \phi_k$.

□

Höchstens, nicht genau

Bemerkung 13.3.6 (Ein häufiges Missverständnis)

Satz 13.3.5 verspricht genau ein Polynom vom Grad *höchstens* $n - 1$, nicht vom Grad *genau* $n - 1$. Der führende Koeffizient darf null sein, und wenn die Daten schon auf einem Polynom kleineren Grades liegen, ist er es auch. Der Ansatzraum $\mathcal{F}_n$ enthält diese Polynome ebenfalls.

Beispiel 13.3.7 (Drei Punkte auf einer Geraden)

Für die $n = 3$ Punkte $(0, 0)$, $(1, 1)$, $(2, 2)$ lautet das System aus Satz 13.2.8

$$\begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ a_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix}, \quad \text{Lösung } \mathbf{a} = (0, 1, 0)^\top.$$

Das eindeutige Polynom vom Grad höchstens 2 ist also

$$p(x) = 0 \cdot x^2 + 1 \cdot x + 0 = x,$$

eine Gerade und damit vom Grad 1. Die Eindeutigkeit gilt trotzdem: Ein zweites Polynom vom Grad höchstens 2 durch dieselben drei Punkte gibt es nicht.

Der Rechenweg und sein Aufwand

Algorithmus 13.3.8 (Polynominterpolation in der Monombasis)

Gegeben seien Daten (x_i, y_i) , $i = 1, \dots, n$, mit paarweise verschiedenen x_i .

1. *Vandermonde-Matrix aufstellen:* $B_{ik} = x_i^{k-1}$.
2. *System lösen:* $\mathbf{B}\mathbf{a} = \mathbf{y}$ mit Gauß-Elimination (Abschnitt 5.2), Aufwand $O(n^3)$.
3. *Auswerten:* $p(x) = \sum_{k=1}^n a_k x^{k-1}$ an den gewünschten Stellen.

In R sind das wenige Zeilen, hier für $n = 10$ Stellen in $[0, 1]$ und eine Funktion f , deren Werte wir interpolieren.

```
x <- seq(0, 1, length = 10)
y <- f(x)

B <- outer(x, 0:9, "^") # Vandermonde-Matrix: cbind(1, x, x^2, ...)
a <- solve(B, y)

xnew <- seq(0, 1, length = 100)
fhat <- outer(xnew, 0:9, "^") %*% a

ggplot() + geom_point(aes(x, y)) + geom_line(aes(xnew, fhat))
```

`outer(x, 0:9, "^")` erzeugt die Matrix aus Definition 13.3.4, `solve` ruft die Elimination auf, und die Auswertung auf dem feinen Gitter ist wieder ein Matrix-Vektor-Produkt. Dieses 10×10 -System verliert allerdings etwa sieben der rund 16 Dezimalstellen doppelter Genauigkeit; warum, zeigt der nächste Unterabschnitt.

Problem 1: die Kondition der Monombasis

Bemerkung 13.3.9 (Warum die Spalten fast parallel werden)

Die k -te Spalte der Vandermonde-Matrix ist der Vektor

$$\mathbf{b}_k = (x_1^{k-1}, x_2^{k-1}, \dots, x_n^{k-1})^\top.$$

Für wachsendes k unterscheiden sich diese Vektoren immer weniger in ihrer *Richtung*: Auf $[0, 1]$ verkleinert jedes weitere Potenzieren alle Einträge außer dem letzten, der zu $x_n = 1$ gehört, und so konzentrieren sich die Vektoren immer mehr auf ihre letzten Komponenten. Bei $n = 10$ gleichmäßig verteilten Stellen in $[0, 1]$ schließen $\mathbf{b}_1$ und $\mathbf{b}_2$ noch einen Winkel von $32,6^\circ$ ein, $\mathbf{b}_5$ und $\mathbf{b}_6$ nur noch $5,5^\circ$, und $\mathbf{b}_9$ und $\mathbf{b}_{10}$ nur $2,7^\circ$.

Fast parallele Spalten heißen: fast linear abhängig, also eine Matrix, die einer singulären nahe kommt. Das misst die Konditionszahl $\kappa(\mathbf{B})$ (Abschnitt 4.2), und sie wächst hier sehr schnell.

Beispiel 13.3.10 (Konditionszahlen, der Größenordnung nach)

Wir interpolieren an n gleichmäßig verteilten Stellen in $[0, 1]$ durch ein Polynom vom Grad $n - 1$ und sehen uns die Konditionszahl der Vandermonde-Matrix an.

n	Polynomgrad	$\kappa_2(\mathbf{B})$	$\kappa_\infty(\mathbf{B})$
5	4	$6,9 \cdot 10^2$	$1,7 \cdot 10^3$
10	9	$1,5 \cdot 10^7$	$4,8 \cdot 10^7$
15	14	$4,0 \cdot 10^{11}$	$1,6 \cdot 10^{12}$
20	19	$1,1 \cdot 10^{16}$	$4,9 \cdot 10^{16}$

Die Werte sind als Größenordnungen zu lesen; sie hängen von der Norm ab und von der Lage der Stellen. Auf $[-1, 1]$ statt $[0, 1]$ liefert dieselbe Rechnung bei $n = 20$ nur $\kappa_2 \approx 2,7 \cdot 10^8$.

Entscheidend ist der Trend, und der ist in jeder Norm derselbe: exponentielles Wachstum. Die Faustregel aus Abschnitt 4.2 beschränkt den relativen Fehler der berechneten Koeffizienten der Größenordnung nach durch $\kappa(\mathbf{B}) \cdot \varepsilon$ mit $\varepsilon \approx 2,2 \cdot 10^{-16}$ (Maschinengenauigkeit, Abschnitt 4.1). Bei $n = 10$ steht dort $3 \cdot 10^{-9}$, bei $n = 15$ schon 10^{-4} . Bei $n = 20$ ist die Schranke mit 2 größer als die gesuchten Zahlen selbst: Von der Lösung bleibt nichts Verlässliches übrig.

Bemerkung 13.3.11 (Der Ausweg: orthogonalisierte Basen)

Die schlechte Kondition ist eine Eigenschaft der *Basis*, nicht des Ansatzraums. Nach Abschnitt 13.2 ändert ein Basiswechsel den Interpolanten nicht, nur die Koeffizienten und den Rechenweg. Wählen wir Basisfunktionen, die sich weniger ähneln, wird die Basismatrix besser konditioniert. Klassisch sind dafür die *orthogonalen Polynome* (Legendre, Chebyshev, Hermite), die bezüglich eines Skalarprodukts von Funktionen orthogonal sind. An denselben gleichmäßig verteilten Stellen wie oben liefern die Chebyshev-Polynome $\kappa_2 \approx 2,2$ statt $6,9 \cdot 10^2$ bei $n = 5$ und $\kappa_2 \approx 4,8 \cdot 10^3$ statt $1,1 \cdot 10^{16}$ bei $n = 20$, ein Gewinn von zwölf Zehnerpotenzen.

Das einfachste Skalarprodukt von Funktionen auf $[-1, 1]$ ist $\langle f, g \rangle = \int_{-1}^1 f(x) g(x) dx$, das Gegenstück zu $\mathbf{x}^\top \mathbf{y}$ im $\mathbb{R}^n$. Mit ihm läuft das Gram-Schmidt-Verfahren aus Abschnitt 7.4 im Funktionenraum wie im $\mathbb{R}^n$: Auf die Monome $1, x, x^2$ angewandt, lässt es x unverändert, weil $\langle x, 1 \rangle = 0$ ist, und macht aus x^2

$$p_2(x) = x^2 - \frac{\langle x^2, 1 \rangle}{\langle 1, 1 \rangle} \cdot 1 - \frac{\langle x^2, x \rangle}{\langle x, x \rangle} \cdot x = x^2 - \frac{2/3}{2} - 0 = x^2 - \frac{1}{3},$$

bis auf einen Faktor das Legendre-Polynom $P_2(x) = \frac{1}{2}(3x^2 - 1)$. Legendre-, Chebyshev- und Hermite-Polynome entstehen so aus verschiedenen Skalarprodukten, also verschiedenen Gewichtsfunktionen und Intervallen.

In R ersetzt `poly(x, 3)` die Spalten `cbind(x, x^2, x^3)` durch Spalten, die bezüglich des diskreten Skalarprodukts $\sum_i f(x_i) g(x_i)$ an den *gegebenen* Stellen orthonormal sind; berechnet werden sie über eine stabile Orthogonalisierung der Vandermonde-Spalten. In `cbind(1, poly(x, 3))` stehen dann alle Spalten senkrecht aufeinander, mit den Längen $\sqrt{n}, 1, 1, 1$. Die Konditionszahl dieser Matrix ist $\sqrt{n}$.

Interaktiv: Die Monombasis und ihre Kondition

Warum sind die Spalten einer Vandermonde-Matrix auf $[0, 1]$ fast parallel? Die erste Tafel macht die Ursache sichtbar.

Interaktives Element — nur in der Web-Fassung

Der Regler erhöht die Zahl der Stellen, die Schalter wechseln zwischen drei Basissystemen desselben Ansatzraums.

Interaktives Element — nur in der Web-Fassung

Beide Monom-Kurven sind im logarithmischen Bild ungefähr Geraden, ihre Konditionszahl wächst also exponentiell in n . Verschieben auf $[-1, 1]$ drückt nur die Steigung, Chebyshev drückt sie deutlich stärker.

Problem 2: Stabilität und Lokalität

Ändern wir einen einzigen Messwert, so ändert sich der Interpolant im gesamten Intervall, und oft nicht am stärksten dort, wo wir geändert haben.

Satz 13.3.12 (Wie sich eine Datenänderung fortpflanzt)

Seien p das interpolierende Polynom vom Grad höchstens $n - 1$ zu den Daten (x_i, y_i) und $\tilde{p}$ das interpolierende Polynom zu denselben Daten, bei denen nur y_j um δ verändert wurde. Dann gilt

$$\tilde{p} - p = \delta \cdot \ell_j,$$

wobei ℓ_j das eindeutige Polynom vom Grad höchstens $n - 1$ mit $\ell_j(x_j) = 1$ und $\ell_j(x_i) = 0$ für $i \neq j$ ist.

Beweis.

- (1) Die Differenz $\tilde{p} - p$ ist ein Polynom vom Grad höchstens $n - 1$, und an den Stellen nimmt sie die Werte $0, \dots, 0, \delta, 0, \dots, 0$ an, mit δ an der j -ten Position.

beide Polynome interpolieren dieselben Daten bis auf den j -ten Wert, ihre Differenz interpoliert also die Differenz der Daten

- (2) Dieselben Werte hat $\delta \cdot \ell_j$, und auch dieses Polynom hat Grad höchstens $n - 1$. Nach der Eindeutigkeit in Satz 13.3.5 sind beide Polynome gleich.

□

Bemerkung 13.3.13 (Was das in Zahlen heißt)

Die Polynome ℓ_j heißen *Lagrange-Grundpolynome*, und Satz 13.3.12 sagt: Der Ausschlag einer Datenänderung ist überall dort groß, wo $|\ell_j|$ groß ist. Rechnen wir das für $n = 10$ gleichmäßig verteilte Stellen in $[0, 1]$ aus und heben den fünften Wert bei $x_5 = 4/9 \approx 0,444$ um $\delta = 0,1$ an, so verschiebt sich der Interpolant um bis zu **0,40**, das Vierfache der Störung. Erreicht wird dieses Maximum bei $x \approx 0,035$, also am *anderen Ende* des Intervalls. Der größte solche Verstärkungsfaktor liegt bei diesen zehn Stellen bei 4,03 und gehört zu den beiden mittleren, x_5 und x_6 .

Die Methode ist also *instabil*, weil sie kleine Datenänderungen verstärkt, und *nicht lokal*, weil jedes ℓ_j auf dem ganzen Intervall von null verschieden ist. Beides liegt am Ansatzraum, nicht an der Basis, denn ℓ_j ist durch die Stellen und den Ansatzraum festgelegt. Abhilfe schafft erst ein Ansatzraum aus Basisfunktionen, die außerhalb eines kleinen Bereichs verschwinden (Abschnitt 13.4).

Vertiefung (optional): Wenn alle Werte gleichzeitig gestört werden

Wie groß der Effekt werden kann, hängt an der Zahl der Stellen. Stören wir alle Werte gleichzeitig um höchstens δ , so ändert sich der Interpolant um höchstens $\Lambda_n \cdot \delta$ mit $\Lambda_n = \max_x \sum_{j=1}^n |\ell_j(x)|$, und diese Schranke wird bei passend gewählten Vorzeichen auch angenommen. Für gleichmäßig verteilte Stellen wächst diese Zahl schnell, nämlich auf 2,2 bei $n = 5$, 17,9 bei $n = 10$, 283 bei $n = 15$ und 5890 bei $n = 20$. Für die Chebyshev-Knoten, die uns gleich wieder begegnen, bleibt sie im selben Bereich zwischen 2,0 und 2,9.

Das Runge-Phänomen

Wird wenigstens der Interpolant selbst besser, wenn wir mehr Stützstellen nehmen? Bei einer beliebig oft differenzierbaren Funktion wäre das zu erwarten; Carl Runge hat 1901 gezeigt, dass es nicht stimmt.

Beispiel 13.3.14 (Runge 1901)

Wir interpolieren

$$f(x) = \frac{1}{1 + 25x^2} \quad \text{auf } [-1, 1]$$

an n gleichmäßig verteilten Knoten durch das Polynom p_{n-1} vom Grad $n - 1$. Die Funktion f ist beliebig oft differenzierbar, also $f \in \mathcal{C}^\infty$, und beschränkt durch 1.

Trotzdem konvergieren die Interpolanten nicht gleichmäßig gegen f . Der Fehler $\|f - p_{n-1}\|_\infty = \max_{x \in [-1, 1]} |f(x) - p_{n-1}(x)|$ wächst über alle Grenzen, und zwar durch immer stärkere **Oszillationen** nahe den Intervallenden. In der Mitte passt sich das Polynom dabei immer besser an.

Bemerkung 13.3.15 (Divergenz schon, aber nicht monoton)

Die knappe Schreibweise $\|f - p_{n-1}\|_\infty \rightarrow \infty$ für $n \rightarrow \infty$ legt nahe, dass jeder zusätzliche Knoten die Lage verschlimmert; das ist nicht so. Für gleichmäßig verteilte Knoten ergeben sich diese größten Fehler:

n Knoten	Polynomgrad	größter Fehler	Stelle des Maximums
5	4	0,44	$x \approx \pm 0,80$
10	9	0,30	$x \approx \pm 0,93$
15	14	7,2	$x \approx \pm 0,96$
20	19	8,6	$x \approx \pm 0,97$

Von $n = 5$ auf $n = 10$ fällt der Fehler, erst danach wächst er, dann aber schnell (bei $n = 25$ auf 257); unbeschränkt ist das Wachstum nur asymptotisch. Die letzte Spalte zeigt, wo das Problem liegt: Das Fehlermaximum wandert mit wachsendem n immer näher an die Ränder ± 1 .

Vertiefung (optional): Chebyshev-Knoten als Gegenmittel

Bemerkung 13.3.16 (Ein Ausweg: die Knoten anders legen)

An der Basis liegt es nicht, denn zu gegebenen Knoten ist das Polynom nach Satz 13.3.5 eindeutig, gleich in welcher Basis wir es aufschreiben. Es liegt an den *Knoten*: Legen wir sie an den Rändern dichter, statt sie gleichmäßig zu verteilen, verschwindet das Problem. Die übliche Wahl sind die *Chebyshev-Knoten*

$$x_i = \cos\left(\frac{(2i-1)\pi}{2n}\right), \quad i = 1, \dots, n,$$

die Nullstellen des n -ten Chebyshev-Polynoms. Für Runges Funktion sinkt der größte Fehler damit auf 0,047 bei $n = 15$ und 0,038 bei $n = 20$, gegen 7,2 und 8,6 oben, und er fällt weiter: 0,015 bei $n = 21$, dem Ende des Reglerbereichs im Widget unten. Dieser Gewinn ist allerdings asymptotisch. Bei $n = 4, 6$ und 8 Knoten schneiden die gleichmäßig verteilten Knoten etwas besser ab.

Chebyshev-Knoten vermeiden das Runge-Phänomen, setzen aber voraus, dass wir die Stellen frei wählen dürfen (Bemerkung 13.3.16). Bei gemessenen Daten liegen sie fest, und dann hilft nur ein anderer Ansatzraum.

Interaktiv: Runges Funktion, zwei Knotenfamilien

Wann wird der Fehler zum ersten Mal größer als die Funktion selbst?

Schätzfrage. Schätzen wir, ab welcher Knotenzahl n der größte Fehler bei äquidistanten Knoten erstmals über 1 liegt.

Lösung: 9 Knoten

Bei $n = 9$ steht dort 1,05. Ungerade Knotenzahlen liegen durchweg über den benachbarten geraden, weil nur sie einen Knoten auf die Spitze von f legen; bei $n = 10$ fällt der Fehler deshalb wieder auf 0,30.

Die Knöpfe wählen zwischen äquidistanten und Chebyshev-Knoten: Mit äquidistanten Knoten wachsen die Ausschläge an den Rändern, mit Chebyshev-Knoten bleibt die Kurve dort ruhig, sobald n nicht zu klein ist. Die zweite Tafel trägt die Fehlerkurven beider Familien übereinander; sie erscheint erst nach dem Auflösen.

Existenz und Eindeutigkeit sind damit geklärt; das globale Polynom hohen Grades ist trotzdem schlecht konditioniert, nicht lokal und konvergiert nicht einmal für glatte f . Der Rest des Kapitels nimmt deshalb statt eines Polynoms hohen Grades viele Polynome kleinen Grades, jedes nur auf einem kurzen Stück gültig und glatt zusammengesetzt: die *Splines* aus Abschnitt 13.4.

Selbsttest

1. Durch n Punkte mit paarweise verschiedenen x_i läuft genau ein Polynom vom Grad höchstens $n - 1$.

Antwort: Wahr

Das ist Satz 13.3.5. Die Eindeutigkeit folgt aus Korollar 13.3.2 über die Differenz zweier Interpolanten, die Existenz aus der Invertierbarkeit der Vandermonde-Matrix.

2. Das interpolierende Polynom durch n Punkte hat den Grad genau $n - 1$.

Antwort: Falsch

Es hat Grad *höchstens* $n - 1$. Für die drei Punkte $(0, 0)$, $(1, 1)$, $(2, 2)$ liefert das System die Koeffizienten $(0, 1, 0)^T$, das Polynom ist also $p(x) = x$ und damit vom Grad 1 (Beispiel 13.3.7).

3. Ein Polynom vom Grad höchstens 5 mit sechs verschiedenen Nullstellen kann noch von null verschiedene Werte annehmen.

Antwort: Falsch

Nach Korollar 13.3.2 ist es das Nullpolynom und nimmt überall den Wert null an: Ein Polynom vom Grad höchstens 5, das nicht das Nullpolynom ist, hat höchstens fünf verschiedene Nullstellen.

4. Die Vandermonde-Matrix ist zu paarweise verschiedenen Stellen stets invertierbar und kann trotzdem numerisch unbrauchbar sein.

Antwort: Wahr

Invertierbarkeit ist eine Ja-Nein-Frage, Kondition eine Frage des Ausmaßes. Bei $n = 20$ gleichmäßig verteilten Stellen in $[0, 1]$ ist $\det \mathbf{B} \neq 0$, aber $\kappa_2(\mathbf{B}) \approx 10^{16}$, und damit ist die Schranke $\kappa \cdot \varepsilon$ für den relativen Fehler von der Größe 1 (Beispiel 13.3.10).

5. Bei äquidistanten Knoten wird der Fehler $\max |f - p_{n-1}|$ für Runges Funktion mit jedem zusätzlichen Knoten größer.

Antwort: Falsch

Er wächst asymptotisch über alle Grenzen, aber nicht monoton: von $n = 5$ auf $n = 10$ fällt er von 0,44 auf 0,30 (Bemerkung 13.3.15). Erst danach setzt das Wachstum durch, mit 7,2 bei $n = 15$ und 8,6 bei $n = 20$.

6. Wechseln wir von der Monobasis zu den Chebyshev-Polynomen, so verschwindet bei gleichmäßig verteilten Knoten auch das Runge-Phänomen.

Antwort: Falsch

Der Basiswechsel bessert die Kondition des Gleichungssystems, mehr nicht. Nach Satz 13.3.5 gehört zu den Daten dasselbe eindeutige Polynom, gleich in welcher Basis wir es aufschreiben, also auch derselbe Fehler. Gegen die Oszillationen hilft nur, die Knoten anders zu legen oder den Ansatzraum zu wechseln (Bemerkung 13.3.16).

7. Heben wir bei fester Knotenmenge einen einzigen Wert y_j um δ an, so ändert sich der Interpolant an jeder Stelle x um $\delta \ell_j(x)$.

Antwort: Wahr

So steht es in Satz 13.3.12, und der Beweis ist die Eindeutigkeit aus Satz 13.3.5. Weil ℓ_j nur an den anderen Knoten verschwindet, wirkt die Änderung im gesamten Intervall, bei $n = 10$ mit einem Faktor bis 4,03 und am stärksten fern von x_j (Bemerkung 13.3.13).

Vertiefung: Heath, *Scientific Computing*, §7.3.1 (Monobasis und Vandermonde-Matrix), §7.3.4 (orthogonale Polynome) und §7.3.5 (Interpolation stetiger Funktionen mit Runge-Phänomen und Chebyshev-Knoten); die Lagrange-Grundpolynome aus Satz 13.3.12 stehen dort in §7.3.2.

13.4 Splines und B-Splines

Abschnitt 13.3 endet mit einer Beobachtung: Ein einzelnes Polynom durch viele Datenpunkte oszilliert zwischen ihnen. Es ist ein **globales** Objekt, jeder Koeffizient wirkt überall und jede Messung auf die ganze Kurve. Wir zerlegen deshalb das Intervall in kleine Stücke und legen auf jedes ein

Polynom von *festem, niedrigem* Grad; mit der Datenmenge wächst dann nur die Zahl der Stücke. Damit daraus keine unstetige Funktion wird, verlangen wir an den Nahtstellen so viel Glattheit, wie der Grad zulässt.

Stückweise Polynome mit vorgeschriebener Glattheit

Definition 13.4.1 (Polynom-Spline vom Grad q)

Sei $[a, b] \subset \mathbb{R}$ ein Intervall und sei

$$a = \xi_0 < \xi_1 < \dots < \xi_m = b$$

ein Gitter von *Knoten* (knots). Eine Funktion $s : [a, b] \rightarrow \mathbb{R}$ heißt *Polynom-Spline vom Grad q* (polynomial spline of degree q) zu diesem Gitter, wenn

1. auf jedem Teilintervall ein Polynom steht: $s(x) = p_k(x)$ für $x \in [\xi_{k-1}, \xi_k)$ mit Polynomen p_k vom Grad höchstens q , $k = 1, \dots, m$ (auf dem letzten Teilintervall abgeschlossen), und
2. die Nahtstellen glatt sind: $s \in \mathcal{C}^{q-1}([a, b])$, also sind s und seine ersten $q-1$ Ableitungen auf ganz $[a, b]$ stetig.

Die Menge aller solchen Funktionen bezeichnen wir mit $\mathcal{S}_q$.

Bemerkung 13.4.2 (Was in dieser Definition steckt)

Grad höchstens q . „Polynome q -ten Grades“ meint stets „vom Grad höchstens q “, sonst wäre nicht einmal die Nullfunktion ein Spline und $\mathcal{S}_q$ kein Vektorraum.

Die Glattheit ist eine Forderung. Eine stückweise durch Polynome vom Grad höchstens q definierte Funktion darf an jedem Knoten springen. Erst Bedingung 2 macht sie zum Spline. $\mathcal{C}^{q-1}$ ist dabei die *größtmögliche* Glattheit, die wir verlangen können, ohne den Spline zu einem einzigen globalen Polynom zu zwingen: Ist auch die q -te Ableitung stetig, so stimmen benachbarte Polynome in allen Ableitungen überein und sind damit gleich.

Der Fall $q = 0$. $\mathcal{C}^{-1}$ bedeutet: keine Stetigkeitsforderung; ein Spline vom Grad 0 ist eine Treppenfunktion. Ab $q = 1$ ist s stetig, ab $q = 2$ auch knickfrei.

Beispiel 13.4.3 (Die Grade 0, 1 und 3)

Auf dem Gitter $0 < 1 < 2 < 3$ sehen die drei gebräuchlichsten Grade so aus.

- $q = 0$: konstante Stücke, Sprünge an den Knoten erlaubt. Das ist der Histogramm-Fall.
- $q = 1$: der Streckenzug durch die Daten, stetig, mit Knicken an den Knoten. Für Interpolation braucht er keine Rechnung, wir verbinden die Punkte.
- $q = 3$: kubische Stücke, an den Knoten stimmen Funktionswert, Steigung und Krümmung überein. Ein Knick ist nicht mehr zu sehen, und darum ist $q = 3$ der Standardfall.

Wie viele Parameter hat ein Spline?

Nach Abschnitt 13.2 entscheidet die Größe des Ansatzraums darüber, wie viele Bedingungen wir stellen dürfen.

Satz 13.4.4 (Dimension des Spline-Raums)

Sei $q \geq 1$ und sei $\mathcal{S}_q$ der Raum der Polynom-Splines vom Grad q zum Gitter $a = \xi_0 < \dots < \xi_m = b$. Dann ist $\mathcal{S}_q$ ein Vektorraum der Dimension

$$\dim \mathcal{S}_q = m + q, \quad (13.4.1)$$

und die $m + q$ Funktionen

$$1, x, \dots, x^q, (x - \xi_1)_+^q, \dots, (x - \xi_{m-1})_+^q \quad \text{mit} \quad u_+ := \max(u, 0)$$

bilden eine Basis, die *Basis der abgeschnittenen Potenzen* (truncated power basis).

Vertiefung (optional): Warum die abgeschnittenen Potenzen eine Basis bilden

Der Beweis baut einen Spline von links nach rechts aus Monomen und abgeschnittenen Potenzen auf und zeigt, dass diese Familie linear unabhängig ist. Die Abzählung darunter kommt ohne ihn aus.

Beweis.

- (1) Jede der genannten Funktionen liegt in $\mathcal{S}_q$.

Die Monome $1, x, \dots, x^q$ sind auf ganz $[a, b]$ Polynome vom Grad höchstens q und beliebig oft differenzierbar. Für die abgeschnittene Potenz $g_i(x) = (x - \xi_i)_+^q$ ist $g_i \equiv 0$ links von ξ_i und $g_i(x) = (x - \xi_i)^q$ rechts davon, auf beiden Seiten also ein Polynom vom Grad höchstens q .

Für $j \leq q - 1$ ist die j -te Ableitung rechts von ξ_i gleich $q(q-1)\dots(q-j+1)(x - \xi_i)^{q-j}$ mit Exponent $q-j \geq 1$; sie verschwindet also in ξ_i , ebenso wie die Ableitung von links. Damit ist $g_i \in \mathcal{C}^{q-1}$, und erst die q -te Ableitung springt (von 0 auf $q!$).

- (2) Jedes $s \in \mathcal{S}_q$ ist eine Linearkombination dieser Funktionen.

Sei p_1 das Polynom auf dem ersten Teilintervall. Wir zeigen per Induktion über k , dass es Zahlen $d_1, \dots, d_{k-1}$ gibt mit

$$s(x) = p_1(x) + \sum_{i=1}^{k-1} d_i (x - \xi_i)_+^q \quad \text{für } x \in [a, \xi_k).$$

Für $k = 1$ ist das die Definition von p_1 . Gilt die Darstellung bis ξ_k , so ist die Differenz r zwischen s und der rechten Seite auf $[\xi_k, \xi_{k+1})$ ein Polynom vom Grad höchstens q , und ihre Ableitungen der Ordnungen $0, \dots, q-1$ verschwinden in ξ_k .

Ein Polynom vom Grad höchstens q , dessen Ableitungen bis zur Ordnung $q-1$ in ξ_k verschwinden, ist aber ein Vielfaches von $(x - \xi_k)^q$ (Taylor-Entwicklung um ξ_k). Das liefert d_k und den Induktionsschritt.

Beide Funktionen sind dort $\mathcal{C}^{q-1}$ und stimmen links von ξ_k überein, also stimmen auch ihre einseitigen Ableitungen bis zur Ordnung $q-1$ überein und die der Differenz sind null.

- (3) Die Funktionen sind linear unabhängig.

Verschwindet eine Linearkombination auf ganz $[a, b]$, so verschwindet sie insbesondere auf $[a, \xi_1)$. Dort tragen nur die Monome bei, also ist das Polynom $\sum_j c_j x^j$ auf einem ganzen Intervall null und damit das Nullpolynom, $c_0 = \dots = c_q = 0$.

Auf $[\xi_1, \xi_2)$ bleibt dann nur $d_1(x - \xi_1)^q$ übrig, also $d_1 = 0$, und so weiter bis $d_{m-1} = 0$.

Ein Polynom vom Grad höchstens q hat höchstens q Nullstellen, sofern es nicht das Nullpolynom ist; ein Intervall enthält unendlich viele Punkte.

- (4) Damit ist die angegebene Familie eine Basis, und ihre Länge ist $(q+1) + (m-1) = m+q$.

□

Bemerkung 13.4.5 (Die Parameterzählung als Gegenprobe)

Zum selben Ergebnis führt eine Abzählung ohne Basis.

- Ohne Glattheitsforderung: m Teilintervalle mit je $q + 1$ Koeffizienten, also $m(q + 1)$ freie Parameter.
- An jedem der $m - 1$ inneren Knoten: q Bedingungen, nämlich Stetigkeit von s und der ersten $q - 1$ Ableitungen.

Das ergibt

$$m(q + 1) - (m - 1)q = mq + m - mq + q = m + q.$$

Für $q = 3$ und $m = 5$ sind das $5 \cdot 4 - 4 \cdot 3 = 20 - 12 = 8 = m + q$. Die Rechnung setzt voraus, dass die $(m - 1)q$ Bedingungen linear unabhängig sind; das liefert Satz 13.4.4 nach.

Beide Wege stützen sich auf *einfache innere Knoten* (kein ξ_i tritt doppelt auf) und *maximale Glattheit* $\mathcal{C}^{q-1}$. Erlauben wir an einem Knoten weniger Glattheit, so fällt dort eine Bedingung weg und die Dimension steigt um eins.

Interpolation mit kubischen Splines

Wir interpolieren $n = m + 1$ Datenpunkte, die an den Knoten selbst liegen, mit $q = 3$.

Bemerkung 13.4.6 (Zwei Bedingungen fehlen: Randbedingungen)

Nach (13.4.1) hat der Ansatzraum die Dimension $m + 3$, die Daten liefern aber nur $n = m + 1$ Gleichungen. Es fehlen also genau *zwei* Bedingungen, und ohne sie hat das Interpolationsproblem unendlich viele Lösungen. Üblich sind drei Sorten von *Randbedingungen* (boundary conditions):

Typ	Bedingung
natürlich	$s''(a) = s''(b) = 0$
eingespannt	$s'(a)$ und $s'(b)$ vorgegeben
periodisch	$s'(a) = s'(b)$ und $s''(a) = s''(b)$

Liegt keine Information über den Rand vor, ist der *natürliche Spline* der Standard, denn unter allen Interpolanten mit zwei stetigen Ableitungen hat er die kleinste Gesamtkrümmung $\int_a^b |g''(x)|^2 dx$ (Abschnitt 13.5). Im periodischen Fall zählt $s(a) = s(b)$ nicht als eine der beiden Bedingungen: Bei periodischen Daten ($y_0 = y_m$) folgt es schon aus der Interpolation, sonst widerspricht es ihr.

Beispiel 13.4.7 (Kubischer Spline durch vier Punkte)

Gegeben seien die vier Punkte $(0, 0)$, $(1, 1)$, $(2, 0)$, $(3, -1)$, also $m = 3$ Teilintervalle. Auf jedes legen wir ein kubisches Polynom $p_k(x) = c_{k1} + c_{k2}x + c_{k3}x^2 + c_{k4}x^3$; das sind $3 \cdot 4 = 12$ Unbekannte. Die Bedingungen:

Typ	Anzahl	Beispiel
Interpolation	4	$p_1(0) = 0, p_1(1) = 1, p_2(2) = 0, p_3(3) = -1$
s stetig	2	$p_1(1) = p_2(1)$
s' stetig	2	$p_1'(1) = p_2'(1)$
s'' stetig	2	$p_1''(1) = p_2''(1)$
natürlicher Rand	2	$s''(0) = s''(3) = 0$

Zusammen $4 + 2 + 2 + 2 + 2 = 12$ Bedingungen für 12 Unbekannte, und das lineare Gleichungssystem ist eindeutig lösbar. Jeder Datenpunkt wird dabei nur *einmal* gezählt: Dass etwa auch $p_2(1) = 1$ gilt, erzwingt schon die Stetigkeitszeile.

Die Lösung lautet

$$p_1(x) = \frac{1}{15}(23x - 8x^3), \quad p_2(x) = \frac{1}{15}(-18 + 77x - 54x^2 + 10x^3), \quad p_3(x) = \frac{1}{15}(78 - 67x + 18x^2 - 2x^3).$$

Zur Probe an der Naht $x = 1$: $p_1(1) = p_2(1) = 1$, $p_1'(1) = p_2'(1) = -\frac{1}{15}$ und $p_1''(1) = p_2''(1) = -\frac{48}{15}$; an den Rändern ist $p_1''(0) = 0$ und $p_3''(3) = \frac{36-36}{15} = 0$.

Interaktiv: Das Zwölf-mal-zwölf-System

Wie viele der zwölf Koeffizienten ändern sich, wenn wir einen einzigen Messwert verschieben?

Interaktives Element — nur in der Web-Fassung

Die Naht ist unsichtbar, obwohl links und rechts davon verschiedene Polynome stehen; das Readout zeigt, dass Wert, Steigung und Krümmung bis auf Rundung übereinstimmen. Beim Verschieben eines einzigen Messwerts ändern sich dagegen *alle* zwölf Koeffizienten. Dass eine andere Darstellung desselben Ansatzraums darin anders ausgeht, zeigt Bemerkung 13.4.14.

B-Splines

Die stückweise Monomdarstellung aus Beispiel 13.4.7 erbt die schlechte Kondition der Monombasis (Abschnitt 13.3), ihre Matrix hat keine erkennbare Struktur, und jeder Koeffizient hängt an allen Daten. Wir suchen deshalb eine bessere *Basis* von $\mathcal{S}_q$ im Sinn von Abschnitt 13.2; nach Satz 13.4.4 hat sie genau $m + q$ Funktionen. Die abgeschnittenen Potenzen aus demselben Satz taugen dafür nicht, denn jede ist auf dem ganzen Stück rechts ihres Knotens von null verschieden und wird für großes x sehr groß. Stattdessen nehmen wir die B-Splines.

Definition 13.4.8 (Erweiterte Knotenfolge und B-Splines)

Zum Gitter $a = \xi_0 < \dots < \xi_m = b$ und zum Grad $q \geq 0$ setzen wir die *erweiterte Knotenfolge* $\tau_1 \leq \dots \leq \tau_{m+2q+1}$ fest durch

$$\tau_1 = \dots = \tau_{q+1} = \xi_0, \quad \tau_{q+1+i} = \xi_i \quad (i = 1, \dots, m-1), \quad \tau_{m+q+1} = \dots = \tau_{m+2q+1} = \xi_m. \quad (13.4.2)$$

Die Randknoten treten also $(q+1)$ -fach auf, die inneren einfach; zusammen sind das $(q+1) + (m-1) + (q+1) = m + 2q + 1$ Knoten.

Die B-Splines $B_k^{(q)}$, $k = 1, \dots, m+q$, sind rekursiv über den Grad erklärt. Für $q = 0$ ist

$$B_k^{(0)}(x) = \mathbb{1}(\tau_k \leq x < \tau_{k+1}),$$

und für $q > 0$ gilt die *Cox-de-Boor-Rekursion*

$$B_k^{(q)}(x) = \frac{x - \tau_k}{\tau_{k+q} - \tau_k} B_k^{(q-1)}(x) + \frac{\tau_{k+q+1} - x}{\tau_{k+q+1} - \tau_{k+1}} B_{k+1}^{(q-1)}(x). \quad (13.4.3)$$

Ein Summand mit verschwindendem Nenner wird dabei als 0 gelesen; das betrifft nur die mehrfachen Randknoten. Am rechten Rand lesen wir das letzte nichtleere Knotenintervall als abgeschlossen, damit die Basisfunktionen auch in b definiert sind.

Satz 13.4.9 (Die B-Splines sind eine Basis)

Mit den Bezeichnungen aus Definition 13.4.8 gilt für $q \geq 1$:

1. *Lokaler Träger:* $B_k^{(q)}(x) = 0$ für $x \notin [\tau_k, \tau_{k+q+1}]$, und $B_k^{(q)}(x) > 0$ für $\tau_k < x < \tau_{k+q+1}$.
2. *Zerlegung der Eins:* $\sum_{k=1}^{m+q} B_k^{(q)}(x) = 1$ für alle $x \in [a, b]$.
3. *Glattheit:* $B_k^{(q)} \in \mathcal{C}^{q-1}$, jedes $B_k^{(q)}$ liegt also selbst in $\mathcal{S}_q$.
4. *Basis:* $B_1^{(q)}, \dots, B_{m+q}^{(q)}$ sind linear unabhängig und spannen $\mathcal{S}_q$ auf. Jeder Spline s vom Grad q besitzt daher genau eine Darstellung

$$s(x) = \sum_{k=1}^{m+q} a_k B_k^{(q)}(x). \quad (13.4.4)$$

Einen Beweis führen wir nicht, und die Rekursion dient im Weiteren nur als Referenz. Aussage 1 und 3 lesen sich an einem Rekursionsschritt ab (Vertiefung unten), und weil $m+q$ die Dimension aus Satz 13.4.4 ist, ist ein aufspannendes System automatisch eine Basis.

Damit ist der Anschluss an Abschnitt 13.2 hergestellt: Wir wählen $\phi_k = B_k^{(q)}$ als Basisfunktionen, stellen das System $\mathbf{B}\mathbf{a} = \mathbf{y}$ auf und lösen es. Neu ist nur, wie gut dieses System konditioniert ist.

Interaktiv: Die B-Spline-Basis erkunden

Wie viele Basisfunktionen sind an einer Stelle aktiv, und wie entsteht ihre Form aus der Rekursion?

Interaktives Element – nur in der Web-Fassung

Die gestrichelte Summe liegt über dem ganzen Gitter konstant bei eins, obwohl die einzelnen Kurven ganz verschieden aussehen. Und an jeder Stelle sind höchstens $q+1$ Basisfunktionen von null verschieden: Das ist die Zahl, die gleich die Rechenzeit bestimmt.

Vertiefung (optional): Die Cox-de-Boor-Rekursion von Hand

Bemerkung 13.4.10 (Warum die Knotenfolge so lang sein muss)

Zu $m + q$ Basisfunktionen nur $m + q$ Knoten anzusetzen, liegt nahe, reicht aber nicht: Die Rekursion (13.4.3) greift für $k = m + q$ auf τ_{m+2q+1} zu, es braucht also $m + 2q + 1$ Knoten.

Ebenso wichtig ist, dass sich die drei Vorschriften in (13.4.2) nicht überschneiden. Der linke Randblock belegt die Indizes $1, \dots, q + 1$, die inneren Knoten die Indizes $q + 2, \dots, q + m$, der rechte Randblock die Indizes $m + q + 1, \dots, m + 2q + 1$: Jeder Index bekommt genau einen Wert. Begänne der rechte Block schon bei $m + 1$, so bekäme für $q = 3$ und $m = 5$ der Knoten τ_6 sowohl ξ_2 als auch ξ_5 zugewiesen.

Beispiel 13.4.11 (Grad 1: die Hutfunktionen)

Für $\xi = (0, 1, 2)$, also $m = 2$, und $q = 1$ lautet die erweiterte Knotenfolge

$$\tau = (0, 0, 1, 2, 2),$$

das sind $m + 2q + 1 = 5$ Knoten und damit $m + q = 3$ Basisfunktionen. Die Rekursion liefert

$$B_1^{(1)}(x) = \begin{cases} 1 - x, & 0 \leq x < 1 \\ 0 & \text{sonst,} \end{cases} \quad B_2^{(1)}(x) = \begin{cases} x, & 0 \leq x < 1 \\ 2 - x, & 1 \leq x \leq 2 \end{cases} \quad B_3^{(1)}(x) = \begin{cases} x - 1, & 1 \leq x \leq 2 \\ 0 & \text{sonst.} \end{cases}$$

An der Stelle $x = 0,25$ etwa stehen dort die Werte 0,75, 0,25 und 0, bei $x = 1,5$ die Werte 0, 0,5 und 0,5. In beiden Fällen ist die Summe 1, und das gilt an jeder Stelle. Jede dieser drei Hutfunktionen ist selbst ein Spline vom Grad 1, nichtnegativ und nur auf höchstens $q + 1 = 2$ Gitterintervallen von null verschieden. An den Rändern sorgen die doppelten Knoten dafür, dass der Träger kürzer ausfällt.

Interaktiv: Ein Rekursionsschritt Stück für Stück

Die Rekursion aus (13.4.3) baut $B_3^{(q)}$ aus zwei Nachbarn vom Grad $q - 1$ auf, jeder mit einer eigenen Gewichtsrampe. Wo beide Rampen tragen, entsteht die zusätzliche Glattheit; wo nur eine trägt, wächst der Träger um ein Intervall.

Interaktives Element — nur in der Web-Fassung

Bemerkung 13.4.12 (B-Splines in R)

In R liefert `splines::bs()` die Auswertungsmatrix **B** direkt:

```
y <- f(x)
B <- splines::bs(x, df = 10, degree = 3, intercept = TRUE)
a <- solve(B, y)

xnew <- seq(0, 1, length = 100)
Bnew <- splines::bs(xnew, knots = attr(B, "knots"),
                    Boundary.knots = attr(B, "Boundary.knots"),
                    degree = attr(B, "degree"),
                    intercept = TRUE)

fhat <- Bnew %%% a
```

Die erste Hälfte ist der Algorithmus aus Abschnitt 13.2: Basis auswerten, System lösen. Die zweite wertet den Interpolanten an neuen Stellen aus, und dafür muss die neue Basisma-

trix zu *derselben* Basis gehören; deshalb reichen wir innere Knoten, Randknoten und Grad weiter, statt `bs()` sie aus `xnew` neu bestimmen zu lassen. Vergessen wir das, gibt es keine Fehlermeldung: Die Spaltenzahl stimmt, und heraus kommt eine glatte Kurve, nur nicht die geschätzte. Am sichersten erledigt das bei einem angepassten Modell die zugehörige `predict()`-Methode.

Warum B-Splines? Kondition und Aufwand

Bemerkung 13.4.13 (Konditionszahlen: eine Größenordnung, kein Messwert)

Für $n = 20$ Punkte in $[0, 1]$ stellen wir zwei Basissysteme gegenüber. Die Konditionszahlen sind Größenordnungen; sie hängen von der Norm, der Lage der Auswertungsstellen und der Knotenwahl ab.

Basis	Grad	Konditionszahl
Monombasis	19	$\kappa(\mathbf{B}_{\text{mono}}) \approx 10^{16}$
kubische B-Splines	3	$\kappa(\mathbf{B}_{\text{spline}}) \approx 10^1 \text{ bis } 10^2$

Die obere Zeile setzt die Tabelle aus Abschnitt 13.3 fort; in exakter rationaler Arithmetik nachgerechnet ist $\kappa_1 = 4,4 \cdot 10^{16}$, während die kubische B-Spline-Kollokationsmatrix mit ebenfalls 20 Basisfunktionen in derselben Norm auf $\kappa_1 = 37$ kommt, gut fünfzehn Größenordnungen weniger (mit dem aufgerundeten Tabellenwert 10^2 vierzehn). Bei $\kappa \approx 10^{16}$ ist von den etwa sechzehn signifikanten Stellen eines `double` im Ergebnis nichts mehr sicher, während $\kappa \approx 40$ nicht einmal zwei Stellen kostet (Faustregel in Abschnitt 4.2).

Bemerkung 13.4.14 (Bandstruktur und Aufwand)

Der zweite Vorteil ist die Struktur der Matrix. Nach Satz 13.4.9 sind an jeder Stelle x_i höchstens $q+1$ Basisfunktionen von null verschieden, in der i -ten Zeile von $\mathbf{B}$ stehen also höchstens $q+1$ Einträge ungleich null, und sie stehen nebeneinander. $\mathbf{B}$ ist eine dünn besetzte *Bandmatrix* mit Bandbreite ungefähr q .

Die Elimination bearbeitet deshalb in jedem Schritt nur die höchstens q Zeilen unterhalb des Pivots, die noch im Band liegen, und in jeder nur die höchstens q Einträge des Bandes (Abschnitt 5.3). Bei einer Systemgröße N kostet das

$$O(Nq^2) \quad \text{statt} \quad O(N^3)$$

(Abschnitt 2.4). Dabei ist $N = m + q$ die Zahl der Basisfunktionen; bei Interpolation an n Punkten ist $N = n$.

Für $N = 1000$ und $q = 3$ ist das Verhältnis $N^3/(Nq^2) = N^2/q^2 = 10^6/9 \approx 111\,000$, also ein Beschleunigungsfaktor der Größenordnung 10^5 . Verglichen werden dabei Operationszahlen, keine gemessenen Laufzeiten.

Eigenschaften

Splines, meist mit $q = 3$, sind heute das gebräuchlichste Basissystem zur Funktionsapproximation.

Satz 13.4.15 (Eigenschaften von Splines und B-Splines)

Sei $q \geq 1$.

1. *Approximierbarkeit:* Zu jeder stetigen Funktion f auf $[a, b]$ und jedem $\varepsilon > 0$ gibt es ein Gitter, dessen maximale Knotenweite $\max_k |\xi_k - \xi_{k-1}|$ klein genug ist, sodass der zugehörige Raum $\mathcal{S}_q$ ein s mit $\|f - s\|_\infty < \varepsilon$ enthält.
2. *Ableitung und Integral:* Die Ableitung eines Splines vom Grad q ist ein Spline vom Grad $q - 1$ zum selben Gitter, eine Stammfunktion ist ein Spline vom Grad $q + 1$.
3. *Lokaler Träger:* $B_k^{(q)}$ verschwindet außerhalb von $[\tau_k, \tau_{k+q+1}]$, also außerhalb von höchstens $q + 1$ Gitterintervallen.

Aussage 2 folgt durch stückweises Ableiten: Der Grad jedes Stücks sinkt um eins, und aus $s \in \mathcal{C}^{q-1}$ wird $s' \in \mathcal{C}^{q-2}$, wieder die maximale Glattheit zum Grad $q - 1$. Die Ableitung eines kubischen Splines ist also ein quadratischer Spline, die Krümmung eine stückweise lineare Funktion. Aussage 1 ist im Fall $q = 1$ die gleichmäßige Stetigkeit von f , für höhere Grade ein klassisches Resultat der Approximationstheorie; wie schnell der Fehler mit der Knotenweite fällt, klärt Abschnitt 13.6.

Bemerkung 13.4.16 (Ableitungen und Integral des Splines)

Das Integral des Splines approximiert das Integral von f , denn aus $\|f - s\|_\infty < \varepsilon$ folgt sofort die Schranke $(b - a)\varepsilon$ für die Differenz der Integrale. Für die Ableitungen gilt das nur eingeschränkt: f muss selbst genügend oft differenzierbar sein, und jede Ableitungsordnung kostet eine Potenz der Knotenweite. Eine kleine Abweichung in den Funktionswerten sagt für sich genommen nichts über die Steigungen.

Bemerkung 13.4.17 (Was die Lokalität praktisch bedeutet)

Verschieben wir einen einzigen Messwert, so ändert sich nur eine rechte Seite, und die zugehörige Zeile von $\mathbf{B}$ enthält nur die wenigen Basisfunktionen in seiner Umgebung. Die Lösung des Gleichungssystems koppelt die Koeffizienten allerdings weiter, denn die Inverse einer Bandmatrix ist im Allgemeinen dicht; bei gut konditionierten Bandsystemen fällt der Einfluss aber typischerweise schnell mit dem Abstand ab. Ein globales Polynom wirkt dagegen über das ganze Intervall, am stärksten oft weit weg von der gestörten Stelle (Abschnitt 13.3).

Interaktiv: Ein Datenpunkt wandert

Wie weit vom verschobenen Punkt entfernt ist von der Störung noch etwas zu sehen – beim Polynom und beim Spline?

Interaktives Element — nur in der Web-Fassung

Fern vom gestörten Punkt trennen sich die beiden Ansatzräume: Mehr als zwei Knoten entfernt bleibt die Spline-Änderung in der Voreinstellung unter 0,037, während das Polynom dort weiterhin 2,320 ausschlägt, und zwar am äußeren Rand. Lokal ist die B-Spline-Darstellung damit, abgeschottet aber nicht: Neun der elf Koeffizienten reagieren messbar, obwohl an der verschobenen Stelle nur drei Basisfunktionen von null verschieden sind. Nur die beiden Randkoeffizienten bleiben exakt stehen, weil sie beim offenen Knotenvektor unmittelbar an den Randwerten hängen.

Selbsttest

1. Ein Spline vom Grad q auf m Teilintervallen ist ein Polynom vom Grad mq .

Antwort: Falsch

Er ist kein einzelnes Polynom, sondern eine Zusammensetzung aus m Polynomen vom Grad *höchstens* q . Der Grad wächst nicht mit der Zahl der Stücke; das ist der Zweck der Konstruktion. Nur im Sonderfall $m = 1$ liegt ein einzelnes Polynom vor, und auch dann vom Grad höchstens q .

2. Zur Beschreibung eines Splines vom Grad q auf $m + 1$ Knoten brauchen wir $m + q$ Parameter.

Antwort: Wahr

Das ist Satz 13.4.4, unter seinen beiden Annahmen: einfache innere Knoten und maximale Glattheit $\mathcal{C}^{q-1}$. Die Abzählung dazu lautet $m(q + 1) - (m - 1)q = m + q$; für $q = 3$ und $m = 5$ also $20 - 12 = 8$. Verlangen wir an einem Knoten weniger Glattheit, steigt die Zahl.

3. Jede Funktion, die auf jedem Teilintervall mit einem Polynom vom Grad höchstens q übereinstimmt, ist ein Spline vom Grad q .

Antwort: Falsch

Die Glattheit gehört zur Definition (Bemerkung 13.4.2). Die Funktion, die auf $[0, 1)$ konstant 0 und auf $[1, 2]$ konstant 1 ist, besteht aus zwei Polynomen vom Grad höchstens 3, ist aber nicht einmal stetig und damit kein kubischer Spline. Ein Spline vom Grad 0 ist sie dagegen, denn dort fordert $\mathcal{C}^{-1}$ nichts.

4. Fordern wir von einem kubischen Spline zusätzlich, dass auch s''' stetig ist, so bekommen wir eine glattere, aber immer noch stückweise verschiedene Kurve.

Antwort: Falsch

Dann stimmen benachbarte kubische Polynome an ihrer Nahtstelle in allen vier Ableitungen der Ordnungen 0 bis 3 überein und sind deshalb identisch. Aus dem Spline wird ein einziges globales Polynom vom Grad höchstens 3, und wir sind zurück bei dem Ansatz, den wir gerade verlassen haben. $\mathcal{C}^{q-1}$ ist die höchste sinnvolle Glattheitsforderung.

5. Interpolieren wir $n = m + 1$ Datenpunkte mit einem kubischen Spline zum Gitter der Datenpunkte, so ist der Interpolant eindeutig bestimmt.

Antwort: Falsch

Der Ansatzraum hat die Dimension $m + 3$, die Daten liefern aber nur $m + 1$ Gleichungen. Zwei Bedingungen fehlen, und ohne sie gibt es unendlich viele Lösungen (Bemerkung 13.4.6). Erst eine Randbedingung wie $s''(a) = s''(b) = 0$ macht das System quadratisch und regulär.

6. Die Ableitung eines kubischen Splines ist ein quadratischer Spline zum selben Gitter.

Antwort: Wahr

Stückweises Ableiten senkt den Grad jedes Stücks von 3 auf 2, und aus $\mathcal{C}^2$ wird $\mathcal{C}^1$ (Satz 13.4.15). Das ist die maximale Glattheit zum Grad 2. Entsprechend ist die zweite Ableitung eines kubischen Splines stückweise linear und stetig, während die dritte stückweise konstant ist und an den Knoten springen darf.

7. Verschieben wir einen Datenpunkt, so ändern sich nur die Koeffizienten derjenigen B-Splines, die an dieser Stelle von null verschieden sind.

Antwort: Falsch

Die Änderung ist lokalisiert, aber nicht exakt lokal. An einem inneren Datenpunkt sind bei

$q = 3$ nur drei Basisfunktionen von null verschieden, im Beispiel des Widgets reagieren jedoch neun von elf Koeffizienten messbar: 1,732, dann 0,464, 0,124, 0,031, 0,010. Das Gleichungssystem koppelt die Koeffizienten über das Band, und die Kopplung fällt je Knotenabstand auf gut ein Viertel, statt abzubrechen.

Vertiefung: Heath behandelt die stückweise polynomiale Interpolation in §7.4, die kubischen Splines in §7.4.2 und die B-Splines samt Rekursion und Bandstruktur in §7.4.3; die klassische Referenz zur Sache ist Carl de Boor, A Practical Guide to Splines.

13.5 Minimale Krümmung

Bis hierher war Interpolation ein lineares Problem: Basis wählen, System lösen (Abschnitt 13.2). Offen ist, warum gerade *kubische* Splines der Standard sind; Grad 2 wäre billiger, Grad 5 glatter. Die Antwort ist ein Optimalitätssatz: Unter allen zweimal stetig differenzierbaren Funktionen durch dieselben Punkte hat der natürliche kubische Spline die geringste Gesamtkrümmung, er löst also ein Optimierungsproblem. Im Englischen heißt diese Eigenschaft *minimal wiggleness*.

Bemerkung 13.5.1 (Was von hier an gebraucht wird)

Ab Abschnitt 13.7 brauchen wir aus der linearen Algebra Kleinste Quadrate (Abschnitt 7.1) und die Pseudoinverse (Abschnitt 7.6), aus der Statistik die Designmatrix eines linearen Modells und die Zerlegung des mittleren quadratischen Fehlers in Bias und Varianz (Abschnitt 13.8). Aus der Analysis kommen die Glattheitsklassen $\mathcal{C}^k$ der k -mal stetig differenzierbaren Funktionen hinzu, hier $\mathcal{C}^2$ und in Abschnitt 13.6 $\mathcal{C}^4$, dazu Integrale wie $\int |f''(x)|^2 dx$ und die partielle Integration.

Splines, kurz erinnert

Bemerkung 13.5.2 (Spline)

Ein kubischer Spline setzt kubische Polynome an den Knoten $\xi_1 < \dots < \xi_{m-1}$ zu einer $\mathcal{C}^2$ -Funktion zusammen (Abschnitt 13.4): Wert, erste und zweite Ableitung gehen ohne Sprung über die Knoten.

Zur Benennung, weil im Satz weiter unten andere Buchstaben stehen: $\xi_1, \dots, \xi_{m-1}$ sind dabei nur die *inneren* Trennstellen. Im Krümmungssatz fallen die Knoten mit den Stützstellen zusammen und heißen deshalb $x_1, \dots, x_n$, die beiden Intervallenden mitgezählt. Bei n Datenpunkten ist also $m = n - 1$ und $\xi_k = x_{k+1}$.

Krümmung als Zielgröße

Um „möglichst glatt“ rechenbar zu machen, brauchen wir eine Zahl für die Welligkeit einer Funktion. Die zweite Ableitung f'' ist groß, wo sich die Steigung schnell ändert, und verschwindet genau für Geraden; weil nur die Stärke der Biegung zählt und nicht ihre Richtung, quadrieren wir sie und integrieren über das Intervall.

Definition 13.5.3 (Krümmungsfunktional)

Für $g \in \mathcal{C}^2[a, b]$ heißt

$$J(g) := \int_a^b |g''(x)|^2 dx \quad (13.5.1)$$

das *Krümmungsfunktional* von g auf $[a, b]$.

J ist eine Zielfunktion auf einem Funktionenraum, und $J(g) = 0$ gilt genau für die affinen Funktionen $g(x) = \alpha x + \beta$. Je größer $J(g)$, desto stärker ist die Kurve gekrümmt.

Streng genommen misst J nicht die geometrische Krümmung $\kappa(x) = |g''(x)|/(1 + g'(x)^2)^{3/2}$; nur für flache Kurven mit $|g'| \ll 1$ ist $\kappa \approx |g''|$. Der Name „minimale Krümmung“ ist trotzdem eingebürgert, gemeint ist immer (13.5.1). Dass J quadratisch ist, macht das Folgende möglich: Quadratische Ziele führen auf lineare Gleichungen, wie bei den Kleinsten Quadraten in Kapitel 7.

Gesucht ist also unter allen $\mathcal{C}^2$ -Funktionen durch die gegebenen Punkte die mit dem kleinsten J . Interpolanten gibt es unendlich viele (Abschnitt 13.1), das Minimum dagegen ist eindeutig, und es hat einen Namen.

Satz 13.5.4 (Kubische Splines haben minimale Krümmung)

Seien $n \geq 2$ und $(x_1, y_1), \dots, (x_n, y_n) \in [a, b] \times \mathbb{R}$ mit $a = x_1 < x_2 < \dots < x_n = b$. Sei s ein natürlicher kubischer Spline mit Knoten $x_1, \dots, x_n$, der diese Punkte interpoliert, also $s(x_i) = y_i$ für alle i und

$$s''(a) = s''(b) = 0.$$

Sei $g \in \mathcal{C}^2[a, b]$ eine weitere Funktion mit $g(x_i) = y_i$ für alle i . Dann gilt

$$\int_a^b |s''(x)|^2 dx \leq \int_a^b |g''(x)|^2 dx,$$

also $J(s) \leq J(g)$.

Der Beweis besteht im Kern aus zwei partiellen Integrationen über die Knotenintervalle; die natürlichen Randbedingungen lassen dabei einen störenden Randterm verschwinden.

Beweis.

- (1) Wir setzen $h := g - s$. Dann ist $h \in \mathcal{C}^2[a, b]$, und weil s und g dieselben Werte interpolieren, gilt

$$h(x_i) = 0 \quad \text{für } i = 1, \dots, n.$$

s ist auf jedem Teilintervall ein Polynom und an den Knoten zweimal stetig differenzierbar, liegt also selbst in $\mathcal{C}^2$; die Differenz zweier $\mathcal{C}^2$ -Funktionen ist wieder $\mathcal{C}^2$.

- (2) Ausmultiplizieren von $g'' = s'' + h''$ unter dem Integral liefert die Zerlegung

$$J(g) = J(s) + 2 \int_a^b s''(x) h''(x) dx + \int_a^b (h''(x))^2 dx. \quad (13.5.2)$$

Zu zeigen bleibt, dass der mittlere Term verschwindet.

binomische Formel $(u + v)^2 = u^2 + 2uv + v^2$ mit $u = s''$ und $v = h''$; alle drei Integrale existieren, weil s'' und h'' stetig sind

- (3) Auf jedem einzelnen Knotenintervall $[x_{i-1}, x_i]$ ist s ein Polynom vom Grad höchstens 3, dort also beliebig oft differenzierbar. Deshalb zerlegen wir das mittlere Integral und integrieren auf jedem Stück zweimal partiell:

$$\int_{x_{i-1}}^{x_i} s'' h'' dx = \left[s'' h' - s^{(3)} h \right]_{x_{i-1}}^{x_i} + \int_{x_{i-1}}^{x_i} s^{(4)} h dx.$$

zweimal partiell integriert: der erste Durchgang schiebt einen Strich von h'' auf s'' und hinterlässt den Randterm $s'' h'$ samt $-\int s^{(3)} h'$, der zweite behandelt dieses Integral genauso und liefert den Randterm $-s^{(3)} h$ und $+\int s^{(4)} h$

- (4) Als kubisches Polynom hat s auf jedem Teilintervall $s^{(4)} \equiv 0$. Die Integrale fallen weg, übrig bleiben die Randterme:

$$\int_a^b s'' h'' dx = \sum_{i=2}^n \left[s'' h' - s^{(3)} h \right]_{x_{i-1}}^{x_i}.$$

die dritte Ableitung eines kubischen Polynoms ist konstant, die vierte null; das gilt stückweise, an den Knoten selbst ist $s^{(3)}$ im Allgemeinen unstetig

- (5) Die Summe teleskopiert, allerdings mit zwei verschiedenen Begründungen. Für den ersten Anteil sind s'' und h' an jedem inneren Knoten stetig, der Beitrag vom rechten Rand des einen Intervalls hebt also den vom linken Rand des nächsten auf:

$$\sum_{i=2}^n \left[s'' h' \right]_{x_{i-1}}^{x_i} = \left[s'' h' \right]_a^b = s''(b) h'(b) - s''(a) h'(a) = 0.$$

Der zweite Anteil verschwindet sogar summandenweise, weil h an jedem Knoten null ist.

$s''(a) = s''(b) = 0$ ist die natürliche Randbedingung; für den zweiten Anteil ist $s^{(3)}(x_i) h(x_i) = 0$ von beiden Seiten, ganz gleich wie $s^{(3)}$ dort springt

- (6) Damit ist der mittlere Term in (13.5.2) null, und es bleibt

$$J(g) = J(s) + \int_a^b (h''(x))^2 dx \geq J(s). \quad (13.5.3)$$

der verbleibende Integrand ist ein Quadrat, also nirgends negativ, und damit ist auch sein Integral nicht negativ

- (7) Für den Gleichheitsfall lesen wir (13.5.3) rückwärts. Aus $J(g) = J(s)$ folgt $\int_a^b (h'')^2 dx = 0$, und weil $(h'')^2$ stetig und nirgends negativ ist, folgt daraus $h'' \equiv 0$ auf $[a, b]$. Also ist h affin, $h(x) = \alpha x + \beta$. Wegen $n \geq 2$ hat h mindestens zwei verschiedene Nullstellen $x_1 \neq x_2$, und eine affine Funktion mit zwei Nullstellen ist die Nullfunktion. Also $h \equiv 0$ und $g = s$.

hätte $(h'')^2$ an einer Stelle einen positiven Wert, wäre es aus Stetigkeitsgründen auf einer ganzen Umgebung positiv und das Integral echt größer als null; aus $\alpha x_1 + \beta = \alpha x_2 + \beta = 0$ mit $x_1 \neq x_2$ folgt $\alpha = 0$ und dann $\beta = 0$

□

Vertiefung (optional): Was der Beweis von den Randbedingungen braucht

Bemerkung 13.5.5 (Was die Randterme wirklich brauchen)

Der Beweis braucht drei Voraussetzungen.

1. Das Teleskopieren von $s'' h'$ braucht die Stetigkeit von s'' und von h' über die Knoten hinweg. Beides ist vorhanden: s ist als kubischer Spline in $\mathcal{C}^2$, und h ist es nach Voraussetzung an g . Wäre g nur stückweise glatt mit Knick, ginge der Schritt nicht.
2. Die dritte Ableitung $s^{(3)}$ darf an den Knoten dagegen springen, und sie tut es im Allgemeinen auch. Der Term verschwindet allein wegen $h(x_i) = 0$: Der Sprung wird mit null multipliziert. Deshalb müssen die Knoten des Splines die Datenpunkte sein.
3. Für den letzten Rest $[s'' h']_a^b$ hilft kein Verschwinden von h mehr, denn dort steht h' . Die natürliche Bedingung $s''(a) = s''(b) = 0$ macht ihn null, und das ist der einfachste Weg. Es ist nicht der einzige: Verlangen wir stattdessen von allen Kandidaten vorgeschriebene Randsteigungen, so ist $h'(a) = h'(b) = 0$, und der Term verschwindet ebenso. Das führt auf den eingespannten Spline (clamped spline), für den derselbe Satz in seiner Klasse gilt.

Eine Voraussetzung im Satzkopf ist dabei leicht zu übersehen: $a = x_1$ und $x_n = b$, die äußersten Knoten sind also die Intervallenden. Liegen die Daten echt im Inneren, setzen wir den Spline außerhalb linear fort; dort ist $s'' = 0$, $J(s)$ bleibt unverändert, und die Ungleichung überträgt sich auf das größere Intervall.

Korollar 13.5.6 (Der natürliche kubische Spline ist der einzige Minimierer)

Unter den Voraussetzungen von Satz 13.5.4 ist s der *eindeutige* Minimierer von J in der Menge

$$\{g \in \mathcal{C}^2[a, b] : g(x_i) = y_i \text{ für } i = 1, \dots, n\}.$$

Das ist der letzte Beweisschritt: Jeder andere Interpolant mit demselben Krümmungswert ist s selbst.

Satz 13.5.4 setzt voraus, dass ein natürlicher kubischer Spline durch die Punkte existiert. Das tut er, und er ist eindeutig: Das zugehörige tridiagonale Gleichungssystem für die zweiten Ableitungen ist strikt diagonaldominant und damit regulär.

Vertiefung (optional): Die Abzählung und das tridiagonale System dahinter

Bemerkung 13.5.7 (Existenz: die Abzählung geht auf)

Bei n Knoten gibt es $n - 1$ Teilintervalle mit je 4 Koeffizienten, zusammen $4(n - 1)$ Unbekannte. Dem stehen $2(n - 1)$ Interpolationsbedingungen gegenüber (jedes Stück trifft beide Endwerte), $2(n - 2)$ Glattheitsbedingungen an den inneren Knoten (erste und zweite Ableitung) und die 2 natürlichen Randbedingungen. Summe: $2(n - 1) + 2(n - 2) + 2 = 4(n - 1)$, also genauso viele Gleichungen wie Unbekannte. Für $n = 5$ etwa sind es 16 auf beiden Seiten.

Abzählen allein ist noch kein Existenzbeweis, denn gleich viele Gleichungen wie Unbekannte heißt nicht, dass die Matrix regulär ist. Das zeigt sich aber, wenn wir die $4(n - 1)$ Koeffizienten zugunsten der Momente $M_i := s''(x_i)$ eliminieren. Mit den Abständen $h_i := x_{i+1} - x_i$ bleibt für jeden inneren Knoten $i = 2, \dots, n - 1$ genau eine Gleichung übrig,

$$h_{i-1} M_{i-1} + 2(h_{i-1} + h_i) M_i + h_i M_{i+1} = 6 \left(\frac{y_{i+1} - y_i}{h_i} - \frac{y_i - y_{i-1}}{h_{i-1}} \right),$$

dazu $M_1 = M_n = 0$ aus der natürlichen Randbedingung. Das ist ein tridiagonales System in $n - 2$ Unbekannten, und sein Diagonaleintrag ist mit $2(h_{i-1} + h_i)$ doppelt so groß wie die Summe der beiden Nebeneinträge. Damit ist es strikt diagonaldominant, also regulär: Der natürliche kubische Spline existiert und ist eindeutig. Zugleich ist es ein Bandsystem, wie es Abschnitt 5.3 als ausnutzbare Sonderstruktur aufführt: Die Elimination verlässt das Band nie, der Aufwand wächst also nur linear in n statt kubisch. Deshalb bleiben Splines auch bei vielen Punkten billig. Für die drei Punkte aus Beispiel 13.5.8 bleibt davon die einzelne Gleichung $4M_2 = -12$ mit $M_2 = -3$, und das ist das $s''(1) = -3$, das wir dort ausrechnen. Abschnitt 13.4 zählt denselben Ansatz für vier Punkte durch.

Beispiel: Spline gegen Parabel

An drei Punkten lässt sich Satz 13.5.4 von Hand nachrechnen.

Beispiel 13.5.8 (Drei Punkte, zwei Interpolanten)

Gegeben: die Punkte $(0, 0)$, $(1, 1)$, $(2, 0)$, also $a = 0$, $b = 2$ und Knoten $x_1 = 0$, $x_2 = 1$, $x_3 = 2$. Der natürliche kubische Spline ist

$$s(x) = \begin{cases} 1,5x - 0,5x^3 & x \in [0, 1], \\ 1,5(2 - x) - 0,5(2 - x)^3 & x \in [1, 2]. \end{cases}$$

Interpolation: $s(0) = 0$, $s(1) = 1,5 - 0,5 = 1$ und $s(2) = 0$, jeweils aus dem passenden Ast.

Glattheit im inneren Knoten: Aus $s'(x) = 1,5 - 1,5x^2$ links und $s'(x) = -1,5 + 1,5(2 - x)^2$ rechts wird an der Stelle $x = 1$ beidseitig 0; aus $s''(x) = -3x$ links und $s''(x) = -3(2 - x)$ rechts beidseitig -3 . Der Spline ist also $\mathcal{C}^2$.

Natürlichkeit: $s''(0) = 0$ und $s''(2) = -3 \cdot 0 = 0$.

Damit rechnen wir das Krümmungsintegral aus, getrennt nach Teilintervall:

$$\begin{aligned} J(s) &= \int_0^1 (-3x)^2 dx + \int_1^2 (-3(2 - x))^2 dx \\ &= \int_0^1 9x^2 dx + \int_0^1 9u^2 du \\ &= 9 \cdot \left[\frac{x^3}{3} \right]_0^1 + 9 \cdot \left[\frac{u^3}{3} \right]_0^1 = 3 + 3 = 6. \end{aligned}$$

Im zweiten Integral haben wir $u = 2 - x$ substituiert; das Minuszeichen aus $du = -dx$ und die gedrehten Grenzen heben sich auf.

Zum Vergleich die Parabel $p(x) = -x^2 + 2x$. Auch sie interpoliert, denn $p(0) = 0$, $p(1) = 1$ und $p(2) = 0$. Ihre Ableitungen sind $p'(x) = -2x + 2$ und $p''(x) = -2$, also

$$J(p) = \int_0^2 (-2)^2 dx = 4 \cdot 2 = 8.$$

Interpolant	$\int_0^2 f''(x) ^2 dx$
Spline s	6
Parabel p	8

Der Spline gewinnt, wie Satz 13.5.4 es verlangt. Der Überschuss lässt sich mit (13.5.3) sogar benennen: Mit $h = p - s$ ist $h''(x) = -2 + 3x$ auf $[0, 1]$ und

$$\int_0^1 (3x - 2)^2 dx = \left[\frac{(3x-2)^3}{9} \right]_0^1 = \frac{1}{9} - \left(-\frac{8}{9} \right) = 1,$$

auf $[1, 2]$ aus Symmetriegründen ebenso. Zusammen ist $\int_0^2 (h'')^2 dx = 2$, und tatsächlich ist $6 + 2 = 8$.

Interaktiv: Eine ganze Schar von Interpolanten

Weil $h = p - s$ an allen drei Stützstellen verschwindet, interpoliert jede Mischung $g_t = s + t h$ dieselben Daten, für jedes $t \in \mathbb{R}$. Der Regler fährt diese Schar ab: $t = 0$ ist der Spline, $t = 1$ die Parabel des Beispiels. Die Farben tragen dieselben Rollen wie im Text.

Schätzfrage. Bei welchem t wird die Krümmungsenergie minimal?

Lösung: 0 t

Das Krümmungsintegral der Schar ist $J(g_t) = J(s) + t^2 \int (h'')^2 dx = 6 + 2t^2$, eine nach oben geöffnete Parabel in t . Ihr Minimum liegt bei $t = 0$, und das ist gerade der Spline.

Die zweite Ansicht zeigt, woher der Unterschied kommt: zwei Geradenstücke von s'' gegen die Konstante -2 von p'' . Wegen $\int_0^2 s'' h'' dx = 0$ fällt der gemischte Term aus dem Integral heraus, und übrig bleibt der quadratische Zuschlag in t .

Über die Approximationsgüte sagt Satz 13.5.4 nichts: Alle Konkurrenten treffen die Daten exakt und unterscheiden sich nur in der Krümmung dazwischen. Wie weit ein Spline von einer zugrunde liegenden Funktion abweicht, klärt Abschnitt 13.6.

Selbsttest

1. Jeder kubische Spline, der die Punkte interpoliert, minimiert das Krümmungsfunktional J .

Antwort: Falsch

Nur der natürliche: Ohne $s''(a) = s''(b) = 0$ bleibt im Beweis der Randterm $[s'' h']_a^b$ stehen, und der kann jedes Vorzeichen haben. Kubische Spline-Interpolanten zu denselben Daten gibt es unendlich viele, weil zwei Randbedingungen frei sind. Die Parabel aus Beispiel 13.5.8 ist selbst einer (ein Polynom vom Grad 2 ist auch ein kubischer Spline), aber wegen $p''(0) = -2 \neq 0$ nicht der natürliche, und ihr J ist um 2 größer.

2. Beim Teleskopieren der Randterme darf $s^{(3)}$ an den Knoten springen.

Antwort: Wahr

Der Term $s^{(3)} h$ wird an jedem Knoten mit $h(x_i) = 0$ multipliziert und verschwindet dadurch

von beiden Seiten, egal wie der Sprung aussieht. Für den anderen Term $s'' h'$ gilt das nicht, dort braucht es die Stetigkeit von s'' und h' und am Rand die natürlichen Bedingungen (Bemerkung 13.5.5).

3. Der Beweis setzt voraus, dass auch die Vergleichsfunktion $g''(a) = g''(b) = 0$ erfüllt.

Antwort: Falsch

Diese Forderung wird nirgends gebraucht. Sie wäre sogar schädlich: Sie schliesse die meisten $\mathcal{C}^2$ -Interpolanten aus, und gerade gegen die soll der Spline gewinnen. Verwendet werden nur $g \in \mathcal{C}^2$ und $g(x_i) = y_i$.

4. Der Überschuss $J(p) - J(s) = 2$ im Beispiel ist genau $\int_0^2 (h'')^2 dx$ mit $h = p - s$.

Antwort: Wahr

Das ist Gleichung (13.5.3), und im Beispiel rechnet es sich aus: Auf $[0, 1]$ ist $h''(x) = -2 + 3x$ mit $\int_0^1 (3x - 2)^2 dx = 1$, auf $[1, 2]$ aus Symmetriegründen ebenso, zusammen $2 = 8 - 6$. Der Kreuzterm aus (13.5.2) fällt weg, sonst stimmte die Rechnung nicht.

5. Aus $J(g) = J(s)$ folgt stets $g = s$, auch bei nur einer Stützstelle.

Antwort: Falsch

Bei $n = 1$ ist jede affine Funktion durch den einen Punkt ein Interpolant mit $J = 0$, Minimierer gibt es also unendlich viele. Der Schluss von $h'' \equiv 0$ auf $h \equiv 0$ braucht zwei verschiedene Nullstellen von h , also $n \geq 2$.

Vertiefung: Heath führt natürliche kubische Splines in Kapitel 7 (Interpolation), Abschnitt 7.4.2 ein und rechnet dort denselben Drei-Punkte-Fall mit acht Bedingungen vor. Die Minimaleigenschaft selbst steht als Satz 7.57 bei Deuflhard und Hohmann, Numerische Mathematik 1; dort findet sich auch die Rechtfertigung, warum statt der geometrischen Krümmung deren Näherung f'' integriert wird.

13.6 Approximationsfehler

Splines setzen sich aus Polynomstücken zusammen und sind darum effizient zu berechnen (Abschnitt 13.4), und unter allen Interpolanten mit stetiger zweiter Ableitung hat der natürliche kubische Spline die kleinste Krümmung (Abschnitt 13.5). Außerdem fängt ein hinreichend feines Knotengitter jede stetige Funktion beliebig genau ein. Eine Geschwindigkeit nennt diese Aussage nicht: Sie sagt weder, wie viele Knoten wir brauchen, noch was wir gewinnen, wenn wir die Zahl der Teilintervalle verdoppeln.

Gitterweite und Fehlerschranke

Definition 13.6.1 (Partition und Gitterweite)

Eine *Partition* des Intervalls $[a, b]$ ist eine geordnete Folge von Stellen

$$a = x_0 < x_1 < \dots < x_n = b.$$

Ihre *Gitterweite* (mesh width) ist die Länge des größten Teilintervalls,

$$h := \max_{i=1, \dots, n} |x_i - x_{i-1}|.$$

h ist ein Maximum, kein Mittelwert: Ein einziges breites Teilintervall bestimmt die Gitterweite, wie fein die übrigen auch liegen.

Satz 13.6.2 (Approximationsfehler kubischer Splines)

Sei $a = x_0 < \dots < x_n = b$ eine Partition mit Gitterweite h , und sei $f \in \mathcal{C}^4[a, b]$. Dann gibt es einen kubischen Spline s mit Knoten $x_0, \dots, x_n$, der f an allen Knoten interpoliert,

$$s(x_i) = f(x_i) \quad \text{für } i = 0, \dots, n,$$

und dessen Fehler die Schranke

$$\max_{x \in [a, b]} |f(x) - s(x)| \leq C \cdot h^4 \cdot \max_{x \in [a, b]} |f^{(4)}(x)| \quad (13.6.1)$$

erfüllt, mit einer kleinen Konstanten C . Für kubische Splines mit passenden Randbedingungen gilt sie mit $C = \frac{5}{384}$.

Die Konstante $\frac{5}{384}$ gilt für den *eingespannten* kubischen Spline (Abschnitt 13.4), der zusätzlich $s'(a) = f'(a)$ und $s'(b) = f'(b)$ erfüllt. Der *natürliche* Spline erzwingt dagegen $s''(a) = s''(b) = 0$; ist $f''(a)$ oder $f''(b)$ ungleich null, erreicht er die Ordnung h^4 global nicht. Das Beispiel unten rechnet deshalb mit dem eingespannten Spline.

Vertiefung (optional): Natürlicher oder eingespannter Spline

Bemerkung 13.6.3 (Welcher Spline die Konstante trägt)

Satz 13.6.2 behauptet die Existenz eines kubischen Splines, nicht die Güte eines beliebigen Randabschlusses. Die scharfe Konstante $\frac{5}{384}$ gilt für den eingespannten Spline und ebenso für die passende Randbedingung zweiter Ordnung $s''(a) = f''(a)$ und $s''(b) = f''(b)$. Dem natürlichen Spline steht sie nicht pauschal zu: Passen seine Randwerte $s''(a) = s''(b) = 0$ nicht zu $f''(a)$ und $f''(b)$, so ist er am Rand schlechter, und sein maximaler Fehler fällt global nur wie h^2 .

Zwei eigene Rechnungen zeigen das. Für $f(x) = e^x$ auf $[0, 1]$ ist $f''(0) = 1 \neq 0$, und der maximale Fehler des natürlichen Splines sinkt beim Halbieren von h nur auf ein Viertel: $2,08 \cdot 10^{-3}$, $5,21 \cdot 10^{-4}$, $1,30 \cdot 10^{-4}$ und $3,26 \cdot 10^{-5}$ für $n = 8, 16, 32, 64$. Die Fehlerspitze rückt dabei immer näher an den rechten Rand ($x \approx 0,95$, dann $0,976$, $0,988$ und $0,994$), der Rest des Intervalls ist längst genauer. Noch schärfer ist $f(x) = x^3$: Dort steht rechts in (13.6.1) eine Null, denn $f^{(4)} \equiv 0$, und tatsächlich ist f selbst ein kubischer Spline und interpoliert sich fehlerfrei. Der natürliche Spline auf vier gleich langen Teilintervallen weicht dagegen um $0,018$ ab, weil er $s''(1) = 0$ erzwingt, während $f''(1) = 6$ ist.

Im Beispiel unten schreiben wir die Randableitungen $s'(0) = f'(0)$ und $s'(1) = f'(1)$ vor. Wie viel daran hängt, zeigt der natürliche Spline derselben Funktion. Auf groben Gittern ist der Unterschied klein, weil die Funktion an beiden Rändern fast flach ausläuft: Bei fünf Knoten messen wir $0,341$ statt $0,324$. Sobald das Gitter fein wird, dominiert der Randfehler. Bei 33 Knoten sitzt der größte Fehler des natürlichen Splines nicht mehr an der Spitze im Inneren, sondern bei $x \approx 0,012$ am linken Rand, und bei 65 Knoten ist er mit $1,84 \cdot 10^{-5}$ sogar *größer* als die Schranke $1,49 \cdot 10^{-5}$ aus (13.6.1). Ein Widerspruch wäre das nur, wenn der Satz die Schranke für jeden Randabschluss behauptete.

Bemerkung 13.6.4 (Wie wir die Schranke lesen)

1. Je enger das Gitter, desto besser die Approximation. Die Gitterweite steht in der *vierten* Potenz: Halbieren wir h , so fällt die Schranke auf $2^{-4} = \frac{1}{16}$ ihres Werts.

2. Der zweite Faktor gehört der Funktion, nicht dem Verfahren. Je kleiner $|f^{(4)}|$, desto kleiner die Schranke; je glatter also f ist, desto weniger Knoten kostet dieselbe Genauigkeit. Für ein Polynom vom Grad höchstens drei steht rechts sogar null.
3. Beide Faktoren sind Maxima über das *ganze* Intervall; lokal gerechnet steht für jedes Teilintervall dessen eigene Länge neben dem dortigen Maximum von $|f^{(4)}|$ (für Geradenstücke im Beweis zu Satz 13.6.5). Deshalb verdichten wir das Gitter dort, wo $|f^{(4)}|$ groß ist, f also stark von einem kubischen Polynom abweicht, und dünnen es aus, wo f fast gerade verläuft.

Wie viel an Punkt 3 hängt, zeigt $f(x) = \sin(2\pi x)$ auf $[0, 1]$: Zehn Knoten, die die linke Intervallhälfte als ein einziges Teilstück lassen und die rechte in acht gleiche Stücke teilen ($h = 0,5$), ergeben für den natürlichen kubischen Spline den maximalen Fehler 0,479. Neun gleichmäßig verteilte Knoten kommen auf 0,00107 und sind trotz eines Knotens weniger rund 450-mal genauer.

Woher der Exponent kommt

Warum vier? Der Exponent hängt am Grad der Polynomstücke; am einfachsten sehen wir das an geraden Stücken, dem Streckenzug durch die Punkte $(x_i, f(x_i))$.

Satz 13.6.5 (Fehler der stückweise linearen Interpolation)

Sei $f \in \mathcal{C}^2[a, b]$ und sei p der Streckenzug durch die Punkte $(x_i, f(x_i))$ zu einer Partition mit Gitterweite h . Dann gilt

$$\max_{x \in [a, b]} |f(x) - p(x)| \leq \frac{h^2}{8} \max_{x \in [a, b]} |f''(x)|. \quad (13.6.2)$$

Bei Geradenstücken steht h^2 neben f'' , allgemein bei Polynomstücken vom Grad q die Potenz h^{q+1} neben der $(q+1)$ -ten Ableitung, für kubische Stücke also h^4 neben $f^{(4)}$. Der Grad bleibt dabei fest, verfeinert wird nur das Gitter; die Probleme der Polynominterpolation hohen Grades (Abschnitt 13.3) treten deshalb nicht auf.

Vertiefung (optional): Beweis für Geradenstücke und das allgemeine Muster

Der Beweis arbeitet auf einem einzelnen Teilintervall, konstruiert eine Hilfsfunktion mit drei Nullstellen und wendet zweimal den Satz von Rolle an. Die Bemerkung danach beschreibt das allgemeine Muster.

Beweis.

- (1) Wir arbeiten auf einem einzelnen Teilintervall $[x_{i-1}, x_i]$ der Länge h_i und halten darin eine Stelle $\tilde{x}$ mit $x_{i-1} < \tilde{x} < x_i$ fest. Dort ist p die Gerade durch die beiden Endpunkte.

An den Knoten selbst ist die Differenz null, dort ist nichts zu zeigen; jede Stelle aus $[a, b]$ liegt in einem solchen Teilintervall

- (2) Wir setzen $w(t) := (t - x_{i-1})(t - x_i)$ und wählen $\lambda \in \mathbb{R}$ so, dass die Hilfsfunktion

$$g(t) := f(t) - p(t) - \lambda w(t)$$

auch in $\tilde{x}$ verschwindet.

Wegen $x_{i-1} < \tilde{x} < x_i$ ist $w(\tilde{x}) \neq 0$, also ist $\lambda = (f(\tilde{x}) - p(\tilde{x}))/w(\tilde{x})$ die einzige mögliche Wahl

- (3) Damit hat g drei Nullstellen in $[x_{i-1}, x_i]$: die beiden Knoten und $\tilde{x}$. Zwischen je zwei benachbarten Nullstellen liegt eine Nullstelle von g' , also hat g' zwei Nullstellen, und dasselbe Argument liefert ein ξ im Inneren mit $g''(\xi) = 0$.

Satz von Rolle, der Spezialfall des Mittelwertsatzes mit gleichen Funktionswerten an beiden Enden; g ist zweimal stetig differenzierbar, weil f es ist und p, w Polynome sind

- (4) Auf dem Teilintervall ist p linear, also $p'' \equiv 0$, und $w'' \equiv 2$. Aus $g''(\xi) = 0$ folgt daher

$$f''(\xi) - 2\lambda = 0, \quad \text{also} \quad \lambda = \frac{1}{2}f''(\xi).$$

- (5) Setzen wir das in $g(\tilde{x}) = 0$ ein, so steht die punktweise Darstellung des Fehlers da:

$$f(\tilde{x}) - p(\tilde{x}) = \frac{1}{2}f''(\xi)(\tilde{x} - x_{i-1})(\tilde{x} - x_i).$$

Der Betrag des Produkts ist $(\tilde{x} - x_{i-1})(x_i - \tilde{x})$; zwei nichtnegative Zahlen mit fester Summe h_i haben ihr größtes Produkt, wenn beide gleich $h_i/2$ sind, also ist er höchstens $h_i^2/4$

- (6) Auf dem Teilintervall gilt somit $|f - p| \leq \frac{h_i^2}{8} \max |f''|$, wobei das Maximum nur über dieses Teilintervall läuft. Wegen $h_i \leq h$ und weil das Maximum über $[a, b]$ mindestens so groß ist, gilt (13.6.2) auf jedem Teilintervall und damit auf ganz $[a, b]$. □

Bemerkung 13.6.6 (Das Muster hinter dem Exponenten)

Das Hilfsprodukt w hat einen Faktor je Interpolationsbedingung im Teilintervall, jeder Faktor ist von der Größenordnung h , und genauso oft wird differenziert. Bei Geradenstücken sind es zwei Bedingungen, zwei Ableitungen und h^2 , bei Stücken vom Grad q entsprechend $q+1$ Bedingungen, $q+1$ Ableitungen und h^{q+1} . Der Restterm im Satz von Taylor hat dieselbe Bauart: Dort steht eine höhere Ableitung an einer Zwischenstelle mal eine Potenz des Abstands, hier $\frac{1}{2}f''(\xi)$ mal ein Produkt von Abständen.

Für Splines ist der Beweis deutlich länger, weil die Anschlussbedingungen die Teilintervalle koppeln: Der Spline auf einem Stück hängt über das Gleichungssystem aus Abschnitt 13.4 an *allen* Daten, und darauf beruht seine Glattheit. Das Zählen der Ordnung bleibt dasselbe, und kein Schritt verlangt einen wachsenden Polynomgrad.

Ein numerisches Beispiel

Beispiel 13.6.7 (Ein Buckel auf dem Einheitsintervall)

Wir nehmen einen schmalen Buckel,

$$f(x) = \exp\left(-\alpha\left(x - \frac{2}{5}\right)^2\right) \quad \text{mit } \alpha = 40, \quad x \in [0, 1].$$

Mit $t := x - \frac{2}{5}$ ist

$$f^{(4)}(x) = (12\alpha^2 - 48\alpha^3 t^2 + 16\alpha^4 t^4) f(x), \quad M_4 := \max_{x \in [0, 1]} |f^{(4)}(x)| = 12\alpha^2 = 19200,$$

und das Maximum liegt in der Spitze $t = 0$. Um sie herum, auf einem schmalen Streifen, entsteht fast der ganze Fehler; an beiden Rändern ist f praktisch null.

Auf gleichmäßigen Gittern mit $n+1$ Knoten ist $h = 1/n$, und (13.6.1) liefert die Schranke $\frac{5}{384}h^4 M_4$. Die vierte Spalte haben wir selbst gerechnet: Wir bestimmen den eingespannten

kubischen Spline über das tridiagonale System seiner zweiten Ableitungen an den Knoten und messen $\max |f - s|$ auf einem feinen Raster.

Knoten $n + 1$	Gitterweite h	Schranke Ch^4M_4	gemessener Fehler	Faktor
5	0,25	0,977	0,324	–
9	0,125	0,0610	0,0239	13,6
17	0,0625	$3,81 \cdot 10^{-3}$	$1,11 \cdot 10^{-3}$	21,6
33	0,03125	$2,38 \cdot 10^{-4}$	$5,16 \cdot 10^{-5}$	21,4
65	0,015625	$1,49 \cdot 10^{-5}$	$3,05 \cdot 10^{-6}$	16,9
129	0,0078125	$9,31 \cdot 10^{-7}$	$1,87 \cdot 10^{-7}$	16,3

Auf groben Gittern ist der Fehler deutlich sichtbar: Bei fünf Knoten beträgt er 0,324, rund ein Drittel der Buckelhöhe 1. Der Spline erreicht an der Spitze nur 0,71 und schwingt rechts davon bis $-0,056$ unter die Nulllinie.

Der Faktor 16 stellt sich nicht sofort ein. Die Schranke fällt bei jeder Halbierung exakt auf ein Sechzehntel, der gemessene Fehler dagegen erst um den Faktor 13,6, dann um 21,6 und 21,4; ab 65 Knoten liegen die Faktoren bei 16,9 und 16,3. Der Grund ist Punkt 3 von Bemerkung 13.6.4: $|f^{(4)}|$ ist fast nur auf der Breite $1/\sqrt{\alpha} \approx 0,16$ um die Spitze von null verschieden, und solange h von dieser Größenordnung ist, hängt der Fehler stark davon ab, wie die Knoten zur Spitze liegen; die Ordnung 4 zeigt sich erst, wenn h klein gegen diese Breite ist.

Bemerkung 13.6.8 (Schranke und gemessener Fehler)

Die Schranke gilt für jedes $f \in \mathcal{C}^4[a, b]$ und jede Partition, der gemessene Fehler gehört zu einer Funktion auf einem Gitter. Aus dem Faktor 16 wird deshalb keine Gleichung, sondern eine Aussage über die Größenordnung, in Landau-Notation $\|f - s\|_\infty = O(h^4)$. Wir sagen, der Fehler sei von vierter Ordnung in h , wie bei der Konvergenzordnung iterativer Verfahren; nur läuft hier statt eines Iterationszählers die Gitterweite gegen null.

Interaktiv: Vom groben zum feinen Gitter

Um welchen Faktor erwarten wir beim Halbieren von h einen kleineren Fehler? Das Widget rechnet den Buckel aus Beispiel 13.6.7 nach und beginnt schon bei drei Knoten.

Schätzfrage. Schätzen wir den asymptotischen Faktor beim Halbieren von h .

Lösung: 16

Die Schranke fällt bei jeder Halbierung von h exakt auf ein Sechzehntel, denn sie hängt an h^4 . Der gemessene Faktor schwankt auf den groben Gittern stark (1,36, 13,58, 21,59 und 21,44) und kommt dem asymptotischen Wert erst am rechten Ende mit 16,91 nahe.

Im oberen Bild bleibt der Spline mit drei Knoten bei 0,67; erst ab neun Knoten liegen Funktion und Interpolant nahezu übereinander. Im unteren Bild verschwindet der Fehler an jedem Knoten und bildet dazwischen Bäuche, die sich um die Spitze sammeln, wo $|f^{(4)}|$ groß ist.

Was Splines stark macht

Bemerkung 13.6.9 (Vier Stärken auf einen Blick)

1. *Effiziente Berechnung.* In der B-Spline-Basis führt die Interpolation auf ein Gleichungssystem mit Bandstruktur (Abschnitt 13.4), und Bandstruktur senkt den Aufwand

(Bemerkung 5.3.9 in Abschnitt 5.3). Die zweiten Ableitungen des kubischen Spline-Interpolanten an den Knoten lösen sogar ein *tridiagonales* System, das $O(n)$ statt $O(n^3)$ Operationen kostet.

2. *Stabilität und Lokalität.* B-Splines haben kompakten Träger: Eine Änderung an einem Datenpunkt wirkt nur lokal, und die Basis ist weit besser konditioniert als die Monombasis (Abschnitt 13.3, Kondition in Abschnitt 4.2).
3. *Minimale Krümmung.* Unter allen Interpolanten aus $\mathcal{C}^2$ macht der natürliche kubische Spline $\int_a^b |f''(x)|^2 dx$ am kleinsten (Abschnitt 13.5).
4. *Approximationsfehler $O(h^4)$ bei passenden Randbedingungen.* Halbieren wir h , so fällt die Schranke aus Satz 13.6.2 um den Faktor 16, ohne dass wir den Polynomgrad anrühren. Für einen natürlichen Spline ohne passende Randkrümmung gilt diese globale Ordnung im Allgemeinen nicht (Bemerkung 13.6.3).

Alle vier Punkte gelten für *Interpolation*, also für Daten ohne Rauschen. Tragen die y_i eine Zufallskomponente, wollen wir sie nicht mehr exakt treffen, und aus dem Interpolationsproblem wird ein Glättungsproblem (Abschnitt 13.7).

Selbsttest

1. Halbieren wir die Gitterweite, so fällt die Schranke aus Satz 13.6.2 auf ein Sechzehntel.

Antwort: Wahr

Die Schranke ist $Ch^4 M_4$, und nur h ändert sich. Aus $(h/2)^4 = h^4/16$ folgt der Faktor $\frac{1}{16}$ exakt. In Beispiel 13.6.7 sind das die Werte 0,977, 0,0610, $3,81 \cdot 10^{-3}$, $2,38 \cdot 10^{-4}$ und so fort.

2. Auch der tatsächliche Fehler wird bei jeder Halbierung von h genau 16-mal kleiner.

Antwort: Falsch

(13.6.1) ist eine obere Schranke, keine Gleichung. Am Buckel aus Beispiel 13.6.7 messen wir die Faktoren 13,6, 21,6, 21,4, 16,9 und 16,3; erst wenn das Gitter die Spitze auflöst, nähern sie sich 16, ohne die Zahl genau zu treffen. Als Aussage über die Größenordnung bleibt die Faustregel „Fehler wird $2^4 = 16$ -mal kleiner“ richtig.

3. Weil $f(x) = x^3$ die Bedingung $f^{(4)} \equiv 0$ erfüllt, interpoliert der natürliche kubische Spline diese Funktion fehlerfrei.

Antwort: Falsch

Fehlerfrei ist der Spline aus Satz 13.6.2, und das ist hier f selbst: Ein kubisches Polynom ist ein kubischer Spline. Der natürliche Spline erzwingt zusätzlich $s''(a) = s''(b) = 0$, während $f''(1) = 6$ ist. Auf vier gleich langen Teilintervallen von $[0, 1]$ weicht er um 0,018 ab, obwohl die rechte Seite von (13.6.1) null ist (Bemerkung 13.6.3).

4. Ein einziges breites Teilintervall verdirbt die Schranke, auch wenn alle übrigen Knoten dicht liegen.

Antwort: Wahr

h ist das Maximum der Teilintervall-Längen (Definition 13.6.1), und die Schranke wächst mit seiner vierten Potenz. Die Rechnung zu $\sin(2\pi x)$ zeigt es am gemessenen Fehler: Zehn Knoten mit einer Lücke der Breite 0,5 liefern 0,479, neun gleichmäßig verteilte Knoten dagegen 0,00107.

5. Satz 13.6.2 gibt eine Fehlerschranke für jede stetige Funktion f auf $[a, b]$.

Antwort: Falsch

Der Satz verlangt $f \in \mathcal{C}^4[a, b]$, denn auf der rechten Seite steht $\max |f^{(4)}|$. Dass sich stetige Funktionen durch Splines beliebig genau approximieren lassen, ist eine andere Aussage (Abschnitt 13.4); sie nennt keine Geschwindigkeit. Bei weniger Glattheit ergibt sich eine schwächere Ordnung: Satz 13.6.5 verlangt nur $f \in \mathcal{C}^2$ und liefert dafür auch nur $O(h^2)$.

6. Bei stückweise linearer Interpolation bringt eine Halbierung der Gitterweite nur den Faktor 4.

Antwort: Wahr

Satz 13.6.5 gibt die Schranke $h^2/8 \cdot \max |f''|$, und h^2 viertelt sich beim Halbieren. Für $\sin(2\pi x)$ messen wir die Fehler 0,211, 0,0704, 0,0188 und 0,00479 bei $n = 4, 8, 16, 32$, also die Faktoren 2,99, 3,73 und 3,93. Der kubische Spline gewinnt pro Verfeinerung deutlich mehr; das ist ein Grund, warum kubisch die übliche Wahl ist.

Vertiefung: Heath entwickelt die stückweise Polynominterpolation und die kubischen Splines in Kapitel 7. Die scharfe Konstante $5/384$ für den eingespannten kubischen Spline geht auf C. A. Hall und W. Meyer, *Optimal error bounds for cubic spline interpolation*, *Journal of Approximation Theory* 16 (1976), 105–122, zurück.

13.7 Glättung und Regression

Bisher waren die Daten exakt: Ein Interpolant läuft durch jeden Punkt, und Satz 13.6.2 sagt, wie weit er dazwischen danebenliegen kann. Messwerte sind aber selten exakt (ein Sensor rauscht, eine Stichprobe streut), und ein Interpolant lief durch jeden Messfehler. Wir verlangen deshalb nur noch, dass die Kurve die Daten ungefähr trifft; das ist die Glättung aus Abschnitt 13.1.

Das Modell

Definition 13.7.1 (Regressionsmodell mit additivem Fehler)

An Stellen $x_1, \dots, x_n \in [a, b]$ beobachten wir

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, n, \quad (13.7.1)$$

mit einer unbekannten Funktion f und Zufallsfehlern $\varepsilon_1, \dots, \varepsilon_n$, die

$$\mathbb{E}[\varepsilon_i | x_i] = 0$$

erfüllen. Gesucht ist eine Schätzung $\hat{f}$ von f .

Der Unterschied zur Interpolation steckt allein im roten Term. Ohne ihn wären die y_i Funktionswerte, und wir wären wieder in Abschnitt 13.6.

Bemerkung 13.7.2 (Was in der Fehlerannahme steckt)

1. Die Beobachtungen streuen an jeder Stelle *um* $f(x_i)$ herum, nicht systematisch daneben: $f(x)$ ist der bedingte Erwartungswert $\mathbb{E}[y | x]$, und ε_i ist reine Streuung. Ohne diese Forderung wäre f nicht einmal bestimmt, denn $(g + c, \varepsilon - c)$ liefert für jede Konstante c dieselben Beobachtungen wie (g, ε) .
2. Über Abhängigkeit und Streuung der ε_i sagt die Annahme nichts, und die KQ-

Herleitung dieses Abschnitts braucht beides nicht. Unkorreliertheit und die gemeinsame Varianz σ^2 kommen erst in Abschnitt 13.8 ins Spiel.

Wie messen wir, ob ein Kandidat $\hat{f}$ zu den Daten passt? Mit derselben Größe wie in Kapitel 7, der Summe der quadrierten Abweichungen:

$$\text{RSS}(\hat{f}) := \sum_{i=1}^n (y_i - \hat{f}(x_i))^2. \quad (13.7.2)$$

Die Abkürzung steht für *residual sum of squares*, die Residuenquadratsumme. Die einzelnen Differenzen $r_i = y_i - \hat{f}(x_i)$ heißen *Residuen*.

Bemerkung 13.7.3 (Die Aufgabe ist so noch entartet)

Über *alle* Funktionen ist das Minimum von (13.7.2) null, und angenommen wird es von jedem der unendlich vielen Interpolanten der Daten (Abschnitt 13.1). Alle übernehmen an den Datenstellen jedes ϵ_i , und die RSS kann zwischen einem brauchbaren und einem beliebig schlechten Verlauf zwischen den Punkten nicht unterscheiden. Die Zielfunktion allein legt also nichts fest; es gibt zwei Auswege:

- Wir minimieren nur über einen *kleinen* Funktionenraum; das ist der Weg der nächsten Seiten.
- Wir minimieren über einen großen Raum und bestrafen unruhige Kandidaten; darauf kommen wir am Ende des Abschnitts zurück.

Der Basisansatz macht daraus ein KQ-Problem

Den ersten Weg kennen wir schon aus der Interpolation (Abschnitt 13.2): Wir legen endlich viele Funktionen fest und lassen nur deren Linearkombinationen zu.

Definition 13.7.4 (Ansatzraum und Designmatrix)

Seien $\phi_1, \dots, \phi_K$ fest gewählte Funktionen auf $[a, b]$, die *Basisfunktionen*, und sei

$$\mathcal{F}_K := \left\{ \sum_{k=1}^K a_k \phi_k : a_1, \dots, a_K \in \mathbb{R} \right\}$$

der von ihnen aufgespannte Ansatzraum. Die *Designmatrix* zu den Stellen $x_1, \dots, x_n$ ist

$$\mathbf{B} := \begin{pmatrix} \phi_1(x_1) & \cdots & \phi_K(x_1) \\ \vdots & \ddots & \vdots \\ \phi_1(x_n) & \cdots & \phi_K(x_n) \end{pmatrix} \in \mathbb{R}^{n \times K}, \quad b_{ik} = \phi_k(x_i).$$

Das ist die Matrix aus Satz 13.2.8.

Für Splines sind die ϕ_k die B-Splines zu einem gewählten Knotenvektor $\xi_1 < \dots < \xi_{m-1}$ (Abschnitt 13.4). Wir halten die beiden Rollen auseinander: x_i sind die Stellen, an denen *gemessen* wurde, ξ_j die Stellen, an denen die Polynomstücke *zusammengesetzt* werden. Beide dürfen verschieden liegen, und bei der Glättung tun sie das auch.

Satz 13.7.5 (Glättung ist ein lineares Kleinste-Quadrate-Problem)

Sei $\hat{f} = \sum_{k=1}^K a_k \phi_k \in \mathcal{F}_K$ mit Koeffizientenvektor $\mathbf{a} = (a_1, \dots, a_K)^\top$. Dann gilt

$$\sum_{i=1}^n (y_i - \hat{f}(x_i))^2 = \|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2^2, \quad \mathbf{y} = (y_1, \dots, y_n)^\top, \quad (13.7.3)$$

und $\mathbf{a}$ minimiert die linke Seite genau dann, wenn es die Normalengleichungen

$$\mathbf{B}^\top \mathbf{B} \mathbf{a} = \mathbf{B}^\top \mathbf{y} \quad (13.7.4)$$

erfüllt. Hat $\mathbf{B}$ vollen Spaltenrang K , so ist die Lösung eindeutig, $\hat{\mathbf{a}} = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}$. Andernfalls ist die Lösungsmenge ein affiner Raum, und $\hat{\mathbf{a}} = \mathbf{B}^+ \mathbf{y}$ ist ihr Element kleinster Norm. Der Vektor der angepassten Werte $\mathbf{B}\hat{\mathbf{a}}$ ist in beiden Fällen eindeutig.

Vertiefung (optional): Beweis der Kleinste-Quadrate-Darstellung

Beweis.

- (1) Nach Definition der Designmatrix ist der Wert von $\hat{f}$ an der Stelle x_i gerade die i -te Komponente von $\mathbf{B}\mathbf{a}$:

$$\hat{f}(x_i) = \sum_{k=1}^K a_k \phi_k(x_i) = \sum_{k=1}^K b_{ik} a_k = (\mathbf{B}\mathbf{a})_i.$$

Die i -te Zeile von $\mathbf{B}$ enthält genau die Werte $\phi_1(x_i), \dots, \phi_K(x_i)$, das Skalarprodukt mit $\mathbf{a}$ ist die Auswertung

- (2) Damit ist die Summe der quadrierten Residuen die quadrierte euklidische Norm des Vektors $\mathbf{y} - \mathbf{B}\mathbf{a}$, also (13.7.3).

$$\|\mathbf{v}\|_2^2 = \sum_i v_i^2 \text{ mit } v_i = y_i - (\mathbf{B}\mathbf{a})_i$$

- (3) Jedes Element von $\mathcal{F}_K$ hat einen Koeffizientenvektor, und jeder Koeffizientenvektor liefert ein Element von $\mathcal{F}_K$. Das Minimieren über $\mathcal{F}_K$ ist deshalb dasselbe wie das Minimieren über $\mathbf{a} \in \mathbb{R}^K$, und das ist das lineare Kleinste-Quadrate-Problem $\min_{\mathbf{a}} \|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2$ aus Abschnitt 7.1.

Die Zuordnung $\mathbf{a} \mapsto \sum_k a_k \phi_k$ bildet $\mathbb{R}^K$ auf $\mathcal{F}_K$ ab; ein Minimum der einen Aufgabe ist eines der anderen

- (4) Die Minimierer von $\|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2$ sind genau die Lösungen der Normalengleichungen (13.7.4). Das ist die Projektions-Eigenschaft aus Abschnitt 7.1: Der Abstand wird minimal, wenn $\mathbf{B}\mathbf{a}$ die orthogonale Projektion von $\mathbf{y}$ auf den Spaltenraum von $\mathbf{B}$ ist, und das heißt, dass das Residuum auf allen Spalten senkrecht steht, $\mathbf{B}^\top(\mathbf{y} - \mathbf{B}\mathbf{a}) = \mathbf{0}$.

Ausmultipliziert ist $\mathbf{B}^\top(\mathbf{y} - \mathbf{B}\mathbf{a}) = \mathbf{0}$ dasselbe wie $\mathbf{B}^\top \mathbf{B} \mathbf{a} = \mathbf{B}^\top \mathbf{y}$

- (5) Ist $\text{rang}(\mathbf{B}) = K$, so ist $\mathbf{B}^\top \mathbf{B}$ symmetrisch positiv definit und damit invertierbar (Abschnitt 7.3), die Lösung von (13.7.4) also eindeutig. Ist $\text{rang}(\mathbf{B}) < K$, so unterscheiden sich je zwei Lösungen um ein Element des Kerns von $\mathbf{B}$; unter ihnen wählt die Pseudoinverse die mit der kleinsten Norm (Abschnitt 7.6).

$\mathbf{a}^\top \mathbf{B}^\top \mathbf{B} \mathbf{a} = \|\mathbf{B}\mathbf{a}\|_2^2 > 0$ für $\mathbf{a} \neq \mathbf{0}$ gilt genau bei vollem Spaltenrang

- (6) Die angepassten Werte sind die orthogonale Projektion von $\mathbf{y}$ auf den Spaltenraum, und eine Projektion hängt nur vom Unterraum ab, nicht von der gewählten Darstellung. Sie ist deshalb auch bei Rangdefekt eindeutig.

□

Bemerkung 13.7.6 (Wie wir das System numerisch lösen)

Die Normalgleichungen quadrieren die Konditionszahl, $\kappa_2(\mathbf{B}^\top \mathbf{B}) = \kappa_2(\mathbf{B})^2$; deshalb zieht Kapitel 7 die QR-Zerlegung vor (Abschnitt 7.4, Vergleich der Verfahren in Abschnitt 7.6), und der R-Code am Ende dieses Abschnitts nutzt `qr.solve`. Für B-Splines ist der Schaden klein: Für den Datensatz unseres Widgets messen wir $\kappa_2(\mathbf{B}) \approx 5,6$ bei $K = 10$ und $\kappa_2(\mathbf{B}) \approx 65$ bei $K = 40$, die Monombasis derselben Größe liegt viele Zehnerpotenzen darüber (Abschnitt 13.3). Dazu kommt die Bandstruktur: Jede Basisfunktion lebt nur über wenigen Teilintervallen, also ist $\mathbf{B}^\top \mathbf{B}$ dünn besetzt und die Zerlegung günstig (Abschnitt 5.3).

Bemerkung 13.7.7 (Wann die Designmatrix vollen Spaltenrang hat)

Notwendig ist $K \leq n$, aber das reicht nicht: Die Basisfunktionen müssen auch *auf den Daten* linear unabhängig sein, und dafür müssen die Knoten zu den Messstellen passen. Nach dem Satz von Schoenberg und Whitney muss jede Basisfunktion einen eigenen, passend geordneten Datenpunkt belegen können. Mit Knoten auf den Quantilen der x_i gelingt das bis $K = n$; das Widget legt seine Knoten daher auf Quantile, wie es auch `splines::bs()` tut.

Vertiefung (optional): Die Schoenberg-Whitney-Bedingung im Detail

Für B-Splines vom Grad q mit erweitertem Knotenvektor τ lautet die Bedingung: Es müssen sich Indizes $i_1 < \dots < i_K$ finden, sodass die jeweils zugeordnete Basisfunktion am eigenen Datenpunkt positiv ist,

$$B_k^{(q)}(x_{i_k}) > 0, \quad k = 1, \dots, K.$$

Im Inneren des Knotengebiets ist das gleichbedeutend mit $\tau_k < x_{i_k} < \tau_{k+q+1}$. Bei einem offenen, an den Rändern geklemmten Knotenvektor gehören die positiven Randwerte der ersten und letzten Basisfunktion ausdrücklich dazu.

Die naheliegende Abschwächung „jede Basisfunktion sieht mindestens einen Datenpunkt“ genügt dafür nicht. Unsere eigene Rechnung mit den 50 Punkten des Widgets, aber *gleichmäßigen* Knoten auf $[0, 2\pi]$, zeigt es: Bei $K = 35$ hat jede der 35 Basisfunktionen mindestens einen Datenpunkt im Träger, und trotzdem bricht die Cholesky-Zerlegung von $\mathbf{B}^\top \mathbf{B}$ ab, weil sieben der 32 Knotenintervalle leer bleiben und die Bedingung damit verletzt ist.

Interpolation und Glättung sind derselbe Rahmen

Der Rahmen aus Satz 13.7.5 deckt beide Aufgaben ab.

Definition 13.7.8 (Interpolation und Glättung im Basisansatz)

Eine Anpassung *interpoliert* die Daten, wenn ihre Residuen verschwinden, also wenn

$$\mathbf{B}\hat{\mathbf{a}} = \mathbf{y} \quad \text{beziehungsweise} \quad \hat{f}(x_i) = y_i \quad \text{für alle } i$$

gilt. Bei einer *Glättung* dürfen Residuen verbleiben, damit die Schätzung nicht jede beobachtete Schwankung übernehmen muss.

Ohne Strafterm ist $K = n$ mit invertierbarem $\mathbf{B}$ der Interpolationsfall und $K < n$ mit vollem Spaltenrang der Glättungsfall, denn dann lässt sich nicht mehr jeder Datenvektor interpolieren. Die Zahlen K und n allein legen die Begriffe aber nicht fest; entscheidend sind Rang, rechte Seite und ein möglicher Strafterm.

Bemerkung 13.7.9 (Warum Interpolation das Rauschen erbt)

Warum ist das exakte Treffen schlecht? Setzen wir (13.7.1) in die Interpolationsbedingung ein:

$$\hat{f}(x_i) = y_i = f(x_i) + \varepsilon_i \quad \implies \quad \hat{f}(x_i) - f(x_i) = \varepsilon_i.$$

An jeder Beobachtungsstelle ist der Schätzfehler exakt der Messfehler. Er wird nicht kleiner, wenn wir mehr Daten erheben, denn jeder neue Punkt bringt seinen eigenen Fehler mit, den der Interpolant übernimmt. Zwischen den Punkten wird es eher schlechter: Liegen zwei Stellen dicht beieinander und ziehen ihre Fehler in verschiedene Richtungen, muss die Kurve dazwischen steil werden. Modelliert eine Schätzung auf diese Weise den Zufallsanteil der Daten mit, spricht die Statistik von Überanpassung.

Bei $K < n$ und vollem Spaltenrang wird dagegen jeder Koeffizient aus mehreren Beobachtungen bestimmt, und in dieser Mittelung hebt sich ein Teil der Fehler auf. Der Nachteil: Der kleine Ansatzraum enthält f vielleicht nicht; wie sich beides gegeneinander verrechnet, ist das Thema von Abschnitt 13.8.

Beispiel 13.7.10 (Fünfzig verrauschte Punkte)

Wir ziehen einmal $n = 50$ Stellen gleichverteilt auf $[0, 2\pi]$, werten dort

$$f(x) = \sin(x) + \frac{1}{2} \sin(2x)$$

aus und addieren normalverteilte Fehler mit $\sigma = 0,3$ (fester Startwert; die gezogenen Fehler haben die empirische Streuung 0,266). Darauf passen wir kubische B-Splines mit K Basisfunktionen an, Knoten auf den Quantilen der x_i . Für vier Werte von K rechnet unser Widget:

K	RSS	$\hat{\sigma}$	Abstand zu f	größte Abweichung
4	6,421	0,374	0,247	0,467
10	3,084	0,278	0,086	0,532
20	2,460	0,286	0,269	2,223
40	0,557	0,236	1,908	8,574

Dabei ist $\hat{\sigma} = \sqrt{\text{RSS} / (n - K)}$ der übliche Residualstandardfehler, eine Schätzung von σ ; fehlt f im Ansatzraum, enthält er zusätzlich den Anpassungsfehler (lack of fit), wie bei $K = 4$. „Abstand zu f “ ist die Wurzel aus dem mittleren quadrierten Abstand

$$\frac{1}{2\pi} \int_0^{2\pi} (\hat{f}(x) - f(x))^2 dx.$$

Die beiden mittleren Spalten lassen sich aus den Daten berechnen, die beiden rechten nur mit Kenntnis von f . Und sie laufen auseinander: Von $K = 10$ auf $K = 40$ fällt die Residuenquadratsumme auf weniger als ein Fünftel, während der Abstand zur wahren Funktion auf das Zweiundzwanzigfache steigt. Am besten trifft in unserem Lauf $K = 11$ mit einem Abstand von 0,072.

Die Tabelle zeigt drei Regime. Bei $K = 4$ ist der Ansatzraum der Raum der kubischen Polynome, und die Kurve ist zu starr für beide Wellen von f ; zwischen $K = 6$ und $K = 15$ liegt sie im Rauschband, mit $\hat{\sigma}$ zwischen 0,278 und 0,306 nahe der wahren Streuung 0,3. Ab $K = 16$ beginnen die Ausschläge, und der Abstand zu f wächst wieder, während die Residuen weiter fallen.

Bemerkung 13.7.11 (Die Residuen fallen nicht immer)

Für *geschachtelte* Räume kann die Residuenquadratsumme mit wachsendem K nicht steigen, denn der alte Minimierer bleibt zulässig. Knoten auf Quantilen wandern aber mit K , und dann sind die Räume nicht geschachtelt. In unserem Lauf steigt die Residuenquadratsumme bei elf der 36 Schritte von K auf $K + 1$ wieder an, etwa von $K = 6$ auf $K = 7$.

Interaktiv: Ein Regler für die Flexibilität

Welcher der drei Werte von K dürfte die unbekannte wahre Funktion am besten treffen? Das Widget rechnet den Fit für jedes K zwischen 4 und 40 neu.

Schätzfrage. Welcher der drei Fälle wirkt als Schätzer am plausibelsten?

Lösung: *passend*

$K = 4$ ist zu starr, $K = 40$ zu flexibel. Im Reglerbereich hat $K = 11$ den kleinsten mittleren Abstand zum wahren f – ausrechnen ließe sich das an echten Daten allerdings nicht, weil dazu f bekannt sein müsste.

Am Regler durchlaufen wir die drei Regime: Die rot gezeichneten Residuen werden im Mittel kürzer, während die grüne Kurve immer weniger mit der violett gezeichneten wahren Funktion zu tun hat und von $K = 30$ an meist das Bildfenster verlässt. Die untere Tafel zeigt die K Basisfunktionen, die mit wachsendem K schmaler und zahlreicher werden.

Der zweite Weg: strafen statt weglassen

Bei der Glättung über einen kleinen Ansatzraum steuert K die Glattheit in groben Stufen, und Zahl und Lage der Knoten müssen vorab feststehen. Der zweite Weg aus Bemerkung 13.7.3 lässt viele Knoten zu und bestraft unruhige Lösungen: Wir minimieren $\sum_i (y_i - g(x_i))^2 + \lambda \int_a^b |g''(x)|^2 dx$ entweder über allen $\mathcal{C}^2$ -Funktionen (*Glättungsspline*, Knoten in allen Datenpunkten) oder über einer großen B-Spline-Basis mit $K < n$ (*Penalized Splines*, die Grundlage der additiven Modelle). Der Strafterm ist das Krümmungsfunktional aus Abschnitt 13.5, und gesteuert wird mit λ statt mit K .

Vertiefung (optional): Glättungssplines und Penalized Splines im Detail**Definition 13.7.12 (Penalisiertes Kleinste-Quadrate-Kriterium)**

Für $\lambda \geq 0$ heißt

$$\sum_{i=1}^n (y_i - g(x_i))^2 + \lambda \int_a^b |g''(x)|^2 dx \quad (13.7.5)$$

das *penalisierte* Kleinste-Quadrate-Kriterium, und ein Minimierer über $\mathcal{C}^2[a, b]$ heißt *Glättungsspline* (smoothing spline). Der Parameter λ heißt *Glättungsparameter*.

Wir schreiben $J(g) = \int_a^b |g''|^2 dx$ für das Krümmungsfunktional, das in Abschnitt 13.5 den natürlichen kubischen Spline ausgezeichnet hat.

Bemerkung 13.7.13 (Was der Strafterm bewirkt)

1. *Der Minimierer ist wieder ein Spline.* Für $\lambda > 0$ und mindestens zwei verschiedene Beobachtungsstellen ist der Minimierer von (13.7.5) über $\mathcal{C}^2[a, b]$ ein natürlicher kubischer Spline mit Knoten in *allen* verschiedenen Datenpunkten. Das ist der Satz von Schoenberg und Reinsch, den wir hier nicht beweisen; Green und Silverman führen ihn in Kapitel 2 vor. Bei paarweise verschiedenen x_i hat der daraus entstehende natürliche Spline-Raum Dimension $K = n$, und trotzdem entsteht für $\lambda > 0$ keine Interpolation.
2. *Die beiden Grenzfälle sind vertraut.* Für $\lambda \rightarrow 0$ verschwindet die Strafe. Bei paarweise verschiedenen Datenstellen bleiben im Grenzwert die Interpolanten, und unter ihnen wählt der Strafterm den mit der kleinsten Krümmung, also den natürlichen kubischen Spline aus Satz 13.5.4. Bei wiederholten Stellen mit verschiedenen Beobachtungen kann es dagegen keinen Interpolanten aller Einzelwerte geben. Für $\lambda \rightarrow \infty$ wird jeder Kandidat mit $J(g) > 0$ ausgeschlossen; übrig bleiben die Funktionen mit $g'' \equiv 0$, also die Geraden, und unter ihnen die Kleinste-Quadrate-Gerade. Der Glättungsparameter bewegt die Schätzung stufenlos zwischen Interpolation und einfacher linearer Regression.
3. *Stetige Steuerung.* Statt einer ganzen Zahl K wählen wir die stetige Größe λ , und die Knotenwahl fällt als Frage weg. Dafür ist das Gleichungssystem von der Größe n statt K .

Bemerkung 13.7.14 (Penalized Splines und die Nähe zu Ridge)

Zwischen beiden Wegen liegt der in der Praxis übliche Kompromiss: eine große, aber nicht datengroße Basis ($K < n$) und ein Strafterm. Solche *Penalized Splines* führen auf ein Kriterium, das sich vollständig in Matrixform schreiben lässt. Mit $\mathbf{P}_{jk} := \int_a^b \phi_j''(x) \phi_k''(x) dx$ ist $\int_a^b |\hat{f}''|^2 dx = \mathbf{a}^\top \mathbf{P} \mathbf{a}$, und (13.7.5) wird zu

$$\|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2^2 + \lambda \mathbf{a}^\top \mathbf{P} \mathbf{a}.$$

Ableiten nach $\mathbf{a}$ und Nullsetzen liefert die gestraften Normalengleichungen

$$(\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{P}) \mathbf{a} = \mathbf{B}^\top \mathbf{y}.$$

Mit $\mathbf{P} = \mathbf{I}$ steht dort die Ridge-Regression aus Abschnitt 12.5, und der Effekt ist derselbe: Der Zuschlag macht das System auch dann eindeutig lösbar, wenn $\mathbf{B}$ keinen vollen Spaltenrang hat. Beim Krümmungs-Strafterm ist $\mathbf{P}$ allerdings nur positiv semidefinit, denn affine Funktionen haben Strafe null. Positiv definit wird $\mathbf{B}^\top \mathbf{B} + \lambda \mathbf{P}$ dann, sobald keine affine Funktion an allen Datenstellen verschwindet, wofür zwei verschiedene x_i genügen. Der Unterschied zu Ridge liegt in der Bedeutung: Dort werden *große* Koeffizienten bestraft, hier *unruhige* Funktionen. Wie λ gewählt wird, ist dieselbe Frage wie die nach dem richtigen K ; Abschnitt 13.8 kommt darauf zurück.

Wann welche Methode?

Situation	Methode
präzise, rauschfreie Daten	Interpolation
verrauschte Messungen	Glättung
Vorhersage auf neuen Daten	Glättung

Die dritte Zeile ist die am wenigsten offensichtliche: Auf den vorliegenden Daten hat die Interpolation die kleinste Residuenquadratsumme, nämlich null. Bei der Vorhersage an einer *neuen* Stelle zählt aber der Abstand zu f , und der ist bei einer glatten Schätzung kleiner (Beispiel 13.7.10).

Beispiel: Glättung in R

Für den Datensatz aus Beispiel 13.7.10 sieht das in R so aus:

```
B <- splines::bs(x, df = 10, intercept = TRUE) # n x 10 Designmatrix
a_hat <- qr.solve(B, y) # KQ-Loesung ueber QR

x_new <- seq(0, 2 * pi, length = 200)
B_new <- splines::bs(x_new,
                     knots = attr(B, "knots"),
                     Boundary.knots = attr(B, "Boundary.knots"),
                     intercept = TRUE)
f_hat <- B_new %*% a_hat
```

- `bs()` baut die Designmatrix **B**; `df = 10` mit `intercept = TRUE` fordert $K = 10$ Spalten, bei Grad 3 also $10 - 3 - 1 = 6$ innere Knoten auf den Quantilen der x_i . Wir wählen nicht die Knoten, sondern ihre Anzahl.
- `qr.solve(B, y)` löst das überbestimmte System über die QR-Zerlegung (Abschnitt 7.4), den stabileren Weg (Bemerkung 13.7.6).
- Für die Vorhersage braucht `B_new` *dieselbe* Basis; deshalb übernehmen wir `knots` und `Boundary.knots` von `B`, sonst gehört `B_new` ohne Fehlermeldung zu einer anderen Basis als `a_hat` (Bemerkung 13.4.12).

Selbsttest

1. Im Glättungs-Widget kann $K = 40$ eine kleinere RSS und zugleich eine schlechtere Annäherung an die wahre Funktion liefern.

Antwort: Wahr

Die RSS misst nur die Anpassung an die verrauschten Daten; bei großem K folgt der Fit einzelnen Störungen. In Beispiel 13.7.10 hat $K = 40$ die kleinste RSS und den größten Abstand zu f .

2. Minimieren wir $\sum_i (y_i - \hat{f}(x_i))^2$ über alle Funktionen $\hat{f}$, so erhalten wir die bestmögliche Schätzung von f .

Antwort: Falsch

Das Minimum ist null und wird von jedem Interpolanten angenommen, und davon gibt es unendlich viele (Abschnitt 13.1). Alle diese Funktionen übernehmen die Fehler ε_i punktweise (Bemerkung 13.7.9). Erst eine Einschränkung des Suchraums oder ein Strafterm macht die Aufgabe sinnvoll.

3. Ist $K = n$ und hat **B** vollen Rang, so ist die Residuenquadratsumme null.

Antwort: Wahr

Dann ist **B** quadratisch und invertierbar, (13.7.4) hat die Lösung $\hat{\mathbf{a}} = \mathbf{B}^{-1}\mathbf{y}$, und der Fit trifft jeden Punkt exakt. Für den Datensatz aus Beispiel 13.7.10 rechnen wir mit $K = n = 50$ eine Residuenquadratsumme von 10^{-16} nach. Ein guter Schätzer ist das nicht: Die Koeffizienten erreichen dabei Beträge über $3 \cdot 10^4$, und $\kappa_2(\mathbf{B})$ steigt auf rund $2 \cdot 10^5$.

4. Damit $\mathbf{B}^\top \mathbf{B}$ invertierbar ist, genügt es, dass jede Basisfunktion mindestens einen Datenpunkt in ihrem Träger hat.

Antwort: Falsch

Gebraucht wird die Bedingung von Schoenberg und Whitney aus Bemerkung 13.7.7, und die verlangt für jede Basisfunktion einen *eigenen* Datenpunkt in der richtigen Reihenfolge. Unsere Gegenrechnung mit gleichmäßigen Knoten und $K = 35$ auf 50 Punkten erfüllt die schwächere Forderung, und trotzdem bricht die Cholesky-Zerlegung ab.

5. Auch bei Rangdefekt von $\mathbf{B}$ sind die angepassten Werte $\hat{\mathbf{B}}\mathbf{a}$ eindeutig bestimmt.

Antwort: Wahr

Sie sind die orthogonale Projektion von $\mathbf{y}$ auf den Spaltenraum von $\mathbf{B}$, und die hängt nur vom Unterraum ab (Satz 13.7.5). Nicht eindeutig sind dagegen die Koeffizienten und mit ihnen die Funktion $\hat{f}$ selbst: Zwei Lösungen unterscheiden sich um ein Element des Kerns von $\mathbf{B}$, und die zugehörige Funktion verschwindet nur an den Datenstellen, nicht überall.

6. Mit wachsendem K fällt die Residuenquadratsumme in jedem Schritt.

Antwort: Falsch

Für geschachtelte Ansatzräume stimmt es, denn der alte Minimierer bleibt zulässig. Wandern die Knoten mit K , etwa weil sie auf Quantilen liegen, so sind die Räume nicht geschachtelt: In unserem Lauf steigt die Residuenquadratsumme bei elf von 36 Schritten wieder an, von $K = 6$ auf $K = 7$ etwa von 3,435 auf 4,016 (Bemerkung 13.7.11).

Vertiefung: Die Theorie der Glättungssplines samt Existenz- und Eindeutigkeitsatz entwickeln P. J. Green und B. W. Silverman, Nonparametric Regression and Generalized Linear Models, Chapman und Hall 1994, Kapitel 2; die Penalized Splines und die additiven Modelle dahinter stehen bei S. N. Wood, Generalized Additive Models: An Introduction with R, 2. Auflage 2017. Die Rangbedingung aus Bemerkung 13.7.7 geht auf I. J. Schoenberg und A. Whitney (1953) zurück und wird bei C. de Boor, A Practical Guide to Splines, Springer 2001, bewiesen.

13.8 Bias-Varianz und Modellwahl

In Abschnitt 13.7 haben wir mit $K < n$ Basisfunktionen geglättet. Offen blieb die Frage, die in der Praxis am wichtigsten ist: Wie groß soll K sein? Zwei Effekte wirken gegeneinander. Zu wenige Basisfunktionen können f nicht darstellen, zu viele lassen den Schätzer dem Rauschen folgen.

Bemerkung 13.8.1 (Modell, Designmatrix, Schätzer)

Die Bezeichnungen stammen aus Abschnitt 13.7. An festen Stellen $x_1 < \dots < x_n$ in $[a, b]$ beobachten wir

$$y_i = f(x_i) + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i] = 0, \quad \text{Var}[\varepsilon_i] = \sigma^2,$$

mit unkorrelierten Fehlern. Zu einer Basis $\phi_1, \dots, \phi_K$ von Splinefunktionen (Abschnitt 13.2) bilden wir die Designmatrix $\mathbf{B} \in \mathbb{R}^{n \times K}$ mit Einträgen $B_{ik} = \phi_k(x_i)$, schreiben $\phi(\mathbf{x}) = (\phi_1(x), \dots, \phi_K(x))^T$ und erhalten den Kleinst-Quadrate-Schätzer

$$\hat{\mathbf{a}} = \mathbf{B}^+ \mathbf{y}, \quad \hat{f}(\mathbf{x}) = \phi(\mathbf{x})^T \hat{\mathbf{a}}. \quad (13.8.1)$$

Dabei ist $\mathbf{B}^+$ die Pseudoinverse (Abschnitt 7.6); hat $\mathbf{B}$ vollen Spaltenrang K , so ist $\mathbf{B}^+ = (\mathbf{B}^T \mathbf{B})^{-1} \mathbf{B}^T$, und (13.8.1) ist die gewöhnliche Lösung der Normalgleichungen (Abschnitt 7.1).

Der Schätzer ist *linear* in den Daten, er entsteht durch Multiplikation mit einer festen Matrix. Mit $\mathbf{y} = \mathbf{f} + \boldsymbol{\varepsilon}$, wobei $\mathbf{f} = (f(x_1), \dots, f(x_n))^T$ die rauschfreien Werte sammelt, zerfällt er in

$$\hat{\mathbf{a}} = \mathbf{B}^+ \mathbf{f} + \mathbf{B}^+ \boldsymbol{\epsilon}.$$

Der erste Summand ist deterministisch, der zweite trägt den ganzen Zufall. Diese Aufteilung ist die Bias-Varianz-Zerlegung in Rohform.

Bias: zu wenige Basisfunktionen

Der deterministische erste Summand misst, wie gut sich f im Spann unserer K Basisfunktionen darstellen lässt.

Satz 13.8.2 (Der Bias ist der Approximationsfehler ohne Rauschen)

Hat $\mathbf{B}$ vollen Spaltenrang, so gilt für jedes $x \in [a, b]$

$$\mathbb{E}[\hat{f}(x)] = \boldsymbol{\phi}(x)^\top \mathbf{B}^+ \mathbf{f}. \quad (13.8.2)$$

Der Erwartungswert des Schätzers ist damit dieselbe Anpassung, die wir aus rauschfreien Daten bekämen. Der *Bias* $\mathbb{E}[\hat{f}(x)] - f(x)$ hängt damit weder von σ noch von der einzelnen Ziehung ab.

Liegen die Knoten gleichmäßig auf $[a, b]$, sind die ϕ_k eine Basis der kubischen Splines zu diesen Knoten und ist $f \in \mathcal{C}^4[a, b]$, so gilt zusätzlich

$$\frac{1}{n} \sum_{i=1}^n (\mathbb{E}[\hat{f}(x_i)] - f(x_i))^2 \leq \left(Ch^4 \max_{x \in [a, b]} |f^{(4)}(x)| \right)^2 = O(K^{-8}), \quad (13.8.3)$$

wobei h die Gitterweite der Knoten ist.

Vertiefung (optional): Beweis der Bias-Darstellung

Beweis.

- (1) Nach (13.8.1) ist $\hat{f}(x)$ eine feste Linearkombination der y_i . Aus der Linearität des Erwartungswerts folgt

$$\mathbb{E}[\hat{f}(x)] = \boldsymbol{\phi}(x)^\top \mathbf{B}^+ \mathbb{E}[\mathbf{y}] = \boldsymbol{\phi}(x)^\top \mathbf{B}^+ \mathbf{f}.$$

$\mathbf{B}^+$ und $\boldsymbol{\phi}(x)$ hängen nur von den Stellen x_i und der Basis ab, nicht von den Beobachtungen; und $\mathbb{E}[\mathbf{y}] = \mathbf{f}$, weil $\mathbb{E}[\boldsymbol{\epsilon}] = 0$

- (2) Die rechte Seite von (13.8.2) ist der Kleinste-Quadrate-Fit an die rauschfreien Werte $\mathbf{f}$. Nennen wir ihn $\hat{f}_0$. Er minimiert unter allen Funktionen s des Ansatzraums $\mathcal{F}_K$, also des Spanns von $\phi_1, \dots, \phi_K$ (Abschnitt 13.7), die Summe $\sum_{i=1}^n (f(x_i) - s(x_i))^2$.

Das ist die definierende Eigenschaft der Kleinste-Quadrate-Lösung, angewendet auf den Datenvektor $\mathbf{f}$ statt auf $\mathbf{y}$

- (3) Zu den Knoten unserer Basis gehört nach Satz 13.6.2 ein kubischer Spline s^* , der f dort interpoliert und $\max_x |f(x) - s^*(x)| \leq Ch^4 \max_x |f^{(4)}(x)|$ erfüllt. Dieser Spline liegt in $\mathcal{F}_K$.

Kubische Splines zu m Teilintervallen bilden einen Raum der Dimension $m + 3 = K$, und $\phi_1, \dots, \phi_K$ ist eine Basis davon (Abschnitt 13.4)

- (4) Mit Schritt 2 und Schritt 3 folgt

$$\sum_{i=1}^n (f(x_i) - \hat{f}_0(x_i))^2 \leq \sum_{i=1}^n (f(x_i) - s^*(x_i))^2 \leq n \left(Ch^4 \max_x |f^{(4)}(x)| \right)^2,$$

und Division durch n gibt (13.8.3).

- (5) Gleichmäßige Knoten auf einem festen Intervall $[a, b]$ bedeuten $h = (b-a)/(K-3)$, also $h = O(1/K)$ und damit $h^8 = O(K^{-8})$.

K Basisfunktionen vom Grad 3 gehören zu $K-3$ Teilintervallen (Schritt 3), die Gitterweite fällt also wie $1/K$

□

Bemerkung 13.8.3 (Woran die Ordnung hängt)

Gebraucht werden gleichmäßige Knoten auf einem festen Intervall, $f \in \mathcal{C}^4$ und kubische Stücke; fällt eine Bedingung weg, ändert sich der Exponent. Bei Geradenstücken oder einer Funktion mit nur zwei stetigen Ableitungen steht h^2 statt h^4 (Satz 13.6.5), und ein einziges breites Teilintervall verdirbt die Gitterweite (Definition 13.6.1). Die Kurzform $\max_x |f(x) - \hat{f}(x)| = O(h^4)$ ist die punktweise Fassung ohne Rauschen; Satz 13.8.2 mittelt über die Entwurfsstellen und quadriert, daher $O(K^{-8})$ statt $O(K^{-4})$.

Varianz: zu viele Basisfunktionen

Der zweite Summand $\mathbf{B}^+ \epsilon$ trägt den Zufall und wächst mit K . Ziehen wir die Daten mehrfach neu, so liegen die Schätzkurven bei kleinem K fast übereinander und verfehlen f alle in dieselbe Richtung, während sie bei großem K im Mittel richtig liegen, einzeln aber weit auffächern, weil jede ihrem eigenen Rauschen folgt.

Satz 13.8.4 (Gemittelte Varianz eines linearen Schätzers)

Seien die ϵ_i unkorreliert mit $\text{Var}[\epsilon_i] = \sigma^2$ (homoskedastisch), und habe $\mathbf{B}$ vollen Spaltenrang K . Dann gilt für jedes x

$$\text{Var}[\hat{f}(x)] = \sigma^2 \phi(x)^\top (\mathbf{B}^\top \mathbf{B})^{-1} \phi(x), \quad (13.8.4)$$

und über die Entwurfsstellen gemittelt sogar exakt

$$\frac{1}{n} \sum_{i=1}^n \text{Var}[\hat{f}(x_i)] = \frac{\sigma^2 K}{n}. \quad (13.8.5)$$

Vertiefung (optional): Beweis der gemittelten Varianzformel

Beweis.

- (1) Für die Kovarianzmatrix des Koeffizientenvektors gilt, wobei $\text{Var}[\cdot]$ für einen Vektor die Matrix der Kovarianzen bezeichnet,

$$\text{Var}[\hat{\mathbf{a}}] = \mathbf{B}^+ \text{Var}[\mathbf{y}] (\mathbf{B}^+)^T = \sigma^2 \mathbf{B}^+ (\mathbf{B}^+)^T = \sigma^2 (\mathbf{B}^\top \mathbf{B})^{-1}.$$

$\text{Var}[\mathbf{M}\mathbf{y}] = \mathbf{M} \text{Var}[\mathbf{y}] \mathbf{M}^\top$ für feste $\mathbf{M}$; $\text{Var}[\mathbf{y}] = \sigma^2 \mathbf{I}_n$ wegen Unkorreliertheit und Homoskedastizität; und mit $\mathbf{B}^+ = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top$ kürzt sich $\mathbf{B}^\top \mathbf{B}$ heraus

- (2) Daraus folgt (13.8.4), denn $\hat{f}(x) = \phi(x)^\top \hat{\mathbf{a}}$ ist eine Linearkombination der Koeffizienten.

$\text{Var}[\mathbf{c}^\top \mathbf{v}] = \mathbf{c}^\top \text{Var}[\mathbf{v}] \mathbf{c}$, hier mit $\mathbf{c} = \boldsymbol{\phi}(\mathbf{x})$

- (3) Nun summieren wir (13.8.4) über die Entwurfsstellen. Der Vektor $\boldsymbol{\phi}(\mathbf{x}_i)^\top$ ist die i -te Zeile von $\mathbf{B}$, also ist

$$\sum_{i=1}^n \boldsymbol{\phi}(\mathbf{x}_i)^\top (\mathbf{B}^\top \mathbf{B})^{-1} \boldsymbol{\phi}(\mathbf{x}_i) = \text{tr} \left((\mathbf{B}^\top \mathbf{B})^{-1} \sum_{i=1}^n \boldsymbol{\phi}(\mathbf{x}_i) \boldsymbol{\phi}(\mathbf{x}_i)^\top \right) = \text{tr}(\mathbf{I}_K) = K.$$

Jeder Summand ist ein Skalar und damit gleich seiner Spur; die Zyklicität der Spur (Abschnitt 3.1) zieht den Vektor nach vorn, und $\sum_{i=1}^n \boldsymbol{\phi}(\mathbf{x}_i) \boldsymbol{\phi}(\mathbf{x}_i)^\top = \mathbf{B}^\top \mathbf{B}$

- (4) Multiplikation mit σ^2/n liefert (13.8.5). □

Bemerkung 13.8.5 (Was die Varianzformel besagt)

Rechts in (13.8.5) steht keine Eigenschaft der Basis, keine Knotenlage und keine Konditionszahl, nur σ^2 , K und n : Im Mittel kostet jede Basisfunktion σ^2/n an Varianz, unabhängig von ihrer Form. Das ist die exakte Fassung der Ordnungsaussage $\text{Var}[\hat{f}(\mathbf{x})] = O(K/n)$.

Die *Hatmatrix* $\mathbf{H} = \mathbf{B}(\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top$ bildet die Beobachtungen auf die angepassten Werte ab, und der Beweis zeigt $\text{tr}(\mathbf{H}) = K$. Diese Spur heißt die *Anzahl effektiver Freiheitsgrade* des Schätzers; bei einer unbestraften Regression mit K Basisfunktionen ist sie K .

Punktweise gilt nur (13.8.4), und an einer Stelle, in deren Nähe kaum Daten liegen, kann $\text{Var}[\hat{f}(\mathbf{x})]$ um Größenordnungen über $\sigma^2 K/n$ liegen. Werten wir (13.8.4) im Beispiel unten auf einem gleichmäßigen Gitter über $[0, 2\pi]$ statt an den 100 Entwurfsstellen aus, so ist die mittlere Varianz bei $K = 40$ nicht 0,036, sondern 5,04.

Der Kompromiss: mittlerer quadratischer Fehler

Satz 13.8.6 (Zerlegung des mittleren quadratischen Fehlers)

Für jedes $\mathbf{x}$ gilt

$$\underbrace{\mathbb{E}[(\hat{f}(\mathbf{x}) - f(\mathbf{x}))^2]}_{\text{MSE}} = \underbrace{(\mathbb{E}[\hat{f}(\mathbf{x})] - f(\mathbf{x}))^2}_{\text{Bias}^2} + \underbrace{\text{Var}[\hat{f}(\mathbf{x})]}_{\text{Varianz}}. \quad (13.8.6)$$

Vertiefung (optional): Beweis der Bias-Varianz-Zerlegung

Beweis.

- (1) Wir schreiben $\mu := \mathbb{E}[\hat{f}(\mathbf{x})]$ und schieben diesen Wert ein:

$$(\hat{f}(\mathbf{x}) - f(\mathbf{x}))^2 = (\hat{f}(\mathbf{x}) - \mu)^2 + 2(\hat{f}(\mathbf{x}) - \mu)(\mu - f(\mathbf{x})) + (\mu - f(\mathbf{x}))^2.$$

- (2) Jetzt nehmen wir den Erwartungswert. Der mittlere Term fällt weg, der erste ist die Varianz, der letzte ist deterministisch.

$\mathbb{E}[\hat{f}(\mathbf{x}) - \mu] = 0$ nach Definition von μ , und $\mu - f(\mathbf{x})$ ist keine Zufallsgröße, darf also aus dem Erwartungswert gezogen werden □

Setzen wir Satz 13.8.2 und Satz 13.8.4 in (13.8.6) ein und mitteln über die Entwurfsstellen, so er-

halten wir unter den Voraussetzungen von Satz 13.8.2 für eine Konstante $C_1 > 0$ die zentrale Obergrenze dieses Abschnitts:

$$\frac{1}{n} \sum_{i=1}^n \mathbb{E} \left[(\hat{f}(x_i) - f(x_i))^2 \right] \leq \underbrace{C_1 K^{-8}}_{\text{obere Schranke für Bias}^2} + \underbrace{\frac{\sigma^2 K}{n}}_{\text{Varianz}}. \quad (13.8.7)$$

Die Schranke für den ersten Term fällt mit wachsendem K schnell, der zweite Term wächst linear, also hat die *rechte Seite* ein Minimum dazwischen. Der tatsächliche MSE muss sein Minimum nicht an derselben Stelle haben, denn der Bias darf unter seiner Schranke liegen oder schwanken.

Bemerkung 13.8.7 (Heuristisches Balance-Modell für die Knotenzahl)

Nehmen wir zusätzlich an, dass der quadrierte Bias in dem interessierenden Bereich tatsächlich wie $c_1 K^{-8}$ mit $c_1 > 0$ verläuft, statt nur nach oben so beschränkt zu sein, erhalten wir das Proxy-Kriterium $g(K) = c_1 K^{-8} + c_2 K/n$. Ableiten und Nullsetzen gibt

$$g'(K) = -8c_1 K^{-9} + \frac{c_2}{n} \stackrel{!}{=} 0 \implies K^* = \left(\frac{8c_1}{c_2} \right)^{1/9} n^{1/9},$$

und dort sind beide Summanden von derselben Ordnung:

$$c_1 (K^*)^{-8} \sim n^{-8/9}, \quad \frac{c_2 K^*}{n} \sim n^{1/9-1} = n^{-8/9}.$$

Unter dieser zusätzlichen Annahme ergeben sich also $K^* \asymp n^{1/9}$ und eine Proxy-Rate $n^{-8/9}$; eine rigorose Optimalitätsaussage wäre das erst mit einer passenden unteren Schranke. Aus derselben Rechnung folgt $c_1 (K^*)^{-8} = \frac{1}{8} c_2 K^*/n$: Im Optimum dieses Modells trägt der quadrierte Bias ein Neuntel der Summe, eine Eigenschaft der Potenzform, nicht des tatsächlichen MSE.

Die Ordnung $K^* \asymp n^{1/9}$ ist *rein asymptotisch*: Mit Konstante 1 liefert die Formel für $n = 100$ den Wert $K^* = 1,67$, und niemand approximiert eine schwingende Funktion mit zwei Basisfunktionen. Es fehlt der Faktor $(8c_1/c_2)^{1/9}$, der an der vierten Ableitung von f und an σ hängt. Merken lässt sich deshalb der Balance-Exponent, keine konkrete Knotenzahl.

Ein numerisches Beispiel

Beispiel 13.8.8 (Bias und Varianz beim Sinusbeispiel)

Wir nehmen $f(x) = \sin(3x)$ auf $[0, 2\pi]$, $n = 100$ feste, einmal gleichverteilt gezogene Stellen und $\sigma = 0,3$. Für 200 simulierte Datensätze passen wir jeweils einen kubischen Regressionspline mit K Basisfunktionen an und schätzen daraus Bias, Varianz und MSE an den Entwurfsstellen. Alle Zahlen der Tabelle sind unsere eigene Rechnung.

K	Bias ²	Varianz	$\sigma^2 K/n$	MSE
5	0,4103	0,0044	0,0045	0,4147
8	0,0344	0,0071	0,0072	0,0415
9	0,1174	0,0080	0,0081	0,1254
15	0,0001	0,0135	0,0135	0,0136
40	0,0001	0,0358	0,0360	0,0360

Die geschätzte Varianz trifft die Vorhersage $\sigma^2 K/n$ aus Satz 13.8.4 in jeder Zeile auf zwei Prozent genau; die Abweichung ist Simulationsfehler. Der MSE fällt zwischen $K = 9$ und $K = 15$ um eine Größenordnung und steigt danach wieder an. Wo genau sein Minimum liegt, rechnet das Widget unten aus.

Bemerkung 13.8.9 (Der Bias fällt nicht monoton)

Zwischen $K = 8$ und $K = 9$ steigt der quadrierte Bias in der Tabelle wieder an. Beide Anpassungen sind schlecht, denn fünf beziehungsweise sechs Teilintervalle sind für drei Sinusperioden zu wenig. Welche weniger schlecht ausfällt, entscheidet die Lage der Knoten relativ zu f . Bei $K = 9$ sitzen die fünf inneren Knoten exakt auf den Nullstellen $k\pi/3$ von $\sin(3x)$, wo auch f'' verschwindet, während die Funktion zwischen den Knoten am stärksten gekrümmt ist.

Ein Widerspruch zu Satz 13.8.2 ist das nicht: $O(K^{-8})$ ist eine obere Schranke für große K , keine Garantie für jeden einzelnen Schritt, wie schon bei den gemessenen Faktoren in Abschnitt 13.6.

Interaktiv: Bias, Varianz und MSE in der Simulation

Wo vermuten wir vor dem Blick auf die MSE-Kurve ihr Minimum? Das Widget rechnet die Tabelle mit festem Startwert nach, jeder Aufruf zeigt dieselbe Simulation.

Schätzfrage. Welche Knotenzahl minimiert in dieser festen Simulation den MSE?

Lösung: 12 K

Das Minimum liegt bei $K = 12$ mit einem MSE von 0,0120: Bei $K = 5$ ist der MSE das 34,5-fache davon, bei $K = 40$ das Dreifache. Bias² 0,0013 und Varianz 0,0107 ergänzen sich dort zu 0,0120, der Bias trägt also nur noch 11 Prozent. Das stimmt hier numerisch mit dem Ein-Neuntel-Verhältnis des Proxy-Modells überein, ist aber keine theoretisch erzwungene Übereinstimmung. Innerhalb von zehn Prozent gleichwertig sind $K = 12$ bis 14.

Die obere Tafel zeigt die Daten einer Ziehung in Blau, die wahre Funktion violett gestrichelt, die inneren Knoten als orange Marken und in Grün die Schätzer der ersten zwölf Wiederholungen samt Mittelwert; bei $K = 40$ liegt nur noch dieser Mittelwert auf f . Die Balkentafel zeigt die Anteile am MSE, die logarithmische Tafel den Verlauf aller drei Größen über K . Dort fällt der rote Bias steil, die grüne Varianz steigt langsam, und die graue Summe hat ihr Minimum dazwischen.

Wie wählt man K in der Praxis?

Wir kennen f nicht, also lassen sich Bias und MSE nicht ausrechnen, nur die Residuen. Diese werden mit wachsendem K im Trend kleiner, bis ein vollrangiger Fall mit $K = n$ jeden Datenpunkt exakt trifft (Bemerkung 13.7.11). Die Anpassung an die Daten belohnt Flexibilität, nicht Vorhersagegüte, und taugt nicht als Auswahlkriterium.

Bemerkung 13.8.10 (Drei Auswege)

1. *Kreuzvalidierung.* Wir halten einen Teil der Daten zurück, passen auf dem Rest an und messen den Fehler auf dem zurückgehaltenen Teil. Punkte, die nicht an der Anpassung beteiligt waren, bestrafen Überanpassung von selbst. Gewählt wird das K mit dem kleinsten Validierungsfehler.

2. *Informationskriterien.* AIC und BIC addieren zur Anpassungsgüte, der negativen doppelten Log-Likelihood, einen Strafterm, der mit der Parameterzahl wächst. Für normalverteilte Fehler sind sie bis auf Konstanten $n \log(\text{RSS}_K/n) + 2K$ beziehungsweise $n \log(\text{RSS}_K/n) + \log(n) K$; BIC bestraft schärfer, sobald $n \geq 8$ ist.
3. *Generalisierte Kreuzvalidierung.* Sie schätzt den Kreuzvalidierungsfehler aus einer einzigen Anpassung.

Definition 13.8.11 (Generalisierte Kreuzvalidierung)

Mit der Residuenquadratsumme $\text{RSS}_K = \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$ heißt

$$\text{GCV}(K) = \frac{\text{RSS}_K/n}{(1 - K/n)^2} \quad (13.8.8)$$

der *GCV-Kriteriumswert*. Gewählt wird das K , das ihn minimiert.

Für unseren unbestraften KQ-Fit mit vollem Spaltenrang ist $\text{tr}(\mathbf{H}) = K$; für einen allgemeinen linearen Glätter steht im Nenner die effektive Freiheitsgradzahl $\text{tr}(\mathbf{H})$ anstelle von K .

Bemerkung 13.8.12 (Warum der Nenner nötig ist)

Der Zähler fällt im Trend mit K und würde allein die flexibelsten Fits bevorzugen. Der Nenner wirkt dem entgegen; er stammt aus der Kreuzvalidierung, die jeden Punkt einmal weglässt. Je näher K an n rückt, desto stärker vergrößert er den beobachteten Fehler, denn ein Schätzer mit vielen Parametern rechnet seine eigenen Residuen künstlich klein.

Vertiefung (optional): Woher der Nenner kommt

Für einen linearen Schätzer $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$ lässt sich das Residuum, das beim Weglassen des i -ten Punktes entstünde, ohne erneute Anpassung ausrechnen: Es ist $(y_i - \hat{f}(x_i))/(1 - H_{ii})$, was man mit der Sherman-Morrison-Formel nachrechnet. Die Kreuzvalidierung wird damit zu einer einzigen Formel. Ersetzt man darin alle H_{ii} durch ihren Mittelwert $\text{tr}(\mathbf{H})/n$, so steht (13.8.8) da, denn nach Bemerkung 13.8.5 ist $\text{tr}(\mathbf{H}) = K$.

Die Leave-one-out-Identität hält dabei die Designmatrix und damit die Basis fest. Würden wir nach dem Weglassen jedes Punkts auch quantilbasierte Knoten neu bestimmen, entstünde ein anderes Verfahren, für das die Formel nicht exakt dieselbe Kreuzvalidierung berechnet.

Beispiel 13.8.13 (Was die Kriterien in unserem Datensatz wählen)

Für die erste der 200 Ziehungen aus Beispiel 13.8.8 werten wir (13.8.8) für $K = 4, \dots, 40$ aus: Das Minimum liegt bei $K = 10$ mit $\text{GCV} = 0,0895$, und AIC und BIC in den Formen aus Bemerkung 13.8.10 wählen dasselbe K . Der wahre MSE ist bei $K = 12$ am kleinsten; $K = 10$ liefert 0,0157 statt 0,0120, rund 30 Prozent mehr. Für ein Kriterium, das f nicht kennt und mit einer einzigen Ziehung auskommt, ist das gut. Die Kriterien schätzen den Fehler aber nur, und auf einer anderen Ziehung fällt die Wahl anders aus.

Bemerkung 13.8.14 (Der praktische Ausweg: groß wählen und bestrafen)

In der Anwendung wird K meist nicht feinjustiert: Wir wählen es groß, sodass der Bias sicher klein ist, und steuern die Glattheit über einen Strafterm. Das führt auf *P-Splines* und *additive Modelle*, in R etwa mit `mgcv : : gam()`. Der Strafparameter ist stufenlos und lässt sich mit denselben Kriterien feiner einstellen als die ganzzahlige Knotenzahl; die effektiven

Freiheitsgrade $\text{tr}(\mathbf{H})$ aus Bemerkung 13.8.5 sind dann keine ganze Zahl mehr und fallen mit wachsendem Strafparameter stetig. Die gestraften Normalengleichungen stehen in Bemerkung 13.7.14, die Glättungssplines aus Abschnitt 13.7 sind der Grenzfall $K = n$ mit Strafterm.

Selbsttest

1. Je größer K , desto kleiner der Bias: Die Verzerrung fällt monoton.

Antwort: Falsch

Satz 13.8.2 gibt eine obere Schranke der Ordnung $O(K^{-8})$, keine monotone Folge. In unserer Simulation steigt der quadrierte Bias von 0,0344 bei $K = 8$ auf 0,1174 bei $K = 9$, weil bei $K = 9$ die inneren Knoten auf die Nullstellen von $\sin(3x)$ fallen (Bemerkung 13.8.9). Erst über größere Schritte in K setzt sich der Trend durch.

2. Der Bias hängt nicht von der Rauschstärke σ ab.

Antwort: Wahr

Nach (13.8.2) ist $\mathbb{E}[\hat{f}(x)] = \phi(x)^\top \mathbf{B}^+ \mathbf{f}$, und darin kommt σ nicht vor. Stärkeres Rauschen vergrößert die Varianz, nicht die Verzerrung.

3. Die über die Entwurfsstellen gemittelte Varianz ist exakt $\sigma^2 K/n$, unabhängig davon, wo die Knoten liegen.

Antwort: Wahr

Das ist (13.8.5): Der Beweis braucht nur einen KQ-Fit mit vollem Spaltenrang K und unkorrelierte homoskedastische Fehler, am Ende steht $\text{tr}(\mathbf{I}_K) = K$, und Basis wie Knotenlage gehen nicht ein. Unsere Simulation bestätigt es in jeder Zeile der Tabelle aus Beispiel 13.8.8.

4. Dann ist auch die Varianz an jeder einzelnen Stelle x gleich $\sigma^2 K/n$.

Antwort: Falsch

Gemittelt wird über die n Entwurfsstellen, und dort ist die Aussage exakt. Zwischen den Datenpunkten und an den Rändern kann die Varianz weit darüber liegen: Bei $K = 40$ misst unsere Simulation über ein feines Gitter auf $[0, 2\pi]$ eine mittlere Varianz von 5,04 statt 0,036. Punktweise gilt nur (13.8.4), und dort steht $\phi(x)$ im Ausdruck.

5. Im Minimum des MSE sind quadrierter Bias und Varianz allgemein gleich groß.

Antwort: Falsch

Schon im glatten Proxy-Modell sind am Optimum die *Änderungsraten*, nicht die Beiträge gleich: $g'(K^*) = 0$ heißt, dass eine infinitesimale Verfeinerung genauso viel Varianz kostet, wie sie an Bias spart. Für die spezielle Form $c_1 K^{-8} + c_2 K/n$ trägt der Bias dort ein Neuntel der Summe, eine Eigenschaft dieses Modells und keine allgemeine MSE-Identität; im simulierten Beispiel liegt der Anteil bei $K = 12$ zufällig nahe daran (Beispiel 13.8.8).

6. GCV lässt sich ausrechnen, ohne f zu kennen.

Antwort: Wahr

In (13.8.8) stehen nur die Residuenquadratsumme, n und K , alles beobachtbare Größen. Modellwahlkriterien schätzen den Vorhersagefehler, statt ihn zu messen, und treffen das MSE-Optimum deshalb nur ungefähr: In Beispiel 13.8.13 wählt GCV $K = 10$, während $K = 12$ am besten wäre.

Vertiefung: Die Bias-Varianz-Zerlegung und die Modellwahlkriterien behandeln T. Hastie, R. Tibshira-

ni und J. Friedman, *The Elements of Statistical Learning*, Kapitel 7; die generalisierte Kreuzvalidierung geht auf P. Craven und G. Wahba, *Smoothing noisy data with spline functions*, *Numerische Mathematik* 31 (1979), 377–403, zurück, *P-Splines und additive Modelle* entwickelt S. N. Wood, *Generalized Additive Models: An Introduction with R*, 2. Auflage 2017.

13.9 Multivariat und Zusammenfassung

Bisher spielte alles auf einem Intervall: eine Variable, Knoten darauf, eine Kurve. Reale Datensätze bringen mehrere Kovariablen mit, und die Übertragung des Basisansatzes auf $f : \mathbb{R}^p \rightarrow \mathbb{R}$ ist eine Anwendung des Tensorprodukts aus Abschnitt 9.4, deren Aufwand allerdings exponentiell in p wächst. Danach fassen wir das Kapitel und das Skript zusammen.

Tensor-Produkt-Basen

Eine Basis für Funktionen mehrerer Variablen bauen wir aus den univariaten Bausteinen: Aus K Basisfunktionen pro Variable bilden wir alle möglichen Produkte.

Definition 13.9.1 (Tensor-Produkt-Basis)

Für jede Variable x_r sei ein K -dimensionaler Funktionenraum auf einem Intervall I_r mit Basis $\phi_{r1}, \dots, \phi_{rK}$ gegeben, etwa ein B-Spline-Raum aus Abschnitt 13.4. Die zugehörige *Tensor-Produkt-Basis* auf $I_1 \times \dots \times I_p$ besteht aus den K^p Produkten

$$\phi_{1j_1}(x_1) \times \dots \times \phi_{pj_p}(x_p), \quad j_1, \dots, j_p \in \{1, \dots, K\},$$

und der Ansatz für $f : I_1 \times \dots \times I_p \rightarrow \mathbb{R}$ lautet

$$\hat{f}(\mathbf{x}) = \sum_{j_1=1}^K \dots \sum_{j_p=1}^K a_{j_1, \dots, j_p} (\phi_{1j_1}(x_1) \times \dots \times \phi_{pj_p}(x_p)) \quad (13.9.1)$$

mit dem Koeffizienten-Tensor

$$\mathbf{A} = (a_{j_1, \dots, j_p})_{j_i=1, \dots, K, i=1, \dots, p} \in \mathbb{R}^{K \times \dots \times K}.$$

Bemerkung 13.9.2 (Was das Tensorkapitel dazu schon gesagt hat)

Die Konstruktion ist das Tensorprodukt von Funktionenräumen aus Abschnitt 9.4: Produkte von Basiselementen bilden wieder eine Basis, und die Dimensionen multiplizieren sich, für p Faktoren also zu K^p . Dort fiel auch schon der Name für die Folgen, *Fluch der Dimensionalität* (curse of dimensionality). Anschaulich legen wir ein Gitter über den p -dimensionalen Raum, das mit jeder Variablen um den Faktor K wächst.

Bemerkung 13.9.3 (Es bleibt ein lineares Kleinste-Quadrate-Problem)

Der Ansatz (13.9.1) ist linear in den Koeffizienten. Nummerieren wir die K^p Indexkombinationen $(j_1, \dots, j_p)$ durch, so wird aus $\mathbf{A}$ ein Vektor $\mathbf{a} \in \mathbb{R}^{K^p}$, und mit der Designmatrix $\mathbf{B} \in \mathbb{R}^{n \times K^p}$, deren Zeilen die K^p Produkte an der Beobachtungsstelle $\mathbf{x}_i$ enthalten, steht wieder

$$\min_{\mathbf{a}} \|\mathbf{y} - \mathbf{B} \mathbf{a}\|_2^2$$

da, das Problem aus Satz 13.7.5 mit mehr Spalten, lösbar über die Normalengleichungen oder besser über eine QR-Zerlegung (Abschnitt 7.4). Vollen Spaltenrang kann $\mathbf{B}$ aber nur haben, wenn $n \geq K^p$ ist: Mit $K = 10$ Basisfunktionen je Variable und $p = 5$ Kovariablen brauchen wir mindestens 100 000 Beobachtungen, bevor die Anpassung überhaupt eindeutig ist.

Der Fluch der Dimensionalität

Drei Größen wachsen exponentiell in p : der Speicher für $\mathbf{A}$, der Aufwand einer Auswertung und die Datenmenge für eine feste Genauigkeit. Jede für sich macht den vollen Tensoransatz jenseits weniger Variablen unbrauchbar.

Beispiel 13.9.4 (Zehn Basisfunktionen je Variable)

Wir rechnen mit $K = 10$ und speichern jeden Koeffizienten als Gleitkommazahl doppelter Genauigkeit, also mit 8 Byte.

Dimension p	Koeffizienten K^p	Speicher
1	10	80 Bytes
2	100	800 Bytes
3	1000	8 kB
5	100 000	800 kB
10	10^{10}	80 GB

Bis $p = 5$ ist der Koeffizienten-Tensor handlich, bei $p = 10$ passt er in keinen üblichen Arbeitsspeicher (dezimale Präfixe, 1 kB = 1000 Bytes). Der Sprung von $p = 5$ auf $p = 10$ ist ein Faktor 10^5 , allein durch fünf weitere Variablen.

Der Datenbedarf wächst genauso; mit der Rechnung aus Abschnitt 13.8 lässt er sich direkt hinschreiben.

Satz 13.9.5 (Eine MSE-Obergrenze im Multivariaten)

Wir beobachten $y_i = f(\mathbf{x}_i) + \epsilon_i$ an n festen Stellen mit unkorrelierten, homoskedastischen Fehlern vom Mittelwert null und passen (13.9.1) mit kubischen Spline-Bausteinen auf einem gleichmäßigen Gitter an. Hat $\mathbf{B}$ vollen Spaltenrang K^p und besitzt die verwendete Tensorprodukt-Splinefolge für f eine gleichmäßige Approximationsschranke $\inf_{s \in \mathcal{F}_K} \|f - s\|_\infty \leq CK^{-4}$ (etwa unter den üblichen Glattheitsannahmen an die partiellen Ableitungen vierter Ordnung), so gilt für den an den Entwurfstellen gemittelten Fehler

$$\text{MSE}(\hat{f}) \leq \underbrace{C_1 K^{-8}}_{\text{Bias}^2\text{-Schranke}} + \underbrace{\frac{\sigma^2 K^p}{n}}_{\text{Varianz}} \quad (13.9.2)$$

mit einer Konstante $C_1 > 0$. Die Wahl $K \asymp n^{1/(8+p)}$ balanciert die rechte Seite und liefert die Garantie

$$\text{MSE}(\hat{f}) = O(n^{-8/(8+p)}). \quad (13.9.3)$$

Vertiefung (optional): Wie sich die Rate im Multivariaten ausbalanciert

Der Beweis ist die Rechnung aus Abschnitt 13.8 mit K^p statt K Spalten: Varianzsatz übernehmen, Bias-Schranke voraussetzen, Summe minimieren, einsetzen.

Beweis.

- (1) Der Varianzterm ist Satz 13.8.4. Dessen Beweis benutzt vom Schätzer nur, dass er die Kleinste-Quadrate-Anpassung an eine Designmatrix mit vollem Spaltenrang ist; wie viele Spalten sie hat und wie ihre Einträge zustande kommen, geht nicht ein. Hier sind es K^p Spalten, also ist die gemittelte Varianz $\sigma^2 K^p/n$.

am Ende des Beweises steht $\text{tr}(\mathbf{I}_{K^p}) = K^p$ statt $\text{tr}(\mathbf{I}_K) = K$

- (2) Für den Bias verwenden wir die im Satz ausdrücklich vorausgesetzte Tensorprodukt-Approximation. Der rauschfreie KQ-Fit ist an den Entwurfsstellen mindestens so gut wie dieser Vergleichsspline, also ist der gemittelte quadrierte Bias höchstens $C_1 K^{-8}$.

dieselbe Vergleichsrechnung wie in Satz 13.8.2; die genaue Herleitung der Tensorprodukt-Schranke gehört zur mehrdimensionalen Approximationstheorie und wird hier als Voraussetzung sichtbar gemacht

- (3) Wir minimieren nun die bewiesene Obergrenze $g(K) = c_1 K^{-8} + c_2 K^p/n$ mit Konstanten $c_1, c_2 > 0$. Ableiten und Nullsetzen gibt

$$g'(K) = -8c_1 K^{-9} + \frac{c_2 p K^{p-1}}{n} \stackrel{!}{=} 0 \implies K^{8+p} = \frac{8c_1 n}{c_2 p},$$

also $K^* \sim n^{1/(8+p)}$.

Multiplikation mit $K^9 n/(c_2 p)$ sammelt alle K -Potenzen auf einer Seite; g fällt für kleine und wächst für große K , die einzige positive Nullstelle ist also das Minimum

- (4) Einsetzen von K^* in beide Summanden liefert

$$c_1 (K^*)^{-8} \sim n^{-8/(8+p)}, \quad \frac{c_2 (K^*)^p}{n} \sim n^{p/(8+p)-1} = n^{-8/(8+p)},$$

und damit (13.9.3).

$$p/(8+p) - 1 = (p-8-p)/(8+p) = -8/(8+p)$$

□

Bemerkung 13.9.6 (Was die Rate über Datenmengen sagt)

(13.9.3) ist eine Obergrenze bei der Wahl $K \asymp n^{1/(8+p)}$, nicht der Fehler für jedes K . Als grobe Planungsheuristik setzen wir die in der $\mathcal{O}$ -Notation verborgene Konstante gleich eins. Aus $n^{-8/(8+p)} \leq \varepsilon$ folgt dann $n \geq \varepsilon^{-(8+p)/8}$, für $\varepsilon = 0,01$ also $n \geq 10^{(8+p)/4}$.

Dimension p	Rate	Proxy- n bei Konstante 1
1	$n^{-8/9}$	$10^{2,25} \approx 178$
2	$n^{-8/10} = n^{-0,8}$	$10^{2,5} \approx 316$
5	$n^{-8/13}$	$10^{3,25} \approx 1778$
10	$n^{-8/18}$	$10^{4,5} \approx 31\,623$

Die dritte Spalte ist eine Orientierung, keine Stichprobenplanung, denn die entscheidenden Konstanten hängen am Problem. Ihre Botschaft steckt im Exponenten $(8+p)/4$: Jede weitere Variable multipliziert die nötige Datenmenge mit $10^{1/4} \approx 1,78$, bei $\varepsilon = 10^{-4}$ sogar mit $\varepsilon^{-1/8} \approx 3,16$. Der Datenbedarf wächst also exponentiell in p , wie der Speicherbedarf.

Bemerkung 13.9.7 (Auch die Auswertung kostet)

Eine Auswertung von $\hat{f}$ kostet für eine Basis ohne besondere Struktur $O(K^p)$, denn die Summe in (13.9.1) hat K^p Summanden. Bei B-Splines sind an einer festen Stelle je Variable höchstens $q + 1$ Basisfunktionen von null verschieden (Abschnitt 13.4), im Produkt also höchstens $(q + 1)^p$ Summanden, für $p = 10$ und $q = 3$ noch $4^{10} = 1\,048\,576$ statt 10^{10} . Das spart fünf Größenordnungen, aber 4^p wächst ebenfalls exponentiell, und gespeichert werden müssen die K^p Koeffizienten ohnehin.

Additive Modelle statt voller Produkte

Der Ausweg ist keine bessere Numerik, sondern eine Annahme über f . Wenn wir darauf verzichten, beliebige Wechselwirkungen zwischen den Variablen darzustellen, schrumpft der Ansatzraum stark.

Definition 13.9.8 (Additives Modell)

Ein *additives Regressionsmodell* setzt statt des vollen Tensorprodukts eine Summe univariater Funktionen an:

$$\hat{f}(\mathbf{x}) = \beta_0 + \sum_{i=1}^p f_i(x_i), \quad (13.9.4)$$

wobei jede Komponente f_i in einem eigenen K -dimensionalen Ansatzraum liegt, etwa dem der kubischen Splines aus Abschnitt 13.7.

Ein *generalisiertes additives Modell* (GAM) erweitert diese Form wie ein generalisiertes lineares Modell um eine Verteilung für $Y \mid X$ und eine Linkfunktion g :

$$g(\mathbb{E}[Y \mid X = \mathbf{x}]) = \beta_0 + \sum_{i=1}^p f_i(x_i).$$

Für Gaußfehler und den Identitätslink ergibt sich das additive Modell oben.

Bemerkung 13.9.9 (Vorteile und Grenzen additiver Modelle)

Skalierbar. Zu den pK Komponenten-Koeffizienten kommt der Achsenabschnitt β_0 , zusammen $pK + 1$ statt K^p . Jede Komponente ist aber nur bis auf eine additive Konstante bestimmt, denn eine Konstante ließe sich von f_1 nach f_2 verschieben, ohne (13.9.4) zu ändern; mit einer Zentrierungsbedingung je Komponente (etwa: ihre Werte an den Beobachtungsstellen summieren sich zu null) bleiben $p(K - 1) + 1 = O(pK)$ frei wählbare Koeffizienten. Für $p = K = 10$ sind das 91 statt 10^{10} , ein Faktor von gut 10^8 : Aus dem exponentiellen Wachstum in p wird ein lineares.

Interpretierbar. Jede Komponente ist eine Funktion einer einzigen Variablen und lässt sich als Kurve zeichnen; beim vollen Tensorprodukt ist der Effekt einer Kovariablen nur gemeinsam mit allen anderen definiert.

Die Einschränkung. Wechselwirkungen fallen weg: Ein GAM kann nicht darstellen, dass die Wirkung von x_1 vom Wert von x_2 abhängt. Wo einzelne Wechselwirkungen gebraucht werden, nehmen wir sie gezielt als Tensorprodukt-Term für zwei oder drei Variablen dazu.

In R ist `mgcv : : gam()` die Standardimplementierung, mit automatischer Wahl der Glättungsparameter über die Kriterien aus Abschnitt 13.8.

Interaktiv: Koeffizientenzahl von Tensorprodukt und additivem Modell

Die Tabelle oben rechnet mit $K = 10$. Wie groß wird der Koeffizienten-Tensor, wenn wir zwei Variablen weglassen, dafür aber doppelt so fein auflösen?

Schätzfrage. Schätzen wir den Speicherbedarf in GB für $K = 20$ und $p = 8$.

Lösung: 205 GB

$20^8 = 2,56 \cdot 10^{10}$ Koeffizienten zu je 8 Byte sind rund 205 GB – mehr als die 80 GB der Tabellenzeile für $K = 10$ und $p = 10$. Zwei Variablen weniger sparen hier weniger, als die feinere Auflösung kostet: Die Verdopplung von K verdoppelt alle acht Faktoren von K^8 , das Weglassen spart nur zwei Faktoren 10.

Über der Dimension p mit logarithmischer senkrechter Achse sind die K^p Koeffizienten des vollen Tensorprodukts (orange) eine Gerade, die $p(K-1)+1$ freien Parameter des zentrierten additiven Modells (grün) eine flach liegende Kurve. Der K -Regler kippt die orange Gerade, weil K in ihrer Steigung sitzt, und verschiebt die grüne Kurve kaum. Die Werttafel rechnet Speicherbedarf, Mindestzahl an Beobachtungen und Konvergenzrate zum eingestellten Zustand mit.

Vertiefung (optional): Additivität ist mehr als ein Verzicht**Bemerkung 13.9.10 (Warum das mehr ist als eine Notlösung)**

Die Additivität sieht nach einem Verzicht aus. Ist f tatsächlich additiv und bleibt p fest, so ist sie mehr als das: Unter den üblichen Regularitäts- und Designannahmen lassen sich die einzelnen Komponenten mit derselben eindimensionalen Rate schätzen wie eine univariate Funktion; p geht dann in die Konstante ein. Für vierfach glatte Komponenten wird aus der vollen Rate $n^{-8/(8+p)}$ wieder die univariate Rate $n^{-8/9}$. Der Fluch der Dimensionalität ist damit nicht bekämpft, sondern durch eine Strukturannahme umgangen. Entsprechende Optimalitätsresultate gehen auf C. J. Stone (1985) zurück und sind ein Grund, warum additive Modelle in der Statistik so verbreitet sind.

Vertiefung (optional): Radiale Basisfunktionen und Splines im maschinellen Lernen

Tensor-Produkt-Basis und additives Modell behandeln die Variablen getrennt und setzen die Bausteine anschließend zusammen. Für Stellen, die als verstreute Punkte im $\mathbb{R}^p$ anfallen, passt das schlecht: Messstationen auf einer Landkarte liegen nicht auf einem Gitter, und ein Gitter, das sie alle abdeckt, wäre in weiten Teilen leer. Die übliche Antwort sind *radiale Basisfunktionen* (radial basis functions), die statt eines Gitters nur Zentren brauchen und den Ansatz linear in den Koeffizienten lassen.

Bemerkung 13.9.11 (Radiale Basisfunktionen)

Eine radiale Basisfunktion hängt nur vom Abstand zu einem Zentrum $\mathbf{c}_k$ ab,

$$\phi_k(\mathbf{x}) = \rho(\|\mathbf{x} - \mathbf{c}_k\|), \quad \text{etwa mit } \rho(r) = \exp(-r^2/(2h^2)),$$

oft dienen die Datenpunkte selbst als Zentren. Es ist wieder das Kleinste-Quadrate-Problem aus Bemerkung 13.9.3, nur mit anderen Spalten.

Diese Freiheit hat eine Kehrseite: Die Basismatrix ist im Allgemeinen voll besetzt, denn eine Gaußglocke wird nirgends exakt null, und die Lokalität der B-Splines aus Abschnitt 13.4 geht verloren, solange wir nicht eigens Kerne mit beschränktem Träger wählen. Der Bandbreitenparameter h spielt dabei die Rolle des Knotenabstands: klein heißt flexibel und unruhig, groß heißt glatt und träge.

Zwei aktuelle Verwendungen benutzen Splines als Modellbaustein, nicht als Interpolationsverfahren. *Kolmogorow-Arnold-Netze* ersetzen die feste Aktivierungsfunktion eines neuronalen Netzes durch

lernbare B-Splines (Bemerkung 13.1.6).

Normalizing Flows bauen eine komplizierte Wahrscheinlichkeitsverteilung aus einer einfachen auf, indem sie eine invertierbare Abbildung dazwischenschalten. Die Dichte der transformierten Größe enthält den Betrag der Determinante ihrer Jacobimatrix (Abschnitt 10.3), und deshalb muss die Abbildung zweierlei können: sich invertieren und ihre Determinante effizient ausrechnen lassen. Geeignet parametrisierte *streng monotone* Splines leisten beides: Strikte Monotonie macht die eindimensionale Abbildung bijektiv, und ihre Ableitung steht stückweise sofort da. Häufig verwendet werden dafür monotone rationale quadratische Splines.

Was vom Kapitel bleibt

Am Anfang stand die Aufgabe, eine Funktion zu finden, die zu gegebenen Daten passt; am Ende steht ein lineares Gleichungssystem, dessen Matrix wir selbst wählen. Das Kapitel war eine Reihe von Entscheidungen über diese Matrix und ihre Folgen.

Bemerkung 13.9.12 (Kernkonzepte des Kapitels)

1. **Drei Aufgaben, ein Rechenweg.** Approximation misst global in einer Norm, Interpolation verlangt exakte Treffer an den Daten, Glättung lässt Residuen zu, weil die Daten Rauschen tragen (Abschnitt 13.1). Die Interpolationsbedingung allein legt nichts fest: Mit p ist auch $p + g$ ein Interpolant, sobald $g(x_i) = 0$ gilt (Satz 13.1.8).
2. **Die Basisdarstellung macht daraus ein Gleichungssystem.** Mit $\hat{f} = \sum_k a_k \phi_k$ wird die Interpolation zu $\mathbf{B}\mathbf{a} = \mathbf{y}$ mit $B_{ik} = \phi_k(x_i)$ (Abschnitt 13.2). Der Ansatzraum bestimmt die Kurve, das Basissystem nur Koeffizienten, Kondition und Rechenweg, die Knotenlage die Güte zwischen den Daten (Beispiel 13.2.12, Bemerkung 13.3.11, Bemerkung 13.3.16).
3. **Polynome sind theoretisch einfach und numerisch problematisch.** Durch n Punkte läuft genau ein Polynom vom Grad höchstens $n - 1$ (Abschnitt 13.3). Die Monombasis hat eine exponentiell wachsende Kondition, und selbst für beliebig oft differenzierbares f muss die Folge der Interpolanten an gleichmäßig verteilten Knoten nicht konvergieren (Runge-Phänomen).
4. **Splines halten den Grad klein und die Wirkung lokal.** Polynome vom festen Grad q , $\mathcal{C}^{q-1}$ -glatt zusammengesetzt, bilden den Raum $\mathcal{S}_q$ der Dimension $m+q$ (Abschnitt 13.4). Die B-Spline-Basis hat lokale Träger und macht $\mathbf{B}$ zu einer dünn besetzten Bandmatrix, lösbar in $O(Nq^2)$ statt $O(N^3)$.
5. **Minimale Krümmung.** Unter allen $\mathcal{C}^2$ -Interpolanten minimiert der *natürliche* kubische Spline $J(f) = \int (f'')^2 dx$; der Beweis stützt sich auf die Randbedingungen $s''(a) = s''(b) = 0$ (Abschnitt 13.5).
6. **Approximationsordnung.** Für $f \in \mathcal{C}^4$ ist der Fehler des interpolierenden kubischen Splines durch $Ch^4 \max_x |f^{(4)}(x)|$ beschränkt, mit passenden Randbedingungen mit $C = 5/384$; stückweise linear liefert nur h^2 (Abschnitt 13.6).
7. **Glättung statt Interpolation.** Mit einem vollrangigen kleinen Ansatzraum ($K < n$) wird die Anpassung zum Kleinste-Quadrate-Problem $\min_{\mathbf{a}} \|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2^2$; der zweite Weg bestraft in einem großen Raum die Krümmung mit $\lambda \int (g'')^2 dx$ (Abschnitt 13.7).
8. **Bias-Varianz.** Der gemittelte quadrierte Bias ist durch $C_1 K^{-8}$ beschränkt, die gemittelte Varianz ist exakt $\sigma^2 K/n$, und unter der Proxy-Annahme $\text{Bias}^2 \asymp c_1 K^{-8}$ balanciert $K \asymp n^{1/9}$ beide Terme. In der Praxis wird K über Kreuzvalidierung, AIC, BIC oder GCV

gewählt (Abschnitt 13.8).

9. **Fluch der Dimensionalität.** Die Tensor-Produkt-Basis braucht K^p Koeffizienten und garantiert nur die Rate $O(n^{-8/(8+p)})$. Additive Modelle kommen mit $O(pK)$ Koeffizienten aus und sind interpretierbar, verzichten aber auf Wechselwirkungen.

Selbsttest zum Kapitel

1. Damit der Interpolant zu n Datenpunkten eindeutig ist, genügt es, genau $K = n$ Basisfunktionen zu wählen.

Antwort: Falsch

Die Zahl allein reicht nicht, $\mathbf{B}$ muss auch invertierbar sein. Mit $\phi_1(x) = 1$, $\phi_2(x) = x$ und $\phi_3(x) = 1 + x$ und den Stellen 0, 1, 2 ist die dritte Spalte die Summe der ersten beiden, also $\det \mathbf{B} = 0$ (Satz 13.2.4, Bemerkung 13.2.5). Mit der Monombasis dagegen, also mit Polynomen vom Grad höchstens $n - 1$, steht dort die Vandermonde-Matrix mit $\det \mathbf{B} = 2$, und Satz 13.3.5 sichert die Eindeutigkeit.

2. Es gibt beliebig oft differenzierbare Funktionen, für die der größte Fehler der Interpolation an gleichmäßig verteilten Knoten über alle Grenzen wächst, obwohl der Fehler an den Knoten selbst stets null ist.

Antwort: Wahr

Das ist Runge's Funktion $f(x) = 1/(1 + 25x^2)$ auf $[-1, 1]$ (Beispiel 13.3.14). Nachgerechnet steigt der größte Fehler von 0,44 bei $n = 5$ über 7,2 bei $n = 15$ auf 257 bei $n = 25$, während die Interpolationsbedingung an jedem einzelnen Knoten exakt erfüllt bleibt. Interpolation sagt nur etwas über die Stützstellen aus.

3. In der Basismatrix zu kubischen B-Splines stehen in jeder Zeile höchstens vier Einträge ungleich null.

Antwort: Wahr

An jeder Stelle sind höchstens $q + 1 = 4$ der Basisfunktionen von null verschieden, denn $B_k^{(q)}$ verschwindet außerhalb von $[\tau_k, \tau_{k+q+1}]$ (Satz 13.4.9). Für 20 Stützstellen und 20 kubische B-Splines haben wir das nachgezählt: nirgends mehr als vier, an den Rändern weniger. Daraus wird die Bandstruktur und mit ihr der Aufwand $O(Nq^2)$ statt $O(N^3)$, bei $N = 1000$ und $q = 3$ ein Verhältnis von $N^2/q^2 \approx 111\,000$ (Bemerkung 13.4.14).

4. Zwei verschiedene Basen desselben Ansatzraums liefern denselben Interpolanten, können aber Basismatrizen sehr unterschiedlicher Kondition haben.

Antwort: Wahr

Der Ansatzraum bestimmt die Kurve, die Basis nur die Koeffizienten: Monom- und Newton-Basis geben beide $\hat{f}(x) = 1 + x^2$, einmal mit $\mathbf{a} = (1, 0, 1)^\top$ und einmal mit $\mathbf{a} = (1, 1, 1)^\top$ (Beispiel 13.2.12). An der Kondition ändert ein solcher Wechsel dagegen sehr viel, bei $n = 20$ gleichmäßig verteilten Stellen um zwölf Zehnerpotenzen (Bemerkung 13.3.11).

5. Der Übergang von der Monombasis zu den kubischen B-Splines ist ein Basiswechsel im Sinn der vorigen Aussage, der Interpolant bleibt also derselbe.

Antwort: Falsch

Hier wechselt nicht die Basis, sondern der Ansatzraum: Die n Monome spannen die Polynome vom Grad höchstens $n - 1$ auf, die $m + q$ kubischen B-Splines den Spline-Raum $\mathcal{S}_3$, für $n > 4$ eine ganz andere Menge von Funktionen. Im Störungs-Widget von Abschnitt 13.4 liegen deshalb

links ein Polynom vom Grad 8 und rechts ein stückweise kubischer Spline durch dieselben neun Punkte.

6. Zu jeder stetigen Funktion f auf $[a, b]$ und jeder Genauigkeit $\varepsilon > 0$ gibt es ein Gitter, auf dem bereits ein stückweise linearer Spline s mit $\|f - s\|_\infty < \varepsilon$ existiert.

Antwort: Wahr

Das ist Satz 13.4.15, Punkt 1, im Fall $q = 1$; dort folgt er direkt aus der gleichmäßigen Stetigkeit von f auf einem abgeschlossenen Intervall. Der Weg über wachsenden Polynomgrad kann scheitern (Runge-Phänomen), der Weg über feinere Gitter bei festem Grad nicht.

7. Bei der Spline-Interpolation wächst mit jedem zusätzlichen Datenpunkt der Grad des Interpolanten.

Antwort: Falsch

Der Grad q ist fest gewählt, meist $q = 3$; mit den Daten wächst die Zahl der Teilintervalle und damit die Dimension $m + q$ des Ansatzraums (Satz 13.4.4). Bei der Polynominterpolation lässt der Ansatzraum für n Punkte dagegen Polynome bis zum Grad $n - 1$ zu (Satz 13.3.5), auch wenn das tatsächliche Interpolationspolynom kleineren Grad haben darf. Weil der Grad bei Splines nicht mitwächst, treten die Oszillationen aus Abschnitt 13.3 nicht auf.

8. Unter allen Funktionen, die die Punkte (x_i, y_i) interpolieren, minimiert der natürliche kubische Spline $J(f) = \int_a^b (f'')^2 dx$.

Antwort: Falsch

Ohne Glattheitsforderung ist die Aussage falsch: Der Polygonzug durch die Punkte ist zwischen den Knoten linear und käme auf $J = 0$, in Beispiel 13.5.8 gegen $J(s) = 6$. An den Knoten selbst existiert seine zweite Ableitung allerdings nicht, J ist für ihn streng genommen undefiniert. Satz 13.5.4 vergleicht deshalb nur $\mathcal{C}^2$ -Interpolanten, und unter denen gewinnt der natürliche Spline.

9. Verdoppeln wir die Zahl der Teilintervalle eines gleichmäßigen Gitters, so fällt die Fehlerschranke für kubische Spline-Interpolation auf ein Sechzehntel, die für stückweise lineare Interpolation dagegen nur auf ein Viertel.

Antwort: Wahr

In (13.6.1) steht h^4 , in Satz 13.6.5 h^2 , und die verdoppelte Teilintervallzahl (von N auf $2N - 1$ Knoten, wie in der Folge 5, 9, 17, 33) halbiert h ; das gibt die Faktoren $2^4 = 16$ beziehungsweise $2^2 = 4$. Auf hinreichend feinen Gittern laufen auch die gemessenen Faktoren im kubischen Fall gegen 16 (Beispiel 13.6.7), im linearen gegen 4.

10. Interpolation und Glättung sind zwei verschiedene Verfahren; die Interpolation fällt nicht unter den Kleinste-Quadrate-Ansatz dieses Kapitels.

Antwort: Falsch

Interpolation ist der Spezialfall des KQ-Ansatzes mit verschwindenden Residuen: Mit $K = n$ Basisfunktionen und invertierbarer Designmatrix ist die Kleinste-Quadrate-Lösung $\hat{\mathbf{a}} = \mathbf{B}^{-1}\mathbf{y}$, die Residuenquadratsumme null und jeder Punkt exakt getroffen. Ein kleiner vollrangiger Raum mit $K < n$ lässt für generische Daten Residuen stehen, ein großer Raum kann durch einen Strafterm ebenfalls glätten (Definition 13.7.8). Ein interpolierender Schätzer übernimmt dafür die Fehler ϵ_i an den Datenstellen punktweise.

11. Allein aus der Bias-Obergrenze folgt, dass die tatsächlich MSE-optimale Knotenzahl von der Ordnung $n^{1/9}$ ist.

Antwort: Falsch

Bewiesen ist nur $\text{Bias}^2 \leq C_1 K^{-8}$. Minimieren wir die daraus entstehende Obergrenze oder nehmen zusätzlich $\text{Bias}^2 \asymp c_1 K^{-8}$ an, erhalten wir $K \asymp n^{1/9}$ und die Garantie beziehungsweise Proxy-Rate $n^{-8/9}$ (Bemerkung 13.8.7). Für eine Aussage über das tatsächliche oder minimax-optimale K braucht es zusätzlich eine passende untere Schranke und genaue Annahmen an Funktionsklasse und Design.

12. Bei $p = 10$ Kovariablen und $K = 10$ Basisfunktionen je Variable ist der Koeffizienten-Tensor mit rund 80 MB noch gut zu handhaben.

Antwort: Falsch

Es sind 10^{10} Koeffizienten, und mit 8 Byte je Zahl macht das $8 \cdot 10^{10}$ Bytes, also 80 GB und nicht 80 MB (Beispiel 13.9.4). Dazu kämen mindestens ebenso viele Beobachtungen, damit die Designmatrix vollen Spaltenrang haben kann. Daran scheitert der volle Tensoransatz in hohen Dimensionen.

13. Ein additives Modell mit p Variablen und K Basisfunktionen je Komponente hat eine Koeffizientenzahl der Ordnung pK , wächst also nur linear in p .

Antwort: Wahr

Das ist (13.9.4): pK Komponenten-Koeffizienten plus Achsenabschnitt, nach Zentrierung $p(K - 1) + 1$ frei wählbare. Für $p = 10$ und $K = 10$ sind das 91 freie Parameter statt 10^{10} . Dafür fallen die Wechselwirkungen weg (Bemerkung 13.9.9).

14. Die Rate $O(n^{-8/(8+p)})$ ist eine obere Schranke für den MSE, gleich welches K wir wählen.

Antwort: Falsch

Sie ist die Garantie aus der ausbalancierten Obergrenze und gilt für eine Wahl $K \asymp n^{1/(8+p)}$ unter den Voraussetzungen von Satz 13.9.5. Für ein beliebiges K steht nur die zweigliedrige Schranke (13.9.2) zur Verfügung: K zu klein lässt eine große Bias-Schranke, K zu groß macht die Varianz groß.

Wie es weitergeht

Drei Themen hat dieses Kapitel nur angeschnitten: die theoretische Analyse statistischer Verfahren, die Eigenschaften von Parameterschätzern und die Funktionsapproximation über das hier Gezeigte hinaus. Dazu bieten sich die Vorlesungen von Thomas Nagler an, *Statistical Learning Theory* im Master und *Mathematical Statistics* für Bachelor und Master. Additive Modelle und ihre Verwandten behandelt *Statistik V: Konzepte statistischer Modellierung* im Bachelor.

Schluss

Damit endet das Skript. Begonnen haben wir mit der Frage, warum Rechnen mit endlicher Genauigkeit schiefgehen kann, und mit den Werkzeugen dagegen: Kondition, Stabilität, Aufwandsanalyse. Darauf baute die numerische lineare Algebra auf, von der Elimination über die Zerlegungen bis zur Singulärwertzerlegung, und darauf die Analysis mehrerer Veränderlicher mit Ableitungen, Konvexität und Optimierung. Dieses letzte Kapitel hat alles zusammengeführt: Eine Spline-Anpassung ist ein Kleinste-Quadrate-Problem, ihre Lösung ein Zerlegungsverfahren, ihre Güte eine Frage von Approximationsordnung und Kondition, und ihre Modellwahl ein Optimierungsproblem.

Vertiefung: Heath, *Scientific Computing*, Kapitel 7 fasst Interpolation, stückweise polynomiale Interpolation und Splines samt Übungsaufgaben zusammen; die klassische Referenz zur Sache ist C. de

Boor, *A Practical Guide to Splines. Die gestrafte Glättung entwickeln* P. Eilers und B. Marx, *Flexible Smoothing with B-splines and Penalties*, *Statistical Science* 11 (1996), 89–121; *Tensorprodukt-Splines und additive Modelle samt mgcv behandelt* S. N. Wood, *Generalized Additive Models: An Introduction with R*, 2. Auflage 2017. Die Rate additiver Schätzer geht auf C. J. Stone, *Additive regression and other nonparametric models*, *Annals of Statistics* 13 (1985), 689–705, zurück, der Begriff „Fluch der Dimensionalität“ auf R. Bellman, *Dynamic Programming*, 1957.

13.10 Übungsempfehlungen

Wer den Stoff dieses Kapitels an weiteren Aufgaben üben möchte, findet sie in den Lehrbüchern der Vorlesung. Die Tabellen listen passende Aufgaben, die lohnendsten zuerst. Deutsche Übersetzungen der Aufgabenstellungen und ausführliche Musterlösungen stehen auf der Kurs-Webseite.

Die Sterne schätzen ein, wie viel eine Aufgabe für diese Vorlesung bringt. ★★★ heißt *empfohlen*: zentraler Kursstoff, nah an Klausuraufgaben. ★★ heißt *lohnend*: Kursstoff, aber ein Randthema oder ein anderer Aufgabentyp als in der Klausur. ★ heißt *Vertiefung*: geht größtenteils über den Kursstoff hinaus oder wiederholt nur Grundlagen. Der Aufwand ist grob geschätzt, für eine Bearbeitung ohne Blick in die Lösung.

Empfohlen (★★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 7.1 (a)	Interpolationspolynom vom Grad zwei in der Monomialbasis	leicht, ca. 15 Min.
Heath Exercise 7.5 (a)	Interpolationspolynom in der Monomialbasis	mittel, ca. 30 Min.
Heath Review Question 7.23	Vorteil stückweiser Polynome bei vielen Datenpunkten	leicht, ca. 15 Min.
Heath Review Question 7.28	Parameter- und Bedingungsählung beim natürlichen kubischen Spline	mittel, ca. 15 Min.

Lohnend (★★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Heath Exercise 7.6	Fehlerschranke der Polynominterpolation von $\sin$	mittel, ca. 30 Min.
Heath Exercise 7.16	Eigenschaften von B-Splines nachrechnen	schwer, 1 Std. und mehr
Lange Problem 10.6	Integral und Ableitungen des natürlichen kubischen Splines an drei Knoten	mittel, 1 Std. und mehr

Vertiefung (★)

Aufgabe	Thema	Schwierigkeit, Aufwand
Deuffhard/Hohmann Aufgabe 7.2	Optimale Knotenwahl – Interpolationsfehler und Tschebyscheff-Knoten	schwer, 1 Std. und mehr
Schaback/Wendland Aufgabe 8.6	Operatornorm der Interpolationsabbildung (Lebesgue-Konstante)	schwer, 1 Std. und mehr
Deuffhard/Hohmann Aufgabe 7.9	Der Algorithmus von de Boor	schwer, 1 Std. und mehr
Schaback/Wendland Aufgaben 11.2 und 11.3	Äquidistante B-Splines als Faltungen; B-Spline als Peano-Kern	schwer, 1 Std. und mehr
Lange Problem 10.10	Bayes-Interpretation des Glättungssplines	schwer, 1 Std. und mehr

Bücher: Heath: *Scientific Computing* (2. Aufl.); Deuffhard/Hohmann: *Numerische Mathematik 1* (4. Aufl.); Schaback/Wendland: *Numerische Mathematik* (5. Aufl.); Lange: *Numerical Analysis for Statisticians* (2. Aufl.).