Matrix-Spur und Matrixnormen

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- Normen als Fehlermaße
- Konditionszahlen
- **Lineare Algebra**
  - Matrixoperationen (Addition, Multiplikation, Transposition)
  - Eigenwerte und Eigenvektoren
  - Orthogonalität
  - Skalarprodukte
  - Grundlegende Vektornormen (Euklidische Norm $\|\boldsymbol{x}\|_2$, p-Normen)
- **Analysis**
  - Grenzwerte und Suprema
  - Maximum/Minimum von Funktionen

Die Spur einer Matrix

Matrix-Trace (Spur)

Def.: Spur

Die **Spur** (“trace”) einer quadratischen Matrix $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ ist die Summe ihrer Diagonalelemente:

$$\operatorname{tr}(\boldsymbol{A}) := \sum_{i=1}^{n} a_{ii}$$

Bemerkungen:

- Nur für quadratische Matrizen definiert
- Skalare Invariante der Matrix

Beispiele:

- $\operatorname{tr}(\boldsymbol{I}_n) = n$ $\qquad\qquad$ $\operatorname{tr}\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = 1 + 4 = 5$
- $\operatorname{tr}\begin{pmatrix} 2 & -1 & 0 \\ 0 & 3 & 5 \\ 1 & 0 & -2 \end{pmatrix} = 2 + 3 + (-2) = 3$

Grundlegende Eigenschaften der Spur

Theorem: Eigenschaften der Spur

Für Matrizen $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{n \times n}$ und $c \in \mathbb{R}$:

1. *Additiv*:
   $\operatorname{tr}(\boldsymbol{A} + \boldsymbol{B}) = \operatorname{tr}(\boldsymbol{A}) + \operatorname{tr}(\boldsymbol{B})$
2. *Homogen*:
   $\operatorname{tr}(c\boldsymbol{A}) = c \cdot \operatorname{tr}(\boldsymbol{A})$
3. *Zyklisch*:
   $\operatorname{tr}(\boldsymbol{AB}) = \operatorname{tr}(\boldsymbol{BA})$
4. *Ähnlichkeitsinvariant*:
   $\operatorname{tr}(\boldsymbol{PAP}^{-1}) = \operatorname{tr}(\boldsymbol{A})$ (für invertierbares $\boldsymbol{P} \in \mathbb{R}^{n \times n}$)
5. *Transpositionsinvariant*:
   $\operatorname{tr}(\boldsymbol{A}^\top) = \operatorname{tr}(\boldsymbol{A})$

Wichtigste Eigenschaft:

Zyklische Vertauschung:

$$\operatorname{tr}(\boldsymbol{ABC}) = \operatorname{tr}(\boldsymbol{BCA}) = \operatorname{tr}(\boldsymbol{CAB})$$

Vorsicht:

$\operatorname{tr}(\boldsymbol{AB}) = \operatorname{tr}(\boldsymbol{BA})$, aber $\operatorname{tr}(\boldsymbol{AB}) \neq \operatorname{tr}(\boldsymbol{A}) \cdot \operatorname{tr}(\boldsymbol{B})$!

Spur und Eigenwerte

Theorem: Spur als Summe der Eigenwerte

Für eine Matrix $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ mit Eigenwerten $\lambda_1, \ldots, \lambda_n$:

$$\operatorname{tr}(\boldsymbol{A}) = \sum_{i=1}^{n} \lambda_i$$

Beweisskizze:

siehe Anhang

Kernidee:

Für diagonalisierbare $\boldsymbol{A} = \boldsymbol{P}\boldsymbol{D}\boldsymbol{P}^{-1}$ folgt die Aussage direkt aus der Ähnlichkeitsinvarianz (4).

Frobenius-Norm

Def.: Frobenius-Norm

Die **Frobenius-Norm** einer Matrix $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ ist

$$\|\boldsymbol{A}\|_F := \sqrt{\sum_{i=1}^{m} \sum_{j=1}^{n} a_{ij}^2}$$

Bemerkungen:

- Analog zur euklidischen Vektornorm
- Auch als **Hilbert-Schmidt-Norm** bekannt
- Misst sowas wie die “Größe” der Matrix

Spur und Frobenius-Norm

Verbindung zur Frobenius-Norm:

Für eine Matrix $\boldsymbol{A} \in \mathbb{R}^{m \times n}$:

$$\|\boldsymbol{A}\|_F = \sqrt{\sum_{i=1}^{m} \sum_{j=1}^{n} a_{ij}^2} = \sqrt{\operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{A})}$$

Beweis:

$$\boldsymbol{A}^\top \boldsymbol{A} = \begin{pmatrix} \sum_{i=1}^{m} a_{i1}^2 & \sum_{i=1}^{m} a_{i1} a_{i2} & \cdots \\ \sum_{i=1}^{m} a_{i2} a_{i1} & \sum_{i=1}^{m} a_{i2}^2 & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

$$\implies \operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{A}) = \sum_{j=1}^{n} \sum_{i=1}^{m} a_{ij}^2$$

Spur = Summe der Diagonalelemente; die Nicht-Diagonalelemente fallen weg.

Matrixnormen - Definition und Beispiele

Motivation

Warum brauchen wir `Matrixnormen`?

- Größe einer Matrix messen
- *Fehler* in Berechnungen quantifizieren
- *Konvergenz* von Algorithmen analysieren
- *Konditionierung* von Problemen verstehen

Problem mit der Frobenius-Norm:

- Ignoriert die Eigenschaften der **lineare Transformation** $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x}$, die $\boldsymbol{A}$ repräsentiert
- Behandelt Matrix wie langen Vektor:
  invariant gegen Anordnung der Einträge
- misst nur die *Summe* der quadrierten Bildlängen der Einheitsvektoren

$$\|\boldsymbol{A}\|_F^2 = \sum_j \|\boldsymbol{A}\boldsymbol{e}_j\|_2^2$$

  — nicht, wie stark $\boldsymbol{A}$ einen Vektor *maximal* verzerren kann

Frage:

Wie können wir Normen definieren, die die Transformationseigenschaften berücksichtigen?

Matrixnorm

Def.: Matrixnorm

Eine Funktion $\|\cdot\| : \mathbb{R}^{m\times n} \to [0, \infty)$ ist eine **Matrixnorm**, wenn für alle $\boldsymbol{A}, \boldsymbol{B} \in \mathbb{R}^{m\times n}$ und $c \in \mathbb{R}$ gilt:

1. *Definitheit*:
   $\|\boldsymbol{A}\| = 0 \iff \boldsymbol{A} = \boldsymbol{0}$
2. *Absolute Homogenität*:
   $\|c\boldsymbol{A}\| = |c| \cdot \|\boldsymbol{A}\|$
3. *Dreiecksungleichung*:
   $\|\boldsymbol{A} + \boldsymbol{B}\| \leq \|\boldsymbol{A}\| + \|\boldsymbol{B}\|$

Bemerkung:

- Selbe Axiome wie für *Vektornormen*
- Eine *Vektornorm* ist eine Matrixnorm auf $\mathbb{R}^{n\times 1}$

Aus Vektornormen abgeleitete Matrixnormen

Methode: Vektorisierung

1. Schreibe Matrix als langen Vektor

$$\operatorname{vec}(\boldsymbol{A}) = \begin{pmatrix} a_{11} \\ \vdots \\ a_{m1} \\ \vdots \\ a_{1n} \\ \vdots \\ a_{mn} \end{pmatrix} \in \mathbb{R}^{mn}$$

2. Wende Vektornorm an

Beispiele:

- **Frobenius-Norm**:

$$\|\boldsymbol{A}\|_F = \|\operatorname{vec}(\boldsymbol{A})\|_2$$

- **Summennorm**:

$$\|\boldsymbol{A}\|_S = \|\operatorname{vec}(\boldsymbol{A})\|_1 = \sum_{i,j} |a_{ij}|$$

- **Maximumsnorm**:

$$\|\boldsymbol{A}\|_M = \|\operatorname{vec}(\boldsymbol{A})\|_\infty = \max_{i,j} |a_{ij}|$$

Problem mit element-weisen Normen

Verlust der Transformationsinterpretation:

Beispiel: Betrachte $\boldsymbol{A} = \boldsymbol{I}_n$ (Identitätsmatrix)

- $\|\boldsymbol{I}_n\|_F = \sqrt{n}$ (wächst mit Dimension!)
- $\|\boldsymbol{I}_n\|_S = n$
- $\|\boldsymbol{I}_n\|_M = 1$

Problem: Die Transformation $\boldsymbol{x} \mapsto \boldsymbol{I}_n\boldsymbol{x} = \boldsymbol{x}$ ändert nichts, aber Frobenius- und Summennorm wachsen mit n!

Lösung: *Operatornormen*, die die Transformation direkt messen

Beispiel: Problematische Frobenius-Norm

$$\boldsymbol{A}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \boldsymbol{A}_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \boldsymbol{A}_3 = \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{pmatrix}$$

Frobenius-Norm:

$$\|\boldsymbol{A}_1\|_F = \sqrt{1^2 + 1^2} = \|\boldsymbol{A}_2\|_F = \sqrt{1^2 + 1^2} = \|\boldsymbol{A}_3\|_F = \sqrt{(\sqrt{2})^2} = \sqrt{2}$$

$\Longrightarrow$ Selbe Frobenius-Norm, **Transformationen völlig unterschiedlich:**

Mit $\boldsymbol{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$:

- $\boldsymbol{A}_1\boldsymbol{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ (Identität, keine Änderung)
- $\boldsymbol{A}_2\boldsymbol{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ (Koordinatenvertauschung: Spiegelung an $x_1 = x_2$)
- $\boldsymbol{A}_3\boldsymbol{x} = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix}$ (Streckung der Projektion auf erste Komponente um $\sqrt{2}$)

Operatornormen

Operatornormen

Def.: Operatornorm

Sei $\|\cdot\|_V$ eine *Vektornorm* (definiert auf $\mathbb{R}^n$ und $\mathbb{R}^m$). Die **Operatornorm** von $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ ist:

$$\|\boldsymbol{A}\|_V := \max_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|_V}{\|\boldsymbol{x}\|_V} = \max_{\|\boldsymbol{x}\|_V = 1} \|\boldsymbol{A}\boldsymbol{x}\|_V$$

Interpretation:

- Misst maximale **Streckung** durch $\boldsymbol{A}$ (im Sinne der Vektornorm)
  - große Norm $\rightarrow$ starke “Streckung”
  - kleine Norm $\rightarrow$ schwache “Streckung” / starke “Stauchung”
- *Streckungsfaktor* von $\boldsymbol{x}$ unter $\boldsymbol{A}$: $\frac{\|\boldsymbol{A}\boldsymbol{x}\|_V}{\|\boldsymbol{x}\|_V}$

Visualisierung: Operatornorm

$$\boldsymbol{A} = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$$

```r
(A <- matrix(c(2, 1, 0, 1), nrow = 2, byrow = TRUE))
```

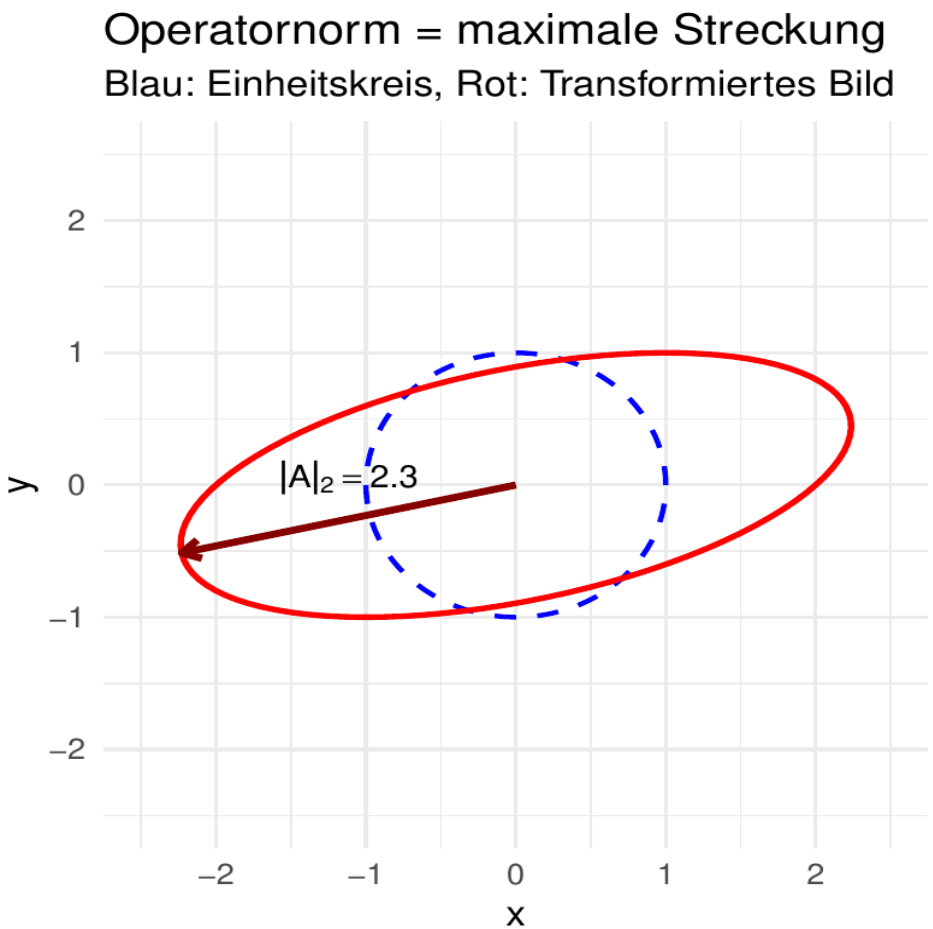
```
     [,1] [,2]
[1,]    2    1
[2,]    0    1
```

```r
(AtA <- crossprod(A))
```

```
     [,1] [,2]
[1,]    4    2
[2,]    2    2
```

```r
eigen(AtA)$values |> sqrt()
```

```
[1] 2.288 0.874
```



Wichtige Operatornormen

Basierend auf verschiedenen p-Normen

$$\|\boldsymbol{v}\|_p = \left(\sum_i |v_i|^p \right)^{1/p} \quad \text{für } 1 \leq p < \infty$$

bzw. $\|\boldsymbol{v}\|_\infty = \max_i |v_i|$:

Spektralnorm ($p = 2$):

$$\|\boldsymbol{A}\|_2 = \max_{\|\boldsymbol{x}\|_2 = 1} \|\boldsymbol{A}\boldsymbol{x}\|_2 = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}$$

Spaltensummennorm ($p = 1$):

$$\|\boldsymbol{A}\|_1 = \max_{\|\boldsymbol{x}\|_1 = 1} \|\boldsymbol{A}\boldsymbol{x}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^{m} |a_{ij}|$$

Zeilensummennorm ($p = \infty$):

$$\|\boldsymbol{A}\|_\infty = \max_{\|\boldsymbol{x}\|_\infty = 1} \|\boldsymbol{A}\boldsymbol{x}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^{n} |a_{ij}|$$

Einschub: Orthogonalmatrizen

Def.: Orthogonalmatrix

Eine Matrix $\boldsymbol{Q} \in \mathbb{R}^{n \times n}$ heißt **Orthogonalmatrix**, wenn ihre Spalten *orthonormale Vektoren* sind, also $\boldsymbol{Q}^\top \boldsymbol{Q} = \boldsymbol{I}$.

Nützliche Eigenschaften

- Geometrisch:
  $\boldsymbol{Q}$ beschreibt eine *Rotation und/oder Spiegelung* in $\mathbb{R}^n$.
- für Orthogonalmatrizen $\boldsymbol{Q}_1, \dots, \boldsymbol{Q}_n$ ist auch $\boldsymbol{Q} = \boldsymbol{Q}_1 \cdots \boldsymbol{Q}_n$ *orthogonal*.
- Normerhaltend:
  $\|\boldsymbol{Q}\boldsymbol{x}\|_2 = \sqrt{\boldsymbol{x}^\top \boldsymbol{Q}^\top \boldsymbol{Q} \boldsymbol{x}} = \sqrt{\boldsymbol{x}^\top \boldsymbol{x}} = \|\boldsymbol{x}\|_2$ für alle $\boldsymbol{x} \in \mathbb{R}^n$.
- Unitär:
  Es gilt $|\lambda_1(\boldsymbol{Q})| = \cdots = |\lambda_n(\boldsymbol{Q})| = 1$.
- $\boldsymbol{Q}^{-1} = \boldsymbol{Q}^\top$ ist wieder orthogonal, also $\|\boldsymbol{Q}\|_2 = \|\boldsymbol{Q}^{-1}\|_2 = 1$
  $\implies \kappa_2(\boldsymbol{Q}) = \|\boldsymbol{Q}\|_2 \cdot \|\boldsymbol{Q}^{-1}\|_2 = 1$
  $\implies$ Multiplikation mit $\boldsymbol{Q}$ oder $\boldsymbol{Q}^{-1}$ ist immer gut konditioniert.
  $\implies$ Multiplikation mit $\boldsymbol{Q}$ oder $\boldsymbol{Q}^{-1}$ verschlechtert nicht die Stabilität von Algorithmen.

Spektralnorm und Spektralzerlegung

Theorem

Für $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Spektralzerlegung $\boldsymbol{A}^\top \boldsymbol{A} = \boldsymbol{P} \boldsymbol{\Lambda} \boldsymbol{P}^\top$, wobei $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \ldots, \lambda_r, 0, \ldots, 0)$ mit $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$:

$$\|\boldsymbol{A}\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}$$

Beweis:
siehe Anhang

Interpretation:

- Wurzel des größten Eigenwerts von $\boldsymbol{A}^\top \boldsymbol{A}$ = maximaler Streckungsfaktor
- intuitiver über *Singulärwerte* / **SVD** (später...)

Beispiele für Operatornormen

Beispiel 1:

$$\boldsymbol{A} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$$

Spaltensummennorm:

$$\|\boldsymbol{A}\|_1 = \max\{|2| + |0|, |1| + |3|\} = 4$$

Zeilensummennorm:

$$\|\boldsymbol{A}\|_\infty = \max\{|2| + |1|, |0| + |3|\} = 3$$

Spektralnorm: $\|\boldsymbol{A}\|_2 = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})} \approx 3.26$

Beispiel 2: Identitätsmatrix $\boldsymbol{I}_n$

- $\|\boldsymbol{I}_n\|_1 = \|\boldsymbol{I}_n\|_2 = \|\boldsymbol{I}_n\|_\infty = 1$ ✓
- Macht Sinn: $\boldsymbol{I}_n$ verändert nichts!

Schattennormen

Schatten-p-Normen

Def.: Schatten-p-Normen

Die **Schatten-p-Norm** ($1 \leq p \leq \infty$) einer Matrix $\boldsymbol{A} \in \mathbb{R}^{m \times n}$, deren Kreuzprodukt $\boldsymbol{A}^\top \boldsymbol{A}$ die Eigenwerte $\boldsymbol{\lambda} = (\lambda_1, \ldots, \lambda_n)$ hat, ist:

$$\|\boldsymbol{A}\|_{S,p} := \|\boldsymbol{\lambda}^{1/2}\|_p = \left(\sum_{i=1}^{n} \lambda_i^{p/2} \right)^{1/p}$$

Wichtige Spezialfälle:

- $p = \infty$: $\|\boldsymbol{A}\|_{S,\infty} = \sqrt{\lambda_{\max}} = \|\boldsymbol{A}\|_2$ (Spektralnorm)
- $p = 2$: $\|\boldsymbol{A}\|_{S,2} = \|\boldsymbol{\lambda}^{1/2}\|_2 = \|\boldsymbol{A}\|_F$ (Frobenius-Norm!)
- $p = 1$: $\|\boldsymbol{A}\|_{S,1} = \|\boldsymbol{A}\|_* = \sum_{i=1}^{r} \sqrt{\lambda_i}$ (Nuklearnorm)

Überraschung: Frobenius-Norm ist eine Schatten-Norm!

Schatten-Normen

- Benannt nach dem Mathematiker **Robert Schatten** (1911-1977)
- Schatten-Normen sind *unitär invariant*, d.h. invariant unter orthogonalen Transformationen:
  Für orthogonale Matrizen $\boldsymbol{P}, \boldsymbol{Q}$ gilt $\|\boldsymbol{PAQ}\|_{S,p} = \|\boldsymbol{A}\|_{S,p}$
  Beweis: $(\boldsymbol{PAQ})^\top(\boldsymbol{PAQ}) = \boldsymbol{Q}^\top\boldsymbol{A}^\top\boldsymbol{AQ}$ und $\boldsymbol{A}^\top\boldsymbol{A}$ haben dieselben Eigenwerte.
- **Warum ist $\|\boldsymbol{A}\|_{S,2} = \|\boldsymbol{A}\|_F$?**
  Wie bereits gezeigt gilt $\|\boldsymbol{A}\|_F^2 = \operatorname{tr}(\boldsymbol{A}^\top\boldsymbol{A})$; mit der Spektralzerlegung $\boldsymbol{A}^\top\boldsymbol{A} = \boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}^\top$ folgt

$$\|\boldsymbol{A}\|_F^2 = \operatorname{tr}(\boldsymbol{P}\boldsymbol{\Lambda}\boldsymbol{P}^\top) = \operatorname{tr}(\boldsymbol{\Lambda}) = \sum_{i=1}^{r}\lambda_i = \|\boldsymbol{A}\|_{S,2}^2$$

  ($\boldsymbol{P}, \boldsymbol{P}^\top$ heben sich weg: zyklische Vertauschung und $\boldsymbol{P}^\top\boldsymbol{P} = \boldsymbol{I}$)
- **Anwendung:** Schatten-Normen sind ideal für *Approximationsprobleme*, da sie invariant unter Koordinatentransformationen sind.

Eigenschaften von Matrixnormen

Normenäquivalenz

Theorem: Alle Matrixnormen sind äquivalent

Für je zwei Matrixnormen $\|\cdot\|_a$ und $\|\cdot\|_b$ auf $\mathbb{R}^{m\times n}$ (bei festen m, n) existieren Konstanten $c, C > 0$ mit:

$$c\|\boldsymbol{A}\|_a \leq \|\boldsymbol{A}\|_b \leq C\|\boldsymbol{A}\|_a$$

Explizite Konstanten (Beispiele):

- $\|\boldsymbol{A}\|_2 \leq \|\boldsymbol{A}\|_F \leq \sqrt{\min(m,n)}\|\boldsymbol{A}\|_2$
- $\|\boldsymbol{A}\|_F \leq \|\boldsymbol{A}\|_* \leq \sqrt{\min(m,n)}\|\boldsymbol{A}\|_F$
- $\frac{1}{\sqrt{n}}\|\boldsymbol{A}\|_\infty \leq \|\boldsymbol{A}\|_2 \leq \sqrt{m}\|\boldsymbol{A}\|_\infty$

Wichtig:

- **Äquivalenz $\neq$ Gleichheit**
- Verschiedene Normen können Matrizen **unterschiedlich ordnen**
- Jede Norm hat ihre eigene **Interpretation**

Submultiplikativität

Definition: Submultiplikative Norm

Eine Matrixnorm $\|\cdot\|$ heißt **submultiplikativ**, wenn für alle $\boldsymbol{A}, \boldsymbol{B}$ mit passenden Dimensionen gilt:

$$\|\boldsymbol{AB}\| \leq \|\boldsymbol{A}\| \cdot \|\boldsymbol{B}\|$$

- Alle *Operatornormen* und *Schatten-Normen* sind submultiplikativ
- Die *Maximumsnorm* nicht (Gegenbeispiel: siehe Anhang)

Warum ist das wichtig?

- Kontrolliert **Fehlerfortpflanzung** in Matrixprodukten
- Ermöglicht **Konvergenzanalyse** iterativer Verfahren
- Verbindet Normen mit **Spektralradius**

Verträglichkeit von Normen

Def.: Verträgliche Norm

Eine Matrixnorm $\|\cdot\|$ ist **verträglich** mit einer Vektornorm $\|\cdot\|_V$, wenn:

$$\|\boldsymbol{A}\boldsymbol{x}\|_V \leq \|\boldsymbol{A}\| \cdot \|\boldsymbol{x}\|_V$$

Verträglichkeiten:

1. **Jede submultiplikative Norm** ist mit sich selbst verträglich
2. **Jede Operatornorm** ist mit ihrer induzierenden Vektornorm verträglich
3. **Frobenius-Norm** ist mit der euklidischen Norm verträglich

Anwendung:

Verträglichkeit ermöglicht **Fehlerabschätzungen**: Wenn $\|\boldsymbol{e}\|_V$ klein ist, dann ist auch $\|\boldsymbol{A}\boldsymbol{e}\|_V$ kontrolliert.

Matrixnormen und Konditionierung

Konditionszahl einer (invertierbaren) Matrix:

$$\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\| \cdot \|\boldsymbol{A}^{-1}\|$$

Für Spektralnorm:

$$\kappa_2(\boldsymbol{A}) = \|\boldsymbol{A}\|_2 \cdot \|\boldsymbol{A}^{-1}\|_2 = \frac{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})^{1/2}}{\lambda_{\min}(\boldsymbol{A}^\top \boldsymbol{A})^{1/2}}$$

Interpretation:

- $\kappa \approx 1$: Gut konditioniert
- $\kappa \gg 1$: Schlecht konditioniert
- $\kappa = \infty$: Singulär

Verbindung zu *Spektralzerlegung* / **SVD**: Konditionierung wird durch das Verhältnis von größtem zu kleinstem *Singulärwert* bestimmt!

Normen in der Fehleranalyse

Rückwärts-Fehleranalyse:

Problem:
Löse $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$, erhalte $\tilde{\boldsymbol{x}}$

Frage:
Für welches gestörte Problem ist $\tilde{\boldsymbol{x}}$ die exakte Lösung?

Antwort:
$(\boldsymbol{A} + \boldsymbol{\Delta A})\tilde{\boldsymbol{x}} = \boldsymbol{b}$ mit $\boldsymbol{\Delta A} = -\boldsymbol{r}\tilde{\boldsymbol{x}}^\top / \|\tilde{\boldsymbol{x}}\|^2$ für $\boldsymbol{r} = \boldsymbol{A}\tilde{\boldsymbol{x}} - \boldsymbol{b}$

Fehlerabschätzung:

$$\frac{\|\boldsymbol{\Delta A}\|_2}{\|\boldsymbol{A}\|_2} = \frac{\|\boldsymbol{r}\|_2}{\|\boldsymbol{A}\|_2 \cdot \|\tilde{\boldsymbol{x}}\|_2}$$

Interpretation:
Normen quantifizieren die **relative Störung** des Problems!

Zusammenfassung

Zusammenfassung

- *Spur*:

$$\operatorname{tr}(\boldsymbol{A}) = \sum_{i=1}^{n} a_{ii} = \sum_{i=1}^{n} \lambda_i$$

  linear, *zyklisch* ($\operatorname{tr}(\boldsymbol{AB}) = \operatorname{tr}(\boldsymbol{BA})$), ähnlichkeitsinvariant
- **Drei Familien von Matrixnormen:**
  1. *Element-weise Normen* ($\|\boldsymbol{A}\|_F$, $\|\boldsymbol{A}\|_S$, $\|\boldsymbol{A}\|_M$): einfach zu berechnen, verlieren aber die Transformationsinterpretation
  2. *Operatornormen* ($\|\boldsymbol{A}\|_1$, $\|\boldsymbol{A}\|_2$, $\|\boldsymbol{A}\|_\infty$): messen maximale Streckung, *submultiplikativ*, *verträglich*
  3. *Schatten-Normen* ($\|\boldsymbol{A}\|_{S,p}$): basieren auf Eigen-/Singulärwerten, *unitär invariant*
- **Verbindungen:**
  - *Frobenius-Norm* ist element-weise Norm **und** Schatten-Norm: $\|\boldsymbol{A}\|_F = \sqrt{\operatorname{tr}(\boldsymbol{A}^\top \boldsymbol{A})} = \sqrt{\sum_i \lambda_i} = \|\boldsymbol{A}\|_{S,2}$
  - *Spektralnorm* $\|\boldsymbol{A}\|_2 = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}$ verbindet Operatornormen mit Spektralzerlegung / **SVD**
  - *Konditionszahl*: $\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\| \cdot \|\boldsymbol{A}^{-1}\|$

Self-Check

Quiz - Trace Eigenschaften

Welche Aussagen sind korrekt?

1. $\mathrm{tr}(\boldsymbol{A}\boldsymbol{B}) = \mathrm{tr}(\boldsymbol{A}) \cdot \mathrm{tr}(\boldsymbol{B})$
2. $\mathrm{tr}(\boldsymbol{A}\boldsymbol{B}) = \mathrm{tr}(\boldsymbol{B}\boldsymbol{A})$
3. $\mathrm{tr}(\boldsymbol{A}^\top) = -\mathrm{tr}(\boldsymbol{A})$
4. $\mathrm{tr}(\boldsymbol{I}_n) = n$
5. Wenn $\boldsymbol{A}$ invertierbar ist, dann $\mathrm{tr}(\boldsymbol{A}^{-1}) = 1/\mathrm{tr}(\boldsymbol{A})$

Quiz - Normen berechnen

Gegeben: $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 3 & 0 \end{pmatrix}$

Berechne:

1. $\|\boldsymbol{A}\|_1$ (Spaltensummennorm)
2. $\|\boldsymbol{A}\|_\infty$ (Zeilensummennorm)
3. $\|\boldsymbol{A}\|_F$ (Frobenius-Norm)

Anhang

Beweisskizze: Spur als Summe der Eigenwerte

Beweisskizze: (für diagonalisierbare $\boldsymbol{A}$)

Sei $\boldsymbol{A} = \boldsymbol{P}\boldsymbol{D}\boldsymbol{P}^{-1}$ eine Diagonalisierung, also $\boldsymbol{D} = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$

$$\implies \operatorname{tr}(\boldsymbol{A}) = \operatorname{tr}\left(\boldsymbol{P}\boldsymbol{D}\boldsymbol{P}^{-1}\right) \overset{(4)}{=} \operatorname{tr}(\boldsymbol{D}) = \sum_{i=1}^{n} \lambda_i$$

($\boldsymbol{P}$, $\boldsymbol{P}^{-1}$ heben sich per Ähnlichkeitsinvarianz (4) weg.)

Beweis für allgemeine $\boldsymbol{A}$ über charakteristisches Polynom.

↩ zurück: „Spur und Eigenwerte”

Beweis: Spektralnorm und Spektralzerlegung

Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Spektralzerlegung $\boldsymbol{A}^\top \boldsymbol{A} = \boldsymbol{P} \boldsymbol{\Lambda} \boldsymbol{P}^\top$, wobei $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \ldots, \lambda_r, 0, \ldots, 0)$ mit $\lambda_1 \geq \cdots \geq \lambda_r > 0$.

Beweis (Skizze):

$$\|\boldsymbol{A}\boldsymbol{x}\|_2^2 = \boldsymbol{x}^\top \boldsymbol{A}^\top \boldsymbol{A} \boldsymbol{x} = \boldsymbol{x}^\top \boldsymbol{P} \boldsymbol{\Lambda} \boldsymbol{P}^\top \boldsymbol{x} = \|\boldsymbol{\Lambda}^{1/2} \boldsymbol{P}^\top \boldsymbol{x}\|_2^2$$

Weil $\boldsymbol{P}$ *orthogonal* ist, durchläuft $\boldsymbol{P}^\top \boldsymbol{x}$ die Einheitssphäre wenn $\boldsymbol{x}$ dies tut, also

$$\max_{\|\boldsymbol{x}\|_2 = 1} \|\boldsymbol{\Lambda}^{1/2} \boldsymbol{P}^\top \boldsymbol{x}\|_2^2 = \max_{\|\boldsymbol{y}\|_2 = 1} \|\boldsymbol{\Lambda}^{1/2} \boldsymbol{y}\|_2^2 = \lambda_1,$$

$$\text{da } \|\boldsymbol{\Lambda}^{1/2} \boldsymbol{y}\|_2^2 = \sum_{i=1}^{r} \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^{r} y_i^2 \leq \lambda_1,$$

$$\text{mit Gleichheit für } \boldsymbol{y} = \boldsymbol{e}_1.$$

■

↩ zurück: „Spektralnorm und Spektralzerlegung"

Gegenbeispiel: Maximumsnorm ist nicht submultiplikativ

Beispiel: $\boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$

$$\boldsymbol{A}^2 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$$

$$\|\boldsymbol{A}\|_M = 1, \quad \|\boldsymbol{A}^2\|_M = 2$$

$$\|\boldsymbol{A}^2\|_M = 2 > 1 = \|\boldsymbol{A}\|_M \cdot \|\boldsymbol{A}\|_M$$

Reparatur: Gesamtnorm

$$\|\boldsymbol{A}\|_G = \sqrt{mn}\|\boldsymbol{A}\|_M$$

Diese ist submultiplikativ!

↩ zurück: „Submultiplikativität"

Ausblick: Normen in Machine Learning

Ridge Regression (L2-Regularisierung):

$$\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \lambda \|\boldsymbol{x}\|_2^2$$

LASSO (L1-Regularisierung):

$$\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \lambda \|\boldsymbol{x}\|_1$$

Nuclear Norm Regularisierung (Matrix Completion):

$$\min_{\boldsymbol{X}} \|\boldsymbol{P}_\Omega(\boldsymbol{X}) - \boldsymbol{P}_\Omega(\boldsymbol{M})\|_F^2 + \lambda \|\boldsymbol{X}\|_*$$

($\boldsymbol{P}_\Omega$: behält nur die beobachteten Einträge Ω, Rest $= 0$)

$\Longrightarrow$ Verschiedene Normen führen zu verschiedenen Lösungscharakteristika!