

Matrix-Spur und Matrixnormen

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- Normen als Fehlermaße
- Konditionszahlen
- **Lineare Algebra**
 - Matrixoperationen (Addition, Multiplikation, Transposition)
 - Eigenwerte und Eigenvektoren
 - Orthogonalität
 - Skalarprodukte
 - Grundlegende Vektornormen (Euklidische Norm $\|\boldsymbol{x}\|_2$, p -Normen)
- **Analysis**
 - Grenzwerte und Suprema
 - Maximum/Minimum von Funktionen

Die Spur einer Matrix

Matrix-Trace (Spur)

Def.: Spur

Die **Spur** (“trace”) einer quadratischen Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ ist die Summe ihrer Diagonalelemente:

$$\text{tr}(\mathbf{A}) := \sum_{i=1}^n a_{ii}$$

Bemerkungen:

- Nur für quadratische Matrizen definiert
- Skalare Invariante der Matrix

Beispiele:

- $\text{tr}(\mathbf{I}_n) = n$ $\text{tr} \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = 1 + 4 = 5$
- $\text{tr} \begin{pmatrix} 2 & -1 & 0 \\ 0 & 3 & 5 \\ 1 & 0 & -2 \end{pmatrix} = 2 + 3 + (-2) = 3$

Grundlegende Eigenschaften der Spur

Theorem: Eigenschaften der Spur

Für Matrizen $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ und $c \in \mathbb{R}$:

1. *Additiv:*

$$\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$$

2. *Homogen:*

$$\text{tr}(c\mathbf{A}) = c \cdot \text{tr}(\mathbf{A})$$

3. *Zyklisch:*

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$$

4. *Ähnlichkeitsinvariant:*

$$\text{tr}(\mathbf{PAP}^{-1}) = \text{tr}(\mathbf{A}) \text{ (für invertierbares } \mathbf{P} \in \mathbb{R}^{n \times n})$$

5. *Transpositionsinvariant:*

$$\text{tr}(\mathbf{A}^\top) = \text{tr}(\mathbf{A})$$

Wichtigste Eigenschaft:

Zyklische Vertauschung:

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{BCA}) = \text{tr}(\mathbf{CAB})$$

Vorsicht:

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}), \text{ aber } \text{tr}(\mathbf{AB}) \neq \text{tr}(\mathbf{A}) \cdot \text{tr}(\mathbf{B})!$$

Spur und Eigenwerte

Theorem: Spur als Summe der Eigenwerte

Für eine Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ mit Eigenwerten $\lambda_1, \dots, \lambda_n$:

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n \lambda_i$$

Beweisskizze:

siehe [Anhang](#)

Kernidee:

Für diagonalisierbare $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$ folgt die Aussage direkt aus der Ähnlichkeitsinvarianz (4).

Frobenius-Norm

Def.: Frobenius-Norm

Die **Frobenius-Norm** einer Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ ist

$$\|\mathbf{A}\|_F := \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}$$

Bemerkungen:

- Analog zur euklidischen Vektornorm
- Auch als **Hilbert-Schmidt-Norm** bekannt
- Misst sowas wie die “Größe” der Matrix

Spur und Frobenius-Norm

Verbindung zur Frobenius-Norm:

Für eine Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$:

$$\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2} = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})}$$

Beweis:

$$\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} \sum_{i=1}^m a_{i1}^2 & \sum_{i=1}^m a_{i1}a_{i2} & \cdots \\ \sum_{i=1}^m a_{i2}a_{i1} & \sum_{i=1}^m a_{i2}^2 & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$
$$\implies \text{tr}(\mathbf{A}^\top \mathbf{A}) = \sum_{j=1}^n \sum_{i=1}^m a_{ij}^2$$

Spur = Summe der **Diagonalelemente**; die **Nicht-Diagonalelemente** fallen weg.

Matrixnormen - Definition und Beispiele

Motivation

Warum brauchen wir **Matrixnormen**?

- Größe einer Matrix messen
- **Fehler** in Berechnungen quantifizieren
- **Konvergenz** von Algorithmen analysieren
- **Konditionierung** von Problemen verstehen

Problem mit der Frobenius-Norm:

- Ignoriert die Eigenschaften der **lineare Transformation** $x \mapsto Ax$, die A repräsentiert
- Behandelt Matrix wie langen Vektor:
invariant gegen Anordnung der Einträge
- misst nur die *Summe* der quadrierten Bildlängen der Einheitsvektoren

$$\|A\|_F^2 = \sum_j \|Ae_j\|_2^2$$

— nicht, wie stark A einen Vektor *maximal* verzerren kann

Frage:

Wie können wir Normen definieren, die die Transformationseigenschaften berücksichtigen?

Matrixnorm

Def.: Matrixnorm

Eine Funktion $\|\cdot\| : \mathbb{R}^{m \times n} \rightarrow [0, \infty)$ ist eine **Matrixnorm**, wenn für alle $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$ und $c \in \mathbb{R}$ gilt:

1. *Definitheit*:

$$\|\mathbf{A}\| = 0 \iff \mathbf{A} = \mathbf{0}$$

2. *Absolute Homogenität*:

$$\|c\mathbf{A}\| = |c| \cdot \|\mathbf{A}\|$$

3. *Dreiecksungleichung*:

$$\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$$

Bemerkung:

- Selbe Axiome wie für **Vektornormen**
- Eine **Vektornorm** ist eine Matrixnorm auf $\mathbb{R}^{n \times 1}$

Aus Vektornormen abgeleitete Matrixnormen

Methode: Vektorisierung

1. Schreibe Matrix als langen Vektor

$$\text{vec}(\mathbf{A}) = \begin{pmatrix} a_{11} \\ \vdots \\ a_{m1} \\ \vdots \\ a_{1n} \\ \vdots \\ a_{mn} \end{pmatrix} \in \mathbb{R}^{mn}$$

2. Wende Vektornorm an

Beispiele:

- **Frobenius-Norm:**

$$\|\mathbf{A}\|_F = \|\text{vec}(\mathbf{A})\|_2$$

- **Summennorm:**

$$\|\mathbf{A}\|_S = \|\text{vec}(\mathbf{A})\|_1 = \sum_{i,j} |a_{ij}|$$

- **Maximumsnorm:**

$$\|\mathbf{A}\|_M = \|\text{vec}(\mathbf{A})\|_\infty = \max_{i,j} |a_{ij}|$$

Problem mit element-weisen Normen

Verlust der Transformationsinterpretation:

Beispiel: Betrachte $\mathbf{A} = \mathbf{I}_n$ (Identitätsmatrix)

- $\|\mathbf{I}_n\|_F = \sqrt{n}$ (wächst mit Dimension!)
- $\|\mathbf{I}_n\|_S = n$
- $\|\mathbf{I}_n\|_M = 1$

Problem: Die Transformation $\mathbf{x} \mapsto \mathbf{I}_n \mathbf{x} = \mathbf{x}$ ändert nichts, aber Frobenius- und Summennorm wachsen mit n !

Lösung: *Operatornormen*, die die Transformation direkt messen

Beispiel: Problematische Frobenius-Norm

$$\mathbf{A}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \mathbf{A}_2 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \mathbf{A}_3 = \begin{pmatrix} \sqrt{2} & 0 \\ 0 & 0 \end{pmatrix}$$

Frobenius-Norm:

$$\|\mathbf{A}_1\|_F = \sqrt{1^2 + 1^2} = \|\mathbf{A}_2\|_F = \sqrt{1^2 + 1^2} = \|\mathbf{A}_3\|_F = \sqrt{(\sqrt{2})^2} = \sqrt{2}$$

$\implies$ Selbe Frobenius-Norm, **Transformationen völlig unterschiedlich:**

Mit $\mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$:

- $\mathbf{A}_1 \mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ (Identität, keine Änderung)
- $\mathbf{A}_2 \mathbf{x} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ (Koordinatenvertauschung: Spiegelung an $x_1 = x_2$)
- $\mathbf{A}_3 \mathbf{x} = \begin{pmatrix} \sqrt{2} \\ 0 \end{pmatrix}$ (Streckung der Projektion auf erste Komponente um $\sqrt{2}$)

Operatornormen

Operatornormen

Def.: Operatornorm

Sei $\|\cdot\|_V$ eine *Vektornorm* (definiert auf $\mathbb{R}^n$ und $\mathbb{R}^m$). Die **Operatornorm** von $\mathbf{A} \in \mathbb{R}^{m \times n}$ ist:

$$\|\mathbf{A}\|_V := \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|_V}{\|\mathbf{x}\|_V} = \max_{\|\mathbf{x}\|_V=1} \|\mathbf{A}\mathbf{x}\|_V$$

Interpretation:

- Misst maximale **Streckung** durch $\mathbf{A}$ (im Sinne der Vektornorm)
 - große Norm $\rightarrow$ starke “Streckung”
 - kleine Norm $\rightarrow$ schwache “Streckung” / starke “Stauchung”
- *Streckungsfaktor* von $\mathbf{x}$ unter $\mathbf{A}$: $\frac{\|\mathbf{A}\mathbf{x}\|_V}{\|\mathbf{x}\|_V}$

Visualisierung: Operatornorm

$$A = \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}$$

```
1 (A <- matrix(c(2, 1, 0, 1), nrow = 2, byrow = TRUE))
```

```
      [,1] [,2]  
[1,]    2    1  
[2,]    0    1
```


```
1 (AtA <- crossprod(A))
```

```
      [,1] [,2]  
[1,]    4    2  
[2,]    2    2
```

```
1 eigen(AtA)$values |> sqrt()
```

```
[1] 2.288 0.874
```

Operatornorm = maximale Streckung
Blau: Einheitskreis, Rot: Transformiertes Bild



Wichtige Operatornormen

Basierend auf verschiedenen p -Normen

$$\|\mathbf{v}\|_p = \left(\sum_i |v_i|^p \right)^{1/p} \quad \text{für } 1 \leq p < \infty$$

bzw. $\|\mathbf{v}\|_\infty = \max_i |v_i|$:

Spektralnrm ($p = 2$):

$$\|\mathbf{A}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{Ax}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$$

Spaltensummennorm ($p = 1$):

$$\|\mathbf{A}\|_1 = \max_{\|\mathbf{x}\|_1=1} \|\mathbf{Ax}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

Zeilensummennorm ($p = \infty$):

$$\|\mathbf{A}\|_\infty = \max_{\|\mathbf{x}\|_\infty=1} \|\mathbf{Ax}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

Einschub: Orthogonalmatrizen

Def.: Orthogonalmatrix

Eine Matrix $Q \in \mathbb{R}^{n \times n}$ heißt **Orthogonalmatrix**, wenn ihre Spalten *orthonormale Vektoren* sind, also $Q^\top Q = I$.

Nützliche Eigenschaften

- Geometrisch:
 Q beschreibt eine *Rotation und/oder Spiegelung* in $\mathbb{R}^n$.
- für Orthogonalmatrizen $Q_1, \dots, Q_n$ ist auch $Q = Q_1 \cdots Q_n$ **orthogonal**.
- Normerhaltend:
 $\|Qx\|_2 = \sqrt{x^\top Q^\top Q x} = \sqrt{x^\top x} = \|x\|_2$ für alle $x \in \mathbb{R}^n$.
- Unitär:
Es gilt $|\lambda_1(Q)| = \dots = |\lambda_n(Q)| = 1$.
- $Q^{-1} = Q^\top$ ist wieder orthogonal, also $\|Q\|_2 = \|Q^{-1}\|_2 = 1$
 $\implies \kappa_2(Q) = \|Q\|_2 \cdot \|Q^{-1}\|_2 = 1$
 $\implies$ Multiplikation mit Q oder Q^{-1} ist immer gut konditioniert.
 $\implies$ Multiplikation mit Q oder Q^{-1} verschlechtert nicht die Stabilität von Algorithmen.

Spektralnrm und Spektralzerlegung

Theorem

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$, wobei $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0)$ mit $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0$:

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$$

Beweis:

siehe **Anhang**

Interpretation:

- Wurzel des größten Eigenwerts von $\mathbf{A}^\top \mathbf{A}$ = maximaler Streckungsfaktor
- intuitiver über **Singulärwerte** / **SVD** (später...)

Beispiele für Operatornormen

Beispiel 1:

$$\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$$

Spaltensummennorm:

$$\|\mathbf{A}\|_1 = \max\{|2| + |0|, |1| + |3|\} = 4$$

Zeilensummennorm:

$$\|\mathbf{A}\|_\infty = \max\{|2| + |1|, |0| + |3|\} = 3$$

Spektralnrm: $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})} \approx 3.26$

Beispiel 2: Identitätsmatrix $\mathbf{I}_n$

- $\|\mathbf{I}_n\|_1 = \|\mathbf{I}_n\|_2 = \|\mathbf{I}_n\|_\infty = 1 \checkmark$
- Macht Sinn: $\mathbf{I}_n$ verändert nichts!

Schattennormen

Schatten-p-Normen

Def.: Schatten-p-Normen

Die **Schatten-p-Norm** ($1 \leq p \leq \infty$) einer Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$, deren Kreuzprodukt $\mathbf{A}^\top \mathbf{A}$ die Eigenwerte $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_n)$ hat, ist:

$$\|\mathbf{A}\|_{S,p} := \|\boldsymbol{\lambda}^{1/2}\|_p = \left(\sum_{i=1}^n \lambda_i^{p/2} \right)^{1/p}$$

Wichtige Spezialfälle:

- $p = \infty$: $\|\mathbf{A}\|_{S,\infty} = \sqrt{\lambda_{\max}} = \|\mathbf{A}\|_2$ (Spektralnrm)
- $p = 2$: $\|\mathbf{A}\|_{S,2} = \|\boldsymbol{\lambda}^{1/2}\|_2 = \|\mathbf{A}\|_F$ (Frobenius-Norm!)
- $p = 1$: $\|\mathbf{A}\|_{S,1} = \|\mathbf{A}\|_* = \sum_{i=1}^r \sqrt{\lambda_i}$ (Nuklearnrm)

Überraschung: Frobenius-Norm ist eine Schatten-Norm!

Schatten-Normen

- Benannt nach dem Mathematiker **Robert Schatten** (1911-1977)
- Schatten-Normen sind **unitär invariant**, d.h. invariant unter orthogonalen Transformationen:
Für orthogonale Matrizen $\mathbf{P}, \mathbf{Q}$ gilt $\|\mathbf{PAQ}\|_{S,p} = \|\mathbf{A}\|_{S,p}$
Beweis: $(\mathbf{PAQ})^\top (\mathbf{PAQ}) = \mathbf{Q}^\top \mathbf{A}^\top \mathbf{A} \mathbf{Q}$ und $\mathbf{A}^\top \mathbf{A}$ haben dieselben Eigenwerte.
- **Warum ist $\|\mathbf{A}\|_{S,2} = \|\mathbf{A}\|_F$?**
Wie bereits gezeigt gilt $\|\mathbf{A}\|_F^2 = \text{tr}(\mathbf{A}^\top \mathbf{A})$; mit der Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$ folgt

$$\|\mathbf{A}\|_F^2 = \text{tr}(\mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top) = \text{tr}(\mathbf{\Lambda}) = \sum_{i=1}^r \lambda_i = \|\mathbf{A}\|_{S,2}^2$$

($\mathbf{P}, \mathbf{P}^\top$ heben sich weg: zyklische Vertauschung und $\mathbf{P}^\top \mathbf{P} = \mathbf{I}$)

- **Anwendung:** Schatten-Normen sind ideal für **Approximationsprobleme**, da sie invariant unter Koordinatentransformationen sind.

Eigenschaften von Matrixnormen

Normenäquivalenz

Theorem: Alle Matrixnormen sind äquivalent

Für je zwei Matrixnormen $\|\cdot\|_a$ und $\|\cdot\|_b$ auf $\mathbb{R}^{m \times n}$ (bei festen m, n) existieren Konstanten $c, C > 0$ mit:

$$c\|\mathbf{A}\|_a \leq \|\mathbf{A}\|_b \leq C\|\mathbf{A}\|_a$$

Explizite Konstanten (Beispiele):

- $\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{\min(m, n)} \|\mathbf{A}\|_2$
- $\|\mathbf{A}\|_F \leq \|\mathbf{A}\|_* \leq \sqrt{\min(m, n)} \|\mathbf{A}\|_F$
- $\frac{1}{\sqrt{n}} \|\mathbf{A}\|_\infty \leq \|\mathbf{A}\|_2 \leq \sqrt{m} \|\mathbf{A}\|_\infty$

Wichtig:

- **Äquivalenz $\neq$ Gleichheit**
- Verschiedene Normen können Matrizen **unterschiedlich ordnen**
- Jede Norm hat ihre eigene **Interpretation**

Submultiplikativität

Definition: Submultiplikative Norm

Eine Matrixnorm $\| \cdot \|$ heißt **submultiplikativ**, wenn für alle A, B mit passenden Dimensionen gilt:

$$\|AB\| \leq \|A\| \cdot \|B\|$$

- Alle **Operatornormen** und **Schatten-Normen** sind submultiplikativ
- Die **Maximumsnorm** nicht (Gegenbeispiel: siehe **Anhang**)

Warum ist das wichtig?

- Kontrolliert **Fehlerfortpflanzung** in Matrixprodukten
- Ermöglicht **Konvergenzanalyse** iterativer Verfahren
- Verbindet Normen mit **Spektralradius**

Verträglichkeit von Normen

Def.: Verträgliche Norm

Eine Matrixnorm $\| \cdot \|$ ist **verträglich** mit einer Vektornorm $\| \cdot \|_V$, wenn:

$$\| \mathbf{A} \mathbf{x} \|_V \leq \| \mathbf{A} \| \cdot \| \mathbf{x} \|_V$$

Verträglichkeiten:

1. **Jede submultiplikative Norm** ist mit sich selbst verträglich
2. **Jede Operatornorm** ist mit ihrer induzierenden Vektornorm verträglich
3. **Frobenius-Norm** ist mit der euklidischen Norm verträglich

Anwendung:

Verträglichkeit ermöglicht **Fehlerabschätzungen**: Wenn $\| \mathbf{e} \|_V$ klein ist, dann ist auch $\| \mathbf{A} \mathbf{e} \|_V$ kontrolliert.

Matrixnormen und Konditionierung

Konditionszahl einer (invertierbaren) Matrix:

$$\kappa(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$$

Für Spektralnorm:

$$\kappa_2(\mathbf{A}) = \|\mathbf{A}\|_2 \cdot \|\mathbf{A}^{-1}\|_2 = \frac{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})^{1/2}}{\lambda_{\min}(\mathbf{A}^\top \mathbf{A})^{1/2}}$$

Interpretation:

- $\kappa \approx 1$: Gut konditioniert
- $\kappa \gg 1$: Schlecht konditioniert
- $\kappa = \infty$: Singulär

Verbindung zu *Spektralzerlegung* / **SVD**: Konditionierung wird durch das Verhältnis von größtem zu kleinstem Singulärwert bestimmt!

Normen in der Fehleranalyse

Rückwärts-Fehleranalyse:

Problem:

Löse $\mathbf{A}\mathbf{x} = \mathbf{b}$, erhalte $\tilde{\mathbf{x}}$

Frage:

Für welches gestörte Problem ist $\tilde{\mathbf{x}}$ die exakte Lösung?

Antwort:

$(\mathbf{A} + \Delta\mathbf{A})\tilde{\mathbf{x}} = \mathbf{b}$ mit $\Delta\mathbf{A} = -\mathbf{r}\tilde{\mathbf{x}}^\top / \|\tilde{\mathbf{x}}\|^2$ für $\mathbf{r} = \mathbf{A}\tilde{\mathbf{x}} - \mathbf{b}$

Fehlerabschätzung:

$$\frac{\|\Delta\mathbf{A}\|_2}{\|\mathbf{A}\|_2} = \frac{\|\mathbf{r}\|_2}{\|\mathbf{A}\|_2 \cdot \|\tilde{\mathbf{x}}\|_2}$$

Interpretation:

Normen quantifizieren die **relative Störung** des Problems!

Zusammenfassung

Zusammenfassung

- **Spur:**

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii} = \sum_{i=1}^n \lambda_i$$

linear, zyklisch ($\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$), ähnlichkeitsinvariant

- **Drei Familien von Matrixnormen:**

1. *Element-weise Normen* ($\|\mathbf{A}\|_F, \|\mathbf{A}\|_S, \|\mathbf{A}\|_M$): einfach zu berechnen, verlieren aber die Transformationsinterpretation
2. *Operatornormen* ($\|\mathbf{A}\|_1, \|\mathbf{A}\|_2, \|\mathbf{A}\|_\infty$): messen maximale Streckung, **submultiplikativ**, **verträglich**
3. *Schatten-Normen* ($\|\mathbf{A}\|_{S,p}$): basieren auf Eigen-/Singulärwerten, **unitär invariant**

- **Verbindungen:**

- **Frobenius-Norm** ist element-weise Norm **und** Schatten-Norm:

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^\top \mathbf{A})} = \sqrt{\sum_i \lambda_i} = \|\mathbf{A}\|_{S,2}$$

- **Spektralnrm** $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$ verbindet Operatornormen mit Spektralzerlegung / **SVD**
- **Konditionszahl**: $\kappa(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$

Self-Check

Quiz - Trace Eigenschaften

Welche Aussagen sind korrekt?

1. $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{A}) \cdot \text{tr}(\mathbf{B})$
2. $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$
3. $\text{tr}(\mathbf{A}^\top) = -\text{tr}(\mathbf{A})$
4. $\text{tr}(\mathbf{I}_n) = n$
5. Wenn $\mathbf{A}$ invertierbar ist, dann $\text{tr}(\mathbf{A}^{-1}) = 1/\text{tr}(\mathbf{A})$

Quiz - Normen berechnen

Gegeben: $A = \begin{pmatrix} 1 & 2 \\ 3 & 0 \end{pmatrix}$

Berechne:

1. $\|A\|_1$ (Spaltensummennorm)
2. $\|A\|_\infty$ (Zeilensummennorm)
3. $\|A\|_F$ (Frobenius-Norm)

Anhang

Beweisskizze: Spur als Summe der Eigenwerte

Beweisskizze: (für diagonalisierbare $\mathbf{A}$)

Sei $\mathbf{A} = \mathbf{P}\mathbf{D}\mathbf{P}^{-1}$ eine Diagonalisierung, also $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_n)$

$$\implies \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{P}\mathbf{D}\mathbf{P}^{-1}) \stackrel{(4)}{=} \text{tr}(\mathbf{D}) = \sum_{i=1}^n \lambda_i$$

($\mathbf{P}, \mathbf{P}^{-1}$ heben sich per Ähnlichkeitsinvarianz (4) weg.)

Beweis für allgemeine $\mathbf{A}$ über charakteristisches Polynom.

↔ zurück: „Spur und Eigenwerte“

Beweis: Spektralnorm und Spektralzerlegung

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang r und Spektralzerlegung $\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top$, wobei $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_r, 0, \dots, 0)$ mit $\lambda_1 \geq \dots \geq \lambda_r > 0$.

Beweis (Skizze):

$$\|\mathbf{A}\mathbf{x}\|_2^2 = \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{x}^\top \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top \mathbf{x} = \|\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x}\|_2^2$$

Weil $\mathbf{P}$ *orthogonal* ist, durchläuft $\mathbf{P}^\top \mathbf{x}$ die Einheitssphäre wenn $\mathbf{x}$ dies tut, also

$$\max_{\|\mathbf{x}\|_2=1} \|\mathbf{\Lambda}^{1/2} \mathbf{P}^\top \mathbf{x}\|_2^2 = \max_{\|\mathbf{y}\|_2=1} \|\mathbf{\Lambda}^{1/2} \mathbf{y}\|_2^2 = \lambda_1,$$

$$\text{da } \|\mathbf{\Lambda}^{1/2} \mathbf{y}\|_2^2 = \sum_{i=1}^r \lambda_i y_i^2 \leq \lambda_1 \sum_{i=1}^r y_i^2 \leq \lambda_1,$$

mit Gleichheit für $\mathbf{y} = \mathbf{e}_1$. ■

↔ zurück: „Spektralnorm und Spektralzerlegung“

Gegenbeispiel: Maximumsnorm ist nicht submultiplikativ

Beispiel: $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$

$$\mathbf{A}^2 = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$$

$$\|\mathbf{A}\|_M = 1, \quad \|\mathbf{A}^2\|_M = 2$$

$$\|\mathbf{A}^2\|_M = 2 > 1 = \|\mathbf{A}\|_M \cdot \|\mathbf{A}\|_M$$

Reparatur: Gesamtnorm

$$\|\mathbf{A}\|_G = \sqrt{mn} \|\mathbf{A}\|_M$$

Diese ist submultiplikativ!

↔ zurück: „Submultiplikativität“

Ausblick: Normen in Machine Learning

Ridge Regression (L2-Regularisierung):

$$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_2^2$$

LASSO (L1-Regularisierung):

$$\min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

Nuclear Norm Regularisierung (Matrix Completion):

$$\min_{\mathbf{X}} \|\mathbf{P}_\Omega(\mathbf{X}) - \mathbf{P}_\Omega(\mathbf{M})\|_F^2 + \lambda \|\mathbf{X}\|_*$$

($\mathbf{P}_\Omega$: behält nur die beobachteten Einträge Ω , Rest = 0)

$\implies$ Verschiedene Normen führen zu verschiedenen Lösungscharakteristika!