Numerische Fehleranalyse

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- Algorithmuskonzept
- Komplexitätsanalyse
- Verständnis, dass Algorithmen (meist) *approximative* Lösungen berechnen
- **Lineare Algebra I**
  - Vektor- und Matrixnormen
  - Normeigenschaften: Definitheit, Homogenität, Dreiecksungleichung
  - Matrixoperationen und Matrix-Vektor-Produkte
- **Analysis I**
  - Grenzwerte und Konvergenz
  - Stetigkeit
  - Grundlagen Taylor-Approximation

Fehleranalyse

Fehleranalysis

- Wenn ein Computer etwas speichert/rechnet, macht er Fehler.
- Der *absolute Fehler* ist dabei

$$\text{absoluter Fehler} = \text{fehlerhafter Wert} - \text{tatsächlicher Wert}.$$

- Es ist üblicher, Fehler *relativ* zu betrachten:

$$\text{relativer Fehler} = \frac{\text{fehlerhafter Wert} - \text{tatsächlicher Wert}}{\text{tatsächlicher Wert}}$$

  - Vorteil: Keine Einheiten, Fehler in %.
  - Nachteil: tatsächlicher Wert kann nicht 0 sein.
- Es gilt dann

$$\text{fehlerhafter Wert} = \text{tatsächlicher Wert} \times (1 + \text{relativer Fehler})$$

Fehlermaß

Def.: Fehlermaß

Sei V ein Vektorraum mit (Semi-)Norm $\|\cdot\|$ und $\widetilde{\boldsymbol{v}} \in V$ eine Approximation zu $\boldsymbol{v} \in V$. Dann ist

- der **absolute Fehler**

$$\boldsymbol{\Delta}_{\boldsymbol{v}} = \widetilde{\boldsymbol{v}} - \boldsymbol{v},$$

- der **relative Fehler** (nur definiert falls $\|\boldsymbol{v}\| > 0$)

$$\delta_{\boldsymbol{v}} = \frac{\|\widetilde{\boldsymbol{v}} - \boldsymbol{v}\|}{\|\boldsymbol{v}\|} = \frac{\|\boldsymbol{\Delta}_{\boldsymbol{v}}\|}{\|\boldsymbol{v}\|}.$$

- Ist $\|\boldsymbol{\Delta}_{\boldsymbol{v}}\| \leq \varepsilon$ bzw. $\delta_{\boldsymbol{v}} \leq \varepsilon$, dann nennen wir ε eine absolute bzw. relative *Fehlerschranke*.

Fehlermaß

Lemma: Fehlerschranken

Es gilt

$$\|\boldsymbol{z}\|(1-\delta_z) \leq \|\widetilde{\boldsymbol{z}}\| \leq \|\boldsymbol{z}\|(1+\delta_z).$$

Beweis:

$$\begin{aligned}
\delta_z &= \frac{\|\widetilde{\boldsymbol{z}} - \boldsymbol{z}\|}{\|\boldsymbol{z}\|} \\
\|\widetilde{\boldsymbol{z}} - \boldsymbol{z}\| &= \delta_z \|\boldsymbol{z}\| \\
|\|\widetilde{\boldsymbol{z}}\| - \|\boldsymbol{z}\|| &\leq \delta_z \|\boldsymbol{z}\| && \text{[umgekehrte Dreiecksungl.]} \\
-\delta_z \|\boldsymbol{z}\| \leq \|\widetilde{\boldsymbol{z}}\| - \|\boldsymbol{z}\| &\leq \delta_z \|\boldsymbol{z}\| && \text{[Definition von Betrag]} \\
\|\boldsymbol{z}\| - \delta_z \|\boldsymbol{z}\| \leq \|\widetilde{\boldsymbol{z}}\| &\leq \|\boldsymbol{z}\| + \delta_z \|\boldsymbol{z}\|. && \blacksquare
\end{aligned}$$

Beispiel: Fehlermaße für Vektoren

Sei $\boldsymbol{v} = \begin{pmatrix} 3 \\ 4 \end{pmatrix}$ und $\widetilde{\boldsymbol{v}} = \begin{pmatrix} 3.2 \\ 4.3 \end{pmatrix}$ mit der Euklidischen Norm $\|\cdot\|_2$.

- **Absoluter Fehler:**

$$\boldsymbol{\Delta}_v = \widetilde{\boldsymbol{v}} - \boldsymbol{v} = \begin{pmatrix} 3.2 \\ 4.3 \end{pmatrix} - \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.3 \end{pmatrix}$$

- **Norm des absoluten Fehlers:**

$$\|\boldsymbol{\Delta}_v\|_2 = \sqrt{0.2^2 + 0.3^2} = \sqrt{0.04 + 0.09} = \sqrt{0.13} \approx 0.361$$

- **Relativer Fehler:**

$$\delta_v = \frac{\|\boldsymbol{\Delta}_v\|_2}{\|\boldsymbol{v}\|_2} = \frac{\sqrt{0.13}}{\sqrt{3^2 + 4^2}} = \frac{\sqrt{0.13}}{5} \approx \frac{0.361}{5} \approx 0.072 = 7.2\%$$

- **Fehlerschranke:** Mit $\varepsilon = 0.1$ gilt $\delta_v \approx 0.072 < 0.1$, also ist $\varepsilon = 0.1$ eine relative Fehlerschranke.

Fehlerzerlegung

- Sei
  - f ein Problem mit idealem Input $\boldsymbol{x}$
  - $\widetilde{f}$ ein zugehöriger Algorithmus
  - und $\widetilde{\boldsymbol{x}}$ der tatsächliche Input.
- Ein Algorithmus folgt dem Schema:
  - Input $\widetilde{\boldsymbol{x}} \longrightarrow$ Algorithmus $\widetilde{f} \longrightarrow$ Ergebnis $\widetilde{f}(\widetilde{\boldsymbol{x}})$
- Ein Fehler im Ergebnis $\widetilde{f}(\widetilde{\boldsymbol{x}}) \neq f(\boldsymbol{x})$ kann entstehen durch
  - Fehler im Input $\widetilde{\boldsymbol{x}}$ (durch Messen/Speichern von $\boldsymbol{x}$)
    - unvermeidbar
  - Fehler im Algorithmus $\widetilde{f}$ (durch Rundung/Approximation)
    - können wir beeinflussen

Fehlerzerlegung

$$
\begin{aligned}
\text{Gesamtfehler} &= \widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x}) \\
&= \underbrace{\widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\widetilde{\boldsymbol{x}})}_{\substack{\text{Fehler im Algorithmus} \\ \text{(Maschinenarithmetik)}}} + \underbrace{f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})}_{\substack{\text{Folgefehler aus Input} \\ \text{(exakte Arithmetik)}}}
\end{aligned}
$$

- Erster Term misst nur den Fehler des Algorithmus (bei gegebenem/fixen Input), nicht den Inputfehler.

  Ist er "klein", nennen wir den Algorithmus $\widetilde{f}$ **stabil**.
- Zweiter Term hängt nicht vom Algorithmus $\widetilde{f}$ ab.
  Ist er "klein", nennen wir das Problem f an der Stelle $\boldsymbol{x}$ **gut konditioniert**.

Beispiel: Fehlerzerlegung

- Es gilt $e^x := \sum_{n=0}^{\infty} \frac{x^n}{n!}$
- Angenommen, wir wollen $f(\pi) = e^\pi$ berechnen und verwenden dazu die Approximationen $\widetilde{\pi} = 3$ und $\widetilde{f}(x) = \sum_{n=0}^{2} x^n/n!$

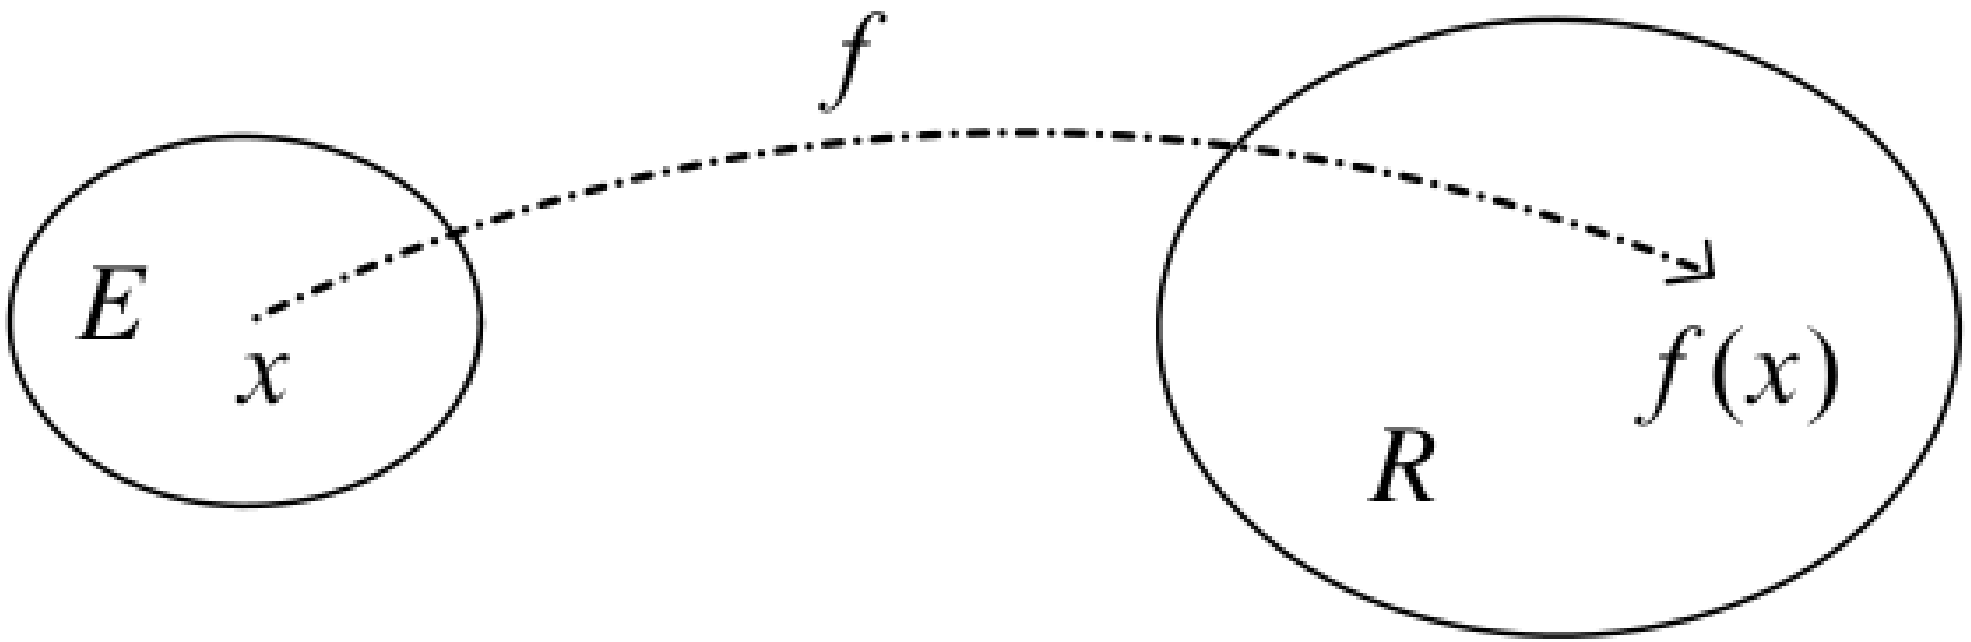
Zerlege den Gesamtfehler in die zwei erwähnten Teile.

Lösung:

$$
\begin{aligned}
\widetilde{f}(3) - f(\pi) &= \big[\widetilde{f}(3) - f(3)\big] + \big[f(3) - f(\pi)\big] \\
&= \text{Fehler im Algorithmus} + \text{Folgefehler aus Input} \\
&= \left[-\sum_{n=3}^{\infty} 3^n/n!\right] + \left[e^3 - e^\pi\right] \\
&\approx \left[\left(1 + \tfrac{3}{1} + \tfrac{9}{2}\right) - e^3\right] + [20.1 - 23.1] \\
&\approx [-11.6] + [-3]
\end{aligned}
$$

Kondition

Kondition



- Inputfehler betrachten wir als *unvermeidbar.*
- Manche Probleme sind schwer zu lösen, weil sie *zu sensitiv bzgl. des Inputs* sind:
  $\rightarrow$ Outputmenge $R = f(E)$ ist *groß* gegenüber der Menge fehlerhafter Inputs
  $E = \left\{ \widetilde{\boldsymbol{x}} \colon \frac{\|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \delta \right\}$.
- Wir nennen das Problem dann **schlecht konditioniert**.

Kondition: Beispiel

Beispiel:

- Sei $f(x) = x^{-1}$
- Sei $x = 10^{-17}, \widetilde{x} = x + \varepsilon$ mit $\varepsilon \in (-10^{-17}, 10^{-17})$.
- $\implies f(\widetilde{x}) \in (1/2 \cdot 10^{17}, \infty)$ und

$$\left| \frac{f(\widetilde{x}) - f(x)}{f(x)} \right| \in [0, \infty).$$

Achtung:
Die Störung ist hier *relativ zu* x nicht klein (bis zu 100%).
Bei relativ *kleinen* Störungen ist $x \mapsto 1/x$ dagegen harmlos: der relative Outputfehler ist dann ungefähr so groß wie der relative Inputfehler.
Es kommt also darauf an, *welche* Art von Inputfehler unvermeidbar ist.

Kondition

- Im Folgenden betrachten wir Abbildungen $f\colon \mathbb{R}^n \to \mathbb{R}^m$.
- $\|\cdot\|$ bezeichnet dabei eine beliebige Vektornorm (bzw. die dadurch induzierte *Operatornorm* für Matrizen).

Def.: Konditionszahl

Sei f ein Problem mit Input $\boldsymbol{x}$.

- Die **absolute Konditionszahl** ist die kleinste Zahl $\kappa_{abs} = \kappa_{abs}(f, \boldsymbol{x})$ mit

$$\|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})\| \leq \kappa_{abs} \|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|, \quad \text{für } \widetilde{\boldsymbol{x}} \to \boldsymbol{x}.$$

- Die **relative Konditionszahl** (für $\|\boldsymbol{x}\| > 0, \|f(\boldsymbol{x})\| > 0$) ist die kleinste Zahl $\kappa_{rel} = \kappa_{rel}(f, \boldsymbol{x})$ mit

$$\frac{\|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})\|}{\|f(\boldsymbol{x})\|} \leq \kappa_{rel} \frac{\|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|}{\|\boldsymbol{x}\|}, \quad \text{für } \widetilde{\boldsymbol{x}} \to \boldsymbol{x}.$$

Interpretation

$$\|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})\| \leq \kappa_{abs} \|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|, \qquad \frac{\|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})\|}{\|f(\boldsymbol{x})\|} \leq \kappa_{rel} \frac{\|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|}{\|\boldsymbol{x}\|}.$$

- *gut konditioniert* ($\kappa \lesssim 1$):
  Inputfehler führt zu ähnlich großem oder kleinerem Outputfehler.
- *schlecht konditioniert* ($\kappa \gg 1$):
  Inputfehler können zu viel größeren Outputfehlern führen.
- *schlecht gestellt* ($\kappa = \infty$):
  Der Fehlerverstärkungsfaktor ist unbeschränkt — beliebig kleine Inputfehler können (relativ zu ihrer Größe) beliebig stark verstärkt werden.

Beispiel

- Sei $f(\boldsymbol{x}) = \boldsymbol{A}^{-1}\boldsymbol{x} = \boldsymbol{y}$.
- Absolute Konditionszahl:

$$\|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})\| = \|\boldsymbol{A}^{-1}(\widetilde{\boldsymbol{x}} - \boldsymbol{x})\| \leq \|\boldsymbol{A}^{-1}\|\,\|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|$$
$$\Longrightarrow \quad \kappa_{abs} = \|\boldsymbol{A}^{-1}\|$$

- Relative Konditionszahl: Sei $\boldsymbol{h} = \widetilde{\boldsymbol{x}} - \boldsymbol{x}$, dann

$$\frac{\|\boldsymbol{A}^{-1}\boldsymbol{h}\| \,/\, \|\boldsymbol{A}^{-1}\boldsymbol{x}\|}{\|\boldsymbol{h}\| \,/\, \|\boldsymbol{x}\|} = \underbrace{\frac{\|\boldsymbol{A}^{-1}\boldsymbol{h}\|}{\|\boldsymbol{h}\|}}_{\leq \|\boldsymbol{A}^{-1}\|} \cdot \frac{\|\boldsymbol{x}\|}{\|\boldsymbol{A}^{-1}\boldsymbol{x}\|}$$

$$\Longrightarrow \qquad \kappa_{rel} = \|\boldsymbol{A}^{-1}\| \frac{\|\boldsymbol{x}\|}{\|\boldsymbol{A}^{-1}\boldsymbol{x}\|} = \kappa_{abs} \frac{\|\boldsymbol{A}\boldsymbol{y}\|}{\|\boldsymbol{y}\|} \leq \kappa_{abs}\|\boldsymbol{A}\| = \|\boldsymbol{A}^{-1}\|\|\boldsymbol{A}\|$$

  (Gleichheit im ersten Faktor, weil $\boldsymbol{h}$ entlang einer die Operatornorm maximierenden Richtung gewählt werden darf.)
- $\kappa(\boldsymbol{A}) = \|\boldsymbol{A}^{-1}\|\|\boldsymbol{A}\|$ wird in der linearen Algebra auch *Konditionszahl von $\boldsymbol{A}$* genannt — sie ist die von $\boldsymbol{x}$ unabhängige *obere Schranke* für κ_{rel}, nicht κ_{rel} selbst.
- Für die Operatornorm $\|\cdot\|_2$ (*Spektralnorm*) gilt

$$\kappa_2(\boldsymbol{A}) = \frac{\sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}}{\sqrt{\lambda_{\min}(\boldsymbol{A}^\top \boldsymbol{A})}}.$$

Quiz

Sei

$$\boldsymbol{A} = \begin{pmatrix} 2 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 0.1 \end{pmatrix}.$$

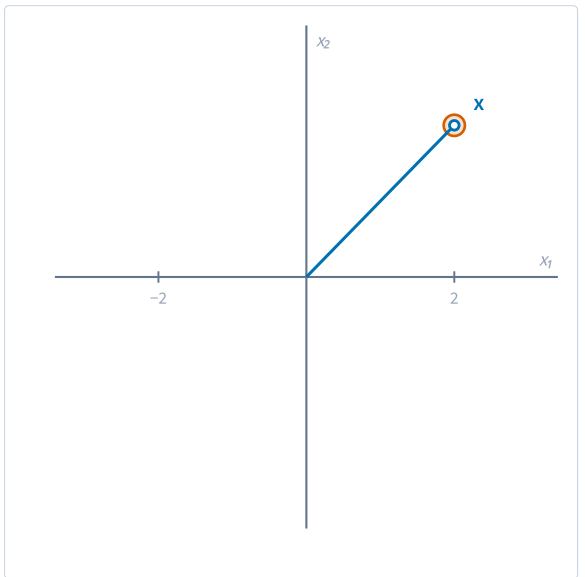
Was ist die Konditionszahl der Matrix bezüglich der 2-Norm?

1. 2
2. 20
3. 5
4. 50

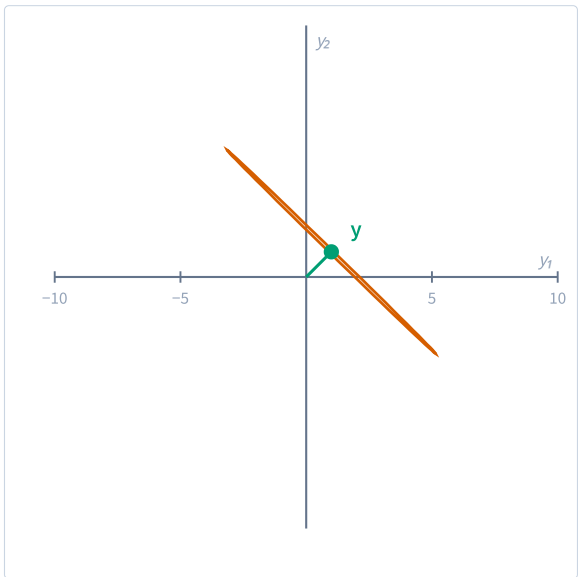
Interaktive Demo: Kondition

▸ *Ziehen wir \(\bx\) im linken Feld im Kreis herum und beobachten, wie sich die rote Ellipse rechts dabei streckt und staucht.*

Inputebene: rechte Seite \(\bx\) und die plausiblen Inputs



Lösungsebene: \(\by = \bA^{-1}\bx\) und das Bild des Kreises



Drehung (κ = 1) | mäßig gedehnt | **schlecht konditioniert** | fast singulär

x₁ 2,00

x₂ 2,05

rel. Inputfehler 5,0 %

rel. Inputfehler 5,0 %

rel. Outputfehler 410 %

`A = (1,00 1,00; 1,00 1,05)`

`y = A⁻¹x = (1,00; 1,00)`

`Schranke κ(A) = σ_max/σ_min = 82,04 · ausgeschöpft zu 100 %`

`σ_max = 2,025, σ_min = 0,0247`

`κ_rel(f, x) = 82,03`

✗ **Die ungünstige rechte Seite.** \(\kappa_{rel}(f, \bx)\) = 82,0 schöpft 100 % der Schranke \(\kappa(\bA)\) = 82,0 aus. Bemerkung 4.2.7 sagt genau das: Die Schranke ist kein Pessimismus, sie wird für ungünstige rechte Seiten angenommen. Aus 5,0 % Inputfehler werden hier 410 % Outputfehler.

Aufgabe

Sei $f(\boldsymbol{x}) = x_1 + x_2 = \binom{1}{1}^\top \boldsymbol{x} = \mathbf{1}^\top \boldsymbol{x}$.

1. Was sind die Konditionszahlen?
2. Für welche $\boldsymbol{x}$ ist das Problem schlecht konditioniert?

Lösung:

- Bezüglich der euklidischen Norm gilt (Cauchy-Schwarz)

$$|f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})| = |\mathbf{1}^\top(\widetilde{\boldsymbol{x}} - \boldsymbol{x})| \leq \|\mathbf{1}\|_2 \|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|_2 = \sqrt{2}\|\widetilde{\boldsymbol{x}} - \boldsymbol{x}\|_2,$$

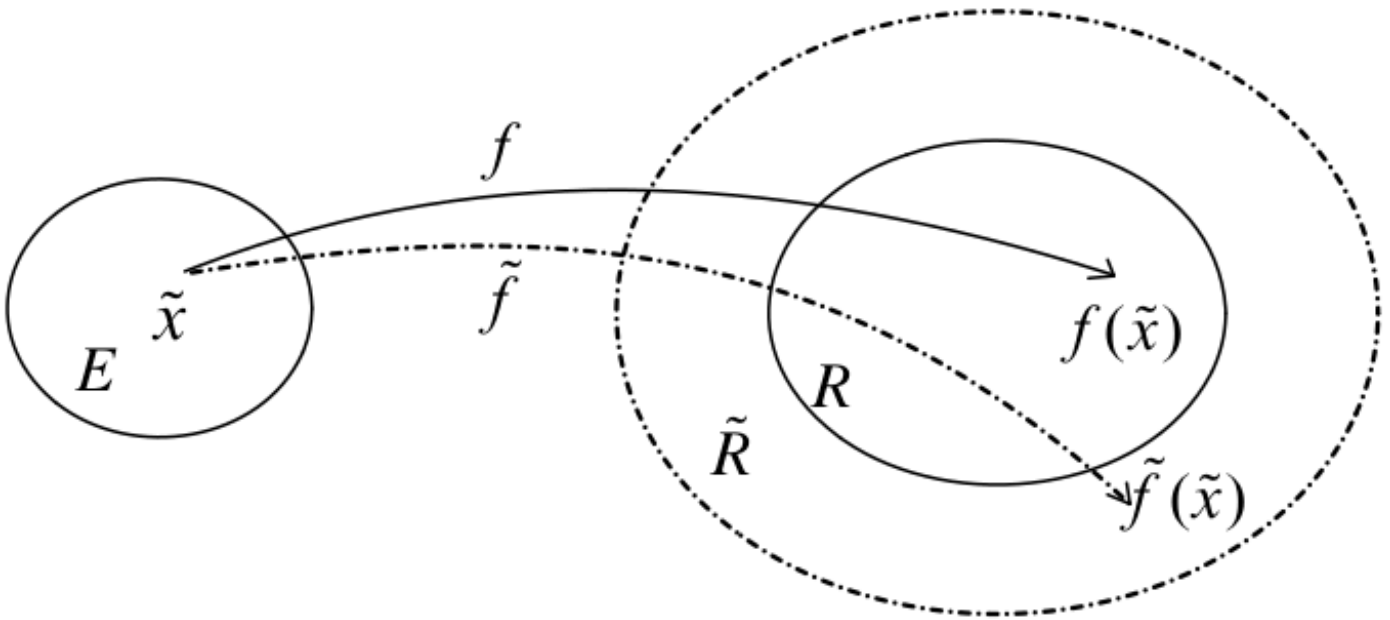
  mit Gleichheit falls $(\widetilde{\boldsymbol{x}} - \boldsymbol{x}) \parallel \mathbf{1}$, deshalb $\kappa_{abs} = \sqrt{2}$ und

$$\kappa_{rel} = \kappa_{abs} \frac{\|\boldsymbol{x}\|_2}{|x_1 + x_2|} = \sqrt{2} \frac{\|\boldsymbol{x}\|_2}{|x_1 + x_2|}.$$

- Für $0 < |x_1 + x_2| \ll \|\boldsymbol{x}\|_2$ ist $\kappa_{rel} \gg 1$ und das Problem somit schlecht konditioniert

Stabilität von Algorithmen

Stabilität



$$\begin{aligned}\text{Gesamtfehler} &= \widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x}) \\ &= \underbrace{\widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\widetilde{\boldsymbol{x}})}_{\text{Fehler im Algorithmus}} + \underbrace{f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x})}_{\text{Folgefehler aus Input}}\end{aligned}$$

- Analog zur Kondition können wir auch den algorithmischen Fehler $\widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\widetilde{\boldsymbol{x}})$ untersuchen.
- Ist er “klein”, nennen wir $\widetilde{f}$ **stabil**.

Beispiel: Stochastic Gradient Descent

Optimierung der Verlustfunktion $L(\theta)$ mit $\theta_{k+1} = \theta_k - \alpha\hat{\nabla}L(\theta_k)$

Stabiler Algorithmus:

- Kleine Lernrate α (z.B. 0.001)
- (Numerische) Fehler akkumulieren langsam
- $\rightarrow$ Konvergiert zuverlässig zu einem Optimum

Instabiler Algorithmus:

- Zu große Lernrate α (z.B. 1.0)
- Verstärkt Rundung-/Schätzfehler des Gradienten $\hat{\nabla}L(\theta_k)$
- $\rightarrow$ Oszilliert oder divergiert

Das ist eine *Analogie* zum Konzept der *Stabilität* — hier mischen sich numerische Fehler und die Konvergenzdynamik des Verfahrens:

- Problem f: Finde Minimum von $L(\theta)$
- Algorithmus $\widetilde{f}$: Stochastic Gradient Descent mit endlicher Präzision
- Algorithmischer Fehler: Akkumuliert Rundung-/Schätzfehler über k

Stabilität: Wichtigste Erkenntnis

Theorem: Stabilität zusammengesetzter Algorithmen

Sei f ein Problem mit Input $\boldsymbol{x}$, wobei $f(\boldsymbol{x}) = (h \circ g)(\boldsymbol{x})$ für zwei Teilprobleme g und h. Dann gilt für einen Algorithmus $\widetilde{f} = \widetilde{h} \circ \tilde{g}$:

$$\frac{\|\widetilde{f}(\boldsymbol{x}) - f(\boldsymbol{x})\|}{\|f(\boldsymbol{x})\|} \leq \frac{\|\widetilde{h}(\widetilde{\boldsymbol{y}}) - h(\widetilde{\boldsymbol{y}})\|}{\|h(\boldsymbol{y})\|} + \kappa_{rel}(h, g(\boldsymbol{x})) \frac{\|\tilde{g}(\boldsymbol{x}) - g(\boldsymbol{x})\|}{\|g(\boldsymbol{x})\|},$$

wobei $\boldsymbol{y} = g(\boldsymbol{x})$, $\widetilde{\boldsymbol{y}} = \tilde{g}(\boldsymbol{x})$.

- Ein schlecht konditioniertes Teilproblem h (an der Stelle $\boldsymbol{y} = g(\boldsymbol{x})$) verstärkt Fehler in $\tilde{g}$, wäre also ein *Indiz* für die Instabilität von $\widetilde{f}$.
- Deshalb sollten wir **schlecht konditionierte Schritte immer so früh wie möglich** im Algorithmus ausführen.

Stabilität: Wichtigste Erkenntnis

Beweis:

$$
\begin{aligned}
\frac{\|\widetilde{f}(\boldsymbol{x}) - f(\boldsymbol{x})\|}{\|f(\boldsymbol{x})\|} &= \frac{\|\widetilde{h}(\tilde{g}(\boldsymbol{x})) - h(g(\boldsymbol{x}))\|}{\|h(g(\boldsymbol{x}))\|} \\
&= \frac{\|\widetilde{h}(\tilde{g}(\boldsymbol{x})) - h(\tilde{g}(\boldsymbol{x})) + h(\tilde{g}(\boldsymbol{x})) - h(g(\boldsymbol{x}))\|}{\|h(g(\boldsymbol{x}))\|} \\
&\leq \frac{\|\widetilde{h}(\tilde{g}(\boldsymbol{x})) - h(\tilde{g}(\boldsymbol{x}))\|}{\|h(g(\boldsymbol{x}))\|} + \frac{\|h(\tilde{g}(\boldsymbol{x})) - h(g(\boldsymbol{x}))\|}{\|h(g(\boldsymbol{x}))\|} \\
&\leq \frac{\|\widetilde{h}(\widetilde{\boldsymbol{y}}) - h(\widetilde{\boldsymbol{y}})\|}{\|h(\boldsymbol{y})\|} + \kappa_{rel}(h, g(\boldsymbol{x})) \frac{\|\tilde{g}(\boldsymbol{x}) - g(\boldsymbol{x})\|}{\|g(\boldsymbol{x})\|}.
\end{aligned}
$$

Fehler von $\widetilde{h}$ selbst + durch h verstärkter Fehler von $\tilde{g}$ –

Idee: Einfügen von $0 = -h(\tilde{g}(\boldsymbol{x})) + h(\tilde{g}(\boldsymbol{x}))$, dann Dreiecksungleichung.

Beispiel: Stabilität der Varianz

Problem: Berechne Stichprobenvarianz

$$f(\boldsymbol{x}) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2.$$

Algorithmen:

$$\widetilde{f}_1(\boldsymbol{x}) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2, \quad \widetilde{f}_2(\boldsymbol{x}) = \left(\frac{1}{n}\sum_{i=1}^{n}x_i^2\right) - \overline{x}^2$$

- Bei $\widetilde{f}_2$ berechnen wir zum Schluss die Differenz $h(a,b) = a - b$ mit

$$a = \frac{1}{n}\sum_{i=1}^{n}x_i^2 \quad \text{und} \quad b = \overline{x}^2.$$

Beispiel: Stabilität der Varianz

- Die Konditionszahl ist dabei

$$\kappa_{rel}(h, (a, b)) = \sqrt{2} \frac{\sqrt{a^2 + b^2}}{|a - b|}.$$

- Falls a, b groß sind, aber $a \approx b$ gilt, ist $\kappa_{rel}(h, (a, b))$ groß.
- In diesem Fall kann h also vorangegangene Fehler massiv verstärken!

```
1  set.seed(5)
2  x <- rnorm(10^3, mean = 0, sd = 1) + 10^10
3  mean((x - mean(x))^2)
```

```
[1] 1.02
```

```
1  mean(x^2) - mean(x)^2
```

```
[1] 16384
```

Übersicht

- *Absoluter Fehler*: $\boldsymbol{\Delta}_{\boldsymbol{v}} = \widetilde{\boldsymbol{v}} - \boldsymbol{v}$
- *Relativer Fehler*: $\delta_{\boldsymbol{v}} = \frac{\|\widetilde{\boldsymbol{v}} - \boldsymbol{v}\|}{\|\boldsymbol{v}\|}$
- *Fehlerzerlegung*:
  Gesamtfehler = *algorithmische Fehler* $(\widetilde{f}(\widetilde{\boldsymbol{x}}) - f(\widetilde{\boldsymbol{x}}))$ + *Input-Folgefehler* $(f(\widetilde{\boldsymbol{x}}) - f(\boldsymbol{x}))$
- *Kondition*: Sensitivität eines Problems bzgl. *Inputfehlern*
- *Konditionszahlen*: Absolut und relativ $(\kappa_{abs}, \kappa_{rel})$
- *Konditionszahl einer Matrix*: $\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\|\|\boldsymbol{A}^{-1}\|$
- *Stabilität*:
  Ein Algorithmus ist stabil, wenn der *algorithmische Fehler* klein ist.
- *Stabilität zusammengesetzter Algorithmen*:
  Fehlerfortpflanzung über Algorithmus-Teilschritte

Wrap-up

Heute gelernt

- Die *Kondition* eines Problems beschreibt dessen **Sensitivität** bzgl. Inputfehlern.
- Die *Stabilität* eines Algorithmus beschreibt dessen **Robustheit** bzgl. Fehler.
- **Schlecht konditionierte Teilschritte möglichst früh ausführen!**

Nächste Vorlesung

- Numerische Lösung von linearen Gleichungssystemen (LGS)