

Singulärwertzerlegung (SVD)

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- **Matrixnormen** und ihre Eigenschaften, speziell:
 - **Spektralnorm** $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$
 - **Orthogonalmatrizen** $\mathbf{Q}$ mit $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$
- Matrixzerlegungskonzepte
- **Lineare Algebra**
 - Eigenwerte und Eigenvektoren: $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$
 - Rang einer Matrix
 - Fundamentale Unterräume: $\text{col}(\mathbf{A})$, $\text{ker}(\mathbf{A})$, $\text{col}(\mathbf{A}^\top)$
 - Projektionen auf Unterräume

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ symmetrisch ($\mathbf{A} = \mathbf{A}^\top$). Welche Aussage gilt **immer**?

1. Alle Eigenwerte von $\mathbf{A}$ sind ≥ 0 .
2. $\mathbf{A}$ ist orthogonal diagonalisierbar: $\mathbf{A} = \mathbf{Q}\mathbf{D}\mathbf{Q}^\top$ mit reellen Eigenwerten.
3. $\mathbf{A}$ ist invertierbar.
4. $\mathbf{A}$ hat n verschiedene Eigenwerte.

Frage 2: Was ist der Rang von $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$?

1. 0
2. 1
3. 2
4. 3

Motivation

Diagonalisierung ist limitiert

- Eigenwertzerlegung funktioniert nur für **quadratische** Matrizen – und auch dort nicht immer:
 $\begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ hat nur den Eigenwert 0 mit eindimensionalem Eigenraum, also keine Eigenvektorbasis
- Orthogonale Diagonalisierung bisher nur für **symmetrische** Matrizen
- **Problem:**
Die meisten Matrizen sind weder quadratisch noch symmetrisch.

Was wir wollen: Eine Zerlegung $A = PDQ^{-1}$


- für *beliebige* $m \times n$ Matrizen, so dass
- D “diagonal” ist und
- P und Q **Orthogonalmatrizen** sind

Geometrische Intuition

Die Einheitssphäre als Testfall:

- Betrachte alle Vektoren $\mathbf{x}$ mit $\|\mathbf{x}\| = 1$
- Nach Transformation: $\mathbf{A}\mathbf{x}$ hat verschiedene Längen
- **Frage:** Welche Richtung $\mathbf{A}\mathbf{x}$ wurde am stärksten (zweitstärksten, drittstärksten, ...) gestreckt?

Beispiel: $\mathbf{A} \in \mathbb{R}^{2 \times 3}$



- Einheitssphäre in $\mathbb{R}^3 \rightarrow$ ausgefüllte Ellipse in $\mathbb{R}^2$; stärkste Streckung: Hauptachse, zweitstärkste: Nebenachse; Richtungen in $\ker(\mathbf{A})$ werden auf $\mathbf{0}$ gestaucht

► Interaktive Visualisierung im Skript

Die Grundidee

Maximierungsproblem:

$$\max_{\|x\|=1} \|Ax\|$$

Trick: Maximiere $\|Ax\|^2$ statt $\|Ax\|$

$$\|Ax\|^2 = (Ax)^\top (Ax) = x^\top (A^\top A)x$$

Erkenntnis: Dies ist eine quadratische Form bezüglich $A^\top A$!

Im Folgenden immer: $\|\cdot\| \equiv \|\cdot\|_2$!

SVD: Singulärwerte und Singulärvektoren

Die Matrix $\mathbf{A}^\top \mathbf{A}$

Theorem: Eigenschaften von $\mathbf{A}^\top \mathbf{A}$

Für $\mathbf{A} \in \mathbb{R}^{m \times n}$ gilt:

1. $\mathbf{A}^\top \mathbf{A}$ ist symmetrisch: $(\mathbf{A}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{A}$
2. $\mathbf{A}^\top \mathbf{A}$ ist positiv semidefinit: $\mathbf{x}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{x} \geq 0$ für alle $\mathbf{x} \in \mathbb{R}^n$; insbesondere sind alle Eigenwerte $\lambda_i \geq 0$

Beweis für (2): $\mathbf{x}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{x} = \|\mathbf{Ax}\|_2^2 \geq 0$; für jeden normierten Eigenvektor $\mathbf{v}_i$ ($\|\mathbf{v}_i\| = 1$) gilt damit:

$$0 \leq \|\mathbf{Av}_i\|_2^2 = \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_i = \mathbf{v}_i^\top (\lambda_i \mathbf{v}_i) = \lambda_i$$

Folgerung: $\mathbf{A}^\top \mathbf{A}$ ist orthogonal diagonalisierbar!

Bsp: Eigenschaften von $\mathbf{A}^\top \mathbf{A}$

Sei $\mathbf{A} = (\mathbf{a}_1 \quad \mathbf{a}_2) = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$

$$\begin{aligned} \mathbf{A}^\top \mathbf{A} &= \begin{pmatrix} \mathbf{a}_1^\top \\ \mathbf{a}_2^\top \end{pmatrix} (\mathbf{a}_1 \quad \mathbf{a}_2) = \begin{pmatrix} \mathbf{a}_1^\top \mathbf{a}_1 & \mathbf{a}_1^\top \mathbf{a}_2 \\ \mathbf{a}_2^\top \mathbf{a}_1 & \mathbf{a}_2^\top \mathbf{a}_2 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \end{aligned}$$

Symmetrie: ✓

Positiv semidefinit:

$$\det(\mathbf{A}^\top \mathbf{A} - \lambda \mathbf{I}) = (6 - \lambda)(5 - \lambda) - 16 = \lambda^2 - 11\lambda + 14 = 0$$

$$\lambda_{1,2} = \frac{11 \pm \sqrt{11^2 - 4 \cdot 1 \cdot 14}}{2} = \frac{11 \pm \sqrt{65}}{2}$$

$$\implies \lambda_1 \approx 9.53, \quad \lambda_2 \approx 1.47$$

$\lambda_1, \lambda_2 > 0 \implies \mathbf{A}^\top \mathbf{A}$ hier sogar positiv *definit* – mehr als das vom Theorem garantierte “semidefinit”, da $\mathbf{A}$ vollen Spaltenrang hat ($\text{rang}(\mathbf{A}) = n = 2$)

Definition: Singulärwerte

Seien $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ die Eigenwerte von $\mathbf{A}^\top \mathbf{A}$.

Def.: Singulärwerte

Die **Singulärwerte** von $\mathbf{A}$ sind:

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \dots, n$$

Interpretation:

- $\sigma_1 = \max_{\|x\|=1} \|\mathbf{A}x\|$ (maximale Streckung)
- σ_n entspricht der minimalen Streckung / maximalen Stauchung
- $\sigma_i = 0 \iff \lambda_i = 0$

Bsp: Singulärwerte

Matrix $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}$: $\mathbf{A}^\top \mathbf{A}$ mit $\boldsymbol{\lambda} \approx (9.53, 1.47)$:

Singulärwerte:

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{9.53} \approx 3.09$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{1.47} \approx 1.21$$

Interpretation:

- $\sigma_1 \approx 3.09$: Maximale Streckung der Matrix $\mathbf{A}$ ($\mathbf{v}_1$ wird um Faktor 3.1 gestreckt)
- $\sigma_2 \approx 1.21$: Minimale Streckung ($\mathbf{v}_2$ wird um Faktor 1.2 gestreckt)
- Verhältnis $\frac{\sigma_{\max}}{\sigma_{\min}} \approx 2.55$ zeigt, wie unterschiedlich die Streckung je nach Richtung ist (*anisotrop*).

Definition: Singulärvektoren

Def.: Rechte und linke Singulärvektoren

Rechte Singulärvektoren $\mathbf{v}_i$:

- Normierte Eigenvektoren von $\mathbf{A}^\top \mathbf{A}$
- $\mathbf{A}^\top \mathbf{A} \mathbf{v}_i = \lambda_i \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i$

Linke Singulärvektoren $\mathbf{u}_i$:

- Definiert durch: $\mathbf{u}_i = \frac{\mathbf{A} \mathbf{v}_i}{\sigma_i}$ (für $\sigma_i > 0$)

Wichtige Eigenschaften:

- $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ ist orthonormal
- $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ ist orthonormal ($r = \text{rang}(\mathbf{A})$)

Beweis der Orthonormalität: siehe [Anhang](#)

Bsp: Singulärvektoren

$$\text{Matrix } \mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} : \quad \mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \text{ mit } \boldsymbol{\lambda} \approx (9.53, 1.47):$$

Rechte Singulärvektoren (normierte Eigenvektoren von $\mathbf{A}^\top \mathbf{A}$):

$$\begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \mathbf{v}_1 = 9.53 \mathbf{v}_1 \implies \mathbf{v}_1 \approx \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix}, \quad \mathbf{v}_2 \approx \begin{pmatrix} -0.662 \\ 0.75 \end{pmatrix} \text{ (normiert, orthogonal zu } \mathbf{v}_1)$$

Linke Singulärvektoren ($\mathbf{u}_i = \mathbf{A}\mathbf{v}_i/\sigma_i$), eine Rechnung exemplarisch:

$$\mathbf{u}_1 = \frac{\mathbf{A}\mathbf{v}_1}{\sigma_1} \approx \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix} / 3.09 = \begin{pmatrix} -0.672 \\ -0.7 \\ -0.243 \end{pmatrix}, \quad \text{analog: } \mathbf{u}_2 \approx \begin{pmatrix} 0.691 \\ -0.474 \\ -0.546 \end{pmatrix}$$

Check: $\mathbf{u}_1^\top \mathbf{u}_2 \approx 0$ und $\|\mathbf{u}_1\| \approx 1$ ✓ (vollständige Rechnung: siehe **Anhang**)

Live-Demo: SVD in R

Stimmt unsere Handrechnung? **Vorhersage:** Was liefert `svd(A)`?

```
1 A <- matrix(c(1, 2,  
2               2, 1,  
3               1, 0), nrow = 3, byrow = TRUE)  
4 svd(A)
```

```
$d  
[1] 3.09 1.21
```

```
$u  
      [,1] [,2]  
[1,] -0.672 0.691  
[2,] -0.700 -0.474  
[3,] -0.243 -0.546
```

```
$v  
      [,1] [,2]  
[1,] -0.750 -0.662  
[2,] -0.662 0.750
```

- $d \approx (3.09, 1.21)$: wie von Hand berechnet ✓
- u, v : Singulärvektoren – Vorzeichen nicht eindeutig ($\pm u_i, \pm v_i$ ebenfalls gültig)!

Fundamentale Unterräume

Theorem: Charakterisierung der Unterräume

Angenommen $\mathbf{A}$ hat r Singulärwerte ungleich Null. Dann:

1. $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ ist Orthonormalbasis für $\text{col}(\mathbf{A}^\top)$ (Zeilenraum)
2. $\{\mathbf{A}\mathbf{v}_1, \dots, \mathbf{A}\mathbf{v}_r\}$ ist Orthogonalbasis für $\text{col}(\mathbf{A})$ (Spaltenraum) – normiert ($\|\mathbf{A}\mathbf{v}_i\| = \sigma_i$) sind das die $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$
3. $\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}$ ist Orthonormalbasis für $\ker(\mathbf{A})$ (Nullraum)
4. $\text{rang}(\mathbf{A}) = r$

Interpretation: SVD gibt uns explizite Orthonormalbasen für alle Fundamentalräume! (für den linken Nullraum $\ker(\mathbf{A}^\top)$: erweiterte $\mathbf{u}_{r+1}, \dots, \mathbf{u}_m \rightarrow$ SVD-Hauptsatz & Beispiel)

Rechenbeispiel: Fundamentale Unterräume (1)

Für $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$ mit $\mathbf{A}^\top \mathbf{A} = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$ und $\text{rang}(\mathbf{A}) = 1$:

- **Singulärwerte:**

$$\lambda_1(\mathbf{A}^\top \mathbf{A}) = 4, \lambda_2(\mathbf{A}^\top \mathbf{A}) = 0$$

$\implies \sigma_1(\mathbf{A}) = 2$: Maximale Streckung durch $\mathbf{A}$ um Faktor 2 in Richtung $\mathbf{v}_1$; Faktor 0 in Richtung $\mathbf{v}_2$

- **Zeilenraum: Rechte Singulärvektoren**

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$$\implies \text{col}(\mathbf{A}^\top) = \text{span}\{\mathbf{v}_1\} = \text{span}\left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}$$

- **Spaltenraum: Linke Singulärvektoren** $\mathbf{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{u}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$

($\mathbf{u}_2, \mathbf{u}_3$: orthonormale Ergänzung, da $\sigma_2 = 0$; $\rightarrow$ SVD-Hauptsatz)

$$\implies \text{col}(\mathbf{A}) = \text{span}\{\mathbf{u}_1\} = \text{span}\left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \right\}$$

Rechenbeispiel: Fundamentale Unterräume (2)

Weiter mit $\mathbf{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$, $\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$, $\mathbf{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}$, $\mathbf{u}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$:

(Rechter) Nullraum: $\ker(\mathbf{A}) = \text{span}\{\mathbf{v}_2\} = \text{span}\left\{\begin{pmatrix} 1 \\ -1 \end{pmatrix}\right\}$ Verifikation: $\mathbf{A} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \quad \checkmark$

Linker Nullraum: $\ker(\mathbf{A}^\top) = \text{span}\{\mathbf{u}_2, \mathbf{u}_3\} = \text{span}\left\{\begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}\right\}$ Verifikation:
 $\mathbf{A}^\top \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \quad \checkmark$

Der SVD-Hauptsatz

Theorem: Singulärwertzerlegung

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = r$. Dann existiert eine Zerlegung:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$$

wobei:

- $\mathbf{V} \in \mathbb{R}^{n \times n}$: Orthogonalmatrix (rechte Singulärvektoren in Spalten)
- $\mathbf{U} \in \mathbb{R}^{m \times m}$: Orthogonalmatrix (linke Singulärvektoren erweitert zu Basis)
- $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$: "Diagonalmatrix" mit Singulärwerten

Beweis (Konstruktionsskizze): siehe [Anhang](#)

Die Struktur von Σ

Form der Matrix Σ :

$$\Sigma = \begin{pmatrix} \text{diag}(\sigma_1, \dots, \sigma_r) & 0_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{pmatrix}$$

Beispiele:

A quadratisch ($m = n = 3, r = 2$):

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

A rechteckig ($m = 2, n = 3, r = 2$):

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix}$$

Geometrische Interpretation

Transformation: $x \mapsto Ax = U\Sigma V^\top x$

Drei Schritte:

1. $V^\top$:

Koordinatentransformation (Rotation/Spiegelung) zu “optimalen” Richtungen

2. Σ :

“Streckung” entlang dieser Achsen um Faktoren σ_i , Nullsetzen für $i > r$

3. U :

Koordinatentransformation (Rotation/Spiegelung) zurück in den Zielraum

$\implies$ **SVD zerlegt *jede* lineare Transformation von $\mathbb{R}^n$ nach $\mathbb{R}^m$ in “Drehen-Strecken-Drehen”.**

Reduzierte SVD und Pseudoinverse

Reduzierte SVD

Problem: Viele Nulleinträge in $\Sigma \in \mathbb{R}^{m \times n}$, sobald $\text{rang}(\mathbf{A}) = r < m$ oder $r < n$ ($\mathbf{A}$ rangdefizient oder nicht quadratisch):

- Σ enthält $(m - r)$ Nullzeilen **und** $(n - r)$ Nullspalten
- Entsprechende Spalten in $\mathbf{U}$ bzw. $\mathbf{V}$ werden mit 0 multipliziert

Idee: Partitioniere $\mathbf{U} = (\mathbf{U}_r \mid \mathbf{U}_{m-r})$, $\mathbf{V} = (\mathbf{V}_r \mid \mathbf{V}_{n-r})$ mit $\mathbf{U}_r \in \mathbb{R}^{m \times r}$, $\mathbf{V}_r \in \mathbb{R}^{n \times r}$ und behalte nur die ersten r Singulärwerte und -vektoren:

Def.: Reduzierte SVD

Die **reduzierte SVD** von $\mathbf{A}$ mit $\text{rang}(\mathbf{A}) = r$ ist

$$\mathbf{A} = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top$$

wobei:

- $\mathbf{U}_r \in \mathbb{R}^{m \times r}$: Erste r linke Singulärvektoren
- $\mathbf{V}_r \in \mathbb{R}^{n \times r}$: Erste r rechte Singulärvektoren
- $\Sigma_r \in \mathbb{R}^{r \times r}$: $\text{diag}(\sigma_1, \dots, \sigma_r)$

Vorteile:

Moore-Penrose Pseudoinverse

Motivation: Was wenn $\mathbf{A}$ nicht quadratisch/invertierbar?

Def.: Moore-Penrose Pseudoinverse

Für jede Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit Rang $r \geq 1$ und *reduzierter SVD* $\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top$ ist die **Moore-Penrose Pseudoinverse**:

$$\mathbf{A}^+ := \mathbf{V}_r \mathbf{\Sigma}_r^{-1} \mathbf{U}_r^\top \in \mathbb{R}^{n \times m}$$

Bemerkung:

$\mathbf{\Sigma}_r^{-1} = \text{diag}(1/\sigma_1, \dots, 1/\sigma_r)$; für $\mathbf{A} = \mathbf{0}$ (also $r = 0$) setzt man $\mathbf{A}^+ = \mathbf{0} \in \mathbb{R}^{n \times m}$

Eigenschaften der Pseudoinverse

Theorem: Eigenschaften von $\mathbf{A}^+$

1. $\mathbf{A}\mathbf{A}^+\mathbf{x} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{x}$ für alle $\mathbf{x} \in \mathbb{R}^m$
2. $\mathbf{A}^+\mathbf{A}\mathbf{x} = \text{proj}_{\text{col}(\mathbf{A}^\top)}\mathbf{x}$ für alle $\mathbf{x} \in \mathbb{R}^n$
3. $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$ (Konsistenz)
4. $\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+$ (Konsistenz)

Warum Projektion?

$\mathbf{A}\mathbf{A}^+ = \mathbf{U}_r \Sigma_r \mathbf{V}_r^\top \mathbf{V}_r \Sigma_r^{-1} \mathbf{U}_r^\top = \mathbf{U}_r \mathbf{U}_r^\top$, und die Spalten von $\mathbf{U}_r$ sind eine Orthonormalbasis von $\text{col}(\mathbf{A})$.

Spezialfälle:

- Wenn $\text{rang}(\mathbf{A}) = m$: $\mathbf{A}\mathbf{A}^+ = \mathbf{I}_m$
- Wenn $\text{rang}(\mathbf{A}) = n$: $\mathbf{A}^+\mathbf{A} = \mathbf{I}_n$
- Wenn $\mathbf{A}$ quadratisch und invertierbar: $\mathbf{A}^+ = \mathbf{A}^{-1}$

Anwendungen

Spektralnrm und SVD

Bisher: $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^\top \mathbf{A})}$

Aus Definition SVD ist bekannt, dass $\lambda_j(\mathbf{A}^\top \mathbf{A}) = \sigma_j(\mathbf{A})^2$

Also:

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A})$$

Interpretation: Größter Singulärwert = maximale Streckung

Die SVD als Summe von Rang-1 Matrizen

SVD in Summenform:

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^\top = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$$

Interpretation:

- Jeder Term $\mathbf{u}_i \mathbf{v}_i^\top$ ist eine **Rang-1 Matrix** (mit $\|\mathbf{u}_i \mathbf{v}_i^\top\|_F = 1$)
- σ_i gewichtet die Bedeutung des i -ten Terms
- Große $\sigma_i \rightarrow$ wichtige Richtungen
- Kleine $\sigma_i \rightarrow$ weniger wichtige Richtungen

Idee für Approximation: Verwende nur die wichtigsten Terme!

Rang-k Approximation

Low-Rank Approximation:

$$\mathbf{A}_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top \quad (k < r)$$

Theorem: Optimale Approximation

$\mathbf{A}_k$ ist beste Rang- k Approximation von $\mathbf{A}$ bezüglich der Frobenius- und Spektral-Normen, d.h. $\mathbf{A}_k$ löst beide Approximationsprobleme:

$$\mathbf{A}_k \in \arg \min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rang}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_F \quad \text{und} \quad \mathbf{A}_k \in \arg \min_{\substack{\mathbf{B} \in \mathbb{R}^{m \times n} \\ \text{rang}(\mathbf{B}) \leq k}} \|\mathbf{A} - \mathbf{B}\|_2$$

Approximationsfehler:

- $\|\mathbf{A} - \mathbf{A}_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}$
- $\|\mathbf{A} - \mathbf{A}_k\|_2 = \sigma_{k+1}$

Interpretation: Fehler bestimmt durch *weggelassene* Singulärwerte

Nicht-Eindeutigkeit in Spektralnorm: Für $\mathbf{A} = \text{diag}(3, 2)$, $k = 1$ und $\mathbf{B}_b = \text{diag}(b, 0)$ gilt $\|\mathbf{A} - \mathbf{B}_b\|_2 = \max\{|3 - b|, 2\}$. Damit sind alle $b \in [1, 5]$ optimal; die abgeschnittene SVD entspricht $b = 3$. In Frobenius-Norm ist nur $b = 3$ optimal, denn der Fehler ist $\sqrt{(3 - b)^2 + 2^2}$.

Wahl der optimalen Rang-k Approximation

Kriterien für die Wahl von k :

1. Relativer Fehler (Spektralnorm):

$$\frac{\|\mathbf{A} - \mathbf{A}_k\|_2}{\|\mathbf{A}\|_2} = \frac{\sigma_{k+1}}{\sigma_1}$$

2. Relativer Fehler (Frobenius-Norm):

$$\frac{\|\mathbf{A} - \mathbf{A}_k\|_F}{\|\mathbf{A}\|_F} = \frac{\sqrt{\sum_{i=k+1}^r \sigma_i^2}}{\sqrt{\sum_{i=1}^r \sigma_i^2}}$$

3. “Energieerhaltung”:

$$\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} \geq p \quad (p \cdot 100\% \text{ der "Energie"})$$

Praktische Heuristik: k am “Ellenbogen” im $\log(\sigma_i)$ -Plot wählen – dort, wo die Singulärwerte abknicken.
(Typische Verläufe: siehe *Anhang*)


Anwendung: Datenkompression

Bildkompression – Originalbild: 659×512 Pixel-Matrix (pro Farbkanal)


- Volle Speicherung: $659 \times 512 = 337.408$ Zahlen; **Rang-50 SVD**:
 $(659 \times 50) + 50 + (50 \times 512) = 58.600$ Zahlen $\implies$ *Speicherersparnis*: $\approx 83\%$ (Speicheranteil $\approx 17\%$)!
- **Vorgehen**: SVD berechnen, k anhand der Singulärwerte wählen, nur U_k , Σ_k , V_k speichern.



Original



Singulärwerte pro Kanal



$k = 5$



$k = 20$



$k = 50$



$k = 200$

Bildquelle: C. A. Jensen, Porträt C. F. Gauß (1840), gemeinfrei (Wikimedia Commons).

Interaktive Demo: Bildkompression



Fallback: ► [App direkt öffnen](#) — Screenshot im Anhang.

Anwendung: Empfehlungssysteme

Collaborative Filtering / Recommender Systems

Problem: Netflix-Szenario: m Nutzer, n Filme, aber Daten sehr *sparse*: meiste Nutzer haben meiste Filme nicht bewertet

$$\mathbf{R} = \begin{pmatrix} 5 & ? & 1 & ? & 4 \\ ? & 3 & ? & 4 & ? \\ 2 & 1 & ? & ? & 5 \\ ? & 5 & 4 & 3 & ? \end{pmatrix} \in \mathbb{R}^{m \times n}$$

Idee: Nutzer-Film-Präferenzen liegen in einem *niedrigdimensionalen Raum* (Genres und Nutzerklassen).

SVD-Ansatz:

1. Ergänze fehlende Einträge (z.B. durch Spaltenmittelwerte)
2. Berechne Rang- k Approximation: $\mathbf{R}_k = \mathbf{U}_k \mathbf{\Sigma}_k \mathbf{V}_k^\top$
3. Nutze $\mathbf{R}_k$ für Vorhersagen fehlender Ratings

Interpretation: $\mathbf{v}_j$ = “gelernte” Film-Genres, $\mathbf{u}_i$ = Nutzer-Präferenzen in diesen Genre-Dimensionen, σ_i = Wichtigkeit der Dimension (*mehr: siehe Anhang*)

Wann ist SVD besonders nützlich?

Ideale Situationen für SVD:

1. *Niedrig-Rang Strukturen*: $\text{rang}(\mathbf{A}) \ll \min(m, n)$
2. *Schnell abfallende Singulärwerte*: Wenige dominieren
3. *Überbestimmte Systeme*: $m > n$, möglicherweise inkonsistent
4. *Datenanalyse*: Hauptkomponentenanalyse (PCA) ohne Kreuzprodukte zu berechnen.
5. *Numerische Robustheit*: Alternative zu Normalgleichungen

Rechenaufwand:

- **SVD**: $O(\min(m^2n, mn^2))$, für $m \gg n$ etwa $4mn^2$
- *Normalgleichungen*: $O(mn^2 + n^3)$, für $m \gg n$ etwa mn^2 .
- Für $m \gg n$ sind Normalgleichungen schneller, aber SVD ist robuster $\rightarrow$ trade-off zwischen Geschwindigkeit und Stabilität

SVD vs. Eigenwertzerlegung

Eigenschaft	Eigenwertzerlegung	SVD
<i>Matrix-Typ</i>	Quadratisch	Beliebig $m \times n$
<i>Orthogonale Zerlegung</i>	Nur symmetrisch ($\rightarrow$ Spektralzerlegung)	Immer
<i>Numerische Stabilität</i>	Kann instabil sein	Stabil
<i>Existenz</i>	Nur für diagonalisierbare A	Immer
<i>Geometrische Interpretation</i>	Hauptachsen (symmetrisch)	“Optimale” Koordinaten

Zusammenfassung & Self-Check

Zusammenfassung

Kernkonzepte:

1. SVD erweitert Eigenwertzerlegung auf beliebige $m \times n$ Matrizen
2. Singulärwerte vs. Eigenwerte: $\sigma_i(\mathbf{A}) = \sqrt{\lambda_i(\mathbf{A}^\top \mathbf{A})}$
3. Hauptsatz: $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ mit orthogonalen $\mathbf{U}$ ($m \times m$), $\mathbf{V}$ ($n \times n$), diagonalem $\mathbf{\Sigma}$ ($m \times n$)
4. Reduzierte SVD: $\mathbf{A} = \mathbf{U}_r\mathbf{\Sigma}_r\mathbf{V}_r^\top$ für Effizienz ($r = \text{rang}(\mathbf{A})$)
5. Pseudoinverse: $\mathbf{A}^+ = \mathbf{V}_r\mathbf{\Sigma}_r^{-1}\mathbf{U}_r^\top$

Anwendungen: Lösung von **Kleinste-Quadrate-Problemen**, optimale **Low-Rank Approximation** (Datenkompression, -analyse)

Praktische Hinweise:

- SVD **nicht** über $\mathbf{A}^\top \mathbf{A}$ berechnen (numerisch instabil) – spezielle Algorithmen (z.B. Golub-Reinsch) nutzen: in R `svd(A)`
- *truncated SVD* für sehr große Matrizen: `irlba::irlba(A, nv = k)` (iterativ, Lanczos) bzw. `irlba::svdr(A, k)` (randomisiert)

Self-Check

Welche Aussagen sind korrekt?

1. Wenn $\mathbf{A} \in \mathbb{R}^{m \times n}$, dann ist $\mathbf{A}^\top \mathbf{A} \in \mathbb{R}^{m \times m}$
2. Wenn $\mathbf{A} \in \mathbb{R}^{m \times n}$, dann ist $\mathbf{A}^\top \mathbf{A}$ symmetrisch
3. Die Eigenwerte von $\mathbf{A}^\top \mathbf{A}$ sind die Singulärwerte von $\mathbf{A}$
4. Wenn $\mathbf{A} \in \mathbb{R}^{n \times n}$, dann ist $\mathbf{A}$ immer diagonalisierbar
5. $\mathbf{A}^\top \mathbf{A}$ ist immer orthogonal diagonalisierbar

Anhang

Orthogonalität der Singulärvektoren

Warum sind die $\sigma_i \mathbf{u}_i = \mathbf{A} \mathbf{v}_i$ orthogonal?

Für $i \neq j$:

$$\begin{aligned} (\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j) &= \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_j \\ &= \mathbf{v}_i^\top (\lambda_j \mathbf{v}_j) \\ &= \lambda_j (\mathbf{v}_i^\top \mathbf{v}_j) \\ &= \lambda_j \cdot 0 = 0 \end{aligned}$$

Für $i = j$:

$$\|\mathbf{A} \mathbf{v}_i\|^2 = \mathbf{v}_i^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{v}_i = \lambda_i \|\mathbf{v}_i\|^2 = \lambda_i = \sigma_i^2$$

$\implies$ Für $i, j \leq r$ (also $\sigma_i, \sigma_j > 0$) ist $\mathbf{u}_i^\top \mathbf{u}_j = \frac{(\mathbf{A} \mathbf{v}_i)^\top (\mathbf{A} \mathbf{v}_j)}{\sigma_i \sigma_j} = 0$ für $i \neq j$ bzw. $= 1$ für $i = j$: Die $\mathbf{u}_1, \dots, \mathbf{u}_r$ sind orthonormal! (Die übrigen $\mathbf{u}_{r+1}, \dots, \mathbf{u}_m$ werden als orthonormale Ergänzung gewählt.)

$\hookleftarrow$ zurück: „Definition: Singulärvektoren“

Bsp: Singulärvektoren – vollständige Rechnung (1)

Matrix $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}$: $\mathbf{A}^\top \mathbf{A}$ mit $\boldsymbol{\lambda} \approx (9.53, 1.47)$:

Rechte Singulärvektoren (Eigenvektoren von $\mathbf{A}^\top \mathbf{A}$):

Für $\lambda_1 \approx 9.53$:

$$\begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \begin{pmatrix} v_1^{(1)} \\ v_2^{(1)} \end{pmatrix} = 9.53 \begin{pmatrix} v_1^{(1)} \\ v_2^{(1)} \end{pmatrix}$$

Lösung: $\mathbf{v}_1 \approx \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix}$

Für $\lambda_2 \approx 1.47$: $\mathbf{v}_2 \approx \begin{pmatrix} -0.662 \\ 0.75 \end{pmatrix}$ (normiert, orthogonal zu $\mathbf{v}_1$)

Bsp: Singulärvektoren – vollständige Rechnung (2)

Linke Singulärvektoren:

$$\mathbf{u}_1 = \frac{\mathbf{A}\mathbf{v}_1}{\sigma_1} \approx \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix} / 3.09 = \begin{pmatrix} -0.672 \\ -0.7 \\ -0.243 \end{pmatrix}, \quad \text{analog: } \mathbf{u}_2 = \frac{\mathbf{A}\mathbf{v}_2}{\sigma_2} \approx \begin{pmatrix} 0.691 \\ -0.474 \\ -0.546 \end{pmatrix}$$

Verifikation Orthonormalität:

- $\mathbf{u}_1^\top \mathbf{u}_2 \approx (-0.672)(0.691) + (-0.7)(-0.474) + (-0.243)(-0.546) = -0.464 + 0.332 + 0.133 \approx 0 \quad \checkmark$
- $\|\mathbf{u}_1\| \approx \sqrt{0.672^2 + 0.7^2 + 0.243^2} = \sqrt{0.452 + 0.49 + 0.059} \approx 1 \quad \checkmark$

↔ zurück: „Bsp: Singulärvektoren“

Beweis des SVD-Theorems (Skizze)

Konstruktion der Zerlegung:

1. Rechte Singulärvektoren: Eigenvektoren von $\mathbf{A}^\top \mathbf{A}$

$$\mathbf{V} = (\mathbf{v}_1 \mid \mathbf{v}_2 \mid \cdots \mid \mathbf{v}_n)$$

2. Linke Singulärvektoren: $\mathbf{u}_i = \mathbf{A}\mathbf{v}_i / \sigma_i$ für $i \leq r$

$$\mathbf{U}_r = (\mathbf{u}_1 \mid \mathbf{u}_2 \mid \cdots \mid \mathbf{u}_r)$$

3. Vervollständigung: Erweitere $\mathbf{U}_r$ zu Orthogonalbasis des $\mathbb{R}^m$

4. Verifikation: $\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i$ für $i \leq r$, $\mathbf{A}\mathbf{v}_i = \mathbf{0}$ für $i > r$

↔ zurück: „Der SVD-Hauptsatz“

Typische Singulärwert-Verläufe

1. Schneller Abfall: $\sigma_i \approx c \cdot e^{-\alpha i}$

- Gut geeignet für Low-Rank Approximation
- Wenige dominante Singulärwerte

2. Linearer Abfall: $\sigma_i \approx c - \alpha i$

- Moderate Approximation möglich
- Mittlerer Kompressionsfaktor

3. Langsamer Abfall: $\sigma_i \approx c \cdot i^{-\alpha}$

- Schwierige Approximation
- Viele wichtige Komponenten

↔ zurück: „Wahl der optimalen Rang-k Approximation“

Empfehlungssysteme: Details

Interpretation der Faktoren:

- **Rechte Singulärvektoren** v_j : “gelernte” Film-Genres
 - v_1 könnte “Action vs. Drama” kodieren, v_2 “Komödie vs. Thriller”, etc
- **Linke Singulärvektoren** u_i : Nutzer-Präferenzen in diesen Genre-Dimensionen
- **Singulärwerte** σ_i : Wichtigkeit dieser Genre-Dimension

Vorteile:

- Reduziert Speicher: $k + (m + n) \cdot k \ll m \cdot n$ für $k \ll \min(m, n)$
- “Glättet” die Daten (Low-Rank = *Regularisierung*)
- Kann auch bei sehr spärlichen Daten funktionieren

Modernere Varianten:

- *Matrix Completion*: Low-Rank-Faktorisierung nur über die *beobachteten* Einträge; mit Nichtnegativitäts-Nebenbedingung: *Non-negative Matrix Factorization* (NMF)

↔ zurück: „Anwendung: Empfehlungssysteme“