Singulärwertzerlegung (SVD)

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- **Matrixnormen** und ihre Eigenschaften, speziell:
  - *Spektralnorm* $\|\boldsymbol{A}\|_2 = \sqrt{\lambda_{\max}(\boldsymbol{A}^\top \boldsymbol{A})}$
  - *Orthogonalmatrizen* $\boldsymbol{Q}$ mit $\boldsymbol{Q}^\top \boldsymbol{Q} = \boldsymbol{I}$
- Matrixzerlegungskonzepte
- **Lineare Algebra**
  - Eigenwerte und Eigenvektoren: $\boldsymbol{A}\boldsymbol{v} = \lambda \boldsymbol{v}$
  - Rang einer Matrix
  - Fundamentale Unterräume: $\mathrm{col}(\boldsymbol{A}), \ker(\boldsymbol{A}), \mathrm{col}(\boldsymbol{A}^\top)$
  - Projektionen auf Unterräume

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ *symmetrisch* ($\boldsymbol{A} = \boldsymbol{A}^\top$). Welche Aussage gilt **immer**?

1. Alle Eigenwerte von $\boldsymbol{A}$ sind ≥ 0.
2. $\boldsymbol{A}$ ist orthogonal diagonalisierbar: $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{D}\boldsymbol{Q}^\top$ mit reellen Eigenwerten.
3. $\boldsymbol{A}$ ist invertierbar.
4. $\boldsymbol{A}$ hat n verschiedene Eigenwerte.

Frage 2: Was ist der Rang von $\boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$?

1. 0
2. 1
3. 2
4. 3

Motivation

Diagonalisierung ist limitiert

- Eigenwertzerlegung funktioniert nur für **quadratische** Matrizen – und auch dort nicht immer:
  $\begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}$ hat nur den Eigenwert 0 mit eindimensionalem Eigenraum, also keine Eigenvektorbasis
- Orthogonale Diagonalisierung bisher nur für **symmetrische** Matrizen
- **Problem**:
  Die meisten Matrizen sind weder quadratisch noch symmetrisch.

Was wir wollen: Eine Zerlegung $\boldsymbol{A = PDQ^{-1}}$

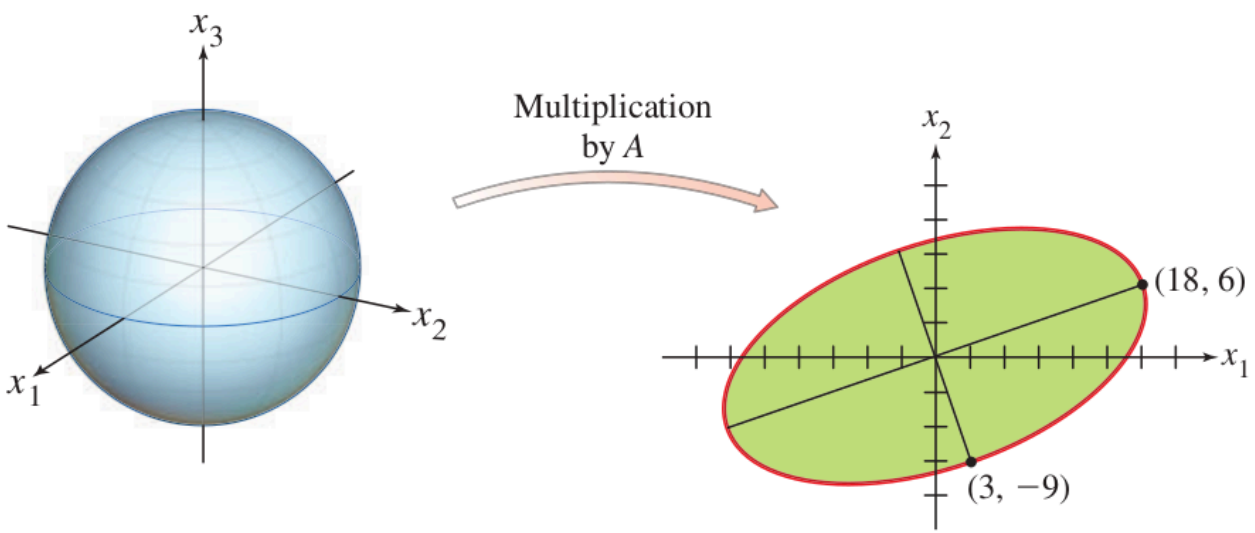
- für *beliebige* $m \times n$ Matrizen, so dass
- $\boldsymbol{D}$ "diagonal" ist und
- $\boldsymbol{P}$ und $\boldsymbol{Q}$ *Orthogonalmatrizen* sind

Geometrische Intuition

Die Einheitssphäre als Testfall:

- Betrachte alle Vektoren $\boldsymbol{x}$ mit $\|\boldsymbol{x}\| = 1$
- Nach Transformation: $\boldsymbol{A}\boldsymbol{x}$ hat verschiedene Längen
- **Frage**: Welche Richtung $\boldsymbol{A}\boldsymbol{x}$ wurde am stärksten (zweitstärksten, drittstärksten, ...) gestreckt?

Beispiel: $\boldsymbol{A} \in \mathbb{R}^{2\times 3}$



- Einheitssphäre in $\mathbb{R}^3 \to$ ausgefüllte Ellipse in $\mathbb{R}^2$; stärkste Streckung: Hauptachse, zweitstärkste: Nebenachse; Richtungen in $\ker(\boldsymbol{A})$ werden auf $\mathbf{0}$ gestaucht

▶ Interaktive Visualisierung im Skript

Die Grundidee

Maximierungsproblem:

$$\max_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|$$

Trick: Maximiere $\|\boldsymbol{A}\boldsymbol{x}\|^2$ statt $\|\boldsymbol{A}\boldsymbol{x}\|$

$$\|\boldsymbol{A}\boldsymbol{x}\|^2 = (\boldsymbol{A}\boldsymbol{x})^\top(\boldsymbol{A}\boldsymbol{x}) = \boldsymbol{x}^\top(\boldsymbol{A}^\top\boldsymbol{A})\boldsymbol{x}$$

Erkenntnis: Dies ist eine quadratische Form bezüglich $\boldsymbol{A}^\top\boldsymbol{A}$!

Im Folgenden immer: $\|\cdot\| \equiv \|\cdot\|_2$!

SVD: Singulärwerte und Singulärvektoren

Die Matrix $\boldsymbol{A}^\top \boldsymbol{A}$

Theorem: Eigenschaften von $\boldsymbol{A}^\top \boldsymbol{A}$

Für $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ gilt:

1. $\boldsymbol{A}^\top \boldsymbol{A}$ ist *symmetrisch*: $\left(\boldsymbol{A}^\top \boldsymbol{A}\right)^\top = \boldsymbol{A}^\top \boldsymbol{A}$
2. $\boldsymbol{A}^\top \boldsymbol{A}$ ist *positiv semidefinit*: $\boldsymbol{x}^\top \left(\boldsymbol{A}^\top \boldsymbol{A}\right)\boldsymbol{x} \geq 0$ für alle $\boldsymbol{x} \in \mathbb{R}^n$; insbesondere sind alle Eigenwerte $\lambda_i \geq 0$

Beweis für (2): $\boldsymbol{x}^\top \left(\boldsymbol{A}^\top \boldsymbol{A}\right)\boldsymbol{x} = \|\boldsymbol{A}\boldsymbol{x}\|_2^2 \geq 0$; für jeden normierten Eigenvektor $\boldsymbol{v}_i$ ($\|\boldsymbol{v}_i\| = 1$) gilt damit:

$$0 \leq \|\boldsymbol{A}\boldsymbol{v}_i\|_2^2 = \boldsymbol{v}_i^\top \left(\boldsymbol{A}^\top \boldsymbol{A}\right)\boldsymbol{v}_i = \boldsymbol{v}_i^\top \left(\lambda_i \boldsymbol{v}_i\right) = \lambda_i$$

Folgerung: $\boldsymbol{A}^\top \boldsymbol{A}$ ist orthogonal diagonalisierbar!

Bsp: Eigenschaften von $\boldsymbol{A}^\top \boldsymbol{A}$

Sei $\boldsymbol{A} = \begin{pmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \in \mathbb{R}^{3\times 2}$

$$\boldsymbol{A}^\top \boldsymbol{A} = \begin{pmatrix} \boldsymbol{a}_1^\top \\ \boldsymbol{a}_2^\top \end{pmatrix} \begin{pmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 \end{pmatrix} = \begin{pmatrix} \boldsymbol{a}_1^\top \boldsymbol{a}_1 & \boldsymbol{a}_1^\top \boldsymbol{a}_2 \\ \boldsymbol{a}_2^\top \boldsymbol{a}_1 & \boldsymbol{a}_2^\top \boldsymbol{a}_2 \end{pmatrix}$$
$$= \begin{pmatrix} 1 & 2 & 1 \\ 2 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix}$$

Symmetrie: ✓

Positiv semidefinit:

$$\det\left(\boldsymbol{A}^\top \boldsymbol{A} - \lambda \boldsymbol{I}\right) = (6-\lambda)(5-\lambda) - 16 = \lambda^2 - 11\lambda + 14 = 0$$
$$\lambda_{1,2} = \frac{11 \pm \sqrt{11^2 - 4\cdot 1 \cdot 14}}{2} = \frac{11 \pm \sqrt{65}}{2}$$
$$\implies \lambda_1 \approx 9.53, \quad \lambda_2 \approx 1.47$$

$\lambda_1, \lambda_2 > 0 \implies \boldsymbol{A}^\top \boldsymbol{A}$ hier sogar positiv *definit* – mehr als das vom Theorem garantierte “semidefinit”, da $\boldsymbol{A}$ vollen Spaltenrang hat ($\operatorname{rang}(\boldsymbol{A}) = n = 2$)

Definition: Singulärwerte

Seien $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ die Eigenwerte von $\boldsymbol{A}^\top \boldsymbol{A}$.

Def.: Singulärwerte

Die **Singulärwerte** von $\boldsymbol{A}$ sind:

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \ldots, n$$

Interpretation:

- $\sigma_1 = \max_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|$ (maximale Streckung)
- σ_n entspricht der minimalen Streckung / maximalen Stauchung
- $\sigma_i = 0 \iff \lambda_i = 0$

Bsp: Singulärwerte

Matrix $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}$: $\quad$ $\boldsymbol{A}^\top \boldsymbol{A}$ mit $\boldsymbol{\lambda} \approx (9.53, 1.47)$:

Singulärwerte:

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{9.53} \approx 3.09$$
$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{1.47} \approx 1.21$$

Interpretation:

- $\sigma_1 \approx 3.09$: Maximale Streckung der Matrix $\boldsymbol{A}$ ($\boldsymbol{v}_1$ wird um Faktor 3.1 gestreckt)
- $\sigma_2 \approx 1.21$: Minimale Streckung ($\boldsymbol{v}_2$ wird um Faktor 1.2 gestreckt)
- Verhältnis $\frac{\sigma_{\max}}{\sigma_{\min}} \approx 2.55$ zeigt, wie unterschiedlich die Streckung je nach Richtung ist (*anisotrop*).

Definition: Singulärvektoren

Def.: Rechte und linke Singulärvektoren

Rechte Singulärvektoren $\boldsymbol{v}_i$:

- Normierte Eigenvektoren von $\boldsymbol{A}^\top \boldsymbol{A}$
- $\boldsymbol{A}^\top \boldsymbol{A} \boldsymbol{v}_i = \lambda_i \boldsymbol{v}_i = \sigma_i^2 \boldsymbol{v}_i$

Linke Singulärvektoren $\boldsymbol{u}_i$:

- Definiert durch: $\boldsymbol{u}_i = \frac{\boldsymbol{A}\boldsymbol{v}_i}{\sigma_i}$ (für $\sigma_i > 0$)

Wichtige Eigenschaften:

- $\{\boldsymbol{v}_1, \ldots, \boldsymbol{v}_n\}$ ist orthonormal
- $\{\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r\}$ ist orthonormal ($r = \operatorname{rang}(\boldsymbol{A})$)

Beweis der Orthonormalität: siehe Anhang

Bsp: Singulärvektoren

Matrix $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}$: $\quad \boldsymbol{A}^\top \boldsymbol{A} = \begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix}$ mit $\boldsymbol{\lambda} \approx (9.53, 1.47)$:

Rechte Singulärvektoren (normierte Eigenvektoren von $\boldsymbol{A}^\top \boldsymbol{A}$):

$$\begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \boldsymbol{v}_1 = 9.53\, \boldsymbol{v}_1 \implies \boldsymbol{v}_1 \approx \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix}, \qquad \boldsymbol{v}_2 \approx \begin{pmatrix} -0.662 \\ 0.75 \end{pmatrix} \text{ (normiert, orthogonal zu } \boldsymbol{v}_1)$$

Linke Singulärvektoren ($\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i / \sigma_i$), eine Rechnung exemplarisch:

$$\boldsymbol{u}_1 = \frac{\boldsymbol{A}\boldsymbol{v}_1}{\sigma_1} \approx \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix} / 3.09 = \begin{pmatrix} -0.672 \\ -0.7 \\ -0.243 \end{pmatrix}, \qquad \text{analog: } \boldsymbol{u}_2 \approx \begin{pmatrix} 0.691 \\ -0.474 \\ -0.546 \end{pmatrix}$$

Check: $\boldsymbol{u}_1^\top \boldsymbol{u}_2 \approx 0$ und $\|\boldsymbol{u}_1\| \approx 1$ ✓ (vollständige Rechnung: siehe Anhang)

Live-Demo: SVD in R

Stimmt unsere Handrechnung? **Vorhersage:** Was liefert `svd(A)`?

```r
A <- matrix(c(1, 2,
              2, 1,
              1, 0), nrow = 3, byrow = TRUE)
svd(A)
```

```
$d
[1] 3.09 1.21

$u
      [,1]   [,2]
[1,] -0.672  0.691
[2,] -0.700 -0.474
[3,] -0.243 -0.546

$v
      [,1]   [,2]
[1,] -0.750 -0.662
[2,] -0.662  0.750
```

- d $\approx (3.09, 1.21)$: wie von Hand berechnet ✓
- u, v: Singulärvektoren – Vorzeichen nicht eindeutig ($\pm \boldsymbol{u}_i$, $\pm \boldsymbol{v}_i$ ebenfalls gültig)!

Fundamentale Unterräume

Theorem: Charakterisierung der Unterräume

Angenommen $\boldsymbol{A}$ hat r Singulärwerte ungleich Null. Dann:

1. $\{\boldsymbol{v}_1, \ldots, \boldsymbol{v}_r\}$ ist Orthonormalbasis für $\mathrm{col}(\boldsymbol{A}^\top)$ (*Zeilenraum*)
2. $\{\boldsymbol{A}\boldsymbol{v}_1, \ldots, \boldsymbol{A}\boldsymbol{v}_r\}$ ist Orthogonalbasis für $\mathrm{col}(\boldsymbol{A})$ (*Spaltenraum*) – normiert ($\|\boldsymbol{A}\boldsymbol{v}_i\| = \sigma_i$) sind das die $\{\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r\}$
3. $\{\boldsymbol{v}_{r+1}, \ldots, \boldsymbol{v}_n\}$ ist Orthonormalbasis für $\ker(\boldsymbol{A})$ (*Nullraum*)
4. $\mathrm{rang}(\boldsymbol{A}) = r$

Interpretation: SVD gibt uns explizite Orthonormalbasen für alle Fundamentalräume! (für den *linken Nullraum* $\ker(\boldsymbol{A}^\top)$: erweiterte $\boldsymbol{u}_{r+1}, \ldots, \boldsymbol{u}_m$ → SVD-Hauptsatz & Beispiel)

Rechenbeispiel: Fundamentale Unterräume (1)

Für $\boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$ mit $\boldsymbol{A}^\top \boldsymbol{A} = \begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$ und rang($\boldsymbol{A}$) = 1:

- **Singulärwerte**:
  $\lambda_1(\boldsymbol{A}^\top \boldsymbol{A}) = 4,\ \lambda_2(\boldsymbol{A}^\top \boldsymbol{A}) = 0$
  $\implies \sigma_1(\boldsymbol{A}) = 2$: Maximale Streckung durch $\boldsymbol{A}$ um Faktor 2 in Richtung $\boldsymbol{v}_1$; Faktor 0 in Richtung $\boldsymbol{v}_2$
- **Zeilenraum: Rechte Singulärvektoren**
  $\boldsymbol{v}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad \boldsymbol{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$
  $\implies$ col($\boldsymbol{A}^\top$) = span$\{\boldsymbol{v}_1\}$ = span$\left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}$
- **Spaltenraum: Linke Singulärvektoren** $\boldsymbol{u}_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \boldsymbol{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \quad \boldsymbol{u}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$

  (*$\boldsymbol{u}_2, \boldsymbol{u}_3$: orthonormale Ergänzung, da $\sigma_2 = 0$; → SVD-Hauptsatz)*
  $\implies$ col($\boldsymbol{A}$) = span$\{\boldsymbol{u}_1\}$ = span$\left\{ \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \right\}$

Rechenbeispiel: Fundamentale Unterräume (2)

Weiter mit $\boldsymbol{A} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{pmatrix}$, $\boldsymbol{v}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$, $\boldsymbol{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}$, $\boldsymbol{u}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$:

(Rechter) Nullraum: $\ker(\boldsymbol{A}) = \operatorname{span}\{\boldsymbol{v}_2\} = \operatorname{span}\left\{ \begin{pmatrix} 1 \\ -1 \end{pmatrix} \right\}$ Verifikation: $\boldsymbol{A} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$ ✓

Linker Nullraum: $\ker(\boldsymbol{A}^\top) = \operatorname{span}\{\boldsymbol{u}_2, \boldsymbol{u}_3\} = \operatorname{span}\left\{ \begin{pmatrix} -1 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} \right\}$ Verifikation:

$$\boldsymbol{A}^\top \begin{pmatrix} -1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}$$ ✓

Der SVD-Hauptsatz

Theorem: Singulärwertzerlegung

Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit $\operatorname{rang}(\boldsymbol{A}) = r$. Dann existiert eine Zerlegung:

$$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$$

wobei:

- $\boldsymbol{V} \in \mathbb{R}^{n \times n}$: Orthogonalmatrix (rechte Singulärvektoren in Spalten)
- $\boldsymbol{U} \in \mathbb{R}^{m \times m}$: Orthogonalmatrix (linke Singulärvektoren erweitert zu Basis)
- $\boldsymbol{\Sigma} \in \mathbb{R}^{m \times n}$: “Diagonalmatrix” mit Singulärwerten

Beweis (Konstruktionsskizze): siehe Anhang

Die Struktur von $\boldsymbol{\Sigma}$

Form der Matrix $\boldsymbol{\Sigma}$:

$$\boldsymbol{\Sigma} = \begin{pmatrix} \operatorname{diag}(\sigma_1, \ldots, \sigma_r) & 0_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{pmatrix}$$

Beispiele:

$\boldsymbol{A}$ *quadratisch* ($m = n = 3, r = 2$):

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

$\boldsymbol{A}$ *rechteckig* ($m = 2, n = 3, r = 2$):

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \end{pmatrix}$$

Geometrische Interpretation

Transformation: $\boldsymbol{x} \mapsto \boldsymbol{A}\boldsymbol{x} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top\boldsymbol{x}$

Drei Schritte:

1. $\boldsymbol{V}^\top$:
   Koordinatentransformation (Rotation/Spiegelung) zu “optimalen” Richtungen
2. $\boldsymbol{\Sigma}$:
   “Streckung” entlang dieser Achsen um Faktoren σ_i, Nullsetzen für $i > r$
3. $\boldsymbol{U}$:
   Koordinatentransformation (Rotation/Spiegelung) zurück in den Zielraum

$\Longrightarrow$ **SVD zerlegt *jede* lineare Transformation von $\mathbb{R}^n$ nach $\mathbb{R}^m$ in “Drehen-Strecken-Drehen”.**

Reduzierte SVD und Pseudoinverse

Reduzierte SVD

Problem: Viele Nulleinträge in $\boldsymbol{\Sigma} \in \mathbb{R}^{m \times n}$, sobald $\operatorname{rang}(\boldsymbol{A}) = r < m$ oder $r < n$ ($\boldsymbol{A}$ rangdefizient *oder* nicht quadratisch):

- $\boldsymbol{\Sigma}$ enthält $(m - r)$ Nullzeilen **und** $(n - r)$ Nullspalten
- Entsprechende Spalten in $\boldsymbol{U}$ bzw. $\boldsymbol{V}$ werden mit 0 multipliziert

Idee: Partitioniere $\boldsymbol{U} = (\boldsymbol{U}_r \mid \boldsymbol{U}_{m-r})$, $\boldsymbol{V} = (\boldsymbol{V}_r \mid \boldsymbol{V}_{n-r})$ mit $\boldsymbol{U}_r \in \mathbb{R}^{m \times r}$, $\boldsymbol{V}_r \in \mathbb{R}^{n \times r}$ und behalte nur die ersten r Singulärwerte und -vektoren:

Def.: Reduzierte SVD

Die **reduzierte SVD** von $\boldsymbol{A}$ mit $\operatorname{rang}(\boldsymbol{A}) = r$ ist

$$\boldsymbol{A} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^\top$$

wobei:

- $\boldsymbol{U}_r \in \mathbb{R}^{m \times r}$: Erste r linke Singulärvektoren
- $\boldsymbol{V}_r \in \mathbb{R}^{n \times r}$: Erste r rechte Singulärvektoren
- $\boldsymbol{\Sigma}_r \in \mathbb{R}^{r \times r}$: $\operatorname{diag}(\sigma_1, \ldots, \sigma_r)$

Vorteile:

Moore-Penrose Pseudoinverse

Motivation: Was wenn $\boldsymbol{A}$ nicht quadratisch/invertierbar?

Def.: Moore-Penrose Pseudoinverse

Für jede Matrix $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit Rang $r \geq 1$ und *reduzierter SVD* $\boldsymbol{A} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^\top$ ist die **Moore-Penrose Pseudoinverse**:

$$\boldsymbol{A}^+ := \boldsymbol{V}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{U}_r^\top \in \mathbb{R}^{n \times m}$$

Bemerkung:

$\boldsymbol{\Sigma}_r^{-1} = \operatorname{diag}(1/\sigma_1, \ldots, 1/\sigma_r)$; für $\boldsymbol{A} = \boldsymbol{0}$ (also $r = 0$) setzt man $\boldsymbol{A}^+ = \boldsymbol{0} \in \mathbb{R}^{n \times m}$

Eigenschaften der Pseudoinverse

Theorem: Eigenschaften von $\boldsymbol{A}^+$

1. $\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{x} = \text{proj}_{\text{col}(\boldsymbol{A})}\boldsymbol{x}$ für alle $\boldsymbol{x} \in \mathbb{R}^m$
2. $\boldsymbol{A}^+\boldsymbol{A}\boldsymbol{x} = \text{proj}_{\text{col}(\boldsymbol{A}^\top)}\boldsymbol{x}$ für alle $\boldsymbol{x} \in \mathbb{R}^n$
3. $\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{A} = \boldsymbol{A}$ *(Konsistenz)*
4. $\boldsymbol{A}^+\boldsymbol{A}\boldsymbol{A}^+ = \boldsymbol{A}^+$ *(Konsistenz)*

Warum Projektion?
$\boldsymbol{A}\boldsymbol{A}^+ = \boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^\top\boldsymbol{V}_r\boldsymbol{\Sigma}_r^{-1}\boldsymbol{U}_r^\top = \boldsymbol{U}_r\boldsymbol{U}_r^\top$, und die Spalten von $\boldsymbol{U}_r$ sind eine Orthonormalbasis von $\text{col}(\boldsymbol{A})$.

Spezialfälle:

- Wenn $\text{rang}(\boldsymbol{A}) = m$: $\boldsymbol{A}\boldsymbol{A}^+ = \boldsymbol{I}_m$
- Wenn $\text{rang}(\boldsymbol{A}) = n$: $\boldsymbol{A}^+\boldsymbol{A} = \boldsymbol{I}_n$
- Wenn $\boldsymbol{A}$ quadratisch und invertierbar: $\boldsymbol{A}^+ = \boldsymbol{A}^{-1}$

Anwendungen

Spektralnorm und SVD

Bisher: $\|\boldsymbol{A}\|_2 = \sqrt{\lambda_{\max}\left(\boldsymbol{A}^\top \boldsymbol{A}\right)}$

Aus Definition SVD ist bekannt, dass $\lambda_j\left(\boldsymbol{A}^\top \boldsymbol{A}\right) = \sigma_j(\boldsymbol{A})^2$

Also:

$$\|\boldsymbol{A}\|_2 = \sigma_{\max}(\boldsymbol{A})$$

Interpretation: Größter Singulärwert = maximale Streckung

Die SVD als Summe von Rang-1 Matrizen

SVD in Summenform:

$$\boldsymbol{A} = \boldsymbol{U}_r \boldsymbol{\Sigma}_r \boldsymbol{V}_r^\top = \sum_{i=1}^{r} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^\top$$

Interpretation:

- Jeder Term $\boldsymbol{u}_i \boldsymbol{v}_i^\top$ ist eine **Rang-1 Matrix** (mit $\left\| \boldsymbol{u}_i \boldsymbol{v}_i^\top \right\|_F = 1$)
- σ_i gewichtet die Bedeutung des i-ten Terms
- Große $\sigma_i \rightarrow$ wichtige Richtungen
- Kleine $\sigma_i \rightarrow$ weniger wichtige Richtungen

Idee für Approximation: Verwende nur die wichtigsten Terme!

Rang-k Approximation

Low-Rank Approximation:

$$\boldsymbol{A}_k = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^\top \quad (k < r)$$

Theorem: Optimale Approximation

$\boldsymbol{A}_k$ ist *beste Rang-k Approximation* von $\boldsymbol{A}$ bezüglich der Frobenius- und Spektral-Normen, d.h. $\boldsymbol{A}_k$ löst beide Approximationsprobleme:

$$\boldsymbol{A}_k \in \arg \min_{\substack{\boldsymbol{B} \in \mathbb{R}^{m \times n} \\ \operatorname{rang}(\boldsymbol{B}) \leq k}} \|\boldsymbol{A} - \boldsymbol{B}\|_F \quad \text{und} \quad \boldsymbol{A}_k \in \arg \min_{\substack{\boldsymbol{B} \in \mathbb{R}^{m \times n} \\ \operatorname{rang}(\boldsymbol{B}) \leq k}} \|\boldsymbol{A} - \boldsymbol{B}\|_2$$

Approximationsfehler:

- $\|\boldsymbol{A} - \boldsymbol{A}_k\|_F = \sqrt{\sum_{i=k+1}^{r} \sigma_i^2}$
- $\|\boldsymbol{A} - \boldsymbol{A}_k\|_2 = \sigma_{k+1}$

Interpretation: Fehler bestimmt durch *weggelassene* Singulärwerte

Nicht-Eindeutigkeit in Spektralnorm: Für $\boldsymbol{A} = \operatorname{diag}(3, 2)$, $k = 1$ und $\boldsymbol{B}_b = \operatorname{diag}(b, 0)$ gilt $\|\boldsymbol{A} - \boldsymbol{B}_b\|_2 = \max\{|3 - b|, 2\}$. Damit sind alle $b \in [1, 5]$ optimal; die abgeschnittene SVD entspricht $b = 3$. In Frobenius-Norm ist nur $b = 3$ optimal, denn der Fehler ist $\sqrt{(3 - b)^2 + 2^2}$.

Wahl der optimalen Rang-k Approximation

Kriterien für die Wahl von k:

1. Relativer Fehler (Spektralnorm):

$$\frac{\|\boldsymbol{A} - \boldsymbol{A}_k\|_2}{\|\boldsymbol{A}\|_2} = \frac{\sigma_{k+1}}{\sigma_1}$$

2. Relativer Fehler (Frobenius-Norm):

$$\frac{\|\boldsymbol{A} - \boldsymbol{A}_k\|_F}{\|\boldsymbol{A}\|_F} = \frac{\sqrt{\sum_{i=k+1}^{r} \sigma_i^2}}{\sqrt{\sum_{i=1}^{r} \sigma_i^2}}$$

3. "Energieerhaltung":

$$\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2} \geq p \quad (\text{p*100\% der "Energie"})$$

Praktische Heuristik: k am "Ellenbogen" im $\log(\sigma_i)$-Plot wählen – dort, wo die Singulärwerte abknicken.
(Typische Verläufe: siehe Anhang)

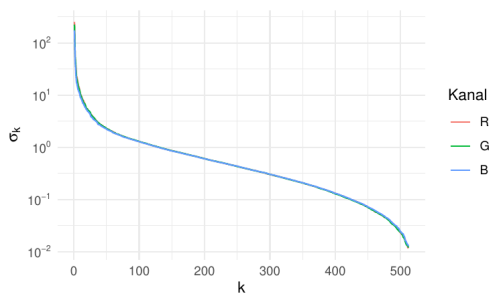
Anwendung: Datenkompression

Bildkompression – *Originalbild*: 659×512 Pixel-Matrix (pro Farbkanal)

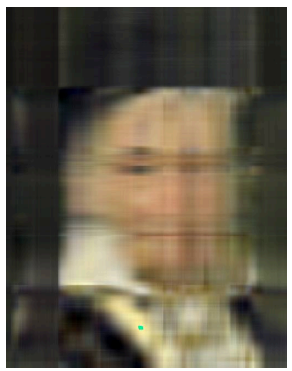
- Volle Speicherung: $659 \times 512 = 337.408$ Zahlen; **Rang-50 SVD**: $(659 \times 50) + 50 + (50 \times 512) = 58.600$ Zahlen $\implies$ *Speicherersparnis*: $\approx 83\%$ (Speicheranteil $\approx 17\%$)!
- **Vorgehen:** SVD berechnen, k anhand der Singulärwerte wählen, nur $\boldsymbol{U}_k, \boldsymbol{\Sigma}_k, \boldsymbol{V}_k$ speichern.



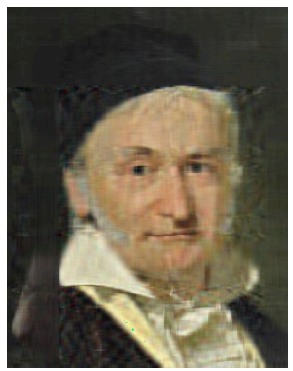
Original



Singulärwerte pro Kanal



$k = 5$



$k = 20$



$k = 50$



$k = 200$

Bildquelle: C. A. Jensen, Porträt C. F. Gauß (1840), gemeinfrei (Wikimedia Commons).

Interaktive Demo: Bildkompression

Fallback: ▶ App direkt öffnen — Screenshot im Anhang.

Anwendung: Empfehlungssysteme

Collaborative Filtering / Recommender Systems

Problem: Netflix-Szenario: m Nutzer, n Filme, aber Daten sehr *sparse*: meiste Nutzer haben meiste Filme nicht bewertet

$$\boldsymbol{R} = \begin{pmatrix} 5 & ? & 1 & ? & 4 \\ ? & 3 & ? & 4 & ? \\ 2 & 1 & ? & ? & 5 \\ ? & 5 & 4 & 3 & ? \end{pmatrix} \in \mathbb{R}^{m \times n}$$

Idee: Nutzer-Film-Präferenzen liegen in einem *niedrigdimensionalen Raum* (Genres und Nutzerklassen).

SVD-Ansatz:

1. Ergänze fehlende Einträge (z.B. durch Spaltenmittelwerte)
2. Berechne Rang-k Approximation: $\boldsymbol{R}_k = \boldsymbol{U}_k \boldsymbol{\Sigma}_k \boldsymbol{V}_k^\top$
3. Nutze $\boldsymbol{R}_k$ für Vorhersagen fehlender Ratings

Interpretation: $\boldsymbol{v}_j$ = "gelernte" Film-Genres, $\boldsymbol{u}_i$ = Nutzer-Präferenzen in diesen Genre-Dimensionen, σ_i = Wichtigkeit der Dimension *(mehr: siehe Anhang)*

Wann ist SVD besonders nützlich?

Ideale Situationen für SVD:

1. *Niedrig-Rang Strukturen*: $\text{rang}(\boldsymbol{A}) \ll \min(m, n)$
2. *Schnell abfallende Singulärwerte*: Wenige dominieren
3. *Überbestimmte Systeme*: $m > n$, möglicherweise inkonsistent
4. *Datenanalyse*: Hauptkomponentenanalyse (PCA) ohne Kreuzprodukte zu berechnen.
5. *Numerische Robustheit*: Alternative zu Normalgleichungen

Rechenaufwand:

- *SVD*: $O(\min(m^2n, mn^2))$, für $m \gg n$ etwa $4mn^2$
- *Normalgleichungen*: $O(mn^2 + n^3)$, für $m \gg n$ etwa mn^2.
- Für $m \gg n$ sind Normalgleichungen schneller, aber SVD ist robuster $\rightarrow$ trade-off zwischen Geschwindigkeit und Stabilität

SVD vs. Eigenwertzerlegung

Eigenschaft	**Eigenwertzerlegung**	**SVD**
Matrix-Typ	Quadratisch	Beliebig $m \times n$
Orthogonale Zerlegung	Nur symmetrisch ($\rightarrow$ Spektralzerlegung)	Immer
Numerische Stabilität	Kann instabil sein	Stabil
Existenz	Nur für diagonalisierbare $\boldsymbol{A}$	Immer
Geometrische Interpretation	Hauptachsen (symmetrisch)	“Optimale” Koordinaten

Zusammenfassung & Self-Check

Zusammenfassung

Kernkonzepte:

1. *SVD erweitert Eigenwertzerlegung* auf beliebige $m \times n$ Matrizen
2. *Singulärwerte vs. Eigenwerte*: $\sigma_i(\boldsymbol{A}) = \sqrt{\lambda_i\left(\boldsymbol{A}^\top \boldsymbol{A}\right)}$
3. *Hauptsatz*: $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$ mit orthogonalen $\boldsymbol{U}$ $(m \times m)$, $\boldsymbol{V}$ $(n \times n)$, diagonalem $\boldsymbol{\Sigma}$ $(m \times n)$
4. *Reduzierte SVD*: $\boldsymbol{A} = \boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^\top$ für Effizienz $(r = \operatorname{rang}(\boldsymbol{A}))$
5. *Pseudoinverse*: $\boldsymbol{A}^+ = \boldsymbol{V}_r\boldsymbol{\Sigma}_r^{-1}\boldsymbol{U}_r^\top$

Anwendungen: Lösung von *Kleinste-Quadrate-Problemen*, optimale *Low-Rank Approximation* (Datenkompression, -analyse)

Praktische Hinweise:

- SVD **nicht** über $\boldsymbol{A}^\top \boldsymbol{A}$ berechnen (numerisch instabil) – spezielle Algorithmen (z.B. Golub-Reinsch) nutzen: in R `svd(A)`
- *truncated SVD* für sehr große Matrizen: `irlba::irlba(A, nv = k)` (iterativ, Lanczos) bzw. `irlba::svdr(A, k)` (randomisiert)

Self-Check

Welche Aussagen sind korrekt?

1. Wenn $\boldsymbol{A} \in \mathbb{R}^{m \times n}$, dann ist $\boldsymbol{A}^\top \boldsymbol{A} \in \mathbb{R}^{m \times m}$
2. Wenn $\boldsymbol{A} \in \mathbb{R}^{m \times n}$, dann ist $\boldsymbol{A}^\top \boldsymbol{A}$ symmetrisch
3. Die Eigenwerte von $\boldsymbol{A}^\top \boldsymbol{A}$ sind die Singulärwerte von $\boldsymbol{A}$
4. Wenn $\boldsymbol{A} \in \mathbb{R}^{n \times n}$, dann ist $\boldsymbol{A}$ immer diagonalisierbar
5. $\boldsymbol{A}^\top \boldsymbol{A}$ ist immer orthogonal diagonalisierbar

Anhang

Orthogonalität der Singulärvektoren

Warum sind die $\sigma_i \boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i$ orthogonal?

Für $i \neq j$:

$$\begin{aligned}(\boldsymbol{A}\boldsymbol{v}_i)^\top (\boldsymbol{A}\boldsymbol{v}_j) &= \boldsymbol{v}_i^\top \left(\boldsymbol{A}^\top \boldsymbol{A}\right) \boldsymbol{v}_j \\ &= \boldsymbol{v}_i^\top (\lambda_j \boldsymbol{v}_j) \\ &= \lambda_j \left(\boldsymbol{v}_i^\top \boldsymbol{v}_j\right) \\ &= \lambda_j \cdot 0 = 0\end{aligned}$$

Für $i = j$:

$$\|\boldsymbol{A}\boldsymbol{v}_i\|^2 = \boldsymbol{v}_i^\top \left(\boldsymbol{A}^\top \boldsymbol{A}\right) \boldsymbol{v}_i = \lambda_i \|\boldsymbol{v}_i\|^2 = \lambda_i = \sigma_i^2$$

$\Longrightarrow$ Für $i, j \leq r$ (also $\sigma_i, \sigma_j > 0$) ist $\boldsymbol{u}_i^\top \boldsymbol{u}_j = \frac{(\boldsymbol{A}\boldsymbol{v}_i)^\top (\boldsymbol{A}\boldsymbol{v}_j)}{\sigma_i \sigma_j} = 0$ für $i \neq j$ bzw. $= 1$ für $i = j$: Die $\boldsymbol{u}_1, \ldots, \boldsymbol{u}_r$ sind orthonormal! *(Die übrigen $\boldsymbol{u}_{r+1}, \ldots, \boldsymbol{u}_m$ werden als orthonormale Ergänzung gewählt.)*

↩ zurück: „Definition: Singulärvektoren"

Bsp: Singulärvektoren – vollständige Rechnung (1)

Matrix $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix}$: $\quad \boldsymbol{A}^\top \boldsymbol{A}$ mit $\boldsymbol{\lambda} \approx (9.53, 1.47)$:

Rechte Singulärvektoren (Eigenvektoren von $\boldsymbol{A}^\top \boldsymbol{A}$):

Für $\lambda_1 \approx 9.53$:

$$\begin{pmatrix} 6 & 4 \\ 4 & 5 \end{pmatrix} \begin{pmatrix} v_1^{(1)} \\ v_2^{(1)} \end{pmatrix} = 9.53 \begin{pmatrix} v_1^{(1)} \\ v_2^{(1)} \end{pmatrix}$$

Lösung: $\boldsymbol{v}_1 \approx \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix}$

Für $\lambda_2 \approx 1.47$: $\boldsymbol{v}_2 \approx \begin{pmatrix} -0.662 \\ 0.75 \end{pmatrix}$ (normiert, orthogonal zu $\boldsymbol{v}_1$)

Bsp: Singulärvektoren – vollständige Rechnung (2)

Linke Singulärvektoren:

$$\boldsymbol{u}_1 = \frac{\boldsymbol{A}\boldsymbol{v}_1}{\sigma_1} \approx \begin{pmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -0.75 \\ -0.662 \end{pmatrix} / 3.09 = \begin{pmatrix} -0.672 \\ -0.7 \\ -0.243 \end{pmatrix}, \qquad \text{analog: } \boldsymbol{u}_2 = \frac{\boldsymbol{A}\boldsymbol{v}_2}{\sigma_2} \approx \begin{pmatrix} 0.691 \\ -0.474 \\ -0.546 \end{pmatrix}$$

Verifikation Orthonormalität:

- $\boldsymbol{u}_1^\top \boldsymbol{u}_2 \approx (-0.672)(0.691) + (-0.7)(-0.474) + (-0.243)(-0.546) = -0.464 + 0.332 + 0.133 \approx 0$ ✓
- $\|\boldsymbol{u}_1\| \approx \sqrt{0.672^2 + 0.7^2 + 0.243^2} = \sqrt{0.452 + 0.49 + 0.059} \approx 1$ ✓

↩ zurück: „Bsp: Singulärvektoren"

Beweis des SVD-Theorems (Skizze)

Konstruktion der Zerlegung:

1. *Rechte Singulärvektoren*: Eigenvektoren von $\boldsymbol{A}^\top \boldsymbol{A}$

$$\boldsymbol{V} = (\boldsymbol{v}_1 \mid \boldsymbol{v}_2 \mid \cdots \mid \boldsymbol{v}_n)$$

2. *Linke Singulärvektoren*: $\boldsymbol{u}_i = \boldsymbol{A}\boldsymbol{v}_i / \sigma_i$ für $i \leq r$

$$\boldsymbol{U}_r = (\boldsymbol{u}_1 \mid \boldsymbol{u}_2 \mid \cdots \mid \boldsymbol{u}_r)$$

3. *Vervollständigung*: Erweitere $\boldsymbol{U}_r$ zu Orthogonalbasis des $\mathbb{R}^m$
4. *Verifikation*: $\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$ für $i \leq r$, $\boldsymbol{A}\boldsymbol{v}_i = \boldsymbol{0}$ für $i > r$

↩ zurück: „Der SVD-Hauptsatz”

Typische Singulärwert-Verläufe

1. Schneller Abfall: $\sigma_i \approx c \cdot e^{-\alpha i}$

- Gut geeignet für Low-Rank Approximation
- Wenige dominante Singulärwerte

2. Linearer Abfall: $\sigma_i \approx c - \alpha i$

- Moderate Approximation möglich
- Mittlerer Kompressionsfaktor

3. Langsamer Abfall: $\sigma_i \approx c \cdot i^{-\alpha}$

- Schwierige Approximation
- Viele wichtige Komponenten

↩ zurück: „Wahl der optimalen Rang-k Approximation”

Empfehlungssysteme: Details

Interpretation der Faktoren:

- **Rechte Singulärvektoren $\boldsymbol{v}_j$**: “gelernte” Film-Genres
  - $\boldsymbol{v}_1$ könnte “Action vs. Drama” kodieren, $\boldsymbol{v}_2$ “Komödie vs. Thriller”, etc
- **Linke Singulärvektoren $\boldsymbol{u}_i$**: Nutzer-Präferenzen in diesen Genre-Dimensionen
- **Singulärwerte σ_i**: Wichtigkeit dieser Genre-Dimension

Vorteile:

- Reduziert Speicher: $k + (m + n) \cdot k \ll m \cdot n$ für $k \ll \min(m, n)$
- “Glättet” die Daten (Low-Rank = *Regularisierung*)
- Kann auch bei sehr spärlichen Daten funktionieren

Modernere Varianten:

- *Matrix Completion:* Low-Rank-Faktorisierung nur über die *beobachteten* Einträge; mit Nichtnegativitäts-Nebenbedingung: *Non-negative Matrix Factorization* (NMF)

↩ zurück: „Anwendung: Empfehlungssysteme”