

Methode der Kleinsten Quadrate

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- **Kondition** & Konditionszahl $\kappa(\mathbf{A})$
- **Matrixnormen** (besonders $\|\cdot\|_2$) und **Orthogonalmatrizen**
- Matrixzerlegungen: **LU-** und **Cholesky-Zerlegung**
- **SVD**: $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$, **Pseudoinverse** $\mathbf{A}^+$, Reduzierte SVD
- **Lineare Algebra**
 - **Normalengleichungen**: $\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}$
 - (Orthogonale) Projektionen auf Unterräume
- **Statistik**
 - Lineares Regressionsmodell $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$
 - Methode der Kleinsten Quadrate (OLS)

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $\text{rang}(\mathbf{A}) = n$. Die Kleinste-Quadrate-Lösung $\hat{\mathbf{x}}$ von $\min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2$ erfüllt ...

1. $\mathbf{A}\hat{\mathbf{x}} = \mathbf{b}$
2. $\mathbf{A}^\top \mathbf{A}\hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}$
3. $\mathbf{A}\mathbf{A}^\top \hat{\mathbf{x}} = \mathbf{A}\mathbf{b}$
4. $\hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}$

Frage 2: Sei $\hat{\mathbf{b}} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}$ die orthogonale Projektion von $\mathbf{b}$ auf den Spaltenraum von $\mathbf{A}$. Welche Aussage gilt **immer**?

1. $\hat{\mathbf{b}} = \mathbf{b}$
2. $\mathbf{b} - \hat{\mathbf{b}} \perp \text{col}(\mathbf{A})$
3. $\|\hat{\mathbf{b}}\|_2 \geq \|\mathbf{b}\|_2$
4. $\hat{\mathbf{b}} = \mathbf{0}$

Recap: Kleinste Quadrate

Recap: Kleinste Quadrate

Kleinste-Quadrate-Problem (KQ-Problem)

- Gegeben sei Matrix $\mathbf{A} \in \mathbb{R}^{m \times n}$ und Vektor $\mathbf{b} \in \mathbb{R}^m$.
- Wir wollen einen Vektor $\hat{\mathbf{x}} \in \mathbb{R}^n$ finden, sodass $\|\mathbf{A}\hat{\mathbf{x}} - \mathbf{b}\|$ minimal ist.

Anmerkung:

- Hat das LGS eine Lösung $\mathbf{x}^*$, dann gilt $\|\mathbf{A}\mathbf{x}^* - \mathbf{b}\| = 0$ und $\mathbf{x}^*$ ist automatisch auch eine Lösung des Kleinste-Quadrate-Problems.
- Interessant ist die Problemstellung insbesondere für “Gleichungssysteme” $\mathbf{A}\mathbf{x}^* \approx \mathbf{b}$, die keine *exakte* Lösung besitzen.

Motivation

KQ-Methode *fundamentalst* in Statistik und Machine Learning:

- **Beispiel: Lineare Regression**

- **Problem:** Vorhersage von Immobilienpreisen basierend auf Wohnfläche
- **Daten:** n Beobachtungen (x_i, y_i) mit x_i = Fläche in m^2 , y_i = Preis in €
- **Modell:** $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ mit Fehlerterm ϵ_i
- **Matrix-Form:** $\mathbf{b} = \mathbf{A}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ mit


$$\mathbf{A} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}$$

- **Lösung:** $\hat{\boldsymbol{\beta}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$ minimiert $\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$

- **Weitere Anwendungen:**

- **Generalisierte Lineare Modelle, Additive Modelle:** approximative Lösungen über iterative KQ-Probleme
- **Deep Learning:** Training neuronaler Netze (minimiert oft KQ-Fehler)
- **Computer Vision:** Kamerakalibration, 3D-Rekonstruktion aus 2D-Bildern
- **Signal Processing:** Rauschreduktion/De-Noising, Signalschätzung
- **Geodäsie:** GPS-Positionsbestimmung
-

Recap: Kleinste Quadrate



Theorem

Die Lösungsmenge des KQ-Problems gleicht der Lösungsmenge des LGS

$$\mathbf{A}\hat{\mathbf{x}} = \hat{\mathbf{b}} \quad \text{mit } \hat{\mathbf{b}} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}.$$

Recap: Kleinste Quadrate

Theorem

Die Lösungsmenge des KQ-Problems gleicht der Lösungsmenge der Normalgleichungen

$$\mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{b}.$$

Theorem

Falls $\text{rang}(\mathbf{A}) = n$, ist $\mathbf{A}^\top \mathbf{A}$ invertierbar und das KQ-Problem hat die eindeutige Lösung

$$\hat{\mathbf{x}} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b} =: \mathbf{A}^+ \mathbf{b}.$$

Quiz

Welche der folgenden Aussagen sind wahr? (*mehrere Antworten möglich*)

1. $\mathbf{A}\mathbf{A}^+ = \mathbf{I}_m$
2. $\mathbf{A}\mathbf{A}^+\mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$
3. $\mathbf{r} = \mathbf{b} - \mathbf{A}\hat{\mathbf{x}} \perp \text{col}(\mathbf{A})$
4. $\mathbf{b} = \text{proj}_V\mathbf{b} + \text{proj}_{V^\perp}\mathbf{b}$ für jeden Untervektorraum V

Kondition des KQ-Problems

Kondition

Vorbemerkungen

- Wir untersuchen nun die **Kondition** von KQ-Problemen $\mathbf{A}\mathbf{x} \approx \mathbf{b}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{b} \in \mathbb{R}^m$.
- Wir beschränken uns auf den Fall $m \geq n$ und $\text{rang}(\mathbf{A}) = n$
 $\implies$ eindeutige Lösung existiert.
- Im folgenden $\|\cdot\| = \|\cdot\|_2$ (natürliche Norm für KQ-Probleme).
- Für nicht notwendigerweise quadratische Matrizen definieren wir

$$\kappa(\mathbf{A}) = \begin{cases} \infty, & \text{rang}(\mathbf{A}) < n, \\ \|\mathbf{A}\| \|\mathbf{A}^+\|, & \text{sonst.} \end{cases}$$

Kondition bezüglich $\mathbf{b}$

Theorem


Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ fix und f das Problem mit Lösung $f(\mathbf{b}) = \mathbf{A}^+ \mathbf{b}$. Dann gilt

$$\frac{\|f(\tilde{\mathbf{b}}) - f(\mathbf{b})\|}{\|f(\mathbf{b})\|} \leq \kappa \frac{\|\tilde{\mathbf{b}} - \mathbf{b}\|}{\|\mathbf{b}\|} \quad \text{mit} \quad \kappa = \kappa_2(\mathbf{A}) \frac{\|\mathbf{b}\|}{\|\text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}\|}.$$

Beweis: siehe **Anhang**

Kondition bezüglich $\mathbf{b}$

$$\kappa = \kappa_2(\mathbf{A}) \frac{\|\mathbf{b}\|}{\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|}$$



Interpretation

- Erinnerung:

$$\|\mathbf{b}\|^2 = \|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|^2 + \|\text{proj}_{\text{col}(\mathbf{A})^\perp}\mathbf{b}\|^2 \geq \|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|^2.$$

- **Frage:** Was sind best und worst case für κ ?

Kondition bezüglich $\mathbf{A}$

Theorem

Sei $\mathbf{b} \in \mathbb{R}^m$ fix und f das Problem mit Lösung $f(\mathbf{A}) = \mathbf{A}^+ \mathbf{b}$. Dann gilt für kleine Störungen $\tilde{\mathbf{A}} \rightarrow \mathbf{A}$ (in erster Ordnung)


$$\frac{\|f(\tilde{\mathbf{A}}) - f(\mathbf{A})\|}{\|f(\mathbf{A})\|} \lesssim \kappa \frac{\|\tilde{\mathbf{A}} - \mathbf{A}\|}{\|\mathbf{A}\|}$$

mit $\kappa = \kappa_2(\mathbf{A}) + \kappa_2(\mathbf{A})^2 \frac{\|\mathbf{r}\|}{\|\text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}\|}.$

Beweis: Sehr aufwändige und langweilige Rechnung.

Kondition bezüglich $\mathbf{A}$

$$\kappa = \kappa_2(\mathbf{A}) + \kappa_2(\mathbf{A})^2 \frac{\|\mathbf{r}\|}{\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|}$$



Interpretation

- Best case: $\mathbf{r} = \mathbf{0} \Rightarrow \mathbf{Ax} = \mathbf{b}$ ist lösbar $\Rightarrow \kappa = \kappa_2(\mathbf{A})$.
- Worst case: $\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b} = \mathbf{0}$, aber $\mathbf{r} \neq \mathbf{0}$
 - $\Rightarrow \mathbf{Ax} = \mathbf{b}$ ist nicht lösbar und $\mathbf{b} \perp \text{col}(\mathbf{A})$
 - $\Rightarrow \kappa = \infty$.
- Normalerweise: $\mathbf{r} \neq \mathbf{0}$ und $\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b} \neq \mathbf{0} \Rightarrow \kappa = O(\kappa_2(\mathbf{A})^2)$.

Lösungsverfahren

Frage

Um die Lösung $\hat{x} = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{b}$ zu berechnen, sei folgende Funktion gegeben:

```
1 kq_solve <- function(A, b) {  
2   solve(t(A) %*% A) %*% t(A) %*% b  
3 }
```

Aufgabe: Finde den Fehler in der Funktion.

Invertiere niemals eine Matrix!

`solve(M)` berechnet die volle Inverse — teurer *und* instabiler, als das LGS $\mathbf{M}\mathbf{x} = \mathbf{c}$ direkt zu lösen.

besser: `solve(M, c)`.

Cholesky-Zerlegung

- Die Normalengleichung $\mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}$ gibt uns ein einfaches Lösungsverfahren:
 1. Berechne $\mathbf{M} = \mathbf{A}^\top \mathbf{A}$ und $\mathbf{c} = \mathbf{A}^\top \mathbf{b}$.
 2. Berechne Cholesky-Zerlegung $\mathbf{M} = \mathbf{L} \mathbf{L}^\top$.
 3. Löse $\mathbf{L} \mathbf{y} = \mathbf{c}$ durch Vorwärtssubstitution.
 4. Löse $\mathbf{L}^\top \mathbf{x} = \mathbf{y}$ durch Rückwärtssubstitution.
- Das Verfahren ist effizient, aber möglicherweise instabil:
 - Fehler in $\mathbf{A}^\top \mathbf{A}$ beeinflussen alle folgenden Schritte.
 - Man kann zeigen, dass der relative algorithmische Fehler typischerweise von der Größenordnung $\kappa_2(\mathbf{A})^2 \epsilon_{mach}^1$ ist.
 - Vergleiche mit Best-Case-Kondition $O(\kappa_2(\mathbf{A}))$.

Alternative Lösungswege

- Wir würden gerne $\mathbf{A}^\top \mathbf{A}$ vermeiden und direkt auf $\mathbf{A}$ operieren.
- Erinnerung: KQ-Lösung zu $\mathbf{A}\mathbf{x} = \mathbf{b}$ ist

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2$$

- Wir wollen das Problem mit einer Matrix $\mathbf{Q}$ zu einem “einfacheren” Problem $\mathbf{Q}\mathbf{A}\mathbf{x} \approx \mathbf{Q}\mathbf{b}$ transformieren ohne die Lösung zu ändern.

$\implies \mathbf{Q}$ soll **Orthogonalmatrix** sein, denn für diese gilt

$$\|\mathbf{Q}\mathbf{A}\mathbf{x} - \mathbf{Q}\mathbf{b}\| = \|\mathbf{Q}(\mathbf{A}\mathbf{x} - \mathbf{b})\| = \|\mathbf{A}\mathbf{x} - \mathbf{b}\|.$$

Erinnerung: **Orthogonalmatrix** $\mathbf{Q}$

- $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$, $\mathbf{Q}^{-1} = \mathbf{Q}^\top$ (“Rotation/Spiegelung”);
- Produkte von Orthogonalmatrizen sind orthogonal.
- Normerhaltend für $\|\cdot\|_2$: $\|\mathbf{Q}\mathbf{z}\|_2 = \sqrt{\mathbf{z}^\top \mathbf{Q}^\top \mathbf{Q} \mathbf{z}} = \sqrt{\mathbf{z}^\top \mathbf{z}} = \|\mathbf{z}\|_2$ für alle $\mathbf{z} \in \mathbb{R}^m$.
- Alle Singulärwerte $\sigma_i(\mathbf{Q}) = 1$ (da $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}$) $\Rightarrow \kappa_2(\mathbf{Q}) = \frac{\sigma_{\max}}{\sigma_{\min}} = 1$
 $\implies$ Multiplikation mit $\mathbf{Q}$ ist immer gut konditioniert.

QR-Zerlegung

Def.: QR-Zerlegung

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $m \geq n$ und $\mathbf{Q} \in \mathbb{R}^{m \times m}$ eine *Orthogonalmatrix*, sodass

$$\mathbf{Q}^\top \mathbf{A} = \begin{pmatrix} \mathbf{R} \\ \mathbf{0}_{(m-n) \times n} \end{pmatrix},$$

wobei $\mathbf{R} \in \mathbb{R}^{n \times n}$ eine *obere Dreiecksmatrix* ist. Dann nennen wir

$$\mathbf{A} = \mathbf{Q} \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix}$$

eine **QR-Zerlegung** von $\mathbf{A}$.

Anmerkung:

- Es gibt immer eine QR-Zerlegung von $\mathbf{A}$.
- Die Zerlegung ist nicht eindeutig.

Beispiel: QR-Zerlegung

Gegeben:

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix}$$

Gesucht:

$$\mathbf{Q}^\top \mathbf{A} = \begin{pmatrix} \mathbf{R} \\ \mathbf{0}_{1 \times 2} \end{pmatrix} \text{ mit } \mathbf{Q} \in \mathbb{R}^{3 \times 3} \text{ und } \mathbf{R} \in \mathbb{R}^{2 \times 2}$$

Methode:

Gram-Schmidt-Orthonormalisierung auf den Spalten von $\mathbf{A}$

Schritt 1: Erste Spalte $\mathbf{a}_1 = (1 \ 0 \ 0)^\top$

- Normalisierung: $\mathbf{q}_1 = \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|} = (1 \ 0 \ 0)^\top \implies R_{11} = \|\mathbf{a}_1\| = 1$

Schritt 2: Zweite Spalte $\mathbf{a}_2 = (2 \ 0 \ 2)^\top$

- Projektion auf $\mathbf{q}_1$: $R_{12} = \mathbf{q}_1^\top \mathbf{a}_2 = 2$
- Orthogonalisierung: $\tilde{\mathbf{q}}_2 = \mathbf{a}_2 - R_{12}\mathbf{q}_1 = (2 \ 0 \ 2)^\top - (2 \ 0 \ 0)^\top = (0 \ 0 \ 2)^\top$
- Normalisierung: $\mathbf{q}_2 = \frac{\tilde{\mathbf{q}}_2}{\|\tilde{\mathbf{q}}_2\|} = (0 \ 0 \ 1)^\top, R_{22} = \|\tilde{\mathbf{q}}_2\| = 2$

Schritt 3: Vervollständige zu Orthonormalbasis von $\mathbb{R}^3$: wähle $\mathbf{q}_3 \perp \mathbf{q}_1, \mathbf{q}_2$, z.B. $\mathbf{q}_3 = (0 \ 1 \ 0)^\top$

Ergebnis: $\mathbf{Q} = (\mathbf{q}_1 \quad \mathbf{q}_2 \quad \mathbf{q}_3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}, \quad \mathbf{R} = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}$ (*Verifikation* $\rightarrow$ Anhang)

QR-Zerlegung: Idee

Theorem

Sei $\mathbf{A} \in \mathbb{R}^{m \times n}$ mit $m \geq n$, $\mathbf{b} \in \mathbb{R}^m$ und $\mathbf{Q} \in \mathbb{R}^{m \times m}$ eine Orthogonalmatrix, sodass

$$\mathbf{Q}^\top \mathbf{A} = \begin{pmatrix} \mathbf{R} \\ \mathbf{0}_{(m-n) \times n} \end{pmatrix} \quad \text{und} \quad \mathbf{Q}^\top \mathbf{b} = \begin{pmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{pmatrix}$$

mit $\mathbf{R} \in \mathbb{R}^{n \times n}$ invertierbar. Dann gilt

$$\hat{\mathbf{x}} = \mathbf{R}^{-1} \mathbf{c}_1 = \arg \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\|_2.$$

Numerisch bilden wir $\mathbf{R}^{-1}$ **nicht** explizit, sondern lösen das Dreieckssystem $\mathbf{R}\hat{\mathbf{x}} = \mathbf{c}_1$ durch Rückwärtssubstitution.

Beweis:

- Es gilt $\|\mathbf{Ax} - \mathbf{b}\|^2 = \|\mathbf{Q}^\top \mathbf{Ax} - \mathbf{Q}^\top \mathbf{b}\|^2 = \|\mathbf{Rx} - \mathbf{c}_1\|^2 + \|\mathbf{c}_2\|^2$.
- Weil der zweite Term nicht von $\mathbf{x}$ abhängt, gilt


$$\arg \min_{\mathbf{x}} \|\mathbf{Ax} - \mathbf{b}\| = \arg \min_{\mathbf{x}} \|\mathbf{Rx} - \mathbf{c}_1\|.$$

- $\hat{\mathbf{x}} = \mathbf{R}^{-1} \mathbf{c}_1$ ist Lösung, weil $\|\mathbf{R}\hat{\mathbf{x}} - \mathbf{c}_1\| = \|\mathbf{RR}^{-1} \mathbf{c}_1 - \mathbf{c}_1\| = 0$.

Konstruktion von Q

- Wie beim Gauß-Verfahren erzeugen wir R durch Nullen unter der Diagonalen. Dazu multiplizieren wir A von links mit **orthogonalen** Transformationen; ihr Produkt ist $Q^\top$.
- In Spalte k sollen die $m - k$ Einträge unter a_{kk} null werden:
- Givens-Rotation:**
- Householder-Reflexion:**

Givens-Rotation




$G_{ij}(\theta)$ dreht die Projektion von a_k auf $\text{span}(e_i, e_j)$ auf e_i .
So wird **ein** ausgewählter Eintrag a_{jk} null.

Bei üblicher Drehrichtung gilt

$$\theta = -\text{atan2}(A_{jk}, A_{ik}).$$

Householder-Reflexion



Definiere den nach oben mit Nullen aufgefüllten Rest der k -ten Spalte von A : $z_k := \sum_{\ell=k}^m A_{\ell k} e_\ell$.
Spiegelebene $v_k^\perp$ halbiert den Winkel zwischen z_k und e_k .
Nach Reflexion gilt $a_{\ell k}^{\text{neu}} = 0$ **für alle** $\ell > k$, Einträge mit $\ell < k$ bleiben unverändert.

$$\text{Wähle } \alpha = \pm \|z_k\|_2, \quad z_k \neq \alpha e_k, \quad v_k = \frac{z_k - \alpha e_k}{\|z_k - \alpha e_k\|_2},$$

$$H_k = I - 2v_k v_k^\top, \quad H_k z_k = \alpha e_k.$$

Pseudoinverse und Kleinste Quadrate

SVD-Lösung:

$$\mathbf{x} = \mathbf{A}^+ \mathbf{b} = \mathbf{V}_r \mathbf{\Sigma}_r^{-1} \mathbf{U}_r^\top \mathbf{b}$$

Warum funktioniert das?

$$\mathbf{A}\mathbf{x} = \mathbf{A}\mathbf{A}^+ \mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})} \mathbf{b}$$

Vorteile gegenüber Normalengleichungen:

- Arbeitet direkt mit $\mathbf{A}$, nicht $\mathbf{A}^\top \mathbf{A} \rightarrow$ numerisch stabiler
- Funktioniert auch für rangdefiziente Matrizen ($\text{rang}(\mathbf{A}) < n$) – liefert dann die KQ-Lösung mit minimaler Norm:

$$\mathbf{A}^+ \mathbf{b} = \arg \min_{\substack{\mathbf{x} \in \mathbb{R}^n \\ \mathbf{A}^\top \mathbf{A} \mathbf{x} = \mathbf{A}^\top \mathbf{b}}} \|\mathbf{x}\|_2$$

- Explizite Konstruktion der Lösung, klare geometrische Interpretation

Demo: Ein KQ-Problem, drei Verfahren

Lineare Regression mit **fast kollinearen** Spalten — die wahre Lösung ist bekannt:

```
1 set.seed(1)
2 m <- 100
3 x <- runif(m)
4 A <- cbind(1, x, x + 1e-6 * runif(m)) # 3. Spalte fast identisch zur 2.
5 beta_wahr <- c(1, 2, 3)
6 b <- A %*% beta_wahr # exakte Daten: Loesung = beta_wahr
7 kappa(A, exact = TRUE)
```

[1] 6592188

$$\bullet \kappa_2(\mathbf{A}) \approx 7 \cdot 10^6 \implies \kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2 \approx 4 \cdot 10^{13}$$

Vorhersage: Doppelte Gleitkommazahlen haben ≈ 16 Dezimalstellen. Wie viele *korrekte* Stellen von β erwarten Sie

- für die Normalgleichungen (Fehler $\sim \kappa_2(\mathbf{A})^2 \epsilon_{mach}$)?
- für QR/SVD (Fehler $\sim \kappa_2(\mathbf{A}) \epsilon_{mach}$)?

Demo: Ergebnisse

```
1 beta_ne <- solve(t(A) %*% A, t(A) %*% b) # Normalgleichungen (ohne Inverse!)
2 beta_qr <- qr.solve(A, b)                # QR-Zerlegung
3 s      <- svd(A)
4 beta_svd <- s$v %*% ((t(s$u) %*% b) / s$d) # SVD: A+ b
5 fehler   <- function(beta_hat) max(abs(beta_hat - beta_wahr))
6 sapply(list("Normalengl." = beta_ne, QR = beta_qr, SVD = beta_svd), fehler)
```

Normalengl.	QR	SVD
8.77e-03	1.19e-11	1.55e-10

- **Normalgleichungen:**

Fehler $\approx 10^{-2}$ —

passt zu $\kappa_2(\mathbf{A})^2 \epsilon_{mach} \approx 4 \cdot 10^{13} \cdot 2 \cdot 10^{-16} \approx 10^{-2}$

⇒ nur noch **2–3 korrekte Stellen**, obwohl wir die Matrixinversion vermieden haben:
die *Quadrierung der Konditionszahl* ist das Problem, nicht (nur) `solve(M)`.

- **QR/SVD:**

Fehler $\approx 10^{-10}$ — passt zu $\kappa_2(\mathbf{A}) \epsilon_{mach} \approx 10^{-9}$

⇒ **ca. 10 korrekte Stellen** statt nur 2–3 bei den Normalgleichungen.

Vergleich der Lösungsverfahren

Verfahren	Ansatz	Komplexität ($m \gg n$)	Stabilität
Cholesky auf $\mathbf{A}^\top \mathbf{A}$	Normalengleichungen	$O(mn^2)$, kleinste Konstante ($\approx mn^2$)	Fehler $O(\kappa_2(\mathbf{A})^2 \epsilon_{mach})$ – potenziell instabil
QR-Zerlegung	löse $\mathbf{R}\hat{\mathbf{x}} = \mathbf{c}_1$	$O(mn^2)$ ($\approx 2mn^2$, Householder)	stabil – Standardwahl
SVD	$\hat{\mathbf{x}} = \mathbf{A}^+ \mathbf{b} = \mathbf{V}_r \mathbf{\Sigma}_r^{-1} \mathbf{U}_r^\top \mathbf{b}$	$O(mn^2)$, größte Konstante	am stabilsten, auch für $\text{rang}(\mathbf{A}) < n$

- Für $m \gg n$ haben alle drei Verfahren dieselbe Komplexitätsordnung $O(mn^2)$ – die Konstanten (und die Stabilität!) unterscheiden sich aber deutlich: Normalengleichungen + Cholesky brauchen etwa halb so viele Operationen wie Householder-QR, die SVD ein Mehrfaches davon.
- SVD besonders sinnvoll, wenn $\mathbf{A}$ fast singulär ist ($\sigma_{\min}(\mathbf{A}) \approx 0 \Rightarrow \kappa(\mathbf{A}) \gg 1$): die $r - k$ kleinsten Singulärwerte auf 0 setzen $\rightarrow$ **Rang-k-Approximation** als Regularisierung.

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- **Kondition des KQ-Problems:**
bzgl. $\mathbf{b}$ abhängig vom Winkel zwischen $\mathbf{b}$ und $\text{col}(\mathbf{A})$,
bzgl. $\mathbf{A}$ typischerweise $O(\kappa_2(\mathbf{A})^2)$.
- $\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2 \implies$ **Normalgleichungen** können instabil sein – und: **Invertiere niemals eine Matrix!**
- Drei Lösungsverfahren:
 - **Cholesky** (schnell, heikel),
 - **QR-Zerlegung** (Standardwahl),
 - **SVD** (am stabilsten, auch für rangdefiziente $\mathbf{A}$).

Nächste Vorlesung

- Probabilistische Methoden
- Iterative Methoden

Self-Check (1/2)

Frage 1: Welches Verfahren ist für KQ-Probleme mit $\text{rang}(\mathbf{A}) = n$ die übliche **Standardwahl** (guter Kompromiss aus Stabilität und Geschwindigkeit)?

1. Cholesky auf $\mathbf{A}^\top \mathbf{A}$
2. QR-Zerlegung
3. SVD
4. Explizite Inversion: `solve(t(A) %*% A) %*% t(A) %*% b`

Frage 2: Für $m \gg n$ gilt für die Komplexität von Cholesky, QR und SVD:

1. Alle drei haben dieselbe Ordnung $O(mn^2 + n^3)$, aber deutlich verschiedene Konstanten.
2. Cholesky ist $O(mn)$, QR ist $O(mn^2)$, SVD ist $O(m^2n^2)$.
3. Die SVD hat exponentielle Laufzeit.
4. QR ist immer am langsamsten.

Self-Check (2/2)

Frage 3: Die Kondition des KQ-Problems bezüglich $\mathbf{b}$ explodiert ($\kappa \rightarrow \infty$) genau dann, wenn ...

1. $\mathbf{b} \in \text{col}(\mathbf{A})$.
2. $\mathbf{b} \perp \text{col}(\mathbf{A})$, d.h. $\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b} = \mathbf{0}$.
3. das Residuum $\mathbf{r} = \mathbf{0}$ ist.
4. $\mathbf{A}$ eine Orthogonalmatrix ist.

Frage 4: Warum sind die Normalengleichungen numerisch heikel, selbst wenn man die explizite Inversion vermeidet?

1. $\mathbf{A}^\top \mathbf{A}$ ist nie invertierbar.
2. Vorwärts-/Rückwärtssubstitution ist instabil.
3. Der Übergang zu $\mathbf{A}^\top \mathbf{A}$ quadriert die Konditionszahl: $\kappa_2(\mathbf{A}^\top \mathbf{A}) = \kappa_2(\mathbf{A})^2$.
4. Die Cholesky-Zerlegung existiert für SPD-Matrizen nicht.

Anhang

Beweis: Kondition bezüglich $\mathbf{b}$

Behauptung: $\frac{\|f(\tilde{\mathbf{b}}) - f(\mathbf{b})\|}{\|f(\mathbf{b})\|} \leq \kappa_2(\mathbf{A}) \frac{\|\mathbf{b}\|}{\|\text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}\|} \cdot \frac{\|\tilde{\mathbf{b}} - \mathbf{b}\|}{\|\mathbf{b}\|}$ für $f(\mathbf{b}) = \mathbf{A}^+\mathbf{b}$.

$$\begin{aligned} \frac{\|\mathbf{A}^+\tilde{\mathbf{b}} - \mathbf{A}^+\mathbf{b}\|}{\|\mathbf{A}^+\mathbf{b}\|} &= \frac{\|\mathbf{A}^+(\tilde{\mathbf{b}} - \mathbf{b})\|}{\|\mathbf{A}^+\mathbf{b}\|} \\ &\leq \frac{\|\mathbf{A}^+\| \|\tilde{\mathbf{b}} - \mathbf{b}\|}{\|\mathbf{A}^+\mathbf{b}\|} && [\text{Submultiplikativitat}] \\ &= \frac{\kappa_2(\mathbf{A})}{\|\mathbf{A}\| \cdot \|\mathbf{A}^+\mathbf{b}\|} \|\tilde{\mathbf{b}} - \mathbf{b}\| && [\text{Def. von } \kappa_2(\mathbf{A})] \\ &\leq \frac{\kappa_2(\mathbf{A})}{\|\mathbf{A}\mathbf{A}^+\mathbf{b}\|} \|\tilde{\mathbf{b}} - \mathbf{b}\| && [\text{Submultiplikativitat}] \end{aligned}$$

und mit $\mathbf{A}\mathbf{A}^+\mathbf{b} = \text{proj}_{\text{col}(\mathbf{A})}\mathbf{b}$ sowie Erweitern mit $\|\mathbf{b}\|/\|\mathbf{b}\|$ folgt die Behauptung. ■

↔ zurück: „Kondition bezüglich $\mathbf{b}$ “

Beispiel: QR-Zerlegung – Verifikation

Aus dem Hauptteil: $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix}$, berechnet via Gram-Schmidt:

- $\mathbf{q}_1 = (1 \ 0 \ 0)^\top$; $\mathbf{q}_2 = (0 \ 0 \ 1)^\top$; $\mathbf{q}_3 = (0 \ 1 \ 0)^\top$
- $R_{11} = 1$; $R_{12} = 2$; $R_{22} = 2$

Verifikation:

$$\mathbf{Q} \begin{pmatrix} \mathbf{R} \\ \mathbf{0} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix} = \mathbf{A} \checkmark$$

und $\mathbf{Q}$ ist orthogonal: $\mathbf{Q}^\top \mathbf{Q} = \mathbf{I}_3$ (Spalten sind orthonormale Vektoren). $\checkmark$

↩ zurück: „Beispiel: QR-Zerlegung“