Methode der Kleinsten Quadrate

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- *Kondition* & Konditionszahl $\kappa(\boldsymbol{A})$
- *Matrixnormen* (besonders $\|\cdot\|_2$) und *Orthogonalmatrizen*
- Matrixzerlegungen: *LU-* und *Cholesky-Zerlegung*
- *SVD*: $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^\top$, *Pseudoinverse* $\boldsymbol{A}^+$, Reduzierte SVD
- **Lineare Algebra**
  - *Normalengleichungen*: $\boldsymbol{A}^\top\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^\top\boldsymbol{b}$
  - (Orthogonale) Projektionen auf Unterräume
- **Statistik**
  - Lineares Regressionsmodell $\boldsymbol{y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$
  - Methode der Kleinsten Quadrate (OLS)

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit $\operatorname{rang}(\boldsymbol{A}) = n$. Die Kleinste-Quadrate-Lösung $\hat{\boldsymbol{x}}$ von $\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2$ erfüllt …

1. $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{b}$
2. $\boldsymbol{A}^\top \boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^\top \boldsymbol{b}$
3. $\boldsymbol{A}\boldsymbol{A}^\top \hat{\boldsymbol{x}} = \boldsymbol{A}\boldsymbol{b}$
4. $\hat{\boldsymbol{x}} = \boldsymbol{A}^\top \boldsymbol{b}$

Frage 2: Sei $\hat{\boldsymbol{b}} = \operatorname{proj}_{\operatorname{col}(\boldsymbol{A})} \boldsymbol{b}$ die orthogonale Projektion von $\boldsymbol{b}$ auf den Spaltenraum von $\boldsymbol{A}$. Welche Aussage gilt **immer**?

1. $\hat{\boldsymbol{b}} = \boldsymbol{b}$
2. $\boldsymbol{b} - \hat{\boldsymbol{b}} \perp \operatorname{col}(\boldsymbol{A})$
3. $\|\hat{\boldsymbol{b}}\|_2 \geq \|\boldsymbol{b}\|_2$
4. $\hat{\boldsymbol{b}} = \boldsymbol{0}$

Recap: Kleinste Quadrate

Recap: Kleinste Quadrate

Kleinste-Quadrate-Problem (KQ-Problem)

- Gegeben sei Matrix $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ und Vektor $\boldsymbol{b} \in \mathbb{R}^m$.
- Wir wollen einen Vektor $\hat{\boldsymbol{x}} \in \mathbb{R}^n$ finden, sodass $\left\| \boldsymbol{A}\hat{\boldsymbol{x}} - \boldsymbol{b} \right\|$ minimal ist.

Anmerkung:

- Hat das LGS eine Lösung $\boldsymbol{x}^*$, dann gilt $\left\| \boldsymbol{A}\boldsymbol{x}^* - \boldsymbol{b} \right\| = 0$ und $\boldsymbol{x}^*$ ist automatisch auch eine Lösung des Kleinste-Quadrate-Problems.
- Interessant ist die Problemstellung insbesondere für "Gleichungssysteme" $\boldsymbol{A}\boldsymbol{x}^* \approx \boldsymbol{b}$, die keine *exakte* Lösung besitzen.

Motivation

KQ-Methode *fundamentalst* in Statistik und Machine Learning:

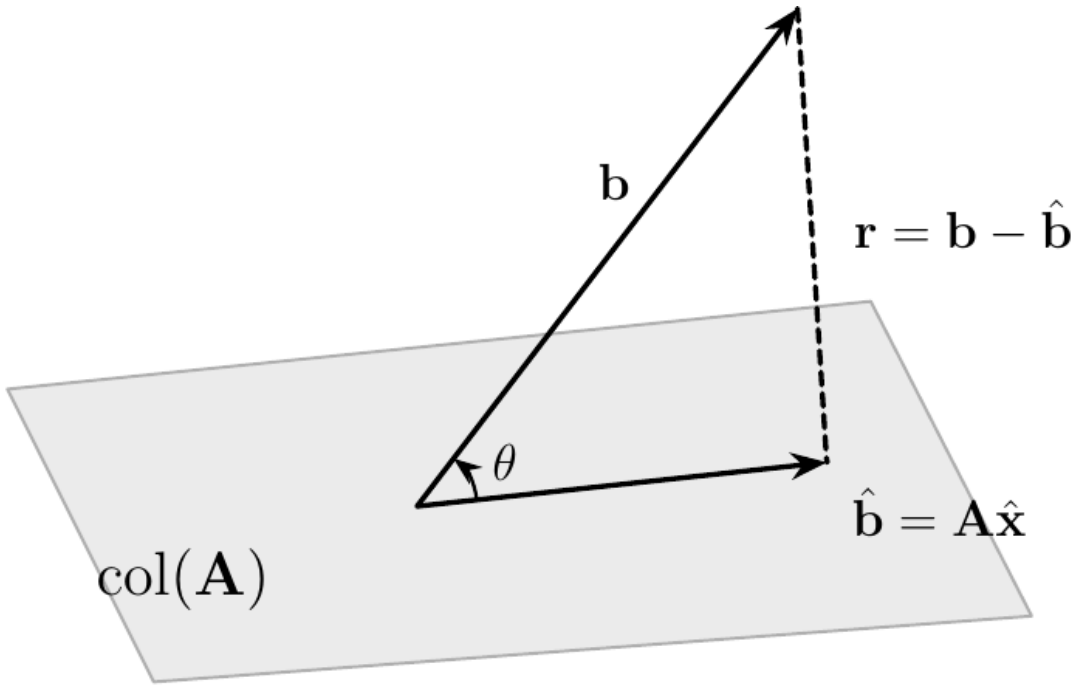
- **Beispiel: Lineare Regression**
  - **Problem:** Vorhersage von Immobilienpreisen basierend auf Wohnfläche
  - **Daten:** n Beobachtungen (x_i, y_i) mit x_i = Fläche in m^2, y_i = Preis in €
  - **Modell:** $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$ mit Fehlerterm ϵ_i
  - **Matrix-Form:** $\boldsymbol{b} = \boldsymbol{A}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ mit

$$\boldsymbol{A} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad \boldsymbol{b} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}$$

  - **Lösung:** $\hat{\boldsymbol{\beta}} = (\boldsymbol{A}^\top \boldsymbol{A})^{-1} \boldsymbol{A}^\top \boldsymbol{b}$ minimiert $\sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$

- **Weitere Anwendungen:**
  - **Generalisierte Lineare Modelle, Additive Modelle:** approximative Lösungen über iterative KQ-Probleme
  - **Deep Learning:** Training neuronaler Netze (minimiert oft KQ-Fehler)
  - **Computer Vision:** Kamerakalibration, 3D-Rekonstruktion aus 2D-Bildern
  - **Signal Processing:** Rauschreduktion/De-Noising, Signalschätzung
  - **Geodäsie:** GPS-Positionsbestimmung
  - ....

Recap: Kleinste Quadrate



Theorem

Die Lösungsmenge des KQ-Problems gleicht der Lösungsmenge des LGS

$$\boldsymbol{A}\hat{\boldsymbol{x}} = \hat{\boldsymbol{b}} \quad \text{mit } \hat{\boldsymbol{b}} = \mathrm{proj}_{\mathrm{col}(\boldsymbol{A})}\boldsymbol{b}.$$

Recap: Kleinste Quadrate

Theorem

Die Lösungsmenge des KQ-Problems gleicht der Lösungsmenge der Normalengleichungen

$$\boldsymbol{A}^\top \boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^\top \boldsymbol{b}.$$

Theorem

Falls $\operatorname{rang}(\boldsymbol{A}) = n$, ist $\boldsymbol{A}^\top \boldsymbol{A}$ invertierbar und das KQ-Problem hat die eindeutige Lösung

$$\hat{\boldsymbol{x}} = (\boldsymbol{A}^\top \boldsymbol{A})^{-1} \boldsymbol{A}^\top \boldsymbol{b} =: \boldsymbol{A}^+ \boldsymbol{b}.$$

Quiz

Welche der folgenden Aussagen sind wahr? *(mehrere Antworten möglich)*

1. $\boldsymbol{A}\boldsymbol{A}^{+} = \boldsymbol{I}_m$
2. $\boldsymbol{A}\boldsymbol{A}^{+}\boldsymbol{b} = \text{proj}_{\text{col}(\boldsymbol{A})}\boldsymbol{b}$
3. $\boldsymbol{r} = \boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}} \perp \text{col}(\boldsymbol{A})$
4. $\boldsymbol{b} = \text{proj}_{V}\boldsymbol{b} + \text{proj}_{V^{\perp}}\boldsymbol{b}$ für jeden Untervektorraum V

Kondition des KQ-Problems

Kondition

Vorbemerkungen

- Wir untersuchen nun die *Kondition* von KQ-Probleme $\boldsymbol{Ax} \approx \boldsymbol{b}$ mit $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ und $\boldsymbol{b} \in \mathbb{R}^m$.
- Wir beschränken uns auf den Fall $m \geq n$ und $\operatorname{rang}(\boldsymbol{A}) = n$
  $\Longrightarrow$ eindeutige Lösung existiert.
- Im folgenden $||\cdot|| = ||\cdot||_2$ (natürliche Norm für KQ-Probleme).
- Für nicht notwendigerweise quadratische Matrizen definieren wir

$$\kappa(\boldsymbol{A}) = \begin{cases} \infty, & \operatorname{rang}(\boldsymbol{A}) < n, \\ \|\boldsymbol{A}\| \, \|\boldsymbol{A}^+\|, & \text{sonst.} \end{cases}$$

Kondition bezüglich $\boldsymbol{b}$

Theorem

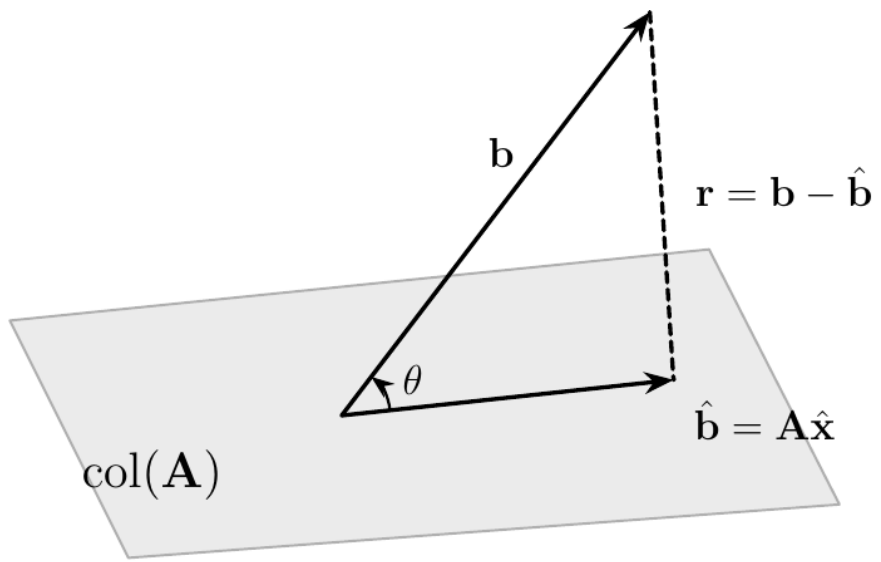
Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ fix und f das Problem mit Lösung $f(\boldsymbol{b}) = \boldsymbol{A}^{+}\boldsymbol{b}$. Dann gilt

$$\frac{\|f(\tilde{\boldsymbol{b}}) - f(\boldsymbol{b})\|}{\|f(\boldsymbol{b})\|} \leq \kappa \frac{\|\tilde{\boldsymbol{b}} - \boldsymbol{b}\|}{\|\boldsymbol{b}\|} \qquad \text{mit} \qquad \kappa = \kappa_2(\boldsymbol{A}) \frac{\|\boldsymbol{b}\|}{\left\|\text{proj}_{\text{col}(\boldsymbol{A})}\boldsymbol{b}\right\|}.$$

Beweis: siehe Anhang

Kondition bezüglich b

$$\kappa = \kappa_2(A) \frac{\|b\|}{\left\|\text{proj}_{\text{col}(A)} b\right\|}$$



Interpretation

- Erinnerung:

$$\|b\|^2 = \left\|\text{proj}_{\text{col}(A)} b\right\|^2 + \left\|\text{proj}_{\text{col}(A)^\perp} b\right\|^2 \geq \left\|\text{proj}_{\text{col}(A)} b\right\|^2.$$

- **Frage:** Was sind best und worst case für κ?

Kondition bezüglich $\boldsymbol{A}$

Theorem

Sei $\boldsymbol{b} \in \mathbb{R}^m$ fix und f das Problem mit Lösung $f(\boldsymbol{A}) = \boldsymbol{A}^+\boldsymbol{b}$. Dann gilt für kleine Störungen $\tilde{\boldsymbol{A}} \to \boldsymbol{A}$ (in erster Ordnung)

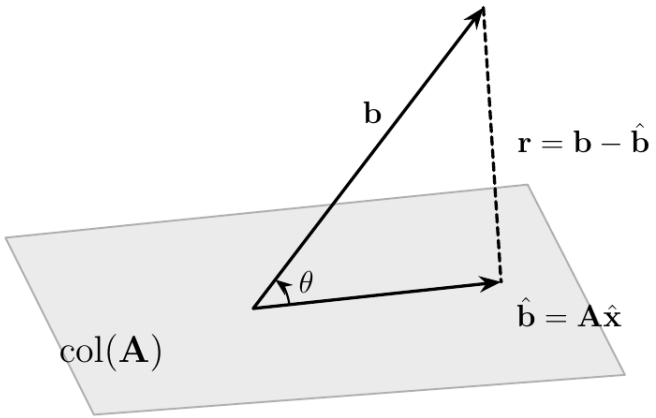
$$\frac{\|f(\tilde{\boldsymbol{A}}) - f(\boldsymbol{A})\|}{\|f(\boldsymbol{A})\|} \lesssim \kappa \frac{\|\tilde{\boldsymbol{A}} - \boldsymbol{A}\|}{\|\boldsymbol{A}\|}$$

$$\text{mit} \quad \kappa = \kappa_2(\boldsymbol{A}) + \kappa_2(\boldsymbol{A})^2 \frac{\|\boldsymbol{r}\|}{\left\|\operatorname{proj}_{\operatorname{col}(\boldsymbol{A})} \boldsymbol{b}\right\|}.$$

Beweis: Sehr aufwändige und langweilige Rechnung.

Kondition bezüglich A

$$\kappa = \kappa_2(A) + \kappa_2(A)^2 \frac{\|r\|}{\left\|\text{proj}_{\text{col}(A)} b\right\|}$$



Interpretation

- Best case: $r = 0 \Rightarrow Ax = b$ ist lösbar $\Rightarrow \kappa = \kappa_2(A)$.
- Worst case: $\text{proj}_{\text{col}(A)} b = 0$, aber $r \neq 0$
  - $\Rightarrow Ax = b$ ist nicht lösbar und $b \perp \text{col}(A)$
  - $\Rightarrow \kappa = \infty$.
- Normalerweise: $r \neq 0$ und $\text{proj}_{\text{col}(A)} b \neq 0 \Rightarrow \kappa = O(\kappa_2(A)^2)$.

Lösungsverfahren

Frage

Um die Lösung $\hat{\boldsymbol{x}} = (\boldsymbol{A}^\top \boldsymbol{A})^{-1} \boldsymbol{A}^\top \boldsymbol{b}$ zu berechnen, sei folgende Funktion gegeben:

```r
kq_solve <- function(A, b) {
  solve(t(A) %*% A) %*% t(A) %*% b
}
```

Aufgabe: Finde den Fehler in der Funktion.

Invertiere niemals eine Matrix!

`solve(M)` berechnet die volle Inverse — teurer *und* instabiler, als das LGS $\boldsymbol{M}\boldsymbol{x} = \boldsymbol{c}$ direkt zu lösen.

besser: `solve(M, c)`.

Cholesky-Zerlegung

- Die Normalengleichung $\boldsymbol{A}^\top \boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^\top \boldsymbol{b}$ gibt uns ein einfaches Lösungsverfahren:
  1. Berechne $\boldsymbol{M} = \boldsymbol{A}^\top \boldsymbol{A}$ und $\boldsymbol{c} = \boldsymbol{A}^\top \boldsymbol{b}$.
  2. Berechne Cholesky-Zerlegung $\boldsymbol{M} = \boldsymbol{L}\boldsymbol{L}^\top$.
  3. Löse $\boldsymbol{L}\boldsymbol{y} = \boldsymbol{c}$ durch Vorwärtssubstitution.
  4. Löse $\boldsymbol{L}^\top \boldsymbol{x} = \boldsymbol{y}$ durch Rückwärtssubstitution.
- Das Verfahren ist effizient, aber möglicherweise instabil:
  - Fehler in $\boldsymbol{A}^\top \boldsymbol{A}$ beeinflussen alle folgenden Schritte.
  - Man kann zeigen, dass der relative algorithmische Fehler typischerweise von der Größenordnung $\kappa_2(\boldsymbol{A})^2 \, {\epsilon_{mach}}^1$ ist.
  - Vergleiche mit Best-Case-Kondition $O(\kappa_2(\boldsymbol{A}))$.

Alternative Lösungswege

- Wir würden gerne $\boldsymbol{A}^\top \boldsymbol{A}$ vermeiden und direkt auf $\boldsymbol{A}$ operieren.
- Erinnerung: KQ-Lösung zu $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ ist

$$\widehat{\boldsymbol{x}} = \arg\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2$$

- Wir wollen das Problem mit einer Matrix $\boldsymbol{Q}$ zu einem "einfacheren" Problem $\boldsymbol{Q}\boldsymbol{A}\boldsymbol{x} \approx \boldsymbol{Q}\boldsymbol{b}$ transformieren ohne die Lösung zu ändern.

$\Longrightarrow$ $\boldsymbol{Q}$ soll *Orthogonalmatrix* sein, denn für diese gilt

$$\|\boldsymbol{Q}\boldsymbol{A}\boldsymbol{x} - \boldsymbol{Q}\boldsymbol{b}\| = \|\boldsymbol{Q}(\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b})\| = \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|.$$

Erinnerung: ***Orthogonalmatrix*** $\boldsymbol{Q}$

- $\boldsymbol{Q}^\top \boldsymbol{Q} = \boldsymbol{I}$, $\boldsymbol{Q}^{-1} = \boldsymbol{Q}^\top$ ("Rotation/Spiegelung");
- Produkte von Orthogonalmatrizen sind orthogonal.
- Normerhaltend für $\|\cdot\|_2$: $\|\boldsymbol{Q}\boldsymbol{z}\|_2 = \sqrt{\boldsymbol{z}^\top \boldsymbol{Q}^\top \boldsymbol{Q}\boldsymbol{z}} = \sqrt{\boldsymbol{z}^\top \boldsymbol{z}} = \|\boldsymbol{z}\|_2$ für alle $\boldsymbol{z} \in \mathbb{R}^m$.
- Alle Singulärwerte $\sigma_i(\boldsymbol{Q}) = 1$ (da $\boldsymbol{Q}^\top \boldsymbol{Q} = \boldsymbol{I}$) $\Rightarrow \kappa_2(\boldsymbol{Q}) = \frac{\sigma_{\max}}{\sigma_{\min}} = 1$
  $\Longrightarrow$ Multiplikation mit $\boldsymbol{Q}$ ist immer gut konditioniert.

QR-Zerlegung

Def.: QR-Zerlegung

Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit $m \geq n$ und $\boldsymbol{Q} \in \mathbb{R}^{m \times m}$ eine *Orthogonalmatrix*, sodass

$$\boldsymbol{Q}^\top \boldsymbol{A} = \begin{pmatrix} \boldsymbol{R} \\ \mathbf{0}_{(m-n) \times n} \end{pmatrix},$$

wobei $\boldsymbol{R} \in \mathbb{R}^{n \times n}$ eine *obere Dreiecksmatrix* ist. Dann nennen wir

$$\boldsymbol{A} = \boldsymbol{Q} \begin{pmatrix} \boldsymbol{R} \\ \mathbf{0} \end{pmatrix}$$

eine **QR-Zerlegung** von $\boldsymbol{A}$.

Anmerkung:

- Es gibt immer eine QR-Zerlegung von $\boldsymbol{A}$.
- Die Zerlegung ist nicht eindeutig.

Beispiel: QR-Zerlegung

Gegeben:

$$\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix}$$

Gesucht:

$\boldsymbol{Q}^\top \boldsymbol{A} = \begin{pmatrix} \boldsymbol{R} \\ \boldsymbol{0}_{1\times 2} \end{pmatrix}$ mit $\boldsymbol{Q} \in \mathbb{R}^{3\times 3}$ und $\boldsymbol{R} \in \mathbb{R}^{2\times 2}$

Methode:

Gram-Schmidt-Orthonormalisierung auf den Spalten von $\boldsymbol{A}$

Schritt 1: Erste Spalte $\boldsymbol{a}_1 = \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}^\top$

- Normalisierung: $\boldsymbol{q}_1 = \frac{\boldsymbol{a}_1}{\|\boldsymbol{a}_1\|} = \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}^\top \implies R_{11} = \|\boldsymbol{a}_1\| = 1$

Schritt 2: Zweite Spalte $\boldsymbol{a}_2 = \begin{pmatrix} 2 & 0 & 2 \end{pmatrix}^\top$

- Projektion auf $\boldsymbol{q}_1$: $R_{12} = \boldsymbol{q}_1{}^\top \boldsymbol{a}_2 = 2$
- Orthogonalisierung: $\tilde{\boldsymbol{q}}_2 = \boldsymbol{a}_2 - R_{12}\boldsymbol{q}_1 = \begin{pmatrix} 2 & 0 & 2 \end{pmatrix}^\top - \begin{pmatrix} 2 & 0 & 0 \end{pmatrix}^\top = \begin{pmatrix} 0 & 0 & 2 \end{pmatrix}^\top$
- Normalisierung: $\boldsymbol{q}_2 = \frac{\tilde{\boldsymbol{q}}_2}{\|\tilde{\boldsymbol{q}}_2\|} = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix}^\top$, $R_{22} = \|\tilde{\boldsymbol{q}}_2\| = 2$

Schritt 3: Vervollständige zu Orthonormalbasis von $\mathbb{R}^3$: wähle $\boldsymbol{q}_3 \perp \boldsymbol{q}_1, \boldsymbol{q}_2$, z.B. $\boldsymbol{q}_3 = \begin{pmatrix} 0 & 1 & 0 \end{pmatrix}^\top$

Ergebnis: $\boldsymbol{Q} = (\boldsymbol{q}_1 \quad \boldsymbol{q}_2 \quad \boldsymbol{q}_3) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}, \quad \boldsymbol{R} = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}$ *(Verifikation → Anhang)*

QR-Zerlegung: Idee

Theorem

Sei $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ mit $m \geq n$, $\boldsymbol{b} \in \mathbb{R}^m$ und $\boldsymbol{Q} \in \mathbb{R}^{m \times m}$ eine *Orthogonalmatrix*, sodass

$$\boldsymbol{Q}^\top \boldsymbol{A} = \begin{pmatrix} \boldsymbol{R} \\ \boldsymbol{0}_{(m-n)\times n} \end{pmatrix} \quad \text{und} \quad \boldsymbol{Q}^\top \boldsymbol{b} = \begin{pmatrix} \boldsymbol{c}_1 \\ \boldsymbol{c}_2 \end{pmatrix}$$

mit $\boldsymbol{R} \in \mathbb{R}^{n \times n}$ invertierbar. Dann gilt

$$\widehat{\boldsymbol{x}} = \boldsymbol{R}^{-1}\boldsymbol{c}_1 = \arg\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2.$$

Numerisch bilden wir $\boldsymbol{R}^{-1}$ **nicht** explizit, sondern lösen das Dreieckssystem $\boldsymbol{R}\widehat{\boldsymbol{x}} = \boldsymbol{c}_1$ durch Rückwärtssubstitution.

Beweis:

- Es gilt $\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|^2 = \left\|\boldsymbol{Q}^\top \boldsymbol{A}\boldsymbol{x} - \boldsymbol{Q}^\top \boldsymbol{b}\right\|^2 = \|\boldsymbol{R}\boldsymbol{x} - \boldsymbol{c}_1\|^2 + \|\boldsymbol{c}_2\|^2$.
- Weil der zweite Term nicht von $\boldsymbol{x}$ abhängt, gilt

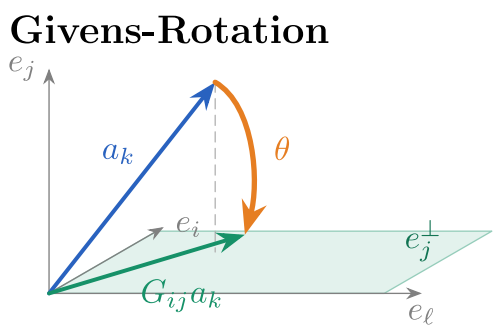
$$\arg\min_{\boldsymbol{x}} \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\| = \arg\min_{\boldsymbol{x}} \|\boldsymbol{R}\boldsymbol{x} - \boldsymbol{c}_1\|.$$

- $\widehat{\boldsymbol{x}} = \boldsymbol{R}^{-1}\boldsymbol{c}_1$ ist Lösung, weil $\left\|\boldsymbol{R}\widehat{\boldsymbol{x}} - \boldsymbol{c}_1\right\| = \left\|\boldsymbol{R}\boldsymbol{R}^{-1}\boldsymbol{c}_1 - \boldsymbol{c}_1\right\| = 0$.

Konstruktion von Q

- Wie beim Gauß-Verfahren erzeugen wir R durch Nullen unter der Diagonalen. Dazu multiplizieren wir A von links mit **orthogonalen** Transformationen; ihr Produkt ist $Q^\top$.
- In Spalte k sollen die $m-k$ Einträge unter a_{kk} null werden:

- *Givens-Rotation*:

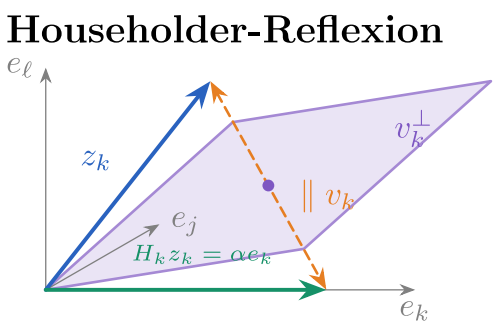


$G_{ij}(\theta)$ dreht die Projektion von a_k auf $\operatorname{span}(e_i, e_j)$ auf e_i.
So wird **ein** ausgewählter Eintrag a_{jk} null.

Bei üblicher Drehrichtung gilt

$$\theta = -\operatorname{atan2}(A_{jk}, A_{ik}).$$

- *Householder-Reflexion*:



Definiere den nach oben mit Nullen aufgefüllten Rest der k-ten Spalte von A: $z_k := \sum_{\ell=k}^{m} A_{\ell k} e_\ell$.
Spiegelebene $v_k^\perp$ halbiert den Winkel zwischen z_k und e_k.
Nach Reflexion gilt $a_{\ell k}^{\text{neu}} = 0$ **für alle** $\ell > k$, Einträge mit $\ell < k$ bleiben unverändert.

$$\text{Wähle } \alpha = \pm\|z_k\|_2, \quad z_k \neq \alpha e_k, \qquad v_k = \frac{z_k - \alpha e_k}{\|z_k - \alpha e_k\|_2},$$

$$H_k = I - 2 v_k v_k^\top, \qquad H_k z_k = \alpha e_k.$$

Pseudoinverse und Kleinste Quadrate

SVD-Lösung:

$$\boldsymbol{x} = \boldsymbol{A}^{+}\boldsymbol{b} = \boldsymbol{V}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{U}_r^{\top} \boldsymbol{b}$$

Warum funktioniert das?

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{A}^{+}\boldsymbol{b} = \mathrm{proj}_{\mathrm{col}(\boldsymbol{A})}\boldsymbol{b}$$

Vorteile gegenüber Normalengleichungen:

- Arbeitet direkt mit $\boldsymbol{A}$, nicht $\boldsymbol{A}^{\top}\boldsymbol{A} \rightarrow$ numerisch stabiler
- Funktioniert auch für rangdefiziente Matrizen ($\mathrm{rang}(\boldsymbol{A}) < n$) – liefert dann die KQ-Lösung mit minimaler Norm:

$$\boldsymbol{A}^{+}\boldsymbol{b} = \arg \min_{\substack{\boldsymbol{x} \in \mathbb{R}^n \\ \boldsymbol{A}^{\top}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\top}\boldsymbol{b}}} \|\boldsymbol{x}\|_2$$

- Explizite Konstruktion der Lösung, klare geometrische Interpretation

Demo: Ein KQ-Problem, drei Verfahren

Lineare Regression mit **fast kollinearen** Spalten — die wahre Lösung ist bekannt:

```r
set.seed(1)
m <- 100
x <- runif(m)
A <- cbind(1, x, x + 1e-6 * runif(m)) # 3. Spalte fast identisch zur 2.!
beta_wahr <- c(1, 2, 3)
b <- A %*% beta_wahr                  # exakte Daten: Loesung = beta_wahr
kappa(A, exact = TRUE)
```

```
[1] 6592188
```

- $\kappa_2(\boldsymbol{A}) \approx 7 \cdot 10^6 \implies \kappa_2(\boldsymbol{A}^\top \boldsymbol{A}) = \kappa_2(\boldsymbol{A})^2 \approx 4 \cdot 10^{13}$

Vorhersage: Doppelte Gleitkommazahlen haben ≈ 16 Dezimalstellen. Wie viele *korrekte* Stellen von $\boldsymbol{\beta}$ erwarten Sie

- für die Normalengleichungen (Fehler $\sim \kappa_2(\boldsymbol{A})^2 \, \epsilon_{mach}$)?
- für QR/SVD (Fehler $\sim \kappa_2(\boldsymbol{A}) \, \epsilon_{mach}$)?

Demo: Ergebnisse

```r
beta_ne  <- solve(t(A) %*% A, t(A) %*% b)  # Normalengleichungen (ohne Inverse!)
beta_qr  <- qr.solve(A, b)                 # QR-Zerlegung
s        <- svd(A)
beta_svd <- s$v %*% ((t(s$u) %*% b) / s$d) # SVD: A+ b
fehler   <- function(beta_hat) max(abs(beta_hat - beta_wahr))
sapply(list("Normalengl." = beta_ne, QR = beta_qr, SVD = beta_svd), fehler)
```

```
Normalengl.          QR         SVD
   8.77e-03    1.19e-11    1.55e-10
```

- **Normalengleichungen**:
  Fehler $\approx 10^{-2}$ –
  passt zu $\kappa_2(\boldsymbol{A})^2\,\epsilon_{mach} \approx 4 \cdot 10^{13} \cdot 2 \cdot 10^{-16} \approx 10^{-2}$
  $\Longrightarrow$ nur noch **2–3 korrekte Stellen**, obwohl wir die Matrixinversion vermieden haben:
  die *Quadrierung der Konditionszahl* ist das Problem, nicht (nur) `solve(M)`.
- **QR/SVD**:
  Fehler $\approx 10^{-10}$ – passt zu $\kappa_2(\boldsymbol{A})\,\epsilon_{mach} \approx 10^{-9}$
  $\Longrightarrow$ **ca. 10 korrekte Stellen** statt nur 2–3 bei den Normalengleichungen.

Vergleich der Lösungsverfahren

Verfahren	Ansatz	Komplexität ($m \gg n$)	Stabilität
Cholesky auf $\boldsymbol{A}^\top \boldsymbol{A}$	Normalengleichungen	$O(mn^2)$, kleinste Konstante ($\approx mn^2$)	Fehler $O\left(\kappa_2(\boldsymbol{A})^2\, \epsilon_{mach}\right)$ – potenziell instabil
QR-Zerlegung	löse $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{c}_1$	$O(mn^2)$ ($\approx 2mn^2$, Householder)	stabil – **Standardwahl**
SVD	$\hat{\boldsymbol{x}} = \boldsymbol{A}^+\boldsymbol{b} = \boldsymbol{V}_r \boldsymbol{\Sigma}_r^{-1} \boldsymbol{U}_r^\top \boldsymbol{b}$	$O(mn^2)$, größte Konstante	am stabilsten, auch für $\operatorname{rang}(\boldsymbol{A}) < n$

- Für $m \gg n$ haben alle drei Verfahren dieselbe Komplexitäts*ordnung* $O(mn^2)$ – die Konstanten (und die Stabilität!) unterscheiden sich aber deutlich: Normalengleichungen + Cholesky brauchen etwa halb so viele Operationen wie Householder-QR, die SVD ein Mehrfaches davon.
- SVD besonders sinnvoll, wenn $\boldsymbol{A}$ fast singulär ist ($\sigma_{\min}(\boldsymbol{A}) \approx 0 \Rightarrow \kappa(\boldsymbol{A}) \gg 1$): die $r - k$ kleinsten Singulärwerte auf 0 setzen $\rightarrow$ **Rang-k-Approximation** als Regularisierung.

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- *Kondition des KQ-Problems*:
  bzgl. $\boldsymbol{b}$ abhängig vom Winkel zwischen $\boldsymbol{b}$ und $\mathrm{col}(\boldsymbol{A})$,
  bzgl. $\boldsymbol{A}$ typischerweise $O(\kappa_2(\boldsymbol{A})^2)$.
- $\kappa_2(\boldsymbol{A}^\top \boldsymbol{A}) = \kappa_2(\boldsymbol{A})^2 \implies$ *Normalengleichungen* können instabil sein — und: **Invertiere niemals eine Matrix!**
- Drei Lösungsverfahren:
  - *Cholesky* (schnell, heikel),
  - *QR-Zerlegung* (Standardwahl),
  - *SVD* (am stabilsten, auch für rangdefiziente $\boldsymbol{A}$).

Nächste Vorlesung

- Probabilistische Methoden
- Iterative Methoden

Self-Check (1/2)

Frage 1: Welches Verfahren ist für KQ-Probleme mit $\operatorname{rang}(\boldsymbol{A}) = n$ die übliche **Standardwahl** (guter Kompromiss aus Stabilität und Geschwindigkeit)?

1. Cholesky auf $\boldsymbol{A}^\top \boldsymbol{A}$
2. QR-Zerlegung
3. SVD
4. Explizite Inversion: `solve(t(A) %*% A) %*% t(A) %*% b`

Frage 2: Für $m \gg n$ gilt für die Komplexität von Cholesky, QR und SVD:

1. Alle drei haben dieselbe Ordnung $O(mn^2 + n^3)$, aber deutlich verschiedene Konstanten.
2. Cholesky ist $O(mn)$, QR ist $O(mn^2)$, SVD ist $O(m^2 n^2)$.
3. Die SVD hat exponentielle Laufzeit.
4. QR ist immer am langsamsten.

Self-Check (2/2)

Frage 3: Die Kondition des KQ-Problems bezüglich $\boldsymbol{b}$ explodiert ($\kappa \to \infty$) genau dann, wenn …

1. $\boldsymbol{b} \in \mathrm{col}(\boldsymbol{A})$.
2. $\boldsymbol{b} \perp \mathrm{col}(\boldsymbol{A})$, d.h. $\mathrm{proj}_{\mathrm{col}(\boldsymbol{A})}\boldsymbol{b} = \boldsymbol{0}$.
3. das Residuum $\boldsymbol{r} = \boldsymbol{0}$ ist.
4. $\boldsymbol{A}$ eine Orthogonalmatrix ist.

Frage 4: Warum sind die Normalengleichungen numerisch heikel, selbst wenn man die explizite Inversion vermeidet?

1. $\boldsymbol{A}^\top \boldsymbol{A}$ ist nie invertierbar.
2. Vorwärts-/Rückwärtssubstitution ist instabil.
3. Der Übergang zu $\boldsymbol{A}^\top \boldsymbol{A}$ quadriert die Konditionszahl: $\kappa_2(\boldsymbol{A}^\top \boldsymbol{A}) = \kappa_2(\boldsymbol{A})^2$.
4. Die Cholesky-Zerlegung existiert für SPD-Matrizen nicht.

Anhang

Beweis: Kondition bezüglich $\boldsymbol{b}$

Behauptung: $\dfrac{\|f(\tilde{\boldsymbol{b}}) - f(\boldsymbol{b})\|}{\|f(\boldsymbol{b})\|} \leq \kappa_2(\boldsymbol{A}) \dfrac{\|\boldsymbol{b}\|}{\left\|\mathrm{proj}_{\mathrm{col}(\boldsymbol{A})}\boldsymbol{b}\right\|} \cdot \dfrac{\|\tilde{\boldsymbol{b}} - \boldsymbol{b}\|}{\|\boldsymbol{b}\|}$ für $f(\boldsymbol{b}) = \boldsymbol{A}^+\boldsymbol{b}$.

$$
\begin{aligned}
\frac{\left\|\boldsymbol{A}^+\tilde{\boldsymbol{b}} - \boldsymbol{A}^+\boldsymbol{b}\right\|}{\|\boldsymbol{A}^+\boldsymbol{b}\|} &= \frac{\left\|\boldsymbol{A}^+(\tilde{\boldsymbol{b}} - \boldsymbol{b})\right\|}{\|\boldsymbol{A}^+\boldsymbol{b}\|} \\
&\leq \frac{\|\boldsymbol{A}^+\| \left\|\tilde{\boldsymbol{b}} - \boldsymbol{b}\right\|}{\|\boldsymbol{A}^+\boldsymbol{b}\|} && [\text{Submultiplikativität}] \\
&= \frac{\kappa_2(\boldsymbol{A})}{\|\boldsymbol{A}\| \cdot \|\boldsymbol{A}^+\boldsymbol{b}\|} \left\|\tilde{\boldsymbol{b}} - \boldsymbol{b}\right\| && [\text{Def. von } \kappa_2(\boldsymbol{A})] \\
&\leq \frac{\kappa_2(\boldsymbol{A})}{\|\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{b}\|} \left\|\tilde{\boldsymbol{b}} - \boldsymbol{b}\right\| && [\text{Submultiplikativität}]
\end{aligned}
$$

und mit $\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{b} = \mathrm{proj}_{\mathrm{col}(\boldsymbol{A})}\boldsymbol{b}$ sowie Erweitern mit $\|\boldsymbol{b}\|/\|\boldsymbol{b}\|$ folgt die Behauptung. ■

↩ zurück: „Kondition bezüglich $\boldsymbol{b}$“

Beispiel: QR-Zerlegung — Verifikation

Aus dem Hauptteil: $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix}$, berechnet via Gram-Schmidt:

- $\boldsymbol{q}_1 = (1 \quad 0 \quad 0)^\top$; $\boldsymbol{q}_2 = (0 \quad 0 \quad 1)^\top$; $\boldsymbol{q}_3 = (0 \quad 1 \quad 0)^\top$
- $R_{11} = 1$; $R_{12} = 2$; $R_{22} = 2$

Verifikation:

$$\boldsymbol{Q} \begin{pmatrix} \boldsymbol{R} \\ \boldsymbol{0} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ 0 & 2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 2 \end{pmatrix} = \boldsymbol{A} \checkmark$$

und $\boldsymbol{Q}$ ist orthogonal: $\boldsymbol{Q}^\top \boldsymbol{Q} = \boldsymbol{I}_3$ (Spalten sind orthonormale Vektoren). ✓

↩ zurück: „Beispiel: QR-Zerlegung”