

Differentialrechnung I

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- Matrix-*Spur* & *Matrixnormen*
- Landau-Notation: $g(h) = o(h) \iff \lim_{h \rightarrow 0} \frac{g(h)}{h} = 0$
- **Analysis** (essentiell)
 - Ableitungen: $f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$
 - Partielle Ableitungen: $\frac{\partial f(\mathbf{x})}{\partial x_i}$
 - Lineare Approximation: $f(x + h) \approx f(x) + f'(x)h$
 - Grundlagen Taylorreihen
- **Lineare Algebra**
 - Matrixinversion und Determinante
 - Normierte (Vektor-)Räume
 - Beschränkte lineare Operatoren

Opener-Quiz: Was wissen Sie noch?

Frage 1: Seien $g, h: \mathbb{R} \rightarrow \mathbb{R}$ differenzierbar. Welche Rechenregeln stimmen?

1. $(g + h)'(x) = g'(x) + h'(x)$
2. $(g \cdot h)'(x) = g'(x) \cdot h'(x)$
3. $(g \cdot h)'(x) = g'(x)h(x) + g(x)h'(x)$
4. $(g \circ h)'(x) = g'(h(x)) \cdot h'(x)$

Frage 2: Welche der folgenden Abbildungen sind *linear*?

1. $L(\mathbf{x}) = \mathbf{A}\mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$
2. $L(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ mit $\mathbf{b} \neq \mathbf{0}$
3. $L(x) = c \cdot x$ mit $c \in \mathbb{R}$, $x \in \mathbb{R}$
4. $L(x) = x^2$

Überblick

- Aus Analysis bekannt: Ableitungen, *Differenzierbarkeit*
- Neue wichtige Technik: **Allgemeinerer Ableitungsbegriff** (*Fréchet-Ableitung*)
 - Ableitungen mit **Matrix-/Vektor-Inputs** oder **-Outputs**
 - Ableitungen in *allgemeineren (normierten) Räumen*

Ableitung von univariaten Funktionen

Recap: Ableitung von univariaten Funktionen



Def.: Differenzierbarkeit

Sei $S \subseteq \mathbb{R}$ offen und $f: S \rightarrow \mathbb{R}$ eine Funktion.

Wir nennen f an der Stelle $x \in S$ **differenzierbar** mit **Ableitung** $f'(x)$, falls

$$\lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} = f'(x).$$

- $f'(x)$ ist die **Steigung einer Tangente an f durch x** .
- Falls diese Steigung nicht eindeutig ist, ist f an der Stelle x nicht differenzierbar:



Quiz

Sei f differenzierbar in x mit Ableitung $f'(x)$.

Frage: Welche Aussagen sind wahr?

1. f' ist eine lineare Funktion.
2. $h \mapsto f'(x)h$ ist eine lineare Funktion (für festes x).
3. $\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - f'(x)h|}{h} = 0$.
4. $f(x+h) = f(x) + f'(x)h + o(h)$.

Beweis (3) $\iff$ (4): $\rightarrow$ Anhang.

Allgemeiner Ableitungsbegriff

Allgemeiner Ableitungsbegriff

- Ableitungen können auf verschiedene Arten auf allgemeinere, **normierte** Räume erweitert werden.
- Die Idee ist immer: **Ableitung** = **lineare Approximation**.
- Die Definition nach Fréchet reicht aus für
 - alle endlich-dimensionalen Räume,
 - einige unendlich-dimensionale Räume.
- Allgemeinere Definitionen: *Gateaux*-, *Hadamard*-Ableitungen.

Allgemeiner Ableitungsbegriff

Def.: (Fréchet-)differenzierbar

Seien $\mathbb{D}$ und $\mathbb{E}$ zwei normierte Räume und $f: \mathbb{D} \rightarrow \mathbb{E}$.

Wir nennen f an der Stelle $x \in \mathbb{D}$ **(Fréchet-)differenzierbar**, falls eine beschränkte lineare Abbildung $D_x f: \mathbb{D} \rightarrow \mathbb{E}$ existiert, sodass

$$f(x + h) = f(x) + D_x f(h) + o(\|h\|) \quad \text{für } h \rightarrow 0.$$

- $D_x f(h)$ beschränkt: Es gibt $M < \infty$, sodass $\|D_x f(h)\| \leq M \|h\| \quad \forall h$.
- $h \rightarrow D_x f(h)$ ist linear in h , hängt aber in beliebiger Weise von x ab.
- Beispiel:
 - Für $f: \mathbb{R} \rightarrow \mathbb{R}$ ist $D_x f(h) = f'(x)h$.
 - $D_x f$ ist beschränkt, wenn $|f'(x)| < \infty$.
- Fehler $o(\|h\|)$: wird relativ zu $\|h\|$ beliebig klein, wenn $h \rightarrow 0$

Konkret: Fréchet-Ableitung von $f(x) = x^2$

Sei $f: \mathbb{R} \rightarrow \mathbb{R}$ mit $f(x) = x^2$. Zu Zeigen: f Fréchet-differenzierbar mit $D_x f(h) = 2xh$.

Prüfen der Definition:

$$\begin{aligned} f(x+h) &= (x+h)^2 = x^2 + 2xh + h^2 \\ &= f(x) + 2xh + h^2 \\ &= f(x) + D_x f(h) + h^2 \\ \implies D_x f(h) &= 2xh \text{ (linear in } h\text{)} \end{aligned}$$

- $\lim_{h \rightarrow 0} \frac{|h^2|}{|h|} = \lim_{h \rightarrow 0} |h| = 0 \implies h^2 = o(|h|) \quad \checkmark$
- $|D_x f(h)| = |2xh| = 2|x| \cdot |h| \leq M|h| \quad \forall h \text{ mit } M = 2|x| < \infty$
 $\implies D_x f$ beschränkt $\checkmark$

$\longrightarrow$ entspricht $f'(x) = 2x$, da $D_x f(h) = f'(x)h = 2x \cdot h$.

Wichtige Spezialfälle

Wichtige Spezialfälle

- Die bereits bekannten Ableitungen sind alle Spezialfälle der Fréchet-Ableitung.
- Besonders wichtige neue Spezialfälle: Ableitungen von Funktionen, die
 - *Skalare, Vektoren oder Matrizen*
 - als *Input oder Output* haben.
- Insbesondere betrachten wir die folgenden Fälle:

Input \ Output	Skalar	Vektor	Matrix
Skalar	$\frac{dy}{dx}$	$\frac{dy}{dx}$	$\frac{dY}{dx}$
Vektor	$\frac{\partial y}{\partial x}$	$\frac{\partial y}{\partial x}$	
Matrix	$\frac{\partial y}{\partial X}$		

Spezialfall: Vektor zu Skalar

Spezialfall: Vektor zu Skalar

Def.: Gradient

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ eine differenzierbare Funktion.

Wir nennen den **Gradienten** von f in $\mathbf{x} \in \mathbb{R}^n$ den *Zeilenvektor*

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \nabla f(\mathbf{x}) = \left(\frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right) \in \mathbb{R}^{1 \times n}$$

$$\implies f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|)$$

mit $D_{\mathbf{x}}f(\mathbf{h}) = \nabla f(\mathbf{x})\mathbf{h}$.

Anmerkung:

Oft wird ∇f auch als Spaltenvektor definiert.


Für uns ist er als **Zeilenvektor** $\in \mathbb{R}^{1 \times n}$ konsistenter und praktischer:

- Der Gradient ist dann genau die $1 \times n$ -**Jacobimatrix** von f .
- Damit wird die Kettenregel zu einer simplen Matrixmultiplikation von Jacobimatrizen, ganz ohne Transponieren.

(→ Kapitel *Differentialrechnung II*)

Spezialfall: Vektor zu Skalar

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$



- Graph von f in grau, der grüne Punkt ist $(\mathbf{x}, f(\mathbf{x}))$.
- Der rote Pfeil zeigt (in die Tangentialebene angehoben) die Richtung des Gradienten $\nabla f(\mathbf{x})^\top$. $\implies$ Richtung, in die f an Stelle $\mathbf{x}$ am **stärksten** steigt
- Die grüne Ebene ist der Graph von $\mathbf{u} \mapsto f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{u} - \mathbf{x})$.

Beispiel: Gradient einer quadratischen Funktion

$$f: \mathbb{R}^2 \rightarrow \mathbb{R} \text{ mit } f(\mathbf{x}) = x_1^2 + 3x_1x_2 + 2x_2^2$$

Schritt 1: Berechne partielle Ableitungen


$$\frac{\partial f(\mathbf{x})}{\partial x_1} = 2x_1 + 3x_2;$$

$$\frac{\partial f(\mathbf{x})}{\partial x_2} = 3x_1 + 4x_2$$


Schritt 2: Gradient als Zeilenvektor

$$\nabla f(\mathbf{x}) = (2x_1 + 3x_2 \quad 3x_1 + 4x_2) \quad (\implies \nabla f: \mathbb{R}^2 \rightarrow \mathbb{R}^{1 \times 2}!)$$

$$f(x_1, x_2) = x_1^2 + 3x_1x_2 + 2x_2^2$$




$$\nabla f(\mathbf{x}) = (2x_1 + 3x_2, 3x_1 + 4x_2)$$




Beispiel: Gradient einer komplexeren Funktion

$$f(x_1, x_2)$$



$$\nabla f(x_1, x_2)$$



Übung: Vektor zu Skalar

Sei $\mathbf{a}, \mathbf{x} \in \mathbb{R}^n$ und

$$f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}.$$

Frage:

Was ist $\nabla f(\mathbf{x})$?

Antwort:

- Es gilt $f(\mathbf{x}) = \sum_{i=1}^n a_i x_i$.
- Deshalb $\frac{\partial f(\mathbf{x})}{\partial x_i} = a_i$.
- Also

$$\nabla f(\mathbf{x}) := \left(\frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right) = (a_1, \dots, a_n) = \mathbf{a}^\top.$$

Übung: Gradient der quadratischen Form

Sei $\mathbf{A} \in \mathbb{R}^{n \times n}$ symmetrische Matrix und $f: \mathbb{R}^n \rightarrow \mathbb{R}$ mit

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

1. $f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n x_i a_{ij} x_j.$

2. Ableiten nach x_k :

$$\begin{aligned} \frac{\partial f(\mathbf{x})}{\partial x_k} &= \sum_{i=1}^n x_i a_{ik} + \sum_{j=1}^n a_{kj} x_j \\ &= \sum_{i=1}^n a_{ki} x_i + \sum_{j=1}^n a_{kj} x_j \quad (\text{da } \mathbf{A} \text{ symmetrisch}) \\ &= 2 \sum_{i=1}^n a_{ki} x_i = 2(\mathbf{A} \mathbf{x})_k \\ &\implies \nabla f(\mathbf{x}) = 2\mathbf{x}^\top \mathbf{A} \end{aligned}$$

Spezialfall: Ist $\mathbf{A} = \mathbf{I}$, dann $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = \|\mathbf{x}\|_2^2$ und $\nabla f(\mathbf{x}) = 2\mathbf{x}^\top$.

Anwendung: Gradient Descent

Problemstellung:

Minimiere eine Verlustfunktion $L(\theta)$

(z.B. Mean Squared Error eines Modells mit Parametern θ).

Gradient Descent (Gradientenabstieg):

$$\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla L(\theta^{(t)})^\top$$

- $\alpha > 0$: Lernrate (Schrittweite)
- $-\nabla L(\theta^{(t)})^\top$: Negativer Gradient zeigt in Richtung des steilsten *Abstiegs*
- Gradient sagt uns, in welche Richtung wir θ ändern müssen, um näher an ein Minimum (= “*optimales*” Modell) zu kommen
- fundamentaler Basisalgorithmus zur **Optimierung** von neuronalen Netze, komplexen Regressionsmodellen, ...
→ *Optimierung I & II*

Spezialfall: Vektor zu Vektor

Spezialfall: Vektor zu Vektor

Def.: Jacobimatrix

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ eine differenzierbare Funktion mit $f(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))^\top$.

Die **Jacobimatrix** $\mathbf{J}_f(\mathbf{x}) \in \mathbb{R}^{m \times n}$ von f in $\mathbf{x} \in \mathbb{R}^n$ ist

$$\mathbf{J}_f(\mathbf{x}) := \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{pmatrix} \partial f_1(\mathbf{x})/\partial x_1 & \cdots & \partial f_1(\mathbf{x})/\partial x_n \\ \vdots & \ddots & \vdots \\ \partial f_m(\mathbf{x})/\partial x_1 & \cdots & \partial f_m(\mathbf{x})/\partial x_n \end{pmatrix}.$$

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}} f(\mathbf{x}) \mathbf{h} + o(\|\mathbf{h}\|)$$

mit $D_{\mathbf{x}} f(\mathbf{h}) = \mathbf{J}_f(\mathbf{x}) \mathbf{h}$.

- Die Zeilen der **Jacobimatrix** sind **Gradienten** der Komponenten von $f(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x}))^\top$:

$$\mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} \nabla f_1(\mathbf{x}) \\ \vdots \\ \nabla f_m(\mathbf{x}) \end{pmatrix}$$

Spezialfall: Vektor zu Vektor

Wichtige Identitäten:

- $f(\mathbf{x}) = \mathbf{c} \in \mathbb{R}^m \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{0}_{m \times n}$
- $f(\mathbf{x}) = \mathbf{x}$ (d.h. $m = n$) $\implies \mathbf{J}_f(\mathbf{x}) = \mathbf{I}_n$
- $f(\mathbf{x}) = \mathbf{A}\mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{m \times n} \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{A}$
- $f(\mathbf{x}) = (\mathbf{x}^\top \mathbf{A})^\top = \mathbf{A}^\top \mathbf{x}$ mit $\mathbf{A} \in \mathbb{R}^{n \times m} \implies \mathbf{J}_f(\mathbf{x}) = \mathbf{A}^\top$

Übung

$$f(\mathbf{x}) = \mathbf{A}\mathbf{x} \text{ mit } \mathbf{A} \in \mathbb{R}^{m \times n} :$$

$$f_i(\mathbf{x}) = \sum_{j=1}^n a_{ij}x_j \quad (\text{komponentenweise})$$


$$\frac{\partial f_i(\mathbf{x})}{\partial x_k} = \frac{\partial}{\partial x_k} \left(\sum_{j=1}^n a_{ij}x_j \right) = a_{ik}$$

$$\implies \mathbf{J}_f(\mathbf{x}) = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} = \mathbf{A} \quad \checkmark$$

- Lineare Funktionen haben konstante Jacobimatrizen
- Für lineare Funktionen gilt $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{J}_f(\mathbf{x})\mathbf{h}$

Visualisierung: Lineare Transformation $\mathbb{R}^2 \rightarrow \mathbb{R}^2$


$$f(x_1, x_2) = \mathbf{A} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \text{ mit } \mathbf{A} = \begin{bmatrix} 1.5 & 0.5 \\ 0.3 & 1.2 \end{bmatrix}$$



Lineare Funktion: $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \mathbf{J}_f(\mathbf{x})\mathbf{h}$

Geometrische Intuition


$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$$




- $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ transformiert das rote Quadrat links zur roten Fläche rechts.
- Die gekrümmte Darstellung soll verdeutlichen, dass f den Raum lokal verbiegt und streckt, obwohl Urbild und Bild dieselbe Dimension haben.
- Das schwarze Quadrat rechts zeigt das Bild der linearen Approximation durch $\mathbf{J}_f$.

Geometrische Intuition — Jacobimatrix $\mathbb{R}^2 \rightarrow \mathbb{R}^2$

Jacobi-Matrix: Lokale Lineare Approximation



P1:(0.00, 0.79) $\rightarrow$ (0.50, 0.79)




$$J_f(P_1) = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$$

— Wahres $f(\square)$

— Jacobi-Approx.


— Gitter (in X oder Y)

P2:(1.57, 1.57) $\rightarrow$ (1.57, 1.57)



$$J_f(P_2) = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$$

P3:(-0.79, -0.79) $\rightarrow$ (-1.29, -1.29)



$$J_f(P_3) = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Jacobi-Matrix:

$$J_f(x_1, x_2) = \begin{bmatrix} 1 & \cos(2x_2) \\ \cos(2x_1) & 1 \end{bmatrix}$$

$$f(x + h) \approx f(x) + J_f(x)h$$

Spezialfall: Skalar zu Matrix

Spezialfall: Skalar zu Matrix

$$\mathbf{F}: \mathbb{R} \rightarrow \mathbb{R}^{m \times n}$$

- Sei $x \in \mathbb{R}$, seien alle f_{ij} in x differenzierbar, und

$$\mathbf{F}(x) = \begin{pmatrix} f_{11}(x) & \cdots & f_{1n}(x) \\ \vdots & \ddots & \vdots \\ f_{m1}(x) & \cdots & f_{mn}(x) \end{pmatrix}.$$

- Definiere

$$\frac{\partial \mathbf{F}(x)}{\partial x} = \begin{pmatrix} \frac{\partial f_{11}(x)}{\partial x} & \cdots & \frac{\partial f_{1n}(x)}{\partial x} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_{m1}(x)}{\partial x} & \cdots & \frac{\partial f_{mn}(x)}{\partial x} \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

- Dann ist

$$\mathbf{F}(x + h) = \mathbf{F}(x) + D_x \mathbf{F}(h) + o(|h|) \quad \text{mit} \quad D_x \mathbf{F}(h) = \frac{\partial \mathbf{F}(x)}{\partial x} h.$$

Übung: Skalar zu Matrix

Sei, für $x > 0$,

$$\mathbf{F}(x) = \begin{pmatrix} x^2 & 2e^x & 0 \\ 0 & x & \ln(x) \end{pmatrix}.$$

Frage:

Was ist $\frac{\partial \mathbf{F}(x)}{\partial x}$?

Antwort:

$$\frac{\partial \mathbf{F}(x)}{\partial x} = \begin{pmatrix} 2x & 2e^x & 0 \\ 0 & 1 & 1/x \end{pmatrix}.$$

Skalar zu Matrix: Wichtige Identitäten

Für *quadratisches, differenzierbares*

$$\mathbf{F}: \mathbb{R} \rightarrow \mathbb{R}^{n \times n}$$

(erste beide Formeln: $\mathbf{F}(x)$ zusätzlich invertierbar):

- $\frac{\partial \mathbf{F}(x)^{-1}}{\partial x} = -\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \mathbf{F}(x)^{-1}.$
- $\frac{\partial \det(\mathbf{F}(x))}{\partial x} = \det(\mathbf{F}(x)) \operatorname{tr} \left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \right].$
- $\frac{\partial \operatorname{tr}(\mathbf{F}(x))}{\partial x} = \operatorname{tr} \left(\frac{\partial \mathbf{F}(x)}{\partial x} \right).$

(Rechenbeispiel zur Determinanten-Formel: $\rightarrow$ **Anhang** — wichtig z.B. für Ableitungen von Likelihood-Funktionen!)

Beweis: Ableitung der Spur

$$\frac{\partial \text{tr}(\mathbf{F}(x))}{\partial x} = \text{tr}\left(\frac{\partial \mathbf{F}(x)}{\partial x}\right)$$

Beweis:

$$\begin{aligned}\text{tr}(\mathbf{F}(x)) &= \sum_{i=1}^n f_{ii}(x) \\ \frac{\partial}{\partial x} \text{tr}(\mathbf{F}(x)) &= \frac{\partial}{\partial x} \left(\sum_{i=1}^n f_{ii}(x) \right) \\ &= \sum_{i=1}^n \frac{\partial f_{ii}(x)}{\partial x} \\ &= \text{tr}\left(\frac{\partial \mathbf{F}(x)}{\partial x}\right) \quad \checkmark\end{aligned}$$

Spezialfall: Matrix zu Skalar

Spezialfall: Matrix zu Skalar

$$f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$$

- Sei f in $\mathbf{X} \in \mathbb{R}^{m \times n}$ differenzierbar. Definiere:

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = \begin{pmatrix} \partial f(\mathbf{X})/\partial x_{11} & \cdots & \partial f(\mathbf{X})/\partial x_{1n} \\ \vdots & \ddots & \vdots \\ \partial f(\mathbf{X})/\partial x_{m1} & \cdots & \partial f(\mathbf{X})/\partial x_{mn} \end{pmatrix} \in \mathbb{R}^{m \times n}.$$

- Dann ist

$$f(\mathbf{X} + \mathbf{H}) = f(\mathbf{X}) + D_{\mathbf{X}}f(\mathbf{H}) + o(\|\mathbf{H}\|) \quad \text{mit} \quad D_{\mathbf{X}}f(\mathbf{H}) = \text{tr} \left(\left(\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} \right)^{\top} \mathbf{H} \right).$$

Matrix zu Skalar: Beispiel

Beispiel:

- Sei $f(\mathbf{X}) = \mathbf{a}^\top \mathbf{X} \mathbf{b}$ mit $\mathbf{X} \in \mathbb{R}^{m \times n}$, $\mathbf{a} \in \mathbb{R}^m$, $\mathbf{b} \in \mathbb{R}^n$.
- Dann ist

$$f(\mathbf{X}) = \sum_{i=1}^m \sum_{j=1}^n a_i x_{ij} b_j \implies \frac{\partial f(\mathbf{X})}{\partial x_{ij}} = a_i b_j.$$

- Daraus folgt

$$\begin{aligned} \frac{\partial \mathbf{a}^\top \mathbf{X} \mathbf{b}}{\partial \mathbf{X}} &= \begin{pmatrix} a_1 b_1 & \cdots & a_1 b_n \\ \vdots & \ddots & \vdots \\ a_m b_1 & \cdots & a_m b_n \end{pmatrix} = \mathbf{a} \mathbf{b}^\top \\ \implies D_{\mathbf{X}} f(\mathbf{H}) &= \text{tr} \left((\mathbf{a} \mathbf{b}^\top)^\top \mathbf{H} \right) = \text{tr} (\mathbf{b} \mathbf{a}^\top \mathbf{H}) = \mathbf{a}^\top \mathbf{H} \mathbf{b} \end{aligned}$$

- also hier:

$$f(\mathbf{X} + \mathbf{H}) = \mathbf{a}^\top \mathbf{X} \mathbf{b} + \mathbf{a}^\top \mathbf{H} \mathbf{b} = f(\mathbf{X}) + D_{\mathbf{X}} f(\mathbf{H})$$

Wichtige Identitäten: Matrix zu Skalar

- **Quadratische Form:** $f(\mathbf{X}) = \text{tr}(\mathbf{X}\mathbf{A}\mathbf{X}^\top)$ mit symmetrischem $\mathbf{A} \in \mathbb{R}^{n \times n}$

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{X}(\mathbf{A} + \mathbf{A}^\top) = 2\mathbf{X}\mathbf{A}$$

- **Trace-Produkt:** $f(\mathbf{X}) = \text{tr}(\mathbf{A}^\top \mathbf{X})$ mit $\mathbf{A} \in \mathbb{R}^{m \times n}$

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = \mathbf{A}$$

- **Frobenius-Norm:** $f(\mathbf{X}) = \|\mathbf{X}\|_F^2 = \text{tr}(\mathbf{X}^\top \mathbf{X})$

$$\frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} = 2\mathbf{X}$$

(Anwendungsbeispiel Matrixzerlegung / Matrix Completion: → *Anhang*)

Bemerkungen

- Wir haben bewusst ein paar Fälle ausgelassen:
 - Matrix zu Vektor
 - Vektor zu Matrix
 - Matrix zu Matrix
- Diese Fälle werden seltener gebraucht und können (z.B.) über *Tensoren* dargestellt werden.
- Zur *Störungsanalyse* von Matrixrechnungen kann man auch $h \mapsto f(\mathbf{X} + h\mathbf{E})$ nach Skalar h ableiten (= Ableitung in “Richtung” $\mathbf{E}$.)
- Formeln für die meisten in Anwendungen vorkommenden Ableitungen findet man in dem *Matrix Cookbook* von Petersen & Pedersen (2012).
- Abbildungen zwischen Funktionenräumen → Übung.

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- Fréchet-Ableitung auf normierten Räumen: **Ableitung = lineare Approximation**
- Spezialfälle für Skalare, Vektoren, Matrizen: *Gradient* (Zeilenvektor!), *Jacobimatrix*, Matrixableitungen

Nächste Vorlesung

- Eigenschaften, Rechenregeln, höhere Ableitungen

Self-Check

Frage 1: Sei $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$ mit $\mathbf{a}, \mathbf{x} \in \mathbb{R}^n$. Was ist $\nabla f(\mathbf{x})$?

1. $\mathbf{a}^\top$
2. $\mathbf{a}\mathbf{a}^\top$
3. $\mathbf{x}^\top$
4. $\mathbf{a}^\top \mathbf{x}$

Frage 2: Sei $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit *symmetrischem* $\mathbf{A} \in \mathbb{R}^{n \times n}$. Was ist $\nabla f(\mathbf{x})$?

1. $\mathbf{A}\mathbf{x}$
2. $2\mathbf{x}^\top \mathbf{A}$
3. $2\mathbf{A}$
4. $\mathbf{x}^\top \mathbf{A}\mathbf{x}$

Frage 3: Sei $f: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ differenzierbar. Welche Dimension hat die Jacobimatrix $\mathbf{J}_f(\mathbf{x})$?

1. 3×2
2. 2×3
3. 3×3
4. 2×2

Anhang

Quiz: Beweis Aussage (3) $\Longleftrightarrow$ (4)

“ $\implies$ ”: Angenommen (3) gilt, also $\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - f'(x)h|}{h} = 0$.

- Definiere $r(h) := f(x+h) - f(x) - f'(x)h$.
- Also: $\lim_{h \rightarrow 0} \frac{|r(h)|}{h} = 0$, also $r(h) = o(h)$.
- Und damit: $f(x+h) = f(x) + f'(x)h + r(h) = f(x) + f'(x)h + o(h)$. ✓

“ $\Longleftarrow$ ”: Angenommen (4) gilt, also $f(x+h) = f(x) + f'(x)h + o(h)$.

- Dann ist $f(x+h) - f(x) - f'(x)h = o(h)$.
- Per Definition von $o(h)$: $\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - f'(x)h|}{h} = \lim_{h \rightarrow 0} \frac{|o(h)|}{h} = 0$. ✓

↔ zurück: „Quiz“

Beispiel: Ableitung der Determinante

Vertiefung zu “Skalar zu Matrix: Wichtige Identitäten” — **wichtig** für Ableitungen von Likelihood-Funktionen in der Statistik!

$$\frac{\partial \det(\mathbf{F}(x))}{\partial x} = \det(\mathbf{F}(x)) \operatorname{tr} \left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \right]$$

Beispiel: $\mathbf{F}(x) = \begin{pmatrix} x & 0 \\ 0 & 2x \end{pmatrix}$.

Direkte Berechnung:

$$\det(\mathbf{F}(x)) = x \cdot 2x = 2x^2 \quad \implies \quad \frac{\partial}{\partial x} \det(\mathbf{F}(x)) = 4x$$

Überprüfung (für $x \neq 0$, sonst existiert $\mathbf{F}(x)^{-1}$ nicht):

$$\begin{aligned} \frac{\partial \mathbf{F}(x)}{\partial x} &= \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad \mathbf{F}(x)^{-1} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix} \\ \mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} &= \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/x \end{pmatrix} \\ \operatorname{tr} \left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \right] &= 1/x + 1/x = 2/x \\ \det(\mathbf{F}(x)) \cdot \operatorname{tr} \left[\mathbf{F}(x)^{-1} \frac{\partial \mathbf{F}(x)}{\partial x} \right] &= 2x^2 \cdot \frac{2}{x} = 4x \quad \checkmark \end{aligned}$$

↩ zurück: „Skalar zu Matrix: Wichtige Identitäten“

Anwendung: Matrixzerlegung & Matrix Completion

Vertiefung zu “Wichtige Identitäten: Matrix zu Skalar”.

Gegeben: Unvollständig nur an Indizes $(i, j) \in \Omega$ beobachtete Matrix $\mathbf{Y} \in \mathbb{R}^{m \times n}$ (z.B. User-Ratings von Filmen)

Ziel: Finde Low-Rank-Approximation $\mathbf{Y} \approx \mathbf{UV}^\top$ mit $\mathbf{U} \in \mathbb{R}^{m \times k}$, $\mathbf{V} \in \mathbb{R}^{n \times k}$.

Verlustfunktion:

$$L(\mathbf{U}, \mathbf{V}) = \frac{1}{2} \sum_{(i,j) \in \Omega} \left(y_{ij} - [\mathbf{UV}^\top]_{ij} \right)^2 = \frac{1}{2} \|\mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{UV}^\top)\|_F^2; \quad \mathbf{P}_\Omega = [\mathbb{I}_{(i,j) \in \Omega}]$$

($\odot$: elementweises (Hadamard-)Produkt)

Gradienten für Optimierung:

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{U}} &= -(\mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{UV}^\top))\mathbf{V} \\ \frac{\partial L}{\partial \mathbf{V}} &= -(\mathbf{P}_\Omega \odot (\mathbf{Y} - \mathbf{UV}^\top))^\top \mathbf{U} \end{aligned}$$

Anwendungen: Missing Data Imputation, Recommender Systems / Collaborative Filtering, ...

↩ zurück: „Wichtige Identitäten: Matrix zu Skalar”