Differentialrechnung I

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- Matrix-*Spur* & *Matrixnormen*
- Landau-Notation: $g(h) = o(h) \iff \lim_{h \to 0} \frac{g(h)}{h} = 0$
- **Analysis** (essentiell)
  - Ableitungen: $f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$
  - Partielle Ableitungen: $\frac{\partial f(\boldsymbol{x})}{\partial x_i}$
  - Lineare Approximation: $f(x + h) \approx f(x) + f'(x)h$
  - Grundlagen Taylorreihen
- **Lineare Algebra**
  - Matrixinversion und Determinante
  - Normierte (Vektor-)Räume
  - Beschränkte lineare Operatoren

Opener-Quiz: Was wissen Sie noch?

Frage 1: Seien $g, h\colon \mathbb{R} \to \mathbb{R}$ differenzierbar. Welche Rechenregeln stimmen?

1. $(g + h)'(x) = g'(x) + h'(x)$
2. $(g \cdot h)'(x) = g'(x) \cdot h'(x)$
3. $(g \cdot h)'(x) = g'(x)h(x) + g(x)h'(x)$
4. $(g \circ h)'(x) = g'\big(h(x)\big) \cdot h'(x)$

Frage 2: Welche der folgenden Abbildungen sind *linear*?

1. $L(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$ mit $\boldsymbol{A} \in \mathbb{R}^{m \times n}$, $\boldsymbol{x} \in \mathbb{R}^n$
2. $L(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$ mit $\boldsymbol{b} \neq \boldsymbol{0}$
3. $L(x) = c \cdot x$ mit $c \in \mathbb{R}$, $x \in \mathbb{R}$
4. $L(x) = x^2$

Überblick

- Aus Analysis bekannt: Ableitungen, *Differenzierbarkeit*
- Neue wichtige Technik: **Allgemeinerer Ableitungsbegriff** (*Fréchet-Ableitung*)
  - Ableitungen mit **Matrix-/Vektor-Inputs** oder **-Outputs**
  - Ableitungen in *allgemeineren (normierten) Räumen*

Ableitung von univariaten Funktionen

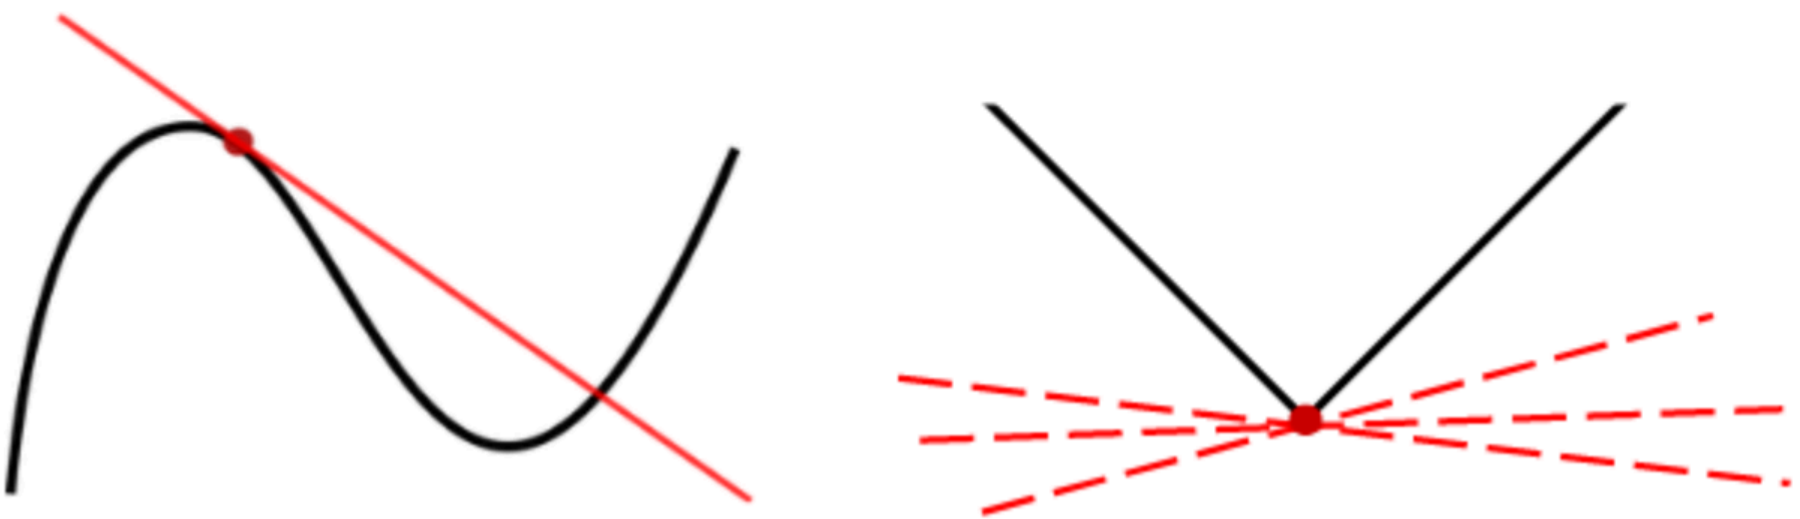
Recap: Ableitung von univariaten Funktionen

Def.: Differenzierbarkeit

Sei $S \subseteq \mathbb{R}$ offen und $f\colon S \to \mathbb{R}$ eine Funktion.
Wir nennen f an der Stelle $x \in S$ **differenzierbar** mit **Ableitung** $f'(x)$, falls

$$\lim_{h \to 0} \frac{f(x+h) - f(x)}{h} = f'(x).$$

- $f'(x)$ ist die **Steigung einer Tangente an f durch x**.
- Falls diese Steigung nicht eindeutig ist, ist f an der Stelle x nicht differenzierbar:



Quiz

Sei f differenzierbar in x mit Ableitung $f'(x)$.

Frage: Welche Aussagen sind wahr?

1. f' ist eine lineare Funktion.
2. $h \mapsto f'(x)h$ ist eine lineare Funktion (für festes x).
3. $\lim_{h \to 0} \dfrac{|f(x+h) - f(x) - f'(x)h|}{h} = 0.$
4. $f(x+h) = f(x) + f'(x)h + o(h).$

Beweis (3) $\iff$ (4): $\to$ *Anhang.*

Allgemeiner Ableitungsbegriff

Allgemeiner Ableitungsbegriff

- Ableitungen können auf verschiedene Arten auf allgemeinere, `normierte` Räume erweitert werden.
- Die Idee ist immer: ***Ableitung*** **= lineare Approximation**.
- Die Definition nach Fréchet reicht aus für
  - alle endlich-dimensionalen Räume,
  - einige unendlich-dimensionale Räume.
- Allgemeinere Definitionen: *Gateaux-*, *Hadamard-Ableitungen*.

Allgemeiner Ableitungsbegriff

Def.: (Fréchet-)differenzierbar

Seien $\mathbb{D}$ und $\mathbb{E}$ zwei normierte Räume und $f: \mathbb{D} \to \mathbb{E}$.

Wir nennen f an der Stelle $x \in \mathbb{D}$ **(Fréchet-)differenzierbar**, falls eine beschränkte lineare Abbildung $D_x f: \mathbb{D} \to \mathbb{E}$ existiert, sodass

$$f(x+h) = f(x) + D_x f(h) + o(\|h\|) \quad \text{für } h \to 0.$$

- $D_x f(h)$ *beschränkt*: Es gibt $M < \infty$, sodass $\|D_x f(h)\| \leq M \|h\| \; \forall h$.
- $h \to D_x f(h)$ ist *linear in* h, hängt aber in beliebiger Weise von x ab.
- *Beispiel:*
  - Für $f: \mathbb{R} \to \mathbb{R}$ ist $D_x f(h) = f'(x)h$.
  - $D_x f$ ist beschränkt, wenn $|f'(x)| < \infty$.
- Fehler $o(\|h\|)$: wird *relativ* zu $\|h\|$ beliebig klein, wenn $h \to 0$

Konkret: Fréchet-Ableitung von $f(x) = x^2$

Sei $f\colon \mathbb{R} \to \mathbb{R}$ mit $f(x) = x^2$. *Zu Zeigen:* f Fréchet-differenzierbar mit $D_x f(h) = 2xh$.

Prüfen der Definition:

$$\begin{aligned} f(x+h) &= (x+h)^2 = x^2 + 2xh + h^2 \\ &= f(x) + 2xh + h^2 \\ &= f(x) + D_x f(h) + h^2 \\ \implies D_x f(h) &= 2xh \ (\text{linear in } h) \end{aligned}$$

- $\lim_{h\to 0} \frac{|h^2|}{|h|} = \lim_{h\to 0} |h| = 0 \implies h^2 = o(|h|)$ ✓
- $|D_x f(h)| = |2xh| = 2|x| \cdot |h| \leq M|h| \ \forall h$ mit $M = 2|x| < \infty$
  $\implies D_x f$ beschränkt ✓

$\longrightarrow$ entspricht $f'(x) = 2x$, da $D_x f(h) = f'(x)h = 2x \cdot h$.

Wichtige Spezialfälle

Wichtige Spezialfälle

- Die bereits bekannten Ableitungen sind alle Spezialfälle der Fréchet-Ableitung.
- Besonders wichtige neue Spezialfälle: Ableitungen von Funktionen, die
  - *Skalare, Vektoren oder Matrizen*
  - als *Input oder Output* haben.
- Insbesondere betrachten wir die folgenden Fälle:

Input \ Output	**Skalar**	**Vektor**	**Matrix**
Skalar	$\frac{dy}{dx}$	$\frac{d\boldsymbol{y}}{dx}$	$\frac{d\boldsymbol{Y}}{dx}$
Vektor	$\frac{\partial y}{\partial \boldsymbol{x}}$	$\frac{\partial \boldsymbol{y}}{\partial \boldsymbol{x}}$	
Matrix	$\frac{\partial y}{\partial \boldsymbol{X}}$		

Spezialfall: Vektor zu Skalar

Spezialfall: Vektor zu Skalar

Def.: Gradient

Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ eine *differenzierbare* Funktion.

Wir nennen den **Gradienten** von f in $\boldsymbol{x} \in \mathbb{R}^n$ den *Zeilenvektor*

$$\frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}} = \nabla f(\boldsymbol{x}) = \left(\frac{\partial f(\boldsymbol{x})}{\partial x_1}, \cdots, \frac{\partial f(\boldsymbol{x})}{\partial x_n} \right) \in \mathbb{R}^{1\times n}$$

$$\implies f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)$$

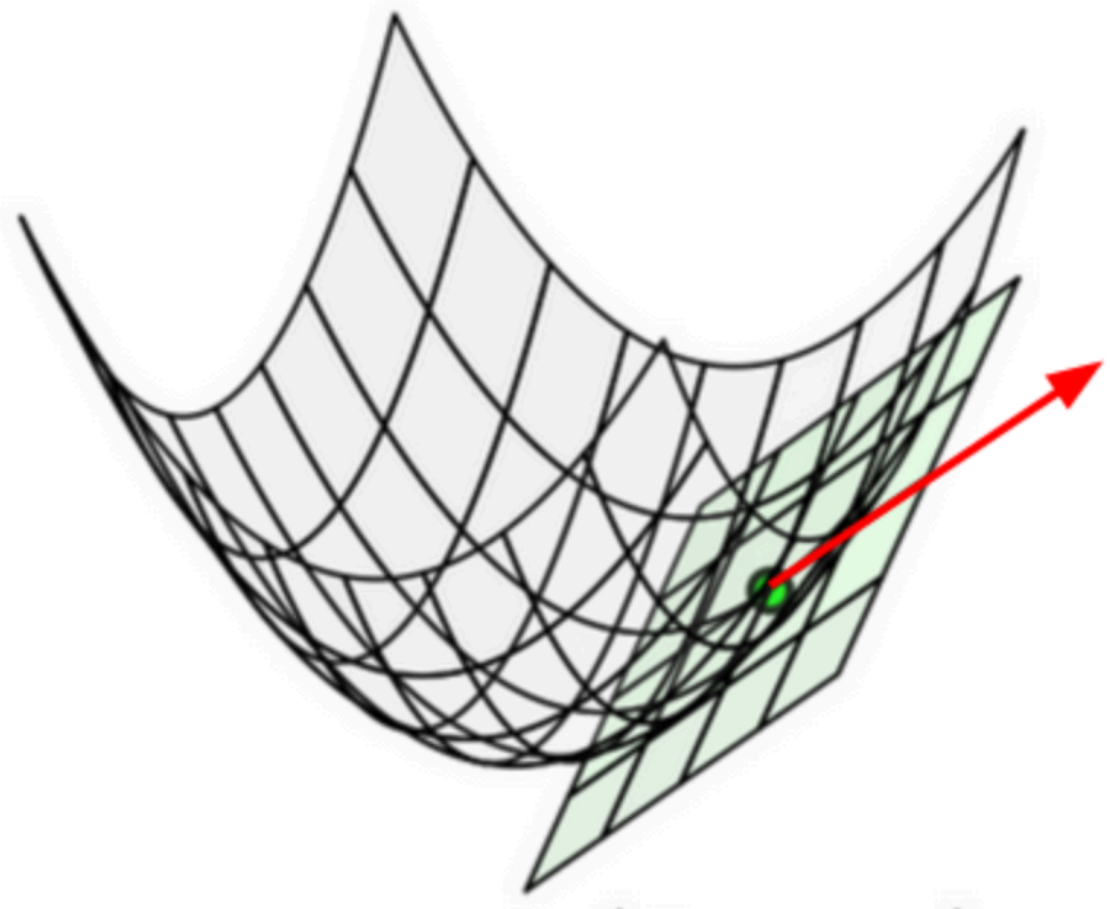
mit $D_{\boldsymbol{x}} f(\boldsymbol{h}) = \nabla f(\boldsymbol{x})\boldsymbol{h}$.

Anmerkung:

Oft wird ∇f auch als Spaltenvektor definiert.
Für uns ist er als **Zeilenvektor** $\in \mathbb{R}^{1\times n}$ konsistenter und praktischer:
- Der Gradient ist dann genau die $1 \times n$-*Jacobimatrix* von f.
- Damit wird die Kettenregel zu einer simplen Matrixmultiplikation von Jacobimatrizen, ganz ohne Transponieren.
($\to$ Kapitel *Differentialrechnung II*)

Spezialfall: Vektor zu Skalar

$f\colon \mathbb{R}^n \to \mathbb{R}$



- Graph von f in grau, der grüne Punkt ist $(\boldsymbol{x}, f(\boldsymbol{x}))$.
- Der rote Pfeil zeigt (in die Tangentialebene angehoben) die Richtung des Gradienten $\nabla f(\boldsymbol{x})^\top$. $\implies$ *Richtung, in die f an Stelle $\boldsymbol{x}$ am **stärksten** steigt*
- Die grüne Ebene ist der Graph von $\boldsymbol{u} \mapsto f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})(\boldsymbol{u} - \boldsymbol{x})$.

Beispiel: Gradient einer quadratischen Funktion

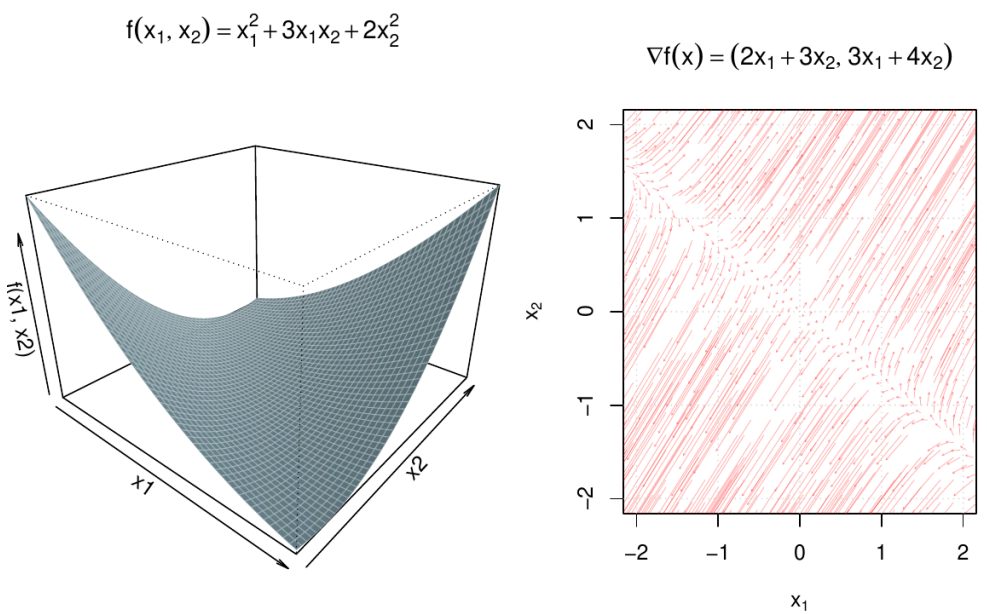
$$f\colon \mathbb{R}^2 \to \mathbb{R} \text{ mit } f(\boldsymbol{x}) = x_1^2 + 3x_1x_2 + 2x_2^2$$

Schritt 1: Berechne partielle Ableitungen

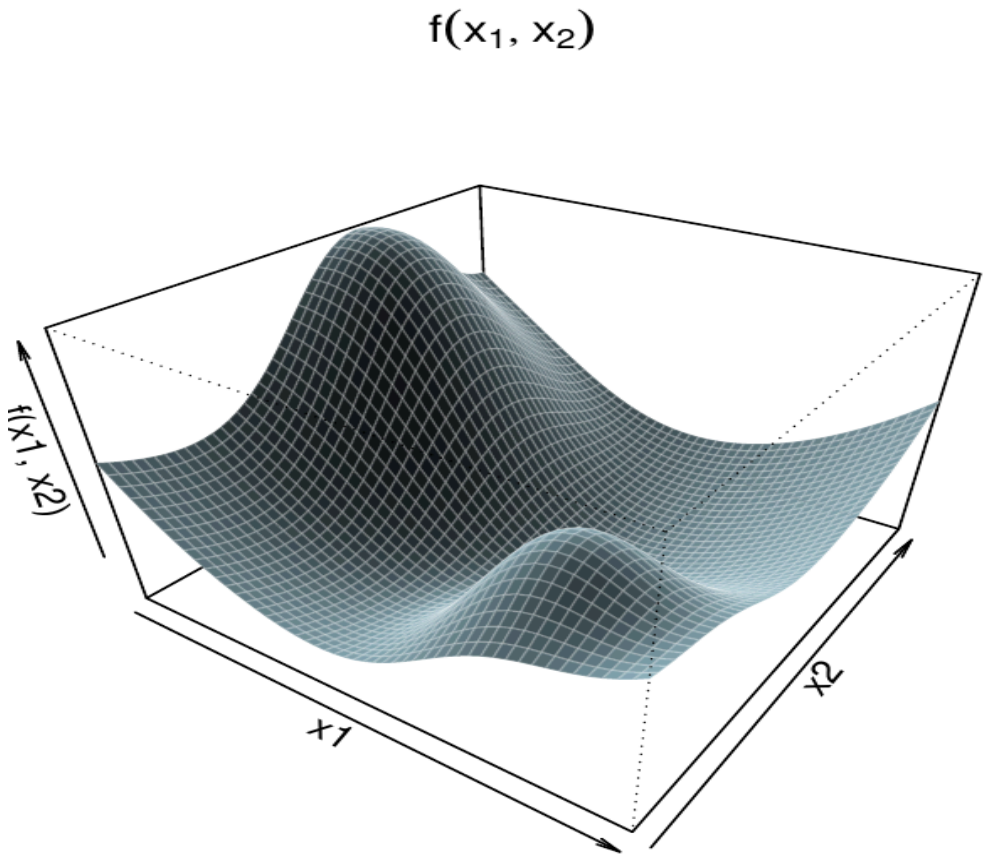
$$\frac{\partial f(\boldsymbol{x})}{\partial x_1} = 2x_1 + 3x_2; \qquad \frac{\partial f(\boldsymbol{x})}{\partial x_2} = 3x_1 + 4x_2$$

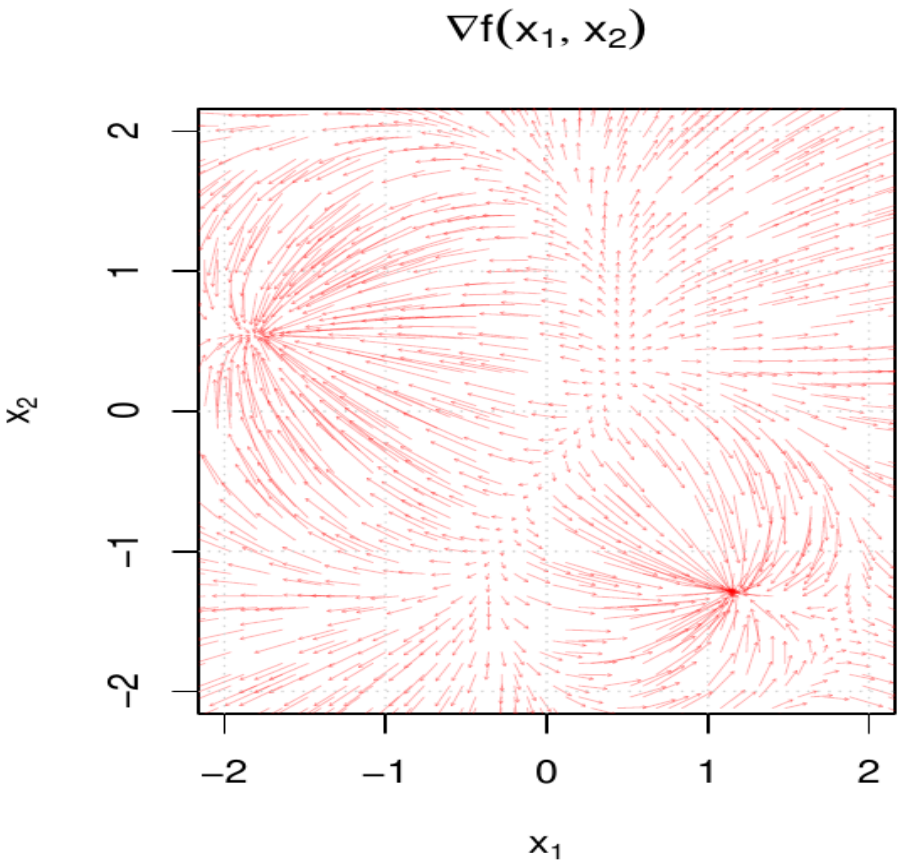
Schritt 2: Gradient als Zeilenvektor

$$\nabla f(\boldsymbol{x}) = (2x_1 + 3x_2 \quad 3x_1 + 4x_2) \qquad (\implies \nabla f\colon \mathbb{R}^2 \to \mathbb{R}^{1\times 2}!)$$



Beispiel: Gradient einer komplexeren Funktion





Übung: Vektor zu Skalar

Sei $\boldsymbol{a}, \boldsymbol{x} \in \mathbb{R}^n$ und

$$f(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x}.$$

Frage:

Was ist $\nabla f(\boldsymbol{x})$?

Antwort:

- Es gilt $f(\boldsymbol{x}) = \sum_{i=1}^{n} a_i x_i$.
- Deshalb $\frac{\partial f(\boldsymbol{x})}{\partial x_i} = a_i$.
- Also

$$\nabla f(\boldsymbol{x}) := \left(\frac{\partial f(\boldsymbol{x})}{\partial x_1}, \cdots, \frac{\partial f(\boldsymbol{x})}{\partial x_n} \right) = (a_1, \ldots, a_n) = \boldsymbol{a}^\top.$$

Übung: Gradient der quadratischen Form

Sei $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ symmetrische Matrix und $f\colon \mathbb{R}^n \to \mathbb{R}$ mit

$$f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}.$$

1. $f(\boldsymbol{x}) = \sum_{i=1}^{n} \sum_{j=1}^{n} x_i a_{ij} x_j$.
2. Ableiten nach x_k:

$$\begin{aligned}
\frac{\partial f(\boldsymbol{x})}{\partial x_k} &= \sum_{i=1}^{n} x_i a_{ik} + \sum_{j=1}^{n} a_{kj} x_j \\
&= \sum_{i=1}^{n} a_{ki} x_i + \sum_{j=1}^{n} a_{kj} x_j \quad (\text{da } \boldsymbol{A} \text{ symmetrisch}) \\
&= 2 \sum_{i=1}^{n} a_{ki} x_i = 2(\boldsymbol{A}\boldsymbol{x})_k \\
&\implies \nabla f(\boldsymbol{x}) = 2\boldsymbol{x}^\top \boldsymbol{A}
\end{aligned}$$

Spezialfall: Ist $\boldsymbol{A} = \boldsymbol{I}$, dann $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{x} = \|\boldsymbol{x}\|_2^2$ und $\nabla f(\boldsymbol{x}) = 2\boldsymbol{x}^\top$.

Anwendung: Gradient Descent

Problemstellung:
Minimiere eine Verlustfunktion $L(\boldsymbol{\theta})$
(z.B. Mean Squared Error eines Modells mit Parametern $\boldsymbol{\theta}$).

Gradient Descent (**Gradientenabstieg**):

$$\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \alpha \nabla L\left(\boldsymbol{\theta}^{(t)}\right)^\top$$

- $\alpha > 0$: Lernrate (Schrittweite)
- $-\nabla L\left(\boldsymbol{\theta}^{(t)}\right)^\top$: Negativer Gradient zeigt in Richtung des steilsten *Abstiegs*
- Gradient sagt uns, in welche Richtung wir $\boldsymbol{\theta}$ ändern müssen, um näher an ein Minimum (= *"optimales"* Modell) zu kommen
- fundamentaler Basisalgorithmus zur **Optimierung** von neuronalen Netze, komplexen Regressionsmodellen, ...
  $\rightarrow$ *Optimierung I & II*

Spezialfall: Vektor zu Vektor

Spezialfall: Vektor zu Vektor

Def.: Jacobimatrix

Sei $f\colon \mathbb{R}^n \to \mathbb{R}^m$ eine differenzierbare Funktion mit $f(\boldsymbol{x}) = \big(f_1(\boldsymbol{x}), \dots, f_m(\boldsymbol{x})\big)^\top$.

Die **Jacobimatrix** $\boldsymbol{J}_f(\boldsymbol{x}) \in \mathbb{R}^{m\times n}$ von f in $\boldsymbol{x} \in \mathbb{R}^n$ ist

$$\boldsymbol{J}_f(\boldsymbol{x}) := \frac{\partial f(\boldsymbol{x})}{\partial \boldsymbol{x}} = \begin{pmatrix} \partial f_1(\boldsymbol{x})/\partial x_1 & \cdots & \partial f_1(\boldsymbol{x})/\partial x_n \\ \vdots & \ddots & \vdots \\ \partial f_m(\boldsymbol{x})/\partial x_1 & \cdots & \partial f_m(\boldsymbol{x})/\partial x_n \end{pmatrix}.$$

$ f(+) = f() + D_{} f() + o(||)$

mit $D_{\boldsymbol{x}} f(\boldsymbol{h}) = \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h}$.

- Die *Zeilen* der *Jacobimatrix* sind *Gradienten* der Komponenten von $f(\boldsymbol{x}) = \big(f_1(\boldsymbol{x}), \dots, f_m(\boldsymbol{x})\big)^\top$:

$$\boldsymbol{J}_f(\boldsymbol{x}) = \begin{pmatrix} \nabla f_1(\boldsymbol{x}) \\ \vdots \\ \nabla f_m(\boldsymbol{x}) \end{pmatrix}$$

Spezialfall: Vektor zu Vektor

Wichtige Identitäten:

- $f(\boldsymbol{x}) = \boldsymbol{c} \in \mathbb{R}^m \quad \Longrightarrow \boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{0}_{m \times n}$
- $f(\boldsymbol{x}) = \boldsymbol{x}$ (d.h. $m = n$) $\quad \Longrightarrow \boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{I}_n$
- $f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$ mit $\boldsymbol{A} \in \mathbb{R}^{m \times n} \quad \Longrightarrow \boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{A}$
- $f(\boldsymbol{x}) = \left(\boldsymbol{x}^\top \boldsymbol{A}\right)^\top = \boldsymbol{A}^\top \boldsymbol{x}$ mit $\boldsymbol{A} \in \mathbb{R}^{n \times m} \quad \Longrightarrow \boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{A}^\top$

Übung

$$f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} \text{ mit } \boldsymbol{A} \in \mathbb{R}^{m \times n}:$$

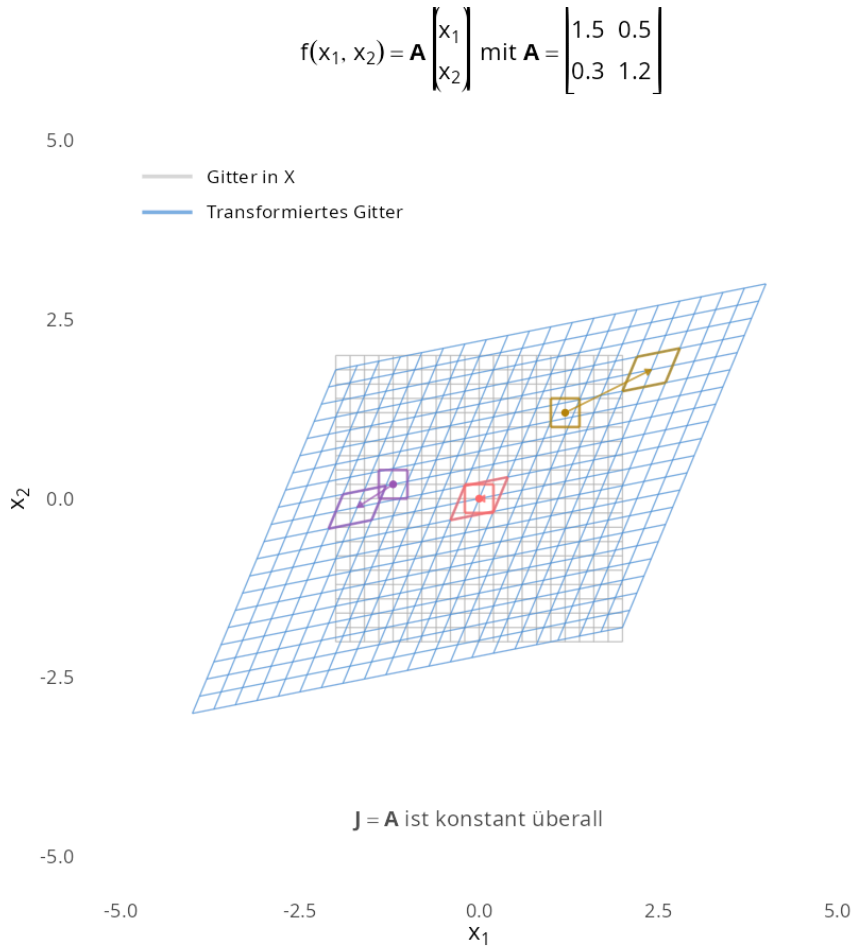
$$f_i(\boldsymbol{x}) = \sum_{j=1}^{n} a_{ij} x_j \quad \text{(komponentenweise)}$$

$$\frac{\partial f_i(\boldsymbol{x})}{\partial x_k} = \frac{\partial}{\partial x_k} \left(\sum_{j=1}^{n} a_{ij} x_j \right) = a_{ik}$$

$$\implies \boldsymbol{J}_f(\boldsymbol{x}) = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} = \boldsymbol{A} \quad \checkmark$$

- Lineare Funktionen haben konstante Jacobimatrizen
- Für lineare Funktionen gilt $f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h}$

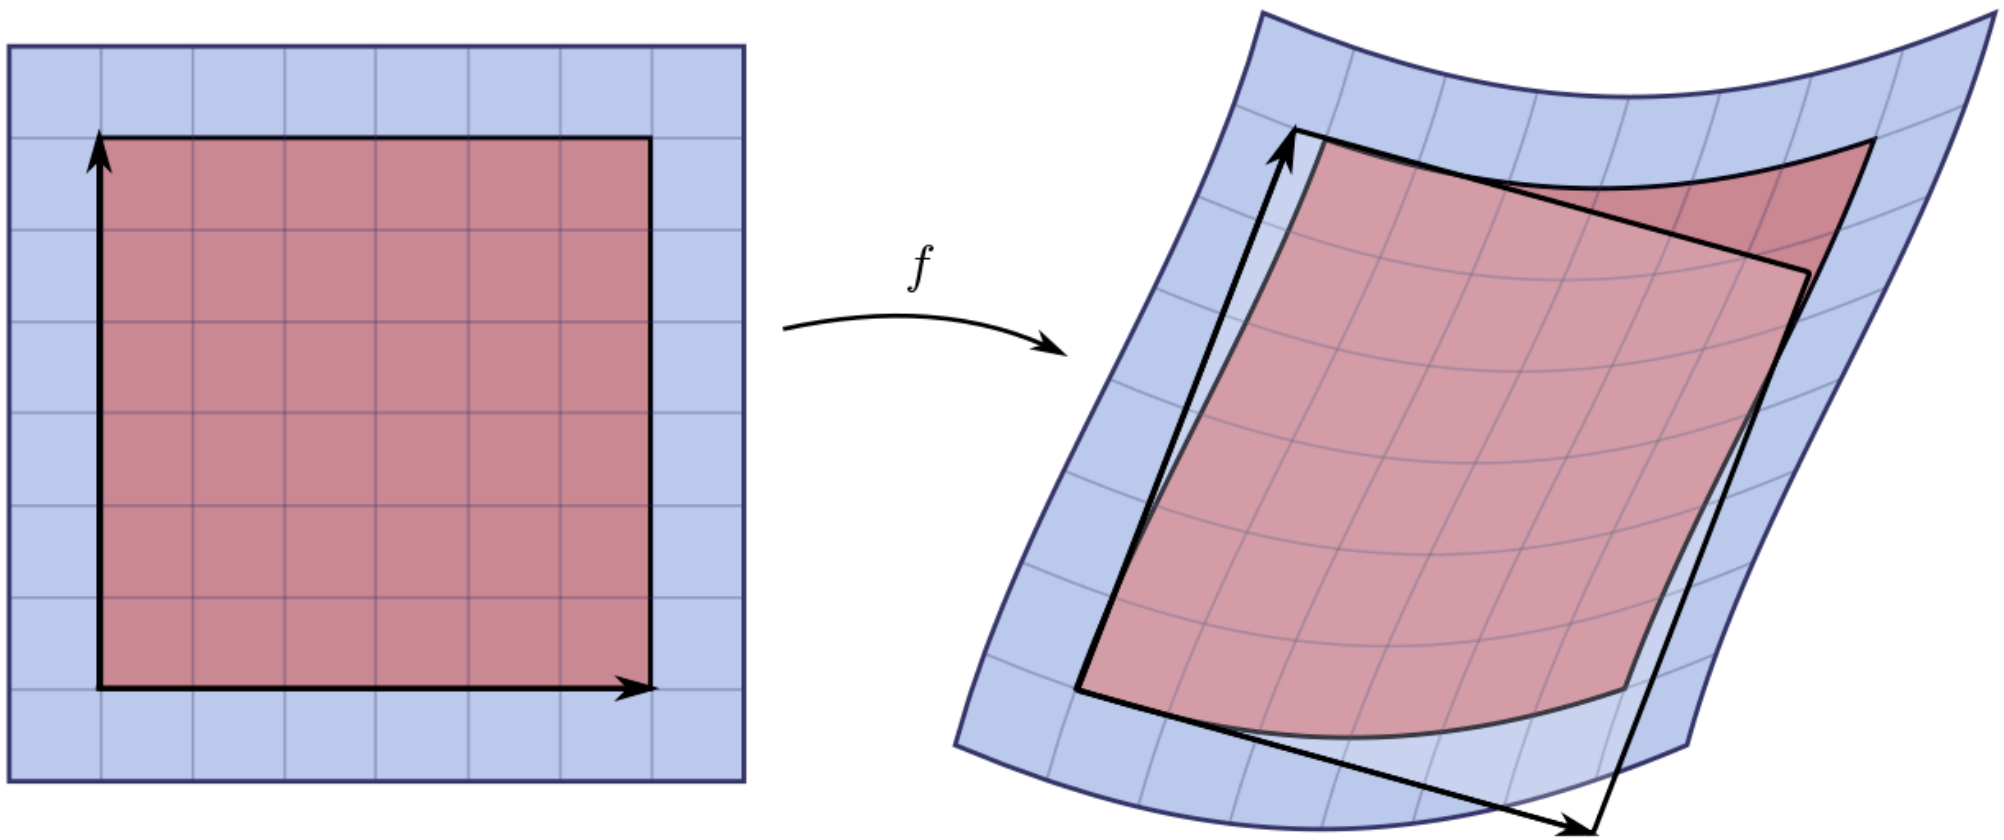
Visualisierung: Lineare Transformation $\mathbb{R}^2 \to \mathbb{R}^2$



Lineare Funktion: $f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h}$

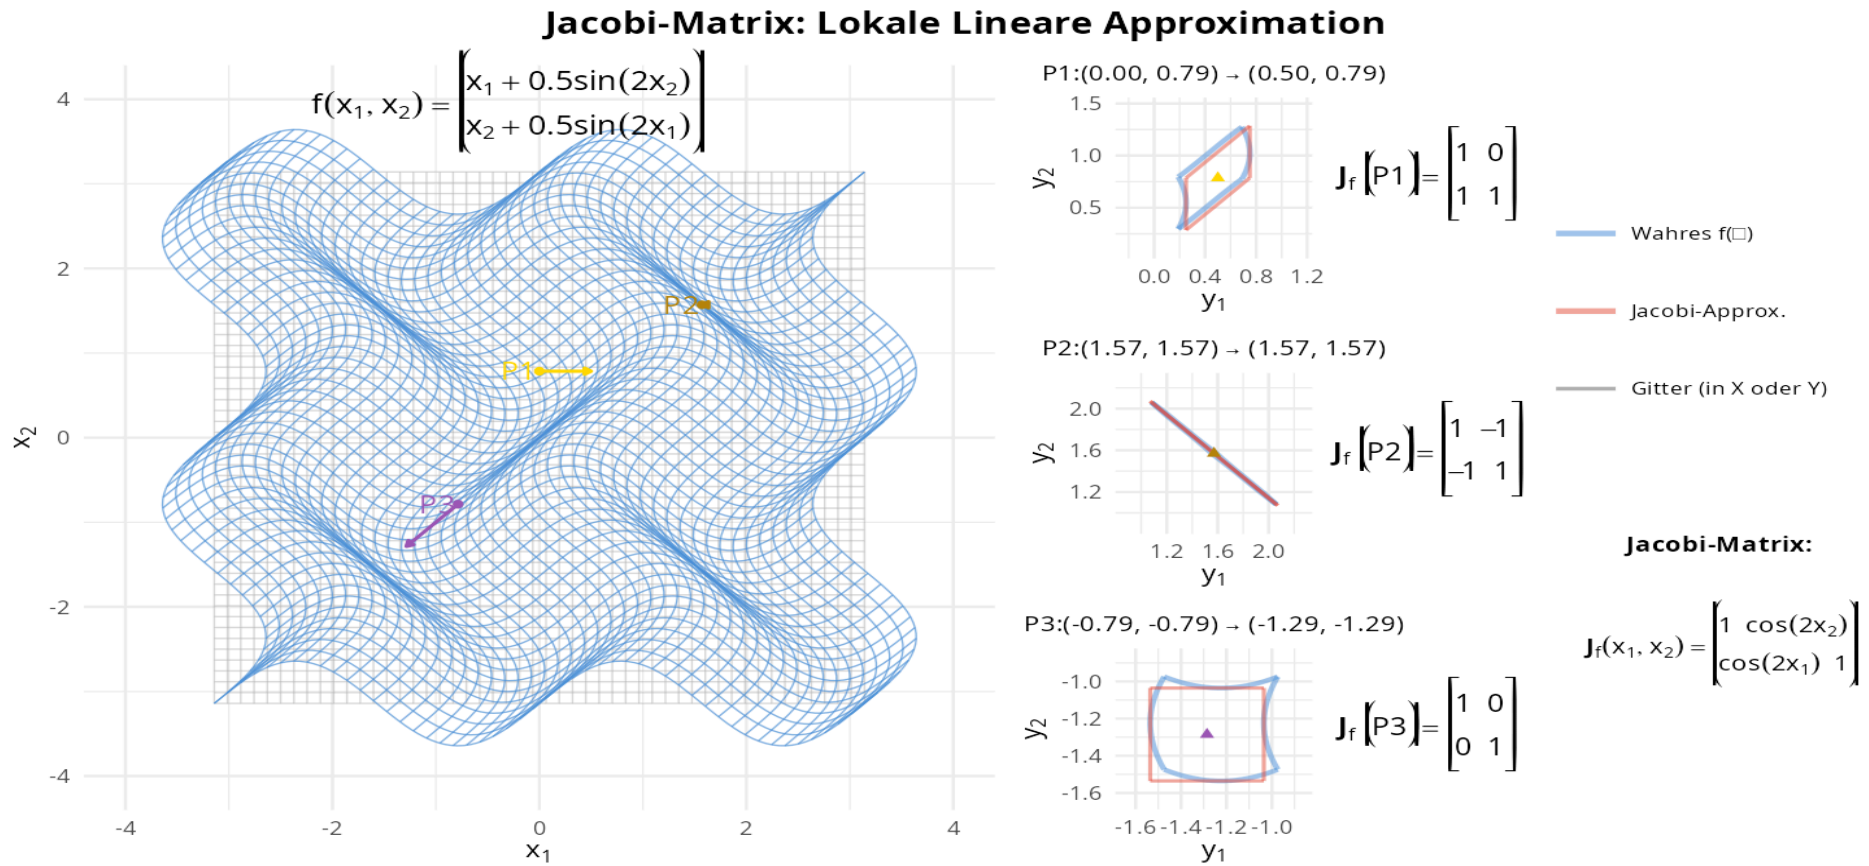
Geometrische Intuition

$f\colon \mathbb{R}^n \to \mathbb{R}^m$



- $f\colon \mathbb{R}^2 \to \mathbb{R}^2$ transformiert das rote Quadrat links zur roten Fläche rechts.
- Die gekrümmte Darstellung soll verdeutlichen, dass f den Raum lokal verbiegt und streckt, obwohl Urbild und Bild dieselbe Dimension haben.
- Das schwarze Quadrat rechts zeigt das Bild der linearen Approximation durch $\boldsymbol{J}_f$.

Geometrische Intuition — Jacobimatrix $\mathbb{R}^2 \to \mathbb{R}^2$



$$f(\boldsymbol{x} + \boldsymbol{h}) \approx f(\boldsymbol{x}) + \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h}$$

Spezialfall: Skalar zu Matrix

Spezialfall: Skalar zu Matrix

$$\boldsymbol{F}\colon \mathbb{R} \to \mathbb{R}^{m\times n}$$

- Sei $x \in \mathbb{R}$, seien alle f_{ij} in x differenzierbar, und

$$\boldsymbol{F}(x) = \begin{pmatrix} f_{11}(x) & \cdots & f_{1n}(x) \\ \vdots & \ddots & \vdots \\ f_{m1}(x) & \cdots & f_{mn}(x) \end{pmatrix}.$$

- Definiere

$$\frac{\partial \boldsymbol{F}(x)}{\partial x} = \begin{pmatrix} \frac{\partial f_{11}(x)}{\partial x} & \cdots & \frac{\partial f_{1n}(x)}{\partial x} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_{m1}(x)}{\partial x} & \cdots & \frac{\partial f_{mn}(x)}{\partial x} \end{pmatrix} \in \mathbb{R}^{m\times n}.$$

- Dann ist

$$\boldsymbol{F}(x+h) = \boldsymbol{F}(x) + D_x\boldsymbol{F}(h) + o(|h|) \quad \text{mit} \quad D_x\boldsymbol{F}(h) = \frac{\partial \boldsymbol{F}(x)}{\partial x} h.$$

Übung: Skalar zu Matrix

Sei, für $x > 0$,

$$\boldsymbol{F}(x) = \begin{pmatrix} x^2 & 2e^x & 0 \\ 0 & x & \ln(x) \end{pmatrix}.$$

Frage:

Was ist $\frac{\partial \boldsymbol{F}(x)}{\partial x}$?

Antwort:

$$\frac{\partial \boldsymbol{F}(x)}{\partial x} = \begin{pmatrix} 2x & 2e^x & 0 \\ 0 & 1 & 1/x \end{pmatrix}.$$

Skalar zu Matrix: Wichtige Identitäten

Für *quadratisches, differenzierbares*

$$\boldsymbol{F}\colon \mathbb{R} \to \mathbb{R}^{n\times n}$$

(erste beide Formeln: $\boldsymbol{F}(x)$ zusätzlich invertierbar):

- $\dfrac{\partial \boldsymbol{F}(x)^{-1}}{\partial x} = -\boldsymbol{F}(x)^{-1}\dfrac{\partial \boldsymbol{F}(x)}{\partial x}\boldsymbol{F}(x)^{-1}.$
- $\dfrac{\partial \det\big(\boldsymbol{F}(x)\big)}{\partial x} = \det\big(\boldsymbol{F}(x)\big)\operatorname{tr}\left[\boldsymbol{F}(x)^{-1}\dfrac{\partial \boldsymbol{F}(x)}{\partial x}\right].$
- $\dfrac{\partial \operatorname{tr}\big(\boldsymbol{F}(x)\big)}{\partial x} = \operatorname{tr}\left(\dfrac{\partial \boldsymbol{F}(x)}{\partial x}\right).$

(Rechenbeispiel zur Determinanten-Formel: → Anhang — wichtig z.B. für Ableitungen von Likelihood-Funktionen!)

Beweis: Ableitung der Spur

$$\frac{\partial \operatorname{tr}\big(\boldsymbol{F}(x)\big)}{\partial x} = \operatorname{tr}\left(\frac{\partial \boldsymbol{F}(x)}{\partial x}\right)$$

Beweis:

$$\begin{aligned}
\operatorname{tr}\big(\boldsymbol{F}(x)\big) &= \sum_{i=1}^{n} f_{ii}(x) \\
\frac{\partial}{\partial x}\operatorname{tr}\big(\boldsymbol{F}(x)\big) &= \frac{\partial}{\partial x}\left(\sum_{i=1}^{n} f_{ii}(x)\right) \\
&= \sum_{i=1}^{n} \frac{\partial f_{ii}(x)}{\partial x} \\
&= \operatorname{tr}\left(\frac{\partial \boldsymbol{F}(x)}{\partial x}\right) \quad \checkmark
\end{aligned}$$

Spezialfall: Matrix zu Skalar

Spezialfall: Matrix zu Skalar

$$f\colon \mathbb{R}^{m\times n} \to \mathbb{R}$$

- Sei f in $\boldsymbol{X} \in \mathbb{R}^{m\times n}$ differenzierbar. Definiere:

$$\frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}} = \begin{pmatrix} \partial f(\boldsymbol{X})/\partial x_{11} & \cdots & \partial f(\boldsymbol{X})/\partial x_{1n} \\ \vdots & \ddots & \vdots \\ \partial f(\boldsymbol{X})/\partial x_{m1} & \cdots & \partial f(\boldsymbol{X})/\partial x_{mn} \end{pmatrix} \in \mathbb{R}^{m\times n}.$$

- Dann ist

$$f(\boldsymbol{X}+\boldsymbol{H}) = f(\boldsymbol{X}) + D_{\boldsymbol{X}} f(\boldsymbol{H}) + o(\|\boldsymbol{H}\|) \quad \text{mit} \quad D_{\boldsymbol{X}} f(\boldsymbol{H}) = \operatorname{tr}\left(\left(\frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}}\right)^{\top} \boldsymbol{H}\right).$$

Matrix zu Skalar: Beispiel

Beispiel:

- Sei $f(\boldsymbol{X}) = \boldsymbol{a}^\top \boldsymbol{X}\boldsymbol{b}$ mit $\boldsymbol{X} \in \mathbb{R}^{m\times n}$, $\boldsymbol{a} \in \mathbb{R}^m$, $\boldsymbol{b} \in \mathbb{R}^n$.
- Dann ist

$$f(\boldsymbol{X}) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_i x_{ij} b_j \quad \Longrightarrow \quad \frac{\partial f(\boldsymbol{X})}{\partial x_{ij}} = a_i b_j.$$

- Daraus folgt

$$\frac{\partial \boldsymbol{a}^\top \boldsymbol{X}\boldsymbol{b}}{\partial \boldsymbol{X}} = \begin{pmatrix} a_1 b_1 & \cdots & a_1 b_n \\ \vdots & \ddots & \vdots \\ a_m b_1 & \cdots & a_m b_n \end{pmatrix} = \boldsymbol{a}\boldsymbol{b}^\top$$

$$\Longrightarrow \; D_{\boldsymbol{X}} f(\boldsymbol{H}) = \operatorname{tr}\left(\left(\boldsymbol{a}\boldsymbol{b}^\top\right)^\top \boldsymbol{H}\right) = \operatorname{tr}\left(\boldsymbol{b}\boldsymbol{a}^\top \boldsymbol{H}\right) = \boldsymbol{a}^\top \boldsymbol{H}\boldsymbol{b}$$

- also hier:

$$f(\boldsymbol{X}+\boldsymbol{H}) = \boldsymbol{a}^\top \boldsymbol{X}\boldsymbol{b} + \boldsymbol{a}^\top \boldsymbol{H}\boldsymbol{b} = f(\boldsymbol{X}) + D_{\boldsymbol{X}} f(\boldsymbol{H})$$

Wichtige Identitäten: Matrix zu Skalar

- **Quadratische Form:** $f(\boldsymbol{X}) = \operatorname{tr}\left(\boldsymbol{X}\boldsymbol{A}\boldsymbol{X}^\top\right)$ mit symmetrischem $\boldsymbol{A} \in \mathbb{R}^{n\times n}$

$$\frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}} = \boldsymbol{X}\left(\boldsymbol{A} + \boldsymbol{A}^\top\right) = 2\boldsymbol{X}\boldsymbol{A}$$

- **Trace-Produkt:** $f(\boldsymbol{X}) = \operatorname{tr}\left(\boldsymbol{A}^\top \boldsymbol{X}\right)$ mit $\boldsymbol{A} \in \mathbb{R}^{m\times n}$

$$\frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}} = \boldsymbol{A}$$

- **Frobenius-Norm:** $f(\boldsymbol{X}) = \|\boldsymbol{X}\|_F^2 = \operatorname{tr}\left(\boldsymbol{X}^\top \boldsymbol{X}\right)$

$$\frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}} = 2\boldsymbol{X}$$

(Anwendungsbeispiel Matrixzerlegung / Matrix Completion: → Anhang)

Bemerkungen

- Wir haben bewusst ein paar Fälle ausgelassen:
  - Matrix zu Vektor
  - Vektor zu Matrix
  - Matrix zu Matrix
- Diese Fälle werden seltener gebraucht und können (z.B.) über *Tensoren* dargestellt werden.
- Zur *Störungsanalyse* von Matrixrechnungen kann man auch $h \mapsto f(\boldsymbol{X} + h\boldsymbol{E})$ nach Skalar h ableiten (= Ableitung in "Richtung" $\boldsymbol{E}$.)
- Formeln für die meisten in Anwendungen vorkommenden Ableitungen findet man in dem *Matrix Cookbook* von Petersen & Pedersen (2012).
- Abbildungen zwischen Funktionenräumen $\longrightarrow$ Übung.

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- Fréchet-Ableitung auf normierten Räumen: **Ableitung = lineare Approximation**
- Spezialfälle für Skalare, Vektoren, Matrizen: *Gradient* (Zeilenvektor!), *Jacobimatrix*, Matrixableitungen

Nächste Vorlesung

- Eigenschaften, Rechenregeln, höhere Ableitungen

Self-Check

Frage 1: Sei $f(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x}$ mit $\boldsymbol{a}, \boldsymbol{x} \in \mathbb{R}^n$. Was ist $\nabla f(\boldsymbol{x})$?

1. $\boldsymbol{a}^\top$
2. $\boldsymbol{a}\boldsymbol{a}^\top$
3. $\boldsymbol{x}^\top$
4. $\boldsymbol{a}^\top \boldsymbol{x}$

Frage 2: Sei $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ mit *symmetrischem* $\boldsymbol{A} \in \mathbb{R}^{n \times n}$. Was ist $\nabla f(\boldsymbol{x})$?

1. $\boldsymbol{A}\boldsymbol{x}$
2. $2\boldsymbol{x}^\top \boldsymbol{A}$
3. $2\boldsymbol{A}$
4. $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$

Frage 3: Sei $f\colon \mathbb{R}^3 \to \mathbb{R}^2$ differenzierbar. Welche Dimension hat die Jacobimatrix $\boldsymbol{J}_f(\boldsymbol{x})$?

1. 3×2
2. 2×3
3. 3×3
4. 2×2

Anhang

Quiz: Beweis Aussage (3) $\iff$ (4)

“$\implies$”: Angenommen (3) gilt, also $\lim_{h\to 0} \frac{|f(x+h)-f(x)-f'(x)h|}{h} = 0$.

- Definiere $r(h) := f(x+h) - f(x) - f'(x)h$.
- Also: $\lim\limits_{h\to 0} \dfrac{|r(h)|}{h} = 0$, also $r(h) = o(h)$.
- Und damit: $f(x+h) = f(x) + f'(x)h + r(h) = f(x) + f'(x)h + o(h)$. ✓

“$\impliedby$”: Angenommen (4) gilt, also $f(x+h) = f(x) + f'(x)h + o(h)$.

- Dann ist $f(x+h) - f(x) - f'(x)h = o(h)$.
- Per Definition von $o(h)$: $\lim\limits_{h\to 0} \dfrac{|f(x+h) - f(x) - f'(x)h|}{h} = \lim\limits_{h\to 0} \dfrac{|o(h)|}{h} = 0$. ✓

↩ zurück: „Quiz”

Beispiel: Ableitung der Determinante

*Vertiefung zu "Skalar zu Matrix: Wichtige Identitäten" — **wichtig** für Ableitungen von Likelihood-Funktionen in der Statistik!*

$$\frac{\partial \det\big(\boldsymbol{F}(x)\big)}{\partial x} = \det\big(\boldsymbol{F}(x)\big)\operatorname{tr}\left[\boldsymbol{F}(x)^{-1}\frac{\partial \boldsymbol{F}(x)}{\partial x}\right]$$

Beispiel: $\boldsymbol{F}(x) = \begin{pmatrix} x & 0 \\ 0 & 2x \end{pmatrix}$.

Direkte Berechnung:

$$\det(\boldsymbol{F}(x)) = x \cdot 2x = 2x^2 \quad \Longrightarrow \quad \frac{\partial}{\partial x}\det(\boldsymbol{F}(x)) = 4x$$

Überprüfung (für $x \neq 0$, sonst existiert $\boldsymbol{F}(x)^{-1}$ nicht):

$$\frac{\partial \boldsymbol{F}(x)}{\partial x} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}, \quad \boldsymbol{F}(x)^{-1} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix}$$

$$\boldsymbol{F}(x)^{-1}\frac{\partial \boldsymbol{F}(x)}{\partial x} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/(2x) \end{pmatrix}\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1/x & 0 \\ 0 & 1/x \end{pmatrix}$$

$$\operatorname{tr}\left[\boldsymbol{F}(x)^{-1}\frac{\partial \boldsymbol{F}(x)}{\partial x}\right] = 1/x + 1/x = 2/x$$

$$\det(\boldsymbol{F}(x)) \cdot \operatorname{tr}\left[\boldsymbol{F}(x)^{-1}\frac{\partial \boldsymbol{F}(x)}{\partial x}\right] = 2x^2 \cdot \frac{2}{x} = 4x \quad \checkmark$$

↩ zurück: „Skalar zu Matrix: Wichtige Identitäten"

Anwendung: Matrixzerlegung & *Matrix Completion*

Vertiefung zu “Wichtige Identitäten: Matrix zu Skalar”.

Gegeben: Unvollständig nur an Indizes $(i,j) \in \Omega$ beobachtete Matrix $\boldsymbol{Y} \in \mathbb{R}^{m \times n}$ (z.B. User-Ratings von Filmen)

Ziel: Finde Low-Rank-Approximation $\boldsymbol{Y} \approx \boldsymbol{U}\boldsymbol{V}^\top$ mit $\boldsymbol{U} \in \mathbb{R}^{m \times k}$, $\boldsymbol{V} \in \mathbb{R}^{n \times k}$.

Verlustfunktion:

$$L(\boldsymbol{U}, \boldsymbol{V}) = \frac{1}{2} \sum_{(i,j) \in \Omega} \left(y_{ij} - \left[\boldsymbol{U}\boldsymbol{V}^\top \right]_{ij} \right)^2 = \frac{1}{2} \left\| \boldsymbol{P}_\Omega \odot (\boldsymbol{Y} - \boldsymbol{U}\boldsymbol{V}^\top) \right\|_F^2; \qquad \boldsymbol{P}_\Omega = \left[\mathbb{I}_{(i,j) \in \Omega} \right]$$

($\odot$: *elementweises* (Hadamard-)Produkt)

Gradienten für Optimierung:

$$\frac{\partial L}{\partial \boldsymbol{U}} = -\left(\boldsymbol{P}_\Omega \odot \left(\boldsymbol{Y} - \boldsymbol{U}\boldsymbol{V}^\top \right) \right) \boldsymbol{V}$$
$$\frac{\partial L}{\partial \boldsymbol{V}} = -\left(\boldsymbol{P}_\Omega \odot \left(\boldsymbol{Y} - \boldsymbol{U}\boldsymbol{V}^\top \right) \right)^\top \boldsymbol{U}$$

Anwendungen: Missing Data Imputation, Recommender Systems / Collaborative Filtering, …

↩ zurück: „Wichtige Identitäten: Matrix zu Skalar”