

Differentialrechnung II

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- **Fréchet-Differenzierbarkeit:** $f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|)$
- **Gradient** $\nabla f(\mathbf{x})$ für $f : \mathbb{R}^n \rightarrow \mathbb{R}$
- **Jacobimatrix** $\mathbf{J}_f(\mathbf{x})$ für $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$
- Matrixableitungen: $\partial f / \partial \mathbf{X}$
- **Analysis:**
 - Produktregel: $(fg)' = f'g + fg'$ & Kettenregel: $(g \circ f)' = g'(f) \cdot f'$
 - Höhere Ableitungen: $f'', f''', \dots$
 - Taylorreihen: $f(x + h) = f(x) + f'(x)h + (1/2)f''(x)h^2 + \dots$
- **Lineare Algebra:**
 - **Multilineare** & **Bilineare** Abbildungen: $\langle \cdot, \cdot \rangle$
 - Quadratische Formen: $\mathbf{x}^\top \mathbf{A} \mathbf{x}$
 - Komposition von Funktionen

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $f: \mathbb{R} \rightarrow \mathbb{R}$ differenzierbar in x mit Ableitung $f'(x)$. Welche Aussagen sind wahr?

1. f' ist eine lineare Funktion.
2. $h \mapsto f'(x)h$ ist eine lineare Funktion (für festes x).
3. $f(x+h) = f(x) + f'(x)h + o(h)$ für $h \rightarrow 0$.
4. “ $o(h)$ ” steht für eine Funktion $r(h)$ mit $\lim_{h \rightarrow 0} \frac{r(h)}{h} = 0$.

Frage 2: Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ differenzierbar. Welche Dimension hat die Jacobimatrix $\mathbf{J}_f(\mathbf{x})$?

1. $n \times m$
2. $m \times n$
3. $n \times n$
4. $m \times m$

Eigenschaften und Rechenregeln

Wichtige Eigenschaften: Stetigkeit

Theorem: Stetigkeit aus Differenzierbarkeit

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Räume und $f: \mathbb{D} \rightarrow \mathbb{E}$ in $\boldsymbol{x} \in \mathbb{D}$ differenzierbar.
Dann ist f in $\boldsymbol{x}$ stetig.

Beweis.

- Per Definition ist $D_{\boldsymbol{x}}f$ beschränkt und linear. Insbesondere gilt

$$\|D_{\boldsymbol{x}}f(\boldsymbol{h})\| \leq M \|\boldsymbol{h}\|, \quad \text{d.h.} \quad D_{\boldsymbol{x}}f(\boldsymbol{h}) = O(\|\boldsymbol{h}\|).$$

- Also ist

$$f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + D_{\boldsymbol{x}}f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|) = f(\boldsymbol{x}) + O(\|\boldsymbol{h}\|) \quad \text{für } \|\boldsymbol{h}\| \rightarrow 0.$$

- Für $\|\boldsymbol{h}\| \rightarrow 0$ erhalten wir $f(\boldsymbol{x} + \boldsymbol{h}) \rightarrow f(\boldsymbol{x})$. ■

Notation:

$r(\boldsymbol{h}) = O(\|\boldsymbol{h}\|)$ für $\|\boldsymbol{h}\| \rightarrow 0$ heißt:

$\|r(\boldsymbol{h})\| \leq C \|\boldsymbol{h}\|$ für alle hinreichend kleinen $\boldsymbol{h}$ –

im Unterschied zu $r(\boldsymbol{h}) = o(\|\boldsymbol{h}\|)$, wo $\|r(\boldsymbol{h})\| / \|\boldsymbol{h}\| \rightarrow 0$ gilt.

Bsp: Stetig aber nicht differenzierbar

Betrachte $f: \mathbb{R} \rightarrow \mathbb{R}$ mit $f(x) = |x|$.

- f stetig in $x = 0$: Für $h \rightarrow 0$ gilt $f(0 + h) = |h| \rightarrow 0 = f(0)$. ✓
- f nicht differenzierbar in $x = 0$:

$$\begin{aligned}\lim_{h \rightarrow 0^+} \frac{f(h) - f(0)}{h} &= \lim_{h \rightarrow 0^+} \frac{|h|}{h} = \lim_{h \rightarrow 0^+} \frac{h}{h} = 1, \\ \lim_{h \rightarrow 0^-} \frac{f(h) - f(0)}{h} &= \lim_{h \rightarrow 0^-} \frac{|h|}{h} = \lim_{h \rightarrow 0^-} \frac{-h}{h} = -1.\end{aligned}$$

Da die linksseitigen und rechtsseitigen Grenzwerte verschieden sind, existiert $f'(0)$ nicht. ✕

Fazit:

- Differenzierbarkeit $\implies$ Stetigkeit
- aber Stetigkeit $\not\implies$ Differenzierbarkeit!

Wichtige Eigenschaften: Linearität

Theorem: Linearität der Ableitungsoperation

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Räume und $f, g: \mathbb{D} \rightarrow \mathbb{E}$ in $\boldsymbol{x} \in \mathbb{D}$ differenzierbar. Dann ist für alle $c_1, c_2 \in \mathbb{R}$ auch $c_1 f + c_2 g$ in $\boldsymbol{x}$ differenzierbar, mit

$$D_{\boldsymbol{x}}(c_1 f + c_2 g) = c_1 D_{\boldsymbol{x}} f + c_2 D_{\boldsymbol{x}} g.$$

Beweis: $\rightarrow$ Übung

Wichtige Eigenschaften: Linearität

Beispiele

- Für $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}$: $(c_1 f + c_2 g)' = c_1 f' + c_2 g'$
- Für $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}$:

$$\nabla [c_1 f(\mathbf{x}) + c_2 g(\mathbf{x})] = c_1 \nabla f(\mathbf{x}) + c_2 \nabla g(\mathbf{x})$$

- Für $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}^m$:

$$\mathbf{J}_{c_1 f + c_2 g}(\mathbf{x}) = c_1 \mathbf{J}_f(\mathbf{x}) + c_2 \mathbf{J}_g(\mathbf{x})$$

- Für $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}^{m \times n}$:

$$\frac{\partial [c_1 \mathbf{F}(x) + c_2 \mathbf{G}(x)]}{\partial x} = c_1 \frac{\partial \mathbf{F}(x)}{\partial x} + c_2 \frac{\partial \mathbf{G}(x)}{\partial x}$$

- Für $\mathbb{D} = \mathbb{R}^{m \times n}, \mathbb{E} = \mathbb{R}$:

$$\frac{\partial [c_1 f(\mathbf{X}) + c_2 g(\mathbf{X})]}{\partial \mathbf{X}} = c_1 \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}} + c_2 \frac{\partial g(\mathbf{X})}{\partial \mathbf{X}}$$

Bsp: Linearität der Ableitung

Gegeben: $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$ und $g(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}$ mit $\mathbf{a} = (1, 2)^\top$.

Berechne $\nabla h(\mathbf{x})$ für $h(\mathbf{x}) = 3f(\mathbf{x}) - 2g(\mathbf{x})$ an der Stelle $\mathbf{x} = (1, -1)^\top$.

(Achtung: h ist hier ausnahmsweise ein Funktionsname, nicht der Zuwachs h .)

Lösung:

1. Berechne Gradienten:

- Für $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x} = x_1^2 + x_2^2$ gilt: $\nabla f(\mathbf{x}) = (2x_1, 2x_2)$
- Für $g(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} = x_1 + 2x_2$ gilt: $\nabla g(\mathbf{x}) = \mathbf{a}^\top = (1, 2)$

2. Wende Linearität an:

$$\nabla h(\mathbf{x}) = 3\nabla f(\mathbf{x}) - 2\nabla g(\mathbf{x}) = 3(2x_1, 2x_2) - 2(1, 2) = (6x_1 - 2, 6x_2 - 4)$$

3. Setze $\mathbf{x} = (1, -1)^\top$ ein:

$$\nabla h \left(\begin{pmatrix} 1 \\ -1 \end{pmatrix} \right) = (6 \cdot 1 - 2, 6 \cdot (-1) - 4) = (4, -10)$$

Rechenregeln: Produktregel

Theorem: Produktregel

Seien $\mathbb{D}, \mathbb{E}, \mathbb{B}$ normierte Räume, $f, g: \mathbb{D} \rightarrow \mathbb{E}$ in $\mathbf{x} \in \mathbb{D}$ differenzierbar, $\langle \cdot, \cdot \rangle: \mathbb{E} \times \mathbb{E} \rightarrow \mathbb{B}$ eine beschränkte bilineare Abbildung und $b(\mathbf{x}) = \langle f(\mathbf{x}), g(\mathbf{x}) \rangle$.

Dann gilt

$$D_{\mathbf{x}}b(\mathbf{h}) = \langle D_{\mathbf{x}}f(\mathbf{h}), g(\mathbf{x}) \rangle + \langle f(\mathbf{x}), D_{\mathbf{x}}g(\mathbf{h}) \rangle.$$

Beweis (kompakt):

Differenzierbarkeit von f, g einsetzen, Bilinearität ausmultiplizieren:

$$\begin{aligned} b(\mathbf{x} + \mathbf{h}) &= \langle f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|), g(\mathbf{x}) + D_{\mathbf{x}}g(\mathbf{h}) + o(\|\mathbf{h}\|) \rangle \\ &= b(\mathbf{x}) + \underbrace{\langle D_{\mathbf{x}}f(\mathbf{h}), g(\mathbf{x}) \rangle + \langle f(\mathbf{x}), D_{\mathbf{x}}g(\mathbf{h}) \rangle}_{= D_{\mathbf{x}}b(\mathbf{h}) \text{ (linear in } \mathbf{h})} + \underbrace{\langle D_{\mathbf{x}}f(\mathbf{h}), D_{\mathbf{x}}g(\mathbf{h}) \rangle + o(\|\mathbf{h}\|)}_{= O(\|\mathbf{h}\|^2) + o(\|\mathbf{h}\|) = o(\|\mathbf{h}\|)} \end{aligned} \quad \blacksquare$$

Kreuzterm: $D_{\mathbf{x}}f(\mathbf{h}), D_{\mathbf{x}}g(\mathbf{h})$ sind beide $O(\|\mathbf{h}\|)$ (beschränkte lineare Abbildungen), die bilineare Abbildung multipliziert die Größenordnungen $\rightarrow O(\|\mathbf{h}\|^2)$.

Rechenregeln: Produktregel

Beispiele:

- $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}, \mathbb{B} = \mathbb{R}$:

$$b(x) = f(x)g(x) \implies b'(x) = f'(x)g(x) + g'(x)f(x).$$

- $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}, \mathbb{B} = \mathbb{R}$:

$$b(\mathbf{x}) = f(\mathbf{x})g(\mathbf{x}) \implies \nabla b(\mathbf{x}) = g(\mathbf{x})\nabla f(\mathbf{x}) + f(\mathbf{x})\nabla g(\mathbf{x}).$$

- $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}^m, \mathbb{B} = \mathbb{R}$:

$$b(\mathbf{x}) = f(\mathbf{x})^\top g(\mathbf{x}) \implies \nabla b(\mathbf{x}) = g(\mathbf{x})^\top \mathbf{J}_f(\mathbf{x}) + f(\mathbf{x})^\top \mathbf{J}_g(\mathbf{x}).$$

- $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}^{n \times n}, \mathbb{B} = \mathbb{R}$:

$$b(x) = \text{tr} [\mathbf{F}(x)\mathbf{G}(x)] \implies b'(x) = \text{tr} \left[\frac{\partial \mathbf{F}(x)}{\partial x} \mathbf{G}(x) \right] + \text{tr} \left[\mathbf{F}(x) \frac{\partial \mathbf{G}(x)}{\partial x} \right].$$

Übung: Ableitung quadratischer Formen

Sei $b(\boldsymbol{x}) = f(\boldsymbol{x})^\top g(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A} \boldsymbol{x}$ mit $f(\boldsymbol{x}) = \boldsymbol{x}$ und $g(\boldsymbol{x}) = \boldsymbol{A} \boldsymbol{x}$.

Aufgabe:

Berechne $\nabla b(\boldsymbol{x})$.

Lösung:

- Es gilt $\boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{I}_n$ und $\boldsymbol{J}_g(\boldsymbol{x}) = \boldsymbol{A}$.
- Dann ist nach der Produktregel

$$\begin{aligned}\nabla b(\boldsymbol{x}) &= g(\boldsymbol{x})^\top \boldsymbol{J}_f(\boldsymbol{x}) + f(\boldsymbol{x})^\top \boldsymbol{J}_g(\boldsymbol{x}) \\ &= (\boldsymbol{A} \boldsymbol{x})^\top \boldsymbol{I}_n + \boldsymbol{x}^\top \boldsymbol{A} = \boldsymbol{x}^\top (\boldsymbol{A} + \boldsymbol{A}^\top)\end{aligned}$$

- falls $\boldsymbol{A}$ symmetrisch also: $\nabla b(\boldsymbol{x}) = 2\boldsymbol{x}^\top \boldsymbol{A}$

Rechenregeln: Kettenregel

Theorem: Kettenregel

Seien $\mathbb{D}_1, \mathbb{D}_2, \mathbb{D}_3$ normierte Räume und $f: \mathbb{D}_1 \rightarrow \mathbb{D}_2, g: \mathbb{D}_2 \rightarrow \mathbb{D}_3$, sodass $g \circ f: \mathbb{D}_1 \rightarrow \mathbb{D}_3$.
Ist f in $\boldsymbol{x} \in \mathbb{D}_1$ und g in $\boldsymbol{y} = f(\boldsymbol{x}) \in \mathbb{D}_2$ differenzierbar, dann ist

$$D_{\boldsymbol{x}}(g \circ f) = D_{\boldsymbol{y}}g \circ D_{\boldsymbol{x}}f.$$

Kettenregel: Beweis

- Da f differenzierbar ist, gilt

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|).$$

- Daraus folgt

$$\begin{aligned}(g \circ f)(\mathbf{x} + \mathbf{h}) &= g(f(\mathbf{x}) + D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|)) \\[g \text{ diff'bar:}] &= g(f(\mathbf{x})) + D_{\mathbf{y}}g(D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|)) + o(\|\mathbf{h}\|) \\[D_{\mathbf{y}}g \text{ linear:}] &= g(f(\mathbf{x})) + D_{\mathbf{y}}g(D_{\mathbf{x}}f(\mathbf{h})) + D_{\mathbf{y}}g(o(\|\mathbf{h}\|)) + o(\|\mathbf{h}\|) \\[D_{\mathbf{y}}g \text{ beschr.:}] &= g(f(\mathbf{x})) + D_{\mathbf{y}}g(D_{\mathbf{x}}f(\mathbf{h})) + o(\|\mathbf{h}\|) \\ &= (g \circ f)(\mathbf{x}) + (D_{\mathbf{y}}g \circ D_{\mathbf{x}}f)(\mathbf{h}) + o(\|\mathbf{h}\|)\end{aligned}$$

Zeile 2:

Der Restterm von g ist zunächst nur klein im weitergereichten Zuwachs $\mathbf{k} = D_{\mathbf{x}}f(\mathbf{h}) + o(\|\mathbf{h}\|)$, also $o(\|\mathbf{k}\|)$.

Da $D_{\mathbf{x}}f$ beschränkt ist ($\|D_{\mathbf{x}}f(\mathbf{h})\| \leq M_f \|\mathbf{h}\|$), gilt für kleine $\mathbf{h}$ aber $\|\mathbf{k}\| \leq (M_f + 1) \|\mathbf{h}\|$ –

damit ist $o(\|\mathbf{k}\|)$ auch $o(\|\mathbf{h}\|)$.

Rechenregeln: Kettenregel

Beispiele:

Anwendung: Kleinste Quadrate via Matrixkalkül

Problem (Kapitel 7 — Lineare Regression):

Response $\mathbf{y} \in \mathbb{R}^n$, Designmatrix $\mathbf{X} \in \mathbb{R}^{n \times p}$:

$$\ell(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 \rightarrow \min_{\boldsymbol{\beta}}$$

Schritt 1 — als Skalarprodukt schreiben:

$$\ell(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \langle f(\boldsymbol{\beta}), f(\boldsymbol{\beta}) \rangle \quad \text{mit } f(\boldsymbol{\beta}) = \mathbf{y} - \mathbf{X}\boldsymbol{\beta}$$

Schritt 2 — Jacobimatrix des inneren Terms (Linearität):

$$\mathbf{J}_f(\boldsymbol{\beta}) = -\mathbf{X}$$

Schritt 3 — Produktregel (mit $g = f$, beide Summanden gleich):

$$\begin{aligned} \nabla \ell(\boldsymbol{\beta}) &= f(\boldsymbol{\beta})^\top \mathbf{J}_f(\boldsymbol{\beta}) + f(\boldsymbol{\beta})^\top \mathbf{J}_f(\boldsymbol{\beta}) \\ &= 2 (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (-\mathbf{X}) = -2 (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{X} \end{aligned}$$

Anwendung: Kleinste Quadrate — Normalengleichungen

Schritt 4 — Gradient nullsetzen:

Am Minimum muss der Gradient verschwinden. (*Optimalitätsbedingung* → *Optimierung I*):

$$\nabla \ell(\hat{\beta}) = -2 (\mathbf{y} - \mathbf{X}\hat{\beta})^\top \mathbf{X} \stackrel{!}{=} \mathbf{0}^\top$$

Transponieren und umstellen:

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0} \quad \Longrightarrow \quad \boxed{\mathbf{X}^\top \mathbf{X} \hat{\beta} = \mathbf{X}^\top \mathbf{y}}$$

→ die *Normalengleichungen*: **die KQ-Lösung aus Kapitel 7 — jetzt hergeleitet!**

Payoff:

- Produkt- & Kettenregel im Matrixkalkül liefern die KQ-Lösung in 4 Zeilen — ohne eine einzige partielle Ableitung auszuschreiben.
- “ $\nabla \ell = \mathbf{0}^\top$ ” als Optimalitätsbedingung wird systematisch ausgebaut: → *Optimierung I & II*.
- Gleiche Rechnung mit Strafterm $\lambda \|\beta\|_2^2$ ergibt die Ridge-Regression (→ Übung).

Anwendung: Backprop in Neuronalen Netzen

- NN ist eine Funktion $f(\mathbf{x}) = (f_K \circ \dots \circ f_2 \circ f_1)(\mathbf{x}) = \hat{\mathbf{y}}$ aufgebaut aus verketteten Funktionen:

$$\text{Input } \mathbf{x} \xrightarrow{f_1} \mathbf{z}_1 \xrightarrow{f_2} \mathbf{z}_2 \xrightarrow{\dots} \dots \xrightarrow{f_K} \text{Output } \hat{\mathbf{y}}$$

- Jedes layer f_k
 - hat eine Gewichtsmatrix $\mathbf{W}_k \in \mathbb{R}^{d_k \times d_{k-1}}$ und
 - berechnet $f_k(\mathbf{z}_{k-1}) = \sigma_k(\mathbf{W}_k \mathbf{z}_{k-1})$,
 - wobei $\sigma_k : \mathbb{R}^{d_k} \rightarrow \mathbb{R}^{d_k}$ komponentenweise wirkt.
- Verlustfunktion $L(\hat{\mathbf{y}})$ misst Güte der Outputs.
- Wir brauchen $\frac{\partial L}{\partial \mathbf{W}_k}$ zur Optimierung.

Kettenregel mit Jacobimatrizen:

$$\frac{\partial L}{\partial \mathbf{W}_k} = \frac{\partial L}{\partial \hat{\mathbf{y}}} \cdot \mathbf{J}_{f_K}(\mathbf{z}_{K-1}) \cdot \mathbf{J}_{f_{K-1}}(\mathbf{z}_{K-2}) \cdots \mathbf{J}_{f_{k+1}}(\mathbf{z}_k) \cdot \frac{\partial f_k(\mathbf{z}_{k-1})}{\partial \mathbf{W}_k}$$

Backpropagation = effiziente Berechnung dieser Jacobimatrizen-Kette!

Beispiel:

Mit ReLU-Aktivierung $\sigma(x) = \max(0, x)$ ist $f_k(\mathbf{z}_{k-1}) = \max(\mathbf{0}, \mathbf{W}_k \mathbf{z}_{k-1})$, also:

$$\mathbf{J}_{f_k}(\mathbf{z}_{k-1}) = \text{diag}(\mathbb{I}_{\mathbf{W}_k \mathbf{z}_{k-1} > 0}) \cdot \mathbf{W}_k$$

(nur für $(\mathbf{W}_k \mathbf{z}_{k-1})_i \neq 0$: an den Knickstellen ist $\max(0, \cdot)$ nicht differenzierbar)

Übung

Sei $h(\mathbf{x}) = \|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{x}}$.

Frage:

Was ist $\nabla h(\mathbf{x})$ für $\mathbf{x} \neq \mathbf{0}$?

Antwort:

- Für $g(x) = \sqrt{x} = x^{1/2}$ gilt $g'(x) = \frac{1}{2x^{1/2}}$.
- Für $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{x}$ gilt $\nabla f(\mathbf{x}) = 2\mathbf{x}^\top$.
- Nach der Kettenregel ist

$$\nabla h(\mathbf{x}) = g'(f(\mathbf{x})) \nabla f(\mathbf{x}) = \frac{2\mathbf{x}^\top}{2f(\mathbf{x})^{1/2}} = \frac{\mathbf{x}^\top}{\|\mathbf{x}\|}.$$

- (In $\mathbf{x} = \mathbf{0}$ ist $\|\cdot\|_2$ nicht differenzierbar.)

Ableitungen höheren Grades

Ableitungen höheren Grades

Def.: k -mal (Fréchet-)differenzierbar

Seien $\mathbb{D}$ und $\mathbb{E}$ zwei normierte Räume und $f: \mathbb{D} \rightarrow \mathbb{E}$. Definiere $D_x^0 f := f(x)$.

Wir nennen f an der Stelle $x \in \mathbb{D}$ **k -mal (Fréchet-)differenzierbar**, falls für $j = 1, \dots, k$ beschränkte, multilineare Abbildungen $D_x^j f: \mathbb{D}^j \rightarrow \mathbb{E}$ existieren, sodass für alle $h_1, \dots, h_{j-1}$ und für $h \rightarrow 0$ gilt:

$$D_x^j f(h_1, \dots, h_{j-1}, h) = D_{x+h}^{j-1} f(h_1, \dots, h_{j-1}) - D_x^{j-1} f(h_1, \dots, h_{j-1}) + o(\|h\|) \prod_{i=1}^{j-1} \|h_i\|$$

- Höhere Ableitungen sind also wieder (multi-)lineare Annäherungen an die (lokale) Veränderung der nächstniedrigeren Ableitung von $f \implies$ Ableitungen berechnen wir wie gewohnt iterativ
- Höhere Ableitungen involvieren i.a. **Tensoren**, deren Stufe wächst mit j .

Konkret: Hesse-Matrix ($k = 2$)

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ (z.B. eine Log-Likelihood) und $f \in \mathcal{C}^2$.

- $j = 1$:
 $D_x f(\mathbf{h}_1) = \nabla f(\mathbf{x}) \mathbf{h}_1$ – lineare Abbildung, dargestellt durch den **Gradienten** (Zeilenvektor).

- $j = 2$:
Die Definition fragt: wie verändert sich Df selbst, wenn wir $\mathbf{x}$ um $\mathbf{h}$ verschieben?

$$D_{\mathbf{x}+\mathbf{h}} f(\mathbf{h}_1) - D_{\mathbf{x}} f(\mathbf{h}_1) = [\nabla f(\mathbf{x} + \mathbf{h}) - \nabla f(\mathbf{x})] \mathbf{h}_1$$

- Lineare Approximation des Gradienten (jede Komponente von ∇f ist selbst differenzierbar):

$$\nabla f(\mathbf{x} + \mathbf{h}) - \nabla f(\mathbf{x}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) + o(\|\mathbf{h}\|)$$

- Einsetzen ergibt die *bilineare* Abbildung

$$D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}) = \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_1$$

dargestellt durch die Matrix $\mathbf{H}_f(\mathbf{x})$ der zweiten partiellen Ableitungen: die **Hesse-Matrix**

(Symmetrie von $\mathbf{H}_f$ für $f \in \mathcal{C}^2$: $\rightarrow$ Satz von Schwarz, gleich.)

Höhergradige Ableitung für Vektor-zu-Skalar

Def.: Hesse-Matrix

Die **Hesse-Matrix** $\mathbf{H}_f(\mathbf{x})$ einer zweimal differenzierbaren Funktion $f: S \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$ (S offen) ist die Matrix der zweiten partiellen Ableitungen, also

$$\mathbf{H}_f(\mathbf{x}) := \left(\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} \right)_{i,j=1,\dots,n} \in \mathbb{R}^{n \times n}.$$

Hier ist:

- $D_{\mathbf{x}} f(\mathbf{h}) = \nabla f(\mathbf{x}) \mathbf{h}$
- $D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) = \mathbf{h}_1^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}_2$ mit Hesse-Matrix $\mathbf{H}_f(\mathbf{x}) \in \mathbb{R}^{n \times n}$.
- $(D_{\mathbf{x}}^3 f \in \mathbb{R}^{n \times n \times n})$ wäre ein Tensor mit $(D_{\mathbf{x}}^3 f)_{i,j,k} = \frac{\partial^3 f(\mathbf{x})}{\partial x_k \partial x_j \partial x_i}$ und $D_{\mathbf{x}}^3 f(\mathbf{h}_1, \mathbf{h}_2, \mathbf{h}_3) = \sum_{i,j,k} (D_{\mathbf{x}}^3 f)_{i,j,k} h_{1i} h_{2j} h_{3k}$

Symmetrische Hesse-Matrizen

Theorem: Satz von Schwarz

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ zweimal stetig differenzierbar ($f \in \mathcal{C}^2$). Dann gilt:

$$\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j} = \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i} \quad \text{für alle } i, j.$$

$\implies$ Hesse-Matrix für $f \in \mathcal{C}^2$ ist symmetrisch: $\mathbf{H}_f(\mathbf{x}) = \mathbf{H}_f(\mathbf{x})^\top$.

- Reihenfolge der partiellen Ableitungen spielt unter Stetigkeitsbedingungen keine Rolle
- Reduziert Anzahl der zu berechnenden Ableitungen von n^2 auf $\frac{n(n+1)}{2}$
- Wichtig für numerische Verfahren und Optimierung: nutze Symmetrie der Hesse-Matrix

Geometrische Interpretation und Konvexität

Hesse-Matrix charakterisiert die *lokale Krümmung* einer Funktion:

1. Definitheit der Hesse-Matrix:

Für $f \in \mathcal{C}^2$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$, an einem **kritischen Punkt** $\mathbf{x}^*$ (d.h. $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$):

- $\mathbf{H}_f(\mathbf{x}^*)$ **positiv definit** ($\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} > 0$ für alle $\mathbf{h} \neq \mathbf{0}$) $\implies \mathbf{x}^*$ ist ein **lokales Minimum**
- $\mathbf{H}_f(\mathbf{x}^*)$ **negativ definit** ($\mathbf{h}^\top \mathbf{H}_f(\mathbf{x}^*) \mathbf{h} < 0$ für alle $\mathbf{h} \neq \mathbf{0}$) $\implies \mathbf{x}^*$ ist ein **lokales Maximum**
- $\mathbf{H}_f(\mathbf{x}^*)$ **indefinit** (positive und negative Eigenwerte) $\implies \mathbf{x}^*$ ist ein **Sattelpunkt**

2. Konvexität:

$f \in \mathcal{C}^2$ ist **konvex** auf einer *offenen, konvexen* Menge $S \subseteq \mathbb{R}^n \iff \mathbf{H}_f(\mathbf{x}) \succeq 0$ (*positiv semidefinit*) für alle $\mathbf{x} \in S$.

3. Quadratische Approximation:

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h}$$

- beste quadratische Approximation von f in der Umgebung von $\boldsymbol{x}$ ($\rightarrow$ Taylorentwicklung)
- $\boldsymbol{H}_f(\boldsymbol{x})$ beschreibt die lokale Krümmung von f in Richtung $\boldsymbol{h}$
- Eigenvektoren der Hesse-Matrix geben die Hauptkrümmungsrichtungen an, Eigenwerte die Stärke der Krümmung in diesen Richtungen

Praxisrelevanz Hesse-Matrix

- Heuristik: in typischen hochdimensionalen (nicht-konvexen) Problemen sind echte lokale Minima / Maxima **selten**, die meisten kritischen Punkte sind **Sattelpunkte!** $\implies$ SGD & co funktionieren
 $\implies$ *Singularity incoming* (maybe....)
- **Statistik:**
 - Wichtiger Spezialfall für $f: \mathbb{R}^p \rightarrow \mathbb{R}$: *(Log-)Likelihood-Funktion*
 - Hesse-Matrix der negativen Log-Likelihood ($\rightarrow$ beobachtete *Fisher-Information*) bestimmt Unsicherheit von Schätzern
- **ML:**
Hesse-Matrix der Verlustfunktion bestimmt Konditionierung von Optimierungsproblemen
- **Optimierung:**
Hesse-Matrix bestimmt Konvergenzverhalten von Optimierungsalgorithmen

Anwendung: Fisher-Information

Def.: Fisher-Informationsmatrix

Für ein statistisches Modell mit Log-Likelihood $\ell(\boldsymbol{\theta})$ und Parameter $\boldsymbol{\theta} \in \mathbb{R}^p$ ist die **Fisher-Informationsmatrix**, definiert als

$$\mathbf{I}(\boldsymbol{\theta}) := \mathbb{E}[-\mathbf{H}_{\ell}(\boldsymbol{\theta})] = -\mathbb{E}\left[\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \theta_i \partial \theta_j}\right]_{i,j} \in \mathbb{R}^{p \times p}.$$

Intuition:

- Stark gekrümmte Log-Likelihood $\implies$ Daten sind “informativ” über optimales $\boldsymbol{\theta}$
- Flache Log-Likelihood $\implies$ wenig Information, Parameter schwer zu schätzen

Wichtige Konsequenz:

Asymptotische Effizienz des ML-Schätzers:

Für ML-Schätzer $\hat{\boldsymbol{\theta}}_{ML}$ gilt (unter Regularitätsbedingungen) für großes n approximativ

$$\text{Var}(\hat{\boldsymbol{\theta}}_{ML}) \approx \mathbf{I}(\boldsymbol{\theta})^{-1},$$

der MLE erreicht damit asymptotisch die *Cramér-Rao-Schranke*, die untere Schranke für die Varianz unverzerrter Schätzer.

$\implies$ mehr Information $\rightarrow$ kleinere Varianz $\rightarrow$ präzisere Schätzung

Höhergradige Ableitung für Vektor-zu-Vektor

Wichtiger Fall:

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$$

- **Beispiel:** Score-Funktion $\nabla \ell(\boldsymbol{\theta})^\top$ (in der Zeilenkonvention ist $\nabla \ell$ eine Zeile, erst die Transponierte bildet $\mathbb{R}^p \rightarrow \mathbb{R}^p$ ab), Momenten-Gleichungen
- j -te Ableitung ist multilineare Abbildung $D_{\mathbf{x}}^j f: (\mathbb{R}^n)^j \rightarrow \mathbb{R}^m: \rightarrow$ Stufe $j + 1$ -Tensor mit Dimensionen $m \times \underbrace{n \times n \times \cdots \times n}_{j\text{-mal}}$

$$D_{\mathbf{x}}^j f(\mathbf{h}_1, \dots, \mathbf{h}_j) = \sum_{i_1, \dots, i_j=1}^n \underbrace{\frac{\partial^j f(\mathbf{x})}{\partial x_{i_j} \cdots \partial x_{i_1}}}_{\in \mathbb{R}^m} h_{1,i_1} \cdots h_{j,i_j}$$

- Insbesondere:

$$D_{\mathbf{x}} f(\mathbf{h}) = \mathbf{J}_f(\mathbf{x}) \mathbf{h}, \quad D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) = \sum_{i=1}^n \frac{\partial \mathbf{J}_f(\mathbf{x})}{\partial x_i} \mathbf{h}_1 \cdot h_{2,i}$$

(ausgeschriebene Summenformeln für $j = 1, 2, 3$: $\rightarrow$ *Anhang*)

Taylorapproximation

Taylorentwicklung: univariate Funktionen

Theorem: Taylorentwicklung I

Sei $f: \mathbb{R} \rightarrow \mathbb{R}$ $(k + 1)$ -mal stetig differenzierbar.

Dann gilt für $h \rightarrow 0$:


$$f(x + h) = f(x) + \sum_{j=1}^k \frac{1}{j!} f^{(j)}(x) h^j + o(|h|^k).$$

- **Taylorpolynom** $T_k(x + h) := \sum_{j=0}^k \frac{1}{j!} f^{(j)}(x) h^j$ (Entwicklungspunkt x)
- Dies ist nützlich um Funktionen lokal durch einfaches Polynom zu approximieren.
- Je höher der Grad k , desto besser die *lokale* Approximation für $h \rightarrow 0$ – *global* muss sie dadurch nicht besser werden!
- Essenzielles Tool in Konvergenzanalysen (z.B. asymptotische Normalität des Maximum-Likelihood-Schätzers).

Beweisskizze: $\rightarrow$ *Anhang*.

Taylorentwicklung: univariate Funktionen

$$f(x) \approx T_k(x) = f(0) + f'(0)x + \frac{1}{2}f''(0)x^2 + \frac{1}{6}f'''(0)x^3 + \dots$$



Taylor-Approximationen für $\exp(x)$ in $x = 0$

Taylorentwicklung: Allgemein

Theorem: Taylorentwicklung II

Seien V, W normierte Räume und $f: V \rightarrow W$ k -mal stetig Fréchet-differenzierbar ($f \in \mathcal{C}^k$).
Dann gilt für $\mathbf{h} \rightarrow \mathbf{0}$:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \sum_{j=1}^k \frac{1}{j!} D_{\mathbf{x}}^j f(\underbrace{\mathbf{h}, \dots, \mathbf{h}}_{j\text{-mal}}) + o(\|\mathbf{h}\|^k).$$

- Gleiche Struktur wie univariat: Polynom in $\mathbf{h}$ mit multilinearen Koeffizienten $D_{\mathbf{x}}^j f$.

Beweisskizze (Reduktion auf den 1D-Fall): $\rightarrow$ Anhang.

Taylorapproximation für Vektor-zu-Skalar

- Es gilt:


$$\begin{aligned}f(\mathbf{x} + \mathbf{h}) &= f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|) \\&= f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h} + \frac{1}{2}\mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h} + o(\|\mathbf{h}\|^2) \\&= f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h} + \frac{1}{2}\mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h} + \frac{1}{6} \sum_{i,j,l=1}^n \frac{\partial^3 f(\mathbf{x})}{\partial x_i \partial x_j \partial x_l} h_i h_j h_l + o(\|\mathbf{h}\|^3) \\&= \dots\end{aligned}$$

- Alternative Formulierung mit Entwicklungspunkt $\mathbf{x}_0$:


$$\begin{aligned}f(\mathbf{x}) &= f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|) \\&= f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^\top \mathbf{H}_f(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|^2) \\&= \dots\end{aligned}$$

Taylorapproximation für Vektor-zu-Skalar


1. Ordnung: $f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T(\mathbf{x} - \mathbf{x}_0)$




2. Ordnung: $\dots + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^T \mathbf{H}_f(\mathbf{x} - \mathbf{x}_0)$



1. Ordnung: Höhenlinien



2. Ordnung: Höhenlinien



Selbst ausprobieren: [Shiny-App](#)

Anwendung: Newton-Raphson-Verfahren

Problemstellung:

Finde $\mathbf{x}^* = \arg \min_{\mathbf{x}} f(\mathbf{x})$ für zweimal stetig diff.bare $f: \mathbb{R}^n \rightarrow \mathbb{R}$

Idee:

Approximiere $f(\mathbf{x})$ um aktuellen Punkt $\mathbf{x}^{(k)}$ durch das Taylor-Polynom 2. Ordnung (Entwicklungspunkt $\mathbf{x}^{(k)}$):

$$f(\mathbf{x}) \approx T_2(\mathbf{x}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^\top \mathbf{H}_f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

Newton-Schritt:

Minimiere $T_2(\mathbf{x})$ bzgl. $\mathbf{x}$. (für $\mathbf{H}_f(\mathbf{x}^{(k)})$ positiv definit, sonst hat T_2 kein Minimum):

$$\begin{aligned} \nabla T_2(\mathbf{x}) &= \nabla f(\mathbf{x}^{(k)}) + (\mathbf{x} - \mathbf{x}^{(k)})^\top \mathbf{H}_f(\mathbf{x}^{(k)}) \stackrel{!}{=} \mathbf{0}^\top \\ \implies (\mathbf{x} - \mathbf{x}^{(k)})^\top &= -\nabla f(\mathbf{x}^{(k)}) \mathbf{H}_f(\mathbf{x}^{(k)})^{-1} \end{aligned}$$

Newton-Iteration:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \left(\nabla f(\mathbf{x}^{(k)}) \mathbf{H}_f(\mathbf{x}^{(k)})^{-1} \right)^\top$$

Enorme Relevanz in ML/Statistics:

Maximum-Likelihood-Schätzung; IRLS/IWLS für GLMs; Trust-Region-Methoden ($\rightarrow$ Optimierung II)

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- Eigenschaften: Stetigkeit und Linearität der Ableitung
- Rechenregeln: *Produktregel* und *Kettenregel* → Matrixkalkül liefert z.B. die *Normalengleichungen* der KQ-Schätzung in 4 Zeilen
- Höhergradige Ableitungen: multilineare Abbildungen, *Hesse-Matrix* & Krümmung
- *Taylorapproximation* und Newton-Raphson-Verfahren

Self-Check

Frage 1: Sei $b(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit symmetrischem $\mathbf{A} \in \mathbb{R}^{n \times n}$. Was ist $\nabla b(\mathbf{x})$?

1. $2\mathbf{x}^\top \mathbf{A}$
2. $\mathbf{x}^\top \mathbf{A}$
3. $2\mathbf{A}$
4. $2\mathbf{A}\mathbf{x}\mathbf{x}^\top$

Frage 2: Sei f $(k + 1)$ -mal stetig differenzierbar und T_k das Taylorpolynom vom Grad k um x . Welche Ordnung hat der Approximationsfehler $f(x + h) - T_k(x + h)$ für $h \rightarrow 0$?

1. $o(|h|^k)$
2. $o(|h|^{k+1})$
3. $O(1)$
4. $o(|h|)$, unabhängig von k

Frage 3: Ein Newton-Schritt zur Minimierung von $f: \mathbb{R}^n \rightarrow \mathbb{R}$ basiert auf ...

1. dem Taylorpolynom 1. Ordnung plus einer Schrittweite.
2. dem Taylorpolynom 2. Ordnung: er braucht Gradient **und** Hesse-Matrix.
3. nur der Hesse-Matrix.
4. dem Satz von Schwarz.

Nächste Vorlesung

- Konvexität

Anhang

Alternatives Beispiel (Kettenregel): Logistische Regression

Problemstellung:

Binäre Klassifikation mit $Y \in \{0, 1\}$ und Features $\mathbf{x} \in \mathbb{R}^p$: $P(Y = 1 \mid \mathbf{x}) = \sigma(\boldsymbol{\beta}^\top \mathbf{x})$ mit $\sigma(t) = \frac{1}{1+e^{-t}}$

Verlustfunktion für eine Beobachtung $(\mathbf{x}, y)$ ist:

$$\ell(\boldsymbol{\beta}) = -[y \log(\sigma(\boldsymbol{\beta}^\top \mathbf{x})) + (1 - y) \log(1 - \sigma(\boldsymbol{\beta}^\top \mathbf{x}))] = - \begin{cases} \log(P(Y = 1 \mid \mathbf{x})) & \text{für } y = 1 \\ \log(P(Y = 0 \mid \mathbf{x})) & \text{für } y = 0 \end{cases}$$

Ableitung für $y = 1$: $\ell(\boldsymbol{\beta})|_{y=1} = -\log \sigma(\boldsymbol{\beta}^\top \mathbf{x}) = g(f(\boldsymbol{\beta}))$

- $f(\boldsymbol{\beta}) = \boldsymbol{\beta}^\top \mathbf{x}$ mit $\nabla f(\boldsymbol{\beta}) = \mathbf{x}^\top$
- $g(t) = -\log \sigma(t)$ mit $g'(t) = -\frac{\sigma'(t)}{\sigma(t)}$
- $\sigma'(t) = \frac{e^{-t}}{(1+e^{-t})^2} = \sigma(t)(1 - \sigma(t))$, also $g'(t) = -\frac{\sigma(t)(1-\sigma(t))}{\sigma(t)} = -(1 - \sigma(t)) = \sigma(t) - 1$

Mit Kettenregel und $\hat{y} = \sigma(\boldsymbol{\beta}^\top \mathbf{x})$:

$$\nabla \ell(\boldsymbol{\beta}) = g'(f(\boldsymbol{\beta})) \nabla f(\boldsymbol{\beta}) = (\sigma(\boldsymbol{\beta}^\top \mathbf{x}) - 1) \mathbf{x}^\top = (\hat{y} - 1) \mathbf{x}^\top$$

- analog für $y = 0$:

$$\nabla \ell(\boldsymbol{\beta})|_{y=0} = \hat{y} \mathbf{x}^\top$$

Taylorentwicklung I: Beweisskizze (univariat)

Vertiefung: Beweisskizze.

Sei $h > 0$ (Fall $h < 0$ analog). Definiere auf $[x, x + h]$:

$$F(t) := \sum_{j=0}^k \frac{f^{(j)}(t)}{j!} (x + h - t)^j, \quad \text{also } F(x + h) = f(x + h), \quad F(x) = T_k(x + h),$$

$$G(t) := (x + h - t)^{k+1}, \quad \text{also } G(x + h) = 0, \quad G(x) = h^{k+1},$$

mit $F'(t) = \frac{f^{(k+1)}(t)}{k!} (x + h - t)^k$ (Teleskopsumme!) und $G'(t) = -(k + 1)(x + h - t)^k \neq 0$ auf $(x, x + h)$.

Cauchy-Mittelwertsatz: es gibt $\xi \in (x, x + h)$ mit

$$\frac{F(x + h) - F(x)}{G(x + h) - G(x)} = \frac{F'(\xi)}{G'(\xi)} \implies f(x + h) - T_k(x + h) = \frac{f^{(k+1)}(\xi)}{(k + 1)!} h^{k+1} = o(|h|^k). \blacksquare$$

Wieso $o(|h|^k)$? $f^{(k+1)}$ stetig $\implies$ lokal beschränkt durch ein M , also $|f^{(k+1)}(\xi) h^{k+1} / (k + 1)!| / |h|^k \leq \frac{M}{(k+1)!} |h| \xrightarrow{h \rightarrow 0} 0$.

↔ zurück: „Taylorentwicklung: univariate Funktionen“

Taylorentwicklung II: Beweisskizze (allgemein)

Vertiefung: Beweisskizze.

Fixiere $\boldsymbol{x} \in V$. Für $\boldsymbol{h} = \mathbf{0}$ ist die Aussage trivial; sei also $\boldsymbol{h} \neq \mathbf{0}$.

- Setze $s := \|\mathbf{h}\|$ und $\mathbf{u} := \mathbf{h}/s$ (also $\|\mathbf{u}\| = 1, \mathbf{h} = s\mathbf{u}$).
- Definiere $\psi: \mathbb{R}_{\geq 0} \rightarrow W$ durch $\psi(w) := f(\mathbf{x} + w\mathbf{u})$.
- Wiederholte Kettenregel liefert: $\psi^{(j)}(w) = D_{\mathbf{x}+w\mathbf{u}}^j \underbrace{f(\mathbf{u}, \dots, \mathbf{u})}_{j\text{-mal}}$.
- 1D-Taylor für ψ um $w = 0$ – in der *Peano-Form*, die nur $\psi \in \mathcal{C}^k$ braucht (Satz I setzt stärker $\mathcal{C}^{k+1}$ voraus):

$$\psi(s) = \sum_{j=0}^k \frac{s^j}{j!} \psi^{(j)}(0) + o(s^k) \quad \text{für } s \rightarrow 0.$$
- Mit $\psi(s) = f(\mathbf{x} + \mathbf{h}), \psi(0) = f(\mathbf{x})$ und $\psi^{(j)}(0) = D_{\mathbf{x}}^j f(\mathbf{u}, \dots, \mathbf{u})$:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \sum_{j=1}^k \frac{s^j}{j!} D_{\mathbf{x}}^j f(\mathbf{u}, \dots, \mathbf{u}) + o(s^k).$$

- Multilinearität von $D_{\mathbf{x}}^j f$: $D_{\mathbf{x}}^j f(\mathbf{u}, \dots, \mathbf{u}) = D_{\mathbf{x}}^j f\left(\frac{\mathbf{h}}{s}, \dots, \frac{\mathbf{h}}{s}\right) = \frac{1}{s^j} D_{\mathbf{x}}^j f(\mathbf{h}, \dots, \mathbf{h})$.
- Mit $s = \|\mathbf{h}\|$:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \sum_{j=1}^k \frac{1}{j!} D_{\mathbf{x}}^j f(\mathbf{h}, \dots, \mathbf{h}) + o(\|\mathbf{h}\|^k). \blacksquare$$

(Drei technische Feinheiten des Arguments: $\rightarrow$ *Anhang*.)

$\leftarrow$ zurück: „Taylorentwicklung: Allgemein“

Taylorentwicklung II: Beweisskizze — Feinheiten

Drei Punkte machen die Skizze zum vollständigen Beweis — hier für den im Kurs relevanten Fall $V = \mathbb{R}^n$, $W = \mathbb{R}^m$ (allgemeine normierte Räume brauchen andere Argumente):

- 1) Definitionsbereich:** f muss auf einer Umgebung von $\mathbf{x}$ definiert sein, die das ganze Segment $\mathbf{x} + w\mathbf{u}$, $0 \leq w \leq s$, enthält — für hinreichend kleines $\|\mathbf{h}\|$ ist das erfüllt.
- 2) W -wertiges 1D-Taylor:** Der 1D-Satz mit Peano-Restglied gilt zunächst für reellwertige Funktionen; wegen $\dim W < \infty$ wendet man ihn **koordinatenweise** auf $\psi = (\psi_1, \dots, \psi_m)$ an und sammelt die Restglieder ein.
- 3) Gleichmäßigkeit in der Richtung:** Das $o(s^k)$ aus dem 1D-Satz gilt zunächst *pro fester Richtung* $\mathbf{u}$. Damit daraus $o(\|\mathbf{h}\|^k)$ für **beliebige** $\mathbf{h} \rightarrow \mathbf{0}$ wird, muss der Fehlerterm gleichmäßig über alle Richtungen klein werden: Betrachte das Restglied für $j = k$ in Lagrange-Form — die Differenz $D_{\mathbf{x}+\xi\mathbf{u}}^k f - D_{\mathbf{x}}^k f$ wird wegen der **Stetigkeit von** $D^k f$ und der **Kompaktheit der Einheitssphäre** $\{\|\mathbf{u}\| = 1\}$ gleichmäßig klein.

↔ zurück: „Taylorentwicklung II: Beweisskizze (allgemein)“

Höhere Ableitungen für Vektor-zu-Vektor: explizite Formeln

Für $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ ist insbesondere:

$$D_{\mathbf{x}} f(\mathbf{h}) = \sum_{i=1}^n \frac{\partial f(\mathbf{x})}{\partial x_i} h_i = \mathbf{J}_f(\mathbf{x}) \mathbf{h},$$

$$D_{\mathbf{x}}^2 f(\mathbf{h}_1, \mathbf{h}_2) = \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 f(\mathbf{x})}{\partial x_j \partial x_i} h_{1,i} h_{2,j} = \sum_{i=1}^n \frac{\partial \mathbf{J}_f(\mathbf{x})}{\partial x_i} \mathbf{h}_1 \cdot h_{2,i},$$

$$D_{\mathbf{x}}^3 f(\mathbf{h}_1, \mathbf{h}_2, \mathbf{h}_3) = \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n \frac{\partial^3 f(\mathbf{x})}{\partial x_k \partial x_j \partial x_i} h_{1,i} h_{2,j} h_{3,k} = \sum_{i=1}^n \sum_{j=1}^n \frac{\partial^2 \mathbf{J}_f(\mathbf{x})}{\partial x_j \partial x_i} \mathbf{h}_1 \cdot h_{2,i} \cdot h_{3,j}$$

↔ zurück: „Höhergradige Ableitung für Vektor-zu-Vektor“