Differentialrechnung II

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- *Fréchet-Differenzierbarkeit*: $f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)$
- *Gradient* $\nabla f(\boldsymbol{x})$ für $f : \mathbb{R}^n \to \mathbb{R}$
- *Jacobimatrix* $\boldsymbol{J}_f(\boldsymbol{x})$ für $f : \mathbb{R}^n \to \mathbb{R}^m$
- Matrixableitungen: $\partial f / \partial \boldsymbol{X}$
- **Analysis:**
  - Produktregel: $(fg)' = f'g + fg'$ &
    Kettenregel: $(g \circ f)' = g'(f) \cdot f'$
  - Höhere Ableitungen: $f'', f''', \ldots$
  - Taylorreihen: $f(x+h) = f(x) + f'(x)h + (1/2)f''(x)h^2 + \ldots$
- **Lineare Algebra:**
  - *Multilineare* & *Bilineare* Abbildungen: $\langle \cdot, \cdot \rangle$
  - Quadratische Formen: $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$
  - Komposition von Funktionen

Opener-Quiz: Was wissen Sie noch?

Frage 1: Sei $f\colon \mathbb{R} \to \mathbb{R}$ differenzierbar in x mit Ableitung $f'(x)$. Welche Aussagen sind wahr?

1. f' ist eine lineare Funktion.
2. $h \mapsto f'(x)h$ ist eine lineare Funktion (für festes x).
3. $f(x+h) = f(x) + f'(x)h + o(h)$ für $h \to 0$.
4. "$o(h)$" steht für eine Funktion $r(h)$ mit $\lim_{h\to 0} \frac{r(h)}{h} = 0$.

Frage 2: Sei $f\colon \mathbb{R}^n \to \mathbb{R}^m$ differenzierbar. Welche Dimension hat die Jacobimatrix $\boldsymbol{J}_f(\boldsymbol{x})$?

1. $n \times m$
2. $m \times n$
3. $n \times n$
4. $m \times m$

Eigenschaften und Rechenregeln

Wichtige Eigenschaften: Stetigkeit

Theorem: Stetigkeit aus Differenzierbarkeit

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Räume und $f\colon \mathbb{D} \to \mathbb{E}$ in $\boldsymbol{x} \in \mathbb{D}$ differenzierbar.
Dann ist f in $\boldsymbol{x}$ stetig.

Beweis.

- Per Definition ist $D_{\boldsymbol{x}} f$ beschränkt und linear. Insbesondere gilt

$$\|D_{\boldsymbol{x}} f(\boldsymbol{h})\| \leq M \|\boldsymbol{h}\|, \quad \text{d.h.} \quad D_{\boldsymbol{x}} f(\boldsymbol{h}) = O(\|\boldsymbol{h}\|).$$

- Also ist

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|) = f(\boldsymbol{x}) + O(\|\boldsymbol{h}\|) \text{ für } \|\boldsymbol{h}\| \to 0.$$

- Für $\|\boldsymbol{h}\| \to 0$ erhalten wir $f(\boldsymbol{x}+\boldsymbol{h}) \to f(\boldsymbol{x})$. ■

Notation:

$r(\boldsymbol{h}) = O(\|\boldsymbol{h}\|)$ für $\|\boldsymbol{h}\| \to 0$ heißt:
$\|r(\boldsymbol{h})\| \leq C \|\boldsymbol{h}\|$ für alle hinreichend kleinen $\boldsymbol{h}$ –
im Unterschied zu $r(\boldsymbol{h}) = o(\|\boldsymbol{h}\|)$, wo $\|r(\boldsymbol{h})\| / \|\boldsymbol{h}\| \to 0$ gilt.

Bsp: Stetig aber nicht differenzierbar

Betrachte $f\colon \mathbb{R} \to \mathbb{R}$ mit $f(x) = |x|$.

- f stetig in $x = 0$: Für $h \to 0$ gilt $f(0+h) = |h| \to 0 = f(0)$. ✓
- f *nicht* differenzierbar in $x = 0$:

$$\lim_{h \to 0^+} \frac{f(h) - f(0)}{h} = \lim_{h \to 0^+} \frac{|h|}{h} = \lim_{h \to 0^+} \frac{h}{h} = 1,$$
$$\lim_{h \to 0^-} \frac{f(h) - f(0)}{h} = \lim_{h \to 0^-} \frac{|h|}{h} = \lim_{h \to 0^-} \frac{-h}{h} = -1.$$

  Da die linksseitigen und rechtsseitigen Grenzwerte verschieden sind, existiert $f'(0)$ nicht. ×

Fazit:

- Differenzierbarkeit $\implies$ Stetigkeit
- aber Stetigkeit $\not\Longleftarrow$ Differenzierbarkeit!

Wichtige Eigenschaften: Linearität

Theorem: Linearität der Ableitungsoperation

Seien $\mathbb{D}$ und $\mathbb{E}$ normierte Räume und $f, g\colon \mathbb{D} \to \mathbb{E}$ in $\boldsymbol{x} \in \mathbb{D}$ differenzierbar.
Dann ist für alle $c_1, c_2 \in \mathbb{R}$ auch $c_1 f + c_2 g$ in $\boldsymbol{x}$ differenzierbar, mit

$$D_{\boldsymbol{x}}(c_1 f + c_2 g) = c_1 D_{\boldsymbol{x}} f + c_2 D_{\boldsymbol{x}} g.$$

Beweis: $\rightarrow$ Übung

Wichtige Eigenschaften: Linearität

Beispiele

- Für $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}$: $(c_1 f + c_2 g)' = c_1 f' + c_2 g'$
- Für $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}$:

$$\nabla \left[c_1 f(\boldsymbol{x}) + c_2 g(\boldsymbol{x}) \right] = c_1 \nabla f(\boldsymbol{x}) + c_2 \nabla g(\boldsymbol{x})$$

- Für $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}^m$:

$$\boldsymbol{J}_{c_1 f + c_2 g}(\boldsymbol{x}) = c_1 \boldsymbol{J}_f(\boldsymbol{x}) + c_2 \boldsymbol{J}_g(\boldsymbol{x})$$

- Für $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}^{m \times n}$:

$$\frac{\partial \left[c_1 \boldsymbol{F}(x) + c_2 \boldsymbol{G}(x) \right]}{\partial x} = c_1 \frac{\partial \boldsymbol{F}(x)}{\partial x} + c_2 \frac{\partial \boldsymbol{G}(x)}{\partial x}$$

- Für $\mathbb{D} = \mathbb{R}^{m \times n}, \mathbb{E} = \mathbb{R}$:

$$\frac{\partial \left[c_1 f(\boldsymbol{X}) + c_2 g(\boldsymbol{X}) \right]}{\partial \boldsymbol{X}} = c_1 \frac{\partial f(\boldsymbol{X})}{\partial \boldsymbol{X}} + c_2 \frac{\partial g(\boldsymbol{X})}{\partial \boldsymbol{X}}$$

Bsp: Linearität der Ableitung

Gegeben: $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{x}$ und $g(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x}$ mit $\boldsymbol{a} = (1, 2)^\top$.

Berechne $\nabla h(\boldsymbol{x})$ für $h(\boldsymbol{x}) = 3f(\boldsymbol{x}) - 2g(\boldsymbol{x})$ an der Stelle $\boldsymbol{x} = (1, -1)^\top$.

(Achtung: h ist hier ausnahmsweise ein Funktionsname, nicht der Zuwachs $\boldsymbol{h}$.)

Lösung:

1. Berechne Gradienten:
   - Für $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{x} = x_1^2 + x_2^2$ gilt: $\nabla f(\boldsymbol{x}) = (2x_1, 2x_2)$
   - Für $g(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x} = x_1 + 2x_2$ gilt: $\nabla g(\boldsymbol{x}) = \boldsymbol{a}^\top = (1,\ 2)$
2. Wende Linearität an:

$$\nabla h(\boldsymbol{x}) = 3\nabla f(\boldsymbol{x}) - 2\nabla g(\boldsymbol{x}) = 3(2x_1,\ 2x_2) - 2(1,\ 2) = (6x_1 - 2,\ 6x_2 - 4)$$

3. Setze $\boldsymbol{x} = (1, -1)^\top$ ein:

$$\nabla h\left(\begin{pmatrix} 1 \\ -1 \end{pmatrix}\right) = (6 \cdot 1 - 2,\ 6 \cdot (-1) - 4) = (4,\ -10)$$

Rechenregeln: Produktregel

Theorem: Produktregel

Seien $\mathbb{D}, \mathbb{E}, \mathbb{B}$ normierte Räume, $f, g\colon \mathbb{D} \to \mathbb{E}$ in $\boldsymbol{x} \in \mathbb{D}$ differenzierbar, $\langle \cdot, \cdot \rangle\colon \mathbb{E} \times \mathbb{E} \to \mathbb{B}$ eine beschränkte bilineare Abbildung und $b(\boldsymbol{x}) = \langle f(\boldsymbol{x}), g(\boldsymbol{x}) \rangle$.

Dann gilt

$$D_{\boldsymbol{x}} b(\boldsymbol{h}) = \langle D_{\boldsymbol{x}} f(\boldsymbol{h}), g(\boldsymbol{x}) \rangle + \langle f(\boldsymbol{x}), D_{\boldsymbol{x}} g(\boldsymbol{h}) \rangle.$$

Beweis (kompakt):

Differenzierbarkeit von f, g einsetzen, Bilinearität ausmultiplizieren:

$$\begin{aligned} b(\boldsymbol{x}+\boldsymbol{h}) &= \big\langle f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|),\ g(\boldsymbol{x}) + D_{\boldsymbol{x}} g(\boldsymbol{h}) + o(\|\boldsymbol{h}\|) \big\rangle \\ &= b(\boldsymbol{x}) + \underbrace{\langle D_{\boldsymbol{x}} f(\boldsymbol{h}), g(\boldsymbol{x}) \rangle + \langle f(\boldsymbol{x}), D_{\boldsymbol{x}} g(\boldsymbol{h}) \rangle}_{= D_{\boldsymbol{x}} b(\boldsymbol{h}) \text{ (linear in } \boldsymbol{h})} + \underbrace{\langle D_{\boldsymbol{x}} f(\boldsymbol{h}), D_{\boldsymbol{x}} g(\boldsymbol{h}) \rangle + o(\|\boldsymbol{h}\|)}_{= O(\|\boldsymbol{h}\|^2) + o(\|\boldsymbol{h}\|) = o(\|\boldsymbol{h}\|)} \end{aligned}$$

■

Kreuzterm: $D_{\boldsymbol{x}} f(\boldsymbol{h}), D_{\boldsymbol{x}} g(\boldsymbol{h})$ sind beide $O(\|\boldsymbol{h}\|)$ (beschränkte lineare Abbildungen), die bilineare Abbildung multipliziert die Größenordnungen $\to O(\|\boldsymbol{h}\|^2)$.

Rechenregeln: Produktregel

Beispiele:

- $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}, \mathbb{B} = \mathbb{R}$:

$$b(x) = f(x)g(x) \quad \Longrightarrow \quad b'(x) = f'(x)g(x) + g'(x)f(x).$$

- $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}, \mathbb{B} = \mathbb{R}$:

$$b(\boldsymbol{x}) = f(\boldsymbol{x})g(\boldsymbol{x}) \quad \Longrightarrow \quad \nabla b(\boldsymbol{x}) = g(\boldsymbol{x})\nabla f(\boldsymbol{x}) + f(\boldsymbol{x})\nabla g(\boldsymbol{x}).$$

- $\mathbb{D} = \mathbb{R}^n, \mathbb{E} = \mathbb{R}^m, \mathbb{B} = \mathbb{R}$:

$$b(\boldsymbol{x}) = f(\boldsymbol{x})^\top g(\boldsymbol{x}) \quad \Longrightarrow \quad \nabla b(\boldsymbol{x}) = g(\boldsymbol{x})^\top \boldsymbol{J}_f(\boldsymbol{x}) + f(\boldsymbol{x})^\top \boldsymbol{J}_g(\boldsymbol{x}).$$

- $\mathbb{D} = \mathbb{R}, \mathbb{E} = \mathbb{R}^{n\times n}, \mathbb{B} = \mathbb{R}$:

$$b(x) = \operatorname{tr}\left[\boldsymbol{F}(x)\boldsymbol{G}(x)\right] \quad \Longrightarrow \quad b'(x) = \operatorname{tr}\left[\frac{\partial \boldsymbol{F}(x)}{\partial x}\boldsymbol{G}(x)\right] + \operatorname{tr}\left[\boldsymbol{F}(x)\frac{\partial \boldsymbol{G}(x)}{\partial x}\right].$$

Übung: Ableitung quadratischer Formen

Sei $b(\boldsymbol{x}) = f(\boldsymbol{x})^\top g(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ mit $f(\boldsymbol{x}) = \boldsymbol{x}$ und $g(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$.

Aufgabe:

Berechne $\nabla b(\boldsymbol{x})$.

Lösung:

- Es gilt $\boldsymbol{J}_f(\boldsymbol{x}) = \boldsymbol{I}_n$ und $\boldsymbol{J}_g(\boldsymbol{x}) = \boldsymbol{A}$.
- Dann ist nach der Produktregel

$$\begin{aligned}\nabla b(\boldsymbol{x}) &= g(\boldsymbol{x})^\top \boldsymbol{J}_f(\boldsymbol{x}) + f(\boldsymbol{x})^\top \boldsymbol{J}_g(\boldsymbol{x}) \\ &= (\boldsymbol{A}\boldsymbol{x})^\top \boldsymbol{I}_n + \boldsymbol{x}^\top \boldsymbol{A} = \boldsymbol{x}^\top \left(\boldsymbol{A} + \boldsymbol{A}^\top\right)\end{aligned}$$

- falls $\boldsymbol{A}$ symmetrisch also: $\nabla b(\boldsymbol{x}) = 2\boldsymbol{x}^\top \boldsymbol{A}$

Rechenregeln: Kettenregel

Theorem: Kettenregel

Seien $\mathbb{D}_1, \mathbb{D}_2, \mathbb{D}_3$ normierte Räume und $f\colon \mathbb{D}_1 \to \mathbb{D}_2$, $g\colon \mathbb{D}_2 \to \mathbb{D}_3$, sodass $g \circ f\colon \mathbb{D}_1 \to \mathbb{D}_3$. Ist f in $\boldsymbol{x} \in \mathbb{D}_1$ und g in $\boldsymbol{y} = f(\boldsymbol{x}) \in \mathbb{D}_2$ differenzierbar, dann ist

$$D_{\boldsymbol{x}}(g \circ f) = D_{\boldsymbol{y}} g \circ D_{\boldsymbol{x}} f.$$

Kettenregel: Beweis

- Da f differenzierbar ist, gilt

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|).$$

- Daraus folgt

$$\begin{aligned}
(g \circ f)(\boldsymbol{x}+\boldsymbol{h}) &= g\left(f(\boldsymbol{x}) + D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)\right) \\
[g \text{ diff'bar:}] \qquad &= g\left(f(\boldsymbol{x})\right) + D_{\boldsymbol{y}} g\left(D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)\right) + o(\|\boldsymbol{h}\|) \\
[D_{\boldsymbol{y}} g \text{ linear:}] \qquad &= g\left(f(\boldsymbol{x})\right) + D_{\boldsymbol{y}} g\left(D_{\boldsymbol{x}} f(\boldsymbol{h})\right) + D_{\boldsymbol{y}} g\left(o(\|\boldsymbol{h}\|)\right) + o(\|\boldsymbol{h}\|) \\
[D_{\boldsymbol{y}} g \text{ beschr.:}] \qquad &= g\left(f(\boldsymbol{x})\right) + D_{\boldsymbol{y}} g\left(D_{\boldsymbol{x}} f(\boldsymbol{h})\right) + o(\|\boldsymbol{h}\|) \\
&= (g \circ f)(\boldsymbol{x}) + (D_{\boldsymbol{y}} g \circ D_{\boldsymbol{x}} f)(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)
\end{aligned}$$

■

Zeile 2:
Der Restterm von g ist zunächst nur klein im weitergereichten Zuwachs $\boldsymbol{k} = D_{\boldsymbol{x}} f(\boldsymbol{h}) + o(\|\boldsymbol{h}\|)$, also $o(\|\boldsymbol{k}\|)$.
Da $D_{\boldsymbol{x}} f$ beschränkt ist ($\|D_{\boldsymbol{x}} f(\boldsymbol{h})\| \leq M_f \|\boldsymbol{h}\|$), gilt für kleine $\boldsymbol{h}$ aber $\|\boldsymbol{k}\| \leq (M_f + 1)\|\boldsymbol{h}\|$ –
damit ist $o(\|\boldsymbol{k}\|)$ auch $o(\|\boldsymbol{h}\|)$.

Rechenregeln: Kettenregel

Beispiele:

Anwendung: Kleinste Quadrate via Matrixkalkül

Problem (Kapitel 7 — Lineare Regression):
Response $\boldsymbol{y} \in \mathbb{R}^n$, Designmatrix $\boldsymbol{X} \in \mathbb{R}^{n \times p}$:

$$\ell(\boldsymbol{\beta}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2 \to \min_{\boldsymbol{\beta}}$$

Schritt 1 — als Skalarprodukt schreiben:

$$\ell(\boldsymbol{\beta}) = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}) = \langle f(\boldsymbol{\beta}), f(\boldsymbol{\beta}) \rangle \quad \text{mit } f(\boldsymbol{\beta}) = \boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}$$

Schritt 2 — Jacobimatrix des inneren Terms (Linearität):

$$\boldsymbol{J}_f(\boldsymbol{\beta}) = -\boldsymbol{X}$$

Schritt 3 — Produktregel (mit $g = f$, beide Summanden gleich):

$$\begin{aligned} \nabla \ell(\boldsymbol{\beta}) &= f(\boldsymbol{\beta})^\top \boldsymbol{J}_f(\boldsymbol{\beta}) + f(\boldsymbol{\beta})^\top \boldsymbol{J}_f(\boldsymbol{\beta}) \\ &= 2\,(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^\top (-\boldsymbol{X}) = -2\,(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta})^\top \boldsymbol{X} \end{aligned}$$

Anwendung: Kleinste Quadrate — Normalengleichungen

Schritt 4 — Gradient nullsetzen:
Am Minimum muss der Gradient verschwinden. (*Optimalitätsbedingung* → *Optimierung I*):

$$\nabla \ell(\widehat{\boldsymbol{\beta}}) = -2\left(\boldsymbol{y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}\right)^\top \boldsymbol{X} \overset{!}{=} \mathbf{0}^\top$$

Transponieren und umstellen:

$$\boldsymbol{X}^\top\left(\boldsymbol{y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}}\right) = \mathbf{0} \quad \Longrightarrow \quad \boxed{\boldsymbol{X}^\top \boldsymbol{X}\,\widehat{\boldsymbol{\beta}} = \boldsymbol{X}^\top \boldsymbol{y}}$$

→ die *Normalengleichungen*: **die KQ-Lösung aus Kapitel 7 — jetzt hergeleitet!**

Payoff:

- Produkt- & Kettenregel im Matrixkalkül liefern die KQ-Lösung in 4 Zeilen — ohne eine einzige partielle Ableitung auszuschreiben.
- "$\nabla \ell = \mathbf{0}^\top$" als Optimalitätsbedingung wird systematisch ausgebaut: → *Optimierung I & II*.
- Gleiche Rechnung mit Strafterm $\lambda\|\boldsymbol{\beta}\|_2^2$ ergibt die Ridge-Regression (→ Übung).

Anwendung: Backprop in Neuronalen Netzen

- NN ist eine Funktion $f(\boldsymbol{x}) = (f_K \circ \cdots \circ f_2 \circ f_1)(\boldsymbol{x}) = \hat{\boldsymbol{y}}$ aufgebaut aus verketteten Funktionen:

$$\text{Input } \boldsymbol{x} \xrightarrow{f_1} \boldsymbol{z}_1 \xrightarrow{f_2} \boldsymbol{z}_2 \xrightarrow{\cdots} \cdots \xrightarrow{f_K} \text{ Output } \hat{\boldsymbol{y}}$$

- Jedes *layer* f_k
  - hat eine Gewichtsmatrix $\boldsymbol{W}_k \in \mathbb{R}^{d_k \times d_{k-1}}$ und
  - berechnet $f_k(\boldsymbol{z}_{k-1}) = \sigma_k(\boldsymbol{W}_k \boldsymbol{z}_{k-1})$,
  - wobei $\sigma_k : \mathbb{R}^{d_k} \to \mathbb{R}^{d_k}$ komponentenweise wirkt.
- Verlustfunktion $L(\hat{\boldsymbol{y}})$ misst Güte der Outputs.
- Wir brauchen $\frac{\partial L}{\partial \boldsymbol{W}_k}$ zur Optimierung.

Kettenregel mit Jacobimatrizen:

$$\frac{\partial L}{\partial \boldsymbol{W}_k} = \frac{\partial L}{\partial \hat{\boldsymbol{y}}} \cdot \boldsymbol{J}_{f_K}(\boldsymbol{z}_{K-1}) \cdot \boldsymbol{J}_{f_{K-1}}(\boldsymbol{z}_{K-2}) \cdots \boldsymbol{J}_{f_{k+1}}(\boldsymbol{z}_k) \cdot \frac{\partial f_k(\boldsymbol{z}_{k-1})}{\partial \boldsymbol{W}_k}$$

Backpropagation = effiziente Berechnung dieser Jacobimatrizen-Kette!

Beispiel:
Mit ReLU-Aktivierung $\sigma(x) = \max(0, x)$ ist $f_k(\boldsymbol{z}_{k-1}) = \max(\boldsymbol{0}, \boldsymbol{W}_k \boldsymbol{z}_{k-1})$, also:

$$\boldsymbol{J}_{f_k}(\boldsymbol{z}_{k-1}) = \operatorname{diag}\left(\mathbb{I}_{\boldsymbol{W}_k \boldsymbol{z}_{k-1} > 0}\right) \cdot \boldsymbol{W}_k$$

(nur für $(\boldsymbol{W}_k \boldsymbol{z}_{k-1})_i \neq 0$: an den Knickstellen ist $\max(0, \cdot)$ nicht differenzierbar)

Übung

Sei $h(\boldsymbol{x}) = \|\boldsymbol{x}\|_2 = \sqrt{\boldsymbol{x}^\top \boldsymbol{x}}$.

Frage:

Was ist $\nabla h(\boldsymbol{x})$ für $\boldsymbol{x} \neq \boldsymbol{0}$?

Antwort:

- Für $g(x) = \sqrt{x} = x^{1/2}$ gilt $g'(x) = \frac{1}{2x^{1/2}}$.
- Für $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{x}$ gilt $\nabla f(\boldsymbol{x}) = 2\boldsymbol{x}^\top$.
- Nach der Kettenregel ist

$$\nabla h(\boldsymbol{x}) = g'\big(f(\boldsymbol{x})\big) \nabla f(\boldsymbol{x}) = \frac{2\boldsymbol{x}^\top}{2f(\boldsymbol{x})^{1/2}} = \frac{\boldsymbol{x}^\top}{\|\boldsymbol{x}\|}.$$

- (In $\boldsymbol{x} = \boldsymbol{0}$ ist $\|\cdot\|_2$ *nicht* differenzierbar.)

Ableitungen höheren Grades

Ableitungen höheren Grades

Def.: k-mal (Fréchet-)differenzierbar

Seien $\mathbb{D}$ und $\mathbb{E}$ zwei normierte Räume und $f\colon \mathbb{D} \to \mathbb{E}$. Definiere $D^0_{\boldsymbol{x}} f := f(\boldsymbol{x})$.

Wir nennen f an der Stelle $\boldsymbol{x} \in \mathbb{D}$ **k-mal (Fréchet-)differenzierbar**,
falls für $j = 1, \ldots, k$ *beschränkte, multilineare Abbildungen* $D^j_{\boldsymbol{x}} f\colon \mathbb{D}^j \to \mathbb{E}$ existieren,
sodass für alle $\boldsymbol{h}_1, \ldots, \boldsymbol{h}_{j-1}$ und für $\boldsymbol{h} \to \mathbf{0}$ gilt:

$$D^j_{\boldsymbol{x}} f(\boldsymbol{h}_1, \ldots, \boldsymbol{h}_{j-1}, \boldsymbol{h}) = D^{j-1}_{\boldsymbol{x}+\boldsymbol{h}} f(\boldsymbol{h}_1, \ldots, \boldsymbol{h}_{j-1}) - D^{j-1}_{\boldsymbol{x}} f(\boldsymbol{h}_1, \ldots, \boldsymbol{h}_{j-1}) + o(\|\boldsymbol{h}\|) \prod_{i=1}^{j-1} \|\boldsymbol{h}_i\|$$

- Höhere Ableitungen sind also wieder (multi-)lineare Annäherungen an die (lokale) Veränderung der nächstniedrigeren Ableitung von $f \implies$ Ableitungen berechnen wir wie gewohnt iterativ
- Höhere Ableitungen involvieren i.a. Tensoren, deren Stufe wächst mit j.

Konkret: Hesse-Matrix ($k = 2$)

Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ (z.B. eine Log-Likelihood) und $f \in \mathcal{C}^2$.

- $j = 1$:
  $D_{\boldsymbol{x}} f(\boldsymbol{h}_1) = \nabla f(\boldsymbol{x})\, \boldsymbol{h}_1$ – *lineare* Abbildung, dargestellt durch den *Gradienten* (Zeilenvektor).
- $j = 2$:
  Die Definition fragt: *wie verändert sich Df selbst*, wenn wir $\boldsymbol{x}$ um $\boldsymbol{h}$ verschieben?

$$D_{\boldsymbol{x}+\boldsymbol{h}} f(\boldsymbol{h}_1) - D_{\boldsymbol{x}} f(\boldsymbol{h}_1) = [\nabla f(\boldsymbol{x} + \boldsymbol{h}) - \nabla f(\boldsymbol{x})]\boldsymbol{h}_1$$

- Lineare Approximation des Gradienten (jede Komponente von ∇f ist selbst differenzierbar):

$$\nabla f(\boldsymbol{x} + \boldsymbol{h}) - \nabla f(\boldsymbol{x}) = \boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x}) + o(\|\boldsymbol{h}\|)$$

- Einsetzen ergibt die *bilineare* Abbildung

$$D^2_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}) = \boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\, \boldsymbol{h}_1$$

  dargestellt durch die Matrix $\boldsymbol{H}_f(\boldsymbol{x})$ der zweiten partiellen Ableitungen: die **Hesse-Matrix**

(Symmetrie von $\boldsymbol{H}_f$ für $f \in \mathcal{C}^2$: $\to$ Satz von Schwarz, gleich.)

Höhergradige Ableitung für Vektor-zu-Skalar

Def.: Hesse-Matrix

Die **Hesse-Matrix** $\boldsymbol{H}_f(\boldsymbol{x})$ einer zweimal differenzierbaren Funktion $f\colon S \subseteq \mathbb{R}^n \to \mathbb{R}$ (S offen) ist die *Matrix der zweiten partiellen Ableitungen*, also

$$\boldsymbol{H}_f(\boldsymbol{x}) := \left(\frac{\partial^2 f(\boldsymbol{x})}{\partial x_i \partial x_j} \right)_{i,j=1,\ldots,n} \in \mathbb{R}^{n \times n}.$$

Hier ist:

- $D_{\boldsymbol{x}} f(\boldsymbol{h}) = \nabla f(\boldsymbol{x}) \boldsymbol{h}$
- $D^2_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}_2) = \boldsymbol{h}_1^\top \boldsymbol{H}_f(\boldsymbol{x}) \boldsymbol{h}_2$ mit *Hesse-Matrix* $\boldsymbol{H}_f(\boldsymbol{x}) \in \mathbb{R}^{n \times n}$.
- ($D^3_{\boldsymbol{x}} f \in \mathbb{R}^{n \times n \times n}$ wäre ein *Tensor* mit $\left(D^3_{\boldsymbol{x}} f\right)_{i,j,k} = \frac{\partial^3 f(\boldsymbol{x})}{\partial x_k \partial x_j \partial x_i}$ und $D^3_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}_2, \boldsymbol{h}_3) = \sum_{i,j,k} \left(D^3_{\boldsymbol{x}} f\right)_{i,j,k} h_{1i} h_{2j} h_{3k}$)

Symmetrische Hesse-Matrizen

Theorem: Satz von Schwarz

Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ zweimal stetig differenzierbar ($f \in \mathcal{C}^2$). Dann gilt:

$$\frac{\partial^2 f(\boldsymbol{x})}{\partial x_i \partial x_j} = \frac{\partial^2 f(\boldsymbol{x})}{\partial x_j \partial x_i} \quad \text{für alle } i, j.$$

$\Longrightarrow$ Hesse-Matrix für $f \in \mathcal{C}^2$ ist symmetrisch: $\boldsymbol{H}_f(\boldsymbol{x}) = \boldsymbol{H}_f(\boldsymbol{x})^\top$.

- Reihenfolge der partiellen Ableitungen spielt unter Stetigkeitsbedingungen keine Rolle
- Reduziert Anzahl der zu berechnenden Ableitungen von n^2 auf $\frac{n(n+1)}{2}$
- Wichtig für numerische Verfahren und Optimierung: nutze Symmetrie der Hesse-Matrix

Geometrische Interpretation und Konvexität

Hesse-Matrix charakterisiert die *lokale Krümmung* einer Funktion:

1. Definitheit der Hesse-Matrix:

Für $f \in \mathcal{C}^2$, $f\colon \mathbb{R}^n \to \mathbb{R}$, an einem *kritischen Punkt* $\boldsymbol{x}^*$ (d.h. $\nabla f(\boldsymbol{x}^*) = \mathbf{0}^\top$):

- $\boldsymbol{H}_f(\boldsymbol{x}^*)$ **positiv definit** ($\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x}^*)\boldsymbol{h} > 0$ für alle $\boldsymbol{h} \neq \mathbf{0}$) $\implies$ $\boldsymbol{x}^*$ ist ein **lokales Minimum**
- $\boldsymbol{H}_f(\boldsymbol{x}^*)$ **negativ definit** ($\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x}^*)\boldsymbol{h} < 0$ für alle $\boldsymbol{h} \neq \mathbf{0}$) $\implies$ $\boldsymbol{x}^*$ ist ein **lokales Maximum**
- $\boldsymbol{H}_f(\boldsymbol{x}^*)$ **indefinit** (positive und negative Eigenwerte) $\implies$ $\boldsymbol{x}^*$ ist ein **Sattelpunkt**

2. Konvexität:

$f \in \mathcal{C}^2$ ist **konvex** auf einer *offenen, konvexen* Menge $S \subseteq \mathbb{R}^n$ $\iff$
$\boldsymbol{H}_f(\boldsymbol{x}) \succeq 0$ (*positiv semidefinit*) für alle $\boldsymbol{x} \in S$.

3. Quadratische Approximation:

$$f(\boldsymbol{x} + \boldsymbol{h}) \approx f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h}$$

- beste quadratische Approximation von f in der Umgebung von $\boldsymbol{x}$ ($\rightarrow$ *Taylorentwicklung*)
- $\boldsymbol{H}_f(\boldsymbol{x})$ beschreibt die lokale Krümmung von f in Richtung $\boldsymbol{h}$
- Eigenvektoren der Hesse-Matrix geben die Hauptkrümmungsrichtungen an, Eigenwerte die Stärke der Krümmung in diesen Richtungen

Praxisrelevanz Hesse-Matrix

- Heuristik: in typischen hochdimensionalen (nicht-konvexen) Problemen sind echte lokale Minima / Maxima **selten**, die meisten kritischen Punkte sind **Sattelpunkte**! $\Longrightarrow$ SGD & co funktionieren

  $\Longrightarrow$ *Singularity incoming* (maybe....)

- **Statistik**:
  - Wichtiger Spezialfall für $f\colon \mathbb{R}^p \to \mathbb{R}$: *(Log-)Likelihood-Funktion*
  - Hesse-Matrix der negativen Log-Likelihood ($\to$ beobachtete *Fisher-Information*) bestimmt Unsicherheit von Schätzern
- **ML**:
  Hesse-Matrix der Verlustfunktion bestimmt Konditionierung von Optimierungsproblemen
- **Optimierung**:
  Hesse-Matrix bestimmt Konvergenzverhalten von Optimierungsalgorithmen

Anwendung: Fisher-Information

Def.: Fisher-Informationsmatrix

Für ein statistisches Modell mit Log-Likelihood $\ell(\boldsymbol{\theta})$ und Parameter $\boldsymbol{\theta} \in \mathbb{R}^p$ ist die **Fisher-Informationsmatrix**, definiert als

$$\boldsymbol{I}(\boldsymbol{\theta}) := \mathbb{E}\left[-\boldsymbol{H}_\ell(\boldsymbol{\theta})\right] = -\mathbb{E}\left[\frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \theta_i \partial \theta_j}\right]_{i,j} \in \mathbb{R}^{p \times p}.$$

Intuition:

- Stark gekrümmte Log-Likelihood $\implies$ Daten sind "informativ" über optimales $\boldsymbol{\theta}$
- Flache Log-Likelihood $\implies$ wenig Information, Parameter schwer zu schätzen

Wichtige Konsequenz:

Asymptotische Effizienz des ML-Schätzers:
Für ML-Schätzer $\widehat{\boldsymbol{\theta}}_{ML}$ gilt (unter Regularitätsbedingungen) für großes n approximativ

$$\mathbb{V}\mathrm{ar}(\widehat{\boldsymbol{\theta}}_{ML}) \approx \boldsymbol{I}(\boldsymbol{\theta})^{-1},$$

der MLE erreicht damit asymptotisch die *Cramér-Rao-Schranke*, die untere Schranke für die Varianz unverzerrter Schätzer.
$\implies$ mehr Information $\rightarrow$ kleinere Varianz $\rightarrow$ präzisere Schätzung

Höhergradige Ableitung für Vektor-zu-Vektor

Wichtiger Fall:

$$f\colon \mathbb{R}^n \to \mathbb{R}^m$$

- **Beispiel:** Score-Funktion $\nabla \ell(\boldsymbol{\theta})^\top$ (in der Zeilenkonvention ist $\nabla \ell$ eine Zeile, erst die Transponierte bildet $\mathbb{R}^p \to \mathbb{R}^p$ ab), Momenten-Gleichungen
- j-te Ableitung ist multilineare Abbildung $D^j_{\boldsymbol{x}} f\colon (\mathbb{R}^n)^j \to \mathbb{R}^m$: $\to$ Stufe $j+1$-Tensor mit Dimensionen $m \times \underbrace{n \times n \times \cdots \times n}_{j-\text{mal}}$:

$$D^j_{\boldsymbol{x}} f(\boldsymbol{h}_1, \ldots, \boldsymbol{h}_j) = \sum_{i_1,\ldots,i_j=1}^{n} \underbrace{\frac{\partial^j f(\boldsymbol{x})}{\partial x_{i_j} \cdots \partial x_{i_1}}}_{\in \mathbb{R}^m} h_{1,i_1} \cdots h_{j,i_j}$$

- Insbesondere:

$$D_{\boldsymbol{x}} f(\boldsymbol{h}) = \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h}, \qquad D^2_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}_2) = \sum_{i=1}^{n} \frac{\partial \boldsymbol{J}_f(\boldsymbol{x})}{\partial x_i} \boldsymbol{h}_1 \cdot h_{2,i}$$

(ausgeschriebene Summenformeln für $j = 1, 2, 3$: $\to$ Anhang)

Taylorapproximation

Taylorentwicklung: univariate Funktionen

Theorem: Taylorentwicklung I

Sei $f: \mathbb{R} \to \mathbb{R}$ $(k+1)$-mal *stetig differenzierbar*.

Dann gilt für $h \to 0$:

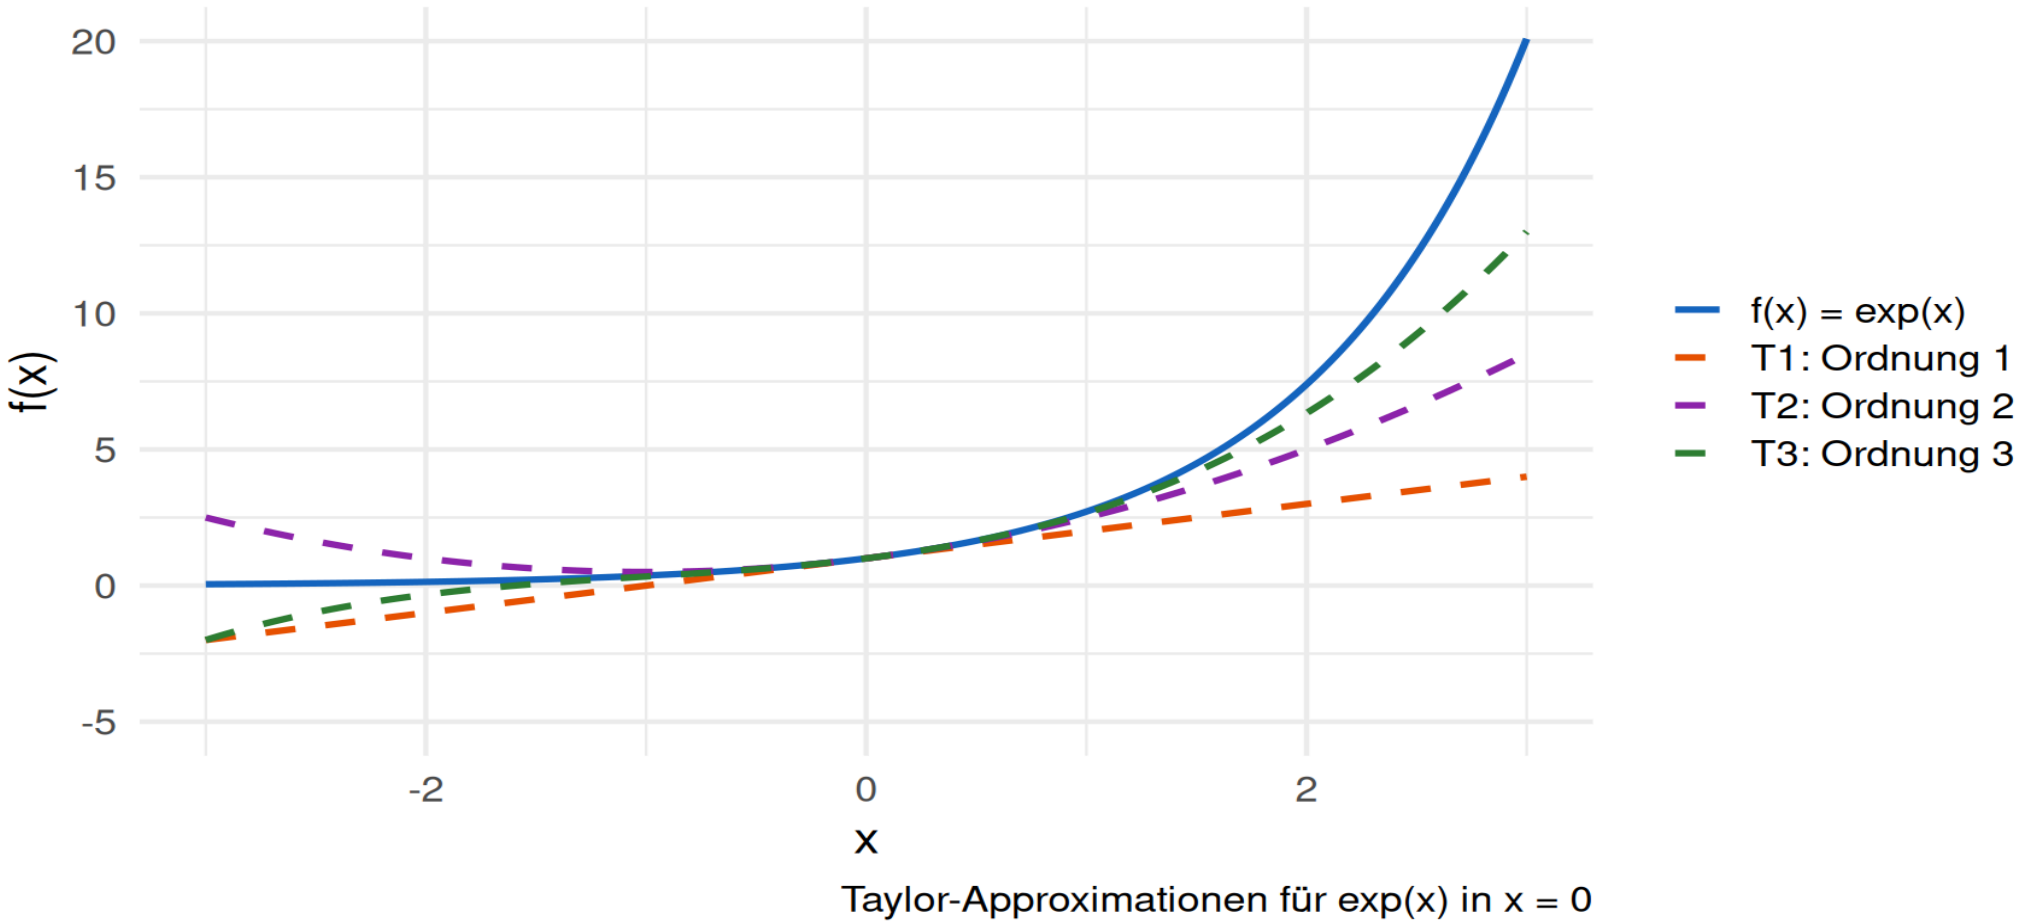
$$f(x+h) = f(x) + \sum_{j=1}^{k} \frac{1}{j!} f^{(j)}(x) h^j + o\big(|h|^k\big).$$

- *Taylorpolynom* $T_k(x+h) := \sum_{j=0}^{k} \frac{1}{j!} f^{(j)}(x) h^j$ (Entwicklungspunkt x)
- Dies ist nützlich um Funktionen lokal durch einfaches Polynom zu approximieren.
- Je höher der Grad k, desto besser die *lokale* Approximation für $h \to 0$ — *global* muss sie dadurch nicht besser werden!
- Essenzielles Tool in Konvergenzanalysen (z.B. asymptotische Normalität des Maximum-Likelihood-Schätzers).

Beweisskizze: → *Anhang*.

Taylorentwicklung: univariate Funktionen

$$f(x) \approx T_k(x) = f(0) + f'(0)x + \frac{1}{2}f''(0)x^2 + \frac{1}{6}f'''(0)x^3 + \dots$$



Taylorentwicklung: Allgemein

Theorem: Taylorentwicklung II

Seien V, W normierte Räume und $f\colon V \to W$ k-mal *stetig Fréchet-differenzierbar* ($f \in \mathcal{C}^k$). Dann gilt für $\boldsymbol{h} \to \mathbf{0}$:

$$f(\boldsymbol{x}+\boldsymbol{h}) = f(\boldsymbol{x}) + \sum_{j=1}^{k} \frac{1}{j!} D_{\boldsymbol{x}}^{j} f(\underbrace{\boldsymbol{h}, \ldots, \boldsymbol{h}}_{j\text{-mal}}) + o\big(\|\boldsymbol{h}\|^k\big).$$

- Gleiche Struktur wie univariat: Polynom in $\boldsymbol{h}$ mit multilinearen Koeffizienten $D_{\boldsymbol{x}}^{j} f$.

Beweisskizze (Reduktion auf den 1D-Fall): → *Anhang*.

Taylorapproximation für Vektor-zu-Skalar

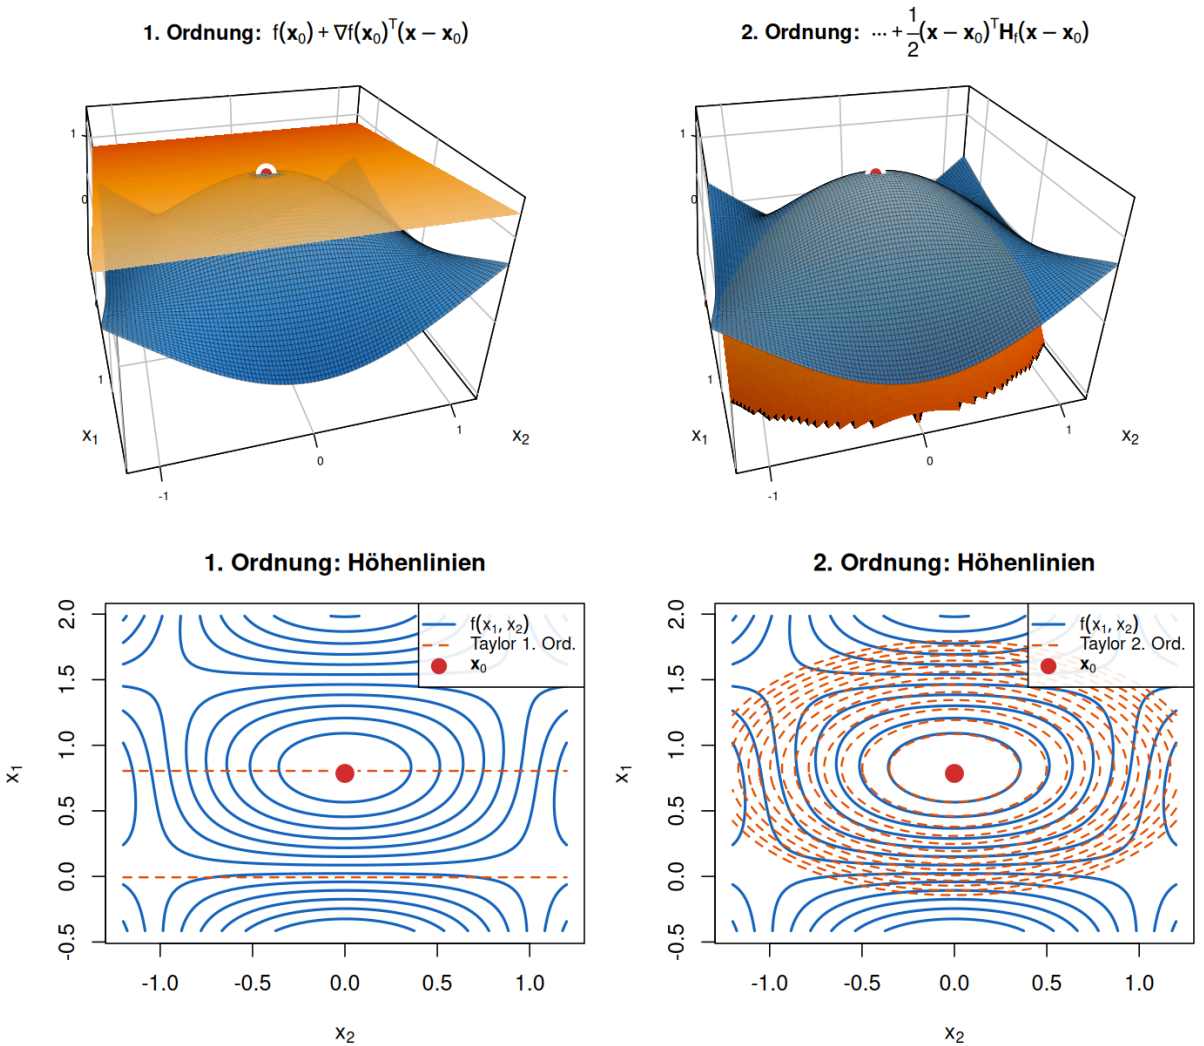
- Es gilt:

$$
\begin{aligned}
f(\boldsymbol{x}+\boldsymbol{h}) &= f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\boldsymbol{h} + o(\|\boldsymbol{h}\|) \\
&= f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h} + o(\|\boldsymbol{h}\|^2) \\
&= f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h} + \frac{1}{6}\sum_{i,j,l=1}^{n} \frac{\partial^3 f(\boldsymbol{x})}{\partial x_i \partial x_j \partial x_l} h_i h_j h_l + o(\|\boldsymbol{h}\|^3) \\
&= \dots
\end{aligned}
$$

- Alternative Formulierung mit Entwicklungspunkt $\boldsymbol{x}_0$:

$$
\begin{aligned}
f(\boldsymbol{x}) &= f(\boldsymbol{x}_0) + \nabla f(\boldsymbol{x}_0)(\boldsymbol{x}-\boldsymbol{x}_0) + o(\|\boldsymbol{x}-\boldsymbol{x}_0\|) \\
&= f(\boldsymbol{x}_0) + \nabla f(\boldsymbol{x}_0)(\boldsymbol{x}-\boldsymbol{x}_0) + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{x}_0)^\top \boldsymbol{H}_f(\boldsymbol{x}_0)(\boldsymbol{x}-\boldsymbol{x}_0) + o(\|\boldsymbol{x}-\boldsymbol{x}_0\|^2) \\
&= \dots
\end{aligned}
$$

Taylorapproximation für Vektor-zu-Skalar



Selbst ausprobieren: Shiny-App

Anwendung: Newton-Raphson-Verfahren

Problemstellung:
Finde $\boldsymbol{x}^* = \arg\min_{\boldsymbol{x}} f(\boldsymbol{x})$ für zweimal stetig diff.bare $f\colon \mathbb{R}^n \to \mathbb{R}$

Idee:
Approximiere $f(\boldsymbol{x})$ um aktuellen Punkt $\boldsymbol{x}^{(k)}$ durch das Taylor-Polynom 2. Ordnung (Entwicklungspunkt $\boldsymbol{x}^{(k)}$):

$$f(\boldsymbol{x}) \approx T_2(\boldsymbol{x}) = f\left(\boldsymbol{x}^{(k)}\right) + \nabla f\left(\boldsymbol{x}^{(k)}\right)\left(\boldsymbol{x} - \boldsymbol{x}^{(k)}\right) + \frac{1}{2}\left(\boldsymbol{x} - \boldsymbol{x}^{(k)}\right)^\top \boldsymbol{H}_f\left(\boldsymbol{x}^{(k)}\right)\left(\boldsymbol{x} - \boldsymbol{x}^{(k)}\right)$$

Newton-Schritt:
Minimiere $T_2(\boldsymbol{x})$ bzgl. $\boldsymbol{x}$. (für $\boldsymbol{H}_f\left(\boldsymbol{x}^{(k)}\right)$ *positiv definit* , sonst hat T_2 kein Minimum):

$$\begin{aligned}\nabla T_2(\boldsymbol{x}) = \nabla f\left(\boldsymbol{x}^{(k)}\right) + \left(\boldsymbol{x} - \boldsymbol{x}^{(k)}\right)^\top \boldsymbol{H}_f\left(\boldsymbol{x}^{(k)}\right) &\overset{!}{=} \mathbf{0}^\top \\ \implies \left(\boldsymbol{x} - \boldsymbol{x}^{(k)}\right)^\top &= -\nabla f\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{H}_f\left(\boldsymbol{x}^{(k)}\right)^{-1}\end{aligned}$$

Newton-Iteration:

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \left(\nabla f\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{H}_f\left(\boldsymbol{x}^{(k)}\right)^{-1}\right)^\top$$

Enorme Relevanz in ML/Statistics:

Maximum-Likelihood-Schätzung; IRLS/IWLS für GLMs; Trust-Region-Methoden ($\rightarrow$ *Optimierung II*)

Self-Check & Zusammenfassung

Wrap-up

Heute gelernt

- Eigenschaften: Stetigkeit und Linearität der Ableitung
- Rechenregeln: *Produktregel* und *Kettenregel* $\longrightarrow$ Matrixkalkül liefert z.B. die *Normalengleichungen* der KQ-Schätzung in 4 Zeilen
- Höhergradige Ableitungen: multilineare Abbildungen, *Hesse-Matrix* & Krümmung
- *Taylorapproximation* und Newton-Raphson-Verfahren

Self-Check

Frage 1: Sei $b(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ mit *symmetrischem* $\boldsymbol{A} \in \mathbb{R}^{n\times n}$. Was ist $\nabla b(\boldsymbol{x})$?

1. $2\boldsymbol{x}^\top \boldsymbol{A}$
2. $\boldsymbol{x}^\top \boldsymbol{A}$
3. $2\boldsymbol{A}$
4. $2\boldsymbol{A}\boldsymbol{x}\boldsymbol{x}^\top$

Frage 2: Sei f $(k+1)$-mal stetig differenzierbar und T_k das Taylorpolynom vom Grad k um x. Welche Ordnung hat der Approximationsfehler $f(x+h) - T_k(x+h)$ für $h \to 0$?

1. $o\left(|h|^k\right)$
2. $o\left(|h|^{k+1}\right)$
3. $O(1)$
4. $o(|h|)$, unabhängig von k

Frage 3: Ein Newton-Schritt zur Minimierung von $f\colon \mathbb{R}^n \to \mathbb{R}$ basiert auf …

1. dem Taylorpolynom 1. Ordnung plus einer Schrittweite.
2. dem Taylorpolynom 2. Ordnung: er braucht Gradient **und** Hesse-Matrix.
3. nur der Hesse-Matrix.
4. dem Satz von Schwarz.

Nächste Vorlesung

- Konvexität

Anhang

Alternatives Beispiel (Kettenregel): Logistische Regression

Problemstellung:
Binäre Klassifikation mit $Y \in \{0, 1\}$ und Features $\boldsymbol{x} \in \mathbb{R}^p$: $P(Y = 1 \mid \boldsymbol{x}) = \sigma(\boldsymbol{\beta}^\top \boldsymbol{x})$ mit $\sigma(t) = \frac{1}{1+e^{-t}}$

Verlustfunktion für eine Beobachtung $(\boldsymbol{x}, y)$ ist:

$$\ell(\boldsymbol{\beta}) = -\left[y \log\left(\sigma(\boldsymbol{\beta}^\top \boldsymbol{x})\right) + (1-y) \log\left(1 - \sigma(\boldsymbol{\beta}^\top \boldsymbol{x})\right)\right] = -\begin{cases} \log(P(Y = 1 \mid \boldsymbol{x})) & \text{für } y = 1 \\ \log(P(Y = 0 \mid \boldsymbol{x})) & \text{für } y = 0 \end{cases}$$

Ableitung *für* $y = 1$: $\ell(\boldsymbol{\beta})|_{y=1} = -\log \sigma(\boldsymbol{\beta}^\top \boldsymbol{x}) = g(f(\boldsymbol{\beta}))$

- $f(\boldsymbol{\beta}) = \boldsymbol{\beta}^\top \boldsymbol{x}$ mit $\nabla f(\boldsymbol{\beta}) = \boldsymbol{x}^\top$
- $g(t) = -\log \sigma(t)$ mit $g'(t) = -\frac{\sigma'(t)}{\sigma(t)}$
- $\sigma'(t) = \frac{e^{-t}}{(1+e^{-t})^2} = \sigma(t)(1 - \sigma(t))$, also $g'(t) = -\frac{\sigma(t)(1-\sigma(t))}{\sigma(t)} = -(1 - \sigma(t)) = \sigma(t) - 1$

Mit Kettenregel und $\hat{y} = \sigma(\boldsymbol{\beta}^\top \boldsymbol{x})$:

$$\nabla \ell(\boldsymbol{\beta}) = g'(f(\boldsymbol{\beta})) \nabla f(\boldsymbol{\beta}) = (\sigma(\boldsymbol{\beta}^\top \boldsymbol{x}) - 1)\boldsymbol{x}^\top = (\hat{y} - 1)\boldsymbol{x}^\top$$

- analog für $y = 0$:

$$\nabla \ell(\boldsymbol{\beta})|_{y=0} = \hat{y}\boldsymbol{x}^\top$$

Taylorentwicklung I: Beweisskizze (univariat)

Vertiefung: Beweisskizze.

Sei $h > 0$ (Fall $h < 0$ analog). Definiere auf $[x, x+h]$:

$$F(t) := \sum_{j=0}^{k} \frac{f^{(j)}(t)}{j!}(x+h-t)^j, \qquad \text{also } F(x+h) = f(x+h),\ F(x) = T_k(x+h),$$

$$G(t) := (x+h-t)^{k+1}, \qquad \text{also } G(x+h) = 0,\ G(x) = h^{k+1},$$

mit $F'(t) = \frac{f^{(k+1)}(t)}{k!}(x+h-t)^k$ (Teleskopsumme!) und $G'(t) = -(k+1)(x+h-t)^k \neq 0$ auf $(x, x+h)$.

Cauchy-Mittelwertsatz: es gibt $\xi \in (x, x+h)$ mit

$$\frac{F(x+h)-F(x)}{G(x+h)-G(x)} = \frac{F'(\xi)}{G'(\xi)} \quad \Longrightarrow \quad f(x+h) - T_k(x+h) = \frac{f^{(k+1)}(\xi)}{(k+1)!}\,h^{k+1} = o\left(|h|^k\right). \ \blacksquare$$

Wieso $o(|h|^k)$? $f^{(k+1)}$ stetig $\Longrightarrow$ lokal beschränkt durch ein M, also $\left|f^{(k+1)}(\xi)\,h^{k+1}/(k+1)!\right|/|h|^k \le \frac{M}{(k+1)!}\,|h| \xrightarrow{h\to 0} 0$.

↩ zurück: „Taylorentwicklung: univariate Funktionen"

Taylorentwicklung II: Beweisskizze (allgemein)

Vertiefung: Beweisskizze.

Fixiere $\boldsymbol{x} \in V$. Für $\boldsymbol{h} = \mathbf{0}$ ist die Aussage trivial; sei also $\boldsymbol{h} \neq \mathbf{0}$.

- Setze $s := \|\boldsymbol{h}\|$ und $\boldsymbol{u} := \boldsymbol{h}/s$ (also $\|\boldsymbol{u}\| = 1$, $\boldsymbol{h} = s\boldsymbol{u}$).
- Definiere $\psi\colon \mathbb{R}_{\geq 0} \to W$ durch $\psi(w) := f(\boldsymbol{x} + w\boldsymbol{u})$.
- Wiederholte Kettenregel liefert: $\psi^{(j)}(w) = D^j_{\boldsymbol{x}+w\boldsymbol{u}} f(\underbrace{\boldsymbol{u}, \ldots, \boldsymbol{u}}_{j\text{-mal}})$.
- 1D-Taylor für ψ um $w = 0$ — in der *Peano-Form*, die nur $\psi \in \mathcal{C}^k$ braucht (Satz I setzt stärker $\mathcal{C}^{k+1}$ voraus): $\psi(s) = \sum_{j=0}^{k} \frac{s^j}{j!} \psi^{(j)}(0) + o(s^k) \quad \text{für } s \to 0.$
- Mit $\psi(s) = f(\boldsymbol{x} + \boldsymbol{h})$, $\psi(0) = f(\boldsymbol{x})$ und $\psi^{(j)}(0) = D^j_{\boldsymbol{x}} f(\boldsymbol{u}, \ldots, \boldsymbol{u})$:

$$f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \sum_{j=1}^{k} \frac{s^j}{j!} D^j_{\boldsymbol{x}} f(\boldsymbol{u}, \ldots, \boldsymbol{u}) + o(s^k).$$

- Multilinearität von $D^j_{\boldsymbol{x}} f$: $D^j_{\boldsymbol{x}} f(\boldsymbol{u}, \ldots, \boldsymbol{u}) = D^j_{\boldsymbol{x}} f\left(\frac{\boldsymbol{h}}{s}, \ldots, \frac{\boldsymbol{h}}{s}\right) = \frac{1}{s^j} D^j_{\boldsymbol{x}} f(\boldsymbol{h}, \ldots, \boldsymbol{h})$.
- Mit $s = \|\boldsymbol{h}\|$:

$$f(\boldsymbol{x} + \boldsymbol{h}) = f(\boldsymbol{x}) + \sum_{j=1}^{k} \frac{1}{j!} D^j_{\boldsymbol{x}} f(\boldsymbol{h}, \ldots, \boldsymbol{h}) + o(\|\boldsymbol{h}\|^k). \quad \blacksquare$$

(Drei technische Feinheiten des Arguments: → Anhang.)

↩ zurück: „Taylorentwicklung: Allgemein"

Taylorentwicklung II: Beweisskizze — Feinheiten

Drei Punkte machen die Skizze zum vollständigen Beweis — hier für den im Kurs relevanten Fall $V = \mathbb{R}^n$, $W = \mathbb{R}^m$ (allgemeine normierte Räume brauchen andere Argumente):

1) Definitionsbereich: f muss auf einer Umgebung von $\boldsymbol{x}$ definiert sein, die das ganze Segment $\boldsymbol{x} + w\boldsymbol{u}$, $0 \leq w \leq s$, enthält — für hinreichend kleines $\|\boldsymbol{h}\|$ ist das erfüllt.

2) W-wertiges 1D-Taylor: Der 1D-Satz mit Peano-Restglied gilt zunächst für reellwertige Funktionen; wegen $\dim W < \infty$ wendet man ihn **koordinatenweise** auf $\psi = (\psi_1, \ldots, \psi_m)$ an und sammelt die Restglieder ein.

3) Gleichmäßigkeit in der Richtung: Das $o(s^k)$ aus dem 1D-Satz gilt zunächst *pro fester Richtung* $\boldsymbol{u}$. Damit daraus $o(\|\boldsymbol{h}\|^k)$ für **beliebige** $\boldsymbol{h} \to \boldsymbol{0}$ wird, muss der Fehlerterm gleichmäßig über alle Richtungen klein werden: Betrachte das Restglied für $j = k$ in Lagrange-Form — die Differenz $D^k_{\boldsymbol{x}+\xi\boldsymbol{u}} f - D^k_{\boldsymbol{x}} f$ wird wegen der **Stetigkeit von** $D^k f$ und der **Kompaktheit der Einheitssphäre** $\{\, \| \boldsymbol{u} \| = 1\}$ gleichmäßig klein.

↩ zurück: „Taylorentwicklung II: Beweisskizze (allgemein)"

Höhere Ableitungen für Vektor-zu-Vektor: explizite Formeln

Für $f\colon \mathbb{R}^n \to \mathbb{R}^m$ ist insbesonders:

$$D_{\boldsymbol{x}} f(\boldsymbol{h}) = \sum_{i=1}^{n} \frac{\partial f(\boldsymbol{x})}{\partial x_i} h_i = \boldsymbol{J}_f(\boldsymbol{x})\boldsymbol{h},$$

$$D^2_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}_2) = \sum_{i=1}^{n}\sum_{j=1}^{n} \frac{\partial^2 f(\boldsymbol{x})}{\partial x_j \partial x_i} h_{1,i} h_{2,j} = \sum_{i=1}^{n} \frac{\partial \boldsymbol{J}_f(\boldsymbol{x})}{\partial x_i} \boldsymbol{h}_1 \cdot h_{2,i},$$

$$D^3_{\boldsymbol{x}} f(\boldsymbol{h}_1, \boldsymbol{h}_2, \boldsymbol{h}_3) = \sum_{i=1}^{n}\sum_{j=1}^{n}\sum_{k=1}^{n} \frac{\partial^3 f(\boldsymbol{x})}{\partial x_k \partial x_j \partial x_i} h_{1,i} h_{2,j} h_{3,k} = \sum_{i=1}^{n}\sum_{j=1}^{n} \frac{\partial^2 \boldsymbol{J}_f(\boldsymbol{x})}{\partial x_j \partial x_i} \boldsymbol{h}_1 \cdot h_{2,i} \cdot h_{3,j}$$

↩ zurück: „Höhergradige Ableitung für Vektor-zu-Vektor”