Konvexität

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 25.08.2026

Verwendete Vorkenntnisse

- Normen, Skalarprodukträume
- Gradient ∇f & *Hesse-Matrix* $\boldsymbol{H}_f$ (Kap. 10/11)
- **Lineare Algebra**
  - Vektorräume
  - Linearkombinationen: $\sum w_i \boldsymbol{v}_i$
  - Positiv definite Matrizen
- **Analysis**
  - Grenzwerte; Supremum & Infimum
  - Abgeschlossene Mengen
- **Wahrscheinlichkeitstheorie**
  - Erwartungswert $\mathbb{E}[X]$ als gewichteter Durchschnitt
  - Jensen-Ungleichung

Einführung

Einführung

- *Konvexität* ist ein wichtiges Konzept in der Mathematik, besonders in
  - Optimierung
  - Wahrscheinlichkeitstheorie
- Der Begriff bezieht sich meist auf die (verwandten) Konzepte
  - *konvexe Mengen*
  - *konvexe Funktionen*
- Beides ist gewissermaßen eine Verallgemeinerung von Linearitätskonzepten

Diese Folien: $\rightarrow$ wichtigste Definitionen und Eigenschaften

Warum Konvexität wichtig ist

In Optimierung / ML / Statistik:

- Konvexe Optimierungsprobleme sind *gutartig*: jedes lokale Minimum ist *global* ($\rightarrow$ *Optimierung I*)
- Viele Algorithmen basieren auf konvexer Optimierung, z.B.:
  - Maximum Likelihood (*meist* konkave Log-Likelihoods = konvexe *negative* Log-Likelihoods): GLMs etc.
  - Support Vector Machines
  - Ridge Regression

In der Wahrscheinlichkeitstheorie:

- *Jensen'sche Ungleichung* nutzt Konvexität für Erwartungswerte
- KL-Divergenz ist konvex (wichtig für *Variational Inference*)
- Varianz als Konvexitätseigenschaft: $\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$

Konvexkombinationen

Konvexkombinationen

Def.: Konvexkombination

Sei V ein Vektorraum und $\mathcal{X} = \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_k\} \subset V$.
Dann nennen wir $\boldsymbol{x}$ eine **Konvexkombination** von Vektoren in $\mathcal{X}$,
falls es Koeffizienten $w_1, \ldots, w_k \geq 0$ gibt mit

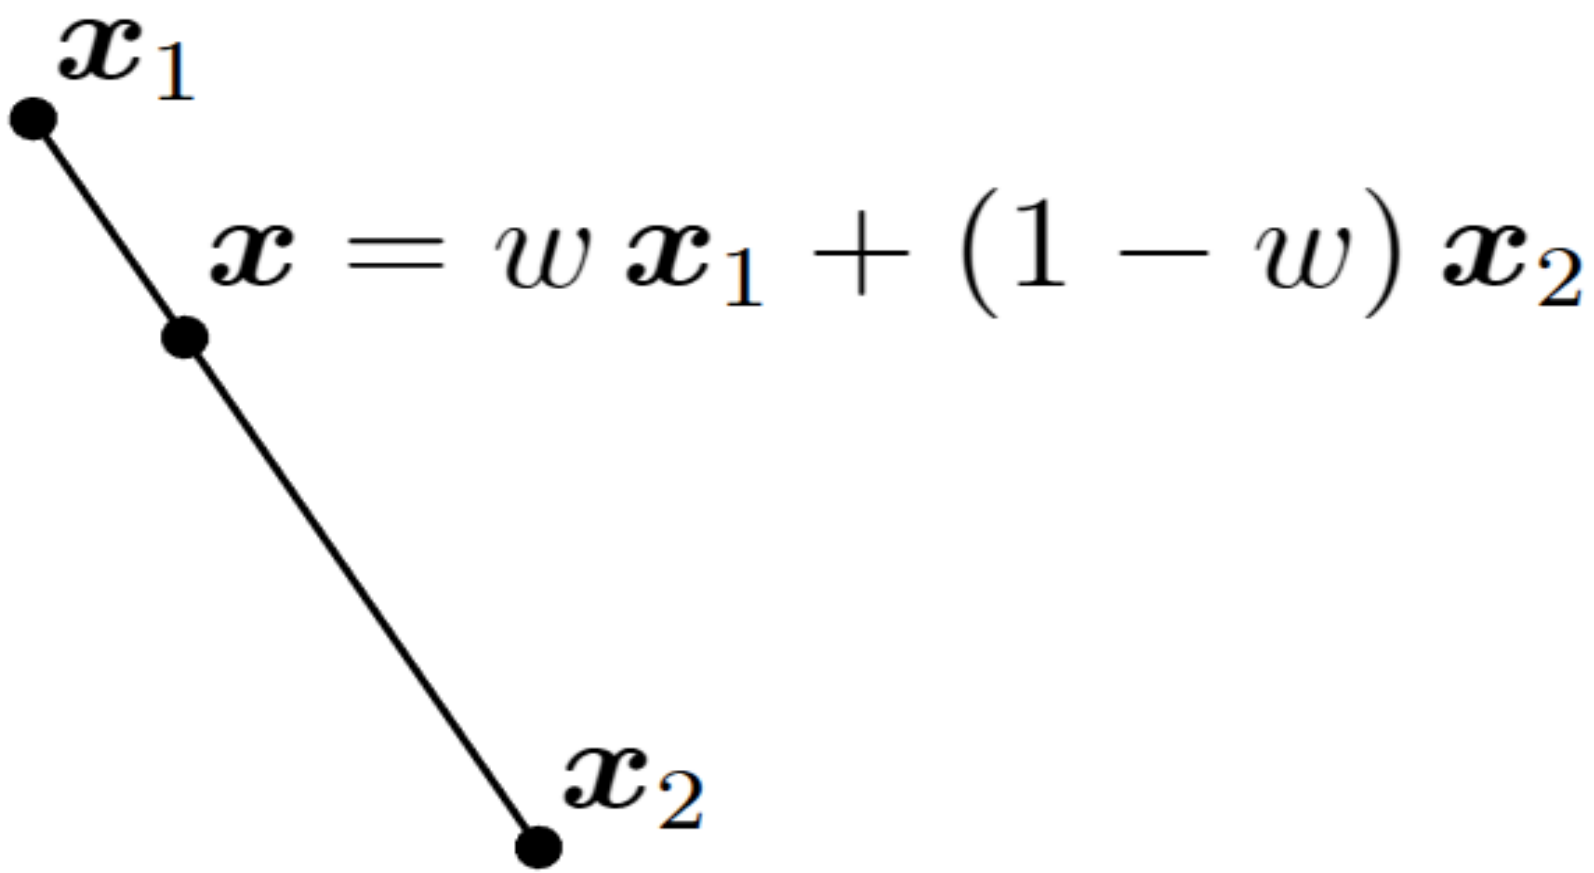
$$\boldsymbol{x} = \sum_{i=1}^{k} w_i \boldsymbol{x}_i \qquad \text{und} \qquad \sum_{i=1}^{k} w_i = 1.$$

- *Konvexkombinationen* sind spezielle Linearkombinationen.
- Sie können als gewichteter Durchschnitt interpretiert werden.
- **Bsp.:** Erwartungswert $\mathbb{E}(X)$ für diskrete Zufallsvariable X mit endlichem Träger ist Konvexkombination der Werte des Trägers $\mathcal{X} = T_X$:

$$\mathbb{E}(X) = \sum_{x_j \in T_X} \mathbb{P}(X = x_j) x_j$$

Konvexkombinationen

- Die Menge aller Konvexkombinationen zweier Vektoren $\boldsymbol{x}_1, \boldsymbol{x}_2$ ist das *Liniensegment*, das $\boldsymbol{x}_1$ und $\boldsymbol{x}_2$ verbindet.

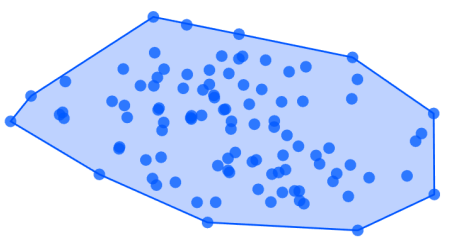


Konvexe Hülle

Def.: Konvexe Hülle

Sei $\mathcal{X} \subset V$ eine beliebige Menge von Vektoren.
Die *Menge aller Konvexkombinationen* von endlich vielen Vektoren aus $\mathcal{X}$ wird als **konvexe Hülle** $\operatorname{conv}(\mathcal{X})$ von $\mathcal{X}$ bezeichnet:

$$\operatorname{conv}(\mathcal{X}) = \left\{ \boldsymbol{x} = \sum_{i=1}^{N} w_i \boldsymbol{x}_i \colon N \in \mathbb{N}, \boldsymbol{x}_i \in \mathcal{X}, w_i \geq 0, \sum_{i=1}^{N} w_i = 1 \right\}$$



- *Extrempunkte* sind die Punkte $\boldsymbol{x}_i \in \mathcal{X}$, die sich nur mit $w_i = 1$ (und allen übrigen Gewichten 0) darstellen lassen.
- Die *konvexe Hülle* ist die kleinste konvexe Menge, die $\mathcal{X}$ enthält.

Konkretes Beispiel im $\mathbb{R}^2$: → Anhang.

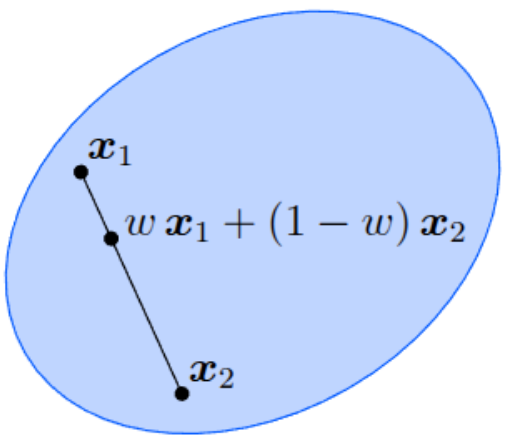
Konvexe Mengen

Konvexe Mengen: Definition

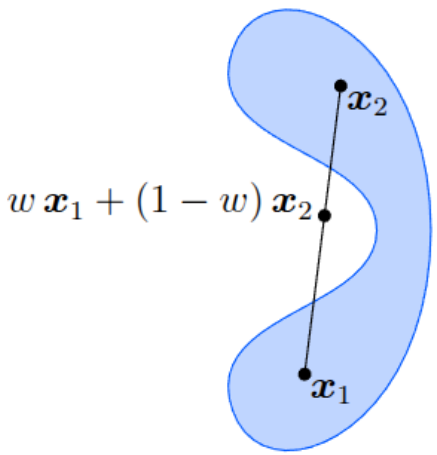
Def.: Konvexe Menge

Eine Menge $\mathcal{X} \subset V$ in Vektorraum V wird als **konvex** bezeichnet, falls für alle $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt:

$$\lambda \boldsymbol{x} + (1 - \lambda)\boldsymbol{y} \in \mathcal{X}.$$



konvex



nicht konvex

Konvexe Mengen enthalten für alle Paare von Punkten auch das Liniensegment zwischen diesen Punkten $\implies$ sie haben keine “Einbuchtungen” oder “Löcher”.

Quiz: Konvexe Mengen

Welche der folgenden Mengen ist konvex?

1. Die leere Menge $\emptyset$.
2. Ein Vektorraum V.
3. Die Einheitssphäre $\{\boldsymbol{x} \in V \colon \|\boldsymbol{x}\| = 1\}$.
4. Der geschlossene Ball $\{\boldsymbol{x} \in V \colon \|\boldsymbol{x}\| \leq r\}$.
5. Die Menge $\{(x, y) \in \mathbb{R}^2 \colon y \leq x^2\}$.

Konvexe Mengen: Beispiele

Weitere Beispiele

- Ein offener Ball $\{\boldsymbol{x} \in V : \|\boldsymbol{x}\| < r\}$.
- Der *Simplex*

$$\Delta^N = \left\{ \boldsymbol{x} \in \mathbb{R}^N : x_i \geq 0, \sum_{i=1}^{N} x_i = 1 \right\}.$$

- Die Menge aller *positiv semi-definiten* Matrizen in $\mathbb{R}^{n \times n}$.

Simplex - Beispiel und Anwendung

Beispiel in $\mathbb{R}^3$:
Simplex Δ^3 besteht aus allen Punkten $\boldsymbol{x} = (x_1, x_2, x_3)$ mit $x_1, x_2, x_3 \geq 0$ und $x_1 + x_2 + x_3 = 1 = \|\boldsymbol{x}\|_1$

Extrempunkte:

$$\boldsymbol{e}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \boldsymbol{e}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \boldsymbol{e}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

Anwendung in der Statistik:

- Δ^N definiert (die Menge aller) Wahrscheinlichkeitsverteilungen über N Ereignisse. Beispiel: $\boldsymbol{p} = (0.2, 0.5, 0.3)$ beschreibt eine kategoriale Verteilung mit drei Kategorien
- Wichtig für: Softmax-Regression/Multinomial-Modelle, Dirichlet-Verteilungen, ...

Geometrisch:

Δ^2 ist die Strecke von $(1, 0)$ nach $(0, 1)$,
Δ^3 das Dreieck zwischen $\boldsymbol{e}_1, \boldsymbol{e}_2$ und $\boldsymbol{e}_3$,
Δ^4 ein Tetraeder, ...

PSD-Matrizen bilden eine konvexe Menge

Def.: Positiv Semi-Definit

Eine *symmetrische* Matrix $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ ist **positiv semi-definit (PSD)**
$\iff \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} \geq 0 \; \forall \, \boldsymbol{x} \in \mathbb{R}^n$.

Wir schreiben: $\boldsymbol{A} \succeq 0$

Seien $\boldsymbol{A}_1, \boldsymbol{A}_2 \succeq 0$ und $\lambda \in [0, 1]$.

Zu zeigen:
$\boldsymbol{A}_\lambda = \lambda \boldsymbol{A}_1 + (1 - \lambda)\boldsymbol{A}_2 \succeq 0$.

Für beliebiges $\boldsymbol{x} \in \mathbb{R}^n$:

$$\begin{aligned} \boldsymbol{x}^\top \boldsymbol{A}_\lambda \boldsymbol{x} &= \boldsymbol{x}^\top [\lambda \boldsymbol{A}_1 + (1 - \lambda)\boldsymbol{A}_2]\boldsymbol{x} \\ &= \lambda \boldsymbol{x}^\top \boldsymbol{A}_1 \boldsymbol{x} + (1 - \lambda)\boldsymbol{x}^\top \boldsymbol{A}_2 \boldsymbol{x} \\ &\geq \lambda \cdot 0 + (1 - \lambda) \cdot 0 = 0 \quad (\text{da } \boldsymbol{A}_1, \boldsymbol{A}_2 \succeq 0) \quad \blacksquare \end{aligned}$$

Anwendung:
Kovarianzmatrizen sind stets *PSD* (*SPD* nur, falls keine Komponente linear von den übrigen abhängt) und bilden eine *konvexe Menge*.

Konvexe Mengen: Eigenschaften

- Viele wichtige Operationen erhalten Konvexität.

Theorem: Konvexitätserhaltung

Seien $\mathcal{X}, \mathcal{X}_1, \mathcal{X}_2, \ldots$ konvexe Mengen. Dann sind auch die folgenden Mengen konvex:

- *Schnittmenge:*
  $\mathcal{S} = \bigcap_{i \in I} \mathcal{X}_i$ für eine beliebige Indexmenge I (alle $\mathcal{X}_i$ im selben Vektorraum)
- *Kartesisches Produkt:*
  $\mathcal{X}_1 \times \cdots \times \mathcal{X}_k$
- *Affine Abbildungen:*
  $f\colon \mathbb{R}^n \to \mathbb{R}^m$ mit $f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$ und $\mathcal{X} \subseteq \mathbb{R}^n$: Bildmenge
  $f(\mathcal{X}) = \{\boldsymbol{y} = f(\boldsymbol{x})\colon \boldsymbol{x} \in \mathcal{X}\}$ ist konvex.
- *Summen:*
  $\mathcal{X}_1 \oplus \mathcal{X}_2 := \{\boldsymbol{x}_1 + \boldsymbol{x}_2\colon \boldsymbol{x}_1 \in \mathcal{X}_1, \boldsymbol{x}_2 \in \mathcal{X}_2\}$ ($\mathcal{X}_1, \mathcal{X}_2$ im selben Vektorraum)

- **Beispiel** für die Nützlichkeit der Schnitt-Eigenschaft:
  Polyeder (= Schnitte von *Halbräumen*) sind konvex – wichtig für *lineare Programmierung* ($\rightarrow$ *Optimierung unter linearen Nebenbedingungen*)!

Konvexe Hülle: Eigenschaften

- Eine *konvexe Hülle* ist selbst eine *konvexe Menge* (Konvexkombinationen von Konvexkombinationen aus $\mathcal{X}$ sind wieder Konvexkombinationen aus $\mathcal{X}$).
- Sie ist die **kleinste konvexe Menge, die ganz $\mathcal{X}$ enthält**.

Proposition

Es gilt $\operatorname{conv}(\mathcal{X}) = \bigcap_{\mathcal{X} \subseteq \mathcal{Y}, \mathcal{Y} \text{ konvex}} \mathcal{Y}$.

Beweis:

Sei $\mathcal{S} = \bigcap_{\mathcal{X} \subseteq \mathcal{Y}, \mathcal{Y} \text{ konvex}} \mathcal{Y}$.

- Da $\mathcal{X} \subseteq \mathcal{Y}$ und $\mathcal{Y}$ konvex ist, ist jede Konvexkombination von Punkten aus $\mathcal{X}$ auch in jedem $\mathcal{Y}$ (konvexe Mengen enthalten – per Induktion über die Anzahl der Punkte – alle Konvexkombinationen endlich vieler ihrer Punkte). Es folgt $\operatorname{conv}(\mathcal{X}) \subseteq \mathcal{S}$.
- Da der Schnitt auch über die Menge $\mathcal{Y} = \operatorname{conv}(\mathcal{X})$ geht, ist automatisch auch $\mathcal{S} \subseteq \operatorname{conv}(\mathcal{X})$.

Konvexe Mengen: Anwendung

- Konvexe Mengen/Hüllen sind wichtig in der Optimierung.

Beispiel:

- Sei $\mathcal{X} \subseteq \mathbb{N}^n$. Jedes $\boldsymbol{x} \in \mathcal{X}$ beschreibt eine Zusammensetzung von n verschiedenen Gegenständen: $x_i = k$ bedeutet, dass k Einheiten des i-ten Gegenstands vorhanden sind.
- Jeder Gegenstand hat einen Wert v_i und wir wollen das $\boldsymbol{x} \in \mathcal{X}$ mit maximalem Wert finden:

$$\boldsymbol{x}^\star \in \operatorname*{arg\,max}_{\boldsymbol{x} \in \mathcal{X}} \sum_{i=1}^{n} v_i x_i.$$

- Falls $\mathcal{X}$ sehr groß ist, dauert es zu lang, den Wert jeden Vektors auszurechnen.
- Man kann zeigen, dass das Maximum (auch) an einem Extrempunkt von $\operatorname{conv}(\mathcal{X})$ angenommen wird $\rightarrow$ oft viel leichter zu finden.

Konvexe Mengen: Projektionstheorem

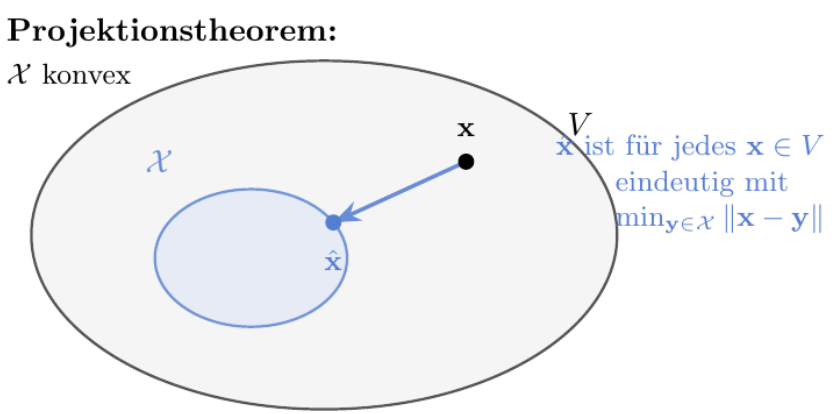
- Eine weitere wichtige Eigenschaft ist Existenz & Eindeutigkeit von *Projektionen* auf konvexe Mengen:

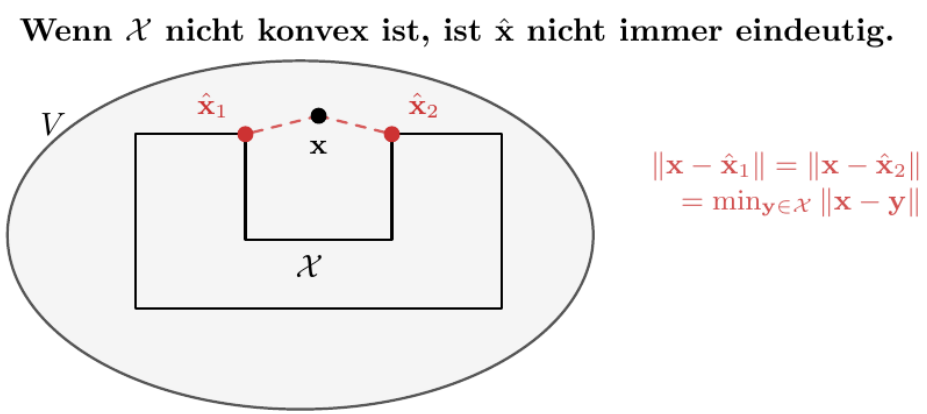
Theorem: Projektionstheorem

Sei $\mathcal{X} \neq \emptyset$ eine abgeschlossene, konvexe Teilmenge eines *vollständigen* Skalarproduktraums V (z.B. $V = \mathbb{R}^n$).
Dann existiert für jeden Punkt $\boldsymbol{x} \in V$ genau ein Punkt $\hat{\boldsymbol{x}} \in \mathcal{X}$, der den minimalen Abstand zu $\boldsymbol{x}$ hat:

$$\|\boldsymbol{x} - \hat{\boldsymbol{x}}\| = \min_{\boldsymbol{y} \in \mathcal{X}} \|\boldsymbol{x} - \boldsymbol{y}\|.$$

Dieser Punkt ist die **Projektion** von $\boldsymbol{x}$ auf $\mathcal{X}$.





Konvexe Funktionen

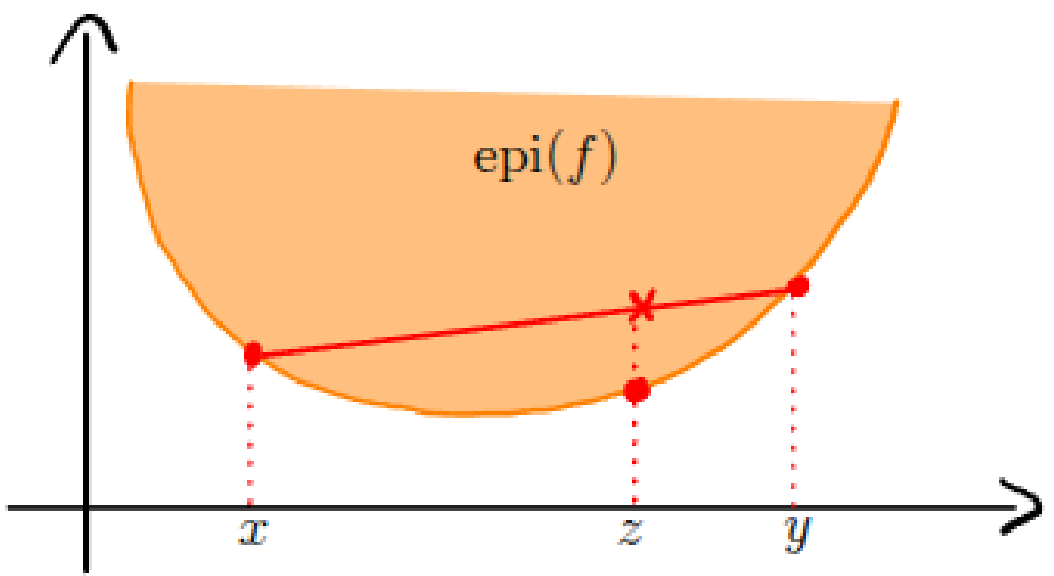
Konvexe Funktionen

Def.: Epigraph

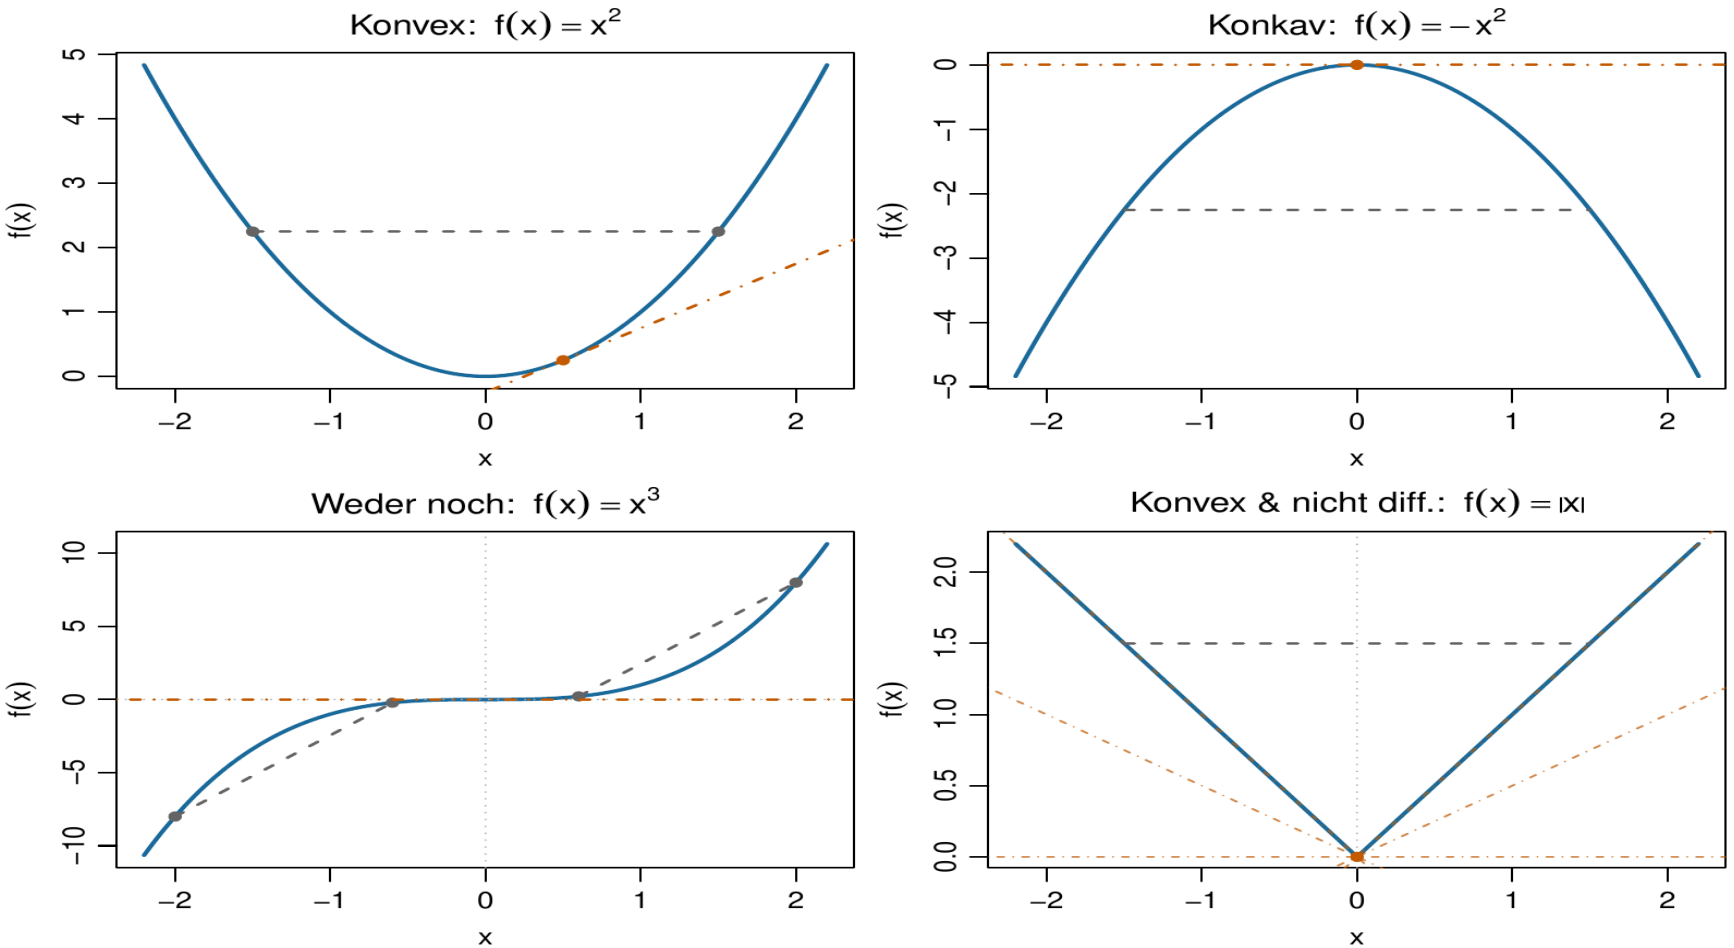
Der **Epigraph** einer Funktion $f\colon \mathcal{X} \to \mathbb{R}$ ist die Menge

$$\operatorname{epi}(f) = \{(\boldsymbol{x}, t) \in \mathcal{X} \times \mathbb{R} \colon t \geq f(\boldsymbol{x})\}$$

- Der *Epigraph* enthält alle Punkte in $\mathcal{X} \times \mathbb{R}$, die auf oder über dem Graphen von f liegen.
- *Konvexe Funktionen* $f\colon \mathcal{X} \to \mathbb{R}$ sind solche, deren *Epigraph* eine konvexe Menge ist. ($\mathcal{X}$ ist dann automatisch konvex.)



Konvex vs. Konkav



Konvexe Funktionen

- Eine gängigere Definition erfolgt direkt über Ungleichungen.

Def.: Konvexe Funktion

Sei $\mathcal{X}$ konvex und $f\colon \mathcal{X} \to \mathbb{R}$ eine Funktion.
Dann heißt f **konvex**, falls für alle $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt

$$f(\lambda \boldsymbol{x} + (1 - \lambda)\boldsymbol{y}) \leq \lambda f(\boldsymbol{x}) + (1 - \lambda) f(\boldsymbol{y}).$$

- Intuitiv sagt die Definition (für $f : \mathbb{R}^n \to \mathbb{R}$):
  Die Strecke zwischen den Graphenpunkten $(\boldsymbol{x}, f(\boldsymbol{x}))$ und $(\boldsymbol{y}, f(\boldsymbol{y}))$ liegt *nie unter* dem Funktionsgraphen.
  Konvexe Funktionen sind also *"nach oben geöffnet"*.
- Wir nennen eine Funktion f **konkav**, wenn $-f$ *konvex* ist.

Konvexe Funktion - Verifikation

Zu zeigen:
$f(x) = |x|$ ist konvex auf $\mathbb{R}$.

Seien $x, y \in \mathbb{R}$ beliebig und $\lambda \in [0, 1]$. Zu prüfen:

$$f(\lambda x + (1-\lambda)y) \overset{?}{\leq} \lambda f(x) + (1-\lambda) f(y)$$

Beweis (Dreiecksungleichung):

$$\begin{aligned} f(\lambda x + (1-\lambda)y) &= |\lambda x + (1-\lambda)y| \\ &\leq |\lambda x| + |(1-\lambda)y| \\ &= \lambda |x| + (1-\lambda)|y| \\ &= \lambda f(x) + (1-\lambda) f(y) \quad \blacksquare \end{aligned}$$

Konvexe Funktionen: Beispiele

Die folgenden multivariaten Funktionen sind konvex:

- *Affine* Funktionen:
  $f(\boldsymbol{x}) = \boldsymbol{b}^\top \boldsymbol{x} + a$ mit $\boldsymbol{b} \in \mathbb{R}^n$, $a \in \mathbb{R}$.
  Sie sind gleichzeitig *auch* *konkav*!
- Manche *quadratischen* Funktionen:
  $f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{Q}\boldsymbol{x} + \boldsymbol{b}^\top \boldsymbol{x} + a$ mit $\boldsymbol{Q} \in \mathbb{R}^{n \times n}$, $\boldsymbol{b} \in \mathbb{R}^n$, $a \in \mathbb{R}$, **falls der symmetrische Anteil** $\frac{1}{2}(\boldsymbol{Q} + \boldsymbol{Q}^\top)$ ***positiv semidefinit*** **ist** (für symmetrisches $\boldsymbol{Q}$ also: falls $\boldsymbol{Q} \succeq 0$).
- ***Jede*** *Norm*: $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$, d.h. jede Funktion mit den Eigenschaften
  - $f(c\boldsymbol{x}) = |c| f(\boldsymbol{x})$
  - $f(\boldsymbol{x} + \boldsymbol{y}) \leq f(\boldsymbol{x}) + f(\boldsymbol{y})$
  - $f(\boldsymbol{x}) \geq 0$ und $f(\boldsymbol{x}) = 0 \implies \boldsymbol{x} = \boldsymbol{0}$

Anwendung in ML / Statistik:

- **Kleinste-Quadrate-Verlust:**
  $f(\boldsymbol{w}) = \|\boldsymbol{A}\boldsymbol{w} - \boldsymbol{y}\|_2^2 = \boldsymbol{w}^\top (\boldsymbol{A}^\top \boldsymbol{A}) \boldsymbol{w} - 2\boldsymbol{y}^\top \boldsymbol{A}\boldsymbol{w} + \|\boldsymbol{y}\|_2^2$ mit $\boldsymbol{Q} = \boldsymbol{A}^\top \boldsymbol{A} \succeq 0$ (immer PSD!) $\implies$
  konvexes *Optimierungsproblem*
- **Ridge-Regression:**
  $f(\boldsymbol{w}) = \|\boldsymbol{A}\boldsymbol{w} - \boldsymbol{y}\|_2^2 + \lambda \|\boldsymbol{w}\|_2^2$ mit $\lambda > 0$ ist **strikt konvex**,
  d.h. die Konvexitäts-Ungleichung gilt strikt für $\boldsymbol{w} \neq \boldsymbol{w}'$
  ($\rightarrow$ eindeutige Lösung; formale Definition und Konsequenzen im Kapitel *Optimierung I*)

Konvexe Funktionen: Eigenschaften

Proposition

Seien $f_1, f_2, \ldots : \mathcal{X} \to \mathbb{R}$ konvexe Funktionen. Dann sind auch die folgenden Funktionen konvex:

i. $f(\boldsymbol{x}) = f_1(\boldsymbol{x}) + f_2(\boldsymbol{x})$.

ii. $f(\boldsymbol{x}) = c f_1(\boldsymbol{x}), c \geq 0$.

iii. $f(\boldsymbol{x}) = \max_{i=1,\ldots,k} f_i(\boldsymbol{x})$.

iv. $f(\boldsymbol{x}) = \lim_{n\to\infty} f_n(\boldsymbol{x})$, vorausgesetzt der Grenzwert existiert für alle $\boldsymbol{x} \in \mathcal{X}$.

Beweis für (ii) + (iv): → *Anhang*.

Jensen-Ungleichung

Satz: Jensen-Ungleichung

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine *konvexe Menge* und $f\colon \mathcal{X} \to \mathbb{R}$ eine *konvexe Funktion.*
Dann gilt für alle $N \in \mathbb{N}$, alle $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N \in \mathcal{X}$ und alle $w_1, \ldots, w_N \geq 0$ mit $\sum_{i=1}^{N} w_i = 1$:

$$f\left(\sum_{i=1}^{N} w_i \boldsymbol{x}_i\right) \leq \sum_{i=1}^{N} w_i f(\boldsymbol{x}_i).$$

- Die *Jensen-Ungleichung* verallgemeinert die Definition von Konvexität auf beliebig viele Punkte.
- Der Beweis erfolgt per Induktion über N.

Anwendung: Nichtnegative Varianz

Für eine Zufallsvariable X mit endlichem Träger T_X ist $\mathbb{E}[X] = \sum_{x \in T_X} P(X = x)x$ eine *Konvexkombination* der Werte in T_X (Gewichte = Wahrscheinlichkeiten).
Mit der *Jensen-Ungleichung* und da $x \mapsto x^2$ *konvex* ist gilt also:

$$\mathbb{E}[X]^2 = f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)] = \mathbb{E}[X^2]$$

Umstellen ergibt:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \geq 0$$

Für allgemeine integrierbare X gilt die Ungleichung ebenfalls – der Beweis läuft dann über Stützgeraden statt über endliche Konvexkombinationen.

Konvexe Vektor-zu-Skalar-Funktionen

Theorem

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine offene, *konvexe Menge* und $f\colon \mathcal{X} \to \mathbb{R}$ zweimal stetig differenzierbar.
Dann sind die folgenden Aussagen äquivalent:

i. f ist konvex.

ii. $f(\boldsymbol{y}) \geq f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})(\boldsymbol{y} - \boldsymbol{x})$ für alle $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$.

iii. $\boldsymbol{H}_f(\boldsymbol{x})$ ist positiv semidefinit für alle $\boldsymbol{x} \in \mathcal{X}$.

- (i): f ist konvex genau dann wenn die Sehne zwischen zwei Punkten des Graphen nie *unter* dem Funktionsgraphen verläuft.
- (ii): f ist konvex genau dann wenn die Tangente an f nie *über* dem Funktionsgraphen verläuft.
- (iii): f ist konvex genau dann wenn die `Hesse-Matrix` positiv semidefinit ist (d.h.: nicht-negative Krümmung in alle Richtungen an jeder Stelle).

Beweis: → *Anhang*.

Konvexität & Spektrum der Hesse-Matrix

Für $f \in \mathcal{C}^2$ ist $\boldsymbol{H}_f(\boldsymbol{x})$ symmetrisch
$\implies$ $\boldsymbol{H}_f(\boldsymbol{x})$ hat reelle Eigenwerte λ_i und orthonormale Eigenvektoren $\boldsymbol{v}_i$:

- Lokale Taylor-Approximation um $\boldsymbol{x}$:
  $f(\boldsymbol{x}+\boldsymbol{h}) \approx f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\,\boldsymbol{h} + \frac{1}{2}\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h} = f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})\,\boldsymbol{h} + \frac{1}{2}\sum_{i=1}^{n} \lambda_i \left(\boldsymbol{v}_i^\top \boldsymbol{h}\right)^2$
  - $\lambda_i > 0$: in $\boldsymbol{v}_i$-Richtung um $\boldsymbol{x}$ herum *konvex* (nach oben gekrümmt)
  - $\lambda_i < 0$: in $\boldsymbol{v}_i$-Richtung um $\boldsymbol{x}$ herum *konkav* (nach unten gekrümmt)
  - $|\lambda_i|$ misst Stärke der Krümmung in $\boldsymbol{v}_i$-Richtung

Wrap-up

Heute gelernt

- *Konvexkombinationen* = gewichtete Durchschnitte; *konvexe Hülle* = kleinste konvexe Obermenge
- *Konvexe Mengen* enthalten alle Verbindungsstrecken; Konvexität bleibt unter Schnitten, Produkten, affinen Abbildungen und Summen erhalten
- *Projektionen* auf nichtleere abgeschlossene konvexe Mengen (in vollständigen Skalarprodukträumen) existieren und sind eindeutig
- *Konvexe Funktionen*: *Epigraph* konvex $\iff$ Sehnen-Ungleichung; *Jensen-Ungleichung*
- $\mathcal{C}^2$-Charakterisierung: f konvex $\iff$ *Hesse-Matrix* überall PSD

Nächste Vorlesung

- Optimierung I – u.a.: warum konvexe Optimierungsprobleme “gutartig” sind

Self-Check: Konvexe Funktionen

Welche der folgenden Funktionen ist konvex?

1. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = ax + b, a, b \in \mathbb{R}$.
2. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = x^4$.
3. $f\colon \mathbb{R}_+ \to \mathbb{R}, f(x) = \sqrt{x}$.
4. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = e^x$.
5. $f\colon \mathbb{R}_+ \to \mathbb{R}, f(x) = \ln x$.

Self-Check: Klassifikation

Klassifizieren Sie: **konvex**, **strikt konvex** (d.h., die Ungleichung gilt strikt für $\boldsymbol{x} \neq \boldsymbol{y}$, $\lambda \in (0, 1)$) oder **keins von beiden**?

1. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = |x|$
2. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = e^x$
3. $f\colon \mathbb{R} \to \mathbb{R}, f(x) = ax + b, a, b \in \mathbb{R}$
4. $f\colon \mathbb{R}_+ \to \mathbb{R}, f(x) = \sqrt{x}$

Anhang

Konvexe Hülle - Beispiel im $\mathbb{R}^2$

(Zusatzbeispiel)

Sei $\mathcal{X} = \{(0,0), (2,0), (1,2)\} \subset \mathbb{R}^2$ (die Ecken eines Dreiecks).

Extrempunkte:
Alle drei Punkte in $\mathcal{X}$ sind *Extrempunkte*, da sie nur durch $w_i = 1, w_j = 0 \; \forall \, j \neq i$ erreicht werden können.

Konvexe Hülle:
$\text{conv}(\mathcal{X})$ ist die Menge aller Punkte der Form

$$\boldsymbol{x} = w_1 \begin{pmatrix} 0 \\ 0 \end{pmatrix} + w_2 \begin{pmatrix} 2 \\ 0 \end{pmatrix} + w_3 \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

mit $w_1, w_2, w_3 \geq 0$ und $w_1 + w_2 + w_3 = 1$.

Konkreter Punkt: Für $w_1 = w_2 = w_3 = \frac{1}{3}$:

$$\boldsymbol{x} = \tfrac{1}{3} \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \tfrac{1}{3} \begin{pmatrix} 2 \\ 0 \end{pmatrix} + \tfrac{1}{3} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ \frac{2}{3} \end{pmatrix}$$

Dieser Punkt (Schwerpunkt!) liegt im Inneren des Dreiecks.

↩ zurück: „Konvexe Hülle"

Beispiel: Schnitt konvexer Mengen

(Zusatzbeispiel)

Konkrete Mengen im $\mathbb{R}^2$:

- $\mathcal{X}_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$ (Halbraum, konvex)
- $\mathcal{X}_2 = \{(x, y) \in \mathbb{R}^2 : x \geq 0\}$ (Halbraum, konvex)
- $\mathcal{X}_3 = \{(x, y) \in \mathbb{R}^2 : y \geq 0\}$ (Halbraum, konvex)

Schnitt:

$$\mathcal{S} = \mathcal{X}_1 \cap \mathcal{X}_2 \cap \mathcal{X}_3 = \{(x, y) : x \geq 0, y \geq 0, x + y \leq 1\}$$

Dies ist ein Dreieck mit Ecken $(0, 0), (1, 0), (0, 1)$ - offensichtlich konvex!

Generell:

Polyeder (als Schnitte von Halbräumen) sind konvex – wichtig für *lineare Programmierung* (Optimierung unter linearen Nebenbedingungen)!

↩ zurück: „Konvexe Mengen: Eigenschaften”

Konvexitätserhaltung: Beweis

- *(i) Schnitt:*
  Sei $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{S}$, $\lambda \in [0,1]$ und $\boldsymbol{z} = \lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}$.
  Dann gilt $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{S} \implies \boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}_i \; \forall i \in I$.
  $\mathcal{X}_i$ konvex $\forall i \in I \implies \boldsymbol{z} \in \mathcal{X}_i \; \forall i \in I \implies \boldsymbol{z} \in \mathcal{S}$.
- *(ii) Kartesisches Produkt:*
  Seien $(\boldsymbol{x}_1, \ldots, \boldsymbol{x}_k), (\boldsymbol{y}_1, \ldots, \boldsymbol{y}_k) \in \mathcal{X}_1 \times \cdots \times \mathcal{X}_k; \lambda \in [0,1]$.
  Weil $\mathcal{X}_i$ konvex, ist auch

$$\begin{aligned} &\lambda(\boldsymbol{x}_1, \ldots, \boldsymbol{x}_k) + (1-\lambda)(\boldsymbol{y}_1, \ldots, \boldsymbol{y}_k) \\ &= (\lambda \boldsymbol{x}_1 + (1-\lambda)\boldsymbol{y}_1, \ldots, \lambda \boldsymbol{x}_k + (1-\lambda)\boldsymbol{y}_k) \in (\mathcal{X}_1 \times \cdots \times \mathcal{X}_k) \end{aligned}$$

- *(iii) Affine Abb.:*
  Sei $\boldsymbol{y}_1 = f(\boldsymbol{x}_1), \boldsymbol{y}_2 = f(\boldsymbol{x}_2) \in f(\mathcal{X})$ für $\boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{X}$; $\lambda \in [0,1]$. Dann gilt:

$$\begin{aligned} \lambda \boldsymbol{y}_1 + (1-\lambda)\boldsymbol{y}_2 &= \lambda(\boldsymbol{A}\boldsymbol{x}_1 + \boldsymbol{b}) + (1-\lambda)(\boldsymbol{A}\boldsymbol{x}_2 + \boldsymbol{b}) \\ &= \boldsymbol{A}(\lambda \boldsymbol{x}_1 + (1-\lambda)\boldsymbol{x}_2) + \boldsymbol{b} \\ &= f(\lambda \boldsymbol{x}_1 + (1-\lambda)\boldsymbol{x}_2) \in f(\mathcal{X}). \end{aligned}$$

- *(iv) Summe:*
  Folgt aus (ii) und (iii):
  $\mathcal{X}_1 \times \mathcal{X}_2$ ist konvex, $f(\boldsymbol{x}_1, \boldsymbol{x}_2) = \boldsymbol{x}_1 + \boldsymbol{x}_2$ ist linear, also ist auch $f(\mathcal{X}_1 \times \mathcal{X}_2) = \mathcal{X}_1 \oplus \mathcal{X}_2$ konvex.

↩ zurück: „Konvexe Mengen: Eigenschaften”

Projektionstheorem: Beweisskizze

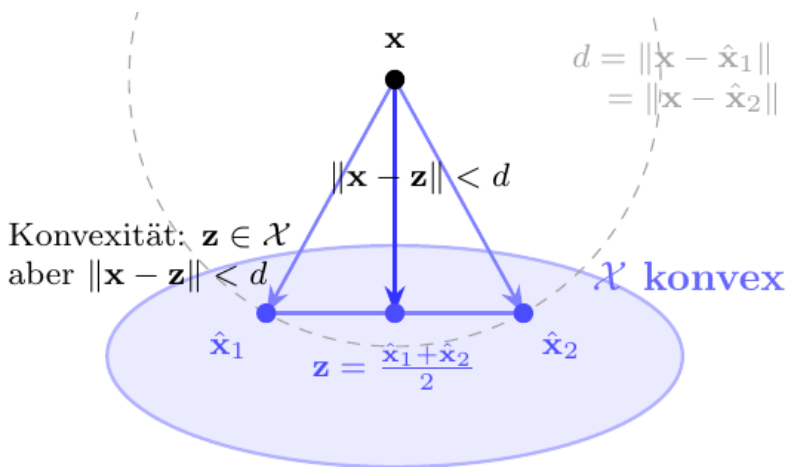
- **Existenz:**
  Eine Minimierungsfolge ist beschränkt und besitzt daher einen Grenzwert (in $\mathbb{R}^n$: Bolzano-Weierstraß; allgemein: Parallelogrammgleichung $\to$ Cauchy-Folge + Vollständigkeit von V);
  $\mathcal{X}$ abgeschlossen $\implies$ dieser Grenzwert liegt in $\mathcal{X}$

- **Eindeutigkeit:**
  Angenommen, es *gäbe* $\hat{\boldsymbol{x}}_1 \neq \hat{\boldsymbol{x}}_2$ mit demselben minimalen Abstand d zu $\boldsymbol{x}$.

Für jedes $\lambda \in [0,1]$ gilt wegen Konvexität
$\boldsymbol{z} = \lambda\hat{\boldsymbol{x}}_1 + (1-\lambda)\hat{\boldsymbol{x}}_2 \in \mathcal{X}$ und nach der Dreiecksungleichung:

$$\|\boldsymbol{x} - \boldsymbol{z}\| \leq \lambda\|\boldsymbol{x} - \hat{\boldsymbol{x}}_1\| + (1-\lambda)\|\boldsymbol{x} - \hat{\boldsymbol{x}}_2\| = d$$

Wegen der Minimalität von d gilt sogar $\|\boldsymbol{x} - \boldsymbol{z}\| = d$.
Wähle Mittelpunkt $\boldsymbol{z} = (\hat{\boldsymbol{x}}_1 + \hat{\boldsymbol{x}}_2)/2$ und setze $\boldsymbol{u} := \boldsymbol{x} - \hat{\boldsymbol{x}}_1$,
$\boldsymbol{v} := \boldsymbol{x} - \hat{\boldsymbol{x}}_2$.



Aus der Definition von $\boldsymbol{z}$ folgt $\boldsymbol{x} - \boldsymbol{z} = \frac{\boldsymbol{u}+\boldsymbol{v}}{2}$, $\quad \boldsymbol{z} - \hat{\boldsymbol{x}}_1 = \frac{\boldsymbol{u}-\boldsymbol{v}}{2}$,
und diese sind orthogonal: $\left\langle \boldsymbol{x} - \boldsymbol{z}, \boldsymbol{z} - \hat{\boldsymbol{x}}_1 \right\rangle = \frac{1}{4}\langle \boldsymbol{u}+\boldsymbol{v}, \boldsymbol{u}-\boldsymbol{v}\rangle = \frac{1}{4}\left(\|\boldsymbol{u}\|^2 - \|\boldsymbol{v}\|^2\right) = \frac{1}{4}\left(d^2 - d^2\right) = 0$

Damit also auch

$$\begin{aligned}\|\boldsymbol{x} - \hat{\boldsymbol{x}}_1\|^2 &= \|(\boldsymbol{x} - \boldsymbol{z}) + (\boldsymbol{z} - \hat{\boldsymbol{x}}_1)\|^2 \\ &= \|\boldsymbol{x} - \boldsymbol{z}\|^2 + \|\boldsymbol{z} - \hat{\boldsymbol{x}}_1\|^2 && [(\boldsymbol{x} - \boldsymbol{z}) \perp (\boldsymbol{z} - \hat{\boldsymbol{x}}_1)] \\ &> \|\boldsymbol{x} - \boldsymbol{z}\|^2,\end{aligned}$$

also: *Widersprüchlich* $d^2 > d^2 \implies$ Projektion eindeutig. ■

↩ zurück: „Konvexe Mengen: Projektionstheorem”

Konvexe Funktionen: Beweise I

(Beweis der $\mathcal{C}^2$-Charakterisierung; (i) $\iff$ (ii))

- $(i) \implies (ii)$: Setze $t = (1 - \lambda)$. Dann gilt

$$
\begin{aligned}
& f(\lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}) \leq \lambda f(\boldsymbol{x}) + (1-\lambda) f(\boldsymbol{y}) \\
\iff \quad & f(\lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}) - f(\boldsymbol{x}) \leq (1-\lambda)[f(\boldsymbol{y}) - f(\boldsymbol{x})] \\
\iff \quad & f(\boldsymbol{y}) - f(\boldsymbol{x}) \geq \frac{f(\boldsymbol{x} + t(\boldsymbol{y} - \boldsymbol{x})) - f(\boldsymbol{x})}{t} \quad \text{für } t > 0. \quad \blacksquare
\end{aligned}
$$

  (Für $t \to 0$ erhalten wir (ii).)

- $(ii) \implies (i)$: Sei $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$, $\lambda \in [0, 1]$ und definiere $\boldsymbol{z} = \lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}$. (ii) impliziert

$$
\begin{aligned}
\lambda f(\boldsymbol{x}) &\geq \lambda f(\boldsymbol{z}) + \lambda \nabla f(\boldsymbol{z})(\boldsymbol{x} - \boldsymbol{z}) \\
\text{und } (1-\lambda) f(\boldsymbol{y}) &\geq (1-\lambda) f(\boldsymbol{z}) + (1-\lambda) \nabla f(\boldsymbol{z})(\boldsymbol{y} - \boldsymbol{z}).
\end{aligned}
$$

  Summieren wir die beiden Ungleichungen, erhalten wir

$$
\lambda f(\boldsymbol{x}) + (1-\lambda) f(\boldsymbol{y}) \geq f(\boldsymbol{z}) + 0 = f(\lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}). \quad \blacksquare
$$

↩ zurück: „Konvexe Vektor-zu-Skalar-Funktionen”

Konvexe Funktionen: Beweise II

(Beweis der $\mathcal{C}^2$-Charakterisierung, fortgesetzt; (ii) $\iff$ (iii))

- $(ii) \implies (iii)$: Sei $\boldsymbol{h} \in \mathbb{R}^n$ beliebig. Nach Definition der zweiten Ableitung gilt für $t \to 0$,

$$
\begin{aligned}
f(\boldsymbol{x} + t\boldsymbol{h}) - f(\boldsymbol{x}) - t\nabla f(\boldsymbol{x})\boldsymbol{h} - \frac{t^2}{2}\boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h} &= o(t^2) \qquad \text{[Taylorpolynom]} \\
\iff \boldsymbol{h}^\top \boldsymbol{H}_f(\boldsymbol{x})\boldsymbol{h} &= 2\,\frac{f(\boldsymbol{x} + t\boldsymbol{h}) - f(\boldsymbol{x}) - t\nabla f(\boldsymbol{x})\boldsymbol{h}}{t^2} + o(1) \\
&\geq 0 + o(1) \to 0.
\end{aligned}
$$

  (Da die linke Seite nicht von t abhängt, folgt (iii).)

- $(iii) \implies (ii)$: *Taylor's Theorem*: für $f \in \mathcal{C}^2$ und jedes $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$ $\exists\, t \in (0, 1)$, so dass:

$$
\begin{aligned}
f(\boldsymbol{y}) &= f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})(\boldsymbol{y} - \boldsymbol{x}) + \frac{1}{2}(\boldsymbol{y} - \boldsymbol{x})^\top \boldsymbol{H}_f(\boldsymbol{x} + t(\boldsymbol{y} - \boldsymbol{x}))(\boldsymbol{y} - \boldsymbol{x}) \\
&\geq f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})(\boldsymbol{y} - \boldsymbol{x})
\end{aligned}
$$

Konvexe Funktionen: Beweis der Eigenschaften

(Proposition Summe/Skalierung/Maximum/Grenzwert)

Seien $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$, $\lambda \in [0,1]$ und $\boldsymbol{z} := \lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y}$.

(ii) Skalierung: Für $f = cf_1$ mit $c \geq 0$ gilt

$$\begin{aligned} f(\boldsymbol{z}) &= c\, f_1(\boldsymbol{z}) \\ &\leq c\,[\lambda f_1(\boldsymbol{x}) + (1-\lambda) f_1(\boldsymbol{y})] \\ &= \lambda f(\boldsymbol{x}) + (1-\lambda) f(\boldsymbol{y}). \end{aligned}$$

Die Ungleichung folgt aus der Konvexität von f_1; Multiplikation mit $c \geq 0$ erhält ihre Richtung.

(iv) Grenzwert: Wegen der Konvexität von f_n gilt für jedes n

$$f_n(\boldsymbol{z}) \leq \lambda f_n(\boldsymbol{x}) + (1-\lambda) f_n(\boldsymbol{y}).$$

Da alle beteiligten Folgen konvergieren, können wir den Grenzwert bilden:

$$\begin{aligned} f(\boldsymbol{z}) &= \lim_{n\to\infty} f_n(\boldsymbol{z}) \\ &\leq \lambda \lim_{n\to\infty} f_n(\boldsymbol{x}) + (1-\lambda) \lim_{n\to\infty} f_n(\boldsymbol{y}) \\ &= \lambda f(\boldsymbol{x}) + (1-\lambda) f(\boldsymbol{y}). \end{aligned}$$

↩ zurück: „Konvexe Funktionen: Eigenschaften”