

Konvexität

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- Normen, Skalarprodukträume
- Gradient ∇f & Hesse-Matrix $\mathbf{H}_f$ (Kap. 10/11)
- **Lineare Algebra**
 - Vektorräume
 - Linearkombinationen: $\sum w_i \mathbf{v}_i$
 - Positiv definite Matrizen
- **Analysis**
 - Grenzwerte; Supremum & Infimum
 - Abgeschlossene Mengen
- **Wahrscheinlichkeitstheorie**
 - Erwartungswert $\mathbb{E}[X]$ als gewichteter Durchschnitt
 - Jensen-Ungleichung

Einführung

Einführung

- *Konvexität* ist ein wichtiges Konzept in der Mathematik, besonders in
 - Optimierung
 - Wahrscheinlichkeitstheorie
- Der Begriff bezieht sich meist auf die (verwandten) Konzepte
 - *konvexe Mengen*
 - *konvexe Funktionen*
- Beides ist gewissermaßen eine Verallgemeinerung von Linearitätskonzepten

Diese Folien: → wichtigste Definitionen und Eigenschaften

Warum Konvexität wichtig ist

In Optimierung / ML / Statistik:

- Konvexe Optimierungsprobleme sind *gutartig*: jedes lokale Minimum ist *global* ($\rightarrow$ *Optimierung I*)
- Viele Algorithmen basieren auf konvexer Optimierung, z.B.:
 - Maximum Likelihood (*meist* konkave Log-Likelihoods = konvexe *negative* Log-Likelihoods): GLMs etc.
 - Support Vector Machines
 - Ridge Regression

In der Wahrscheinlichkeitstheorie:

- *Jensen'sche Ungleichung* nutzt Konvexität für Erwartungswerte
- KL-Divergenz ist konvex (wichtig für *Variational Inference*)
- Varianz als Konvexitätseigenschaft: $\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$

Konvexkombinationen

Konvexkombinationen

Def.: Konvexkombination

Sei V ein Vektorraum und $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_k\} \subset V$.

Dann nennen wir $\mathbf{x}$ eine **Konvexkombination** von Vektoren in $\mathcal{X}$, falls es Koeffizienten $w_1, \dots, w_k \geq 0$ gibt mit


$$\mathbf{x} = \sum_{i=1}^k w_i \mathbf{x}_i \quad \text{und} \quad \sum_{i=1}^k w_i = 1.$$

- **Konvexkombinationen** sind spezielle Linearkombinationen.
- Sie können als gewichteter Durchschnitt interpretiert werden.
- **Bsp.:** Erwartungswert $\mathbb{E}(X)$ für diskrete Zufallsvariable X mit endlichem Träger ist Konvexkombination der Werte des Trägers $\mathcal{X} = T_X$:

$$\mathbb{E}(X) = \sum_{x_j \in T_X} \mathbb{P}(X = x_j) x_j$$

Konvexkombinationen

- Die Menge aller Konvexkombinationen zweier Vektoren x_1, x_2 ist das *Liniensegment*, das x_1 und x_2 verbindet.




Konvexe Hülle

Def.: Konvexe Hülle

Sei $\mathcal{X} \subset V$ eine beliebige Menge von Vektoren.

Die Menge aller Konvexkombinationen von endlich vielen Vektoren aus $\mathcal{X}$ wird als **konvexe Hülle** $\text{conv}(\mathcal{X})$ von $\mathcal{X}$ bezeichnet:

$$\text{conv}(\mathcal{X}) = \left\{ \mathbf{x} = \sum_{i=1}^N w_i \mathbf{x}_i : N \in \mathbb{N}, \mathbf{x}_i \in \mathcal{X}, w_i \geq 0, \sum_{i=1}^N w_i = 1 \right\}$$



- **Extrempunkte** sind die Punkte $\mathbf{x}_i \in \mathcal{X}$, die sich nur mit $w_i = 1$ (und allen übrigen Gewichten 0) darstellen lassen.
- Die **konvexe Hülle** ist die kleinste konvexe Menge, die $\mathcal{X}$ enthält.

Konkretes Beispiel im $\mathbb{R}^2$: → *Anhang*.


Konvexe Mengen

Konvexe Mengen: Definition


Def.: Konvexe Menge

Eine Menge $\mathcal{X} \subset V$ in Vektorraum V wird als **konvex** bezeichnet, falls für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt:

$$\lambda \mathbf{x} + (1 - \lambda) \mathbf{y} \in \mathcal{X}.$$



konvex



nicht konvex

Konvexe Mengen enthalten für alle Paare von Punkten auch das Liniensegment zwischen diesen Punkten $\implies$ sie haben keine “Einbuchtungen” oder “Löcher”.

Quiz: Konvexe Mengen

Welche der folgenden Mengen ist konvex?

1. Die leere Menge $\emptyset$.
2. Ein Vektorraum V .
3. Die Einheitssphäre $\{\mathbf{x} \in V: \|\mathbf{x}\| = 1\}$.
4. Der geschlossene Ball $\{\mathbf{x} \in V: \|\mathbf{x}\| \leq r\}$.
5. Die Menge $\{(x, y) \in \mathbb{R}^2: y \leq x^2\}$.

Konvexe Mengen: Beispiele

Weitere Beispiele

- Ein offener Ball $\{\mathbf{x} \in V: \|\mathbf{x}\| < r\}$.
- Der *Simplex*

$$\Delta^N = \left\{ \mathbf{x} \in \mathbb{R}^N: x_i \geq 0, \sum_{i=1}^N x_i = 1 \right\}.$$

- Die Menge aller *positiv semi-definiten* Matrizen in $\mathbb{R}^{n \times n}$.

Simplex - Beispiel und Anwendung

Beispiel in $\mathbb{R}^3$:

Simplex Δ^3 besteht aus allen Punkten $\mathbf{x} = (x_1, x_2, x_3)$ mit $x_1, x_2, x_3 \geq 0$ und $x_1 + x_2 + x_3 = 1 = \|\mathbf{x}\|_1$

Extrempunkte:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \mathbf{e}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

Anwendung in der Statistik:

- Δ^N definiert (die Menge aller) Wahrscheinlichkeitsverteilungen über N Ereignisse. Beispiel:
 $\mathbf{p} = (0.2, 0.5, 0.3)$ beschreibt eine kategoriale Verteilung mit drei Kategorien
- Wichtig für: Softmax-Regression/Multinomial-Modelle, Dirichlet-Verteilungen, ...

Geometrisch:

Δ^2 ist die Strecke von $(1, 0)$ nach $(0, 1)$,
 Δ^3 das Dreieck zwischen $\mathbf{e}_1, \mathbf{e}_2$ und $\mathbf{e}_3$,
 Δ^4 ein Tetraeder, ...

PSD-Matrizen bilden eine konvexe Menge

Def.: Positiv Semi-Definit

Eine *symmetrische* Matrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ ist **positiv semi-definit (PSD)**

$$\iff \mathbf{x}^\top \mathbf{A} \mathbf{x} \geq 0 \quad \forall \mathbf{x} \in \mathbb{R}^n.$$

Wir schreiben: $\mathbf{A} \succeq 0$

Seien $\mathbf{A}_1, \mathbf{A}_2 \succeq 0$ und $\lambda \in [0, 1]$.

Zu zeigen:

$$\mathbf{A}_\lambda = \lambda \mathbf{A}_1 + (1 - \lambda) \mathbf{A}_2 \succeq 0.$$

Für beliebiges $\mathbf{x} \in \mathbb{R}^n$:

$$\begin{aligned} \mathbf{x}^\top \mathbf{A}_\lambda \mathbf{x} &= \mathbf{x}^\top [\lambda \mathbf{A}_1 + (1 - \lambda) \mathbf{A}_2] \mathbf{x} \\ &= \lambda \mathbf{x}^\top \mathbf{A}_1 \mathbf{x} + (1 - \lambda) \mathbf{x}^\top \mathbf{A}_2 \mathbf{x} \\ &\geq \lambda \cdot 0 + (1 - \lambda) \cdot 0 = 0 \quad (\text{da } \mathbf{A}_1, \mathbf{A}_2 \succeq 0) \quad \blacksquare \end{aligned}$$

Anwendung:

Kovarianzmatrizen sind stets **PSD** (**SPD** nur, falls keine Komponente linear von den übrigen abhängt) und bilden eine **konvexe Menge**.

Konvexe Mengen: Eigenschaften

- Viele wichtige Operationen erhalten Konvexität.

Theorem: Konvexitätserhaltung

Seien $\mathcal{X}, \mathcal{X}_1, \mathcal{X}_2, \dots$ konvexe Mengen. Dann sind auch die folgenden Mengen konvex:

- *Schnittmenge:*
 $\mathcal{S} = \bigcap_{i \in I} \mathcal{X}_i$ für eine beliebige Indexmenge I (alle $\mathcal{X}_i$ im selben Vektorraum)
- *Kartesisches Produkt:*
 $\mathcal{X}_1 \times \dots \times \mathcal{X}_k$
- *Affine Abbildungen:*
 $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ mit $f(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{b}$ und $\mathcal{X} \subseteq \mathbb{R}^n$: Bildmenge
 $f(\mathcal{X}) = \{\mathbf{y} = f(\mathbf{x}) : \mathbf{x} \in \mathcal{X}\}$ ist konvex.
- *Summen:*
 $\mathcal{X}_1 \oplus \mathcal{X}_2 := \{\mathbf{x}_1 + \mathbf{x}_2 : \mathbf{x}_1 \in \mathcal{X}_1, \mathbf{x}_2 \in \mathcal{X}_2\}$ ($\mathcal{X}_1, \mathcal{X}_2$ im selben Vektorraum)

- **Beispiel** für die Nützlichkeit der Schnitt-Eigenschaft:
Polyeder (= Schnitte von **Halbräumen**) sind konvex – wichtig für *lineare Programmierung* (→ *Optimierung unter linearen Nebenbedingungen*)!

Konvexe Hülle: Eigenschaften

- Eine **konvexe Hülle** ist selbst eine **konvexe Menge** (Konvexkombinationen von Konvexkombinationen aus $\mathcal{X}$ sind wieder Konvexkombinationen aus $\mathcal{X}$).
- Sie ist die **kleinste konvexe Menge, die ganz $\mathcal{X}$ enthält**.

Proposition

Es gilt $\text{conv}(\mathcal{X}) = \bigcap_{\mathcal{X} \subseteq \mathcal{Y}, \mathcal{Y} \text{ konvex}} \mathcal{Y}$.

Beweis:

Sei $\mathcal{S} = \bigcap_{\mathcal{X} \subseteq \mathcal{Y}, \mathcal{Y} \text{ konvex}} \mathcal{Y}$.

- Da $\mathcal{X} \subseteq \mathcal{Y}$ und $\mathcal{Y}$ konvex ist, ist jede Konvexkombination von Punkten aus $\mathcal{X}$ auch in jedem $\mathcal{Y}$ (konvexe Mengen enthalten – per Induktion über die Anzahl der Punkte – alle Konvexkombinationen endlich vieler ihrer Punkte). Es folgt $\text{conv}(\mathcal{X}) \subseteq \mathcal{S}$.
- Da der Schnitt auch über die Menge $\mathcal{Y} = \text{conv}(\mathcal{X})$ geht, ist automatisch auch $\mathcal{S} \subseteq \text{conv}(\mathcal{X})$.

Konvexe Mengen: Anwendung

- Konvexe Mengen/Hüllen sind wichtig in der Optimierung.

Beispiel:

- Sei $\mathcal{X} \subseteq \mathbb{N}^n$. Jedes $\mathbf{x} \in \mathcal{X}$ beschreibt eine Zusammensetzung von n verschiedenen Gegenständen: $x_i = k$ bedeutet, dass k Einheiten des i -ten Gegenstands vorhanden sind.
- Jeder Gegenstand hat einen Wert v_i und wir wollen das $\mathbf{x} \in \mathcal{X}$ mit maximalem Wert finden:

$$\mathbf{x}^* \in \arg \max_{\mathbf{x} \in \mathcal{X}} \sum_{i=1}^n v_i x_i.$$

- Falls $\mathcal{X}$ sehr groß ist, dauert es zu lang, den Wert jeden Vektors auszurechnen.
- Man kann zeigen, dass das Maximum (auch) an einem Extrempunkt von $\text{conv}(\mathcal{X})$ angenommen wird $\rightarrow$ oft viel leichter zu finden.

Konvexe Mengen: Projektionstheorem

- Eine weitere wichtige Eigenschaft ist Existenz & Eindeutigkeit von **Projektionen** auf konvexe Mengen:

Theorem: Projektionstheorem

Sei $\mathcal{X} \neq \emptyset$ eine abgeschlossene, konvexe Teilmenge eines *vollständigen* Skalarproduktraums V (z.B. $V = \mathbb{R}^n$).


Dann existiert für jeden Punkt $\mathbf{x} \in V$ genau ein Punkt $\hat{\mathbf{x}} \in \mathcal{X}$, der den minimalen Abstand zu $\mathbf{x}$ hat:

$$\|\mathbf{x} - \hat{\mathbf{x}}\| = \min_{\mathbf{y} \in \mathcal{X}} \|\mathbf{x} - \mathbf{y}\|.$$


Dieser Punkt ist die **Projektion** von $\mathbf{x}$ auf $\mathcal{X}$.

Projektionstheorem:

$\mathcal{X}$ konvex



Wenn $\mathcal{X}$ nicht konvex ist, ist $\hat{\mathbf{x}}$ nicht immer eindeutig.



Konvexe Funktionen


Konvexe Funktionen

Def.: Epigraph





Der **Epigraph** einer Funktion $f: \mathcal{X} \rightarrow \mathbb{R}$ ist die Menge

$$\text{epi}(f) = \{(\mathbf{x}, t) \in \mathcal{X} \times \mathbb{R} : t \geq f(\mathbf{x})\}$$

- Der **Epigraph** enthält alle Punkte in $\mathcal{X} \times \mathbb{R}$, die auf oder über dem Graphen von f liegen.
- **Konvexe Funktionen** $f: \mathcal{X} \rightarrow \mathbb{R}$ sind solche, deren **Epigraph** eine konvexe Menge ist. ($\mathcal{X}$ ist dann automatisch konvex.)



Konvex vs. Konkav



Konvexe Funktionen

- Eine gängigere Definition erfolgt direkt über Ungleichungen.

Def.: Konvexe Funktion

Sei $\mathcal{X}$ konvex und $f: \mathcal{X} \rightarrow \mathbb{R}$ eine Funktion.

Dann heißt f **konvex**, falls für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ und alle $\lambda \in [0, 1]$ gilt

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

- Intuitiv sagt die Definition (für $f: \mathbb{R}^n \rightarrow \mathbb{R}$):
Die Strecke zwischen den Graphenpunkten $(\mathbf{x}, f(\mathbf{x}))$ und $(\mathbf{y}, f(\mathbf{y}))$ liegt *nie unter* dem Funktionsgraphen.
Konvexe Funktionen sind also “nach oben geöffnet”.
- Wir nennen eine Funktion f **konkav**, wenn $-f$ **konvex** ist.

Konvexe Funktion - Verifikation

Zu zeigen:

$f(x) = |x|$ ist konvex auf $\mathbb{R}$.

Seien $x, y \in \mathbb{R}$ beliebig und $\lambda \in [0, 1]$. Zu prüfen:

$$f(\lambda x + (1 - \lambda)y) \stackrel{?}{\leq} \lambda f(x) + (1 - \lambda)f(y)$$

Beweis (Dreiecksungleichung):

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= |\lambda x + (1 - \lambda)y| \\ &\leq |\lambda x| + |(1 - \lambda)y| \\ &= \lambda|x| + (1 - \lambda)|y| \\ &= \lambda f(x) + (1 - \lambda)f(y) \quad \blacksquare \end{aligned}$$

Konvexe Funktionen: Beispiele

Die folgenden multivariaten Funktionen sind konvex:

- **Affine Funktionen:**

$$f(\mathbf{x}) = \mathbf{b}^\top \mathbf{x} + a \text{ mit } \mathbf{b} \in \mathbb{R}^n, a \in \mathbb{R}.$$

Sie sind gleichzeitig auch **konkav**!

- Manche **quadratischen** Funktionen:

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + a \text{ mit } \mathbf{Q} \in \mathbb{R}^{n \times n}, \mathbf{b} \in \mathbb{R}^n, a \in \mathbb{R}, \text{ falls der symmetrische Anteil } \frac{1}{2}(\mathbf{Q} + \mathbf{Q}^\top) \text{ positiv semidefinit ist (für symmetrisches } \mathbf{Q} \text{ also: falls } \mathbf{Q} \succeq 0).$$

- **Jede Norm:** $f(\mathbf{x}) = \|\mathbf{x}\|$, d.h. jede Funktion mit den Eigenschaften

- $f(c\mathbf{x}) = |c|f(\mathbf{x})$
- $f(\mathbf{x} + \mathbf{y}) \leq f(\mathbf{x}) + f(\mathbf{y})$
- $f(\mathbf{x}) \geq 0$ und $f(\mathbf{x}) = 0 \implies \mathbf{x} = \mathbf{0}$

Anwendung in ML / Statistik:

- **Kleinste-Quadrate-Verlust:**

$$f(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|_2^2 = \mathbf{w}^\top (\mathbf{A}^\top \mathbf{A}) \mathbf{w} - 2\mathbf{y}^\top \mathbf{A} \mathbf{w} + \|\mathbf{y}\|_2^2 \text{ mit } \mathbf{Q} = \mathbf{A}^\top \mathbf{A} \succeq 0 \text{ (immer PSD!) } \implies \text{konvexes Optimierungsproblem}$$

- **Ridge-Regression:**

$$f(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2 \text{ mit } \lambda > 0 \text{ ist strikt konvex,}$$

d.h. die Konvexitäts-Ungleichung gilt strikt für $\mathbf{w} \neq \mathbf{w}'$

($\rightarrow$ eindeutige Lösung; formale Definition und Konsequenzen im Kapitel *Optimierung I*)

Konvexe Funktionen: Eigenschaften

Proposition

Seien $f_1, f_2, \dots: \mathcal{X} \rightarrow \mathbb{R}$ konvexe Funktionen. Dann sind auch die folgenden Funktionen konvex:

- i. $f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x})$.
- ii. $f(\mathbf{x}) = cf_1(\mathbf{x}), c \geq 0$.
- iii. $f(\mathbf{x}) = \max_{i=1, \dots, k} f_i(\mathbf{x})$.
- iv. $f(\mathbf{x}) = \lim_{n \rightarrow \infty} f_n(\mathbf{x})$, vorausgesetzt der Grenzwert existiert für alle $\mathbf{x} \in \mathcal{X}$.

Beweis für (ii) + (iv): → Anhang.

Jensen-Ungleichung

Satz: Jensen-Ungleichung

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine *konvexe Menge* und $f: \mathcal{X} \rightarrow \mathbb{R}$ eine *konvexe Funktion*.

Dann gilt für alle $N \in \mathbb{N}$, alle $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ und alle $w_1, \dots, w_N \geq 0$ mit $\sum_{i=1}^N w_i = 1$:

$$f\left(\sum_{i=1}^N w_i \mathbf{x}_i\right) \leq \sum_{i=1}^N w_i f(\mathbf{x}_i).$$

- Die *Jensen-Ungleichung* verallgemeinert die Definition von Konvexität auf beliebig viele Punkte.
- Der Beweis erfolgt per Induktion über N .

Anwendung: Nichtnegative Varianz

Für eine Zufallsvariable X mit endlichem Träger T_X ist $\mathbb{E}[X] = \sum_{x \in T_X} P(X = x)x$ eine **Konvexkombination** der Werte in T_X (Gewichte = Wahrscheinlichkeiten).

Mit der **Jensen-Ungleichung** und da $x \mapsto x^2$ **konvex** ist gilt also:

$$\mathbb{E}[X]^2 = f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)] = \mathbb{E}[X^2]$$

Umstellen ergibt:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \geq 0$$

Für allgemeine integrierbare X gilt die Ungleichung ebenfalls – der Beweis läuft dann über Stützgeraden statt über endliche Konvexkombinationen.

Konvexe Vektor-zu-Skalar-Funktionen

Theorem

Sei $\mathcal{X} \subseteq \mathbb{R}^n$ eine offene, *konvexe Menge* und $f: \mathcal{X} \rightarrow \mathbb{R}$ zweimal stetig differenzierbar. Dann sind die folgenden Aussagen äquivalent:

- i. f ist konvex.
 - ii. $f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x})$ für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$.
 - iii. $\mathbf{H}_f(\mathbf{x})$ ist positiv semidefinit für alle $\mathbf{x} \in \mathcal{X}$.
- (i): f ist konvex genau dann wenn die Sehne zwischen zwei Punkten des Graphen nie *unter* dem Funktionsgraphen verläuft.
 - (ii): f ist konvex genau dann wenn die Tangente an f nie *über* dem Funktionsgraphen verläuft.
 - (iii): f ist konvex genau dann wenn die **Hesse-Matrix** positiv semidefinit ist (d.h.: nicht-negative Krümmung in alle Richtungen an jeder Stelle).

Beweis: → *Anhang*.

Konvexität & Spektrum der Hesse-Matrix

Für $f \in \mathcal{C}^2$ ist $\mathbf{H}_f(\mathbf{x})$ symmetrisch

$\implies \mathbf{H}_f(\mathbf{x})$ hat reelle Eigenwerte λ_i und orthonormale Eigenvektoren $\mathbf{v}_i$:

- Lokale Taylor-Approximation um $\mathbf{x}$:

$$f(\mathbf{x} + \mathbf{h}) \approx f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_f(\mathbf{x}) \mathbf{h} = f(\mathbf{x}) + \nabla f(\mathbf{x}) \mathbf{h} + \frac{1}{2} \sum_{i=1}^n \lambda_i (\mathbf{v}_i^\top \mathbf{h})^2$$

- $\lambda_i > 0$: in $\mathbf{v}_i$ -Richtung um $\mathbf{x}$ herum **konvex** (nach oben gekrümmt)
- $\lambda_i < 0$: in $\mathbf{v}_i$ -Richtung um $\mathbf{x}$ herum **konkav** (nach unten gekrümmt)
- $|\lambda_i|$ misst Stärke der Krümmung in $\mathbf{v}_i$ -Richtung

Wrap-up

Heute gelernt

- **Konvexkombinationen** = gewichtete Durchschnitte; **konvexe Hülle** = kleinste konvexe Obermenge
- **Konvexe Mengen** enthalten alle Verbindungsstrecken; Konvexität bleibt unter Schnitten, Produkten, affinen Abbildungen und Summen erhalten
- **Projektionen** auf nichtleere abgeschlossene konvexe Mengen (in vollständigen Skalarprodukträumen) existieren und sind eindeutig
- **Konvexe Funktionen**: **Epigraph** konvex $\iff$ Sehnen-Ungleichung; **Jensen-Ungleichung**
- $\mathcal{C}^2$ -Charakterisierung: f konvex $\iff$ **Hesse-Matrix** überall PSD

Nächste Vorlesung

- Optimierung I – u.a.: warum konvexe Optimierungsprobleme “gutartig” sind

Self-Check: Konvexe Funktionen

Welche der folgenden Funktionen ist konvex?

1. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = ax + b, a, b \in \mathbb{R}.$

2. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = x^4.$

3. $f: \mathbb{R}_+ \rightarrow \mathbb{R}, f(x) = \sqrt{x}.$

4. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = e^x.$

5. $f: \mathbb{R}_+ \rightarrow \mathbb{R}, f(x) = \ln x.$

Self-Check: Klassifikation

Klassifizieren Sie: **konvex**, **strikt konvex** (d.h., die Ungleichung gilt strikt für $x \neq y$, $\lambda \in (0, 1)$) oder **keins von beiden**?

1. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = |x|$
2. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = e^x$
3. $f: \mathbb{R} \rightarrow \mathbb{R}, f(x) = ax + b, a, b \in \mathbb{R}$
4. $f: \mathbb{R}_+ \rightarrow \mathbb{R}, f(x) = \sqrt{x}$

Anhang

Konvexe Hülle - Beispiel im $\mathbb{R}^2$

(Zusatzbeispiel)

Sei $\mathcal{X} = \{(0, 0), (2, 0), (1, 2)\} \subset \mathbb{R}^2$ (die Ecken eines Dreiecks).

Extrempunkte:

Alle drei Punkte in $\mathcal{X}$ sind *Extrempunkte*, da sie nur durch $w_i = 1, w_j = 0 \ \forall j \neq i$ erreicht werden können.

Konvexe Hülle:

$\text{conv}(\mathcal{X})$ ist die Menge aller Punkte der Form

$$\mathbf{x} = w_1 \begin{pmatrix} 0 \\ 0 \end{pmatrix} + w_2 \begin{pmatrix} 2 \\ 0 \end{pmatrix} + w_3 \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

mit $w_1, w_2, w_3 \geq 0$ und $w_1 + w_2 + w_3 = 1$.

Konkreter Punkt: Für $w_1 = w_2 = w_3 = \frac{1}{3}$:

$$\mathbf{x} = \frac{1}{3} \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \frac{1}{3} \begin{pmatrix} 2 \\ 0 \end{pmatrix} + \frac{1}{3} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 1 \\ \frac{2}{3} \end{pmatrix}$$

Dieser Punkt (Schwerpunkt!) liegt im Inneren des Dreiecks.

↩ zurück: „Konvexe Hülle“

Beispiel: Schnitt konvexer Mengen

(Zusatzbeispiel)

Konkrete Mengen im $\mathbb{R}^2$:

- $\mathcal{X}_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$ (Halbraum, konvex)
- $\mathcal{X}_2 = \{(x, y) \in \mathbb{R}^2 : x \geq 0\}$ (Halbraum, konvex)
- $\mathcal{X}_3 = \{(x, y) \in \mathbb{R}^2 : y \geq 0\}$ (Halbraum, konvex)

Schnitt:

$$\mathcal{S} = \mathcal{X}_1 \cap \mathcal{X}_2 \cap \mathcal{X}_3 = \{(x, y) : x \geq 0, y \geq 0, x + y \leq 1\}$$

Dies ist ein Dreieck mit Ecken $(0, 0)$, $(1, 0)$, $(0, 1)$ - offensichtlich konvex!

Generell:

Polyeder (als Schnitte von Halbräumen) sind konvex – wichtig für *lineare Programmierung* (Optimierung unter linearen Nebenbedingungen)!

↔ zurück: „Konvexe Mengen: Eigenschaften“

Konvexitätserhaltung: Beweis

- (i) Schnitt:

Sei $\mathbf{x}, \mathbf{y} \in \mathcal{S}$, $\lambda \in [0, 1]$ und $\mathbf{z} = \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$.

Dann gilt $\mathbf{x}, \mathbf{y} \in \mathcal{S} \implies \mathbf{x}, \mathbf{y} \in \mathcal{X}_i \forall i \in I$.

$\mathcal{X}_i$ konvex $\forall i \in I \implies \mathbf{z} \in \mathcal{X}_i \forall i \in I \implies \mathbf{z} \in \mathcal{S}$.

- (ii) Kartesisches Produkt:

Seien $(\mathbf{x}_1, \dots, \mathbf{x}_k), (\mathbf{y}_1, \dots, \mathbf{y}_k) \in \mathcal{X}_1 \times \dots \times \mathcal{X}_k; \lambda \in [0, 1]$.

Weil $\mathcal{X}_i$ konvex, ist auch

$$\begin{aligned} & \lambda(\mathbf{x}_1, \dots, \mathbf{x}_k) + (1 - \lambda)(\mathbf{y}_1, \dots, \mathbf{y}_k) \\ &= (\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{y}_1, \dots, \lambda \mathbf{x}_k + (1 - \lambda) \mathbf{y}_k) \in (\mathcal{X}_1 \times \dots \times \mathcal{X}_k) \end{aligned}$$

- (iii) Affine Abb.:

Sei $\mathbf{y}_1 = f(\mathbf{x}_1), \mathbf{y}_2 = f(\mathbf{x}_2) \in f(\mathcal{X})$ für $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{X}; \lambda \in [0, 1]$. Dann gilt:

$$\begin{aligned} \lambda \mathbf{y}_1 + (1 - \lambda) \mathbf{y}_2 &= \lambda(\mathbf{A} \mathbf{x}_1 + \mathbf{b}) + (1 - \lambda)(\mathbf{A} \mathbf{x}_2 + \mathbf{b}) \\ &= \mathbf{A}(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) + \mathbf{b} \\ &= f(\lambda \mathbf{x}_1 + (1 - \lambda) \mathbf{x}_2) \in f(\mathcal{X}). \end{aligned}$$

- (iv) Summe:

Folgt aus (ii) und (iii):

$\mathcal{X}_1 \times \mathcal{X}_2$ ist konvex, $f(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1 + \mathbf{x}_2$ ist linear, also ist auch $f(\mathcal{X}_1 \times \mathcal{X}_2) = \mathcal{X}_1 \oplus \mathcal{X}_2$ konvex.

Projektionstheorem: Beweisskizze

- **Existenz:**

Eine Minimierungsfolge ist beschränkt und besitzt daher einen Grenzwert (in $\mathbb{R}^n$: Bolzano-Weierstraß;
allgemein: Parallelogrammgleichung $\rightarrow$ Cauchy-Folge + Vollständigkeit von V);
 $\mathcal{X}$ abgeschlossen $\implies$ dieser Grenzwert liegt in $\mathcal{X}$

- **Eindeutigkeit:**

Angenommen, es gäbe $\hat{\mathbf{x}}_1 \neq \hat{\mathbf{x}}_2$ mit demselben minimalen Abstand d zu $\mathbf{x}$.

Für jedes $\lambda \in [0, 1]$ gilt wegen Konvexität

$\mathbf{z} = \lambda \hat{\mathbf{x}}_1 + (1 - \lambda) \hat{\mathbf{x}}_2 \in \mathcal{X}$ und nach der Dreiecksungleichung:

$$\|\mathbf{x} - \mathbf{z}\| \leq \lambda \|\mathbf{x} - \hat{\mathbf{x}}_1\| + (1 - \lambda) \|\mathbf{x} - \hat{\mathbf{x}}_2\| = d$$


Wegen der Minimalität von d gilt sogar $\|\mathbf{x} - \mathbf{z}\| = d$.

Wähle Mittelpunkt $\mathbf{z} = (\hat{\mathbf{x}}_1 + \hat{\mathbf{x}}_2)/2$ und setze $\mathbf{u} := \mathbf{x} - \hat{\mathbf{x}}_1$,

$\mathbf{v} := \mathbf{x} - \hat{\mathbf{x}}_2$.

Aus der Definition von $\mathbf{z}$ folgt $\mathbf{x} - \mathbf{z} = \frac{\mathbf{u} + \mathbf{v}}{2}$, $\mathbf{z} - \hat{\mathbf{x}}_1 = \frac{\mathbf{u} - \mathbf{v}}{2}$,

und diese sind orthogonal: $\langle \mathbf{x} - \mathbf{z}, \mathbf{z} - \hat{\mathbf{x}}_1 \rangle = \frac{1}{4} \langle \mathbf{u} + \mathbf{v}, \mathbf{u} - \mathbf{v} \rangle = \frac{1}{4} (\|\mathbf{u}\|^2 - \|\mathbf{v}\|^2) = \frac{1}{4} (d^2 - d^2) = 0$



Damit also auch

$$\begin{aligned}\|\mathbf{x} - \hat{\mathbf{x}}_1\|^2 &= \|(\mathbf{x} - \mathbf{z}) + (\mathbf{z} - \hat{\mathbf{x}}_1)\|^2 \\ &= \|\mathbf{x} - \mathbf{z}\|^2 + \|\mathbf{z} - \hat{\mathbf{x}}_1\|^2 \\ &> \|\mathbf{x} - \mathbf{z}\|^2,\end{aligned}$$

$$[(\mathbf{x} - \mathbf{z}) \perp (\mathbf{z} - \hat{\mathbf{x}}_1)]$$

also: *Widersprüchlich* $d^2 > d^2 \implies$ Projektion eindeutig. ■

↔ zurück: „Konvexe Mengen: Projektionstheorem“

Konvexe Funktionen: Beweise I

(Beweis der $\mathcal{C}^2$ -Charakterisierung; (i) $\iff$ (ii))

- (i) $\implies$ (ii): Setze $t = (1 - \lambda)$. Dann gilt

$$\begin{aligned} & f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \\ \iff & f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) - f(\mathbf{x}) \leq (1 - \lambda)[f(\mathbf{y}) - f(\mathbf{x})] \\ \iff & f(\mathbf{y}) - f(\mathbf{x}) \geq \frac{f(\mathbf{x} + t(\mathbf{y} - \mathbf{x})) - f(\mathbf{x})}{t} \quad \text{für } t > 0. \quad \blacksquare \end{aligned}$$

(Für $t \rightarrow 0$ erhalten wir (ii).)

- (ii) $\implies$ (i): Sei $\mathbf{x}, \mathbf{y} \in \mathcal{X}$, $\lambda \in [0, 1]$ und definiere $\mathbf{z} = \lambda \mathbf{x} + (1 - \lambda)\mathbf{y}$. (ii) impliziert

$$\begin{aligned} \lambda f(\mathbf{x}) &\geq \lambda f(\mathbf{z}) + \lambda \nabla f(\mathbf{z})(\mathbf{x} - \mathbf{z}) \\ \text{und } (1 - \lambda)f(\mathbf{y}) &\geq (1 - \lambda)f(\mathbf{z}) + (1 - \lambda)\nabla f(\mathbf{z})(\mathbf{y} - \mathbf{z}). \end{aligned}$$

Summieren wir die beiden Ungleichungen, erhalten wir

$$\lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}) \geq f(\mathbf{z}) + 0 = f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}). \quad \blacksquare$$

Konvexe Funktionen: Beweise II

(Beweis der $\mathcal{C}^2$ -Charakterisierung, fortgesetzt; (ii) $\iff$ (iii))

- (ii) $\implies$ (iii): Sei $\mathbf{h} \in \mathbb{R}^n$ beliebig. Nach Definition der zweiten Ableitung gilt für $t \rightarrow 0$,

$$\begin{aligned} f(\mathbf{x} + t\mathbf{h}) - f(\mathbf{x}) - t\nabla f(\mathbf{x})\mathbf{h} - \frac{t^2}{2}\mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h} &= o(t^2) \quad [\text{Taylorpolynom}] \\ \iff \mathbf{h}^\top \mathbf{H}_f(\mathbf{x})\mathbf{h} &= 2 \frac{f(\mathbf{x} + t\mathbf{h}) - f(\mathbf{x}) - t\nabla f(\mathbf{x})\mathbf{h}}{t^2} + o(1) \\ &\geq 0 + o(1) \rightarrow 0. \end{aligned}$$

(Da die linke Seite nicht von t abhängt, folgt (iii).)

- (iii) $\implies$ (ii): *Taylor's Theorem*: für $f \in \mathcal{C}^2$ und jedes $\mathbf{x}, \mathbf{y} \in \mathcal{X} \exists t \in (0, 1)$, so dass:

$$\begin{aligned} f(\mathbf{y}) &= f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x}) + \frac{1}{2}(\mathbf{y} - \mathbf{x})^\top \mathbf{H}_f(\mathbf{x} + t(\mathbf{y} - \mathbf{x}))(\mathbf{y} - \mathbf{x}) \\ &\geq f(\mathbf{x}) + \nabla f(\mathbf{x})(\mathbf{y} - \mathbf{x}) \end{aligned}$$

Konvexe Funktionen: Beweis der Eigenschaften

(Proposition Summe/Skalierung/Maximum/Grenzwert)

Seien $\mathbf{x}, \mathbf{y} \in \mathcal{X}$, $\lambda \in [0, 1]$ und $\mathbf{z} := \lambda \mathbf{x} + (1 - \lambda) \mathbf{y}$.

(ii) Skalierung: Für $f = cf_1$ mit $c \geq 0$ gilt

$$\begin{aligned} f(\mathbf{z}) &= c f_1(\mathbf{z}) \\ &\leq c [\lambda f_1(\mathbf{x}) + (1 - \lambda) f_1(\mathbf{y})] \\ &= \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \end{aligned}$$

Die Ungleichung folgt aus der Konvexität von f_1 ; Multiplikation mit $c \geq 0$ erhält ihre Richtung.

(iv) Grenzwert: Wegen der Konvexität von f_n gilt für jedes n

$$f_n(\mathbf{z}) \leq \lambda f_n(\mathbf{x}) + (1 - \lambda) f_n(\mathbf{y}).$$

Da alle beteiligten Folgen konvergieren, können wir den Grenzwert bilden:

$$\begin{aligned} f(\mathbf{z}) &= \lim_{n \rightarrow \infty} f_n(\mathbf{z}) \\ &\leq \lambda \lim_{n \rightarrow \infty} f_n(\mathbf{x}) + (1 - \lambda) \lim_{n \rightarrow \infty} f_n(\mathbf{y}) \\ &= \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}). \end{aligned}$$