Optimierung I: Grundlagen & Verfahren erster Ordnung

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)
Material: Thomas Nagler
LMU München

Version: 26.08.2026

Opener-Quiz

Opener-Quiz

Beim Reinkommen: QR-Code scannen und die 2 Einstiegsfragen beantworten.

Frage 1: Sei $[a, b] \subset \mathbb{R}$ und $f\colon [a, b] \to \mathbb{R}$. Wir wollen $f(x) = 0$ lösen. Welche der folgenden Aussagen ist wahr?

1. Falls f stetig ist, hat $f(x) = 0$ genau eine Lösung.
2. Falls $f(a) < 0$ und $f(b) > 0$, hat $f(x) = 0$ mindestens eine Lösung.
3. Falls f streng monoton ist, hat $f(x) = 0$ höchstens eine Lösung.

Frage 2: Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ konvex und differenzierbar mit $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$. Was folgt?

1. $\boldsymbol{x}^\star$ ist ein lokales, aber nicht unbedingt globales Minimum.
2. $\boldsymbol{x}^\star$ ist ein globales Minimum.
3. $\boldsymbol{x}^\star$ kann auch ein Sattelpunkt sein.

Verwendete Vorkenntnisse

- *Gradient* $\nabla f(\boldsymbol{x})$ für $f : \mathbb{R}^n \to \mathbb{R}$; $\nabla f(\boldsymbol{x})^\top$ ist die Richtung des steilsten *Anstiegs*
- *Hesse-Matrix* $\boldsymbol{H}_f(\boldsymbol{x})$ als Matrix zweiter Ableitungen: *Krümmung*
- *Konvexität von Mengen und Funktionen*
- **Analysis:**
  - Notwendige Bedingung für Extrema: $f'(x^\star) = 0$
  - Hinreichende Bedingung für Minima: $f'(x^\star) = 0$ **und** $f''(x^\star) > 0$
  - Zwischenwertsatz
- **Lineare Algebra:**
  - *positiv definite* Matrizen
  - *Konditionszahl* einer Matrix

Motivation & Einführung

Einführung

- Ein **nichtlineares Gleichungssystem** für $f\colon \mathbb{R}^n \to \mathbb{R}^m$ hat die Form

$$f(\boldsymbol{x}) = \mathbf{0}$$

  $\to$ Wie finden wir Lösungen $\boldsymbol{x}^\star$?
- Ein **unbeschränktes Optimierungsproblem** für $f\colon \mathbb{R}^n \to \mathbb{R}$ hat die Form

$$\boldsymbol{x}^\star = \arg\min_{\boldsymbol{x}} f(\boldsymbol{x}) \quad \text{bzw.} \quad \boldsymbol{x}^\star = \arg\max_{\boldsymbol{x}} f(\boldsymbol{x}),$$

  $\implies$ Falls f *differenzierbar* ist, muss $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$ gelten.
- Ein *beschränktes Optimierungsproblem* stellt zusätzliche Bedingungen an Lösungen $\boldsymbol{x}^\star$:

$$\boldsymbol{x}^\star = \arg\min_{\boldsymbol{x} \in S} f(\boldsymbol{x})$$

  mit *Nebenbedingungen* $S \subset \mathbb{R}^n$, z.B:
  - $S = \{\boldsymbol{x} \in \mathbb{R}^n \colon g_i(\boldsymbol{x}) = 0, i = 1, \dots, m\}$ (Gleichungsnebenbedingungen) und/oder
  - $S = \{\boldsymbol{x} \in \mathbb{R}^n \colon h_j(\boldsymbol{x}) \leq 0, j = 1, \dots, p\}$ (Ungleichungsnebenbedingungen) $\to$ Kapitel *Optimierung II*
- Alle diese Probleme werden meist *iterativ* gelöst.

Warum Optimierung?

Statistik und ML bestehen großteils aus Optimierungsproblemen:

- **Maximum-Likelihood-Schätzung** für i.i.d. $y_1, \ldots, y_n$ mit Dichte $f_Y(y \mid \boldsymbol{\theta})$:

$$\widehat{\boldsymbol{\theta}}_{\text{ML}} = \arg\max_{\boldsymbol{\theta}} \left(\sum_{i=1}^{n} \log f_Y(y_i \mid \boldsymbol{\theta}) \right)$$

- **Supervised Learning** mit *Verlustfunktion* $L(y, \hat{y})$ und Vorhersagen $\hat{y}_i := p_\theta(\boldsymbol{x}_i)$ aus Features $\boldsymbol{x}_i$:

$$\widehat{\boldsymbol{\theta}} = \arg\min_{\boldsymbol{\theta}} \left(\sum_{i=1}^{n} L(y_i, p_\theta(\boldsymbol{x}_i)) \right)$$

  z.B. **Lineare Regression:** $\widehat{\boldsymbol{\beta}} = \arg\min_\beta \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2$ oder **Neuronale Netze**.

- **Regularisierte Regression (Ridge: $p = 2$, Lasso: $p = 1$):**

$$\widehat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \left(\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_p^p \right)$$

  kann als *beschränktes Optimierungsproblem* mit $S = \{\boldsymbol{\beta} : \ \|\boldsymbol{\beta}\|_p^p \leq c(\lambda)\}$ formuliert werden:

$$\arg \min_{\boldsymbol{\beta}:\ \|\boldsymbol{\beta}\|_p^p \leq c(\lambda)} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2$$

Nichtlineare Gleichungssysteme

Lösbarkeit

Theorem

Sei $f\colon [a,b] \to \mathbb{R}$ streng monoton, stetig und $f(a) \cdot f(b) \leq 0$.

Dann hat die Gleichung $f(x) = 0$ eine eindeutige Lösung.

Beweis.

- Weil f streng monoton ist, kann es höchstens eine Lösung geben.
- Falls $f(a) \cdot f(b) = 0$, ist $f(a) = 0$ oder $f(b) = 0$.
- $f(a) \cdot f(b) < 0$ bedeutet, dass $f(a)$ und $f(b)$ verschiedenes Vorzeichen haben.
- Nehmen wir o.B.d.A. an, dass $f(a) < 0 < f(b)$.
  Weil f stetig ist, gibt es nach dem Zwischenwertsatz ein $x \in (a,b)$, sodass $f(x) = 0$. ■

Anmerkung:
Diese Bedingungen sind *hinreichend*, aber nicht *notwendig* für Lösbarkeit.

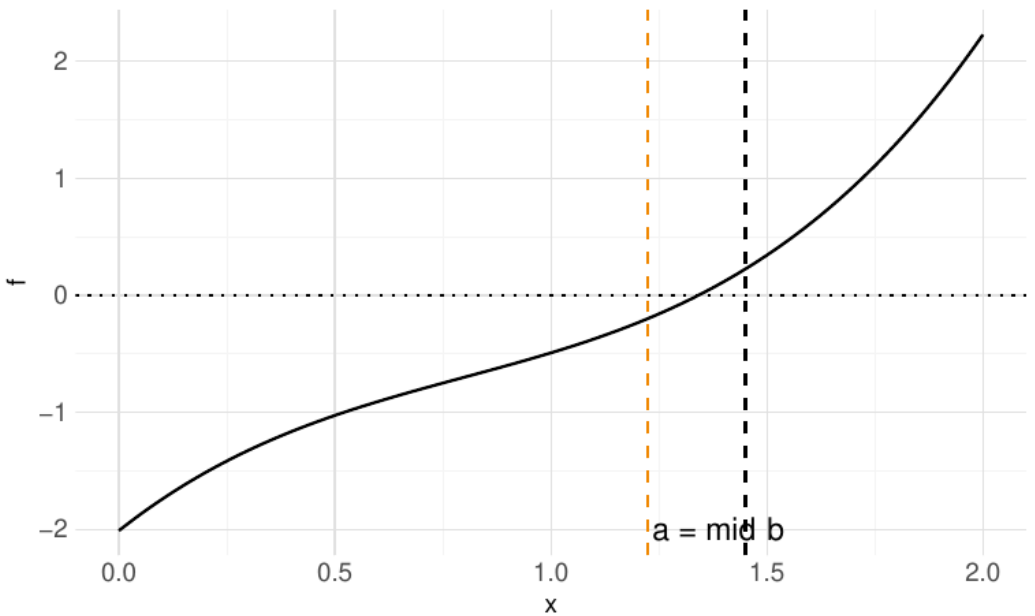
Bisektionsverfahren

Ziel:
Löse $f(x) = 0$, $f: \mathbb{R} \to \mathbb{R}$.

Bisektionsverfahren

- *Inputs:*
  - **Stetige** Funktion f
  - Zwei Punkte a, b mit $f(a) \cdot f(b) < 0$ (also: unterschiedliche Vorzeichen)
  - Ziel-Genauigkeit ϵ: $\left|x^\star - x^{(k)}\right| < \epsilon$

```r
bisect <- function(f, a, b, eps) {
  while (b - a > eps) {
    mid <- (a + b) / 2
    if (f(a) * f(mid) <= 0) b <- mid else a <- mid
  }
  return((a + b) / 2)
}
```



Kommentare:

- Kann auch verwendet werden, um die **Umkehrfunktion** $f^{-1}(y)$ auszuwerten: Löse $f(x) - y = 0$.
- Der Algorithmus benötigt $\left\lceil \log_2 \left(\frac{b-a}{\epsilon} \right) \right\rceil$ Schritte.
- Eignet sich nur für **univariate** Funktionen.

Newton-Raphson-Verfahren

Ziel:
Löse $f(x) = 0$ für $f\colon \mathbb{R} \to \mathbb{R}$ differenzierbar.

Idee:
Approximiere f lokal durch eine Tangente und finde deren Nullstelle.

Taylor-Entwicklung um $x^{(k)}$:

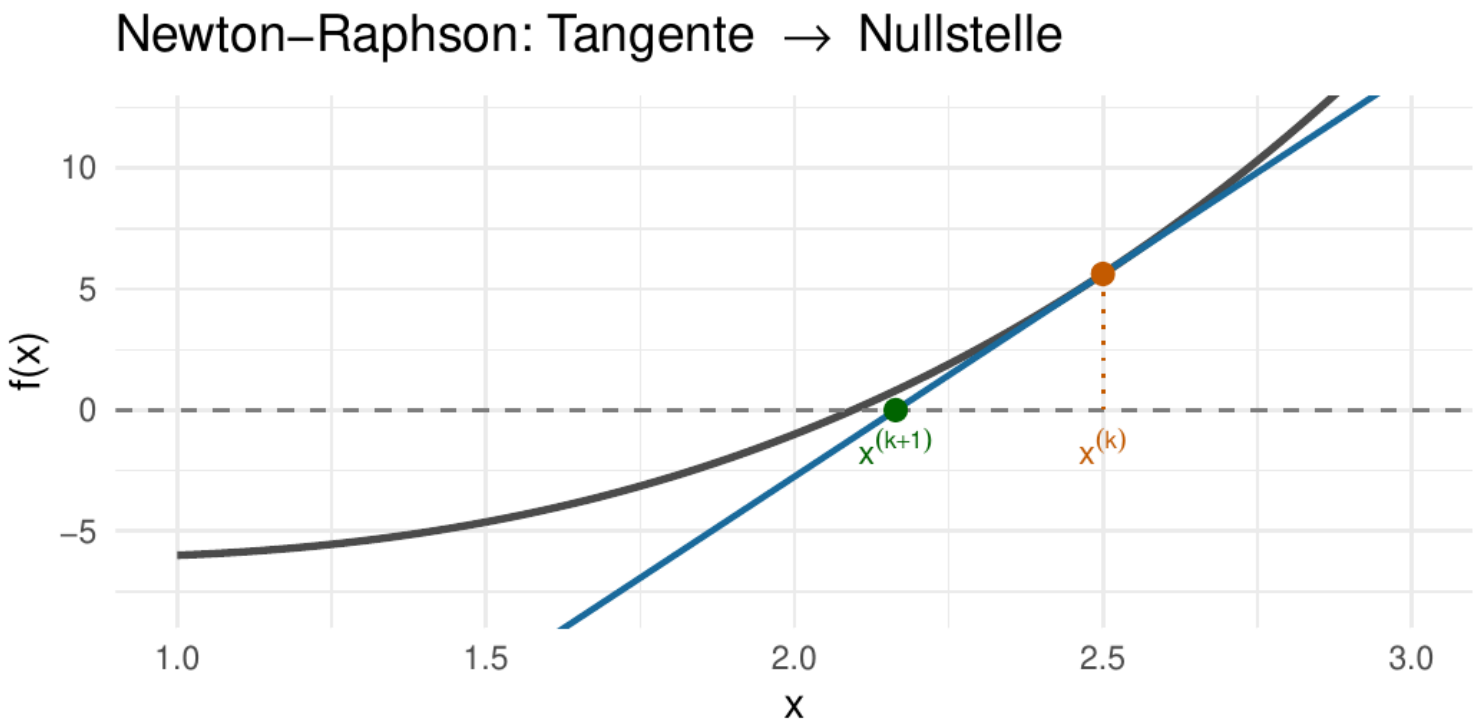
$$f(x) \approx f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) \overset{!}{=} 0$$

Newton-Raphson-Iteration

$$x^{(k+1)} = x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$$

Geometrisch:
Schnittpunkt der Tangente an f im Punkt $x^{(k)}$ mit der x-Achse.

Newton-Raphson: Visualisierung



- **Konvergenz:** Quadratisch nahe einer *einfachen* Nullstelle ($f'(x^\star) \neq 0$): $e_{k+1} \approx C \cdot e_k^2$ für $e_k := \left|x^{(k)} - x^\star\right|$ mit $C = \frac{|f''(x^\star)|}{2|f'(x^\star)|}$
- **Verbindung zur Optimierung:**
  Newton für $\min f(\boldsymbol{x})$ ist Newton-Raphson für $\nabla f(\boldsymbol{x}) = \mathbf{0}^\top$!
  ($\rightarrow$ Kapitel *Optimierung II*)
- Für multivariate Probleme heute: *Gradientenverfahren*.

Das Optimierungsproblem

Das Optimierungsproblem

Ziel:
Finde das Minimum von $f(\boldsymbol{x})$, $f\colon \mathbb{R}^n \to \mathbb{R}$.

$$\boldsymbol{x}^\star = \arg\min_{\boldsymbol{x}\in\mathbb{R}^n} f(\boldsymbol{x})$$

Wichtige Beobachtungen:

- Maximierung ist äquivalent: $\max f(\boldsymbol{x}) = -\min(-f(\boldsymbol{x}))$
- Ist f differenzierbar, muss am Minimum gelten:

$$\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$$

  $\Longrightarrow$ Optimierung $\simeq$ Lösen von Gleichungssystemen!

- **Problem:**
  $\nabla f(\boldsymbol{x}) = \mathbf{0}^\top$ meist nicht analytisch lösbar
  $\Longrightarrow$ *iterative Verfahren* nötig

Konvexe Funktionen in der Optimierung

- Konvexe Funktionen ergeben *einfachere* Optimierungsprobleme:

Proposition

Für jede differenzierbare, konvexe Funktion $f\colon \mathbb{R}^n \to \mathbb{R}$ sind die folgenden Aussagen äquivalent:

i. $\boldsymbol{x}^\star$ ist ein globales Minimum von f.

ii. $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$.

- Das bedeutet:
  - Jeder kritische Punkt ist ein lokales Minimum.
  - Jedes lokale Minimum ist ein globales Minimum.

Wenn wir ein konvexes Optimierungsproblem lösen, finden wir garantiert ein *globales* Optimum!

(Beweis → Anhang)

Strikt konvexe Funktionen

- Um die **Eindeutigkeit** von Minima zu garantieren, benötigen wir eine stärkere Form von Konvexität.

Def.: Strikte Konvexität

Sei $\mathcal{X}$ konvex. Eine Funktion $f\colon \mathcal{X} \to \mathbb{R}$ heißt **strikt konvex**, falls für alle $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{X}$ mit $\boldsymbol{x} \neq \boldsymbol{y}$ und alle $\lambda \in (0, 1)$ gilt

$$f(\lambda \boldsymbol{x} + (1 - \lambda)\boldsymbol{y}) < \lambda f(\boldsymbol{x}) + (1 - \lambda) f(\boldsymbol{y}).$$

Proposition

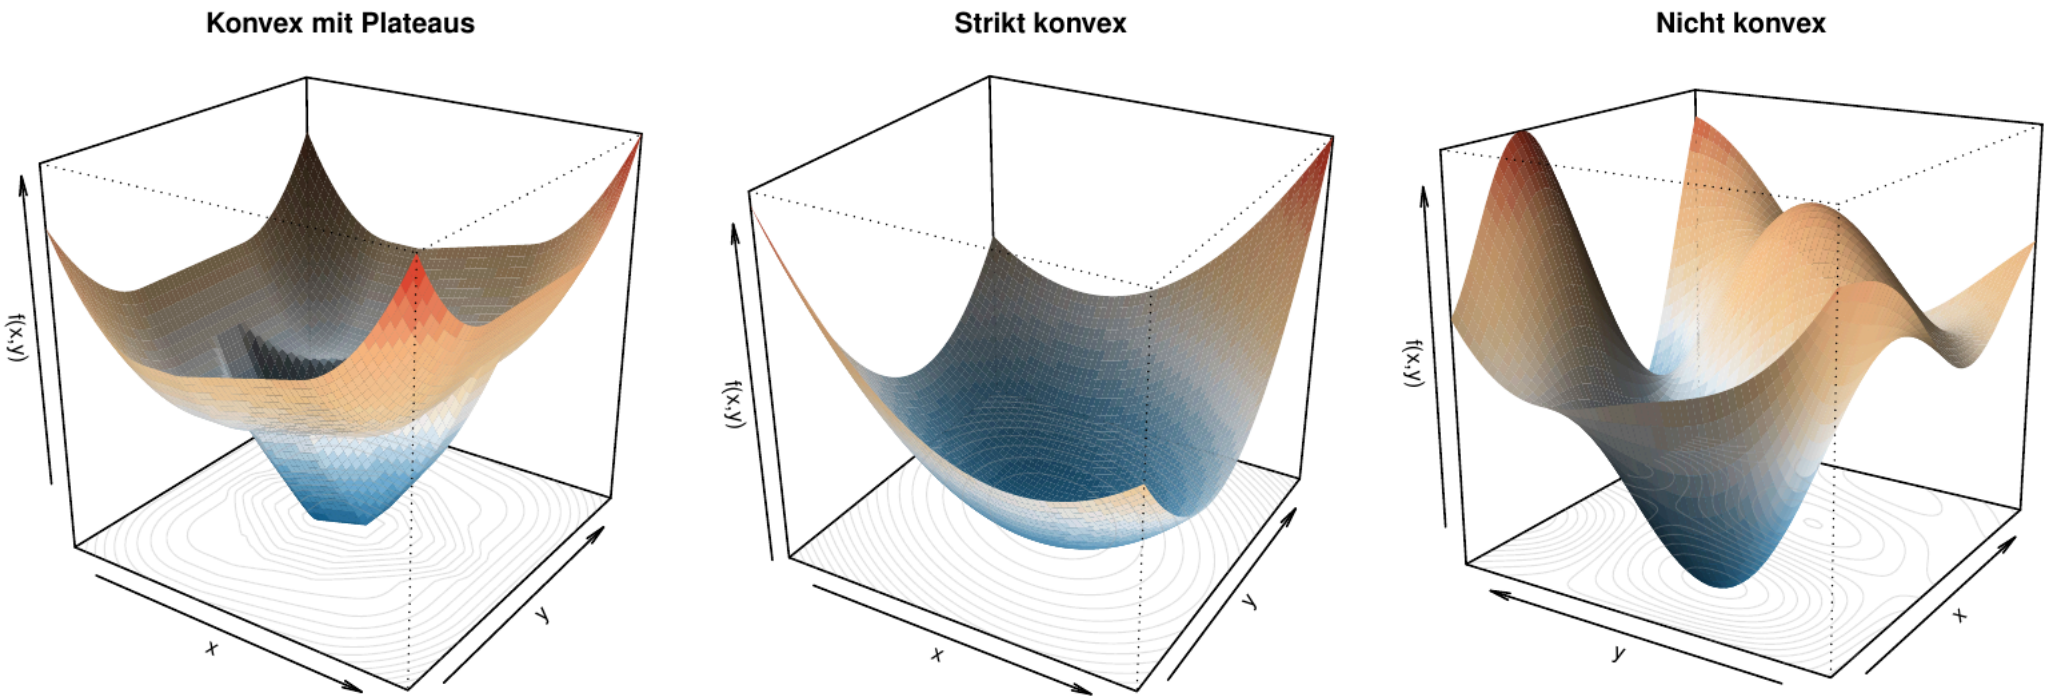
Sei $f\colon \mathbb{R}^n \to \mathbb{R}$ *strikt konvex.*

Dann hat f höchstens ein Minimum.

Wenn wir ein *strikt* konvexes Optimierungsproblem lösen, finden wir garantiert das *eindeutige globale* Optimum!

- Gilt auch mit konvexer zulässiger Menge;
  Spezialfall *Projektionstheorem*: quadrierte Distanz $\|\boldsymbol{x} - \boldsymbol{y}\|^2$ ist strikt konvex in $\boldsymbol{y}$.

Optimierungslandschaften



- Links: konvex mit Plateaus – Minimums*region*, flache Teilstücke
- Mitte: strikt konvex – “Schüssel” mit eindeutigem Minimum.
- Rechts: nicht konvex – mehrere Täler und lokale Minima ohne Garantie für Globalität.

(Non-)Konvexe Optimierung in ML & Statistik

1. **Strikt konvexe Probleme** haben eine einzige *eindeutige* Lösung, z.B.

- KQ-Probleme $\min_\beta \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2$ für $\boldsymbol{X}$ mit vollem Spaltenrang ($\boldsymbol{H} = 2\boldsymbol{X}^\top \boldsymbol{X} \succ 0$)
- genereller: ML-Schätzung für GLMs mit kanonischem Link (konkave Log-Likelihood $\implies$ neg. LL konvex)
- Graph LASSO (regularisierte Kovarianzschätzung)
- Ridge Regression $\min_\beta \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_2^2$, strikt konvex für $\lambda > 0$ ($\rightarrow$ Übung) & Elastic Net
- Support Vector Machines: konvexer Hinge-Loss $L(y, \hat{y}) = \max(0, 1 - y\hat{y})$ + strikt konvexe L_2-Regularisierung (strikt konvex nur in $\boldsymbol{w}$ — der Achsenabschnitt b ist i.A. *nicht* eindeutig)

2. **Konvexe Probleme** (nicht *strikt*!) haben manchmal nur eine *Lösungsmenge*, z.B. LASSO, Quantilregression, KQ-Probleme ohne vollen Spaltenrang

3. **Nicht-konvexe Probleme** mit (lokalen Minima und) *Sattelpunkten*
   $\implies$ verschiedene Initialisierungen/Algorithmen $\rightarrow$ (evtl.) verschiedene Lösungen, zum Beispiel:

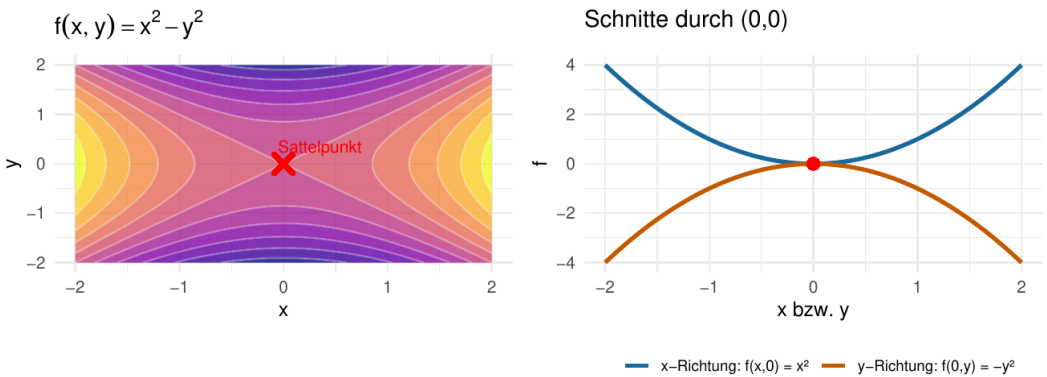
- **Neuronale Netze**
- **Clusteranalysen** (z.B. k-*means*, Mischverteilungsmodelle) - **Bäume** (CART, Random Forest, XGBoost, ...)
- *Latente Variablen* (GLMM, SEM, Faktoranalysen, ...)
- Variablenselektion (L_0, *Best Subset*, ...)
- Embeddings (tSNE, UMAP, `word2vec`, ...)
- *Matrix-Completion*
- **Hyperparameter-Tuning**: meist nichtmal stetig $\rightarrow$ Gitter-, Zufalls- oder Bayes-Optimierung

Sattelpunkte

Bei **nicht-konvexen** Funktionen: $\nabla f(\boldsymbol{x}) = \mathbf{0}^\top$ bedeutet nicht unbedingt Minimum!

Definition: Sattelpunkt

Ein *kritischer Punkt* $\boldsymbol{x}^\star$ mit $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$ heißt **Sattelpunkt**, wenn $\boldsymbol{H}_f(\boldsymbol{x}^\star)$ *indefinit* ist (sowohl positive als auch negative Eigenwerte).



Beispiel $f(x, y) = x^2 - y^2$:

- $\nabla f = (2x, -2y) = \mathbf{0}^\top$ bei $(0, 0)^\top$ ✓
- $\boldsymbol{H}_f = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$: Eigenwerte $2 > 0$, $-2 < 0$
  $\Longrightarrow$ **indefinit**
- $(0, 0)^\top$ ist Minimum in x-Richtung, Maximum in y-Richtung

Konsequenzen:

- In vielen hochdimensionalen, nicht-konvexen Modellen treten Sattelpunkte auf.
- In hohen Dimensionen sind sie i.A. häufiger als lokale Minima.

Optimalitätsbedingungen: Zusammenfassung

Für $f : \mathbb{R}^n \to \mathbb{R}$ zweimal stetig differenzierbar:

Notwendige Bedingung (1. Ordnung)

$\boldsymbol{x}^\star$ lokales Minimum $\implies$ $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$ ($\boldsymbol{x}^\star$ ist *stationärer Punkt*)

Hinreichende Bedingung (2. Ordnung)

$\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$ und $\boldsymbol{H}_f(\boldsymbol{x}^\star) \succ 0$ $\implies$ $\boldsymbol{x}^\star$ ist lokales Minimum

Klassifikation *stationärer Punkte* $\left(\nabla f = \mathbf{0}^\top\right)$:

$\boldsymbol{H}_f(\boldsymbol{x}^\star)$	**Punkt ist...**
$\succ 0$ (positiv definit)	*Striktes* lokales Minimum
$\prec 0$ (negativ definit)	*Striktes* lokales Maximum
indefinit	Sattelpunkt
semidefinit, aber nicht definit	Unklar, weitere Analyse nötig

So wichtig:

Für **konvexe Funktionen** ist jedes *lokale* Minimum auch **global** (keine *Sattelpunkte*)!

Iterative Optimierungsverfahren

Taxonomie: Optimierungsverfahren

Klassifikation nach verwendeter **Ableitungsinformation**:

Ordnung	Verwendet	Beispiele
0-te Ordnung	nur $f(\boldsymbol{x})$	*Nelder-Mead*, Gittersuche
1-te Ordnung	$f, \nabla f$	*Gradient Descent*, *Momentum GD*, *SGD*
2-te Ordnung	$f, \nabla f, \boldsymbol{H}_f$	*Newton* ($\rightarrow$ Kapitel *Optimierung II*)

Trade-off:

- 0-te Ordnung: robust, keine Ableitungen nötig, aber langsam
- Höhere Ordnung $\rightarrow$ schnellere Konvergenz, aber teurer pro Schritt
- In der Praxis oft: Superlineare Verfahren (z.B. *Quasi-Newton (BFGS)*, $\rightarrow$ Kapitel *Optimierung II*) als Kompromiss zwischen 1. und 2. Ordnung

Nelder-Mead: Ableitungsfreie Optimierung

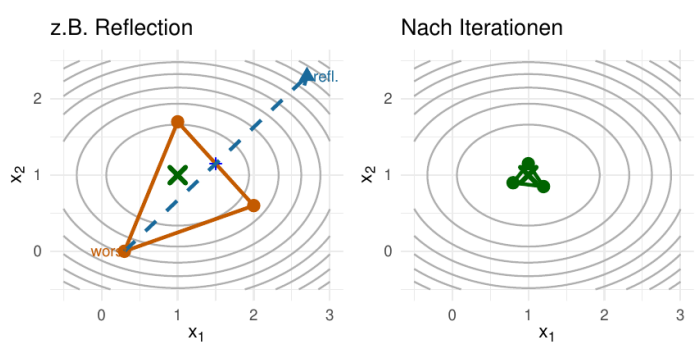
0-te Ordnung: Verwendet nur Funktionswerte $f(\boldsymbol{x})$, keine Ableitungen.

Simplex-Methode

- Arbeitet mit einem *Simplex*: $n+1$ Punkte in $\mathbb{R}^n$ (Dreieck in 2D, Tetraeder in 3D)
- Iterativ: ersetze schlechtesten Punkt durch besseren

Simplex-Operationen: (*Interaktive Demo*)

1. ***Reflection:*** Spiegle schlechtesten Punkt am Schwerpunkt der anderen
2. ***Expansion:*** Gehe weiter in vielversprechende Richtung
3. ***Contraction:*** Ziehe zusammen wenn Reflection nicht hilft
4. ***Shrink:*** Verkleinere gesamten Simplex zum besten Punkt hin



Nelder-Mead: Eigenschaften

Wann `Nelder-Mead` verwenden?

Situation	Geeignet?
Ableitungen nicht verfügbar	✓
Niedrige Dimension ($n \leq 10$)	✓
Nicht-glatte Zielfunktion	✓
Hohe Dimension ($n > 50$)	× (zu langsam)
Präzise Konvergenz nötig	× (i.A. keine Garantien)

Komplexität:
$O(n)$ Funktionsauswertungen pro Iteration, meist *viele* Iterationen nötig.

Fazit:
Robuste Methode für "schwierige" Probleme ohne Ableitungen, aber langsam. Oft als **Startpunktsuche** vor gradientenbasierten Methoden verwendet.

Gradientenabstieg

Gradientenabstieg: Die Kernidee

Der Gradient zeigt bergauf:

$\Longrightarrow$ Der negative Gradient zeigt bergab!

Gradientenabstieg (Gradient Descent / GD)

Die Iterationsvorschrift ist gegeben durch:

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \gamma \nabla f\left(\boldsymbol{x}^{(k)}\right)^\top$$

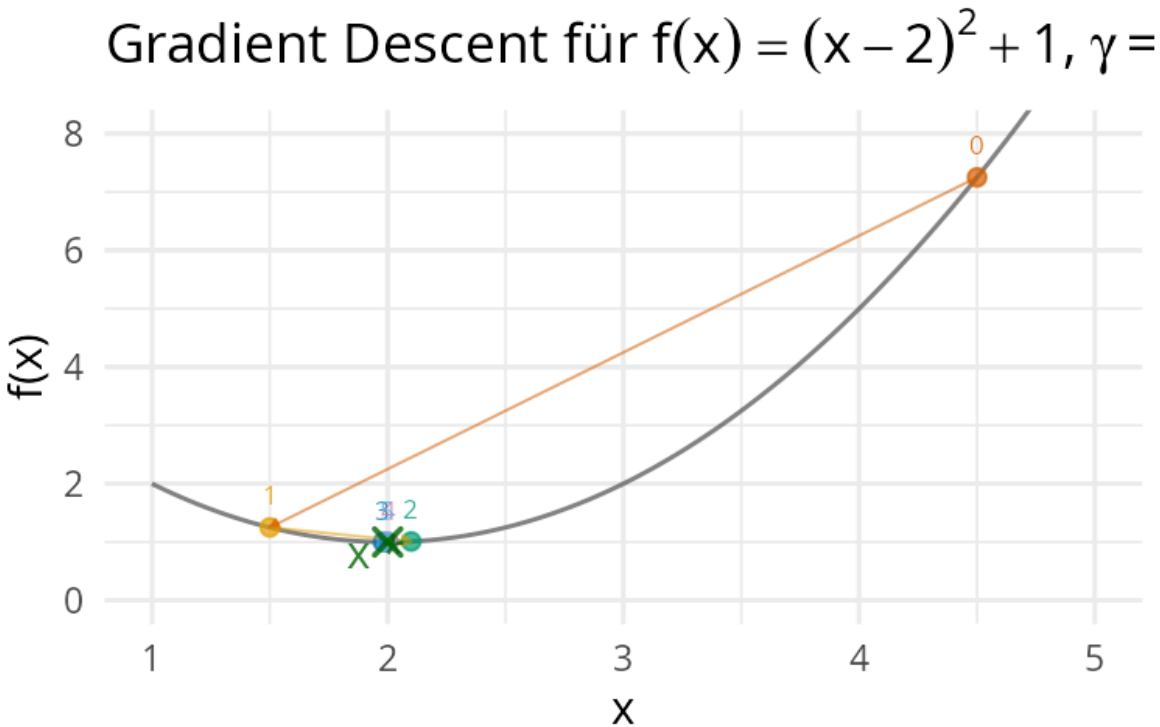
- $\gamma > 0$: *Schrittweite* (*learning rate*)
- $-\nabla f\left(\boldsymbol{x}^{(k)}\right)^\top$: Richtung des steilsten Abstiegs an Stelle $\boldsymbol{x}^{(k)}$

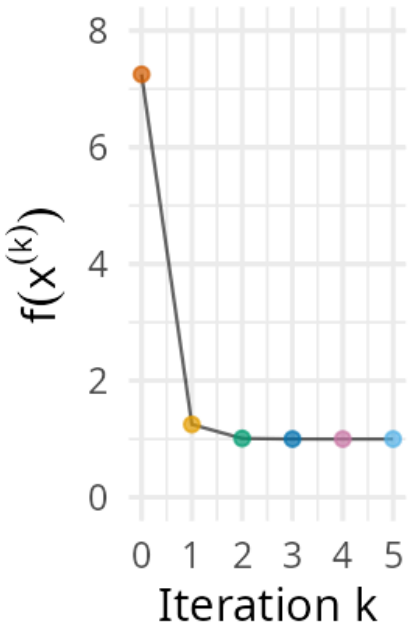
Intuition: Gehe immer in die Richtung, in der es am steilsten bergab geht.

$-\nabla f(\boldsymbol{x})^\top$ ist für *jedes* differenzierbare f eine Abstiegsrichtung, solange $\nabla f(\boldsymbol{x}) \neq \mathbf{0}^\top$ – sie zeigt aber i.A. *nicht direkt* auf das Minimum!
Falls *Konvexität* gilt, ist jeder stationäre Punkt dann bereits *global* optimal.

Bemerkung:

Gradientenabstieg: $f : \mathbb{R} \to \mathbb{R}$





k	x^(k)	f'(x^(k))
0	4.500	5.000
1	1.500	-1.000
2	2.100	0.200
3	1.980	-0.040
4	2.004	0.008
5	1.999	-0.002

Idee:

Starte bei $x^{(0)}$ und verbessere schrittweise:

$$x^{(k+1)} = x^{(k)} - \gamma f'\left(x^{(k)}\right)$$

Beispiel Gradientenabstieg: Schritt für Schritt

Problem:
Minimiere $f(x) = (x-2)^2 + 1$ mit Startwert $x^{(0)} = 4.5$, Schrittweite $\gamma = 0.6$

Ableitung:
$f'(x) = 2x - 4$

Iterationen:

$$
\begin{aligned}
x^{(0)} &= 4.5 \\
x^{(1)} &= x^{(0)} - 0.6 \cdot f'(x^{(0)}) = 4.5 - 0.6 \cdot (2 \cdot 4.5 - 4) = 4.5 - 3 = 1.5 \\
x^{(2)} &= x^{(1)} - 0.6 \cdot f'(x^{(1)}) = 1.5 - 0.6 \cdot (2 \cdot 1.5 - 4) = 1.5 + 0.6 = 2.1 \\
x^{(3)} &= 2.1 - 0.6 \cdot (2 \cdot 2.1 - 4) = 1.98 \\
&\vdots
\end{aligned}
$$

Konvergenz:
$x^{(k)} \to 2$ (analytisches Minimum: $f'(x^\star) = 0 \implies x^\star = 2$)

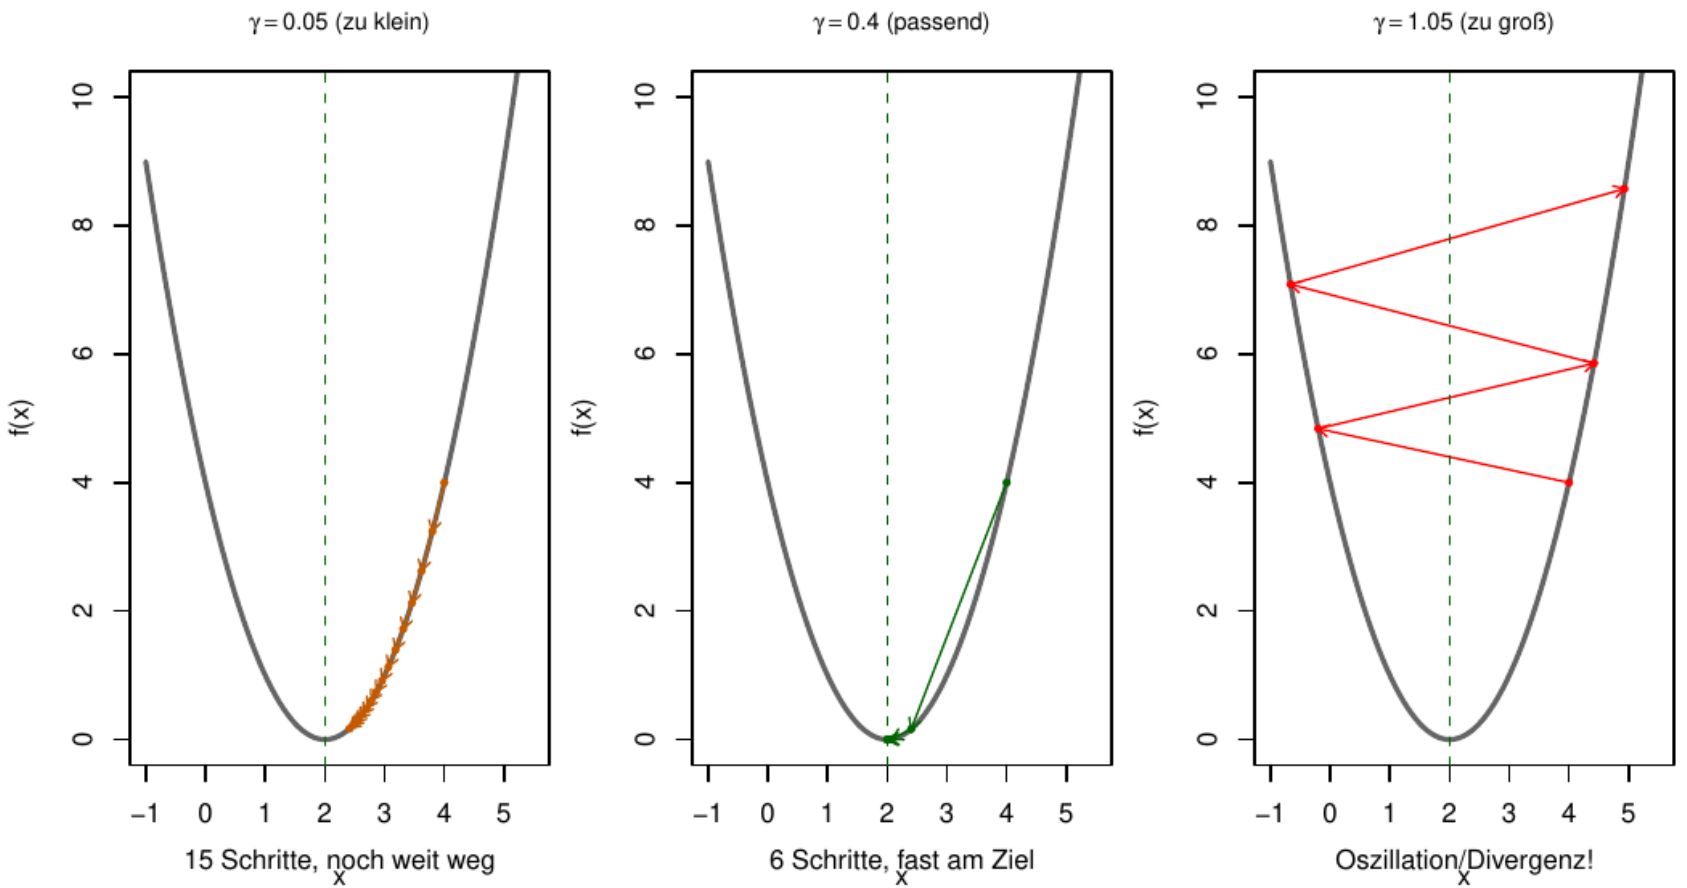
Quiz: Gradient Descent

Sei $f(\boldsymbol{x}) = x_1^2 + x_2^2$ und $\boldsymbol{x}^{(0)} = (4, 3)^\top$ mit Schrittweite $\gamma = 0.25$.

Frage: Wo liegt $\boldsymbol{x}^{(1)}$ nach einem GD-Schritt?

1. $(2, 1.5)^\top$
2. $(0, 0)^\top$
3. $(3, 2)^\top$
4. $(8, 6)^\top$

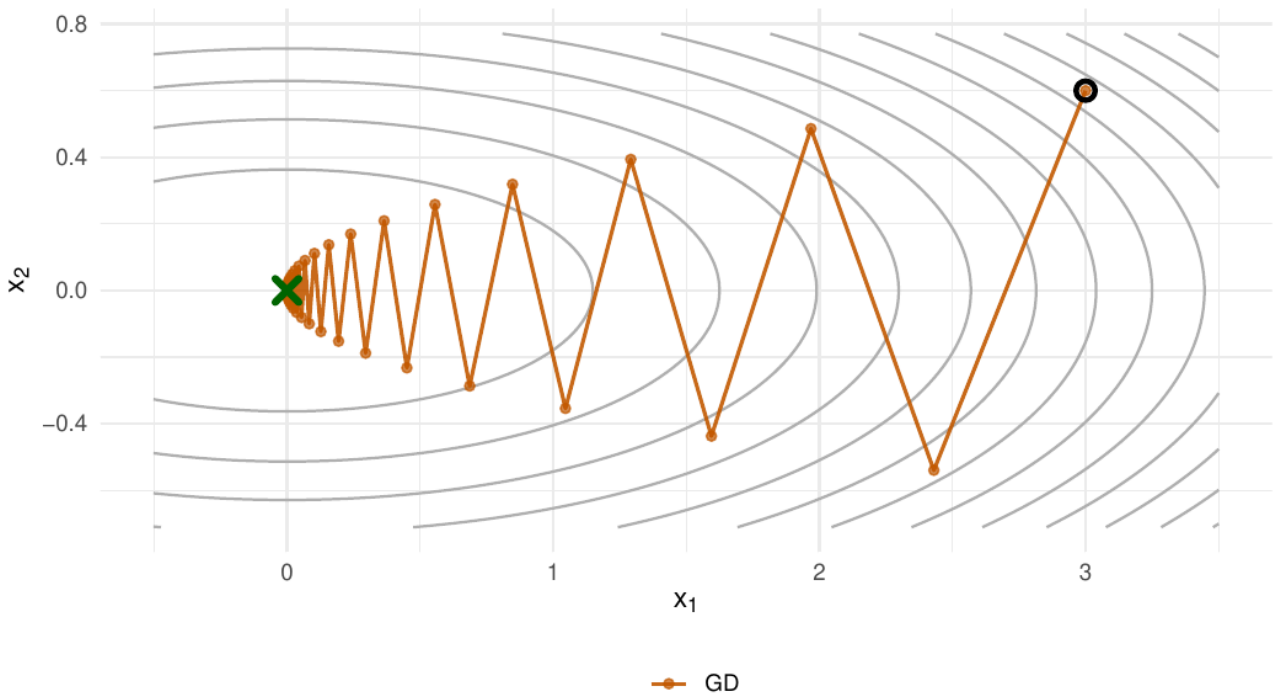
Die Rolle der Schrittweite γ



Dilemma:
γ muss

- klein genug sein für *Konvergenz*,
- aber groß genug für *Effizienz*...

Problem: Zick-Zack bei schlechter Kondition



Bei **hoher Konditionszahl** $\kappa\left(\boldsymbol{H}_f\right)$ oszilliert GD oft stark.

- $\kappa\left(\boldsymbol{H}_f\right)$ ist groß, wenn die Krümmung von f in verschiedenen Richtungen stark unterschiedlich ist (z.B. “Canyons”)
- Wann und wie schnell konvergiert GD also überhaupt? $\rightarrow$ jetzt
- **Interaktiv ausprobieren:** Shiny-App: Gradient Descent

↩ zurück: „Konvergenzrate & Kondition”

Konvergenz: Lipschitz-stetiger Gradient

Def.: Lipschitz-Stetigkeit

Eine Funktion $f : \mathbb{R}^n \to \mathbb{R}^m$ heißt **Lipschitz-stetig** mit Konstante $L > 0$, falls:

$$\|f(\boldsymbol{x}) - f(\boldsymbol{y})\| \leq L\|\boldsymbol{x} - \boldsymbol{y}\| \quad \forall \boldsymbol{x}, \boldsymbol{y}$$

Intuition:
Funktionswerte ändern sich *höchstens* L-mal so schnell wie Funktionsargumente. Je größer L, desto "gezackter" kann f sein $\implies$ kleinere Schrittweiten γ nötig.

- *Lipschitz-stetiger Gradient* ∇f:
  $\|\nabla f(\boldsymbol{x}) - \nabla f(\boldsymbol{y})\| \leq L\|\boldsymbol{x} - \boldsymbol{y}\|$
  $\to$ Steigung von f ändert sich nicht zu abrupt.
- Äquivalent (für zweimal differenzierbares f):
  $\|\boldsymbol{H}_f(\boldsymbol{x})\|_2 \leq L \; \forall \, \boldsymbol{x}$ mit $L = \sup_{\boldsymbol{x}} \max_i |\lambda_i \left(\boldsymbol{H}_f(\boldsymbol{x})\right)|$
  $\to$ Krümmung von f ist beschränkt
- L heißt auch *Lipschitz-Konstante* von f (oder ∇f)

Konvergenzrate bei Konvexität

Konvergenzrate: Gradientenabstieg

Für *konvexes* f mit *Lipschitz-stetigem* Gradient ∇f und *Lipschitz-Konstante* L, das sein Minimum in $\boldsymbol{x}^\star$ annimmt,
gilt für *Schrittweite* $\gamma \leq \frac{1}{L}$ und alle Iterationen $k \geq 1$:

$$f\left(\boldsymbol{x}^{(k)}\right) - f(\boldsymbol{x}^\star) \leq \frac{\|\boldsymbol{x}^{(0)} - \boldsymbol{x}^\star\|^2}{2\gamma k}$$

Interpretation:
Der *Funktionswertabstand* $f\left(\boldsymbol{x}^{(k)}\right) - f(\boldsymbol{x}^\star)$ sinkt mit Rate $O(1/k)$
$\implies$ es braucht $k \sim 1/\varepsilon$ Schritte, bis er $< \varepsilon$ ist (... relativ langsam!)

Achtung:
Über den Abstand $\left\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star\right\|$ sagt diese Schranke *nichts*.

Starke Konvexität: lineare Konvergenzrate

Def.: Starke Konvexität

Eine *zweimal differenzierbare* Funktion f heißt **stark konvex** (μ-*strongly convex*) mit Parameter $\mu > 0$, falls:

$$\boldsymbol{H}_f(\boldsymbol{x}) - \mu \boldsymbol{I} \succeq 0 \quad \forall \boldsymbol{x}$$

(ableitungsfrei äquivalent: $f(\boldsymbol{x}) - \frac{\mu}{2} \|\boldsymbol{x}\|^2$ ist konvex)

- $\mu = \inf_{\boldsymbol{x}} \lambda_{\min}(\boldsymbol{H}_f(\boldsymbol{x}))$: minimale (positive!) Krümmung von f

Konvergenzrate: Stark konvexer Gradientenabstieg

Für *stark konvexes* f mit Parameter $\mu > 0$ und *Lipschitz-stetigem* Gradienten mit *Lipschitz-Konstante* L gilt für $\gamma = \frac{1}{L}$:

$$f\left(\boldsymbol{x}^{(k)}\right) - f(\boldsymbol{x}^\star) \leq \rho^k \cdot \left(f\left(\boldsymbol{x}^{(0)}\right) - f\left(\boldsymbol{x}^\star\right)\right), \quad \rho = 1 - \frac{\mu}{L} < 1$$

$\Longrightarrow$ schnellere Konvergenz bei starker Konvexität

Konvergenzrate & Kondition

Verallgemeinerte *Kondition* für Funktionen:

- $\rho = \frac{\kappa_f - 1}{\kappa_f}$ mit Konditionszahl $\kappa_f = \frac{\sup_{\boldsymbol{x}} \lambda_{\max}(\boldsymbol{H}_f(\boldsymbol{x}))}{\inf_{\boldsymbol{x}} \lambda_{\min}(\boldsymbol{H}_f(\boldsymbol{x}))} = \frac{L}{\mu}$
- Großes $\kappa_f \implies \rho \to 1 \implies$ langsame Konvergenz:
  Zick-Zack-Trajektorien durch “Canyons” mit anisotropischer Krümmung
  ($\to$ genau das vorhin gesehene Zick-Zack-Problem!)
- Für quadratische Funktionen $f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$ mit $\boldsymbol{A} \succ 0$ ist $\boldsymbol{H}_f = \boldsymbol{A}$,
  also $\kappa_f = \kappa(\boldsymbol{A})$
  $\to$ selbe *Konditionszahl* wie in der numerischen linearen Algebra!

Abbruchkriterien (Stopping Criteria)

Wann beenden wir die Iteration $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - \gamma \nabla f(\boldsymbol{x}^{(k)})^\top$?

Typische Abbruchkriterien

1. *Gradient klein:* $\left\| \nabla f(\boldsymbol{x}^{(k)}) \right\| < \varepsilon_{\text{grad}}$
2. *Funktionswert stagniert:* $\frac{\left| f(\boldsymbol{x}^{(k+1)}) - f(\boldsymbol{x}^{(k)}) \right|}{\left| f(\boldsymbol{x}^{(k)}) \right|} < \varepsilon_f$
3. *Iterationen ausgeschöpft:* $k > k_{\max}$

- Üblicherweise kombiniert man mehrere Kriterien
- Typische Werte: $\varepsilon_{\text{grad}} \approx 10^{-6}$ bis 10^{-8}, $k_{\max} \approx 1000$ bis 10000

Achtung:

Kriterien können bei nicht stark konvexen oder schlecht konditionierten Problemen versagen — $\|\nabla f\|$ oder $\left| f^{(k+1)} - f^{(k)} \right|$ kann beliebig klein werden, obwohl $\boldsymbol{x}^{(k)}$ noch weit vom Optimum entfernt ist!

Line Search: Adaptive Schrittweite

Problem:
Eine feste Schrittweite γ ist oft suboptimal.

Idee:
Wähle $\gamma^{(k)}$ in jedem Schritt so, dass f "genug" sinkt.

Backtracking Line Search (*Armijo*)

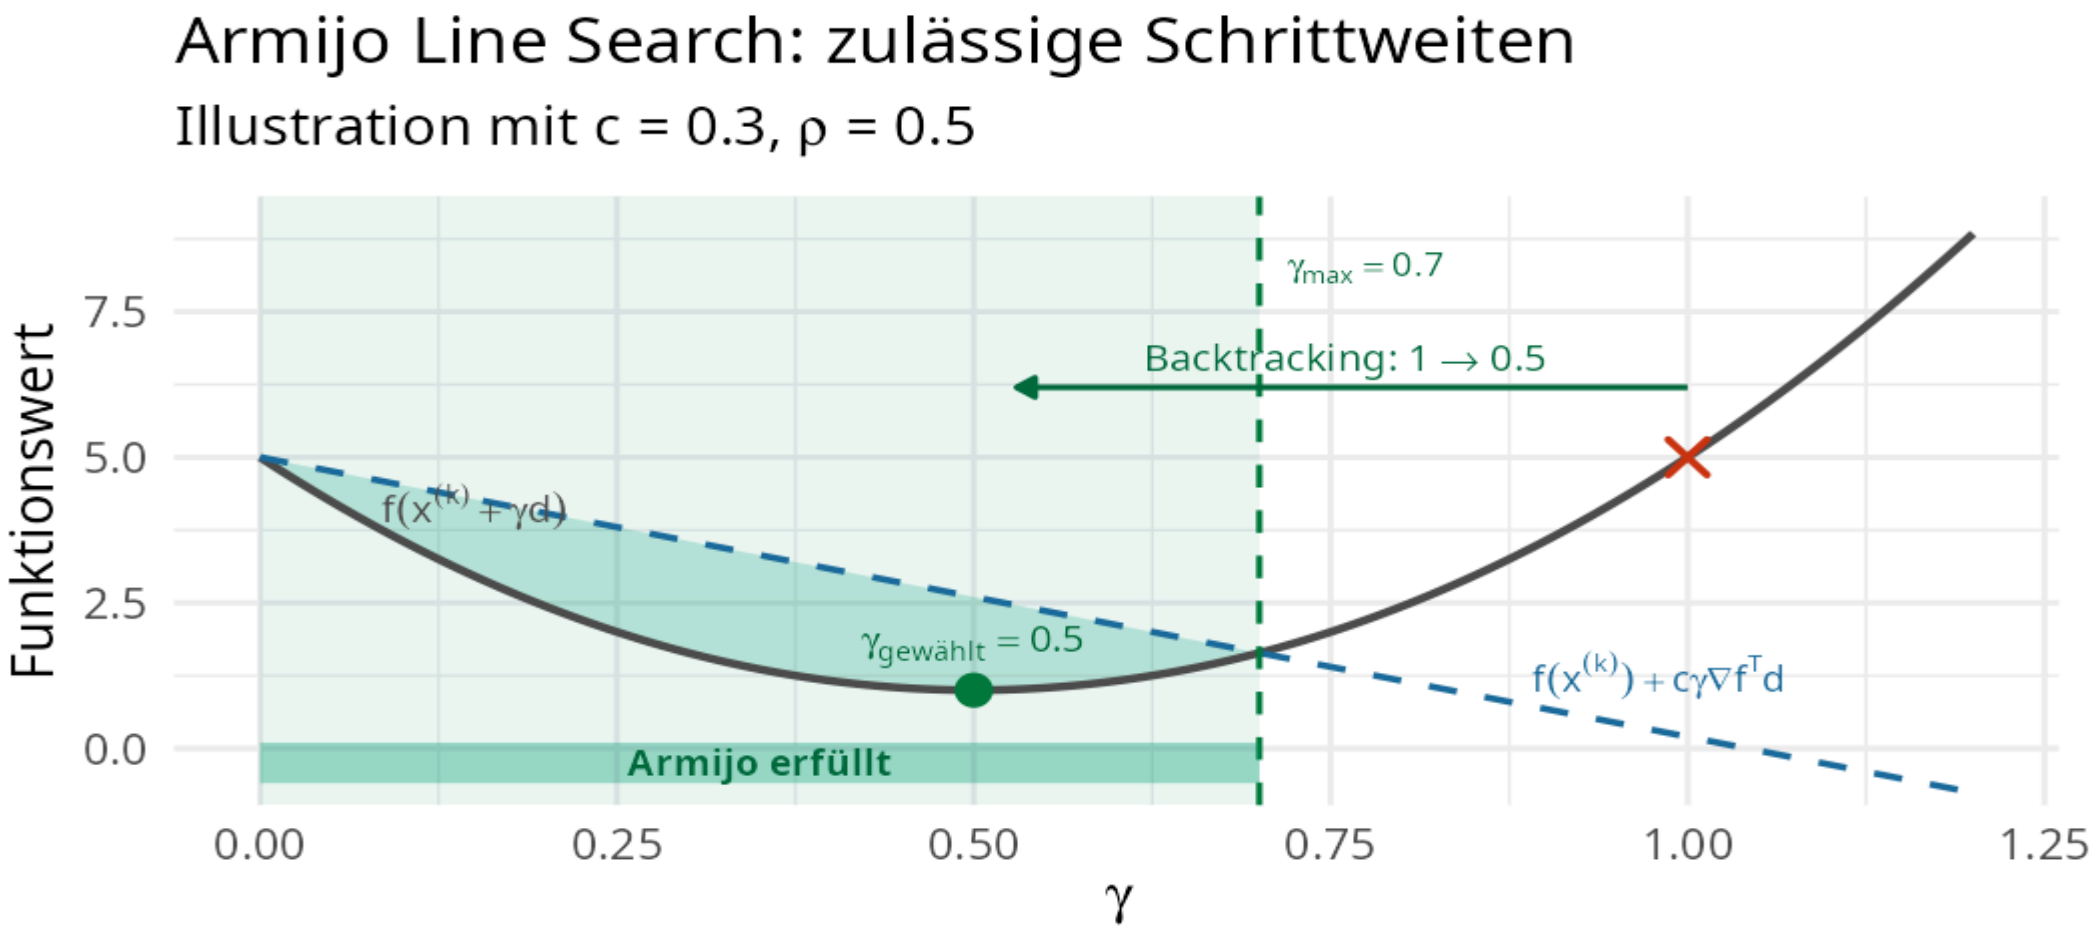
Gegeben: Richtung $\boldsymbol{d} = -\nabla f(\boldsymbol{x}^{(k)})^\top$, Parameter $c \in (0,1)$, $\rho \in (0,1)$

1. Starte mit $\gamma = 1$
2. `while` $f\left(\boldsymbol{x}^{(k)} + \gamma \boldsymbol{d}\right) > f\left(\boldsymbol{x}^{(k)}\right) + c\gamma \nabla f\left(\boldsymbol{x}^{(k)}\right)\boldsymbol{d}$:
   - $\gamma \leftarrow \rho\gamma$ (verkleinere Schrittweite)
3. `return` γ

Armijo-Bedingung:
Fordert "genügend Abstieg" — Funktionswert muss proportional zum erwarteten Abstieg sinken.

Achtung:
ρ ist hier der *Verkleinerungsfaktor* der Schrittweite — nicht die Konvergenzrate $\rho = 1 - \mu/L$ von vorhin.

Line Search: Visualisierung



Typische Parameter: $c = 10^{-4}$, $\rho = 0.5$

Quasi-Newton: *BFGS* verwendet automatisch *Line Search* ($\rightarrow$ Kapitel *Optimierung II*)

Zusammenfassung

Self-Check: Gradientenabstieg

1. Sei $f(\boldsymbol{x}) = x_1^2 + 4x_2^2$ und $\boldsymbol{x}^{(0)} = (2, 1)^\top$ mit Schrittweite $\gamma = 0.25$. Wo liegt $\boldsymbol{x}^{(1)}$?

1. $(1, -1)^\top$
2. $(1.5, 0)^\top$
3. $(1, 0)^\top$
4. $(0, 0)^\top$

2. Welche Aussagen sind wahr?

1. GD konvergiert für jede Schrittweite $\gamma > 0$ gegen ein lokales Minimum.
2. Für konvexes f mit L-Lipschitz-Gradient und $\gamma \leq 1/L$ gilt: Fehler $= O(1/k)$.
3. Für stark konvexes f konvergiert GD linear, d.h. Fehler $= O(\rho^k)$ mit $\rho < 1$.
4. Ist $\left\|\nabla f(\boldsymbol{x}^{(k)})\right\|$ klein, dann ist $\boldsymbol{x}^{(k)}$ nahe am Minimum.

Zusammenfassung

Methode	Wann verwenden?
Bisektion	univariate Nullstellen; braucht nur Stetigkeit + Vorzeichenwechsel
Newton-Raphson	Nullstellen glatter Funktionen; quadratische Konvergenz
Nelder-Mead	Optimierung ohne Ableitungen, niedrige Dimension ($n \leq 10$)
Gradient Descent	Optimierung großer differenzierbarer Probleme; einfache Implementierung

- **Konvexität** $\implies$ jedes lokale Minimum ist global;
  strikte Konvexität $\implies$ *höchstens ein* Minimum (also eindeutig, falls existent)
  - **Konvergenz von GD:**
  - Rate $O(1/k)$ (konvex) bzw. $O(\rho^k)$ (stark konvex)
  - $\rho = 1 - \frac{\mu}{L}$ bei $\gamma = \frac{1}{L}$
  - alternativ Schrittweite adaptiv mit *Line Search*

Im Kapitel Optimierung II:
Newton-Verfahren (“Newton-Raphson für $\nabla f = \mathbf{0}^\top$”), Quasi-Newton (BFGS), Momentum & SGD, Optimierung unter Nebenbedingungen (Lagrange/KKT)

Anhang

Fixpunktiteration erster Ordnung

(in der Vorlesung nur als Bemerkung: GD ist die Fixpunktiteration für $\nabla f(\boldsymbol{x})^\top = \mathbf{0}$)

Ziel: Löse $f(\boldsymbol{x}) = \mathbf{0}$, $f\colon \mathbb{R}^n \to \mathbb{R}^n$ monoton steigend (d.h. $(f(\boldsymbol{x}) - f(\boldsymbol{y}))^\top (\boldsymbol{x} - \boldsymbol{y}) \geq 0 \; \forall\, \boldsymbol{x}, \boldsymbol{y}$).

- Wir definieren die Iteration

$$\boldsymbol{x}^{(k)} = \boldsymbol{x}^{(k-1)} - \gamma f(\boldsymbol{x}^{(k-1)}).$$

- Ist f differenzierbar, erhalten wir aus einer Taylorapproximation 1. Ordnung um $\boldsymbol{x}^\star$:

$$\begin{aligned}\left\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star\right\| &\approx \left\|\boldsymbol{x}^{(k-1)} - \boldsymbol{x}^\star - \underbrace{\gamma f(\boldsymbol{x}^\star)}_{=\mathbf{0}} - \gamma \boldsymbol{J}_f(\boldsymbol{x}^\star)\left(\boldsymbol{x}^{(k-1)} - \boldsymbol{x}^\star\right)\right\| \\ &= \left\|\left(\boldsymbol{I}_n - \gamma \boldsymbol{J}_f(\boldsymbol{x}^\star)\right)\left(\boldsymbol{x}^{(k-1)} - \boldsymbol{x}^\star\right)\right\| \\ &\leq \left\|\boldsymbol{I}_n - \gamma \boldsymbol{J}_f(\boldsymbol{x}^\star)\right\| \left\|\boldsymbol{x}^{(k-1)} - \boldsymbol{x}^\star\right\|.\end{aligned}$$

- Falls $\rho := \left\|\boldsymbol{I}_n - \gamma \boldsymbol{J}_f(\boldsymbol{x}^\star)\right\| < 1$, gilt *lokal* (für Startwerte nahe genug an $\boldsymbol{x}^\star$)

$$\left\|\boldsymbol{x}^{(k)} - \boldsymbol{x}^\star\right\| = O(\rho^k)$$

- Exakt mit diesem ρ und *global* gilt das nur für affines f — dort verschwindet der oben weggelassene Restterm.

↩ zurück: „Gradientenabstieg: Die Kernidee"

Fixpunktiteration erster Ordnung

Vorteile:

- Simples Verfahren auch für multivariate Funktionen
- Schnelle Konvergenz für gutartige Funktionen

Nachteile:

- Schrittweite γ muss gut gewählt sein:
  - zu klein: langsame Konvergenz
  - zu groß: gar keine Konvergenz

In der Praxis:

- Folge $\gamma_k \to 0$.
- Falls f fallend, betrachte $-f$.

Beweis: Globale Optimalität bei Konvexität

Proposition

Für jede differenzierbare, konvexe Funktion $f\colon \mathbb{R}^n \to \mathbb{R}$ sind äquivalent: (i) $\boldsymbol{x}^\star$ ist ein globales Minimum von f. (ii) $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$.

Beweis.

- $(i) \implies (ii)$: Jedes globale Minimum ist ein lokales Minimum. Dort muss $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$ gelten. ■
- $(ii) \implies (i)$: Sei $\boldsymbol{x}^\star$ ein Punkt mit $\nabla f(\boldsymbol{x}^\star) = \mathbf{0}^\top$. Dann gilt für alle $\boldsymbol{y} \in \mathbb{R}^n$

$$f(\boldsymbol{y}) \geq f(\boldsymbol{x}^\star) + \nabla f(\boldsymbol{x}^\star)(\boldsymbol{y} - \boldsymbol{x}^\star) = f(\boldsymbol{x}^\star).$$

  Also ist $\boldsymbol{x}^\star$ ein globales Minimum. ■

↩ zurück: „Konvexe Funktionen in der Optimierung"