

Optimierung I: Grundlagen & Verfahren erster Ordnung

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Opener-Quiz

Opener-Quiz

Beim Reinkommen: QR-Code scannen und die 2 Einstiegsfragen beantworten.

Frage 1: Sei $[a, b] \subset \mathbb{R}$ und $f: [a, b] \rightarrow \mathbb{R}$. Wir wollen $f(x) = 0$ lösen. Welche der folgenden Aussagen ist wahr?

1. Falls f stetig ist, hat $f(x) = 0$ genau eine Lösung.
2. Falls $f(a) < 0$ und $f(b) > 0$, hat $f(x) = 0$ mindestens eine Lösung.
3. Falls f streng monoton ist, hat $f(x) = 0$ höchstens eine Lösung.

Frage 2: Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ konvex und differenzierbar mit $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$. Was folgt?

1. $\mathbf{x}^*$ ist ein lokales, aber nicht unbedingt globales Minimum.
2. $\mathbf{x}^*$ ist ein globales Minimum.
3. $\mathbf{x}^*$ kann auch ein Sattelpunkt sein.

Verwendete Vorkenntnisse

- **Gradient** $\nabla f(\mathbf{x})$ für $f : \mathbb{R}^n \rightarrow \mathbb{R}$; $\nabla f(\mathbf{x})^\top$ ist die Richtung des steilsten *Anstiegs*
- **Hesse-Matrix** $\mathbf{H}_f(\mathbf{x})$ als Matrix zweiter Ableitungen: *Krümmung*
- **Konvexität von Mengen und Funktionen**
- **Analysis:**
 - Notwendige Bedingung für Extrema: $f'(\mathbf{x}^\star) = 0$
 - Hinreichende Bedingung für Minima: $f'(\mathbf{x}^\star) = 0$ **und** $f''(\mathbf{x}^\star) > 0$
 - Zwischenwertsatz
- **Lineare Algebra:**
 - **positiv definite** Matrizen
 - **Konditionszahl** einer Matrix

Motivation & Einführung

Einführung

- Ein **nichtlineares Gleichungssystem** für $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ hat die Form

$$f(\mathbf{x}) = \mathbf{0}$$

→ Wie finden wir Lösungen $\mathbf{x}^*$?

- Ein **unbeschränktes Optimierungsproblem** für $f: \mathbb{R}^n \rightarrow \mathbb{R}$ hat die Form

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} f(\mathbf{x}) \quad \text{bzw.} \quad \mathbf{x}^* = \arg \max_{\mathbf{x}} f(\mathbf{x}),$$

⇒ Falls f **differenzierbar** ist, muss $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ gelten.

- Ein **beschränktes Optimierungsproblem** stellt zusätzliche Bedingungen an Lösungen $\mathbf{x}^*$:

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in S} f(\mathbf{x})$$

mit **Nebenbedingungen** $S \subset \mathbb{R}^n$, z.B:

- $S = \{\mathbf{x} \in \mathbb{R}^n: g_i(\mathbf{x}) = 0, i = 1, \dots, m\}$ (Gleichungsnebenbedingungen) und/oder
 - $S = \{\mathbf{x} \in \mathbb{R}^n: h_j(\mathbf{x}) \leq 0, j = 1, \dots, p\}$ (Ungleichungsnebenbedingungen) → Kapitel *Optimierung II*
- Alle diese Probleme werden meist **iterativ** gelöst.

Warum Optimierung?

Statistik und ML bestehen grōßteils aus **Optimierungsproblemen**:

- **Maximum-Likelihood-Schätzung** für i.i.d. $y_1, \dots, y_n$ mit Dichte $f_Y(y \mid \theta)$:

$$\hat{\theta}_{\text{ML}} = \arg \max_{\theta} \left(\sum_{i=1}^n \log f_Y(y_i \mid \theta) \right)$$

- **Supervised Learning** mit Verlustfunktion $L(y, \hat{y})$ und Vorhersagen $\hat{y}_i := p_{\theta}(\mathbf{x}_i)$ aus Features $\mathbf{x}_i$:

$$\hat{\theta} = \arg \min_{\theta} \left(\sum_{i=1}^n L(y_i, p_{\theta}(\mathbf{x}_i)) \right)$$

z.B. **Lineare Regression**: $\hat{\beta} = \arg \min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$ oder **Neuronale Netze**.

- **Regularisierte Regression (Ridge: $p = 2$, Lasso: $p = 1$):**

$$\hat{\beta} = \arg \min_{\beta} \left(\|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_p^p \right)$$

kann als **beschränktes Optimierungsproblem** mit $S = \{\beta : \|\beta\|_p^p \leq c(\lambda)\}$ formuliert werden:

$$\arg \min_{\beta: \|\beta\|_p^p \leq c(\lambda)} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$$

Nichtlineare Gleichungssysteme

Lösbarkeit

Theorem

Sei $f: [a, b] \rightarrow \mathbb{R}$ streng monoton, stetig und $f(a) \cdot f(b) \leq 0$.

Dann hat die Gleichung $f(x) = 0$ eine eindeutige Lösung.

Beweis.

- Weil f streng monoton ist, kann es höchstens eine Lösung geben.
- Falls $f(a) \cdot f(b) = 0$, ist $f(a) = 0$ oder $f(b) = 0$.
- $f(a) \cdot f(b) < 0$ bedeutet, dass $f(a)$ und $f(b)$ verschiedene Vorzeichen haben.
- Nehmen wir o.B.d.A. an, dass $f(a) < 0 < f(b)$.

Weil f stetig ist, gibt es nach dem Zwischenwertsatz ein $x \in (a, b)$, sodass $f(x) = 0$. ■

Anmerkung:

Diese Bedingungen sind *hinreichend*, aber nicht *notwendig* für Lösbarkeit.

Bisektionsverfahren

Ziel:


Löse $f(x) = 0$, $f: \mathbb{R} \rightarrow \mathbb{R}$.

Bisektionsverfahren

- Inputs:

- **Stetige** Funktion f
- Zwei Punkte a, b mit $f(a) \cdot f(b) < 0$ (also: unterschiedliche Vorzeichen)
- Ziel-Genauigkeit ϵ : $|x^* - x^{(k)}| < \epsilon$

```
1 bisect <- function(f, a, b, eps) {  
2   while (b - a > eps) {  
3     mid <- (a + b) / 2  
4     if (f(a) * f(mid) <= 0) b <- mid else a <- mid  
5   }  
6   return((a + b) / 2)  
7 }
```



Kommentare:

- Kann auch verwendet werden, um die **Umkehrfunktion** $f^{-1}(y)$ auszuwerten: Löse $f(x) - y = 0$.
- Der Algorithmus benötigt $\lceil \log_2 \left(\frac{b-a}{\epsilon} \right) \rceil$ Schritte.
- Eignet sich nur für **univariate** Funktionen.

Newton-Raphson-Verfahren

Ziel:

Löse $f(x) = 0$ für $f: \mathbb{R} \rightarrow \mathbb{R}$ differenzierbar.

Idee:

Approximiere f lokal durch eine Tangente und finde deren Nullstelle.

Taylor-Entwicklung um $x^{(k)}$:

$$f(x) \approx f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) \stackrel{!}{=} 0$$


Newton-Raphson-Iteration

$$x^{(k+1)} = x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$$

Geometrisch:

Schnittpunkt der Tangente an f im Punkt $x^{(k)}$ mit der x -Achse.

Newton-Raphson: Visualisierung



- **Konvergenz:** Quadratisch nahe einer *einfachen* Nullstelle ($f'(x^*) \neq 0$): $e_{k+1} \approx C \cdot e_k^2$ für $e_k := |x^{(k)} - x^*|$ mit $C = \frac{|f''(x^*)|}{2|f'(x^*)|}$
- **Verbindung zur Optimierung:**
Newton für $\min f(x)$ ist Newton-Raphson für $\nabla f(x) = \mathbf{0}^\top$!
(→ Kapitel *Optimierung II*)
- Für multivariate Probleme heute: **Gradientenverfahren**.

Das Optimierungsproblem

Das Optimierungsproblem

Ziel:

Finde das Minimum von $f(\boldsymbol{x})$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

$$\boldsymbol{x}^* = \arg \min_{\boldsymbol{x} \in \mathbb{R}^n} f(\boldsymbol{x})$$

Wichtige Beobachtungen:

- Maximierung ist äquivalent: $\max f(\boldsymbol{x}) = -\min(-f(\boldsymbol{x}))$
- Ist f differenzierbar, muss am Minimum gelten:

$$\nabla f(\boldsymbol{x}^*) = \mathbf{0}^\top$$

$\implies$ Optimierung $\simeq$ Lösen von Gleichungssystemen!

- **Problem:**

$\nabla f(\boldsymbol{x}) = \mathbf{0}^\top$ meist nicht analytisch lösbar

$\implies$ *iterative Verfahren* nötig

Konvexe Funktionen in der Optimierung

- Konvexe Funktionen ergeben *einfachere* Optimierungsprobleme:

Proposition

Für jede differenzierbare, konvexe Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ sind die folgenden Aussagen äquivalent:

- i. $\mathbf{x}^*$ ist ein globales Minimum von f .
- ii. $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$.

- Das bedeutet:
 - Jeder kritische Punkt ist ein lokales Minimum.
 - Jedes lokale Minimum ist ein globales Minimum.

Wenn wir ein konvexes Optimierungsproblem lösen, finden wir garantiert ein *globales* Optimum!

(Beweis → *Anhang*)

Strikt konvexe Funktionen

- Um die **Eindeutigkeit** von Minima zu garantieren, benötigen wir eine stärkere Form von Konvexität.

Def.: Strikte Konvexität

Sei $\mathcal{X}$ konvex. Eine Funktion $f: \mathcal{X} \rightarrow \mathbb{R}$ heißt **strikt konvex**, falls für alle $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ mit $\mathbf{x} \neq \mathbf{y}$ und alle $\lambda \in (0, 1)$ gilt

$$f(\lambda \mathbf{x} + (1 - \lambda) \mathbf{y}) < \lambda f(\mathbf{x}) + (1 - \lambda) f(\mathbf{y}).$$

Proposition

Sei $f: \mathbb{R}^n \rightarrow \mathbb{R}$ *strikt konvex*.


Dann hat f höchstens ein Minimum.

Wenn wir ein *strikt* konvexes Optimierungsproblem lösen, finden wir garantiert das *eindeutige globale Optimum*!


- Gilt auch mit konvexer zulässiger Menge;
Spezialfall **Projektionstheorem**: quadrierte Distanz $\|\mathbf{x} - \mathbf{y}\|^2$ ist strikt konvex in $\mathbf{y}$.

Optimierungslandschaften


Konvex mit Plateaus



Strikt konvex



Nicht konvex



- Links: konvex mit Plateaus – *Minimumsregion*, flache Teilstücke
- Mitte: strikt konvex – “Schüssel” mit eindeutigem Minimum.
- Rechts: nicht konvex – mehrere Täler und lokale Minima ohne Garantie für Globalität.

(Non-)Konvexe Optimierung in ML & Statistik

1. **Strikt konvexe Probleme** haben eine einzige *eindeutige* Lösung, z.B.

- KQ-Probleme $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2$ für $\mathbf{X}$ mit vollem Spaltenrang ($\mathbf{H} = 2\mathbf{X}^\top \mathbf{X} \succ 0$)
- Ridge Regression $\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2$, strikt konvex für $\lambda > 0$ ($\rightarrow$ Übung) & Elastic Net
- genereller: ML-Schätzung für GLMs mit kanonischem Link (konkave Log-Likelihood $\implies$ neg. LL konvex)
- Support Vector Machines: konvexer Hinge-Loss $L(y, \hat{y}) = \max(0, 1 - y\hat{y})$ + strikt konvexe L_2 -Regularisierung (strikt konvex nur in $\mathbf{w}$ – der Achsenabschnitt b ist i.A. *nicht* eindeutig)
- Graph LASSO (regularisierte Kovarianzschätzung)

2. **Konvexe Probleme** (nicht *strikt*!) haben manchmal nur eine *Lösungsmenge*, z.B. LASSO, Quantilregression, KQ-Probleme ohne vollen Spaltenrang

3. **Nicht-konvexe Probleme** mit (lokalen Minima und) **Sattelpunkten** $\implies$ verschiedene Initialisierungen/Algorithmen $\rightarrow$ (evtl.) verschiedene Lösungen, zum Beispiel:

- **Neuronale Netze**
- Variablenselektion (L_0 , *Best Subset*, ...)
- **Clusteranalysen** (z.B. *k-means*, Mischverteilungsmodelle) - **Bäume** (CART, Random Forest, XGBoost, ...)
- Embeddings (tSNE, UMAP, [word2vec](#), ...)
- **Matrix-Completion**
- **Latente Variablen** (GLMM, SEM, Faktoranalysen, ...)
- **Hyperparameter-Tuning**: meist nichtmal stetig $\rightarrow$ Gitter-, Zufalls- oder Bayes-Optimierung

Sattelpunkte

Bei **nicht-konvexen** Funktionen: $\nabla f(\mathbf{x}) = \mathbf{0}^\top$ bedeutet nicht unbedingt Minimum!

Definition: Sattelpunkt


Ein *kritischer Punkt* $\mathbf{x}^*$ mit $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ heißt **Sattelpunkt**, wenn $\mathbf{H}_f(\mathbf{x}^*)$ *indefinit* ist (sowohl positive als auch negative Eigenwerte).

Beispiel $f(x, y) = x^2 - y^2$:

- $\nabla f = (2x, -2y) = \mathbf{0}^\top$ bei $(0, 0)^\top$ ✓
- $\mathbf{H}_f = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$: Eigenwerte $2 > 0$, $-2 < 0$
 $\implies$ **indefinit**
- $(0, 0)^\top$ ist Minimum in x -Richtung, Maximum in y -Richtung

Konsequenzen:

- In vielen hochdimensionalen, nicht-konvexen Modellen treten Sattelpunkte auf.
- In hohen Dimensionen sind sie i.A. häufiger als lokale Minima.



Optimalitätsbedingungen: Zusammenfassung

Für $f : \mathbb{R}^n \rightarrow \mathbb{R}$ zweimal stetig differenzierbar:

Notwendige Bedingung (1. Ordnung)

$\mathbf{x}^*$ lokales Minimum $\implies \nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ ($\mathbf{x}^*$ ist *stationärer Punkt*)

Hinreichende Bedingung (2. Ordnung)

$\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ und $\mathbf{H}_f(\mathbf{x}^*) \succ 0 \implies \mathbf{x}^*$ ist lokales Minimum

Klassifikation stationärer Punkte ($\nabla f = \mathbf{0}^\top$):

$\mathbf{H}_f(\mathbf{x}^*)$	Punkt ist...
$\succ 0$ (positiv definit)	Striktes lokales Minimum
$\prec 0$ (negativ definit)	Striktes lokales Maximum
indefinit	Sattelpunkt
semidefinit, aber nicht definit	Unklar, weitere Analyse nötig

⚠ So wichtig:

Für **konvexe Funktionen** ist jedes *lokale* Minimum auch **global** (keine *Sattelpunkte*)!

Iterative Optimierungsverfahren

Taxonomie: Optimierungsverfahren

Klassifikation nach verwendeter **Ableitungsinformation**:

Ordnung	Verwendet	Beispiele
0-te Ordnung	nur $f(x)$	<i>Nelder-Mead</i> , Gittersuche
1-te Ordnung	$f, \nabla f$	<i>Gradient Descent</i> , <i>Momentum GD</i> , <i>SGD</i>
2-te Ordnung	$f, \nabla f, \mathbf{H}_f$	<i>Newton</i> (→ Kapitel <i>Optimierung II</i>)

Trade-off:

- 0-te Ordnung: robust, keine Ableitungen nötig, aber langsam
- Höhere Ordnung → schnellere Konvergenz, aber teurer pro Schritt
- In der Praxis oft: Superlineare Verfahren (z.B. *Quasi-Newton (BFGS)*, → Kapitel *Optimierung II*) als Kompromiss zwischen 1. und 2. Ordnung

Nelder-Mead: Ableitungsfreie Optimierung


0-te Ordnung: Verwendet nur Funktionswerte $f(\mathbf{x})$, keine Ableitungen.

Simplex-Methode

- Arbeitet mit einem *Simplex*: $n + 1$ Punkte in $\mathbb{R}^n$ (Dreieck in 2D, Tetraeder in 3D)
- Iterativ: ersetze schlechtesten Punkt durch besseren

Simplex-Operationen: (*Interaktive Demo*)

1. **Reflection:** Spiegle schlechtesten Punkt am Schwerpunkt der anderen
2. **Expansion:** Gehe weiter in vielversprechende Richtung
3. **Contraction:** Ziehe zusammen wenn Reflection nicht hilft
4. **Shrink:** Verkleinere gesamten Simplex zum besten Punkt hin



Nelder-Mead: Eigenschaften

Wann Nelder-Mead verwenden?

Situation	Geeignet?
Ableitungen nicht verfügbar	✓
Niedrige Dimension ($n \leq 10$)	✓
Nicht-glatte Zielfunktion	✓
Hohe Dimension ($n > 50$)	✗ (zu langsam)
Präzise Konvergenz nötig	✗ (i.A. keine Garantien)

Komplexität:

$O(n)$ Funktionsauswertungen pro Iteration, meist *viele* Iterationen nötig.

Fazit:

Robuste Methode für “schwierige” Probleme ohne Ableitungen, aber langsam. Oft als **Startpunktsuche** vor gradientenbasierten Methoden verwendet.

Gradientenabstieg

Gradientenabstieg: Die Kernidee

Der Gradient zeigt bergauf:

⇒ Der negative Gradient zeigt bergab!

Gradientenabstieg (Gradient Descent / GD)

Die Iterationsvorschrift ist gegeben durch:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)})^\top$$

- $\gamma > 0$: **Schrittweite** (*learning rate*)
- $-\nabla f(\mathbf{x}^{(k)})^\top$: Richtung des steilsten Abstiegs an Stelle $\mathbf{x}^{(k)}$

Intuition: Gehe immer in die Richtung, in der es am steilsten bergab geht.



$-\nabla f(\mathbf{x})^\top$ ist für *jedes* differenzierbare f eine Abstiegsrichtung, solange $\nabla f(\mathbf{x}) \neq \mathbf{0}^\top$ – sie zeigt aber i.A. *nicht direkt* auf das Minimum!

Falls **Konvexität** gilt, ist jeder stationäre Punkt dann bereits *global optimal*.

Bemerkung:

Gradientenabstieg: $f : \mathbb{R} \rightarrow \mathbb{R}$

Gradient Descent für $f(x) = (x - 2)^2 + 1$, $\gamma = 0.6$



k	$x^{(k)}$	$f'(x^{(k)})$
0	4.500	5.000
1	1.500	-1.000
2	2.100	0.200
3	1.980	-0.040
4	2.004	0.008
5	1.999	-0.002

Idee:

Starte bei $x^{(0)}$ und verbessere schrittweise:

$$x^{(k+1)} = x^{(k)} - \gamma f' \left(x^{(k)} \right)$$

Beispiel Gradientenabstieg: Schritt für Schritt

Problem:

Minimiere $f(x) = (x - 2)^2 + 1$ mit Startwert $x^{(0)} = 4.5$, Schrittweite $\gamma = 0.6$

Ableitung:

$$f'(x) = 2x - 4$$

Iterationen:

$$x^{(0)} = 4.5$$

$$x^{(1)} = x^{(0)} - 0.6 \cdot f'(x^{(0)}) = 4.5 - 0.6 \cdot (2 \cdot 4.5 - 4) = 4.5 - 3 = 1.5$$

$$x^{(2)} = x^{(1)} - 0.6 \cdot f'(x^{(1)}) = 1.5 - 0.6 \cdot (2 \cdot 1.5 - 4) = 1.5 + 0.6 = 2.1$$

$$x^{(3)} = 2.1 - 0.6 \cdot (2 \cdot 2.1 - 4) = 1.98$$

$\vdots$

Konvergenz:

$$x^{(k)} \rightarrow 2 \text{ (analytisches Minimum: } f'(x^*) = 0 \implies x^* = 2)$$




Quiz: Gradient Descent

Sei $f(\mathbf{x}) = x_1^2 + x_2^2$ und $\mathbf{x}^{(0)} = (4, 3)^\top$ mit Schrittweite $\gamma = 0.25$.

Frage: Wo liegt $\mathbf{x}^{(1)}$ nach einem GD-Schritt?

1. $(2, 1.5)^\top$
2. $(0, 0)^\top$
3. $(3, 2)^\top$
4. $(8, 6)^\top$

Die Rolle der Schrittweite γ




Dilemma:

γ muss

- klein genug sein für *Konvergenz*,
- aber groß genug für *Effizienz*...

Problem: Zick-Zack bei schlechter Kondition



Bei **hoher Konditionszahl** $\kappa(\mathbf{H}_f)$ oszilliert GD oft stark.

- $\kappa(\mathbf{H}_f)$ ist groß, wenn die Krümmung von f in verschiedenen Richtungen stark unterschiedlich ist (z.B. “Canyons”)
- Wann und wie schnell konvergiert GD also überhaupt? → jetzt
- **Interaktiv ausprobieren:** Shiny-App: Gradient Descent

↔ zurück: „Konvergenzrate & Kondition“

Konvergenz: Lipschitz-stetiger Gradient

Def.: Lipschitz-Stetigkeit

Eine Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ heißt **Lipschitz-stetig** mit Konstante $L > 0$, falls:

$$\|f(\mathbf{x}) - f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\| \quad \forall \mathbf{x}, \mathbf{y}$$

Intuition:

Funktionswerte ändern sich *höchstens* L -mal so schnell wie Funktionsargumente. Je größer L , desto “gezackter” kann f sein $\implies$ kleinere Schrittweiten γ nötig.

- **Lipschitz-stetiger Gradient** ∇f :
 $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$
 $\rightarrow$ Steigung von f ändert sich nicht zu abrupt.
- Äquivalent (für zweimal differenzierbares f):
 $\|\mathbf{H}_f(\mathbf{x})\|_2 \leq L \quad \forall \mathbf{x}$ mit $L = \sup_{\mathbf{x}} \max_i |\lambda_i(\mathbf{H}_f(\mathbf{x}))|$
 $\rightarrow$ Krümmung von f ist beschränkt
- L heißt auch **Lipschitz-Konstante** von f (oder ∇f)

Konvergenzrate bei Konvexität

Konvergenzrate: Gradientenabstieg

Für *konvexes* f mit *Lipschitz-stetigem* Gradient ∇f und *Lipschitz-Konstante* L , das sein Minimum in $\mathbf{x}^*$ annimmt,
gilt für *Schrittweite* $\gamma \leq \frac{1}{L}$ und alle Iterationen $k \geq 1$:

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq \frac{\|\mathbf{x}^{(0)} - \mathbf{x}^*\|^2}{2\gamma k}$$

Interpretation:

Der *Funktionswertabstand* $f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*)$ sinkt mit Rate $O(1/k)$
 $\implies$ es braucht $k \sim 1/\varepsilon$ Schritte, bis er $< \varepsilon$ ist (... relativ langsam!)

Achtung:

Über den Abstand $\|\mathbf{x}^{(k)} - \mathbf{x}^*\|$ sagt diese Schranke *nichts*.

Starke Konvexität: lineare Konvergenzrate

Def.: Starke Konvexität

Eine *zweimal differenzierbare* Funktion f heißt **stark konvex** (μ -strongly convex) mit Parameter $\mu > 0$, falls:

$$\mathbf{H}_f(\mathbf{x}) - \mu \mathbf{I} \succeq 0 \quad \forall \mathbf{x}$$

(ableitungsfrei äquivalent: $f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}\|^2$ ist konvex)

- $\mu = \inf_{\mathbf{x}} \lambda_{\min}(\mathbf{H}_f(\mathbf{x}))$: minimale (positive!) Krümmung von f

Konvergenzrate: Stark konvexer Gradientenabstieg

Für *stark konvexes* f mit Parameter $\mu > 0$ und *Lipschitz-stetigem* Gradienten mit *Lipschitz-Konstante* L gilt für $\gamma = \frac{1}{L}$:

$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq \rho^k \cdot \left(f(\mathbf{x}^{(0)}) - f(\mathbf{x}^*) \right), \quad \rho = 1 - \frac{\mu}{L} < 1$$

$\implies$ schnellere Konvergenz bei starker Konvexität

Konvergenzrate & Kondition

Verallgemeinerte **Kondition** für Funktionen:

- $\rho = \frac{\kappa_f - 1}{\kappa_f}$ mit Konditionszahl $\kappa_f = \frac{\sup_{\mathbf{x}} \lambda_{\max}(\mathbf{H}_f(\mathbf{x}))}{\inf_{\mathbf{x}} \lambda_{\min}(\mathbf{H}_f(\mathbf{x}))} = \frac{L}{\mu}$
- Großes $\kappa_f \implies \rho \rightarrow 1 \implies$ langsame Konvergenz:
Zick-Zack-Trajektorien durch “Canyons” mit anisotropischer Krümmung
($\rightarrow$ genau das vorhin gesehene **Zick-Zack-Problem!**)
- Für quadratische Funktionen $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x}$ mit $\mathbf{A} \succ 0$ ist $\mathbf{H}_f = \mathbf{A}$,
also $\kappa_f = \kappa(\mathbf{A})$
 $\rightarrow$ selbe **Konditionszahl** wie in der numerischen linearen Algebra!

Abbruchkriterien (Stopping Criteria)

Wann beenden wir die Iteration $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \gamma \nabla f(\mathbf{x}^{(k)})^\top$?

Typische Abbruchkriterien

1. *Gradient klein:* $\|\nabla f(\mathbf{x}^{(k)})\| < \varepsilon_{\text{grad}}$
2. *Funktionswert stagniert:* $\frac{|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})|}{|f(\mathbf{x}^{(k)})|} < \varepsilon_f$
3. *Iterationen ausgeschöpft:* $k > k_{\text{max}}$

- Üblicherweise kombiniert man mehrere Kriterien
- Typische Werte: $\varepsilon_{\text{grad}} \approx 10^{-6}$ bis 10^{-8} , $k_{\text{max}} \approx 1000$ bis 10000

Achtung:

Kriterien können bei nicht stark konvexen oder schlecht konditionierten Problemen versagen — $\|\nabla f\|$ oder $|f^{(k+1)} - f^{(k)}|$ kann beliebig klein werden, obwohl $\mathbf{x}^{(k)}$ noch weit vom Optimum entfernt ist!

Line Search: Adaptive Schrittweite

Problem:

Eine feste Schrittweite γ ist oft suboptimal.

Idee:

Wähle $\gamma^{(k)}$ in jedem Schritt so, dass f “genug” sinkt.

Backtracking Line Search (Armijo)

Gegeben: Richtung $\mathbf{d} = -\nabla f(\mathbf{x}^{(k)})^\top$, Parameter $c \in (0, 1)$, $\rho \in (0, 1)$

1. Starte mit $\gamma = 1$
2. **while** $f(\mathbf{x}^{(k)} + \gamma \mathbf{d}) > f(\mathbf{x}^{(k)}) + c\gamma \nabla f(\mathbf{x}^{(k)}) \mathbf{d}$:
 - $\gamma \leftarrow \rho\gamma$ (verkleinere Schrittweite)
3. **return** γ

Armijo-Bedingung:

Fordert “genügend Abstieg” — Funktionswert muss proportional zum erwarteten Abstieg sinken.


Achtung:

ρ ist hier der *Verkleinerungsfaktor* der Schrittweite — nicht die Konvergenzrate $\rho = 1 - \mu/L$ von vorhin.

Line Search: Visualisierung

Armijo Line Search: zulässige Schrittweiten

Illustration mit $c = 0.3$, $\rho = 0.5$



Typische Parameter: $c = 10^{-4}$, $\rho = 0.5$

Quasi-Newton: *BFGS* verwendet automatisch *Line Search* ($\rightarrow$ Kapitel *Optimierung II*)

Zusammenfassung

Self-Check: Gradientenabstieg

1. Sei $f(\mathbf{x}) = x_1^2 + 4x_2^2$ und $\mathbf{x}^{(0)} = (2, 1)^\top$ mit Schrittweite $\gamma = 0.25$. Wo liegt $\mathbf{x}^{(1)}$?

1. $(1, -1)^\top$

2. $(1.5, 0)^\top$

3. $(1, 0)^\top$

4. $(0, 0)^\top$

2. Welche Aussagen sind wahr?

1. GD konvergiert für jede Schrittweite $\gamma > 0$ gegen ein lokales Minimum.

2. Für konvexes f mit L -Lipschitz-Gradient und $\gamma \leq 1/L$ gilt: Fehler $= O(1/k)$.

3. Für stark konvexes f konvergiert GD linear, d.h. Fehler $= O(\rho^k)$ mit $\rho < 1$.

4. Ist $\|\nabla f(\mathbf{x}^{(k)})\|$ klein, dann ist $\mathbf{x}^{(k)}$ nahe am Minimum.

Zusammenfassung

Methode	Wann verwenden?
Bisektion	univariate Nullstellen; braucht nur Stetigkeit + Vorzeichenwechsel
Newton-Raphson	Nullstellen glatter Funktionen; quadratische Konvergenz
Nelder-Mead	Optimierung ohne Ableitungen, niedrige Dimension ($n \leq 10$)
Gradient Descent	Optimierung großer differenzierbarer Probleme; einfache Implementierung

- **Konvexität** $\implies$ jedes lokale Minimum ist global;
strikte Konvexität $\implies$ *höchstens ein* Minimum (also eindeutig, falls existent)
 - **Konvergenz von GD:**
 - Rate $O(1/k)$ (konvex) bzw. $O(\rho^k)$ (stark konvex)
 - $\rho = 1 - \frac{\mu}{L}$ bei $\gamma = \frac{1}{L}$
 - alternativ Schrittweite adaptiv mit *Line Search*

Im Kapitel Optimierung II:

Newton-Verfahren (“Newton-Raphson für $\nabla f = \mathbf{0}^\top$ ”), Quasi-Newton (BFGS), Momentum & SGD, Optimierung unter Nebenbedingungen (Lagrange/KKT)

Anhang

Fixpunktiteration erster Ordnung

(in der Vorlesung nur als Bemerkung: GD ist die Fixpunktiteration für $\nabla f(\mathbf{x})^\top = \mathbf{0}$)

Ziel: Löse $f(\mathbf{x}) = \mathbf{0}$, $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ monoton steigend (d.h. $(f(\mathbf{x}) - f(\mathbf{y}))^\top (\mathbf{x} - \mathbf{y}) \geq 0 \forall \mathbf{x}, \mathbf{y}$).

- Wir definieren die Iteration

$$\mathbf{x}^{(k)} = \mathbf{x}^{(k-1)} - \gamma f(\mathbf{x}^{(k-1)}).$$

- Ist f differenzierbar, erhalten wir aus einer Taylorapproximation 1. Ordnung um $\mathbf{x}^*$:

$$\begin{aligned} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| &\approx \left\| \mathbf{x}^{(k-1)} - \mathbf{x}^* - \underbrace{\gamma f(\mathbf{x}^*)}_{=\mathbf{0}} - \gamma \mathbf{J}_f(\mathbf{x}^*) (\mathbf{x}^{(k-1)} - \mathbf{x}^*) \right\| \\ &= \left\| (\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)) (\mathbf{x}^{(k-1)} - \mathbf{x}^*) \right\| \\ &\leq \|\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)\| \|\mathbf{x}^{(k-1)} - \mathbf{x}^*\|. \end{aligned}$$

- Falls $\rho := \|\mathbf{I}_n - \gamma \mathbf{J}_f(\mathbf{x}^*)\| < 1$, gilt *lokal* (für Startwerte nahe genug an $\mathbf{x}^*$)

$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\| = O(\rho^k)$$

- Exakt mit diesem ρ und *global* gilt das nur für affines f – dort verschwindet der oben weggelassene Restterm.

Fixpunktiteration erster Ordnung

Vorteile:

- Simple Verfahren auch für multivariate Funktionen
- Schnelle Konvergenz für gutartige Funktionen

Nachteile:

- Schrittweite γ muss gut gewählt sein:
 - zu klein: langsame Konvergenz
 - zu groß: gar keine Konvergenz

In der Praxis:

- Folge $\gamma_k \rightarrow 0$.
- Falls f fallend, betrachte $-f$.

Beweis: Globale Optimalität bei Konvexität

Proposition

Für jede differenzierbare, konvexe Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}$ sind äquivalent: (i) $\mathbf{x}^*$ ist ein globales Minimum von f . (ii) $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$.

Beweis.

- $(i) \implies (ii)$: Jedes globale Minimum ist ein lokales Minimum. Dort muss $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$ gelten. ■
- $(ii) \implies (i)$: Sei $\mathbf{x}^*$ ein Punkt mit $\nabla f(\mathbf{x}^*) = \mathbf{0}^\top$. Dann gilt für alle $\mathbf{y} \in \mathbb{R}^n$

$$f(\mathbf{y}) \geq f(\mathbf{x}^*) + \nabla f(\mathbf{x}^*)(\mathbf{y} - \mathbf{x}^*) = f(\mathbf{x}^*).$$

Also ist $\mathbf{x}^*$ ein globales Minimum. ■

↩ zurück: „Konvexe Funktionen in der Optimierung“