

Funktionsapproximation: Krümmung, Approximation, Glättung

Fortgeschrittene mathematische Methoden in der Statistik

Vorlesung: Fabian Scheipl (fabian.scheipl@lmu.de)

Material: Thomas Nagler

LMU München

Verwendete Vorkenntnisse

- **Lineare Algebra:**

- *Kleinste Quadrate* und *Pseudoinverse*

- **Analysis:**

- $\mathcal{C}^k$ -Funktionen (insb. $\mathcal{C}^2$ und $\mathcal{C}^4$): k -mal stetig differenzierbar
- Integration $(\int |f''(x)|^2 dx)$

- **Funktionsapproximation I:**

- *Basen von Funktionenräumen*: $\hat{f}(x) = \sum_k a_k \phi_k(x)$ mit *Basisfunktionen* ϕ_k und *Basiskoeffizienten* a_k
- *(B-)Splines*
- *Interpolation* vs. *Glättung*

- **Statistik:**

- Designmatrix eines Linearen Modells
- Bias-Varianz-Zerlegung und MSE
- Kreuzvalidierung, Informationskriterien (AIC, BIC)

Opener-Quiz: Was wissen Sie noch?

Frage 1:

Was bedeutet $f \in \mathcal{C}^4[a, b]$?

1. f ist auf $[a, b]$ viermal differenzierbar.
2. f ist auf $[a, b]$ viermal *stetig* differenzierbar.
3. f ist stetig und durch 4 beschränkt.
4. f ist ein Polynom vom Grad höchstens 4.

Frage 2:




Sei $\mathbf{B} \in \mathbb{R}^{n \times K}$ mit vollem Spaltenrang ($K < n$). Die KQ-Lösung von $\min_{\mathbf{a}} \|\mathbf{y} - \mathbf{B}\mathbf{a}\|_2^2$ ist ...

1. $\hat{\mathbf{a}} = \mathbf{B}^{-1}\mathbf{y}$
2. $\hat{\mathbf{a}} = \mathbf{B}^\top \mathbf{y}$
3. $\hat{\mathbf{a}} = \mathbf{B}^+ \mathbf{y} = (\mathbf{B}^\top \mathbf{B})^{-1} \mathbf{B}^\top \mathbf{y}$
4. $\hat{\mathbf{a}} = (\mathbf{B}\mathbf{B}^\top)^{-1} \mathbf{B}\mathbf{y}$

Nützliche Theorie zu Splines

Splines

Erinnerung: Ein **Spline** vom Grad q ist eine Funktion, die Polynome an den Punkten $\xi_1, \dots, \xi_{m-1}$ **glatt** zusammensetzt: dort stimmen alle Ableitungen bis zur Ordnung $q - 1$ überein, d.h. $s \in \mathcal{C}^{q-1}$.



- Splines von Grad ℓ zu festen Knoten bilden einen **Funktionenraum**
- **B-Splines** sind eine besonders gutartige **Basis** dieses Raums.

Minimale Krümmung

Kubische Splines erzeugen besonders einfache “glatte” Kurven.

Das ist kein Zufall:

Man kann sie herleiten, indem man Interpolanden mit *minimaler Krümmung* sucht (diese Eigenschaft hat auf englisch auch den schönen Namen *minimal wiggleness*).

Theorem: Kubische Splines haben minimale Krümmung

Seien $(x_1, y_1), \dots, (x_n, y_n) \in [a, b] \times \mathbb{R}$ mit $a = x_1 < x_2 < \dots < x_n = b$ und s ein *natürlicher kubischer Spline*, der diese Punkte interpoliert (d.h. mit $s''(a) = s''(b) = 0$).

Sei $g \in \mathcal{C}^2[a, b]$ eine weitere Funktion mit $g(x_i) = y_i \quad \forall i$.

Dann gilt:

$$\int_a^b |s''(x)|^2 dx \leq \int_a^b |g''(x)|^2 dx.$$

“Krümmung” meint hier $\int_a^b |f''(x)|^2 dx$, nicht das Integral der geometrischen Krümmung $\kappa = |f''| / (1 + (f')^2)^{3/2}$ – beide fallen nur für flache Kurven mit $|f'| \ll 1$ zusammen. Der Name ist trotzdem eingebürgert.

Minimale Krümmung: Beweis

Sei s der natürliche kubische Spline-Interpolant zu (x_i, y_i) .

Für einen anderen Interpolanten $g \in \mathcal{C}^2$ setze $g = s + h$ mit $h(x_i) = 0 \forall i$.

Sei $J(g) := \int_a^b (g''(x))^2 dx$. Dann gilt

$$J(g) = J(s) + 2 \int_a^b s''(x)h''(x)dx + \int_a^b (h''(x))^2 dx.$$

Auf jedem Intervall $[x_{i-1}, x_i]$, $i = 2, \dots, n$, gilt durch partielle Integration

$$\int s''h''dx = \left[s''h' - s^{(3)}h \right]_{x_{i-1}}^{x_i} + \int s^{(4)}h dx.$$

- für kubische Splines ist $s^{(4)} = 0$
- $\sum_{i=2}^n \left[s''h' - s^{(3)}h \right]_{x_{i-1}}^{x_i} = \left[s''h' \right]_a^b = 0$, weil
 - $\left[s^{(3)}h \right]_{x_{i-1}}^{x_i} = 0$ wegen $h(x_i) = 0$,
 - sich die inneren $s''h'$ -Randterme paarweise aufheben (s'' und h' sind an den inneren Knoten stetig,
 - und $s''(a) = s''(b) = 0$ (natürlicher Spline).

$$\implies J(g) = J(s) + \int_a^b (h''(x))^2 dx \geq J(s) \implies \text{Gleichheit nur für } h \equiv 0. \quad \blacksquare$$

Letzter Schritt:

Gleichheit heißt $\int_a^b (h'')^2 dx = 0$, also $h'' \equiv 0$ (h'' ist stetig), also h affin;

da h an den $n \geq 2$ Stellen x_i verschwindet, folgt $h \equiv 0 \implies$ Der Spline s ist der **einzige** Minimierer.

Minimale Krümmung: Beispiel

Gegeben:

Punkte $(0, 0)$, $(1, 1)$, $(2, 0)$


Natürlicher kubischer Spline:

$$s(x) = \begin{cases} \frac{3}{2}x - \frac{1}{2}x^3 & x < 1 \\ \frac{3}{2}(2-x) - \frac{1}{2}(2-x)^3 & x \geq 1 \end{cases}$$

$$s''(x) = -3x \text{ bzw. } s''(x) = -3(2-x) \\ \implies s''(0) = s''(2) = 0 \checkmark$$

Vergleich mit Parabel:

$$p(x) = -x^2 + 2x$$



Interpolant $\int_0^2 |f''(x)|^2 dx$

Spline s	6
------------	---

Parabel p	8
-------------	---

$\implies$ Spline hat kleinere Krümmung!

Approximationseigenschaft

- Bereits erwähnt: Wenn die *Gitterweite* (der größte Abstand zweier benachbarter Knoten) hinreichend klein ist, kann jede stetige Funktion f beliebig genau approximiert werden. Genauer:

Theorem: Approximationsfehler kubischer Splines

Sei $a = x_0 < x_1 < \dots < x_n = b$ eine Partition mit **Gitterweite** $h := \max_i |x_i - x_{i-1}|$. Für jedes $f \in \mathcal{C}^4[a, b]$ sei s der eindeutig bestimmte *eingespannte kubische Spline-Interpolant* mit

$$f(x_i) = s(x_i) \quad \forall i, \quad s'(a) = f'(a), \quad s'(b) = f'(b).$$

Dann gilt

$$\max_{x \in [a, b]} |f(x) - s(x)| \leq \frac{5}{384} h^4 \max_{x \in [a, b]} |f^{(4)}(x)|.$$


Erkenntnisse:

Approximation: Lokaler Fehler


Gegeben:

$f(x) = \exp\left(-40\left(x - \frac{2}{5}\right)^2\right)$ auf $[0, 1]$ mit $\max |f^{(4)}(x)| = 19200$ (am schmalen Peak $x = \frac{2}{5}$, der kein Knoten ist)

Spline-Interpolanten



Lokale Fehler (log(1+)-Skala)



— $f(x)$ — $n+1 = 5$ — $n+1 = 7$ — $n+1 = 9$ — $n+1 = 17$ $|f^{(4)}|$ (skaliert)

Beobachtung:

Mit nur fünf Knoten ist die Abweichung deutlich sichtbar. Sie konzentriert sich um den schmalen Peak, wo $|f^{(4)}|$ groß ist; an den Knoten selbst ist der Interpolationsfehler natürlich null.

Approximation: h^4 -Rate

Knoten $n + 1$	Gitterweite h	Fehlerschranke $\frac{5}{384} h^4 \max_x f^{(4)}(x) $	Tatsächlicher Fehler $\max_x f(x) - s(x) $
5	0.25	≈ 0.977	≈ 0.324
7	0.1667	≈ 0.193	≈ 0.1048
9	0.125	≈ 0.061	≈ 0.0239
17	0.0625	≈ 0.0038	≈ 0.00111

Beobachtung:

- Halbierung von h verkleinert die *Schranke* exakt um $2^4 = 16$.
- Der tatsächliche Fehler muss bei groben Gittern nicht exakt diesem Faktor folgen (hier: ≈ 14 und ≈ 22): $O(h^4)$ beschreibt die *asymptotische* Rate.


Berechnet für den **eingespannten** Spline-Interpolanten aus dem Theorem, also mit $s'(0) = f'(0)$ und $s'(1) = f'(1)$.

Approximation: Zusammenfassung

- (B-)Splines sind extrem mächtige Werkzeuge in der *Funktionsapproximation*.
- Sie haben hervorragende theoretische und praktische Eigenschaften:
 - Effiziente Berechnung (B-Splines)
 - Stabilität/Lokalität (B-Splines)
 - Minimale Krümmung des natürlichen kubischen Spline-Interpolanten
 - Approximationsfehler $O(h^4)$ für kubische Splines

Glättungs-/Regressionsprobleme

Das Problem



Modell:

$$y_i = f(x_i) + \epsilon_i, \quad \epsilon_i \text{ i.i.d.} \quad \text{mit } \mathbb{E}[\epsilon_i | x_i] = 0.$$

Problem:

Finde eine Funktion $\hat{f}$ mit kleinem Fehler

$$\sum_{i=1}^n \left(y_i - \hat{f}(x_i) \right)^2.$$

Über **alle** Funktionen ist dieses Minimum 0 und wird von jedem Interpolanten angenommen (davon gibt es unendlich viele; siehe Kapitel Funktionsapproximation I) $\rightarrow$ entartetes Problem.

Wir brauchen eine Einschränkung des Suchraums!

Die Lösung

1. Nehme an, dass $\hat{f} \in \mathcal{F}_K$, d.h. $\hat{f}(x) = \sum_{k=1}^K a_k \phi_k(x)$ für

- **Basisfunktionen** $\phi_1, \dots, \phi_K$ (bekannt; z.B. **B-Spline-Basis**)
- **Basiskoeffizienten** $a_1, \dots, a_K$ (unbekannt)

2. Löse das KQ-Problem

$$\min_{\hat{f} \in \mathcal{F}_K} \sum_{i=1}^n \left(y_i - \hat{f}(x_i) \right)^2 = \min_{\mathbf{a}} \left\| \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} - \begin{pmatrix} \phi_1(x_1) & \cdots & \phi_K(x_1) \\ \vdots & \ddots & \vdots \\ \phi_1(x_n) & \cdots & \phi_K(x_n) \end{pmatrix} \begin{pmatrix} a_1 \\ \vdots \\ a_K \end{pmatrix} \right\|_2^2.$$

Unterschied zu Interpolation:

- **Interpolation**: $K = n$
- **Glättung**: $K < n$

Warum Glättung statt Interpolation?

Interpolation ($K = n$):

- Passt **alle** Datenpunkte exakt an:

$$\hat{f}(x_i) = y_i \quad \forall i,$$

sofern $\mathbf{B}$ invertierbar ist (mit ungünstig platzierten Knoten kann $\mathbf{B}$ auch für $K = n$ singulär sein)

- **Problem:**

$\hat{f}$ modelliert auch das Rauschen ε_i !

Glättung ($K < n$):


- Akzeptiert, dass $\hat{f}(x_i) \neq y_i$
- Erzielt eine **glattere, generalisierbarere** Funktion
- *Alternative:*
 - **Smoothing Splines** mit $K = n + \text{Glattheits-Penalty } \lambda \int |f''|^2$
(auch: **Penalized Splines** mit $K < n + \text{Glattheits-Penalty} \rightarrow \text{Additive Modelle}$)

Wann welche Methode?

Situation	Methode
Präzise, rauschfreie Daten	Interpolation
Verrauschte Messungen	Glättung
Vorhersage für neue Daten	Glättung

Beispiel

```
1 set.seed(42)
2 n <- 50
3 x <- sort(runif(n, 0, 2 * pi))
4 f_true <- function(x) sin(x) + 0.5 * sin(2 * x)
5 y <- f_true(x) + rnorm(n, sd = 0.3)
6
7 # Designmatrix: B-Spline-Basis, K = 10
8 B <- splines::bs(x, df = 10, intercept = TRUE,
9   Boundary.knots = c(0, 2 * pi))
10 a_hat <- qr.solve(B, y) # KQ via QR
11 #! äquivalent:
12 #! Q * R * a = y --> R * a = Q^T * y --> a = R^-1 * Q^T * y
13 #! qrB <- qr(B)
14 #! a_hat <- backsolve(qr.R(qrB), t(qr.Q(qrB)) %*% y)
15
16 # Auswertung auf neuen Punkten
17 x_new <- seq(0, 2 * pi, length = 200)
18 B_new <- splines::bs(x_new,
19   knots = attr(B, "knots"),
20   Boundary.knots = attr(B, "Boundary.knots"),
21   intercept = TRUE)
22 f_hat <- B_new %*% a_hat
```



Bias-Varianz Trade-off: Bias

Annahme: gleichmäßige Knoten auf $[a, b]$, $f \in \mathcal{C}^4$, kubische Splines

- Für Spline mit K Basisfunktionen:

$$h = \max_i |\xi_i - \xi_{i-1}| = O(1/K).$$

- Wäre $\epsilon_i = 0$, hätten wir

$$\max_{x \in [a, b]} |f(x) - \hat{f}(x)| = O(h^4) = O(K^{-4}).$$

- Der Approximationsfehler wird im statistischen Kontext auch **Bias** genannt.
- Für **kleinen Bias** müssen wir also K **möglichst groß** wählen.

Bias-Varianz Trade-off: Varianz

Annahme: $\mathbb{E}\text{Var}[\epsilon_i] = \sigma^2 \forall i$ (homoskedastisch)*

- Da $\boldsymbol{\epsilon} = (\epsilon_1, \dots, \epsilon_n)^\top$ zufällig ist, ist auch

$$\hat{\mathbf{a}} = \mathbf{B}^+ \mathbf{y} = \mathbf{B}^+ \mathbf{f} + \mathbf{B}^+ \boldsymbol{\epsilon}$$

zufällig.

$\mathbf{B}^+$ ist **Pseudoinverse** der Designmatrix $\mathbf{B} = [\phi_k(x_i)] \in \mathbb{R}^{n \times K}$ des KQ-Problems für $\mathbf{f} = (f(x_1), \dots, f(x_n))^\top$.

- Man kann zeigen, dass

$$\text{Var} [\hat{f}(x)] = \text{Var} \left[\sum_{k=1}^K \hat{a}_k \phi_k(x) \right] = O(K/n).$$

- Für **kleine Varianz** wollen wir also K **möglichst klein** wählen.

Exakt ist das im Mittel über die Designpunkte: $\frac{1}{n} \sum_{i=1}^n \text{Var} [\hat{f}(x_i)] = \sigma^2 K/n$ (Spur der Hatmatrix = K , falls $\mathbf{B}$ vollen Spaltenrang hat); punktwise braucht die Rate Zusatzannahmen an Knoten und Design.


Vorhersage: Wenn K wächst — steigt Bias oder Varianz?

Think–Pair–Share (2 Minuten, mit Sitznachbar:in):

- Wenn K wächst: Was passiert mit dem **Bias**? Was mit der **Varianz**?
- Skizzieren Sie **Bias², Varianz und $MSE = \text{Bias}^2 + \text{Varianz}$** als Funktionen von K (auf Papier!).
- Wo liegt das optimale K — eher klein, eher groß, oder dazwischen? Woran erkennt man es in Ihrer Skizze?

→ Auflösung im folgenden Abschnitt zum Bias-Varianz-Trade-off.

Bias-Varianz Trade-off



- **Auflösung:**

Bias² fällt in K , Varianz steigt in K – der MSE setzt sich aus beiden zusammen:

$$\mathbb{E} \left[\left(\hat{f}(x) - f(x) \right)^2 \right] = \left(\mathbb{E} \left[\hat{f}(x) \right] - f(x) \right)^2 + \text{Var} \left[\hat{f}(x) \right] = O(K^{-8} + K/n).$$

- Das optimale K liegt *dazwischen*: am Minimum der MSE-Kurve, wo sich fallender Bias und steigende Varianz gerade ausbalancieren.

Die (theoretisch) optimale Wahl von K

$$\mathbb{E} \left[\left(\hat{f}(x) - f(x) \right)^2 \right] = O(K^{-8} + K/n)$$

- Die (theoretisch!) optimale Wahl $K \sim n^{1/9}$ balanciert beide Teile aus und es gilt dann:

$$\mathbb{E} \left[\left(\hat{f}(x) - f(x) \right)^2 \right] = O(n^{-8/9}).$$

- *Rein asymptotische Ordnung* — taugliches K in der Praxis deutlich größer, da Konstanten bei moderatem n dominieren.

Bias-Varianz: Beispiel

Setup:

$$f(x) = \sin(3x), n = 100, \sigma = 0.3$$



Modell	K	Bias ²	Var	MSE
Unteranpassung	5	0.416	0.005	0.421
Nahezu optimal	15	0.000	0.014	0.014
Überanpassung	40	0.000	0.036	0.036

(Bias² und Varianz exakt berechnet für den KQ-Fit, gemittelt über äquidistante Designpunkte;
 $\text{Var} = \sigma^2 K/n$)

Interpretation:

- $K = 5$: Spline zu starr $\implies$ hoher Bias
- $K = 40$: Spline passt Rauschen an $\implies$ hohe Varianz
- $K = 15$: Balanciert Bias und Varianz

Über $K \in 4, \dots, 60$



Wie wählt man K in der Praxis?

Problem:

Wir kennen f nicht, also wissen wir nicht, ob K optimal ist!

Mögliche Ansätze:

1. **Kreuzvalidierung**: Wähle K , das den Validierungsfehler minimiert
2. **Informationskriterien**: AIC und BIC balancieren Anpassung und Komplexität
3. **GCV**:
$$\text{GCV}(K) = \frac{\text{RSS}_K/n}{(1-K/n)^2}$$

Praktisch verwendeter Ansatz:

- wähle K “groß genug”
- steuere Glattheit der Funktionsschätzung über **Penalisierung**.
→ **P-Splines**, **Additive Modelle**
In R z.B. `mgcv : gam()`

Multivariate Funktionsapproximation

Multivariate Funktionsapproximation

- Zur Approximation von multivariaten $f: \mathbb{R}^p \rightarrow \mathbb{R}$ kann man eine **Tensor-Produkt-Basis** bilden (vgl. Tensorproduktbasen im Kapitel *Tensoren*):

$$\hat{f}(\mathbf{x}) = \sum_{j_1=1}^K \cdots \sum_{j_p=1}^K a_{j_1, \dots, j_p} (\phi_{j_1}(x_1) \times \cdots \times \phi_{j_p}(x_p))$$

mit Koeffizienten

$$\mathbf{A} = (a_{j_1, \dots, j_p})_{j_i=1, \dots, K, i=1, \dots, p} \in \mathbb{R}^{K \times \cdots \times K}.$$

- $\mathbf{A}$ kann wieder durch Lösung eines gewöhnlichen KQ-Problems gefunden werden.
- Aber: **Fluch der Dimensionalität**
 - $\hat{f}$ auswerten kostet $O(K^p)$ (mit B-Splines wegen der lokalen Träger nur $(q+1)^p$ Summanden – ebenfalls exponentiell in p).
 - $\text{MSE}(\hat{f}) = O(K^{-8} + K^p/n)$; mit “optimalem” $K \sim n^{1/(8+p)}$: $\text{MSE} = O(n^{-8/(8+p)})$
 $\implies$ sehr langsam für großes p .

Fluch der Dimensionalität

Szenario: $f: \mathbb{R}^p \rightarrow \mathbb{R}$ mit $K = 10$ Basisfunktionen pro Dimension

Speicher:

Dim. p	Koeffizienten K^p	Speicher
1	10	80 Bytes
2	100	800 Bytes
3	1 000	8 kB
5	100 000	800 kB
10	10^{10}	80 GB

Dezimale Präfixe: 1 kB = 10^3 Bytes, 1 GB = 10^9 Bytes.

⇒ Speicherbedarf und Datenbedarf wachsen **exponentiell** mit p !

Konvergenz (optimales $K \sim n^{1/(8+p)}$):

Dim. p	Konvergenzrate	n für $MSE \leq 0.01$
1	$n^{-8/9}$	≈ 180
2	$n^{-0.8}$	≈ 320
5	$n^{-8/13}$	$\approx 1\,800$
10	$n^{-8/18}$	$\approx$ 32 000

illustrative Werte – entscheidende Konstanten sind problemabhängig

GAMs: Lösung für multivariate Probleme

Problem:

Tensor-Produkt mit K^p Parametern für $p > 3$ unpraktikabel

Lösungsansatz:

Benutze *additive* Struktur statt vollem Tensor-Produkt:

Statt

$$\hat{f}(\mathbf{x}) = \sum_{j_1=1}^K \cdots \sum_{j_p=1}^K a_{j_1, \dots, j_p} \prod_{i=1}^p \phi_{j_i}(x_i) \quad (K^p \text{ Koeffizienten})$$

verwende **Generalisiertes Additives Modell (GAM)**:

$$\hat{f}(\mathbf{x}) = \beta_0 + \sum_{i=1}^p f_i(x_i) \quad (pK + 1 \text{ Koeffizienten})$$

Genauer:

$pK + 1$ Koeffizienten, wegen Identifizierbarkeit (f_i sind nur bis auf additive Konstanten bestimmt) nur $p(K - 1) + 1$ frei wählbar – Größenordnung $O(pK)$.

Aber:

rein additiv – *Interaktionseffekte* (z.B. $f(x_1, x_2) = x_1 \cdot x_2$) werden nicht erfasst; dafür: zusätzliche niedrigdimensionale Tensorprodukt-Terme.

Vorteile:

- *Skalierbar*: $O(pK)$ statt $O(K^p)$ Parameter
- *Interpretierbar*: Effekt jeder Variable einzeln visualisierbar
- **In R**: `mgcv::gam()` mit automatischer Glättungsparameterwahl

Self-Check & Zusammenfassung

Ausblick

Mehr zu

- theoretischer Analyse von statistischen Methoden
- Eigenschaften von Parameterschätzung
- Funktionsapproximation

in Thomas Naglers Vorlesungen:

- *Statistical Learning Theory* (MSc)
- *Mathematical Statistics* (BSc/MSc)

Mehr zu GAMs & co in *Statistik V: Konzepte Statistischer Modellierung* (BSc)

Self-Check

Frage 1: Unter allen Interpolanten $g \in \mathcal{C}^2[a, b]$ der Punkte $(x_i, y_i) \dots$

1. minimiert der natürliche kubische Spline $\int_a^b |g''(x)|^2 dx$.
2. ist der natürliche kubische Spline der *einzige* Interpolant, der $\sum_i (g(x_i) - y_i)^2$ minimiert.
3. hat jeder kubische Spline kleinere Krümmung als jedes Polynom.
4. minimiert die Parabel die Krümmung.

Frage 2: Wir verdoppeln die Anzahl der Basisfunktionen K (bei festem n). Dann gilt (asymptotisch):

1. Bias sinkt, Varianz steigt.
2. Bias steigt, Varianz sinkt.
3. Bias und Varianz sinken beide.
4. Bias und Varianz steigen beide.

Frage 3: Was bedeutet die “optimale Wahl” $K \sim n^{1/9}$?

1. In der Praxis ist $K = \lceil n^{1/9} \rceil$ immer die beste Wahl.
2. Rein asymptotische Ordnung — praktisch wählt man K deutlich größer, da die Konstanten dominieren.
3. K muss linear mit n wachsen.
4. Der MSE fällt dann mit Rate $n^{-1/9}$.

Wrap-up

Heute gelernt

- Eigenschaften kubischer Splines (*Minimale Krümmung* des natürlichen Spline-Interpolanten, Approximationsfehler $O(h^4)$)
- *Bias-Varianz Trade-off* bei der Glättung: $\text{MSE} = O(K^{-8} + K/n)$
- Praktische Modellwahl mit CV, AIC, GCV — oder K groß + Penalisierung
- *Fluch der Dimensionalität* und GAMs als Lösung

Finito!